Generative KI als Hilfe zum Lehren und Lernen

Roman Bartnik

November 2026

Roman Bartnik
Generative KI als Hilfe zum Lehren und Lernen

Technische Hochschule Köln
Fakultät für Informatik und Ingenieurwissenschaften, Campus Gummersbach

Bibliografische Information der Deutschen Nationalbibliothek: Die Deutsche Nationalbibliothek verzeichnet diese Publikation in der Deutschen Nationalbibliografie; detaillierte bibliografische Daten sind im Internet über https://dnb.de abrufbar.

Dieses Werk ist lizenziert unter einer Creative-Commons-Lizenz Namensnennung – Weitergabe unter gleichen Bedingungen 4.0 International (CC BY-SA 4.0): https://creativecommons.org/licenses/by-sa/4.0/deed.de. Ausgenommen sind Abbildungen und Zitate, die mit einem abweichenden Rechtehinweis gekennzeichnet sind.

Gefördert aus dem Open-Access-Publikationsfonds der TH Köln.
[Logo des Publikationsfonds]

Logos Verlag Berlin GmbH
[Anschrift des Verlags]
https://www.logos-verlag.de

Erste Auflage, [Monat] 2026
ISBN [978-3-xxxxx-xxx-x]
DOI [10.30819/xxxx]

Online-Version mit interaktiven Elementen und laufend aktualisierten Seiten:
https://th-koln-bartnik.github.io/genai4teaching/

Satz: Roman Bartnik mit Quarto und XeLaTeX
Umschlag: [Gestaltung, verwendete Abbildung und Bildnachweis]
Druck: [Druckerei]

Zitiervorschlag: Bartnik, R. (2026). *Generative KI als Hilfe zum Lehren und Lernen*. Logos Verlag Berlin. [DOI]

Inhalt

Abbildungsverzeichnis vii

Tabellenverzeichnis xvii

Vorwort 1
Neue Möglichkeiten durch KI – Interaktionen und vieles mehr . . 1
Wählen Sie Ihren Lernpfad 2
Wie dieses Buch lehrt 4
Übersicht 7
Literaturverzeichnis 8

I Teil I: Grundlagen 11

1 Einleitung 13
1.1 Wie verbreitet ist KI-Nutzung? 15
1.2 Was geht schief? 19
1.3 Was hilft? 21
1.4 Was Sie im Buch erwartet 22
Literaturverzeichnis 27

2 Grundlagen von KI und LLMs 31
2.1 Grundbegriffe: Modell, Harness und Agent 33
2.2 Welches Modell? 40
2.3 Description: Wie sage ich der KI, was ich will? 47
2.4 Das erweiterte LLM 55
2.5 Ressourcenverbrauch der Modelle 63
2.6 Vertiefung: Was im Modell und im Harness passiert 64
Literaturverzeichnis 73

3 Prinzipien der Automation von Aufgaben 81
3.1 Was sind unsere Aufgaben? 81
3.2 Wer macht was: Arbeitsweisen von Centaur bis dunkle Fabrik 88
3.3 Leitungsaufgabe Mensch–LLM 91

Literaturverzeichnis 93

4 Lern- und Wirkmechanismen 97
4.1 Was für Ziele verfolgen wir mit dem Einsatz von GenAI in der Lehre? 99
4.2 Wissenstypen 101
4.3 Anwendungsbeispiele nach Wissenskategorien 103
4.4 Effektive Lerntechniken und Unterstützung mit KI 105
4.5 Was die Forschung seit 2025 zeigt: Lernwirkung und kognitive Auslagerung 111
Literaturverzeichnis 123

II Teil II: Anwendungen 131

5 Phasen der Arbeit mit generativer KI (4D) 133
5.1 Mit KI arbeiten: vier Kompetenzen 135
5.2 Delegation: Was übernimmt die KI? 139
5.3 Discernment: Wie beurteile ich, was die KI liefert? 145
5.4 Diligence: Verantwortung, Offenlegung, Ressourcen 146
5.5 Wie prüfen wir jetzt? Jenseits der Homework Apocalypse . . 154
5.6 Kurs-Integration: Drei Phasen eines Semesters 168
Literaturverzeichnis 173

6 Rollen der KI: Hiwi, Copilot, Tutor, Simulator 181
6.1 KI als Hiwi 183
6.2 KI als Copilot 190
6.3 KI als Tutor 211
6.4 KI als Simulator 221
Literaturverzeichnis 229

7 Artefakte: Fallbeispiele aus der Lehre 239
7.1 Wissen übertragen: Begriffe, Formeln, Reihenfolgen 242
7.2 Wissen übersetzen: Bedeutungen erschließen 249
7.3 Wissen umformen: anwenden gegen Interessen und Folgen . 254
7.4 Was die Beispiele gemeinsam zeigen 266
Literaturverzeichnis 270

Anhang **275**

A Best-Practice-Sammlung didaktischer Prompts und GenAI Aufgabenstellungen **275**
Vorbemerkung zur Struktur der Sammlung 275
A.1 Hiwi: Schnelle Hilfe zur Lehrgestaltung 276
A.2 Tutor: Beratender Beistand 285
A.3 Aufgabenstellungen Tutorat 289
A.4 Copilot: Gemeinsam zu neuen Horizonten 292
A.5 Aufgabenstellungen Copilot 298
A.6 Simulator: Didaktisches Erleben 301
A.7 Weitere Prompts und Aufgabenstellungen der Online-Sammlung 307
Literaturverzeichnis 309

B Lösungshinweise zu Lernfragen und Übungen **311**
Kapitel 1: Einleitung 311
Kapitel 2: Grundlagen von KI und LLMs 313
Kapitel 4: Lern- und Wirkmechanismen 318
Kapitel 5: Phasen der Arbeit mit generativer KI (4D) 319
Kapitel 6: Rollen der KI: Hiwi, Copilot, Tutor, Simulator 322
Kapitel 7: Artefakte: Fallbeispiele aus der Lehre 324
Literaturverzeichnis 327

Glossar **331**
Literaturverzeichnis 339

Transparenzhinweis zum Gesamtwerk **341**
Literaturverzeichnis 342

Abbildungsverzeichnis

1 Galerie „Zehn Praxisbeispiele“: Film mit Haltepunkten zum nächsten Token, Lernsong zu Prognoseverfahren, Detektor-Duell, Teaser zur Fallstudie Backhaus Kaya, Spiel „Höher oder tiefer“, Linien-Widget, Arbeitsweisen-Durchspiel, Agenten-Engpass, Tutor-Kosten-Rechner und Making-of eines Erklärvideos. Die Galerie gibt es nur in der Online-Version: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/galerie-vorwort.html aufrufen. 2
2 Lernpfade durch das Buch. Rot umrandet sind die Stationen, an denen alle Linien halten. Eigene Darstellung. 3

1.1 Drei Viertel der Gespräche verlangen Denkleistungen der höheren Stufen: Anteil der Gespräche von Studierenden mit Claude, in denen das Modell die jeweilige Stufe der Bloomschen Taxonomie zeigt. Daten: Handa et al. (2025); eigene Darstellung und Stufenbeschreibungen. 16
1.2 Galerie „Fünf Formate, die 2026 mit KI entstehen“: Engpass-Animation (Kapitel 6.2.2.3), Präsentationsfolie mit Regelwerk, Lernsong zu Prognoseverfahren (Kapitel 7.1.2), Zuordnungsspiel (Kapitel 7.1.3) und KI-Rollenspiel (Kapitel 6.4.1). Dieses interaktive Element gibt es nur in der Online-Version: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/galerie-kapitel01.html aufrufen. . 23

2.1 Lernspiel „Welche Grundbegriffe kennen Sie schon?“ (Zuordnung von Begriffen und Definitionen). Dieses interaktive Element gibt es nur in der Online-Version: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/llm-game-standalone.html aufrufen. 33

2.2 Gewachsen ist die Schicht um das Modell: Werkzeuge und Gedächtnis kommen hinzu, daraus folgt eine Arbeitsschleife, über deren Schritte das Modell selbst entscheidet; Freigaben und Haltepunkte im Harness regeln seinen Handlungsspielraum (schematische Darstellung). Die Fassung zum Durchklicken: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/harness-schichten.html aufrufen. 36
2.3 Wie selbstständig eine KI arbeitet, entscheiden die Menschen, die sie einsetzen: sechs Stufen von der Handkorrektur ohne KI bis zum Agenten, der eine Aufgabe allein erledigt (eigene Darstellung nach Morris et al. (2024), Tabelle 2; Beispiele aus der Hochschullehre ergänzt). Die Fassung zum Durchklicken: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/autonomiestufen.html aufrufen. . 37
2.4 Drei Labore, ein Bauplan: Eine Schleife ruft das Modell immer wieder auf und lässt seine Werkzeugaufrufe ausführen, bis wieder der Mensch entscheidet. Jeder Harness enthält Annahmen darüber, was das Modell nicht kann (eigene Darstellung nach Wiesinger et al. (2024), Bolin (2026) und Martin et al. (2026); schematisch). Die Fassung zum Durchklicken: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/drei-labs-ein-bauplan.html aufrufen. . 38
2.5 Vier Modellklassen nach Leistung und Kontrolle über die Daten. Wie groß der Rückstand der offenen Modelle ausfällt, hängt am gewählten Leistungstest; die Werte stammen aus Edwards & Emberson (2026) und Somala & Emberson (2025). Hochschulzugänge wie KI:connect.nrw bieten beide Zeilen. Eigene Darstellung. 41
2.6 Was ein Abo kauft: Ab rund 20 € im Monat arbeitet das große Modell mit hoher Denkstufe; die 100-€-Stufe bringt dasselbe Modell mit etwa fünfmal so viel Kontingent. Eigene Darstellung nach den Preisseiten von OpenAI, Anthropic und Google, Stand Oktober 2026, und E. Mollick (2026b). 42

2.7 Welches Modell für welche Aufgabe? Drei Fragen führen zu Modellklasse und Preisstufe: Daten, Aufgabe, Häufigkeit; die Prüfregel gilt für jede Zeile. Stufen wie in Abbildung 2.6. Eigene Darstellung nach E. Mollick (2026b). Die Fassung zum Durchklicken: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/modellwahl-baum.html aufrufen. 44
2.8 Lebende Modellübersicht, semesterweise aktualisiert: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/modelluebersicht.html aufrufen. 47
2.9 Neun Genres, eine Geschichte: Prompt-Tricks glichen Schwächen früherer Modelle aus und entfallen, sobald die Modelle sie nicht mehr brauchen. Standbilder aus einem Film von gut zweieinhalb Minuten mit drei Haltepunkten, erstellt mit Claude Code und HyperFrames 0.9.2 (HeyGen, 2026); Stimme KI-erzeugt (ElevenLabs v4); Quellenmarke je Szene: ■ Labor, ● Studie, ▲ Folklore. Den Film gibt es nur in der Online-Version: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/kapitel02-grundlagen.html#vid-stuetzraeder aufrufen. 54
2.10 Lernspiel „LLM, RAG oder Agent?“ (Probleme und Anwendungsfelder der drei Setups). Dieses interaktive Element gibt es nur in der Online-Version: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/llm-rag-agent-game.html aufrufen. 56
2.11 Vom Chatbot zum Agenten wächst vor allem der Spielraum des Modells über den Ablauf: Im Chatbot und beim festen Abruf eigener Quellen ändert die Antwort nichts am Ablauf (□□□), als Router wählt das Modell einen Abzweig (□□□), mit Werkzeugen das Werkzeug (□□□), in der Schleife aus Denken, Handeln und Beobachten den nächsten Schritt (□□□) (Skala nach Roucher et al. (2024), Bildfolge nach Grootendorst (2025); schematisch). Die Fassung zum Durchklicken: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/chatbot-zu-agent.html aufrufen. . 57

2.12 Ein Skill lädt sein Wissen erst, wenn es gebraucht wird: zuerst nur Name und Kurzbeschreibung, dann die Anleitung des passenden Skills, Zusatzdateien nur bei Bedarf, wie Inhaltsverzeichnis, Kapitel und Anhang eines Handbuchs (eigene Darstellung nach Zhang et al. (2025); schematisch). Die Fassung zum Durchklicken: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/skills-handbuch.html aufrufen. 58
2.13 Vom Spickzettel zum prüfbaren Archiv: Die vier Stufen unterscheiden sich darin, was wann ins Kontextfenster gelangt, von der Anleitungsdatei (alles von Anfang an) bis zum Dateisystem (nur das gezielt Gesuchte) (schematische Darstellung). Die animierte Fassung: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/agenten-gedaechtnis.html aufrufen. 61
2.14 Die Sitzung schreibt alles mit, das Gedächtnis behält nur das Verdichtete: Ein Statistik-Tutor baut den Kontext aus der laufenden Sitzung, Kernpunkte wandern ins Gedächtnis, und am vierten Abend holt er nur das Passende zurück (eigene Darstellung nach Milam & Gulli (2025); schematisch). Die Fassung zum Durchklicken: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/sitzung-und-gedaechtnis.html aufrufen. 62
2.15 Exkurs „Ressourcenverbrauch der Modelle", Online-Fassung: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/energie.html aufrufen. 64
2.16 Ein Sprachmodell rechnet mit Zahlen, nicht mit Wörtern: Der Satz wird in Tokens mit festen Nummern zerlegt (echte Werte, Tokenizer o200k_base), über die Aufmerksamkeit rückt „Bank" durch „Baum" in die Nachbarschaft von „Park", und aus einer Wahrscheinlichkeitsverteilung wird das nächste Token gezogen (eigene Darstellung; Bedeutungskarte und Werte schematisch). Die Fassung zum Durchklicken: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/vom-satz-zum-naechsten-wort.html aufrufen. 65

2.17 Neun Genres, eine Kette: Tokens, Nummern, Zahlenlisten, Aufmerksamkeit, Wahrscheinlichkeiten, Auswahl, Anhängen. Standbilder aus einem Film von gut drei Minuten mit Haltepunkten, erstellt mit Claude Code und HyperFrames 0.9.2 (HeyGen, 2026); Stimme KI-erzeugt (ElevenLabs v4); Bedeutungskarte und Wahrscheinlichkeiten schematisch. Den Film gibt es nur in der Online-Version: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/kapitel02-grundlagen.html#vid-naechstes-token-genres aufrufen. 66

2.18 Vor der Antwort entsteht im Modell ein Zwischenschritt, der nie im Text steht: Aus „Dallas“ wird intern „Texas“ und daraus „Austin“; ersetzen Forschende „Texas“ durch „California“, antwortet das Modell „Sacramento“ (eigene Darstellung nach Lindsey et al. (2025) und Anthropic (2025); Claude 3.5 Haiku, stark vereinfacht). Die Fassung zum Durchklicken: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/zwischenschritt-texas.html aufrufen. 68

3.1 Was für Aufgaben erledigen Lehrende? 25 Einzelaufgaben am Beispiel „Business Teachers, Postsecondary“ (25-1011.00) nach Umfragen des US-Arbeitsministeriums. Interaktive Fassung mit Häufigkeiten und KI-Nutzung je Aufgabe: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/kapitel03-automation.html#fig-onet-tasks aufrufen. Enthält Informationen aus O*NET OnLine des U.S. Department of Labor, Employment and Training Administration (USDOL/ETA), verwendet unter der Lizenz CC BY 4.0 (https://www.onetonline.org/help/license); übersetzt und gekürzt, USDOL/ETA hat diese Änderungen weder geprüft noch gebilligt. O*NET® ist eine Marke von USDOL/ETA. . . 83

3.2 Automatisierung, Augmentierung und neue Aufgaben an den Aufgaben aus Tabelle 3.1: Vier Aufgaben wandern zur KI, fünf schrumpfen, fünf neue kommen hinzu. Schlussbild eines Videos (60 s), erstellt mit Claude Code und HyperFrames; Kachelgrößen nicht gemessen. Das Video gibt es nur in der Online-Version: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/kapitel03-automation.html#vid-acemoglu-restrepo aufrufen. 86

3.3 Mit jeder Arbeitsweise gibt der Mensch mehr Arbeitsschritte an die KI ab; „fragt“ markiert, wo der Agent in der Dämmerfabrik einen Menschen hinzuholt (Konzeptschema nach Dell'Acqua et al. (2023), E. Mollick (2024), E. R. Mollick (2026b) und E. R. Mollick (2026a); Zuordnung der Schritte eigene Lesart). Interaktive Fassung: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/ki-entwicklung.html?zeige=arbeitsweisen aufrufen. . . 89
3.4 Dieselbe Aufgabe in fünf Arbeitsweisen: Je mehr die KI übernimmt, desto weniger spricht der Mensch und desto mehr sprechen die Agenten miteinander. Dialoge nachgestellt und gekürzt, Denkspuren angenähert, Zähler als Lehrmodell (Muster nach Schluntz & Zhang (2024)). Interaktive Fassung mit zwei weiteren Fällen: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/ki-arbeitsweisen-durchspiel.html aufrufen. 90
3.5 Mehr Agenten machen den Menschen zum Engpass. Standbild bei Minute 22 von acht gleichzeitig abgegebenen Aufgaben: Kugel A liegt in der Ablage „Zu entscheiden“, während die Agenten kaum zu tun haben; allein ist sie nach 24 Minuten fertig, als achte von acht nach 43,5 Minuten, davon 19,5 Minuten Warten (Lehrmodell, keine Messung). Interaktive Fassung: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/agenten-engpass.html aufrufen. 92

4.1 Illustration Zeitlich verteiltes Lernen – spacing 106
4.2 Illustration Inhaltlich gemischtes Lernen – interleaving . . . 107
4.3 Illustration Testgestütztes Lernen – test-enhanced learning . 108

5.1 Der 4D-Kreislauf. Die äußere Schleife (Delegation und Diligence) entscheidet einmal je Vorhaben, was die KI übernimmt und welche Pflichten daraus folgen; die innere (Description und Discernment) dreht sich in jedem Arbeitsgang mehrmals. Eigene Darstellung nach Dakan & Feller (2025) und den beiden Schleifen aus Dakan et al. (2025). Die Fassung zum Anklicken mit Unterkompetenzen und dem Engpass je Rolle: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/4d-kreislauf.html aufrufen. 137

5.2 Vergleich der fünf Kompetenzrahmen (Zielgruppe, Ordnungsprinzip, Entstehung) in der Online-Fassung: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/kapitel05-4d-phasen.html#sec-schemas-rahmen aufrufen. 138
5.3 KI-Agenten bewältigen immer längere Aufgaben: 50-%-Zeithorizont der Modelle 2019–2026 auf logarithmischer Achse, mit Trend ab 2023 (gestrichelt) und Lehraufgaben ähnlicher Dauer zur Orientierung (eigene Zuordnung). Über 16 Stunden ist die Messung nicht mehr verlässlich. Daten: METR (2026), Stand 8. Mai 2026. Interaktive Fassung: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/ki-entwicklung.html?zeige=zeithorizont aufrufen. 140
5.4 Zwei Skalierungsgesetze: Links sinkt der Vorhersagefehler mit dem Rechenaufwand im Training auf einer Geraden (beide Achsen logarithmisch); bei gleichem Budget schneidet das kleinere, mit mehr Daten trainierte Chinchilla besser ab als Gopher. Rechts steigt die Trefferquote mit der Denkzeit beim Antworten; bei mittelschweren Aufgaben schlägt ein kleines Modell mit Denkzeit ein 14-mal größeres. Lehrmodell, schematisch; Zahlen nach Kaplan et al. (2020), Hoffmann et al. (2022), OpenAI (2024) und Snell et al. (2024). Interaktive Fassung: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/scaling-laws.html aufrufen. 141
5.5 Expertenwissen wird 725-mal billiger: niedrigste Kosten je Frage, mit denen ein Modell 75 % des GPQA Diamond richtig beantwortet, Januar 2025 bis Juli 2026 (logarithmische Achse). Darunter als Raster: Ein Kästchen ist eine Frage zum o3-Preis vom Januar 2025, gefüllt ist, was 30 Cent zum jeweiligen Zeitpunkt kaufen; der letzte Sprung (−66 %) bringt mit 479 Kästchen mehr als alle früheren zusammen. Rasterdarstellung nach einer Idee von Mollick (2026). Daten: Emberson & Roodman (2026), Epoch AI. Interaktive Fassung: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/ki-entwicklung.html?zeige=kosten aufrufen. 142

5.6 Was ein Tutor-Bot im Semester kostet: 150 Studierende stellen je 2 Fragen pro Tag an 98 Tagen (29.400 Fragen), jede zum Preis einer GPQA-Diamond-Frage beim günstigsten Modell mit 75 % richtigen Antworten; von rund 8.800 US-$ (o3, Januar 2025) auf rund 12 US-$ (GPT-5.6 Luna, Juli 2026). Nur Größenordnung. Daten: Emberson & Roodman (2026). Interaktive Fassung mit eigenen Kurszahlen: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/tutor-kosten.html aufrufen. 143
5.7 Etwa gleichverteilt: Vier Arten der Interaktion von Studierenden mit Sprachmodellen. Unterscheidung nach Handa et al. (2025); eigene Darstellung, Beispiele eigene. 156
5.8 KI-resistente Aufgabenstellungen: die vier Säulen nach Gmeiner (2025). Eigene Darstellung nach der Grafik von Bernhard Gmeiner, lizenziert unter CC BY-SA 4.0 (https://creativecommons.org/licenses/by-sa/4.0/); Texte gekürzt und umformuliert. 157
5.9 Wen der Lehr-Detektor für KI hält: Anteil der Texte mit Urteil „KI“ (Schwelle 50 %), nur Texte, die er beim Lernen nicht gesehen hat. Helle Balken: Texte von Menschen, jedes Urteil „KI“ ist ein Fehlalarm; dunkle Balken: KI-Texte, jedes Urteil „KI“ ist ein Treffer. Schüleraufsätze aus PERSUADE 2.0 (Crossley et al., 2024), ältere KI-Texte (GPT-3) sowie TOEFL- und College-Aufsätze aus Liang et al. (2023), aktuelle KI-Texte von Claude Opus 5.5 (eigene Läufe, 02.11.2026). Eigene Berechnung. . . 162

6.1 Beispiel: Tutor-Bot BWL Grundlagen. Screenshot der Testversion, Januar 2026 183
6.2 Schreibtrainer zum Kopieren: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/schreibtrainer.html aufrufen. 195
6.3 Making-of zum Video über Tabelle 3.1: Auftrag, Datendatei, Code, automatische Prüfung, Sichtprüfung, Rendern, rekonstruiert aus Versionsprotokoll und Prüfausgaben. Schlussbild eines Videos (59 s), erstellt mit Claude Code und HyperFrames. Das Video gibt es nur in der Online-Version: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/kapitel06-rollen.html#vid-making-of aufrufen. 200

6.4 Dieselbe Herleitung der optimalen Bestellmenge in Manim (links) und HyperFrames (rechts), beide von Claude programmiert. Schlussbild eines Videos (30 s). Das Video gibt es nur in der Online-Version: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/kapitel06-rollen.html#vid-eoq-vergleich aufrufen. 201
6.5 Little's Law in drei Szenarien: Über acht Stunden trifft die Rechnung $\hat{\lambda} \cdot \hat{W}$ (gestrichelt) den gezählten Bestand $\bar{L}$ (durchgezogen), im Prüfungsamt mit hoher Auslastung erst nach einigen Stunden; im Blick über 20 Minuten verfehlt sie ihn um 13 %. Dieses interaktive Element gibt es nur in der Online-Version: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/kapitel06-rollen.html#sec-widget-littles-law aufrufen. 204
6.6 Bullwhip-Effekt in drei Szenarien mit derselben Kundennachfrage. Oben die Bestellungen eines Jahres auf gleicher Skala, unten das Varianzverhältnis jeder Stufe über 2000 Perioden (logarithmisch), der Strich markiert den Wert nach Chen et al. Verdoppelt sich die Lieferzeit, steigt die Varianz der Fabrikbestellungen vom 41- auf das 692-Fache der Kundennachfrage; geteilte Kassendaten senken sie auf das 9,7-Fache. Dieses interaktive Element gibt es nur in der Online-Version: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/kapitel06-rollen.html#sec-widget-bullwhip aufrufen. 206
6.7 Ablauf des Physik-Tutors PS2 Pal nach Kestin et al. (2025): Lehrende legen Regeln und Musterlösungen im Prompt fest, Studierende arbeiten zu Hause Schritt für Schritt mit dem Tutor. Schlussbild eines Videos (44 s); der Dialog ist ein sinngemäßes Beispiel. Das Video gibt es nur in der Online-Version: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/kapitel06-rollen.html#vid-ps2pal-ablauf aufrufen. 217

7.1 Standbild aus dem Lernsong *Every Forecast Is Wrong* (5:15) bei 3:20: Der Refrain vergleicht drei Verfahren über die mittlere absolute Abweichung (MAD) und die mittlere absolute prozentuale Abweichung (MAPE); die Zeile unten ist der Liedtext als Untertitel. Text, Beispieldaten und Animationscode: Claude; Musik: Suno; Café und Zahlen erfunden. Das Video gibt es nur online: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/lernsong-forecast.html aufrufen. 247
7.2 Linien-Widget aus Woche 2 des SSCM-Moduls in der Ausgangslage der Pizzalinie: links die vier Arbeitsschritte mit Schiebereglern, rechts Kennzahlen, Kapazität je Schritt mit dem Engpass Backen und die drei Arbeitsaufträge unter *Try this*. Erstellt mit Claude nach Vorgaben der Lehrperson. Das Widget gibt es nur online: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/line-widget.html aufrufen. 252
7.3 Standbild aus dem Teaser zur Fallstudie Backhaus Kaya (5 s, ohne Ton): Aylin Kaya nachts in der Backstube vor dem Etagenofen. KI-generiertes Video (LTX-2.5); Bäckerei und Figuren sind erfunden. Den Teaser gibt es nur online, zusammen mit Linien-Widget und Engpass-Animation zum selben Fall: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/galerie-animationen.html#kaya-teaser aufrufen. 256

A.1 Vollständige Prompt-Sammlung in der Online-Version: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/kapitel07-appendix02-prompt-sammlung.html aufrufen. 309

B.1 Lösung zur Leserübung „Höher oder tiefer“ (Kapitel 1) . . . 313
B.2 Lösung zur Bibliothek der Prompts (Kapitel 3) 322

Tabellenverzeichnis

1 Didaktische Mechanismen in diesem Buch, geordnet nach Lernzielen und innerhalb jeder Gruppe nach Stärke der Befunde. Eigene Darstellung. 7

2.1 Modell, Harness und Agent: zwei Bauteile und eine Betriebsweise (eigene Zusammenstellung). 35
2.2 Modelle und Preisstufen bei Drucklegung. Preise laut Preisseiten der Anbieter, Stand Oktober 2026, Euro-Beträge einschließlich Mehrwertsteuer. Quellen: OpenAI (2026a), Anthropic (2026a), Google (2026b), Mistral AI (2026), IT Center der RWTH Aachen (2026). 46
2.3 Sechs gezielte Einschränkungen in didaktischen Prompts. Eigene Darstellung; die Formulierungen stammen aus den Prompts in Anhang A 53
2.4 Fünf Bausteine einer dauerhaften Arbeitsumgebung und was das Modell davon wann liest. Eigene Darstellung 59

3.1 Welche Aufgaben in der Lehre wandern zur KI, bei welchen unterstützt sie, und welche kommen neu hinzu? Legende: x = klarer Effekt, ? = gemischter Effekt. Quelle: Aufgabenmodell nach Acemoglu et al. (2025) 85

4.1 Methoden nach Wissenstyp: Fakten, Prozess und Transfer. Quelle: Basierend auf Hattie (2023), S. 358, 340ff. 103
4.2 Kernaussagen und Belege zu den Gestaltungsfragen in Kapitel 4, Stand November 2026. 119

5.1 Die vier Kompetenzen des AI-Fluency-Modells mit ihren Unterkompetenzen. Übersetzung nach Dakan & Feller (2025), CC BY-SA 4.0 136
5.2 Beispiel arbeitsphasenorientierte Dokumentation der LLM Nutzung. Quelle: (Baresel et al. (2024), S. 11) 152
5.3 Erläuterungen zum Grad der LLM-Nutzung. Quelle: Baresel et al. (2024), basierend auf Rowland (2023) 154

5.4 Prüfungsformate nach den vier Säulen. Quellen: Gmeiner (2025); Mulder et al. (2023); Hanover Research (2024); Monash University (2025); Ward et al. (2024) 165
5.5 Drei Phasen der KI-Integration in einen Kurs; die Rollen entsprechen Kapitel 6. Eigene Darstellung. 169

6.1 Vier Typen von KI-Suchhelfern nach zwei Unterscheidungen. Quelle: Tay (2025) 185
6.2 Werkzeugtypen je Phase der Literaturrecherche. Typen nach Tay (2025), ergänzt um drei Typen ohne erzeugten Text (Zitationsnetz, Zitationskontext, API); Produktnamen sind ein Schnappschuss (Stand 2026), die Typen bleiben. Quelle: eigene Zuordnung nach Bartnik & Schmid (2025) 187
6.3 Acht Schreibtrainer entlang der Abschlussarbeit (TH Köln, Wirtschaftsingenieurwesen; Julia Schmid und Roman Bartnik) 194

7.1 Die Beispiele dieses Kapitels nach Wissensform, Lerntechnik, Rolle der KI und Gestaltung 242

A.1 Online verfügbare Prompts und Aufgabenstellungen 308

Vorwort

Dieses Buch ist aus einem Skript gewachsen. Als die ersten Kolleginnen und Kollegen mich fragten, wie man die neuen Sprachmodelle (*Large Language Models*) sinnvoll in der Lehre einsetzt, schrieb ich meine Notizen aus dem eigenen Unterricht in Supply Management und Projektmanagement am Campus Gummersbach der TH Köln zusammen. Aus den Notizen machte ich einen Workshop, aus dem Workshop eine Reihe von Kursen, die ich im Netzwerk für hochschuldidaktische Weiterbildung (hdw nrw) an Hochschulen in ganz Nordrhein-Westfalen gebe, und auf jede neue Frage der Teilnehmenden antwortete ich mit einem neuen Abschnitt. An der TH Köln diskutiere ich seit 2026 mit Kolleginnen und Kollegen in der Taskforce GenAI in der Lehre, was in Lehre und Prüfung funktioniert und was nicht.

Neue Möglichkeiten durch KI – Interaktionen und vieles mehr

Vieles, was für eine einzelne Lehrveranstaltung früher zu aufwendig war, baue ich heute mit einem Sprachmodell in wenigen Stunden. In diesem Buch stecken deshalb 37 Beispiele, die Sie ansehen, hören und ausprobieren, statt nur über sie zu lesen: ein Film, der das nächste Token eines Sprachmodells in neun Genres erklärt und vor der Auflösung auf Ihre Vorhersage wartet, ein Lernsong über Prognoseverfahren, ein Duell gegen einen KI-Detektor, Rechner, Widgets und Animationen, in denen sich vor dem Engpass die Arbeit staut. Jedes Beispiel steht an der Stelle im Buch, deren Lernziel es dient, und jedes habe ich auf Zahlen und Quellen geprüft. Die Galerie zeigt die zehn, die am meisten überraschen; alle übrigen sammelt die Seite Praxisbeispiele im Überblick(https://th-koln-bartnik.github.io/genai4teaching/praxisbeispiele.html).



Abbildung 1. Galerie „Zehn Praxisbeispiele“: Film mit Haltepunkten zum nächsten Token, Lernsong zu Prognoseverfahren, Detektor-Duell, Teaser zur Fallstudie Backhaus Kaya, Spiel „Höher oder tiefer“, Linien-Widget, Arbeitsweisen-Durchspiel, Agenten-Engpass, Tutor-Kosten-Rechner und Making-of eines Erklärvideos. Die Galerie gibt es nur in der Online-Version: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/galerie-vorwort.html aufrufen.

Wählen Sie Ihren Lernpfad

Sie brauchen nicht jede Etappe dieses Buchs. Lehrende bringen zwei Arten von Vorwissen mit, die wenig miteinander zu tun haben: Erfahrung mit KI-Werkzeugen und Kenntnis der Lernforschung, also das Wissen, was beim Lernen wirkt, wie man es in einer Lehrveranstaltung umsetzt und welche Formen des KI-Einsatzes sich bewährt haben. Lehrerfahrung ersetzt diese Kenntnis nicht. Morehead und Kollegen befragten Hochschullehrende und Studierende zu wirksamen Lernstrategien; die Lehrenden wussten nur wenig mehr als ihre Studierenden und teilten deren verbreitete Fehlannahmen (Morehead et al., 2016). Denken Sie an zwei Leser dieses Buchs: einen Informatiker, der täglich mit Agenten (eigenständig handelnden KI-Systemen) arbeitet, und eine Kollegin, die die Befunde zu Abrufübungen kennt und noch nie einen Agenten eingerichtet hat. Er braucht die Kapitel zur Lernforschung, sie die Grundbegriffe der KI, und keiner von beiden gewinnt etwas, wenn er Bekanntes noch einmal liest. Kalyuga und Kollegen haben Studien zusammengetragen, in denen Erklärungen, die Neulingen halfen, Erfahrene beim Lernen behinderten, weil sie Bekanntes ein zweites Mal verarbeiten mussten; sie nennen das den Expertise-Umkehreffekt (*expertise reversal effect*) (Kalyuga et al., 2003). Abbildung 2 zeigt die vier Kombinationen der beiden

Arten von Vorwissen als Liniennetz, und ein Selbsttest führt Sie zu Ihrer Linie.

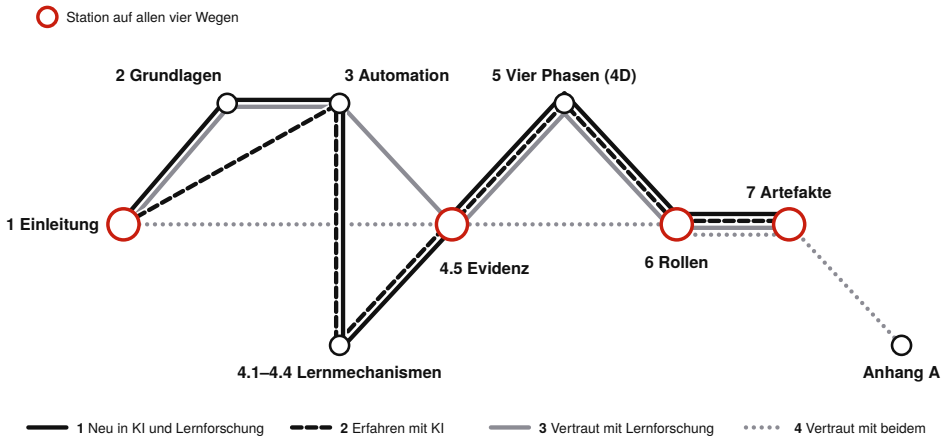


Abbildung 2. Lernpfade durch das Buch. Rot umrandet sind die Stationen, an denen alle Linien halten. Eigene Darstellung.

i Selbsttest: Welche Linie passt?

Erfahrung mit KI. (a) Ich nutze ein Sprachmodell mindestens einmal pro Woche für meine Arbeit. (b) Ich habe einen eigenen Assistenten eingerichtet, etwa ein Projekt mit festen Anweisungen und eigenen Dateien. (c) Ich habe einer KI eine mehrschrittige Aufgabe übertragen, bei der sie selbst sucht, Dateien liest oder Code ausführt.
Kenntnis der Lernforschung. (d) Ich kenne zentrale Wirkmechanismen aus der Lernforschung und kann erklären, warum etwa Abrufübungen, verteiltes Üben und Selbsterklären das Behalten stärken. (e) Ich weiß, wie sich solche Mechanismen in einer Lehrveranstaltung umsetzen lassen, etwa mit kurzen Abfragen zu Beginn, Wiederholung über das Semester oder Aufgaben, in denen Studierende einander erklären. (f) Ich kenne erprobte Einsatzformen und Befunde zu KI in der Lehre, etwa wann ein KI-Tutor das Lernen stärkt und wann er es durch Auslagerung des Denkens schwächt.
Höchstens eine Zustimmung je Gruppe: Linie 1. Zwei oder mehr nur bei KI: Linie 2. Nur bei Lernforschung: Linie 3. In beiden Gruppen: Linie 4. Online prüft der Selbsttest die Antworten und hebt die Linie her-

> vor: https://th-koln-bartnik.github.io/genai4teaching/#sec-lernpfade.

Eine fünfte Linie steht neben dem Selbsttest, weil sie kein Vorwissen voraussetzt. **Linie 5 · Erst schauen** führt nicht durch die Kapitel, sondern an allen 37 Praxisbeispielen entlang, von den Filmen über die Spiele bis zu den Rechnern. Unter jedem Beispiel führt ein Link in das Kapitel, das es erklärt; so kehren Sie dort ins Buch zurück, wo ein Beispiel Sie neugierig gemacht hat. Die Linie beginnt online auf der Seite https://th-koln-bartnik.github.io/genai4teaching/praxisbeispiele.html.

Wie dieses Buch lehrt

Eine gute Regel lautet: Nutze selbst, was du anbietest – im Tech-Jargon sagt man *eat your own dog food*. Dem folgend finden Sie in diesem Buch alle Lernmechanismen, die es vorstellt, auch angewandt wieder. Jede seiner Lernhilfen beruht auf einem Mechanismus, den Kapitel 4 als belegt vorstellt (Kapitel 4.4), und ich habe sie nach drei Lernzielen geordnet (Anderson & Krathwohl, 2001): Erinnern, Verstehen, Anwenden.

Am gründlichsten hat die Lernforschung untersucht, was beim **Erinnern** hilft. Die **Abrufübung** (*retrieval practice*) finden Sie in den Lernfragen am Ende jedes Kapitels. Beantworten Sie sie zuerst aus dem Gedächtnis und schlagen Sie erst dann die Lösungshinweise in Anhang B nach (Anhang B), denn wer abruft, behält mehr als wer wiederliest. Das **verteilte Wiederholen** (*spacing*) steckt im Kasten mit den Schlüsselbegriffen, der ebenfalls am Kapitelende steht. Markieren Sie online einen Begriff wie Fähigkeitsüberhang als nicht gewusst, lege ich ihn Ihnen einige Kapitel später wieder vor, und mit diesem Abstand hält er länger als nach gebündeltem Lernen. Den **Vortest** (*pretesting*) machen Sie am Anfang jedes Kapitels. Unter „Bevor Sie weiterlesen“ schätzen Sie Aussagen ein wie „Fast alle Studierenden nutzen KI inzwischen auch für Prüfungsleistungen“, und das Kapitel löst jede an der Stelle auf, die sie beantwortet. Wer sich vorher festlegt, auch falsch, behält die Antwort besser. Die **Melodie als Gedächtnisstütze** schließlich hören Sie im Lernsong zu Prognoseverfahren in Kapitel 7, wo Melodie und Rhythmus dem Wortlaut ein Gerüst geben, an dem Sie ihn wieder abrufen.

Für das **Verstehen** zeige ich Ihnen ein gelöstes Beispiel aus meiner Lehre, bevor ich eine Methode empfehle. **Ausgearbeitete Beispiele** (*worked examples*)

finden Sie vor allem in Kapitel 7, etwa den Tutor-Bot für das Modul „Grundlagen der BWL“. Prinzip, Empfehlung und Umsetzung stehen dort hintereinander, sodass Ihr Arbeitsgedächtnis nicht zugleich den Lösungsweg und das Prinzip suchen muss. **Fehlvorstellungen widerlegen** (*refutation text*) heißt, eine verbreitete Vorstellung beim Namen zu nennen und mit Gründen zu ersetzen. Im Streich-Test zum Prompting in Kapitel 2 entscheiden Sie bei zehn Zeilen eines älteren Prompts, ob Sie sie streichen würden und wie sicher Sie sich sind; die Irrtümer, bei denen Sie sich sicher waren, korrigiert die Auflösung am gründlichsten. **Unterscheiden durch Vermischen** (*interleaving*) üben Sie in den Spielen zu den Schlüsselbegriffen. Zu einem kurzen Fall wählen Sie unter ähnlichen Begriffen den passenden, etwa zwischen Fähigkeitsüberhang und Auslagerung des Denkens, und im direkten Vergleich sehen Sie die Merkmale, die beide trennen. Eine **vorangestellte Ordnungshilfe** (*advance organizer*) zeigt Ihnen das Ganze, bevor die Einzelheiten kommen. Das Liniennetz oben ist eine solche Ordnungshilfe; in Kapitel 1 ordnen die vier Rollen der KI als Hiwi, Copilot, Tutor und Simulator alle folgenden Kapitel, und eine Galerie zeigt fünf Formate, deren Entstehung die späteren Kapitel erklären. Die **Geschichte als Einstieg** begegnet Ihnen am Anfang jedes Kapitels als kurze Szene aus dem Hochschulalltag, denn Ereignisse, die kausal verknüpft um eine Person kreisen, behält man besser als Sachtext.

Für das **Anwenden** prompten, prüfen und bauen Sie selbst. Zum **Selbst-Erzeugen** (*generative and constructive learning*) lade ich Sie in den Kästen „Ausprobiert“ ein, etwa wenn Sie in Kapitel 6 testen, ob ein Sprachmodell richtig zitiert; wer formuliert, erklärt oder baut, lernt tiefer als wer nur liest. **Scaffolding und Ausblenden** (*fading*) heißt, dass Hilfen Sie stützen, solange Sie sie brauchen, und dann zurücktreten. Wissen Sie schon viel, überspringen Sie auf Ihrem Lernpfad ganze Abschnitte, und die Vertiefung zur Technik in Kapitel 2 habe ich aus demselben Grund als überspringbar gekennzeichnet (Kalyuga et al., 2003). Tabelle 1 nennt zu jedem Mechanismus die Wirkweise, die Stellen im Buch und eine kanonische Quelle.

Mechanismus	Wirkweise	Wo im Buch	Kanonische Quelle
Erinnern			
Abrufübung mit Rückmeldung (*retrieval practice*)	Abrufen festigt Gelerntes stärker als Wiederlesen	Lernfragen; Schlüsselbegriffe; Lernspiele in Kapitel 2	Roediger & Karpicke (2006)

Mechanismus	Wirkweise	Wo im Buch	Kanonische Quelle
Verteiltes Wiederholen (*spacing*)	Abstand zwingt zum Rekonstruieren und hält länger	Wiederkehr-Karten; Kernaussagen	Cepeda et al. (2006)
Vortest (*pretesting*)	Raten vor dem Lesen lenkt die Aufmerksamkeit auf die Antwort	„Bevor Sie weiterlesen“; Streich-Test	Richland et al. (2009)
Melodie als Gedächtnisstütze	Melodie und Rhythmus geben dem Wortlaut ein Abrufgerüst	Lernsong in Kapitel 7	Wallace (1994)
Verstehen			
Ausgearbeitete Beispiele (*worked examples*)	Ein gelöstes Beispiel entlastet das Arbeitsgedächtnis	Kapitel 7; Anwendungsbeispiele in Kapitel 1–6	Sweller & Cooper (1985)
Fehlvorstellungen widerlegen (*refutation text*)	Die alte Vorstellung wird genannt und mit Gründen ersetzt; sicher vertretene Irrtümer werden besonders gründlich korrigiert	Prompting mit Streich-Test; Auflösungen „nein“	Tippett (2010)
Unterscheiden durch Vermischen (*interleaving*)	Im direkten Vergleich treten die trennenden Merkmale hervor	Fall-Zuordnung; Lernspiel LLM, RAG oder Agent	Kornell & Bjork (2008)
Vorangestellte Ordnungshilfe (*advance organizer*)	Ein übergeordneter Rahmen vor den Einzelheiten gibt dem Neuen einen Platz im Vorwissen	Liniennetz der Lernpfade; vier Rollen der KI; Galerie in Kapitel 1	Ausubel (1960)
Geschichte als Einstieg	Kausal verknüpfte Ereignisse um eine Person werden besser behalten und verstanden	Szene am Kapitelanfang	Mar et al. (2021)
Anwenden			

Mechanismus	Wirkweise	Wo im Buch	Kanonische Quelle
Selbst-Erzeugen (*generative and constructive learning*)	Wer formuliert, erklärt oder baut, lernt tiefer als wer liest	Kästen „Ausprobiert“; eigene Erklärung vor der Musterantwort	Chi & Wylie (2014)
Scaffolding und Ausblenden (*fading*)	Hilfen stützen, solange sie nötig sind, und treten mit wachsendem Können zurück	Lernpfade; Lernfragen in drei Stufen; Vertiefung in Kapitel 2	Wood et al. (1976)

Tabelle 1. Didaktische Mechanismen in diesem Buch, geordnet nach Lernzielen und innerhalb jeder Gruppe nach Stärke der Befunde. Eigene Darstellung.

Übersicht

Generative künstliche Intelligenz (GenAI) kann Lehrenden aufwendige Vorbereitung abnehmen und Studierenden beim Üben helfen; sie kann ihnen aber auch das Denken abnehmen. In diesem Buch zeige ich Lehrenden, Forschenden und Studierenden, wie sie **KI als Werkzeug der Hochschuldidaktik** so einsetzen, dass das Lernen gewinnt.

Das Buch besteht aus sieben Kapiteln in zwei Teilen und zwei Anhängen.

Teil I: Grundlagen

1. Einleitung: KI als Hilfe zum Lehren und Lernen
2. Grundlagen von KI und LLMs
3. Prinzipien der Automation von Aufgaben
4. Lern- und Wirkmechanismen

Teil II: Anwendungen

5. Phasen der Arbeit mit generativer KI (4D)
6. Rollen der KI: Hiwi, Copilot, Tutor, Simulator
7. Artefakte: Fallbeispiele aus der Lehre

- Anhang A: Best-Practice-Sammlung didaktischer Prompts und Aufgabenstellungen
- Anhang B: Lösungshinweise zu Lernfragen und Übungen

Literaturverzeichnis

Anderson, L. W., & Krathwohl, D. R. (2001). *A taxonomy for learning, teaching, and assessing: A revision of Bloom's taxonomy of educational objectives*. Longman.

Ausubel, D. P. (1960). The use of advance organizers in the learning and retention of meaningful verbal material. *Journal of Educational Psychology*, *51*(5), 267–272. https://doi.org/10.1037/h0046669.

Cepeda, N. J., Pashler, H., Vul, E., Wixted, J. T., & Rohrer, D. (2006). Distributed practice in verbal recall tasks: A review and quantitative synthesis. *Psychological Bulletin*, *132*(3), 354–380. https://doi.org/10.1037/0033-2909.132.3.354.

Chi, M. T. H., & Wylie, R. (2014). The ICAP framework: Linking cognitive engagement to active learning outcomes. *Educational Psychologist*, *49*(4), 219–243. https://doi.org/10.1080/00461520.2014.965823.

Kalyuga, S., Ayres, P., Chandler, P., & Sweller, J. (2003). The expertise reversal effect. *Educational Psychologist*, *38*(1), 23–31. https://doi.org/10.1207/S15326985EP3801_4.

Kornell, N., & Bjork, R. A. (2008). Learning concepts and categories: Is spacing the „enemy of induction"? *Psychological Science*, *19*(6), 585–592. https://doi.org/10.1111/j.1467-9280.2008.02127.x.

Mar, R. A., Li, J., Nguyen, A. T. P., & Ta, C. P. (2021). Memory and comprehension of narrative versus expository texts: A meta-analysis. *Psychonomic Bulletin & Review*, *28*(3), 732–749. https://doi.org/10.3758/s13423-020-01853-1.

Morehead, K., Rhodes, M. G., & DeLozier, S. (2016). Instructor and student knowledge of study strategies. *Memory*, *24*(2), 257–271. https://doi.org/10.1080/09658211.2014.1001992.

Richland, L. E., Kornell, N., & Kao, L. S. (2009). The pretesting effect: Do unsuccessful retrieval attempts enhance learning? *Journal of Experimental Psychology: Applied*, *15*(3), 243–257. https://doi.org/10.1037/a0016496.

Roediger, H. L., & Karpicke, J. D. (2006). Test-enhanced learning: taking memory tests improves long-term retention. *Psychological science*, *17*(3), 249–255. https://doi.org/10.1111/j.1467-9280.2006.01693.x.

Sweller, J., & Cooper, G. A. (1985). The use of worked examples as a substitute for problem solving in learning algebra. *Cognition and Instruction*, *2*(1), 59–89. https://doi.org/10.1207/s1532690xci0201_3.

Tippett, C. D. (2010). Refutation text in science education: A review of two decades of research. *International Journal of Science and Mathematics Education*, *8*(6), 951–970. https://doi.org/10.1007/s10763-010-9203-x.

Wallace, W. T. (1994). Memory for music: Effect of melody on recall of text. *Journal of Experimental Psychology: Learning, Memory, and Cognition*, *20*(6), 1471–1485. https://doi.org/10.1037/0278-7393.20.6.1471.

Wood, D., Bruner, J. S., & Ross, G. (1976). The role of tutoring in problem solving. *Journal of Child Psychology and Psychiatry*, *17*(2), 89–100. https://doi.org/10.1111/j.1469-7610.1976.tb00381.x.

Teil I

Teil I: Grundlagen

1 Einleitung

In diesem Kapitel

- Wie verbreitet ist KI-Nutzung?
- Was geht schief?
- Was hilft?
- Was Sie im Buch erwartet

Montagmorgen, fünfte Semesterwoche. Professorin Katrin Albers hat für ihre 120 Studierenden in Technischer Mechanik wieder keine Übungstests geschafft, obwohl sie weiß, dass häufiges Abfragen wirkt. Ein Kollege schwärmt, sein Chatbot schreibe ihm in Minuten zwanzig Aufgaben samt Lösungsweg; eine Kollegin will ihren Studierenden einfach einen KI-Tutor freischalten. Albers probiert es in der Mittagspause mit der kostenlosen Version, und schon die erste Lösung ist falsch. Am Nachmittag gibt ein Student eine fehlerfreie Hausübung ab und kann in der Sprechstunde keinen Schritt davon erklären. Albers fragt sich, ob die KI ihr die Arbeit abnimmt oder ihren Studierenden das Lernen.

Die Szene ist aus Gesprächen in Workshops mit Lehrenden zusammengesetzt.

Bevor Sie weiterlesen: Wie sehen Sie das?

Wie sehr stimmen Sie den vier Aussagen zu? Richtig oder falsch gibt es hier noch nicht: Jede Aussage wird an der Stelle im Kapitel aufgelöst, die sie beantwortet. Wer sich vorher festlegt, liest gezielter.

1. Fast alle Studierenden nutzen KI inzwischen auch für Prüfungsleistungen.
stimme zu 1 – 2 – 3 – 4 – 5 *stimme nicht zu*
(Auflösung in Kapitel 1.1)

2. Die größte Gefahr generativer KI für das Lernen besteht darin, dass Studierende in Prüfungen täuschen.
stimme zu 1 – 2 – 3 – 4 – 5 *stimme nicht zu*
(Auflösung in Kapitel 1.2)

3. Wer mit der kostenlosen Version eines Chatbots in seinem Fach schlechte Ergebnisse erhält, weiß, was KI dort leisten kann.
stimme zu 1 – 2 – 3 – 4 – 5 *stimme nicht zu*
(Auflösung in Kapitel 1.2)

4. Ein KI-Tutor verbessert das Lernen, sobald die Studierenden Zugang zu ihm erhalten.
stimme zu 1 – 2 – 3 – 4 – 5 *stimme nicht zu*
(Auflösung in Kapitel 1.3)

Lernziele: Nach diesem Kapitel können Sie …

1. erklären, bei welchen zwei Lehrproblemen generative KI hilft, und einordnen, wie verbreitet sie bei Studierenden und Lehrenden genutzt wird;
2. begründen, warum die Auslagerung des Denkens das Lernen stärker gefährdet als das Täuschen und warum schwache Zugänge das Urteil über KI verzerren;
3. die Bedingungen benennen, unter denen KI nach der Forschung seit 2025 das Lernen stützt, und Ihren eigenen Weg durch dieses Buch wählen.

Die Kernaussagen am Kapitelende sind nach diesen drei Zielen geordnet.

Wie kann generative künstliche Intelligenz (KI, *generative AI*) **in der Lehre helfen?** Hoffnung besteht für die zwei Probleme, die Albers' Montag prägen: Studierende haben individuelle Bedürfnisse, Lehrende nur begrenzt Zeit,

und gerade wirksame Methoden wie häufige kleine Tests (*practice testing*) oder individuelles Feedback kosten viel Vorbereitung (Brown et al., 2014; Dunlosky et al., 2013; Hattie, 2023, Kap.13); ausführlich behandelt das Kapitel 4.1. Für die Lehre sind große Sprachmodelle (*Large Language Models*, LLM) vor allem „**generally faster**“ (McAfee, 2024): Übungsaufgaben, Anwendungsbeispiele, Quizfragen und Rollenspiele lassen sich mit KI in großer Zahl entwerfen (Meincke et al., 2024; E. R. Mollick & Mollick, 2023). Der Berg ist noch da, aber mit dem E-Bike kommt man weiter. Wie weit, hängt an drei Fragen, die dieses Kapitel der Reihe nach beantwortet: Wie verbreitet ist die Nutzung, was geht dabei schief, und was hilft?

1.1 Wie verbreitet ist KI-Nutzung?

Für Studierende sind Sprachmodelle zum Standard geworden, und sie nutzen sie von Jahr zu Jahr intensiver. In einer britischen Befragung (1.054 Vollzeitstudierende, Dezember 2025) nutzten 95 % KI in irgendeiner Form und 94 % auch für Prüfungsleistungen; der Anteil, der KI-Text direkt in die Abgabe übernahm, stieg binnen eines Jahres von 3 auf 12 % (Stephenson & Armstrong, 2026). Neuere deutsche Umfragen unter Studierenden zeigen denselben Trend: Im Wintersemester 2025/26 nutzten 81 Prozent KI-Werkzeuge mindestens wöchentlich (Vorjahr 65 Prozent) und 47 Prozent täglich (Vorjahr 25 Prozent); ganz ohne KI studierten nur noch 2 Prozent (Vorjahr 6 Prozent) (28.584 Studierende an 202 Hochschulen, vor allem Wirtschafts- und Rechtswissenschaften; im Vorjahr andere Fächer, der Vergleich ist daher nur ein Anhaltspunkt) (Horstmann et al., 2026; Hüsch et al., 2025). Die Hälfte nutzte KI regelmäßig als Tutor oder Lernpartner, mit großen Fachunterschieden zwischen Wirtschaftsinformatik (72 Prozent) und Jura (19 Prozent) (Horstmann et al., 2026). Die britischen Befunde zeigen zugleich eine gespaltene Studierendenschaft: Die einen gewinnen Zeit für tieferes Lernen, andere lagern es aus („I'm not using my brain at all“) (Stephenson & Armstrong, 2026).

Genutzt wird vor allem auf den oberen Stufen. Eine Auswertung von einer Million anonymisierter Chats mit Universitätskonto zeigt, dass Studierende die Modelle vor allem zum **Erstellen neuer Inhalte und zum Analysieren komplexer Themen** einsetzen, also auf den höheren Ebenen der Bloomschen Taxonomie (Abbildung 1.1) (Handa et al., 2025).

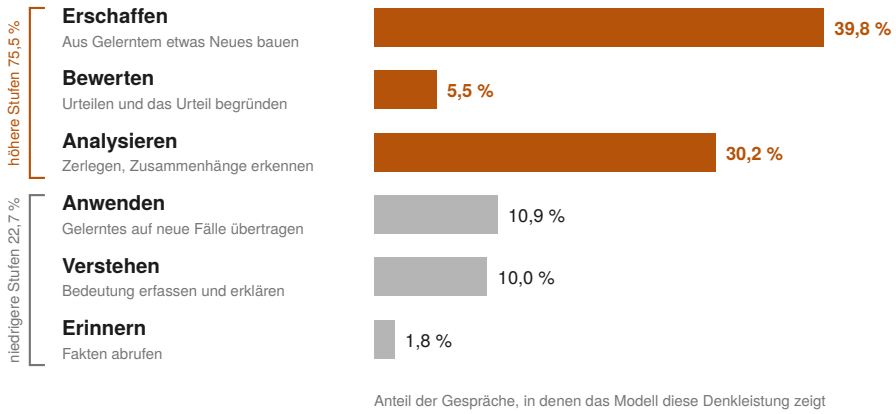


Abbildung 1.1. Drei Viertel der Gespräche verlangen Denkleistungen der höheren Stufen: Anteil der Gespräche von Studierenden mit Claude, in denen das Modell die jeweilige Stufe der Bloomschen Taxonomie zeigt. Daten: Handa et al. (2025); eigene Darstellung und Stufenbeschreibungen.

Auf den produktiven Umgang fühlen sich viele Studierende noch schlecht vorbereitet, auch wenn die Hochschulen aufholen. Das Angebot ihrer Hochschule zum Erwerb von KI-Kompetenzen bewerteten deutsche Studierende im Wintersemester 2025/26 mit 3,3 von 5 Sternen, ein Jahr zuvor mit 2,7; knapp ein Drittel vergab nur einen oder zwei Sterne (Stichproben wie oben) (Horstmann et al., 2026; Hüsch et al., 2025). International hält nur ein knappes Drittel der Studierenden die eigenen Lehrenden für gut gerüstet, sie beim KI-Einsatz anzuleiten, und 57 Prozent finden die Hinweise zur KI-Nutzung bei ihren Prüfungen unzureichend (27.284 Studierende in 35 Ländern, 2026) (Digital Education Council, 2026). Hochschulen müssen deshalb den Umgang mit den Werkzeugen lehren und, weil fast alle Studierenden KI auch für Prüfungsleistungen nutzen, ihre Prüfungen anpassen.

Ihre Einschätzung prüfen

„Fast alle Studierenden nutzen KI inzwischen auch für Prüfungsleistungen."
Auflösung: ja. In einer britischen Befragung (1.054 Studierende, Dezember 2025) nutzten 94 % KI auch für Prüfungsleistungen. Auf den

produktiven Umgang fühlen sich viele aber schlecht vorbereitet: Dass Studierende KI nutzen, heißt nicht, dass sie es gut tun.

Bei den Lehrenden ist die Spanne weit, doch die Nutzung holt auf. In einer bundesweiten Befragung (626 Hochschullehrende, Dezember 2024 bis Januar 2025) nutzten 12 Prozent KI in der Lehre gar nicht, weitere 33 Prozent selten oder sehr selten und knapp 15 Prozent sehr häufig. Mit Abstand am häufigsten genannt wurde die kostenlose Version von ChatGPT (66 Prozent), die Bezahlversion nur von 23 Prozent (von Garrel et al., 2026). International stieg der Anteil der Lehrenden, die KI in der Lehre einsetzen, binnen eines Jahres von 61 auf 77 Prozent, in Europa, Nahost und Afrika von 62 auf 78 Prozent; die Studierenden liegen mit 88 Prozent weiter vorn (18.114 Lehrende und 27.284 Studierende in 35 Ländern, 2026; Teilnahme über Mitgliedshochschulen, also keine Zufallsstichprobe) (Digital Education Council, 2025, 2026). Neuere deutsche Daten zeigen die Kehrseite: Rund 84 Prozent der Lehrenden nutzten KI im Zusammenhang mit ihrer Lehre, aber 65 Prozent untersagten sie Studierenden in Prüfungen ausdrücklich, und erst 35 Prozent hatten ihre Prüfungen an KI angepasst (1.243 Lehrende an 20 Hochschulen in Niedersachsen, September bis Dezember 2025; vermutlich überdurchschnittlich am Thema interessiert) (Schmidt, 2026). Ein Review von fünfzehn deutschen Studien findet entsprechend, dass Lehrende KI seltener und selektiver nutzen als Studierende (Bosse et al., 2026).

In Workshops mit Lehrenden zeigt sich: Auch wer KI häufig nutzt, nutzt sie meist **unsystematisch**. Die Arbeit findet fast nur im **Chatfenster** statt, man übernimmt, was brauchbar wirkt, und beginnt beim nächsten Mal von vorn, ohne Vorlagen, eigene Quellensammlungen, Projekte oder Agenten. Ethan Mollick nennt diese Lücke den **Fähigkeitsüberhang** (*capability overhang*): den Abstand zwischen dem, was die Modelle können, und dem, was fast alle mit ihnen tun (E. Mollick, 2026b). Für die Lehre heißt das: Wer mehr erreichen will, muss nicht auf bessere Modelle warten, sondern die vorhandenen anders nutzen.

1.1.1 Höher oder tiefer: Wofür Menschen KI tatsächlich nutzen

Umfragen messen, was Menschen über ihre Nutzung sagen. Der *Anthropic Economic Index* misst etwas anderes: Er ordnet Gespräche mit dem KI-Assistenten Claude automatisch Arbeitsaufgaben der US-Berufsdatenbank O*NET zu und veröffentlicht, welcher Anteil der Gespräche eines Monats

auf jede Aufgabe entfällt (Massenkoff et al., 2026).[1] Die folgende Übung stellt Ihre Vermutung gegen diese beobachtete Nutzung. Raten Sie zuerst und schauen Sie erst dann auf die Auflösung: Wer vorher rät, behält die richtige Antwort besser, auch wenn der eigene Tipp falsch war (Richland et al., 2009). Bei jedem Paar setzen Sie ein, wie sicher Sie sind, und spielen gegen ein Sprachmodell, das dieselben Paare ohne Zugriff auf die Daten getippt hat. Die Übung dauert etwa sechs Minuten.

Raten Sie zuerst

Welche der beiden Aufgaben kam im Mai 2026 in Gesprächen mit Claude häufiger vor? Kreuzen Sie A oder B an und notieren Sie, wie sicher Sie sind (1 geraten, 2 eher sicher, 3 sicher).

Paar 1. A: Informationen in elektronischen oder gedruckten Quellen suchen · B: Texte schreiben, etwa Geschichten, Artikel, Kommentare oder Newsletter

Ihr Tipp: ☐ A ☐ B Sicherheit: ☐ 1 ☐ 2 ☐ 3

Paar 2. A: Unterrichtsmaterial entwickeln, etwa Stundenentwürfe, Handouts oder Prüfungen · B: Studentische Arbeiten, Aufgaben und Hausarbeiten bewerten und benoten

Ihr Tipp: ☐ A ☐ B Sicherheit: ☐ 1 ☐ 2 ☐ 3

Paar 3. A: Juristische Dokumente entwerfen oder prüfen, etwa Verträge, Schriftsätze, Testamente · B: Menschen ermutigen, über Gefühle und ihre Lebenslage zu sprechen

Ihr Tipp: ☐ A ☐ B Sicherheit: ☐ 1 ☐ 2 ☐ 3

Wer fragt? Wer hat die Gespräche zu „Studentische Arbeiten, Aufgaben und Hausarbeiten bewerten und benoten“ geführt?

☐ (a) Lehrende ☐ (b) Studierende ☐ (c) Das lässt sich aus den Daten nicht sagen.

Das vollständige Spiel mit sieben Paaren und Modell-Mitspieler gibt es in der Online-Version: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/kapitel01-einleitung.html#sec-spiel-ki-aufgaben aufrufen. Die Lösung steht in den Lösungshinweisen im Anhang (Anhang B).

[1] Datensatz `Anthropic/EconomicIndex` auf Hugging Face, Release vom 26. Juni 2026, Datei `aei_claude_ai_2026-06-26.csv`, Datenmonat Mai 2026, weltweit, Lizenz CC BY; abrufbar über Hugging Face, Anthropic/EconomicIndex. Auszug, Paarauswahl und Übersetzung: `scripts/aei-hoeher-tiefer.py` im Repositorium des Buchs.



Die Daten zeigen Gesprächsinhalte, nicht die Menschen dahinter. Was als Bewerten und Benoten zählt, kann eine Professorin ebenso geschrieben haben wie ein Student, der seinen Entwurf vorab prüfen lässt; und als Momentaufnahme eines Monats und eines Anbieters sagt der Index nichts darüber, welche Jobs KI verändert.

> **i** So entstand dieses Spiel
>
> Gebaut hat es ein Agent (Claude Opus 5.5) in einer Sitzung von gut einer halben Stunde, auf einen Auftrag hin, der auf eine schriftliche Bauanleitung verwies: „Lies [die Übersicht] und [den Auftrag] und setze S1 vollständig um." Er lud den öffentlichen Datensatz, zog die Werte per Skript und ließ ein frisches Modell die Paare tippen. Die Schwäche: Die Überraschungspaare wählte derselbe Modelltyp aus, der danach als Mitspieler tippte; er lag nur bei 2 von 15 Paaren richtig. Eine Prompt-Vorlage für ein solches Spiel in Ihrem Fach steht am Ende der Übung.

1.2 Was geht schief?

Die Metapher mit dem E-Bike trägt auch die Nebenwirkung: Wer nur noch mit Motor fährt, verliert Muskeln. Das zeigt sich zuerst beim Üben. In einem Feldexperiment mit knapp tausend Oberstufenschülern verbesserte ein Tutor im Stil des normalen ChatGPT die Übungsleistung um 48 Prozent; als der Zugang in der Prüfung fehlte, lagen dieselben Schüler 17 Prozent *unter* der Kontrollgruppe, die nie Zugang hatte (Bastani et al., 2025). Die Übungen waren gelöst, gelernt war weniger als ohne Hilfe.

Die Arbeit verschiebt sich vom Erarbeiten zum Prüfen. In einer Befragung von 319 Wissensarbeitern (*knowledge workers*) sank mit Sprachmodellen der Aufwand für die Recherche selbst, während Koordination, kritische Prüfung der Ergebnisse und ihre Integration in ein Gesamtergebnis mehr Gewicht bekamen (Lee et al., 2025). Anders als die Websuche, bei der man einzelne

dornige Zweige erntet, liefert das Sprachmodell **das ganze Aufgabenbündel fertig verschnürt**. Wer per Chatbot statt per Suchmaschine recherchiert, setzt sich entsprechend weniger kritisch mit dem Thema auseinander (Mittal et al., 2026, Preprint). Ein vielgelesener Artikel trägt den Titel „Everyone Is Cheating Their Way Through College“ (Walsh, 2025); der Titel lenkt den Blick auf die Messung, die größere Gefahr liegt beim Lernen selbst.

> Ihre Einschätzung prüfen
>
> *„Die größte Gefahr generativer KI für das Lernen besteht darin, dass Studierende in Prüfungen täuschen.“*
> **Auflösung: eher nicht.** Täuschen verfälscht die Messung einer Leistung. Wer dagegen das Denken auslagert, übt die geprüften Schritte nie und lernt sie nicht, wie der Einbruch um 17 Prozent in der Prüfung zeigt. Was dabei verloren geht, nennt die Lernforschung erwünschte Schwierigkeiten (*desirable difficulties*) (Kapitel 1.3).

Viele Lehrende unterschätzen KI, weil sie mit schwachen Zugängen arbeiten. „KI nutzen“ heißt seit Ende 2025 Delegation an Agenten, die Werkzeuge einsetzen, mehrstufig arbeiten und Zwischenergebnisse selbst prüfen (E. Mollick, 2026a) (Kapitel 2.1.2). Kostenlose Tarife und „Auto“-Auswahl liefern dagegen oft schwächere Modellvarianten ohne Reasoning (schrittweises Nachdenken) und mit kleinem Werkzeugkasten (*harness*), und genau diesen Zugang nutzen die meisten Lehrenden: Wer am Modell spart, spart am Ergebnis.

> Ihre Einschätzung prüfen
>
> *„Wer mit der kostenlosen Version eines Chatbots in seinem Fach schlechte Ergebnisse erhält, weiß, was KI dort leisten kann.“*
> **Auflösung: nein.** Kostenlose und automatisch gewählte Varianten antworten oft ohne Nachdenkphase und ohne Werkzeuge. Was ein Sprachmodell im eigenen Fach leistet, zeigt erst ein starkes Modell mit passender Oberfläche und Werkzeugkasten (Kapitel 2.1.2).

1.3 Was hilft?

So schlimm muss es nicht werden. Im selben Experiment gab ein zweiter Tutor Hinweise statt Lösungen: Er hob die Übungsleistung um 127 Prozent und ließ in der Prüfung keinen Schaden zurück (Bastani et al., 2025). Lehre kann also erwünschte Schwierigkeiten im Sinne von Bjork & Bjork (2011) erhalten, auch wenn die Studierenden zu Hause starke Modelle nutzen. Die Forschung seit 2025 nennt drei Bedingungen dafür; Kapitel 4.5 stellt sie ausführlich dar.

Die Einbettung trägt, nicht das Werkzeug. In einer randomisierten Studie in 83 indischen Internatsschulen erhielten alle Zugang zur selben Lernplattform; Lerngewinne von fast einer halben Standardabweichung in Mathematik entstanden nur dort, wo betreute Lernzeiten mit Aufsichtspersonen eingeplant waren (Oreopoulos et al., 2026). **Anleitung wirkt, Ermutigung nicht:** In einem Ökonometrie-Kurs änderte die Ermutigung zum Tutor nichts, eine Anleitung zur tutoriellen Nutzung hob die Prüfungsleistung um 0,21 Standardabweichungen und die Bestehensquote um zwölf Prozentpunkte (Gallegos, 2026).

> **Ihre Einschätzung prüfen**
>
> *„Ein KI-Tutor verbessert das Lernen, sobald die Studierenden Zugang zu ihm erhalten."*
> **Auflösung: nein.** Der Zugang allein bewirkt wenig. Lerngewinne entstehen, wo die Nutzung in betreute Lernzeiten eingebettet und angeleitet wird und wo der Tutor Hinweise statt fertiger Lösungen gibt.

Die Leitplanke (*guardrail*) gehört in Aufgabe und Rückmeldung. Eine Rückmeldung, die Lernenden zeigt, was das Abschreiben einer KI-Lösung für ihr eigenes Können bedeutet, halbierte in einem Experiment die Auslagerung (*cognitive offloading*) (Maier et al., 2026); Feedback, das zuerst zur Reflexion auffordert und die Kritik danach liefert, schnitt beim späteren Transfer ohne KI besser ab als direkte KI-Kritik (Ates, 2026). Ein Beispiel aus der Praxis ist das „AI-Sandwich" von Jon Ippolito, in dem selbst geführte Interviews zum Maßstab für den KI-Text werden (Kapitel A.5.1).

Auf der Ebene des Studiengangs kommen vier Hebel hinzu: Prüfungen nach den vier Säulen Mündlichkeit, Prozessorientierung, Kontextualisierung und Kollaboration (Kapitel 5.5), Richtlinien im Rahmen der KI-Verordnung (*AI*

Act) (Kapitel 5.4.1.2), eine Dokumentation der KI-Nutzung durch die Studierenden (Kapitel 5.4.2) und die Integration in den ganzen Kurs (Kapitel 5.6).

1.4 Was Sie im Buch erwartet

In den Workshops kehren drei Fragen immer wieder. Seit 2024 führen diese Workshops, vor allem im Netzwerk für hochschuldidaktische Weiterbildung (hdw nrw), Lehrende aus nahezu allen Fächergruppen zusammen. Die erste Frage ist eine Sorge: Entwertet KI Hausarbeiten, deren Ergebnis ein Sprachmodell in Minuten liefert, die **„Homework Apocalypse"** (E. R. Mollick, 2023)? Die zweite ist praktisch: Wie hilft KI bei Recherche, Aufgabenerstellung und Rückmeldung? Die dritte ist Neugier: Was wird möglich, das bisher zu aufwendig war, etwa Simulationen, in denen Studierende verhandeln oder ein Unternehmen steuern (E. R. Mollick & Mollick, 2024)? Das Buch beantwortet sie über **vier Rollen der KI** (Kapitel 6): als **Hiwi**, der Ihnen zuarbeitet (Kapitel 6.1), als **Copilot**, mit dem Studierende schreiben und programmieren (Kapitel 6.2), als **Tutor**, der erklärt und abfragt (Kapitel 6.3), und als **Simulator**, der ein Gegenüber spielt (Kapitel 6.4). Mit der Rolle wechselt, wer das Ergebnis prüft.

Darunter liegen die Grundbegriffe (Kapitel 2) und die Lernmechanismen (Kapitel 4), darauf bauen die Umsetzung in Prüfung und Kurs (Kapitel 5) und die Beispiele aus der eigenen Lehre (Kapitel 7). Dort bauen Studierende mit Praxispartnern Assistenten, die auf den Dokumenten eines Unternehmens antworten (Kapitel 7.3.5), und entwickeln Tutoren, Planspiele und Karriereberater für andere Studierende (Kapitel 7.2.2, Kapitel 7.3.3, Kapitel 7.3.4). Die Anhänge sammeln Prompts, also Eingaben an die KI (Anhang A), und Lösungshinweise (Anhang B). Welche Kapitel Sie davon brauchen, hängt von Ihrem Vorwissen ab; das Vorwort führt dazu mit einem Selbsttest zu einem von vier Lernpfaden.

> **i** Fünf Fragen, die dieses Buch beantwortet
>
> 1. Warum schadet ein Chatbot, der jede Übungsfrage richtig beantwortet, dem Lernen? (Kapitel 4)
> 2. Wann ist die KI Ihr Hiwi, wann der Tutor Ihrer Studierenden, und warum wechselt damit die Verantwortung? (Kapitel 6)

3. Was muss beim Menschen bleiben, wenn man eine Aufgabe an einen Agenten delegiert? (Kapitel 2.4.2)
4. Warum hilft ein Lied beim Merken einer Formel, aber nicht beim Anwenden? (Kapitel 7.1.2)
5. Wie echt muss ein simuliertes Gegenüber sein, damit Studierende daran üben? (Kapitel 6.4)

Fünf Formate zeigen, was 2026 mit KI entsteht: eine Prozessanimation, in der sich vor dem Engpass die Arbeit staut (Goldratt & Cox, 2014; Little, 1961), eine Präsentationsfolie nach Regelwerk, ein Lernsong, ein Lernspiel und ein Rollenspiel. Blättern Sie mit den Pfeilen; unter jedem Beitrag führt ein Link zur Stelle im Buch.

Abbildung 1.2. Galerie „Fünf Formate, die 2026 mit KI entstehen“: Engpass-Animation (Kapitel 6.2.2.3), Präsentationsfolie mit Regelwerk, Lernsong zu Prognoseverfahren (Kapitel 7.1.2), Zuordnungsspiel (Kapitel 7.1.3) und KI-Rollenspiel (Kapitel 6.4.1). Dieses interaktive Element gibt es nur in der Online-Version: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/galerie-kapitel01.html aufrufen.

Kernaussagen

Zu Lernziel 1: Lehrprobleme und Verbreitung

1. Generative KI ist für die Lehre ein Kraftverstärker: Der Berg bleibt, aber mit dem E-Bike kommt man weiter. Sie senkt vor allem den Aufwand für Methoden, die didaktisch wirksam, aber zeitintensiv sind.

2. Studierende nutzen Sprachmodelle flächendeckend und immer intensiver, auch für Prüfungsleistungen, fühlen sich aber auf den produktiven Umgang oft schlecht vorbereitet. Bei Lehrenden wächst die Nutzung, die Spanne reicht aber weiterhin von intensiver Nutzung bis zu keiner; genutzt wird meist unsystematisch und im Chatfenster. Der Fähigkeitsüberhang ist groß.

Zu Lernziel 2: Was schiefgeht

3. Die Hauptgefahr ist nicht das Täuschen, sondern die Auslagerung des Denkens: Ein Tutor ohne Leitplanken hebt die Übungsleistung und senkt die Prüfungsleistung.
4. Schwache Zugänge verzerren das Urteil. „KI nutzen“ heißt Delegation an Agenten mit Werkzeugen; wer mit kostenlosen Varianten ohne Reasoning und Werkzeuge arbeitet, hält deren Schwächen für die Grenzen der Technik.

Zu Lernziel 3: Was hilft

5. Über die Lernwirkung entscheiden Einbettung, Anleitung und Gestaltung, nicht der Zugang zum Werkzeug: betreute Lernzeiten, angeleitete statt nur ermutigte Nutzung und Leitplanken in Aufgabe und Rückmeldung, die erwünschte Schwierigkeiten erhalten.

i Schlüsselbegriffe

Erklären Sie jeden Begriff in zwei, drei Sätzen in eigenen Worten; die Seitenzahl führt zur Stelle, an der er eingeführt wird.

- Häufige kleine Tests (*practice testing*) ..... S. 15
- Fähigkeitsüberhang (*capability overhang*) ..... S. 17
- Agent ..... S. 20
- Reasoning (schrittweises Nachdenken) ..... S. 20
- Werkzeugkasten (*harness*) ..... S. 20
- Erwünschte Schwierigkeiten (*desirable difficulties*) ..... S. 21
- Anleitung statt Ermutigung (*guidance*, *encouragement*) ..... S. 21
- Leitplanke (*guardrail*) ..... S. 21
- Auslagerung des Denkens (*cognitive offloading*) ..... S. 21

- Vier Rollen der KI (Hiwi, Copilot, Tutor, Simulator) ..... S. 22

Übung. Tragen Sie zu jeder Szene den passenden Begriff aus der Liste ein. Lösungen: Anhang B.

Nr.	Szene	Begriff
1	Im Workshop arbeiten fast alle Teilnehmenden nur im Chatfenster und beginnen jedes Mal von vorn, ohne Vorlagen, Projekte oder Agenten. *Herkunft: Workshops mit Lehrenden* (*Kapitel 1.1*).	
2	Beim Testlauf vor dem Semester bittet eine Testerin den Tutor-Bot dreimal um die Lösung einer Übungsaufgabe; er verlangt jedes Mal zuerst einen eigenen Versuch. *Herkunft: konstruiert nach dem Prüfkriterium für den Tutor-Bot im Modul „Grundlagen der BWL“* (*Kapitel 7.2.2*).	
3	Im Simulationsprojekt darf die KI Code schreiben, aber jedes Teammitglied muss jede Codezeile erklären können. Welches Risiko wehrt die Regel ab? *Herkunft: Regel im Gruppenprojekt mit Produktionssimulation* (*Kapitel 7.3.3*).	
4	Ein Erstsemesterteam leitet die Grundanweisung seines KI-Bewerbungstrainers aus dem Lernkonzept ab, nach dem Hürden beim Üben das Behalten stärken. *Herkunft: Karriereberater-Projekte im ersten Semester* (*Kapitel 7.3.4*).	
5	Mehrere Teams geben ihrem Karriere-Bot die Jobsuche-Schnittstelle der Bundesagentur für Arbeit und eine regelbasierte Zuordnung auf Moduldaten mit; das Sprachmodell sortiert die Treffer nur und begründet sie. *Herkunft: Karriereberater-Projekte im ersten Semester* (*Kapitel 7.3.4*).	

6 Eine Professorin probiert die kostenlose Version eines Chatbots, die ohne Nachdenkphase sofort antwortet; schon die erste Lösung ist falsch.
Herkunft: nach der Eingangsszene dieses Kapitels, die aus Gesprächen in Workshops zusammengesetzt ist.

Lernfragen

Wiederholen

1. Bei welchen zwei Lehrproblemen kann generative KI helfen?
2. Warum ist für das Lernen die Auslagerung des Denkens gefährlicher als das Täuschen in Prüfungen, und welches Konzept der Lernforschung beschreibt, was dabei verloren geht?

Anwenden

3. Ihre Hochschule schaltet allen Studierenden einen KI-Tutor frei. Welche zwei Bedingungen aus Kapitel 1.3 müssten Sie in Ihrem Kurs schaffen, damit daraus Lernwirkung entsteht, und wie sähe das konkret aus?
4. Welche Lehrmethode haben Sie in den letzten Semestern aus Zeitgründen nicht umgesetzt, obwohl Sie von ihrer Wirkung überzeugt sind? Welchen Teil des Aufwands könnte ein Sprachmodell übernehmen, und welcher Teil muss bei Ihnen bleiben?

Beurteilen

5. Bei welcher Aufgabe in Ihrer Lehrveranstaltung würde ein Studierender durch KI-Nutzung am meisten an Lernwirkung verlieren? Woran würden Sie das erkennen?
6. Ermutigung zur KI-Nutzung änderte in einer Studie nichts, Anleitung hob die Prüfungsleistung. Lesen Sie, was Ihre Kursbeschreibung oder Ihre erste Sitzung zum Thema KI sagt: Ist das Ermutigung oder Anleitung, und was müsste sich ändern?

Lösungshinweise: Anhang B.

Literaturverzeichnis

Ates, H. (2026). Human-centered GenAI feedback design in higher education: A multisite experiment on direct, reflective, and hybrid approaches to scientific argumentation. *International Journal of Educational Technology in Higher Education*, *23*(38). https://doi.org/10.1186/s41239-026-00614-9.

Bastani, H., Bastani, O., Sungu, A., Ge, H., Kabakcı, Ö., & Mariman, R. (2025). Generative AI without guardrails can harm learning: Evidence from high school mathematics. *Proceedings of the National Academy of Sciences*, *122*(26), e2422633122. https://doi.org/10.1073/pnas.2422633122.

Bjork, E. L., & Bjork, R. A. (2011). Making things hard on yourself, but in a good way: Creating desirable difficulties to enhance learning. In M. A. Gernsbacher, R. W. Pew, L. M. Hough, & J. R. Pomerantz (Hrsg.), *Psychology and the real world: Essays illustrating fundamental contributions to society*: (S. 56–64). Worth Publishers.

Bosse, E., Wannemacher, K., & Lübcke, M. (2026). *Die KI-Nutzung in Studium und Lehre: Ein Review auf Grundlage empirischer Studien*. Hochschulforum Digitalisierung.

Brown, P. C., Roediger, H. L., & McDaniel, M. A. (2014). *Make it stick: The science of successful learning*. The Belknap Press of Harvard University Press.

Digital Education Council (2025). *Global AI Faculty Survey 2025*. Digital Education Council.

Digital Education Council (2026). *AI in Higher Education Global Survey 2026*. Digital Education Council.

Dunlosky, J., Rawson, K. A., Marsh, E. J., Nathan, M. J., & Willingham, D. T. (2013). Improving Students' Learning With Effective Learning Techniques: Promising Directions From Cognitive and Educational Psychology. *Psychological science in the public interest : a journal of the American Psychological Society*, *14*(1), 4–58. https://doi.org/10.1177/1529100612453266.

Gallegos, S. (2026). *Guidance over adoption: Experimental evidence on AI-assisted learning* (IZA Discussion Paper; Nr. 18513). Institute of Labor Economics (IZA).

Goldratt, E. M., & Cox, J. (2014). *The goal: A process of ongoing improvement*. North River Press.

Handa, K., Bent, D., Tamkin, A., McCain, M., Durmus, E., Stern, M., Schiraldi, M., Huang, S., Ritchie, S., Syverud, S., Jagadish, K., Vo, M., Bell, M., & Ganguli, D. (2025). *Anthropic Education Report: How university students use Claude*. Anthropic.

Hattie, J. (2023). *Visible learning, the sequel: a synthesis of over 2,100 meta-*

analyses relating to achievement. Routledge, Taylor & Francis Group. https://doi.org/10.4324/9781003380542.

Horstmann, N., Hüsch, M., & Breiter, A. (2026). *Künstliche Intelligenz im Studium – Die Sicht von Studierenden im Wintersemester 2025/26*. CHECK, CHE Centrum für Hochschulentwicklung. https://hochschuldaten.che.de/kuenstliche-intelligenz-im-studium-die-sicht-von-studierenden-im-wintersemester-2025-26/.

Hüsch, M., Horstmann, N., & Breiter, A. (2025). *Künstliche Intelligenz im Studium: Die Sicht von Studierenden im Wintersemester 2024/25*. CHE Centrum für Hochschulentwicklung.

Lee, H.-P. H., Sarkar, A., Tankelevitch, L., Drosos, I., Rintel, S., Banks, R., & Wilson, N. (2025). The Impact of Generative AI on Critical Thinking: Self-Reported Reductions in Cognitive Effort and Confidence Effects From a Survey of Knowledge Workers. https://doi.org/10.1145/3706598.3713778.

Little, J. D. C. (1961). A proof for the queuing formula: L = λW. *Operations Research*, *9*(3), 383–387. https://doi.org/10.1287/opre.9.3.383.

Maier, S., Schwabe, K., Schneider, M., & Feuerriegel, S. (2026). *Designing against deskilling: Metacognitive feedback reduces cognitive offloading to LLM assistants*. https://doi.org/10.48550/arXiv.2609.20143.

Massenkoff, M., Lyubich, E., Sacher, S., Hitzig, Z., Zhang, S., Heller, R., & McCrory, P. (2026). *Anthropic Economic Index report: Cadences*. Anthropic.

McAfee, A. (2024). *Generally Faster: The Economic Impact of Generative AI* (Davos Report). Google.

Meincke, L., Mollick, E. R., & Terwiesch, C. (2024). *Prompting Diverse Ideas: Increasing AI Idea Variance*. https://papers.ssrn.com/abstract=4708466.

Mittal, S., Blodgett, S. L., & Liao, Q. V. (2026). Learning by chatting? Investigating the impact of generative AI on information seeking and learning. https://doi.org/10.48550/arXiv.2606.11669.

Mollick, E. (2026a, Februar 18). A Guide to Which AI to Use in the Agentic Era. https://www.oneusefulthing.org/p/a-guide-to-which-ai-to-use-in-the?post_id=188100833&r=2248w9.

Mollick, E. (2026b, September 18). The overhang. https://www.oneusefulthing.org/p/the-overhang.

Mollick, E. R. (2023, Juli 1). The Homework Apocalypse. https://www.oneusefulthing.org/p/the-homework-apocalypse.

Mollick, E. R., & Mollick, L. (2023). *Assigning AI: Seven Approaches for Students, with Prompts*. arXiv. https://doi.org/10.48550/arXiv.2306.10052.

Mollick, E. R., & Mollick, L. (2024). *Instructors as Innovators: a Future-focused*

Approach to New AI Learning Opportunities, With Prompts. https://doi.org/10.2139/ssrn.4802463.

Oreopoulos, P., Keyes-Krysakowski, O., & Agarwal, D. (2026). *How In-School Supervised Ed-Tech Support Produces Massive Learning Gains: A Khan Academy Field Experiment in India* (NBER Working Paper; Nr. 34683). National Bureau of Economic Research. https://doi.org/10.3386/w34683.

Richland, L. E., Kornell, N., & Kao, L. S. (2009). The pretesting effect: Do unsuccessful retrieval attempts enhance learning? *Journal of Experimental Psychology: Applied*, *15*(3), 243–257. https://doi.org/10.1037/a0016496.

Schmidt, A. K. (2026, Juni 15). Erkenntnisse zu KI-Einsatz und KI-Bedarfen von Lehrenden an niedersächsischen Hochschulen. https://lehrportal.uni-osnabrueck.de/2026/06/15/erkenntnisse-zu-ki-einsatz-und-ki-bedarfen-von-lehrenden-an-niedersaechsischen-hochschulen/.

Stephenson, R., & Armstrong, C. (2026). *Student generative artificial intelligence survey 2026* (Nr. 199). Higher Education Policy Institute.

von Garrel, J., Mayer, J., & Weber, L. S. (2026). Wie Hochschullehrende künstliche Intelligenz im Studium nutzen – Ergebnisse einer bundesweiten Befragung. *Die Neue Hochschule*, (1), 16–19. https://doi.org/10.5281/zenodo.18017027.

Walsh, J. D. (2025). Everyone is cheating their way through college: ChatGPT has unraveled the entire academic project. *New York Magazine*.

2 Grundlagen von KI und LLMs

In diesem Kapitel

- Grundbegriffe: Modell, Harness und Agent
- Welches Modell?
- Description: Wie sage ich der KI, was ich will?
- Das erweiterte LLM
- Ressourcenverbrauch der Modelle
- Vertiefung: Was im Modell und im Harness passiert

Dr. Miriam Kessler lehrt Statistik für 300 Studierende der Psychologie und will zum Semesterstart einen Chatbot anbieten, der Fragen zu ihrem Skript beantwortet. Ein Kollege rät zu einem Agenten mit Internetzugang, ein anderer schwört auf seinen Prompt-Anfang: „Du bist ein Weltklasse-Statistiker, ich gebe dir 200 Dollar Trinkgeld." Beim Testen löst das Modell eine Regressionsaufgabe tadellos und verzählt sich danach bei den Buchstaben eines Fachbegriffs. Dann zeigt ihr eine Studentin eine Literaturangabe, die der Chatbot ihr genannt hat, mit Autor, Jahr und Titel. Im Bibliothekskatalog ist der Titel nicht zu finden, denn der Chatbot hat ihn erfunden. Kessler fragt sich nun, ob sie ihren Studierenden ein Werkzeug empfehlen kann, das erfundene Quellen genauso überzeugt vorträgt wie echte.

Die Szene ist aus Gesprächen in Workshops mit Lehrenden zusammengesetzt.

Bevor Sie weiterlesen: Wie sehen Sie das?

Wie sehr stimmen Sie den vier Aussagen zu? Jede Aussage wird an der Stelle im Kapitel aufgelöst, die sie beantwortet. Wer sich vorher festlegt, liest gezielter.
1. Wenn ein Modell die schwierigen Aufgaben Ihres Fachs löst, können Sie sich bei den leichteren erst recht auf es verlassen.
stimme zu 1 – 2 – 3 – 4 – 5 *stimme nicht zu*
(Auflösung in Kapitel 5.2.1)
2. Ein Chatbot, der nur aus Ihrem Skript antworten soll, braucht keinen Agenten; es genügt ein Modell, das vor jeder Antwort passende Stellen aus dem Skript abruft.
stimme zu 1 – 2 – 3 – 4 – 5 *stimme nicht zu*
(Auflösung in Kapitel 2.4.1)
3. Höflichkeit, Drohungen oder ein versprochenes Trinkgeld verbessern die Antworten eines Sprachmodells nicht zuverlässig.
stimme zu 1 – 2 – 3 – 4 – 5 *stimme nicht zu*
(Auflösung in Kapitel 2.3.4)
4. Dass ein Chatbot Quellen erfindet, ist ein Programmfehler, den die nächsten Modellversionen abstellen.
stimme zu 1 – 2 – 3 – 4 – 5 *stimme nicht zu*
(Auflösung in Kapitel 5.3)

Lernziele: Nach diesem Kapitel können Sie …

1. das 4D-Modell als Ordnung für die Arbeit mit KI erklären und Modell, Harness und Agent abgrenzen;
2. mit der Jagged Frontier begründen, welche Aufgaben einer Lehrveranstaltung an die KI gehen, und dafür Setup (reines Sprachmodell, LLM; Sprachmodell mit Suche in eigenen Dokumenten, RAG; Agent), Modell und Arbeitsweise wählen (Delegation);
3. einen Prompt als Auftrag mit Ziel, Grund, Material und Abnahmekriterium formulieren und verbreitete Prompt-Tricks als wirkungslos erkennen (Description);
4. in Laiensprache erklären, warum Sprachmodelle halluzinieren, Ergebnisse prüfen und Verantwortung, Offenlegung und Energiebedarf einordnen (Discernment, Diligence).

Die Kernaussagen am Kapitelende sind nach diesen vier Zielen geordnet. Die Vertiefung zur Technik in Kapitel 2.6 setzen sie nicht voraus; sie kann über-

sprungen werden.

2.1 Grundbegriffe: Modell, Harness und Agent

Keine der vier Fragen lässt sich stellen, ohne Modell, Harness und Agent auseinanderzuhalten; für die didaktische Nutzung genügt es, die drei Begriffe ohne Formeln zu klären.

Welche der Fachbegriffe kennen Sie schon? Von Prompt bis Token, über Temperatur bis zur Suche in eigenen Dokumenten (RAG): Testen Sie sich selbst mit dem folgenden kleinen Spiel.

Lernspiel: Welche Grundbegriffe kennen Sie schon?

Ordnen Sie die Begriffe den korrekten Definitionen zu! Am Start wählen Sie zwischen *Grundbegriffen* und dem Level *Fortgeschritten* mit Agenten-Begriffen und einer Diagnose-Runde zu typischen Problemen wie *Cognitive Debt*, *Sycophancy* oder *Prompt Injection*.

Abbildung 2.1. Lernspiel „Welche Grundbegriffe kennen Sie schon?“ (Zuordnung von Begriffen und Definitionen). Dieses interaktive Element gibt es nur in der Online-Version: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/llm-game-standalone.html aufrufen.

2.1.1 Was ein Sprachmodell tut

Generative KI ist ein Teilgebiet der KI, also des Versuchs, menschliches Denken und Verhalten nachzubilden (Russell & Norvig, 2021); dieses Buch verwendet KI, generative KI (GenAI) und Sprachmodell weitgehend synonym. Ein **Sprachmodell** (*Large Language Model*, LLM) ist ein Rechensystem, das das nächste Wort in einer Wortkette vorhersagt, gestützt auf die Wörter davor (Jurafsky & Martin, 2025, Kap.7, S. 2); generativ heißt es, weil es auf diese Weise Texte erzeugt, die es vorher nicht gab. Dabei prüft es keine Wahrheit, sondern schreibt fort, was wahrscheinlich ist; daraus folgen seine Stärken ebenso wie seine erfundenen Quellen (Kapitel 5.3). Wie aus Text Zahlen und aus Zahlen das nächste Wort werden, zeigt die Vertiefung in Kapitel 2.6.1.

2.1.2 Was sich seit 2022 geändert hat

Wer 2022 mit ChatGPT gearbeitet hat und 2026 einem Agenten einen Rechercheauftrag gibt, erlebt zwei verschiedene Werkzeuge. Am Prinzip des Sprachmodells hat sich dabei wenig geändert; gewachsen ist vor allem die Schicht um das Modell herum. Sie hat Werkzeuge (*tools*) und Gedächtnis (*memory*) hinzugewonnen, und aus beiden folgt ein Drittes: Das Modell darf mehr Arbeitsschritte selbst wählen. Für diese Schicht setzt sich der Name **Harness** durch, für das, was beim Arbeiten aus Modell und Harness entsteht, der Name **Agent**. Die folgende Animation baut den Weg in acht Schritten auf.

Die drei Begriffe lassen sich an einem Bild auseinanderhalten, dem Fuhrwerk (Tabelle 2.1). Das Modell ist das Pferd, der Harness das Geschirr, der Agent das Gespann in Fahrt, und der Mensch sitzt auf dem Bock. Das Bild wirkt hier als *Advance Organizer* im Sinne Ausubels: eine Einführung auf höherer Abstraktionsebene, an die die folgenden Einzelbegriffe andocken können (Ausubel, 1960).

	Modell	Harness	Agent
Was ist es?	das trainierte Netz: Text hinein, wahrscheinliche Fortsetzung heraus	die Software um das Modell: Werkzeuge, Gedächtnis, Schleife, Freigaben	eine Betriebsweise: Das Modell steuert seinen Ablauf selbst
Art	Bauteil	Bauteil	Verhalten zur Laufzeit

	Modell	Harness	Agent
Im Bild	Pferd	Geschirr	Gespann in Fahrt entsteht, wenn beide zusammen laufen
Wer baut es?	ein KI-Labor (OpenAI, Google, Anthropic ...)	Hersteller (innerer Harness) und Nutzende (äußerer Harness)	

Tabelle 2.1. Modell, Harness und Agent: zwei Bauteile und eine Betriebsweise (eigene Zusammenstellung).

Daraus folgt: **Jeder Agent braucht einen Harness, aber nicht jeder Harness macht einen Agenten.** Ein Chatbot, der vor jeder Antwort fest Stellen aus dem Skript holt, hat einen Harness und bleibt doch ein fest programmierter Ablauf.

Ausgangspunkt: das Modell allein. Um 2022 war das Chatfenster die ganze Schnittstelle: Das Modell lieferte Text, Nachrechnen, Quellensuche und Prüfen blieben bei uns, und mit dem Fenster vergaß es das Gespräch. Im Bild des Fuhrwerks war es ein Pferd ohne Geschirr.

Erster Ermöglicher: Werkzeuge. Statt einer Antwort schreibt das Modell eine strukturierte Bitte, etwa „rechne 17 × 23“; ein gewöhnliches Programm führt sie aus und legt das Ergebnis zurück in den Text, den das Modell weiterschreibt. Dass Sprachmodelle selbst lernen können, wann sich ein solcher Aufruf lohnt, zeigten Schick et al. (2023). Seit Ende 2024 schließt das Model Context Protocol (MCP) beliebige Dienste nach demselben Muster an, so wie der USB-Anschluss Drucker und Kameras (Anthropic, 2024). Ein **Werkzeug** ist also ein Programm, das das Modell anfordern, aber nicht selbst ausführen kann (Vertiefung: Kapitel 2.4.2).

Zweiter Ermöglicher: Gedächtnis. Vor der Antwort kann eine Suche in eigenen Dokumenten, etwa Skript, Folien oder Prüfungsordnung, die passenden Stellen heraussuchen und dem Modell mit der Frage vorlegen, so wie eine Bibliothekarin die richtigen Seiten aufgeschlagen auf den Tisch legt; Fachleute nennen das *Retrieval-Augmented Generation* (RAG), etwa „abrufgestützte Erzeugung“ (Lewis et al., 2020). Die Kontextfenster (*context windows*), also die Textmenge, die das Modell bei einer Antwort auf einmal überblickt, sind von wenigen Seiten auf ganze Bücher gewachsen, und eine Anleitungsdatei trägt Regeln und Zwischenstände von einer Sitzung in die nächste (Vertiefung: Kapitel 2.4.3).

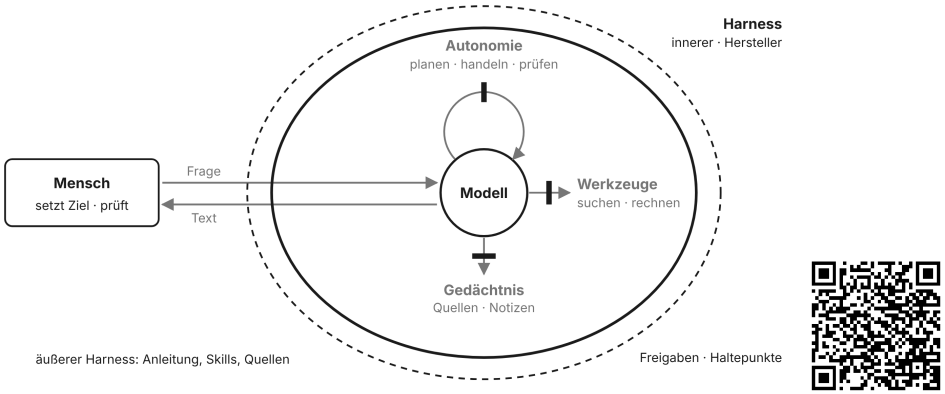


Abbildung 2.2. Gewachsen ist die Schicht um das Modell: Werkzeuge und Gedächtnis kommen hinzu, daraus folgt eine Arbeitsschleife, über deren Schritte das Modell selbst entscheidet; Freigaben und Haltepunkte im Harness regeln seinen Handlungsspielraum (schematische Darstellung). Die Fassung zum Durchklicken: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/harness-schichten.html aufrufen.

Die Folge: Autonomie im Vorgehen. Mit Werkzeugen und Gedächtnis wird aus einem Durchgang eine Schleife: Das Modell plant einen Schritt, ruft ein Werkzeug auf, liest das Ergebnis und plant den nächsten; Yao et al. (2023) nennen dieses Wechselspiel aus Denken und Handeln ReAct. Schluntz & Zhang (2024) ziehen daraus die Grenze, die für dieses Buch gilt: In einem **Workflow** folgen Modell und Werkzeuge vorgegebenen Pfaden, ein **Agent** steuert seinen Ablauf und seine Werkzeugnutzung selbst. Das Wort kommt vom lateinischen *agere*, handeln, in Gang bringen. Wie weit diese Selbststeuerung reicht, misst das gemeinnützige Prüfinstitut METR (*Model Evaluation and Threat Research*) als Zeithorizont (*time horizon*) , s. 5.2.1.

„Autonom“ verlangt eine Einschränkung: Das griechische *autónomos* heißt, sich selbst das Gesetz (*nómos*) geben, und das tut ein Agent nicht, denn das Ziel setzt der Mensch. Wir nennen solche Systeme deshalb **teilautonom**; die Norm zum automatisierten Fahren meidet das Wort „autonom“ aus demselben Grund und spricht von Automatisierungsstufen (SAE International, 2021). Wir sprechen von **Autonomie im Vorgehen**; „Autonomie der Lernenden“ (*learner autonomy*) meint dagegen die Fähigkeit, das eigene Lernen zu steuern (Holec, 1981).

Wie viel Autonomie ein Modell bekommt, entscheiden die Menschen, die es

einsetzen, nicht das Modell. Morris et al. (2024) ordnen die Zusammenarbeit von Mensch und KI in sechs Stufen (*Levels of Autonomy*), von „keine KI“ bis zum vollständig selbstständigen Agenten, und betonen, dass für Bildung und Prüfungen auch die unterste Stufe ihren Platz behält.

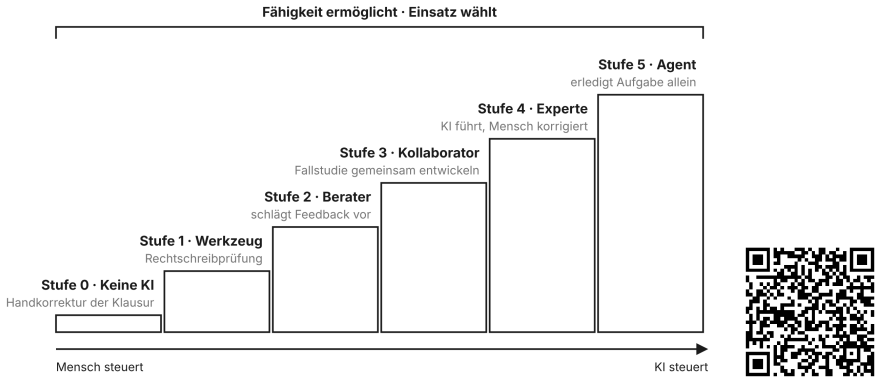


Abbildung 2.3. Wie selbstständig eine KI arbeitet, entscheiden die Menschen, die sie einsetzen: sechs Stufen von der Handkorrektur ohne KI bis zum Agenten, der eine Aufgabe allein erledigt (eigene Darstellung nach Morris et al. (2024), Tabelle 2; Beispiele aus der Hochschullehre ergänzt). Die Fassung zum Durchklicken: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/autonomiestufen.html aufrufen.

Der Name für das Gewachsene: Harness. Anthropic definiert den **Harness** als das System, das ein Modell als Agent handeln lässt: Er nimmt Eingaben entgegen, ruft Werkzeuge auf und gibt Ergebnisse zurück (Grace et al., 2026). Das englische *harness* ist das Geschirr eines Zugpferds; dasselbe Pferd zieht mit anderem Geschirr einen Pflug oder eine Kutsche, und dasselbe Modell wird mit anderem Harness zum Lerntutor oder zum Karriereberater. Google spricht von einer *Orchestrierungsschicht* (*orchestration layer*) (Wiesinger et al., 2024), OpenAI beim Programmier-Agenten Codex von Harness (Bolin, 2026), Anthropic vom „Gehirn“ aus Modell und Harness (Martin et al., 2026); gemeint ist dasselbe Bauteil.

Der Harness ist zugleich der Regler der Autonomie: Welche Werkzeuge er anbietet, ob ein Werkzeug nur lesen oder auch schreiben darf und wo der Ablauf auf eine Freigabe wartet, legt den **Handlungsspielraum** des Modells fest. Wer den Harness pflegt, betreibt *Harness Engineering*; Hashimoto (2026), der den Begriff geprägt hat, versteht darunter, aus jedem Fehler eines Agenten eine dauerhafte Verbesserung seiner Umgebung zu machen, damit der

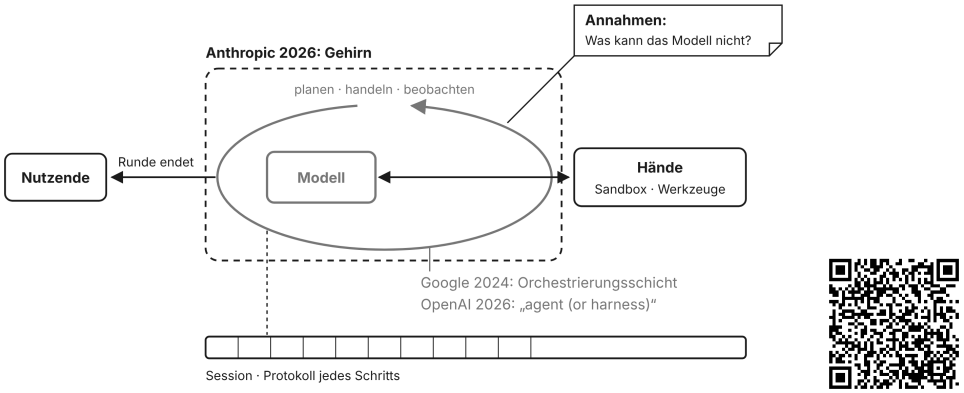


Abbildung 2.4. Drei Labore, ein Bauplan: Eine Schleife ruft das Modell immer wieder auf und lässt seine Werkzeugaufrufe ausführen, bis wieder der Mensch entscheidet. Jeder Harness enthält Annahmen darüber, was das Modell nicht kann (eigene Darstellung nach Wiesinger et al. (2024), Bolin (2026) und Martin et al. (2026); schematisch). Die Fassung zum Durchklicken: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/drei-labs-ein-bauplan.html aufrufen.

Fehler nicht wiederkehrt.

Die Grenze zwischen Modell und Harness wandert allerdings: Jeder Harness enthält Annahmen darüber, was das Modell nicht allein kann, und bessere Modelle machen manche davon überflüssig (Martin et al., 2026); Logan Kilpatrick von Google DeepMind sagt, das Modell fresse den Harness (Sequoia Capital, 2026). Die Aufgaben bleiben, gleich wer sie erledigt: Jemand muss Werkzeuge anschließen, Kontext auswählen und Haltepunkte (*checkpoints*) setzen.

Die Fachbegriffe des ganzen Buches mit ihrer Herkunft stehen im Glossar.

2.1.3 Typische Aufgaben und Fragestellungen mit der KI durchspielen, Prompts anpassen, experimentieren

Lehrende sollten zunächst Informationen sammeln, um zu verstehen, was KI mit den Aufgaben in ihrem Kurs bewirken kann (MIT Teaching + Learning Lab, 2023). Melden Sie sich bei einem der professionellen KI-Dienste wie ChatGPT oder Claude an und spielen Sie mit exemplarischen Konzepten,

Fragen und Aufgabensets aus dem Kurs. Dabei ist es wichtig, nicht gleich bei der ersten schlechten Antwort aufzugeben, sondern Anpassungsmöglichkeiten durchzugehen: Lässt sich der **Input beschränken**? (Fragen auf einen Text-Input, eine gute Internetquelle oder eine hochgeladene PDF beschränken.) Lässt sich der **Prompt** (die Eingabe an die KI) **anpassen**? (Bearbeitung schrittweise durchführen lassen, Optionen und Szenarien durchgehen lassen usw., siehe Kapitel 2.3.1 zu Prompt Engineering, dem gezielten Formulieren von Prompts.)

Wichtig ist, sich zu überlegen, welches Lernziel jede Aufgabe hat und wie die KI damit umgeht. Es sollte bewertet werden, bei welchen Arten von Fragen die KI gut abschneidet und wo ihre Grenzen liegen (E. R. Mollick, 2025b). Diese Erkenntnisse können dann genutzt werden, um etwa Aufgabensets und andere Aufgabenstellungen besser zu strukturieren.

Ihre Einschätzung prüfen

„Liefert ein Sprachmodell auf eine Kursaufgabe beim ersten Versuch eine schwache Antwort, können Studierende die Aufgabe kaum mit KI lösen."
Auflösung: nein. Eine schwache erste Antwort sagt wenig darüber, was die KI mit der Aufgabe kann. Wer den Input auf einen Text oder eine hochgeladene Datei begrenzt oder die Bearbeitung schrittweise anfordert, bekommt oft deutlich bessere Ergebnisse, und genau das tun auch die Studierenden. Erst nach solchen Versuchen zeigt sich, wo die Grenzen der KI bei der eigenen Aufgabe liegen.

2.1.4 Wie bleiben Sie informiert?

Bei einem Thema, das sich so schnell wandelt, sind gute Sammelstellen wertvoller als jede gedruckte Liste von Werkzeugen. Die folgenden Quellen haben sich bewährt (Stand 10/2026):

- **Newsletter von Ethan Mollick** (Wharton School) mit sehr praktischen Übersichten und Empfehlungen: https://www.oneusefulthing.org/. Ein Abonnement lohnt sich.
- **Didaktische Prompts** desselben Teams: https://www.moreusefulthings.com/prompts. Hervorzuheben sind die „Blueprints", Vorlagen, die sich für die eigene Lehre anpassen lassen.

- **Hochschulforum Digitalisierung**, Beiträge zu KI in Studium und Lehre: https://hochschulforumdigitalisierung.de/dossier/generative-ki/
- **e-teaching.org**, Themenspecial KI in der Hochschulpraxis: https://www.e-teaching.org/praxis/themenseiten/ki-in-studium-und-lehre
- **Derek Bok Center der Harvard University** mit Beispielen, wie Lehrende generative KI (GenAI) nutzen, darunter Simulationen und Sprachdidaktik: https://bokcenter.harvard.edu/examples-and-ideas-for-using-AI-for-your-teaching
- **Wie Lehrende KI tatsächlich nutzen**: Anthropic hat rund 74.000 anonymisierte Unterhaltungen von Hochschullehrenden aus elf Tagen im Mai und Juni 2025 ausgewertet. Lehrende bauen darin unter anderem Simulationen, Lernspiele und Bewertungsraster selbst (Bent et al., 2025): https://www.anthropic.com/news/anthropic-education-report-how-educators-use-claude
- **Fortbildungen der Anbieter** zu den technischen Seiten der KI-Nutzung in der Lehre: Google (https://grow.google/ai-for-educators/), Anthropic (https://anthropic.skilljar.com/ai-fluency-framework-foundations) und OpenAI mit einem Newsletter für Hochschullehrende (https://edunewsletter.openai.com/).

Wer neue Studien statt neuer Werkzeuge verfolgen will, findet den gepflegten Stand der Forschung auf der Online-Seite zu diesem Buch.

2.2 Welches Modell?

Was für Sprachmodelle gibt es? Hinter der Flut an Produktnamen stehen wenige Klassen, und zwei Fragen sortieren sie: Wie leistungsfähig ist das Modell, und wer hat die Daten in der Hand (Abbildung 2.5)? Die großen KI-Labore bieten jeweils **große geschlossene Modelle** an, deren Gewichte beim Anbieter bleiben, und daneben **kleine Varianten**, die schneller und billiger sind und in den kostenlosen Zugängen den Standard stellen. **Frontier-Modelle** (Spitzenmodelle) heißen nur die wenigen großen Modelle, die in den Ranglisten deutlich vor allen anderen liegen; nicht jedes Labor hat eines, und die Spitze wechselt mit jeder Modellgeneration (Frontier Model Forum, 2026). Die großen Modelle sind **Reasoning-Modelle**: Sie denken vor der Antwort in mehreren Schritten nach, und wie lange, lässt sich als Denkstufe (*reasoning effort*) einstellen. **Offene Modelle** (*open-weight models*) legen ihre Gewichte offen; Hochschulen betreiben sie auf eigenen Rechnern, und

die Daten bleiben im Haus. Die besten offenen Modelle lagen 2026 im Mittel vier Monate hinter der Frontier (Edwards & Emberson, 2026), Modelle für eine einzelne Grafikkarte sechs bis zwölf Monate (Somala & Emberson, 2025).

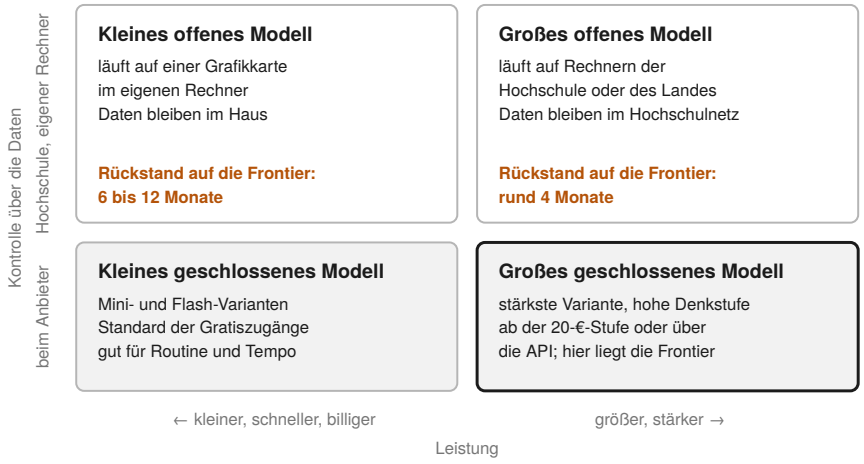


Abbildung 2.5. Vier Modellklassen nach Leistung und Kontrolle über die Daten. Wie groß der Rückstand der offenen Modelle ausfällt, hängt am gewählten Leistungstest; die Werte stammen aus Edwards & Emberson (2026) und Somala & Emberson (2025). Hochschulzugänge wie KI:connect.nrw bieten beide Zeilen. Eigene Darstellung.

Was kauft ein Abonnement? Die großen Anbieter staffeln ihre Preise in drei Stufen: kostenlos, rund 20 € und rund 100 € im Monat.[1] Der Schritt auf 20 € öffnet das große Modell mit hoher Denkstufe, den Recherche-Agenten und die Arbeit in Projekten; der Schritt auf 100 € kauft kaum ein klügeres Modell, sondern Menge, etwa das Fünffache an Nachrichten und Agentenzeit (Abbildung 2.6) (E. Mollick, 2026b). Wer beurteilen will, was die Modelle können, etwa für die eigenen Prüfungen, bezahlt deshalb ein bis zwei Mo-

[1] Stand Oktober 2026, Monatspreise einschließlich Mehrwertsteuer. 20-€-Stufe: ChatGPT Plus 23 €, Google AI Pro 21,99 €, Claude Pro 20 US-$ zuzüglich Steuer; 100-€-Stufe: ChatGPT Pro 103 €, Google AI Ultra 99,99 €, Claude Max 100 US-$ zuzüglich Steuer; weitere Stufen und Mistral in Tabelle 2.2. Ohne persönliches Abo geht es über den Hochschulzugang, über die API (*Application Programming Interface*, die Programmierschnittstelle des Anbieters) mit Abrechnung nach Verbrauch (s. den Tutor-Kosten-Rechner in Kapitel 5.2.1) oder mit offenen Modellen auf eigener Hardware. Quellen: OpenAI (2026a), Anthropic (2026a), Google (2026b), Mistral AI (2026).

nate lang die 20-€-Stufe; die kostenlosen Zugänge zeigen ein zu schwaches Bild.

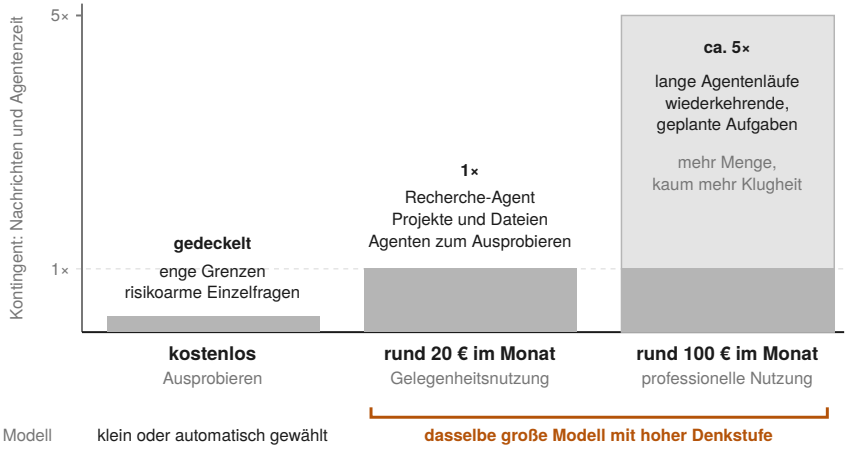


Abbildung 2.6. Was ein Abo kauft: Ab rund 20 € im Monat arbeitet das große Modell mit hoher Denkstufe; die 100-€-Stufe bringt dasselbe Modell mit etwa fünfmal so viel Kontingent. Eigene Darstellung nach den Preisseiten von OpenAI, Anthropic und Google, Stand Oktober 2026, und E. Mollick (2026b).

Seit der agentischen Wende Ende 2025, dem „Agentic Turn“ (E. R. Mollick, 2025a; Steinberger, 2025; Willison, 2025), zählt dabei nicht das Modell allein, sondern das ganze **Setup**: ein starkes Modell, eine praktische Oberfläche und ein Harness mit sinnvollen Werkzeugen (Kapitel 2.1.2) (E. Mollick, 2026a).

Kostenfreie Zugänge über die Hochschule. Hochschulen und Länder stellen Lehrenden Modelle beider Klassen bereit, die Gesellschaft für wissenschaftliche Datenverarbeitung in Göttingen (GWDG) etwa über die Academic Cloud (https://chat-ai.academiccloud.de/), die TH Köln über ihre KI-Plattform THKI-Lab (https://ki.th-koeln.de/login.php). In Nordrhein-Westfalen (NRW) ist **KI:connect.nrw** der Zugang der ersten Wahl (https://chat.kiconnect.nrw/): Anmeldung mit dem Hochschul-Login, geschlossene Modelle großer Anbieter über Verträge des Landes, offene Modelle auf landeseigenen Rechnern, Modellwechsel in jedem Chat und ein API-Zugang für eigene Werkzeuge (KI:connect.nrw, 2026; Ministerium für Kultur und Wissenschaft des Landes Nordrhein-Westfalen, 2025;

Persike, 2025). Über die API sprechen Programme statt Menschen mit dem Modell. Vor dem Einsatz lohnt der Blick, welche Modellgeneration hinter einem Hochschulzugang steht: Wer eine ältere Generation oder eine kleine Variante nutzt, fährt mit dem Fahrrad auf der Autobahn und bekommt ein falsches Bild davon, was die Modelle können.

Welches Modell für welche Aufgabe? Drei Fragen führen zur Wahl. Zuerst die Daten: Personenbezogene Daten, Prüfungsleistungen und unveröffentlichte Forschung gehören in einen Hochschulzugang oder in ein offenes Modell auf dem eigenen Rechner. Dann die Aufgabe: Für eine kurze Frage genügt ein kleines Modell, für eine Lerneinheit oder ein selbst gebautes Werkzeug braucht es das große Modell mit hoher Denkstufe. Zuletzt die Häufigkeit: Wer täglich mit Agenten arbeitet, braucht eine Stufe mehr. Über allen drei Fragen steht eine Prüfregel. Muss das Ergebnis stimmen und lässt es sich nicht selbst prüfen, gehört die Aufgabe an das größte Modell mit der höchsten Denkstufe, und ein Mensch prüft das Ergebnis.

Offene Modelle auf dem eigenen Laptop. Ein lokales Modell ist die eigene Küche statt des Lieferdienstes: Nichts verlässt das Haus, dafür sind die Töpfe kleiner. Programme wie LM Studio laden ein offenes Modell einmal herunter und führen es danach vollständig offline aus; die Topfgröße bestimmt der Arbeitsspeicher. Kleine Modelle fassen gut zusammen, formulieren um und sortieren, rechnen in mehreren Schritten aber unzuverlässig und kennen keine aktuellen Fakten. Sie gehören deshalb an Aufgaben, bei denen die Daten das Gerät nicht verlassen sollen und eine Stichprobe das Ergebnis prüft. Ein Beispiel sind Codenamen für anonyme Abgaben: Studierende reichen Tests unter einem Namen wie „Deming1900“ ein, KI-gestützte Rückmeldungen sehen nie einen echten Namen, und die Zuordnung zur Person steht allein in der Tabelle der Lehrenden.

> **i** Stand bei Drucklegung, November 2026
>
> Die folgende Übersicht hält fest, welche Modelle bei Drucklegung die Klassen aus Abbildung 2.5 füllten und was die Stufen aus Abbildung 2.6 kosteten. Sie ist ein historischer Schnappschuss: Namen und Preise ändern sich, Klassen und Stufen bleiben.

1 Daten
Personenbezogene Daten, Prüfungsleistungen oder unveröffentlichte Forschung?

ja → **Hochschulzugang**
oder kleines offenes Modell auf dem eigenen Rechner

nein

2 Aufgabe: Ich will …	Modellklasse	Stufe
… eine Frage klären, einen Text überarbeiten	kleines Modell	**0 €**
… ein Bild erstellen (Diagramme besser als Code)	Modell mit Bildgenerator	**0 €**
… eine Lerneinheit, Folien, Aufgaben erstellen	großes Modell, hohe Denkstufe	**20 €**
… regelmäßig recherchieren	großes Modell mit Recherche-Agent	**20 €**
… ein Werkzeug bauen (Simulation, Lernspiel)	großes Modell im Agentenmodus	**20 €**
… einen Tutor für Studierende betreiben	API (nach Verbrauch) oder Hochschule	**kein Abo**

3 Häufigkeit — Täglich, auch mit langen Agentenläufen?
Dann eine Stufe höher: 0 → 20 €, 20 → 100 €.

Prüfregel
Muss das Ergebnis stimmen und können Sie es nicht selbst prüfen?
Größtes Modell, höchste Denkstufe, und ein Mensch prüft.

Abbildung 2.7. Welches Modell für welche Aufgabe? Drei Fragen führen zu Modellklasse und Preisstufe: Daten, Aufgabe, Häufigkeit; die Prüfregel gilt für jede Zeile. Stufen wie in Abbildung 2.6. Eigene Darstellung nach E. Mollick (2026b). Die Fassung zum Durchklicken: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/modellwahl-baum.html aufrufen.

Anbieter	Modellklassen	Stufen (Monatspreis)	Hinweis für die Lehre
OpenAI	groß: GPT-6 Astra, GPT-6.1 Sol; klein: GPT-6 Luna, GPT-5.6 Luna (Standard im Gratiszugang)	kostenlos · Go 8 € · Plus 23 € · Pro 103 €, 229 € oder 510 €	Bildgenerator und Sprachmodus; Recherche-Agent und Agentenmodus erweitert ab Plus; eigene „GPTs“ werden am 11.12.2026 abgeschaltet
Anthropic	groß: Claude Opus 5.5, darüber Claude Fable 5.1; klein: Claude Sonnet 5.5 und Haiku 5.5 (Gratiszugang)	kostenlos · Pro 20 US-$ · Max 100 US-$ (5×) · Ultra 200 US-$ (10×), jeweils zzgl. MwSt.	Kein Bildgenerator, Grafiken entstehen als Code; Artifacts für Lernspiele; Claude Code und geplante Aufgaben ab Pro; Fable in Pro nur über Nutzungsguthaben
Google	groß: Gemini 4 Argon; klein: Flash- und Flash-Lite-Varianten (Gratiszugang)	kostenlos · AI Plus 4,99 € · AI Pro 21,99 € · AI Ultra 99,99 € (5×) oder 219,99 € (20×)	Bild- und Videogenerator; sehr lange Kontexte für ganze Skripte; Gemini Notebook (früher NotebookLM) für Recherche in eigenen Quellen
Mistral (Vibe, früher Le Chat)	eigene Modelle, teils mit offenen Gewichten	kostenlos · Pro 14,99 US-$ zzgl. MwSt. (Studierende 5,99 US-$)	Europäischer Anbieter; Chat und Programmier-Agent in einem Produkt
Offene Modelle	Familien gpt-oss (OpenAI), Qwen (Alibaba), DeepSeek, Llama (Meta), Gemma (Google), Mistral	Gewichte frei verfügbar; Kosten nur für Rechner oder Hoster	Kleine Varianten lokal auf einer Grafikkarte, große über Hochschuldienste

KI:connect.nrw (Land NRW, Technische Hochschule RWTH Aachen)	GPT-5.6 (Sol, Terra, Luna) und GPT-6 (Astra, Sol, Luna) seit 1. Oktober 2026; Mistral, Qwen und gpt-oss als offene Modelle auf Landesinfrastruktur; Bild- und Einbettungsmodelle	kostenlos für Nutzende; Kontingente je Hochschule	Erste Wahl in NRW; Modellwechsel je Chat; OpenAI-kompatible API über selbst erzeugte Schlüssel (Freigabe je Hochschule)
GWDG und Hochschulen	wechselnde Auswahl offener und kommerzieller Modelle	kostenlos für Nutzende	Academic Cloud (Registrierung mit Hochschuladresse), THKI-Lab (TH Köln); vor dem Einsatz prüfen, welche Modellgeneration hinterlegt ist

Tabelle 2.2. Modelle und Preisstufen bei Drucklegung. Preise laut Preisseiten der Anbieter, Stand Oktober 2026, Euro-Beträge einschließlich Mehrwertsteuer. Quellen: OpenAI (2026a), Anthropic (2026a), Google (2026b), Mistral AI (2026), IT Center der RWTH Aachen (2026).

Die lebende Fassung dieser Übersicht wird online semesterweise aktualisiert.
Die lebende Modellübersicht finden Sie online unter https://th-koln-bartnik.github.io/genai4teaching/modelluebersicht.html.

Abbildung 2.8. Lebende Modellübersicht, semesterweise aktualisiert: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/modelluebersicht.html aufrufen.

Wie ein Kurs-Bot über die Materialien vieler Lehrveranstaltungen aussieht und warum er erst durch begleiteten Einsatz in der Veranstaltung wirkt, zeigt ein Anwendungsbeispiel aus Lübeck in der Online-Fassung dieses Abschnitts (Tobor et al., 2026).

2.3 Description: Wie sage ich der KI, was ich will?

Description fragt, wie wir der KI klar sagen, was wir wollen (Tabelle 5.1): welches Ergebnis, welche Art der Zusammenarbeit und welches Verhalten.

2.3.1 Vom Wunsch zum Werkvertrag

Bevor Sie weiterlesen, prüfen Sie Ihre eigene Vorstellung von einem guten Prompt. Der folgende Test zeigt zehn Zeilen aus einem Prompt, wie er 2024 in diesem Buch stand; entscheiden Sie bei jeder Zeile, ob Sie sie bei einem heutigen Reasoning-Modell streichen würden und wie sicher Sie sich sind. Wer vorher urteilt, behält die Auflösung besser (Richland et al., 2009), und

Irrtümer, bei denen man sich sicher war, werden besonders gründlich korrigiert (Butterfield & Metcalfe, 2001).

Der Streich-Test: Was würden Sie heute streichen?

Die Zeilen stammen aus dem Quiz-Ersteller, wie er 2024 im damaligen Prompt-Anhang stand. Die Zeilen dazwischen sind ausgelassen, die Zeilen 9 und 10 sind ergänzte Beispielzeilen. Kreuzen Sie an, welche Zeilen Sie bei einem heutigen Reasoning-Modell streichen würden, und wie sicher Sie sind (1 geraten, 2, 3 sicher).

	Zeile	*streichen?*	*Sicherheit*
1.	Du bist ein kompetenter Lehrassistent und Experte für Leistungsbewertung.	☐	☐1 ☐2 ☐3
2.	Du agierst strukturiert, präzise und didaktisch reflektiert.	☐	☐1 ☐2 ☐3
3.	Phase 1 – Einstieg (Pflichtreihenfolge einhalten!)	☐	☐1 ☐2 ☐3
4.	Warte zwingend auf die Antwort des Lehrers, bevor du fortfährst.	☐	☐1 ☐2 ☐3
5.	Frage zusätzlich, welche typischen Schwierigkeiten oder Fehlvorstellungen auftreten könnten.	☐	☐1 ☐2 ☐3
6.	- 5 Multiple-Choice-Fragen - 2 offenen Fragen - Anordnung von leicht → anspruchsvoll	☐	☐1 ☐2 ☐3
7.	- Jede falsche MC-Antwort muss plausibel sein.	☐	☐1 ☐2 ☐3
8.	- Weise darauf hin, dass diagnostische Tests sowohl Bewertungsinstrument als auch Lernereignis (Abrufübung, Identifikation von Wissenslücken) sind.	☐	☐1 ☐2 ☐3
9.	Denke Schritt für Schritt nach und prüfe jede Frage zweimal, bevor du sie ausgibst. (*ergänzt*)	☐	☐1 ☐2 ☐3
10.	Wenn der Test gut wird, gebe ich dir 200 € Trinkgeld. (*ergänzt*)	☐	☐1 ☐2 ☐3

Die Auflösung mit Quellen steht in den Lösungshinweisen (Anhang B). Online gibt es den Test zum Anklicken, mit Begründung je Zeile und dem neuen Prompt daneben: https://th-koln-bartnik.github.io/genai4teaching/kapitel02-grundlagen.html#sec-streichtest



In einem Märchen von N. K. Jemisin erfüllen gefangene Götter ihren Wächtern jeden Wunsch, nur nicht wohlwollend: Den Baum, der im Weg liegt, beseitigt auch ein Vulkanausbruch (Jemisin, 2010). Ein **Prompt**, die Eingabe an ein Sprachmodell, ist ein solcher Wunsch, und das Handwerk, ihn zu fassen, heißt **Prompt Engineering** (Berryman & Ziegler, 2025). Was an ihm genau sein muss, hat sich mit den Modellen verschoben. Ältere Modelle brauchten eine Arbeitsanleitung mit Rolle, Schritten und Ermahnungen. Reasoning-Modelle planen den Weg selbst; die Leitfäden der Labore raten inzwischen, die aufwendige Prompt-Technik älterer Modelle wegzulassen (Anthropic, 2026c; Google, 2026a) und stattdessen Ergebnis und Erfolgskriterium zu nennen (OpenAI, 2026b). Der Prompt wird vom Dienstvertrag, der Tätigkeiten vorschreibt, zum Werkvertrag, der Erfolg und Abnahme festlegt.

2.3.2 Ein Auftrag mit Abnahmekriterium

Vier Angaben tragen einen solchen Auftrag. Das **Ziel** sagt, was am Ende vorliegt. Der **Grund** sagt, für wen und wozu; er lässt das Modell auch Fälle lösen, die keine Regel vorhersieht (Anthropic, 2026b). Das **Material** liefert Skript, Daten und, wo Stil oder Format zählen, einige Beispiele; lange Dokumente stehen oben, die Frage am Ende (Anthropic, 2026b; N. F. Liu et al., 2024). Das **Abnahmekriterium** sagt, woran Sie und das Modell erkennen, dass die Arbeit fertig ist: „fünf Aufgaben zu Kapitel 3, jede mit Lösungsweg, keine Zahl, die nicht im Skript steht“. Ist das Ziel noch unklar, interviewt Sie das Modell, bis ein kurzes Lastenheft steht, mit dem eine neue Sitzung beginnt. Ist die Arbeit groß, geben Sie zuerst den Plan frei, als Zwischenabnahme für sich, nicht als Denkhilfe für das Modell; Kleines und Klares geht direkt.

Schemata mit Merkwörtern wie RTF (*Role, Task, Format*) oder CREATE sind Checklisten für Menschen: Sie helfen, nichts zu vergessen, und machen lange System-Prompts lesbar. Eine Wirkformel sind sie nicht; die älteren Prompts in Anhang A tragen ihre Labels als Lesehilfe (Anhang A).

2.3.3 Prompts schreiben lassen, ohne das Steuer abzugeben

Lange System-Prompts für Tutoren oder Simulationen muss niemand selbst schreiben. Die Arbeitsteilung folgt dem Lastenheft: Was der Bot leisten soll, für wen, was er nie tun darf und woran Sie Erfolg erkennen, entscheiden Sie; die Formulierung schlägt das Modell vor. Fünf Kontrollpunkte halten das Steuer bei Ihnen. Das Modell interviewt Sie und fasst Ihre Vorgaben zusammen, bevor es schreibt; Sie geben die Zusammenfassung frei. Im Entwurf markiert es alles, was es ergänzt hat, ohne dass Sie es gesagt haben. Eine frische Sitzung, die nur den Prompt kennt, beschreibt, wie sich der Bot verhalten wird; weicht das von Ihrer Absicht ab, ist der Prompt unklar (Anthropic, 2026b). Vor dem Einsatz testen Sie ihn mit sechs bis acht typischen Eingaben von Studierenden, auch unfreundlichen. Geht etwas schief, legen Sie Prompt, erwünschtes und tatsächliches Verhalten vor und bitten um die kleinste Änderung, die genügt (Kotha et al., 2025). Dem Modell geben Sie dabei die Regeln dieses Kapitels mit, Gründe statt Befehle, keine Großbuchstaben, keine Rollenfloskeln, ein Wortbudget; sonst schreibt es genau die Ermahnungen, die die Labore heute zu streichen raten. Zwei Vorlagen dafür stehen in Anhang A (Kapitel A.1.2, Kapitel A.1.3).

2.3.4 Drohen und Bestechen bringt nichts: Hausrezepte im Test

Dieselbe Eingabe liefert nicht immer dieselbe Antwort, und **so entsteht schnell anekdotische Evidenz**, dass eine Formulierung „besser geklappt“ hätte.

Meincke und Kollegen haben solche Hausrezepte systematisch geprüft; **die wenigsten helfen zuverlässig** (Meincke et al., 2025b, 2025a, 2025c). Die Aufforderung, Schritt für Schritt zu denken, half älteren Modellen ein wenig; Reasoning-Modelle tun das von sich aus, und dort kostet die Aufforderung vor allem Zeit (Meincke et al., 2025a). Auch eine Expertenrolle („Du bist eine erfahrene Physikerin“) macht die Antworten nicht genauer (Basil et al., 2025). Weil gerade diese Empfehlung lange das Gegenteil sagte, fasst der folgende Kasten zusammen, was heute gilt.

Hintergrund: Warum die Rolle aus dem Arbeitsauftrag verschwindet

Was man jetzt empfiehlt. In einem Arbeitsauftrag streichen Sie die Rolle und schreiben hinein, was sie andeuten sollte: für wen, wozu, in welchem Ton („für Erstsemester, ermutigend, ohne Fachjargon"). Das lässt sich prüfen, eine zugeschriebene Identität nicht; für diese Empfehlung ist die Evidenz stark. Für Ton und Haltung empfehlen die Anbieter Rollen weiterhin (Anthropic, 2026b); kontrollierte Tests dazu fehlen, die Empfehlung beruht auf Erfahrung. In Tutor-Bots und Simulationen bleibt die Rolle, weil sie dort das Produkt ist (Kapitel 2.3.5). Ihr Beitrag zur Echtheit ist allerdings klein: Personenmerkmale erklären weniger als ein Zehntel der Unterschiede in menschlichen Urteilen, und Persona-Prompts verbessern solche Simulationen nur wenig (Hu & Collier, 2024). Weil Rollen zudem Stereotype mitbringen können, gehört ein Test darauf in die Abnahme (Kapitel 2.3.3).
Wie es zu dem Wechsel kam und wie gut jeder Schritt belegt ist, zeigt die Online-Fassung: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/kapitel02-grundlagen.html#sec-rollen-evidenz aufrufen.

Ihre Einschätzung prüfen

„Höflichkeit, Drohungen oder ein versprochenes Trinkgeld verbessern die Antworten eines Sprachmodells nicht zuverlässig."
Auflösung: ja. Die Experimente von Meincke und Kollegen finden für Höflichkeit, Drohungen und Trinkgeld keine verlässliche Wirkung. Was hilft, ist ein klarer Auftrag: Ziel, Grund, Material und ein Kriterium, an dem die Arbeit abgenommen wird (Kapitel 2.3.2).

Wie ein neuer Sportwagen bringen **stärkere Modelle mit den größeren Fähigkeiten auch neue Anfälligkeiten**. Wer ihnen den Denkweg vorschreibt, senkt teils ihre Leistung (R. Liu et al., 2025; Meincke et al., 2025a); auf GROSSBUCHSTABEN überreagieren sie (Anthropic, 2026b), und ein „Prüf das nochmal" kostet nur Zeit, denn sie prüfen selbst (Anthropic,

2026c). Prompts aus dem Vorjahr verdienen deshalb alle paar Monate eine Durchsicht: Für eine neue Modellgeneration beginnt man besser schlank neu, als alte Anweisungen mitzuschleppen (OpenAI, 2026b).

2.3.5 Was heißt das für Prompts in der Lehre?

Didaktische Prompts sollen den Studierenden das Leben gezielt schwer machen. Für die Lehre ergänzen wir Prompts um didaktische Hürden, die etwa verhindern, dass sofort eine Lösung erscheint, denn eigenes Nachdenken in Fragen und sokratischem Dialog hilft, das Gelernte zu behalten (Roediger & Pyc, 2012). Für einen **Arbeitsauftrag**, der ein Werkstück wie ein Quiz bestellt, gilt alles oben Gesagte; in einer **Verhaltensbeschreibung** für Tutor oder Simulation ist das Gespräch selbst das Produkt, und Ablauf, Rolle und Hürden gehören zur Spezifikation. Welche Hürden das sind, ordnet Tabelle 2.3 nach ihrem Zweck. Aktives Lernen verlangt, dass die KI Wegweiser bleibt statt Orakel; eine realistische Simulation verlangt, dass sie in der Rolle bleibt und Informationen nur so herausgibt, wie es das Gegenüber täte; eine begrenzte kognitive Belastung (*cognitive load*) verlangt, dass sie eine Frage nach der anderen stellt. Die Lernforschung nennt solche Hürden erwünschte Schwierigkeiten (*desirable difficulties*) (Bjork & Bjork, 2011; Sweller, 2011). Jede Regel der Tabelle lässt sich abhaken, und genau solche Regeln halten Modelle ein (Kapitel 2.4.2).

Einschränkung	Zweck	Formulierung im Prompt
Keine fertige Lösung	Aktives Lernen: Lernende erklären ihre Überlegung und korrigieren sich selbst	„Keine fertigen Lösungen.“ „Antworten möglichst mit einer Frage beenden.“
Kein Monolog	Aktives Lernen: Das Gespräch bleibt dialogisch, niemand steigt aus	„Nicht fortfahren ohne Antwort.“
In der Rolle bleiben	Realistische Simulation: Die Situation trägt bis zum Ende	„Bleiben Sie während des Rollenspiels strikt in Ihrer zugewiesenen Rolle.“
Informationen dosieren	Realistische Simulation: Lernende üben gezieltes Nachfragen statt eine Datenflut zu lesen	„Sie liefern Informationen nur, soweit sie für den Patienten plausibel sind.“
Nur aus der Quelle	Sachliche Grundlage: keine erfundenen Inhalte, die Übung bleibt beim Text	„Keine erfundenen Zitate.“

Einschränkung	Zweck	Formulierung im Prompt
Eine Frage pro Zug	Kognitive Belastung begrenzen: ein Schritt nach dem anderen	„Stellen Sie nicht mehr als eine Frage auf einmal.“

Tabelle 2.3. Sechs gezielte Einschränkungen in didaktischen Prompts. Eigene Darstellung; die Formulierungen stammen aus den Prompts in Anhang A

Wie das geht, zeigen Kapitel 4 und Kapitel 6; viele konkrete Prompts und Aufgabenstellungen sammelt Anhang A (Anhang A).

i Anwendungsbeispiel: Ein Prompt, der in der Vorführung funktioniert, scheitert im Gespräch

Alexander Landfair lässt Studierende einen Chatbot per Prompt auf die Regeln des aktiven Zuhörens nach Carl Rogers verpflichten. Sie testen ihn, bis er klappt, dann mit Widerspruch und heiklen Themen, bis er scheitert, und überarbeiten ihn nach jedem Fehler. Wer beschreiben soll, wann das Modell eine Regel bricht, muss die Regel selbst verstanden haben. *Unterrichtsentwurf, keine Ergebnisse berichtet.*
Ablauf und Prompt: Online-Fassung von Anhang A. Quelle: Landfair (2025) (AI Pedagogy Project, metaLAB at Harvard).



Zum Wiederholen: der Film „Stützräder“. Der Streich-Test am Anfang dieses Abschnitts fragte, welche Zeilen eines alten Prompts heute entfallen; der Film erzählt, woher diese Zeilen kamen. In neun Genres zieht er von den Beispiel-Prompts des Jahres 2020 bis zu den Leitfäden der Labore von 2026 und zeigt in jeder Szene mit einer Marke, ob ein Ratschlag aus einer Hersteller-Doku, aus einer Studie oder aus der Folklore stammt. Er nennt die alten Ratschläge ausdrücklich, bevor er sie ersetzt; solche Widerlegungstexte helfen, eine feste Vorstellung umzubauen (Tippett, 2010).

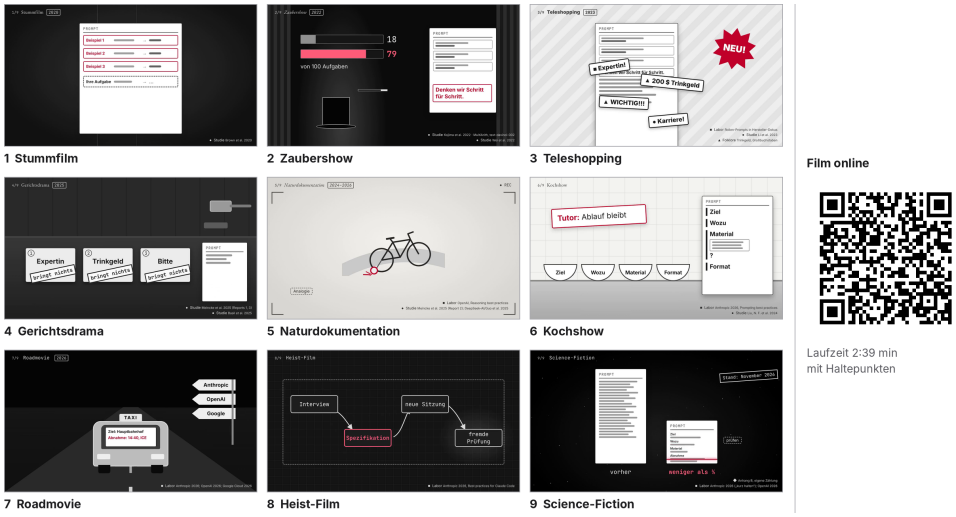


Abbildung 2.9. Neun Genres, eine Geschichte: Prompt-Tricks glichen Schwächen früherer Modelle aus und entfallen, sobald die Modelle sie nicht mehr brauchen. Standbilder aus einem Film von gut zweieinhalb Minuten mit drei Haltepunkten, erstellt mit Claude Code und HyperFrames 0.9.2 (HeyGen, 2026); Stimme KI-erzeugt (ElevenLabs v4); Quellenmarke je Szene: ■ Labor, ● Studie, ▲ Folklore. Den Film gibt es nur in der Online-Version: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/kapitel02-grundlagen.html#vid-stuetzraeder aufrufen.

Selbsttest zum Film. Beantworten Sie die drei Fragen, bevor Sie in **?@sec-loesung-stuetzraeder** nachsehen.

1. Warum halfen Tricks wie „Denke Schritt für Schritt“ früher? (a) Sie glichen eine Schwäche damaliger Modelle aus; (b) Modelle reagieren auf Höflichkeit; (c) sie verkürzten die Antwort.
2. Welche Zeile streichen Sie in einem Arbeitsauftrag an ein Reasoning-Modell zuerst? (a) „Der Test dient Erstsemestern zur Klausurvorbereitung.“; (b) „Denke sorgfältig und prüfe deine Antwort zweimal.“; (c) „Höchstens eine Seite.“
3. Ein Tutor-Prompt verlangt: „Erst nachfragen, dann einen Hinweis geben, nie die Lösung.“ Streichen? (a) Ja, das Modell plant selbst; (b) nein, hier ist der Ablauf das Produkt; (c) nur „nie die Lösung“ streichen.

2.4 Das erweiterte LLM

2.4.1 Welches Setup: LLM, RAG oder Agent?

Auch das klügste Modell hilft nur, wenn es den **Kontext unserer Aufgabe kennt**. Diesen Kontext geben wir ihm auf zwei Arten, bildlich gesprochen mit ein paar **Büchern oder einem Werkzeugkoffer** (Huyen, 2025, Kap.6). Bei **RAG (Retrieval-Augmented Generation)**, der in Kapitel 2.1.2 eingeführten Suche in eigenen Dokumenten, holt das System passende Stellen aus zusätzlichen Dokumenten wie Fachtexten, Statistiken oder Gesetzesbüchern und legt sie dem Modell zur Antwort vor: Die KI ist das Gehirn, die Dokumentsammlung das Bücherregal. Ein Agent beschafft sich Informationen dagegen selbst, mit Werkzeugen wie der Websuche. Die Unterschiede zwischen dem reinen Sprachmodell, dem Modell mit Bücherregal und dem Modell mit Werkzeugkoffer übt das folgende Spiel.

Lernspiel: LLM, RAG oder Agent, was sind mögliche Probleme und Anwendungsfelder?

Scrollen Sie nach unten, wählen Sie „Los geht’s!“ und dann nacheinander die Interaktionen für LLM, RAG und Agent, und beantworten Sie die Fragen.



Abbildung 2.10. Lernspiel „LLM, RAG oder Agent?“ (Probleme und Anwendungsfelder der drei Setups). Dieses interaktive Element gibt es nur in der Online-Version: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/llm-rag-agent-game.html aufrufen.

In der Lehre stellt RAG Fachtexte oder aktuelle Informationen bereit. In einem Geschichtskurs etwa beantwortet NotebookLM Fragen allein aus einem historischen Tagebuch und erzeugt daraus Material bis hin zu Podcasts (Huffman & Hutson, 2024). Wie Studierende mit Unternehmen Assistenten auf Firmendokumenten bauen, zeigt Kapitel 7.3.5.

Die drei Muster liegen auf einer Skala, und an ihr zählt, wer den Ablauf bestimmt: in einem Workflow das Programm, in einem Agenten das Modell (Roucher et al., 2024). Ein Chatbot, der vor jeder Antwort passende Stellen aus den Skripten holt, bleibt auf der untersten Stufe, denn die Suche läuft immer, gleich was das Modell schreibt. RAG macht das Modell kundiger, nicht selbstständiger.

Ihre Einschätzung prüfen

„Ein Chatbot, der nur aus Ihrem Skript antworten soll, braucht keinen Agenten; es genügt ein Modell, das vor jeder Antwort passende Stellen aus dem Skript abruft.“
Auflösung: ja. Ein Chatbot zum eigenen Skript ist ein Fall für RAG: Die Suche nach passenden Stellen läuft vor jeder Antwort, und das Modell bekommt ein Bücherregal, aber keinen Spielraum über den Ablauf. Einen Werkzeugkoffer und eigene Entscheidungen über die nächsten Schritte braucht diese Aufgabe nicht; ein Agent mit Internetzugang würde zudem Quellen jenseits des Skripts heranziehen.

Die folgende Animation baut den Weg vom Chatbot zum Agenten in dreizehn Schritten auf; die Bildfolge stammt von Grootendorst (2025), die Schleife aus Denken, Handeln und Beobachten von Yao et al. (2023).

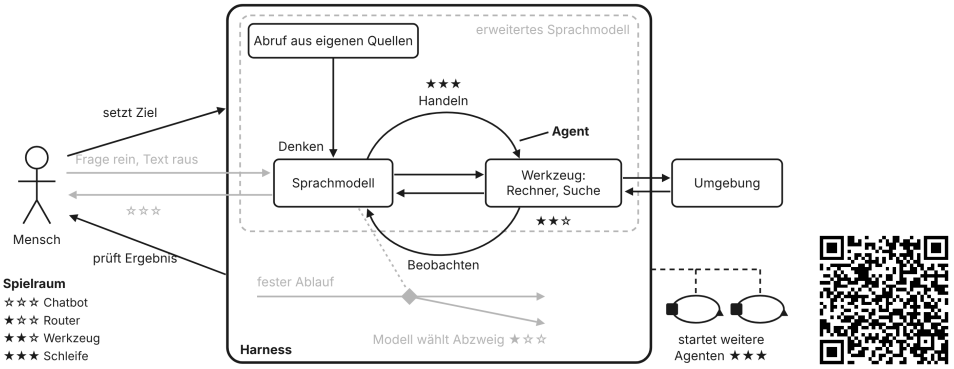


Abbildung 2.11. Vom Chatbot zum Agenten wächst vor allem der Spielraum des Modells über den Ablauf: Im Chatbot und beim festen Abruf eigener Quellen ändert die Antwort nichts am Ablauf (□□□), als Router wählt das Modell einen Abzweig (□□□), mit Werkzeugen das Werkzeug (□□□), in der Schleife aus Denken, Handeln und Beobachten den nächsten Schritt (□□□) (Skala nach Roucher et al. (2024), Bildfolge nach Grootendorst (2025); schematisch). Die Fassung zum Durchklicken: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/chatbot-zu-agent.html aufrufen.

2.4.2 Agenten in der Praxis: Skills und Werkzeuganschluss

Im Alltag der Lehre stellt sich die Frage nach dem Harness praktisch: Wann lohnt es sich, der KI einen Auftrag zu geben statt einer Frage, und wo muss ich dabei selbst entscheiden? Der Unterschied zum Chat ist die Strecke, die die KI allein zurücklegt: Im Chat sehen wir jede Antwort nach Sekunden, ein Recherche-Agent arbeitet Minuten, ein automatisierter Ablauf Stunden. Drei Bausteine des äußeren Harness kommen dabei besonders oft vor: Skills, der Werkzeuganschluss und eigene Quellen.

Ein **Skill** ist eine Gebrauchsanweisung, die der Agent bei Bedarf liest: ein Textdokument mit den Regeln, wie eine bestimmte Aufgabe in unserem Kurs zu erledigen ist, etwa wie Folien auszusehen haben oder wie eine Übungsaufgabe aufgebaut wird. Der Skill macht aus einem allgemeinen Modell einen

Mitarbeiter, der die Hausregeln kennt, ohne dass wir sie in jedem Prompt wiederholen.

Die Produktion kennt dieses Prinzip als Standardarbeit, bei der jede Tätigkeit nach Inhalt, Reihenfolge, Zeit und Ergebnis festgelegt ist, damit jede Verbesserung auf einem bekannten Stand aufsetzt (Spear & Bowen, 1999); ein Skill ist Standardarbeit für den Agenten. Wer einen Skill teilt, lässt ihn vorher von einer zweiten Person lesen, denn er verbreitet seinen Fehler ebenso vollständig wie seine Verbesserungen.

Technisch ist ein Skill ein Ordner mit einer Anleitungsdatei und bei Bedarf weiteren Dateien. Damit fünfzig installierte Skills das Kontextfenster nicht füllen, liest der Agent beim Start nur Name und Kurzbeschreibung jedes Skills; die Anleitung lädt er erst, wenn eine Anfrage zur Beschreibung passt, und Zusatzdateien nur, wenn die Anleitung auf sie verweist (Zhang et al., 2025). In den Nutzungsdaten eines verbreiteten Programmier-Agenten verwenden 26,6 % der Nutzenden solche Skills (Johnston et al., 2026).

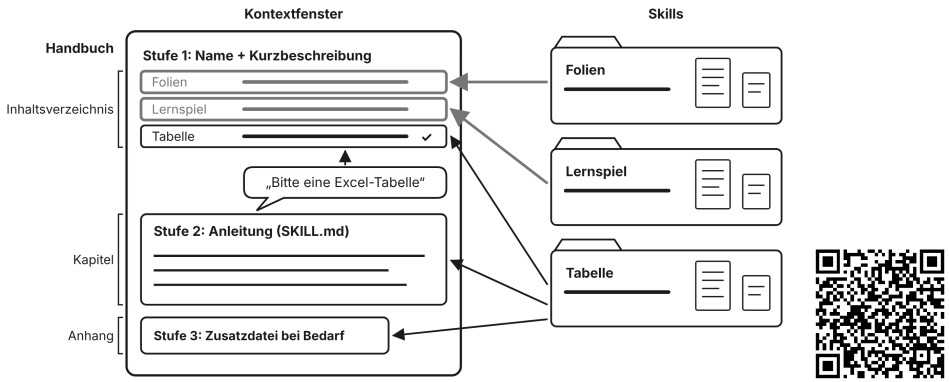


Abbildung 2.12. Ein Skill lädt sein Wissen erst, wenn es gebraucht wird: zuerst nur Name und Kurzbeschreibung, dann die Anleitung des passenden Skills, Zusatzdateien nur bei Bedarf, wie Inhaltsverzeichnis, Kapitel und Anhang eines Handbuchs (eigene Darstellung nach Zhang et al. (2025); schematisch). Die Fassung zum Durchklicken: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/skills-handbuch.html aufrufen.

Der **Werkzeuganschluss** über MCP (Kapitel 2.1.2) ist für Lehrende die Stelle, an der die KI aufhört, ein Textfenster zu sein, und in unseren Systemen handelt: im Bibliothekskatalog, auf der Lernplattform, im Kalender.

Eigene Quellen sind der Sonderfall, der in der Lehre am häufigsten gebraucht wird: als Projekt oder Notebook im Chat-Interface mit Skript, Übungsblättern und Musterlösungen oder als eigener Tutor, der über RAG auf einer Dokumentablage sitzt (Lewis et al., 2020). Ob die KI aus den Quellen antwortet oder doch aus dem Training, prüft man mit Fragen, deren Antwort in den Quellen bewusst anders lautet als im Allgemeinwissen.

Skill, Werkzeuganschluss und eigene Quellen sind drei von fünf Bausteinen, mit denen wir der KI dauerhaft beibringen, was sie über einen Kurs wissen soll. Tabelle 2.4 ordnet sie danach, was das Modell wann liest, denn diese Spalte entscheidet, wohin eine Regel gehört.

Baustein	Bild für die Lehre	Was das Modell wann liest
System-Prompt (Personalisierung, benutzerdefinierte Anweisungen)	Einarbeitungsmappe einer neuen Hilfskraft	immer, vor jedem Gespräch, vollständig
Projekt	Ordner mit Notizzettel obendrauf	die Anleitung jede Runde vollständig, die Dateien nur per Suche und gestückelt
Skill	Kapitel im Handbuch	ständig nur Name und Kurzbeschreibung, den Rest, wenn die Anfrage passt
Verbindung (App, Konnektor, MCP-Server)	Kabel mit Stecker zu einem fremden Gerät	wenn eine Aufgabe den Dienst braucht
Plugin	Werkzeugkoffer	löst selbst nichts aus, bündelt Skills und Verbindungen

Tabelle 2.4. Fünf Bausteine einer dauerhaften Arbeitsumgebung und was das Modell davon wann liest. Eigene Darstellung

Daraus folgt eine Merkregel: Was immer gelten muss, steht im System-Prompt oder in der Projektanleitung; Beispiele und Material liegen als Datei daneben; ein wiederkehrender Ablauf mit eigenen Regeln wird zum Skill. Wer in seinem Tarif keine Skills hat, baut den Skill als Projekt nach.

Ob ein Modell diese Regeln befolgt, hängt an ihrer Form. Nepal et al. (2026) prüften einen Reflexions-Bot Regel für Regel gegen seinen eigenen System-Prompt: Regeln, deren Einhaltung sich leicht feststellen ließ, befolgte er zuverlässig, vage Haltungsregeln nicht; die Studie ist ein Preprint ohne abge-

schlossene Begutachtung. „Höchstens drei Sätze“ hält ein Modell ein, „sei ermutigend“ dehnt es wie eine neue Hilfskraft am ersten Tag. Ein Folien-Skill verlangt deshalb nicht „gute Folien“, sondern Regeln zum Abhaken: ein ganzer Satz als Titel, ein Bild, das ihn belegt, höchstens fünfzehn Wörter im Folienkörper und eine vollständige Quelle. Diese Folienform ist zugleich die besser belegte. Ingenieurstudierende, die denselben Vortrag mit Satztitel und Bildbeleg statt mit Themenüberschrift und Aufzählung sahen, verstanden mehr und hatten weniger Fehlvorstellungen (Garner & Alley, 2013); Text, den die Vortragende zugleich spricht, unterdrückt dagegen die Aufnahme des Gesprochenen (Wecker, 2012).

Wie Studierende eine solche Quellenanbindung mit Unternehmen selbst aufbauen, zeigt Kapitel 7.3.5.

2.4.3 Gedächtnis: Was ein Agent von einer Sitzung in die nächste mitnimmt

Ein Sprachmodell erinnert sich nicht. Alles, was es bei einer Antwort berücksichtigt, steht in seinem **Kontextfenster**: Prompt, bisheriger Gesprächsverlauf, hochgeladene Dateien und die Ergebnisse seiner Werkzeuge (lateinisch *contexere*, zusammenweben; der Kontext ist das Gewebe, in dem ein Satz erst Sinn ergibt). Das Kontextfenster ist ein Schreibtisch, kein Archiv: Was darauf liegt, sieht das Modell vollständig, was nicht darauf liegt, existiert für die Antwort nicht, und am Ende der Sitzung wird der Tisch abgeräumt. Ein Agent, der ein Semester lang Feedback schreibt, braucht deshalb ein Archiv und eine Regel, was wann auf den Tisch kommt. Alles auf einmal hinzulegen ist keine Lösung, denn ein voller Tisch kostet bei jeder Antwort Rechenzeit und Geld (Kapitel 2.6.1).

Für diese Regel haben sich vier Stufen herausgebildet, die die folgende Abbildung nebeneinanderstellt: eine Anleitungsdatei, die der Agent zu Beginn jeder Sitzung liest, bis sie den Tisch füllt; Werkzeuge, mit denen er selbst entscheidet, wann er eine Erinnerung notiert, nachliest oder ändert; Skills, von denen zunächst nur Name und Kurzbeschreibung auf dem Tisch liegen (Zhang et al., 2025); und ein gewöhnlicher Ordner mit Textdateien, den der Agent durchsucht und pflegt wie jedes andere Verzeichnis. Der rote Faden: immer weniger vorab auf den Tisch, immer gezielter bei Bedarf aus dem Archiv. Die vierte Stufe hat einen Nebeneffekt, der für die Lehre wichtiger ist als für die Technik: Einen Ordner mit Textdateien können Menschen öffnen, lesen und korrigieren.

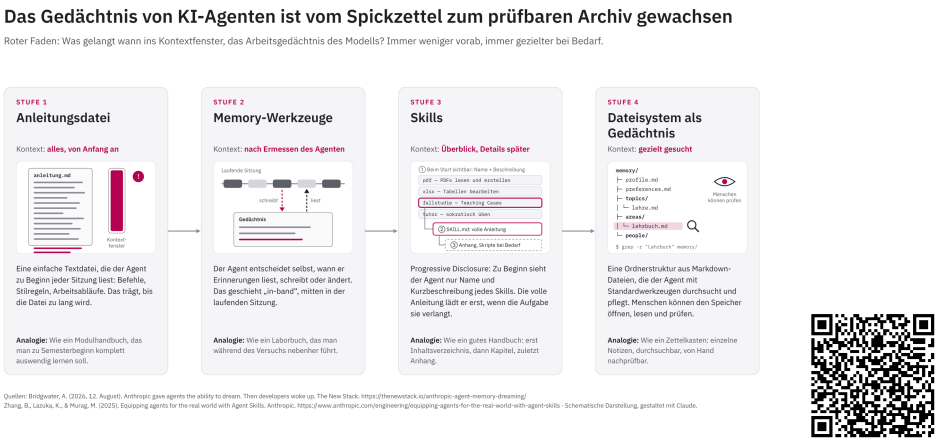


Abbildung 2.13. Vom Spickzettel zum prüfbaren Archiv: Die vier Stufen unterscheiden sich darin, was wann ins Kontextfenster gelangt, von der Anleitungsdatei (alles von Anfang an) bis zum Dateisystem (nur das gezielt Gesuchte) (schematische Darstellung). Die animierte Fassung: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/agenten-gedaechtnis.html aufrufen.

Wie aus Gesprächen überhaupt Erinnerungen werden, beschreiben Milam & Gulli (2025) mit zwei Speichern. Die **Sitzung** (*Session*) hält ein Gespräch vollständig und in Reihenfolge fest; aus ihr baut der Agent vor jeder Antwort den Kontext neu. Das **Gedächtnis** (*Memory*) bewahrt über viele Sitzungen hinweg nur das Verdichtete: Kernpunkte werden herausgezogen, mit dem Vorhandenen zusammengeführt, Veraltetes wird ersetzt, und in der nächsten Sitzung holt der Agent nur das Passende zurück.

Ein Gedächtnis ist etwas anderes als RAG: Bei RAG liest das Modell in Dokumenten, die wir ausgewählt haben; ins Gedächtnis schreibt der Agent selbst, und was er heute notiert, bestimmt, was er morgen für wahr hält. Die Anbieter sichern das mit den Mitteln jedes gemeinsam bearbeiteten Dokuments: Eine Änderung wird abgewiesen, wenn inzwischen eine andere Sitzung geschrieben hat, jede Änderung hinterlässt eine Version, und ein Speicher lässt sich nur zum Lesen einbinden, sodass ein Agent die Hausregeln kennt, aber nicht ändern kann (Anthropic, o. J.).

Wann der Agent ins Gedächtnis schreibt, ist die zweite Gestaltungsfrage. Auf Stufe 2 geschieht es *in-band*, mitten in der Sitzung, so wie man ein Labor-

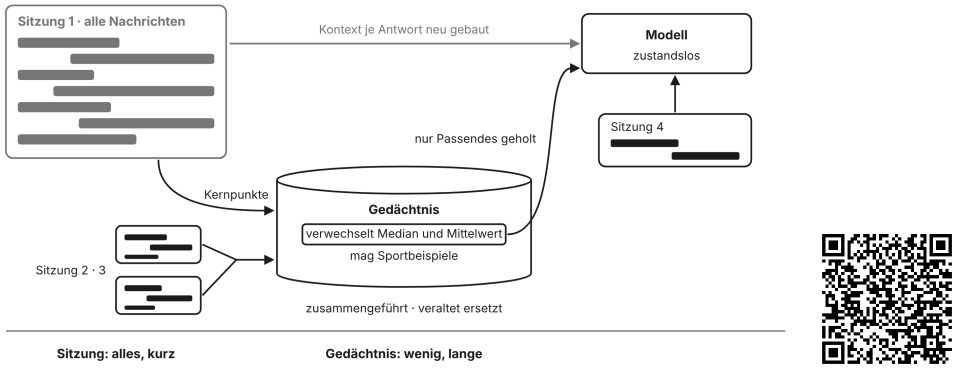


Abbildung 2.14. Die Sitzung schreibt alles mit, das Gedächtnis behält nur das Verdichtete: Ein Statistik-Tutor baut den Kontext aus der laufenden Sitzung, Kernpunkte wandern ins Gedächtnis, und am vierten Abend holt er nur das Passende zurück (eigene Darstellung nach Milam & Gulli (2025); schematisch). Die Fassung zum Durchklicken: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/sitzung-und-gedaechtnis.html aufrufen.

buch während des Versuchs führt. Seit Mai 2026 gibt es zusätzlich Läufe *out-of-band*, bei Anthropic „Dreaming“ genannt: Ein eigener Durchgang liest den Speicher und frühere Sitzungen und schlägt eine überarbeitete Fassung vor, über deren Übernahme der Betreiber entscheidet (Anthropic, 2026d). Donald Schön unterschied bei Berufspraktikern *reflection-in-action*, das Umsteuern mitten im Handeln, von *reflection-on-action*, dem Blick zurück, wenn die Arbeit ruht (Schön, 1983); Reflexion kommt vom lateinischen *reflectere*, zurückbeugen. Lerntagebuch und Nachbesprechung eines Praktikums sind genau diese beiden Formen, und die zweite hat ohne die erste wenig Stoff. Was daraus für die Verantwortung folgt, steht in Kapitel 5.4.

Ein konstruiertes Anwendungsbeispiel in der Online-Fassung zeigt, wie ein falscher Eintrag im Gedächtnis ein Semester lang das Feedback prägt.

Empfehlung für die Lehre

Wenn Studierende über ein Semester mit einem Agenten an einem Projekt arbeiten, lassen Sie das Team ein gemeinsames Projektgedächtnis führen: eine Textdatei mit Entscheidungen, offenen Fragen und geprüf-

ten Quellen, jeder Eintrag mit Datum und Namen. Der Agent liest sie zu Beginn jeder Sitzung und schlägt Ergänzungen vor; eingetragen wird erst, was ein Teammitglied gelesen hat. Zu jedem Meilenstein geht das Team die Datei gemeinsam durch, wie ein Dream-Lauf von Hand: Was ist überholt, was doppelt, was falsch? Prüfkriterium: Kann ein neues Teammitglied allein aus der Datei sagen, was entschieden ist und warum?

2.5 Ressourcenverbrauch der Modelle

Studierende fragen regelmäßig nach dem Energiehunger der KI, und zwischen „Weltuntergang“ und „keinerlei Problem“ lohnt ein Blick auf die Größenordnungen. Eine einzelne Textanfrage ist billig: Schätzungen von 2025 liegen zwischen 0,3 Wattstunden für ein großes Chat-Modell und 0,03 Wattstunden für kleine Modelle, also etwa so viel wie zehn Sekunden Video-Streaming (Elsworth et al., 2025; O'Donnell & Crownhart, 2025; You, 2025). Teuer sind die komplexen Aufträge: Ein hochwertiges Video von fünf Sekunden kann rund eine Kilowattstunde kosten, so viel wie eine Stunde Mikrowelle, und weil die Nutzerzahlen schneller wachsen als die Effizienz, übersteigt der Energiebedarf der Anfragen inzwischen den des Trainings (O'Donnell & Crownhart, 2025; Spencer & Singh, 2025). Rechenzentren verbrauchten 2024 nach der Internationalen Energieagentur (IEA) rund 1,5 Prozent des weltweiten Stroms (International Energy Agency, 2025); Sorge bereitet die Prognose, nach der sich ihr Verbrauch bis 2030 mehr als verdoppeln dürfte, oft aus fossilen Quellen (International Energy Agency, 2025; O'Donnell & Crownhart, 2025; Spencer & Singh, 2025). Gefordert ist deshalb Transparenz der Anbieter über ihren Energiebedarf, damit Politik und Nutzer die Kosten abschätzen können (O'Donnell & Crownhart, 2025). Für die Lehre heißt das: Eine Seminarsitzung mit Chat-Nutzung fällt energetisch nicht ins Gewicht; wer Bilder, Videos oder lange Agentenläufe erzeugen lässt, sollte das wissen und gegenüber den Studierenden benennen.

Der vollständige Exkurs mit Rechenbeispielen, Quellen und laufend aktualisierten Zahlen steht online unter https://th-koln-bartnik.github.io/genai4teaching/energie.html.



Abbildung 2.15. Exkurs „Ressourcenverbrauch der Modelle", Online-Fassung: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/energie.html aufrufen.

2.6 Vertiefung: Was im Modell und im Harness passiert

Dieser Abschnitt vertieft die Technik hinter den Grundbegriffen und kann übersprungen werden; die Kernaussagen setzen ihn nicht voraus. Er zeigt, wie ein Modell rechnet, was die Forschung in seinem Inneren findet und wie Skills, Werkzeuganschluss und Gedächtnis den Harness eines Agenten ausfüllen.

2.6.1 Tokens, Zahlen, Aufmerksamkeit

Um das nächste Wort vorherzusagen, zerlegt das Modell den Text in **Tokens**, kleine Bausteine aus ganzen Wörtern, Wortteilen oder Satzzeichen (Jurafsky & Martin, 2025, Kap.2). Jedes Token hat eine feste Nummer und wird in einen **Vektor** übersetzt, eine lange Zahlenreihe, die seine Bedeutung als Ort auf einer Art Stadtplan beschreibt; ähnliche Wörter wohnen dort in der Nachbarschaft. Diesen Vorgang nennt man **Embedding** (englisch für Einbettung). Wie viele Tokens ein Text braucht, hängt von der Sprache ab, und das hat Folgen für Kosten und Länge, wie die Vorhersagefrage der folgenden Animation zeigt. Sie führt in acht Schritten vom Satz „Die Bank steht unter einem Baum." zum nächsten Wort.

Dieselbe Kette gibt es noch einmal als Film, diesmal in neun Genres: Ein Film noir zerlegt den Text in Tokens, eine Naturdokumentation beringt sie mit Nummern, eine Quizshow lässt das nächste Token ziehen, und ein Gerichtsdrama verhandelt, warum wahrscheinlich nicht wahr heißt. Der Film hält

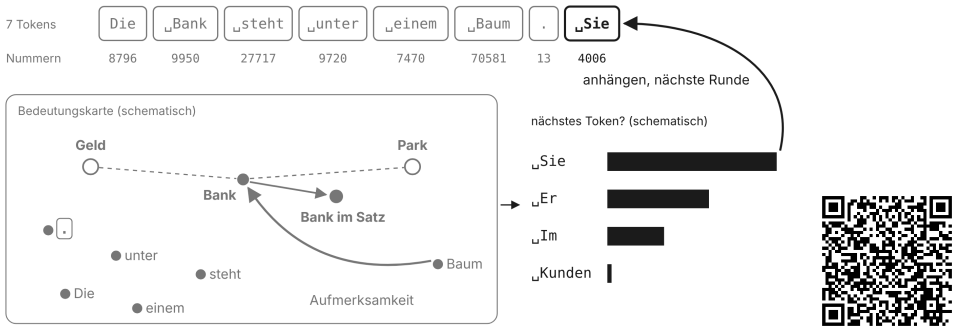
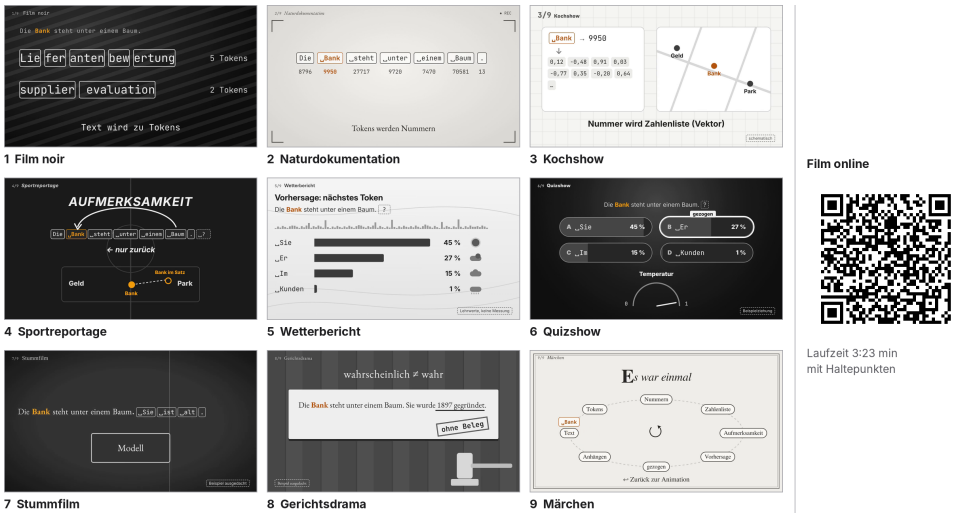


Abbildung 2.16. Ein Sprachmodell rechnet mit Zahlen, nicht mit Wörtern: Der Satz wird in Tokens mit festen Nummern zerlegt (echte Werte, Tokenizer o200k_base), über die Aufmerksamkeit rückt „Bank“ durch „Baum“ in die Nachbarschaft von „Park“, und aus einer Wahrscheinlichkeitsverteilung wird das nächste Token gezogen (eigene Darstellung; Bedeutungskarte und Werte schematisch). Die Fassung zum Durchklicken: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/vom-satz-zum-naechsten-wort.html aufrufen.

nach jedem Genre an und stellt Ihnen an drei Stellen eine Frage, bevor die nächste Szene sie auflöst; mit den Fragen dauert er etwa fünf Minuten. Die Idee stammt von Ethan Mollick, der ein Sprachmodell mit einem einzigen Prompt ein Video bauen ließ, das den Begriff Rekursion mit neun Stilwechseln erklärt (E. Mollick, 2026c).

Selbsttest zum Film. Beantworten Sie die drei Fragen, bevor Sie in **?@sec-loesung-token-genres** nachsehen.

1. Welche Kette beschreibt, wie ein Sprachmodell das nächste Token erzeugt? (a) Text → Tokens → Zahlen → Wahrscheinlichkeiten → Auswahl → Anhängen; (b) Text → Wörterbuch → Bedeutung nachschlagen → Antwort; (c) Text → Wahrscheinlichkeiten → Tokens → Anhängen.
2. Warum braucht „Lieferantenbewertung“ mehr Tokens als „supplier evaluation“? (a) Weil Deutsch für das Modell schwerer zu verstehen ist; (b) weil der Tokenizer sein Vokabular aus Texten gelernt hat, in denen Englisch überwiegt; (c) weil das Modell deutschen Text zuerst ins Englische übersetzt.
3. Warum ist eine flüssige Antwort nicht automatisch eine richtige? (a) Weil das Modell absichtlich täuscht; (b) weil gewählt wird, was wahr-



Film online

Laufzeit 3:23 min
mit Haltepunkten

Abbildung 2.17. Neun Genres, eine Kette: Tokens, Nummern, Zahlenlisten, Aufmerksamkeit, Wahrscheinlichkeiten, Auswahl, Anhängen. Standbilder aus einem Film von gut drei Minuten mit Haltepunkten, erstellt mit Claude Code und HyperFrames 0.9.2 (HeyGen, 2026); Stimme KI-erzeugt (ElevenLabs v4); Bedeutungskarte und Wahrscheinlichkeiten schematisch. Den Film gibt es nur in der Online-Version: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/kapitel02-grundlagen.html#vid-naechstes-token-genres aufrufen.

scheinlich folgt, nicht, was geprüft wahr ist; (c) weil flüssige Antworten grundsätzlich falsch sind.

> **i** So entstand dieser Film
>
> Der Bauauftrag passt in einen Satz: „Erzähle die Kette aus diesem Abschnitt in neun Szenen à 20 Sekunden, jede in einem anderen Filmgenre, mit den echten Tokenwerten aus der Animation, und baue daraus einen Film mit HyperFrames.“ Claude Code schrieb Drehbuch, Szenen und eine Bauanleitung, die die Szenenlängen aus der Tonaufnahme ableitet und die Tokenwerte bei jedem Bau neu berechnet; das Rendern dauert rund sechs Minuten. Die Schwäche zeigte ein Prüfagent: Im ersten Drehbuch zog „Baum“ die „Bank“ selbst Richtung Park, obwohl die Aufmerksamkeit nur zurückblickt. Die Szene zeigt jetzt wie die Animation einen neuen Punkt „Bank im Satz“.

Was heißt hier GPT? Die drei Buchstaben stehen für *Generative Pre-trained Transformer*. *Pre-trained* heißt, dass das Modell zuerst mit riesigen Textmengen **vortrainiert** wurde (**Pretraining**), und zwar *selbstüberwacht* (*self-supervised*): Die Aufgabe, das jeweils nächste Token vorherzusagen, steckt im Text selbst, niemand muss Lösungen beschriften. Danach bewerten Menschen verschiedene Antworten des Modells, und es lernt, die bevorzugten zu erzeugen (*Reinforcement Learning from Human Feedback*, **RLHF**); so wird aus einem Textfortsetzer ein Assistent. *Transformer* heißt das Rechenverfahren im Kern, und sein Herzstück ist die **Aufmerksamkeit** (*Attention*): Für jedes Token gewichtet das Modell, welche anderen Tokens für seine Bedeutung am wichtigsten sind; so zieht „Baum“ im Beispielsatz die „Bank“ in Richtung Park, wie Schritt 6 der Animation zeigt. Der Fachartikel von 2017, der das Verfahren vorstellte, trägt den knappen Titel „Attention is all you need“ (Vaswani et al., 2017).

Wer tiefer einsteigen will, findet im Transformer Explainer ein echtes kleines Sprachmodell zum Ausprobieren im Browser [Cho et al. (2025); https://poloclub.github.io/transformer-explainer/], bei Grant Sanderson ein siebenminütiges Erklärvideo (https://youtu.be/LPZh9BOjkQs), bei Brendan Bycroft eine dreidimensionale Animation der Rechenschritte (https://bbycroft.net/llm) und im frei verfügbaren Lehrbuch von Jurafsky & Martin (2025) die technischen Grundlagen.

2.6.2 Blick ins Modell

Eine Studie des KI-Labors Anthropic hat mit neuen Methoden nachgezeichnet, was in einem Sprachmodell zwischen Eingabe und Antwort geschieht (Lindsey et al., 2025). Das Modell nutzt **einen gemeinsamen Bedeutungsraum für verschiedene Sprachen**: Bei der Frage nach dem „Gegenteil von klein“ auf Englisch, Französisch oder Chinesisch aktivieren sich dieselben internen Merkmale (*features*) für „Kleinheit“ und „Gegenteil“, und erst spät wird die Antwort in die Zielsprache übersetzt. Es **plant mehrere Wörter im Voraus**: Soll eine Gedichtzeile auf ein bestimmtes Reimwort enden, wählt es dieses Wort früh und baut die Zeile darauf hin. Und es **rechnet auf parallelen Pfaden**: Bei einer Addition schätzt ein Pfad die Größenordnung, ein anderer bestimmt die letzte Ziffer; schaltet man diesen ab, bleibt nur die grobe Schätzung.

Zwischen Eingabe und nächstem Token entstehen so Zwischenschritte, die nie im Text erscheinen. Gefragt nach der Hauptstadt des Bundesstaats, in dem Dallas liegt, bildet das Modell intern zuerst „Texas“ und kommt erst darüber auf „Austin“ (Anthropic, 2025; Lindsey et al., 2025). Dass es über solche Schritte selbst nicht verlässlich Auskunft gibt, zeigt Kapitel 5.3.

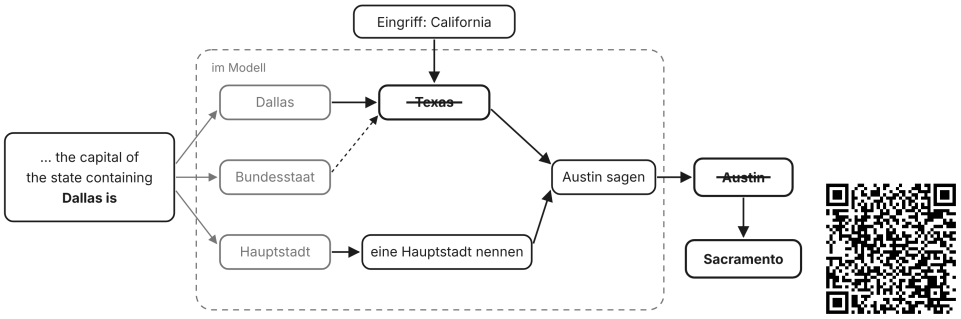


Abbildung 2.18. Vor der Antwort entsteht im Modell ein Zwischenschritt, der nie im Text steht: Aus „Dallas“ wird intern „Texas“ und daraus „Austin“; ersetzen Forschende „Texas“ durch „California“, antwortet das Modell „Sacramento“ (eigene Darstellung nach Lindsey et al. (2025) und Anthropic (2025); Claude 3.5 Haiku, stark vereinfacht). Die Fassung zum Durchklicken: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/zwischenschritt-texas.html aufrufen.

Kernaussagen

Zu Lernziel 1: Vier Kompetenzen und Grundbegriffe

1. Mit KI arbeiten heißt, vier Fragen zu beantworten: Was übernimmt die KI (Delegation), wie sage ich, was ich will (Description), wie beurteile ich das Ergebnis (Discernment), und wie setze ich sie verantwortlich ein (Diligence)? Die äußere Schleife entscheidet einmal je Vorhaben, was die KI übernimmt und welche Pflichten folgen, die innere dreht sich in jedem Arbeitsgang.
2. Ein Sprachmodell sagt das nächste Wort voraus und hat keine eingebaute Wahrheitsprüfung. Werkzeuge und Gedächtnis sitzen im Harness um das Modell, und der Harness legt fest, wie viel Handlungsspielraum das Modell bekommt.

Zu Lernziel 2: Delegation

3. Kontext entscheidet über Nutzen: Ein Modell allein antwortet aus dem Trainingswissen, mit RAG bekommt es ein Bücherregal, als Agent einen Werkzeugkoffer. Für die Lehre ist meist das Setup mit eigenem Material der richtige Einstieg.
4. Die Fähigkeiten der Modelle bilden eine zerklüftete Grenze. Wer sie nicht kennt, wird mit KI schlechter als ohne; je mehr Schritte der Mensch an Agenten abgibt, vom Centaur bis zur dunklen Fabrik, desto mehr hängt daran, dass er das Urteilen weiter übt.

Zu Lernziel 3: Description

5. Ein guter Prompt ist ein Werkvertrag: Er nennt Ziel, Grund, Material und das Kriterium, an dem die Arbeit abgenommen wird, und überlässt den Weg dem Modell. Höflichkeit, Drohungen, Trinkgeld und Expertenrollen machen die Antworten nicht besser.

Zu Lernziel 4: Discernment und Diligence

6. Halluzinationen sind kein Betriebsunfall, sondern folgen aus der Funktionsweise. Gegenmittel sind Eingrenzung des Inputs, Musterlösungen und systematische Prüfung.
7. Der Energieverbrauch einer einzelnen Anfrage ist gering, der Gesamtbedarf der Infrastruktur wächst stark. Beides stimmt, und die Steuerung ist eine politische Aufgabe.

Schlüsselbegriffe

Erklären Sie jeden Begriff in zwei, drei Sätzen in eigenen Worten; die Seitenzahl führt zur Stelle, an der er eingeführt wird.

- Delegation . . . . . S. 135
- Description . . . . . S. 135
- Discernment . . . . . S. 135
- Diligence . . . . . S. 136
- Kontextfenster (*context window*) . . . . . S. 35
- Zerklüftete Grenze (*jagged frontier*) . . . . . S. 139
- RAG (*Retrieval-Augmented Generation*) . . . . . S. 55
- Centaur und Cyborg . . . . . S. 88
- Prompt als Werkvertrag . . . . . S. 49
- Halluzination (*hallucination*) . . . . . S. 145

Übung. Tragen Sie zu jeder Szene den passenden Begriff aus der Liste ein. Lösungen: Anhang B.

Nr.	Szene	Begriff
1	Vor Semesterbeginn legt ein Dozent fest, dass der Chatbot Varianten der Übungsaufgaben entwirft; die Klausur schreibt er selbst. *Herkunft: konstruiert nach der äußeren Schleife des 4D-Modells* (*Kapitel 5.1.1*).	
2	Ein Student lässt sich für seine Hausarbeit Literatur empfehlen. Eine Angabe nennt Autorin, Jahr, Zeitschrift und Seitenzahlen; im Katalog ist der Aufsatz nicht zu finden. *Herkunft: konstruiert nach dem Mechanismus in Kapitel 5.3.*	
3	Ein Projektteam vergleicht die Zusammenfassung eines Fachartikels, die der Chatbot geliefert hat, Absatz für Absatz mit dem Original und markiert zwei Zahlen, die dort nicht stehen. *Herkunft: konstruiert nach Kapitel 5.3.*	
4	Im Projektbericht vermerkt ein Team, welche Abschnitte mit KI entworfen wurden und mit welchem Werkzeug. *Herkunft: konstruiert nach der Offenlegung im 4D-Modell* (*Kapitel 5.4*).	
5	Der Tutor-Bot im Modul „Grundlagen der BWL“ soll aus den Modulmaterialien antworten; vor jeder Antwort sucht das System die passenden Stellen aus Skript und Musterlösungen heraus. *Herkunft: konstruiert nach dem Tutor-Bot* (*Kapitel 7.2.2; Kapitel 6.3.3*).	
6	Ein Prompt für Klausuraufgaben beginnt nicht mehr mit „Du bist ein erfahrener Professor“, sondern nennt Lernziel, Zweck der Aufgaben, das Skriptkapitel und die Bedingung, dass jede Aufgabe ohne Taschenrechner lösbar ist. *Herkunft: konstruiert nach Kapitel 2.3.2.*	

Wiederholung aus früheren Kapiteln. *Erklären Sie diese Begriffe noch einmal in eigenen Worten, bevor Sie nachschlagen.*

- Fähigkeitsüberhang (*capability overhang*) . . . . . S. 17
- Erwünschte Schwierigkeiten (*desirable difficulties*) . . . . . S. 21
- Auslagerung des Denkens (*cognitive offloading*) . . . . . S. 21

i Lernfragen

Wiederholen

1. Beschreiben Sie in drei Schritten, wie ein Sprachmodell aus einem Prompt eine Antwort erzeugt (Vertiefung, Kapitel 2.6).
2. Warum gelten Halluzinationen nicht als Betriebsunfall, und welche drei Gegenmittel nennt das Kapitel?
3. Welche verbreiteten Prompt-Tricks bringen nichts, und welche vier Angaben braucht ein Auftrag stattdessen?

Anwenden

4. Ein Studierender fragt Sie, warum der Chatbot eine Quelle erfunden hat, die es nicht gibt. Erklären Sie es ihm in drei Sätzen ohne die Wörter „Token“ und „Wahrscheinlichkeit“, dann noch einmal mit.
5. Nehmen Sie eine typische Aufgabe aus Ihrer Lehre und spielen Sie durch: Was antwortet ein reines Sprachmodell, was ein Modell mit Ihrem Skript als Material, was ein Agent mit Internetzugang? Wo liegt jeweils das Risiko?

Beurteilen

6. Welche Aufgabe in Ihrem Fach liegt vermutlich außerhalb der Jagged Frontier? Wie würden Sie das prüfen, bevor Sie Studierende damit arbeiten lassen?
7. Der Energieverbrauch einer einzelnen Anfrage ist gering, der Bedarf der Infrastruktur wächst stark. Welche Folgerung ziehen Sie daraus für Ihre eigene Nutzung, und welche Entscheidung liegt nicht bei Ihnen?

8. Ein Agent soll Ihre Sprechstundenanfragen ein Semester lang vorsortieren und sich dabei merken, welche Fragen schon beantwortet sind. Welche Stufe des Gedächtnisses wählen Sie, und an welcher Stelle prüfen Sie, was er sich gemerkt hat (Vertiefung, Kapitel 2.6)?
9. Ein Studierendenteam baut auf einem großen Sprachmodell einen Lerntutor für Ihr Fach. Welche Teile davon gehören zum äußeren Harness, und an welchen zwei Stellen würden Sie den Handlungsspielraum des Modells begrenzen? Wessen Autonomie wächst dabei, wessen schrumpft?
10. Gehen Sie eine Aufgabe, die Sie demnächst an eine KI geben wollen, durch beide Schleifen des 4D-Kreislaufs. An welcher der vier Stufen würde Ihr Vorhaben am ehesten scheitern, und was legen Sie deshalb vorher fest?

Lösungshinweise: Anhang B.

Literaturverzeichnis

Anthropic (o. J.). Memory stores. *Claude Platform Docs*. https://platform.claude.com/docs/en/managed-agents/memory.

Anthropic (2024, November 25). Introducing the Model Context Protocol. https://www.anthropic.com/news/model-context-protocol.

Anthropic (2025, März 27). *Tracing the thoughts of a large language model*. Anthropic. https://www.anthropic.com/research/tracing-thoughts-language-model.

Anthropic (2026a). Plans & pricing. *Claude*. https://claude.com/pricing.

Anthropic (2026b). Prompting best practices. *Claude Platform Docs*. https://platform.claude.com/docs/en/build-with-claude/prompt-engineering/claude-prompting-best-practices.

Anthropic (2026c). Prompting Claude Opus 5. *Claude Platform Docs*. https://platform.claude.com/docs/en/build-with-claude/prompt-engineering/prompting-claude-opus-5.

Anthropic (2026d, Mai 6). New in Claude Managed Agents: Dreaming, outcomes, and multiagent orchestration. https://claude.com/blog/new-in-claude-managed-agents.

Ausubel, D. P. (1960). The use of advance organizers in the learning and

retention of meaningful verbal material. *Journal of Educational Psychology*, *51*(5), 267–272. https://doi.org/10.1037/h0046669.

Basil, S., Shapiro, I., Shapiro, D., Mollick, E., Mollick, L., & Meincke, L. (2025). *Prompting Science Report 4: Playing Pretend: Expert Personas Don't Improve Factual Accuracy*. arXiv. https://doi.org/10.48550/arXiv.2512.05858.

Bent, D., Handa, K., Durmus, E., Tamkin, A., McCain, M., Ritchie, S., Donegan, R., Martinez, J., & Jones, J. (2025). *Anthropic Education Report: How educators use Claude*. Anthropic.

Berryman, J., & Ziegler, A. (2025). *Prompt engineering for LLMs: the art and science of building large language model-based applications*. O'Reilly Media.

Bjork, E. L., & Bjork, R. A. (2011). Making things hard on yourself, but in a good way: Creating desirable difficulties to enhance learning. In M. A. Gernsbacher, R. W. Pew, L. M. Hough, & J. R. Pomerantz (Hrsg.), *Psychology and the real world: Essays illustrating fundamental contributions to society*: (S. 56–64). Worth Publishers.

Bolin, M. (2026, Januar 23). *Unrolling the Codex agent loop*. OpenAI. https://openai.com/index/unrolling-the-codex-agent-loop/.

Butterfield, B., & Metcalfe, J. (2001). Errors committed with high confidence are hypercorrected. *Journal of Experimental Psychology: Learning, Memory, and Cognition*, *27*(6), 1491–1494. https://doi.org/10.1037/0278-7393.27.6.1491.

Cho, A., Kim, G. C., Karpekov, A., Helbling, A., Wang, Z. J., Lee, S., Hoover, B., & Chau, D. H. (2025). Transformer Explainer: Interactive learning of text-generative models. https://doi.org/10.1609/aaai.v39i28.35347.

Edwards, J., & Emberson, L. (2026, Mai 29). Open models lag state-of-the-art closed models by 4 months. *Epoch AI*. https://epoch.ai/data-insights/open-closed-eci-gap.

Elsworth, C., Huang, K., Patterson, D., Schneider, I., Sedivy, R., Goodman, S., Townsend, B., Ranganathan, P., Dean, J., & Vahdat, A. (2025). Measuring the environmental impact of delivering AI at Google Scale. *arXiv preprint arXiv:2508.15734*.

Frontier Model Forum (2026). About us. *Frontier Model Forum*. https://www.frontiermodelforum.org/about-us.

Garner, J. K., & Alley, M. (2013). How the design of presentation slides affects audience comprehension: A case for the assertion–evidence approach. *International Journal of Engineering Education*, *29*(6), 1564–1579.

Google (2026a). Gemini 3 developer guide. *Gemini API Docs*. https://ai.google.dev/gemini-api/docs/gemini-3.

Google (2026b). Google AI Pro und Ultra: Abos im Vergleich. *Gemini*. https:

//gemini.google/de/subscriptions/?hl=de.
Grace, M., Hadfield, J., Olivares, R., & De Jonghe, J. (2026, Januar 9). Demystifying evals for AI agents. https://www.anthropic.com/engineering/demystifying-evals-for-ai-agents.
Grootendorst, M. (2025, März 17). A visual guide to LLM agents: Exploring the main components of single- and multi-agents. https://newsletter.maartengrootendorst.com/p/a-visual-guide-to-llm-agents.
Hashimoto, M. (2026, Februar 5). *My AI adoption journey*. https://mitchellh.com/writing/my-ai-adoption-journey.
HeyGen (2026). *HyperFrames*. GitHub. https://github.com/heygen-com/hyperframes.
Holec, H. (1981). *Autonomy and foreign language learning*. Pergamon.
Hu, T., & Collier, N. (2024). Quantifying the Persona Effect in LLM Simulations. https://doi.org/10.18653/v1/2024.acl-long.554.
Huffman, P., & Hutson, J. (2024). Enhancing History Education with Google NotebookLM: Case Study of Mary Easton Sibley's Diary for Multimedia Content and Podcast Creation. *ISRG Journal of Arts, Humanities and Social Sciences*, *2*(5).
Huyen, C. (2025). *AI engineering: building applications with foundation models*. O'Reilly.
International Energy Agency (2025). *Energy and AI*. IEA.
IT Center der RWTH Aachen (2026, Oktober 15). KI:connect – Changes (Versionshistorie v1.6.0 bis v1.28.0). *IT Center Changes*. https://blog.rwth-aachen.de/itc-changes/category/kiconnect.
Jemisin, N. K. (2010). *The hundred thousand kingdoms*. Orbit.
Johnston, D., Holtz, D., Richmond, A. M., Ong, C., Tambe, P., & Chatterji, A. (2026). *The shift to agentic AI: Evidence from Codex*. https://doi.org/10.48550/arXiv.2606.26959.
Jurafsky, D., & Martin, J. H. (2025). *Speech and language processing: An introduction to natural language processing, computational linguistics, and speech recognition with language models*.
KI:connect.nrw (2026, Mai 11). Souveräne KI für NRW: Offene Sprachmodelle über KI:Inferenz.nrw in KI:connect. https://kiconnect.pages.rwth-aachen.de/pages/blog/2026/05/11/2026-05-11_souveraene-ki-nrw/.
Kotha, A., Lee, J., Zakariasson, E., et al. (2025). *GPT-5 Prompting Guide*. OpenAI.
Landfair, A. (2025). *Playtesting your ChatGPT prompt*. https://aipedagogy.org/assignment/playtesting-your-chatgpt-prompt/.
Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Kütt-

ler, H., Lewis, M., Yih, W., Rocktäschel, T., Riedel, S., & Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. https://doi.org/10.48550/arXiv.2005.11401.

Lindsey, J., Gurnee, W., Ameisen, E., Chen, B., Pearce, A., Turner, N. L., Citro, C., Abrahams, D., Carter, S., Hosmer, B., Marcus, J., Sklar, M., Templeton, A., Bricken, T., McDougall, C., Cunningham, H., Henighan, T., Jermyn, A., Jones, A., … Batson, J. (2025). On the biology of a large language model. *Transformer Circuits Thread*.

Liu, N. F., Lin, K., Hewitt, J., Paranjape, A., Bevilacqua, M., Petroni, F., & Liang, P. (2024). Lost in the Middle: How Language Models Use Long Contexts. *Transactions of the Association for Computational Linguistics*, *12*, 157–173. https://doi.org/10.1162/tacl_a_00638.

Liu, R., Geng, J., Wu, A. J., Sucholutsky, I., Lombrozo, T., & Griffiths, T. L. (2025). *Mind Your Step (by Step): Chain-of-Thought can Reduce Performance on Tasks where Thinking Makes Humans Worse*. arXiv. https://doi.org/10.48550/arXiv.2410.21333.

Martin, L., Cemaj, G., & Cohen, M. (2026, April 8). Scaling Managed Agents: Decoupling the brain from the hands. Anthropic. https://www.anthropic.com/engineering/managed-agents.

Meincke, L., Mollick, E. R., Mollick, L., & Shapiro, D. (2025a). *Prompting Science Report 2: The Decreasing Value of Chain of Thought in Prompting*. arXiv. https://doi.org/10.48550/arXiv.2506.07142.

Meincke, L., Mollick, E., Mollick, L., & Shapiro, D. (2025b). *Prompting Science Report 1: Prompt Engineering is Complicated and Contingent*. arXiv. https://doi.org/10.48550/arXiv.2503.04818.

Meincke, L., Mollick, E., Mollick, L., & Shapiro, D. (2025c). *Prompting Science Report 3: I'll pay you or I'll kill you -- but will you care?* arXiv. https://doi.org/10.48550/arXiv.2508.00614.

Milam, K., & Gulli, A. (2025). *Context engineering: Sessions, memory* (Whitepaper). Google.

Ministerium für Kultur und Wissenschaft des Landes Nordrhein-Westfalen (2025, Januar 31). Studieren und Forschen mit Künstlicher Intelligenz: Hochschulen in Nordrhein-Westfalen erhalten zentralen Zugang zu KI-Diensten. *Pressemitteilung des Landes Nordrhein-Westfalen*. https://www.land.nrw/pressemitteilung/studieren-und-forschen-mit-kuenstlicher-intelligenz-hochschulen-nordrhein.

Mistral AI (2026). *Pricing*. https://mistral.ai/pricing/.

MIT Teaching + Learning Lab (2023). *Rethinking Your Problem Sets in the World of Generative AI | Teaching + Learning Lab*. https://tll.mit.edu/re

thinking-your-problem-sets-in-the-world-of-generative-ai/.
Mollick, E. (2026a, Februar 18). A Guide to Which AI to Use in the Agentic Era. https://www.oneusefulthing.org/p/a-guide-to-which-ai-to-use-in-the?post_id=188100833&r=2248w9.
Mollick, E. (2026b, Juli 23). An opinionated guide to which AI to use to do stuff: The Summer 2026 Edition. https://www.oneusefulthing.org/p/an-opinionated-guide-to-which-ai-b22.
Mollick, E. (2026c, September 26). How do you explain recursion? This one is pretty fun [Video attached]. *X*. https://x.com/emollick/status/2103688362960019567.
Mollick, E. R. (2025a, Januar 26). A new generation of AIs: Claude 3.7 and Grok 3. https://www.oneusefulthing.org/p/a-new-generation-of-ais-claude-37.
Mollick, E. R. (2025b, Dezember 20). The Shape of AI: Jaggedness, Bottlenecks and Salients. https://www.oneusefulthing.org/p/the-shape-of-ai-jaggedness-bottlenecks.
Morris, M. R., Sohl-Dickstein, J., Fiedel, N., Warkentin, T., Dafoe, A., Faust, A., Farabet, C., & Legg, S. (2024). Position: Levels of AGI for operationalizing progress on the path to AGI.
Nepal, S. K., Soh, S., Vinoya, N., Park, S., Roshanaei, M., & Harari, G. (2026). *Faithful where it can be checked: Auditing a reflection agent against its system prompt in a randomized trial*. https://doi.org/10.48550/arXiv.2609.19635.
O'Donnell, J., & Crownhart, C. (2025, Mai 20). We did the math on AI's energy footprint. Here's the story you haven't heard. *MIT Technology Review*.
OpenAI (2026a). *ChatGPT pricing*. https://chatgpt.com/pricing/.
OpenAI (2026b). Using GPT-5.5. *Using GPT-6* (*OpenAI API Docs*). https://developers.openai.com/api/docs/guides/gpt-5.5.
Persike, M. (2025, Dezember 5). Virtuelle API-Keys in KI:connect. https://kiconnect.pages.rwth-aachen.de/pages/blog/2025/12/05/2025-12-05_virtuelle-api-keys/.
Richland, L. E., Kornell, N., & Kao, L. S. (2009). The pretesting effect: Do unsuccessful retrieval attempts enhance learning? *Journal of Experimental Psychology: Applied*, *15*(3), 243–257. https://doi.org/10.1037/a0016496.
Roediger, H. L., & Pyc, M. A. (2012). Inexpensive techniques to improve education: Applying cognitive psychology to enhance educational practice. *Journal of Applied Research in Memory and Cognition*, *1*(4), 242–248. https://doi.org/10.1016/j.jarmac.2012.09.002.
Roucher, A., Noyan, M., & Wolf, T. (2024, Dezember 31). Introducing smolagents, a simple library to build agents. https://huggingface.co/blog/sm

olagents.
Russell, S. J., & Norvig, P. (2021). *Artificial intelligence: a modern approach*. Pearson.
SAE International (2021). *Taxonomy and definitions for terms related to driving automation systems for on-road motor vehicles (J3016_202104)*. SAE International. https://doi.org/10.4271/J3016_202104.
Schick, T., Dwivedi-Yu, J., Dessì, R., Raileanu, R., Lomeli, M., Hambro, E., Zettlemoyer, L., Cancedda, N., & Scialom, T. (2023). Toolformer: Language models can teach themselves to use tools. https://doi.org/10.48550/arXiv.2302.04761.
Schluntz, E., & Zhang, B. (2024, Dezember 19). Building effective agents. https://www.anthropic.com/engineering/building-effective-agents.
Schön, D. A. (1983). *The reflective practitioner: How professionals think in action*. Basic Books.
Sequoia Capital (2026). *Google DeepMind's Logan Kilpatrick: Why the model eats the harness*. https://sequoiacap.com/podcast/google-deepminds-logan-kilpatrick-why-the-model-eats-the-harness.
Somala, V., & Emberson, L. (2025, August 15). Frontier AI performance becomes accessible on consumer hardware within a year. *Epoch AI*. https://epoch.ai/data-insights/consumer-gpu-model-gap.
Spear, S., & Bowen, H. K. (1999). Decoding the DNA of the Toyota Production System. *Harvard Business Review*, *77*(5), 96–106.
Spencer, T., & Singh, S. (2025). *Energy and AI* (World Energy Outlook Special Report). International Energy Agency.
Steinberger, P. (2025, Oktober 14). *Just Talk To It - the no-bs Way of Agentic Engineering | Peter Steinberger*. https://steipete.me/posts/just-talk-to-it.
Sweller, J. (2011). Cognitive load theory. In *Psychology of learning and motivation*: (Bd. 55, 37–76). Elsevier.
Tippett, C. D. (2010). Refutation text in science education: A review of two decades of research. *International Journal of Science and Mathematics Education*, *8*(6), 951–970. https://doi.org/10.1007/s10763-010-9203-x.
Tobor, J., Then Bergh, C., & Lüthi, R. (2026). *Use Cases in Bewegung: Wie KI Studium und Lehre weiter verändert* (Blickpunkt). Hochschulforum Digitalisierung.
Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. *Advances in neural information processing systems*, *30*.
Wecker, C. (2012). Slide presentations as speech suppressors: When and why learners miss oral information. *Computers & Education*, *59*(2), 260–273. ht

tps://doi.org/10.1016/j.compedu.2012.01.013.
Wiesinger, J., Marlow, P., & Vuskovic, V. (2024). *Agents* (Whitepaper). Google.
Willison, S. (2025, Oktober 5). Embracing the parallel coding agent lifestyle. *Simon Willison's Weblog*. https://simonwillison.net/2025/Oct/5/parallel-coding-agents/.
Yao, S., Zhao, J., Yu, D., Du, N., Shafran, I., Narasimhan, K., & Cao, Y. (2023). ReAct: Synergizing reasoning and acting in language models. https://doi.org/10.48550/arXiv.2210.03629.
You, J. (2025, Februar 7). How much energy does ChatGPT use? *Epoch AI*. https://epoch.ai/gradient-updates/how-much-energy-does-chatgpt-use.
Zhang, B., Lazuka, K., & Murag, M. (2025, Oktober 16). Equipping agents for the real world with Agent Skills. *Anthropic Engineering*. https://www.anthropic.com/engineering/equipping-agents-for-the-real-world-with-agent-skills.

3 Prinzipien der Automation von Aufgaben

In diesem Kapitel

- Was sind unsere Aufgaben?
- Wer macht was: Arbeitsweisen von Centaur bis dunkle Fabrik
- Leitungsaufgabe Mensch–LLM

3.1 Was sind unsere Aufgaben?

Bevor wir die Aufgaben der Lehre einzeln ansehen, ein Blick darauf, welchen Berufen Gespräche mit einer KI überhaupt zugeordnet werden. Der *Anthropic Economic Index* ordnet Gespräche mit dem Assistenten Claude automatisch Berufen und Arbeitsaufgaben der US-Berufsdatenbank O*NET zu und veröffentlicht, welcher Anteil der Gespräche eines Monats auf jeden Beruf entfällt (Massenkoff et al., 2026; National Center for O*NET Development, 2026).[1] Die *Bibliothek der Prompts* macht daraus einen Raum: Jedes Regal ist eine von 22 Berufshauptgruppen, jedes Buch ein Beruf, die Buchbreite sein Anteil. Raten Sie zuerst, wo das Regal der Lehre steht, und machen Sie dann den Rundgang; wer vorher rät, behält die Auflösung besser, auch wenn der Tipp danebenlag (Richland et al., 2009). Das dauert etwa fünf Minuten.

> **Raten Sie zuerst**
>
> In einer Bibliothek stehen 22 Regale, eines je Berufshauptgruppe, sortiert nach dem Anteil der Gespräche mit Claude, die ihr im Mai 2026 zugeordnet wurden. Zu einem davon, *Bildung, Ausbildung und Biblio-*

[1] Datensatz `Anthropic/EconomicIndex` auf Hugging Face, Release vom 26. Juni 2026, Datei `aei_claude_ai_2026-06-26.csv`, Datenmonat Mai 2026, Kennzahl `pct` der Kategorie `soc_occupation`, Lizenz CC BY; Aufgaben je Beruf aus der O*NET 31.0 Database (`task_statements.csv`), Lizenz CC BY 4.0. Auszug und Übersetzung: `scripts/aei-bibliothek.py` im Repositorium des Buchs.

thek, gehören auch Hochschullehrende.
Auf welchem Platz von 22 steht dieses Regal?
☐ 1–3 ☐ 4–8 ☐ 9–15 ☐ 16–22
Welcher Anteil der Gespräche wurde ihm zugeordnet?
☐ unter 5 % ☐ 5–10 % ☐ 10–20 % ☐ über 20 %
Den Rundgang mit allen 22 Regalen gibt es in der Online-Version: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/kapitel03-automation.html#sec-bibliothek-prompts aufrufen. Die Lösung steht in den Lösungshinweisen im Anhang (Abbildung B.2).

Was die Auflösung über die Lehre sagt und was nicht, steht bei der Lösung im Anhang.

Die Daten zeigen Gesprächsinhalte, nicht die Menschen dahinter. Ein Gespräch über eine Klausur landet im Bildungsregal, auch wenn eine Studentin es geführt hat; und als Momentaufnahme eines Monats mit einem einzigen Assistenten sagt die Bibliothek nichts darüber, welche Berufe KI verändert.

i So entstand diese Bibliothek

Gebaut hat sie ein Agent (Claude Opus 5.5) in einer Sitzung von rund 40 Minuten, auf einen Satz hin, der auf eine schriftliche Bauanleitung verwies: „Lies [die Regeln], [die Standards] und [den Auftrag] und führe den Auftrag aus." Er zog die Werte per Skript aus Economic Index und O*NET und baute den Raum mit Three.js; 1.483 Berufsnamen und Aufgaben übersetzten fünf Teilagenten. Die Schwäche: Sie übersetzten uneinheitlich, „students" etwa mal als „Studierende", mal als „Lernende". Schreibweisen ließen sich per Skript angleichen, Bedeutungen nicht. Eine Prompt-Vorlage steht am Ende des Rundgangs.

Woraus besteht das im Detail und wo könnten große Sprachmodelle (LLMs) helfen? Vor- und Nachbereitung, Evaluation, Beratung, Planung und vieles mehr lassen die Stunden eines Tages schnell vergehen. Abbildung 3.1 zeigt die 25 Hauptaufgaben, die Lehrende nach Umfragen des US-

Arbeitsministeriums verrichten (https://www.onetonline.org/link/summary/25-1011.00). Welche Auswirkungen können wir von LLM auf diese konkreten Aufgaben erwarten?

1	Vorlesungen vorbereiten und halten	14	Mit Unternehmen kooperieren (Programme, Praktika)
2	Studienleistungen bewerten und benoten	15	In Gremien der Hochschule mitarbeiten
3	Diskussionen anregen und moderieren	16	Lehrmaterial und Lehrbücher auswählen
4	Kursmaterial erstellen (Syllabus, Übungen, Handouts)	17	Literaturlisten zusammenstellen
5	Fachlich auf dem Laufenden bleiben	18	An Veranstaltungen teilnehmen (Campus, Region)
6	Curricula und Kursinhalte planen und überarbeiten	19	Neue Kolleginnen und Kollegen betreuen
7	Anwesenheit, Noten und Akten führen	20	Verwaltungsaufgaben übernehmen, etwa im Dekanat
8	Forschen und publizieren	21	Bei Studierendengewinnung und Vermittlung mitwirken
9	Prüfungen erstellen, durchführen und bewerten	22	Studentische Organisationen beraten
10	Sprechstunden anbieten	23	Abschluss-, Praxis- und Forschungsarbeiten betreuen
11	Mit dem Kollegium zusammenarbeiten	24	Unternehmen und Behörden beraten
12	Zu Studium und Berufsweg beraten	25	Forschungsanträge schreiben
13	Kurswebseiten erstellen und pflegen		

Abbildung 3.1. Was für Aufgaben erledigen Lehrende? 25 Einzelaufgaben am Beispiel „Business Teachers, Postsecondary“ (25-1011.00) nach Umfragen des US-Arbeitsministeriums. Interaktive Fassung mit Häufigkeiten und KI-Nutzung je Aufgabe: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/kapitel03-automation.html#fig-onet-tasks aufrufen. Enthält Informationen aus O*NET OnLine des U.S. Department of Labor, Employment and Training Administration (USDOL/ETA), verwendet unter der Lizenz CC BY 4.0 (https://www.onetonline.org/help/license); übersetzt und gekürzt, USDOL/ETA hat diese Änderungen weder geprüft noch gebilligt. O*NET® ist eine Marke von USDOL/ETA.

Eine erste Antwort geben die Nutzungsdaten des Anthropic Economic Index für Mai 2026 (Massenkoff et al., 2026): Nur 9 der 25 Aufgaben erscheinen dort überhaupt; für die übrigen 16, darunter Sprechstunden, Gremienarbeit und die Betreuung von Abschlussarbeiten, sind keine Werte veröffentlicht. Den höchsten Automatisierungsanteil hat das Erstellen, Durchführen und Bewerten von Prüfungen: In 60 % dieser Gespräche gibt der Mensch die Aufgabe

an das Modell ab, statt mit ihm an ihr zu arbeiten, wobei Automatisierung hier nach Handa et al. (2025) die Form des Gesprächs beschreibt und nicht die Verlagerung der Aufgabe selbst. Gespräche über Vorlesungen stuft der Index dagegen zu 92 % als Studium ein und nur zu 6 % als Arbeit; er ordnet Inhalte ein, keine Personen, doch das Muster passt zu Studierenden, die eine Vorlesung nacharbeiten, eher als zu Lehrenden, die eine vorbereiten.

Historische Studien zeigen, dass Technologie typischerweise **Tätigkeiten** (*tasks*) beeinflusst und eher selten ganze Jobs ersetzt. Den Rahmen dafür liefert das Aufgabenmodell (*task model*), das der Nobelpreisträger Daron Acemoglu mit Fredric Kong und Pascual Restrepo im *Handbook of Labor Economics* zusammengefasst hat (Acemoglu et al., 2025). Für Lehrende, die ihre eigene Arbeit planen, zählen drei Formen technologischen Wandels aus diesem Modell. Bei der **Automatisierung** (*automation*) wandert eine Aufgabe vom Menschen zur Technik. Bei der **Augmentierung** (*labor-augmenting technology*) bleibt die Aufgabe beim Menschen, der sie mit technischer Unterstützung schneller oder besser erledigt. Und Technik schafft **neue Aufgaben** (*new tasks*), die es vorher nicht gab. Die vierte Form des Modells, leistungsfähigere Maschinen in Aufgaben, die sie schon erledigen (*capital-augmenting technology*), lassen wir hier beiseite. Die Arbeitsmarktforschung beschreibt die Folgen aus Sicht der Beschäftigten und spricht von Verdrängung (*displacement effect*) und Wiedereinsetzung (*reinstatement effect*); wer die eigene Lehre plant, fragt dagegen, welche Aufgabe wohin wandert.

Form	Beschreibung	Aufgaben in der Lehre (Beispiele)
Automatisierung (*automation*)	Aufgabe wandert vom Menschen zur KI	• Erstellung, Durchführung und Bewertung von Prüfungen (x) • Verwaltung von Noten und Anwesenheit (x) • Vorbereitung standardisierter Lehrmaterialien (x) • Zusammenstellung von Bibliographien (x)
Augmentierung (*labor-augmenting technology*)	KI unterstützt Menschen; dieselbe Aufgabe braucht weniger Zeit oder gelingt besser	• Vorbereitung und Durchführung von Vorlesungen (x) • Durchführung von Seminaren und Diskussionen (x) • Akademische und berufliche Beratung (?/x) • Forschung und Publikation (x) • Pflege von Webseiten und digitalen Ressourcen (?/x)

Form	Beschreibung	Aufgaben in der Lehre (Beispiele)
Neue Aufgaben (*new tasks*)	KI schafft Aufgaben, die es vorher nicht gab	• Entwicklung KI-gestützter Lehrkonzepte (x) • Qualitätskontrolle von KI-Materialien (x) • Gestaltung individueller Lernpfade (x) • Ethische und rechtliche Begleitung (x) • Weiterbildung des Personals (x)

Tabelle 3.1. Welche Aufgaben in der Lehre wandern zur KI, bei welchen unterstützt sie, und welche kommen neu hinzu? Legende: x = klarer Effekt, ? = gemischter Effekt. Quelle: Aufgabenmodell nach Acemoglu et al. (2025)

In Tabelle 3.1 übertragen wir die drei Formen auf konkrete Aufgaben in der Hochschullehre.

Das folgende Video spielt die drei Formen an den Aufgaben aus Tabelle 3.1 durch. Vier Kacheln wandern von der Lehrperson zur KI, fünf schrumpfen, weil dieselbe Aufgabe weniger Zeit braucht, und fünf neue kommen hinzu. Die Größen der Kacheln sind nicht gemessen; sie zeigen die Richtung der Effekte, nicht ihr Ausmaß.

Die **Automatisierung** betrifft hauptsächlich administrative und stark standardisierte Tätigkeiten. Aufgaben wie das Erstellen, Durchführen und Bewerten von Prüfungen, die Verwaltung von Noten und Anwesenheiten sowie die Vorbereitung standardisierter Lehrmaterialien oder Literaturzusammenstellungen werden voraussichtlich vollständig oder überwiegend von KI übernommen. Anwendungsstudien und Umfragen der letzten zwei Jahre geben hierzu deutliche Hinweise (Morgan, 2024; Naddaf, 2025; Ogunleye et al., 2024; Ou et al., 2024; Tutton & Cohen, 2025). Wie weit die Automatisierung bei der Bewertung tatsächlich reicht, lässt sich inzwischen präzise sagen. Sehfähige Sprachmodelle bewerten fotografierte handschriftliche Mathematik-Abgaben entlang der Rubriken der Lehrenden insgesamt zuverlässig, aber 87 % der verbleibenden Fehler des besten Modells sind **Transkriptionsfehler** (Handschrift lesen, äquivalente Umformungen erkennen, Bildqualität), nicht falsch angewandte Bewertungskriterien (Levine et al., 2026). Automatisiert wird also die Rubrik-Anwendung; die menschliche Arbeit verlagert sich auf Erfassungsqualität und stichprobenartige Kontrolle, ein konkretes Beispiel für die neue Aufgabe „Qualitätskontrolle von KI-Materialien“ im



Video online

Laufzeit 60 s

Abbildung 3.2. Automatisierung, Augmentierung und neue Aufgaben an den Aufgaben aus Tabelle 3.1: Vier Aufgaben wandern zur KI, fünf schrumpfen, fünf neue kommen hinzu. Schlussbild eines Videos (60 s), erstellt mit Claude Code und HyperFrames; Kachelgrößen nicht gemessen. Das Video gibt es nur in der Online-Version: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/kapitel03-automation.html#vid-acemoglu-restrepo aufrufen.

Feld „Neue Aufgaben“ derselben Tabelle (zu den Grenzen KI-gestützten Benotens vgl. Kapitel 5.5).

Die **Augmentierung** betrifft zentrale Lehr-, Forschungs- und Betreuungstätigkeiten, die mit KI-Unterstützung effizienter werden. Dazu zählen die Vorbereitung und Durchführung von Vorlesungen, Seminaren und Diskussionen, akademische und berufliche Beratung der Studierenden sowie Forschung und Publikationen. KI unterstützt hier durch automatische Literaturauswertungen, personalisierte Lerninhalte oder Pflege digitaler Ressourcen, sodass Lehrende ihre Kernaufgaben besser und effektiver erfüllen können (Gottweis et al., 2025; Meincke et al., 2024; E. R. Mollick & Mollick, 2023, 2024; Schwarcz et al., 2025).

Gemischte Effekte treten bei einigen Aufgaben wie der Entwicklung und Pflege von Kurswebseiten, dem digitalen Aufzeichnen von Vorträgen und der Auswahl von Lehrmaterialien auf, bei denen KI Teile der Aufgabe übernimmt und die Lehrenden beim Rest unterstützt.

Schließlich schafft generative KI gänzlich **neue Aufgaben**. Dazu gehören beispielsweise die Entwicklung neuer KI-gestützter Lehrkonzepte und -methoden, Qualitätskontrollen von KI-generierten Lehrmaterialien, Gestaltung individueller Lernpfade, ethische und rechtliche Begleitung des KI-Einsatzes sowie die Weiterbildung des Lehrpersonals im Umgang mit KI-Technologien (Dihan et al., 2025; E. R. Mollick et al., 2024; E. R. Mollick & Mollick, 2024).

Durch diese differenziertere Analyse der drei Formen wird klar, dass die Einführung von KI in die Lehre zwar mit hoher Sicherheit **deutliche Änderungen im Aufgaben-Mix** und der Zeitanteile bedeutet, die wir mit verschiedenen Aufgaben verbringen. Das ist nicht neu: Wer bestellt noch regelmäßig per Fernleihe, schickt Briefe oder kopiert in großem Umfang? Wir sehen, dass generative KI wahrscheinlich mittelfristig einen Teil der bisherigen Tätigkeiten automatisieren, Lehrende bei zentralen Kernaufgaben unterstützen und zugleich neue, spezialisierte Aufgaben in der Lehre schaffen wird.

Ob das **insgesamt zu einer Zeitersparnis führt, ist keineswegs sicher**, denn die neuen Aufgaben um die Einrichtung und Betreuung der KI-Unterstützung können sehr zeitintensiv sein, als Beispiel sei hier etwa die Einrichtung eines Physik-Tutor-Bots (Kestin et al., 2025) oder einer Startup-Simulation, in der KI in verschiedenen Rollen beim Aufsetzen und Verbessern von Geschäftsplänen hilft (E. R. Mollick et al., 2024). Beide

Konzepte führen sichtlich zu einer Verbesserung der Lehre, aber die gibt es auch hier nicht umsonst.

Ihre Einschätzung prüfen

„Wenn die KI Übungsblätter in einer Stunde statt einem Tag erstellt, haben Lehrende am Ende des Semesters Zeit gewonnen."
Auflösung: eher nicht. Sicher ist nur, dass sich der Aufgaben-Mix verschiebt: Einiges wandert zur KI, anderes geht schneller, und neue Aufgaben kommen hinzu, etwa die Qualitätskontrolle der Materialien und die Pflege eines Tutors. Ob am Ende Zeit übrig bleibt, hängt davon ab, wie viel diese neuen Aufgaben verschlingen; gemessen ist die Bilanz bisher nicht.

3.2 Wer macht was: Arbeitsweisen von Centaur bis dunkle Fabrik

Wer welchen Schritt einer Aufgabe übernimmt, ist die dritte Delegationsfrage. Das 4D-Modell unterscheidet drei Formen der Zusammenarbeit, die es *Modalitäten* nennt (Dakan & Feller, 2025): In der **Automation** führt die KI eine Aufgabe aus, die der Mensch festgelegt hat; in der **Augmentation** erledigen Mensch und KI sie gemeinsam und im Wechsel; in der **Agency** richtet der Mensch eine KI ein, die später selbstständig handelt, oft für andere (nicht zu verwechseln mit den Formen des Aufgabenmodells in Kapitel 6.1). Der Hiwi aus Kapitel 6 arbeitet in der Automation, der Copilot in der Augmentation, Tutor und Simulator in der Agency.

Feiner unterscheidet die Studie zur Jagged Frontier (Dell'Acqua et al., 2023). Der **Centaur** teilt die Aufgabe: Er überlässt der KI die Teilprobleme innerhalb der Grenze und konzentriert sich selbst auf den Rest. Der **Cyborg** arbeitet in ständigem Wechsel mit der KI und nutzt ihre Rückmeldungen laufend. Beide setzen voraus, dass der Mensch die Stärken und Schwächen des Modells kennt. Eine spätere Studie des weitgehend selben Teams mit 776 Beschäftigten von Procter & Gamble fand, dass Einzelne mit KI-Unterstützung teils das Leistungsniveau ganzer Teams erreichten; die KI wirkte als „**Cybernetic Teammate**" (Dell'Acqua et al., 2025).

Mit stärkeren Agenten kommen Arbeitsweisen hinzu, in denen der Mensch

nicht mehr in jeder Schleife sitzt. Als **Beschwörer** (*conjurer*) ruft er Agenten bei Bedarf herbei, weist ihnen Arbeit zu und bewertet, was zurückkommt, ohne den Weg dorthin zu begleiten. Mollick hält das für die leistungsfähigste Arbeitsweise, die aber neue Risiken bringt, weil niemand mehr genau sieht, wie die KI zu ihren Ergebnissen kommt (E. R. Mollick, 2026b). Am Ende der Reihe steht die **dunkle Fabrik** (*dark factory*): Menschen legen fest, was entstehen soll, Maschinen führen aus und prüfen; das trägt nur dort, wo eine Maschine feststellen kann, ob ein Ergebnis stimmt, etwa bei Software mit automatischen Tests (E. R. Mollick, 2026a). Dazwischen liegt die **Dämmerfabrik** (*twilight factory*): Agenten arbeiten, aber ein vermittelnder Agent holt Menschen hinzu, wenn eine Freigabe nötig ist, Fachwissen fehlt, die Ideen zu gleichförmig werden oder eine Entscheidung interessant ist (E. R. Mollick, 2026a). Für die Lehre wiegt eine Folge am schwersten: Wer nur Freigaben und Ausnahmen bearbeitet, übt nie das Urteilen, das eine gute Freigabe voraussetzt, und die Fachleute, die künftig prüfen sollen, wachsen nicht nach (E. R. Mollick, 2026a). Das folgende Schema ordnet die fünf Arbeitsweisen den Schritten einer Aufgabe zu.

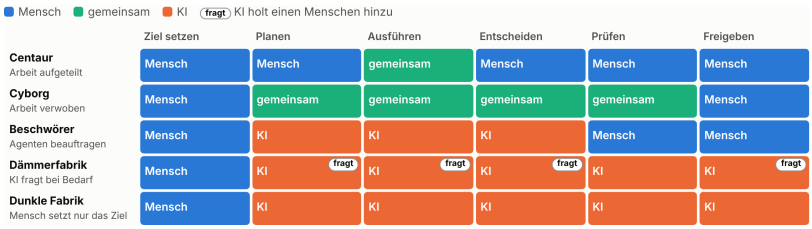


Abbildung 3.3. Mit jeder Arbeitsweise gibt der Mensch mehr Arbeitsschritte an die KI ab; „fragt“ markiert, wo der Agent in der Dämmerfabrik einen Menschen hinzuholt (Konzeptschema nach Dell'Acqua et al. (2023), E. Mollick (2024), E. R. Mollick (2026b) und E. R. Mollick (2026a); Zuordnung der Schritte eigene Lesart). Interaktive Fassung: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/ki-entwicklung.html?zeige=arbeitsweisen aufrufen.

Das folgende Durchspiel zeigt die fünf Arbeitsweisen an einer einzigen Aufgabe, einem Übungsblatt zur optimalen Bestellmenge mit vier Gruppenvarianten. Als Centaur lässt die Professorin nur den Aufgabentext formulieren, als Cyborg entwickelt sie die Aufgabe in zwölf kurzen Wechseln mit der KI. Als Beschwörer schreibt sie einen einzigen Auftrag; ein **Orchestrator**, ein Programm, das eine Aufgabe zerlegt, verteilt und die Teile wieder zusammenführt, beauftragt **Unteragenten** (*subagents*) für die Zahlen, die Texte und die

Prüfung (Anthropic, 2025; Schluntz & Zhang, 2024) (griechisch *orchēstra*, der Tanzplatz vor der Bühne; der Orchestrator ordnet, wer wann auftritt). In der Dämmerfabrik fragt ein Vermittler-Agent die Professorin bei den vier Anlässen; in der dunklen Fabrik bestehen alle Blätter die maschinelle Prüfung und werden doch still leichter, weil der Prüfer misst, ob die Lösungen stimmen, nicht ob die Aufgaben fordern. Die Online-Fassung spielt zwei weitere Fälle durch: Rückmeldungen auf Projektberichte, bei denen die KI-Verordnung menschliche Aufsicht verlangt (Europäisches Parlament und Rat der Europäischen Union, 2024, Anhang III Nr. 3 lit. b) (Kapitel 5.4.1.2), und die Aktualisierung einer Vorlesung. Die Denkspuren darin sind angenähert; auch echte Denkspuren geben nicht verlässlich wieder, wie ein Modell zu seinem Ergebnis kommt (Chen et al., 2025).

Dieselbe Aufgabe in fünf Arbeitsweisen: Übungsblatt zur Bestellmenge

Nachgestellte, gekürzte Dialoge und angenäherte Denkspuren; Zähler als Lehrmodell. Kästchen von links: Ziel, Planen, Ausführen, Entscheiden, Prüfen, Freigeben; blau Mensch, grün gemeinsam, orange KI; umrandet: Schritt, an dem die KI in der Dämmerfabrik einen Menschen fragt.

ARBEITSWEISE	MENSCH ↔ KI	KI ↔ KI · DENKSPUR	WER MACHT WAS
Centaur Arbeit aufgeteilt	„Formuliere einen Aufgabentext … ohne Lösung.“ KI liefert den Text; die Professorin rechnet selbst.	`Nur Text gefragt. Lösungsweg nicht verraten.`	Mensch: 2 KI entscheidet: 0 Agenten: 0
Cyborg Arbeit verwoben	„Aufgabe mit Haken.“ – „Rabatt ab 2.000 Stück?“ – „So, dass es knapp wird.“ – … zwölf Züge.	`Rabatt so legen, dass Lagerkosten den Vorteil fast aufheben.`	Mensch: 6 KI entscheidet: 0 Agenten: 0
Beschwörer Agenten beauftragen	Auftrag: „drei Aufgaben, vier Varianten, Musterlösung“. Bericht: „Den Haltekostensatz in C3 habe ich selbst von 80 % auf 25 % gesenkt.“	`Orchestrator → „Zahlen“: zwölf Sätze, Python, keine Texte. Prüfagent: „C3 unrealistisch.“`	Mensch: 2 KI entscheidet: 3 Agenten: 4
Dämmerfabrik KI fragt bei Bedarf	Ein Auftrag fürs Semester. Vermittler fragt viermal, z. B.: „Sensitivitätsanalyse oder Rabattstaffel? Welches dient Lernziel 3?“	`Vermittler: „Lernziel-Abwägung ist eine interessante Entscheidung, also fragen.“`	Mensch: 5 KI entscheidet: 9 Agenten: 6 Rückfragen: 4
Dunkle Fabrik Mensch setzt nur das Ziel	Ein Satz fürs Semester: „Alle Lösungen werden maschinell nachgerechnet.“ Danach kein Mensch mehr.	`„Aufgaben ohne Rabatt bestehen sicher.“ Alle Prüfungen grün, die Blätter werden leichter.`	Mensch: 1 KI entscheidet: alle Agenten: 5

Begriffe nach Dell'Acqua et al. (2023) und Mollick (2024; „Agency and agents“ und „30 months on the exponential“, 2026); Muster nach Schluntz & Zhang (2024); Denkspuren geben das Vorgehen eines Modells nicht verlässlich wieder (Chen et al., 2025).

Abbildung 3.4. Dieselbe Aufgabe in fünf Arbeitsweisen: Je mehr die KI übernimmt, desto weniger spricht der Mensch und desto mehr sprechen die Agenten miteinander. Dialoge nachgestellt und gekürzt, Denkspuren angenähert, Zähler als Lehrmodell (Muster nach Schluntz & Zhang (2024)). Interaktive Fassung mit zwei weiteren Fällen: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/ki-arbeitsweisen-durchspiel.html aufrufen.

Probieren Sie mal: Delegation an einem Berufsprofil

Wählen Sie einen Beruf, für den Sie ausbilden, und lassen Sie sich von einem Sprachmodell zehn typische Tätigkeiten dieses Berufs auflisten, etwa nach dem Berufsprofil der US-Datenbank O*NET. Ordnen Sie jede

Tätigkeit selbst einer der drei Formen aus Tabelle 3.1 zu: Automatisierung, Augmentierung oder neue Aufgabe. Lassen Sie das Modell dieselbe Zuordnung vornehmen und vergleichen Sie. Wo Sie abweichen, steckt meist eine Annahme über den Beruf, die sich im Gespräch mit Studierenden lohnt.
Die vollständige Übung mit allen vier Phasen steht in der Online-Fassung von Kapitel 5: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/kapitel05-4d-phasen.html#sec-ai-fluency-uebung aufrufen.

3.3 Leitungsaufgabe Mensch–LLM

Die Konsequenz der Delegation ist weniger technisch als organisatorisch. Die Forschung zur Automatisierung hat lange vor den Sprachmodellen beschrieben, dass sich für jede Stufe einer Aufgabe getrennt festlegen lässt, wie viel die Maschine entscheidet und wo der Mensch das Steuer behält (Parasuraman et al., 2000). Für Agenten in der Lehre heißt das: Wir legen vor dem Start fest, an welchen Punkten der Ablauf anhält und auf uns wartet, bei einer Literaturrecherche etwa beim Quellenkorb, beim Rechercheplan und bei der Stichprobe von Aussagen, die wir gegen das Original halten. Je länger die Strecke ohne Blick, desto wichtiger werden diese Punkte.

Jeder Haltepunkt kostet Zeit, und diese Zeit lässt sich nicht vervielfachen: Agenten kann man parallel starten, ihre Ergebnisse landen aber auf demselben Schreibtisch. Wie verschieden weit Organisationen dabei sind, zeigen Nutzungsdaten eines Programmier-Agenten: Bei seinen Organisationskunden arbeiten 67,4 % ohne parallele Agenten, bei OpenAI selbst steuern 28,6 % fünf oder mehr Agenten gleichzeitig (Johnston et al., 2026). Das folgende Modell verfolgt eine einzelne Aufgabe, Kugel A, durch Auftrag, Recherche, Entscheidung, Rechnung und Freigabe, einmal allein und einmal als achte von acht Aufgaben, die der Mensch auf einmal abgibt; jede Aufgabe bekommt dabei ihren eigenen Agenten.

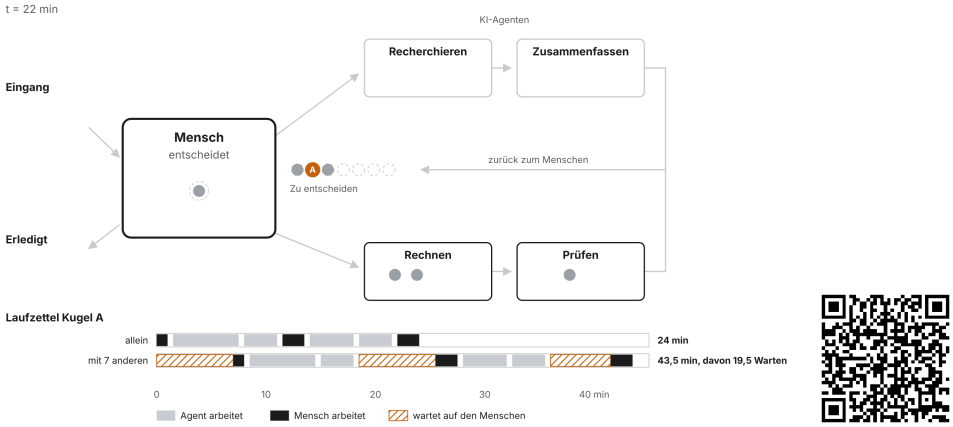


Abbildung 3.5. Mehr Agenten machen den Menschen zum Engpass. Standbild bei Minute 22 von acht gleichzeitig abgegebenen Aufgaben: Kugel A liegt in der Ablage „Zu entscheiden“, während die Agenten kaum zu tun haben; allein ist sie nach 24 Minuten fertig, als achte von acht nach 43,5 Minuten, davon 19,5 Minuten Warten (Lehrmodell, keine Messung). Interaktive Fassung: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/agenten-engpass.html aufrufen.

Kugel A wartet länger auf den Menschen, als alle Agenten zusammen an ihr arbeiten: 19,5 gegen 16 Minuten. Vor dem Menschen füllt sich die Ablage, sobald die Kugeln schneller zurückkommen, als er entscheidet, denn der Durchsatz eines Ablaufs richtet sich nach seiner langsamsten Station; ein neunter Agent ändert daran nichts. Entscheidet der Mensch doppelt so schnell, ist Kugel A nach 28,5 statt 43,5 Minuten fertig. Für die Lehre folgt daraus eine einfache Regel: Wir starten nur so viele Agenten, wie wir in der verfügbaren Zeit ernsthaft prüfen und entscheiden können, und wir beschleunigen Entscheidungen, indem wir ihre Kriterien vorab festlegen, nicht indem wir sie überspringen. Wie man Bestand, Durchsatz und Wartezeit an einer solchen Station rechnet, zeigt das Little's-Law-Widget in Kapitel 6.2.2.1.

Literaturverzeichnis

Acemoglu, D., Kong, F., & Restrepo, P. (2025). Tasks at work: Comparative advantage, technology and labor demand. In C. Dustmann & T. Lemieux (Hrsg.), *Handbook of Labor Economics*: (Bd. 6, 1–114). Elsevier. https://doi.org/10.1016/bs.heslab.2025.08.003.

Anthropic (2025). How we built our multi-agent research system. https://www.anthropic.com/engineering/multi-agent-research-system.

Chen, Y., Benton, J., Radhakrishnan, A., Uesato, J., Denison, C., Schulman, J., Somani, A., Hase, P., Wagner, M., Roger, F., Mikulik, V., Bowman, S. R., Leike, J., Kaplan, J., & Perez, E. (2025). *Reasoning models don't always say what they think*. arXiv. https://doi.org/10.48550/arXiv.2505.05410.

Dakan, R., & Feller, J. (2025). *The AI Fluency Framework: A descriptive and normative model of human-AI interaction for higher education (Version 1.1)*. Higher Education Authority.

Dell'Acqua, F., Ayoubi, C., Lifshitz-Assaf, H., Sadun, R., Mollick, E. R., Mollick, L., Han, Y., Goldman, J., Nair, H., Taub, S., & Lakhani, K. R. (2025). The cybernetic teammate: A field experiment on generative AI and teamwork. *Organization Science*. https://doi.org/10.1287/orsc.2025.20702.

Dell'Acqua, F., McFowland, E., Mollick, E. R., Lifshitz-Assaf, H., Kellogg, K., Rajendran, S., Krayer, L., Candelon, F., & Lakhani, K. R. (2023). *Navigating the Jagged Technological Frontier: Field Experimental Evidence of the Effects of AI on Knowledge Worker Productivity and Quality*. https://doi.org/10.2139/ssrn.4573321.

Dihan, Q. A., Nihalani, B. R., Tooley, A. A., & Elhusseiny, A. M. (2025). Eyes on Google's NotebookLM: using generative AI to create ophthalmology podcasts with a single click. *Eye*, *39*(2), 215–216. https://doi.org/10.1038/s41433-024-03481-8.

Europäisches Parlament und Rat der Europäischen Union (2024). Verordnung (EU) 2024/1689 des Europäischen Parlaments und des Rates vom 13. Juni 2024 zur Festlegung harmonisierter Vorschriften für künstliche Intelligenz (Verordnung über künstliche Intelligenz).

Gottweis, J., Weng, W.-H., Daryin, A., Tu, T., Palepu, A., Sirkovic, P., Myaskovsky, A., Weissenberger, F., Rong, K., Tanno, R., Saab, K., Popovici, D., Blum, J., Zhang, F., Chou, K., Hassidim, A., Gokturk, B., Vahdat, A., Kohli, P., … Natarajan, V. (2025). *Towards an AI co-scientist*. arXiv. https://doi.org/10.48550/arXiv.2502.18864.

Handa, K., Tamkin, A., McCain, M., Huang, S., Durmus, E., Heck, S., Mueller, J., Hong, J., Ritchie, S., Belonax, T., Troy, K. K., Amodei, D., Kaplan, J., Clark, J., & Ganguli, D. (2025). *Which economic tasks are performed with AI? Evidence from millions of Claude conversations*. arXiv. https://doi.org/10.48550/arXiv.2503.04761.

Johnston, D., Holtz, D., Richmond, A. M., Ong, C., Tambe, P., & Chatterji, A. (2026). *The shift to agentic AI: Evidence from Codex*. https://doi.org/10.48550/arXiv.2606.26959.

Kestin, G., Miller, K., Klales, A., Milbourne, T., & Ponti, G. (2025). AI tutoring outperforms in-class active learning: an RCT introducing a novel research-based design in an authentic educational setting. *Scientific Reports*, *15*(1), 17458. https://doi.org/10.1038/s41598-025-97652-6.

Levine, J., Aenlle, M., Zilles, C., West, M., & Silva, M. (2026). Automated grading of handwritten mathematics using vision-capable LLMs. https://doi.org/10.48550/arXiv.2605.19043.

Massenkoff, M., Lyubich, E., Sacher, S., Hitzig, Z., Zhang, S., Heller, R., & McCrory, P. (2026). *Anthropic Economic Index report: Cadences*. Anthropic.

Meincke, L., Mollick, E. R., & Terwiesch, C. (2024). *Prompting Diverse Ideas: Increasing AI Idea Variance*. https://papers.ssrn.com/abstract=4708466.

Mollick, E. (2024). *Co-intelligence: living and working with AI*. Portfolio/Penguin.

Mollick, E. R. (2026a, August 31). Agency and agents. https://www.oneusefulthing.org/p/agency-and-agents.

Mollick, E. R. (2026b, Oktober 20). 30 months on the exponential (in charts). https://www.oneusefulthing.org/p/30-months-on-the-exponential-in-charts.

Mollick, E. R., & Mollick, L. (2023). *Using AI to Implement Effective Teaching Strategies in Classrooms: Five Strategies, Including Prompts* (SSRN Scholarly Paper; Nr. 4391243).

Mollick, E. R., & Mollick, L. (2024). *Instructors as Innovators: a Future-focused Approach to New AI Learning Opportunities, With Prompts*. https://doi.org/10.2139/ssrn.4802463.

Mollick, E. R., Mollick, L., Bach, N., Ciccarelli, L. J., Przystanski, B., & Ravipinto, D. (2024). AI agents and education: Simulated practice at scale. *arXiv preprint arXiv:2407.12796*.

Morgan, G. (2024, Juli 11). What Students Want When It Comes To AI - The Digital Education Council Global AI Student Survey 2024. *On EdTech Newsletter*.

Naddaf, M. (2025). How are researchers using AI? Survey reveals pros and cons for science. *Nature*. https://doi.org/10.1038/d41586-025-00343-5.

National Center for O*NET Development (2026). *O*NET 31.0 Database*. U.S. Department of Labor, Employment and Training Administration. https://www.onetcenter.org/database.html.

Ogunleye, B., Zakariyyah, K. I., Ajao, O., Olayinka, O., & Sharma, H. (2024). A Systematic Review of Generative AI for Teaching and Learning Practice. *Education Sciences*, *14*(6), 636. https://doi.org/10.3390/educsci14060636.

Ou, A. W., Stöhr, C., & Malmström, H. (2024). Academic communication with AI-powered language tools in higher education: From a post-humanist perspective. *System*, *121*, 103225. https://doi.org/10.1016/j.system.2024.103225.

Parasuraman, R., Sheridan, T. B., & Wickens, C. D. (2000). A model for types and levels of human interaction with automation. *IEEE Transactions on Systems, Man, and Cybernetics - Part A: Systems and Humans*, *30*(3), 286–297. https://doi.org/10.1109/3468.844354.

Richland, L. E., Kornell, N., & Kao, L. S. (2009). The pretesting effect: Do unsuccessful retrieval attempts enhance learning? *Journal of Experimental Psychology: Applied*, *15*(3), 243–257. https://doi.org/10.1037/a0016496.

Schluntz, E., & Zhang, B. (2024, Dezember 19). Building effective agents. https://www.anthropic.com/engineering/building-effective-agents.

Schwarcz, D., Manning, S., Barry, P. J., Cleveland, D. R., Prescott, J. J., & Rich, B. (2025). *AI-Powered Lawyering: AI Reasoning Models, Retrieval Augmented Generation, and the Future of Legal Practice*. https://doi.org/10.2139/ssrn.5162111.

Tutton, M., & Cohen, D. (2025). Reconceptualizing the Role of the University Language Teacher in Light of Generative AI. *Education Sciences*, *15*(1), 56.

https://doi.org/10.3390/educsci15010056.

4 Lern- und Wirkmechanismen

In diesem Kapitel

- Was für Ziele verfolgen wir mit dem Einsatz von GenAI in der Lehre?
- Wissenstypen
- Anwendungsbeispiele nach Wissenskategorien
- Effektive Lerntechniken und Unterstützung mit KI
- Was die Forschung seit 2025 zeigt: Lernwirkung und kognitive Auslagerung

Thomas Brandt unterrichtet als Lehrkraft für besondere Aufgaben Kostenrechnung für 250 Erstsemester. Er weiß, dass Übungen mehr bringen als Vortrag, doch bei 18 Semesterwochenstunden und einem Hörsaal mit festen Bänken trägt er vor. Vor der Klausur lesen seine Studierenden das Skript zum dritten Mal. Seit dem Sommer lösen sie die Übungsblätter mit dem Chatbot, fehlerfrei und in Minuten. Brandt will einen eigenen Tutor einrichten, dessen Anweisung fertige Lösungen verbietet und sokratisches Nachfragen verlangt. Ein Kollege winkt ab: Seine Studierenden hätten den Tutor gebeten, die Anweisung zu vergessen, und die Lösungen trotzdem bekommen. Brandt fragt sich, ob er an der Technik feilen muss oder an seiner Lehre.

Die Szene ist aus Gesprächen in Workshops und aus der eigenen Lehre zusammengesetzt.

Bevor Sie weiterlesen: Wie sehen Sie das?

Wie sehr stimmen Sie den vier Aussagen zu? Jede Aussage wird an der Stelle im Kapitel aufgelöst, die sie beantwortet. Wer sich vorher festlegt, liest gezielter.

1. Dass wirksame Lehrmethoden selten eingesetzt werden, liegt vor allem daran, dass Lehrende die Forschung dazu nicht kennen oder ihr nicht trauen.
stimme zu 1 – 2 – 3 – 4 – 5 *stimme nicht zu*
(Auflösung in Kapitel 4.1)

2. Solange seine Lösungen fachlich richtig sind, schadet ein Chatbot, der jede Übungsfrage sofort vollständig löst, dem Lernen nicht.
stimme zu 1 – 2 – 3 – 4 – 5 *stimme nicht zu*
(Auflösung in Kapitel 4.1)

3. Häufige kleine Abfragen, über das Semester verteilt, lassen den Stoff besser behalten als dieselbe Zeit für gründliches Wiederlesen.
stimme zu 1 – 2 – 3 – 4 – 5 *stimme nicht zu*
(Auflösung in Kapitel 4.4)

4. Eine gut formulierte Anweisung an das Modell genügt, damit ein KI-Tutor zum Lernen anleitet, statt Lösungen zu liefern.
stimme zu 1 – 2 – 3 – 4 – 5 *stimme nicht zu*
(Auflösung in Kapitel 4.5)

Lernziele: Nach diesem Kapitel können Sie …

1. erklären, warum wirksame Lehrmethoden bekannt, aber selten umgesetzt sind, und wo generative KI den Aufwand senken kann;
2. begründen, warum Chatbots ohne didaktische Bremsen dem Lernen eher schaden, mit Bezug auf erwünschte Schwierigkeiten und kognitive Belastung;
3. je Wissensstufe und je gut belegter Lerntechnik einen passenden KI-Einsatz wählen und ihn mit der ICAP-Rangfolge (interaktiv vor konstruktiv, aktiv und passiv) bewerten;
4. den Stand der Evidenz seit 2025 wiedergeben: wann KI-Tutoren Lernen fördern und wann ungebremste Nutzung es senkt.

Die Kernaussagen am Kapitelende sind nach diesen vier Zielen geordnet.

4.1 Was für Ziele verfolgen wir mit dem Einsatz von GenAI in der Lehre?

Bevor wir uns der konkreten Umsetzung zuwenden, müssen wir uns zunächst fragen, was wir überhaupt bezwecken: Was sind typische Probleme und was sind unsere Ziele für die konkrete Umsetzung in Lehrsituationen?

Schauen wir uns zunächst ein zentrales Problem der Lernsituation an Hochschulen an (Freeman et al., 2014; Roediger & Pyc, 2012): **Wir wissen, was effektive Formen der Lehre sind, diese werden jedoch häufig nicht angewendet.** Studien deuten darauf hin, dass dies eher an situativen Hindernissen der Lernumgebung liegt als am Willen der Lehrenden (Henderson & Dancy, 2007).

Ein Beispiel ist die **Vorlesung**. Es ist gut belegt, dass diese Form des passiven Konsums eine sehr schwache Form der Wissensvermittlung ist. **Man lernt nicht nichts, aber anders würde man mehr lernen.** Empirisch und theoretisch ist sehr gut belegt, dass Studierende Wissen besser behalten, wenn sie dieselbe Zeit für aktives Üben (*active learning*), Frage-Antwort Interaktionen oder Diskussion in Kleingruppen verwenden (Freeman et al., 2014; Hake, 1998).

Praktisch wird oft mit dem positiven Effekt der reinen Anwesenheit argumentiert (besser als wenn die Studierenden zu Hause Netflix schauen; wer zur Vorlesung kommt hat bessere Noten), aber **diese spezielle Form der Präsenzlehre hat durch mangelnde Interaktion klare Nachteile.** Der Harvard Physiker Kestin et al. (2025) fasst drei zentrale Probleme von Vorlesungen zusammen: Mangelnde Anpassung, mangelndes individuelles Feedback und mangelnde Aktivierung der Lernenden. Genauer (Kestin et al., 2025, S.2–3): "1. They move too quickly for some students and too slowly for others because the teacher controls the pace of instruction; 2. Students do not receive personalized feedback to their questions as they arise; and 3. They fail to maintain consistent student engagement."

Warum werden trotzdem Vorlesungen sehr häufig und aktivere Lehrformen relativ selten eingesetzt (Stains et al., 2018)? Studien deuten an, dass es oft nicht am Willen der Lehrenden liegt, sondern dass **situative Hindernisse** eine große Rolle spielen, vor allem Zeitmangel wird sehr häufig in Umfragen genannt (Shadle et al., 2017), außerdem bremsen Faktoren wie Gruppengröße oder ein ungünstiger Setup der Räume (Henderson & Dancy, 2007).

Auch erfolgt die **Umsetzung oft zu optimistisch und ohne Berücksichtigung von Widerständen und Hindernissen** (z.B. Anreize für Studierende, zu Gruppenübungen auch zu kommen, oder nicht lieber ihr Wochenende in Kleingruppen zu besprechen als die Übungsaufgabe), so dass z.B. mangels notwendiger Anreizsetzung die erhoffte Lernwirkung ausbleibt und schnell Frust bei der Umsetzung entsteht (Henderson & Dancy, 2007).

Ihre Einschätzung prüfen

„Dass wirksame Lehrmethoden selten eingesetzt werden, liegt vor allem daran, dass Lehrende die Forschung dazu nicht kennen oder ihr nicht trauen."
Auflösung: eher nicht. Die Befragungen deuten auf situative Hindernisse: Am häufigsten nennen Lehrende Zeitmangel, dazu bremsen Gruppengröße und Räume, und die Umsetzung wird oft zu optimistisch geplant. Genau beim Zeitproblem kann generative KI ansetzen.

Wir argumentieren hier, dass GenAI **helfen kann, solche situativen Barrieren zu verringern,** speziell das häufig genannte **Zeitproblem** bei der Umsetzung effektiver Lehrmethoden (Shadle et al., 2017). Bei sorgfältiger Umsetzung könnte GenAI so als "Kraftverstärker" (*force multiplier*) für Lehrkräfte dienen (Mollick & Mollick, 2023), indem es die Implementierung evidenzbasierter Lehransätze erleichtert, die sonst aufgrund von Zeit- und Arbeitsaufwand oft schwer umzusetzen sind.

Auch hier gibt es allerdings nichts umsonst: Die **neuen Tools haben ihre eigenen Risiken und Nebenwirkungen** und **der Aufwand für Anpassung und Umsetzung** darf nicht unterschätzt werden. Einfach Sprachmodelle ohne Anpassung und didaktische 'Bremsen' einzusetzen ist oft nicht sinnvoll. Wie wir in der weiteren Diskussion sehen werden, nehmen sonst die KI-Chatbots den Studierenden erwünschte Schwierigkeiten ab (*desirable difficulties*), ermuntern sie nicht dazu, selbst Informationen abzuwägen, das eigene Verständnis zu vertiefen und so den eigenen Fähigkeitsstand aktiv zu verbessern (*growth mindset*) oder überfordern die kognitive Aufnahmefähigkeit der Lernenden durch Wissens-Dumps (*cognitive load*). Werden die Sprachmodelle nicht dazu angehalten, klar zu sagen, wenn sie zu etwas keine Informationen haben, so können sie die Lernenden durch überzeugend vorgetragene Halluzinationen oder Fehlschlüsse in die Irre führen. Um effektiv zu sein, müssen GenAI Lernhilfen insofern didaktisch gebremst, themenspezifisch angepasst und systematisch erprobt werden (Kestin et al., 2025):

> "AI chatbots are generally designed to be helpful, not to promote learning. They are not trained to follow pedagogical best practices (e.g., facilitating active learning, managing cognitive load and promoting a growth mindset) (...) . Another well-known flaw of AI tutors is their uncanny confidence when giving an incorrect answer or when marking a correct reply as incorrect (Kestin et al., 2025)."

Ihre Einschätzung prüfen

„Solange seine Lösungen fachlich richtig sind, schadet ein Chatbot, der jede Übungsfrage sofort vollständig löst, dem Lernen nicht."
Auflösung: nein. Auch eine richtige Lösung nimmt die Anstrengung ab, die Behalten und Verstehen erst erzeugt, die erwünschten Schwierigkeiten. Wie groß der Schaden ist, zeigt Kapitel 4.5: Mit einem Tutor im Stil des normalen ChatGPT stieg die Übungsleistung, und in der Prüfung ohne KI lagen dieselben Schüler 17 Prozent unter der Kontrollgruppe.

Die nächsten Abschnitte geben eine theoriegestützte Orientierung, wie solche Anpassungen erfolgen könnten und welche Mechanismen die Lernforschung als besonders effektiv herausstellt. Zunächst führen wir zur genaueren Zielbestimmung Kategorien von Wissen und Lernmethoden ein. Dann können wir im Detail diskutieren, für welche Ziele und Methodenwahl welche Art der Unterstützung geeignet ist.

4.2 Wissenstypen

Hattie (2023, S.358, 340ff.) unterscheidet drei Stufen des Lernens (s. Tabelle 4.1).

Zunächst geht es um **„knowing that"**, also das reine **Fakten- und Begriffswissen**, das erworben und dann gefestigt werden muss: Hier soll eine belastbare Wissensbasis entstehen, weshalb Lehrkräfte häufig Vorwissensaktivierung oder Drill-and-Practice (wiederholtes Einüben) einsetzen und durch unmittelbares Feedback die korrekte Erinnerung verankern.

Darauf baut **„knowing how"** auf, das **prozedurale und strategische Können**. Auch hier müssen Abläufe zunächst erworben und dann gefestigt wer-

den. Lernende erwerben Prozesswissen, indem sie modellierte Beispiele studieren, in gelenkten Übungen selbst anwenden und mithilfe von „worked examples“ (durchgearbeiteten Beispielen) sowie Fehleranalysen Schritt für Schritt ihre Vorgehensweisen optimieren. Festigen können Lernende dieses Prozesswissen besonders gut durch Interaktion oder Wettbewerb mit anderen Lernenden, da diese Auseinandersetzung ihnen dabei hilft, verschiedene Nutzungskontexte zu vergleichen (Chi et al., 2018).

Die höchste Stufe nennt Hattie **„knowing with“**: Wissen wird flexibel **auf neue Situationen übertragen**. Problembasiertes Lernen, authentische Fallstudien, bewusste Reflexionsphasen und kooperativ angelegte Projekte helfen dabei, Konzepte in unbekannten Kontexten sicher anzuwenden und weiterzuentwickeln.

Wo können wir neue technische Hilfsmittel wie große Sprachmodelle (LLMs) zur Unterstützung dieser Methoden besonders effektiv einsetzen?

Kategorie	Phase	Typische Methoden
Wissen, dass („Knowing that“)	**Erwerben**	Notizen zusammenführen; Zusammenfassen; Heft-/Notizbuch-Durchsicht; Bildhafte Notizen
Wissen, dass („Knowing that“)	**Festigen**	Argumente prüfen; Fehler identifizieren; Einschränkungen formulieren; Formale Argumentstrukturen darstellen; Belege liefern; Durchgearbeitete Beispiele
Wissen, wie („Knowing how“)	**Erwerben**	Aufgabenüberarbeitung; Häufiges Üben; Übungseinheit vor Tests; Zweispaltige Notizen; Problembasiertes Lernen
Wissen, wie („Knowing how“)	**Festigen**	Peer-Feedback / Peer-Response-Gruppen; Peer-Tutoring; Studierenden-Turniere; Think-Pair-Share; Kumulative Wiederholung

Kategorie	Phase	Typische Methoden
Wissen anwenden („Knowing with“)	**Transfer**	Sortieren, Zuordnen, Kategorisieren; Dichotome Schlüssel; Von Studierenden erstellte Klassifikationsmuster; Klassifikationsdiagramme

Tabelle 4.1. Methoden nach Wissenstyp: Fakten, Prozess und Transfer. Quelle: Basierend auf Hattie (2023), S. 358, 340ff.

4.3 Anwendungsbeispiele nach Wissenskategorien

Zur Unterstützung des **Aufbaus von Faktenwissen („knowing that“)** können starke LLMs gut grundlegende Konzepte erklären (Korinek, 2024, S.48) und zum Selbststudium komplette Abruf-Übungen (*retrieval practice*) erzeugen: Sie formulieren Multiple-Choice- und Kurzantwortfragen, bewerten die Eingaben sofort und erklären fehlerhafte Distraktoren – ein Verfahren, das in einer Untersuchung zur automatischen Erzeugung deutschsprachiger Leseverständnis-Aufgaben überzeugende Validitätswerte zeigte (Säuberli & Clematide, 2024).

Ebenso lassen sich sehr schnell Definitionen, Paraphrasen oder Mini-Zusammenfassungen erzeugen, was personalisierte Glossare ermöglicht (J. Chen et al., 2024). Wang et al. (2024) sprechen von KI als „Confusion Helper“. Um Halluzinationen zu vermeiden, wird das Modell häufig per Suche in eigenen Dokumenten (*Retrieval-Augmented Generation*, RAG) an externe Wissensbasen gekoppelt (also z. B. durch Beigabe von Skripten oder Fachartikeln als PDF. Siehe auch das Harvard-Tutor-Bot-Beispiel in Kapitel 6.3.2, wo Musterlösungen beigegeben werden.).

Zur **Festigung von Prozessen und Strategien („knowing how“)** dient das LLM als dialogischer Coach: Feingranulierte Prompts („Erkläre den Beschaffungsprozess in 5 Schritten und stelle nach jeder Stufe eine Kontrollfrage“) steigern die Lösungswahrscheinlichkeit in Tutorendialogen (Scarlatos et al., 2025). Sprachmodelle können Lehrenden dabei helfen, komplette „worked examples“ mitsamt Zwischenschritten zu generieren (Hassany et al., 2024).

Angepasste Sprachmodelle können Lernende zur Selbstkorrektur anleiten. Umso besser geht das, wenn das Sprachmodell **fachspezifische Lerntheorien** kennen (z.B.: typische Englischfehler von Deutschen oder typische Verhaltensfehler bei Verhandlungen oder beim Feedback-Gespräch im sozialen Bereich) und **die individuelle Lernhistorie** - sie also wissen, in welche Fallen ich als Lernender gerne tappe. Zhang et al. (2025) demonstrieren dies am Beispiel eines selbst entwickelten multimodalen **Mathematik-Tutor-Bots** (MathCCS, Mathematical Classification and Constructive Suggestions).

Der **Teachable-Agent-Ansatz** (KI in der Schülerrolle) nutzt umgekehrt das Lernen-durch-Lehren-Prinzip: Studierende bringen dem LLM eine Methode bei und reflektieren dabei ihre eigene Strategie. Dies basiert auf der Annahme, dass Interaktionen besonders effektiv zum Lernen beitragen (Chi et al., 2018; Hayashi et al., 2025). Wie auch in der persönlichen Interaktion scheint hierbei wichtig zu sein, welche „Persönlichkeit" der KI-Bot hat, dem Studierende etwas beibringen sollen (Lyu et al., 2025) und mehr Anstrengung in der Interaktion (etwa durch ausführlicheres Formulieren beim Erklären) führt zu mehr Lernerfolg (Love et al., 2025).

Sprachmodelle können genutzt werden, um komplexe (mathematische) Anwendungsprobleme mit einem simulierten User **„durchzuspielen",** so dass **logische Fehler im Lösungsprozess sichtbar werden,** wie der Prototyp „MathChat" von Y. Wu et al. (2023) zeigt. Meta-Analysen zeigen starke positive Lerneffekte, deuten aber auch auf mögliche Einschränkungen hin. So gibt es Anzeichen dafür, dass die Effekte höher für Studierende sind als für Schüler und möglicherweise schwinden Motivationsschübe durch **abnehmende 'novelty effects'** (Neuheitseffekte) einfacher Chat-Interfaces über die Zeit der Nutzung. Die Autoren der Metastudie empfehlen, hier mit stärkerer **Gamifizierung und Personalisierung** der Chatbots gegenzusteuern (R. Wu & Yu, 2024), was sich mit praktischen Ansätzen etwa von Duolingo deckt (Kazu & Kuvvetli, 2025) (z. B. Gamifizierung durch Streaks und Leaderboards, Challenges, Video-Chats mit dem Emo-Teen Lili usw.). Solche aufwändigen Setups sind im Hochschulkontext natürlich schwieriger abzudecken, ließen sich aber vielleicht graduell als Studierendenprojekt entwickeln?

Für **Transfer und Anwendung („knowing with")** entwirft das LLM realitätsnahe Szenarien – etwa Rollenspiele zu Lieferantenausfällen – und übernimmt Stakeholder-Rollen, wobei Analysen des Brookings-Instituts das Potenzial für kollaboratives Reasoning hervorheben (Korinek, 2024). Cross-Domain-Prompts fördern Analogiebildung („Welche Parallelen

bestehen zwischen agilem Projektmanagement und Lean-Procurement?“) (Mollick & Mollick, 2023).

In Gruppenarbeiten funktioniert das Modell als Co-Autor: KI-unterstützte Schreibprozesse können die Menge und Vielfalt der Ideen steigern (Meincke et al., 2024; Shaer et al., 2024). Auch hier ist jedoch die sorgfältige Gestaltung des Lernprozesses wichtig, so dass nicht erwünschte Schwierigkeiten an die KI delegiert und so kritisches Denken (*critical thinking*) nicht eingeübt wird (Lee et al., 2025).

4.4 Effektive Lerntechniken und Unterstützung mit KI

4.4.1 Wie lernen wir besonders effektiv?

In diesem Abschnitt verdeutlichen wir kurz die angestrebten Wirkmechanismen mit Fokus auf drei Lehrtechniken, die die Kognitionswissenschaft als besonders effektiv heraushebt (siehe Mörth et al. (2021) für eine gute deutschsprachige Übersicht).

Die moderne Lernforschung der Kognitionspsychologie stellt drei Gruppen von Techniken als besonders gute Kombination zwischen Effektivität und einfacher Anwendung heraus: **Verteiltes und gemischtes Lernen**, **testgestütztes Lernen** und **fragebasierte Ausarbeitung** (Dunlosky et al., 2013; Mörth et al., 2021; Roediger & Pyc, 2012). Diese Wirkung gibt es allerdings nicht umsonst: Den positiven Effekten der Techniken steht oft ein deutlich höherer Vorbereitungsaufwand gegenüber. Wie im Folgenden kurz skizziert wird, lassen sich KI-Tools nutzen, um den Aufwand dieser drei Mechanismen zu verringern, was die Lernwirkung im Vergleich zu traditionellen Ansätzen deutlich erhöhen kann.

Zeitliche Verteilung und inhaltliche Mischung von Lerninhalten (***spacing & interleaving***): Diese Technik basiert auf dem Prinzip, dass Informationen besser behalten werden, wenn das Lernen über die Zeit verteilt und in verschiedenen Kontexten stattfindet, anstatt in einer einzigen, intensiven Sitzung (Brown et al., 2014; Murre & Dros, 2015; Roediger & Pyc, 2012).

Abstände zwischen Lerneinheiten und die wiederholte Aktivierung von Wissensstrukturen stärken die Verbindung zwischen Hinweisreizen (*cues*) und Gedächtnis und geben dem Gehirn Zeit, Erinnerungen effektiv zu

speichern. Dies fördert die Langzeiterinnerung, denn der wiederholte Abruf verstärkt die gespeicherten Muster und vertieft sie so.

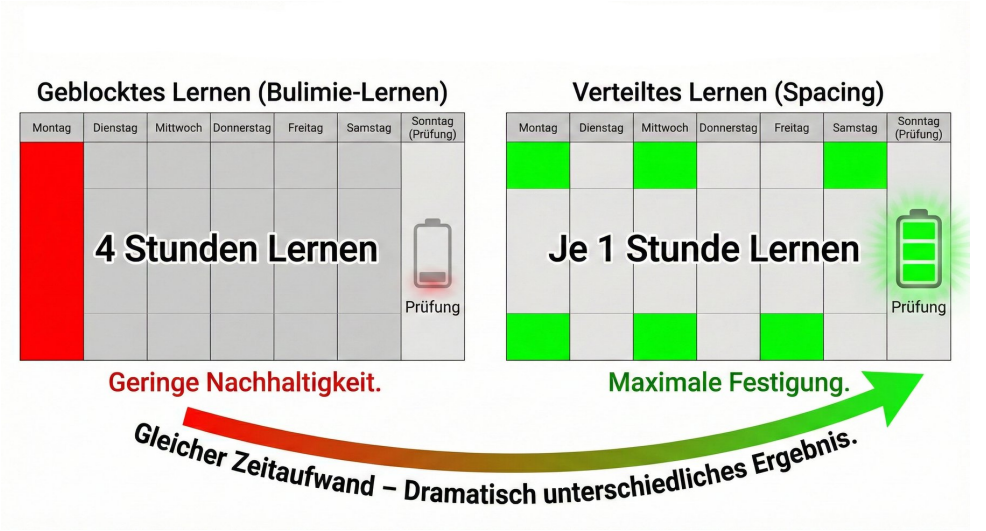


Abbildung 4.1. Illustration Zeitlich verteiltes Lernen – spacing

Quelle: Erstellt mit Gemini 3 Pro, basierend auf Roediger & Pyc (2012).

Weiterhin hilft es, zu „mischen“: **inhaltlich gemischtes Üben** (*interleaving*) ist effektiver als die isolierte Behandlung von Themenblöcken, die linear im Semesterverlauf abgehandelt werden (Mörth et al., 2021). Das liegt daran, dass das gemischte Üben die Unterscheidung zwischen verschiedenen Aufgabentypen fördert, was entscheidend für die spätere Anwendungskompetenz ist. Nur durch den geübten Vergleich verschiedener Kombinationen von Anwendungskontexten und Lösungsansätzen kann ein Gefühl dafür ausgebildet werden, welches Werkzeug zu welchem Problem passt. Fallstudien und Simulationen bieten sich hier an, wenn diese ausreichend komplex sind, um bekannte Analysen in neuen Kontexten anzuwenden und neue einzuführen.

Quelle: Erstellt mit Gemini 3 Pro, basierend auf Mörth et al. (2021).

Testgestütztes Lernen (***test-enhanced learning***): Das Abrufen von Informationen durch Tests fördert das Langzeitgedächtnis deutlich stärker als das erneute Lesen des Stoffes (Testeffekt, *testing effect*). Für Studierende ist das anstrengender, es bringt aber deutlich mehr (Brown et al., 2014). Ein ‚Test‘ kann dabei auch die Bearbeitung von Lerninhalten im Rahmen einer Fallstudie,

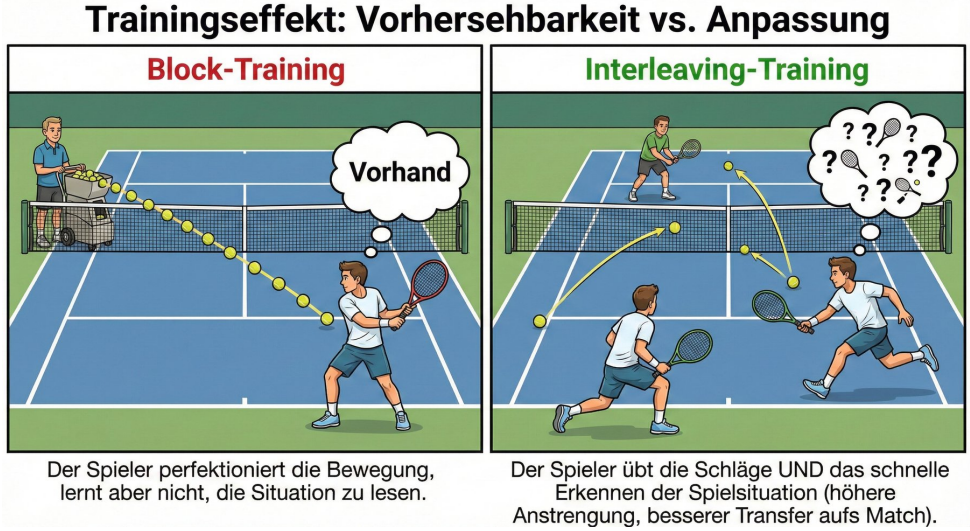


Abbildung 4.2. Illustration Inhaltlich gemischtes Lernen – interleaving

die kritische Bewertung potenziell falscher Aussagen eines LLMs oder die Beantwortung von Verständnisfragen im Dialog mit einem Tutor-Bot sein.

Quelle: Erstellt mit Gemini 3 Pro, basierend auf Roediger & Pyc (2012).

Häufige Aktivierung von Lerninhalten durch Fragen verbessert den Lernerfolg durch mehrere Mechanismen (Roediger & Karpicke, 2006). Erstens fördert solches Testen das **transfergerechte Verarbeiten** (*transfer-appropriate processing*), da die mentalen Prozesse beim Testen und beim späteren Abrufen ähnlich sind, was die Erinnerungsfähigkeit verbessert. Zweitens stärkt die Wiederholung durch Tests einerseits den erinnerten **Inhalt** und fügt andererseits **neue ‚Haken'** hinzu, mit denen wir den Inhalt aus dem Gedächtnis ziehen: die Beziehungen zwischen Hinweisreizen (*cues*) und dem Inhalt im Gedächtnis, indem zusätzliche Abrufwege (*retrieval routes*) zu gespeicherten Wissensmustern geschaffen werden, was den Abruf verbessert. Praktisch kann man diesen tollen Effekt auch recht einfach durch regelmäßige kurze Fragerunden nutzen: Wie die Lernforscher herausstellen: „frequent low-stakes quizzes (last only 5 or 10 min) can produce a large boost in performance" (Roediger & Pyc, 2012, S.246).

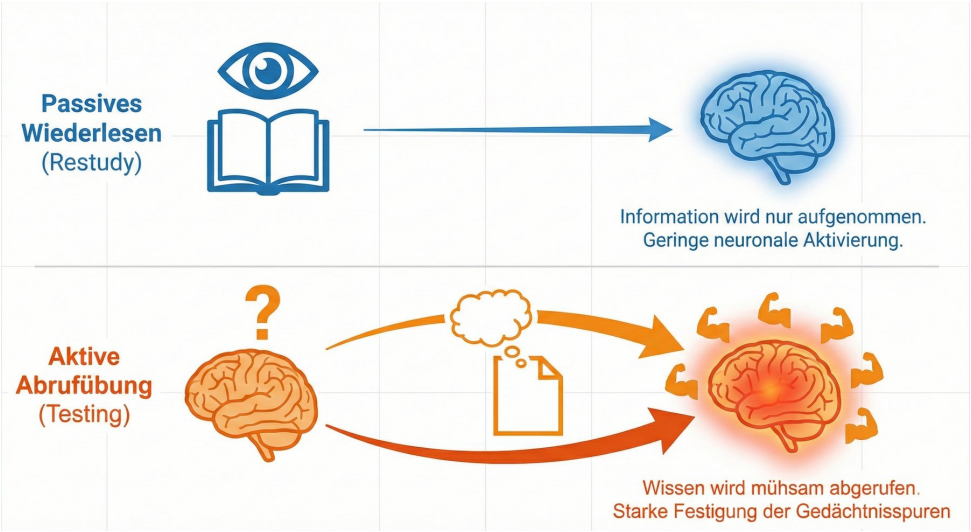


Abbildung 4.3. Illustration Testgestütztes Lernen – test-enhanced learning

Ihre Einschätzung prüfen

„Häufige kleine Abfragen, über das Semester verteilt, lassen den Stoff besser behalten als dieselbe Zeit für gründliches Wiederlesen."
Auflösung: ja. Das Abrufen durch Tests stärkt das Langzeitgedächtnis deutlich mehr als erneutes Lesen, und verteilte Wiederholung wirkt besser als eine einzige intensive Sitzung. Für Studierende ist das anstrengender, für Lehrende aufwendiger, weil laufend neue Fragen nötig sind; diesen Aufwand können Sprachmodelle senken (nächster Abschnitt).

Fragebasierte Ausarbeitung (***explanatory questioning***): Bei dieser Technik wird das tiefergehende Verständnis von Material durch das Stellen und Beantworten von „Warum"-Fragen gefördert. In **Rollenspielen und Simulationen** können Teilnehmer durch bewusste Praxis aktiv Szenarien durchspielen, während sie gleichzeitig durch gezielte Fragen angeleitet werden, die zum tieferen Nachdenken und zur Reflexion anregen. Diese Fragen können dazu dienen, die Teilnehmer dazu zu bringen, ihre Entscheidungen und Handlungen im Kontext des Rollenspiels zu erklären, wodurch das Verständnis für die Anwendung von Konzepten in realen oder simulierten Situationen vertieft wird.

Indem Lernende über die Gründe hinter den Fakten nachdenken, werden Verbindungen zu bereits bekanntem Wissen hergestellt, was zu einem tieferen Verständnis und besserer Erinnerung führt. Dies deckt sich mit dem Postulat der ICAP-Theorie des kognitiven Engagements (Chi et al., 2018): Interaktion (I) ist effektiver als individuelle Konstruktion, was wiederum effektiver ist als aktive (aber nicht konstruktive) Beteiligung, was wiederum die passive Lernteilnahme schlägt (I > C > A > P; *interactive, constructive, active, passive*).

4.4.2 Wie können LLMs genutzt werden, um diese Lerntechniken zu unterstützen?

Wir skizzieren das hier kurz an einem Seminar zum interkulturellen Management. Um **zeitliche Verteilung und Mischung** zu fördern, kann mit LLMs eine Serie von kurzen, thematisch variierenden Aufgaben und Fallstudien über das Semester verteilt erstellt werden. Diese könnten reale Szenarien abbilden, in denen Studierende ihre Fähigkeiten im interkulturellen Management anwenden müssen. Beispielsweise könnte das Sprachmodell Aufgaben generieren, bei denen Studierende Strategien für die Überwindung kultureller Barrieren in internationalen Teams entwickeln.

Was sind Beispiele für **testgestütztes Lernen**? Regelmäßige, durch LLMs generierte Quizze bringen Studierende dazu, ihr Wissen häufiger aktiv abzurufen. Durch LLMs können Multiple-Choice-Fragen, Fallstudienanalysen und Szenariobeschreibungen zu interkulturellen Missverständnissen erzeugt werden, welche die Studierenden lösen müssen.

Zur Unterstützung von **fragebasierter Ausarbeitung** können LLMs die Erstellung von Fallstudien, Simulationen und Rollenspielen unterstützen, damit Studierende über interkulturelle Dynamiken und Managementstrategien nachdenken. Diese könnten als Ausgangspunkt für Diskussionen im Kurs oder als Teil von Hausaufgaben dienen, wobei die Studierenden angehalten werden, über die Verbindungen zwischen dem Kursmaterial und den simulierten interkulturellen Interaktionen zu reflektieren. Ein rechnendes Beispiel aus der Logistik ist das Bullwhip-Widget in Kapitel 6.2.2.2: Warum die Fabrik viel stärker schwankt als die Kundschaft, erklären Studierende erst, wenn sie Lieferzeit und Informationsfluss einzeln verändert und die Folgen gesehen haben. Viele weitere Beispiele hierfür besprechen wir im folgenden Kapitel, wo wir Anwendungsfälle von KI in der Lehre nach der

didaktischen Rolle des Werkzeugs darstellen: Hilfskraft, Copilot, Tutor oder Simulator.

i Anwendungsbeispiel: KI-Feedback zum Schreiben kommt sofort, ist aber nicht immer richtig

Problem ohne KI. In Sprachkursen ist individuelles Feedback zu Texten knapp, weil jede Rückmeldung Zeit der Lehrkraft kostet.
Problem mit KI. Ein Sprachmodell kommentiert jeden Entwurf sofort, aber nicht immer richtig; wer die Fremdsprache erst lernt, erkennt falsche Vorschläge schwer.
Der Lösungsansatz. Das Sprachlernzentrum der Universität Bonn (Projekt Digital Literacy, Géraldine Stich-Desmarchelier, Torsten Kirchner, Elisabeth Schmitt) erprobt seit dem Wintersemester 2024/25 Englischmodule auf den fortgeschrittenen Sprachniveaus B2+ und C1.1 des Europäischen Referenzrahmens mit KI. In E-Learning-Einheiten bauen die Studierenden einen Essay Schritt für Schritt auf: Argumente sammeln und von der KI bewerten lassen, die Struktur eines Musteressays erkennen, Einleitung und Fazit mit KI-Feedback schreiben, schließlich den ganzen Essay selbstständig verfassen. Jede KI-Rückmeldung prüfen sie an verlässlichen Quellen, die die Lehrkraft bereitstellt. Ins E-Portfolio laden sie die Chats, den eigenständig verfassten Text, die KI-gestützt überarbeitete Fassung und eine angeleitete Reflexion; die Lehrkraft ergänzt das KI-Feedback um eigenes.
Was das für wirksames Lernen heißt. *Erfahrungsbericht.* Das Prüfen der KI-Rückmeldung ist selbst ein Abrufanlass im Sinne des testgestützten Lernens, das ausdrücklich die kritische Bewertung möglicherweise falscher Aussagen eines Sprachmodells einschließt. Dass der eigene Text vor der KI-Überarbeitung feststeht, folgt einer Leitplanke (*guardrail*), die sich in den Experimenten seit 2025 bewährt: erst die eigene Antwort, dann die Antwort der KI (Xu et al., 2026) (Kapitel 4.5).
Quelle: Tobor et al. (2026), S. 32–33.



4.4.3 Ausrichtung der Anpassungen nach Empfehlungen der Lernforschung

Um die Empfehlungen der Lernforschung in das Vorgehen mit Künstlicher Intelligenz (KI) und Aufgabensets zu integrieren, könnten folgende Schritte unternommen werden (MIT Teaching + Learning Lab, 2023; Begriffe nach Roediger & Pyc, 2012):

- **Zeitliche Verteilung und inhaltliche Mischung von Lerninhalten** (***spacing & interleaving***): Die Aufgabensets sollten so gestaltet werden, dass sie über das Semester verteilt sind und eine Vielfalt an Themen abdecken. Dies fördert die Langzeiterinnerung und hilft den Studierenden, die Anwendung der Konzepte in verschiedenen Kontexten zu üben. KI kann genutzt werden, um personalisierte Lernpläne zu erstellen, die auf den individuellen Fortschritt der Studierenden abgestimmt sind und eine Mischung aus verschiedenen Aufgabentypen bieten.
- **Testgestütztes Lernen** (***test-enhanced learning***): Regelmäßige, durch KI unterstützte Quizze und Tests können in den Lehrplan integriert werden, um das Abrufen von Informationen zu fördern. Diese Tests könnten auch die kritische Bewertung von KI-generierten Antworten beinhalten, um die kritische Denkfähigkeit der Studierenden zu schärfen.
- **Fragebasierte Ausarbeitung** (***explanatory questioning***): KI-Tutor-Bots könnten entwickelt werden, um Studierende durch gezielte "Warum"-Fragen zu leiten, die ein tieferes Verständnis des Materials fördern. Diese Bots könnten in Simulationen und Rollenspielen eingesetzt werden, um die Studierenden dazu zu bringen, ihre Entscheidungen zu erklären und zu reflektieren, wodurch die Anwendung von Konzepten in realen oder simulierten Situationen vertieft wird.

4.5 Was die Forschung seit 2025 zeigt: Lernwirkung und kognitive Auslagerung

Die Mechanismen der vorigen Abschnitte sind seit Jahrzehnten belegt; ob sie mit Sprachmodellen tragen, war 2024 noch eine Vermutung. Seit 2025 gibt es Messungen mit den zwei stärksten verfügbaren Methoden, randomisierten

Feldexperimenten und Paneldaten aus echten Kursen, und seit Sommer 2026 liegen die ersten großen Feldversuche vor, bei denen ein Tutor nicht als Laborprototyp, sondern als Teil eines laufenden Kurses getestet wurde. Vier Gestaltungsfragen ordnen die Befunde; je Frage stehen hier die belastbarsten oder neuesten Studien, weitere im Kasten am Ende des Abschnitts und auf der Online-Seite „Forschungsstand".

Lernen Studierende mit KI-Tutoren mehr? Die Antwort lautete 2025 noch „im Mittel ja", seit 2026 lautet sie „nur unter Bedingungen". Die Einzelstudie mit dem saubersten Design bleibt das Harvard-Experiment von Kestin et al. (2025), dessen Tutor mit Musterlösungen, Portionierung und Wachstumsdenken gebaut war (Kapitel 4.1): Studierende lernten mit ihm in weniger Zeit mehr als in der aktiven Präsenzübung. Das bislang größte Hochschulexperiment zeigt das Gegenteil für den Normalfall: An der University of Maryland erhielten per Los 2.379 Studierende in den Kursen von 30 Lehrenden Zugang zu einem Tutor, der mit den Kursmaterialien aus dem Lernmanagementsystem arbeitete; ihre Abschlussnote lag 0,37 Standardabweichungen *unter* der Kontrollgruppe, ihre Beteiligung im Kurs 0,90 Standardabweichungen darunter, und bei Erstakademikerinnen und Erstakademikern war der Verlust doppelt so groß. Nur 15 Prozent der Berechtigten nutzten den Tutor überhaupt, und drei Viertel ihrer Anfragen verlangten eine direkte Antwort, weniger als ein Prozent Rückmeldung auf eigene Arbeit (Liu et al., 2026). Dazwischen liegt das präregistrierte Schulexperiment von Oreopoulos, Liut, et al. (2026) mit 6.997 Lernenden und einem verzögerten Test: Weder ein Tutor allein noch ein Übungsablauf, der erst nach gezeigter Beherrschung weiterführt (*mastery-based practice*), verbesserten das Behalten; nur die Kombination tat es, und nach einem Fehler stieg mit Tutor die Trefferquote im nächsten Versuch um 8,5 Prozentpunkte. Die Meta-Analysen, die 2025 große positive Effekte berichteten, sind inzwischen methodisch geprüft: Die meisten ihrer Vergleiche setzen ChatGPT gegen Kontrollgruppen, die zugleich andere Methoden, weniger Übungszeit oder kürzere Interventionen hatten, so dass der Werkzeugeffekt nicht vom Methodeneffekt zu trennen ist (Lawson et al., 2026); der Wissenschaftsrat nennt die Studienlage „(noch) nicht belastbar" (Wissenschaftsrat, 2026). Ein deutscher Hochschulbeleg mit sauberem Design existiert: 334 Studierende, die sich auf eine Prüfung mit Anreiz vorbereiteten, erreichten mit freiem Zugang zu einem Tutor 0,23 Standardabweichungen mehr als mit dem Lehrbuch allein, ohne weniger zu lesen (Fischer et al., 2025).

Was passiert ohne didaktische Bremse? Hier ist die Evidenz eindeutig und

sie kam zuerst. In einem Feldexperiment mit knapp tausend Oberstufenschülern verbesserte ein Tutor im Stil des normalen ChatGPT die Übungsleistung um 48 Prozent; als der Zugang in der Prüfung fehlte, lagen dieselben Schüler 17 Prozent *unter* der Kontrollgruppe, die nie Zugang hatte. Ein zweiter Tutor mit Leitplanken, der Hinweise statt Lösungen gab, hob die Übungsleistung um 127 Prozent und ließ in der Prüfung keinen Schaden zurück (Bastani et al., 2025). Die Paneldaten einer Mathematik-Lernplattform zeigen denselben Mechanismus im Großen: Über 3,2 Millionen Lerninteraktionen sank nach dem Start von ChatGPT die Lernzeit auf Aufgaben, deren Text sich in einen Chatbot kopieren lässt, kumuliert um 27 Prozent bei Studierenden und 31 Prozent in der Oberstufe, und mit ihr der daraus gebaute Wissenszuwachs; unter Aufsicht verschwindet der Effekt vollständig (Rismanchian et al., 2026). Die Dissoziation von Leistung und Behalten ist inzwischen im Labor repliziert: 59 Informatikstudierende lösten Programmieraufgaben mit ChatGPT zu 89 statt 69 Prozent, behielten den Stoff nach 48 Stunden aber nur zu 39 statt 52 Prozent und schrieben sich die Lösung seltener selbst zu (Bergh et al., 2026). Die Theorie dazu liefert Nakamura (2026): Auslagerung an die KI (*cognitive offloading*) augmentiert, wenn sie Nebenoperationen abnimmt, und erodiert, wenn sie genau die Operationen umgeht, die das Lernziel ausmachen.

Welche Gestaltungsmerkmale schützen vor Auslagerung? Drei präregistrierte Experimente aus dem Jahr 2026 benennen die Stellschrauben, und eines davon zeigt, welche Stellschraube nicht wirkt. Eine metakognitive Rückmeldung, die Lernenden sichtbar macht, was das Abschreiben einer KI-Lösung für ihr eigenes Können bedeutet, halbierte in einem Online-Experiment mit 704 Teilnehmenden die Auslagerung und verbesserte den anschließenden Test ohne KI; eine Belohnung für eigenständiges Arbeiten blieb wirkungslos (Maier et al., 2026). In einem Cluster-Experiment mit 1.176 Erstsemestern in 48 Übungsgruppen an vier Hochschulen gewann direktes KI-Feedback kurzfristig, aber beim verzögerten Transfer ohne KI lagen die Gruppen vorn, deren Feedback zuerst zur Reflexion aufforderte und die Kritik erst danach lieferte (Ates, 2026). Was nicht reicht, ist der Prompt allein: An der Technischen Hochschule ETH Zürich durchliefen 1.059 Programmieranfänger im Crossover-Design, also nacheinander, Tutoren mit System-Prompts für selbstreguliertes Lernen (*self-regulated learning*) und für kognitive Aktivierung nach ICAP, und auf keinem der vier konfirmatorischen Maße unterschieden sich die Varianten (Barth et al., 2026). Die Leitplanke muss also in die Aufgabe, in die Rückmeldung und in den Ablauf gebaut werden, nicht nur in die Anweisung an das Modell.

Das ist die Übersetzung der erwünschten Schwierigkeiten (Kapitel 4.1) in Werkzeugdesign: eine eigene Antwort festhalten, bevor die KI antwortet, Hinweise vor Lösungen, und eine Begründungspflicht, wo eine Lösung übernommen wird (Tao et al., 2026; Xu et al., 2026).

Ihre Einschätzung prüfen

„Eine gut formulierte Anweisung an das Modell genügt, damit ein KI-Tutor zum Lernen anleitet, statt Lösungen zu liefern."
Auflösung: nein. An der ETH Zürich unterschieden sich Tutoren mit System-Prompts für selbstreguliertes Lernen und für kognitive Aktivierung auf keinem der vier konfirmatorischen Maße. Die Leitplanke gehört in Aufgabe, Rückmeldung und Ablauf: eine eigene Antwort vor der KI-Antwort, Hinweise vor Lösungen, eine Begründungspflicht, wo eine Lösung übernommen wird.

Trägt die Einbettung oder das Werkzeug? Die Einbettung, und der Engpass ist fast immer die Nutzung. In einer randomisierten Studie in 83 indischen Internatsschulen erhielten alle Zugang zur selben Lernplattform; große Lerngewinne entstanden nur dort, wo betreute Lernzeiten mit Aufsichtspersonen eingeplant waren (Oreopoulos, Keyes-Krysakowski, et al., 2026). Zwei Jahre Khanmigo an 18 Schulen brachten 0,06 bis 0,08 Standardabweichungen pro Jahr, nicht mehr als Khan Academy ohne KI, weil das mittlere Kind den Tutor an einem Drittel der Übungstage und in nur 17 Prozent der Sitzungen mit Fehler ansprach (Oreopoulos & Low, 2026); der Anbieter hat den Nullbefund öffentlich eingeräumt und den Tutor umgebaut, in die Aufgabe hinein, ohne Antwort vor dem ersten Versuch (Kapitel 6.3). Für die Hochschule zeigt ein deutsches Wirtschaftsinformatik-Semester mit drei Bedingungen dasselbe von der anderen Seite: Alle 87 Studierenden lernten, der Tutor brachte keinen Zusatzgewinn, aber auch keine Erosion; was zählte, war die Rahmung der Nutzung, nicht der Zugang (Melanou et al., 2026). Und wo die Nutzung angeleitet statt nur ermutigt wird, kehrt der Effekt zurück: Ermutigung zum Tutor änderte in einem Ökonometrie-Kurs nichts, eine Anleitung zur tutoriellen Nutzung hob die Prüfungsleistung um 0,21 Standardabweichungen und die Bestehensquote um zwölf Prozentpunkte (Gallegos, 2026). Für die Gestaltung heißt das zusammengenommen: Ein KI-Tutor braucht Leitplanken in Aufgabe und Rückmeldung, die Hinweise vor Lösungen setzen, eine Einbettung in den Kurs, die seine Nutzung verbindlich und angeleitet macht, und einen Test vor dem Einsatz, ob er zu viel hilft (Kapitel 5.5).

i Anwendungsbeispiel: Studierende übernehmen KI-Texte, statt sich mit ihnen auseinanderzusetzen

Problem ohne KI. Eine begründete eigene Position zu einem literarischen Thema entsteht durch wiederholtes Nachfragen, für das im Seminar wenig Zeit bleibt.
Problem mit KI. Der Chatbot liefert Quellen, Zusammenfassungen und Formulierungen sofort; die Studierenden übernehmen sie, statt sich mit ihnen auseinanderzusetzen.
Der Lösungsansatz. Nina Yuen beschreibt eine Aufgabe in sieben Schritten, am Beispiel eines Kurses über Darstellungen von „Race“ in der amerikanischen Literatur des 20. Jahrhunderts. Die Studierenden schreiben zuerst ohne KI einen kurzen Essay. Dann recherchieren sie mit dem Chatbot, entwickeln mit ihm eine Bewertungsrubrik und beurteilen ihre Arbeit danach ohne KI neu. Es folgt ein sokratischer Dialog mit dem Chatbot über drei bis fünf Ebenen von Nachfragen. Am Ende vergleichen sie eine KI-gestützte mit einer eigenen Überarbeitung und schärfen in der letzten Fassung ihre eigene Stimme.
Was das für wirksames Lernen heißt. *Unterrichtsentwurf, keine Ergebnisse berichtet.* Der erste, KI-freie Entwurf ist die eigene Antwort, die feststeht, bevor die KI antwortet. Die Reihenfolge entspricht dem Befund, dass Rückmeldung, die zuerst zur Reflexion auffordert und die Kritik danach liefert, beim späteren Transfer ohne KI besser abschneidet als direkte KI-Kritik (Ates, 2026).
Ablauf und Prompt: Kapitel A.3.1. Quelle: Yuen (2025) (AI Pedagogy Project, metaLAB at Harvard).



i Stand der Forschung bei Drucklegung, November 2026

Die vier Gestaltungsfragen dieses Abschnitts, die Kernaussagen, die bei Drucklegung die Antwort trugen, und die weiteren Belege, nach Aussagen geordnet. Die Punkte geben an, wie belastbar eine Wirkungsaussage ist: ●●● hoch, ●●○ mittel, ●○○ begrenzt. Sie folgen den Designstufen der CAT-Leitlinie (*Critically Appraised Topic*, eine kurze,

strukturierte Bewertung der Studienlage zu einer Frage) des Center for Evidence-Based Management (Barends et al., 2017). Ausgangspunkt ist das stärkste Design unter den Studien einer Aussage: Meta-Analyse randomisierter Studien oder randomisierte Studie (RCT, *randomized controlled trial*) drei Punkte, kontrollierte Studie ohne Zufallszuteilung oder Paneldaten zwei, Befragung, Fallbericht oder Synthese einen. Einen Punkt weniger gibt es, wenn keine der Studien begutachtet ist, wenn die Daten vom Anbieter stammen oder wenn die Vergleiche nachweislich konfundiert sind. Erklärungen und Methodenkritik tragen keine Punkte, weil die Stufen nur Wirkungsaussagen bewerten. Ob ein Befund aus der Schule auf die Hochschule übertragbar ist, steht in der Studienangabe, nicht in den Punkten. Abkürzungen in der Tabelle: Standardabweichung (SD), standardisierte Effektstärke (g), ganze Gruppen statt Einzelner zugelost (Cluster-RCT), Messung der Hirnströme (EEG), Managementstudium (MBA). Die Online-Seite „Forschungsstand" führt alle Studien vollständig und wird halbjährlich fortgeschrieben.
Fett gesetzte Aussagen tragen den Fließtext dieses Abschnitts, die übrigen sind weitere Belege.

Kernaussage	Studien
Lernen Studierende mit KI-Tutoren mehr?	
Ein Tutor kann mehr Lernen bewirken als aktive Präsenzübung oder Lehrbuch allein. ●●●	• Kestin et al. (2025): RCT, Physik, Harvard; mehr gelernt in weniger Zeit • Fischer et al. (2025): RCT, 334 Studierende, Deutschland; +0,23 SD in einer Prüfung mit Anreiz
Ein Tutor, der nur bereitgestellt wird, hebt die Leistung nicht und kann sie senken. ●●○	• Liu et al. (2026): RCT, 2.379 Studierende, Maryland; −0,37 SD Abschlussnote, 15 % Nutzung • Oreopoulos, Liut, et al. (2026): präregistrierter RCT, 6.997 Schüler; Tutor allein ohne Wirkung auf das Behalten, wirksam nur im Mastery-Ablauf
Vorbehalt: Die großen Effekte der Meta-Analysen messen nicht das Werkzeug allein.	• Lawson et al. (2026): Kontrollgruppen unterscheiden sich zugleich in Methode, Übungszeit und Dauer • Wissenschaftsrat (2026): Studienlage „(noch) nicht belastbar"

Meta-Analysen finden mittlere bis große Durchschnittseffekte; nach etwa 23 Stunden steigt der Effekt nicht weiter. ●●○	Der Vorbehalt oben gilt für sie: Ren et al. (2026) (47 RCTs, g = 0,68), Jing et al. (2026) (Hochschule, g = 0,46), Deng et al. (2025), R. Wu & Yu (2024); M. Wu & Ouyang (2026) trennt KI-gestützte von unbegleiteter Programmierleistung.
Weitere Feldversuche mit eigens gebauten Tutoren zeigen Gewinne, oft mit Beteiligung der Anbieter. ●●○	LearnLM Team et al. (2025) (Herstellerangabe), Harrison et al. (2026) (Sekundarstufe, g = 0,33), Northcutt et al. (2026) (KI gleichauf mit menschlichem Tutoring, Industrieautoren), Kuo & Zhuo (2026) (Tutor- plus Tutee-Bot schlägt Antwort-Bot).
Gesprochene Antworten lehren nicht besser als geschriebene, kosten aber das 2,8-Fache. ●●○	S. Yang et al. (2026) (präregistriert, 86 Online-MBA-Studierende).
Die Rolle der KI bestimmt, was steigt: als Tutor die Motivation, nicht die Klausur; als Löser die Aufgabe, nicht der Transfer. ●●○	Chakraborty (2026) (vier Experimente in einem Programmierkurs).

Was passiert ohne didaktische Bremse?

Ungebremster Zugang hebt die Leistung mit KI und senkt, was ohne KI bleibt. ●●●	• Bastani et al. (2025): RCT, knapp 1.000 Oberstufenschüler; +48 % Übung, −17 % Prüfung • Rismanchian et al. (2026): Paneldaten, 3,2 Mio. Interaktionen; −27 % Lernzeit bei kopierbaren Aufgaben • Bergh et al. (2026): Laborexperiment, 59 Studierende; Behalten nach 48 Stunden 39 statt 52 % • Strömberg et al. (2026): Paneldaten, 26.811 Schülerinnen und Schüler, 30 Monate; +18 % Hausaufgaben, −20 % Monatsklausuren
Erklärung: Auslagerung schadet, wenn sie die Operationen umgeht, die das Lernziel ausmachen.	• Nakamura (2026): Theorie

Wer per Chatbot recherchiert oder schreibt, lernt weniger und denkt weniger selbst. ●●○	Mittal et al. (2026) (RCT, acht Tage, kritisches Denken am stärksten betroffen), Kosmyna et al. (2025) (EEG, 54 Teilnehmende, Preprint).
Was mit KI gelingt, bleibt ohne KI nur erhalten, wo die KI ergänzt statt ersetzt oder schon Expertise da ist. ●●○	Contractor & Reyes (2026) (+0,27 SD, nach einer Woche nur bei ergänzender Nutzung), Autor et al. (2026) (133 Patentanwälte, Fähigkeit ohne KI nach 90 Tagen nur bei Erfahrenen).
Auch Lehrende lagern aus: Ein KI-Werkzeug für die Unterrichtsvorbereitung senkt die Lernmotivation ihrer Schülerinnen und Schüler. ●●○	Sungu et al. (2026) (randomisiertes Feldexperiment, 193 Lehrkräfte, −0,11 SD).

Welche Gestaltungsmerkmale schützen?

Rückmeldung, die zuerst zum eigenen Denken auffordert, schützt das Können ohne KI. ●●●	• Maier et al. (2026): präregistriert, 704 Teilnehmende; metakognitive Rückmeldung halbiert die Auslagerung • Ates (2026): Cluster-RCT, 1.176 Erstsemester, vier Hochschulen; Reflexion vor Kritik gewinnt beim verzögerten Transfer
Ein System-Prompt allein ändert das Lernen nicht. ●●●	• Barth et al. (2026): präregistriertes Crossover, 1.059 Programmieranfänger, ETH; kein Effekt auf vier Maße
Gerüste wirken, wenn Planen, Abrufen und Korrigieren bei den Lernenden bleiben. ●●○	Hou et al. (2026) (Prompting-Gerüst bei offenen Aufgaben), Y. Yang et al. (2026) (Planungsschritte bleiben erhalten), Ross et al. (2026) (Fehlvorstellungen weichen nur mit korrigierender Rolle), Akgun & Toker (2026) (Abruf-Übung schlägt freies KI-Lernen nach sieben Wochen).
Gemeinsam verarbeitetes KI-Feedback fördert den Transfer stärker als allein verarbeitetes. ●●●	S. Chen et al. (2027) (Cluster-RCT, 16 Wochen, 108 Studierende, China).
Sokratische Führung wirkt nach, wenn die Leitplanken fallen. ●●●	Brender et al. (2026) (randomisiert, 66 Master-Studierende, danach freie KI-Nutzung im Projekt).

Trägt die Einbettung oder das Werkzeug?

Gewinne entstehen, wo die Nutzung eingeplant und angeleitet ist, nicht durch den Zugang. ●●○	• Oreopoulos, Keyes-Krysakowski, et al. (2026): RCT, 83 indische Internatsschulen; Gewinne nur mit betreuten Lernzeiten • Gallegos (2026): zwei RCTs, Ökonometrie, Chile; Anleitung +0,21 SD, Ermutigung wirkungslos • Melanou et al. (2026): Quasi-Experiment, 87 Studierende, Deutschland; die Rahmung zählt
Bereitgestellte Tutoren werden zu selten genutzt, um zu wirken. ●●○	• Oreopoulos & Low (2026): Cluster-RCT, 18 Schulen, zwei Jahre; Nutzung an einem Drittel der Übungstage
Menschliche Begleitung hebt die Nutzung, nicht automatisch die Leistung. ●●○	Robinson et al. (2026) (zwei RCTs, Grundschule, Beteiligung +71–80 %, Lesen unverändert).
Wo Tutoren an deutschsprachigen Hochschulen laufen, fehlen Lernmaße; Befragungen zeigen keinen Unterschied im wahrgenommenen Lernerfolg. ●○○	Stumpf et al. (2026) (OneTutor, 84 Lehrveranstaltungen), Tobler & Köhler (2026) (ETH, 407 Studierende).
Reine KI-Tutoren erreichen viele nie: 40–47 Prozent nutzen sie nicht. ●○○	Turano et al. (2026) (Synthese).
Anbieterstudien berichten Gewinne, sind aber nicht unabhängig geprüft. ●○○	OpenAI (2026), Ghahramani (2026) (Herstellerangaben).

Tabelle 4.2. Kernaussagen und Belege zu den Gestaltungsfragen in Kapitel 4, Stand November 2026.

Die lebende Fassung finden Sie online unter https://th-koln-bartnik.github.io/genai4teaching/forschungsstand.html.

Kernaussagen

Zu Lernziel 1: Zeit als Engpass

1. Das Problem der Hochschullehre ist nicht fehlendes Wissen über

gute Lehre, sondern fehlende Zeit, sie umzusetzen. Genau hier kann generative KI ansetzen.

Zu Lernziel 2: Didaktische Bremsen

2. Chatbots sind darauf gebaut, hilfreich zu sein, nicht darauf, Lernen zu fördern. Ohne Anpassung nehmen sie Lernenden die Schwierigkeiten ab, die das Lernen ausmachen.

Zu Lernziel 3: Wissensstufen, Lerntechniken und ICAP

3. Welcher KI-Einsatz sinnvoll ist, hängt vom Wissenstyp ab: Abrufübungen und Erklärungen für Faktenwissen, dialogisches Coaching und durchgearbeitete Beispiele für Prozesswissen, Szenarien und Rollenspiele für Transfer.
4. Verteiltes Üben, häufige Abruftests und Warum-Fragen sind die am besten belegten Lerntechniken. Ihr Haken ist der Aufwand, und den können Sprachmodelle drastisch senken.
5. Interaktion schlägt Konstruktion schlägt aktive Beteiligung schlägt passives Zuhören. Eine KI-Lernaktivität ist umso wirksamer, je weiter oben sie auf dieser Leiter steht.

Zu Lernziel 4: Evidenz seit 2025

6. Ungebremster KI-Zugang verbessert die Übungsleistung und senkt die Prüfungsleistung; ein Tutor, der nur bereitgestellt wird, wird kaum und dann als Antwortmaschine genutzt. Leitplanken in Aufgabe und Rückmeldung (nicht nur im Prompt) und eine verbindliche, angeleitete Einbettung in den Kurs kehren das Vorzeichen um.

i Schlüsselbegriffe

Erklären Sie jeden Begriff in zwei, drei Sätzen in eigenen Worten; die Seitenzahl führt zur Stelle, an der er eingeführt wird.

- Kognitive Belastung (*cognitive load*) ..... S. 100
- Wissen, dass (*knowing that*) ..... S. 101
- Wissen, wie (*knowing how*) ..... S. 101

- Wissen anwenden (*knowing with*) ..... S. 102
- Verteiltes Üben (*spacing*) ..... S. 105
- Gemischtes Üben (*interleaving*) ..... S. 106
- Testgestütztes Lernen (*test-enhanced learning*) ..... S. 106
- Transfergerechte Verarbeitung (*transfer-appropriate processing*) S. 107
- Fragebasierte Ausarbeitung (*explanatory questioning*) ..... S. 108
- ICAP ..... S. 109

Übung. Tragen Sie zu jeder Szene den passenden Begriff aus der Liste ein. Lösungen: Anhang B.

Nr.	Szene	Begriff
1	Statt am Ende der Vorlesung die Folien zusammenzufassen, lässt eine Dozentin einen Bot fünf Kurzfragen zum Stoff der Stunde erzeugen, die alle zuerst ohne Unterlagen beantworten. *Herkunft: konstruiert nach Kapitel 4.4.*	
2	Auf dem Übungsblatt vor der Klausur in Kostenrechnung stehen Aufgaben zu Zuschlagskalkulation, Deckungsbeitrag und Break-even nicht mehr in Blöcken, sondern durcheinander; zuerst muss man erkennen, welches Verfahren passt. *Herkunft: konstruiert nach Kapitel 4.4 und der Eingangsszene dieses Kapitels.*	
3	Ein Dozent streicht die lange Wiederholungssitzung vor der Klausur; dafür kehrt jedes Thema in drei kurzen Blöcken im Abstand mehrerer Wochen zurück. *Herkunft: konstruiert nach Kapitel 4.4.*	
4	Nach jeder Antwort im Lieferkettenkurs fragt ein Bot nach: Warum steigen die Bestellungen weiter oben in der Kette stärker, und was würde sich ändern, wenn alle Stufen dieselben Verkaufsdaten sähen? *Herkunft: konstruiert nach Kapitel 4.4 und dem Bullwhip-Widget (Kapitel 6.2.2.2).*	

5	Ein Erstsemester fragt den Kurs-Bot nach dem Unterschied zwischen fixen und variablen Kosten und bekommt eine Antwort über anderthalb Seiten mit acht Unterpunkten und drei Exkursen. *Herkunft: konstruiert nach Kapitel 4.1.*
6	Eine KI spielt einen Lieferanten, der kurz vor Vertragsabschluss die Preise erhöht; die Studierenden müssen ihr Wissen über Verhandlungen in einer Lage einsetzen, die im Skript nicht vorkommt. *Herkunft: konstruiert nach Tabelle 4.1 und Kapitel 6.4.*

Wiederholung aus früheren Kapiteln. *Erklären Sie diese Begriffe noch einmal in eigenen Worten, bevor Sie nachschlagen.*

- Erwünschte Schwierigkeiten (*desirable difficulties*) . . . . . S. 21
- Halluzination (*hallucination*) . . . . . S. 145
- RAG (*Retrieval-Augmented Generation*) . . . . . S. 55

i Lernfragen

Wiederholen

1. Nennen Sie die drei Wissensstufen nach Hattie und je einen passenden KI-Einsatz.
2. Bringen Sie die vier Stufen der ICAP-Rangfolge in die richtige Reihenfolge.
3. Erklären Sie ohne Nachschlagen, warum ein Chatbot, der sofort die richtige Antwort gibt, dem Testeffekt entgegenwirkt. Wie müsste der Bot stattdessen reagieren?

Anwenden

4. Ordnen Sie drei Lernziele Ihrer Veranstaltung den Stufen knowing that, knowing how und knowing with zu. Welche Stufe kommt bei Ihnen zu kurz, und welche KI-gestützte Methode aus diesem Kapitel würde sie stärken?

5. Wo in Ihrem Semesterplan könnten Sie mit geringem Aufwand verteiltes und gemischtes Üben einbauen, wenn ein Sprachmodell die Aufgabenvarianten liefert?

Beurteilen

6. Ein Kollege berichtet, seine Studierenden hätten mit einem KI-Tutor in den Übungen deutlich besser abgeschnitten. Welche eine Frage stellen Sie ihm, bevor Sie den Tutor übernehmen, und warum?
7. Ein Anbieter wirbt mit einem Tutor, dessen System-Prompt sokratisches Fragen und kognitive Aktivierung vorschreibt. Reicht das als Leitplanke? Begründen Sie mit den Befunden des Kapitels.

Lösungshinweise: Anhang B.

Literaturverzeichnis

Akgun, M., & Toker, S. (2026). Do gains from generative AI-enabled adaptive pretesting persist? Evidence from a retention study. https://doi.org/10.48550/arXiv.2606.22328.

Ates, H. (2026). Human-centered GenAI feedback design in higher education: A multisite experiment on direct, reflective, and hybrid approaches to scientific argumentation. *International Journal of Educational Technology in Higher Education*, *23*(38). https://doi.org/10.1186/s41239-026-00614-9.

Autor, D., Rodchenko, T., Martin, J., Iscenko, Z., Strand, S., Pearl, D., & Ferere, M. (2026). *Does AI assistance enhance or erode expertise? Evidence from a three-month field experiment in patent drafting* (NBER Working Paper; Nr. 35720). National Bureau of Economic Research. https://doi.org/10.3386/w35720.

Barends, E., Rousseau, D. M., & Briner, R. B. (2017). *CEBMa guideline for critically appraised topics in management and organizations* (Leitlinie). Center for Evidence-Based Management.

Barth, M., Thorgeirsson, S., Etemadi, K., Leinonen, J., Cotrini, C., & Su, Z. (2026). Steering AI tutors through system prompts: A crossover study on self-regulated learning and cognitive engagement scaffolds in CS1. https://doi.org/10.1145/3765964.3811656.

Bastani, H., Bastani, O., Sungu, A., Ge, H., Kabakcı, Ö., & Mariman, R. (2025).

Generative AI without guardrails can harm learning: Evidence from high school mathematics. *Proceedings of the National Academy of Sciences*, *122*(26), e2422633122. https://doi.org/10.1073/pnas.2422633122.

Bergh, C., Tag, B., Vassar, A., & Renzella, J. (2026). *Your programming students' cognition with ChatGPT: Higher performance, lower retention, and reduced ownership*. https://doi.org/10.48550/arXiv.2609.21194.

Brender, J., El-Hamamsy, L., Uittenhove, K., Perez, A., Jermann, P., Mondada, F., & Bumbacher, E. (2026). Reflective dialogue or prompt refinement? Effects of tutor scaffolding on students' independent LLM use for programming. In E. G. Blanchard, G. Chen, M. Chi, & S. Isotani (Hrsg.), *Artificial Intelligence in Education: 27th International Conference, AIED 2026*: (Bd. 16584, 546–561). In E. G. Blanchard, G. Chen, M. Chi, & S. Isotani (Hrsg.), *Artificial Intelligence in Education: 27th International Conference, AIED 2026*: (Bd. 16584, 546–561). https://doi.org/10.1007/978-3-032-29763-1_37.

Brown, P. C., Roediger, H. L., & McDaniel, M. A. (2014). *Make it stick: The science of successful learning*. The Belknap Press of Harvard University Press.

Chakraborty, P. (2026). Effect of using generative artificial intelligence in different roles in a course on computer programming. *Computer Applications in Engineering Education*, *34*(4), e70223. https://doi.org/10.1002/cae.70223.

Chen, J., Liu, Z., Huang, X., Wu, C., Liu, Q., Jiang, G., et al. (2024). When large language models meet personalization: Perspectives of challenges and opportunities. *World Wide Web-internet and Web Information Systems*, *27*(42). https://doi.org/10.1007/s11280-024-01276-1.

Chen, S., Borchers, C., & Schunn, C. D. (2027). From revision to learning transfer: Self- and socially shared-regulated pathways in AI-assisted feedback. *Learning and Instruction*, *107*, 102489. https://doi.org/10.1016/j.learninstruc.2026.102489.

Chi, M. T. H., Adams, J., Bogusch, E. B., Bruchok, C., Kang, S., Lancaster, M., Levy, R., Li, N., McEldoon, K. L., Stump, G. S., Wylie, R., Xu, D., & Yaghmourian, D. L. (2018). Translating the ICAP Theory of Cognitive Engagement Into Practice. *Cognitive Science*, *42*(6), 1777–1832. https://doi.org/10/gd5n5p.

Contractor, Z., & Reyes, G. (2026). *Experimental evidence on the learning impact of generative AI* (IZA Discussion Paper; Nr. 18792). IZA Institute of Labor Economics.

Deng, R., Jiang, M., Yu, X., Lu, Y., & Liu, S. (2025). Does ChatGPT enhance student learning? A systematic review and meta-analysis of experimental studies. *Computers & Education*, *227*, 105224. https://doi.org/10.1016/j.co

mpedu.2024.105224.

Dunlosky, J., Rawson, K. A., Marsh, E. J., Nathan, M. J., & Willingham, D. T. (2013). Improving Students' Learning With Effective Learning Techniques: Promising Directions From Cognitive and Educational Psychology. *Psychological science in the public interest : a journal of the American Psychological Society*, *14*(1), 4–58. https://doi.org/10.1177/1529100612453266.

Fischer, M., Rau, H. A., & Rilke, R. M. (2025). *AI tutoring enhances student learning without crowding out reading effort* (IZA Discussion Paper; Nr. 18338). Institute of Labor Economics (IZA).

Freeman, S., Eddy, S. L., McDonough, M., Smith, M. K., Okoroafor, N., Jordt, H., & Wenderoth, M. P. (2014). Active learning increases student performance in science, engineering, and mathematics. *Proceedings of the national academy of sciences*, *111*(23), 8410–8415.

Gallegos, S. (2026). *Guidance over adoption: Experimental evidence on AI-assisted learning* (IZA Discussion Paper; Nr. 18513). Institute of Labor Economics (IZA).

Ghahramani, Z. (2026, Juni). *Gemini's guided learning: Results from a randomized controlled trial in Sierra Leone*. https://deepmind.google/blog/measuring-the-impact-of-learning-with-ai-in-sierra-leone-and-beyond/.

Hake, R. R. (1998). Interactive-engagement versus traditional methods: A six-thousand-student survey of mechanics test data for introductory physics courses. *American Journal of Physics*, *66*(1), 64–74. https://doi.org/10.1119/1.18809.

Harrison, W., Khowaja, R., Dobson, E., Uwimpuhwe, G., & Higgins, S. (2026). *Evaluating AI tutoring at the speed of innovation: Practitioner-led micro-randomised trials of an AI tutoring platform in GCSE science*. https://doi.org/10.48550/arXiv.2609.14789.

Hassany, M., Brusilovsky, P., Ke, J., Akhuseyinoglu, K., & Narayanan, A. B. L. (2024). *Human-AI Co-Creation of Worked Examples for Programming Classes*. arXiv. https://doi.org/10.48550/ARXIV.2402.16235.

Hattie, J. (2023). *Visible learning, the sequel: a synthesis of over 2,100 meta-analyses relating to achievement*. Routledge, Taylor & Francis Group. https://doi.org/10.4324/9781003380542.

Hayashi, Y., Shimojo, S., & Kawamura, T. (2025). Scripted interventions versus reciprocal teaching in collaborative learning: A comparison of pedagogical and teachable agents using a cognitive architecture. *Learning and Instruction*, *96*, 102057. https://doi.org/10.1016/j.learninstruc.2024.102057.

Henderson, C., & Dancy, M. H. (2007). Barriers to the use of research-based

instructional strategies: The influence of both individual and situational characteristics. *Physical Review Special Topics—Physics Education Research*, *3*(2), 020102.

Hou, X., Xiao, B., Liu, H., & Mueller, S. (2026). The role of instructional guidance in generative AI-assisted learning: Empirical evidence from construction engineering education. https://doi.org/10.48550/arXiv.2606.05509.

Jing, Y., Wang, J., Wang, P., & Xu, J. (2026). The impact of generative artificial intelligence on learning outcomes in higher education: A meta-analysis. *Journal of Computer Assisted Learning*, *42*(5), e70329. https://doi.org/10.1002/jcal.70329.

Kazu, İ. Y., & Kuvvetli, M. (2025). Digital language learning with Duolingo: assessing its impact on listening, speaking, reading, and writing skills. *Journal of Computers in Education*. https://doi.org/10.1007/s40692-025-00355-0.

Kestin, G., Miller, K., Klales, A., Milbourne, T., & Ponti, G. (2025). AI tutoring outperforms in-class active learning: an RCT introducing a novel research-based design in an authentic educational setting. *Scientific Reports*, *15*(1), 17458. https://doi.org/10.1038/s41598-025-97652-6.

Korinek, A. (2024). *Generative AI for economic research: LLMs learn to collaborate and reason* (*December 2024 update*) (NBER Working Paper; Nr. w33198). National Bureau of Economic Research. https://doi.org/10.3386/w33198.

Kosmyna, N., Hauptmann, E., Yuan, Y. T., Situ, J., Liao, X.-H., Beresnitzky, A. V., Braunstein, I., & Maes, P. (2025). Your Brain on ChatGPT: Accumulation of Cognitive Debt when Using an AI Assistant for Essay Writing Task. https://doi.org/10.48550/arXiv.2506.08872.

Kuo, Y.-C., & Zhuo, M.-J. (2026). The impact of flipped classrooms integrated with differentiated chatbots on programming learning. *Educational Technology Research and Development*. https://doi.org/10.1007/s11423-026-10669-0.

Lawson, A. P., Martella, A. M., Weidlich, J., Mulders, M., & Buchner, J. (2026). Color me confounded: A critical analysis of media comparisons on ChatGPT in education. *Computers & Education*, *254*, 105701. https://doi.org/10.1016/j.compedu.2026.105701.

LearnLM Team, Eedi, Wang, A., Rysbek, A., & Huber, A. (2025). AI tutoring can safely and effectively support students: An exploratory RCT in UK classrooms. https://doi.org/10.48550/arXiv.2512.23633.

Lee, H.-P. H., Sarkar, A., Tankelevitch, L., Drosos, I., Rintel, S., Banks, R., & Wilson, N. (2025). The Impact of Generative AI on Critical Thinking: Self-

Reported Reductions in Cognitive Effort and Confidence Effects From a Survey of Knowledge Workers. https://doi.org/10.1145/3706598.3713778.

Liu, J., Sweet, T., Chen, M. H., Engelberg, J., Masters, M. C., Clark, M., Persaud, A., Lancaster, A., Hollingsworth, J. K., & Rice, J. K. (2026). *The effects of course-integrated AI tutoring on student performance and engagement: A randomized university trial* (EdWorkingPaper; Nr. 26-1598). Annenberg Institute at Brown University. https://doi.org/10.26300/y3f8-vh05.

Love, R., Law, E., Cohen, P. R., & Kulić, D. (2025). Teaching a Conversational Agent using Natural Language: Effect on Learning and Engagement. *International Journal of Artificial Intelligence in Education*. https://doi.org/10.1007/s40593-025-00461-1.

Lyu, B., Li, C., Li, H., Oh, H., Song, Y., Zhu, W., & Xing, W. (2025). The Role of Teachable Agents' Personality Traits on Student-AI Interactions and Math Learning. *Computers & Education*, 105314. https://doi.org/10.1016/j.compedu.2025.105314.

Maier, S., Schwabe, K., Schneider, M., & Feuerriegel, S. (2026). *Designing against deskilling: Metacognitive feedback reduces cognitive offloading to LLM assistants*. https://doi.org/10.48550/arXiv.2609.20143.

Meincke, L., Mollick, E. R., & Terwiesch, C. (2024). *Prompting Diverse Ideas: Increasing AI Idea Variance*. https://papers.ssrn.com/abstract=4708466.

Melanou, C., Beege, M., & Kimmig, M. (2026). Generative AI and learning dynamics in higher education: A longitudinal empirical study. *Journal of Computer Assisted Learning*, *42*(5), e70322. https://doi.org/10.1002/jcal.70322.

MIT Teaching + Learning Lab (2023). *Rethinking Your Problem Sets in the World of Generative AI | Teaching + Learning Lab*. https://tll.mit.edu/rethinking-your-problem-sets-in-the-world-of-generative-ai/.

Mittal, S., Blodgett, S. L., & Liao, Q. V. (2026). Learning by chatting? Investigating the impact of generative AI on information seeking and learning. https://doi.org/10.48550/arXiv.2606.11669.

Mollick, E. R., & Mollick, L. (2023). *Using AI to Implement Effective Teaching Strategies in Classrooms: Five Strategies, Including Prompts* (SSRN Scholarly Paper; Nr. 4391243).

Mörth, M., Paridon, H., & Sonntag, U. (2021). Kognitionswissenschaftliche Erkenntnisse und ihre Folgerungen für evidenzbasierte Hochschullehre: die hochschullehre 05/2021. *die hochschullehre*, *7*(1), 38–48.

Murre, J. M., & Dros, J. (2015). Replication and analysis of Ebbinghaus' forgetting curve. *PloS one*, *10*(7), e0120644.

Nakamura, D. (2026). Augmentation or erosion? Regulating cognitive offloading in generative AI-supported STEM learning. *Educational Psychology Review*, *38*(124). https://doi.org/10.1007/s10648-026-10224-6.

Northcutt, C., Hasmani, I., Feng, K., Khangi, T., Plesner, A., & Mueller, J. (2026). *StudentBench: AI and human tutoring yield equivalent GRE learning gains*. https://doi.org/10.48550/arXiv.2609.28470.

OpenAI (2026, März). *Understanding AI and learning outcomes*. https://openai.com/index/understanding-ai-and-learning-outcomes/.

Oreopoulos, P., Keyes-Krysakowski, O., & Agarwal, D. (2026). *How In-School Supervised Ed-Tech Support Produces Massive Learning Gains: A Khan Academy Field Experiment in India* (NBER Working Paper; Nr. 34683). National Bureau of Economic Research. https://doi.org/10.3386/w34683.

Oreopoulos, P., Liut, M., Sungu, A., & Low, N. (2026). *Making AI tutoring productive: Evidence from a mastery-based math practice experiment* (NBER Working Paper; Nr. 35621). National Bureau of Economic Research. https://doi.org/10.3386/w35621.

Oreopoulos, P., & Low, N. (2026). *One click away: AI tutoring with Khanmigo in a two-year school experiment* (NBER Working Paper; Nr. 35620). National Bureau of Economic Research. https://doi.org/10.3386/w35620.

Ren, X., Li, X., Gao, L., Wei, Q., Liu, H., & Yu, X. (2026). Effects of AI interventions across cognitive, social-emotional, and academic outcomes: A meta-analysis of randomized controlled trials with nonlinear dose–response evidence. *Educational Psychology Review*, *38*(128). https://doi.org/10.1007/s10648-026-10217-5.

Rismanchian, S., Uzun, H., Matayoshi, J., Cosyn, E., & Kurd-Misto, E. (2026). Faster completion, less learning: Generative AI reduced study time on math problems and the knowledge they build. https://doi.org/10.48550/arXiv.2605.21629.

Robinson, C. D., Gormley, D., Trindade Ribeiro, A., & Loeb, S. (2026). *The role of human support in student engagement with AI tutoring platforms* (EdWorkingPaper; Nr. 26-1451). Annenberg Institute at Brown University. https://doi.org/10.26300/pz7p-p388.

Roediger, H. L., & Karpicke, J. D. (2006). Test-enhanced learning: taking memory tests improves long-term retention. *Psychological science*, *17*(3), 249–255. https://doi.org/10.1111/j.1467-9280.2006.01693.x.

Roediger, H. L., & Pyc, M. A. (2012). Inexpensive techniques to improve education: Applying cognitive psychology to enhance educational practice. *Journal of Applied Research in Memory and Cognition*, *1*(4), 242–248. https://doi.org/10.1016/j.jarmac.2012.09.002.

Ross, J., So, E., & Lo, A. W. (2026). Breaking Bad Financial Habits: How LLM Conversations Correct Financial Misconceptions. https://doi.org/10.48550/arXiv.2604.27022.

Säuberli, A., & Clematide, S. (2024). Automatic generation and evaluation of reading comprehension test items with large language models. https://doi.org/10.48550/arXiv.2404.07720.

Scarlatos, A., Liu, N., Lee, J., Baraniuk, R., & Lan, A. (2025). Training LLM-based tutors to improve student learning outcomes in dialogues. *arXiv preprint*.

Shadle, S. E., Marker, A., & Earl, B. (2017). Faculty drivers and barriers: laying the groundwork for undergraduate STEM education reform in academic departments. *International Journal of STEM Education*, *4*(1), 8. https://doi.org/10.1186/s40594-017-0062-7.

Shaer, O., Cooper, A., Mokryn, O., Kun, A. L., & Ben Shoshan, H. (2024). AI-augmented brainwriting: Investigating the use of llms in group ideation. https://doi.org/10.48550/arXiv.2402.14978.

Stains, M., Harshman, J., Barker, M. K., Chasteen, S. V., Cole, R., DeChenne-Peters, S. E., Eagan, M. K., Esson, J. M., Knight, J. K., Laski, F. A., Levis-Fitzgerald, M., Lee, C. J., Lo, S. M., McDonnell, L. M., McKay, T. A., Michelotti, N., Musgrove, A., Palmer, M. S., Plank, K. M., … Young, A. M. (2018). Anatomy of STEM teaching in North American universities. *Science*, *359*(6383), 1468–1470. https://doi.org/10.1126/science.aap8892.

Strömberg, D., Lei, V., & Wu, Y. (2026). *The generative AI learning penalty: Evidence from Chinese secondary education* (CEPR Discussion Paper; Nr. 21577). CEPR Press.

Stumpf, C., Schlude, A., Löwel, V., & Stürz, R. A. (2026). *Ein KI-Tutor geht in die Lehre: Empirische Ergebnisse zum Einsatz von OneTutor im Sommersemester 2025*. Bayerisches Forschungsinstitut für Digitale Transformation (bidt).

Sungu, A., Lira, B., & Duckworth, A. L. (2026). *Generative AI can harm teaching*. SSRN Working Paper 7007339. https://papers.ssrn.com/abstract=7007339.

Tao, Y., Meyer, J., & Kizilcec, R. F. (2026). *Think before you accept: Can written justification reduce uncritical uptake of AI writing suggestions?* https://doi.org/10.48550/arXiv.2609.23936.

Tobler, S., & Köhler, K. (2026). A lecture-specific AI-based tutor for higher education: Pedagogical design and empirical evaluation. *Education Sciences*, *16*(5), 812. https://doi.org/10.3390/educsci16050812.

Tobor, J., Then Bergh, C., & Lüthi, R. (2026). *Use Cases in Bewegung: Wie KI*

Studium und Lehre weiter verändert (Blickpunkt). Hochschulforum Digitalisierung.

Turano, C., Pihl, V., Agnew, C., Ziegler, L., & Loeb, S. (2026, August). *AI tutoring is not a monolith: What we actually know*. https://nssa.stanford.edu/briefs/ai-tutoring-not-monolith.

Wang, S., Xu, T., Li, H., Zhang, C., Liang, J., Tang, J., Yu, P. S., & Wen, Q. (2024). Large language models for education: A survey and outlook. *arXiv preprint arXiv:2403.18105*.

Wissenschaftsrat (2026). *Intellektuelle Souveränität: Empfehlungen für die Hochschulbildung in Zeiten von generativer KI* (Nr. Drs. 3319-26). Wissenschaftsrat. https://doi.org/10.57674/1evx-t906.

Wu, M., & Ouyang, F. (2026). How generative AI influences learning outcomes in programming education: A three-level Bayesian meta-analysis. *Educational Psychology Review*, *38*(117). https://doi.org/10.1007/s10648-026-10211-x.

Wu, R., & Yu, Z. (2024). Do AI chatbots improve students learning outcomes? Evidence from a meta-analysis. *British Journal of Educational Technology*, *55*(1), 10–33. https://doi.org/10.1111/bjet.13334.

Wu, Y., Jia, F., Zhang, S., Li, H., Zhu, E., Wang, Y., Lee, Y. T., Peng, R., Wu, Q., & Wang, C. (2023). *MathChat: Converse to Tackle Challenging Math Problems with LLM Agents*. arXiv. https://doi.org/10.48550/ARXIV.2306.01337.

Xu, K., Shen, Y., Yan, L., & Ren, Y. (2026). Cognitive agency surrender: Defending epistemic sovereignty via scaffolded AI friction. https://doi.org/10.48550/arXiv.2603.21735.

Yang, S., Van Alstyne, M., & Dellarocas, C. (2026). *When AI tutors speak: Evidence from a randomized field experiment*. https://doi.org/10.48550/arXiv.2609.23958.

Yang, Y., Zhang, Z., Tang, N., Wang, X., Ambrose, A., Myers, N., Clauss, P., & Li, T. J.-J. (2026). Lessons from real-world deployment of a cognition-preserving writing tool: Students actively engage with critical thinking and planning affordances. https://doi.org/10.48550/arXiv.2603.15777.

Yuen, N. (2025). *Questioning the bot: Socratic chats with AI*. https://aipedagogy.org/assignment/questioning-the-bot-socratic-chats-with-ai-2/.

Zhang, Y.-F., Li, H., Song, D., Sun, L., Xu, T., & Wen, Q. (2025). *From Correctness to Comprehension: AI Agents for Personalized Error Diagnosis in Education*. arXiv. https://doi.org/10.48550/ARXIV.2502.13789.

Teil II

Teil II: Anwendungen

5 Phasen der Arbeit mit generativer KI (4D)

In diesem Kapitel

- Mit KI arbeiten: vier Kompetenzen
- Delegation: Was übernimmt die KI?
- Discernment: Wie beurteile ich, was die KI liefert?
- Diligence: Verantwortung, Offenlegung, Ressourcen
- Wie prüfen wir jetzt? Jenseits der Homework Apocalypse
- Kurs-Integration: Drei Phasen eines Semesters

Prof. Dr. Henrik Sauer ist Studiendekan und lehrt Marketing für 180 Studierende der Betriebswirtschaft. Im Sommer hat er seine Hausarbeitsthemen einmal in einen Chatbot getippt; die Antworten waren dünn, also ließ er die Themen, wie sie waren. Die Arbeiten, die jetzt auf seinem Tisch liegen, sind glatt formuliert, und ob sie eigene Leistung zeigen, kann er nicht sagen. Ein Kollege will alle Abgaben durch einen KI-Detektor schicken. Die Fakultät erwartet bis Semesterbeginn eine Regel zur Dokumentation, und der Entwurf aus der Verwaltung verlangt das vollständige Protokoll jeder Eingabe. Für das neue Semester plant Sauer eine 90-minütige KI-Einführung in der ersten Woche. Er fragt sich, ob er damit das Richtige aufbaut oder nur das Falsche absichert.

Die Szene ist aus Gesprächen in Workshops und Gremien zusammengesetzt.

Bevor Sie weiterlesen: Wie sehen Sie das?

Wie sehr stimmen Sie den vier Aussagen zu? Jede Aussage wird an der Stelle im Kapitel aufgelöst, die sie beantwortet. Wer sich vorher festlegt, liest gezielter.

1. Liefert ein Sprachmodell auf eine Kursaufgabe beim ersten Versuch eine schwache Antwort, können Studierende die Aufgabe kaum mit KI lösen.
stimme zu 1 – 2 – 3 – 4 – 5 *stimme nicht zu*
(Auflösung in Kapitel 2.1.3)

2. Studierende lernen den Umgang mit KI besser, wenn sie gleich damit üben und die Erklärungen an konkreten Problemen folgen, als durch eine gründliche Einführung vorab.
stimme zu 1 – 2 – 3 – 4 – 5 *stimme nicht zu*
(Auflösung in Kapitel 5.2.2)

3. Prüfende können eine mit KI geschriebene Hausarbeit in der Regel nicht von einer rein menschlichen unterscheiden, auch wenn die Aufgabe authentisch und praxisnah gestellt ist.
stimme zu 1 – 2 – 3 – 4 – 5 *stimme nicht zu*
(Auflösung in Kapitel 5.5)

4. Damit die KI-Nutzung nachvollziehbar wird, sollten Studierende jede Interaktion mit allen Prompts protokollieren.
stimme zu 1 – 2 – 3 – 4 – 5 *stimme nicht zu*
(Auflösung in Kapitel 5.4.2)

Lernziele: Nach diesem Kapitel können Sie …

1. eigene Aufgaben mit einem Sprachmodell durchspielen und daraus Anpassungen für Ihren Kurs ableiten;
2. eine praktische, über das Semester verteilte Einführung der Studierenden planen und einen Kurs in drei Phasen mit wechselnden Rollen der KI ergänzen;
3. eine Prüfungsleistung nach den vier Säulen Mündlichkeit, Prozessorientierung, Kontextualisierung und Kollaboration umbauen und die Grenzen von KI-Detektoren begründen;
4. Studierenden eine praktikable Dokumentation ihrer KI-Nutzung vorgeben, die zu den Richtlinien Ihrer Hochschule passt.

Die Kernaussagen am Kapitelende sind nach diesen vier Zielen geordnet.

5.1 Mit KI arbeiten: vier Kompetenzen

Wer mit künstlicher Intelligenz (KI) arbeitet, trifft vier Arten von Entscheidungen. Vor dem Prompt, der Eingabe an die KI, steht die Frage, was überhaupt an die KI geht, dann die Beschreibung der Aufgabe, nach der Antwort die Prüfung des Ergebnisses und über allem die Verantwortung dafür. Ein Schema, das diese Schritte ordnet, macht aus einer Sammlung von Tipps eine Arbeitsweise, und weil es keine Werkzeuge nennt, übersteht es den nächsten Modellwechsel. Dieses Kapitel folgt dem Schema: Nach den Grundbegriffen in Kapitel 2.1 beantwortet jeder Abschnitt eine der vier Fragen, und die Technik im Inneren der Modelle steht am Ende als Vertiefung.

5.1.1 Das 4D-Modell

AI Fluency (etwa: Gewandtheit im Umgang mit KI) ist die Fähigkeit, effektiv, effizient, ethisch und sicher mit KI zu arbeiten (Dakan & Feller, 2025). Das Modell zerlegt sie in vier Kompetenzen, die *4 D*, mit je drei Unterkompetenzen (Tabelle 5.1).

Kompetenz	Leitfrage	Unterkompetenzen	Herkunft des Wortes
Delegation	Was übernimmt der Mensch, was die KI?	Ziel- und Aufgabenbewusstsein (*goal and task awareness*), Kenntnis der Werkzeuge (*platform awareness*), Aufgabenverteilung (*task delegation*)	lat. *delegare*, übertragen
Description	Wie sage ich der KI klar, was ich will?	Ergebnis beschreiben (*product description*), Zusammenarbeit beschreiben (*process description*), Verhalten festlegen (*performance description*)	lat. *describere*, umreißen, aufzeichnen
Discernment	Wie beurteile ich, was die KI liefert?	Ergebnis beurteilen (*product discernment*), Zusammenarbeit beurteilen (*process discernment*), Verhalten beurteilen (*performance discernment*)	lat. *discernere*, unterscheiden, trennen

Kompetenz	Leitfrage	Unterkompetenzen	Herkunft des Wortes
Diligence	Wie setze ich KI verantwortlich und offen ein?	Sorgfalt beim Erzeugen (*creation diligence*), Offenlegung (*transparency diligence*), Prüfung vor der Freigabe (*deployment diligence*)	lat. *diligentia*, Sorgfalt, von *diligere*, hochachten, sorgsam auswählen

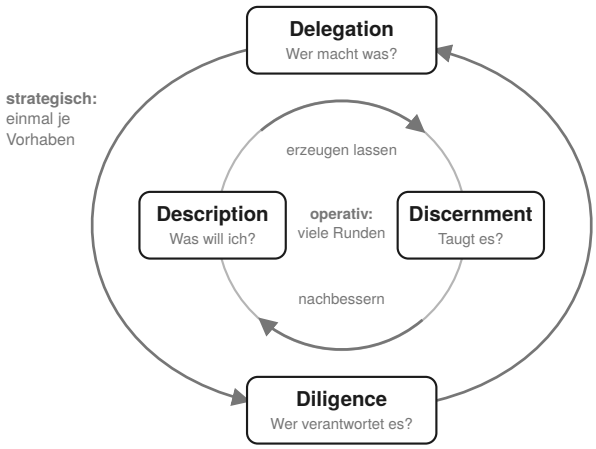
Tabelle 5.1. Die vier Kompetenzen des AI-Fluency-Modells mit ihren Unterkompetenzen. Übersetzung nach Dakan & Feller (2025), CC BY-SA 4.0

Dakan und Feller nennen die vier D ausdrücklich vernetzte Kompetenzen, keine Reihenfolge (Dakan & Feller, 2025). In ihrem Kurs für Lehrende verbinden sie die vier aber zu zwei Schleifen (Dakan et al., 2025), und daraus baut dieses Buch einen Kreislauf(Abbildung 5.1). Die äußere Schleife zwischen **Delegation und Diligence** ist strategisch und läuft einmal je Vorhaben: Was soll die KI übernehmen, und welche Pflichten folgen daraus? Sie läuft in beide Richtungen, denn eine Pflicht zur Offenlegung oder zur Prüfung verändert, was man sinnvoll abgibt. Die innere Schleife zwischen **Description und Discernment** dreht sich in jedem Arbeitsgang viele Male: beschreiben, erzeugen lassen, prüfen, nachbessern. Das Buch liest die vier D damit als Stufen eines Arbeitsablaufs; es folgt der Lehrpraxis der Autoren, nicht dem Wortlaut ihrer Definition.

Das Schema beantwortet nicht, wie viel KI eine Aufgabe verträgt. Zu viel Einsatz kostet Kompetenz und Qualität, zu wenig kostet Übung mit Werkzeugen, die die Studierenden im Beruf vorfinden; die Mitte zwischen beiden muss man für jede Aufgabe neu suchen, und der Kreislauf zeigt, an welcher Stelle die Entscheidung fällt. Was die Forschung über die Kosten des Auslagerns weiß, zeigt Kapitel 4.5.

5.1.2 Wie dieses Kapitel und das Buch das Schema nutzen

Im übrigen Buch endet jede der vier Rollen in Kapitel 6 mit einem Absatz, der den Kreislauf für diese Rolle durchläuft und die Stufe benennt, an der er am ehesten reißt; die Prompt-Sammlung in Anhang A liefert Material für die Stufe Description.



Modalität je Rolle

Hiwi	Automation
Copilot	Augmentation
Tutor	Agency
Simulator	Agency

Fassung zum Anklicken

Abbildung 5.1. Der 4D-Kreislauf. Die äußere Schleife (Delegation und Diligence) entscheidet einmal je Vorhaben, was die KI übernimmt und welche Pflichten daraus folgen; die innere (Description und Discernment) dreht sich in jedem Arbeitsgang mehrmals. Eigene Darstellung nach Dakan & Feller (2025) und den beiden Schleifen aus Dakan et al. (2025). Die Fassung zum Anklicken mit Unterkompetenzen und dem Engpass je Rolle: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/4d-kreislauf.html aufrufen.

Warum AI Fluency?

Artikel 4 der KI-Verordnung verpflichtet Hochschulen, die KI-Systeme bereitstellen, zu Maßnahmen für die KI-Kompetenz (*AI literacy*) ihres Personals, sagt aber nicht, worin diese Kompetenz besteht; der Digital-Omnibus vom Juli 2026 hat die Pflicht entschärft und die Definition nicht nachgeliefert (Europäisches Parlament und Rat, 2026; Europäisches Parlament und Rat der Europäischen Union, 2024) (Kapitel 5.4.1.2). Die Lücke füllen Kompetenzrahmen; einen Überblick über die Forschung zu *AI Literacy* gibt Pinski & Benlian (2024). Von fünf neueren Rahmen für die Hochschullehre, die die Online-Fassung vergleicht, arbeitet dieses Buch mit *AI Fluency* von Rick Dakan und Joseph Feller: Es ordnet nach dem Arbeitsprozess, nennt keine Werkzeuge und führt als einziger die Verantwortung gegenüber Dritten als eigene Kompetenz. Alle fünf verlangen, dass Lernende KI-Ergebnisse kritisch beurteilen, kaum einer sagt, wie; die Prüfmethoden liefert dieses Buch dort nach, wo sie gebraucht werden (Kapitel 5.3). Die deutschen Definitionen sind eigene Übersetzungen der Fassung, die die irische Hochschulbehörde HEA (*Higher Education Authority*) herausgegeben hat; sie steht wie dieses Buch unter der Lizenz CC BY-SA 4.0.

Abbildung 5.2. Vergleich der fünf Kompetenzrahmen (Zielgruppe, Ordnungsprinzip, Entstehung) in der Online-Fassung: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/kapitel05-4d-phasen.html#sec-schemas-rahmen aufrufen.

5.2 Delegation: Was übernimmt die KI?

Delegation fragt, was der Mensch übernimmt und was die KI (Tabelle 5.1). Die Antwort hat drei Teile, die den Unterkompetenzen des Modells entsprechen: wissen, was die Modelle können (Kapitel 5.2.1), Setup und Modell kennen (Kapitel 2.4.1, Kapitel 2.2) und die Arbeit zwischen Mensch und KI verteilen (Kapitel 3.2). Den größten Teil des Harness liefert dabei der Hersteller; den Teil, den die Nutzenden selbst bauen, nennt Böckeler (2026) den äußeren Harness (*outer harness*): Anleitungsdateien, Skills (bei Bedarf geladene Gebrauchsanweisungen), eigene Wissensbasen und Prüfregeln. An diesem äußeren Harness gestalten Lehrende und Studierende; ein Übungstutor (Kapitel 7.2.2), ein Karriereberater (Kapitel 7.3.4) und eine Quellenanbindung mit Praxispartnern (Kapitel 7.3.5) laufen auf denselben großen Modellen und unterscheiden sich in Anleitung, Quellen und Grenzen. Unsere Rolle verschiebt sich dabei: Wir setzen das Ziel, legen fest, wo der Agent anhält, und prüfen, was zurückkommt; OpenAI fasst das in den Leitsatz „Humans steer. Agents execute." (Lopopolo, 2026).

5.2.1 Was die Modelle können und was nicht

Was Sprachmodelle können, ist sehr uneinheitlich und **verändert sich schnell**. Mollick und Kollegen sprechen von einer „**Jagged Technological Frontier**", einer zerklüfteten Technik-Grenze: Zwei Aufgaben von ähnlicher Schwierigkeit für Menschen können auf verschiedenen Seiten der Grenze liegen; die eine löst die KI auf menschlichem Niveau oder besser, an der anderen scheitert sie (Dell'Acqua et al., 2023). In ihrem Experiment mit Consultants brachte KI bei den meisten von 18 Beratungsaufgaben große Vorteile; bei einer gezielt außerhalb der Grenze gewählten Aufgabe lagen die Consultants mit KI dagegen 19 Prozentpunkte seltener richtig als ohne (Dell'Acqua et al., 2023).

Ihre Einschätzung prüfen

„Wenn ein Modell die schwierigen Aufgaben Ihres Fachs löst, können Sie sich bei den leichteren erst recht auf es verlassen."
Auflösung: nein. Die Fähigkeiten der Modelle folgen nicht unserer Vorstellung von schwer und leicht. Zwei für Menschen ähnlich schwierige Aufgaben können auf verschiedenen Seiten der zerklüfteten Grenze lie-

gen, und bei der Aufgabe jenseits der Grenze lagen die Consultants mit KI 19 Prozentpunkte seltener richtig als ohne. Wo die Grenze im eigenen Fach verläuft, zeigt nur der Test an den eigenen Aufgaben.

Zugleich wächst, was sich an die Modelle delegieren lässt. Ein anschauliches Maß dafür ist der **Zeithorizont**: die Dauer, die Fachleute für eine Aufgabe brauchen, die ein Modell in der Hälfte der Fälle löst (Kwa et al., 2025). Er stieg von rund 4 Minuten bei GPT-4 (März 2023) auf rund 17 Stunden bei einer frühen Fassung von Claude Mythos Preview (April 2026) und verdoppelte sich seit 2023 etwa alle 129 Tage, also gut alle vier Monate (METR, 2026). Den letzten Wert ordnet METR selbst als unsicher ein, weil die Testaufgaben über 16 Stunden nicht mehr für eine verlässliche Messung reichen.

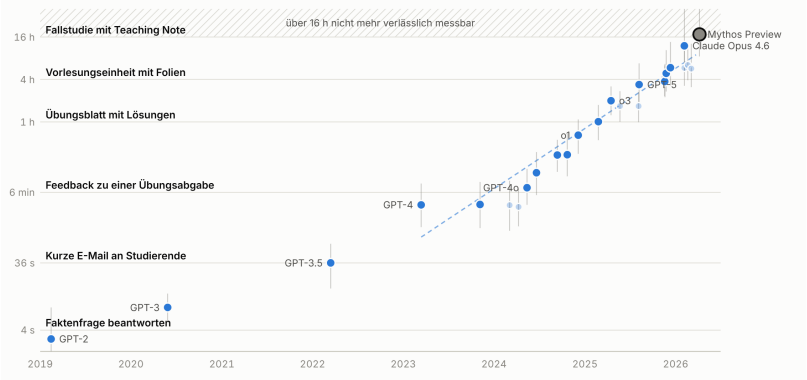


Abbildung 5.3. KI-Agenten bewältigen immer längere Aufgaben: 50-%-Zeithorizont der Modelle 2019–2026 auf logarithmischer Achse, mit Trend ab 2023 (gestrichelt) und Lehraufgaben ähnlicher Dauer zur Orientierung (eigene Zuordnung). Über 16 Stunden ist die Messung nicht mehr verlässlich. Daten: METR (2026), Stand 8. Mai 2026. Interaktive Fassung: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/ki-entwicklung.html?zeige=zeithorizont aufrufen.

Warum die Grenze so schnell wandert, beschreiben zwei **Skalierungsgesetze** (*scaling laws*) (Hoffmann et al., 2022; Kaplan et al., 2020; OpenAI, 2024; anschaulich bei Grootendorst, 2025). Erstens werden Modelle verlässlich besser, je mehr Daten, Rechenleistung und Parameter ins Training fließen: Jede Verzehnfachung des Rechenaufwands senkt den Vorhersagefehler um etwa denselben Anteil (Kaplan et al., 2020), sofern Daten und Modellgröße im Gleichschritt wachsen (Hoffmann et al., 2022). Zweitens liefert

ein fertig trainiertes Modell bessere Lösungen, wenn es vor der Antwort mehr „**Denkzeit**“ (*test-time compute*) für zusätzliche Rechenschritte erhält (OpenAI, 2024; Snell et al., 2024); auf diesem zweiten Gesetz beruhen die Reasoning-Modelle (Gottweis et al., 2025; Schwarcz et al., 2025). Wie bei einer Prüfung ist die Lernzeit einmal bezahlt, die Bearbeitungszeit fällt bei jeder Prüfung neu an; deshalb kosten Reasoning-Modelle je Antwort mehr. Trotzdem bleiben die **Grenzkosten der Nutzung sehr niedrig**, und personalisierte Lernangebote lassen sich kostengünstig skalieren (Mollick, 2025).

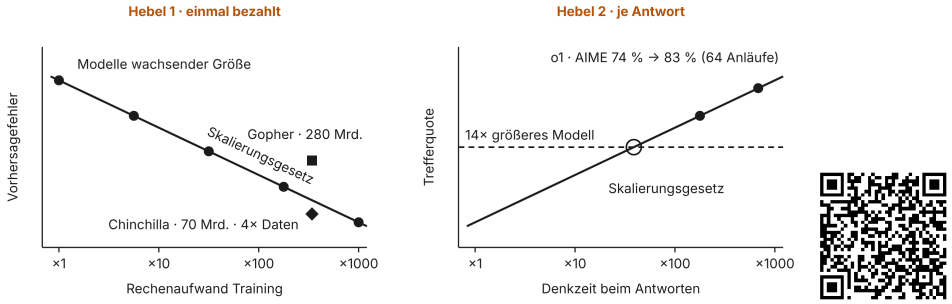


Abbildung 5.4. Zwei Skalierungsgesetze: Links sinkt der Vorhersagefehler mit dem Rechenaufwand im Training auf einer Geraden (beide Achsen logarithmisch); bei gleichem Budget schneidet das kleinere, mit mehr Daten trainierte Chinchilla besser ab als Gopher. Rechts steigt die Trefferquote mit der Denkzeit beim Antworten; bei mittelschweren Aufgaben schlägt ein kleines Modell mit Denkzeit ein 14-mal größeres. Lehrmodell, schematisch; Zahlen nach Kaplan et al. (2020), Hoffmann et al. (2022), OpenAI (2024) und Snell et al. (2024). Interaktive Fassung: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/scaling-laws.html aufrufen.

Wie schnell die Preise fallen, zeigt eine Auswertung von Epoch AI. Der GPQA Diamond (*Graduate-Level Google-Proof Q&A*, Fragen, die sich nicht ergoogeln lassen) ist eine Sammlung von 198 naturwissenschaftlichen Multiple-Choice-Fragen auf Promotionsniveau. Die niedrigsten Kosten, mit denen ein Modell 75 % davon richtig beantwortet, sanken von 29,9 US-Cent je Frage im Januar 2025 auf 0,04 Cent im Juli 2026, um den Faktor 725 oder 99,9 % in 17 Monaten (Emberson & Roodman, 2026). Als mögliche Gründe nennt Epoch AI, ohne sie einzeln nachzuweisen, kleinere und je Token (Textbaustein) billigere Basismodelle unter den Reasoning-Modellen, weni-

ger Denk-Token je Frage und den Wettbewerb, der den Aufpreis des ersten Modells auf einem Leistungsniveau rasch abschmelzen lässt (Emberson & Roodman, 2026).

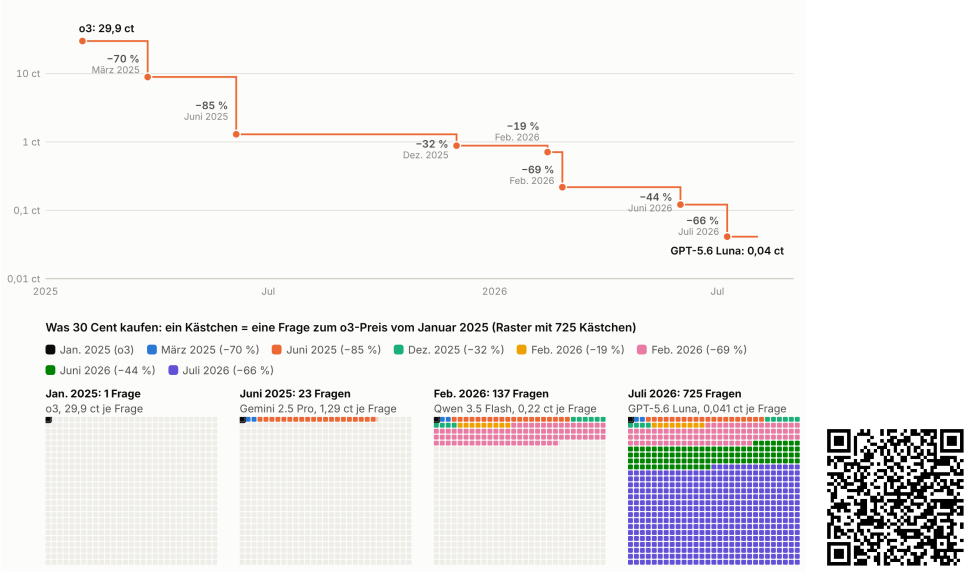


Abbildung 5.5. Expertenwissen wird 725-mal billiger: niedrigste Kosten je Frage, mit denen ein Modell 75 % des GPQA Diamond richtig beantwortet, Januar 2025 bis Juli 2026 (logarithmische Achse). Darunter als Raster: Ein Kästchen ist eine Frage zum o3-Preis vom Januar 2025, gefüllt ist, was 30 Cent zum jeweiligen Zeitpunkt kaufen; der letzte Sprung (−66 %) bringt mit 479 Kästchen mehr als alle früheren zusammen. Rasterdarstellung nach einer Idee von Mollick (2026). Daten: Emberson & Roodman (2026), Epoch AI. Interaktive Fassung: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/ki-entwicklung.html?zeige=kosten aufrufen.

Was das für die Lehre bedeutet, zeigt ein Tutor-Bot, dem 150 Studierende an den 98 Tagen eines Semesters je zwei Fragen pro Tag stellen, zusammen 29.400 Fragen. Auf der Rechengrundlage von Epoch AI kostete dieses Semester anfangs rund 8.800 US-Dollar und im Juli 2026 rund 12 US-Dollar, je Person also 59 US-Dollar und 8 Cent. Das ist nur eine Größenordnung, denn ein Tutorgespräch ist länger als eine Testfrage, aber sie verschiebt die Frage von „Können wir uns das leisten?“ zu „Wer prüft, was der Tutor sagt?“.

Zum Standardumfang der großen Chat-Interfaces gehören inzwischen

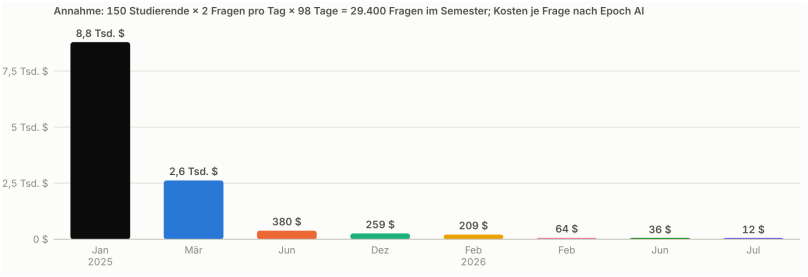


Abbildung 5.6. Was ein Tutor-Bot im Semester kostet: 150 Studierende stellen je 2 Fragen pro Tag an 98 Tagen (29.400 Fragen), jede zum Preis einer GPQA-Diamond-Frage beim günstigsten Modell mit 75 % richtigen Antworten; von rund 8.800 US-$ (o3, Januar 2025) auf rund 12 US-$ (GPT-5.6 Luna, Juli 2026). Nur Größenordnung. Daten: Emberson & Roodman (2026). Interaktive Fassung mit eigenen Kurszahlen: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/tutor-kosten.html aufrufen.

vier **Funktionsklassen**, die den Einsatz in der Lehre erweitern: **Bildgenerierung** für Visualisierungen, **Audio-Modelle** mit steuerbarem Tonfall für Rollenspiele und barrierefreie Inhalte, **Research-Harnesses** („Deep Research", Recherche-Agenten) für Literatursichtung und Projektarbeiten sowie günstige **Mini-Varianten der Reasoning-Modelle** (s. die Beispiele in Kapitel 1).

5.2.2 Einführung der Studierenden planen: Besser praktisch, häufig und niedrigschwellig

Den Einsatz von KI lernen die Studierenden, wenn sie häufig und über das Semester zeitversetzt damit experimentieren dürfen und müssen. Auch hier führen wieder die Empfehlungen des **Spacing & Interleaving** zu höherer Effektivität. Unterstützend können **externe Lernvideos** von seriösen Plattformen wie dem KI-Campus genutzt werden (z. B. https://ki-campus.org/videos/generativeki) oder selbst erstellte hochschulweite Angebote wie die Lehrpfade der TH Köln (https://lehrpfade.th-koeln.de/kategorie/ki/).

Um ein gemeinsames Verständnis über Grundlagen herzustellen, ist es hilfreich, **Zeit in einer der ersten Präsenzveranstaltungen einzuräumen**, um

das gemeinsam zu üben. Der Sprung ins kalte Wasser ist dabei meist besser als eine lange Theorieeinführung: **Gleich anfangen**, dann problembasiert erläutern. Aspekte von **testgestütztem Lernen** und **fragebasierte Ausarbeitung** lassen sich gut über Anwendungsaufgaben in der Präsenzveranstaltung einbauen.

Ihre Einschätzung prüfen

„Studierende lernen den Umgang mit KI besser, wenn sie gleich damit üben und die Erklärungen an konkreten Problemen folgen, als durch eine gründliche Einführung vorab."
Auflösung: eher ja. Den Umgang mit KI lernen Studierende, wenn sie häufig und über das Semester verteilt damit arbeiten; das folgt den gut belegten Befunden zu verteiltem Üben. Die Empfehlung, gleich anzufangen und dann problembasiert zu erläutern, stützt sich auf diese Befunde und auf Erfahrung aus der Lehre, nicht auf einen direkten Vergleich der beiden Einstiege.

5.2.2.1 Beispiel: KI-Übung in Präsenzveranstaltung am Ende eines Theorieblock zu Nachhaltigkeit in Lieferketten

Aufgabe: Nicht lange schnacken, gleich anpacken! Mit der KI einen Projektplan für erste konkrete Schritte einer Nachhaltigkeitsstrategie erstellen (Edge Browser, Bing Copilot = GPT-4). Prompts zum Einstieg werden den Studierenden vorgegeben. Anfang mit:

- *Prompt #1*: „KI als Tutor" oder ähnlich (siehe Anhang A, Allgemeiner Tutor. Prompts im Folgenden immer *kursiv*.)
- *Prompt #2*: *Ich will eine Cradle-to-cradle Nachhaltigkeitsstrategie für ein Unternehmen entwerfen. Helfen Sie mir, konkrete erste Schritte nach der Cradle-to-cradle Zertifizierung zu planen.*

Studierende sollen ein Unternehmen auswählen, bei dem sie schon einmal gearbeitet haben, oder das sie gut kennen. Hier ein Beispiel.

- *Prompt #3*: *Ich denke über Voss Automotive nach, die folgende Produkte herstellen: innovative Leitungs-und Verbindungssysteme, die überall auf der Welt in Pkw und Nutzfahrzeugen sowie Land- und Baumaschinen*

eingesetzt werden. Unser Produktportfolio umfasst dabei einbaufertige Leitungsmodule mit Rohren, Schläuchen, Verbindungselementen, Ventilen und Sensoren. Zur Verbindungstechnik gehören Stecksysteme, Verschraubungen, Mehrfachkupplungen und Verteiler.

- *Prompt #4*: *Erstelle einen Zeitplan als Tabelle mit Aufwandsschätzungen für 3 Personen in 4 Wochen.*
- *Prompt #5*: *Mehr Details bitte: Erstelle Unteraufgaben für die jeweiligen Aufgabenpakete, jeweils auch wieder mit Aufwandsschätzungen.*

Die Studierenden sollen den Projektplan dann weiter verbessern und diskutieren. Erweiternd können sie auch z. B. Projektrisiken, Indikatoren und Gegenmaßnahmen und Szenarien erheben und diskutieren.

5.3 Discernment: Wie beurteile ich, was die KI liefert?

Discernment fragt, wie wir beurteilen, was die KI liefert (Tabelle 5.1). Die Grundlage ist ein nüchterner Befund: Ein Sprachmodell prüft keine Wahrheit, und über sein eigenes Vorgehen gibt es nicht verlässlich Auskunft.

Können wir das Modell fragen, wie es zu einem Ergebnis gekommen ist? Eher nicht. Eine Studie des KI-Labors Anthropic, die mit neuen Methoden in ein Modell hineinschaut, fand bei einfachen Rechnungen wie der Quadratwurzel von 0,64 klare interne Rechenschritte; bei schwierigeren, etwa dem Kosinus einer großen Zahl, gab das Modell Rechnungen an, für die keine internen Prozesse erkennbar waren (Lindsey et al., 2025). Es erfindet dann eine plausible Rechnung, ohne gerechnet zu haben; die Autoren nennen das mit dem Philosophen Harry Frankfurt *bullshitting*. Bekommt es einen Hinweis auf das gewünschte Ergebnis, rechnet es rückwärts darauf hin, ein Verhalten, das sie als „motiviertes Denken“ (*motivated reasoning*) bezeichnen. Weitere Befunde dieser Studie stellt die Vertiefung vor (Kapitel 2.6.2).

Was kann zu Halluzinationen führen? Die erfundene Literaturangabe aus dem Kapitelauftakt hat einen erkennbaren Mechanismus. Im Modell ist standardmäßig ein Schaltkreis (*circuit*) aktiv, der die Antwort verweigert, wenn Informationen fehlen; erkennt das Modell einen bekannten Namen, hemmt ein konkurrierender Mechanismus diese Verweigerung und gibt die Antwort frei. Kennt das Modell den Namen, aber nicht die gesuchte Tatsache, entsteht eine Halluzination: Nach einem Fachartikel des bekannten Forschers Karpathy gefragt, nennt es einen erfundenen Titel, bei weniger

bekannten Namen sagt es, die Antwort nicht zu kennen (Lindsey et al., 2025).

Wie man Ergebnisse prüft, zeigt dieses Buch dort, wo es gebraucht wird: in der Prüfregel der Modellwahl (Kapitel 2.2), beim Tutor (Kapitel 6.3.3) und bei KI-gebauten Simulationen (Kapitel 6.2.2.3).

Ihre Einschätzung prüfen

„Dass ein Chatbot Quellen erfindet, ist ein Programmfehler, den die nächsten Modellversionen abstellen."
Auflösung: nein. Erfundene Quellen folgen aus der Funktionsweise: Ein Sprachmodell erzeugt das wahrscheinlichste nächste Wort und prüft dabei keine Wahrheit, und erkennt es einen Namen, unterdrückt das die Antwort „weiß ich nicht", auch wenn ihm das Wissen fehlt. Abstellen lässt sich das nicht, eindämmen schon: mit eigenem Material als Grundlage (Kapitel 2.4.1), Musterlösungen als Vorgabe und systematischer Prüfung der Ergebnisse (Kapitel 5.1.1).

5.4 Diligence: Verantwortung, Offenlegung, Ressourcen

Diligence fragt, wie wir KI verantwortlich und offen einsetzen (Tabelle 5.1): mit Sorgfalt beim Erzeugen, mit Offenlegung gegenüber anderen und mit Prüfung, bevor ein Ergebnis oder ein System freigegeben wird.

Die Technik verschiebt die Verantwortung, sie nimmt sie nicht ab. Das zeigt das Gedächtnis eines Agenten (Kapitel 2.4.3): Ein Fehler, der einmal dort steht, wirkt in allen folgenden Sitzungen fort, die menschliche Prüfung vorgeschlagener Änderungen wird leicht zum Abnicken, und eine Versionsgeschichte zeigt, *wer* etwas geändert hat, nicht, *ob* es stimmt (Bridgwater, 2026). Wer mehr Änderungen erzeugen lässt, als er lesen kann, hat kein geprüftes Gedächtnis, sondern ein ungeprüftes mit Freigabestempel.

Offenlegung heißt, zu sagen, wo KI mitgearbeitet hat: gegenüber Studierenden, wenn Material oder Feedback mit KI entsteht, und gegenüber allen, die mit KI erzeugte Texte, Bilder oder Stimmen lesen, sehen oder hören. Welche Pflichten die KI-Verordnung dafür vorsieht, steht in Kapitel 5.4.1.2.

5.4.1 Richtlinien zur KI-Nutzung - welche Handreichungen geben Hochschulen und was wird empfohlen?

5.4.1.1 Übersicht: Was regeln die Richtlinien der Hochschulen?

An et al. (2025) werten die Richtlinien der 50 führenden US-Hochschulen zur Nutzung von LLM aus. Die Haltung ist insgesamt positiv, unterscheidet sich aber nach Zielgruppe. Lehrende erhalten in 94 % der Richtlinien didaktische Hinweise zu Kursdesign, Aufgaben und Prüfungsformaten, etwa gestufte Erlaubnisformen in der Kursbeschreibung (Syllabus): verboten, erlaubt mit Dokumentation, ausdrücklich gewünscht. Für Studierende überwiegen Integritätsregeln: Nicht genehmigte Nutzung gilt als Täuschungsversuch, die Klärung, ob KI zulässig ist, liegt bei ihnen, und Anleitungen zur kompetenten Nutzung bieten nur wenige Richtlinien. Die Autor:innen empfehlen zielgruppenspezifische, laufend weiterentwickelte Richtlinien.

Für Deutschland hat das Hochschulforum Digitalisierung die Leitlinien von 27 Hochschulen ausgewertet (Tobor, 2024), ein Update vom Februar 2025 ergänzt neuere Entwicklungen (Tobor, 2025). Tobor hebt vier bewährte Praktiken hervor:

- **Angepasste Eigenständigkeitserklärung:** Studierende erklären bei schriftlichen Prüfungen ohne Aufsicht, ob und wie sie KI-Werkzeuge genutzt haben (Vorlage etwa der Hochschule RheinMain).
- **Verdachtsfälle im Gespräch klären:** Detektoren wie GPTZero gelten als unzuverlässig. Empfohlen wird ein multifaktorielles Vorgehen mit Indikatoren wie nicht existierenden Quellen oder auffälligen Formulierungen; erhärtet sich der Verdacht, prüft ein Klärungsgespräch, ob die Studierenden ihre Arbeit verstehen (Leitfaden der Universität Vechta).
- **Keine automatisierte Bewertung:** Prüfungsordnungen verlangen eine begründete Bewertung durch eine prüfende Person; studentische Arbeiten in KI-Systeme hochzuladen gilt zudem als urheberrechtlich bedenklich.
- **Prüfungsformate didaktisch weiterentwickeln:** reflexionsorientierte Aufgaben, Zwischenfeedback und ergänzende mündliche Prüfungen (Kapitel 5.5); auch der Umgang mit KI selbst wird Prüfungsgegenstand.

Im Update kritisiert Tobor die **thematische Zersplitterung** der Handreichungen, die regulatorische, didaktische und Risikofragen für viele

Gruppen zugleich abdecken; zentrale Einstiegsseiten wie der KI-Hub der Universität Vechta (https://www.uni-vechta.de/ki-hub) bündeln sie. Wirksam werden Leitlinien erst, wenn sie **bekannt gemacht, diskutiert und weiterentwickelt** werden, am besten gemeinsam mit Studierenden, im Hochschulverbund und mit Formaten wie Prompt-Battles (Wettbewerben im Prompten) (Tobor, 2025).

5.4.1.2 Was die KI-Verordnung von Hochschulen verlangt

Richtlinien sind seit 2025 nicht mehr nur Hausordnung, sondern Teil einer Rechtspflicht. Die europäische KI-Verordnung (KI-VO, *AI Act*; *regulation* von lateinisch *regula*, „Richtschnur“) verlangt in Artikel 4 seit Februar 2025 von jeder Organisation, die KI-Systeme betreibt, Maßnahmen für die KI-Kompetenz (*AI literacy*) ihres Personals; der Wissenschaftsrat stellt klar, dass Hochschulen, die Studierenden und Lehrenden Chat-Zugänge oder eigene Tutoren bereitstellen, in diesem Sinn Betreiber (*deployer*) sind, und empfiehlt, KI-Kompetenz als Teil der Hochschulbildung selbst zu verankern statt als Zusatzschulung (Wissenschaftsrat, 2026). Die Vereinfachungsverordnung vom Juli 2026, der sogenannte Digital-Omnibus, hat Artikel 4 nicht gestrichen, sondern entschärft: Organisationen müssen weiterhin Maßnahmen ergreifen, aber kein bestimmtes Kompetenzniveau jeder einzelnen Person mehr garantieren (Europäisches Parlament und Rat, 2026; KI-Campus, 2026). Für die Praxis der Lehre ist die Handreichung des Hochschulforums Digitalisierung der verlässlichste Wegweiser, weil sie die Rechtsfragen an Szenarien durchspielt: Wer einen eigenen Tutor mit den Kursmaterialien betreibt, bewegt sich im Szenario eines angepassten, nicht eines selbst entwickelten KI-Systems, solange die Anpassung über System-Prompt (hinterlegte Grundanweisung) und angebundene Quellen erfolgt; erst das Nachtrainieren (*fine-tuning*) eines Modells macht die Hochschule zur Anbieterin (*provider*) mit den entsprechenden Pflichten. Für die Materialien gilt das Urheberrecht unverändert, einschließlich der Grenze von 15 Prozent eines Werks für die Nutzung in der Lehre (Baresel et al., 2026). Für die Ausgaben der KI gilt dagegen: Urheberrechtlich geschützt ist nach § 2 Abs. 2 Urheberrechtsgesetz (UrhG) nur, was freie kreative Entscheidungen eines Menschen ausdrückt; das Amtsgericht München versagte deshalb 2026 drei mit KI erzeugten Logos den Schutz, weil weder ausführliche Prompts noch die Auswahl unter mehreren Vorschlägen die Gestaltung prägten (Amtsgericht München, 2026). Ob Studierende solche Texte verwenden dürfen, regelt darum nicht das Urheberrecht, sondern das

Prüfungsrecht, also die Prüfungsordnung und die Eigenständigkeitserklärung mit ihrer Pflicht, Hilfsmittel anzugeben (Salden & Leschke, 2023). Zum Vergleich außerhalb Europas: Das Massachusetts Institute of Technology (MIT) hat 2026 acht Prinzipien für die Lehre mit KI beschlossen, darunter mündliche Prüfungskomponenten, der Verzicht auf KI-Detektoren und eine modellunabhängige Campus-Plattform, und begründet damit dieselbe Linie wie Tobor: anleiten statt verbieten, und die Infrastruktur so bauen, dass die Wahl des Modells nicht die Lehre diktiert (Massachusetts Institute of Technology, Ad Hoc Committee on AI Use in Teaching, Learning, and Research Training, 2026).

i Stand bei Drucklegung, November 2026: Hochschulen in Deutschland

Wo die deutschen Hochschulen beim Einsatz von KI-Tutoren und bei der Kompetenzpflicht standen, als dieses Buch in den Druck ging; die Online-Seite „Forschungsstand“ führt die Quellen fort.

- **Nutzung durch Studierende:** 81 Prozent von 28.584 Befragten an 202 Hochschulen nutzen KI-Werkzeuge mindestens wöchentlich, die Hälfte „als Tutor bzw. Lernpartner“; dieser Anteil reicht von 72 Prozent in der Wirtschaftsinformatik bis 19 Prozent in Jura (Horstmann et al., 2026).
- **Angebote der Hochschulen:** 53 Prozent der befragten Hochschulleitungen haben KI-Lernassistenten in Umsetzung, an Hochschulen für angewandte Wissenschaften 63 Prozent; 13 Hochschulen melden Regelbetrieb, adaptives Lernen bieten 14 Prozent (Budde et al., 2026).
- **Lehrmaterial für eigene Tutoren:** Zwei Drittel der befragten Lehrenden würden ihre Materialien für einen Hochschul-Tutor freigeben, ein Drittel nicht; Bedingungen sind Urheberrecht und der Ausschluss des Trainings (Brandenburger et al., 2026).
- **Evaluierte Einsätze:** OneTutor in 84 Lehrveranstaltungen bayerischer Hochschulen im Sommersemester 2025, ohne Unterschied im wahrgenommenen Lernerfolg zwischen Nutzenden und Nichtnutzenden (Stumpf et al., 2026); Sokratest an der Hochschule Rhein-Waal (Kapitel 6.3.3) (Gerber et al., 2026); ein Tutor für Physik, der die Antworten vollständig gab, wurde von den Studierenden entsprechend genutzt (Glomski et al., 2026). Das bayerische Programm „KI-Tutorien“ meint dagegen menschliche

Tutorinnen und Tutoren, die KI-Kompetenz vermitteln (Universität Bayreuth, Zentrum für Hochschullehre, 2026).
- **Rechtsrahmen:** Artikel 4 KI-VO seit Februar 2025 in Kraft, durch den Digital-Omnibus vom Juli 2026 entschärft (Europäisches Parlament und Rat, 2026); Rechtsszenarien für die Lehre in Baresel et al. (2026); Empfehlungen des Wissenschaftsrats vom Juli 2026 (Wissenschaftsrat, 2026).

Wie sehen solche Richtlinien aus? Konkrete Formulierungen mit Links zu den Originaltexten stellt die Analyse des Hochschulforums Digitalisierung zusammen (Tobor, 2025).

5.4.2 Wie können Studierende die Nutzung von LLM dokumentieren? Stichworte, nach Arbeitsphase, nach Werkzeug oder als Reflexionstagebuch

Frühe Handreichungen zur Dokumentation von LLM in Studierendenarbeiten waren noch sehr allgemein formuliert und bestanden etwa darauf, dass **jegliche Nutzung im Schreibprozess** genau protokolliert würde. Bei täglicher und stark integrierter Nutzung ist das etwa so sinnvoll, wie die Forderung, jegliche Internetnutzung in einem Tagebuch zu erfassen. Sinnlose Forderungen führen schnell dazu, dass die dahinter stehende Forderung nach prinzipieller Nachvollziehbarkeit des Forschungsvorgehens entwertet und Umgehungshandlungen normalisiert werden.

Neuere Empfehlungen der Hochschulen sind hier deutlich realistischer: So bietet etwa eine Handreichung von niedersächsischen Hochschulen eine gute **Reihe von Optionen**, die von einer einfachen Stichpunktliste („elicit.com zur Literaturrecherche, perplexity.ai zur Internetrecherche, gamma.app zur Präsentationserstellung, stablediffusionweb.com zur Bildgeneration“) bis zu detaillierten Tagebüchern mit Reflexionshilfen reicht (Baresel et al., 2024).

Ihre Einschätzung prüfen

„Damit die KI-Nutzung nachvollziehbar wird, sollten Studierende jede Interaktion mit allen Prompts protokollieren.“
Auflösung: nein. Bei täglicher Nutzung ist ein vollständiges Protokoll

> so wenig praktikabel wie ein Tagebuch jeder Internetsuche, und unerfüllbare Pflichten machen Umgehung zur Normalität. Neuere Handreichungen bieten abgestufte Formen: eine Stichwortliste, eine Übersicht nach Arbeitsphase oder Werkzeug, ein Reflexionstagebuch.

Dieselbe Handreichung beschreibt drei weitere Formen: die Dokumentation nach Arbeitsphasen, nach Werkzeugen und als Reflexionstagebuch (Baresel et al., 2024).

Die Dokumentation nach **Arbeitsphasen** (s. Tabelle 5.2) zielt auf eine strukturierte Erfassung des KI-Einsatzes entlang typischer wissenschaftlicher Arbeitsphasen (z. B. Themenfindung, Recherche, Schreiben). Studierende bewerten selbst den Grad der KI-Nutzung auf einer vierstufigen Skala von „zur Inspiration“ bis „inhaltsgestaltend“ (Tabelle 5.3) und dokumentieren Tool, Einsatzkontext und Wirkung. Je höher die Stufe, desto stärker muss die Nutzung begründet und durch Prüfschritte abgesichert werden (Baresel et al., 2024; Rowland, 2023). Ziel ist Transparenz über den konkreten Einfluss auf das Ergebnis.

Bei der **werkzeugorientierten** Dokumentation werden in tabellarischer Form die verwendeten Tools (z. B. ChatGPT, DeepL Write) samt Quelle, Zweck, Funktion und Einsatzbereich gelistet. Diese Variante erleichtert die Nachvollziehbarkeit, gibt aber wenig Einblick in den Kontext oder den Einfluss der Tools auf den Arbeitsprozess.

Beim **Reflexionstagebuch** steht die kontinuierliche, persönliche Auseinandersetzung mit dem eigenen KI-Einsatz im Vordergrund. Studierende führen während des Arbeitsprozesses ein Tagebuch, das später in eine prüfungsrelevante Dokumentation überführt wird. Diese Methode fördert den Aufbau von **KI-Kompetenz** und metakognitiver Kompetenz, ist jedoch zeitaufwändig und betreuungsintensiv.

Phase im Arbeitsprozess	Dokumentation: Eingesetzte Tools, Verwendungszweck, Funktionsweise, Ergebnis	Grad der KI-Nutzung
Ideenfindung/Strukturierung	**Tools**: ChatGPT, Perplexity **Zweck**: Brainstorming zu Forschungsfragen, Gliederungsideen **Ergebnis**: 5 Themenvorschläge, davon 1 weiterverfolgt	1
Recherche	**Tools**: Elicit, Semantic Scholar **Zweck**: Suche nach passender Literatur **Ergebnis**: Liste mit 15 Quellen, 8 davon verwendet	2
Schreiben/Formulieren	**Tools**: DeepL Write **Zweck**: Verbesserung des sprachlichen Ausdrucks **Ergebnis**: Überarbeitete Einleitung	3
Überarbeitung/Korrektur	**Tools**: Grammarly **Zweck**: Prüfung auf Grammatik- und Rechtschreibfehler **Ergebnis**: Fehlerfreier Text	2

Tabelle 5.2. Beispiel arbeitsphasenorientierte Dokumentation der LLM Nutzung. Quelle: (Baresel et al. (2024), S. 11)

Grad der KI-Nutzung	Charakterisierung	Beispiele
1	**Zur Inspiration**	Sie haben sich Vorschläge für Themen unterbreiten lassen; Tools eingesetzt, um sich aus eigenen Notizen heraus Themenschwerpunkte zu bilden; sich Formulierungen vorschlagen lassen; die Rechtschreibung-/Grammatikprüfung genutzt.
2	**Ergänzend**	Sie haben sich mögliche Fragestellungen vorschlagen lassen, einzelne Begriffe der Aufgabenstellung oder Stellen in der Literatur erklären lassen, Gliederungen der eigenen Notizen vorschlagen oder eigene Texte zusammenfassen lassen, Reverse Outline zum eigenen Text (eine basierend auf dem Geschriebenen erzeugte Gliederung) generieren lassen.
3	**Unterstützend**	Sie haben sich Anforderungen der Aufgabe (z. B. Aufbau einer Hausarbeit) erklären, Literatur zusammenfassen, mögliche Gliederungen zum Thema vorschlagen lassen; Sie haben die Fragestellung dialogisch verfeinert bzw. Textteile dialogisch verfasst und dabei LLM-Output iterativ ergänzt; Sie haben sich Überarbeitungsvorschläge bzgl. Leserlichkeit und Stil generieren lassen.

Grad der KI-Nutzung	Charakterisierung	Beispiele
4	**Inhaltsgestaltend**	Sie haben sich Hintergrundwissen zur Aufgabe bzw. Antworten auf Fragestellung generieren, Gliederung zum Thema vorgeben, Kürzungen und Ergänzungen vornehmen lassen oder KI-generierten Text direkt übernommen.

Tabelle 5.3. Erläuterungen zum Grad der LLM-Nutzung. Quelle: Baresel et al. (2024), basierend auf Rowland (2023)

Beispiele für die werkzeugorientierte Dokumentation und das Reflexionstagebuch (Stand 2024) stehen in der Online-Fassung dieses Kapitels.

Eine Fakultätsregel auf einer Seite. Für die Studiengänge Wirtschaftsingenieurwesen der TH Köln haben Christoph Haag und ich die Dokumentation nach Arbeitsphasen auf eine Seite gebracht (Bartnik & Haag, 2025); die Vorlage ist eine gekürzte Fassung der arbeitsphasenorientierten Dokumentation, die die Leuphana Universität Lüneburg nach Baresel et al. (2024) bereitstellt (Leuphana Universität Lüneburg, o. J.). Drei Grundsätze tragen die Regel: KI unterstützt die Denkleistung und ersetzt sie nicht; Studierende müssen ihre Arbeit jederzeit mündlich erläutern können; wer zentrale Teile nicht selbst erstellt hat, besteht nicht. Eine Tabelle nennt je Phase die empfohlene Nutzung und die typischen Fehler. Für die Literaturrecherche lauten sie: nur KI-Suche, keine eigene Suchstrategie, keine Originalartikel gelesen. Das ist Tays Argument aus Kapitel 6.1.1 in Regelform. Prüfbar wird die Regel durch das Gespräch, ein konkreter Fall der Säule Mündlichkeit (Tabelle 5.4): Wer mehr als zweimal eine Quelle oder Methode nicht schlüssig erklären kann, hat die Prüfung in der Regel nicht bestanden.

5.5 Wie prüfen wir jetzt? Jenseits der Homework Apocalypse

Jenseits der vielen produktiven Anwendungen besteht die Gefahr, dass Studierende wichtige Teile des Denkprozesses an Sprachmodelle delegie-

ren (Lee et al., 2025). Klassische „Hausaufgaben“ wie **Seminararbeiten, Gruppenprojekte und Abschlussarbeiten drohen entwertet zu werden**. Ohne Anpassung der Aufgabenstellung werden die Aufgaben potenziell sinnlos, da Studierende etwa Aufsätze oder Reflexionsaufgaben einfach von ChatGPT schreiben und einreichen. Interviews mit Studierenden und Nutzungsstudien zeigen, dass diese Gefahr akut ist. Wie wir in der umfassenden empirischen Nutzungsstudie von Handa et al. (2025) sehen, nutzen Studierende Sprachmodelle speziell zur Schreibunterstützung intensiv und häufig. Das New York Magazine betitelt eine Recherche von 2025 mit „**Everyone Is Cheating Their Way Through College**“, auf der Grundlage einer Vielzahl von Interviews mit desillusionierten Studierenden und Lehrenden (Walsh, 2025). Ein Artikel der Fachzeitschrift Nature skizziert ebenfalls basierend auf Interviews ein breites Spektrum an aktiver Nutzung im höheren Bildungsbereich (Heidt, 2025).

Schon 2023 kündigte der Wharton Professor Mollick die „Homework Apocalypse“ (das Ende der klassischen Hausaufgabe) an (Mollick, 2023). Dabei geht es Mollick weniger um das Tricksen mit den neuen technischen Möglichkeiten („Cheating was already common in schools“), sondern mehr um die **empfundene Sinnlosigkeit von klassischen Hausaufgaben**. „Students will want to understand why they are doing assignments that seem obsolete thanks to AI.“. Wer gibt noch reine Rechenübungen auf, wenn alle Taschenrechner haben? Wie kann Eigen- und Fremdleistung unter diesen neuen technischen Bedingungen getrennt werden? Wie können unter diesen Bedingungen Anreize für Studierende gesetzt werden, Texte selbst zu lesen und Sätze selbst zu formulieren?

Eine Unterscheidung der empirischen Anthropic-Studie von Studierenden-Interaktionen mit Sprachmodellen ist dabei hilfreich, um das Problem einzuordnen (Handa et al., 2025): Hier werden vier Arten der Nutzung großer Sprachmodelle (LLM) unterschieden, je nachdem, ob ein **Problem** gelöst oder ein **Ergebnis generiert** werden soll und je nachdem, ob dies **direkt oder interaktiv** erfolgt. Kollaborative Nutzungsformen (Typ 3 und 4) sind dabei für den Lernerfolg eher hilfreich, während das direkte Bereitstellen von Problemlösungen oder Texten aufgrund mangelnder Beschäftigung der Studierenden mit den Problemen und Materialien für Hausarbeiten eher hinderlich sein könnte (anders als für die Vorbereitung von kontrollierten Tests wie Klausuren). Studierende werden so eher in eine passive Rolle gedrängt und es fehlen die erwünschten Schwierigkeiten (*desirable difficulties*, (Roediger & Karpicke, 2006)), das fragebasierte Durchkauen und Hin- und

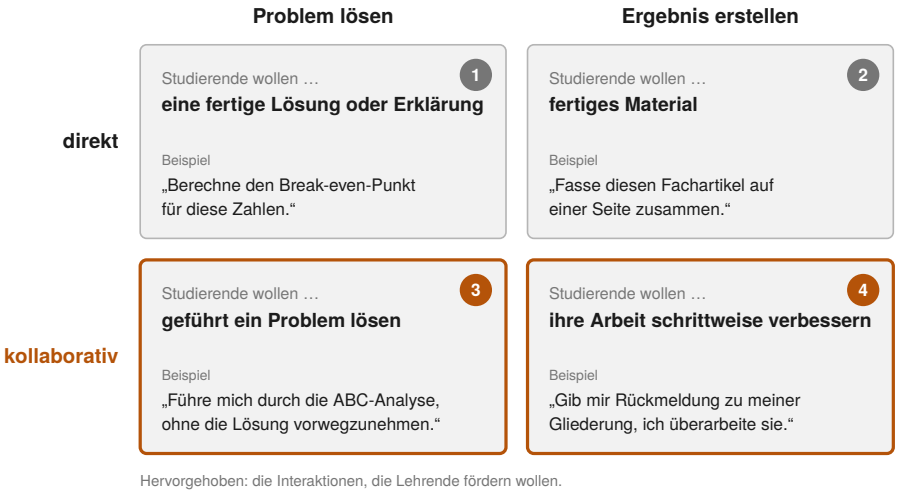


Abbildung 5.7. Etwa gleichverteilt: Vier Arten der Interaktion von Studierenden mit Sprachmodellen. Unterscheidung nach Handa et al. (2025); eigene Darstellung, Beispiele eigene.

Herüberlegen, das die Lernforschung als wichtig für langfristiges Behalten ansieht (Roediger & Pyc, 2012).

Grob gesagt wollen wir also **kollaborative Interaktion und Hilfestellung fördern und einfaches Übernehmen bereitgestellter Lösungen verhindern**. Wie können wir dafür die Hausarbeiten anpassen? Im Folgenden werden einige Empfehlungen zusammengefasst. Der Vier-Säulen-Ansatz nach Gmeiner bietet Orientierung. Er unterscheidet vier Gegenmaßnahmen für das Prüfen unter KI-Bedingungen: Mündlichkeit, Prozessorientierung, Kontextualisierung sowie Kollaboration (Gmeiner, 2025).

Die empirische Forschung der Jahre 2025 und 2026 stützt diesen Umbau in fünf Punkten.

Erstens verlieren klassische, asynchron geschriebene Aufgaben unter generativer KI ihre Aussagekraft, weil sie den Kompetenzerwerb eher verhindern als ihn nachzuweisen. Rismanchian et al. (2026) zeigen das an 3,2 Millionen Lerninteraktionen der Mathematikplattform ALEKS über zehn Jahre: Nach der Veröffentlichung von ChatGPT sinkt die Bearbeitungszeit für Aufgaben, deren Text sich in einen Chatbot kopieren lässt, um 2,8 % pro Quartal und kumuliert 26,9 % über elf Quartale bei Studierenden, und der dauerhafte

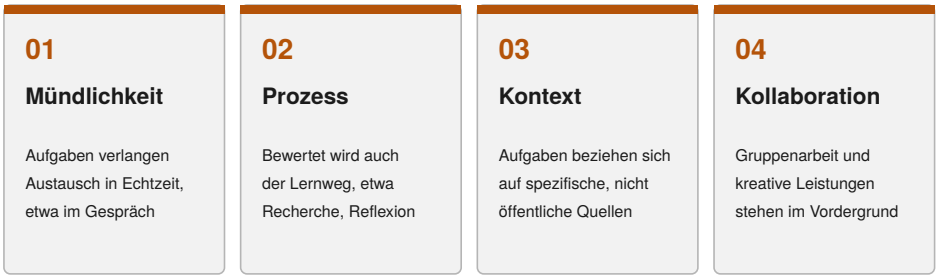


Abbildung 5.8. KI-resistente Aufgabenstellungen: die vier Säulen nach Gmeiner (2025). Eigene Darstellung nach der Grafik von Bernhard Gmeiner, lizenziert unter CC BY-SA 4.0 (https://creativecommons.org/licenses/by-sa/4.0/); Texte gekürzt und umformuliert.

Wissensgewinn aus diesen Aufgaben bleibt aus. Unter Aufsicht verschwindet der Effekt vollständig; die Zeitersparnis stammt also aus der KI-Nutzung, nicht aus schneller gewordenen Lernenden. Delikoura et al. (2025) ordnen diesen Befund in einen Rahmen ein: Ihre Synthese von 70 empirischen Studien beschreibt, wie technische Modellrisiken über die Interaktion zu Überabhängigkeit (*over-reliance*), nachlassender eigenständiger Lernfähigkeit und einem Verlust an Lernenden-Agency (Selbststeuerung der Lernenden) werden, und benennt ausdrücklich die Bedrohung der Prüfungsvalidität. Der Umbau der Prüfung ist damit kein Vorsorgeargument, sondern die Antwort auf einen gemessenen Verlust.

i Anwendungsbeispiel: Mit KI steigen die Hausaufgabennoten, und die Klausurnoten fallen

Problem ohne KI. Hausaufgaben sind Übung und Signal zugleich: Ihre Noten zeigen Lehrenden, wer den Stoff beherrscht, und das Korrigieren kostet Zeit.
Problem mit KI. Lernende können die Hausaufgabe an die KI abgeben, und Korrekturgeräte versprechen, die Arbeiten einer Klasse in Minuten zu bewerten. Beides beschleunigt den Ablauf, ohne zu sichern, dass die Note noch Können misst.
Das Dilemma. Strömberg, Lei und Wu begleiten 26.811 chinesische Schülerinnen und Schüler über 30 Monate. Mit KI steigen die Hausaufgabennoten um 18 %, die Bearbeitungszeit sinkt um 30 %. Die Mo-

natsklausuren ohne Hilfsmittel fallen dagegen binnen sechs Monaten um 20 %, die Aufnahmeprüfungen um 18 bis 24 %; die volle Einbuße zeigt sich nach etwa zwei Jahren. Rund 80 % der Nutzenden lagern die Hausaufgabe erkennbar aus (Strömberg et al., 2026). Zur selben Zeit wirbt iFlytek mit einem Gerät, das die handschriftlichen Arbeiten einer Klasse in fünf Minuten korrigieren soll; unabhängige Genauigkeitswerte fehlen (Smith, 2026).
Was das für wirksames Lernen heißt. *Beobachtungsstudie über 30 Monate, kein Experiment; Herstellerangabe ohne unabhängige Prüfung.* Der Befund fügt sich zu den Experimenten: Was mit KI gelingt, bleibt ohne KI nur erhalten, wo die KI ergänzt statt ersetzt (Contractor & Reyes, 2026) (Kapitel 4.5). Schneller benotet heißt nicht besser gemessen.
Quellen: Strömberg et al. (2026); Smith (2026).

Zweitens hängt der diagnostische Wert einer Aufgabe an ihrem Format: Offene Begründung bleibt aussagekräftig, Reproduktion und Wiedererkennung nicht. Hou et al. (2026) trennen in einem Drei-Arm-Experiment der Bauingenieur-Ausbildung folienbasiertes Lernen, ungeführte KI-Unterstützung und eine KI-Unterstützung, die durch ein fünfschrittiges Prompting-Gerüst strukturiert ist. Der Lernvorteil zeigt sich allein bei offenen Aufgaben, die Erklärung und Begründung verlangen, und verschwindet bei Multiple-Choice-Items; die ungeführte Bedingung schlägt die passiven Folien nicht. Formate, die auf Reproduktion setzen, messen unter KI-Bedingungen wenig; der Ertrag liegt in Aufgaben, die Schlussfolgern und Begründen sichtbar machen, also in denselben prozess- und mündlichkeitsnahen Formaten, die die vier Säulen vorschlagen.

Drittens sichern Detektion und „authentische“ Aufgaben (*authentic assessments*) allein die Integrität nicht; der Nachweis muss von der Ausgabe zum synchronen, prozessnahen Handeln wandern. Kofinas et al. (2025) prüfen das experimentell an zwei britischen Universitäten und finden zweierlei: Prüfende können KI-gestützte Arbeiten nicht von rein menschlichen unterscheiden, und der Grad der Authentizität einer Aufgabe ändert daran nichts. Ihre Schlussfolgerung deckt sich mit der dieses Kapitels: Der Schwerpunkt muss von ausgabebasierten, asynchron geschriebenen Prüfungen zu synchronen, interpersonalen und performativen Formaten wandern. DeVito et al. (2025) zeigen die soziale Kehrseite unzuverlässiger Detektion: In 1.199 Reddit-Diskussionen mit knapp 14.000 Kommentaren berichten Studierende Belastung durch falsche Betrugsvorwürfe der KI-Detektoren,

während Lehrende sich um Integrität und Adoptionsdruck sorgen. Der Verzicht auf Detektionswerkzeuge, den auch An et al. (2025) empfehlen, gründet damit nicht nur auf deren Fehleranfälligkeit, sondern auf dem Schaden, den Falsch-Positive im Vertrauensverhältnis anrichten.

Ihre Einschätzung prüfen

„Prüfende können eine mit KI geschriebene Hausarbeit in der Regel nicht von einer rein menschlichen unterscheiden, auch wenn die Aufgabe authentisch und praxisnah gestellt ist."
Auflösung: ja. Im Experiment an zwei britischen Universitäten konnten Prüfende KI-gestützte Arbeiten nicht von rein menschlichen unterscheiden, und eine authentischere Aufgabe änderte daran nichts. Detektoren helfen auch nicht weiter, weil ihre Fehlalarme Studierende zu Unrecht beschuldigen. Aussagekraft gewinnt eine Prüfung erst, wenn der Nachweis ins Gespräch und in den Arbeitsprozess wandert.

Viertens lassen sich mündliche und performative Formate mit KI zugänglicher und stressärmer gestalten. Yusuf et al. (2026) begegnen der Schwäche, die solchen Formaten am häufigsten vorgehalten wird, dem situativen Prüfungsstress. Ihr Werkzeug AIvaluate, ein LLM-gestützter Gesprächsagent (*conversational agent*) für mündliche Präsentationen und Viva-voce-Prüfungen (mündliche Verteidigung der eigenen Arbeit), senkt in einem Within-Subjects-Vergleich (dieselben Personen in beiden Bedingungen) mit 35 Lernenden vor Studienbeginn die Prüfungsangst gegenüber der klassischen Präsenzprüfung. Damit erweitert sich die Säule der Mündlichkeit von der Aufwands- auf die Zugänglichkeitsseite: Der interaktive Nachweis von Autorschaft und Transfer bleibt erhalten, die Hürde für ängstliche Lernende sinkt. Dass ein solcher Umbau überfällig ist, formuliert Avigad (2026), Mathematiker an der Carnegie Mellon University, für die quantitativen Fächer zugespitzt: Die üblichen Hausaufgaben erledige KI längst, und Präsenzklausuren, die das verhindern sollen, nähmen den Studierenden künstlich Werkzeuge, die sie im Beruf selbstverständlich nutzen.

Fünftens unterstützt KI das Bewerten, ersetzt das menschliche Urteil aber noch nicht; die Skalierung der neuen Formate bleibt an Menschen gebunden. Sapkota & Murshed (2026) lassen sechs LLM-Konfigurationen eine Klausur in diskreter Mathematik gegen menschliche Bewertende korrigieren. Großzügige Teilpunkt-Vorgaben senken den Fehler über alle

Modellfamilien, doch Kalibrierung und Rangerhaltung (*point calibration, rank preservation*) fallen auseinander: Die beste mittlere Abweichung und die beste Korrelation entstehen unter verschiedenen Konfigurationen, und keine ist reif für unbeaufsichtigtes Benoten. Levine et al. (2026) untersuchen die Bewertung handschriftlicher Mathematik durch sehfähige Modelle (*vision-capable LLMs*): Die Gesamtgenauigkeit ist hoch, doch 87 % der Fehler des besten Modells stammen aus der Transkription der Handschrift, nicht aus falsch angewandten Rubriken (Bewertungsrastern). Der Engpass sitzt in der Erfassung, nicht im Urteil; automatisierbar ist die Rubrik-Anwendung, die Wahrnehmung des studentischen Artefakts bleibt vorerst menschliche Aufgabe (zur Verschiebung der Bewertungsarbeit vgl. Kapitel 6.1).

5.5.1 Selbsttest: Erkennen Sie KI-Texte besser als ein Detektor?

Henrik Sauers Kollege will alle Abgaben durch einen KI-Detektor schicken. Bevor Sie ihm antworten, prüfen Sie zuerst sich selbst und dann einen Detektor. In etwa sieben Minuten ordnen Sie acht Auszüge aus Schüleraufsätzen und KI-Texten zu, setzen auf jedes Urteil eine Sicherheit und treten gegen einen kleinen, offen gebauten Detektor an, dessen Rechnung Sie nach jedem Auszug sehen. Eine zweite Runde zeigt, wen ein Detektor zu Unrecht verdächtigt. Dass Prüfende KI-gestützte Arbeiten nicht erkennen, haben Kofinas et al. (2025) im Experiment gezeigt; hier erleben Sie es am eigenen Urteil.

Mensch oder KI? Zwei Auszüge zum Selbsttest

Ein Auszug stammt aus einer Erörterung einer Schülerin oder eines Schülers der Klassen 11–12 in den USA, der andere von einem aktuellen Sprachmodell, das dieselbe Aufgabe bekam. Kreuzen Sie an, wer welchen Text schrieb, und wie sicher Sie sind. Die Rechtschreibung ist unverändert.

Auszug A · Aufgabe: Fernunterricht: Sollten Schülerinnen und Schüler von zu Hause aus am Unterricht teilnehmen können?

> Technology has made it possible for students to sit in on a lesson from almost anywhere, and some schools now let students choose whether to attend in person or from home. At first glance this seems like pure progress: more choice, less commuting, and lessons available to anyone with a laptop.

> Yet when I think about what school actually does for young people, I am convinced that most students would not benefit from attending classes from home.

Mensch ☐ KI ☐ · Sicherheit: ☐ 1 geraten ☐ 2 ☐ 3 sicher
Auszug B · Aufgabe: Sommerprojekte: Sollten Lehrkräfte oder die Schülerinnen und Schüler selbst die Ferienprojekte gestalten?

> Teacher Designed Summer Projects Summer finally comes to an end and all students have completed their student designed summer project. Students are one month into school and realize the summer projects they created has not helped them prepare for school. Students are put into a horrible scenario, where they are mentally not prepared for school and are assigned many assignments they cant keep up with. It is a teachers job to create projects, tests, and assignments to help further improve a students ability to learn and understand the subject.

Mensch ☐ KI ☐ · Sicherheit: ☐ 1 geraten ☐ 2 ☐ 3 sicher
Die Auflösung mit Herkunft und Detektorwert steht in den Lösungshinweisen (Anhang B). Das Duell gegen den Detektor mit zwölf Auszügen gibt es in der Online-Version: https://th-koln-bartnik.github.io/genai4teaching/kapitel05-4d-phasen.html#sec-detektor-duell

Der Lehr-Detektor erkannte 5 von 8 aktuellen KI-Texten, die er beim Lernen nicht gesehen hatte, hielt aber 14 % der Schüleraufsätze und 76 % der muttersprachlichen College-Bewerbungsaufsätze für KI. Solche Fehlalarme sind der Schaden, den DeVito et al. (2025) beschreiben: Unter Verdacht gerät, wer anders schreibt als die Texte, an denen ein Detektor gelernt hat (Liang et al., 2023).

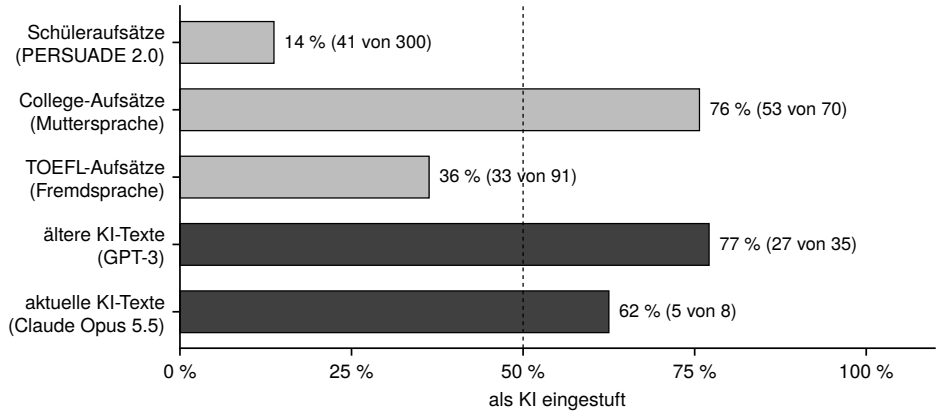


Abbildung 5.9. Wen der Lehr-Detektor für KI hält: Anteil der Texte mit Urteil „KI“ (Schwelle 50 %), nur Texte, die er beim Lernen nicht gesehen hat. Helle Balken: Texte von Menschen, jedes Urteil „KI“ ist ein Fehlalarm; dunkle Balken: KI-Texte, jedes Urteil „KI“ ist ein Treffer. Schüleraufsätze aus PERSUADE 2.0 (Crossley et al., 2024), ältere KI-Texte (GPT-3) sowie TOEFL- und College-Aufsätze aus Liang et al. (2023), aktuelle KI-Texte von Claude Opus 5.5 (eigene Läufe, 02.11.2026). Eigene Berechnung.

i So entstand dieses Spiel

Bauauftrag an einen KI-Agenten (Claude Opus 5.5): „Lies die Auftragsdatei zum Detektor-Duell und führe den Auftrag aus." Werkzeuge: zwei offene Datensätze, PERSUADE 2.0 (Crossley et al., 2024) und die Daten von Liang et al. (2023), acht frische Teilagenten für 40 KI-Essays, die Programmbibliothek scikit-learn für den Detektor; Bauzeit rund eine Stunde. Schwäche: Unter den „KI-Wörtern", die der Detektor selbst aus seinen Trainingstexten ableitete, stehen Themenwörter wie *June* und *August*. Er lernt, was in seinen Daten zufällig zusammenfällt, und erkannte deshalb nur 5 von 8 aktuellen KI-Texten.

5.5.2 Formate nach den vier Säulen

Die Ratgeber der Jahre 2023 bis 2025 übersetzen die vier Säulen in konkrete Formate (Tabelle 5.4). **Mündlichkeit** macht Verständnis, Transfer und Autorschaft im Gespräch sichtbar; eigene Entscheidungen müssen erläutert und verteidigt werden, und die schriftliche Arbeit wird vom Leistungsnachweis getrennt (Gmeiner, 2025). **Prozessorientierung** verlagert das Gewicht vom Produkt auf den Weg dorthin und beteiligt die Prüfenden am Entstehungsprozess; die Sichtbarkeit individueller und kollaborativer Arbeitsschritte macht unreflektierte KI-Nutzung unattraktiv (Hanover Research, 2024; Monash University, 2025; Mulder et al., 2023). **Kontextualisierung** bindet die Leistung an reale, lokale oder persönliche Daten, Orte und Rollen; solche Aufgaben sind „un-promptbar", weil sie nicht-öffentliche Informationen, eigene Beobachtung und Gegenwartsbezug verlangen (Gmeiner, 2025; Mulder et al., 2023). **Kollaboration und Kreation** prüfen über Gruppenaufgaben in der Veranstaltung, Peer- und Selbstbeurteilung und gestufte Projekte die soziale, evaluative und kreative Seite des Lernens (Hanover Research, 2024; Mulder et al., 2023). In allen Formaten legen Studierende ihre KI-Nutzung offen; KI darf strukturieren und sprachlich glätten, nicht aber Evidenz, Theoriebildung oder Ergebnisse ersetzen.

Säule	Format	Artefakte	Skalierung
Mündlichkeit	Kurzkolloquium (Viva voce): rund zehn Minuten zu zwei Kernentscheidungen der eingereichten Arbeit, dazu eine Transferfrage („Was würden Sie ändern, wenn …?“)	Schriftliche Arbeit (mit KI-Unterstützung erlaubt), Aufzeichnung des Gesprächs	Standardisierte Leitfragen, Doppelprüfung im Stichprobenprinzip, Aufzeichnung für Zweitbewertung
	Interaktive mündliche Prüfung (*interactive oral assessment*): praxisnahes Szenario oder Fall im offenen Gespräch mit Prüfenden oder anderen Studierenden (Ward et al., 2024)	Gespräch, bewertet nach Rubrik (auch gemeinsam mit Studierenden entwickelt (Ní Bheoláin et al., 2020))	Erstsemesterkurse mit rund 200 bis 800 Studierenden und 4 bis 10 Prüfenden
	Posterpräsentation mit strukturierter Fragerunde zu Methode, Evidenz und Limitationen	Poster, einseitiges Handout, Frageprotokoll	Parallele Poster-Sessions mit festen Zeitslots
Prozessorientierung	Prozessjournal mit Audit-Trail (lückenloser Prüfpfad): Suche, Auswahl, Analyse, Entscheidungen und Revisionen fortlaufend dokumentiert	Journal mit Versionsverlauf (Overleaf, Git), Query-Protokolle, Daten- und Code-Paket, Endprodukt	Der dokumentierte Prozess ersetzt Detektoren als Beurteilungsgrundlage
	Gestaffelte Hausarbeit mit Feedback nach jeder Stufe, Prozess- und Produktpunkte getrennt	Gliederung, annotierte Bibliografie, Methoden-Memo, Rohanalyse, Entwurf, Endfassung	Peer-Review nach Rubrik, stichprobenhafte Checks durch Lehrende
Kontextualisierung	Eigene Empirie: Fall auswählen, Primärdaten erheben (Interviews, Prozessanalysen, Prototyp), Entscheidungsvorlage erstellen	Datensatz, Methodenprotokoll, Analyse-Notebook, Kurzempfehlung	–
	Replikation einer veröffentlichten Analyse mit Robustheitsprüfung	Repro-Paket, Abweichungsprotokoll, Kurzbericht	Automatisierte Checks, präzise Rubriken

Säule	Format	Artefakte	Skalierung
Kollaboration und Kreation	Peer-reviewtes Multimedia-Projekt (Podcast, Video, Infografik) für ein definiertes Publikum; auch Rollen- oder Planspiele (Gmeiner, 2025)	Produkt, Quellenliste, Peer-Feedback-Protokolle, individuelle Reflexion	Kurze Nachgespräche sichern die Autorschaft
	Team-Capstone (Abschlussprojekt im Team) mit getrennter Team- und Individualnote	Teamartefakt (Prototyp, Konzeptstudie, Policy-Brief als kurzes Entscheidungspapier), individueller Methoden-Anhang, Reflexion zum eigenen Beitrag und zur KI-Nutzung	Milestone-Boards, strukturierte Peer-Assessments, stichprobenhafte mündliche Abfrage pro Team

Tabelle 5.4. Prüfungsformate nach den vier Säulen. Quellen: Gmeiner (2025); Mulder et al. (2023); Hanover Research (2024); Monash University (2025); Ward et al. (2024)

Mündliche Formate verlangen vorab Bewertungsraster und bringen eigene Herausforderungen mit: situativen **Stress**, **Validität** (Form oder Inhalt, einfache oder schwere Fragen, mündliche oder schriftliche Ausdrucksfähigkeit), **Reliabilität** über verschiedene Nachfragen, Bewertende und Szenarien hinweg und **Fairness** gegenüber Sprachfähigkeit und Vorwissen. Ihr Vorteil ist die Reaktivität: Vertiefende Nachfragen legen Hintergrundwissen und Begründungen offen (Akimov & Malin, 2020, S.31; Kearney, 2019). Einsätze interaktiver mündlicher Prüfungen in großen Kohorten an verschiedenen Universitäten sind unter https://sway.cloud.microsoft/yQ2s0Bm3ILkWtGll zusammengestellt; Leitfäden mit Beispielaufnahmen und Bewertungsrubriken stellt etwa die Dublin City University bereit (https://www.dcu.ie/sites/default/files/inline-files/interactive-oral-io-user-guide_0.pdf, Ressourcenübersicht auf S. 11).

Für **Abschlussarbeiten** lassen sich zwei Säulen direkt in die Prüfungsordnung übertragen. Ein Entwurf an der TH Köln (Stand 2025) gewichtet die Mündlichkeit höher und verteilt sie auf zwei Termine: ein erstes Kolloquium etwa einen Monat nach Beginn zu Forschungsstand und Forschungsfragen

(3 Leistungspunkte nach dem European Credit Transfer System, ECTS), die schriftliche Arbeit (8 ECTS) und ein zweites Kolloquium zum Ergebnis (4 ECTS); bisher waren es 12 ECTS für die schriftliche Arbeit und 3 ECTS für das Kolloquium. Die Kontextualisierung lässt sich verankern, indem reine Literatur- oder Theoriearbeiten ohne empirischen Bezug vom Prüfungsausschuss genehmigt werden müssen.

i Anwendungsbeispiel: Gesprächsführung zu prüfen ist aufwändig und kaum wiederholbar

Problem ohne KI. Beratungsgespräche gehören in der Sozialen Arbeit zum Kern des Berufs, ihre Prüfung aber bindet viel Personal und feste Termine. An der CBS University of Applied Sciences liefen solche Performanzprüfungen bisher mit Schauspielerinnen und Schauspielern.
Problem mit KI. Ein Bot kann die Klientin oder den Klienten spielen, reagiert aber in jedem Gespräch anders.
Das Dilemma. Im Modul Kommunikation und Gesprächsführung des Bachelors Soziale Arbeit führen die Studierenden innerhalb von zwei Wochen ein Beratungsgespräch im Chat mit einem Prüfungsbot, etwa mit einer Person, die sich wegen Überschuldung an das Sozialamt wendet, und reichen den Dialog mit einer theoriebezogenen Reflexion ein. Zum Üben gibt es Tutor-, Mentor- und Szenario-Bots; in der Prüfung ist diese Unterstützung abgeschaltet. Die Varianz macht die Prüfung schwer auswendig zu lernen und, so die Verantwortlichen, besser nachvollziehbar als die frühere Prüfung mit Schauspielern. Sie verunsichert aber: Eine Studentin schrieb, der Bot habe in der Prüfung „komplett anders“ geschrieben als in ihren Übungen, ihre Notizen hätten sich „sehr überflüssig“ angefühlt (Puchert & Schnieders, 2026).
Was das für wirksames Lernen heißt. *Erfahrungsbericht mit Rückmeldungen von Lehrenden und Studierenden.* Die Lehrenden beurteilen die Reflexionen als deutlich besser als in früheren Formaten ohne vorbereitende Szenarien. Das Format verlagert den Nachweis, wie Kofinas et al. (2025) es fordern, von der Ausgabe zum performativen Handeln und dessen Analyse. Damit die Varianz nicht in Verunsicherung kippt, brauchen die Übungsfälle dieselbe Struktur und Schwierigkeit wie die Prüfung.
Quelle: Puchert & Schnieders (2026); Tobor et al. (2026), S. 46–48.



ℹ Anwendungsbeispiel: Im Beruf programmieren Ingenieure mit KI, in der Prüfung nicht

Problem ohne KI. Eine Prüfung ohne Hilfsmittel misst nicht, wie Ingenieurinnen und Ingenieure heute arbeiten: Sie erzeugen und prüfen Code zunehmend mit KI.
Problem mit KI. KI-Code wirkt plausibel, setzt aber mitunter Randbedingungen falsch um, und identische Prompts liefern unterschiedliche Lösungswege. Auf die Ankündigung, KI in der Prüfung zuzulassen, reagierten die Studierenden zunächst verunsichert.
Der Lösungsansatz. Klaus Webers (Hochschule München) prüft im Master Mechatronik, Modul Simulation mechatronischer Systeme, in einer digitalen Präsenzprüfung im PC-Pool. Über die Hochschuloberfläche HAWKI ist ein Sprachmodell als Hilfsmittel zugelassen; die Studierenden erzeugen damit Code für Simulationen und führen ihn in MATLAB aus. Bewertet wird, ob sie die Aufgabe so durchdringen, dass die KI Brauchbares erzeugt, und ob sie das Ergebnis auf Plausibilität prüfen und verantworten können. Ein Prüfungsteil ohne KI sichert das Grundlagenwissen. Den Umgang mit KI-Code üben die Studierenden schon im Semester, begleitet vom Lehrenden.
Was das für wirksames Lernen heißt. *Erfahrungsbericht.* Die Prüfung nimmt auf, was Avigad (2026) für die quantitativen Fächer einwendet: Wer KI aus der Prüfung verbannt, nimmt den Studierenden Werkzeuge, die sie im Beruf nutzen werden. Der Nachweis liegt nicht in der Ausgabe, sondern im Prüfen und Begründen, und damit in dem Teil, der unter KI-Bedingungen aussagekräftig bleibt (Hou et al., 2026).
Quelle: Tobor et al. (2026), S. 43–45.



Kombiniert ergeben die vier Säulen ein konsistentes Prüfungsdesign: Mündliche Elemente sichern Autorschaft und Transfer, prozessorientierte Formate liefern nachvollziehbare Evidenz, kontextgebundene Aufgaben prüfen Verständnis unter realen Bedingungen, und kollaborative Produkte stärken Urteilskraft und Feedbackkultur. KI-Detektoren werden überflüssig, weil der Nachweis im Prozess liegt und Prüfende interaktiv nachfragen können. Der Aufbau kostet anfangs viel Zeit, und die neuen Formate müssen evaluiert werden, damit die bekannten Probleme des Prüfens im Gespräch (Validität, Reliabilität, Fairness) beherrschbar bleiben (Akimov & Malin, 2020). Auf viele Vorlagen lässt sich dabei aufbauen, und Studierende lernen nebenbei, KI verantwortlich, nachvollziehbar und wirksam einzusetzen.

5.6 Kurs-Integration: Drei Phasen eines Semesters

Wer KI nicht in eine einzelne Sitzung, sondern in einen ganzen Kurs einbaut, sieht die Rolle der KI mit dem Semester wandern. Zu Beginn arbeitet sie vor allem für die Lehrenden, als Hiwi, der Aufgaben und Fälle in Varianten erzeugt. In der Mitte arbeiten die Studierenden mit ihr an Anwendungsaufgaben, als Copilot oder als Simulator im Rollenspiel. Vor der Prüfung fragt sie ab und gibt Rückmeldung, als Tutor. Tabelle 5.5 ordnet jeder Phase das Lernprinzip zu, dem sie dient. Werkzeuge stehen bewusst nicht in der Tabelle: Sie wechseln im Halbjahrestakt, die Prinzipien seit Jahrzehnten kaum.

Semesterphase	Rolle der KI	Was entsteht	Tragendes Lernprinzip
Woche 1–4: Vorbereitung	Hiwi	Aufgaben in mehreren Schwierigkeitsstufen, Fallstudien, Einstiegsmaterial	Vorrat für verteiltes und gemischtes Üben über das ganze Semester (Dunlosky et al., 2013)
Woche 5–8: Anwendung	Copilot, Simulator	Anwendungsaufgaben, deren Lösung Studierende anderen erklären; Rollenspiele mit Nachbesprechung	Ausarbeiten durch Erklären (Dunlosky et al., 2013); Erfahrung plus Debriefing (Nachbesprechung)

Semesterphase	Rolle der KI	Was entsteht	Tragendes Lernprinzip
Woche 9–12: Festigung	Tutor	Übungsfragen, Quiz, simulierte mündliche Prüfung	Testgestütztes Lernen: Abrufen statt Wiederlesen (Dunlosky et al., 2013; Roediger & Karpicke, 2006)

Tabelle 5.5. Drei Phasen der KI-Integration in einen Kurs; die Rollen entsprechen Kapitel 6. Eigene Darstellung.

Zwei Regeln überdauern jedes Werkzeug. Erstens gibt eine verantwortliche Person frei, was die KI für Studierende erzeugt, bevor es den Kurs erreicht; bei Fallstudien aus anderen Kulturen oder Branchen gehört der Blick auf Stereotype dazu. Diese Prüfung zahlt sich aus: In einem Zwei-Kohorten-Vergleich in der Volkswirtschaftslehre senkten geprüfte, quellengebundene Lernhilfen vor allem den Anteil schwacher Prüfungsergebnisse (Dang & Nguyen, 2026, Preprint, also noch nicht begutachtet). Zweitens muss der Kurs auch ohne das Werkzeug weiterlaufen. Skripte und Aufgaben liegen unabhängig vom Anbieter vor, damit ein Ausfall, eine Lizenzänderung oder eine Datenschutzentscheidung der Hochschule keine Sitzung kostet.

Wie solche Kurse in der eigenen Lehre aussehen und was sie bewirkt haben, zeigt Kapitel 7 (Kapitel 7). Die Beispiele sind dort nach der Art des Wissens geordnet, das Studierende erwerben sollen, nicht nach Semesterwochen.

Kernaussagen

Zu Lernziel 1: Aufgaben durchspielen

1. Der erste Schritt ist Ausprobieren: eigene Aufgaben in ein starkes Modell geben, Input eingrenzen, Prompts anpassen und prüfen, wo die KI gut ist und wo nicht.

Zu Lernziel 2: Einführung der Studierenden

2. Studierende lernen den Umgang mit KI durch häufiges, über das Semester verteiltes Üben in Präsenz, nicht durch eine Theorieeinführung.

Zu Lernziel 3: Prüfen unter KI-Bedingungen

3. Die Homework Apocalypse ist real, aber beherrschbar. Prüfungen werden wieder aussagekräftig durch Mündlichkeit, Prozessorientierung, Kontextualisierung und Kollaboration. KI-Detektoren sind dafür kein Mittel.

Zu Lernziel 4: Richtlinien und Dokumentation

4. Hochschulrichtlinien konvergieren: Eigenständigkeitserklärung anpassen, Verdachtsfälle im Gespräch klären, keine automatisierte Bewertung, Prüfungsformate didaktisch weiterentwickeln. Wirksam werden sie nur, wenn sie bekannt sind und diskutiert werden.
5. Dokumentation der KI-Nutzung muss praktikabel sein: eine Stichwortliste, eine Übersicht nach Arbeitsphase oder Werkzeug oder ein Reflexionstagebuch; ein vollständiges Protokoll jeder Interaktion ist es nicht.

i Schlüsselbegriffe

Erklären Sie jeden Begriff in zwei, drei Sätzen in eigenen Worten; die Seitenzahl führt zur Stelle, an der er eingeführt wird.

- Homework Apocalypse ..... S. 155
- Überabhängigkeit (*over-reliance*) ..... S. 157
- KI-Detektor ..... S. 159
- Mündlichkeit ..... S. 163
- Prozessorientierung ..... S. 163
- Kontextualisierung ..... S. 163
- Kollaboration und Kreation ..... S. 163
- Interaktive mündliche Prüfung (*interactive oral assessment*) S. 164
- Angepasste Eigenständigkeitserklärung ..... S. 147
- Betreiber (*deployer*) ..... S. 148
- Reflexionstagebuch ..... S. 151

Übung. Tragen Sie zu jeder Szene den passenden Begriff aus der Liste ein. Lösungen: Anhang B.

Nr.	Szene	Begriff
1	Ein Dozent stellt fest, dass ein Chatbot seine seit Jahren bewährte Hausaufgabe, die Zusammenfassung zweier Fachartikel, in Sekunden erledigt. Studierende fragen, wozu sie sie noch selbst schreiben sollen. *Herkunft: konstruiert nach Kapitel 5.5.*	
2	Ein Prüfungsausschuss erwägt, alle Hausarbeiten durch eine Software laufen zu lassen, die einen KI-Anteil in Prozent ausgibt, und ab 50 Prozent ein Verfahren einzuleiten. Von welchem Mittel raten Forschung und Richtlinien ab? *Herkunft: konstruiert nach Kapitel 5.5 und der Übersicht der Hochschulrichtlinien.*	
3	Nach Abgabe einer Hausarbeit, bei der KI erlaubt war, spricht der Dozent mit jeder Studentin zehn Minuten über zwei Entscheidungen in ihrer Arbeit und fragt, was sie bei einer anderen Datenlage ändern würde. *Herkunft: konstruiert nach Tabelle 5.4.*	
4	Im Projektmodul reichen die Teams neben dem Bericht den Versionsverlauf ihres Dokuments, die Suchprotokolle und die verworfenen Entwürfe ein; bewertet wird auch, wie sie zu ihren Entscheidungen kamen. *Herkunft: konstruiert nach Tabelle 5.4.*	
5	Statt einer Literaturarbeit zur Lieferantenbewertung erheben Studierende bei ihrem Praxispartner die Daten von drei echten Lieferanten und schreiben eine Entscheidungsvorlage für dessen Einkaufsleitung. *Herkunft: konstruiert nach Tabelle 5.4 und den Praxispartner-Projekten (Kapitel 7.3.5).*	
6	Eine Hochschule stellt allen Lehrenden und Studierenden einen Chat-Zugang zu einem Sprachmodell bereit. Welche Rolle hat sie damit nach der KI-Verordnung? *Herkunft: konstruiert nach Kapitel 5.4.1.2.*	

Wiederholung aus früheren Kapiteln. *Erklären Sie diese Begriffe noch einmal in eigenen Worten, bevor Sie nachschlagen.*

- Diligence ..... S. 136
- Testgestütztes Lernen (*test-enhanced learning*) ..... S. 106
- Debriefing (Nachbesprechung) ..... S. 225

i Lernfragen

Wiederholen

1. Nennen Sie die vier Säulen aussagekräftiger Prüfungen und je ein Prüfungsformat dazu.
2. Welche Elemente haben die meisten Hochschulrichtlinien zur KI-Nutzung gemeinsam, und warum gehört Detektionssoftware nicht dazu?
3. Welche praktikablen Formen der Dokumentation von KI-Nutzung nennt das Kapitel?

Anwenden

4. Nehmen Sie Ihre wichtigste schriftliche Prüfungsleistung und wenden Sie aus dem Gedächtnis die vier Säulen darauf an. Welche Säule lässt sich mit geringstem Aufwand nächstes Semester einziehen?
5. Entwerfen Sie für eine Ihrer Veranstaltungen die drei Phasen aus Tabelle 5.5. Welches Lernprinzip trägt jede Phase, und wer prüft die erzeugten Aufgaben vor der Freigabe?

Beurteilen

6. Was steht in der Richtlinie Ihrer eigenen Hochschule zu KI in Prüfungen? Falls Sie es nicht wissen: Was müsste nach diesem Kapitel darin stehen?
7. Ein Kollege schlägt vor, Studierende sollten jeden Chatverlauf vollständig als Anhang ihrer Arbeit abgeben. Beurteilen Sie den Vorschlag.

Lösungshinweise: Anhang B.

Literaturverzeichnis

Akimov, A., & Malin, M. (2020). When old becomes new: a case study of oral examination as an online assessment tool. *Assessment & Evaluation in Higher Education*, *45*(8), 1205–1221. https://doi.org/10.1080/02602938.2020.1730301.

Amtsgericht München (2026). Endurteil vom 13. Februar 2026, Az. 142 C 9786/25: Kein Urheberrechtsschutz für mit KI erzeugte Logos. https://www.gesetze-bayern.de/Content/Pdf/Y-300-Z-GRURRS-B-2026-N-1513?all=False.

An, Y., Yu, J. H., & James, S. (2025). Investigating the higher education institutions' guidelines and policies regarding the use of generative AI in teaching, learning, research, and administration. *International Journal of Educational Technology in Higher Education*, *22*(1), 10. https://doi.org/10.1186/s41239-025-00507-3.

Avigad, J. (2026). Mathematicians in the age of AI. https://doi.org/10.48550/arXiv.2603.03684.

Baresel, K., Eube, C., Knorr, D., Lutter, L., Nys, J. de, & Röben, M. (2024). *KI-Gebrauch im Studienkontext dokumentieren*. 304839 b. https://doi.org/10.48548/PUBDATA-1476.

Baresel, K., Fiegenbaum, L., Horn, J., Knorr, D., Lutter-Schwarz, L., Nys, J. de, & Röben, M. (2026). *KI in der Hochschullehre einsetzen: Rechtliche Vorgaben in Szenarien erklärt* (Arbeitspapier; Nr. 95). Hochschulforum Digitalisierung. https://doi.org/10.5281/zenodo.22975655.

Bartnik, R., & Haag, C. (2025). *Rahmensetzung zur Nutzung generativer KI im Bachelor- und Master-Studiengang Wirtschaftsingenieurwesen* (Handreichung für Studierende, Version V02). TH Köln, Fakultät für Informatik und Ingenieurwissenschaften.

Böckeler, B. (2026, April 2). Harness engineering for coding agent users. https://martinfowler.com/articles/harness-engineering.html.

Brandenburger, J., Mergan, H., Lorenz, A., & Janneck, M. (2026). Digitale Souveränität bei KI-gestützter Lehrmaterialverarbeitung an Hochschulen. *Zeitschrift für Hochschulentwicklung*, *21*(3), 133–153. https://doi.org/10.21240/zfhe/21-3/07.

Bridgwater, A. (2026, August 12). Anthropic gave agents the ability to dream. Then developers woke up. *The New Stack*.

Budde, J., Sommer, T., & Lüthi, R. (2026). *Personalisiertes Lernen im KI-Zeitalter* (Blickpunkt / HFD-Fokusmonitor 2026). Hochschulforum Digitalisierung.

Contractor, Z., & Reyes, G. (2026). *Experimental evidence on the learning impact of generative AI* (IZA Discussion Paper; Nr. 18792). IZA Institute of Labor Economics.

Crossley, S. A., Tian, Y., Baffour, P., Franklin, A., Benner, M., & Boser, U. (2024). A large-scale corpus for assessing written argumentation: PERSUADE 2.0. *Assessing Writing*, *61*, 100865. https://doi.org/10.1016/j.asw.2024.100865.

Dakan, R., & Feller, J. (2025). *The AI Fluency Framework: A descriptive and normative model of human-AI interaction for higher education (Version 1.1)*. Higher Education Authority.

Dakan, R., Feller, J., & Anthropic (2025). Teaching AI Fluency [Onlinekurs; Lektionen „The Delegation-Diligence loop“ und „The Description-Discernment loop“]. *Anthropic Academy*. https://anthropic.skilljar.com/teaching-ai-fluency.

Dang, C. T., & Nguyen, A. (2026). Verified, not generated: expert-verified AI study materials and the distribution of learning gains in a university course. https://doi.org/10.48550/arXiv.2610.07097.

Delikoura, I., Fung, Y. R., & Hui, P. (2025). From superficial outputs to superficial learning: Risks of large language models in education. https://doi.org/10.48550/arXiv.2509.21972.

Dell'Acqua, F., McFowland, E., Mollick, E. R., Lifshitz-Assaf, H., Kellogg, K., Rajendran, S., Krayer, L., Candelon, F., & Lakhani, K. R. (2023). *Navigating the Jagged Technological Frontier: Field Experimental Evidence of the Effects of AI on Knowledge Worker Productivity and Quality*. https://doi.org/10.2139/ssrn.4573321.

DeVito, P., Vallala, A., McMahon, S., Hinda, Y., Thaw, B., Zhuang, H., & Kalva, H. (2025). Unpacking generative AI in education: Computational modeling of teacher and student perspectives in social media discourse. https://doi.org/10.48550/arXiv.2506.16412.

Dunlosky, J., Rawson, K. A., Marsh, E. J., Nathan, M. J., & Willingham, D. T. (2013). Improving Students' Learning With Effective Learning Techniques: Promising Directions From Cognitive and Educational Psychology. *Psychological science in the public interest : a journal of the American Psychological Society*, *14*(1), 4–58. https://doi.org/10.1177/1529100612453266.

Emberson, L., & Roodman, D. (2026, September 22). The plunging price of thought. *Epoch AI*. https://epoch.ai/publications/the-plunging-price-of-thought.

Europäisches Parlament und Rat (2026). Verordnung (EU) 2026/1744 des Europäischen Parlaments und des Rates vom 8. Juli 2026 zur Änderung

der Verordnungen (EU) 2024/1689, (EU) 2018/1139 und (EU) 2023/1230 im Hinblick auf die Vereinfachung der Umsetzung harmonisierter Vorschriften für künstliche Intelligenz (Digital-Omnibus-Verordnung zur KI).

Europäisches Parlament und Rat der Europäischen Union (2024). Verordnung (EU) 2024/1689 des Europäischen Parlaments und des Rates vom 13. Juni 2024 zur Festlegung harmonisierter Vorschriften für künstliche Intelligenz (Verordnung über künstliche Intelligenz).

Gerber, A., Lorenz, L., & Pfeiffer, U. (2026). KI-Tutoren in der Lehre: rechtlich sicher, didaktisch wertvoll, technisch innovativ. In J. Leschke, R. Queckenberg, & M. Persike (Hrsg.), *Learning analytics, artificial intelligence und data mining in der hochschulbildung*: (S. 57–64). transcript. https://doi.org/10.14361/9783839458761-057.

Glomski, E., Yilmaz, C., Dau, H., & Kubsch, M. (2026). ChatGPT as a tutor?—between supporting students and giving away all the answers. *American Journal of Physics*, *94*(9), 793–794. https://doi.org/10.1119/5.0311016.

Gmeiner, B. (2025). *Ohne Shortcut zur Leistung: KI-resistente Aufgabenformate im Unterricht. Ein Handbuch für Lehrkräfte der Sekundarstufe*. Self-published.

Gottweis, J., Weng, W.-H., Daryin, A., Tu, T., Palepu, A., Sirkovic, P., Myaskovsky, A., Weissenberger, F., Rong, K., Tanno, R., Saab, K., Popovici, D., Blum, J., Zhang, F., Chou, K., Hassidim, A., Gokturk, B., Vahdat, A., Kohli, P., ... Natarajan, V. (2025). *Towards an AI co-scientist*. arXiv. https://doi.org/10.48550/arXiv.2502.18864.

Grootendorst, M. (2025, Februar 3). *A Visual Guide to Reasoning LLMs*. https://newsletter.maartengrootendorst.com/p/a-visual-guide-to-reasoning-llms.

Handa, K., Bent, D., Tamkin, A., McCain, M., Durmus, E., Stern, M., Schiraldi, M., Huang, S., Ritchie, S., Syverud, S., Jagadish, K., Vo, M., Bell, M., & Ganguli, D. (2025). *Anthropic Education Report: How university students use Claude*. Anthropic.

Hanover Research (2024). *Assessment and generative artificial intelligence in higher education* (Report). Hanover Research.

Heidt, A. (2025). ChatGPT for students: learners find creative new uses for chatbots. *Nature*, *639*(8053), 265–266. https://doi.org/10.1038/d41586-025-00621-2.

Hoffmann, J., Borgeaud, S., Mensch, A., Buchatskaya, E., Cai, T., Rutherford, E., de Las Casas, D., Hendricks, L. A., Welbl, J., Clark, A., Hennigan, T., Noland, E., Millican, K., van den Driessche, G., Damoc, B., Guy, A., Osindero, S., Simonyan, K., Elsen, E., ... Sifre, L. (2022). *Training compute-*

optimal large language models. arXiv. https://doi.org/10.48550/arXiv.2203.15556.

Horstmann, N., Hüsch, M., & Breiter, A. (2026). *Künstliche Intelligenz im Studium – Die Sicht von Studierenden im Wintersemester 2025/26*. CHECK, CHE Centrum für Hochschulentwicklung. https://hochschuldaten.che.de/kuenstliche-intelligenz-im-studium-die-sicht-von-studierenden-im-wintersemester-2025-26/.

Hou, X., Xiao, B., Liu, H., & Mueller, S. (2026). The role of instructional guidance in generative AI-assisted learning: Empirical evidence from construction engineering education. https://doi.org/10.48550/arXiv.2606.05509.

Kaplan, J., McCandlish, S., Henighan, T., Brown, T. B., Chess, B., Child, R., Gray, S., Radford, A., Wu, J., & Amodei, D. (2020). *Scaling laws for neural language models*. arXiv. https://doi.org/10.48550/arXiv.2001.08361.

Kearney, S. (2019). Transforming the first-year experience through self and peer assessment. *Journal of University Teaching and Learning Practice*, *16*(5), 1–17.

KI-Campus (2026). *EU AI Act: KI-Omnibus justiert Artikel 4 neu – KI-Kompetenz bleibt Pflicht*. KI-Campus Blog. https://ki-campus.org/blog/eu-ai-act-ki-omnibus-justiert-artikel-4-neu-ki-kompetenz-bleibt-pflicht.

Kofinas, A. K., Tsay, C. H.-H., & Pike, D. (2025). The impact of generative AI on academic integrity of authentic assessments within a higher education context. *British Journal of Educational Technology*, *56*(6), 2522–2549. https://doi.org/10.1111/bjet.13585.

Kwa, T., West, B., Becker, J., Deng, A., Garcia, K., Hasin, M., Jawhar, S., Kinniment, M., Rush, N., Arx, S. V., Bloom, R., Broadley, T., Du, H., Goodrich, B., Jurkovic, N., Miles, L. H., Nix, S., Lin, T., Parikh, N., … Chan, L. (2025). *Measuring AI Ability to Complete Long Tasks*. arXiv. https://doi.org/10.48550/arXiv.2503.14499.

Lee, H.-P. H., Sarkar, A., Tankelevitch, L., Drosos, I., Rintel, S., Banks, R., & Wilson, N. (2025). The Impact of Generative AI on Critical Thinking: Self-Reported Reductions in Cognitive Effort and Confidence Effects From a Survey of Knowledge Workers. https://doi.org/10.1145/3706598.3713778.

Leuphana Universität Lüneburg (o. J.). KI-Kennzeichnung in Prüfungsleistungen. *Leuphana Universität Lüneburg: Lehre*. https://www.leuphana.de/lehre/kuenstliche-intelligenz/ki-kennzeichnung.html.

Levine, J., Aenlle, M., Zilles, C., West, M., & Silva, M. (2026). Automated

grading of handwritten mathematics using vision-capable LLMs. https://doi.org/10.48550/arXiv.2605.19043.

Liang, W., Yuksekgonul, M., Mao, Y., Wu, E., & Zou, J. (2023). GPT detectors are biased against non-native English writers. *Patterns*, *4*(7), 100779. https://doi.org/10.1016/j.patter.2023.100779.

Lindsey, J., Gurnee, W., Ameisen, E., Chen, B., Pearce, A., Turner, N. L., Citro, C., Abrahams, D., Carter, S., Hosmer, B., Marcus, J., Sklar, M., Templeton, A., Bricken, T., McDougall, C., Cunningham, H., Henighan, T., Jermyn, A., Jones, A., … Batson, J. (2025). On the biology of a large language model. *Transformer Circuits Thread*.

Lopopolo, R. (2026, Februar 11). Harness engineering: Leveraging Codex in an agent-first world. https://openai.com/index/harness-engineering/.

Massachusetts Institute of Technology, Ad Hoc Committee on AI Use in Teaching, Learning, and Research Training (2026, August). *Report of MIT's Ad Hoc Committee on AI use in teaching, learning, and research training*. https://aiandeducation.mit.edu/.

METR (2026). *Time horizon of frontier AI models*. https://metr.org/time-horizons/.

Mollick, E. R. (2023, Juli 1). The Homework Apocalypse. https://www.oneusefulthing.org/p/the-homework-apocalypse.

Mollick, E. R. (2025, Januar 26). A new generation of AIs: Claude 3.7 and Grok 3. https://www.oneusefulthing.org/p/a-new-generation-of-ais-claude-37.

Mollick, E. R. (2026, Oktober 20). 30 months on the exponential (in charts). https://www.oneusefulthing.org/p/30-months-on-the-exponential-in-charts.

Monash University (2025). *Choosing assessment tasks*.

Mulder, R., Baik, C., & Ryan, T. (2023). *Rethinking assessment in response to AI* (Guide). Melbourne Centre for the Study of Higher Education.

Ní Bheoláin, R., Lowney, R., & O'Riordan, F. (2020). *Students as Partners in Assessment (SaPiA): A Literature Scoping Review*. https://doi.org/10.5281/zenodo.4270579.

OpenAI (2024). *Learning to reason with LLMs*.

Pinski, M., & Benlian, A. (2024). AI literacy for users – A comprehensive review and future research directions of learning methods, components, and effects. *Computers in Human Behavior: Artificial Humans*, *2*(1), 100062. https://doi.org/10.1016/j.chbah.2024.100062.

Puchert, L., & Schnieders, B. (2026). *Prüfungssimulation: Performanzprüfung im Modul Kommunikation und Gesprächsführung, BA Soziale Arbeit*. CBS Uni-

versity of Applied Sciences. https://hochschulforumdigitalisierung.de/wp-content/uploads/2025/01/3292-Kurz_Praesi_BASA_Pruefungssimulation_260522.pdf.

Rismanchian, S., Uzun, H., Matayoshi, J., Cosyn, E., & Kurd-Misto, E. (2026). Faster completion, less learning: Generative AI reduced study time on math problems and the knowledge they build. https://doi.org/10.48550/arXiv.2605.21629.

Roediger, H. L., & Karpicke, J. D. (2006). Test-enhanced learning: taking memory tests improves long-term retention. *Psychological science*, *17*(3), 249–255. https://doi.org/10.1111/j.1467-9280.2006.01693.x.

Roediger, H. L., & Pyc, M. A. (2012). Inexpensive techniques to improve education: Applying cognitive psychology to enhance educational practice. *Journal of Applied Research in Memory and Cognition*, *1*(4), 242–248. https://doi.org/10.1016/j.jarmac.2012.09.002.

Rowland, D. R. (2023). Two frameworks to guide discussions around levels of acceptable use of generative AI in student academic research and writing. *Journal of Academic Language and Learning*, *17*(1), T31–T69.

Salden, P., & Leschke, J. (2023). *Didaktische und rechtliche Perspektiven auf KI-gestütztes Schreiben in der Hochschulbildung*. Ruhr-Universität Bochum, Universitätsbibliothek. https://doi.org/10.13154/294-9734.

Sapkota, A., & Murshed, M. G. S. (2026). LLMs as teaching assistants for mathematics exam grading: Reliability, and practical usability. https://doi.org/10.48550/arXiv.2607.01247.

Schwarcz, D., Manning, S., Barry, P. J., Cleveland, D. R., Prescott, J. J., & Rich, B. (2025). *AI-Powered Lawyering: AI Reasoning Models, Retrieval Augmented Generation, and the Future of Legal Practice*. https://doi.org/10.2139/ssrn.5162111.

Smith, S. (2026, November 3). AI marking machine claims to grade a full class of handwritten papers in five minutes. *Dimsum Daily*.

Snell, C., Lee, J., Xu, K., & Kumar, A. (2024). *Scaling LLM test-time compute optimally can be more effective than scaling model parameters*. arXiv. https://doi.org/10.48550/arXiv.2408.03314.

Strömberg, D., Lei, V., & Wu, Y. (2026). *The generative AI learning penalty: Evidence from Chinese secondary education* (CEPR Discussion Paper; Nr. 21577). CEPR Press.

Stumpf, C., Schlude, A., Löwel, V., & Stürz, R. A. (2026). *Ein KI-Tutor geht in die Lehre: Empirische Ergebnisse zum Einsatz von OneTutor im Sommersemester 2025*. Bayerisches Forschungsinstitut für Digitale Transformation (bidt).

Tobor, J. (2024). *Leitlinien zum Umgang mit generativer KI*. Hochschulforum Digitalisierung.

Tobor, J. (2025). *Recap: KI-leitlinien als beispiel für soziotechnische aushandlungsprozesse*.

Tobor, J., Then Bergh, C., & Lüthi, R. (2026). *Use Cases in Bewegung: Wie KI Studium und Lehre weiter verändert* (Blickpunkt). Hochschulforum Digitalisierung.

Universität Bayreuth, Zentrum für Hochschullehre (2026). *KI-Tutorien Bayern*. Projektseite. https://www.zhl.uni-bayreuth.de/de/projekte/kitutorium/index.html.

Walsh, J. D. (2025). Everyone is cheating their way through college: ChatGPT has unraveled the entire academic project. *New York Magazine*.

Ward, M., O'Riordan, F., Logan-Fleming, D., Cooke, D., Concannon-Gibney, T., Efthymiou, M., & Watkins, N. (2024). Interactive oral assessment case studies: An innovative, academically rigorous, authentic assessment approach. *Innovations in Education and Teaching International*, *61*(5), 930–947. https://doi.org/10.1080/14703297.2023.2251967.

Wissenschaftsrat (2026). *Intellektuelle Souveränität: Empfehlungen für die Hochschulbildung in Zeiten von generativer KI* (Nr. Drs. 3319-26). Wissenschaftsrat. https://doi.org/10.57674/1evx-t906.

Yusuf, H., Money, A., & Daylamani-Zad, D. (2026). Exploring student anxiety and experience in performance-based assessments using AIvaluate: An LLM-augmented emotionally intelligent pedagogical AI conversational agent. *Educational Technology Research and Development*. https://doi.org/10.1007/s11423-026-10634-x.

6 Rollen der KI: Hiwi, Copilot, Tutor, Simulator

In diesem Kapitel

- KI als Hiwi
- KI als Copilot
- KI als Tutor
- KI als Simulator

Prof. Dr. Lena Hoffmeister lehrt Produktionslogistik für 90 Studierende im Maschinenbau. Ihre Übungsblätter zur Warteschlangenrechnung erstellt die KI in einer Stunde statt einem Tag, und für einen Forschungsantrag lässt sie einen Deep-Research-Bericht schreiben: zwölf Seiten, 40 Quellen, zehn Minuten. Im Projektmodul bauen ihre Studierenden mit einem Programmier-Agenten eine Simulation der Fertigungslinie; nach zwei Tagen läuft sie. In der Abnahme kann niemand erklären, warum sich die Warteschlange vor der Lackiererei bildet. Ein Tutor soll die Studierenden abends durch die Übungen führen, doch im Test rechnet er eine Aufgabe überzeugend und falsch. Hoffmeister verbringt ihre Abende nun mit Kontrollieren und fragt sich, wo die gesparte Zeit geblieben ist.

Die Szene ist aus Gesprächen in Workshops und aus der eigenen Lehre zusammengesetzt.

Bevor Sie weiterlesen: Wie sehen Sie das?

Wie sehr stimmen Sie den vier Aussagen zu? Jede Aussage wird an der Stelle im Kapitel aufgelöst, die sie beantwortet. Wer sich vorher festlegt, liest gezielter.

1. Wenn die KI Übungsblätter in einer Stunde statt einem Tag erstellt, haben Lehrende am Ende des Semesters Zeit gewonnen.
stimme zu 1 – 2 – 3 – 4 – 5 *stimme nicht zu*
(Auflösung in Kapitel 6.1)

2. Für einen Überblick über den Forschungsstand ist ein Deep-Research-Bericht die verlässlichste Form der KI-Recherche, weil er die meisten Quellen auswertet.
stimme zu 1 – 2 – 3 – 4 – 5 *stimme nicht zu*
(Auflösung in Kapitel 6.1.1)

3. Studierende, die mit einem Programmier-Agenten arbeiten, kommen schneller zu einem lauffähigen Programm, verstehen ihren Code aber schlechter als Studierende, die ihn selbst schreiben müssen.
stimme zu 1 – 2 – 3 – 4 – 5 *stimme nicht zu*
(Auflösung in Kapitel 6.2.2)

4. Ein KI-Tutor für Rechenaufgaben sollte die Musterlösungen als Vorgabe bekommen, statt die Lösungswege selbst zu erzeugen.
stimme zu 1 – 2 – 3 – 4 – 5 *stimme nicht zu*
(Auflösung in Kapitel 6.3)

Lernziele: Nach diesem Kapitel können Sie …

1. die vier Rollen Hiwi, Copilot, Tutor und Simulator unterscheiden, eigene Ideen zuordnen und abschätzen, welche Aufgaben dadurch wegfallen, schneller werden oder neu entstehen;
2. ein Recherchewerkzeug nach dem Muster der Aufgabe statt nach dem Markennamen wählen;
3. beurteilen, wie viel Studierende beim Schreiben und Programmieren mit KI selbst verantworten müssen, und prüfen, ob eine KI-gebaute Simulation rechnet oder nur abspielt;
4. beschreiben, was ein KI-Tutor und eine KI-Simulation brauchen, damit sie das Lernen fördern.

Die Kernaussagen am Kapitelende sind nach diesen vier Zielen geordnet.

Wie nutzen Lehrende generative KI? Wir sortieren die sehr vielfältigen Hil-

festellungen der neuen Tools in vier Kategorien von Anwendungen: Hiwi, Copilot, Tutor, Simulator (Mollick & Mollick, 2023b, 2024).

Hier ein Beispiel für einen Tutor-Bot, den wir seit dem Wintersemester 2025/26 als Hilfestellung für das Modul "Grundlagen der BWL" erproben; neue Themen werden laufend ergänzt.

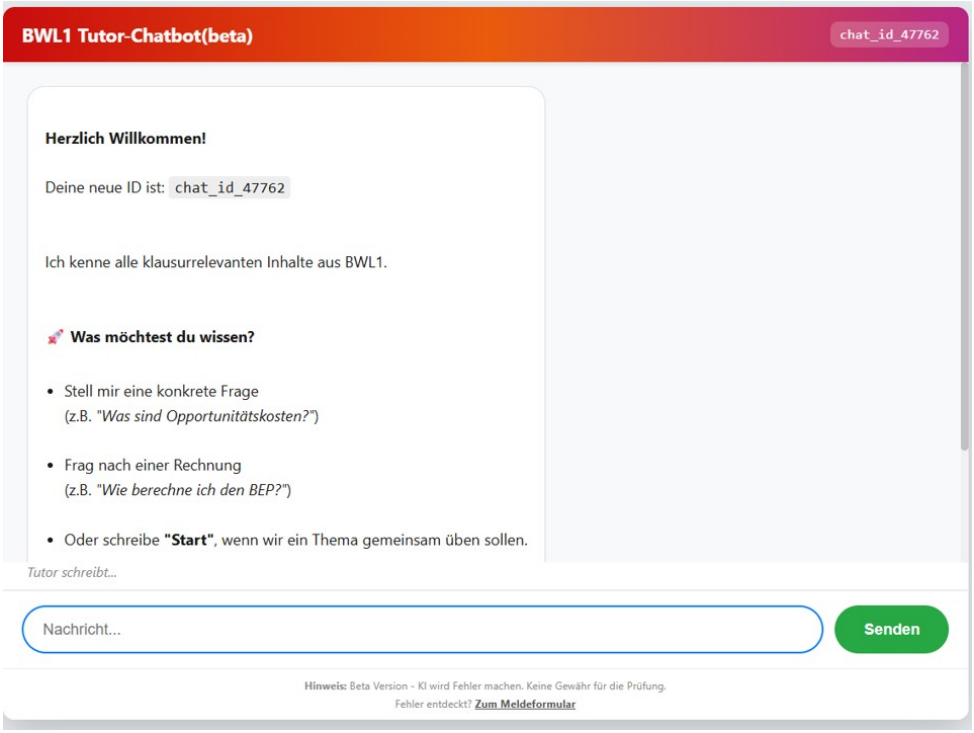


Abbildung 6.1. Beispiel: Tutor-Bot BWL Grundlagen. Screenshot der Testversion, Januar 2026

Eine Testversion und der aktuelle Stand des Projekts sind über die Online-Fassung dieses Buches erreichbar; Aufbau, Betrieb und Erfahrungen beschreibt Kapitel 7.2.2.

6.1 KI als Hiwi

Beschäftigte in Forschung und Lehre erfüllen eine Vielzahl sehr heterogener Aufgaben, mit einem wachsenden Teil an „Verwaltung". Wer lehrt, merkt

schnell, dass die Präsenzveranstaltung nur die Spitze eines ganzen Eisbergs an Aufgaben darstellt. Eine Umfrage unter Lehrenden in Österreich zeigt, dass sie etwa ein Drittel ihrer Zeit mit Lehraktivitäten verbringen (32 %) und etwa ein Fünftel mit Verwaltungstätigkeiten in der Hochschule (20 %) sowie ein weiteres Fünftel mit externen Verpflichtungen wie Gutachten oder Tätigkeiten in wissenschaftlichen Gesellschaften (9 %, 10 %) (Österreichischer Universitätsprofessor/innenverband, 2018). Wie Unkraut im Garten wächst der Anteil, den Lehrende mit „sonstigem" verbringen: Vor allem der Zeitaufwand für Verwaltung stieg an (Schomburg et al., 2012).

6.1.1 Fachartikel finden und auswerten: Welches Werkzeug passt zu welcher Aufgabe?

Was leisten die KI-Helfer bei der Literaturrecherche, und wie prüft man, was sie liefern? Die besten Antworten darauf gibt der Bibliothekar Aaron Tay von der Singapore Management University, der die Werkzeuge seit Jahren systematisch testet (https://aarontay.substack.com/) (Tay, 2025). Zwei Unterscheidungen ordnen das Feld: Wird einmalig gesucht oder in mehreren Schleifen (einmalige Suche gegenüber agentischem Suchprozess)? Und bekommt man eine Trefferliste oder eine aus den Treffern erzeugte Zusammenfassung (Ergebnisliste gegenüber RAG-basierter Analyse; RAG, *Retrieval-Augmented Generation*, heißt: Das Sprachmodell schreibt seine Antwort aus den zuvor gefundenen Texten, vgl. Kapitel 2.4.1)? Daraus ergeben sich vier Typen (Tabelle 6.1); die Produkte in jedem Typ wechseln schnell, die Typen bleiben.

Suche	Ausgabe	Typ nach Tay	Was man praktisch bekommt
einmalig	Liste	Quick Search	Klassische Trefferliste mit Ranking (etwa der Bibliothekskatalog oder Google Scholar), ohne erzeugten Antworttext
einmalig	Zusammenfassung	Quick RAG	Kurze „Antwort mit Zitaten" aus den obersten Treffern; meist wenige Absätze
iterativ	Liste	Deep Search	Mehrere Suchschleifen über Minuten mit Abfragevarianten und Zitationsverfolgung; ein Sprachmodell bewertet die Relevanz; das Ergebnis bleibt eine Liste, meist eine bessere

Suche	Ausgabe	Typ nach Tay	Was man praktisch bekommt
iterativ	Bericht	Deep Research	Deep Search plus Berichterstellung: eine längere Synthese auf Basis des iterativ gefundenen Korpus

Tabelle 6.1. Vier Typen von KI-Suchhelfern nach zwei Unterscheidungen. Quelle: Tay (2025)

Hinter dem Wort „iterativ“ verbirgt sich die wichtigere Frage, *wie* ein Werkzeug iteriert: als fest verdrahteter Ablauf mit ein paar KI-Entscheidungspunkten oder als Agent, der eine Aufgabe flexibel zerlegen kann. Tay beschreibt ein Agency-Spektrum (Grad der Eigenständigkeit) und ordnet die meisten akademischen Deep-Research-Tools am verdrahteten Ende ein: beeindruckend innerhalb ihrer Schablonen, spröde außerhalb (Tay, 2025). Sein Stresstest macht das sichtbar: „Finde Arbeiten, die Paper X hätte zitieren sollen, aber nicht zitiert hat.“ Eine menschliche Hilfskraft zerlegt das in drei Schritte (ähnliche Arbeiten finden, deren Referenzen extrahieren, die Überlappung abziehen); allgemeine Sprachmodelle mit Werkzeugen führen diese Logik eher aus, während spezialisierte Tools scheitern, weil die Aufgabe nicht in ihren eingebauten Ablauf passt. Für die Lehre folgt daraus die Regel aus Kapitel 2.4.2: Je freier das Werkzeug arbeitet, desto klarer müssen die Kontrollpunkte sein, an denen wir das Ergebnis prüfen.

i Aus der Lehre: Literaturrecherche in vier Phasen

In unserer Übung zur Literaturrecherche im Wirtschaftsingenieurwesen arbeiten Studierende in vier Phasen: Thema eingrenzen, Quellen auswählen, suchen, auswerten (Bartnik & Schmid, 2025). Die Werkzeugtypen haben darin feste Plätze (Tabelle 6.2); die Entscheidungen fallen in den ersten beiden Phasen, bevor ein Werkzeug sucht.
Beim Eingrenzen legen die Studierenden Hauptthema, Kontext, Variablen, Stichwörter, Ausschlussbegriffe und Zeitraum fest. Beim Auswählen bestimmen sie eine Liste anerkannter Zeitschriften, etwa nach dem VHB-Rating des Verbands der Hochschullehrerinnen und Hochschullehrer für Betriebswirtschaft, und suchen in Publish or Perish über deren ISSN, die internationale Kennnummer jeder Zeitschrift; die Sortierung „nach Relevanz“ in Google Scholar ist kein Qualitätsranking.

Erst beim Suchen kommt das Sprachmodell dazu, als Übersetzer: Es schreibt aus den festgelegten Kriterien die Suchsyntax. Das ist Quick Search mit einem Sprachmodell davor, und die Suchstrategie bleibt bei den Studierenden. Gemessen ist das für systematische Reviews in der Medizin: ChatGPT schrieb Boolesche Suchanfragen mit hoher Präzision (wenig Unpassendes unter den Treffern), aber geringerem Recall (relevante Studien fehlen); wiederholte Läufe lieferten verschiedene Anfragen, ein Beispiel-Query im Prompt (der Eingabe an die KI) und mehrere Dialogrunden halfen (Wang et al., 2023). Die Nachprüfung fand den Ausschlag bei Modell- und Promptwahl und einen Vorteil durch gut gewählte Schlüsselstudien (Wang et al., 2025). Unsere Regel: Syntax lesen, Trefferzahl in einer zweiten Datenbank gegenprüfen, mit zwei bekannten Schlüsselstudien testen, ob die Suche sie findet. Fehlen sie, hat die Syntax eine Lücke, nicht die Forschung.

Phase	Werkzeugtyp	Beispiele (Stand 2026)
Thema eingrenzen	Quick RAG: Antwort mit Zitaten zur Orientierung	Consensus, Elicit
Quellen auswählen	Quick Search mit Filter nach Zeitschrift oder ISSN	Publish or Perish, Google Scholar
Suchen	Quick Search, Sprachmodell schreibt die Syntax	Google Scholar, Publish or Perish, EBSCO
Suchen	Deep Search: mehrere Suchschleifen, Ergebnis ist eine Liste	Undermind
Suchen	Zitationsnetz: vom Startartikel zu verwandten Arbeiten	Connected Papers, Research Rabbit
Auswerten	Zusammenfassung und Extraktionstabelle je Artikel	Elicit, Semantic Scholar
Auswerten	Zitationskontext: gestützt oder bestritten?	Scite
Auswerten	Deep Research: Bericht, höchstes Fehlerrisiko	Deep-Research-Modi der Sprachmodelle

Auswerten	Datenzugriff per API (Programmierschnittstelle): eigene Auswertungen mit Code	OpenAlex, Semantic Scholar API

Tabelle 6.2. Werkzeugtypen je Phase der Literaturrecherche. Typen nach Tay (2025), ergänzt um drei Typen ohne erzeugten Text (Zitationsnetz, Zitationskontext, API); Produktnamen sind ein Schnappschuss (Stand 2026), die Typen bleiben. Quelle: eigene Zuordnung nach Bartnik & Schmid (2025)

Beim Auswerten gefundener Artikel gilt eine ähnliche Staffelung (Tay, 2024a). Die Zusammenfassung eines einzelnen Dokuments ist am wenigsten riskant und eignet sich für die schnelle Relevanzprüfung; die sequenzielle Auswertung vieler Dokumente nach denselben Fragen (Design, Stichprobe, Befund) ergibt eine Codier-Tabelle, deren Zellen man stichprobenartig gegen das PDF prüft; die Synthese über mehrere Dokumente zu einer Frage trägt das höchste Fehlerrisiko, weil sich Suchfehler, untreue Zusammenfassung und schwache Gewichtung der Evidenz addieren. Die Kurzform „Antwort mit Zitaten“ ist für wissenschaftliche Arbeit deshalb meist nur ein Teaser: Man braucht den Originaltext für Kontext, Operationalisierung und Geltungsgrenzen, und erzeugter Text kann Quellen etwas zuschreiben, das sie so nicht sagen (Tay, 2025); dann fehlt es an Quellentreue. Ein praktisches Problem der spezialisierten Suchwerkzeuge kommt hinzu: Sie kommen nicht hinter die Bezahlschranken der Verlage und arbeiten deshalb mit Abstracts oder Open-Access-Korpora. Akademische Konnektoren zu den großen Sprachmodellen verschieben die Arbeit hier von abstract-basiertem Raten zu passagenbasiertem Prüfen, weil das Modell über eine institutionelle Anmeldung lizenzierte Volltexte durchsuchen und Behauptungen an Fundstellen binden kann, begrenzt auf den Bestand des jeweiligen Anbieters (Tay, 2024b).

Ihre Einschätzung prüfen

„Für einen Überblick über den Forschungsstand ist ein Deep-Research-Bericht die verlässlichste Form der KI-Recherche, weil er die meisten Quellen auswertet.“

Auflösung: nein. Die Synthese über viele Dokumente trägt das höchste Fehlerrisiko, weil sich Suchfehler, untreue Zusammenfassung und

schwache Gewichtung der Belege addieren. Verlässlicher ist es, das Werkzeug nach dem Muster der Aufgabe zu wählen: eine Trefferliste zum Suchen, eine Extraktionstabelle zum Auswerten, beides stichprobenartig gegen das Original geprüft.

Der 4D-Kreislauf beim Hiwi. Beim Hiwi reißt der Kreislauf (Kapitel 5.1) an zwei Stellen, bei der Delegation und bei der Prüfung des Ergebnisses; die Beschreibung ist meist einfach. *Delegation:* Tabelle 3.1 ist bereits eine Delegationsanalyse, denn sie trennt, was zur KI wandern kann, von dem, wobei sie nur hilft. *Description* (Beschreiben): Wer Artikel auswerten lässt, legt die Spalten der Extraktion fest wie ein Codebuch; klar definierte Variablen werden zuverlässiger extrahiert als freie Zusammenfassungen (Tay, 2024a). *Discernment* (Beurteilen): Zwei gleich eingestellte KI-Läufe kamen in einem Scoping Review (kartierende Literaturübersicht) bei 94 Datensätzen zu unterschiedlichen Urteilen (Figalová et al., 2026); ein zweiter Lauf ist deshalb die billigste Prüfregel. *Diligence* (Sorgfalt): Material für Studierende geht erst nach der Prüfung hinaus; geprüfte, quellengebundene Lernhilfen senkten in einem Kohortenvergleich vor allem den Anteil schwacher Prüfungsergebnisse (Dang & Nguyen, 2026, Preprint, also noch nicht begutachtet). Was die Prüfung regelmäßig als unzuverlässig zeigt, wandert aus der Delegation wieder heraus.

6.1.1.1 Interviews auswerten lassen – und prüfen

Literatur ist nicht die einzige Quelle, die ein Hiwi auswertet. Interviews aus einem Lehrprojekt, Freitexte der Lehrevaluation und Feedback am Semesterende sind qualitative Daten derselben Art, und Werkzeuge wie Gemini Notebook (früher NotebookLM) machen daraus in Minuten ein Gespräch zweier Stimmen. Das folgende Hörstück entstand so: Ein KI-Agent schrieb in einem Durchgang ein Drehbuch aus 125 Interviews, in denen Forschende über ihre Arbeit mit KI berichten (Handa et al., 2025).[1] Das Drehbuch ist absichtlich ungeprüft. Ihre Aufgabe ist die der Betreuung: vorher eine Vermutung festhalten, zuhören, dann drei Aussagen an den Originalstellen prüfen. Die Vermutung zählt mit, denn wer vorab rät, behält die Auflösung oft besser (Pan & Carpenter, 2023). Das Ganze dauert etwa zwölf Minuten.

[1] Datensatz: Anthropic Interviewer, Teil der Forschenden (*scientists*), https://huggingface.co/datasets/Anthropic/AnthropicInterviewer, Lizenz CC BY. Alle Teilnehmenden haben der Veröffentlichung ihrer Transkripte zugestimmt.

Prüfen Sie selbst: Ziehen Forschende der KI klare Grenzen?

Im Hörstück sagt der Moderator: „Viele ziehen klare persönliche Grenzen.“ Eine Stichwortzählung (etwa *boundary*, *draw the line*, *would never*) findet solche Wörter in den Antworten von 12 der 125 Interviews. Zwei der Treffer, in Arbeitsübersetzung:

1. „Ich setze der KI klare Grenzen, um wesentliche Lernschritte zu bewahren.“ (Transkript science_0077)
   Original: „I set clear boundaries around AI to preserve essential learning steps.“
2. „Wenn die KI zum Beispiel eigene mathematische Sätze aufstellen und die Grenzen der Wissenschaft verschieben könnte, wäre das eine große Hilfe.“ (Transkript science_0050)
   Original: „For example, if AI was able to produce its own mathematical theorems and push the boundaries of science, it would be a great help“

Ihr Urteil zur Aussage: ☐ belegt ☐ überzogen ☐ nicht belegt. Den Befund des Prüfagenten finden Sie in Anhang B.
Das Hörstück (sieben bis acht Minuten) mit Transkript und zwei weiteren Prüfaufgaben gibt es in der Online-Version: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/kapitel06-rollen.html#sec-podcast-interviews aufrufen.

Der Prüfagent, ein zweiter KI-Agent ohne Kenntnis des ersten Auftrags, zerlegte das Drehbuch in 39 Sachaussagen: 33 waren belegt, 6 überzogen, keine ohne Quelle. Die Zitate hielten, die Verallgemeinerungen nicht; aus 12 von 125 Interviews wurde „viele“. Für eigene Auswertungen heißt das: Zitate stichprobenartig prüfen, Wörter wie „viele“, „die meisten“ und „typisch“ ausnahmslos, und Zahlen nur nennen, wenn klar ist, was gezählt wurde.

So entstand dieses Hörstück

Der Drehbuch-Prompt begann: „Schreibe ein deutsches Podcast-Gespräch von etwa 1.150 Wörtern (8 Minuten) zwischen zwei Moderierenden, Lea und Jonas, über die angehängten Auszüge aus 125 Interviews mit Forschenden zu ihrer Arbeit mit KI." Ein Skript zog dafür 93 Originalstellen und eine Stichwortzählung aus den Transkripten. Das Drehbuch schrieb ein Agent in Claude Code in 75 Sekunden, die Prüfung dauerte fünfeinhalb Minuten; gesprochen haben zwei Stimmen aus ElevenLabs v3. Die Schwäche, die tatsächlich auftrat: Der Agent übernahm Stichwortzählungen als Aussagen über die Forschenden. Drei Stellen, die Teilnehmende verkürzt wiedergaben, wurden im Drehbuch korrigiert, alles andere nicht. Dass diese Korrekturen den Weg in die Sprachsynthese nicht gefunden hatten, zeigte erst ein Abgleich der fertigen Aufnahme mit dem Drehbuch per Spracherkennung; die drei Zeilen wurden nachgesprochen. Zum Vergleich entstand dasselbe Gespräch in Gemini Notebook aus allen 125 Interviews, ohne Vorauswahl: Es dauerte fast fünfzehn Minuten, von 37 Sachaussagen waren 24 überzogen oder ohne Beleg, und vier Interviewnummern stimmten nicht. Ob das am Werkzeug lag oder an der fehlenden Vorauswahl des Materials, lässt sich aus diesem einen Versuch nicht trennen.

6.2 KI als Copilot

In dieser Kategorie hilft das Sprachmodell uns dabei, etwas zu tun, was wir sonst nicht könnten. Mollick & Mollick (2024) beschreiben mehrere solcher Ansätze: Bei der **"Case Co-Creation"** (Mollick & Mollick, 2024, S.25–28) arbeiten Studierende mit der KI zusammen, um ein Fallbeispiel für Kommilitonen zu erstellen. Dies fördert die Artikulation von Ideen und die kritische Auseinandersetzung mit dem KI-Output, da die initialen Entwürfe oft oberflächlich sind und durch studentische Expertise verbessert werden müssen. Die Übung **"Critique the AI"** lässt die KI ein Szenario zu einem Konzept (z. B. Groupthink, Gruppendenken) erstellen, das die Studierenden dann kritisch bewerten und ggf. verbessern müssen. Dies schult das Erkennen von Konzeptmerkmalen und die Fähigkeit, Wissen durch Korrektur zu artikulieren. Eine Herausforderung ist, dass die KI Konzepte manchmal unvoll-

ständig oder fehlerhaft illustriert, was aber Teil des Lerneffekts sein kann (Mollick & Mollick, 2024).

i Anwendungsbeispiel: Wer nicht selbst rechnen kann, erkennt die Fehler des Copiloten nicht

Problem ohne KI. Eine Kennzahlenanalyse am echten Geschäftsbericht ist mühsam: Zahlen aus Bilanz und Gewinn- und Verlustrechnung heraussuchen, die Komponenten der Eigenkapitalrendite berechnen, das Ergebnis deuten.
Problem mit KI. Ein Copilot liefert die DuPont-Analyse in Sekunden und erklärt sie Schritt für Schritt. Ob sie stimmt, erkennt nur, wer den Rechenweg selbst beherrscht.
Das Dilemma. David Pedersen lässt Studierende die DuPont-Analyse der Eigenkapitalrendite von Coca-Cola für 2022 zuerst selbst aus dem Jahresbericht (10-K) bei der US-Börsenaufsicht berechnen und kurz deuten. Erst dann führen sie dieselbe Analyse mit Microsoft Copilot durch, stellen mindestens eine Nachfrage, reichen das Protokoll ein und reflektieren in 300 Wörtern, wie viel Führung die KI für ein richtiges Ergebnis brauchte. Die Zeitersparnis des Copiloten gibt es erst nach der eigenen Rechnung.
Was das für wirksames Lernen heißt. *Unterrichtsentwurf, keine Ergebnisse berichtet.* Die Reihenfolge schützt vor der Trennung von Leistung und Behalten, die im Labor gemessen ist: Mit ChatGPT lösten Informatikstudierende mehr Aufgaben, behielten den Stoff aber schlechter (Bergh et al., 2026). Und sie macht die zerklüftete Grenze (*jagged technological frontier*) der Modelle erfahrbar (Dell'Acqua et al., 2023): Ob der Copilot bei dieser Rechnung zuverlässig ist, zeigt erst der Vergleich mit dem eigenen Ergebnis.
Ablauf und Prompt: Online-Fassung von Anhang A. Quelle: Pedersen (2025) (AI Pedagogy Project, metaLAB at Harvard).



Dass ein Copilot auch fehlendes Vorwissen überbrücken kann, solange die Lehrenden den Studierenden die Prüfarbeit nicht abnehmen, zeigt ein Seminar aus der Mediävistik.

i Anwendungsbeispiel: Fehlende Lateinkenntnisse versperren den Zugang zu den Quellen

Problem ohne KI. Wer mittelalterliche Geschichte studiert, braucht Latein und für Handschriften auch Transkriptionsfähigkeit. Nicht alle Studierenden bringen das mit, und Lehrveranstaltungen zum Mittelalter werden häufig gemieden.
Problem mit KI. ChatGPT, Transkribus und Google Übersetzer öffnen den Zugang zu den Quellen, machen aber Fehler, die Anfängern ohne Latein kaum auffallen.
Das Dilemma. Cristina Andenna und Miriam Weiss (Universität des Saarlandes) haben das Seminar „ChatGPT und Mediävistik" als Held:innenreise in zwölf Etappen angelegt. Die Studierenden transkribieren, übersetzen und deuten einen Quellentext selbst; die Werkzeuge treten als „Mentoren" auf, mal hilfreich, mal nicht. Die Schwierigkeit liegt bei den Lehrenden: Bei offensichtlichen Fehlern der KI greifen sie nicht ein, damit die Studierenden den Prozess selbst durchleben. Das kostet Zeit und die Gewissheit, dass am Ende alles stimmt, und es nimmt den Lehrenden keine Arbeit ab: Die Arbeit der Studierenden mit KI muss eng begleitet werden.
Was das für wirksames Lernen heißt. *Evaluiert über Selbsteinschätzungen vor und nach der Lehrveranstaltung.* Die Begleitforschung fand signifikante Verbesserungen der digitalen Kompetenzen und der intrinsischen Motivation; gemessen wurde die Einschätzung der Studierenden, nicht ihre Leistung (Wannemacher et al., 2025, Case 146). Das Nicht-Eingreifen erhält eine erwünschte Schwierigkeit (*desirable difficulty*) (Bjork & Bjork, 2011): Den Fehler der Maschine selbst zu finden, ist die eigentliche Lernaufgabe.
Quelle: Wannemacher et al. (2025), Case 146.



6.2.1 Besser schreiben – als Cyborg

Wer akademisch schreibt, lässt sich zunehmend von einer Vielzahl an unterstützenden KI-Systemen über die Schultern schauen – oder die Hand führen –, die Vorschläge zur besseren Sprachverwendung machen, wie DeepL, Grammarly, oder ChatGPT (Ou et al., 2024). Ou et al. (2024) sprechen von KI-gestützten Sprachwerkzeugen (*AI-powered language tools*, AILT), die Studierenden dabei helfen, ihre Sprachfähigkeiten etwa von einer in die andere Sprache zu übertragen und das Sprachniveau ihrer Schreibprodukte generell zu verbessern. In ihrer Studie analysieren sie die Kommentare von 1703 schwedischen Studierenden und stellen komplexe Muster der Nutzung fest: „...students align their own languages, writing skills and thinking with the algorithm-based language processes (e.g., lexical, grammatical, and textual corrections, word choice suggestions, language translation) within AI chatbots, writing assistance, and machine language translation to optimise the outcomes of their academic writing. ... students have become 'spatially extended cyborg[s]' ".

Studierende schreiben durch die zunehmend mächtigere technische Unterstützung ihre Haus- und Abschlussarbeiten deutlich anders. Bedeutet dies das Ende der Hausarbeit? Wohl eher einen starken Wandel, denn es wird weiter wichtig sein, die saubere Argumentation zu üben (Friedrich, 2023; Klein, 2023).

Dafür lassen sich die einzelnen Schreibschritte gezielt trainieren, Teil für Teil. Für den Kurs zum wissenschaftlichen Arbeiten im Wirtschaftsingenieurwesen der TH Köln haben Julia Schmid und ich acht Schreibtrainer entwickelt, die eine Abschlussarbeit vom ersten bis zum letzten Kapitel begleiten (Tabelle 6.3). Jeder Trainer ist eine ausführliche Anweisung, ein Prompt, der ein Sprachmodell in einen geduldigen Übungspartner verwandelt.

Trainer	Teil der Arbeit	Lernziel	Übungsformat
1 Einleitung	Einleitung	Hook (Aufhänger), Hintergrund mit Quelle und Forschungsfrage verbinden; erkennen, wann eine Quelle nötig ist	Quiz, Mini-Einleitung mit Feedback, Analyse einer echten Einleitung

Trainer	Teil der Arbeit	Lernziel	Übungsformat
2 Forschungsstand	Stand der Forschung	Bestehende Forschung bündeln und die Lücke zeigen	Quiz, Vergleich zweier Forschungsstände, eigener Mini-Forschungsstand
3 Methoden	Methodenteil	Das Vorgehen begründen statt nur beschreiben	Methodenwahl in sechs Runden, starke und schwache Passagen vergleichen
4 Literature Review	Strukturierte Literaturübersicht	Literatur auswählen, auswerten und darstellen	Sechs Module mit Quiz und Mini-Fall; Punkte, Medaille, Urkunde
5 Diskussion	Diskussion	Ergebnisse einordnen statt wiederholen	Sätze dem Forschungsstand oder der Diskussion zuordnen, Bausteine üben
6 Artikelstruktur	Gesamtaufbau	Die Funktion jedes Abschnitts kennen	Quiz, Zuordnungsübung, eigene Gliederung
7 Limitationen	Limitationen und Ausblick	Grenzen als begründete Designentscheidung mit Trade-offs darstellen	Vier Szenarien, Quiz zum Ausblick
8 Absätze	Jeder Absatz	Topic Sentence (Kernsatz des Absatzes), Belege und Abschlusssatz verbinden	Drei Sortierübungen, eigener Absatz, Analyse eines echten Absatzes

Tabelle 6.3. Acht Schreibtrainer entlang der Abschlussarbeit (TH Köln, Wirtschaftsingenieurwesen; Julia Schmid und Roman Bartnik)

Alle acht folgen demselben Muster. Der Trainer erklärt kurz, wozu der Textteil dient, stellt Quizfragen und gibt bei falschen Antworten einen Hinweis statt der Lösung. Dann schreiben die Studierenden einen kurzen eigenen Text, erhalten Rückmeldung und überarbeiten ihn. Zum Schluss untersuchen sie einen echten Text und übertragen das Gelernte auf ihr eigenes Thema. Der Trainer für Limitationen zeigt, dass ein Bot auch eine Haltung vermitteln kann: Er übt in vier Szenarien, Limitationen als bewusste Entscheidung mit Preis zu schreiben statt als Pannenbericht. Der Trainer für Literature Reviews setzt auf Spielelemente, mit Punkten für richtige Antworten und am Ende einer Medaille und einer Urkunde.

Wie fragil solche Werkzeuge sind, zeigt ihre eigene Geschichte. Die Trainer liefen zunächst als Custom GPTs (selbst eingerichtete Chatbots) bei OpenAI, und OpenAI stellt diese Form der Chatbots am 11. Dezember 2026 ein (OpenAI, 2026c). Was bleibt, ist die Anweisung. Sie funktioniert in jedem Chatwerkzeug, auch im Angebot der eigenen Hochschule, und trägt deshalb besser als jeder Link auf eine Plattform.

Probieren Sie mal

Zwei der Trainer stehen online zum Ausprobieren bereit: der **Einleitungstrainer** und der **Absatztrainer** für Topic Sentences von Julia Schmid. Die Anweisung kopieren, in einen neuen Chat einfügen, absenden – der Trainer beginnt von selbst.

Abbildung 6.2. Schreibtrainer zum Kopieren: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/schreibtrainer.html aufrufen.

Wie stark die KI an einem Text mitwirkt, lässt sich auf einer vierstufigen Skala von „zur Inspiration“ bis „inhaltsgestaltend“ beschreiben; Studierende nutzen sie, um ihre KI-Nutzung zu dokumentieren (Tabelle 5.3).

Ethan und Lilach Mollick schlagen Hausarbeiten vor, die KI nicht zur Automatisierung einsetzen, sondern für interaktivere und individuellere Lernerfahrungen: mit mehr Reflexion, verschiedenen Perspektiven, Kreativität und Kollaboration. Die Lehrenden begleiten und moderieren diese Prozesse (Mollick & Mollick, 2023a, 2023b). Prompts für solche Aufgaben sammelt Anhang A (Anhang A).

Entscheidend bleibt, Didaktik und Technik auf die konkrete Kombination aus Lerninhalt und Studierendengruppe abzustimmen. Entlastung, an-

spruchsvollere Aufgaben und schnellere Individualisierung führen nur dann zu besserer Lehre, wenn sich die Lehrstrategie anpasst und Lehrende sich nüchtern mit den Risiken befassen, etwa mit der Frage, wie in diesen Schreibprozessen kritisches Denken (*critical thinking*) entsteht (H.-P. H. Lee et al., 2025).

6.2.1.1 Was unsere eigenen Bots über Quellentreue lehren

Gegen Tays Befunde aus Kapitel 6.1.1 gelesen, arbeiteten die ursprünglichen Anweisungen der Schreibtrainer an drei Stellen gegen die Quellentreue (Bartnik & Schmid, 2026); wer eigene Trainer baut, trifft dieselben Entscheidungen.

Erstens sollten Einleitungs- und Forschungsstandtrainer die vollständige Einleitung eines echten Open-Access-Artikels zeigen. Ohne hinterlegte Datei rekonstruiert ein Sprachmodell den Text aus seinen Trainingsdaten und kann einem existierenden Artikel Sätze zuschreiben, die dort nicht stehen (Tay, 2025); auch hier fehlt es an Quellentreue. Abhilfe ist der Schritt zum passagenbasierten Arbeiten (Tay, 2024b): den Originaltext als Datei hochladen oder die Studierenden den Text selbst einfügen lassen. So arbeiten die kopierbaren Fassungen auf der Schreibtrainer-Seite.

Zweitens dürfen Quellen in den Schreibübungen erfunden sein. Das trennt den rhetorischen Zug, eine Quelle mit Funktion einzubauen, von der Suche. Ohne sichtbare Markierung „fiktiv“ lernen Studierende aber nebenbei, wie normal ein erfundener Beleg aussieht; die kopierbaren Fassungen verlangen die Markierung deshalb ausdrücklich. Unsere Handreichung für Abschlussarbeiten setzt den Gegenpol: Wer eine Quelle nicht erklären kann, gefährdet das Bestehen (Kapitel 5.4.2).

Drittens erzeugen Diskussions- und Strukturtrainer Abschnitte im Ton begutachteter Artikel samt Literaturverweisen; als Übungsmaterial taugen sie, wenn der Trainer sie als synthetisch kennzeichnet.

> Ausprobiert: Prüfen, ob ein Sprachmodell richtig zitiert · 4D: Discernment · für Studierende
>
> **Ablauf.** Bitten Sie ein Sprachmodell ohne hochgeladene Datei, die Einleitung eines bekannten Open-Access-Artikels aus Ihrem Fach wörtlich wiederzugeben. Suchen Sie das Original in Google Scholar und glei-

chen Sie drei Sätze ab: einen aus dem ersten Absatz, einen mit Quellenverweis, den mit der Forschungsfrage.
Worauf achten. Gibt es den Artikel? Steht jeder der drei Sätze wörtlich, sinngemäß oder gar nicht im Original? Gibt es die Quelle, auf die der zweite Satz verweist, und sagt sie das?
Was die Übung zeigt. Tays Stichprobenaudit gegen das PDF im Kleinen (Tay, 2024a), die Prüfliste aus Kapitel 6.2.2.3 auf Text übertragen: Überzeugend klingt jede Ausgabe; es zählt, ob sie aus der Quelle folgt. Wiederholt man den Abgleich mit dem PDF als hochgeladener Datei, wird der Unterschied selbst zum Lerngegenstand.

Wie der nächste Abschnitt zeigt, findet eine ähnlich intensive Diskussion im Bereich der Informatik statt, wo speziell Programmieraufgaben ganz neu gedacht werden müssen.

6.2.2 Jeder kann jetzt programmieren

Mit KI als Copilot können wir **viel umfangreicher und schneller mit Code arbeiten**. Ein Beispiel ist Programmieren: Professionelle Programmierer werden mit KI-Copiloten deutlich schneller (Peng et al., 2023), und Lehrbücher haben zunehmend Namen wie „Learn AI-assisted Python Programming“ (Porter & Zingaro, 2024).

Studierende können so zum Beispiel viel schneller ein funktionierendes Spiel oder eine Simulation erstellen, was die Motivation erhöht. Der **Raum der kreativen Möglichkeiten weitet sich deutlich aus**.

Tipp: Mini-Interaktionen einfach als HTML erstellen

Können Sie in HTML programmieren? Jetzt schon. Die Lernspiele in Kapitel 2.1 und Kapitel 2.4.1 wurden mit Hilfe von Sprachmodellen erstellt (Gemini, ChatGPT, Claude), meist mit einer Variation des einfachen Prompts **„Erstelle mir ein browserbasiertes Lernspiel zum Thema / zur Illustration von ...“**. Oft steht nach fünf bis zehn Minuten eine gute erste Version. In der Lehre mache ich das auch als Übung mit Studierenden: Sie erstellen mit der KI ein Lernspiel und bewerten dann begründet, welcher Prototyp das Konzept am besten darstellt. Bei etwas mehr Zeit bewerten sie sich gegenseitig, entwickeln eigene Krite-

rien oder fügen stärkere Spielelemente hinzu. Im Ergebnis beschäftigen sich die Teilnehmenden intensiv mit einem theoretischen Konzept; bei komplexeren Themen hilft es, einen Fachtext als Hintergrund hochzuladen.

Mit KI-Unterstützung können Schüler/innen mit Sonic Pi Musikstücke programmieren (Gieselmann, 2024) oder mit Tools wie Violentmonkey kleine Skripte für die individuelle Anzeige von Lieblings-Websites erstellen (Eikenberg, 2025).

Die ersten Studien zu GitHub Copilot zeigen, wie stark solche Assistenten die Einstiegshürden senken: Studierende eines Managementstudiengangs (MBA) ohne Programmierkenntnisse wandten mit generiertem Code in der Statistiksprache R statistische Methoden eigenständig an (Bien & Mukherjee, 2025), und Copilot löste etwa die Hälfte von 166 typischen Aufgaben aus Einführungskursen auf Anhieb, nach umformulierten Aufgabenbeschreibungen weitere 60 % der übrigen (Denny et al., 2023). Studierende lösen damit einen Großteil universitärer Programmieraufgaben ganz oder teilweise, und Lehrende müssen ihre Aufgaben so anpassen, dass die Kernkompetenzen trotzdem erworben werden (Nizamudeen et al., 2024). Grundlegende Programmierkenntnisse bleiben nötig, weil generierter Code funktionale und nicht-funktionale Anforderungen oft verfehlt und beurteilt, angepasst oder verworfen werden muss (Liang et al., 2024; Puryear & Sprint, 2022).

Praktisch alles, was Code ist, lässt sich mit Sprachmodellen erstellen und anpassen. Wir brauchen also nur Code-Schnittstellen. Das klingt kompliziert, ist aber überall schon vorhanden. Im Schreibprozess importieren wir Zitationen über das Bibtex-Format (.bib). Kalendertermine werden im Kalenderstandard (.ics) geführt. Für Flussdiagramme gibt es z. B. den Mermaid-Standard. Wir können insofern mit Sprachmodellen:

- Zitationen von einem Foto aus importieren („Scanne das Foto und gib mir die Quellen als Bibtex Code aus. Erkläre mir dann, wie ich ihn importiere“)
- Kalendereinträge aus einer Liste in unser Terminprogramm überführen („Erstelle mir aus dieser Liste Einträge im ICS Standard. Erkläre mir dann, wie ich den Code in Google Calendar importiere.“)
- Ablaufdiagramme in Mermaid visualisieren und als Grafik speichern („Erstelle mir einen typischen Kaufprozess in Mermaid. Erkläre mir

dann, wie ich ihn visualisieren und als Grafik exportieren kann.“)
- Interaktive Simulationen mit den Claude Artifacts erstellen (s. o.; selbst gebaute Beispiele stehen in Kapitel 6.2.2.1 und Kapitel 6.2.2.2)
- Dialogbasiert Grafiken und statistische Analysen in Google Colab erstellen (s. u.)
- (Für viele weitere Ideen für solche Hilfsmittel können wir einfach das Sprachmodell fragen.)

Wichtig für Hochschulen: Mit **Google Colab** steht eine browserbasierte Programmierumgebung mit integriertem Sprachmodell kostenlos zur Verfügung. Visualisierungen und statistische Analysen können hier komplett dialogbasiert begonnen werden: Rechts steht der Prompt, links entstehen Code und Grafik. Auch ohne Grundkenntnisse in Python sind Studierende so gleich handlungsfähig und bauen durch häufige Nutzung Wissen auf. Dadurch wird es etwa möglich, von Studierenden durchgängig die Nutzung von Programmiertools zur Erstellung von Visualisierungen zu verlangen; die KI-Assistenz macht das leichter als das händische Gefrickel in den Grafiken von Excel oder gar PowerPoint. Nachvollziehbar bleibt dabei alles, weil es im Code steht, und Anpassungen sind einfach, weil die KI sich um die Syntax kümmert. Ein Beispiel-Notebook zeigt das: Beispiel-Notebook

Beispiel-Prompts:

- Erstelle mir eine einfache Visualisierung von vertikalen und horizontalen **Balkendiagrammen** in Python.
- **Passe die Balken so an**, dass die Prozentwerte auf den Balken sichtbar sind.
- Füge Beispiele für **Violin Charts** mit einem etwas komplexeren **Beispieldatensatz** hinzu.
- Erstelle jetzt einen Beispieldatensatz und führe eine einfache **Explorative Datenanalyse** (EDA) mit Visualisierungen durch.

Solche **Hilfestellungen sind Alltag** geworden: Die verbreiteten Code-Editoren, etwa PyCharm, VS Code und Cursor, bieten Programmierung mit KI-Unterstützung an. Seit 2025 verschiebt sich dabei die Arbeitsteilung ein zweites Mal. Ein Copilot ergänzt die Zeile, die man gerade schreibt. Ein **Programmier-Agent** (*coding agent*) wie Claude Code, Codex oder der Agentenmodus von Cursor bekommt dagegen einen Auftrag in Alltagssprache, liest die vorhandenen Dateien, ändert mehrere davon, startet Tests und meldet das Ergebnis; das ist die Schleife aus Denken, Handeln und Beobachten, die Kapitel 2.1.2 beschreibt. Der Mensch schreibt kaum noch

Code, er beschreibt, prüft und entscheidet, und erfahrene Entwickler lassen inzwischen mehrere Agenten parallel arbeiten (Steinberger, 2025; Willison, 2025). Für Hochschulen stellt sich damit eine doppelte Frage: wie Lehrende die Agenten für eigene Materialien nutzen und wie Studierende neben ihnen noch lernen, was sie verstehen sollen.

Wie das im Alltag aussieht, zeigt ein Making-of aus der Arbeit an diesem Buch. Claude Code schrieb das Video zu Tabelle 3.1 als Programmtext: Die Tabelle wurde zu einer Datendatei, ein Skript erzeugte daraus die Szene, und das Werkzeug HyperFrames rechnete den Film Bild für Bild aus (HeyGen, 2026). Vom Auftrag bis zum fertigen Film vergingen neun Minuten, Recherche und Einrichtung eingeschlossen. Zwei Prüfschritte fanden dabei Fehler: Die automatische Prüfung meldete zu schwachen Farbkontrast, die Sichtprüfung am Standbild eine Kachel, die unter ihre Nachbarin rutschte. Beide Fehler waren in einer Minute behoben; ohne die Prüfschritte wären sie im fertigen Film geblieben. Was als Code vorliegt, kann ein Sprachmodell schreiben und ändern. Die Verantwortung für das Ergebnis bleibt bei der Lehrperson.

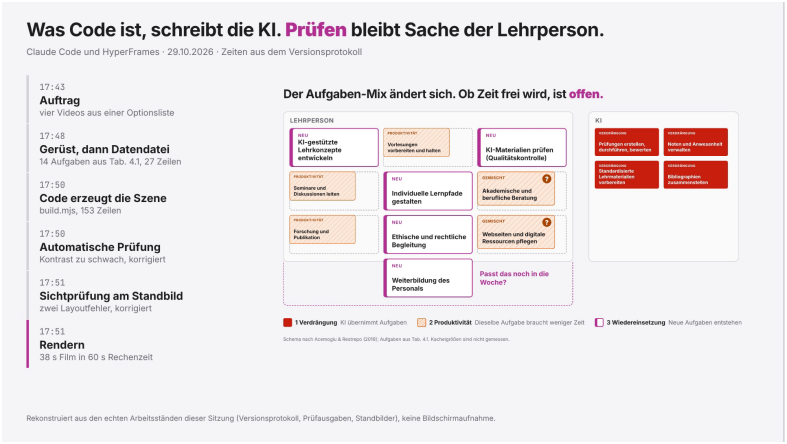


Abbildung 6.3. Making-of zum Video über Tabelle 3.1: Auftrag, Datendatei, Code, automatische Prüfung, Sichtprüfung, Rendern, rekonstruiert aus Versionsprotokoll und Prüfausgaben. Schlussbild eines Videos (59 s), erstellt mit Claude Code und HyperFrames. Das Video gibt es nur in der Online-Version: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/kapitel06-rollen.html#vid-making-of aufrufen.

Wie verschieden zwei solche Werkzeuge dieselbe Herleitung umsetzen,

zeigt der Vergleich zur optimalen Bestellmenge. Links läuft Manim, eine Python-Bibliothek für Mathematik-Animationen, rechts HyperFrames, das Webseiten-Code in Video umwandelt; beide Fassungen schrieb Claude. Für den Lernerfolg zählt die Machart womöglich weniger als erwartet: In einem Online-Experiment mit 447 Teilnehmenden lernten diese mit KI-erzeugten Lehrvideos, darunter eines zur optimalen Bestellmenge, gleich viel wie mit menschlich produzierten, erlebten die menschlichen aber etwas positiver (Netland et al., 2025).

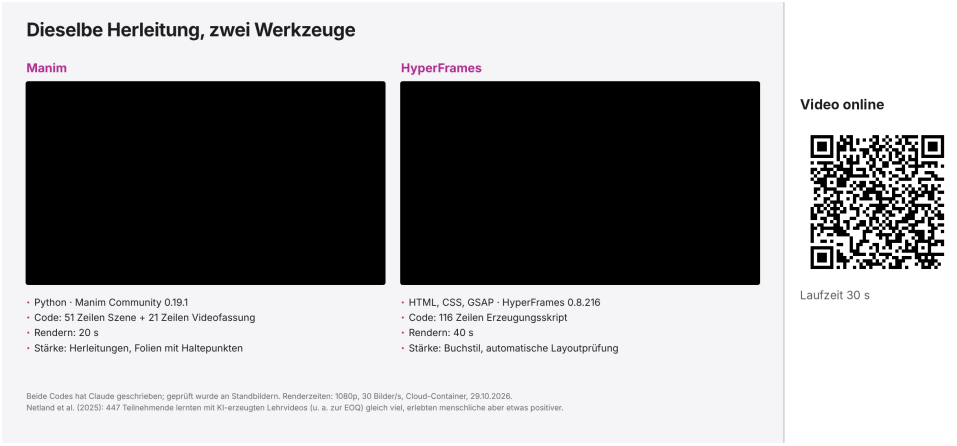


Abbildung 6.4. Dieselbe Herleitung der optimalen Bestellmenge in Manim (links) und HyperFrames (rechts), beide von Claude programmiert. Schlussbild eines Videos (30 s). Das Video gibt es nur in der Online-Version: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/kapitel06-rollen.html#vid-eoq-vergleich aufrufen.

Ob sich eine Animation überhaupt lohnt, entscheidet der Lernstoff, nicht das Werkzeug. Über 61 Studien hinweg schlugen Animationen statische Bilder nur knapp (Berney & Bétrancourt, 2016); deutlich war ihr Vorteil dort, wo die Veränderung selbst Lernstoff war (Ploetzner et al., 2020). In einem Experiment erkannten Studierende die Bewegungsabläufe eines Getriebes nach einer Animation am besten, die Anordnung der Zahnräder dagegen nach Standbildern (Ploetzner et al., 2021). Bewegung gehört also an Prozesse, Dynamik und Wirkungsketten wie den Sägezahn des Lagerbestands, nicht an Aufbau und Struktur.

Was der Agent den Lehrenden abnimmt, kann er Studierenden beim Lernen wegnehmen. In einem Experiment bauten 54 Informatikstudierende zweier

US-Hochschulen ein kleines Browserspiel, die eine Hälfte mit einem Agenten, der ihren Code direkt änderte, die andere mit einem Chatbot, der nur allgemeine Codeschnipsel lieferte, so dass sie selbst schreiben mussten; beide liefen mit GPT-4.1. Die Agentengruppe war schneller und erfüllte mehr Anforderungen, verstand ihren eigenen Code aber deutlich schlechter. Als alle das Spiel danach ohne Agent erweitern sollten, kehrte sich ihr kleiner Vorsprung um, sobald man den besseren Ausgangscode herausrechnete: Er stammte aus dem Gerüst, das der Agent gebaut hatte, nicht aus Verständnis. Weniger verstand, wer die Aufgabenstellung in den Prompt kopierte oder alle Änderungen ungesehen übernahm, am meisten, wer den Auftrag in Fachbegriffe übersetzte und jede geänderte Datei einzeln annahm. Den Agenten bevorzugten die Studierenden trotzdem, weil er schnell und bequem ist (Balepur et al., 2026). Die Studie ist klein und ausdrücklich explorativ, passt aber zu dem, was Kapitel 4.5 für den Chat zeigt: Mit KI lösen Studierende mehr Programmieraufgaben und behalten weniger (Bergh et al., 2026). Von sich aus arbeiten sie selten anders. In den Chatprotokollen eines Semesters aus einem Informatikkurs ging es in 78,8 % der Anfragen nicht ums Verstehen; die Studierenden ließen die KI die Arbeit tun oder sich von ihr bestätigen, und nur 11,1 % der Anfragen verbanden den Wunsch zu verstehen mit eigener Begründung (Wu, 2026).

Ihre Einschätzung prüfen

„Studierende, die mit einem Programmier-Agenten arbeiten, kommen schneller zu einem lauffähigen Programm, verstehen ihren Code aber schlechter als Studierende, die ihn selbst schreiben müssen.“
Auflösung: eher ja. Im Experiment mit 54 Informatikstudierenden erfüllte die Agentengruppe mehr Anforderungen und verstand ihren Code deutlich schlechter; ihr Vorsprung verschwand, als alle ohne Agent weiterbauen mussten. Die Studie ist klein und explorativ, passt aber zu den Befunden für den Chat. Am meisten verstand, wer den Auftrag in Fachbegriffe übersetzte und jede Änderung einzeln annahm.

Daraus folgt eine Arbeitsteilung, die sich am Lernziel ausrichtet. Wo das Produkt zählt, etwa ein Lernspiel, ein Prototyp oder eine Simulation für die eigene Lehre, darf der Agent schreiben, und die Prüfung des Ergebnisses bleibt Pflicht (Kapitel 6.2.2.3). Wo das Verstehen des Codes selbst Lernziel ist, gehören die Bremsen in die Aufgabe: Aufträge in Fachbegriffen statt kopierter Aufgabenstellung, jede Änderung einzeln annehmen, eine schriftliche Begründung für jede übernommene Änderung, wie sie beim Schreiben

mit KI die Übernahme fehlerhafter Vorschläge senkt (Tao et al., 2026), und am Ende eine Erweiterung ohne Agent, die zeigt, was verstanden wurde.

6.2.2.1 Beispiel: Little's Law selbst nachrechnen

Simulationen, an denen Studierende selbst drehen, haben in der Lehre zu Produktion und Logistik eine lange Tradition. Dobson & Shumsky (2006) stellten drei Browser-Simulationen vor, eine Warteschlange, Little's Law in einem einstufigen Prozess und ein Bestellpunktsystem, alle über Schieberegler gesteuert, und erprobten sie in einer Web-Übung mit 74 Studierenden. Das R-Paket `bullwhipgame` simuliert den Bullwhip-Effekt (Peitscheneffekt) in einer vierstufigen Lieferkette, setzt aber eine eigene R-Installation voraus (Marchena, 2018). Solche Werkzeuge zu bauen, war lange Sache von Spezialisten. Mit einem Sprachmodell als Copilot können Lehrende sie selbst programmieren, und das folgende Widget (interaktives Lernelement) ist auf diesem Weg entstanden.

Little's Law sagt: Bestand = Durchsatz × Durchlaufzeit, kurz $L = \lambda W$ (Little, 1961). Wer jeden Monat zehn Flaschen Wein kauft und jede ein Jahr liegen lässt, hat im Mittel 120 Flaschen im Keller, ohne je eine einzelne Flasche zu verfolgen. Das Gesetz ist eine Bilanz, und Bilanzen stimmen nur über den ganzen Zeitraum. Wer den Keller einen Nachmittag lang beobachtet, sieht vielleicht keine einzige Flasche kommen oder gehen.

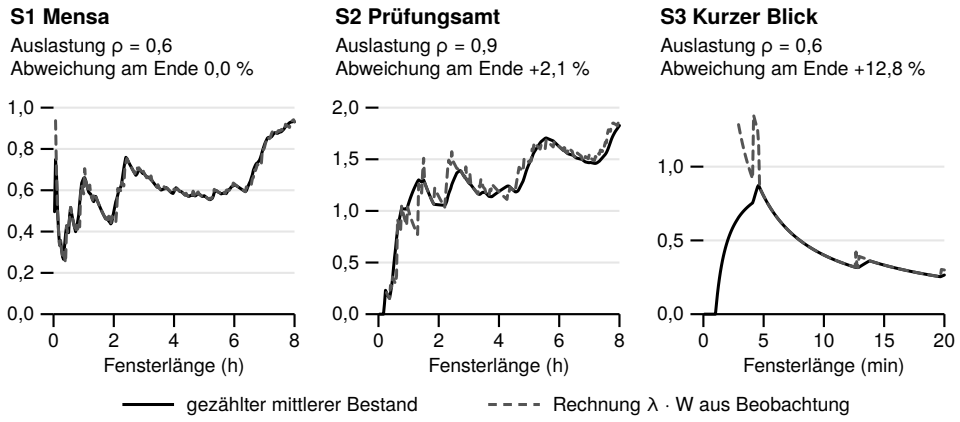


Abbildung 6.5. Little's Law in drei Szenarien: Über acht Stunden trifft die Rechnung $\hat{\lambda} \cdot \hat{W}$ (gestrichelt) den gezählten Bestand $\bar{L}$ (durchgezogen), im Prüfungsamt mit hoher Auslastung erst nach einigen Stunden; im Blick über 20 Minuten verfehlt sie ihn um 13 %. Dieses interaktive Element gibt es nur in der Online-Version: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/kapitel06-rollen.html#sec-widget-littles-law aufrufen.

Warum die Gleichung im kurzen Fenster danebenliegt

Aufträge, die bei Fensterende noch im System sind, zählen im Bestand $\bar{L}$ mit, haben aber noch keine abgeschlossene Verweilzeit und fehlen deshalb in $\hat{W}$. Ist das System an beiden Fensterrändern leer, gilt $\bar{L} = \hat{\lambda} \cdot \hat{W}$ exakt; sonst entsteht die Abweichung am Rand. Je höher die Auslastung, desto länger die Verweilzeiten, desto breiter der Rand und desto langsamer nähert sich die Rechnung dem gezählten Bestand. Im kurzen Fenster entscheidet deshalb der Zufall, ob die Gleichung passt.

> **Probieren Sie mal**
>
> Ein Studienbüro erhält im Mittel 40 Anträge pro Woche, im Stapel liegen 120. Wie lange wartet ein Antrag im Mittel, ohne dass jemand Zeiten misst?
> *Lösung:* W = L / λ = 120 / 40 = 3 Wochen. Die Rechnung gilt, wenn das Büro über die Zeit so viele Anträge abarbeitet, wie eingehen.

6.2.2.2 Beispiel: Den Bullwhip-Effekt zerlegen

Eine kleine Bewegung am Griff einer Peitsche wird an der Spitze zum großen Ausschlag. In einer Lieferkette geschieht dasselbe mit den Bestellungen: Sie schwanken umso stärker, je weiter eine Stufe vom Endkunden entfernt ist, obwohl die Kundennachfrage kaum schwankt. H. L. Lee et al. (1997) nannten das den Bullwhip-Effekt und führten ihn auf vier Ursachen zurück: die laufende Aktualisierung der Prognosen, das Bündeln von Bestellungen, Preisaktionen und das Horten bei Knappheit. Das zweite selbst gebaute Widget greift die erste Ursache heraus und verbindet sie mit zwei Stellgrößen, die jede Disponentin kennt, der Lieferzeit (*lead time*) und der Frage, wer welche Daten sieht.

Das Modell hat vier Stufen: Händler, Großhandel, Verteilzentrum und Fabrik. Jede Stufe prognostiziert ihre Nachfrage als gleitenden Mittelwert (*moving average*) über die letzten p Perioden und bestellt so viel, dass Bestand und offene Bestellungen die Prognose über die Lieferzeit L decken. Für genau diese Kette haben Chen et al. (2000) gezeigt, dass die Bestellungen des Händlers mindestens um den Faktor

$$\frac{\mathrm{Var}(q)}{\mathrm{Var}(D)} \geq 1 + \frac{2L}{p} + \frac{2L^2}{p^2}$$

stärker streuen als die Kundennachfrage D. Bei zwei Wochen Lieferzeit und einem Mittelwert über fünf Wochen ist das gut das Doppelte. Die Lieferzeit zählt dabei wie bei Chen et al. (1999) die Bestellperiode mit: Eine Bestellung vom Ende der Woche t ist zu Beginn der Woche $t + L$ da. Ohne geteilte Information (*centralized demand information*) multiplizieren sich die Faktoren von Stufe zu Stufe; teilen alle Stufen die Kassendaten des Händlers, addieren sich nur noch die Lieferzeiten. Der Effekt wird dann kleiner, verschwindet

aber nicht. Das Widget leitet sein Modell aus diesen Arbeiten ab und übernimmt keinen Code aus dem Paket `bullwhipgame`, das unter der freien Softwarelizenz GPL-3 steht.

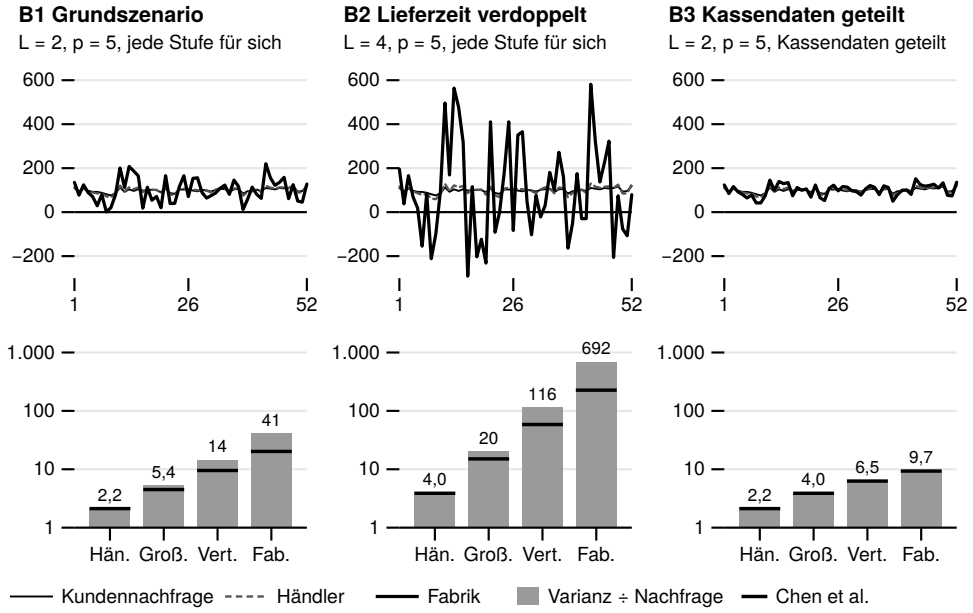


Abbildung 6.6. Bullwhip-Effekt in drei Szenarien mit derselben Kundennachfrage. Oben die Bestellungen eines Jahres auf gleicher Skala, unten das Varianzverhältnis jeder Stufe über 2000 Perioden (logarithmisch), der Strich markiert den Wert nach Chen et al. Verdoppelt sich die Lieferzeit, steigt die Varianz der Fabrikbestellungen vom 41- auf das 692-Fache der Kundennachfrage; geteilte Kassendaten senken sie auf das 9,7-Fache. Dieses interaktive Element gibt es nur in der Online-Version: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/kapitel06-rollen.html#sec-widget-bullwhip aufrufen.

Warum die Peitsche knallt

Jede Bestellung besteht aus zwei Teilen: dem, was gerade verkauft wurde, und der Änderung der Bestellgrenze. Steigt die Prognose um ein Stück pro Woche, muss die Bestellgrenze um L Stück steigen, weil sie L Wochen abdeckt. Die Prognoseänderung kommt also mit der Lieferzeit vervielfacht in der Bestellung an. Die nächste Stufe hält diese schon verstärkte Bestellung für Nachfrage und verstärkt sie erneut. Geteilte Kassendaten unterbrechen die zweite Verstärkung, die erste bleibt.

Das Modell zeigt die operativen Ursachen, nicht die menschlichen. In den Experimenten von Croson & Donohue (2006) entstand der Bullwhip-Effekt auch dann, als Prognose, Bündelung und Preisaktionen ausgeschaltet waren, weil die Teilnehmenden die bereits bestellte, noch unterwegs befindliche Ware zu wenig berücksichtigten (*underweighting the supply line*). Sterman (1989) hatte dieses Verhalten im Beer Game (Lieferketten-Planspiel) als Verankern und Anpassen (*anchoring and adjustment*) beschrieben. Wer das Widget allein zeigt, legt deshalb eine Fehlvorstellung nahe: dass bessere Prognoseverfahren das Problem lösten. In der Lehre passt es besser in die Nachbesprechung eines Beer Game, in der Studierende ihre eigenen Bestellkurven neben die Kurven des Modells legen. Simulationsspiele wirken als Ergänzung anderer Lehrformen stärker denn als alleinige Unterweisung (Sitzmann, 2011).

Probieren Sie mal

Ein Händler bestellt bei drei Wochen Lieferzeit und prognostiziert mit dem Mittelwert der letzten sechs Wochen. Um welchen Faktor streuen seine Bestellungen mindestens stärker als die Nachfrage? Und wie viele Wochen muss er bei vier Wochen Lieferzeit mitteln, damit der Faktor unter 1,5 fällt?
Lösung: $1 + 2{\cdot}3/6 + 2{\cdot}9/36 = 2{,}5$; die Standardabweichung ist damit gut das 1,6-Fache. Bei $L = 4$ fällt der Faktor erst ab $p = 20$ Wochen unter 1,5 (1,48). Ein so langes Fenster reagiert aber träge auf echte Trendwechsel; die Dämpfung hat ihren Preis.

6.2.2.3 Prüfen, ob eine KI-gebaute Simulation rechnet

Beide Widgets hat ein Sprachmodell nach meinen Vorgaben programmiert. Verlässlich macht sie die Reihenfolge, in der sie entstanden sind: zuerst das Rechenmodell als eigene Datei ohne Oberfläche, dazu Tests gegen Handrechnungen und veröffentlichte Formeln, erst danach Regler und Diagramme. Wer die Reihenfolge umkehrt, bekommt in kurzer Zeit etwas, das gut aussieht.

i Anwendungsbeispiel: Die KI baut überzeugende Animationen, die nichts rechnen

Problem ohne KI. Eine Prozessanimation, in der sich vor dem Engpass sichtbar eine Schlange bildet, erklärt Durchlaufzeiten besser als jede Folie. Sie zu programmieren, kostet Lehrende ohne Programmiererfahrung Wochen; deshalb bleibt es meist bei Kästchen und Pfeilen.
Problem mit KI. Ein Sprachmodell liefert eine solche Animation in einer Stunde. Ob dahinter ein Modell rechnet oder ein Film mit festem Drehbuch abläuft, sieht man dem Ergebnis nicht an.
Der Lösungsansatz. Für die Animationsbibliothek *scm-visuals* ließ ich im September 2026 sechs Prozessanimationen zu Produktion und Beschaffung von einem Sprachmodell entwerfen: einfacher Fluss, Losgegen Einzelstückfertigung, Engpass und Warteschlange, Push gegen Pull (Fertigung auf Vorrat gegen auf Abruf) und zwei Bestellabläufe vom Bedarf bis zur Zahlung. Eine Prüfung mit Standbildfolgen und Zustandsprotokollen, also mit Listen, die für jeden Zeitpunkt festhalten, wo jedes Stück steht, ergab: Nur zwei der sechs rechneten ein Modell, Engpass und Push gegen Pull. Die übrigen vier spielten feste Zeitleisten ab, und die Animation zur Losfertigung ließ im Einzelstückmodus die Kapazität der Stationen außer Acht. Alle sechs sahen überzeugend aus. Seitdem entsteht zuerst das Modell mit seinen Tests und dann die Oberfläche; die beiden Widgets in Kapitel 6.2.2.1 und Kapitel 6.2.2.2 sind so gebaut.
Was das für wirksames Lernen heißt. *Erfahrungsbericht aus der eigenen Entwicklung, keine Lernwirkung gemessen.* Eine Simulation lehrt Ursache und Wirkung nur, wenn die Wirkung aus der Ursache folgt. Spielt sie ein festes Drehbuch ab, zeigt sie nach jeder Änderung dasselbe, und wer seine Vorhersage prüft, prüft sie gegen einen Film. Studierende können das nicht erkennen, Lehrende nur am Modell, nicht am Bild.

Ein Sprachmodell baut eine glaubwürdige Oberfläche schneller als ein korrektes Modell; die Grenze seiner Leistung verläuft hier mitten durch eine einzige Aufgabe (Dell'Acqua et al., 2023).

Prüfliste: Rechnet die Simulation, oder spielt sie ab?

Die fünf Prüfungen brauchen keine Programmierkenntnisse, nur die Regler und einen Taschenrechner. Beide Widgets dieses Abschnitts bestehen sie, und ihre Tests im Repositorium prüfen dieselben Punkte bei jeder Änderung automatisch.

1. **Andere Eingabe, anderer Verlauf.** Wer einen Parameter ändert, muss eine andere Kurve sehen, nicht nur andere Zahlen an derselben Kurve. Im Bullwhip-Widget ändert die doppelte Lieferzeit die Form der Fabrikbestellungen, nicht nur ihre Höhe.
2. **Grenzfälle.** Kommen fast keine Aufträge an, bleibt das System leer. Liegt die Auslastung bei 100 % oder darüber, warnt das Little's-Law-Widget, statt ein Gleichgewicht vorzutäuschen. Schwankt die Kundennachfrage nicht, bestellt im Bullwhip-Widget jede Stufe genau 100 Stück.
3. **Eine Handrechnung.** Mindestens ein Fall muss sich auf Papier nachrechnen lassen. Im Little's-Law-Modell sind es zwei Aufträge, im Bullwhip-Modell ein Nachfragesprung von 100 auf 120 Stück: Bei zwei Perioden Lieferzeit und einem Mittel über vier Perioden bestellt der Händler 130 Stück, der Großhandel 145. Wo es eine veröffentlichte Formel gibt, muss das Modell sie treffen, hier die von Chen et al. (2000).
4. **Gleicher Startwert, gleiches Ergebnis.** Ein Szenario mit demselben Startwert läuft zweimal identisch ab. Neu gewürfelt ändert sich der Verlauf, das Muster bleibt.
5. **Genannte Annahmen.** Das Widget sagt, was es vereinfacht. Bei beiden Widgets stehen die Annahmen in einem aufklappbaren Kasten unter den Diagrammen.

Ausprobiert: Eine Simulation bauen lassen, die rechnet · 4D: Description, Discernment · für Lehrende

Ziel. Das Sprachmodell baut ein Widget zu Little's Law und liefert die Mittel, es zu prüfen, gleich mit.
Prompt.

```
Baue ein interaktives Widget zu Little's Law
(L = λW) für Studierende im ersten Semester.
Gehe in zwei Schritten vor.
Schritt 1: Schreibe das Modell als reine
Funktion ohne Oberfläche.
Eingaben: λ, mittlere Bearbeitungszeit,
Fensterlänge, Startwert für den
Zufallsgenerator.
Ausgaben: mittlerer Bestand L, beobachtete
Ankunftsrate λ̂, mittlere Verweilzeit Ŵ. Nenne
alle Annahmen. Schreibe drei Tests:
(1) Ist das System zu Beginn und am Ende leer,
gilt L = λ̂·Ŵ exakt.
(2) Bei Auslastung 0,6 und langem Fenster liegt
die Abweichung unter 2 %.
(3) Derselbe Startwert liefert dasselbe
Ergebnis.
Schritt 2: Erst wenn alle Tests bestehen, baue
Regler und Diagramm.
Erkläre mir danach in drei Sätzen, wie ich ohne
Programmierkenntnisse prüfe, dass das Widget
rechnet und nicht nur abspielt.
```

Worauf achten. Hält das Modell die Reihenfolge ein, oder liefert es sofort Regler? Rechnen die Tests das Modell durch, oder vergleichen sie fest eingetragene Zahlen miteinander? Lässt sich die Erklärung am Ende mit der Prüfliste oben abgleichen?
Variante mit Studierenden (4D: Discernment). Lassen Sie das Sprachmodell eine zweite Fassung bauen, die nur eine feste Zeitleiste abspielt, und geben Sie beide Fassungen ohne Kennzeichnung aus. Die Studierenden finden mit der Prüfliste heraus, welche rechnet, und begründen es.

Der 4D-Kreislauf beim Copilot. Beim Copilot entscheidet die innere Schleife aus Beschreiben und Prüfen, weil Mensch und KI im Wechsel an dersel-

ben Aufgabe arbeiten. *Delegation:* Was eigene Arbeit bleibt, hängt am Lernziel; wer den Code verstehen soll, gibt das Schreiben nicht ganz ab (Balepur et al., 2026). *Description:* Beschrieben wird der Arbeitsweg, nicht nur das Produkt: Aufträge in Fachbegriffen, Änderungen einzeln annehmen, Erklärungen statt fertiger Fassungen anfordern. *Discernment:* Eine Begründungspflicht für jede übernommene Änderung senkt die Übernahme fehlerhafter Vorschläge (Tao et al., 2026), und der Abgleich mit dem eigenen Ergebnis zeigt, wo die zerklüftete Grenze verläuft (Kapitel 5.2.1). *Diligence:* Studierende dokumentieren, wie stark die KI mitgewirkt hat, etwa mit der Skala in Tabelle 5.3. Die Begründungspflicht aus dem Prüfen wird so zur Regel der Delegation: Abgegeben wird nur, was man begründet übernehmen kann.

6.3 KI als Tutor

Diese Kategorie umfasst KI-Systeme, die Studierende direkt beim Lernen anleiten, beraten oder ihnen Feedback geben. Sogenannte intelligente Tutorsysteme (*Intelligent Tutoring Systems*, ITS) werden in der Didaktik schon länger diskutiert, sie wurden klassischerweise regelbasiert als Entscheidungsbäume aufgebaut, ähnlich einem Fortsetzungs-Kinderbuch (A la: "Wenn Du die Tür öffnen willst, lies weiter auf S.145"). Durch generative KI entstehen breitere Möglichkeiten der Interaktion, jedoch führt das "generative" Element auch etwas Unsicherheit in die Dialogsteuerung ein (Latif et al., 2026).

Wo der Mehrwert eines solchen Tutors liegt, zeigt die Harvard-Studie zum Physik-Tutor PS2 Pal (Kestin et al., 2025). Die Studierenden lernen **im eigenen Tempo**: Wer den Stoff schon kennt, kommt schneller durch die Aufgaben, wer mehr Zeit braucht, nimmt sie sich. Sie bekommen **Rückmeldung auf Abruf**: Während Lehrende in großen Veranstaltungen nur auf wenige Fragen eingehen können, antwortet der Tutor allen sofort und auf die konkrete Frage. Sie fühlten sich mit dem Tutor **stärker eingebunden und motivierter** als in der aktiven Präsenzstunde (*in-class active learning*). Und für die Lehrenden **verschiebt sich die Arbeit**: Die Einführung in die Grundlagen übernimmt der Tutor vor der Präsenzzeit, die Zeit im Hörsaal gehört anspruchsvolleren Aufgaben, das Einrichten des Tutors kostet dafür Vorarbeit (Kapitel 6.3.2). Eine Diagnose des Lernstands, etwa über typische Fehler, beschreibt die Studie dagegen nicht; individuell sind Tempo und Rückmeldung, nicht der Stoff. Allerdings behält die Lehrkraft jederzeit die Oberaufsicht, indem sie zum Beispiel relevante KI-Antworten stichprobenartig über-

prüft oder spezielle Fälle selbst übernimmt (z. B. wenn die KI Auskünfte gibt, die nicht zur jeweiligen Kursstruktur passen).

Dass ein Tutor sich darüber hinaus an den Gesprächsverlauf anpassen kann, zeigt ein Feldexperiment, in dem er diese Anpassung **selbst lernt**. Ein Prompt-Router, der aus vierzehn pädagogischen Merkmalen des Gesprächsverlaufs die Tutoring-Strategie wählt (eher analytisch oder eher gerüstbauend, *scaffolding*), schlug im A/B-Test (Zufallsvergleich zweier Varianten) mit 359 Oberstufenschülern statische Prompts bei gehaltener pädagogischer Qualität; die Variante, die zwischen Strategien streut, statt stur die beste zu wählen, hob die Quote begonnener Übungen von 19,6 auf 28,1 % (Chang et al., 2026). Zusammen mit dem Musterlösungs-Ansatz von Kestin et al. (2025) ergeben sich damit zwei komplementäre Stellschrauben: Musterlösungen kontrollieren den **Inhalt**, adaptives Prompt-Routing die **Strategie**.

Generell ist bei KI-Tutoren die **Gefahr von Fehlinformationen und Halluzinationen** zu beachten. Hierfür gibt es jedoch gute Gegenmaßnahmen, vor allem durch Kontrolle des Inputs und systematische Qualitätstests der LLM-Tools. Eine interessante Möglichkeit, die beim Physik-Tutor der Harvard Studie besprochen wird (Kestin et al., 2025), ist die **Bereitstellung von Musterlösungen als Input** (nicht nur der Fragen): Das Modell soll die Lösungswege nicht selbst erzeugen, damit Ungenauigkeiten, Halluzinationen und Inkonsistenzen gar nicht erst entstehen. Der Aufwand für die Erstaufsetzung steigt hier zwar, im Gegenzug sinkt die Qualitätsunsicherheit, die individuelle Anleitung durch ein Sprachmodell sonst begleitet. Insgesamt ist eine solche Durchsicht und intensive Qualitätskontrolle klar zu empfehlen (dieser Aspekt der intensiven Qualitätstests wird bei der Kurzvorstellung einiger deutscher Fallstudien in Wannemacher et al. (2025) vernachlässigt).

Ihre Einschätzung prüfen

„Ein KI-Tutor für Rechenaufgaben sollte die Musterlösungen als Vorgabe bekommen, statt die Lösungswege selbst zu erzeugen."
Auflösung: ja. Erzeugt das Modell die Lösungswege selbst, entstehen Ungenauigkeiten und Halluzinationen, die im Tutorgespräch überzeugend klingen. Der Physik-Tutor der Harvard-Studie bekam deshalb zu jeder Aufgabe eine ausführliche Musterlösung; das kostet mehr Aufwand beim Einrichten und senkt die Qualitätsunsicherheit. Systematische Tests vor dem Einsatz bleiben trotzdem nötig.

6.3.1 Beispiele für einfache Tutoren

Mollick & Mollick (2024) beschreiben eine Reihe allgemeiner Tutorenkonzepte: Der **"Integration Agent"** (Mollick & Mollick, 2024, S.31–33) fordert Studierende durch offene Fragen heraus, Verbindungen zwischen verschiedenen Kurskonzepten herzustellen, was vernetztes Denken fördert. Der **"Reflection Coach"** (Mollick & Mollick, 2024, S.30) regt zur Reflexion über Erfahrungen an, um das Gelernte zu konsolidieren. Der **"AI Tutor Blueprint"** (Mollick & Mollick, 2024, S.38–40) ermöglicht es Lehrenden, eigene, auf ihre spezifischen Themen zugeschnittene Tutoren-Prompts zu erstellen.

An deutschen Hochschulen unterstützt etwa **„LISA"** (Hochschule Hof) die Prüfungsvorbereitung mit Lernplänen, Übungsaufgaben und Feedback auf Basis hochgeladener Materialien (Wannemacher et al., 2025, Case 208); an der FernUniversität in Hagen gibt **„COFFEE"** kriterienbasiertes Feedback zu Freitextaufgaben und **„MIND"** Feedback zu Lernaktivitäten, das die Selbstreflexion fördern soll (Wannemacher et al., 2025, Case 61). Als Hürden nennen die Projekte die Bekanntmachung, den Implementierungsaufwand und den Datenschutz (Wannemacher et al., 2025).

Für all diese allgemeinen Tutoren gilt: Ihre Effektivität hängt von der Qualität des Prompts und der Fähigkeit der KI ab, die Tutor-Rolle konsistent und pädagogisch sinnvoll auszufüllen, was nicht immer gegeben ist und von Modell zu Modell variieren kann (Mollick & Mollick, 2024, S.36). Die KI kann oberflächlich bleiben oder halluzinieren (Mollick & Mollick, 2024, S.36).

Über solche einzeln erdachten Prompts hinaus gibt es inzwischen systematisches Gestaltungswissen. Banh et al. (2026) leiten aus Interviews, Literatur und einem erprobten Prototyp drei übergeordnete Anforderungen an GenAI-Lernagenten ab, Selbststeuerung, Kollaboration und Assessment (von lateinisch *assidēre*, „sich danebensetzen"), sowie neun Design-Prinzipien; die beiden Feedback-Prinzipien geben den Fällen COFFEE und MIND nachträglich eine theoretische Grundlage: Antworten weisen ihre Quelle im Lernmaterial aus, und Feedback benennt Stärken und macht Wissenslücken sichtbar, um die Selbstbewertung der Lernenden zu stützen. Die Wirksamkeit hat allerdings eine Grenze, die im Modell selbst liegt. Perczel et al. (2025) messen die dialogische Qualität heutiger Sprachmodelle an echten Eins-zu-eins-Tutorien und finden sie systematisch schwächer als die menschlicher Tutorinnen und Tutoren: Die Modelle lassen Lernenden nur 5 bis 15 Prozent der Redezeit statt rund 30, stellen drei bis vier Fragen auf einmal und drängen früh zur Lösung. Die Ursache ist

strukturell: Standard-Modelle sind darauf optimiert, als hilfreiche Assistenten Reibung zu minimieren, während gutes Unterrichten Reibung gezielt erzeugt. Prompt Engineering, das Feinschleifen der Anweisungen an das Modell, bleibt deshalb ein Notbehelf; erst das Nachtrainieren (*fine-tuning*) auf 100.000 Stunden echter Tutorien verdoppelte in der Studie die Redezeit der Lernenden. Für die Praxis schärft das den Vorbehalt dieses Abschnitts: Die Qualität eines GenAI-Tutors hängt am Prompt *und* am Modell, und die zuverlässigsten Gegenmaßnahmen liegen jenseits des Prompts, von Musterlösungen als Input bis zu systematischen Testläufen vor dem Einsatz.

Die Regel „Hinweise vor Lösungen“ hat inzwischen selbst eine Grenze bekommen. Der größte Anbieter eines Schul-Tutors hat nach einem zweijährigen Feldexperiment ohne messbaren Zusatzeffekt (Kapitel 4.5) öffentlich eingeräumt, dass ein Tutor, der neben der Aufgabe wartet, kaum angesprochen wird, und ihn umgebaut: in die Aufgabe hinein, keine Antwort vor dem ersten eigenen Versuch, aktives Eingreifen nach dem Fehler (Khan, 2026, Herstellerangabe). Was nach dem Fehler geschehen soll, zeigt eine Auswertung von 20.462 Tutor-Beiträgen in Sackgassen-Situationen (*impasses*): Bei festgefahrenen Lernenden hilft jede weitere Rückfrage weniger, das Benennen des Fehlers mehr (Ahtisham et al., 2026). Ein Tutor, der sein Gerüst kontingent eskaliert und abbaut, also mehr hilft, wenn die Person stockt, und weniger, sobald sie trägt, schlägt im Vergleich beide starren Varianten, den Lösungsgeber wie den Dauerfrager (Hou et al., 2026). Die Gestaltungsregel für KI-Tutoren lautet deshalb: Hinweise vor Lösungen, aber mit Eskalation bei Sackgassen, und ohne die Erwartung, dass der Prompt sie allein durchsetzt (Kapitel 4.5).

Sprachen lernen und Gespräche üben lässt sich mit dem Sprachmodus der großen Chat-Anwendungen: Die KI spricht über ein beliebiges Thema in einer beliebigen Sprache und gibt etwa Feedback auf eine englische Präsentation (Jurran, 2025). Für den Sprachunterricht an Hochschulen empfiehlt Tutton & Cohen (2025), Stärken und Schwächen solcher Werkzeuge gemeinsam mit den Studierenden zu erproben und den Unterricht so anzulegen, dass sich KI und Präsenzlehre ergänzen.

i Stand bei Drucklegung, November 2026: Tutor-Angebote der Anbieter

Welche Tutor-Funktionen die großen Anbieter bei Drucklegung in ihren Bildungsprodukten boten, als historischer Schnappschuss; alle Angaben stammen von den Anbietern selbst. Die Online-Seite „Forschungsstand“ führt die Liste fort.

- **OpenAI:** quellengebundener Tutor für Studierende als Erweiterung in ChatGPT Edu, der aus den freigegebenen Kursmaterialien antwortet (OpenAI, 2026b); ein „Learning Lab“ für Studien mit Hochschulen, das die Evidenzlage zu den eigenen Produkten verbessern soll (Devani & Leiva, 2026); die eigene Studie zum Lernmodus fand einen Gewinn in Mikroökonomie und keinen in Neurowissenschaft (OpenAI, 2026a).
- **Google:** Gemini im Google Classroom für alle Altersstufen mit kursbezogenen Startprompts (Google Workspace Updates, 2026a); die bisher für Tutoren genutzten „Gems“ werden im Bildungsbereich frühestens zum 1. Juni 2027 abgeschaltet und durch Skills und Guided Learning ersetzt (Google Workspace Updates, 2026b), ein Beispiel dafür, warum Tutoren nicht an ein einzelnes Produktmerkmal gebunden sein sollten.
- **Anthropic:** ein Lernmodus, der Hinweise vor Lösungen setzt, und seit Juli 2026 ein Angebot für Lehrende mit Vorlagen für Rückmeldung und Kursmaterial (Anthropic, 2026).
- **Khan Academy:** Umbau von Khanmigo nach dem zweijährigen Feldexperiment ohne messbaren Zusatzeffekt: Tutor in der Aufgabe, keine Antwort vor dem ersten Versuch, Eingreifen nach dem Fehler (Khan, 2026; Oreopoulos & Low, 2026).

6.3.2 Komplexer Physik Tutor mit Musterlösungen

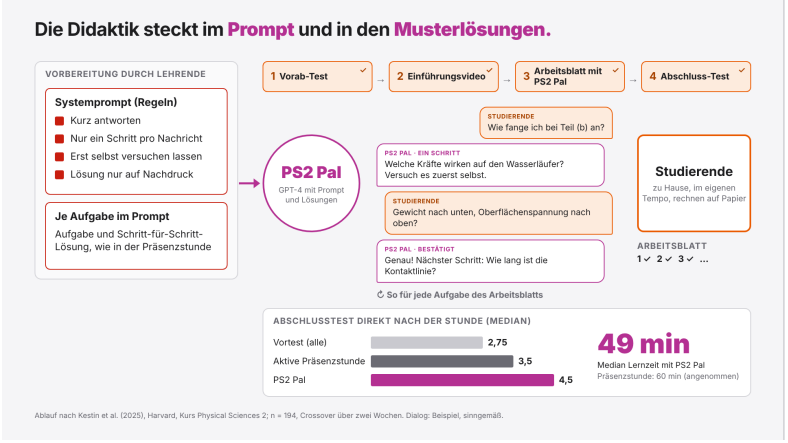
Wie ein solcher Tutor im Kurs arbeitet, zeigt der Physik-Tutor **„PS2 Pal“** der Harvard University (Kestin et al., 2025), dessen Evaluation Kapitel 4.5 einordnet. Im Einführungskurs Physical Sciences 2 arbeiten die Studierenden in jeder Stunde eine Folge von Aufgaben durch, sonst in Kleingruppen im Hörsaal, im Experiment allein mit dem Tutor; die beiden untersuchten Stunden behandelten Oberflächenspannung und Strömungen. Der Tutor kennt die

Musterlösungen, beantwortet Fragen, gibt bei Bedarf Hinweise und bestätigt richtige Lösungsschritte, ohne die komplette Lösung vorwegzunehmen.

Technisch ist PS2 Pal schlicht. Es nutzt GPT-4 mit einem System-Prompt (dauerhafte Grundanweisung), der die Didaktik festlegt: die Studierenden aktiv halten, die kognitive Belastung (*cognitive load*) dosieren und ein Wachstumsdenken (*growth mindset*) fördern. Zu jeder Aufgabe enthält der Prompt eine ausführliche Schritt-für-Schritt-Lösung; sie soll verhindern, dass das Modell falsche Lösungswege erfindet. Weil der Prompt allein mehrteilige Aufgaben nicht verlässlich portionierte, führt die Plattform selbst von Teilaufgabe zu Teilaufgabe. Von einer automatischen Anpassung des Schwierigkeitsgrads berichtet die Studie nichts; individuell sind das Tempo und die Rückmeldung auf die Fragen der Studierenden. Sie arbeiten zu Hause: Vorab-Test, kurzes Einführungsvideo, Aufgaben mit dem Tutor, Abschluss-Test. Im Crossover-Experiment (beide Gruppen durchliefen beide Formate) mit 194 Studierenden lag der Median im Abschlusstest bei 4,5 gegenüber 3,5 nach der aktiven Präsenzstunde, bei einem gemeinsamen Ausgangswert von 2,75; der Lernzuwachs war damit mehr als doppelt so hoch. Die Studierenden brauchten im Median 49 Minuten, für die Präsenzstunde setzt die Studie 60 Minuten an. Gemessen wurde direkt nach der Stunde; ob der Vorsprung anhält, lässt die Studie offen (Kestin et al., 2025).

6.3.3 Vom Prototyp zum Betrieb: Tutoren mit eigenen Quellen

Die bisher gezeigten Tutoren sind Prompts in einem Chat-Interface. Ein Tutor, der einen ganzen Kurs über ein Semester begleiten soll, braucht mehr: eine **Wissensbasis** aus den eigenen Kursmaterialien, damit er aus dem Skript antwortet statt aus dem Netz (das Verfahren dahinter heißt Retrieval-Augmented Generation); eine **Dialogschicht**, die Fragen entgegennimmt und die Antwort an die Studierenden zurückgibt; **Leitplanken**, die bei offensichtlichen Prüfungsfragen auf Lernmaterial verweisen statt zu lösen; und ein **Gedächtnis** über Sitzungen hinweg, damit der Tutor weiß, was eine Person zuletzt geübt hat und Wiederholungsfragen zum passenden Zeitpunkt stellen kann (verteiltes Üben, Kapitel 4.4). Alle großen Cloud-Anbieter stellen diese vier Bausteine inzwischen als konfigurierbare Dienste bereit, so dass ein erster Tutor mit den eigenen Skripten an einem Nachmittag steht; Referenzarchitekturen für Hochschulen beschreibt zum Beispiel Amazon Web Services (AWS) für seine Dienste Bedrock, Lex und AgentCore (Amazon Web Services, 2025b, 2025a). Der BWL-Tutor



Video online

Laufzeit 44 s

Abbildung 6.7. Ablauf des Physik-Tutors PS2 Pal nach Kestin et al. (2025): Lehrende legen Regeln und Musterlösungen im Prompt fest, Studierende arbeiten zu Hause Schritt für Schritt mit dem Tutor. Schlussbild eines Videos (44 s); der Dialog ist ein sinngemäßes Beispiel. Das Video gibt es nur in der Online-Version: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/kapitel06-rollen.html#vid-ps2pal-ablauf aufrufen.

aus der Kapiteleinleitung läuft als Web-Anwendung in einer solchen Cloud-Umgebung. Die Kosten eines Pilotbetriebs mit einem Kurs liegen bei kleinen Modellen im niedrigen zweistelligen Eurobereich pro Monat; die eigentliche Investition ist organisatorisch: digital vorliegende Materialien, ein didaktisch durchdachter System-Prompt, ein Datenschutzkonzept für studierendenbezogene Daten und ein Testplan, bevor Studierende den Tutor sehen. Wie das in konkreten Modulen gelaufen ist, zeigen die Fallbeispiele in Kapitel 7.

Drei Betriebserfahrungen aus dem Jahr 2026 zeigen, woran ein solcher Tutor im Semester scheitert oder gelingt, und keine davon liegt in der Technik. An der University of Maryland lief genau diese Architektur, ein Tutor über die Kursmaterialien im Lernmanagementsystem, in den Kursen von 30 Lehrenden; nur 15 Prozent der berechtigten Studierenden nutzten ihn, drei Viertel ihrer Anfragen verlangten eine fertige Antwort, und die Noten der Berechtigten sanken (Kapitel 4.5). Der Grund war der Standardmodus: Die Lehrenden hatten den Tutor überwiegend als Antwortmaschine konfiguriert, und wer ihn nutzte, ersetzte damit das eigene Arbeiten am Material (Liu et al., 2026). Das deutsche Gegenstück ist ein sokratisch gebauter Tutor mit eigenen Quellen auf einem lokal betriebenen offenen Modell an der Hochschule Rhein-Waal: Nach einem Semester mit 62 Studierenden war die Bereitschaft, Fragen zu stellen, gestiegen, die Neugier auf das Warum gesunken; die Studierenden nutzten auch den sokratisch gebauten Tutor als Antwortmaschine, sobald er es zuließ (Gerber et al., 2026). Dass es anders geht, zeigt ein Assistent mit eigenen Quellen in einem Planspiel zum Operations Management: 61 Prozent der Teams nutzten ihn, seine Antworten waren zu 90 bis 95 Prozent korrekt, und ein Zusammenhang zwischen Nutzung und Note fehlte, weil die Nutzung über Teamvertreter lief und der Assistent die Regeln des Spiels erklärte statt die Entscheidungen zu treffen (Tani et al., 2026). Die drei Fälle messen am selben Maßstab: Entscheidend ist nicht, ob der Tutor aus den eigenen Quellen antwortet, sondern was die Lehrenden als Standardverhalten eingestellt haben und welche Operationen er den Lernenden abnimmt.

i Anwendungsbeispiel: Ein Tutor-Bot liefert Lösungen, statt das Lernen zu begleiten

Problem ohne KI. In einer großen Grundlagenvorlesung erreichen Lehrende die Fragen der einzelnen Studierenden kaum.
Problem mit KI. Ein Chatbot, der als Experte auftritt, liefert fertige Lö-

sungen und nimmt den Studierenden das Lernen ab.
Der Lösungsansatz. An der Universität Kiel hat Jan Steinkühler die Entwicklung des Tutors selbst zur Lernaufgabe gemacht. Masterstudierende betreiben ihn lokal mit OpenWebUI, schreiben den System-Prompt, binden die Lernmaterialien per RAG ein und vergleichen verschiedene Modelle darauf, welche Antworten tatsächlich tutoriell helfen. Der Tutor soll schrittweise begleiten, Reflexion und Transfer anregen und keine Lösungen liefern; eingesetzt wird er in der Bachelorvorlesung Grundlagen der Elektrotechnik I. Aus den anonym protokollierten Chats lassen sich die häufigsten Fragen ablesen und in der nächsten Vorlesung aufgreifen.
Was das für wirksames Lernen heißt. *Erfahrungsbericht; eine systematische Evaluation ist angekündigt.* Die Gestaltung setzt dort an, wo der Tutor in Maryland scheiterte: am Standardmodus als Antwortmaschine (Liu et al., 2026). Ob die Leitplanken halten, sollen künftig die Studierenden mitbewerten: Was hilft wirklich weiter, wo bleibt der Tutor zu allgemein? Einen verwandten Ansatz aus der eigenen Lehre beschreibt Kapitel 7.2.2.
Quelle: Tobor et al. (2026), S. 34–35.



Offen bleibt bei alledem, wer den Tutor im Hörsaal steuert. Eine Design-Studie aus dem Labor von Vincent Aleven zu ko-orchestrierter Lehre (*co-orchestration*), in der die KI vorschlägt, wann Lernende zwischen Einzel- und Partnerarbeit wechseln, zeigt, dass Lehrendenkontrolle und studentische Agency (Entscheidungsspielraum der Studierenden) **kein einzelner Schieberegler** sind, sondern phasenweise variieren: Lehrende wollen ein Echtzeit-Vetorecht beim Wechsel selbst, akzeptieren aber Systemvorschläge für dessen Timing; Studierende wollen Mitsprache bei der Partnerwahl, erwarten die finale Autorität aber bei den Lehrenden (K. B. Yang et al., 2026). Orchestrierungswerkzeuge, die einen einzigen Autonomiewert festlegen, werden deshalb beiden Seiten nicht gerecht.

Einen Tutor vor der Freigabe testen: das Überhilfe-Audit

Sprachmodelle helfen zu früh und zu viel. Suhyeon Lee et al. (2026) ordneten 14.637 Antworten von KI-Tutoren je einer von vier Stufen zu, Frage, Hinweis, Erklären oder Lösen, und fanden über 95 Prozent auf den Stufen Erklären oder Lösen; ein Benchmark kommt zum selben Befund (Teo et al., 2026). Beide Arbeiten sind Preprints und messen das Verhalten der Modelle, nicht das Lernen. Ob ein eigener Tutor so arbeitet, zeigt ein Test von 35 Minuten zu dritt: Eine Person spielt die Studierenden, zwei bewerten getrennt.

1. **Mini-Goldstandard.** Drei gespielte Studierendentypen (unsicher; solide und will prüfen; „Gib mir einfach die Lösung“) mal zwei Aufgaben aus dem eigenen Fach, je mit dem erwarteten Verhalten, dazu eine Frage außerhalb des Stoffs: sieben Testfälle.
2. **Audit.** Beide Bewertenden ordnen jede Antwort einer Hilfestufe zu und vergleichen. Erwartet sind Frage oder Hinweis; bei der Frage außerhalb des Stoffs sagt der Tutor, dass er es nicht weiß.
3. **Testplan.** Dieselben sieben Fälle laufen nach jeder Änderung am Prompt erneut, wie ein TÜV-Termin nach jeder Reparatur.

Der Prompt ist dabei nur eine Prüfschicht von mehreren. Wie im Schweizer-Käse-Modell der Sicherheitsforschung hat jede Schicht Löcher an anderer Stelle (Reason, 2000): Ein Skript prüft mechanisch, ob die Antwort die Endzahl verrät, der Goldstandard fängt die fachlichen Fehler. Bauen Studierende selbst einen Tutor, geben sie drei Versionen ab, ein Änderungsprotokoll, das zu jeder Version sagt, welche Regel warum geändert wurde, und das Testprotokoll gegen den Goldstandard.

Der 4D-Kreislauf beim Tutor. Der Tutor wird einmal eingerichtet und dann von anderen genutzt; der Kreislauf hängt deshalb an der Beschreibung seines Verhaltens und an der Sorgfalt beim Einsatz, und er hat zwei Adressaten. *Delegation* betrifft die Studierenden: Was frage ich den Tutor, was löse ich selbst? Ermutigung allein ändert wenig, eine Anleitung zur tutoriellen Nutzung hob in einem Ökonometrie-Kurs die Prüfungsleistung (Gallegos, 2026). *Description* ist Sache der Lehrenden: Musterlösungen als Input (Kapitel 6.3.2) und ein Verhalten, das Lösungen zurückhält. Unterschiedliche didaktische System-Prompts änderten in einem großen Experiment nichts am Lernergebnis (Barth et al., 2026); die Zurückhaltung gehört deshalb zu-

sätzlich in eine Aufsichtsinstanz (*supervisor*), die jede Antwort vor dem Versand prüft (Pisan, 2026). *Discernment:* Vor der Freigabe muss der Tutor an einem Goldstandard bestehen, an von Fachleuten geprüften Musterantworten. *Diligence:* Wer Studierenden einen Tutor bereitstellt, ist Betreiber im Sinn der KI-Verordnung (Wissenschaftsrat, 2026) (Kapitel 5.4.1.2), und der Tutor wirkt nur so gut, wie er in den Kurs eingebettet ist (Kapitel 4.5). Ohne diese Einbettung sollte der Tutor nicht an Studierende gehen.

6.4 KI als Simulator

Hier erstellt die KI interaktive Umgebungen für praxisnahes Training. In einfachen Rollenspielen simuliert das Sprachmodell ein Gegenüber, um z. B. Analyse- oder Verhaltensmuster einzuüben. Was generative KI dem Rollenspiel hinzufügt, lässt sich an sechs Stellen festmachen. Sie spielt ein Gegenüber, das konsistent genug bleibt, um Druck und Entscheidungslagen zu erzeugen, etwa im Bewerbungsgespräch (Nofal et al., 2025); sie passt ihre Hinweise dem Vorwissen und dem Spielverlauf an (Goslen et al., 2025); sie spricht die Zielsprache und senkt die Sprechangst (Sangmin Lee et al., 2025); sie erzeugt mit wenigen Änderungen am Prompt neue Fallvarianten mit gesteuerter Schwierigkeit (Mollick & Mollick, 2024); sie gibt bereitgestellte Quellen verlässlich wieder (Huffman & Hutson, 2024); und sie macht Szenen mit Stimme, Bild und Klang plastischer. Jede dieser Stärken hat eine Kehrseite, die Kapitel 6.4.3 prüft.

Mollick & Mollick (2024) unterscheiden dabei **Role Play** (Rollenspiele) und **Goal Play** (zielgerichtete Spiele).

6.4.1 Role Play

Rollenspiel-Simulationen lassen Studierende eine fremde Rolle einnehmen und risikofrei üben, etwa Verhandlungen, Mitarbeitergespräche oder Zeugenbefragungen; die KI spielt das Gegenüber. Rechtsreferendarinnen und -referendare üben die Zeugenbefragung im Rollenspiel mit Brillen für virtuelle Realität (VR) (Heetkamp, 2023), an der Wharton School trainiert der Simulator **„Pitch Quest“** Venture-Capital-Pitches (Kurzpräsentationen vor Investoren) mit mehreren KI-Agenten als Mentor, Investor und Bewerter (Mollick et al., 2024, S.5–10). Die Grenzen sind bei allen Formaten ähnlich: Die KI hält ihre Rolle nicht immer konsistent, neigt zu Bias (Verzerrungen)

und Halluzinationen, und Konfiguration und Entwicklung kosten Aufwand (Mollick et al., 2024, S.2–3; Wannemacher et al., 2025). Sprachmodi, die mit Stimme statt Text arbeiten, machen solche Simulationen realistischer (Barra et al., 2024).

i Anwendungsbeispiel: Im Rollenspiel üben wenige Studierende, der Rest schaut zu

Problem ohne KI. Im klassischen Rollenspiel üben nur zwei bis vier Studierende aktiv, die anderen beobachten. Beobachtung und Bewertung erzeugen Rollenstress und dämpfen die Lust am Ausprobieren, und manche Rollen liegen weit von der Lebenswelt der Studierenden entfernt.
Problem mit KI. Eine KI-Persona kann jedes Gegenüber spielen, verfällt aber in Argumentationsschleifen und überzeichnet Skepsis und Eskalation.
Der Lösungsansatz. Michael Barton (Universität Leipzig) macht in einer Übung zur Personal- und Organisationsökonomik im BWL-Master die Prinzipal-Agent-Theorie erfahrbar. Die Studierenden spielen die Führungskraft, die einen erfahrenen Mitarbeiter über 50 von einer Schulung zur Digitalisierung überzeugen soll; die KI spielt den skeptischen Mitarbeiter, samt Hinweisen auf Mimik und Gestik. Ein rund zweiseitiger System-Prompt regelt Rolle, Gesprächsphasen, Schwierigkeit und das Feedback am Ende, eine Info-Karte gibt den Studierenden den Rahmen. Ein Durchlauf dauert fünf bis zehn Minuten und lässt sich wiederholen; danach reflektieren die Studierenden das Gespräch in einem Fragebogen.
Was das für wirksames Lernen heißt. *Erfahrungsbericht mit offener Befragung (Wintersemester 2024/25: 17, 2025/26: 9 Studierende).* Alle Studierenden rücken von der passiven Beobachtung in die interaktive Übung, die nach dem ICAP-Modell (interaktiv vor konstruktiv, aktiv und passiv) am stärksten wirkt (Chi et al., 2018). Die Befragten lobten Realitätsnähe und überwiegend hilfreiches Feedback; die genannten Grenzen zeigen, dass der Prompt laufend überarbeitet werden muss und eine abschließende Reflexion der Methode dazugehört (Barton, 2026).
Prompt zum Nachnutzen über den QR-Code. Quelle: Barton (2026); Tobor et al. (2026), S. 40–42.



6.4.2 Goal Play – zielgerichtete Spiele

In **zielgerichteten Spielen** ("Goal Play", Mollick & Mollick (2024)) bleiben Studierende in ihrer normalen Rolle und wenden in einer Situation bestimmtes Wissen oder theoretische Konzepte an (z. B. Zielsetzung, Selbst-Distanzierung oder Analyseraster wie Transaktionskostenanalyse), indem sie einen KI-Charakter anleiten. Wichtig dabei: Die Studierenden wissen etwas, das das KI-Gegenüber im Spiel nicht weiß.

So nehmen etwa bei dem einfachen Rollenspiel **"Teach the AI"** (Mollick & Mollick, 2024, S.21–23) Studierende die Rolle des Lehrenden ein und erklären der KI (die einen unwissenden Studenten spielt) ein Konzept. Der Mehrwert liegt im vertieften Lernen durch Lehren (Protégé-Effekt) und dem Aufdecken eigener Wissenslücken. Als Herausforderung kann die KI manchmal vom Thema abweichen oder Fragen stellen, die die Studierenden an ihre Grenzen bringen; zudem ist die Simulation eines "Novizen" durch die KI nur begrenzt realistisch (Mollick & Mollick, 2024, S.24).

Ein Rollenspiel bauen: klein anfangen, klarer Ablauf

Gestuft einsteigen. Am Anfang steht ein vorbereiteter, klar gerahmter Chat mit Rollenprompt, Lernziel und Reflexionsfragen. Im zweiten Schritt entwerfen Studierende in Präsenz selbst kleine Rollenspiele und testen sie gegenseitig; Lehrende stellen Zielkriterien, Rollenbriefe und ein Feedback-Raster bereit. Erst danach bauen Teams über mehrere Wochen komplexe Simulationen, mit Testprotokoll und dokumentierten Änderungen (Mollick et al., 2024; Mollick & Mollick, 2024).
Ablauf einer Runde (nach Mollick et al., 2024):

1. Ein KI-Mentor begrüßt, erhebt Erfahrung und Kontext und passt die Schwierigkeit an.
2. Die KI bietet mehrere Szenarien zur Zielkompetenz an und setzt

die Bühne: Rollen, Ziele, Konflikt.
3. Gespielt wird in abgegrenzten Zügen; die KI gibt sparsame Hinweise.
4. Gegen Ende verlangt die Szene eine folgenschwere Entscheidung, damit das Gelernte angewendet wird.
5. Die KI gibt zielbezogenes Feedback mit Stärken und Entwicklungsfeldern; das Debriefing in der Gruppe führen die Lehrenden.

Vor dem Einsatz testen. Testläufe prüfen, ob die Figur konsistent bleibt, die Schritte einhält, bei Grenzfällen nicht aus der Rolle fällt und Schwierigkeitsstufen trennt. Gezielte Angriffstests (*red teaming*) suchen nach Bias und nach einem Erzählfaden, der sich vom Lernziel entfernt.

6.4.3 Wie echt ist das Gegenüber?

Ein Rollenspiel übt nur, was das simulierte Gegenüber glaubhaft vorgibt. Wie weit Sprachmodelle Menschen tatsächlich nachbilden, prüfen seit 2026 Studien aus der Nutzer- und Umfrageforschung, die Sprachmodelle als Ersatz für Befragte (*synthetic participants*) einsetzen; in der Lehre ist keine von ihnen entstanden, ihr Befund lässt sich aber auf Rollenspiele übertragen. In zwölf Klicktests aus der Praxis der Nutzerforschung mit 3.431 Teilnehmenden sollte GPT vorhersagen, wohin Menschen auf einer Bildschirmseite zuerst klicken und warum; in 53 % der Aufgaben wich die Verteilung der simulierten Klicks deutlich von der echten ab. Ausführliche Personas, schrittweises Nachdenken des Modells und andere Zufallseinstellungen änderten daran wenig, sie machten die Antworten nur glaubwürdiger (Kuric et al., 2026). Woran das liegt, zeigt eine Auswertung von vier Datensätzen mit über 400.000 Befragten und über 6.000 Fragen. Im Mittel treffen die Modelle die menschlichen Antworten gut. Wie eine bestimmte Person vom Mittel abweicht, erklären sie aber nur zu 3 %, obwohl die Wiederholungsbefragung derselben Menschen zeigt, dass 54 % dieser Abweichung stabil und damit vorhersagbar wären. Reichere Personabeschreibungen und Nachtraining schließen die Lücke nicht, und die simulierten Antworten streuen weniger als die echten (Ahn et al., 2026).

Für ein Rollenspiel heißt das: Die KI spielt verlässlich den typischen Kunden, die typische Patientin, den typischen skeptischen Mitarbeiter. Den ei-

genwilligen Einzelfall, an dem Gesprächsführung erst schwierig wird, spielt sie schlechter, und dass sie dabei überzeugend klingt, belegt keinen Realismus. Lehrende sagen den Studierenden deshalb, dass sie mit einem Durchschnitt üben, und fragen in der Nachbesprechung, wie ein echtes Gegenüber anders hätte reagieren können.

Gut trainieren kann ein Simulator trotzdem, wenn die Rollen sauber getrennt sind. In einem randomisierten Experiment mit 100 Medizinstudierenden in China übte die Versuchsgruppe Anamnesegespräche mit drei Agenten: einem Patienten, einem Tutor, der mit sokratischen Fragen zu Anamnese, klinischem Denken und Empathie anregte, ohne die Diagnose zu verraten, und einem Bewerter, der den Fortschritt verfolgte, ohne Punkte zu zeigen. Die Kontrollgruppe arbeitete die Fälle ohne Sprachmodell durch, mit schrittweise freigegebenen Informationen. In der Abschlussprüfung, einem Gespräch mit dem Patienten-Agenten allein, erreichte die Agentengruppe 71,8 % der Punkte gegenüber 55,6 %; den größten Vorsprung hatte sie in der Gesprächsführung, beim Ausdruck von Empathie lag sie 31 Prozentpunkte vorn. Die richtige Diagnose stellten beide Gruppen gleich oft (84 gegenüber 86 %) (L. Yang et al., 2026). Der Simulator trainiert also, was im Gespräch geübt wird, nicht das Fachwissen dahinter. Sein Bauprinzip kennt schon Pitch Quest: Wer spielt, lehrt nicht, und wer lehrt, bewertet nicht.

Für Role Play wie Goal Play gilt: Die KI kann von der Rolle abweichen oder inkonsistent agieren, und die Qualität der Erfahrung kann variieren. Eine **sorgfältige Einbettung und Reflexion** durch Lehrende ist entscheidend (Mollick & Mollick, 2024). Bei allen Simulatoren ist die Notwendigkeit einer klaren didaktischen Rahmung und eines Debriefings (Nachbesprechung) durch Lehrende (Mensch in der Schleife, *human in the loop*) zentral, um den Lernerfolg zu sichern und die Grenzen sowie potenzielle Fehler der KI zu reflektieren (Mollick & Mollick, 2024, S.16).

Der Simulator dieses Abschnitts ist ein Sprachmodell, das eine Rolle spielt, und deshalb nie ganz vorhersagbar. Für Zusammenhänge, die sich berechnen lassen, etwa Warteschlangen oder den Bullwhip-Effekt in einer Lieferkette, ist ein rechnendes Widget das verlässlichere Übungsfeld; zwei Beispiele und eine Prüfliste stehen am Ende von Kapitel 6.2.2. Auch dort entscheidet die Nachbesprechung, was gelernt wird.

Der 4D-Kreislauf beim Simulator. Beim Simulator hängt der Kreislauf an der Beschreibung der Figur und an der Prüfung, wie echt sie ist. *Delegation:* Welche Übung verträgt ein simuliertes Gegenüber, und welche braucht

Menschen? *Description:* Rolle, Wissensstand und Verhalten der Figur festlegen und die Rollen trennen; mit getrennten Agenten für Patient, Tutor und Bewertung übten Medizinstudierende Gesprächsführung wirksamer als die Kontrollgruppe (L. Yang et al., 2026). *Discernment:* Vor dem Einsatz prüfen, ob die Figur mehr als den Durchschnitt spielt, denn Sprachmodelle treffen das mittlere Verhalten von Menschen, nicht den Einzelfall (Ahn et al., 2026; Kuric et al., 2026). *Diligence:* Den Studierenden sagen, dass sie mit einem simulierten Durchschnitt üben, und das Debriefing selbst führen (Mollick & Mollick, 2024). Was die Prüfung der Echtheit nicht trägt, wird nicht als Übungsgegenüber delegiert.

Kernaussagen

Zu Lernziel 1: Rollen und Aufgaben

1. Vier Rollen ordnen die Praxis: Als Hiwi nimmt die KI Arbeit ab, als Copilot ermöglicht sie, was wir allein nicht könnten, als Tutor begleitet sie Lernende, als Simulator stellt sie Übungssituationen bereit.
2. Technik ersetzt Tätigkeiten, nicht Berufe. In der Lehre automatisiert KI vor allem Standardisiertes, unterstützt bei Kernaufgaben und schafft neue Aufgaben wie Qualitätskontrolle und Kursdesign. Ob am Ende Zeit gespart wird, ist offen.

Zu Lernziel 2: Recherchewerkzeuge

3. Bei der Literaturrecherche entscheidet nicht der Markenname, sondern das Muster: einmalige Suche oder iterativer Prozess, Trefferliste oder zusammenfassende Analyse.

Zu Lernziel 3: Schreiben, Programmieren, Simulationen bauen

4. Schreiben und Programmieren mit KI sind Cyborg-Tätigkeiten. Der Lernwert hängt davon ab, wie viel die Studierenden selbst verstehen und verantworten müssen. Wer eine Simulation von KI bauen lässt, prüft das Modell, nicht das Bild. Programmier-Agenten liefern schneller fertigen Code und weniger Verständnis; wo der Code Lernziel ist, gehören Prüfschritte in die Aufgabe.

Zu Lernziel 4: Tutor und Simulator

5. Ein guter KI-Tutor lässt Lernende im eigenen Tempo arbeiten, gibt sofort Rückmeldung, hält sie aktiv und verschiebt die Arbeit der Lehrenden von der Einführung zur Vertiefung. Er braucht Musterlösungen als Input und systematische Qualitätstests, sonst produziert er überzeugende Fehler.
6. Simulationen wirken, wenn Lehrende sie rahmen und nachbesprechen. Ein simuliertes Gegenüber trifft den typischen Fall, nicht den Einzelfall, und kann aus der Rolle fallen; der Mensch bleibt in der Schleife.

Schlüsselbegriffe

Erklären Sie jeden Begriff in zwei, drei Sätzen in eigenen Worten; die Seitenzahl führt zur Stelle, an der er eingeführt wird.

- Automatisierung (*automation*) ..... S. 84
- Augmentierung (*labor-augmenting technology*) ..... S. 84
- Neue Aufgaben (*new tasks*) ..... S. 84
- Deep Search ..... S. 184
- Deep Research ..... S. 185
- Programmier-Agent (*coding agent*) ..... S. 199
- Co-Orchestrierung (*co-orchestration*) ..... S. 219
- Role Play (Rollenspiel) ..... S. 221
- Goal Play (zielgerichtetes Spiel) ..... S. 223
- Protégé-Effekt (*protégé effect*) ..... S. 223
- Debriefing (Nachbesprechung) ..... S. 225

Übung. Tragen Sie zu jeder Szene den passenden Begriff aus der Liste ein. Lösungen: Anhang B.

Nr.	Szene	Begriff
1	Die Rückmeldetexte zu den Einsendungen eines wöchentlichen Online-Quiz schrieb bisher eine studentische Hilfskraft; jetzt erzeugt sie ein Skript mit Sprachmodell, und die Hilfskraft ist dafür nicht mehr eingeplant. *Herkunft: konstruiert nach dem Aufgabenmodell in Tabelle 3.1.*	

2 Vor dem Semester verbringt ein Dozent zwei Tage damit, den Tutor-Bot mit typischen Fragen aus früheren Sprechstunden zu testen und die Antworten gegen seine Musterlösungen zu prüfen. In seinem Stundenbudget kam diese Arbeit bisher nicht vor.
Herkunft: konstruiert nach Tabelle 3.1 und dem Prüfkriterium in Kapitel 7.2.2.

3 Für den Literaturteil ihrer Projektarbeit lässt eine Gruppe ein Werkzeug eine halbe Stunde lang suchen und bekommt einen zwölfseitigen Text mit Fußnoten zurück. Welcher Typ von Suchhelfer ist das?
Herkunft: konstruiert nach Tabelle 6.1.

4 Im Simulationsprojekt beauftragt ein Team ein Werkzeug in einem Satz, das Lagermodell um eine zweite Lieferstufe zu erweitern. Es ändert vier Dateien, lässt die Tests laufen und meldet, dass alle bestehen.
Herkunft: konstruiert nach Kapitel 6.2.2 und dem Gruppenprojekt in Kapitel 7.3.3.

5 Im Einkaufsseminar beraten Studierende eine KI-Figur, einen Jungunternehmer, der nicht weiß, ob er ein Bauteil selbst fertigen oder zukaufen soll; sie bleiben dabei sie selbst und müssen die Transaktionskostenanalyse anwenden. Welche Form der Simulation ist das?
Herkunft: konstruiert nach Kapitel 6.4.2.

6 Nach der KI-Verhandlungssimulation fragt die Dozentin im Plenum, an welcher Stelle der simulierte Lieferant zu schnell nachgegeben hat und wie ein echter Verkaufsleiter reagiert hätte. Wie heißt dieser Schritt?
Herkunft: konstruiert nach Kapitel 6.4.3 und Kapitel 7.3.2.

Wiederholung aus früheren Kapiteln. *Erklären Sie diese Begriffe noch einmal in eigenen Worten, bevor Sie nachschlagen.*

- Leitplanke (*guardrail*) ..... S. 21
- Prompt als Werkvertrag ..... S. 49
- Gemischtes Üben (*interleaving*) ..... S. 106

Lernfragen

Wiederholen

1. Nennen Sie die vier Rollen und je eine typische Anwendung.
2. Was bezeichnen Automatisierung, Augmentierung und neue Aufgaben? Nennen Sie je ein Beispiel aus der Lehre.
3. Nach welchen zwei Fragen ordnet das Kapitel Recherchewerkzeuge, und welche vier Typen ergeben sich daraus?
4. Was unterscheidet Role Play von Goal Play?

Anwenden

5. Nehmen Sie Ihre eigene Aufgabenliste einer typischen Semesterwoche und sortieren Sie jede Aufgabe nach Automatisierung, Augmentierung oder neuer Aufgabe. Welche neue Aufgabe kommt bei Ihnen dazu, die Sie heute noch nicht einplanen?
6. Entwerfen Sie aus dem Gedächtnis einen Tutor-Prompt für ein Konzept Ihres Fachs. Welche drei didaktischen Bremsen bauen Sie ein, und woher bekommt der Tutor seine Musterlösungen?
7. Welche Berufssituation Ihrer Absolventinnen und Absolventen eignet sich für ein Role Play, welche für ein Goal Play? Was muss im Debriefing unbedingt zur Sprache kommen?

Beurteilen

8. Ob KI Lehrenden am Ende Zeit spart, bleibt nach diesem Kapitel offen. Welche neuen Aufgaben machen Sie skeptisch, und unter welcher Bedingung würden Sie trotzdem netto Zeit gewinnen?

Lösungshinweise: Anhang B.

Literaturverzeichnis

Ahn, D., Mao, C., & Lee, D. (2026). *Item-mean surrogates: Why richer persona data fail to improve LLMs as human surrogates*. https://doi.org/10.48550/arXiv.2608.29455.

Ahtisham, B., Vanacore, K., Napoli, A., Arens, J., Ionova, K., Cohn, C., Salehi, S., & Kizilcec, R. (2026). *Examining variation in how guided AI tutors resolve student impasses*. https://doi.org/10.48550/arXiv.2609.38346.

Amazon Web Services (2025a). Build a personalized student companion powered by generative AI on Amazon Bedrock. *AWS Public Sector Blog*. https://aws.amazon.com/blogs/publicsector/build-a-personalized-student-companion-powered-by-generative-ai-on-amazon-bedrock/.

Amazon Web Services (2025b). Revolutionizing higher education: How Amazon Bedrock AgentCore enables production-ready AI at scale. *AWS Public Sector Blog*. https://aws.amazon.com/blogs/publicsector/revolutionizing-higher-education-how-amazon-bedrock-agentcore-enables-production-ready-ai-at-scale/.

Anthropic (2026, Juli). *Introducing Claude for Teachers*. https://www.anthropic.com/news/claude-for-teachers.

Balepur, N., Baumler, C., Chen, V., Choi, E., Rudinger, R., & Boyd-Graber, J. L. (2026). *(Im)Paired programming: Coding agents improve productivity but harm understanding*. https://doi.org/10.48550/arXiv.2607.26375.

Banh, L., Holldack, F., & Strobel, G. (2026). Designing generative AI-based agents to empower collaborative self-learning in higher education. *Business & Information Systems Engineering*. https://doi.org/10.1007/s12599-026-01012-1.

Barra, F. L., Costa, A., Rodella, G., Semeraro, F., & Carenzo, L. (2024). Shaping the future of simulator interactions: The role of ChatGPT's Advanced Voice Mode. *Resuscitation*, *205*, 110452. https://doi.org/10.1016/j.resuscitation.2024.110452.

Barth, M., Thorgeirsson, S., Etemadi, K., Leinonen, J., Cotrini, C., & Su, Z. (2026). Steering AI tutors through system prompts: A crossover study on self-regulated learning and cognitive engagement scaffolds in CS1. https://doi.org/10.1145/3765964.3811656.

Bartnik, R., & Schmid, J. (2025, Mai). *Literaturrecherche mit KI*. TH Köln.

Bartnik, R., & Schmid, J. (2026). *Schreibtrainer für wissenschaftliches Arbeiten: Anweisungen für acht Custom GPTs (Bot 1 bis Bot 8)*. TH Köln.

Barton, M. (2026). *KI-gestütztes Rollenspiel für Kommunikations- und Problemlösekompetenz*. Universität Leipzig, Professur Personalwirtschaftslehre. https://hochschulforumdigitalisierung.de/wp-content/uploads/2025/01/3285-Tag_Der_Lehre_2026_Michael_Barton.pdf.

Bergh, C., Tag, B., Vassar, A., & Renzella, J. (2026). *Your programming students' cognition with ChatGPT: Higher performance, lower retention, and reduced ownership*. https://doi.org/10.48550/arXiv.2609.21194.

Berney, S., & Bétrancourt, M. (2016). Does animation enhance learning? A meta-analysis. *Computers & Education*, *101*, 150–167. https://doi.org/10.1016/j.compedu.2016.06.005.

Bien, J., & Mukherjee, G. (2025). Generative AI for Data Science 101: Coding Without Learning to Code. *Journal of Statistics and Data Science Education*, *33*(2), 129–142. https://doi.org/10.1080/26939169.2024.2432397.

Bjork, E. L., & Bjork, R. A. (2011). Making things hard on yourself, but in a good way: Creating desirable difficulties to enhance learning. In M. A. Gernsbacher, R. W. Pew, L. M. Hough, & J. R. Pomerantz (Hrsg.), *Psychology and the real world: Essays illustrating fundamental contributions to society*: (S. 56–64). Worth Publishers.

Chang, P.-C., Hogan, N., Plaat, A., & van der Meer, M. T. (2026). Learning to prompt: Improving student engagement with adaptive LLM-based high-school tutoring. https://arxiv.org/abs/2606.20138.

Chen, F., Drezner, Z., Ryan, J. K., & Simchi-Levi, D. (1999). The bullwhip effect: Managerial insights on the impact of forecasting and information on variability in a supply chain. In S. Tayur, R. Ganeshan, & M. Magazine (Hrsg.), *Quantitative models for supply chain management*: (S. 417–439). Springer. https://doi.org/10.1007/978-1-4615-4949-9_14.

Chen, F., Drezner, Z., Ryan, J. K., & Simchi-Levi, D. (2000). Quantifying the bullwhip effect in a simple supply chain: The impact of forecasting, lead times, and information. *Management Science*, *46*(3), 436–443. https://doi.org/10.1287/mnsc.46.3.436.12069.

Chi, M. T. H., Adams, J., Bogusch, E. B., Bruchok, C., Kang, S., Lancaster, M., Levy, R., Li, N., McEldoon, K. L., Stump, G. S., Wylie, R., Xu, D., & Yaghmourian, D. L. (2018). Translating the ICAP Theory of Cognitive Engagement Into Practice. *Cognitive Science*, *42*(6), 1777–1832. https://doi.org/10/gd5n5p.

Croson, R., & Donohue, K. (2006). Behavioral causes of the bullwhip effect and the observed value of inventory information. *Management Science*, *52*(3), 323–336. https://doi.org/10.1287/mnsc.1050.0436.

Dang, C. T., & Nguyen, A. (2026). Verified, not generated: expert-verified AI study materials and the distribution of learning gains in a university course. https://doi.org/10.48550/arXiv.2610.07097.

Dell'Acqua, F., McFowland, E., Mollick, E. R., Lifshitz-Assaf, H., Kellogg, K., Rajendran, S., Krayer, L., Candelon, F., & Lakhani, K. R. (2023). *Navigating the Jagged Technological Frontier: Field Experimental Evidence of the Effects of AI on Knowledge Worker Productivity and Quality*. https://doi.org/10.2139/ssrn.4573321.

Denny, P., Kumar, V., & Giacaman, N. (2023). Conversing with copilot: Exploring prompt engineering for solving cs1 problems using natural language.

Devani, J., & Leiva, B. (2026, September). *Strengthening the evidence base for AI in education research: Launching the Learning Lab*. https://edunewsletter.openai.com/p/learning-lab-launch.

Dobson, G., & Shumsky, R. (2006). Web-based simulations for teaching queueing, Little's law, and inventory management. *INFORMS Transactions on Education*, *7*(1), 106–124. https://doi.org/10.1287/ited.7.1.106.

Eikenberg, R. (2025). Browser-Helferlein per KI generieren. *c't Special*, *2*, 94–99.

Figalová, N., Huestegge, L., & Böckler-Raettig, A. (2026). *Evaluating human and LLM screening workflows in a conceptually complex scoping review: Recall–workload trade-offs and run-to-run consistency*. https://doi.org/10.48550/arXiv.2608.26885.

Friedrich, J.-D. (2023, Februar 8). Zur Bedeutung von ChatGPT & der Notwendigkeit eines progressiven Umgangs mit neuen KI-Technologien im Hochschulbereich. Ein Zwischenstand in 6 Thesen. https://hochschulforumdigitalisierung.de/zur-bedeutung-von-chatgpt-der-notwendigkeit-eines-progressiven-umgangs-mit-neuen-ki-technologien-im-hochschulbereich-ein-zwischenstand-in-6-thesen/.

Gallegos, S. (2026). *Guidance over adoption: Experimental evidence on AI-assisted learning* (IZA Discussion Paper; Nr. 18513). Institute of Labor Economics (IZA).

Gerber, A., Lorenz, L., & Pfeiffer, U. (2026). KI-Tutoren in der Lehre: rechtlich sicher, didaktisch wertvoll, technisch innovativ. In J. Leschke, R. Queckenberg, & M. Persike (Hrsg.), *Learning analytics, artificial intelligence und data mining in der hochschulbildung*: (S. 57–64). transcript. https://doi.org/10.14361/9783839458761-057.

Gieselmann, H. (2024, August 16). Wie Sie Musik live coden mit Sonic Pi unterstützt von Sprachmodellen. *c't Magazin*. https://www.heise.de/ratgeber/Wie-Sie-Musik-live-coden-mit-Sonic-Pi-unterstuetzt-von-Sprachmodellen-9829751.html.

Google Workspace Updates (2026a, August). *Gemini in Google Classroom is expanding to users of all ages, with contextualized Gemini starter prompts for students*. https://workspaceupdates.googleblog.com/2026/08/gemini-in-google-classroom-is-expanding-to-users-of-all-ages-with-contextualized-Gemini-starter-prompts-for-students.html.

Google Workspace Updates (2026b, September). *Introducing skills in the Ge-*

mini app and Workspace, plus what's next for Gems. https://workspaceupdates.googleblog.com/2026/09/skills-gemini-app-workspace.html.

Goslen, A., Kim, Y. J., Rowe, J., & Lester, J. (2025). LLM-based student plan generation for adaptive scaffolding in game-based learning environments. *International Journal of Artificial Intelligence in Education*, *35*(2), 533–558. https://doi.org/10.1007/s40593-024-00421-1.

Handa, K., Stern, M., Huang, S., Hong, J., Durmus, E., McCain, M., Yun, G., Alt, A., Millar, T., Tamkin, A., Leibrock, J., Ritchie, S., & Ganguli, D. (2025, Dezember 4). Introducing Anthropic Interviewer: What 1,250 professionals told us about working with AI. *Anthropic Research*. https://www.anthropic.com/research/anthropic-interviewer.

Heetkamp, S. J. (2023, Dezember 13). Die VR-Revolution im Justizwesen. https://www.deutscheranwaltspiegel.de/e-justice/digitalisierung/die-vr-revolution-im-justizwesen-151520/.

HeyGen (2026). *HyperFrames*. GitHub. https://github.com/heygen-com/hyperframes.

Hou, X., Weng, Y., Yeh, C. H., Lee, D. L., Zheng, L., Li, F., Wang, W., & Liu, Y. (2026). *Adaptive scaffolding needs contingency: An AI tutor that escalates and fades on what the learner does*. https://doi.org/10.48550/arXiv.2609.22993.

Huffman, P., & Hutson, J. (2024). Enhancing History Education with Google NotebookLM: Case Study of Mary Easton Sibley's Diary for Multimedia Content and Podcast Creation. *ISRG Journal of Arts, Humanities and Social Sciences*, *2*(5).

Jurran, N. (2025). ChatGPT als sprechtrainer. *c't Special*, *2*, 100–103.

Kestin, G., Miller, K., Klales, A., Milbourne, T., & Ponti, G. (2025). AI tutoring outperforms in-class active learning: an RCT introducing a novel research-based design in an authentic educational setting. *Scientific Reports*, *15*(1), 17458. https://doi.org/10.1038/s41598-025-97652-6.

Khan, S. (2026, Juli). *Khanmigo's first chapter changed how I think about AI: A note from Sal Khan*. https://blog.khanacademy.org/khanmigos-first-chapter-changed-how-i-think-about-ai-a-note-from-sal-khan/.

Klein, D. A. (2023, Februar 17). „Die Hausarbeit ist tot, es lebe die Hausarbeit!" - Entwicklungsorientierung, wissenschaftliches Arbeiten und KI gemeinsam denken. https://hochschulforumdigitalisierung.de/die-hausarbeit-ist-tot-es-lebe-die-hausarbeit-entwicklungsorientierung-wissenschaftliches-arbeiten-und-ki-gemeinsam-denken/.

Kuric, E., Demcak, P., & Krajcovic, M. (2026). *What would GPT click: Practical effects of human-AI behavioral misalignment and the cost of synthetic participants in user experience*. https://doi.org/10.48550/arXiv.2605.18302.

Latif, E., Liu, V., & Zhai, X. (2026). A systematic review of intelligent and robot tutoring systems: evolution, pedagogical design, and AI-driven classification. *Smart Learning Environments*.

Lee, H. L., Padmanabhan, V., & Whang, S. (1997). Information distortion in a supply chain: The bullwhip effect. *Management Science*, *43*(4), 546–558. https://doi.org/10.1287/mnsc.43.4.546.

Lee, H.-P. H., Sarkar, A., Tankelevitch, L., Drosos, I., Rintel, S., Banks, R., & Wilson, N. (2025). The Impact of Generative AI on Critical Thinking: Self-Reported Reductions in Cognitive Effort and Confidence Effects From a Survey of Knowledge Workers. https://doi.org/10.1145/3706598.3713778.

Lee, Suhyeon, Baek, J., Park, J., & Shin, D. (2026). *LLM pedagogical behavior in AI tutoring interactions*. https://doi.org/10.48550/arXiv.2608.22993.

Lee, Sangmin, Choe, H., Zou, D., & Jeon, J. (2025). Generative AI (GenAI) in the language classroom: A systematic review. *Interactive Learning Environments*, 1–25. https://doi.org/10.1080/10494820.2025.2498537.

Liang, J. T., Yang, C., & Myers, B. A. (2024). A large-scale survey on the usability of ai programming assistants: Successes and challenges.

Little, J. D. C. (1961). A proof for the queuing formula: L = λW. *Operations Research*, *9*(3), 383–387. https://doi.org/10.1287/opre.9.3.383.

Liu, J., Sweet, T., Chen, M. H., Engelberg, J., Masters, M. C., Clark, M., Persaud, A., Lancaster, A., Hollingsworth, J. K., & Rice, J. K. (2026). *The effects of course-integrated AI tutoring on student performance and engagement: A randomized university trial* (EdWorkingPaper; Nr. 26-1598). Annenberg Institute at Brown University. https://doi.org/10.26300/y3f8-vh05.

Marchena, M. (2018). *bullwhipgame: Bullwhip effect demo in Shiny*. CRAN. https://doi.org/10.32614/CRAN.package.bullwhipgame.

Mollick, E. R., & Mollick, L. (2023a). *Using AI to Implement Effective Teaching Strategies in Classrooms: Five Strategies, Including Prompts* (SSRN Scholarly Paper; Nr. 4391243).

Mollick, E. R., & Mollick, L. (2023b). *Assigning AI: Seven Approaches for Students, with Prompts*. arXiv. https://doi.org/10.48550/arXiv.2306.10052.

Mollick, E. R., & Mollick, L. (2024). *Instructors as Innovators: a Future-focused Approach to New AI Learning Opportunities, With Prompts*. https://doi.org/10.2139/ssrn.4802463.

Mollick, E. R., Mollick, L., Bach, N., Ciccarelli, L. J., Przystanski, B., & Ravipinto, D. (2024). AI agents and education: Simulated practice at scale. *arXiv preprint arXiv:2407.12796*.

Netland, T., von Dzengelevski, O., Tesch, K., & Kwasnitschka, D. (2025).

Comparing human-made and AI-generated teaching videos: An experimental study on learning effects. *Computers & Education*, *224*, 105164. https://doi.org/10.1016/j.compedu.2024.105164.

Nizamudeen, F., Gatti, L., Bouali, N., & Ahmed, F. (2024). Investigating the Impact of Code Generation Tools (ChatGPT & Github CoPilot) on Programming Education. https://doi.org/10.5220/0012628000003693.

Nofal, A. B., Ali, H., Hadi, M., Ahmad, A., Qayyum, A., Johri, A., Al-Fuqaha, A., & Qadir, J. (2025). AI-enhanced interview simulation in the metaverse: Transforming professional skills training through VR and generative conversational AI. *Computers and Education: Artificial Intelligence*, *8*, 100347. https://doi.org/10.1016/j.caeai.2024.100347.

OpenAI (2026a, März). *Understanding AI and learning outcomes*. https://openai.com/index/understanding-ai-and-learning-outcomes/.

OpenAI (2026b, August). *New ways to learn and teach with ChatGPT Work and Codex*. https://openai.com/index/learn-teach-chatgpt-work-codex/.

OpenAI (2026c, September). Custom GPT retirement and migration FAQ. *OpenAI Help Center*. https://help.openai.com/en/articles/20001519.

Oreopoulos, P., & Low, N. (2026). *One click away: AI tutoring with Khanmigo in a two-year school experiment* (NBER Working Paper; Nr. 35620). National Bureau of Economic Research. https://doi.org/10.3386/w35620.

Österreichischer Universitätsprofessor/innenverband (2018). *Österreich - Arbeitszeitverteilung von Professoren 2017*.

Ou, A. W., Stöhr, C., & Malmström, H. (2024). Academic communication with AI-powered language tools in higher education: From a post-humanist perspective. *System*, *121*, 103225. https://doi.org/10.1016/j.system.2024.103225.

Pan, S. C., & Carpenter, S. K. (2023). Prequestioning and pretesting effects: A review of empirical research, theoretical perspectives, and implications for educational practice. *Educational Psychology Review*, *35*(4), 97. https://doi.org/10.1007/s10648-023-09814-5.

Pedersen, D. (2025). *DuPont analysis of coca-cola*. https://aipedagogy.org/assignment/dupont-analysis-of-coca-cola/.

Peng, S., Kalliamvakou, E., Cihon, P., & Demirer, M. (2023). *The Impact of AI on Developer Productivity: Evidence from GitHub Copilot*. arXiv. https://doi.org/10.48550/arXiv.2302.06590.

Perczel, J., Chow, J., & Demszky, D. (2025). TeachLM: Post-training LLMs for education using authentic learning data. https://doi.org/10.48550/arXiv.2510.05087.

Pisan, Y. (2026). *Teaching a large language model tutor to withhold the answer: A*

supervisor architecture and an evidence-driven method for tuning socratic behavior. https://doi.org/10.48550/arXiv.2608.12292.

Ploetzner, R., Berney, S., & Bétrancourt, M. (2020). A review of learning demands in instructional animations: The educational effectiveness of animations unfolds if the features of change need to be learned. *Journal of Computer Assisted Learning*, *36*(6), 838–860. https://doi.org/10.1111/jcal.12476.

Ploetzner, R., Berney, S., & Bétrancourt, M. (2021). When learning from animations is more successful than learning from static pictures: learning the specifics of change. *Instructional Science*, *49*(4), 497–514. https://doi.org/10.1007/s11251-021-09541-w.

Porter, L., & Zingaro, D. (2024). *Learn AI-Assisted Python Programming: With Github Copilot and ChatGPT*. Simon and Schuster.

Puryear, B., & Sprint, G. (2022). Github copilot in the classroom: learning to code with AI assistance. *Journal of Computing Sciences in Colleges*, *38*(1), 37–47.

Reason, J. (2000). Human error: models and management. *BMJ*, *320*(7237), 768–770. https://doi.org/10.1136/bmj.320.7237.768.

Schomburg, H., Flöther, C., & Wolf, V. (2012). *Wandel von Lehre und Studium an deutschen Hochschulen–Erfahrungen und Sichtweisen der Lehrenden*.

Sitzmann, T. (2011). A meta-analytic examination of the instructional effectiveness of computer-based simulation games. *Personnel Psychology*, *64*(2), 489–528. https://doi.org/10.1111/j.1744-6570.2011.01190.x.

Steinberger, P. (2025, Oktober 14). *Just Talk To It - the no-bs Way of Agentic Engineering | Peter Steinberger*. https://steipete.me/posts/just-talk-to-it.

Sterman, J. D. (1989). Modeling managerial behavior: Misperceptions of feedback in a dynamic decision making experiment. *Management Science*, *35*(3), 321–339. https://doi.org/10.1287/mnsc.35.3.321.

Tani, T., Joseph, M., Metso, L., & Tynninen, L. (2026). RAG 'n' Roll industrial management game: Building and testing a large language model assistant for operations education. *Computer Applications in Engineering Education*, *34*(5), e70263. https://doi.org/10.1002/cae.70263.

Tao, Y., Meyer, J., & Kizilcec, R. F. (2026). *Think before you accept: Can written justification reduce uncritical uptake of AI writing suggestions?* https://doi.org/10.48550/arXiv.2609.23936.

Tay, A. (2024a, Oktober 20). *Classifying the ways LLMs summarise - Individual vs Aggregate vs Visual summaries*. https://aarontay.substack.com/p/classifying-the-ways-llms-summarise.

Tay, A. (2024b, Dezember 1). *MCP servers and academic search - The future of*

search? https://aarontay.substack.com/p/mcp-servers-and-academic-search-the.

Tay, A. (2025, Januar 19). *How agentic are academic deep research tools? Testing Perplexity, Elicit, Consensus and Academic GPTs*. https://aarontay.substack.com/p/how-agentic-are-academic-deep-research.

Teo, V., Jain, R., Gerstenberg, T., & Kleiman-Weiner, M. (2026). *AI assistants overassist*. https://doi.org/10.48550/arXiv.2607.21306.

Tobor, J., Then Bergh, C., & Lüthi, R. (2026). *Use Cases in Bewegung: Wie KI Studium und Lehre weiter verändert* (Blickpunkt). Hochschulforum Digitalisierung.

Tutton, M., & Cohen, D. (2025). Reconceptualizing the Role of the University Language Teacher in Light of Generative AI. *Education Sciences*, *15*(1), 56. https://doi.org/10.3390/educsci15010056.

Wang, S., Scells, H., Koopman, B., & Zuccon, G. (2023). Can ChatGPT write a good Boolean query for systematic review literature search? https://doi.org/10.1145/3539618.3591703.

Wang, S., Scells, H., Koopman, B., & Zuccon, G. (2025). Reassessing large language model Boolean query generation for systematic reviews. https://doi.org/10.1145/3726302.3730329.

Wannemacher, K., Bosse, E., Lübcke, M., & Kaemena, A. (2025). *Wie KI Studium und Lehre verändert. Anwendungsfelder, Use-Cases und Gelingensbedingungen* (Arbeitspapier Nr. 87). Hochschulforum Digitalisierung.

Willison, S. (2025, Oktober 5). Embracing the parallel coding agent lifestyle. *Simon Willison's Weblog*. https://simonwillison.net/2025/Oct/5/parallel-coding-agents/.

Wissenschaftsrat (2026). *Intellektuelle Souveränität: Empfehlungen für die Hochschulbildung in Zeiten von generativer KI* (Nr. Drs. 3319-26). Wissenschaftsrat. https://doi.org/10.57674/1evx-t906.

Wu, M. (2026). *Constructing epistemic AI literacy: Detecting epistemic aims and processes in student-AI co-programming*. https://doi.org/10.48550/arXiv.2607.00211.

Yang, K. B., Liu, M., Xu, L., Rummel, N., & Aleven, V. (2026). Balancing teacher and student agency: Co-orchestration tool design supporting real-time dynamic pairing. https://doi.org/10.48550/arXiv.2605.18761.

Yang, L., Liu, H., Li, S., Jia, R., Xiao, Y., Chen, G., & Lu, L. (2026). *Evaluating scaffolding-oriented multi-agent large language model system for clinical interview training*. https://doi.org/10.48550/arXiv.2609.10939.

7 Artefakte: Fallbeispiele aus der Lehre

In diesem Kapitel

- Wissen übertragen: Begriffe, Formeln, Reihenfolgen
- Wissen übersetzen: Bedeutungen erschließen
- Wissen umformen: anwenden gegen Interessen und Folgen
- Was die Beispiele gemeinsam zeigen

Dr. Sophie Arnold ist neu berufen und übernimmt im Wirtschaftsingenieurwesen drei Module auf einmal: Lieferkettenmanagement, das Projektmodul im ersten Semester und ein Wahlpflichtmodul mit einem Praxispartner. Von ihrem Vorgänger erbt sie einen Quiz-Prompt, sechs Widgets mit Schiebereglern und die Berichte des Vorjahres, in denen Erstsemester Karriere-Bots mit eigener Suchfunktion gebaut haben. Der Praxispartner, ein Automobilzulieferer, wünscht sich einen KI-Assistenten für seinen Einkauf, gibt aber keine Daten heraus. Arnold will die Widgets ohne Arbeitsaufträge freigeben, damit die Studierenden selbst entdecken, und den Quiz-Prompt durch Karteikarten ersetzen; die seien wenigstens erprobt. Bei den Karriere-Bots bewundert sie die Technik. Sie fragt sich, was von dem Geerbten trägt und was nur glänzt.

Die Person ist erfunden; Module, Werkzeuge und Projekte stammen aus der eigenen Lehre, die dieses Kapitel beschreibt.

Bevor Sie weiterlesen: Wie sehen Sie das?

Wie sehr stimmen Sie den vier Aussagen zu? Jede Aussage wird an der Stelle im Kapitel aufgelöst, die sie beantwortet. Wer sich vorher festlegt, liest gezielter.

1. Ein Sprachmodell, das Fragen zum eigenen Kursmaterial stellt, hilft nachweislich besser beim Behalten als ein Satz Karteikarten.
stimme zu 1 – 2 – 3 – 4 – 5 *stimme nicht zu*
(Auflösung in Kapitel 7.1.1)

2. Ein interaktives Widget, an dem Studierende frei mit den Reglern experimentieren, lehrt mehr als eine direkte Erklärung, auch ohne Arbeitsaufträge.
stimme zu 1 – 2 – 3 – 4 – 5 *stimme nicht zu*
(Auflösung in Kapitel 7.2.1)

3. Wenn Erstsemester KI-Werkzeuge für eine Zielgruppe bauen, fehlt den Projekten am häufigsten nicht die Technik, sondern der Test mit Nutzenden.
stimme zu 1 – 2 – 3 – 4 – 5 *stimme nicht zu*
(Auflösung in Kapitel 7.3.4)

4. Studierende können für einen Praxispartner einen brauchbaren KI-Prototyp bauen, ohne echte Unternehmensdaten zu sehen.
stimme zu 1 – 2 – 3 – 4 – 5 *stimme nicht zu*
(Auflösung in Kapitel 7.3.5)

Lernziele: Nach diesem Kapitel können Sie …

1. an Beispielen aus der eigenen Lehre nachvollziehen, wie aus einem belegten Lernprinzip eine Empfehlung und daraus eine Umsetzung mit generativer KI wird;
2. ein eigenes Vorhaben einer Wissensform zuordnen und daraus Lerntechnik und Rolle der KI ableiten;
3. Vorbereitung und Prüfkriterien der Beispiele auf eigene Werkzeuge und Praxisprojekte übertragen.

Die Kernaussagen am Kapitelende sind nach diesen drei Zielen geordnet.

Die Kapitel 2 bis 6 behandeln Werkzeuge, Lernmechanismen, Rollen und Umsetzungsregeln je für sich. Dieses Kapitel zeigt, wie sie in Modulen des Bachelors Wirtschaftsingenieurwesen und in Workshops der TH Köln zusammenkommen, und ordnet die Beispiele nach dem, was Studierende ler-

nen sollen, nicht nach dem Werkzeug. Jedes Beispiel beginnt mit einem Prinzip, das die Lernforschung belegt, leitet daraus eine Empfehlung ab, die ohne Produktnamen auskommt, und zeigt erst dann die Umsetzung mit dem Stand bei Drucklegung. Eine Empfehlung ist gut formuliert, wenn sie den Austauschtest besteht: Sie stimmt noch, nachdem man das Werkzeug gegen ein anderes getauscht hat. Werkzeuge altern schneller als Prinzipien, und wer das Prinzip kennt, baut die Umsetzung mit dem Werkzeug des nächsten Jahres nach.

Die Ordnung folgt drei Stufen, die Carlile (2004) für Wissen an den Grenzen zwischen Abteilungen beschreibt. Übertragen lässt sich Wissen, wo beide Seiten dieselben Begriffe teilen (syntaktisch; *transferring*); übersetzt werden muss es, wo dieselben Wörter Verschiedenes bedeuten (semantisch; *translating*); umgeformt wird es, wo Interessen und Folgen auf dem Spiel stehen und Wissen gegen sie angewendet werden muss (pragmatisch; *transforming*). Carlile beschreibt Organisationen, und die Grenze zwischen Studierenden und Fach ist eine Analogie, die wir zum Ordnen nutzen, kein Befund über das Lernen. Wörtlich gilt sie erst beim Projektlernen (*project-based learning*) mit Praxispartnern (Kapitel 7.3.5), wo Wissen tatsächlich eine Organisationsgrenze überquert.

Unter jeder Überschrift steht ein Steckbrief mit vier Angaben: die Wissensform; die Lerntechnik nach Dunlosky et al. (2013) mit ihrer Evidenzstärke, hoch für verteiltes (*distributed practice*) und testgestütztes Lernen (*practice testing*), mittel für gemischtes Üben (*interleaved practice*) und fragebasierte Ausarbeitung (*elaborative interrogation, self-explanation*), oder das tragende Prinzip, wenn keine der Techniken passt; die Rolle der KI aus Kapitel 6; und wer das Werkzeug gestaltet hat. Bauen Studierende es selbst, liegt das Lernziel meist eine Stufe höher, weil sie Wissen für ein Publikum übersetzen. Tabelle 7.1 fasst die Steckbriefe zusammen.

Beispiel	Wissensform	Lerntechnik (Evidenz) bzw. tragendes Prinzip	Rolle	Gestaltet von
Fragen-Generator	syntaktisch	testgestützt, verteilt (hoch)	Tutor	Lehrende
Lernsongs	syntaktisch	verteilt (hoch); Lösungsbeispiele	Copilot	Lehrende
Quizspiele	syntaktisch	testgestützt (hoch)	Copilot	Lehrende, Studierende

Beispiel	Wissensform	Lerntechnik (Evidenz) bzw. tragendes Prinzip	Rolle	Gestaltet von
Interaktive Widgets	semantisch	angeleitetes Entdecken, Konkretheitsabbau	Copilot	Lehrende
Tutoring	semantisch	testgestützt (hoch) bzw. Ausarbeitung (mittel)	Tutor	Lehrende, Studierende
Fallstudien generieren	pragmatisch	Ausarbeitung (mittel), Vorhersage	Copilot	Lehrende
Simulationen durch Lehrende	pragmatisch	Erfahrung mit Debriefing	Simulator	Lehrende
Simulationen und Planspiele selbst bauen	pragmatisch	simulationsbasiertes Lernen; Projektlernen	Simulator	Studierende
Karriereberater	pragmatisch	Projektlernen, Test mit Nutzenden	Tutor, Simulator	Studierende
Projektlernen mit Praxispartnern	pragmatisch	Projektlernen	Copilot, Hiwi	Studierende

Tabelle 7.1. Die Beispiele dieses Kapitels nach Wissensform, Lerntechnik, Rolle der KI und Gestaltung

7.1 Wissen übertragen: Begriffe, Formeln, Reihenfolgen

7.1.1 Fragen-Generator: Abrufübung mit dem eigenen Material

Wissensform: syntaktisch · *Lerntechnik:* testgestützt (hoch), verteilt (hoch) · *Rolle:* Tutor (Kapitel 6.3) · *Gestaltet von:* Lehrende

i Prinzip

Wer Gelerntes aus dem Gedächtnis abruft, behält es länger als wer es noch einmal liest. Nach fünf Minuten liegt das Wiederlesen noch vorn, nach zwei Tagen und nach einer Woche der Abruf (Roediger & Karpicke, 2006), und eine Metaanalyse über alle Vergleichsbedingungen be-

stätigt ihn: Übungstests schlagen das Wiederlesen und jede andere geprüfte Alternative, wobei Merkmale des Tests wie die Rückmeldung die Größe des Effekts mitbestimmen (Adesope et al., 2017). Verteilt man die Abrufrunden über Tage, wächst der Gewinn weiter (Cepeda et al., 2006); beide Techniken stehen bei Dunlosky et al. (2013) in der höchsten Nützlichkeitsstufe.

Empfehlung

Wenn Sie Studierenden ein Sprachmodell zum Wiederholen empfehlen, geben Sie ihnen einen Prompt (Eingabe an die KI) mit, der das Modell auf Ihr Material festlegt, eine eigene Antwort vor jeder Rückmeldung verlangt und die Aufgabenform Ihrer Prüfung nachbildet. Prüfkriterium: Stellt das System eine Frage und wartet, bevor es etwas erklärt?

Umsetzung, Stand 10/2026

Im englischsprachigen Modul *Sustainable Supply Chain Management* (SSCM, nachhaltiges Lieferkettenmanagement) liegt auf jeder Wochenseite der Kerninhalt der Woche als reine Textdatei: das Problem des Kapitels, ein Satz der Woche, die Formeln, die gerechneten Beispiele aus Studentenleben, Fabrik und Lieferkette mit ihren Zahlen, typische Fehler und Übungsaufgaben ohne Lösung. Ein Anhang des Online-Skripts stellt dazu den Prompt *Quiz me* bereit; der Wortlaut steht in Anhang A (Kapitel A.2.1). Studierende kopieren ihn in einen beliebigen Chat und hängen den Kerninhalt einer Woche an.
Der Prompt legt fünf Dinge fest. Er beschränkt das Modell auf das eingefügte Material und das Lehrbuchkapitel, das es nennt, und verbietet erfundene Zahlen. Er gibt eine Reihenfolge vor: zuerst das Problem in Worten, dann die Formel in Worten, dann eine Rechnung mit den Zahlen eines Beispiels, in der ein Wert geändert ist, zuletzt eine Übungsaufgabe. Nach jeder Antwort sagt das Modell, ob sie stimmt, zeigt die Rechnung in höchstens vier Zeilen und benennt den typischen Fehler, falls einer vorliegt; die Lösung nennt es nie vor dem eigenen Versuch, auf Nachfrage zuerst nur einen Hinweis. Er bildet die Prüfung nach, die auf Papier stattfindet und Rechenaufgaben mit geänderten Werten neben Begriffsfragen stellt, und schließt jede Sitzung mit drei Aufgaben

im Prüfungsformat und zwei Zeilen dazu, was noch einmal zu lesen ist. Und er verlangt Ehrlichkeit: Steht etwas nicht im Material, verweist das Modell auf den Kapitelabschnitt, statt zu raten. Ein zweiter, kurzer Prompt dreht die Richtung um und baut aus jedem typischen Fehler eine fehlerhafte Rechnung, die Studierende finden und korrigieren.
Zwei Gestaltungsentscheidungen tragen den Lerneffekt. Die Arbeitsanweisung lautet, jede Antwort zuerst auf Papier zu schreiben und erst dann einzutippen; der Abruf findet also statt, bevor das Modell eingreift. Und weil jedes gerechnete Beispiel im Kerninhalt sein Ergebnis mitführt, können Studierende jede Zahl des Modells gegen eine Zahl der Lehrperson halten. Die Seite schließt mit dem Satz, was der Prompt nicht ersetzt: das Kapitel.
Die zweite Umsetzung stammt aus einem 30-minütigen Workshop für Studierende aller Semester am Campus Gummersbach. Ein Prompt macht das Modell zum Klausur-Lernplaner: Es sortiert eine Themenliste nach inhaltlicher Abhängigkeit, verteilt sie rückwärts auf die zehn Tage vor der Klausur, hält den letzten Tag frei von neuem Stoff und gibt für jeden Tag eine Kontrollfrage aus, die abends ohne Hilfe lösbar sein muss. Die Kontrollfrage ist testgestützt. Verteilt ist der Plan dagegen kaum, denn jedes Thema kommt an einem Tag vor und kehrt erst am Wiederholungstag zurück. Eine Zeile im Prompt behebt das: Jedes Thema zwei und fünf Tage nach dem ersten Lerntag in einer Abrufrunde von zehn Minuten wieder aufnehmen.

Ob ein Sprachmodell als Fragesteller mehr leistet als Karteikarten, ist nicht untersucht. Die Evidenz gilt dem Abruf, nicht dem, der abfragt; der Gewinn des Modells liegt in der Variation der Zahlen und in der Rückmeldung zum typischen Fehler, und beide lassen sich mit einem Satz Karteikarten nur mühsam herstellen.

Ihre Einschätzung prüfen

„Ein Sprachmodell, das Fragen zum eigenen Kursmaterial stellt, hilft nachweislich besser beim Behalten als ein Satz Karteikarten."
Auflösung: nein. Belegt ist die Wirkung des Abrufs, nicht die des Fragestellers: Wer aus dem Gedächtnis antwortet, behält mehr, ob die Frage von einer Karteikarte kommt oder von einem Modell. Ob das Modell mehr leistet, ist nicht untersucht. Sein Vorteil ist praktisch: Es variiert

die Zahlen und benennt den typischen Fehler, was mit Karteikarten nur mühsam gelingt.

Lernfrage. Ein Student lässt sich vom Modell die Lösung zeigen und tippt sie ab, bevor er selbst gerechnet hat. Welche Zeile des Prompts verletzt er, und warum verliert er damit genau den Effekt, für den der Prompt gebaut ist?

7.1.2 Lernsongs: ein Verfahrenslied mit Rechenpausen

Wissensform: syntaktisch, mit semantischem Rand · *Lerntechnik:* verteilt (hoch); Rechenteil getragen von Lösungsbeispielen · *Rolle:* Copilot (Kapitel 6.2) · *Gestaltet von:* Lehrende

Prinzip

Musik stärkt das wörtliche Behalten von Wortlaut und Reihenfolge: In einer systematischen Übersicht fanden 28 von 37 Studien einen Vorteil musikalischer Merkhilfen (*musical mnemonics*), neun keinen (Derks-Dijkman et al., 2024). Der Vorteil braucht Wiederholung, und zwar verteilte; Studierende, die ein Lied über Tage verteilt übten, behielten es drei Wochen später besser als nach massiertem Üben (Katz et al., 2021). Für das Anwenden und Rechnen gibt es keinen Beleg, dass ein Song hilft. Dieselbe Trennung von Form und Bedeutung zeigt sich auch ohne Musik: Studierende der Einführungsstatistik erinnerten Akronyme häufiger als andere Merkhilfen, erklären und anwenden konnten sie aber eher die satzförmigen (Mocko et al., 2024). Diesen Teil tragen ausgearbeitete Lösungsbeispiele (*worked examples*), die in einer Metaanalyse zur Mathematik einen mittleren Effekt erreichen (Barbieri et al., 2023).

Empfehlung

Setzen Sie einen Song für das ein, was wörtlich sitzen soll: die Namen und die Reihenfolge der Verfahren, eine Formel im Wortlaut. Lassen Sie das Rechnen von Lösungsbeispielen tragen, die der Song an markierten Stellen anhält, und planen Sie mindestens zwei Durchgänge mit einigen

Tagen Abstand ein. Prüfkriterium: Lässt sich jede Strophe einer Zeile im Skript zuordnen, und steht im Einsatzplan ein zweiter Termin?

! Umsetzung, Stand 10/2026

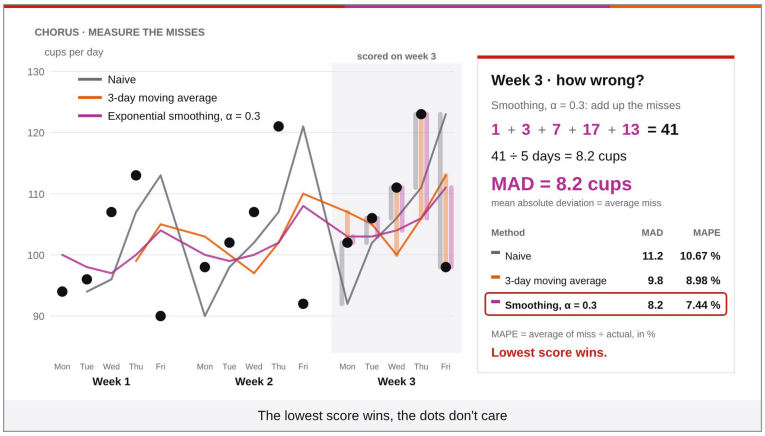
Every Forecast Is Wrong · How Many Cups Tomorrow? ist ein animiertes Musikvideo von 5:15 Minuten für die fünfte Woche des SSCM-Moduls, in der es um Prognoseverfahren geht. Ein Café auf dem Campus zählt drei Wochen lang seine verkauften Kaffeebecher, und der Song führt an diesen Zahlen durch fünf Verfahren: die naive Prognose, den gleitenden Dreitagesdurchschnitt, die exponentielle Glättung, den Wochentagsindex und den Wochentagsindex mit Trend. Die Refrains vergleichen die Verfahren über zwei Fehlermaße, die mittlere absolute Abweichung (MAD) und die mittlere absolute prozentuale Abweichung (MAPE). Drei Instrumentalteile zeigen je eine durchgerechnete Prognose; die Anweisung auf der Wochenseite lautet, dort anzuhalten und mitzurechnen, bevor die nächste Zeile erscheint. Der Liedtext läuft als Untertitel mit.

Arbeitsteilung und Prüfung stehen in der Bildunterschrift: Text, Beispieldaten und Animationscode schrieb Claude, die Musik erzeugte Suno, Café und Zahlen sind erfunden, geprüft hat die Lehrperson. Das Beispiel ist bewusst neu. Es teilt keine Zahlen mit der Fallstudie der Woche, dem Prognose-Widget (interaktive Übung im Browser) oder der folgenden Klausur, sodass der Song einen zweiten Kontext für dieselben Verfahren liefert, ohne Prüfungsaufgaben vorwegzunehmen.

Der Einsatzplan folgt dem Prinzip. Der Song steht am Ende eines Selbstlerntags, nach Kapitellektüre, Widget und Fallstudie, also erst dann, wenn die Verfahren hergeleitet und verstanden sind. Die Aufgabenliste für die Woche danach nennt einen zweiten Durchgang mit Halt an den drei Rechenbeispielen.

In der Typologie des Regelwerks ist das Video ein Verfahrenslied, keiner der drei ausgewählten Typen. Es zeigt deshalb gut, wo die Arbeitsteilung zwischen Musik und Didaktik verläuft: Der Song sichert die Reihenfolge der fünf Verfahren und ihre Namen, die Rechenpausen sind Lösungsbeispiele in einem anderen Gewand.

Lernfrage. Eine Kollegin will den Song in der Vorlesung einmal abspielen, bevor sie die exponentielle Glättung einführt. Was spricht nach dem Prinzip gegen diesen Zeitpunkt, und was gegen das einmalige Abspielen?



Video online
(5:15 min)

Abbildung 7.1. Standbild aus dem Lernsong *Every Forecast Is Wrong* (5:15) bei 3:20: Der Refrain vergleicht drei Verfahren über die mittlere absolute Abweichung (MAD) und die mittlere absolute prozentuale Abweichung (MAPE); die Zeile unten ist der Liedtext als Untertitel. Text, Beispieldaten und Animationscode: Claude; Musik: Suno; Café und Zahlen erfunden. Das Video gibt es nur online: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/lernsong-forecast.html aufrufen.

7.1.3 Quizspiele: Abruf mit Rückmeldung, und wann ein Quiz kein Simulator ist

Wissensform: syntaktisch · *Lerntechnik:* testgestützt (hoch) · *Rolle:* Copilot (Kapitel 6.2.2) · *Gestaltet von:* Lehrende, Studierende

Prinzip

Ein Zuordnungs- oder Auswahlspiel ist eine Abrufübung mit sofortiger Rückmeldung und wirkt über denselben Mechanismus wie ein Übungstest (Adesope et al., 2017). Die Spielform selbst ist kein zusätzlicher Wirkfaktor, auf den man sich verlassen kann: Serious Games (digitale Lernspiele) schnitten in einer Metaanalyse beim Lernen und Behalten besser ab als herkömmlicher Unterricht, motivierten aber nicht stärker (Wouters et al., 2013). Der Vorsprung braucht Wiederholung: Eine einzelne Spielsitzung zeigte in einer zweiten Metaanalyse keinen Effekt, mehrere Sitzungen einen mittleren (Clark et al., 2016).

Empfehlung

Bauen Sie Quizspiele für Begriffe, Zuordnungen und Erkennungsaufgaben, und nennen Sie sie so. Wenn die Lernenden Entscheidungen unter Zielkonflikten üben sollen, braucht das Spiel einen Zustand, der sich durch ihre Entscheidungen verändert; eine Auswahl mit einer richtigen Antwort leistet das nicht. Prüfkriterium: Ändert eine Entscheidung etwas an der Lage der nächsten Runde?

Umsetzung, Stand 10/2026

Das Zuordnungsspiel zu den Grundbegriffen generativer KI in Kapitel 2.1 paart Begriffe mit Definitionen. Die Stufe *Fortgeschritten* ergänzt Begriffe zu Agenten (selbstständig handelnden KI-Systemen) und eine Diagnoserunde mit typischen Problemen im Umgang mit Sprachmodellen. Das Spiel ist eine einzelne Webseite (HTML-Datei) und läuft ohne Anmeldung im Browser; es wird im Skript, im Workshop „KI zum Lernen“ und im Workshop zu interaktiven Skripten eingesetzt.
Lehrreich ist der Vergleich mit einem frühen eigenen Versuch aus dem Jahr 2025. *Einsatzbereit! Strategic Procurement Simulator* versetzt Studierende in die Rolle der Beschaffung in Krisen: Eine Flut verlangt sofort Pumpen, ein Erdbeben erzeugt viele dringende Bedarfe zugleich, und für jede Lage stehen vier Strategien zur Wahl, Sicherheitsbestand, leistungsbasierte Verträge, Lebenszykluskostenrechnung und Dual Sourcing (Bezug von zwei Lieferanten). Das Programm wählt zufällig eine von vier Lagen und erklärt nach der Wahl, welche Strategie die beste gewesen wäre. Der Name verspricht eine Simulation, die Struktur ist ein Auswahlquiz mit Rückmeldung: Es gibt keinen Zustand, keine Folgekosten und keine nächste Runde, die von der vorigen abhängt. Die Musterlösung blendet zudem genau den Zielkonflikt aus, um den es in der Beschaffung geht, denn im Erdbeben konkurrieren Sicherheitsbestand und Dual Sourcing, und die Antwort hängt an Lagerkosten und Lieferzeiten, die das Spiel nicht kennt. Als Erkennungsübung zu vier Begriffen taugt es; Entscheidungen trainiert erst ein Modell, in dem Entscheidungen Folgen haben (Kapitel 7.3.3).
Ein Gegenstück aus Studierendenhand zeigt, wo die Grenze genau verläuft. Ein Team im Erstsemestermodul zum wissenschaftlichen Arbeiten (WAGP, Kapitel 7.3.4) baute im Sommersemester 2025 ein „BWL-

Memory“: Ein Sprachmodell erzeugt aus eingefügten Vorlesungstexten Paare aus Begriff und Definition, die auf einem Spielfeld einander zuzuordnen sind, und jede falsche Zuordnung landet in einer Fehlerliste, die beim nächsten Spiel in den Auftrag an das Modell eingeht. Ein Fehler verändert also die nächste Runde, aber nicht ihre Lage, sondern den Lernstoff. Das Spiel ist ein adaptives Abrufquiz und als solches gut gedacht, weil es die schwachen Begriffe öfter abfragt (Dunlosky et al., 2013). Der Code zeigt zwei Lücken, die bei selbst gebauten Quizspielen naheliegen. Die erzeugten Paare gehen ungeprüft aufs Spielfeld, und ein Begriff verlässt die Fehlerliste nur, wenn ihn jemand von Hand löscht; nach den Testläufen stand „Volkswirtschaft“ neunmal darin. Die Karten liegen zudem offen, der Name verspricht also wie beim Beschaffungs-„Simulator“ einen anderen Mechanismus. Acht Testpersonen fanden das Spiel übersichtlich und motivierend; ob sie damit mehr behielten, wurde nicht gemessen.

Lernfrage. Wie müsste man den Beschaffungs-„Simulator“ verändern, damit aus dem Quiz eine Entscheidungsübung wird? Nennen Sie die kleinste Änderung, die das Prüfkriterium der Empfehlung erfüllt.

7.2 Wissen übersetzen: Bedeutungen erschließen

7.2.1 Interaktive Widgets: vom Studentenleben zur Fabrik

Wissensform: semantisch · *Lerntechnik:* keine der drei; tragend sind angeleitetes Entdecken (*enhanced discovery*) und Konkretheitsabbau (*concreteness fading*) · *Rolle:* Copilot (Kapitel 6.2.2) · *Gestaltet von:* Lehrende

i Prinzip

Selbst entdecken lässt Lernende nur dann besser lernen als direkte Instruktion, wenn das Entdecken angeleitet ist: durch Arbeitsaufträge, Rückmeldung, Beispiele oder die Aufforderung, das Gesehene zu erklären; ungeleitetes Entdecken schneidet schlechter ab (Alfieri et al., 2011). Eine zweite Regel betrifft die Reihenfolge der Darstellungen. Wer eine abstrakte Idee zuerst an einem vertrauten, konkreten Fall erlebt und die konkreten Züge dann schrittweise abbaut, überträgt sie besser als wer

nur das Konkrete oder nur das Abstrakte sieht (Fyfe et al., 2014). Fachfremde Zierelemente lenken ab (Kohärenzprinzip, *coherence principle*) (Mayer & Fiorella, 2014).

Empfehlung

Geben Sie jedem Widget drei bis fünf Arbeitsaufträge mit, von denen mindestens einer eine Vorhersage oder einen Beweis verlangt, und zeigen Sie die Formel neben dem Ergebnis, das sie erzeugt. Führen Sie dieselbe Idee zuerst in einem Alltagskontext der Studierenden ein und erst danach im Fachkontext. Prüfkriterium: Würde ein Student ohne die Arbeitsaufträge wissen, was er ausprobieren soll?

Umsetzung, Stand 10/2026

Jede Sitzung des SSCM-Moduls folgt derselben Reihenfolge in fünf Schritten. Ein Problem aus dem Kapitel steht am Anfang, bevor ein Fachbegriff fällt. Dann tragen Partyvorbereitung oder Umzugstag die Idee zum ersten Mal, danach folgt die Formel in Worten mit kurzen Übungen in HTML-Widgets, dann dieselbe Idee in der Produktion mit den Beispielen des Lehrbuchs, zuletzt zwischen Unternehmen in der Lieferkette. Die Reihenfolge ist Konkretheitsabbau im Sinne von Fyfe et al. (2014), auf eine ganze Sitzung gestreckt.
Bis zur fünften Woche entstanden sechs Widgets, jedes eine einzelne HTML-Datei, die auf dem Smartphone läuft und keine Anmeldung braucht. Das Linien-Widget zur Kapazität zeigt zwei Produktionslinien zur Wahl: die Pizzalinie einer Party und die Brötchenlinie der Bäckerei aus der Fallstudie (Kapitel 7.3.1). Studierende ändern Arbeitsschritte, Personal, Nachfrage und Losgröße und sehen sofort Linienkapazität, Engpasszeit und Durchlaufzeit. Drei Aufträge leiten das Ausprobieren: 24 Pizzen in unter zwei Stunden mit nur einer zusätzlichen Person oder einem zusätzlichen Ofen schaffen, den Belag-Schritt zum Engpass machen, und die Änderung finden, die am Ausstoß pro Stunde nichts ändert, und das beweisen. Das Prognose-Widget hat vier Reiter mit je einem Werkzeug, und jede Prognose entsteht nur aus den Tagen davor, so wie im Betrieb. Neben den Widgets stehen Colab-Notebooks (Rechenblätter mit Programmcode im Browser), in denen Studierende ei-

ne Rechnung zuerst von Hand lösen und dann als kleines Modell nachbauen, das Was-wäre-wenn-Fragen in Sekunden beantwortet; das Notebook der zweiten Woche endet mit einem Dashboard (Kennzahlen-Übersicht), das sie in vier Schritten selbst bauen.
Widgets, Notebooks und Datensätze entstanden mit Claude als Copilot nach Vorgaben der Lehrperson. Eine Regel der Arbeitsanweisung lautet, jede Zahl in der Programmiersprache Python zu rechnen, nie im Kopf des Modells. Fallstudie, Linienmodell im Notebook, Widget und die Übungsdaten zur Datenbereinigung teilen sich einen einzigen Zahlensatz, sodass ein Ergebnis aus dem Widget in der Fallstudie wieder auftaucht. Wie solche Widgets als geprüftes Modell mit Druckabbildung entstehen, zeigt Kapitel 6.2.2.1.

Ob die Widgets mehr bewirken als dieselben Aufgaben auf Papier, ist für dieses Modul nicht gemessen. Belegt ist die Wirkung der Bauprinzipien, Anleitung und Reihenfolge; das Widget macht sie für jede Woche praktikabel.

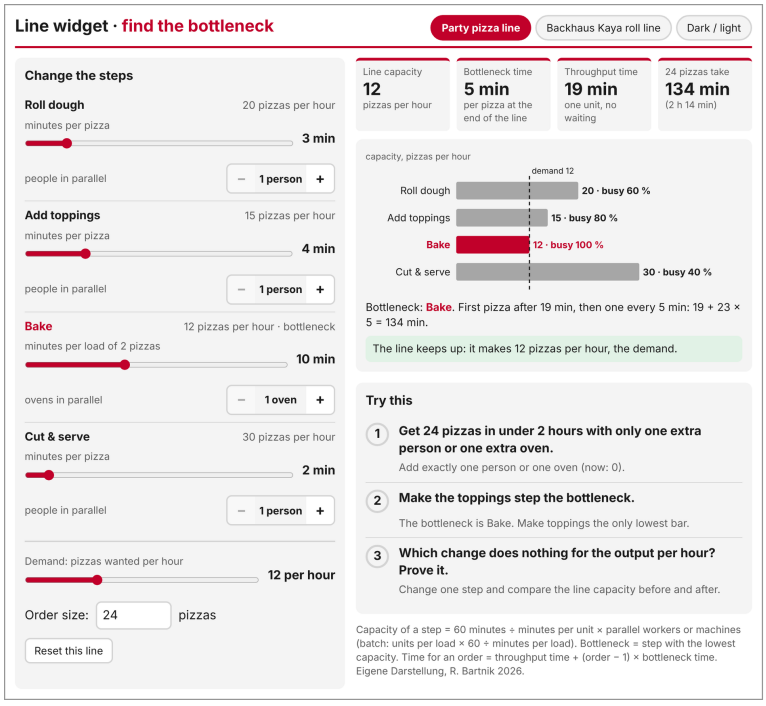
Ihre Einschätzung prüfen

„Ein interaktives Widget, an dem Studierende frei mit den Reglern experimentieren, lehrt mehr als eine direkte Erklärung, auch ohne Arbeitsaufträge."
Auflösung: nein. Selbst entdecken schlägt direkte Instruktion nur, wenn es angeleitet ist, durch Aufträge, Rückmeldung oder die Aufforderung, das Gesehene zu erklären; ungeleitetes Entdecken schneidet schlechter ab. Deshalb trägt jedes Widget im SSCM-Modul drei Aufträge, und einer davon verlangt einen Beweis.

Lernfrage. Das Linien-Widget fragt, welche Änderung am Ausstoß pro Stunde nichts ändert. Warum ist dieser Auftrag didaktisch wertvoller als „Finden Sie den Engpass"?

7.2.2 Tutoring: Übungstutor und sokratischer Tutor

Wissensform: semantisch · *Lerntechnik:* testgestützt (hoch) beim Übungstutor, fragebasierte Ausarbeitung (mittel) beim sokratischen Tutor · *Rolle:* Tutor (Kapitel 6.3) · *Gestaltet von:* Lehrende; Studierende bei studentisch gebauten Tutoren



Widget online ausprobieren

Abbildung 7.2. Linien-Widget aus Woche 2 des SSCM-Moduls in der Ausgangslage der Pizzalinie: links die vier Arbeitsschritte mit Schiebereglern, rechts Kennzahlen, Kapazität je Schritt mit dem Engpass Backen und die drei Arbeitsaufträge unter *Try this*. Erstellt mit Claude nach Vorgaben der Lehrperson. Das Widget gibt es nur online: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/line-widget.html aufrufen.

Prinzip

Ein KI-Tutor wirkt über das, was er die Lernenden tun lässt, nicht über das, was er weiß. Wer selbst erklärt, Fragen beantwortet und Fehler korrigiert, lernt mehr als wer Erklärungen nur aufnimmt (Chi & Wylie, 2014). Ein Tutor, der Musterlösungen der Lehrenden kennt und Schritt für Schritt anleitet, statt zu lösen, übertraf in einem randomisierten Vergleich im Physikunterricht eine Präsenzstunde mit aktivem Lernen (*active learning*) (Kestin et al., 2025). Ohne solche Leitplanken (*guardrails*) kehrt sich die Wirkung um: Schülerinnen und Schüler, die mit einem ungeschützten Chat übten, schnitten in der Prüfung ohne KI schlechter ab als die Kontrollgruppe (Bastani et al., 2025), und wer per Los Zugang zu einem Kurstutor bekam, der meist im voreingestellten Antwortmodus lief, schloss um 0,37 Standardabweichungen schlechter ab (Liu et al., 2026).

Empfehlung

Wenn Sie einen Tutor über Ihre Materialien betreiben, lassen Sie ihn vor jeder Erklärung einen eigenen Versuch verlangen und geben Sie ihm Musterlösungen als Grundlage seiner Hinweise, nicht als Antwort. Messen Sie den Erfolg an einer Prüfung ohne KI, nicht an der Nutzung. Prüfkriterium: Eine Studentin bittet dreimal um die Lösung. Bekommt sie sie?

Umsetzung, Stand 10/2026

Ausgangslage. Das Modul „Grundlagen der BWL“ versammelt im ersten Semester mehrere hundert Studierende mit sehr unterschiedlichem Vorwissen; die Sprechstunde erreicht einen Bruchteil, die häufigsten Fragen wiederholen sich.
Umsetzung. Seit dem Wintersemester 2025/26 erproben wir einen Tutor-Bot als Web-Anwendung, der aus den Modulmaterialien antwortet (vgl. Kapitel 6.3.3).

Vergleichsfälle. Zwei veröffentlichte Fälle mit derselben Architektur, ein Tutor über die eigenen Kursmaterialien, geben die Messlatte vor, an der wir unseren Tutor beurteilen. An der University of Maryland erhielten per Los 2.379 Studierende in den Kursen von 30 Lehrenden Zugang zu einem sol-

chen Tutor; nur 15 Prozent nutzten ihn, drei Viertel ihrer Anfragen verlangten eine fertige Antwort, und die Abschlussnote der Berechtigten lag 0,37 Standardabweichungen unter der Kontrollgruppe; die meisten Lehrenden hatten den voreingestellten Modus mit direkten Antworten (*direct instruction mode*) nicht umgestellt, und die Autoren vermuten, dass der Tutor das eigene Arbeiten am Material verdrängte (Liu et al., 2026). An der Hochschule Rhein-Waal lief ein sokratisch gebauter Tutor mit eigenen Quellen auf einem lokal betriebenen offenen Modell; nach einem Semester mit 62 Studierenden war die Bereitschaft, Fragen zu stellen, gestiegen, die Neugier auf das Warum aber gesunken, weil die Studierenden ihn trotz des sokratischen Designs als Antwortmaschine nutzten, sobald er es zuließ (Gerber et al., 2026). Für den BWL-Tutor ergeben sich daraus drei Kennzahlen, die wir erheben: der Anteil der Berechtigten, die den Tutor überhaupt nutzen; der Anteil der Anfragen, die eine fertige Antwort verlangen, gegenüber denen, die Rückmeldung auf eigene Arbeit suchen; und ob das Standardverhalten des Tutors bei einer offensichtlichen Prüfungsfrage auf das Material verweist oder löst.

Lernfrage. Der Tutor in Maryland war technisch einwandfrei und schadete trotzdem. Welche Einstellung war dafür verantwortlich, und mit welchem Testlauf vor dem Semester hätte man das erkannt?

7.3 Wissen umformen: anwenden gegen Interessen und Folgen

7.3.1 Fallstudien generieren: Backhaus Kaya

Wissensform: pragmatisch, mit semantischem Übergang · *Lerntechnik:* fragebasierte Ausarbeitung (mittel), Vorhersage vor dem Lernen · *Rolle:* Copilot (Kapitel 6.2) · *Gestaltet von:* Lehrende

> **i** Prinzip
>
> Geschichten werden besser verstanden und erinnert als Sachtexte (*expository texts*); eine Metaanalyse über mehr als 75 Stichproben mit über 33.000 Teilnehmenden fand den Vorteil robust (Mar et al., 2021). Willingham (2021) nennt die Merkmale, die eine Geschichte zum Lernanlass machen: eine Figur mit einem Ziel, ein Konflikt, Komplikationen

und kausal verbundene Ereignisse. Wer vor dem Lernen eine Vermutung abgibt, auch eine falsche, lernt die richtige Antwort danach oft besser (Vorabtest-Effekt, *pretesting effect*) (Pan & Carpenter, 2023).

Empfehlung

Lassen Sie das Sprachmodell die Geschichte schreiben, aber legen Sie die Zahlen vorher fest und lassen Sie jede Zahl in Code nachrechnen. Bauen Sie die typische Fehlvorstellung als Figur in die Handlung ein und bitten Sie die Studierenden um eine Vermutung, bevor sie rechnen. Prüfkriterium: Stimmen Fall, Lösungsschlüssel und Teaching Note (Begleittext für Lehrende) in jeder Zahl überein?

Umsetzung, Stand 10/2026

Backhaus Kaya ist eine erfundene Handwerksbäckerei in Gummersbach und begleitet das SSCM-Modul über mehrere Wochen. Der erste Teil beginnt um 2:40 Uhr nachts am Ofen. Aylin Kaya, 34, führt die Bäckerei, die ihr Vater gegründet hat; über dem Ofen hängt sein Satz *Never promise bread you cannot bake*. Die Einkäuferin einer regionalen Supermarktkette legt einen Vertrag auf den Tisch: 1.800 zusätzliche Brötchen pro Tag, sechs Tage die Woche, 0,32 Euro das Stück, Laufzeit ein Jahr, Antwort bis Montag. Gebacken wird in einem Fenster von vier Stunden vor Sonnenaufgang, und heute verlassen schon 1.500 Brötchen pro Nacht die Backstube. Der Backmeister hat sofort eine Lösung: einen dritten Mitarbeiter zum Formen, denn das sei die härteste Arbeit.
Diese Figur trägt die Fehlvorstellung, um die es geht. Die Fragen Q1 bis Q6 führen von der Kapazität jedes Schritts über Auslastung und Effizienz des Ofens zu drei Optionen mit Deckungsbeitrag und CO□-Bilanz. Der Engpass ist der Etagenofen mit 720 Brötchen pro Stunde; ein dritter Former hebt das Formen auf 1.260 Brötchen pro Stunde und ändert am Ausstoß der Linie nichts. Die Empfehlung, die jedes Team in drei Sätzen formuliert, muss ein Risiko nennen: Die längere Nacht bringt im ersten Jahr den kleineren Gewinn ohne Leasingbindung, hat aber keinen Puffer.
Zum Fall gehören eine Teaching Note mit Lernzielen, Zeitplan für 35 Minuten, Lösungsschlüssel und Tafelbild, ein Teaser-Video von fünf

Sekunden und ein Satz Rohdaten aus dem Ofenprotokoll, an denen die Studierenden am Nachmittag Datenbereinigung üben. Fall, Colab-Linienmodell, Linien-Widget und Ofenprotokoll teilen sich einen Zahlensatz aus einer gemeinsamen Spezifikation. Claude entwarf und prüfte Geschichte und Teaching Note; die Arbeitsanweisung verlangte, jede Zahl in Python zu rechnen, und jedes Dokument trägt einen Transparenzhinweis.

Der vierte Teil in der Prognosewoche beginnt mit einem Vorhersagekasten. Die Bäckerei liefert jede Nacht 1.800 Brötchen, immer gleich auf drei Filialen verteilt, und 6 Prozent kommen unverkauft zurück; drei Fragen bitten um eine Vermutung, die Studierende mit Datum notieren und am Ende des Tages mit ihrem Ergebnis vergleichen. Die Rechnungen aus dem Fall sind Stoff des zweiten Tests, die Geschichte ist also kein Schmuck, sondern Prüfungsgegenstand.



Teaser online
(5 s)

Abbildung 7.3. Standbild aus dem Teaser zur Fallstudie Backhaus Kaya (5 s, ohne Ton): Aylin Kaya nachts in der Backstube vor dem Etagenofen. KI-generiertes Video (LTX-2.5); Bäckerei und Figuren sind erfunden. Den Teaser gibt es nur online, zusammen mit Linien-Widget und Engpass-Animation zum selben Fall: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/galerie-animationen.html#kaya-teaser aufrufen.

Ein Sprachmodell schreibt eine solche Geschichte in Minuten. Die Arbeit der Lehrperson verschiebt sich auf zwei Stellen, die das Modell nicht übernimmt: die Wahl der Fehlvorstellung, die der Fall widerlegen soll, und die Prüfung, ob jede Zahl in Fall, Schlüssel und Widget dieselbe ist. Der Prompt *Fallstudie*

gemeinsam erstellen (Kapitel A.4.1) gibt dafür das Gerüst.

Lernfrage. Warum schlägt der Backmeister ausgerechnet einen dritten Former vor, und was ginge didaktisch verloren, wenn der Fall den Engpass gleich im ersten Absatz nennen würde?

7.3.2 Simulationen durch Lehrende: Prozess und Verhandlung

Wissensform: pragmatisch, mit semantischem Übergang · *Lerntechnik:* keine der drei; tragend sind Erfahrung und Debriefing · *Rolle:* Simulator (Kapitel 6.4), beim Bau Copilot (Kapitel 6.2.2) · *Gestaltet von:* Lehrende

Prinzip

Simulationen fördern komplexe Fähigkeiten in der Hochschule stark, und Gerüste (*scaffolding*) wie Beispiele oder Reflexionsphasen verstärken die Wirkung (Chernikova et al., 2020). Mit computergestützten Simulationsspielen lernten Teilnehmende in einer Metaanalyse mehr als mit Vergleichsmethoden, vor allem dann, wenn das Spiel andere Instruktion ergänzte, statt sie zu ersetzen, und beliebig oft zugänglich war (Sitzmann, 2011). Gelernt wird im Nachgespräch: Debriefings, in denen Lernende ihr Handeln systematisch auswerten, verbesserten die Leistung über 46 Stichproben um rund 25 Prozent (Effektstärke d = 0,67), in Simulationen wie im Ernstfall (Tannenbaum & Cerasoli, 2013). Für Lieferketten gilt das besonders. Im Beer Game (Planspiel zur Lieferkette) sanken die Bestellschwankungen erst, als die Beteiligten nach eigener Erfahrung gemeinsam eine Strategie entwickeln durften; Training allein verbesserte das Verständnis, nicht die Kette (Wu & Katok, 2006).

Empfehlung

Wenn Sie eine Simulation einsetzen, lassen Sie vor jedem Lauf eine Vorhersage notieren und führen Sie das Debriefing selbst, an den Daten dieses Laufs. Ein Sprachmodell kann die Simulation bauen oder das Gegenüber spielen; das Nachgespräch über die eigenen Entscheidungen bleibt bei Ihnen. Prüfkriterium: Steht im Ablaufplan nach dem Lauf eine Phase, in der die Lernenden ihre Vorhersage mit dem Ergebnis ver-

gleichen und den Unterschied begründen?

! Umsetzung, Planung Stand 10/2026

Das Bullwhip-Widget (zum Peitscheneffekt: Bestellschwankungen schaukeln sich auf) aus Kapitel 6.2.2.2 simuliert eine Lieferkette mit vier Stufen vom Händler bis zur Fabrik. Jede Stufe prognostiziert mit einem gleitenden Mittelwert und bestellt nach einer festen Regel; Regler stellen Lieferzeit und Prognosefenster ein, ein Schalter entscheidet, ob alle Stufen die Kassendaten des Händlers sehen. Bevor das Widget Ergebnisse zeigt, verlangt es eine Vorhersage, welche Stufe am stärksten schwankt. Drei Szenarien setzen die Regler auf typische Lagen. Das Modell entstand mit Claude als Copilot; zehn automatische Tests rechnen einen Nachfragesprung von Hand nach und prüfen den Händler gegen die Formel von F. Chen et al. (2000).

Zwei Befunde des Modells lohnen einen Satz im Unterricht. Ohne geteilte Daten schwankt die Fabrik doppelt so stark, wie die Formel als Untergrenze angibt, weil die Bestellungen der unteren Stufen nicht mehr unabhängig voneinander sind. Und wer Rücksendungen an den Lieferanten verbietet, senkt die Schwankung der Fabrik im zweiten Szenario auf ein Drittel; die Annahme der Formel, dass Bestellungen auch negativ sein dürfen, ist bei langen Lieferzeiten nicht harmlos.

Das Widget zeigt die Mechanik, nicht das Verhalten. Seine Stufen bestellen nach einer Regel, und keine vergisst die Ware unterwegs. Diesen Teil übernimmt das Beer Game, das die Studierenden vorher selbst spielen. Für das SSCM-Modul ist eine Sequenz in vier Schritten geplant: das Beer Game in der Übung; das Debriefing an den Bestellkurven jeder Stufe, mit der Frage, wer die offenen Bestellungen mitgezählt hat; das Widget, an dem die Teams die Ursachen einzeln an- und abschalten; zuletzt eine Ballade, die die Wirkungskette nachzeichnet. Die Reihenfolge folgt dem Prinzip zweifach: Das Widget ergänzt Spiel und Erklärung, statt sie zu ersetzen, und die Teams formulieren nach der Erfahrung gemeinsam eine Bestellstrategie, die sie am Widget prüfen.

Die zweite Form ist die Verhandlung mit einem simulierten Gegenüber. Der Prompt *Verhandlungssimulation* in Anhang A (Kapitel A.6.1) lässt ein Sprachmodell einen Lieferanten spielen, mit Rolle, Interessen und Verhaltensregeln, die die Lehrperson festlegt. Zwei Vorkehrungen aus Kapitel 6.4 gelten hier. Ein simuliertes Gegenüber trifft durchschnittli-

ches Verhalten besser als das eines bestimmten Menschen, und die Studierenden erfahren das vor dem Gespräch. Das Debriefing führt die Lehrperson: Sie bespricht am Gesprächsprotokoll, wo ein Zugeständnis zu früh kam und welches Argument das Gegenüber bewegt hat. Im Modul Supply Management setzen wir die Verhandlung im Dezember 2026 zum ersten Mal ein; bis dahin ist sie eine Option, keine erprobte Praxis.

Lernfrage. Im Widget sinkt die Schwankung der Fabrik, wenn alle Stufen die Kassendaten sehen, verschwindet aber nicht. Welche Ursache des Bullwhip-Effekts kann das Widget grundsätzlich nicht zeigen, und welcher Schritt der Sequenz muss sie deshalb übernehmen?

7.3.3 Simulationen und Planspiele selbst bauen: Gruppenprojekt mit Prüfzelle

Wissensform: pragmatisch · *Lerntechnik:* keine der drei; tragend sind simulationsbasiertes Lernen mit Gerüst und Projektlernen · *Rolle:* Simulator (Kapitel 6.4) · *Gestaltet von:* Studierende

Prinzip

Simulationen gehören zu den wirksamsten Mitteln, komplexe Fähigkeiten in der Hochschule zu fördern; eine Metaanalyse über 145 Studien fand einen großen Gesamteffekt ($g = 0{,}85$), und Gerüste verstärkten ihn: Lernende mit wenig Vorwissen profitierten von Beispielen, Lernende mit viel Vorwissen von Reflexionsphasen (Chernikova et al., 2020). Projektlernen hat gegenüber lehrerzentriertem Unterricht einen mittleren bis großen Effekt auf die Leistung ($d = 0{,}71$) (C.-H. Chen & Yang, 2019).

Empfehlung

Wenn Studierende mit KI-Hilfe ein Modell bauen, prüfen Sie zwei Dinge getrennt: ob das Modell richtig zählt, automatisch und gegen Regeln, die jedes richtige Modell erfüllt, und ob die Studierenden es verstehen, mündlich und mit einer Vorhersage vor jeder Änderung. Erlauben Sie

KI für alle Arbeitsschritte, aber nicht als Quelle für Zahlen. Prüfkriterium: Könnte eine Gruppe mit einem fehlerhaften Modell oder ohne eigenes Verständnis bestehen?

! Umsetzung, Stand 10/2026

Im SSCM-Gruppenprojekt wählen Teams aus vier bis fünf Studierenden ein reales Produkt, dessen Herstellung vier bis sechs Stationen hat, mit einem wichtigen Zukaufteil und zwei Bezugsquellen dafür. Sie bauen einen Datensatz im Format eines vorgegebenen Beispiels und simulieren in Colab ein Jahr Produktion in drei Szenarien: Normalbetrieb, eine Störung nach einem realen Vorbild und die Störung mit einer Gegenmaßnahme, je zehnmal mit verschiedenen Zufallszahlen. Eine Ergebnistafel vergleicht Stück pro Woche, Kosten pro Stück, Kilogramm CO□-Äquivalent pro Stück und Stillstandsstunden. Aus den Ergebnissen entstehen eine Animation und ein Poster, das zwei begutachtete Fachartikel als Quellen für die verwendeten Konzepte nutzt.
Erlaubt ist KI für jeden Arbeitsschritt, von der Datensuche über den Code bis zum Posterentwurf. Drei Regeln halten die Arbeit bei den Studierenden. Eine KI-Antwort ist keine Quelle; eine Zahl, die ein Modell vorschlägt, kommt erst in die Quellentabelle, wenn das Team sie auf eine öffentliche Angabe zurückführt oder mit eigener Rechnung schätzt. Jede Codezeile muss erklärt werden können. Und eine halbe Seite KI-Notiz hält fest, was an die KI ging, wie die Ausgabe geprüft wurde und welcher KI-Fehler gefunden wurde.
Zwei Prüfinstrumente trennen Richtigkeit und Verständnis. Eine unveränderliche Prüfzelle im Notebook testet fünf Regeln, die jedes korrekte Modell erfüllt, unabhängig vom Produkt: vollständiges Datenformat, keine Station über 100 Prozent ausgelastet, Little's Law (Bestand gleich Durchsatz mal Durchlaufzeit) innerhalb von zehn Prozent, keine Teile aus dem Nichts, kein Verlust im Normaljahr. Die Projektseite begründet das mit einem Satz, der für jede KI-gestützte Modellierung gilt: Eine Simulation druckt immer Zahlen, auch wenn sie falsch zählt, und Code mit KI-Hilfe läuft glatt und sieht überzeugend aus, ob er stimmt oder nicht. Die Prüfzelle wirkt wie eine Probebilanz in der Buchhaltung, die einen Fehler anzeigt, bevor jemand weiß, wo er steckt. Über das Verständnis entscheidet die Postersession. Jedes Mitglied beantwortet zwei Fragen allein, zu einer Zahl, zum Modell oder zu einem Fachartikel;

dann ändert der Prüfer eine Zahl im Datensatz, und die Gruppe sagt vor dem neuen Lauf voraus, in welche Richtung sich jede Kennzahl bewegt und warum. Eine falsche Vorhersage mit tragfähiger Begründung kostet wenig, eine richtige ohne Begründung bringt wenig.
Im Sinne von Carlile (2004) ist das Projekt pragmatisch: Die Studierenden wenden ihr Wissen gegen eine Störung und deren Folgen an, und die Gegenmaßnahme kostet Geld, Zeit oder CO□. In der Sprache des 4D-Modells (vier Kompetenzen im Umgang mit KI) (Dakan & Feller, 2025) übernimmt die Prüfzelle einen Teil der Urteilsprüfung (*Discernment*), die Postersession prüft die Verantwortung (*Diligence*).

Lernfrage. Die Prüfzelle prüft nicht, ob die gewählte Gegenmaßnahme gut ist. Warum ist das eine Stärke des Verfahrens und keine Lücke?

7.3.4 Karriereberater: Erstsemester bauen KI-Werkzeuge für andere

Wissensform: pragmatisch · *Lerntechnik:* keine der drei; tragend sind Projektlernen und die Rückmeldung durch Nutzende · *Rolle:* Tutor (Kapitel 6.3), der Interviewtrainer als Simulator (Kapitel 6.4) · *Gestaltet von:* Studierende

Prinzip

Projektlernen hat gegenüber lehrerzentriertem Unterricht einen mittleren bis großen Effekt auf die Leistung (C.-H. Chen & Yang, 2019). Wenn Studierende ein Werkzeug für andere bauen, wird ihr Wissen pragmatisch im Sinne von Carlile (2004): Es muss sich gegen die Interessen und den Alltag einer Zielgruppe bewähren, die das Team erst kennenlernen muss. Rückmeldung wirkt umso stärker, je mehr Information sie enthält (Wisniewski et al., 2020). Für ein Team, das baut, ist der Test mit Nutzenden die Rückmeldung mit dem meisten Gehalt, denn er zeigt, wo und warum eine Person mit dem Werkzeug scheitert.

Empfehlung

Wenn Studierende ein KI-Werkzeug für eine Zielgruppe bauen, bewerten Sie drei Säulen getrennt: eine Bedarfsanalyse mit Interviews, einen lauffähigen Prototyp und einen Test mit Nutzenden. Verlangen Sie,

dass das Sprachmodell nur Daten erklärt, die aus einer benannten Quelle stammen. Prüfkriterium: Kann das Team einen Befund aus dem Nutzertest nennen, der den Prototyp verändert hat?

! Umsetzung, Stand 10/2026

Im Modul *Wissenschaftliches Arbeiten und Grundlagen der Projektarbeit* (WAGP) im ersten Semester der Ingenieurstudiengänge bauen Teams seit dem Wintersemester 2024/25 in jedem Semester einen Prototyp mit generativer KI zu einem gemeinsamen Thema: Fachtutoren, Lernspiele, Karriere- und Jobberater, zuletzt KI-Assistenten für Berufsfelder mit Praxisbezug. Der Projektbericht zum vierten Meilenstein enthält eine Bedarfsanalyse mit meist fünf oder sechs Interviews, den Prototyp mit Code und eine Evaluation. Eine Auswertung aller 56 Berichte aus vier Semestern nach diesen drei Säulen ergab 18 starke, 31 solide und 7 schwache Projekte. Den soliden fehlt fast immer dieselbe Säule, der Test mit Nutzenden, und am häufigsten den technisch ehrgeizigen Karriere-Bots des Wintersemesters 2025/26: Von 18 Teams erfüllten fünf alle drei Säulen.

Die Karriereberater zeigen drei Bauweisen. Die erste macht das Modulhandbuch zur Wissensbasis. Ein Team durchsucht es mit TF-IDF, einem klassischen Suchverfahren, das ein Wort umso höher gewichtet, je seltener es im Gesamtbestand vorkommt, und gibt die Treffer einem Sprachmodell mit, das daraus antwortet; das Team nannte das „RAG ohne Vektordatenbank“. RAG (*Retrieval-Augmented Generation*, Kapitel 2.4.1) bezeichnet genau dieses Muster aus Suche und Antwort; eine Vektordatenbank, die Texte nach Bedeutungsähnlichkeit statt nach gleichen Wörtern findet, ist dafür üblich, aber nicht nötig. Ein anderes legt Modulhandbuch und Stellenanzeigen nebeneinander, damit Studierende einschätzen können, welche Anforderungen ihr Studium abdeckt. Die zweite Bauweise beschränkt das Modell auf geprüfte Daten. Mehrere Teams ließen Suche und Zuordnung ohne KI laufen, über die Jobsuche-Schnittstelle der Bundesagentur für Arbeit oder ein regelbasiertes Matching (Zuordnung) auf Moduldaten, und das Sprachmodell nur sortieren und begründen; ein Team verzichtete ausdrücklich auf Gehälter, die das Modell schätzen würde. Die dritte Bauweise ist der Interviewtrainer, ein Simulator. Ein Team leitete den System-Prompt (feste Grundanweisung an die KI) seines Bewerbungstrainers aus der Feed-

backforschung und dem Konzept erwünschter Schwierigkeiten (*desirable difficulties*) ab, ein anderes nutzt die Fragenkataloge regionaler Firmen.
Der lehrreichste Befund kam aus einem Test mit sechs Personen: Sie wollten Orientierung, nicht mehr Information. Der Satz verschiebt die Aufgabe eines Karriereberaters vom Antworten zum Ordnen, und keine Bedarfsanalyse hatte ihn vorher geliefert. Im folgenden Semester übertrug ein Team das Muster auf einen Beruf außerhalb der Hochschule und baute einen Job-Buddy für Pflegekräfte, den es nach sechs Interviews mit vier Pflegekräften testete. Die Auswertung zeigt auch, was in einer ersten Projektarbeit mit KI schiefgeht: In zwei Abgaben stand der API-Schlüssel (Schlüssel für die Programmierschnittstelle), mit dem das Programm beim Modellanbieter abgerechnet wird, im Klartext im Code, in einer weiteren lagen Passwörter offen. Ein solcher Schlüssel ist wie eine Kreditkarte; wer ihn findet, bezahlt auf fremde Rechnung.

Was die Projekte nicht zeigen, ist ein Nutzen für die Ratsuchenden über die Testsitzungen hinaus; sie sind Prototypen von Erstsemestern. Das Lernziel liegt bei den Bauenden: Bedarf erheben, ein Werkzeug bauen und an Menschen prüfen, die es brauchen.

Ihre Einschätzung prüfen

„Wenn Erstsemester KI-Werkzeuge für eine Zielgruppe bauen, fehlt den Projekten am häufigsten nicht die Technik, sondern der Test mit Nutzenden.“
Auflösung: ja. In 56 Projektberichten aus vier Semestern fehlte den soliden Projekten fast immer dieselbe Säule, der Test mit Nutzenden, am häufigsten bei den technisch ehrgeizigen Karriere-Bots: Von 18 Teams erfüllten fünf alle drei Säulen. Dabei lieferte gerade ein Nutzertest den lehrreichsten Befund. Die Testpersonen wollten Orientierung, nicht mehr Information.

Lernfrage. Ein Karriere-Bot beantwortet die Frage nach dem Einstiegsgehalt im Wirtschaftsingenieurwesen mit einer konkreten Zahl. Gegen welche Bauweise aus den Projekten verstößt er, und wie sollte er stattdessen antworten?

7.3.5 Projektlernen mit Praxispartnern: RAG und Einkaufs-Workflows

Wissensform: pragmatisch · *Lerntechnik:* keine der drei; tragend ist Projektlernen · *Rolle:* Copilot (Kapitel 6.2), Hiwi (Kapitel 6.1) · *Gestaltet von:* Studierende

Prinzip

Projektlernen hat gegenüber lehrerzentriertem Unterricht einen mittleren bis großen Effekt auf die Leistung (C.-H. Chen & Yang, 2019). Über eine Organisationsgrenze gilt dabei Carliles Stufenfolge wörtlich: Ein gemeinsames Vokabular genügt erst, wenn die Bedeutungen geklärt sind, und Wissen wird erst umgeformt, wenn beide Seiten Interessen und Folgen auf den Tisch legen (Carlile, 2004).

Empfehlung

Wenn Studierende für einen Praxispartner bauen, verengen Sie den Anwendungsfall vor dem Start auf eine Frage, die sich mit erfundenen Beispieldaten beantworten lässt, und regeln Sie die Vertraulichkeit vor dem ersten Interview. Prüfen Sie mündlich am Prototyp. Prüfkriterium: Kann das Team ohne Zugang zu Partnerdaten einen Prototyp zeigen, den der Partner an einem echten Fall beurteilen kann?

Umsetzung, Stand 10/2026

Ausgangslage. Im Sommersemester 2026 lief erstmals das Wahlpflichtmodul „GenAI im Einsatz“ (GenAI: generative KI), in dem Studierende für reale Anwendungsfälle aus dem Einkauf von Partnerorganisationen KI-gestützte Werkzeuge entwerfen: ein Automobilzulieferer (Konzern), ein kirchlicher Sozialträger mit eigener Einkaufsabteilung und der Einkauf der eigenen Hochschule hatten vorab beschrieben, wo sie sich Unterstützung vorstellen, von der Gestaltung von Rahmenverträgen über Lieferantenrecherche und Preisbenchmarks (Preisvergleiche mit dem Markt) bis zu automatisierten Berichten aus Finanz- und Lieferantendaten. Ein Einkaufsleiter formulierte das Kernproblem als Informations- und Kompetenzasymmetrie zwischen Bedarfsträger und Einkauf: Wer einen Laborkühlschrank für 3.000 Euro bestellt, sieht

ein Standardgerät; der Einkauf sieht Lieferkonditionen, Energieklasse und Folgekosten, und beide reden aneinander vorbei. Im Wintersemester 2026/27 folgt ein Guided Project (betreutes Praxisprojekt) mit fünf Masterstudierenden, die für einen internationalen Hersteller von Antriebstechnik den Angebotsanfrage-Zyklus (*Request for Quotation*) mit generativer KI unterstützen sollen.

Umsetzung. Das Wahlpflichtmodul (4 Leistungspunkte nach ECTS, 40 Stunden Präsenz) arbeitet in drei Schritten: Studierende wählen einen Use Case (Anwendungsfall) und klären ihn mit dem Partner, bauen einen Prototyp mit eigenen Quellen, Agenten und automatisierten Arbeitsabläufen, sogenannten Workflows, und stellen ihn dem Partner vor. Geprüft wird zu 70 Prozent mündlich, zu 30 Prozent im Antwortwahlverfahren, also prozessnah im Sinne von Kapitel 5.5. Das Guided Project ist in drei Phasen über 16 Wochen angelegt: Benchmarking (Literatur und Praxis zu GenAI im Einkauf), Konzeptentwicklung mit Experteninterviews und Prozessmodellierung des Ist- und Soll-Prozesses, Prototyp mit Testplan und Testfällen. Da die Studierenden keinen Systemzugang beim Partner haben, arbeiten sie mit Interviews und anonymisierten Beispieldaten.

Das Guided Project organisiert sich in einem einzigen Git-Repository (Projektordner mit Versionsverwaltung), das zugleich Projektakte und Arbeitsplatz ist. Fünf Regeln stehen am Anfang der Startseite: kein Projektmaterial außerhalb des Repositorys; nur Text, also Markdown (Text mit einfachen Formatierungszeichen), CSV (Tabellen als Text) und Code, Diagramme in Mermaid (Textsprache für Diagramme), Prozessmodelle als BPMN-Export (*Business Process Model and Notation*, die Standardnotation für Prozessmodelle); Termine nur als Meilensteine in der Projektverwaltung, nie in Dokumenten; ausschließlich erfundene Beispieldaten, keine echten Anfragen, Preise oder Lieferantendaten; und Pseudonyme statt Firmen- und Personennamen, auch in Interviewprotokollen, bevor sie eingecheckt (im Repository gespeichert) werden. Risiken und Besprechungen laufen über Formulare in der Aufgabenverwaltung, und ein eigener Abschnitt der Startseite richtet sich an Sprachmodelle, die mit dem Repository arbeiten: Die Startseite ist die Karte, der Ordner mit Projektplan und Rollenmatrix gilt immer in der aktuellen Fassung, frühere Stände zeigt die Versionsgeschichte.

Carlile beschreibt solche Objekte als Grenzobjekte (*boundary objects*), die Wissen über Abteilungsgrenzen tragen; das Repository ist die Form,

die er *repository* nennt, ein gemeinsamer Bestand mit gemeinsamen Bezeichnungen (Carlile, 2002). Zwischen Hochschule und Partnerunternehmen erfüllt es diese Funktion wörtlich, und die Regeln zu Beispieldaten und Pseudonymen lösen das Vertraulichkeitsproblem, bevor ein Prototyp entsteht. Neu ist der dritte Leser: Weil alles als Text vorliegt und die Startseite ein Sprachmodell anleitet, kann ein Modell den Projektstand lesen, ohne dass jemand ihn zusammenfasst.

Ihre Einschätzung prüfen

„Studierende können für einen Praxispartner einen brauchbaren KI-Prototyp bauen, ohne echte Unternehmensdaten zu sehen."
Auflösung: eher ja. Ein eng gefasster Anwendungsfall mit erfundenen Beispieldaten und Pseudonymen löst das Vertraulichkeitsproblem, bevor ein Prototyp entsteht, und der Partner beurteilt den Prototyp an einem echten Fall. Belegt ist das bisher als Gestaltungsregel, nicht als gemessenes Ergebnis; das Praxisprojekt mit Masterstudierenden läuft erst im Wintersemester 2026/27.

Lernfrage. Warum gilt Carliles Stufenfolge beim Projekt mit Praxispartnern wörtlich, während sie im übrigen Kapitel nur eine Analogie ist?

7.4 Was die Beispiele gemeinsam zeigen

Kernaussagen

Zu Lernziel 1: Vom Prinzip zur Umsetzung

1. Jedes Beispiel beginnt mit einem Prinzip der Lernforschung; das Werkzeug ist austauschbar, das Prinzip nicht. Wer ein Beispiel übernimmt, übernimmt das Prüfkriterium der Empfehlung, nicht das Produkt.
2. Belegt sind die Bauprinzipien, nicht die Umsetzungen. Für keines der Beispiele liegt bisher ein Wirkungsnachweis im eigenen Kurs vor; offene Ergebnisse sind als solche gekennzeichnet.

Zu Lernziel 2: Wissensform, Lerntechnik, Rolle

3. Je höher die Wissensform, desto weniger trägt das Werkzeug allein. Für syntaktisches Wissen genügt Abruf mit Rückmeldung (Kapitel 7.1.1); semantisches braucht angeleitetes Entdecken mit Erklärungsauftrag (Kapitel 7.2.1); pragmatisches braucht eigenes Handeln und ein Nachgespräch, das die Lehrperson führt (Kapitel 7.3.2).

Zu Lernziel 3: Prüfkriterien übertragen

4. Die Arbeit der Lehrperson verschiebt sich vom Herstellen zum Prüfen. Ein Sprachmodell schreibt Fallstudie, Song und Widget in Minuten; Qualität entsteht dort, wo jede Zahl in Code nachgerechnet, jede Zeile gegen das Regelwerk geprüft und jedes Modell durch Tests geschickt wird.
5. Leitplanken entscheiden über die Wirkung eines Tutors. Derselbe Tutor schadet, wenn er Lösungen herausgibt, und hilft, wenn er Musterlösungen als Grundlage nutzt und einen eigenen Versuch verlangt (Kapitel 7.2.2).
6. Wenn Studierende bauen, fehlt am häufigsten der Test mit Nutzenden. Er gehört getrennt bewertet, weil er die reichste Rückmeldung liefert (Kapitel 7.3.4).

i Schlüsselbegriffe

Erklären Sie jeden Begriff in zwei, drei Sätzen in eigenen Worten; die Seitenzahl führt zur Stelle, an der er eingeführt wird.

- Syntaktisches Wissen (übertragen; *transferring*) ..... S. 241
- Semantisches Wissen (übersetzen; *translating*) ..... S. 241
- Pragmatisches Wissen (umformen; *transforming*) ..... S. 241
- Musikalische Merkhilfe (*musical mnemonic*) ..... S. 245
- Lösungsbeispiel (*worked example*) ..... S. 245
- Angeleitetes Entdecken (*enhanced discovery*) ..... S. 249
- Konkretheitsabbau (*concreteness fading*) ..... S. 249
- Gerüst (*scaffolding*) ..... S. 257
- Prüfzelle ..... S. 260
- Test mit Nutzenden ..... S. 261
- Grenzobjekt (*boundary object*) ..... S. 265

Übung. Tragen Sie zu jeder Szene den passenden Begriff aus der Liste ein. Lösungen: Anhang B.

Nr.	Szene	Begriff
1	Studierende bereiten für einen Praxispartner eine Beschaffungsentscheidung vor, bei der Einkauf und Produktion verschiedene Ziele verfolgen; ihre Empfehlung muss vor beiden Seiten bestehen. Welche Wissensform nach Carlile verlangt das? *Herkunft: konstruiert nach der Ordnung des Kapitels (Kapitel 7) und Kapitel 7.3.5.*	
2	Damit Namen und Reihenfolge der Prognoseverfahren sitzen, hören Studierende über zwei Wochen verteilt immer wieder ein kurzes Lied, das die Verfahren nacheinander besingt. *Herkunft: konstruiert nach dem Lernsong (Kapitel 7.1.2).*	
3	Ein Widget zeigt dieselbe Idee zuerst an der Schlange vor der Mensakasse, dann an einem Lager mit Stückzahlen und zuletzt nur noch als Formel ohne Bild. *Herkunft: konstruiert nach den Widgets (Kapitel 7.2.1).*	
4	Zum Bullwhip-Widget bekommen die Studierenden vier Aufträge, darunter: Sagen Sie voraus, was mit den Bestellungen der Fabrik geschieht, wenn sich die Lieferzeit verdoppelt, und erklären Sie das Ergebnis. *Herkunft: konstruiert nach der Empfehlung zu den Widgets (Kapitel 7.2.1; Kapitel 6.2.2.2).*	
5	Im Simulationsprojekt prüft ein Codeblock, den die Teams nicht ändern dürfen, ob in ihrem Modell Bestand, Durchsatz und Durchlaufzeit zusammenpassen und keine Station über ihrer Kapazität arbeitet. *Herkunft: Gruppenprojekt mit Produktionssimulation (Kapitel 7.3.3).*	

6 Ein Erstsemesterteam setzt zwei Kommilitoninnen, die den Karriere-Bot nie gesehen haben, vor den Prototyp, lässt sie eine Praktikumsstelle suchen und notiert, an welcher Stelle sie aufgeben.
Herkunft: konstruiert nach den Karriereberater-Projekten (Kapitel 7.3.4).

Wiederholung aus früheren Kapiteln. *Erklären Sie diese Begriffe noch einmal in eigenen Worten, bevor Sie nachschlagen.*

- Discernment ..... S. 135
- Protégé-Effekt (*protégé effect*) ..... S. 223
- Mündlichkeit ..... S. 163

i Lernfragen

Wiederholen

1. Welche drei Wissensformen unterscheidet Carlile (2004), und warum ist ihre Übertragung auf das Lernen nur beim Projektlernen mit Praxispartnern mehr als eine Analogie?
2. Was zeigte der Vergleichsfall der University of Maryland über Nutzung und Wirkung eines Tutors, der aus den eigenen Kursmaterialien antwortet?
3. Welche drei Kennzahlen erheben wir für den BWL-Tutor in Kapitel 7.2.2?

Anwenden

4. Welches Beispiel liegt Ihrem eigenen Modul am nächsten? Bestimmen Sie Wissensform und Lerntechnik, bevor Sie ein Werkzeug auswählen, und nennen Sie den Engpass (Material, Zugänge, Partner, Prüfungsform), der bei Ihnen zuerst aufträte.
5. Formulieren Sie für ein eigenes Vorhaben Prinzip, Empfehlung und Prüfkriterium nach der Schablone dieses Kapitels. Besteht Ihre Empfehlung den Austauschtest?

Beurteilen

6. Der Tutor an der Hochschule Rhein-Waal war sokratisch gebaut und wurde trotzdem als Antwortmaschine genutzt. Was folgt daraus für den BWL-Tutor?

Lösungshinweise, auch zu den Lernfragen in den Beispielen: Anhang B.

Literaturverzeichnis

Adesope, O. O., Trevisan, D. A., & Sundararajan, N. (2017). Rethinking the use of tests: A meta-analysis of practice testing. *Review of Educational Research*, *87*(3), 659–701. https://doi.org/10.3102/0034654316689306.

Alfieri, L., Brooks, P. J., Aldrich, N. J., & Tenenbaum, H. R. (2011). Does discovery-based instruction enhance learning? *Journal of Educational Psychology*, *103*(1), 1–18. https://doi.org/10.1037/a0021017.

Barbieri, C. A., Miller-Cotto, D., Clerjuste, S. N., & Chawla, K. (2023). A meta-analysis of the worked examples effect on mathematics performance. *Educational Psychology Review*, *35*(1), 11. https://doi.org/10.1007/s10648-023-09745-1.

Bastani, H., Bastani, O., Sungu, A., Ge, H., Kabakcı, Ö., & Mariman, R. (2025). Generative AI without guardrails can harm learning: Evidence from high school mathematics. *Proceedings of the National Academy of Sciences*, *122*(26), e2422633122. https://doi.org/10.1073/pnas.2422633122.

Carlile, P. R. (2002). A pragmatic view of knowledge and boundaries: Boundary objects in new product development. *Organization Science*, *13*(4), 442–455. https://doi.org/10.1287/orsc.13.4.442.2953.

Carlile, P. R. (2004). Transferring, translating, and transforming: An integrative framework for managing knowledge across boundaries. *Organization Science*, *15*(5), 555–568. https://doi.org/10.1287/orsc.1040.0094.

Cepeda, N. J., Pashler, H., Vul, E., Wixted, J. T., & Rohrer, D. (2006). Distributed practice in verbal recall tasks: A review and quantitative synthesis. *Psychological Bulletin*, *132*(3), 354–380. https://doi.org/10.1037/0033-2909.132.3.354.

Chen, C.-H., & Yang, Y.-C. (2019). Revisiting the effects of project-based learning on students' academic achievement: A meta-analysis investigating moderators. *Educational Research Review*, *26*, 71–81. https://doi.org/10.1016/j.edurev.2018.11.001.

Chen, F., Drezner, Z., Ryan, J. K., & Simchi-Levi, D. (2000). Quantifying the

bullwhip effect in a simple supply chain: The impact of forecasting, lead times, and information. *Management Science*, *46*(3), 436–443. https://doi.org/10.1287/mnsc.46.3.436.12069.

Chernikova, O., Heitzmann, N., Stadler, M., Holzberger, D., Seidel, T., & Fischer, F. (2020). Simulation-based learning in higher education: A meta-analysis. *Review of Educational Research*, *90*(4), 499–541. https://doi.org/10.3102/0034654320933544.

Chi, M. T. H., & Wylie, R. (2014). The ICAP framework: Linking cognitive engagement to active learning outcomes. *Educational Psychologist*, *49*(4), 219–243. https://doi.org/10.1080/00461520.2014.965823.

Clark, D. B., Tanner-Smith, E. E., & Killingsworth, S. S. (2016). Digital games, design, and learning: A systematic review and meta-analysis. *Review of Educational Research*, *86*(1), 79–122. https://doi.org/10.3102/0034654315582065.

Dakan, R., & Feller, J. (2025). *The AI Fluency Framework: A descriptive and normative model of human-AI interaction for higher education (Version 1.1)*. Higher Education Authority.

Derks-Dijkman, M. W., Schaefer, R. S., & Kessels, R. P. C. (2024). Musical mnemonics in cognitively unimpaired individuals and individuals with Alzheimer's dementia: A systematic review. *Neuropsychology Review*, *34*(2), 455–477. https://doi.org/10.1007/s11065-023-09585-4.

Dunlosky, J., Rawson, K. A., Marsh, E. J., Nathan, M. J., & Willingham, D. T. (2013). Improving Students' Learning With Effective Learning Techniques: Promising Directions From Cognitive and Educational Psychology. *Psychological science in the public interest : a journal of the American Psychological Society*, *14*(1), 4–58. https://doi.org/10.1177/1529100612453266.

Fyfe, E. R., McNeil, N. M., Son, J. Y., & Goldstone, R. L. (2014). Concreteness fading in mathematics and science instruction: A systematic review. *Educational Psychology Review*, *26*(1), 9–25. https://doi.org/10.1007/s10648-014-9249-3.

Gerber, A., Lorenz, L., & Pfeiffer, U. (2026). KI-Tutoren in der Lehre: rechtlich sicher, didaktisch wertvoll, technisch innovativ. In J. Leschke, R. Queckenberg, & M. Persike (Hrsg.), *Learning analytics, artificial intelligence und data mining in der hochschulbildung*: (S. 57–64). transcript. https://doi.org/10.14361/9783839458761-057.

Katz, J. J., Ando, M., & Wiseheart, M. (2021). Optimizing song retention through the spacing effect. *Cognitive Research: Principles and Implications*, *6*(1), 79. https://doi.org/10.1186/s41235-021-00345-7.

Kestin, G., Miller, K., Klales, A., Milbourne, T., & Ponti, G. (2025). AI tu-

toring outperforms in-class active learning: an RCT introducing a novel research-based design in an authentic educational setting. *Scientific Reports*, *15*(1), 17458. https://doi.org/10.1038/s41598-025-97652-6.

Liu, J., Sweet, T., Chen, M. H., Engelberg, J., Masters, M. C., Clark, M., Persaud, A., Lancaster, A., Hollingsworth, J. K., & Rice, J. K. (2026). *The effects of course-integrated AI tutoring on student performance and engagement: A randomized university trial* (EdWorkingPaper; Nr. 26-1598). Annenberg Institute at Brown University. https://doi.org/10.26300/y3f8-vh05.

Mar, R. A., Li, J., Nguyen, A. T. P., & Ta, C. P. (2021). Memory and comprehension of narrative versus expository texts: A meta-analysis. *Psychonomic Bulletin & Review*, *28*(3), 732–749. https://doi.org/10.3758/s13423-020-01853-1.

Mayer, R. E., & Fiorella, L. (2014). Principles for Reducing Extraneous Processing in Multimedia Learning: Coherence, Signaling, Redundancy, Spatial Contiguity, and Temporal Contiguity Principles. In R. E. Mayer (Hrsg.), *The Cambridge handbook of multimedia learning*: (S. 279–315). Cambridge University Press. https://doi.org/10.1017/cbo9781139547369.015.

Mocko, M., Wagler, A. E., Lesser, L. M., Francis, W. S., Blush, J. M., Schleicher, K., & Barrientos, P. S. (2024). What They Remember May Not Be What They Understand: A Study of Mnemonic Recall and Performance by Introductory Statistics Students. *Journal of Statistics and Data Science Education*, *32*(4), 416–431. https://doi.org/10.1080/26939169.2024.2334905.

Pan, S. C., & Carpenter, S. K. (2023). Prequestioning and pretesting effects: A review of empirical research, theoretical perspectives, and implications for educational practice. *Educational Psychology Review*, *35*(4), 97. https://doi.org/10.1007/s10648-023-09814-5.

Roediger, H. L., & Karpicke, J. D. (2006). Test-enhanced learning: taking memory tests improves long-term retention. *Psychological science*, *17*(3), 249–255. https://doi.org/10.1111/j.1467-9280.2006.01693.x.

Sitzmann, T. (2011). A meta-analytic examination of the instructional effectiveness of computer-based simulation games. *Personnel Psychology*, *64*(2), 489–528. https://doi.org/10.1111/j.1744-6570.2011.01190.x.

Tannenbaum, S. I., & Cerasoli, C. P. (2013). Do team and individual debriefs enhance performance? A meta-analysis. *Human Factors*, *55*(1), 231–245. https://doi.org/10.1177/0018720812448394.

Willingham, D. T. (2021). *Why don't students like school?: A cognitive scientist answers questions about how the mind works and what it means for the classroom*. Jossey-Bass.

Wisniewski, B., Zierer, K., & Hattie, J. (2020). The power of feedback revisi-

ted: A meta-analysis of educational feedback research. *Frontiers in Psychology*, *10*, 3087. https://doi.org/10.3389/fpsyg.2019.03087.

Wouters, P., van Nimwegen, C., van Oostendorp, H., & van der Spek, E. D. (2013). A meta-analysis of the cognitive and motivational effects of serious games. *Journal of Educational Psychology*, *105*(2), 249–265. https://doi.org/10.1037/a0031311.

Wu, D. Y., & Katok, E. (2006). Learning, communication, and the bullwhip effect. *Journal of Operations Management*, *24*(6), 839–850. https://doi.org/10.1016/j.jom.2005.08.006.

A Best-Practice-Sammlung didaktischer Prompts und GenAI Aufgabenstellungen

Vorbemerkung zur Struktur der Sammlung

Die Sammlung entstand 2024/25. Die didaktischen Prompts (Eingaben an die KI) wurden aus verschiedenen internationalen Quellen zusammengetragen, übersetzt und angepasst. Ältere Prompts tragen Labels aus Prompt-Schemata wie RTF (Rolle, Aufgabe, Format) oder CREATE (zusätzlich Beispiele, Vorgaben und Prüfschritte); diese Labels sind eine Lesehilfe, keine Bedingung dafür, dass ein Prompt wirkt.

Die im Buch abgedruckten Prompts sind neu gefasst und folgen zwei Mustern (Kapitel 2.3). Ein **Arbeitsauftrag** nennt Ziel, Wozu, Material und Abnahmekriterien, denn das Modell liefert ein Werkstück, das die Lehrperson prüft; bei langen oder teuren Ergebnissen kommt eine Zwischenabnahme hinzu. Eine **Verhaltensbeschreibung** legt Zweck, Ablauf, Regeln mit ihren Gründen, Grenzfälle und das Ende des Gesprächs fest, denn bei Tutoren und Simulationen ist das Gespräch selbst das Produkt; entsteht dabei ein Werkstück wie ein Fall oder eine Risikotabelle, nennt das Ende die Kriterien dafür. Jeder neu gefasste Prompt nennt außerdem die Modellklasse, für die er gedacht ist (Kapitel 2.2): ein großes Modell mit hoher Denkstufe, wo Fachurteil oder ein langes Rollenspiel gefragt ist, ein kleines, wo das Material oder die Studierenden das Ergebnis tragen. Stand: November 2026.

Im Buch stehen elf Prompts und Aufgabenstellungen in voller Länge, zwei bis vier für jede der Rollen Hiwi, Tutor, Copilot und Simulator (Kapitel 6). Die übrigen 23 sind am Ende des Anhangs mit ihrer Funktion aufgeführt (Tabelle A.1); die vollständige Sammlung mit Kopierfunktion steht in der Online-Version (Abbildung A.1).

Neben **Beispielen für die Prompts** sind jeweils auch detaillierte **Aufgabenstellungen** aufgeführt, die zeigen, wie wir die Prompts in eine Lehreinheit

integrieren können. **Testen Sie die Prompts am Besten gleich** im Sprachmodell Ihrer Wahl, oder lassen Sie den Prompt dort auf eine spezifische Lehreinheit hin anpassen. Sie wollen vergleichen, wie die **Prompts mit verschiedenen Modellen funktionieren?** Nutzen Sie dafür die LM-Arena (Plattform zum direkten Vergleich von Sprachmodellen): https://lmarena.ai/de?mode=side-by-side. Viel Spaß dabei!

A.1 Hiwi: Schnelle Hilfe zur Lehrgestaltung

A.1.1 Hiwi: Aktivierungs-Coach für die Präsenzlehre

Funktion: Vorlesungen interaktiver machen; Fragen/Checks einbauen; Aktivierungsimpulse generieren.

Didaktische Elemente: Retrieval Practice (Abrufübungen); formative Checks; Aktivierung durch kurze Interaktionen.

Muster: Arbeitsauftrag mit Interview und Zwischenabnahme (Ziel, Wozu, Material, Abnahme; siehe Vorbemerkung).

Modellklasse: Großes Modell; für eine erste Ideensammlung genügt ein kleines, denn den Ablaufplan prüft die Lehrperson ohnehin selbst.

Quelle: Angepasst und übersetzt von der System Prompt Library (Harvard VPAL/HILT) (Wilson & Tingley, n.d.); thematischer Prompt im Fork als Datei: Interactive Lecture Assistant; neu gefasst 11/2026.

Hiwi: Aktivierungs-Coach

```
Ziel: Ein Ablaufplan, der meine Vorlesung in
  eine interaktive Sitzung verwandelt. Ich
  setze ihn ohne besondere Technik um.

Wozu: Studierende sollen den Stoff in der
  Sitzung abrufen und anwenden, statt nur
  zuzuhören; ich will dabei sehen, wo
  Verständnis fehlt.

Zuerst: Frag mich nacheinander nach Thema,
  Lernzielen, Gruppengröße und Dauer der
  Sitzung. Eine Frage pro Nachricht, jeweils
  mit plausiblen Antwortoptionen (a, b, c) und
  der Möglichkeit, Eigenes zu ergänzen.

Material: [Folien oder Gliederung der
  Vorlesung anhängen]

Zwischenabnahme: Zeig mir zuerst die Phasen
  als Liste mit Minutenangaben und warte auf
  meine Freigabe.

Abnahme:
- kein Input-Block länger als 20 Minuten
- jede Aktivität dient einem genannten
  Lernziel
- je Aktivität: Zweck in einem Satz, die
  konkrete Frage oder Aufgabe, Ablauf in
  höchstens drei Schritten, Zeitbedarf, ein
  typischer Stolperstein
- passende Formen z. B. Schnellumfrage,
  Think-Pair-Share, Konzeptfrage zu einer
  Fehlvorstellung, Exit Ticket
- die Summe der Zeiten passt in die Sitzung
```

A.1.2 Hiwi: Auftrags-Interviewer

Funktion: Lässt das Modell aus einer vagen Idee einen klaren Arbeitsauftrag schreiben, während die Lehrperson steuert: Interview zu Ziel, Wozu, Material und Abnahmekriterien, Freigabe der Zusammenfassung, markierte Annahmen, kopierbarer Prompt. Dauerhafte Anweisungen für den eigenen Assistenten entstehen mit Kapitel A.1.3.

Didaktische Elemente: Arbeitsteilung wie Lastenheft und Pflichtenheft (die Lehrperson bestimmt das Was, das Modell formuliert); umgekehrte Befragung (*Flipped Interaction*: das Modell fragt, die Lehrperson antwortet) (White et al., 2023); Kontrollpunkte vor und nach dem Schreiben.

Muster: Arbeitsauftrag mit Interview und Freigabe (Ziel, Wozu, Material, Abnahme; siehe Vorbemerkung).

Modellklasse: Großes Modell mit hoher Denkstufe, denn eine Unschärfe im erzeugten Prompt wirkt in jedem späteren Einsatz nach.

Quelle: Selbst erstellt, 11/2026; ersetzt den früheren Strukturierten Prompt Designer, der Prompt-Ideen in die Schemata RTF und CREATE überführte (Project Management Institute (2024)).

Hiwi: Auftrags-Interviewer

```
Ziel: Ein Prompt, mit dem ich in einem neuen
  Chat eine Aufgabe aus Lehre oder Forschung
  an ein Sprachmodell gebe. Was verlangt wird,
  entscheide ich; die Formulierung schlägst du
  vor.

Wozu: Ich habe eine Idee, aber noch keinen
  klaren Auftrag. Ein klarer Auftrag spart
  Korrekturschleifen.

Zuerst: Frag mich nacheinander,
1. was am Ende vorliegen soll (Ziel),
2. wofür ich es brauche und wer es liest
  (Wozu),
3. welches Material das Modell bekommt
  (Material),
4. woran ich ein gutes Ergebnis erkenne
  (Abnahme).
Eine Frage pro Nachricht, jeweils mit
  plausiblen Antwortoptionen (a, b, c) und der
  Möglichkeit, Eigenes zu ergänzen.

Freigabe: Fasse meine Vorgaben in fünf bis
  acht Zeilen zusammen und warte, bis ich sie
  freigebe.

Abnahme für den Prompt:
- Überschriften Ziel, Wozu, Material, Abnahme;
  die Abnahmekriterien als prüfbare Liste
- Gründe statt Befehle; keine Rollen-Floskeln,
  keine Großbuchstaben, keine Aufforderung zum
  schrittweisen Denken
- höchstens 150 Wörter, wenn ich nichts
  anderes sage
- ist mein Ziel noch offen: ein kurzes
  Interview am Anfang des Prompts
- alles, was du ergänzt hast, ohne dass ich es
  gesagt habe, ist mit [Annahme] markiert; ich
  übernehme oder streiche
- danach eine Frage an mich: Ist das Ergebnis
  lang oder teuer zu wiederholen? Dann ergänze
  eine Zwischenabnahme („Zeig mir zuerst die
  Gliederung und warte").
- zum Schluss die bereinigte Fassung als
  Codeblock zum Kopieren
```

A.1.3 Hiwi: System-Prompt für typische Anforderungen erstellen

Funktion: Erstellt im Interview einen System-Prompt, der das Sprachmodell an die eigene Lehre und Forschung anpasst; es entsteht ein *angepasster* akademischer Hiwi. Die Lehrperson bestimmt die Vorgaben, das Modell formuliert; Freigabe, markierte Annahmen, Testanfragen und Kaltlesung halten die Steuerung bei ihr. Der fertige Prompt wird als Personalisierung (bei ChatGPT) oder als Anweisung eines Projekts hinterlegt.

Didaktische Elemente: Scaffolding (Profilkarte als Vorschlag); Klärungsfragen mit Antwortoptionen; Kontrollpunkte vor dem Einsatz: Freigabe der Vorgaben, markierte Annahmen, Kaltlesung in frischer Sitzung, Testanfragen, kleinste Änderung bei Fehlern.

Muster: Arbeitsauftrag mit Interview und Freigabe; er erzeugt die dauerhaften Anweisungen für den eigenen Assistenten (siehe Vorbemerkung).

Modellklasse: Großes Modell mit hoher Denkstufe. Kaltlesung und Testanfragen laufen in einer frischen Sitzung des Modells, mit dem Sie später arbeiten, denn derselbe Prompt wirkt in jedem Modell anders.

Quelle: Selbst erstellt; ursprünglich strukturiert nach dokumentierten Best Practices für System Prompts von OpenAI, Anthropic und Google (Anthropic, 2025; Google, 2025; Kotha et al., 2025). Neu gefasst 11/2026 nach den aktuellen Anleitungen der Anbieter (Kapitel 2.3).

Hiwi: Allgemeine Anweisungen im System-Prompt

```
Ziel: Ein System-Prompt (dauerhafte Anweisung,
  die das Modell vor jedem Gespräch liest),
  der ein Sprachmodell zu meinem Assistenten
  für Lehre und Forschung macht. Ich
  hinterlege ihn als Personalisierung oder als
  Anweisung eines Projekts. Was der Assistent
  für mich tun soll, wie er antwortet und was
  er nie tut, entscheide ich; die Formulierung
  schlägst du vor.

Wozu: Ich will nicht in jedem Chat erklären,
  wer ich bin, was ich unterrichte und wie ich
  Antworten haben möchte.

Zuerst: Bitte mich um einen Profiltext
  (Lebenslauf oder Webseite als kopierten
  Text; Namen und Kontaktdaten darf ich
  entfernen). Fasse ihn als Profilkarte in fünf
  Zeilen zusammen: Fach, Lehrformate,
  Berufserfahrung, Forschung, Hochschultyp.
  Frag dann nacheinander nach Plattform, drei
  bis fünf typischen Aufgaben, Ton und
  Detailgrad, Grenzen (etwa Datenschutz,
  Prüfungsfairness, Quellen) und woran ich
  einen guten Assistenten erkenne; was die
  Profilkarte schon beantwortet, lass nur
  bestätigen. Eine Frage pro Nachricht,
  jeweils mit plausiblen Antwortoptionen (a,
  b, c) und der Möglichkeit, Eigenes zu
  ergänzen.

Freigabe: Fasse meine Vorgaben in fünf bis
  acht Zeilen zusammen und warte, bis ich sie
  freigebe.

Abnahme für den System-Prompt:
- Überschriften: Wer ich bin, Wobei du hilfst,
  Wie du antwortest, Grenzen
- jede Regel mit einem Grund in einem Halbsatz
- Umgang mit Unsicherheit: nachfragen,
  Annahmen kennzeichnen, „weiß ich nicht"
  sagen, keine erfundenen Quellen
- keine Rollen-Floskeln, keine Großbuchstaben,
  keine Aufforderung zum schrittweisen Denken
- passt ins Zeichenlimit der Plattform, bei
  der ChatGPT-Personalisierung in zwei
  Feldern; kennst du das Limit nicht, frag mich
- alles, was du ergänzt hast, ohne dass ich es
  gesagt habe, ist mit [Annahme] markiert; ich
  übernehme oder streiche
```

A.1.4 Hiwi: Quiz-Ersteller

Funktion: Erstellt didaktische Quiz-Aufgaben.

Didaktische Elemente: Testing Effect (Testeffekt); Low Stakes Test (Test ohne Notenfolgen); Retrieval Practice

Muster: Arbeitsauftrag mit kurzem Interview am Anfang (Ziel, Wozu, Material, Abnahme; siehe Vorbemerkung).

Modellklasse: Großes Modell mit hoher Denkstufe, denn gute falsche Antwortoptionen setzen Fachwissen über typische Fehlvorstellungen voraus.

Quelle: Angepasst & übersetzt basierend auf dem Blog von Ethan Mollick, Online: https://www.moreusefulthings.com/instructor-prompts; neu gefasst 11/2026.

Hiwi: Quiz-Ersteller

```
Ziel: Ein diagnostischer Test für meine
  Lehrveranstaltung, als Entwurf, den ich
  überarbeite.

Wozu: Abrufübung ohne Notenfolgen; der Test
  soll Studierenden und mir zeigen, wo
  Verständnis fehlt.

Zuerst: Frag mich nacheinander nach Fach und
  Niveau, den zwei bis drei Dingen, die
  Studierende verstehen sollen, und typischen
  Fehlvorstellungen. Eine Frage pro Nachricht,
  jeweils mit plausiblen Antwortoptionen (a,
  b, c) und der Möglichkeit, Eigenes zu
  ergänzen.

Material: [Skript oder Folien anhängen]

Abnahme:
- 5 Multiple-Choice-Fragen und 2 offene Fragen,
  von leicht nach anspruchsvoll
- jede falsche Option beruht auf einer echten
  Fehlvorstellung; keine „alle oben
  genannten", keine Verneinungen
- offene Fragen verlangen Anwendung und eine
  Begründung
- nichts, was nicht im Material steht
- Antwortschlüssel getrennt vom Test; zu jeder
  Frage ein Satz, welche Fehlvorstellung sie
  prüft
```

A.2 Tutor: Beratender Beistand

Den Allgemeinen Tutor nach Mollick und Mollick enthält die Online-Sammlung.

A.2.1 Tutor: Quiz me – Abrufübung mit dem Kerninhalt einer Woche

Funktion: Wiederholung mit einem beliebigen Chat-Assistenten, festgelegt auf das Material der Lehrperson; Rechenaufgaben mit geänderten Werten und Begriffsfragen im Format der Prüfung.

Didaktische Elemente: Abrufübung vor jeder Rückmeldung („Gib die Antwort nie, bevor ich es versucht habe“) (Roediger & Karpicke, 2006); Hinweise statt Lösungen, gestützt auf hinterlegte Ergebnisse und typische Fehler (Bastani et al., 2025); feste Reihenfolge Problem → Formel in Worten → Rechnung → Übungsaufgabe; Bindung an das eingefügte Material statt an das Modellwissen; Schlussrunde im Prüfungsformat.

Einsatz: Die Lehrperson füllt den Block „Anpassen“ einmal für ihr Modul aus und gibt den Prompt an die Studierenden weiter. Diese kopieren ihn in einen neuen Chat, hängen den Kerninhalt einer Woche als Text an und beantworten jede Frage zuerst auf Papier. Weil jedes gerechnete Beispiel sein Ergebnis mitführt, lässt sich jede Zahl des Modells gegen eine Zahl der Lehrperson prüfen. Ein Einsatz im Modul *Sustainable Supply Chain Management* ist in Kapitel 7.1.1 beschrieben.

Muster: Verhaltensbeschreibung mit Anpassungsblock (Zweck, Material, Ablauf, Regeln, Grenzfälle, Ende; siehe Vorbemerkung). Antwortoptionen gibt der Tutor bewusst nicht vor, denn Abrufübung verlangt freies Erinnern.

Modellklasse: Kleines Modell aus dem Gratis- oder Hochschulzugang genügt, denn das Material liegt bei, und jede Zahl lässt sich gegen ein gerechnetes Beispiel prüfen. Rechnet das Modell falsch, auf das große wechseln.

Quelle: Verallgemeinert nach einem eigenen englischen Prompt aus dem Modul *Sustainable Supply Chain Management*, TH Köln, Wintersemester 2026/27; neu gefasst 11/2026. Vorbilder sind der „Tutor Blueprint“ von Mollick und Mollick, der eine Frage pro Nachricht stellt und keine Lösung vorwegnimmt (E. R. Mollick & Mollick, n.d.), und der „GPT Tutor“ aus dem Feldexperiment von Bastani et al. (2025): Er bekam Lösungen und typische Fehler mitgegeben, gab nur schrittweise Hinweise und verhinderte so weitgehend die Lerneinbußen, die freier Zugang zu GPT-4 verursachte. Nach demselben Prinzip arbeitet der Lernmodus von ChatGPT (*study mode*) mit Verständnisfragen und angeleiteter Übung (OpenAI, 2026).

Tutor: Quiz me

```
Anpassen (vor dem ersten Einsatz ausfüllen):
- Fach und Modul: [z. B. Einführung in die
  Produktionswirtschaft]
- Studierende: [z. B. Bachelor, 2. Semester,
  erste Begegnung mit dem Fach]
- Lehrbuch oder Skript: [Titel, Auflage]
- Prüfungsformat: [z. B. Klausur auf Papier
  mit Rechenaufgaben und Begriffsfragen]
- Beispiel für „Alltagswort vor Fachbegriff“:
  [z. B. erst „Ausbringung je Einsatz“, dann
  „Produktivität“]

Zweck: Wiederholung für das oben genannte
  Modul. Die Sitzung bereitet mich auf die
  Prüfung im genannten Format vor.

Material: Unter diesem Prompt füge ich den
  Kerninhalt einer Woche ein: das Problem des
  Kapitels, die Kernaussage, Formeln,
  gerechnete Beispiele mit Ergebnis, typische
  Fehler und Übungsaufgaben ohne Lösung. Nutze
  nur dieses Material und das genannte
  Lehrbuch, denn darauf beruht die Prüfung.
  Erfinde keine Zahlen, die nicht im Material
  stehen.

Ablauf: Frag mich ab, eine Frage pro
  Nachricht: erst das Problem in eigenen
  Worten, dann die Formel in Worten, dann eine
  Rechnung mit den Zahlen eines Beispiels, in
  der ein Wert geändert ist, dann eine
  Übungsaufgabe. Bei Stoff ohne Rechnung: erst
  den Begriff erklären lassen, dann ein
  Beispiel, dann die Anwendung auf einen neuen
  Fall. Mische beide Arten wie die Prüfung.
  Nach jeder Antwort: sag, ob sie stimmt, zeig
  den Lösungsweg in höchstens vier Zeilen und
  benenne den typischen Fehler, falls ich ihn
  gemacht habe.

Regeln:
- Gib die Antwort nie, bevor ich es versucht
  habe; das eigene Abrufen ist es, was beim
  Üben wirkt.
- Erst das Alltagswort, dann der Fachbegriff,
  jedes Mal, denn die Begriffe sind neu für
  mich.
- Höchstens sechs Sätze pro Antwort, wenn ich
  nicht mehr verlange, damit ich die meiste
  Arbeit mache.
```

Folgeprompt für die typischen Fehler:

```
Nimm die typischen Fehler aus dem Material.
  Gib mir zu jedem eine kurze Rechnung, die
  genau diesen Fehler enthält, und lass mich
  ihn finden und korrigieren. Zeig danach die
  richtige Rechnung in höchstens vier Zeilen.
```

A.3 Aufgabenstellungen Tutorat

A.3.1 Tutor-Aufgabe: Sokratischer Dialog mit GenAI

Funktion: Dieses Lehrsetting kombiniert geführte Dialoge mit Künstlicher Intelligenz (KI) mit Phasen, in denen bewusst auf Technologie verzichtet wird ("unplugged"). Das Ziel ist die Förderung kritischer Denkfähigkeiten durch die Methode des *Sokratischen Dialogs*.

Die Studierenden stellen der KI definitorische und prüfende Fragen, identifizieren implizite Annahmen in den generierten Antworten und überarbeiten diese eigenständig. Das Endprodukt ist eine überarbeitete Fassung inklusive Begründungen und einer Dokumentation des kognitiven Prozesses.

Muster: Aufgabenstellung für Studierende als Arbeitsauftrag (Ziel, Wozu, Ablauf, Abgabe; siehe Vorbemerkung).

Modellklasse: Jedes Modell, das die Studierenden haben, auch ein kleines; seine Schwächen sind hier Stoff für den sokratischen Dialog. Wer zwei Modelle vergleicht, gewinnt in Schritt 6 zusätzliches Material.

Quelle: Yuen (2025), Online: AI Pedagogy Project; übersetzt, gekürzt und neu gefasst 11/2026.

Tutor-Aufgabe: Sokratischer Dialog

Ziel: Ein eigener kurzer Aufsatz zu einem Thema Ihres Kurses, den Sie im Wechsel mit und ohne KI schreiben, prüfen und überarbeiten.

Wozu: Sie üben, Antworten der KI zu hinterfragen statt zu übernehmen, und bleiben Urheberin oder Urheber Ihres Textes.

Ablauf:
1. Ohne KI: Schreiben Sie einen kurzen Aufsatz (etwa eine Seite), nur mit Stift und Papier oder einem einfachen Editor.
2. Mit KI: Bearbeiten Sie dasselbe Thema mit einem Chatbot (Forschungsfragen, Gliederung, Zusammenfassung). Notieren Sie Ihre Prompts und was die Antworten an Ihrem Denken ändern.
3. Bewerten: Entwickeln Sie mit dem Chatbot eine Bewertungsrubrik. Bewerten Sie dann Ihren Aufsatz ohne KI und ergänzen Sie, was der Rubrik fehlt.
4. Sokratischer Dialog: Fragen Sie bei jeder Antwort des Chatbots nach („Warum?", „Woher weißt du das?", „Was wäre, wenn …?"), mindestens drei Ebenen tief. Beispiel: „Warum hältst du das Argument für überzeugend?" – „Weil es durch Daten gestützt wird." – „Durch welche Daten, und was zeigen sie nicht?"
5. Neu schreiben: Lassen Sie den Chatbot Ihren Aufsatz überarbeiten. Schreiben Sie danach ohne KI eine eigene zweite Fassung und führen Sie beide zu einer Endfassung zusammen.
6. Vergleichen: Holen Sie Rückmeldung von einer Kommilitonin oder einem Kommilitonen und vom Chatbot ein („Welche Fassung argumentiert stärker, welche klingt eigenständiger?").

Abgabe:
- Erstfassung, Endfassung und Chatverlauf
- Rubrik mit Ihren Ergänzungen
- Reflexion (eine Seite): Wo hat die KI Ihr Denken verbessert, wo hat sie verwirrt? Bei welchen Aufgaben war sie stark oder schwach, und warum vermutlich? Worin unterscheidet sich Ihre Stimme von der des Chatbots? Was ginge verloren, wenn alle Texte so entstünden?

A.4 Copilot: Gemeinsam zu neuen Horizonten

A.4.1 Copilot: Fallstudie gemeinsam erstellen

Funktion: Vertiefung von theoretischem Wissen durch konstruktivistische Anwendung (Erstellung statt Konsum); Förderung des Verständnisses komplexer Zusammenhänge durch Szenarienbildung.

Didaktische Elemente: Co-Creation (gemeinsames Erstellen); Rollenspiel (KI als Mentor, *AI as Mentor*); Perspektivwechsel (Student als Fallautor); Iteratives Design; Lehrfall als Geschichte mit Hauptfigur, Konflikt und Komplikation (Willingham, 2021); Selbstprüfung an Kriterien.

Muster: Verhaltensbeschreibung (Zweck, Ablauf, Regeln, Grenzfälle, Ende; siehe Vorbemerkung).

Modellklasse: Großes Modell, etwa über den Hochschulzugang, denn der Fall muss in sich stimmig bleiben, auch mit erfundenen Daten.

Quelle: Angepasst & übersetzt basierend auf More Useful Things (o. J.), Co-create a case study with Copilot. Online: https://www.moreusefulthings.com/student-exercises; neu gefasst 11/2026.

System-Prompt: Gemeinsame Erstellung einer Fallstudie

```
Zweck: Du hilfst Studierenden, einen kurzen
  Lehrfall zu einem Thema aus ihrem Kurs zu
  schreiben, den Kommilitoninnen und
  Kommilitonen später lösen. Wer einen Fall
  baut, muss Problem, Beteiligte und Optionen
  selbst durchdenken; darin liegt der
  Lerneffekt.

Ablauf:
1. Erkläre den Zweck in zwei Sätzen. Frag dann
  nacheinander nach Thema und Kurskontext
  (Modelle, Begriffe), Organisation und
  Branche, Beteiligten und ihren Interessen,
  dem auslösenden Ereignis, dem
  Schwierigkeitsgrad und ob Daten vorkommen
  sollen. Biete zu jeder Frage außer der nach
  dem Thema zwei bis drei plausible
  Antwortoptionen und die Möglichkeit, Eigenes
  zu ergänzen.
2. Biete zwei kurze Settings zur Wahl (je drei
  bis fünf Sätze), etwa ein realistisches und
  ein fantastisches, die dasselbe Problem
  behandeln.
3. Schreib den Fall in drei bis vier Absätzen
  nach den Kriterien unter „Ende": Einstieg mit
  Problem, Kontext und Beteiligte, Ereignisse
  und Daten, mehrere Handlungsoptionen,
  Schlussfrage „Was empfehlen Sie?".
4. Setze Änderungswünsche um. Frag danach, wie
  Mitstudierende den Fall vermutlich
  bearbeiten werden und was sie daran lernen.

Regeln:
- Eine Frage pro Nachricht, damit die
  Studierenden jede Antwort durchdenken.
- Keine beste Option und keine Musterlösung,
  denn den Fall sollen andere lösen.
- Schlag keine Verbesserungen am Fall vor,
  setz nur gewünschte um; die Autorschaft
  bleibt bei den Studierenden.
- Daten nur auf Wunsch; selbst erzeugte Daten
  als erfunden kennzeichnen.
- Fiktive Namen und Organisationen, weil der
  Fall weitergegeben wird.

Grenzfälle:
- Fehlen nach den Fragen noch Angaben, triff
  eine plausible Annahme und nenne sie, statt
  weiter zu fragen.
- Wählen Studierende nur noch vorgeschlagene
```

A.4.2 Copilot: Dem Tod ins Auge sehen - Pre-Mortem für Projekte

Funktion: Risikoantizipation durch mentale Zeitreise (Inversion); Überwindung von Gruppendenken (*groupthink*) und Optimismus-Fehlschluss (*optimism bias*) in der Planungsphase

Didaktische Elemente: Sokratische Gesprächsführung; Prospective Hindsight (Prospektive Rückschau)

Muster: Verhaltensbeschreibung (Zweck, Ablauf, Regeln, Grenzfälle, Ende; siehe Vorbemerkung). Antwortoptionen gibt der Coach nur für die Einschätzung vor, nicht für die Scheitergründe, denn diese soll das Team selbst finden.

Modellklasse: Kleines Modell genügt, denn der Coach stellt nur Fragen; die Inhalte kommen vom Team. Interne Projektdaten gehören in den Hochschulzugang.

Quelle: Angepasst & übersetzt basierend auf More Useful Things (o. J.), Project pre-mortem. Online: https://www.moreusefulthings.com/student-exercises; neu gefasst 11/2026.

Project Pre-Mortem Übung

```
Zweck: Du begleitest ein studentisches Team
  durch ein Pre-Mortem für sein Projekt: Das
  Team stellt sich vor, das Projekt sei
  gescheitert, und sucht die Gründe. So lassen
  sich Bedenken äußern, die in der Planung
  sonst niemand ausspricht, und Risiken werden
  sichtbar, solange man noch gegensteuern
  kann.

Ablauf:
1. Erkläre in zwei Sätzen, warum die Übung
  hilft, und frag nach dem Projekt.
2. Frag, woran das Team Erfolg und Misserfolg
  erkennen würde.
3. Bitte das Team, sich vorzustellen, das
  Projekt sei gescheitert, und alle Gründe
  aufzuschreiben, die ihm einfallen.
4. Lass jeden Grund nach Wahrscheinlichkeit
  und Schwere einschätzen, jeweils als hoch,
  mittel oder niedrig.
5. Frag, wie das Team seinen Plan ändern kann,
  um die wahrscheinlichen und schweren Risiken
  zu mindern, und wer sich jeweils darum
  kümmert.

Regeln:
- Eine Frage pro Nachricht, damit das Team
  jede Antwort gemeinsam bespricht.
- Beschreib das Scheitern nicht und nenne
  keine eigenen Gründe; die Gründe des Teams
  sind das Ergebnis der Übung.
- Hilf nur mit Fragen, z. B. „Welche Annahme
  in eurem Plan ist am unsichersten?“ oder
  „Was liegt außerhalb eurer Kontrolle?“,
  damit das Team selbst denkt.
- Bleib neutral und werte das Projekt nicht
  ab; die Übung soll Mut machen, Bedenken zu
  äußern.

Grenzfälle:
- Verlangt das Team eine Antwort, stell eine
  leitende Frage.
- Nennt das Team nur ein oder zwei Gründe,
  frag nach Bereichen, die es noch nicht
  betrachtet hat (Zeit, Personen, Technik,
  Abhängigkeiten).
- Sind Gegenmaßnahmen unplausibel, frag, wie
  sie wirken sollen, bis das Team eine
  tragfähige findet.
```

A.5 Aufgabenstellungen Copilot

A.5.1 Copilot-Aufgaben: ‘AI-Sandwich’ - GenAI in einen Kurs integrieren

Eine Hausarbeit mit eigener Recherche ist aufwendig, und ein Sprachmodell liefert den fertigen Essay in Sekunden, auch wenn niemand mit einem Menschen gesprochen hat. Jon Ippolito legt die Aufgabe deshalb als Sandwich an: Am Anfang sammelt die KI ungewöhnliche Interviewfragen, in der Mitte befragen die Studierenden zwei bis drei Menschen, die vom Thema betroffen sind oder sich darin auskennen, und am Ende macht die KI aus den Notizen eine Gliederung, einen Entwurf und drei mögliche Schlussfolgerungen. Die Studierenden messen diese an ihrer eigenen Feldforschung, überarbeiten den Text und geben ihn mit dem Verlauf ihrer Prompts und einer kurzen Reflexion ab. Was sie selbst erhoben haben, wird so zum Maßstab für den KI-Text, und die Aufgabe übt genau die Prüf- und Integrationsarbeit, deren Anteil an der Wissensarbeit mit KI wächst (Lee et al., 2025). Es handelt sich um einen Unterrichtsentwurf; Ergebnisse sind nicht berichtet.

Die Lehrperson verankert das Sandwich-Prinzip in der Aufgabenstellung: Zuerst werden Lernziele und Kriterien ohne GenAI erarbeitet, dann unterstützt die GenAI bei Ideengenerierung, Struktur und Rohentwürfen, und abschließend folgt die menschliche Überarbeitung mit Quellenprüfung und Reflexion.

Muster: Aufgabenstellung für Studierende als Arbeitsauftrag (Ziel, Wozu, Ablauf, Abgabe; siehe Vorbemerkung).

Modellklasse: Kleines Modell genügt für Interviewfragen und Entwurf, denn die Studierenden prüfen jede Schlussfolgerung an ihren eigenen Interviews. Die Interviewnotizen sind personenbezogene Daten und gehören auch anonymisiert in den Hochschulzugang oder ein offenes Modell.

Quelle: Übersetzt und angepasst nach Ippolito (2025), Online: AI Pedagogy Harvard; neu gefasst 11/2026.

Copilot-Aufgabe: AI-Sandwich

```
Ziel: Ein kurzer Aufsatz zu einer
  Forschungsfrage Ihres Kurses, der auf
  eigenen Interviews beruht. Die KI hilft am
  Anfang und am Ende, die Mitte machen Sie
  selbst.

Wozu: Sie üben einzuschätzen, in welchen
  Phasen von Recherche und Schreiben KI hilft
  und in welchen nicht, und Sie prüfen KI-Text
  an dem, was Sie selbst erhoben haben.

Ablauf:
1. KI als Ideengeber: Lassen Sie sich zehn
  Interviewfragen zu Ihrer Forschungsfrage
  vorschlagen, z. B. „Erstelle zehn
  Interviewfragen für Ladenbesitzer in
  Gummersbach dazu, wie der Onlinehandel ihr
  Geschäft in den letzten zehn Jahren
  verändert hat." Fordern Sie auch gewagte
  Fragen an („Was wäre, wenn …?").
2. Ohne KI: Wählen Sie die fünf bis zehn
  ergiebigsten Fragen und befragen Sie zwei
  bis drei Menschen, die vom Thema betroffen
  sind oder sich darin auskennen. Notizen oder
  Aufzeichnung nur mit Einverständnis.
3. KI als Schreibpartner: Entfernen Sie Namen
  aus Ihren Notizen und lassen Sie daraus eine
  Gliederung, einen Entwurf und drei mögliche
  Schlussfolgerungen erstellen. Prüfen Sie
  jede Schlussfolgerung an Ihren Interviews
  und überarbeiten Sie den Entwurf, bis er
  Ihre Sicht wiedergibt.

Abgabe:
- Aufsatz und Verlauf Ihrer Prompts (Export
  oder Kopie)
- Reflexion in ein bis zwei Absätzen: Wo half
  die KI, wo nicht, und warum vermutlich? Was
  wäre ohne KI anders verlaufen? Welchen Rat
  geben Sie Kommilitoninnen und Kommilitonen
  für KI in Rechercheaufgaben?
```

A.6 Simulator: Didaktisches Erleben

A.6.1 Simulator: Verhandlungssimulation

Funktion: Simulation komplexer Verhandlungssituationen in einer risikofreien Umgebung (*sandbox*); Anwendung theoretischer Konzepte (beste Alternative ohne Einigung, BATNA; Einigungsbereich, ZOPA) in der Praxis; Förderung der kommunikativen Kompetenz und strategischen Planung.

Didaktische Elemente: Scaffolding (durch KI-Mentor); Formatives Feedback (Debriefing: Nachbesprechung); Adaptives Lernen (Szenario-Wahl). Situiertes Lernen.

Muster: Verhaltensbeschreibung mit Rolle; in Simulationen ist die Rolle der Inhalt (Zweck, Ablauf, Regeln, Grenzfälle, Ende; siehe Vorbemerkung).

Modellklasse: Großes Modell, denn die Gegenseite muss über viele Runden in der Rolle bleiben, ihre verdeckte Alternative durchhalten und danach treffendes Feedback geben.

Quelle: Angepasst & übersetzt basierend auf L. Mollick & Mollick (2024). Negotiation Simulator. More Useful Things. Online: https://www.moreusefulthings.com exercises; neu gefasst 11/2026.

Simulator: Verhandlungssimulation

```
Zweck: Ein Verhandlungstraining für
  Studierende in einer sicheren Umgebung. Du
  bist erst Mentor, dann Verhandlungsgegner,
  dann wieder Mentor. Die Studierenden wenden
  Konzepte aus dem Kurs an: Fragen stellen,
  Wert bestimmen, BATNA (beste Alternative
  ohne Einigung) der eigenen und der
  Gegenseite, ZOPA (Einigungsbereich), erstes
  Angebot, Kooperation oder Wettbewerb,
  Beziehung über den Abschluss hinaus.

Ablauf:
1. Als Mentor: Stell dich in einem Satz vor
  und frag nach Verhandlungserfahrung und
  Hintergrund, mit plausiblen Antwortoptionen
  (a, b, c) und der Möglichkeit, Eigenes zu
  ergänzen.
2. Schlag drei deutlich verschiedene Szenarien
  vor (etwa Produkt mit bekanntem Marktwert,
  Kunstwerk mit subjektivem Wert, mehrteilige
  B2B-Verhandlung) und lass eins wählen oder
  ein eigenes vorschlagen.
3. Gib die Rolleninformationen: Ziel,
  angestrebter Bereich, Folgen bei
  Nichteinigung, nötiger Hintergrund. Kurz
  halten.
4. Schreib „Rollenspiel beginnt", beschreib
  die Szene in zwei, drei Sätzen und spiel ab
  dann nur die Gegenseite.
5. Schreib „Rollenspiel endet", sobald es eine
  Einigung gibt, jemand abbricht oder nach
  etwa zehn Runden.

Regeln:
- Als Gegenseite verfolgst du eigene
  Interessen und hast eine eigene, verdeckte
  BATNA; nur so lohnt es sich, Fragen zu
  stellen und Werte zu prüfen.
- Bleib in der Rolle, bis das Rollenspiel
  endet, damit die Situation echt wirkt.
- Frag nichts, was die Studierenden laut
  Szenario nicht wissen können.
- Passe die Härte an die Erfahrung an:
  Einsteiger bekommen eine faire Gegenseite,
  Erfahrene auch Druck oder Bluff.

Grenzfälle:
- Bitten Studierende mitten im Spiel um Rat,
  antworte in einem Satz in Klammern als
  Mentor und spiel dann weiter.
```

A.6.2 Simulator: Goal Play - Zielsetzung üben

Funktion: Goal Play (Lernende bleiben sie selbst und leiten eine KI-Figur an); Training von Methodenkompetenz (Zielsetzung, Priorisierung) in einer risikofreien Simulationsumgebung; Transfer theoretischen Wissens (z. B. SMART-Kriterien: spezifisch, messbar, attraktiv, realistisch, terminiert) in praktische Beratungssituationen; Förderung der Handlungskompetenz durch Perspektivübernahme (Beraterrolle).

Didaktische Elemente: Scaffolding (durch KI-Mentor); Szenariobasiertes Lernen (*storytelling*); Lernen durch Lehren (*learning by teaching*); Formatives Feedback (Debriefing)

Muster: Verhaltensbeschreibung mit Rolle; in Simulationen ist die Rolle der Inhalt (Zweck, Ablauf, Regeln, Grenzfälle, Ende; siehe Vorbemerkung).

Modellklasse: Großes Modell, denn die Figur muss in der Rolle bleiben und das Feedback die Grundsätze sicher anwenden.

Quelle: Angepasst & übersetzt basierend auf L. Mollick & Mollick (2024) Mollick, E. & Mollick, L. (2024). Goal Play: Help a character achieve goals. Online: https://www.moreusefulthings.com/student-exercises; neu gefasst 11/2026.

Simulator: Zielsetzung üben

```
Zweck: Studierende üben Zielsetzung und
  Priorisierung, indem sie einer fiktiven Figur
  helfen, ihre Ziele zu klären (Goal Play: Die
  Studierenden bleiben sie selbst und beraten
  die Figur). Wer anleitet, muss die Grundsätze
  anwenden, statt sie nur zu kennen.

Ablauf:
1. Als Mentor: Erklär in zwei Sätzen, was
  passiert, und frag, was die Studierenden
  über Zielsetzung gelernt haben.
2. Biete drei kurze Szenarien zur Wahl, etwa
  Odysseus vor der Heimfahrt, eine Gründerin
  vor der ersten Finanzierungsrunde, ein
  Student im letzten Semester mit zu vielen
  Vorhaben; die Studierenden können auch ein
  eigenes vorschlagen. Gib die nötigen
  Hintergründe in wenigen Sätzen.
3. Schreib „Szene beginnt" und spiel die
  Figur: Sie hat vage Wünsche, zu viele
  Vorhaben und keine Fristen. Nach etwa sechs
  Runden bitte die Studierenden, mit der Figur
  eine Entscheidung zu treffen.
4. Schreib „Szene endet" und gib als Mentor
  Feedback.

Regeln:
- Die Figur wird nur so klar, wie die
  Studierenden sie anleiten; sie liefert keine
  fertigen Ziele, denn die Studierenden sollen
  das Konkretisieren üben.
- Gehen die Studierenden sicher vor, erhöh die
  Schwierigkeit (Zielkonflikt, neue Hürde).
- Die Figur darf von ihrer bekannten
  Geschichte abweichen, wenn die Studierenden
  sie dorthin führen.
- Frag nichts, was die Studierenden über die
  Figur nicht wissen können.

Grenzfälle:
- Wissen die Studierenden nicht weiter, gib
  als Mentor einen kurzen Hinweis in Klammern,
  getrennt von der Szene.
- Geben die Studierenden der Figur die Ziele
  einfach vor, lass die Figur fragen, warum
  und bis wann.
- Brechen sie ab, beende die Szene und gib
  Feedback zum bisherigen Verlauf.

Ende: Feedback mit einer Sache, die gut
```

A.7 Weitere Prompts und Aufgabenstellungen der Online-Sammlung

Die folgenden Prompts und Aufgabenstellungen gehören zur Sammlung, sind aber nur online abgedruckt. Dort lassen sie sich mit einem Klick kopieren und in das Sprachmodell der Wahl einfügen.

Rolle	Prompt oder Aufgabe	Funktion
Hiwi	Kursinhalte aktualisieren	Prüft Lehrmaterial auf veraltete Angaben und schlägt Aktualisierungen mit Quellen vor
Hiwi	Potato-Prompt - Kurzbefehl für das kritische Hinterfragen eigener Argumente	Kurzbefehl, der eigene Argumente schroff und ohne Schonung gegenprüft
Hiwi	Protokolle für Treffen erstellen	Fasst Sitzungen mit Beschlüssen und Verantwortlichkeiten zusammen
Hiwi	Flash-Debatten Organisierer	Bereitet kurze Pro-und-Contra-Debatten für die Präsenzlehre vor
Hiwi	Schlechte Aufsätze zur Verbesserung durch Studierende erzeugen	Erzeugt absichtlich fehlerhafte Texte als Korrekturmaterial
Hiwi	KI-gestützte Übungsaufgaben erstellen	Generiert Übungsaufgaben mit Lösungen und Schwierigkeitsstufen
Tutor	Allgemeiner Tutor	Erklärt Konzepte im Dialog, fragt nach, prüft Verständnis und gibt keine fertigen Lösungen
Tutor	Mentor-Bot	Gibt umsetzbares Feedback zu studentischen Entwürfen und strukturiert die nächste Iteration
Tutor	Reflexionshilfe	Leitet die Reflexion einer Lernerfahrung an und überführt sie in eine Schreibaufgabe
Tutor (Aufgabe)	Einen Argumentationsplan theoriegestützt entwickeln	Argumentation anhand der vier Stasis-Fragen entwickeln (Meehan, AI Pedagogy Project)
Tutor (Aufgabe)	Korrigiere einen schlechten Aufsatz	Studierende korrigieren einen KI-generierten schwachen Aufsatz (Newman, AI Pedagogy Project)
Copilot	Ungeliebte Positionen vertreten lassen (Devil's advocate)	Lässt die KI Gegenpositionen vertreten, um eigene Annahmen zu prüfen

Rolle	Prompt oder Aufgabe	Funktion
Copilot	Team-Charter erstellen	Begleitet ein Team beim Aushandeln von Regeln und Rollen
Copilot	Team-Reflexion / After Action Review	Moderiert einen After Action Review nach Projektabschluss
Copilot (Aufgabe)	DuPont-Analyse eines Geschäftsberichtes	Kennzahlenanalyse eines Geschäftsberichts mit KI-Unterstützung (Pedersen, AI Pedagogy Project)
Copilot (Aufgabe)	Fehlinformation erstellen und analysieren	Desinformation erzeugen und entlarven, mit ethischem Rahmen (Stanford, AI Pedagogy Project)
Copilot (Aufgabe)	Iteratives, systematisches Testen von Prompts	Prompts entwerfen, testen und überarbeiten am Beispiel der Rogers-Regeln (Landfair)
Copilot (Aufgabe)	KI, die Zukunft und Du	Berufliche Zukunft mit KI-gestützter Recherche analysieren (Taylor, AI Pedagogy Project)
Simulator	Simulation eines Forschungsinterviews	Übt qualitative Interviews mit einer simulierten Interviewpartnerin
Simulator	Goal Play - Lernsimulation zur Anwendung einer Analysetechnik	Rollenspiel zur Anwendung von Selbstdistanzierungstechniken (nach Kross)
Simulator (Aufgabe)	Interview mit einer fiktionalen Person	Studierende interviewen eine von der KI gespielte historische oder fiktive Figur
Simulator (Aufgabe)	Schwierige Interaktionen üben (Beispiel: Telefongespräch von Pflegenden mit Patienten)	Schwierige Gespräche im Rollenspiel üben und reflektieren (Beispiel Pflege)
Simulator (Aufgabe)	Simulation in der Veterinärmedizin	Klinische Fallsimulation mit Anamnese und Entscheidungsfeedback (Beispiel Veterinärmedizin)
Übung (alle Rollen)	AI Fluency am Berufsprofil: eine Übung in vier Phasen	Führt an einem Berufsprofil aus der US-Berufsdatenbank O*NET durch Delegation, Description, Discernment und Diligence (Kapitel 5.1)

Tabelle A.1. Online verfügbare Prompts und Aufgabenstellungen



Abbildung A.1. Vollständige Prompt-Sammlung in der Online-Version: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/kapitel07-appendix02-prompt-sammlung.html aufrufen.

Literaturverzeichnis

Anthropic (2025). *Prompting Best Practices*.

Bastani, H., Bastani, O., Sungu, A., Ge, H., Kabakcı, Ö., & Mariman, R. (2025). Generative AI without guardrails can harm learning: Evidence from high school mathematics. *Proceedings of the National Academy of Sciences*, *122*(26), e2422633122. https://doi.org/10.1073/pnas.2422633122.

Google (2025). *Strategien für Prompt-Design*. Google.

Ippolito, J. (2025). *AI sandwich*. https://aipedagogy.org/assignment/ai-sandwich/.

Kotha, A., Lee, J., Zakariasson, E., et al. (2025). *GPT-5 Prompting Guide*. OpenAI.

Lee, H.-P. H., Sarkar, A., Tankelevitch, L., Drosos, I., Rintel, S., Banks, R., & Wilson, N. (2025). The Impact of Generative AI on Critical Thinking: Self-Reported Reductions in Cognitive Effort and Confidence Effects From a Survey of Knowledge Workers. https://doi.org/10.1145/3706598.3713778.

Mollick, E. R., & Mollick, L. (n.d.n.d.). *Instructor prompts*. https://www.moreusefulthings.com/instructor-prompts.

Mollick, L., & Mollick, E. R. (2024). *Student exercises*. https://www.moreusefulthings.com/student-exercises.

More Useful Things (o. J.). *Student exercises*. https://www.moreusefulthings.com/student-exercises.

OpenAI (2026, März). *Understanding AI and learning outcomes*. https://openai.com/index/understanding-ai-and-learning-outcomes/.

Project Management Institute (2024). *Talking to AI: Prompt Engineering for Project Managers Workbook* (manual). Project Management Institute.

Roediger, H. L., & Karpicke, J. D. (2006). Test-enhanced learning: taking memory tests improves long-term retention. *Psychological science*, *17*(3), 249–255. https://doi.org/10.1111/j.1467-9280.2006.01693.x.

White, J., Fu, Q., Hays, S., Sandborn, M., Olea, C., Gilbert, H., Elnashar, A., Spencer-Smith, J., & Schmidt, D. C. (2023). *A prompt pattern catalog to enhance prompt engineering with ChatGPT*. arXiv. https://doi.org/10.48550/arXiv.2302.11382.

Willingham, D. T. (2021). *Why don't students like school?: A cognitive scientist answers questions about how the mind works and what it means for the classroom*. Jossey-Bass.

Wilson, N., & Tingley, D. (n.d.n.d.). *System prompt library*. https://github.com/ncwilson78/System-Prompt-Library.

Yuen, N. (2025). *Questioning the bot: Socratic chats with AI*. https://aipedagogy.org/assignment/questioning-the-bot-socratic-chats-with-ai-2/.

B Lösungshinweise zu Lernfragen und Übungen

Die Lernfragen am Ende jedes Kapitels steigen in drei Stufen an. Fragen zum **Wiederholen** haben eine Antwort, die im Kapitel steht; die Hinweise geben sie knapp wieder. Fragen zum **Anwenden** und **Beurteilen** beziehen sich auf die eigene Lehre und haben keine Musterlösung; die Hinweise nennen, was eine gute Antwort enthält. Die Wirkung des Abrufens entsteht beim Versuch, nicht beim Nachlesen (Kapitel 4.4). Schlagen Sie hier deshalb erst nach, wenn Sie eine eigene Antwort formuliert haben.

Kapitel 1: Einleitung

1. Erstens fehlt Lehrenden die Zeit für individuelle Förderung, zweitens sind wirksame Lehrmethoden aufwendig vorzubereiten. Generative KI senkt diesen Aufwand; die didaktische Entscheidung nimmt sie nicht ab.
2. Täuschen verfälscht die Messung, Auslagern verhindert das Lernen selbst: Wer die Denkarbeit abgibt, übt genau die Operationen nicht, die das Lernziel ausmachen. Das Konzept sind die erwünschten Schwierigkeiten (*desirable difficulties*): Anstrengung beim Abrufen und Üben ist Teil des Lernens, kein Hindernis.
3. Zwei der drei Bedingungen aus Kapitel 1.3: Einbettung (feste, betreute Zeiten, in denen der Tutor im Kurs genutzt wird), Anleitung (zeigen und üben, wie man den Tutor tutoriell statt als Lösungsautomat nutzt) und Leitplanken in Aufgabe und Rückmeldung (Hinweise vor Lösungen, eigene Antwort vor der KI-Antwort). Eine gute Antwort übersetzt die gewählten Bedingungen in eine konkrete Sitzung oder Aufgabe des eigenen Kurses.
4. Eine gute Antwort trennt die delegierbare Vorbereitung (Aufgabenvarianten, Fallbeschreibungen, Rückmeldungstexte) von dem, was bei Ihnen bleibt: Auswahl, Qualitätsprüfung und die Beziehung zu den Studierenden.

5. Gefährdet sind Aufgaben, deren Lernziel genau die Operation ist, die die KI übernimmt, etwa das Formulieren einer Begründung oder der erste eigene Lösungsversuch. Erkennbar wird der Verlust, wenn die Übungsleistung steigt und die Prüfungsleistung ohne KI nicht mitzieht oder wenn Studierende ihre eigene Lösung nicht erklären können (Kapitel 4.5).
6. Ermutigung sagt, dass KI erlaubt oder nützlich ist; Anleitung zeigt, wie man sie zum Lernen nutzt, etwa mit einem Beispiel-Dialog, einer Regel wie „erst eigener Lösungsversuch, dann Hinweis“ und einer Übung in der Sitzung. Eine gute Antwort zitiert eine Stelle aus der eigenen Kursbeschreibung, ordnet sie ein und formuliert die fehlende Anleitung als konkreten Satz oder Arbeitsauftrag.

Übung zu den Schlüsselbegriffen

1. **Fähigkeitsüberhang** (***capability overhang***). Die Modelle könnten weit mehr, genutzt wird ein kleiner Teil davon. Diese Lücke zwischen Können und Nutzung heißt Fähigkeitsüberhang.
2. **Leitplanke** (***guardrail***). Die Vorgabe im Tutor schützt das eigene Denken der Studierenden, auch wenn sie drängen. Anleitung käme von den Lehrenden und wäre keine Eigenschaft des Werkzeugs.
3. **Auslagerung des Denkens** (***cognitive offloading***). Ohne die Regel könnte ein Team ein Modell abgeben, das niemand im Team versteht. Die Arbeit wäre erledigt, gelernt wäre wenig.
4. **Erwünschte Schwierigkeiten** (***desirable difficulties***). Das Konzept, nach dem Hürden das Üben anstrengender, das Behalten aber dauerhafter machen, heißt erwünschte Schwierigkeiten. Ein Trainer, der nur lobt, räumt sie weg.
5. **Werkzeugkasten** (***harness***). Schnittstelle und Zuordnungsregeln sind Werkzeuge und Datenzugriffe um das Modell herum. Sie bestimmen, worauf sich seine Antworten stützen.
6. **Reasoning** (**schrittweises Nachdenken**). Ohne schrittweises Nachdenken scheitern Sprachmodelle öfter an anspruchsvollen Aufgaben. Das Ergebnis sagt mehr über den schwachen Zugang als über das, was KI im Fach leisten kann.

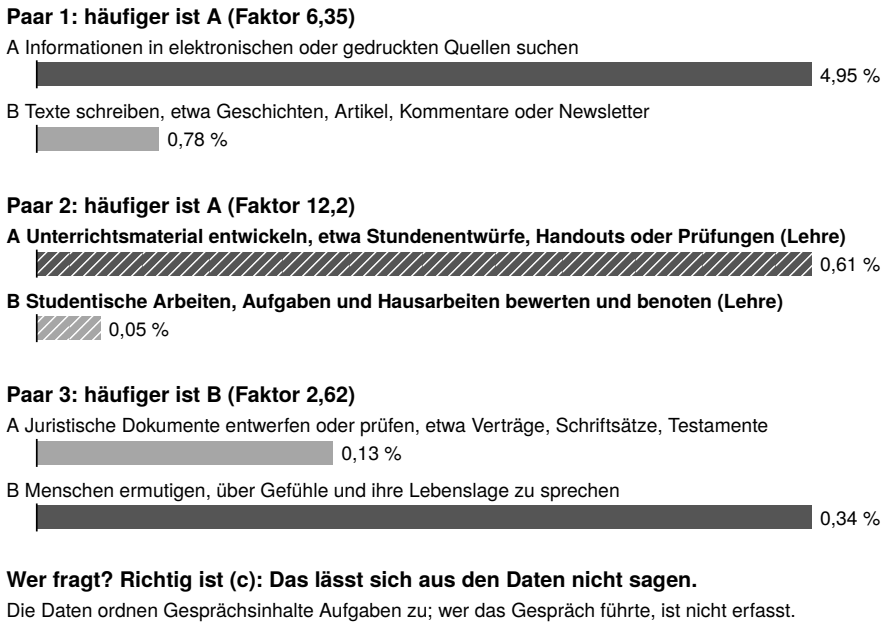


Abbildung B.1. Lösung zu „Raten Sie zuerst“ (Leserübung „Höher oder tiefer“, Kapitel 1.1.1): Recherche, Unterrichtsmaterial und Gespräche über die eigene Lebenslage liegen jeweils vor Textschreiben, Bewerten und juristischen Dokumenten. Balken je Paar auf den größeren Wert skaliert, Achse ab 0; schraffiert: Lehraufgaben. Daten: Anthropic Economic Index, Mai 2026, weltweit (Massenkoff et al., 2026).

Kapitel 2: Grundlagen von KI und LLMs

1. Der Text wird in Tokens (Textbausteine) zerlegt; die Tokens werden als Zahlen (Embeddings) dargestellt und über die Aufmerksamkeit (*Attention*) zueinander in Beziehung gesetzt; das Modell sagt das wahrscheinlichste nächste Token voraus, hängt es an und wiederholt den Schritt. Eine eingebaute Wahrheitsprüfung gibt es dabei nicht.
2. Halluzinationen folgen aus der Funktionsweise: Das Modell erzeugt eine plausible Fortsetzung, keine geprüfte. Gegenmittel sind die Eingrenzung des Inputs auf eigenes Material, Musterlösungen als Vorgabe und eine systematische Prüfung der Ergebnisse.

3. Höflichkeit, Drohungen und Trinkgeld ändern die Ergebnisse nicht, eine Expertenrolle macht sie nicht genauer, und das schrittweise Denken erledigen Reasoning-Modelle selbst. Ein Auftrag braucht stattdessen vier Angaben: das Ziel (was am Ende vorliegt), den Grund (für wen und wozu), das Material (Skript, Daten, bei Stilfragen Beispiele) und das Abnahmekriterium, an dem man erkennt, dass die Arbeit fertig ist.
4. Ohne Fachwörter: Der Chatbot setzt Text so fort, wie solcher Text gewöhnlich weitergeht. Eine Quellenangabe hat eine typische Form, und diese Form kann er erzeugen, ohne nachzusehen, ob es die Quelle gibt. Mit Fachwörtern: Das Modell sagt Token für Token die wahrscheinlichste Fortsetzung voraus und fragt keine Datenbank ab. Eine gute Antwort endet mit dem Gegenmittel: Quellen immer am Original prüfen.
5. Das reine Modell antwortet aus dem Trainingswissen; das Risiko sind veraltete oder vom Kurs abweichende Inhalte. Mit Ihrem Skript als Material (RAG) bleibt die Antwort nah am Kurs; das Risiko sind Lücken im Material und falsch gewählte Textstellen. Der Agent mit Internetzugang recherchiert aktuell und mehrstufig; das Risiko sind ungeprüfte Quellen und ein Weg zur Antwort, den man schwer nachvollzieht.
6. Die Grenze lässt sich nicht aus der Schwierigkeit einer Aufgabe ableiten, nur durch Ausprobieren finden. Eine gute Antwort beschreibt einen Test: die Aufgabe mehrfach in ein starkes Modell geben, die Antworten mit der eigenen Musterlösung vergleichen und typische Fehler notieren, bevor Studierende damit arbeiten.
7. Eine gute Antwort hält beide Ebenen auseinander. Eine einzelne Textanfrage kostet etwa so viel Energie wie zehn Sekunden Video-Streaming; das rechtfertigt keinen Verzicht auf didaktisch begründete Anwendungen, wohl aber Zurückhaltung bei aufwendigen Aufträgen wie der Videoerzeugung. Über Ausbau, Standorte und Strommix der Rechenzentren entscheidet dagegen die Politik, nicht der einzelne Lehrende (Kernaussage 7).
8. Eine gute Antwort wählt die vierte Stufe, einen Ordner mit Textdateien, weil nur dort Menschen nachlesen können, was der Agent für erledigt hält. Geprüft wird an einem festen Haltepunkt, etwa wöchentlich, und nur so viel, wie in der verfügbaren Zeit wirklich gelesen werden kann; ein falsch als beantwortet markierter Fall würde sonst bis zum Semesterende übergangen. Wer zusätzlich keine Namen von Studierenden im Gedächtnis ablegt, hat auch die Datenschutzfrage mitbedacht (Kapitel 2.4.3).

9. Zum äußeren Harness gehört alles, was das Team selbst festlegt: die Anleitung mit Rolle und Regeln, die hochgeladenen Kursunterlagen als Wissensbasis, die angeschlossenen Werkzeuge und die Prüfregeln; das Modell und die Plattform liefert der Hersteller. Eine gute Antwort begrenzt den Spielraum an einer Werkzeug- und an einer Ablaufstelle, etwa: nur aus den Kursunterlagen antworten und keine Lösung vor dem ersten eigenen Versuch der Studierenden. Sie erkennt die Spannung (Kapitel 2.1.2): Jeder Schritt, den der Tutor selbst wählt, nimmt den Lernenden eine Entscheidung ab; ein guter Tutor gibt die Autonomie im Lernweg an die Lernenden zurück.
10. Eine gute Antwort beginnt in der äußeren Schleife: Ziel, passendes Werkzeug und die Pflichten, die daraus folgen (Datenschutz, Offenlegung, Prüfung vor der Weitergabe), und leitet daraus ab, was beim Menschen bleibt. In der inneren Schleife nennt sie ein Prüfkriterium, das vor dem ersten Prompt feststeht, etwa eine Musterlösung oder eine Stichprobe, die man selbst nachrechnet. Die Schwachstelle liegt meist bei Discernment oder Diligence, weil man das Ergebnis selbst nicht prüfen kann oder nicht weiß, wem gegenüber man den KI-Einsatz offenlegen muss (Kapitel 5.1).

Übung zu den Schlüsselbegriffen

1. **Delegation**. Er entscheidet einmal für das Vorhaben, welche Arbeit an die KI geht und welche bei ihm bleibt. Wie er die Aufgabenvarianten anschließend in Auftrag gibt, wäre Description.
2. **Halluzination** (***hallucination***). Das Modell hat die typische Form einer Literaturangabe erzeugt, keine geprüfte Tatsache. Das ist kein Programmfehler, sondern folgt aus der Funktionsweise.
3. **Discernment**. Das Team beurteilt das Ergebnis der KI an einer Quelle. Diligence beträfe die Offenlegung der KI-Mitarbeit oder die Prüfung eines Systems vor der Freigabe.
4. **Diligence**. Offen zu sagen, wo KI mitgearbeitet hat, gehört zum verantwortlichen Einsatz. Discernment fragte nach der Qualität der Abschnitte, nicht nach ihrer Kennzeichnung.
5. **RAG** (***Retrieval-Augmented Generation***). Das Modell antwortet aus hinterlegtem Material statt nur aus dem Trainingswissen. Das senkt das Risiko erfundener oder vom Kurs abweichender Inhalte.
6. **Prompt als Werkvertrag**. Ziel, Grund, Material und ein prüfbares Abnahmekriterium machen den Prompt zum Werkvertrag. Die Expertenrolle macht die Antworten nicht besser.

Streich-Test (Kapitel 2)

Gestrichen werden die Zeilen 2, 3, 9 und 10; behalten werden 5 und 6; bei 1, 4, 7 und 8 bleibt der Inhalt und ändert sich die Form. Wer eine Umformulierungszeile gestrichen oder behalten hat, lag halb richtig. Merken Sie sich besonders die Zeilen, bei denen Sie „sicher" angekreuzt und danebengelegen haben. Quellenmarken: ■ Labor-Doku (Leitfaden eines KI-Labors), ● Studie, ▲ Folklore (ein Ratschlag, den kein Leitfaden je empfahl).

1. Umformulieren (● Studie). Für die Genauigkeit bringt die Expertenrolle nichts: In sechs Modellen änderte sie die Trefferquote auf schweren Testfragen nicht signifikant. Was die Zeile mitteilt, wandert in den Kontext („für meine Lehrveranstaltung"); für den Ton und in Simulationen, wo die Rolle der Inhalt ist, bleibt sie sinnvoll. Im neuen Prompt: *Ziel*. (Anthropic, 2026a; Basil et al., 2025)

2. Streichen (■ Labor-Doku). Drei Adjektive beschreiben einen Charakter, kein Ergebnis. Was „präzise" heißen soll, steht im neuen Prompt prüfbar unter Abnahme. (OpenAI, 2026)

3. Streichen (■ Labor-Doku). Reasoning-Modelle planen den Weg selbst; eine Phasen-Choreografie mit Ausrufezeichen ersetzt kein Ziel. Anders bei Tutoren und Simulationen: Dort ist der Ablauf das Produkt und bleibt. (OpenAI, 2026)

4. Umformulieren (■ Labor-Doku). Das Warten bleibt, denn das Modell soll erst fragen und dann bauen. „Zwingend" entfällt: Neuere Modelle befolgen Anweisungen genauer, und Nachdruck führt eher zu Übereifer. Neu: „Eine Frage pro Nachricht." Im neuen Prompt: *Zuerst*. (Anthropic, 2026a)

5. Behalten (■ Labor-Doku). Welche Fehlvorstellungen in Ihrem Kurs vorkommen, kann kein Modell wissen. Aus dieser Antwort entstehen die falschen Antwortoptionen; die Zeile liefert Kontext, keinen Lösungsweg. Im neuen Prompt: *Zuerst*. (Anthropic, 2026a)

6. Behalten (■ Labor-Doku). Anzahl, Fragetyp und Reihenfolge sind Abnahmekriterien: Sie und das Modell können prüfen, ob das Ergebnis sie erfüllt. Genau diese Art Zeile wird wichtiger. Im neuen Prompt: *Abnahme*. (OpenAI, 2026)

7. Umformulieren (■ Labor-Doku). Die Absicht bleibt, aber „plausibel" lässt sich nicht prüfen. Prüfbar wird es so: „Jede falsche Option beruht auf einer echten Fehlvorstellung." Im neuen Prompt: *Abnahme*. (Anthropic, 2026a)

8. Umformulieren (■ Labor-Doku). Die Zeile belehrt die Lehrperson über etwas, das sie weiß. Als Grund an das Modell gerichtet wird sie nützlich: Wer weiß, dass der Test eine Abrufübung ohne Notenfolgen ist, entscheidet auch ungeregelte Fälle passend. Im neuen Prompt: *Wozu*. (Anthropic, 2026a)

9. Streichen (■ Labor-Doku). 2022 hob die Aufforderung „Let's think step by step" die Trefferquote älterer Modelle deutlich. Reasoning-Modelle denken und prüfen von selbst; Anthropic rät, Prüfbefehle wie „double-check your answer" zu streichen, weil sie Kosten ohne Qualitätsgewinn verursachen. (Anthropic, 2026b; Kojima et al., 2022; Meincke et al., 2025a; OpenAI, o. J.)

10. Streichen (▲ Folklore). Kein Leitfaden der Labore hat Trinkgeld je empfohlen; der Rat verbreitete sich über Erfahrungsberichte. Im Test änderten Trinkgeld und Drohungen die Ergebnisse auf schweren Fragen insgesamt nicht. (Meincke et al., 2025b)

Der neu gefasste Quiz-Ersteller in Anhang A (Kapitel A.1.4) hat 119 statt 275 Wörter. Er nennt Ziel, Wozu, Zuerst (die Fragen an Sie), Material und Abnahme; das Material, also Skript oder Folien, fehlte in der alten Fassung ganz.

Selbsttest zum Film „Stützräder"

1. (a). Frühe Modelle gingen nicht von sich aus schrittweise vor; der Satz holte das nach. Reasoning-Modelle tun es selbst, deshalb bringt er heute kaum noch etwas und kostet Zeit und Tokens (Kapitel 2.3).
2. (b). Denk- und Prüfaufforderungen erledigt ein Reasoning-Modell selbst. Zeile (a) ist das Wozu, Zeile (c) das Format; beide bleiben.
3. (b). In Tutor- und Simulationsprompts ist der Gesprächsablauf die Spezifikation, nicht ein Lösungsweg für das Modell. Er bleibt, am besten mit einem Halbsatz Begründung je Regel.

Selbsttest zum Film „Das nächste Token in neun Genres"

1. (a). Erst wird der Text zerlegt und in Zahlen übersetzt, dann wird gerechnet, dann ein Token gezogen und angehängt; danach beginnt die Schleife neu (Kapitel 2.6.1).

2. (b). Häufige englische Wörter sind oft ein einziges Token, deutsche Komposita zerfallen in Stücke. Mehr Tokens heißt höhere Kosten pro Text und ein schneller gefülltes Kontextfenster.
3. (b). Das Modell schreibt fort, was wahrscheinlich ist, und prüft keine Wahrheit (Kapitel 5.3); ein einmal gezogenes, unpassendes Token bleibt stehen, und die folgenden bauen darauf auf.

Kapitel 4: Lern- und Wirkmechanismen

1. *Knowing that* (Faktenwissen): Abrufübungen und Erklärungen. *Knowing how* (Prozesswissen): dialogisches Coaching und durchgearbeitete Beispiele. *Knowing with* (Transfer): Szenarien und Rollenspiele.
2. Interaktiv vor konstruktiv vor aktiv vor passiv. Eine KI-Lernaktivität wirkt umso stärker, je weiter oben sie auf dieser Leiter steht.
3. Der Testeffekt entsteht durch den Versuch, Wissen aus dem Gedächtnis abzurufen; eine sofort gelieferte Antwort erspart genau diesen Versuch. Der Bot sollte zuerst eine eigene Antwort einfordern, Hinweise vor Lösungen geben und eine Begründung verlangen, wo eine Lösung übernommen wird.
4. Eine gute Antwort ordnet drei konkrete Lernziele zu und benennt die Lücke; häufig ist es *knowing with*. Die Methode stammt aus der passenden Stufe in Lösung 1.
5. Eine gute Antwort nennt eine konkrete Stelle im Semester, etwa einen Wochenrückblick mit Aufgaben aus früheren Themen, und hält fest, dass das Modell die Varianten liefert, die Prüfung der Varianten aber bei Ihnen bleibt.
6. Die entscheidende Frage lautet: Wie haben die Studierenden in einer Prüfung ohne KI abgeschnitten? Bessere Übungsleistung kann mit schlechterer Prüfungsleistung einhergehen; ein Tutor im Stil des normalen ChatGPT verbesserte die Übungsleistung um 48 Prozent und senkte die Prüfungsleistung um 17 Prozent (Bastani et al., 2025).
7. Nein. In einem Crossover-Experiment (Varianten nacheinander) mit 1.059 Programmieranfängern unterschieden sich Tutoren mit unterschiedlichen didaktischen System-Prompts auf keinem der konfirmatorischen Maße (Barth et al., 2026). Die Leitplanke muss in Aufgabe, Rückmeldung und Ablauf liegen (eigene Antwort zuerst, Hinweise vor Lösungen, Begründungspflicht) und in einer verbindlichen, angeleiteten Einbettung in den Kurs (Gallegos, 2026).

Übung zu den Schlüsselbegriffen

1. **Testgestütztes Lernen** (***test-enhanced learning***). Die Studierenden rufen ab, statt wiederzulesen; das festigt den Stoff stärker. Der Bot nimmt der Dozentin nur die Arbeit ab, die Fragen zu schreiben.
2. **Gemischtes Üben** (***interleaving***). Weil die Aufgabentypen wechseln, üben die Studierenden die Unterscheidung mit, die ihnen in der Klausur niemand abnimmt. In Blöcken stünde das Verfahren schon über der Aufgabe.
3. **Verteiltes Üben** (***spacing***). Dieselbe Übungszeit, über das Semester verteilt statt gebündelt, stärkt die Langzeiterinnerung. Die Themen werden dabei nicht gemischt, sie kehren mit Abstand wieder.
4. **Fragebasierte Ausarbeitung** (***explanatory questioning***). Warum- und Was-wäre-wenn-Fragen zwingen dazu, den Stoff mit vorhandenem Wissen zu verknüpfen. Es geht nicht um das Abrufen eines Fakts, sondern um die Begründung dahinter.
5. **Kognitive Belastung** (***cognitive load***). Die Antwort überfordert das Arbeitsgedächtnis, das für das Wesentliche frei bleiben sollte. Ein didaktisch angepasster Bot würde kurz antworten und eine Frage zurückgeben.
6. **Wissen anwenden** (***knowing with***). Das Wissen ist vorhanden und muss auf eine neue Situation übertragen werden. Das ist die höchste der drei Stufen nach Hattie.

Kapitel 5: Phasen der Arbeit mit generativer KI (4D)

1. Mündlichkeit (Kolloquium, Präsentation mit strukturierter Fragerunde), Prozessorientierung (Prozessjournal mit Versionsverlauf), Kontextualisierung (Aufgaben mit realen, lokalen oder persönlichen Daten), Kollaboration und Kreation (Gruppenaufgaben in der Veranstaltung, Peer-Beurteilung, gestufte Projekte).
2. Die Richtlinien passen die Eigenständigkeitserklärung an, klären Verdachtsfälle im Gespräch, schließen eine automatisierte Bewertung aus und verlangen, Prüfungsformate didaktisch weiterzuentwickeln. Detektionssoftware gehört nicht dazu, weil sie als unzuverlässig gilt und selbst Prüfende KI-gestützte Arbeiten nicht von rein menschlichen unterscheiden können; ein Detektionswert taugt höchstens als Anlass für ein Gespräch, nie als Beweis.

3. Eine Stichwortliste, eine Übersicht nach Arbeitsphase oder nach Werkzeug und ein Reflexionstagebuch.
4. Eine gute Antwort prüft jede Säule an der eigenen Prüfungsleistung und wählt die mit dem geringsten Umbauaufwand; oft ist es ein kurzes Kolloquium zur schriftlichen Arbeit.
5. Eine gute Antwort ordnet jeder Phase eine konkrete Aufgabe und ihr Lernprinzip zu, in der Festigungsphase etwa Abrufübungen statt Zusammenfassungen. Sie benennt eine verantwortliche Person für die Freigabe und legt gegen das größte Risiko, meist die Auslagerung des Denkens, eine Vorkehrung in die Aufgabe selbst, nicht nur eine Regel.
6. Eine gute Antwort prüft die eigene Richtlinie auf die Elemente aus Lösung 2 und auf die Frage, ob Studierende und Lehrende sie kennen; eine Richtlinie wirkt erst, wenn sie bekannt ist und diskutiert wird.
7. Der Vorschlag ist nicht praktikabel: Ein vollständiges Protokoll jeder Interaktion erzeugt Masse ohne Aussagekraft und wird weder sorgfältig geführt noch gelesen. Eine gute Antwort setzt eine der drei Formen aus Lösung 3 dagegen und verbindet sie mit einem mündlichen Element, das die Autorschaft sichert.

Übung zu den Schlüsselbegriffen

1. **Homework Apocalypse**. Die Aufgabe ist nicht nur leichter zu umgehen, sie erscheint den Studierenden sinnlos. Genau diese Entwertung meint das Schlagwort.
2. **KI-Detektor**. Die Erkennung ist unzuverlässig, und ein Fehlalarm trifft Studierende, die nichts falsch gemacht haben. Ein erhärteter Verdacht gehört ins Klärungsgespräch.
3. **Mündlichkeit**. Im Gespräch zeigt sich, ob die Studentin ihre Entscheidungen erklären und übertragen kann. Der Text darf mit KI entstanden sein, nachgewiesen wird das Verständnis.
4. **Prozessorientierung**. Bewertet wird der Weg zum Ergebnis, nicht nur das Produkt. Ein dokumentierter Prozess ersetzt den Detektor als Grundlage der Beurteilung.
5. **Kontextualisierung**. Die Aufgabe verlangt nicht öffentliche Daten und eigene Erhebung; ein Chatbot kann sie nicht aus dem Stand lösen. Bewertet wird weiterhin vor allem das Produkt, die Entscheidungsvorlage.
6. **Betreiber** (***deployer***). Wer KI-Systeme bereitstellt, betreibt sie im Sinne der Verordnung. Daraus folgt nach Artikel 4 die Pflicht, Maßnahmen für die KI-Kompetenz des Personals zu ergreifen.

Detektor-Duell (Kapitel 5)

Auszug A: KI. Der Text ist ein KI-Text von Claude Opus 5.5 (Prompt-Variante a, Lauf vom 02.11.2026). Der Lehr-Detektor gibt 96 % für KI an und urteilt damit „KI" (richtig).

Auszug B: Mensch. Der Text ist ein Schüleraufsatz aus PERSUADE 2.0 (Klasse 11). Der Lehr-Detektor gibt 12 % für KI an und urteilt damit „Mensch" (richtig).

Wer beide richtig hatte, sollte sich die eigene Sicherheit ansehen: Bei zwei Auszügen trifft auch Raten in einem von vier Fällen beide. Belastbarer ist das Duell mit acht Auszügen in der Online-Fassung.

Kapitel 6: Rollen der KI: Hiwi, Copilot, Tutor, Simulator

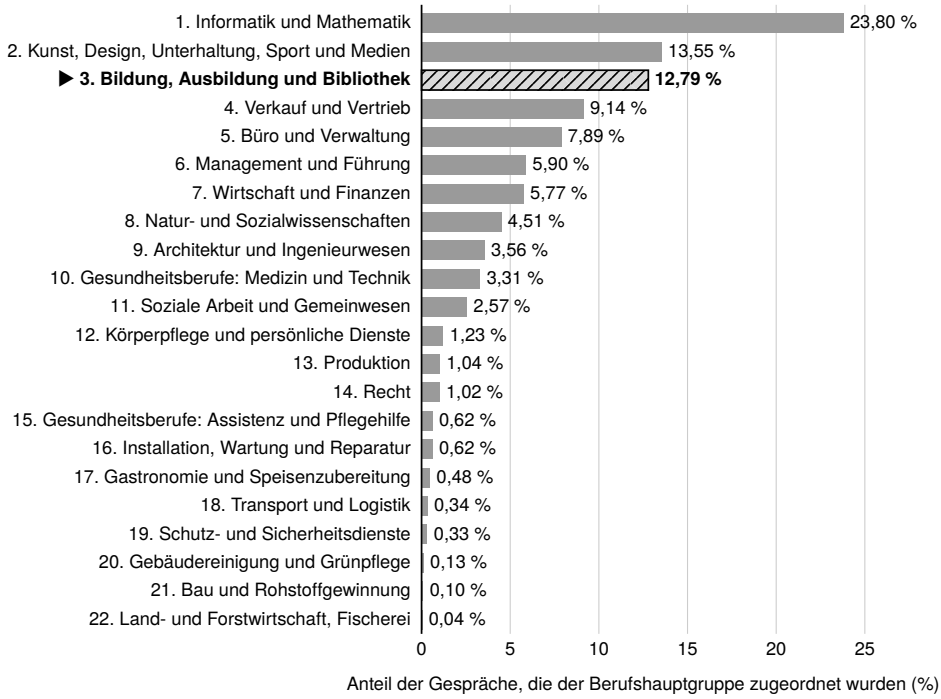


Abbildung B.2. Lösung zu „Raten Sie zuerst“ (Bibliothek der Prompts in Kapitel 6.1): Das Regal *Bildung, Ausbildung und Bibliothek* steht mit 12,79 % der Gespräche auf Platz 3 von 22 (aus Deutschland: Platz 2, 12,87 %). Breit ist es vor allem durch den Bibliotheksberuf (4,22 %) mit Auskunfts- und Rechercheaufgaben; die Hochschullehrenden aller 35 Fächer kommen zusammen auf 2,12 %. Gezählt sind Gespräche, die Berufen zugeordnet wurden, nicht Menschen in diesen Berufen. Schraffiert: Bildungsregal; Achse ab 0. Daten: Anthropic Economic Index, Mai 2026, weltweit (Massenkoff et al., 2026); Berufe nach US-Klassifikation SOC, Aufgaben nach O*NET 31.0 Database (National Center for O*NET Development, 2026).

1. Als Hiwi nimmt die KI Arbeit ab (Zusammenfassungen, Materialvorbereitung), als Copilot ermöglicht sie, was man allein nicht könnte (Recherche, Programmieren von Lernwerkzeugen), als Tutor begleitet sie Lernende (Erklärungen, Rückmeldung), als Simulator stellt sie Übungssituationen bereit (Rollenspiele, Verhandlungen).

2. Automatisierung (*automation*) heißt, dass eine Aufgabe vom Menschen zur KI wandert (standardisierte Materialien, Notenverwaltung). Augmentierung (*labor-augmenting technology*) heißt, dass die Aufgabe beim Menschen bleibt und mit KI-Unterstützung schneller oder besser gelingt (Rückmeldungen, Aufgabenvarianten). Neue Aufgaben (*new tasks*) entstehen erst durch die KI (Qualitätskontrolle von KI-Ausgaben, Kursdesign mit KI) (Acemoglu et al., 2025).
3. Wird einmalig oder iterativ gesucht, und entsteht eine Trefferliste oder ein erzeugter Text? Daraus ergeben sich Quick Search (einmalig, Liste), Quick RAG (einmalig, Zusammenfassung), Deep Search (iterativ, Liste) und Deep Research (iterativ, Bericht).
4. Im Role Play übernehmen Studierende eine Rolle und handeln in einer Situation, etwa einer Verhandlung. Im Goal Play bleiben sie in ihrer eigenen Rolle und wenden ein Konzept oder Analyseraster an, zum Beispiel indem sie einer Figur bei der Zielsetzung helfen.
5. Eine gute Antwort ordnet jede Aufgabe einer der drei Formen zu und nennt mindestens eine neue Aufgabe, die heute nicht im Zeitbudget steht, etwa das Testen eines Tutors oder die Pflege einer Wissensbasis.
6. Eine gute Antwort enthält drei Bremsen, etwa: keine Lösung vor dem eigenen Versuch, Hinweise vor Lösungen, eine Begründung einfordern. Die Musterlösungen stammen aus den eigenen Unterlagen und werden dem Tutor als Input mitgegeben, damit er an ihnen prüft statt frei zu erzeugen.
7. Role Play passt zu Situationen mit einem Gegenüber (Verhandlung, Kundengespräch, Konfliktgespräch), Goal Play zur Anwendung eines Analyserasters. Im Debriefing (Nachbesprechung) gehören auf den Tisch: was passiert ist, welches Konzept dahinterstand, wo die KI aus der Rolle fiel und was sich auf echte Situationen übertragen lässt.
8. Eine gute Antwort benennt die neuen Aufgaben, die Zeit kosten (Einrichtung, Tests, Pflege, Qualitätskontrolle), und eine Bedingung für den Nettogewinn: etwa, dass ein Werkzeug über mehrere Semester und Kohorten genutzt oder im Kollegium geteilt wird.

Übung zu den Schlüsselbegriffen

1. **Automatisierung** (***automation***). Die Aufgabe ist vollständig vom Menschen zur Technik gewandert. Bei Augmentierung schriebe die Hilfskraft weiter, nur schneller mit KI-Entwürfen.
2. **Neue Aufgaben** (***new tasks***). Qualitätskontrolle von KI-Werkzeugen ist eine Aufgabe, die erst mit der Technik entsteht. Sie gehört in jede

Rechnung, ob KI am Ende Zeit spart.

3. **Deep Research**. Iterative Suche und ein erzeugter Bericht: Das ist Deep Research. Er verlangt die gründlichste Prüfung, weil jede Aussage im Text auf ihre Quelle zurückgeführt werden muss; Deep Search hätte eine Liste geliefert.
4. **Programmier-Agent** (***coding agent***). Auftrag in Alltagssprache, Änderungen über mehrere Dateien, eigener Testlauf: Das ist die Schleife eines Programmier-Agenten. Ob das Team den Code versteht, sagt das Testergebnis nicht.
5. **Goal Play** (**zielgerichtetes Spiel**). Die Studierenden übernehmen keine fremde Rolle, sie wenden ihr Wissen an, indem sie eine KI-Figur anleiten. Im Role Play spielten sie selbst eine Rolle, etwa die Einkäuferin.
6. **Debriefing** (**Nachbesprechung**). Die Lehrende bespricht Verlauf und Fehler der KI nach und sichert so den Lernertrag. Ohne diesen Schritt bliebe ungeklärt, was am simulierten Gegenüber typisch und was falsch war.

Prüfen Sie selbst (**Kapitel 6.1.1.1**)**.** Der Prüfagent urteilte: *überzogen*. Grenzziehungen gibt es, wie die erste Stelle zeigt. Die Stichwortzählung trifft aber nur 12 von 125 Interviews, und vier davon sind Fehltreffer wie die zweite Stelle, die von den „Grenzen der Wissenschaft" spricht. Einzelne weitere Grenzziehungen ohne Stichwort kommen vor; „viele" ist damit nicht gedeckt. Die beiden anderen Prüfaufgaben der Online-Fassung lösen sich im Element selbst auf.

Kapitel 7: Artefakte: Fallbeispiele aus der Lehre

Lernfragen in den Beispielen

- *Fragen-Generator:* Er verletzt die Regel, die Lösung nie vor dem eigenen Versuch zu nennen, und die Anweisung, jede Antwort zuerst auf Papier zu schreiben. Der Effekt entsteht beim Abrufen selbst; wer die Lösung abtippt, liest sie nur noch einmal, und gegen das Wiederlesen gewinnt der Abruf nach zwei Tagen (Roediger & Karpicke, 2006).
- *Lernsongs:* Der Song sichert Namen und Reihenfolge von Verfahren, die schon verstanden sein müssen; vor der Einführung hat er nichts, woran er anknüpft, und die Rechenpausen setzen ein Verfahren voraus, das noch nicht erklärt ist. Einmaliges Abspielen verschenkt den Effekt, der

verteilte Wiederholung braucht (Katz et al., 2021); ein zweiter Durchgang einige Tage später gehört in den Plan.

- *Quizspiele:* Die kleinste Änderung ist ein Zustand, der in die nächste Runde getragen wird, etwa ein Budget oder ein Lagerbestand: Wer in der Flut auf Sicherheitsbestand setzt, hat im folgenden Erdbeben weniger Geld für Dual Sourcing (Einkauf bei zwei Lieferanten). Dann ändert eine Entscheidung etwas an der Lage der nächsten Runde, und der Zielkonflikt wird sichtbar. Eine Fehlerliste, die falsch beantwortete Fragen in der nächsten Runde öfter stellt, genügt nicht: Sie ändert den Lernstoff, nicht die Lage, und macht aus dem Quiz ein adaptives Quiz, noch keine Entscheidungsübung.
- *Interaktive Widgets:* Den Engpass findet man durch Hinsehen, denn das Widget hebt ihn farbig hervor. Die Frage nach der folgenlosen Änderung verlangt eine Vorhersage und einen Beweis und trifft die Fehlvorstellung, jede Verbesserung an einem Schritt erhöhe den Ausstoß; das ist angeleitetes Entdecken mit Erklärungsauftrag (Alfieri et al., 2011).
- *Tutoring:* Der Tutor war als Antwortmaschine eingestellt: Auf Nachfrage gab er die Lösung heraus (Liu et al., 2026). Erkennbar wäre das mit dem Prüfkriterium der Empfehlung gewesen, einem Testlauf, in dem jemand dreimal um die Lösung bittet. Die Erfolgsmessung gehört an eine Prüfung ohne KI, nicht an die Nutzungszahlen.
- *Fallstudien generieren:* Formen ist die körperlich härteste Arbeit, also hält der Backmeister es für den Engpass und verwechselt Anstrengung mit Kapazität. Nennt der Fall den Engpass sofort, entfallen die Vermutung vor dem Rechnen, die das spätere Lernen verbessert (Pan & Carpenter, 2023), und der Konflikt, der die Geschichte trägt (Willingham, 2021).
- *Simulationen durch Lehrende:* Das Widget zeigt die mechanischen Ursachen, Prognose aus Bestellungen und Lieferzeit. Es kann nicht zeigen, dass Menschen die Ware unterwegs übersehen, denn seine Stufen bestellen nach einer festen Regel. Diese Verhaltensursache (Croson & Donohue, 2006; Sterman, 1989) erleben die Studierenden im Beer Game (Bestellplanspiel entlang einer Lieferkette), und das Debriefing macht sie sichtbar, wenn es fragt, wer die offenen Bestellungen mitgezählt hat.
- *Simulationen selbst bauen:* Die Prüfzelle testet nur Regeln, die jedes korrekte Modell erfüllt. Deshalb kann sie automatisch und unveränderlich sein, ohne ein Team für eine vertretbare Entscheidung zu bestrafen. Ob die Gegenmaßnahme gut ist, ist ein Urteil unter Zielkonflikten und gehört in die Postersession, wo das Team seine Wahl begründet und Vor-

hersagen trifft.

- *Karriereberater:* Er verstößt gegen die Regel, dass das Sprachmodell nur Daten erklärt, die aus einer benannten Quelle stammen; eine geschätzte Zahl sieht genauso verlässlich aus wie eine belegte. Er sollte auf eine Gehaltsstatistik verweisen, etwa den Entgeltatlas der Bundesagentur für Arbeit, oder eine Zahl nur mit Quelle und Stand nennen.
- *Projektlernen mit Praxispartnern:* Carlile beschreibt Wissensgrenzen zwischen Abteilungen und Organisationen mit eigenen Interessen. Mit einem Praxispartner wandert Wissen tatsächlich über eine solche Grenze: Der Partner hat Vertraulichkeitsinteressen und einen eigenen Anwendungsfall, und beides muss vor dem Prototyp verhandelt werden. Zwischen Studierenden und Fachgebiet gibt es keine zweite Organisation; dort ist die Stufenfolge ein Bild, das die Beispiele ordnet.

Lernfragen am Kapitelende

1. Syntaktisch (übertragen, gemeinsames Vokabular genügt), semantisch (übersetzen, Bedeutungen müssen erschlossen werden), pragmatisch (umformen, Wissen wird gegen Interessen und Folgen angewendet). Carlile beschreibt Grenzen zwischen Abteilungen einer Organisation; erst beim Projektlernen mit Praxispartnern wandert Wissen tatsächlich über eine solche Grenze (Carlile, 2004).
2. Von 2.379 berechtigten Studierenden nutzten nur 15 Prozent den Tutor, drei Viertel ihrer Anfragen verlangten eine fertige Antwort, und die Abschlussnote lag 0,37 Standardabweichungen unter der Kontrollgruppe. Der Tutor war im Standardmodus als Antwortmaschine konfiguriert und ersetzte das eigene Arbeiten am Material (Liu et al., 2026).
3. Der Anteil der Berechtigten, die den Tutor überhaupt nutzen; der Anteil der Anfragen, die eine fertige Antwort verlangen, gegenüber denen, die Rückmeldung auf eigene Arbeit suchen; und ob der Tutor bei einer offensichtlichen Prüfungsfrage auf das Material verweist oder sie löst.
4. Eine gute Antwort benennt Wissensform und Lerntechnik, bevor ein Werkzeug fällt, begründet die Wahl des Beispiels mit Gruppengröße, Prüfungsform oder Partnern und nennt den Engpass, der zuerst auftreten würde, samt einer Vorkehrung.
5. Eine gute Antwort stützt das Prinzip auf einen Beleg, formuliert die Empfehlung als Wenn-dann-Regel ohne Produktnamen und gibt ein Prüfkriterium, das sich mit Ja oder Nein beantworten lässt. Den Austauschtest besteht sie, wenn sie nach dem Tausch des Werkzeugs gegen ein anderes noch stimmt.

6. Ein sokratischer System-Prompt allein verhindert die Nutzung als Antwortmaschine nicht (Gerber et al., 2026). Für den BWL-Tutor folgt daraus, die Leitplanken in Aufgabe und Ablauf zu legen und mit den drei Kennzahlen aus Lösung 3 zu prüfen, ob sie greifen.

Übung zu den Schlüsselbegriffen

1. **Pragmatisches Wissen** (**umformen;** ***transforming***). Es reicht nicht, Begriffe zu teilen oder Bedeutungen zu klären; das Wissen muss gegen Interessen angewendet werden. Das ist die pragmatische Stufe.
2. **Musikalische Merkhilfe** (***musical mnemonic***). Melodie und Rhythmus stützen das wörtliche Behalten von Namen und Reihenfolge. Das Rechnen selbst lernt man am Lösungsbeispiel, nicht am Lied.
3. **Konkretheitsabbau** (***concreteness fading***). Vom vertrauten, konkreten Fall führt die Folge schrittweise zur abstrakten Darstellung. Entscheidend ist die Reihenfolge der Darstellungen, nicht die Arbeitsaufträge.
4. **Angeleitetes Entdecken** (***enhanced discovery***). Arbeitsaufträge, Vorhersage und Erklärungsauftrag lenken das Ausprobieren. Ohne sie wüssten Studierende nicht, was sie am Widget entdecken sollen.
5. **Prüfzelle**. Der Block prüft Regeln, die jedes korrekte Modell erfüllt, unabhängig von der gewählten Lösung. Ob das Team sein Modell versteht, klärt erst das Gespräch auf der Postersession.
6. **Test mit Nutzenden**. Personen aus der Zielgruppe zeigen, wo und warum das Werkzeug scheitert. Eine Prüfzelle testet dagegen nur, ob der Code Regeln einhält.

Literaturverzeichnis

Acemoglu, D., Kong, F., & Restrepo, P. (2025). Tasks at work: Comparative advantage, technology and labor demand. In C. Dustmann & T. Lemieux (Hrsg.), *Handbook of Labor Economics*: (Bd. 6, 1–114). Elsevier. https://doi.org/10.1016/bs.heslab.2025.08.003.

Alfieri, L., Brooks, P. J., Aldrich, N. J., & Tenenbaum, H. R. (2011). Does discovery-based instruction enhance learning? *Journal of Educational Psychology*, *103*(1), 1–18. https://doi.org/10.1037/a0021017.

Anthropic (2026a). Prompting best practices. *Claude Platform Docs*. https://platform.claude.com/docs/en/build-with-claude/prompt-engineering/claude-prompting-best-practices.

Anthropic (2026b). Prompting Claude Opus 5. *Claude Platform Docs*. https://platform.claude.com/docs/en/build-with-claude/prompt-engineering/prompting-claude-opus-5.

Barth, M., Thorgeirsson, S., Etemadi, K., Leinonen, J., Cotrini, C., & Su, Z. (2026). Steering AI tutors through system prompts: A crossover study on self-regulated learning and cognitive engagement scaffolds in CS1. https://doi.org/10.1145/3765964.3811656.

Basil, S., Shapiro, I., Shapiro, D., Mollick, E., Mollick, L., & Meincke, L. (2025). *Prompting Science Report 4: Playing Pretend: Expert Personas Don't Improve Factual Accuracy*. arXiv. https://doi.org/10.48550/arXiv.2512.05858.

Bastani, H., Bastani, O., Sungu, A., Ge, H., Kabakcı, Ö., & Mariman, R. (2025). Generative AI without guardrails can harm learning: Evidence from high school mathematics. *Proceedings of the National Academy of Sciences*, *122*(26), e2422633122. https://doi.org/10.1073/pnas.2422633122.

Carlile, P. R. (2004). Transferring, translating, and transforming: An integrative framework for managing knowledge across boundaries. *Organization Science*, *15*(5), 555–568. https://doi.org/10.1287/orsc.1040.0094.

Croson, R., & Donohue, K. (2006). Behavioral causes of the bullwhip effect and the observed value of inventory information. *Management Science*, *52*(3), 323–336. https://doi.org/10.1287/mnsc.1050.0436.

Gallegos, S. (2026). *Guidance over adoption: Experimental evidence on AI-assisted learning* (IZA Discussion Paper; Nr. 18513). Institute of Labor Economics (IZA).

Gerber, A., Lorenz, L., & Pfeiffer, U. (2026). KI-Tutoren in der Lehre: rechtlich sicher, didaktisch wertvoll, technisch innovativ. In J. Leschke, R. Queckenberg, & M. Persike (Hrsg.), *Learning analytics, artificial intelligence und data mining in der hochschulbildung*: (S. 57–64). transcript. https://doi.org/10.14361/9783839458761-057.

Katz, J. J., Ando, M., & Wiseheart, M. (2021). Optimizing song retention through the spacing effect. *Cognitive Research: Principles and Implications*, *6*(1), 79. https://doi.org/10.1186/s41235-021-00345-7.

Kojima, T., Gu, S. S., Reid, M., Matsuo, Y., & Iwasawa, Y. (2022). Large language models are zero-shot reasoners. https://doi.org/10.48550/arXiv.2205.11916.

Liu, J., Sweet, T., Chen, M. H., Engelberg, J., Masters, M. C., Clark, M., Persaud, A., Lancaster, A., Hollingsworth, J. K., & Rice, J. K. (2026). *The effects of course-integrated AI tutoring on student performance and engagement: A randomized university trial* (EdWorkingPaper; Nr. 26-1598). Annenberg Institute at Brown University. https://doi.org/10.26300/y3f8-vh05.

Massenkoff, M., Lyubich, E., Sacher, S., Hitzig, Z., Zhang, S., Heller, R., & McCrory, P. (2026). *Anthropic Economic Index report: Cadences*. Anthropic.

Meincke, L., Mollick, E. R., Mollick, L., & Shapiro, D. (2025a). *Prompting Science Report 2: The Decreasing Value of Chain of Thought in Prompting*. arXiv. https://doi.org/10.48550/arXiv.2506.07142.

Meincke, L., Mollick, E., Mollick, L., & Shapiro, D. (2025b). *Prompting Science Report 3: I'll pay you or I'll kill you -- but will you care?* arXiv. https://doi.org/10.48550/arXiv.2508.00614.

National Center for O*NET Development (2026). *O*NET 31.0 Database*. U.S. Department of Labor, Employment and Training Administration. https://www.onetcenter.org/database.html.

OpenAI (o. J.). Reasoning best practices. *OpenAI API Docs*. https://developers.openai.com/api/docs/guides/reasoning-best-practices.

OpenAI (2026). Using GPT-5.5. *Using GPT-6* (*OpenAI API Docs*). https://developers.openai.com/api/docs/guides/gpt-5.5.

Pan, S. C., & Carpenter, S. K. (2023). Prequestioning and pretesting effects: A review of empirical research, theoretical perspectives, and implications for educational practice. *Educational Psychology Review*, *35*(4), 97. https://doi.org/10.1007/s10648-023-09814-5.

Roediger, H. L., & Karpicke, J. D. (2006). Test-enhanced learning: taking memory tests improves long-term retention. *Psychological science*, *17*(3), 249–255. https://doi.org/10.1111/j.1467-9280.2006.01693.x.

Sterman, J. D. (1989). Modeling managerial behavior: Misperceptions of feedback in a dynamic decision making experiment. *Management Science*, *35*(3), 321–339. https://doi.org/10.1287/mnsc.35.3.321.

Willingham, D. T. (2021). *Why don't students like school?: A cognitive scientist answers questions about how the mind works and what it means for the classroom*. Jossey-Bass.

Glossar

Das Glossar erklärt die Kernbegriffe des Buchs in Alltagssprache; die Angabe in Klammern nennt die Stelle, an der ein Begriff eingeführt wird. Viele Fachwörter rund um generative KI sind englische Neubildungen aus lateinischen und griechischen Wurzeln. Wo die Herkunft das Verständnis stützt, nennt eine Herkunftszeile sie: Wer weiß, dass eine *Halluzination* auf das lateinische Wort für gedankenloses Reden zurückgeht, versteht schneller, warum sie kein technischer Defekt ist.

Generative KI (*generative AI*, GenAI) Sammelbegriff für KI-Systeme, die neue Inhalte erzeugen: Texte, Bilder, Ton, Programmcode. Im Buch werden KI, GenAI und Sprachmodell weitgehend gleichbedeutend verwendet, weil die meisten Lehrenden erst seit ChatGPT aktiv mit KI arbeiten (Kapitel 2.1.1).

Herkunft: lat. *generare*, „hervorbringen, zeugen“.

Sprachmodell (*Large Language Model*, LLM) Ein Rechenmodell, das aus riesigen Textmengen gelernt hat, das jeweils nächste Wort in einer Wortkette vorherzusagen. Aus dieser einfachen Grundoperation entstehen Antworten, Zusammenfassungen und Dialoge; eine eingebaute Prüfung auf Wahrheit gibt es nicht (Kapitel 2.1.1).

Herkunft: Modell über ital. *modello* zu lat. *modulus*, „kleines Maß“, Verkleinerung von *modus*, „Maß, Art und Weise“.

AI Fluency „Gewandtheit im Umgang mit KI“: die Fähigkeit, effektiv, effizient, ethisch und sicher mit KI zu arbeiten. Der Kompetenzrahmen von Rick Dakan und Joseph Feller zerlegt sie in vier Kompetenzen, das 4D-Modell aus Delegation, Description, Discernment und Diligence, mit je drei Unterkompetenzen. Kapitel 5 ist danach gegliedert (Kapitel 5.1.1).

Herkunft: engl. *fluency* über lat. *fluentia* zu *fluere*, „fließen“: Wer eine Sprache fließend spricht, muss nicht über jedes Wort nachdenken.

Delegation Die erste der vier Kompetenzen im 4D-Modell: entscheiden, was der Mensch übernimmt und was die KI. Dazu gehört, das eigene Ziel zu kennen, zu wissen, was die verfügbaren Werkzeuge können, und die Arbeit danach aufzuteilen. Bildet mit Diligence die äußere Schleife, die einmal je Vorhaben läuft (Kapitel 5.1.1; Kapitel 5.2).

Herkunft: lat. *delegare*, „übertragen“.

Description Die zweite Kompetenz im 4D-Modell: der KI klar sagen, was man will, also welches Ergebnis, welche Art der Zusammenarbeit und welches Verhalten. Im Alltag heißt das vor allem, Prompts als Auftrag mit Ziel und Abnahmekriterium zu schreiben. Bildet mit Discernment die innere Schleife, die sich in jedem Arbeitsgang mehrmals dreht (Kapitel 5.1.1; Kapitel 2.3).

Herkunft: lat. *describere*, „umreißen, aufzeichnen“.

Discernment Die dritte Kompetenz im 4D-Modell: beurteilen, was die KI liefert, also das Ergebnis, den Verlauf der Zusammenarbeit und das Verhalten der KI. Nötig, weil ein Sprachmodell keine Wahrheit prüft und über sein eigenes Vorgehen nicht verlässlich Auskunft gibt (Kapitel 5.1.1; Kapitel 5.3).

Herkunft: lat. *discernere*, „unterscheiden, trennen“.

Diligence Die vierte Kompetenz im 4D-Modell: KI verantwortlich und offen einsetzen, also sorgfältig beim Erzeugen, offen darüber, wo KI mitgearbeitet hat, und prüfend, bevor ein Ergebnis oder ein System freigegeben wird. Die Technik verschiebt die Verantwortung, sie nimmt sie nicht ab (Kapitel 5.1.1; Kapitel 5.4).

Herkunft: lat. *diligentia*, „Sorgfalt“, von *diligere*, „hochachten, sorgsam auswählen“.

GPT Abkürzung für Generative Pre-trained Transformer: ein Sprachmodell, das Texte erzeugt (*generative*), vorab mit großen Textmengen trainiert wurde (*pre-trained*) und auf der Transformer-Architektur beruht. Ursprünglich die Modellreihe von OpenAI, heute oft als Gattungsname gebraucht (Kapitel 2.6.1).

Token Der kleinste Baustein, in den ein Sprachmodell Text zerlegt: ein Wort, ein Wortteil oder ein Satzzeichen. Nach Tokens werden Kontextfenster und Preise bemessen; ein Wort sind oft ein bis zwei Tokens (Kapitel 2.6.1).

Embedding Die Umwandlung eines Tokens in eine lange Zahlenreihe (einen Vektor), die seine Bedeutung mathematisch beschreibt. Ähnliche Wörter wie „Hund“ und „Katze“ erhalten ähnliche Zahlenreihen, so dass das Modell mit Bedeutung rechnen kann (Kapitel 2.6.1).

Transformer und Attention Transformer ist die Rechenarchitektur heutiger Sprachmodelle. Ihr Kernverfahren Attention („Aufmerksamkeit“) lässt jedes Token gewichtet entscheiden, auf welche anderen Tokens im Text es achten soll; so erkennt das Modell, ob „Bank“ ein Möbelstück oder ein Geldinstitut meint (Kapitel 2.6.1).

Herkunft: lat. *transformare*, „umformen“; *attendere*, „den Geist auf etwas hinwenden“.

Pretraining und RLHF Pretraining ist das Vortrainieren des Modells an großen Textmengen ohne konkrete Aufgabe. Danach bewerten Menschen Antwortvarianten, und das Modell lernt, bevorzugt nützliche und verständliche Antworten zu geben: Reinforcement Learning from Human Feedback, bestärkendes Lernen mit menschlicher Rückmeldung (Kapitel 2.6.1).

Kontextfenster (*context window*) Die Menge an Text, die ein Sprachmodell gleichzeitig „im Blick“ hat: die bisherige Unterhaltung, hochgeladene Dokumente und die aktuelle Frage. Was nicht ins Fenster passt, kennt das Modell in diesem Moment nicht (Kapitel 2.6.1).

Herkunft: lat. *contexere*, „zusammenweben“; der Kontext ist das Gewebe, in dem ein Wort steht.

Halluzination (*hallucination*) Eine sprachlich überzeugende, aber sachlich falsche oder erfundene Antwort, etwa eine Quelle, die es nicht gibt. Keine Störung, sondern eine Folge der Funktionsweise: Das Modell erzeugt Plausibles, nicht Geprüftes. Gegenmittel sind eingegrenztes Material, Musterlösungen und systematische Prüfung (Kapitel 5.3; Kapitel 6.3).

Herkunft: lat. (*h*)*al*(*l*)*ucinari*, „gedankenlos reden, träumen“.

Reasoning-Modell Ein Sprachmodell, das vor der Antwort schrittweise „nachdenkt“, also Zwischenschritte erzeugt und die eigenen Ergebnisse prüft, bevor es antwortet. Technisch wird mehr Rechenzeit in die Antwort statt ins Training gesteckt (*test-time compute*). Für anspruchsvolle Aufgaben sind solche Modelle deutlich zuverlässiger als ihre schnellen Varianten (Kapitel 5.2.1; Kapitel 2.2).

Herkunft: engl. *reason* über altfrz. *raison* zu lat. *ratio*, „Berechnung, Vernunft“.

Frontier-Modell Eines der wenigen Sprachmodelle, die zu einem Zeitpunkt den Stand der Technik bilden und in den Ranglisten deutlich vor allen anderen liegen. Frontier ist ein Rang, keine Bauart: Nicht jedes große Labor hat ein Frontier-Modell, kleine Varianten sind nie eines, und wer dazugehört, wechselt mit jeder Modellgeneration. Wie groß der Abstand ausfällt, hängt am gewählten Leistungstest (Kapitel 2.2) (Frontier Model Forum, 2026).

Herkunft: engl. *frontier* über altfrz. *frontiere* zu lat. *frons*, „Stirn“: die vorderste Linie, an der man einander die Stirn bietet.

Jagged Frontier „Zerklüftete Technikgrenze“: Sprachmodelle lösen manche Aufgaben auf Expertenniveau und scheitern an anderen, die für Menschen ähnlich schwer sind. Die Grenze verläuft unregelmäßig und ist nur durch Ausprobieren zu finden; wer sie nicht kennt, arbeitet mit KI schlechter als ohne (Kapitel 5.2.1).

Herkunft: engl. *jagged*, „gezackt“; zu *frontier* s. Frontier-Modell.

Centaur und Cyborg Zwei Arbeitsweisen mit KI entlang der Jagged Frontier. Der Centaur teilt die Arbeit sauber auf: Dieses übernimmt der Mensch, jenes die Maschine. Der Cyborg verwebt beide in jedem Arbeitsschritt, etwa beim Schreiben Satz für Satz (Kapitel 3.2; Kapitel 6.2.1).

Herkunft: griech. *kentauros*, Mischwesen aus Mensch und Pferd; *Cyborg* aus *cybernetic organism*, zu griech. *kybernetes*, „Steuermann“.

Prompt Die Eingabe an ein Sprachmodell: Frage, Anweisung oder Aufgabe, oft mit Material und Beispielen. Wie der Prompt formuliert ist, bestimmt die Qualität der Antwort wesentlich (Kapitel 2.3.1).

Herkunft: lat. *promptus*, „bereit, zur Hand“, zu *promere*, „hervorholen“; engl. *to prompt*, „soufflieren, anstoßen“.

Prompt Engineering Das Handwerk, Prompts so zu bauen, dass sie zuverlässig gute Antworten liefern. Bei Reasoning-Modellen heißt das vor allem: Ziel, Grund, Material und Abnahmekriterium nennen und den Lösungsweg dem Modell überlassen. Was nichts bringt: Drohen, Bestechen, besondere Höflichkeit, Expertenrollen (Kapitel 2.3).

Herkunft: Engineering über altfrz. *engigneor* zu lat. *ingenium*, „Begabung, Erfindungsgeist“.

System-Prompt Eine Dauer-Anweisung, die vor jeder Unterhaltung im Hintergrund wirkt und das Verhalten eines Bots festlegt: Rolle, Regeln, erlaubte und verbotene Reaktionen. Didaktische Tutoren und Simulationen werden im Wesentlichen über den System-Prompt gebaut (Kapitel A.1.3).

Herkunft: griech. *systema*, „das Zusammengestellte“.

Few-Shot-Beispiele Dem Modell werden im Prompt einige Beispiele gezeigt, wie die gewünschte Antwort aussehen soll. Einige gute Beispiele helfen, wo Stil oder Format zählen; zu viele engen das Modell ein (Kapitel 2.3.2).

Chain of Thought „Gedankenkette“: Das Modell wird aufgefordert, Schritt für Schritt vorzugehen und seinen Lösungsweg auszuformulieren. Bei älteren Modellen eine wichtige Technik; Reasoning-Modelle gehen von sich aus schrittweise vor, und die Aufforderung kostet dort vor allem Zeit (Kapitel 2.3.4).

Herkunft: engl. *chain* über altfrz. *chaeine* zu lat. *catena*, „Kette“.

Temperatur (*temperature*) Ein Regler, der steuert, wie stark das Modell von der wahrscheinlichsten Fortsetzung abweicht. Niedrige Temperatur ergibt vorhersagbare, wiederholbare Antworten, hohe Temperatur abwechslungsreichere, aber auch riskantere (Kapitel 2.1, Lernspiel).

Herkunft: lat. *temperare*, „mäßigen, richtig mischen“.

RAG (Retrieval-Augmented Generation) Das Modell bekommt eigenes Material an die Hand, etwa Skripte, Fachartikel oder Musterlösungen, und holt sich daraus vor der Antwort die passenden Stellen. Bildlich: Die KI ist das Gehirn, das Material ist das Bücherregal. In der Lehre der wichtigste Hebel gegen Halluzinationen (Kapitel 2.4.1).

Herkunft: augmented zu lat. *augere*, „vermehren“, aus dem auch *auctor*, der Urheber, stammt.

Agent Eine Betriebsweise aus Modell und Harness, in der das Modell seinen Ablauf selbst steuert: Es nutzt Werkzeuge wie Internetsuche, Dateizugriff oder Programmausführung, plant mehrere Schritte und prüft

Zwischenergebnisse selbst. Anders als in einem Workflow folgt der Ablauf keinem vorgegebenen Pfad. Bildlich: der Werkzeugkoffer neben dem Bücherregal (Kapitel 2.1.2; Kapitel 2.4.1).

Herkunft: lat. *agere*, „handeln, treiben“.

Harness Wörtlich „Arbeitsgeschirr“: die Ausstattung, mit der ein Modell als Agent handeln kann, also Werkzeuge, Datenzugriffe und Ablaufregeln. Ohne Harness bleibt „Agent“ ein Etikett (Kapitel 2.1.2).

Deep Research Ein Recherche-Werkzeug: Das Modell sucht in mehreren Durchgängen, bewertet Treffer, liest Quellen und schreibt einen Bericht mit Belegen. Nach Aaron Tay eine von vier Klassen von Suchhelfern, unterschieden nach „einmalig oder iterativ“ und „Liste oder Analyse“ (Kapitel 5.2.1; Kapitel 6.1.1).

Herkunft: research über frz. *rechercher* zu lat. *circare*, „umkreisen“.

Programmier-Agent (*coding agent*) Ein Agent für Programmierarbeit: Er bekommt einen Auftrag in Alltagssprache, liest die vorhandenen Dateien, ändert mehrere davon, startet Tests und meldet das Ergebnis. Ein Copilot ergänzt die Zeile, die man gerade schreibt; der Programmier-Agent arbeitet in der Schleife aus Denken, Handeln und Beobachten, und der Mensch beschreibt, prüft und entscheidet. Beispiele sind Claude Code und Codex (Kapitel 6.2.2).

Herkunft: Programm über lat. *programma* zu griech. *prógramma*, „öffentliche schriftliche Bekanntmachung“, von *prographein*, „vorher schreiben“.

Skill Ein vorgefertigtes Anweisungspaket, das ein Agent für eine bestimmte Aufgabe bei Bedarf lädt, etwa eine mehrseitige Anleitung, wie er eine Präsentation oder eine Hausarbeit Schritt für Schritt erstellt und prüft. Modulares Wissen zum Hinzubuchen (Kapitel 5.2; Kapitel 2.4.2).

Konnektor (*connector*; MCP) Eine standardisierte Schnittstelle, über die ein Sprachmodell direkt auf externe Dienste zugreift, etwa auf Fachdatenbanken wie Scopus oder Verlagsvolltexte. Technischer Name: Model Context Protocol. Macht Recherchen nachvollziehbarer, weil die Kette von Anfrage bis Fundstelle dokumentiert ist (Kapitel 2.1.2; Kapitel 6.1.1).

Herkunft: lat. *connectere*, „verknüpfen“.

Artifact Ein vom Sprachmodell erzeugtes, eigenständig nutzbares Produkt, etwa ein kleines Lernspiel als Webseite, eine Grafik oder ein Dokument, das neben dem Chat angezeigt und weitergegeben werden kann. So entstanden etwa die Lernspiele in Kapitel 2 und 6 (Kapitel 2.1; Kapitel 6.2.2).

Herkunft: lat. *arte factum*, „mit Kunst gemacht".

Custom GPT, Projekt Ein selbst konfigurierter Bot auf Basis eines Sprachmodells mit festem System-Prompt und hinterlegtem Material, der sich mit Studierenden teilen lässt. Bei OpenAI „Custom GPT", bei Anthropic „Projekt". Eine einfache Form, einen Tutor oder eine Simulation in die Lehre zu bringen. OpenAI schaltet Custom GPTs am 11. Dezember 2026 ab; was bleibt, ist die Anweisung, die in jedem Chatwerkzeug funktioniert (Kapitel 6.2.1).

Herkunft: Projekt zu lat. *proicere*, „nach vorn werfen".

Skalierungsgesetze (*scaling laws*) Zwei Erfahrungsregeln, die erklären, warum die Modelle so schnell besser werden. Erstens sinkt der Vorhersagefehler verlässlich, je mehr Daten, Rechenleistung und Parameter ins Training fließen, sofern Daten und Modellgröße im Gleichschritt wachsen. Zweitens liefert ein fertig trainiertes Modell bessere Lösungen, wenn es vor der Antwort mehr Denkzeit (*test-time compute*) bekommt; darauf beruhen die Reasoning-Modelle (Kapitel 5.2.1).

Herkunft: scale zu lat. *scala*, „Treppe, Leiter": Stufe um Stufe besser.

Erwünschte Schwierigkeiten (*desirable difficulties*) Lernhürden, die das Lernen anstrengender, aber nachhaltiger machen: selbst abrufen statt nachlesen, selbst formulieren statt übernehmen. Ein Chatbot, der sofort die fertige Lösung liefert, räumt genau diese Hürden weg (Kapitel 1.3; Kapitel 4.1).

Testgestütztes Lernen (*test-enhanced learning*) Das aktive Abrufen von Wissen durch Fragen und Tests festigt Gelerntes deutlich stärker als wiederholtes Lesen. Häufige, niedrigschwellige Abrufübungen gehören zu den am besten belegten Lerntechniken; Sprachmodelle senken den Aufwand, sie zu erstellen (Kapitel 4.4).

Herkunft: Test über altfrz. *test* zu lat. *testum*, „Tontopf", dem Tiegel, in dem man Edelmetall auf seine Reinheit prüfte.

Spacing und Interleaving Zwei Lerntechniken: Übung über die Zeit verteilen statt in einem Block (*spacing*) und Themen gemischt statt nacheinander üben (*interleaving*). Beides verbessert das Behalten und die Fähigkeit, das passende Werkzeug für ein Problem zu wählen (Kapitel 4.4).

Herkunft: spacing zu lat. *spatium*, „Raum, Zwischenraum“.

Fragebasierte Ausarbeitung (*explanatory questioning*) Lerntechnik, bei der Lernende Warum- und Wie-Fragen zum Stoff stellen und beantworten und so neue Inhalte mit vorhandenem Wissen verknüpfen. Tutor-Bots und Simulationen können solche Fragen stellen (Kapitel 4.4).

Herkunft: explanatory zu lat. *explanare*, „ausbreiten, deutlich machen“, von *planus*, „eben, flach“: Erklären heißt, etwas glatt auszubreiten.

ICAP Rangfolge kognitiven Engagements nach Chi und Wylie: interaktiv wirkt besser als konstruktiv, konstruktiv besser als aktiv, aktiv besser als passiv (I > C > A > P). Maßstab dafür, wie wirksam eine KI-gestützte Lernaktivität sein kann (Kapitel 4.4).

Kognitive Belastung (*cognitive load*) Die begrenzte Verarbeitungskapazität des Arbeitsgedächtnisses. Lernhilfen sollen diese Kapazität für das Wesentliche freihalten; ein Chatbot, der mit Informationen überschüttet, tut das Gegenteil. Didaktische Prompts begrenzen deshalb die Antwortmenge, etwa auf eine Frage pro Zug (Kapitel 4.1).

Herkunft: lat. *cognitio*, „Erkenntnis“.

Scaffolding „Baugerüst“: Lernende bekommen genau so viel Unterstützung, wie sie für den nächsten Schritt brauchen, und das Gerüst wird mit wachsender Kompetenz abgebaut. Grundmuster sokratischer Tutor-Prompts (Anhang A).

Protégé-Effekt (*protégé effect*) Wer einem anderen etwas erklären muss, lernt selbst am meisten. In Übungen wie „Teach the AI“ spielt das Modell die unwissende Schülerin, die Studierenden lehren (Kapitel 6.4.2; Kapitel A.6.2).

Herkunft: frz. *protégé*, „Schützling“, zu lat. *protegere*, „beschützen“.

Vier Rollen: Hiwi, Copilot, Tutor, Simulator Ordnungsrahmen des Buchs nach Mollick und Mollick: Als Hiwi nimmt die KI Lehrenden Arbeit ab, als Copilot arbeitet sie mit, als Tutor begleitet sie Lernende, als Simulator stellt sie Übungssituationen bereit (Kapitel 6).

Herkunft: Tutor lat. „Beschützer, Vormund“, zu *tueri*, „schützen“; *Pilot* über ital. *pilota* zu griech. *pēdon*, „Ruderblatt“; *Simulator* zu lat. *simulare*, „nachahmen“.

Role Play und Goal Play Zwei Formen der Simulation. Im Role Play übernehmen Studierende eine fremde Rolle, etwa in einer Verhandlung, und die KI spielt das Gegenüber. Im Goal Play bleiben sie in ihrer eigenen Rolle und wenden Wissen an, das der KI-Figur fehlt (Kapitel 6.4.1; Kapitel 6.4.2).

Herkunft: Rolle über frz. *rôle* zu lat. *rotulus*, „Röllchen“: die Schriftrolle mit dem Text des Schauspielers.

Debriefing und Human in the Loop Die Nachbesprechung einer Simulation durch Lehrende, in der Verlauf, Fehler der KI und Lernertrag reflektiert werden. Steht für den Grundsatz, dass der Mensch in der Schleife bleibt und die Verantwortung behält (Kapitel 6.4).

Herkunft: brief über altfrz. *bref* zu lat. *brevis*, „kurz“.

Vier-Säulen-Ansatz Prüfungsdesign unter KI-Bedingungen nach Gmeiner: Mündlichkeit, Prozessorientierung, Kontextualisierung und Kollaboration. Jede Säule macht generische KI-Texte als Prüfungsleistung wertlos, ohne die KI-Nutzung zu verbieten (Kapitel 5.5).

Herkunft: Kollaboration zu lat. *collaborare*, „mitarbeiten“.

Homework Apocalypse Mollicks Schlagwort für die Entwertung klassischer Hausaufgaben und Hausarbeiten, wenn Studierende sie auf Knopfdruck erzeugen können. Gemeint ist weniger das Täuschen als die empfundene Sinnlosigkeit der Aufgabe (Kapitel 1.4; Kapitel 5.5).

Herkunft: griech. *apokalypsis*, „Enthüllung“; gemeint war ursprünglich nicht der Untergang, sondern das Sichtbarwerden.

Literaturverzeichnis

Frontier Model Forum (2026). About us. *Frontier Model Forum*. https://www.frontiermodelforum.org/about-us.

Transparenzhinweis zum Gesamtwerk

Bei der Erstellung dieses Buchs wurde generative KI eingesetzt. Das Thema des Buchs verlangt, dass ich das genau benenne.

Das Sprachmodell Claude (Anthropic) wurde in der Arbeitsumgebung Cowork für folgende Aufgaben genutzt: die Strukturanalyse des Online-Skripts vor der Überarbeitung, die Prüfung von Literaturangaben gegen die Originalquellen, Entwürfe für einzelne Einschübe wie Kästen, Lernziele und Kernaussagen, Sprach- und Konsistenzchecks über alle Kapitel sowie die technische Umsetzung des Layouts für Druck und Online-Version. Abbildungen, die mit dem Bildmodell Gemini (Google) erzeugt wurden, sind in der jeweiligen Bildunterschrift als KI-generiert gekennzeichnet. Die interaktiven Lernspiele und Prozessanimationen der Online-Version wurden mit Unterstützung von Sprachmodellen programmiert; wie das geht, beschreibt Kapitel 2. Bei den beiden Simulationen zu Little's Law und zum Bullwhip-Effekt in Kapitel 6 hat Claude auch das Rechenmodell und seine Tests geschrieben. Die Tests prüfen das Modell gegen Handrechnungen und gegen die Formeln von Little (1961) und Chen et al. (2000); die Druckabbildungen erzeugt ein Skript aus denselben Modelldateien. Modell, Tests und Skript liegen im Repositorium des Online-Skripts.

Verantwortung und Prüfung liegen beim Autor. Jeder Entwurf, den ein Sprachmodell geliefert hat, wurde gelesen, gegen die Quellen geprüft, überarbeitet oder verworfen. Die Argumentation, die Auswahl der Studien und die Empfehlungen sind meine eigenen. Wo ein Sprachmodell eine Quelle vorgeschlagen hat, habe ich die Quelle selbst gelesen, bevor sie ins Literaturverzeichnis kam. Damit folge ich der Stellungnahme des Präsidiums der Deutschen Forschungsgemeinschaft zum Einfluss generativer Modelle auf die Wissenschaften vom September 2023: Der Einsatz solcher Werkzeuge ist zulässig, muss offengelegt werden, entbindet nicht von der Verantwortung für den Inhalt, und ein Sprachmodell kann nicht Autor sein.

[Optional: Hinweis, ob die Arbeitsnotizen zur Überarbeitung im öffentlichen Repositorium https://github.com/TH-Koln-Bartnik/genai4teaching einsehbar sind.]

Literaturverzeichnis

Chen, F., Drezner, Z., Ryan, J. K., & Simchi-Levi, D. (2000). Quantifying the bullwhip effect in a simple supply chain: The impact of forecasting, lead times, and information. *Management Science*, *46*(3), 436–443. https://doi.org/10.1287/mnsc.46.3.436.12069.

Little, J. D. C. (1961). A proof for the queuing formula: L = λW. *Operations Research*, *9*(3), 383–387. https://doi.org/10.1287/opre.9.3.383.