Generative KI als Hilfe zum Lehren und Lernen

Roman Bartnik

November 2026

Roman Bartnik
Generative KI als Hilfe zum Lehren und Lernen

Technische Hochschule Köln
Fakultät für Informatik und Ingenieurwissenschaften, Campus Gummersbach

Bibliografische Information der Deutschen Nationalbibliothek: Die Deutsche Nationalbibliothek verzeichnet diese Publikation in der Deutschen Nationalbibliografie; detaillierte bibliografische Daten sind im Internet über https://dnb.de abrufbar.

Dieses Werk ist lizenziert unter einer Creative-Commons-Lizenz Namensnennung – Weitergabe unter gleichen Bedingungen 4.0 International (CC BY-SA 4.0): https://creativecommons.org/licenses/by-sa/4.0/deed.de. Ausgenommen sind Abbildungen und Zitate, die mit einem abweichenden Rechtehinweis gekennzeichnet sind.

Gefördert aus dem Open-Access-Publikationsfonds der TH Köln.
[Logo des Publikationsfonds]

Logos Verlag Berlin GmbH
[Anschrift des Verlags]
https://www.logos-verlag.de

Erste Auflage, [Monat] 2026
ISBN [978-3-xxxxx-xxx-x]
DOI [10.30819/xxxx]

Online-Version mit interaktiven Elementen und laufend aktualisierten Seiten:
https://th-koln-bartnik.github.io/genai4teaching/

Satz: Roman Bartnik mit Quarto und XeLaTeX
Umschlag: [Gestaltung, verwendete Abbildung und Bildnachweis]
Druck: [Druckerei]

Zitiervorschlag: Bartnik, R. (2026). *Generative KI als Hilfe zum Lehren und Lernen*. Logos Verlag Berlin. [DOI]

Inhalt

Abbildungsverzeichnis **vii**

Tabellenverzeichnis **xix**

Übersicht **1**

Vorwort **3**
Wählen Sie Ihren Lernpfad 5

1 Einleitung **9**
1.1 Wie verbreitet ist KI-Nutzung? 11
1.2 Was geht schief? 13
1.3 Was hilft? 15
1.4 Was Sie im Buch erwartet 16

2 Grundbegriffe **21**
2.1 Definition einiger Grundbegriffe 23
2.2 Wie denken Sprachmodelle und warum halluzinieren sie? . 46
2.3 Welches Modell wählen? 49
2.4 Was können die Modelle – und was nicht? 56
2.5 Wo und wie spreche ich mit der KI? 64
2.6 Schemas für den systematischen Umgang mit GenAI 69
2.7 Exkurs: Wie steht es mit dem Ressourcenverbrauch der Modelle? 75

3 Didaktische Ziele und Mechanismen **79**
3.1 Was für Ziele verfolgen wir mit dem Einsatz von GenAI in der Lehre? 81
3.2 Wissenstypen 83
3.3 Anwendungsbeispiele nach Wissenskategorien 85
3.4 Effektive Lerntechniken und Unterstützung mit KI 87
3.5 Was die Forschung seit 2025 zeigt: Lernwirkung und kognitive Auslagerung 93

4 Vier Szenarien der Nutzung von GenAI: Hiwi, Copilot, Tutor, Simulator 105
4.1 KI als Hiwi 107
4.2 KI als Copilot 117
4.3 KI als Tutor 138
4.4 KI als Simulator 146

5 Empfehlungen zur Umsetzung 153
5.1 Typische Aufgaben und Fragestellungen mit der KI durchspielen, Prompts anpassen, experimentieren 154
5.2 Ausrichtung der Anpassungen nach Empfehlungen der Lernforschung 155
5.3 Einführung der Studierenden planen: Besser praktisch, häufig und niedrigschwellig 156
5.4 Wie prüfen wir jetzt? Jenseits der Homework Apocalypse . . 157
5.5 Richtlinien zur KI-Nutzung - welche Handreichungen geben Hochschulen und was wird empfohlen? 166
5.6 Wie können Studierende die Nutzung von LLM dokumentieren? Stichworte, nach Arbeitsphase, nach Werkzeug oder als Reflexionstagebuch 170
5.7 Kurs-Integration: Drei Phasen eines Semesters 174
5.8 Wie bleiben Sie informiert? 177

6 Fallbeispiele aus der Lehre 179
6.1 Wissen übertragen: Begriffe, Formeln, Reihenfolgen 182
6.2 Wissen übersetzen: Bedeutungen erschließen 188
6.3 Wissen umformen: anwenden gegen Interessen und Folgen . 193
6.4 Was die Beispiele gemeinsam zeigen 205

Anhang 207

A Gezielte Einschränkungen in didaktischen Prompts 207

B Best-Practice-Sammlung didaktischer Prompts und GenAI Aufgabenstellungen 211
Vorbemerkung zur Struktur der Sammlung 211
B.1 Hiwi: Schnelle Hilfe zur Lehrgestaltung 211
B.2 Tutor: Beratender Beistand 221
B.3 Aufgabenstellungen Tutorat 224
B.4 Copilot: Gemeinsam zu neuen Horizonten 227
B.5 Aufgabenstellungen Copilot 233

B.6 Simulator: Didaktisches Erleben 236
B.7 Weitere Prompts und Aufgabenstellungen der Online-Sammlung 242

C Umsetzung: Rollenspiele und Simulationen mit generativer KI in der Lehre 245
Vorbemerkung 245
C.1 Was bringen Rollenspiele und Simulationen? Didaktische Mechanismen und Lernziele 245
C.2 Datengrundlage und Methodik 248
C.3 Welchen Mehrwert bringt generative KI? 248
C.4 Was geht nicht? Herausforderungen und Grenzen von GenAI 257
C.5 Wie umsetzen? Empfehlungen für KI-gestützte Rollenspiele 258
C.6 Update: Neuere Studien (Stand Juli 2026) 262
C.7 Liste der durchsuchten Fachzeitschriften 262
C.8 Im Jahr 2025 publizierte Fachartikel zu GenAI-Rollenspielen und Simulationen in der Lehre 262
Transparenzhinweis 263

D Umsetzung: Arbeitsumgebung, Agenten, Tutoren und lokale Modelle 265
Vorbemerkung 265
D.1 Warum Nutzungsmodus und Kontrollpunkte entscheiden . 266
D.2 Arbeitsumgebung einrichten: Wie bringe ich der KI dauerhaft bei, was sie über meinen Kurs wissen soll? 269
D.3 Eigene Quellen anbinden: Wie antwortet die KI aus meinen Texten statt aus dem Netz? 276
D.4 Agenten und akademische Suche: Wo müssen Menschen eingreifen, damit eine Agentenkette nicht entgleist? 280
D.5 Prozesse sichtbar machen: Wie wird aus einer Prozessbeschreibung ein prüfbares Modell? 284
D.6 Workflows automatisieren: Welche wiederkehrende Lehrarbeit lohnt die Automatisierung, und wie bleibt sie kontrollierbar? 289
D.7 KI-Tutoren bauen und prüfen: Wie verhindere ich, dass der Tutor zu viel hilft? 294
D.8 Lokale Modelle: Wann lohnt der Betrieb ohne Cloud, und was leistet ein kleines Modell? 305
D.9 Ausblick: Fortgeschrittene Anwendungen 308
Online-Material 310
Transparenzhinweis 311

E Praxis-Primer für Lehrende **313**
E.1 Primer 0: Welches Format für welches Lehrziel? 313
E.2 Primer A: Didaktische Animationen 314
E.3 Primer B: Präsentationen 318
E.4 Primer C: Lernsongs 322
E.5 Primer D: Lernspiele 326

F Lösungshinweise zu den Lernfragen **333**
Kapitel 1: Einleitung 333
Kapitel 2: Grundbegriffe 334
Kapitel 3: Didaktische Ziele und Mechanismen 336
Kapitel 4: Vier Szenarien der Nutzung von GenAI 337
Kapitel 5: Empfehlungen zur Umsetzung 338
Kapitel 6: Fallbeispiele aus der Lehre 338

Glossar **343**

Transparenzhinweis zum Gesamtwerk **351**

Literaturverzeichnis **353**

Abbildungsverzeichnis

1 Lernpfade durch das Buch. Rot umrandet sind die Stationen, an denen alle Linien halten. Eigene Darstellung. 6

1.1 Schwerpunkte der Nutzung von LLMs (Claude) durch Studierende nach der Bloom'schen Taxonomie (Handa et al., 2025). 12

1.2 Galerie „Fünf Formate, die 2026 mit KI entstehen": Engpass-Animation (Kapitel 4.2.2.3), Präsentationsfolie mit Regelwerk (Kapitel E.3), Lernsong zu Prognoseverfahren (Kapitel 6.1.2), Zuordnungsspiel (Kapitel 6.1.3) und KI-Rollenspiel (Kapitel 4.4.1). Dieses interaktive Element gibt es nur in der Online-Version: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/galerie-kapitel01.html aufrufen. 17

2.1 Lernspiel „Welche Grundbegriffe kennen Sie schon?" (Zuordnung von Begriffen und Definitionen). Dieses interaktive Element gibt es nur in der Online-Version: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/llm-game-standalone.html aufrufen. . 23

2.2 Gewachsen ist vor allem die Schicht um das Modell. Werkzeuge und Gedächtnis kommen hinzu, daraus folgt eine Arbeitsschleife, über deren Schritte das Modell selbst entscheidet; alle drei sitzen im Harness, dessen Freigaben und Haltepunkte den Handlungsspielraum des Modells regeln. Den inneren Harness liefert der Hersteller, den äußeren bauen die Nutzenden (schematische Darstellung). Die Fassung zum Durchklicken: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/harness-schichten.html aufrufen. 24

2.3 Wie selbstständig eine KI arbeitet, entscheiden die Menschen, die sie einsetzen. Sechs Stufen der Zusammenarbeit von der Handkorrektur ohne KI bis zum Agenten, der eine Aufgabe allein erledigt; die Fähigkeit des Modells ermöglicht höhere Stufen, gewählt werden sie im Einsatz (eigene Darstellung nach Morris et al. (2024), Tabelle 2; Beispiele aus der Hochschullehre ergänzt). Die Fassung zum Durchklicken: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/autonomiestufen.html aufrufen. . 27

2.4 Drei Labore, ein Bauplan. Eine Schleife ruft das Modell immer wieder auf und lässt seine Werkzeugaufrufe ausführen, bis eine Runde endet und wieder der Mensch entscheidet; Google nennt sie Orchestrierungsschicht, OpenAI Harness, Anthropic trennt das „Gehirn“ aus Modell und Harness von den „Händen“ und protokolliert jeden Schritt in einer Session. Jeder Harness enthält Annahmen darüber, was das Modell nicht kann (eigene Darstellung nach Wiesinger et al. (2024), Bolin (2026) und Martin et al. (2026); schematisch). Die Fassung zum Durchklicken: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/drei-labs-ein-bauplan.html aufrufen. 28

2.5 Ein Sprachmodell rechnet mit Zahlen, nicht mit Wörtern. Der Satz wird in Tokens zerlegt, jedes Token erhält eine feste Nummer (echte Werte, Tokenizer o200k_base). Über die Aufmerksamkeit rückt „Bank“ durch „Baum“ in die Nachbarschaft von „Park“; aus einer Wahrscheinlichkeitsverteilung wird das nächste Token gezogen und angehängt (eigene Darstellung; Bedeutungskarte und Werte schematisch). Die Fassung zum Durchklicken: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/vom-satz-zum-naechsten-wort.html aufrufen. 31

2.6 Vor der Antwort entsteht im Modell ein Zwischenschritt, der nie im Text steht. Aus „Dallas“ wird intern „Texas“, zusammen mit der Absicht, eine Hauptstadt zu nennen, ergibt das „Austin“; ersetzen Forschende den inneren Schritt „Texas“ durch „California“, antwortet das Modell „Sacramento“ (eigene Darstellung nach Lindsey et al. (2025) und Anthropic (2025c); Befund für Claude 3.5 Haiku, stark vereinfacht). Die Fassung zum Durchklicken: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/zwischenschritt-texas.html aufrufen. 32
2.7 Lernspiel „LLM, RAG oder Agent?“ (Probleme und Anwendungsfelder der drei Setups). Dieses interaktive Element gibt es nur in der Online-Version: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/llm-rag-agent-game.html aufrufen. 33
2.8 Vom Chatbot zum Agenten wächst vor allem der Spielraum des Modells. Im Chatbot ändert die Antwort nichts am Ablauf (□□□), und ein fester Abruf aus eigenen Quellen ändert daran nichts; als Router wählt das Modell zwischen vorgegebenen Abzweigen (□□□), mit Werkzeugen wählt es das Werkzeug (□□□), in der Schleife aus Denken, Handeln und Beobachten den nächsten Schritt (□□□). Der Harness umschließt alles, der Mensch setzt das Ziel und prüft das Ergebnis (Skala nach Roucher et al. (2024), Bildfolge nach Grootendorst (2025b); schematische Darstellung). Die Fassung zum Durchklicken: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/chatbot-zu-agent.html aufrufen. . 35
2.9 Einmal aufschreiben, oft verwenden. Oben wird der Zusammenhang jede Woche neu eingegeben, unten steht er auf einer Skill-Karte. Die Karte kostet in Woche 1 vier Minuten mehr, liegt ab Woche 2 vorn und verhindert, dass eine vergessene Regel die alte Panne zurückbringt (Lehrmodell, keine Messung). Die interaktive Fassung mit Vorhersage und einer fehlerhaften Karte: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/skill-karte.html aufrufen. 37

2.10 Ein Skill lädt sein Wissen erst, wenn es gebraucht wird. Im Kontextfenster liegen zunächst nur Name und Kurzbeschreibung jedes Skills; passt eine Anfrage, folgt die Anleitung dieses einen Skills, Zusatzdateien nur bei Bedarf, wie Inhaltsverzeichnis, Kapitel und Anhang eines Handbuchs (eigene Darstellung nach B. Zhang et al. (2025); schematisch). Die Fassung zum Durchklicken: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/skills-handbuch.html aufrufen. 38

2.11 Mehr Agenten machen den Menschen zum Engpass. Der Mensch gibt Aufgaben ab, Agenten recherchieren, fassen zusammen, rechnen und prüfen, und zweimal kommt jede Aufgabe zum Entscheiden zurück. Das Standbild zeigt Minute 22 von acht gleichzeitig abgegebenen Aufgaben: Kugel A liegt in der Ablage „Zu entscheiden“, während die Agenten kaum zu tun haben. Der Laufzettel darunter: Allein ist Kugel A nach 24 Minuten fertig, als achte von acht nach 43,5 Minuten, davon 19,5 Minuten Warten auf den Menschen (Lehrmodell, keine Messung). Die interaktive Fassung mit Vorhersage und dem Schalter „Der Mensch entscheidet doppelt so schnell“: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/agenten-engpass.html aufrufen. 40

2.12 Vom Spickzettel zum prüfbaren Archiv. Die vier Stufen unterscheiden sich darin, was wann ins Kontextfenster gelangt: bei der Anleitungsdatei alles von Anfang an, bei Memory-Werkzeugen nach Ermessen des Agenten, bei Skills erst der Überblick und dann die Details, beim Dateisystem nur das gezielt Gesuchte (schematische Darstellung). Die animierte Fassung: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/agenten-gedaechtnis.html aufrufen. 42

2.13 Die Sitzung schreibt alles mit, das Gedächtnis behält nur das Verdichtete. Ein Statistik-Tutor baut den Kontext für das zustandslose Modell aus der laufenden Sitzung; nach jeder Sitzung wandern Kernpunkte ins Gedächtnis, werden mit späteren Sitzungen zusammengeführt, und am vierten Abend holt der Tutor nur das Passende zurück (eigene Darstellung nach Milam & Gulli (2025); schematisch). Die Fassung zum Durchklicken: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/sitzung-und-gedaechtnis.html aufrufen. 43
2.14 Visualisierte Gedanken eines Sprachmodells [@lindsey2025] 46
2.15 Vier Modellklassen nach Leistung und Kontrolle über die Daten. Wie groß der Rückstand der offenen Modelle ausfällt, hängt am gewählten Leistungstest; die Werte stammen aus Edwards & Emberson (2026) und Somala & Emberson (2025). Hochschulzugänge wie KI:connect.nrw bieten beide Zeilen. Eigene Darstellung. 49
2.16 Was ein Abo kauft: Ab rund 20 € im Monat arbeitet das große Modell mit hoher Denkstufe; die 100-€-Stufe bringt dasselbe Modell mit etwa fünfmal so viel Kontingent. Eigene Darstellung nach den Preisseiten von OpenAI, Anthropic und Google, Stand Oktober 2026, und E. Mollick (2026b). . . 50
2.17 Welches Modell für welche Aufgabe? Drei Fragen führen zu Modellklasse und Preisstufe: Daten, Aufgabe, Häufigkeit; die Prüfregel gilt für jede Zeile. Stufen wie in Abbildung 2.16. Eigene Darstellung nach E. Mollick (2026b). Die Fassung zum Durchklicken: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/modellwahl-baum.html aufrufen. 52
2.18 Lebende Modellübersicht, semesterweise aktualisiert: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/modelluebersicht.html aufrufen. 55

2.19 KI-Agenten bewältigen immer längere Aufgaben: 50-%-Zeithorizont der Modelle 2019–2026 auf logarithmischer Achse, mit 95-%-Intervallen und Trend ab 2023 (gestrichelt). Links stehen Lehraufgaben ähnlicher Dauer zur Orientierung (eigene Zuordnung). Über 16 Stunden ist die Messung nicht mehr verlässlich. Daten: METR (2026), Stand 8. Mai 2026. Interaktive Fassung: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/ki-entwicklung.html?zeige=zeithorizont aufrufen. . . . 58

2.20 Expertenwissen wird 725-mal billiger: niedrigste Kosten je Frage (API-Preise, logarithmische Achse), mit denen ein Modell 75 % des GPQA Diamond richtig beantwortet, Januar 2025 bis Juli 2026. An jeder Stufe steht, um wie viel die Kosten gegenüber dem bis dahin günstigsten Modell fielen; die größten Sprünge lagen im Juni 2025 (−85 %) und im März 2025 (−70 %). Unten dieselben Stufen als Raster: Ein Kästchen ist eine Frage zum o3-Preis vom Januar 2025, gefüllt ist, was 30 Cent zum jeweiligen Zeitpunkt kaufen. Jede Preisstufe hat eine eigene Farbe, so dass die Fläche zeigt, wie viel ein Schritt ausmachte. Der letzte Sprung (−66 %) bringt mit 479 Kästchen mehr als alle früheren zusammen, obwohl der Preis prozentual weniger fiel als im Juni 2025; so sieht gleichmäßiger exponentieller Preisverfall auf linearer Skala aus. Insgesamt fiel der Preis in 17 Monaten um 99,9 %. Rasterdarstellung nach einer Idee von E. R. Mollick (2026b). Daten: Emberson & Roodman (2026), Epoch AI. Interaktive Fassung, in der sich das Raster Stufe für Stufe füllt: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/ki-entwicklung.html?zeige=kosten aufrufen. 60

2.21 Was ein Tutor-Bot im Semester kostet: 150 Studierende stellen je 2 Fragen pro Tag an 98 Tagen (29.400 Fragen); jede Frage kostet so viel wie eine GPQA-Diamond-Frage mit dem günstigsten Modell, das 75 % richtig beantwortet. Von rund 8.800 US-$ (o3, Januar 2025) auf rund 12 US-$ (GPT-5.6 Luna, Juli 2026). Die Balken tragen dieselben Stufenfarben wie das Raster in Abbildung 2.20. Nur Größenordnung: Tutorgespräche sind länger als Testfragen. Daten: Emberson & Roodman (2026). Interaktive Fassung mit eigenen Kurszahlen: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/tutor-kosten.html aufrufen. 61

2.22 Mit jeder Arbeitsweise gibt der Mensch mehr Arbeitsschritte an die KI ab: Konzeptschema, keine Messdaten. „fragt“ markiert die Schritte, an denen der Agent in der Dämmerfabrik einen Menschen hinzuholt. Begriffe nach Dell'Acqua et al. (2023), E. Mollick (2024), E. R. Mollick (2026b) und E. R. Mollick (2026a); die Zuordnung der Schritte ist eine eigene Lesart. Interaktive Fassung zum Abschalten der Anlässe: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/ki-entwicklung.html?zeige=arbeitsweisen aufrufen. 62

2.23 Dieselbe Aufgabe in fünf Arbeitsweisen: Je weiter rechts im Raster die KI übernimmt, desto weniger spricht der Mensch und desto mehr sprechen die Agenten miteinander. Dialoge nachgestellt und gekürzt, Denkspuren angenähert, Zähler als Lehrmodell; die Zahlen im Übungsblatt sind nachgerechnet. Muster nach Schluntz & Zhang (2024). Interaktive Fassung mit zwei weiteren Fällen (Projektberichte, Vorlesung): QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/ki-arbeitsweisen-durchspiel.html aufrufen. 63

2.24 Der 4D-Kreislauf. Die äußere Schleife (Delegation und Diligence) entscheidet einmal je Vorhaben, was die KI übernimmt und welche Pflichten daraus folgen; die innere (Description und Discernment) dreht sich in jedem Arbeitsgang mehrmals. Eigene Darstellung nach Dakan & Feller (2025) und den beiden Schleifen aus Dakan et al. (2025). Die Fassung zum Anklicken mit Unterkompetenzen und dem Engpass je Rolle: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/4d-kreislauf.html aufrufen. 74
2.25 Exkurs „Ressourcenverbrauch der Modelle", Online-Fassung: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/energie.html aufrufen. 76

3.1 Illustration Zeitlich verteiltes Lernen – spacing 88
3.2 Illustration Inhaltlich gemischtes Lernen – interleaving . . . 89
3.3 Illustration Testgestütztes Lernen – test-enhanced learning . 90

4.1 Beispiel: Tutor-Bot BWL Grundlagen. Screenshot der Testversion, Januar 2026 105
4.2 Was für Aufgaben erledigen Lehrende? 25 Einzelaufgaben am Beispiel „Business Teachers, Postsecondary" nach Umfragen des US-Arbeitsministeriums auf O*NET. Quelle:* ONET, 2025 . 108
4.3 Automatisierung, Augmentierung und neue Aufgaben an den Aufgaben aus Tabelle 4.1: Vier Aufgaben wandern zur KI, fünf schrumpfen, fünf neue kommen hinzu. Schlussbild eines Videos (38 s), erstellt mit Claude Code und HyperFrames; Kachelgrößen nicht gemessen. Das Video gibt es nur in der Online-Version: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/kapitel04.html#vid-acemoglu-restrepo aufrufen. 111
4.4 Einmal fragen oder mehrfach? Nur Ergebnisse oder Analyse? Zwei Unterscheidungen und vier Quadranten von Such-Helfern mit KI; Produktbeispiele Stand 2026. Quelle: Tay (2025) 114
4.5 Schreibtrainer zum Kopieren: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/schreibtrainer.html aufrufen. 122

4.6 Making-of zum Video über Tabelle 4.1: Auftrag, Datendatei, Code, automatische Prüfung, Sichtprüfung, Rendern, rekonstruiert aus Versionsprotokoll und Prüfausgaben. Schlussbild eines Videos (59 s), erstellt mit Claude Code und HyperFrames. Das Video gibt es nur in der Online-Version: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/kapitel04.html#vid-making-of aufrufen. 128
4.7 Dieselbe Herleitung der optimalen Bestellmenge in Manim (links) und HyperFrames (rechts), beide von Claude programmiert. Schlussbild eines Videos (30 s). Das Video gibt es nur in der Online-Version: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/kapitel04.html#vid-eoq-vergleich aufrufen. 128
4.8 Little's Law in drei Szenarien: Über acht Stunden trifft die Rechnung $\hat{\lambda} \cdot \hat{W}$ (gestrichelt) den gezählten Bestand $\bar{L}$ (durchgezogen), im Prüfungsamt mit hoher Auslastung erst nach einigen Stunden; im Blick über 20 Minuten verfehlt sie ihn um 13 %. Dieses interaktive Element gibt es nur in der Online-Version: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/kapitel04.html#sec-widget-littles-law aufrufen. 130
4.9 Bullwhip-Effekt in drei Szenarien mit derselben Kundennachfrage. Oben die Bestellungen eines Jahres auf gleicher Skala, unten das Varianzverhältnis jeder Stufe über 2000 Perioden (logarithmisch), der Strich markiert den Wert nach Chen et al. Verdoppelt sich die Lieferzeit, steigt die Varianz der Fabrikbestellungen vom 41- auf das 692-Fache der Kundennachfrage; geteilte Kassendaten senken sie auf das 9,7-Fache. Dieses interaktive Element gibt es nur in der Online-Version: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/kapitel04.html#sec-widget-bullwhip aufrufen. 133

4.10 Ablauf des Physik-Tutors PS2 Pal nach Kestin et al. (2025): Lehrende legen Regeln und Musterlösungen im Prompt fest, Studierende arbeiten zu Hause Schritt für Schritt mit dem Tutor. Schlussbild eines Videos (44 s); der Dialog ist ein sinngemäßes Beispiel. Das Video gibt es nur in der Online-Version: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/kapitel04.html#vid-ps2pal-ablauf aufrufen. 143

5.1 Etwa gleichverteilt: Vier Arten der Interaktion von Studierenden mit Sprachmodellen. Quelle: Handa et al. (2025) 158
5.2 KI-resistente Aufgabenstellungen – 4 Säulen nach Gmeiner (2025) 159

6.1 Standbild aus dem Lernsong *Every Forecast Is Wrong* (5:15) bei 3:20: Der Refrain vergleicht drei Verfahren über die mittlere absolute Abweichung (MAD) und die mittlere absolute prozentuale Abweichung (MAPE); die Zeile unten ist der Liedtext als Untertitel. Text, Beispieldaten und Animationscode: Claude; Musik: Suno; Café und Zahlen erfunden. Das Video gibt es nur online: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/lernsong-forecast.html aufrufen. 186
6.2 Linien-Widget aus Woche 2 des SSCM-Moduls in der Ausgangslage der Pizzalinie: links die vier Arbeitsschritte mit Schiebereglern, rechts Kennzahlen, Kapazität je Schritt mit dem Engpass Backen und die drei Arbeitsaufträge unter *Try this*. Erstellt mit Claude nach Vorgaben der Lehrperson. Das Widget gibt es nur online: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/line-widget.html aufrufen. 191
6.3 Standbild aus dem Teaser zur Fallstudie Backhaus Kaya (5 s, ohne Ton): Aylin Kaya nachts in der Backstube vor dem Etagenofen. KI-generiertes Video (LTX-2.5); Bäckerei und Figuren sind erfunden. Den Teaser gibt es nur online, zusammen mit Linien-Widget und Engpass-Animation zum selben Fall: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/galerie-animationen.html#kaya-teaser aufrufen. 195

B.1 Vollständige Prompt-Sammlung in der Online-Version: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/kapitel07-appendix02-prompt-sammlung.html aufrufen. 244

C.1 Die 18 durchsuchten Fachzeitschriften und die 16 im Jahr 2025 publizierten Fachartikel stehen in der Online-Version dieses Anhangs: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/kapitel08-appendix03-rollenspiele-simulationen.html#sec-journals-rs aufrufen. 263

D.1 Online-Material zu Übung Ü1: Übungsblatt, Skill-Datei `folien-evidenzbasiert` und Übungsanleitung. QR-Code scannen oder die Online-Version aufrufen. 277
D.2 Online-Material zu Übung Ü2: Übungsblatt mit Tabellenvorlage. QR-Code scannen oder die Online-Version aufrufen. 281
D.3 Online-Material zu Übung Ü3: Übungsblatt mit den drei Prompts und Beispielbericht. QR-Code scannen oder die Online-Version aufrufen. 285
D.4 Online-Material zu Übung Ü4: Übungsblatt, Colab-Notebook für die SimPy-Simulation, UrbanRide-Paket. QR-Code scannen oder die Online-Version aufrufen. 289
D.5 Online-Material zu Übung Ü5 und zu den n8n-Workflow-Vorlagen. QR-Code scannen oder die Online-Version aufrufen. 294
D.6 Online-Material zu Übung Ü6: Übungsblatt, Tutor-Bündel `statistik-tutor` und Build-Prompts. QR-Code scannen oder die Online-Version aufrufen. 305
D.7 Online-Material zu Übung Ü7: Übungsblatt und Primer zur lokalen Automatisierung. QR-Code scannen oder die Online-Version aufrufen. 309
D.8 Online-Material zu Anhang D: Übungsblätter, Skill-Dateien, Notebooks und Workflow-Vorlagen. QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/anhang-d-material.html aufrufen. 311

E.1 Die optimale Bestellmenge gleicht zwei gegenläufige Kosten aus: Endbild der sechsstufigen Animation (Lehrmodell nach Harris (1990)). Die interaktive Fassung, den Prompt-Baustein, das Prüfskript und die Manim-Zellen für Colab gibt es in der Online-Version: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/anhang-primer.html#sec-primer-animationen aufrufen. 317
E.2 Dieselbe Aussage nach F. Chen et al. (2000), zweimal vom selben Sprachmodell gebaut: Ohne Regelwerk erklärt die Folie sich selbst in Sätzen, mit Regelwerk belegt sie den Titel mit einem Diagramm und überlässt die Erklärung der Stimme. Beide Foliensätze, den Prompt-Baustein und das Regelwerk gibt es in der Online-Version: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/anhang-primer.html#sec-primer-praesentationen aufrufen. . . . 321
E.3 Vollfassung von Primer C mit Prompt-Baustein, Stilangabe für den Musikgenerator, Prüfskript für die Spracherkennung und einer durchgespielten Textprobe: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/anhang-primer.html#sec-primer-lernsongs aufrufen. 325
E.4 Vollfassung von Primer D mit Prompt-Baustein, Vorlage für das Testprotokoll und den Befunden aus zehn studentischen Spielprojekten: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/anhang-primer.html#sec-primer-lernspiele aufrufen. 330

Tabellenverzeichnis

2.1 Modell, Harness und Agent: zwei Bauteile und eine Betriebsweise (eigene Zusammenstellung). 25
2.2 Was sich seit 2022 geändert hat: zwei Ermöglicher und eine Folge, alle in der Schicht um das Modell (eigene Zusammenstellung). 29
2.3 Modelle und Preisstufen bei Drucklegung. Preise laut Preisseiten der Anbieter, Stand Oktober 2026, Euro-Beträge einschließlich Mehrwertsteuer. Quellen: OpenAI (2026a), Anthropic (2026a), Google (2026), Mistral AI (2026), IT Center der RWTH Aachen (2026). 54
2.4 Prompt-Empfehlungen der großen KI-Labore. Quellen: Kotha et al. (2025), Google (2025), Anthropic (2025b). . . . 67
2.5 Fünf Kompetenzrahmen für den Umgang mit KI im Vergleich. Eigene Zusammenstellung nach den genannten Quellen . . . 71
2.6 Die vier Kompetenzen des AI-Fluency-Modells mit ihren Unterkompetenzen. Übersetzung nach Dakan & Feller (2025), CC BY-SA 4.0 72

3.1 Methoden nach Wissenstyp: Fakten, Prozess und Transfer. Quelle: Basierend auf Hattie (2023), S. 358, 340ff. 85
3.2 Kernaussagen und Belege zu den Gestaltungsfragen in Kapitel 3, Stand November 2026. 101

4.1 Welche Aufgaben in der Lehre wandern zur KI, bei welchen unterstützt sie, und welche kommen neu hinzu? Legende: x = klarer Effekt, ? = gemischter Effekt. Quelle: Aufgabenmodell nach Acemoglu et al. (2025) 110
4.2 Vier Typen von KI-Suchhelfern nach zwei Unterscheidungen. Quelle: Tay (2025) 113

4.3 Werkzeugtypen je Phase der Literaturrecherche. Typen nach Tay (2025), ergänzt um drei Typen ohne erzeugten Text (Zitationsnetz, Zitationskontext, API); Produktnamen sind ein Schnappschuss (Stand 2026), die Typen bleiben. Quelle: eigene Zuordnung nach Bartnik & Schmid (2025) 116
4.4 Acht Schreibtrainer entlang der Abschlussarbeit (TH Köln, Wirtschaftsingenieurwesen; Julia Schmid und Roman Bartnik) 121

5.1 Prüfungsformate nach den vier Säulen. Quellen: Gmeiner (2025); Mulder et al. (2023); Hanover Research (2024); Monash University (2025); Ward et al. (2024) 163
5.2 Beispiel arbeitsphasenorientierte Dokumentation der LLM Nutzung. Quelle: (Baresel et al. (2024), S. 11) 172
5.3 Erläuterungen zum Grad der LLM-Nutzung. Quelle: Baresel et al. (2024), basierend auf Rowland (2023) 173
5.4 Drei Phasen der KI-Integration in einen Kurs; die Rollen entsprechen Kapitel 4. Eigene Darstellung. 175

6.1 Die Beispiele dieses Kapitels nach Wissensform, Lerntechnik, Rolle der KI und Gestaltung 182

A.1 Gezielte Einschränkungen in didaktischen Prompts. Eigene Darstellung; Formulierungen mit Verweis stammen aus den Prompts in Anhang B. 209

C.1 Anwendungsbeispiele für KI-Rollenspiele und Simulationen 256

D.1 Nutzungsformen generativer KI nach Dauer der Delegation und Ort der menschlichen Prüfung 268
D.2 Fünf Bausteine einer dauerhaften Arbeitsumgebung und was das Modell davon wann liest 271
D.3 Drei Wege, das Tutor-Bündel zu laden 301

E.1 Vier Formate, vier Lehrziele. Die Spalte rechts verweist auf den Primer. 314
E.2 Vom Lehrziel zum Songtyp. Die beiden unteren Zeilen enden ohne Song oder mit dem Song am Schluss einer Sequenz. . . 323
E.3 Vom Lehrziel zum Spieltyp. Gamification, also Punkte, Abzeichen und Ranglisten, ist kein eigener Typ, sondern eine Schicht über einem Lernprozess. 327

Übersicht

Dieses Buch untersucht, wie generative künstliche Intelligenz (GenAI) Lehre, Lernen und Forschung verändern kann. Es richtet sich an Lehrende, Forschende und Studierende, die verstehen möchten, **wie KI als Werkzeug der Hochschuldidaktik** eingesetzt werden kann.

Das Buch besteht aus fünf Kapiteln und vier Anhängen:

1. Einleitung: KI als Hilfe zum Lehren und Lernen
2. Grundbegriffe und technische Grundlagen
3. Didaktische Ziele und Mechanismen
4. Vier Szenarien der Nutzung: KI als Hiwi, Copilot, Tutor und Simulator
5. Empfehlungen zur Umsetzung

- Anhang A: Gezielte Einschränkungen in didaktischen Prompts
- Anhang B: Best-Practice-Sammlung didaktischer Prompts und Aufgabenstellungen
- Anhang C: Umsetzung: Rollenspiele und Simulationen mit generativer KI
- Anhang D: Umsetzung: Arbeitsumgebung, Agenten, Tutoren und lokale Modelle

Vorwort

Dieses Buch ist aus einem Skript gewachsen. Als die ersten Kolleginnen und Kollegen fragten, wie man die neuen Sprachmodelle eigentlich sinnvoll in der Lehre einsetzt, habe ich meine Notizen aus dem eigenen Unterricht in Supply Management und Projektmanagement am Campus Gummersbach der TH Köln zusammengeschrieben. Daraus wurde ein Workshop, aus dem Workshop eine Reihe von Kursen im Netzwerk hdw nrw an Hochschulen in ganz Nordrhein-Westfalen, und aus den Fragen der Teilnehmenden immer neue Abschnitte. Parallel entstand an der TH Köln der Expertisezirkel GenKI, in dem wir seit [Jahr] regelmäßig darüber streiten, was in Lehre und Prüfung funktioniert und was nicht. Das Skript wanderte Anfang 2026 ins Netz, bekam Lernspiele, Animationen und einen Tutor-Bot, und liegt jetzt als Buch vor Ihnen.

Geschrieben ist es für Lehrende an Hochschulen. Sie brauchen keinen IT-Hintergrund. Ich habe selbst keinen; ich unterrichte Wirtschaftsingenieure. Was ich über Token, Kontextfenster oder Agenten weiß, habe ich mir angeeignet, weil ich es für die Lehre brauchte, und genau auf diesem Niveau erkläre ich es hier: so viel Technik, wie nötig ist, um gute didaktische Entscheidungen zu treffen, und keinen Absatz mehr. Wer tiefer einsteigen will, findet an den passenden Stellen Hinweise auf die Fachliteratur.

Das Buch hat zwei Teile, die man unterschiedlich liest. Die Kapitel 1 bis 5 sind ein Argumentationsgang. Wer neu einsteigt, liest sie am besten der Reihe nach; wer Vorwissen mitbringt, kann abkürzen und findet am Ende dieses Vorworts seinen Lernpfad. Kapitel 1 zeigt, was die Modelle heute leisten und wo die Risiken liegen. Kapitel 2 klärt die Grundbegriffe. Kapitel 3 fragt, was wir mit dem Einsatz eigentlich bezwecken, und holt sich die Antwort bei der Lernforschung. Kapitel 4 sortiert die Praxis in vier Rollen der KI: Hiwi, Copilot, Tutor und Simulator. Kapitel 5 zieht daraus Empfehlungen für Kursdesign, Prüfungen und Richtlinien. Kapitel 6 zeigt an Projekten aus meiner Lehre, wie Studierende mit diesen Ideen Assistenten, Tutoren und Planspiele gebaut haben. Die Anhänge A bis D sind dagegen ein Werkzeugkasten, in den man greift, wenn man etwas

Bestimmtes braucht: eine Übersicht didaktischer Prompt-Muster, eine Sammlung erprobter Prompts und Aufgabenstellungen, eine Vertiefung zu Rollenspielen und Simulationen sowie [Kurzbeschreibung Anhang D].

Zum gedruckten Buch gehört eine Online-Version unter https://th-koln-bartnik.github.io/genai4teaching/. Dort stehen die interaktiven Elemente, die sich nicht drucken lassen: die Lernspiele zu den Grundbegriffen, die Klick-Animationen zu Harness, Tokens und Gedächtnis, die Prozessanimationen am Ende des ersten Kapitels. Im Druck finden Sie an diesen Stellen einen QR-Code, der direkt zum jeweiligen Element führt. Zwei Seiten der Online-Version sind außerdem „lebende Seiten", die ich laufend aktualisiere: die Modellübersicht mit den aktuellen Modellen und Zugängen für Hochschulen und der Forschungsstand mit neueren Studien zum Thema. Beides veraltet schneller, als ein Buch gedruckt werden kann.

Damit sind wir bei einer Konvention, die das ganze Buch durchzieht. Ein Buch über eine Technik, die sich alle paar Monate ändert, muss ehrlich damit umgehen, dass es altert. Ich habe deshalb getrennt, was sich hält, und was sich ändert. Der Fließtext ist so geschrieben, dass er auch in einigen Jahren noch stimmen sollte: Die Lernforschung zu verteiltem Üben und Abruftests ist Jahrzehnte alt, die vier Rollen der KI in der Lehre sind von Modellnamen unabhängig, und die Frage, wie man unter neuen Bedingungen prüft, wird uns noch lange begleiten. Alles, was ein Verfallsdatum hat, steht in abgesetzten Kästen mit der Überschrift „Stand bei Drucklegung" und einem Datum: Modellnamen, Preise, Nutzungszahlen, Fähigkeiten, die gerade neu sind. Wenn Sie einen solchen Kasten lesen und das Datum ist zwei Jahre her, nehmen Sie ihn als historische Momentaufnahme und schauen Sie in die Online-Version.

Die Kapitel 1 bis 5 beginnen mit Lernzielen und enden mit Kernaussagen und Fragen zum Weiterdenken. Das ist keine Verzierung. Kapitel 3 plädiert dafür, Lernende regelmäßig zum Abruf zu zwingen, statt sie nur lesen zu lassen; es wäre merkwürdig, wenn das Buch selbst darauf verzichtete.

Viele Menschen haben zu diesem Buch beigetragen. [Dirk Burdinski] hat [Beitrag]. Die Studierenden meiner Module an der TH Köln haben mit mir Tutor-Bots, Lernspiele und Karriereberater gebaut, getestet und gnadenlos kritisiert; [Verweis auf die Kapitel oder Anhänge, in denen diese Projekte beschrieben sind]. [Namen der Studierenden oder Projektgruppen]. Die Teilnehmenden meiner hdw-Kurse und die Mitglieder des Expertisezirkels GenKI haben mit ihren Fragen und Einwänden mehr Abschnitte dieses

Buchs ausgelöst, als ihnen bewusst ist. [Weitere Namen: Kolleginnen und Kollegen, Testleserinnen und Testleser]. Dem Logos Verlag Berlin, insbesondere [Name], danke ich für die unkomplizierte Zusammenarbeit und dafür, dass ein Buch mit QR-Codes, Kästen und einer lebenden Online-Version überhaupt möglich war. Fehler, die übrig geblieben sind, gehen auf mich.

Das Buch erscheint Open Access unter der Lizenz CC BY-SA 4.0. Sie dürfen es kopieren, weitergeben, für Ihre eigenen Workshops umbauen und übersetzen, solange Sie die Quelle nennen und Ihre Fassung unter derselben Lizenz weitergeben. Möglich wurde das durch eine Förderung aus dem Open-Access-Publikationsfonds der TH Köln. Ich halte das für die einzig sinnvolle Form für ein Buch, das Lehrenden helfen soll, ihre Lehre zu verändern: Nehmen Sie, was Sie brauchen, und machen Sie es besser.

[Ort], im [Monat] 2026
Roman Bartnik

Wählen Sie Ihren Lernpfad

Nicht jede Leserin braucht jede Etappe. Lehrende bringen zwei Arten von Vorwissen mit, die wenig miteinander zu tun haben: Erfahrung mit KI-Werkzeugen und Kenntnis der Lernforschung, also ihrer Befunde zu den Wirkmechanismen des Lernens, der Wege, sie in der Lehre umzusetzen, und der erprobten Formen des KI-Einsatzes. Lehrerfahrung allein bringt diese Kenntnis nicht mit sich: In einer Befragung kannten Hochschullehrende wirksame Lernstrategien besser als ihre Studierenden, teilten mit ihnen aber verbreitete Fehlannahmen (Morehead et al., 2016). Ein Informatiker, der täglich mit Agenten arbeitet, hat oft nie gehört, warum verteiltes Üben länger hält; eine Kollegin, die die Befunde zu Abrufübungen kennt, weiß nicht unbedingt, was einen Agenten von einem Chatbot unterscheidet. Beiden kostet die vollständige Strecke mehr als Zeit, denn Erklärungen, die Neulingen helfen, belasten Erfahrene, die Bekanntes ein zweites Mal verarbeiten müssen (Kalyuga et al., 2003).

Abbildung 1 zeigt die vier Kombinationen als Liniennetz. Linie 1 ist für Lesende, denen beides neu ist, und hält an jedem Kapitel. Linie 2 ist für KI-Erfahrene: Sie lässt die Grundbegriffe aus und führt durch das ganze dritte Kapitel, denn dort steht, was Werkzeugwissen nicht ersetzt. Linie

3 ist für Lesende, die die Lernforschung kennen: Sie holt die technischen Grundlagen nach, nimmt aus dem dritten Kapitel nur die neue Evidenz mit und führt nach den vier Rollen zu den Praxis-Primern. Linie 4 ist für Lesende, die in beidem zu Hause sind: Sie springt von der Einleitung zur Evidenz, liest im vierten Kapitel vor allem Tutor und Simulator und endet bei Rollenspielen und Agenten in den Anhängen.

Vier Stationen liegen auf allen Linien: die Einleitung (Kapitel 1), die Forschung seit 2025 (Abschnitt 3.5), die vier Rollen (Kapitel 4) und die Fallbeispiele (Kapitel 6). Sie enthalten, was auch Erfahrene nicht aus anderer Quelle mitbringen. Die Empfehlungen zur Umsetzung (Kapitel 5) und die Anhänge bleiben jeder Linie als Nachschlagestationen offen. Welche Linie passt, zeigen sechs Aussagen, drei zur Erfahrung mit KI und drei zur Kenntnis der Lernforschung; zwei oder drei Zustimmungen in einer Gruppe zählen als Vorwissen.

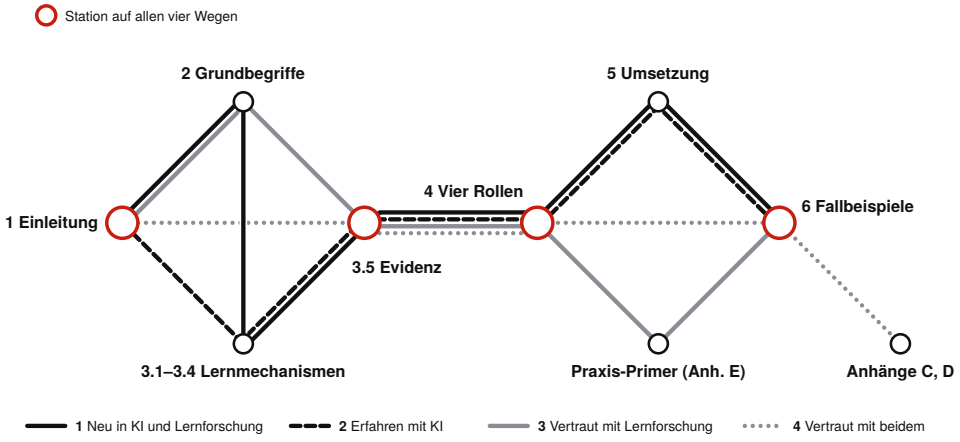

Abbildung 1. Lernpfade durch das Buch. Rot umrandet sind die Stationen, an denen alle Linien halten. Eigene Darstellung.

i Selbsttest: Welche Linie passt?

Erfahrung mit KI. (a) Ich nutze ein Sprachmodell mindestens einmal pro Woche für meine Arbeit. (b) Ich habe einen eigenen Assistenten eingerichtet, etwa ein Projekt mit festen Anweisungen und eigenen Dateien. (c) Ich habe einer KI eine mehrschrittige Aufgabe übertragen,

bei der sie selbst sucht, Dateien liest oder Code ausführt.
Kenntnis der Lernforschung. (d) Ich kenne zentrale Wirkmechanismen aus der Lernforschung und kann erklären, warum etwa Abrufübungen, verteiltes Üben und Selbsterklären das Behalten stärken. (e) Ich weiß, wie sich solche Mechanismen in einer Lehrveranstaltung umsetzen lassen, etwa mit kurzen Abfragen zu Beginn, Wiederholung über das Semester oder Aufgaben, in denen Studierende einander erklären. (f) Ich kenne erprobte Einsatzformen und Befunde zu KI in der Lehre, etwa wann ein KI-Tutor das Lernen stärkt und wann er es durch Auslagerung des Denkens schwächt.
Höchstens eine Zustimmung je Gruppe: Linie 1. Zwei oder mehr nur bei KI: Linie 2. Nur bei Lernforschung: Linie 3. In beiden Gruppen: Linie 4. Online prüft der Selbsttest die Antworten und hebt die Linie hervor: https://th-koln-bartnik.github.io/genai4teaching/vorwort.html#sec-lernpfade.

1 Einleitung

In diesem Kapitel

- Wie verbreitet ist KI-Nutzung?
- Was geht schief?
- Was hilft?
- Was Sie im Buch erwartet

Montagmorgen, fünfte Semesterwoche. Professorin Katrin Albers hat für ihre 120 Studierenden in Technischer Mechanik wieder keine Übungstests geschafft, obwohl sie weiß, dass häufiges Abfragen wirkt. Ein Kollege schwärmt, sein Chatbot schreibe ihm in Minuten zwanzig Aufgaben samt Lösungsweg; eine Kollegin will ihren Studierenden einfach einen KI-Tutor freischalten. Albers probiert es in der Mittagspause mit der kostenlosen Version, und schon die erste Lösung ist falsch. Am Nachmittag gibt ein Student eine fehlerfreie Hausübung ab und kann in der Sprechstunde keinen Schritt davon erklären. Albers fragt sich, ob die KI ihr die Arbeit abnimmt oder ihren Studierenden das Lernen.

Die Szene ist aus Gesprächen in Workshops mit Lehrenden zusammengesetzt.

Bevor Sie weiterlesen: Wie sehen Sie das?

Wie sehr stimmen Sie den vier Aussagen zu? Richtig oder falsch gibt es hier noch nicht: Jede Aussage wird an der Stelle im Kapitel aufgelöst, die sie beantwortet. Wer sich vorher festlegt, liest gezielter.

1. Fast alle Studierenden nutzen KI inzwischen auch für Prüfungsleistungen.
stimme zu 1 – 2 – 3 – 4 – 5 *stimme nicht zu*
(Auflösung in Kapitel 1.1)

2. Die größte Gefahr generativer KI für das Lernen besteht darin, dass Studierende in Prüfungen täuschen.
stimme zu 1 – 2 – 3 – 4 – 5 *stimme nicht zu*
(Auflösung in Kapitel 1.2)

3. Wer mit der kostenlosen Version eines Chatbots in seinem Fach schlechte Ergebnisse erhält, weiß, was KI dort leisten kann.
stimme zu 1 – 2 – 3 – 4 – 5 *stimme nicht zu*
(Auflösung in Kapitel 1.2)

4. Ein KI-Tutor verbessert das Lernen, sobald die Studierenden Zugang zu ihm erhalten.
stimme zu 1 – 2 – 3 – 4 – 5 *stimme nicht zu*
(Auflösung in Kapitel 1.3)

Lernziele: Nach diesem Kapitel können Sie …

1. erklären, bei welchen zwei Lehrproblemen generative KI hilft, und einordnen, wie verbreitet sie bei Studierenden und Lehrenden genutzt wird;
2. begründen, warum die Auslagerung des Denkens das Lernen stärker gefährdet als das Täuschen und warum schwache Zugänge das Urteil über KI verzerren;
3. die Bedingungen benennen, unter denen KI nach der Forschung seit 2025 das Lernen stützt, und Ihren eigenen Weg durch dieses Buch wählen.

Die Kernaussagen am Kapitelende sind nach diesen drei Zielen geordnet.

Wie kann generative künstliche Intelligenz (KI) **in der Lehre helfen?** Hoffnung besteht für die zwei Probleme, die Albers' Montag prägen: Studierende haben individuelle Bedürfnisse, Lehrende nur begrenzt Zeit,

und gerade wirksame Methoden wie häufige kleine Tests oder individuelles Feedback kosten viel Vorbereitung (Brown et al., 2014; Dunlosky et al., 2013; Hattie, 2023, Kap.13); ausführlich behandelt das Kapitel 3.1. Für die Lehre sind große Sprachmodelle (LLM, Large Language Models) vor allem „**generally faster**“ (McAfee, 2024): Übungsaufgaben, Anwendungsbeispiele, Quizfragen und Rollenspiele entstehen mit KI deutlich schneller (Meincke et al., 2024; E. R. Mollick & Mollick, 2023b). Der Berg ist noch da, aber mit dem E-Bike kommt man weiter. Wie weit, hängt an drei Fragen, die dieses Kapitel der Reihe nach beantwortet: Wie verbreitet ist die Nutzung, was geht dabei schief, und was hilft?

1.1 Wie verbreitet ist KI-Nutzung?

Für Studierende sind Sprachmodelle zum Standard geworden. In der britischen Befragung des Higher Education Policy Institute vom Dezember 2025 (n = 1.054 Vollzeitstudierende) nutzten 95 % KI in irgendeiner Form und 94 % auch für Prüfungsleistungen; 12 % übernahmen KI-Text direkt in die Abgabe, 2024 waren es 3 % (Stephenson & Armstrong, 2026). Deutsche Daten des CHE bestätigen das Bild: Im Wintersemester 2025/26 nutzten 81 Prozent von 28.584 befragten Studierenden an 202 Hochschulen KI-Werkzeuge mindestens wöchentlich, und jede zweite Person nutzte sie „als Tutor bzw. Lernpartner“, mit großen Fachunterschieden zwischen Wirtschaftsinformatik (72 Prozent) und Jura (19 Prozent) (Horstmann et al., 2026). Die britischen Befunde zeigen zugleich eine gespaltene Studierendenschaft: Die einen gewinnen Zeit für tieferes Lernen, andere lagern es aus („I'm not using my brain at all“) (Stephenson & Armstrong, 2026).

Genutzt wird vor allem auf den oberen Stufen. Eine Auswertung von einer Million anonymisierter Chats mit Universitätskonto zeigt, dass Studierende die Modelle vor allem zum **Erstellen neuer Inhalte und zum Analysieren komplexer Themen** einsetzen, also auf den höheren Ebenen der Bloomschen Taxonomie (Abbildung 1.1) (Handa et al., 2025).

Auf den produktiven Umgang fühlen sich Studierende schlecht vorbereitet. In der CHE-Befragung vom Wintersemester 2024/25 bewerteten sie das Angebot zum Erwerb von KI-Kompetenzen an ihrer Hochschule mit 2,7 von 5 Sternen (Hüsch et al., 2025). Hochschulen müssen deshalb Prüfungen anpassen und den Umgang mit den Werkzeugen lehren.

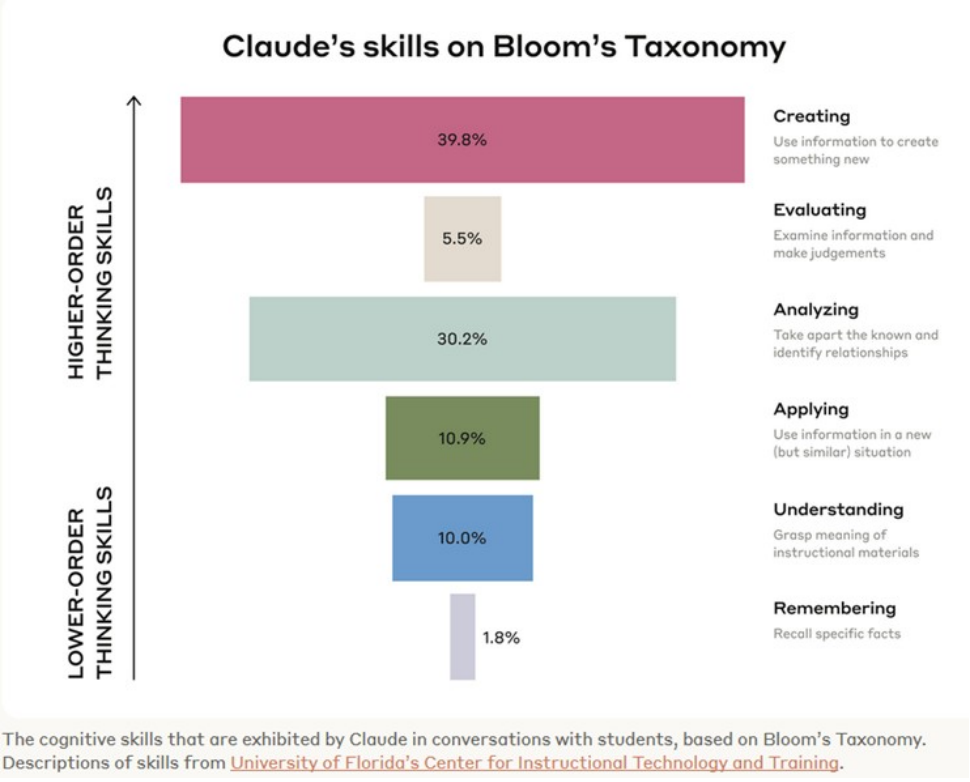

Abbildung 1.1. Schwerpunkte der Nutzung von LLMs (Claude) durch Studierende nach der Bloom'schen Taxonomie (Handa et al., 2025).

Ihre Einschätzung prüfen

„Fast alle Studierenden nutzen KI inzwischen auch für Prüfungsleistungen."
Auflösung: ja. In der britischen HEPI-Befragung nutzten 94 % KI auch für Prüfungsleistungen. Auf den produktiven Umgang fühlen sich viele aber schlecht vorbereitet: Dass Studierende KI nutzen, heißt nicht, dass sie es gut tun.

Bei den Lehrenden ist die Spanne weit. In einer bundesweiten Befragung von 626 Hochschullehrenden (Dezember 2024 bis Januar 2025) nutzten 12 Prozent KI in der Lehre gar nicht, weitere 33 Prozent selten oder sehr selten und knapp 15 Prozent sehr häufig. Mit Abstand am häufigsten genannt wurde die kostenlose Version von ChatGPT (66 Prozent), die Bezahlversion nur von 23 Prozent (von Garrel et al., 2026). International ergibt sich dasselbe Muster: Von 1.681 Lehrenden aus 28 Ländern hatten 61 Prozent KI in der Lehre schon eingesetzt, die große Mehrheit aber nur in geringem bis mittlerem Umfang (Digital Education Council, 2025), und ein Review von fünfzehn deutschen Studien findet, dass Lehrende KI seltener und selektiver nutzen als Studierende (Bosse et al., 2026).

In Workshops mit Lehrenden fällt zudem auf, wie **unsystematisch** die Nutzung meist ist: Sie findet fast nur im **Chatfenster** statt, man übernimmt, was brauchbar wirkt, und beginnt beim nächsten Mal von vorn, ohne Vorlagen, eigene Quellensammlungen, Projekte oder Agenten. Ethan Mollick nennt diese Lücke den **Fähigkeitsüberhang** (*capability overhang*): den Abstand zwischen dem, was die Modelle können, und dem, was fast alle mit ihnen tun (E. Mollick, 2026c). Für die Lehre ist der Überhang Befund und Chance zugleich, denn schon mit den heutigen Modellen wäre viel mehr möglich.

1.2 Was geht schief?

Die Metapher mit dem E-Bike trägt auch die Nebenwirkung: Wer nur noch mit Motor fährt, verliert Muskeln. Das zeigt sich zuerst beim Üben. In einem Feldexperiment mit knapp tausend Oberstufenschülern verbesserte ein Tutor im Stil des normalen ChatGPT die Übungsleistung um 48 Prozent; als der Zugang in der Prüfung fehlte, lagen dieselben Schüler 17 Prozent

unter der Kontrollgruppe, die nie Zugang hatte (Bastani et al., 2025). Die Übungen waren gelöst, gelernt war weniger als ohne Hilfe.

Die Arbeit verschiebt sich vom Erarbeiten zum Prüfen. In einer Befragung von 319 Wissensarbeitern sank mit Sprachmodellen der Aufwand für die Recherche selbst, während Koordination, kritische Prüfung der Ergebnisse und ihre Integration in ein Gesamtergebnis mehr Gewicht bekamen (H.-P. H. Lee et al., 2025). Anders als die Websuche, bei der man einzelne dornige Zweige erntet, liefert das Sprachmodell **das ganze Aufgabenbündel fertig verschnürt**. Wer per Chatbot statt per Suchmaschine recherchiert, setzt sich entsprechend weniger kritisch mit dem Thema auseinander (Mittal et al., 2026, Preprint). Ein vielgelesener Artikel trägt den Titel „Everybody is cheating their way through college“ (Walsh, 2025); der Titel lenkt den Blick auf die Messung, die größere Gefahr liegt beim Lernen selbst.

Ihre Einschätzung prüfen

„Die größte Gefahr generativer KI für das Lernen besteht darin, dass Studierende in Prüfungen täuschen.“
Auflösung: eher nicht. Täuschen verfälscht die Messung einer Leistung. Wer dagegen das Denken auslagert, übt die geprüften Schritte nie und lernt sie nicht, wie der Einbruch um 17 Prozent in der Prüfung zeigt. Was dabei verloren geht, nennt die Lernforschung erwünschte Schwierigkeiten (Kapitel 1.3).

Hinzu kommt ein Zugangsproblem. „KI nutzen“ heißt seit Ende 2025 Delegation an Agenten, die Werkzeuge einsetzen, mehrstufig arbeiten und Zwischenergebnisse selbst prüfen (E. Mollick, 2026a) (Kapitel 2.1.1). Kostenlose Tarife und „Auto“-Auswahl liefern dagegen oft schwächere Modellvarianten ohne Reasoning und mit kleinem Werkzeugkasten, und genau diesen Zugang nutzen die meisten Lehrenden: Wer am Modell spart, spart am Ergebnis.

Ihre Einschätzung prüfen

„Wer mit der kostenlosen Version eines Chatbots in seinem Fach schlechte Ergebnisse erhält, weiß, was KI dort leisten kann.“
Auflösung: nein. Kostenlose und automatisch gewählte Varianten antworten oft ohne Nachdenkphase und ohne Werkzeuge. Was ein

Sprachmodell im eigenen Fach leistet, zeigt erst ein starkes Modell mit passender Oberfläche und Werkzeugkasten (Kapitel 2.1.1).

1.3 Was hilft?

So schlimm muss es nicht werden. Im selben Experiment gab ein zweiter Tutor Hinweise statt Lösungen: Er hob die Übungsleistung um 127 Prozent und ließ in der Prüfung keinen Schaden zurück (Bastani et al., 2025). Lehre kann also erwünschte Schwierigkeiten im Sinne von E. L. Bjork & Bjork (2011) erhalten, auch wenn die Studierenden zu Hause starke Modelle nutzen. Die Forschung seit 2025 nennt drei Bedingungen dafür; Kapitel 3.5 stellt sie ausführlich dar.

Die Einbettung trägt, nicht das Werkzeug. In einer randomisierten Studie in 83 indischen Internatsschulen erhielten alle Zugang zur selben Lernplattform; große Lerngewinne entstanden nur dort, wo betreute Lernzeiten mit Aufsichtspersonen eingeplant waren (Oreopoulos, Keyes-Krysakowski, et al., 2026). **Anleitung wirkt, Ermutigung nicht:** In einem Ökonometrie-Kurs änderte die Ermutigung zum Tutor nichts, eine Anleitung zur tutoriellen Nutzung hob die Prüfungsleistung um 0,21 Standardabweichungen und die Bestehensquote um zwölf Prozentpunkte (Gallegos, 2026).

Ihre Einschätzung prüfen

„Ein KI-Tutor verbessert das Lernen, sobald die Studierenden Zugang zu ihm erhalten."
Auflösung: nein. Der Zugang allein bewirkt wenig. Lerngewinne entstehen, wo die Nutzung in betreute Lernzeiten eingebettet und angeleitet wird und wo der Tutor Hinweise statt fertiger Lösungen gibt.

Die Leitplanke gehört in Aufgabe und Rückmeldung. Eine Rückmeldung, die Lernenden zeigt, was das Abschreiben einer KI-Lösung für ihr eigenes Können bedeutet, halbierte in einem Experiment die Auslagerung (Maier et al., 2026); Feedback, das zuerst zur Reflexion auffordert und die Kritik danach liefert, schnitt beim späteren Transfer ohne KI besser ab als direkte KI-Kritik (Ates, 2026). Ein Beispiel aus der Praxis ist das „AI-Sandwich" von

Jon Ippolito, in dem selbst geführte Interviews zum Maßstab für den KI-Text werden (Kapitel B.5.1).

Auf der Ebene des Studiengangs kommen vier Hebel hinzu: Prüfungen nach den vier Säulen Mündlichkeit, Prozessorientierung, Kontextualisierung und Kollaboration (Kapitel 5.4), Richtlinien im Rahmen der KI-Verordnung (Kapitel 5.5.2), eine Dokumentation der KI-Nutzung durch die Studierenden (Kapitel 5.6) und die Integration in den ganzen Kurs (Kapitel 5.7).

1.4 Was Sie im Buch erwartet

In den Workshops kehren drei Fragen immer wieder. Seit 2024 haben sie vor allem im Netzwerk hdw nrw Lehrende aus nahezu allen Fächergruppen zusammengeführt. Die erste Frage ist eine Sorge: Entwertet KI Hausarbeiten, deren Ergebnis ein Sprachmodell in Minuten liefert, die **„Homework Apocalypse“** (E. R. Mollick, 2023)? Die zweite ist praktisch: Wie hilft KI bei Recherche, Aufgabenerstellung und Rückmeldung? Die dritte ist Neugier: Was wird möglich, das bisher zu aufwendig war, etwa Simulationen, in denen Studierende verhandeln oder ein Unternehmen steuern (E. R. Mollick & Mollick, 2024)? Das Buch beantwortet sie über **vier Rollen der KI** (Kapitel 4): als **Hiwi**, der Ihnen zuarbeitet (Kapitel 4.1), als **Copilot**, mit dem Studierende schreiben und programmieren (Kapitel 4.2), als **Tutor**, der erklärt und abfragt (Kapitel 4.3), und als **Simulator**, der ein Gegenüber spielt (Kapitel 4.4). Mit der Rolle wechselt, wer das Ergebnis prüft.

Darunter liegen die Grundbegriffe (Kapitel 2) und die Lernmechanismen (Kapitel 3), darauf bauen die Umsetzung in Prüfung und Kurs (Kapitel 5) und die Beispiele aus der eigenen Lehre (Kapitel 6). Dort bauen Studierende mit Praxispartnern Assistenten, die auf den Dokumenten eines Unternehmens antworten (Kapitel 6.3.5), und entwickeln Tutoren, Planspiele und Karriereberater für andere Studierende (Kapitel 6.2.2, Kapitel 6.3.3, Kapitel 6.3.4). Die Anhänge sammeln Prompts (Anhang A, Anhang B), Rollenspiele (Anhang C), Arbeitsumgebung und Agenten (Anhang D), Praxis-Primer für Lernmaterial (Anhang E) und Lösungshinweise (Anhang F). Welche Kapitel Sie davon brauchen, hängt von Ihrem Vorwissen ab; das Vorwort führt dazu mit einem Selbsttest zu einem von vier Lernpfaden.

Fünf Fragen, die dieses Buch beantwortet

1. Warum schadet ein Chatbot, der jede Übungsfrage richtig beantwortet, dem Lernen? (Kapitel 3)
2. Wann ist die KI Ihr Hiwi, wann der Tutor Ihrer Studierenden, und warum wechselt damit die Verantwortung? (Kapitel 4)
3. Was muss beim Menschen bleiben, wenn man eine Aufgabe an einen Agenten delegiert? (Kapitel D.1)
4. Warum hilft ein Lied beim Merken einer Formel, aber nicht beim Anwenden? (Kapitel E.4)
5. Wie echt muss ein simuliertes Gegenüber sein, damit Studierende daran üben? (Kapitel 4.4, Anhang C)

Fünf Formate zeigen, was 2026 mit KI entsteht: eine Prozessanimation, in der sich vor dem Engpass die Arbeit staut (Goldratt & Cox, 2014; Little, 1961), eine Präsentationsfolie nach Regelwerk, ein Lernsong, ein Lernspiel und ein Rollenspiel. Blättern Sie mit den Pfeilen; unter jedem Beitrag führt ein Link zur Stelle im Buch.

Abbildung 1.2. Galerie „Fünf Formate, die 2026 mit KI entstehen“: Engpass-Animation (Kapitel 4.2.2.3), Präsentationsfolie mit Regelwerk (Kapitel E.3), Lernsong zu Prognoseverfahren (Kapitel 6.1.2), Zuordnungsspiel (Kapitel 6.1.3) und KI-Rollenspiel (Kapitel 4.4.1). Dieses interaktive Element gibt es nur in der Online-Version: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/galerie-kapitel01.html aufrufen.

Kernaussagen

Zu Lernziel 1: Lehrprobleme und Verbreitung

1. Generative KI ist für die Lehre ein Kraftverstärker: Der Berg bleibt, aber mit dem E-Bike kommt man weiter. Sie senkt vor allem den Aufwand für Methoden, die didaktisch wirksam, aber zeitintensiv sind.
2. Studierende nutzen Sprachmodelle flächendeckend, auch für Prüfungsleistungen, fühlen sich aber auf den produktiven Umgang schlecht vorbereitet. Bei Lehrenden reicht die Spanne von intensiver Nutzung bis zu keiner; genutzt wird meist unsystematisch und im Chatfenster. Der Fähigkeitsüberhang ist groß.

Zu Lernziel 2: Was schiefgeht

3. Die Hauptgefahr ist nicht das Täuschen, sondern die Auslagerung des Denkens: Ein Tutor ohne Leitplanken hebt die Übungsleistung und senkt die Prüfungsleistung.
4. Schwache Zugänge verzerren das Urteil. „KI nutzen“ heißt Delegation an Agenten mit Werkzeugen; wer mit kostenlosen Varianten ohne Reasoning und Werkzeuge arbeitet, hält deren Schwächen für die Grenzen der Technik.

Zu Lernziel 3: Was hilft

5. Über die Lernwirkung entscheiden Einbettung, Anleitung und Gestaltung, nicht der Zugang zum Werkzeug: betreute Lernzeiten, angeleitete statt nur ermutigte Nutzung und Leitplanken in Aufgabe und Rückmeldung, die erwünschte Schwierigkeiten erhalten.

Lernfragen

Wiederholen

1. Bei welchen zwei Lehrproblemen kann generative KI helfen?
2. Warum ist für das Lernen die Auslagerung des Denkens

gefährlicher als das Täuschen in Prüfungen, und welches Konzept der Lernforschung beschreibt, was dabei verloren geht?

Anwenden

3. Ihre Hochschule schaltet allen Studierenden einen KI-Tutor frei. Welche zwei Bedingungen aus Kapitel 1.3 müssten Sie in Ihrem Kurs schaffen, damit daraus Lernwirkung entsteht, und wie sähe das konkret aus?
4. Welche Lehrmethode haben Sie in den letzten Semestern aus Zeitgründen nicht umgesetzt, obwohl Sie von ihrer Wirkung überzeugt sind? Welchen Teil des Aufwands könnte ein Sprachmodell übernehmen, und welcher Teil muss bei Ihnen bleiben?

Beurteilen

5. Bei welcher Aufgabe in Ihrer Lehrveranstaltung würde ein Studierender durch KI-Nutzung am meisten an Lernwirkung verlieren? Woran würden Sie das erkennen?
6. Ermutigung zur KI-Nutzung änderte in einer Studie nichts, Anleitung hob die Prüfungsleistung. Lesen Sie, was Ihre Kursbeschreibung oder Ihre erste Sitzung zum Thema KI sagt: Ist das Ermutigung oder Anleitung, und was müsste sich ändern?

Lösungshinweise: Anhang F.

2 Grundbegriffe

In diesem Kapitel

- Definition einiger Grundbegriffe
- Wie denken Sprachmodelle und warum halluzinieren sie?
- Welches Modell wählen?
- Was können die Modelle – und was nicht?
- Wo und wie spreche ich mit der KI?
- Schemas für den systematischen Umgang mit GenAI
- Exkurs: Wie steht es mit dem Ressourcenverbrauch der Modelle?

Dr. Miriam Kessler lehrt Statistik für 300 Studierende der Psychologie und will zum Semesterstart einen Chatbot anbieten, der Fragen zu ihrem Skript beantwortet. Ein Kollege rät zu einem Agenten mit Internetzugang, ein anderer schwört auf seinen Prompt-Anfang: „Du bist ein Weltklasse-Statistiker, ich gebe dir 200 Dollar Trinkgeld." Beim Testen löst das Modell eine Regressionsaufgabe tadellos und verzählt sich danach bei den Buchstaben eines Fachbegriffs. Dann zeigt ihr eine Studentin eine Literaturangabe, die der Chatbot ihr genannt hat, mit Autor, Jahr und Titel. Die Bibliothek findet sie nicht, denn es gibt sie nicht. Kessler fragt sich, ob sie ihren Studierenden ein Werkzeug empfehlen kann, dessen Fehler sie nicht vorhersieht.

Die Szene ist aus Gesprächen in Workshops mit Lehrenden zusammengesetzt.

Bevor Sie weiterlesen: Wie sehen Sie das?

Wie sehr stimmen Sie den vier Aussagen zu? Jede Aussage wird an der Stelle im Kapitel aufgelöst, die sie beantwortet. Wer sich vorher festlegt, liest gezielter.

1. Ein Chatbot, der nur aus Ihrem Skript antworten soll, braucht keinen Agenten; es genügt ein Modell, das vor jeder Antwort passende Stellen aus dem Skript abruft.
stimme zu 1 – 2 – 3 – 4 – 5 *stimme nicht zu*
(Auflösung in Kapitel 2.1.3)

2. Dass ein Chatbot Quellen erfindet, ist ein Programmfehler, den die nächsten Modellversionen abstellen.
stimme zu 1 – 2 – 3 – 4 – 5 *stimme nicht zu*
(Auflösung in Kapitel 2.2)

3. Wenn ein Modell die schwierigen Aufgaben Ihres Fachs löst, können Sie sich bei den leichteren erst recht auf es verlassen.
stimme zu 1 – 2 – 3 – 4 – 5 *stimme nicht zu*
(Auflösung in Kapitel 2.4)

4. Höflichkeit, Drohungen oder ein versprochenes Trinkgeld verbessern die Antworten eines Sprachmodells nicht zuverlässig.
stimme zu 1 – 2 – 3 – 4 – 5 *stimme nicht zu*
(Auflösung in Kapitel 2.5.5)

Lernziele: Nach diesem Kapitel können Sie …

1. Modell, Harness und Agent abgrenzen, die Nutzungsmuster LLM, RAG und Agent unterscheiden und für eine Lehraufgabe das passende Setup wählen;
2. in Laiensprache erklären, wie ein Sprachmodell Text erzeugt, warum es dabei halluziniert und was eine Anfrage an Energie kostet;
3. mit der Jagged Frontier begründen, warum Modelle bei ähnlich schwierigen Aufgaben sehr unterschiedlich abschneiden;
4. einen Prompt aus Rolle, Aufgabe, Format und Beispielen bauen, verbreitete Prompt-Tricks als wirkungslos erkennen und mit dem 4D-Modell klären, was bei einer Aufgabe an die KI geht und wie das Ergebnis beschrieben, geprüft und verantwortet wird.

Die Kernaussagen am Kapitelende sind nach diesen vier Zielen geordnet.

2.1 Definition einiger Grundbegriffe

Dieser Abschnitt klärt die Begriffe, mit denen das übrige Buch arbeitet, und zwar nur so tief, wie es für die didaktische Nutzung nötig ist. Er beginnt mit dem Gespann aus Modell und Harness, weil sich daran seit 2022 am meisten geändert hat, und schaut erst danach in das Modell hinein.

Welche der Fachbegriffe kennen Sie schon? Von Prompt bis Token, über Temperatur und RAG: Testen Sie sich selbst mit dem folgenden kleinen Spiel.

Lernspiel: Welche Grundbegriffe kennen Sie schon?

Ordnen Sie die Begriffe den korrekten Definitionen zu! Am Start wählen Sie zwischen *Grundbegriffen* und dem Level *Fortgeschritten* mit Agenten-Begriffen und einer Diagnose-Runde zu typischen Problemen wie *Cognitive Debt*, *Sycophancy* oder *Prompt Injection*.

Abbildung 2.1. Lernspiel „Welche Grundbegriffe kennen Sie schon?“ (Zuordnung von Begriffen und Definitionen). Dieses interaktive Element gibt es nur in der Online-Version: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/llm-game-standalone.html aufrufen.

2.1.1 Was sich seit 2022 geändert hat: Modell, Harness und Agent

Wer 2022 mit ChatGPT gearbeitet hat und 2026 einem Agenten einen Rechercheauftrag gibt, erlebt zwei verschiedene Werkzeuge. Am Prinzip des Sprachmodells hat sich dabei wenig geändert: Es bekommt Text

und setzt ihn wahrscheinlich fort. Gewachsen ist vor allem die Schicht um das Modell herum. Sie hat zwei Dinge hinzugewonnen, Werkzeuge und Gedächtnis, und aus beiden folgt ein drittes: Das Modell darf mehr Arbeitsschritte selbst wählen. Für diese Schicht setzt sich der Name **Harness** durch, für das, was beim Arbeiten aus Modell und Harness entsteht, der Name **Agent**. Die folgende Animation baut den Weg in acht Schritten auf; sie ist die Landkarte für den ganzen Abschnitt.

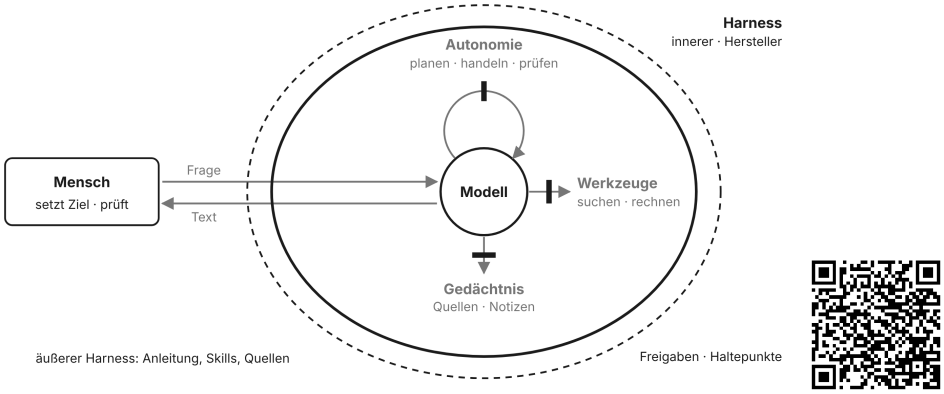

Abbildung 2.2. Gewachsen ist vor allem die Schicht um das Modell. Werkzeuge und Gedächtnis kommen hinzu, daraus folgt eine Arbeitsschleife, über deren Schritte das Modell selbst entscheidet; alle drei sitzen im Harness, dessen Freigaben und Haltepunkte den Handlungsspielraum des Modells regeln. Den inneren Harness liefert der Hersteller, den äußeren bauen die Nutzenden (schematische Darstellung). Die Fassung zum Durchklicken: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/harness-schichten.html aufrufen.

Die drei Begriffe lassen sich an einem Bild auseinanderhalten, dem Fuhrwerk (Tabelle 2.1). Das Modell ist das Pferd, der Harness das Geschirr, der Agent das Gespann in Fahrt, und der Mensch sitzt auf dem Bock. Das Bild wirkt hier als *Advance Organizer* im Sinne Ausubels: eine Einführung auf höherer Abstraktionsebene, an die die folgenden Einzelbegriffe andocken können (Ausubel, 1960).

	Modell	Harness	Agent
Was ist es?	das trainierte Netz: Text hinein, wahrscheinliche Fortsetzung heraus	die Software um das Modell: Werkzeuge, Gedächtnis, Schleife, Freigaben	eine Betriebsweise: Das Modell steuert seinen Ablauf selbst
Art	Bauteil	Bauteil	Verhalten zur Laufzeit
Im Bild	Pferd	Geschirr	Gespann in Fahrt
Wer baut es?	ein KI-Labor (OpenAI, Google, Anthropic ...)	Hersteller (innerer Harness) und Nutzende (äußerer Harness)	entsteht, wenn beide zusammen laufen

Tabelle 2.1. Modell, Harness und Agent: zwei Bauteile und eine Betriebsweise (eigene Zusammenstellung).

Daraus folgt ein Satz, der viele Missverständnisse erspart: **Jeder Agent braucht einen Harness, aber nicht jeder Harness macht einen Agenten.** Ein Chatbot, der vor jeder Antwort fest Stellen aus dem Skript holt, hat einen Harness und bleibt doch ein fest programmierter Ablauf. Die klassische KI-Forschung zieht dieselbe Grenze mit anderen Wörtern: Ein Agent nimmt seine Umwelt über Sensoren wahr und wirkt über Aktoren auf sie ein; seine *Architektur* entspricht dem Harness, sein *Programm* der Steuerung, die heute das Modell übernimmt (Russell & Norvig, 2021, S.54, 65 ff.).

Ausgangspunkt: das Modell allein. Um 2022 war das Chatfenster die ganze Schnittstelle. Wir tippten eine Frage, das Modell lieferte Text, und alles Weitere taten wir selbst: Zahlen nachrechnen, Quellen suchen, das Ergebnis in eine Datei kopieren, die Antwort prüfen und die nächste Frage stellen. Das Modell konnte nichts nachschlagen und nichts ausführen, und es vergaß das Gespräch, sobald das Fenster geschlossen war. Im Bild des Fuhrwerks war es ein Pferd ohne Geschirr: viel Kraft, an nichts angespannt.

Erster Ermöglicher: Werkzeuge. Die erste Erweiterung ist unscheinbar. Statt einer Antwort schreibt das Modell eine strukturierte Bitte, etwa „rechne 17 × 23“ oder „suche nach Little’s Law“; ein gewöhnliches Programm führt sie aus und legt das Ergebnis zurück in den Text, den das Modell weiterschreibt. Dass Sprachmodelle selbst lernen können, wann sich ein solcher Aufruf lohnt, zeigten Schick et al. (2023) an Taschenrechner,

Suchmaschine und Kalender. Ende 2024 kam ein gemeinsamer Stecker hinzu, das Model Context Protocol (MCP), über das sich beliebige Dienste nach demselben Muster anschließen lassen (Anthropic, 2024); es spielt für Agenten die Rolle, die USB für Drucker und Kameras spielt. Ein **Werkzeug** ist also ein Programm, das das Modell anfordern, aber nicht selbst ausführen kann. Wie Werkzeuganschluss und Skills in der Lehre aussehen, vertieft Kapitel 2.1.4.

Zweiter Ermöglicher: Gedächtnis. Die zweite Erweiterung betrifft, was das Modell beim Antworten vor sich hat. RAG legt ihm passende Stellen aus eigenen Dokumenten vor (Lewis et al., 2020), die Kontextfenster sind von wenigen Seiten auf ganze Bücher gewachsen, und eine Anleitungsdatei oder ein Notizordner trägt Regeln und Zwischenstände von einer Sitzung in die nächste. Was davon wann auf den Schreibtisch des Modells kommt, ist eine eigene Gestaltungsfrage; ihr widmet sich Kapitel 2.1.5.

Die Folge: Autonomie im Vorgehen. Mit Werkzeugen und Gedächtnis wird aus einem Durchgang eine Schleife. Das Modell plant einen Schritt, ruft ein Werkzeug auf, liest das Ergebnis und plant den nächsten, so lange, bis die Aufgabe erledigt scheint; Yao et al. (2023) haben dieses Wechselspiel aus Denken und Handeln unter dem Namen ReAct beschrieben. Schluntz & Zhang (2024) ziehen daraus die Grenze, die für dieses Buch gilt: In einem **Workflow** folgen Modell und Werkzeuge vorgegebenen Pfaden, ein **Agent** steuert seinen Ablauf und seine Werkzeugnutzung selbst. Die Stufen dazwischen, vom Router bis zur Schleife, zeigt die Animation in Kapitel 2.1.3. Das Wort kommt vom lateinischen *agere*, handeln, in Gang bringen. Wie weit diese Selbststeuerung inzwischen reicht, misst METR als Zeithorizont: Die Aufgaben, die Modelle in der Hälfte der Fälle allein lösen, sind von Minuten auf Stunden gewachsen , s. 2.4.

„Autonom“ verlangt eine Einschränkung. Das griechische *autónomos* heißt, sich selbst das Gesetz (*nómos*) geben, und das tut ein Agent nicht: Das Ziel setzt der Mensch, das Modell wählt den Weg. Wir sprechen deshalb von **Autonomie im Vorgehen** und nennen solche Systeme **teilautonom**, so wie die Normung des automatisierten Fahrens von Stufen der Automatisierung spricht statt von autonomen Fahrzeugen (SAE International, 2021). Die Pädagogik meint mit Autonomie ohnehin etwas anderes, die Fähigkeit der Lernenden, das eigene Lernen zu steuern (Deci & Ryan, 2000; Holec, 1981). In diesem Buch heißt es deshalb stets „Autonomie des Modells“ oder „Autonomie der Lernenden“, denn jeden Schritt, den ein Agent selbst wählt, muss keine Studentin mehr wählen.

Wie viel Autonomie ein Modell bekommt, ist eine Entscheidung der Menschen, die es einsetzen, keine Eigenschaft des Modells. Morris et al. (2024) ordnen die Zusammenarbeit von Mensch und KI deshalb in sechs Stufen, von „keine KI“ bis zur KI als vollständig selbstständigem Agenten, und betonen ausdrücklich, dass für Bildung und Prüfungen auch die unterste Stufe ihren Platz behält. Die teilautonomen Agenten dieses Kapitels gehören nicht auf ihre oberste Stufe, denn das Ziel setzt weiterhin ein Mensch.

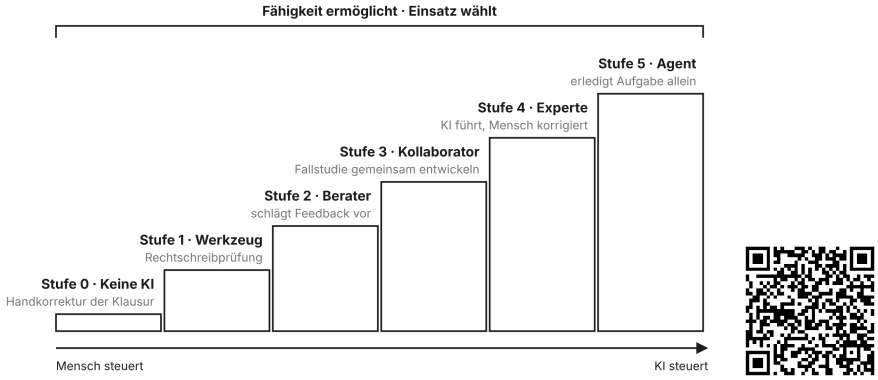

Abbildung 2.3. Wie selbstständig eine KI arbeitet, entscheiden die Menschen, die sie einsetzen. Sechs Stufen der Zusammenarbeit von der Handkorrektur ohne KI bis zum Agenten, der eine Aufgabe allein erledigt; die Fähigkeit des Modells ermöglicht höhere Stufen, gewählt werden sie im Einsatz (eigene Darstellung nach Morris et al. (2024), Tabelle 2; Beispiele aus der Hochschullehre ergänzt). Die Fassung zum Durchklicken: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/autonomiestufen.html aufrufen.

Der Name für das Gewachsene: Harness. Werkzeuge, Gedächtnis und Schleife sind keine Eigenschaften des Modells, sondern Programme um es herum. Anthropic definiert den **Harness** als das System, das ein Modell als Agent handeln lässt: Er nimmt Eingaben entgegen, ruft Werkzeuge auf und gibt Ergebnisse zurück (Grace et al., 2026). Das englische *harness* ist das Geschirr eines Zugpferds, und seit dem 17. Jahrhundert heißt *to harness* im übertragenen Sinn, eine Kraft nutzbar machen. Das Bild trägt weit: Dasselbe Pferd zieht mit anderem Geschirr einen Pflug oder eine Kutsche, und dasselbe Modell wird mit anderem Harness zum Lerntutor oder zum Karriereberater.

Die drei großen Labore beschreiben dieses Bauteil mit verschiedenen Wörtern und meinen im Kern dasselbe. Google nennt die Schleife um Modell und Werkzeuge 2024 *Orchestrierungsschicht* (Wiesinger et al., 2024), OpenAI nennt sie beim Programmieragenten Codex ausdrücklich Harness (Bolin, 2026), und Anthropic fasst Modell und Harness zum „Gehirn“ zusammen, das getrennt von den „Händen“ in einer abgeschotteten Umgebung arbeitet (Martin et al., 2026).

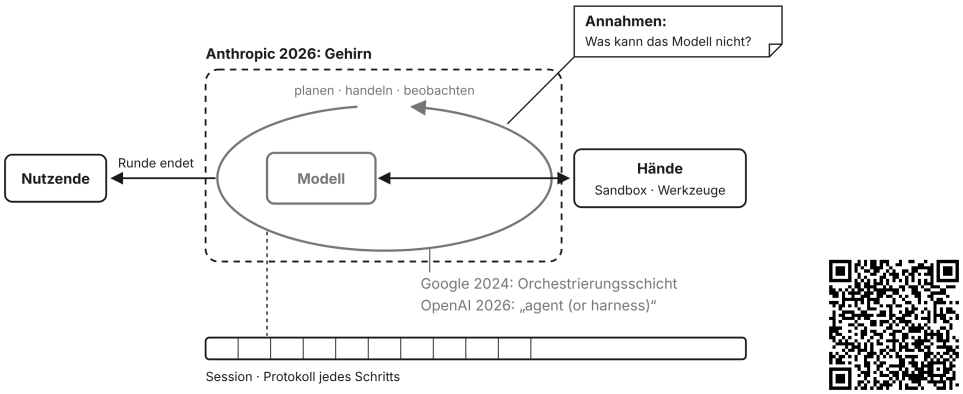

Abbildung 2.4. Drei Labore, ein Bauplan. Eine Schleife ruft das Modell immer wieder auf und lässt seine Werkzeugaufrufe ausführen, bis eine Runde endet und wieder der Mensch entscheidet; Google nennt sie Orchestrierungsschicht, OpenAI Harness, Anthropic trennt das „Gehirn“ aus Modell und Harness von den „Händen“ und protokolliert jeden Schritt in einer Session. Jeder Harness enthält Annahmen darüber, was das Modell nicht kann (eigene Darstellung nach Wiesinger et al. (2024), Bolin (2026) und Martin et al. (2026); schematisch). Die Fassung zum Durchklicken: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/drei-labs-ein-bauplan.html aufrufen.

Der Harness ist zugleich der Regler der Autonomie. Welche Werkzeuge er anbietet, ob ein Werkzeug nur lesen oder auch schreiben darf, wo der Ablauf anhält und auf eine Freigabe wartet: All das legt fest, wie viel **Handlungsspielraum** das Modell bekommt. Dieser Spielraum wird eingeräumt, begrenzt und verstellt, und zwar im Harness, nicht im Modell. Was sich seit 2022 geändert hat, ist vor allem dieser Spielraum: mehr Werkzeuge, mehr Gedächtnis und damit mehr Schritte, über die das Modell selbst entscheidet (Tabelle 2.2). Wer den Harness pflegt, betreibt *Harness Engineering*; Hashimoto (2026), der den Begriff geprägt hat, versteht

darunter, aus jedem Fehler eines Agenten eine dauerhafte Verbesserung seiner Umgebung zu machen, damit der Fehler nicht wiederkehrt.

Richtung	um 2022	2026	Begriff	vertieft in
Werkzeuge (Ermöglicher)	keine; der Mensch rechnet, sucht und kopiert	Websuche, Code ausführen, Dateien lesen und schreiben, angeschlossene Dienste	Werkzeug, Werkzeuganschluss (MCP)	Kapitel 2.1.4
Gedächtnis (Ermöglicher)	das laufende Gespräch, wenige Seiten	eigene Quellen (RAG), ganze Bücher im Kontext, Anleitungsdatei und Notizen über Sitzungen hinweg	Kontext, Gedächtnis	Kapitel 2.1.5
Autonomie im Vorgehen (Folge)	ein Durchgang: Frage, Antwort	Schleife über viele Schritte, Minuten bis Stunden ohne Rückfrage	Agent, teilautonom	Kapitel 2.4

Tabelle 2.2. Was sich seit 2022 geändert hat: zwei Ermöglicher und eine Folge, alle in der Schicht um das Modell (eigene Zusammenstellung).

Die Grenze zwischen Modell und Harness wandert allerdings. Jeder Harness enthält Annahmen darüber, was das Modell nicht allein kann, und mit besseren Modellen werden manche dieser Annahmen überflüssig (Martin et al., 2026). Die Labore trainieren ihre Modelle inzwischen gezielt auf Werkzeuggebrauch und lange Aufgaben, und was gestern ein Programm um das Modell herum leisten musste, kann das Modell morgen selbst; Logan Kilpatrick von Google DeepMind fasst das in die Formel, das Modell fresse den Harness (Sequoia Capital, 2026). Die Begriffe verlieren dadurch nicht ihren Wert, denn sie beschreiben Aufgaben, die erledigt werden müssen, gleich wer sie erledigt: Jemand muss Werkzeuge anschließen, Kontext auswählen und Haltepunkte setzen.

Was das für Lehrende heißt. Den größten Teil des Harness liefert der Hersteller, mit dem Chatfenster, dem Rechercheagenten oder dem Programmieragenten. Böckeler (2026) nennt das den inneren Harness und stellt ihm den äußeren gegenüber, den die Nutzenden selbst bauen: Anleitungsdateien, Skills, eigene Wissensbasen und Prüfregeln. Am

äußeren Harness gestalten Lehrende und Studierende. Die Projekte in Kapitel 6 sind fast alle von dieser Art: Ein Übungstutor (Kapitel 6.2.2), ein Karriereberater (Kapitel 6.3.4) und eine Quellenanbindung mit Praxispartnern (Kapitel 6.3.5) laufen auf denselben großen Modellen und unterscheiden sich in Anleitung, Quellen und Grenzen. Mit dem Handlungsspielraum des Modells ändert sich auch unsere Rolle. Wir stellen nicht mehr jede Frage einzeln, sondern setzen das Ziel, legen fest, wo der Agent anhält, und prüfen, was zurückkommt. OpenAI hat dafür den Leitsatz „Humans steer. Agents execute." ausgegeben (Lopopolo, 2026): Der Mensch lenkt, der Agent führt aus. Wo die Haltepunkte in der Praxis liegen, zeigt Kapitel 2.1.4.

2.1.2 Was im Modell passiert: Tokens, Zahlen, Aufmerksamkeit

Was heißt hier „künstliche Intelligenz"? Generative KI ist ein Teilgebiet der KI, also des Versuchs, menschliches Denken und Verhalten nachzubilden (Russell & Norvig, 2021); für die Lehre macht die Unterscheidung kaum einen Unterschied, und dieses Buch verwendet KI, generative KI (GenAI) und Sprachmodell weitgehend synonym. Ältere Fachartikel meinen mit „KI" allerdings meist bessere statistische Prognosemodelle für Fachleute, etwa für Routen oder Lagerbestände, während Publikationen seit 2022 von Chatbots handeln, die menschenähnlich schreiben und analysieren (Russell & Norvig, 2021). Ein **Sprachmodell** (*Large Language Model*, LLM) ist ein Rechensystem, das das nächste Wort in einer Wortkette vorhersagt, gestützt auf die Wörter davor (Jurafsky & Martin, 2025, Kap.7, S. 2); generativ heißt es, weil es auf diese Weise Texte erzeugt, die es vorher nicht gab.

Dazu zerlegt das Modell den Text in **Tokens**, kleine Bausteine aus ganzen Wörtern, Wortteilen oder Satzzeichen (Jurafsky & Martin, 2025, Kap.2). Jedes Token hat eine feste Nummer und wird in einen **Vektor** übersetzt, eine lange Zahlenreihe, die seine Bedeutung als Ort auf einer Art Stadtplan beschreibt; ähnliche Wörter wohnen dort in der Nachbarschaft. Diesen Vorgang nennt man **Embedding** (englisch für Einbettung). Wie viele Tokens ein Text braucht, hängt von der Sprache ab, und das hat Folgen für Kosten und Länge, wie die Vorhersagefrage der folgenden Animation zeigt. Sie führt in acht Schritten vom Satz „Die Bank steht unter einem Baum." zum nächsten Wort; Zerlegung und Nummern stammen aus einem echten Tokenizer, die Bedeutungskarte und die Wahrscheinlichkeiten sind schematisch.

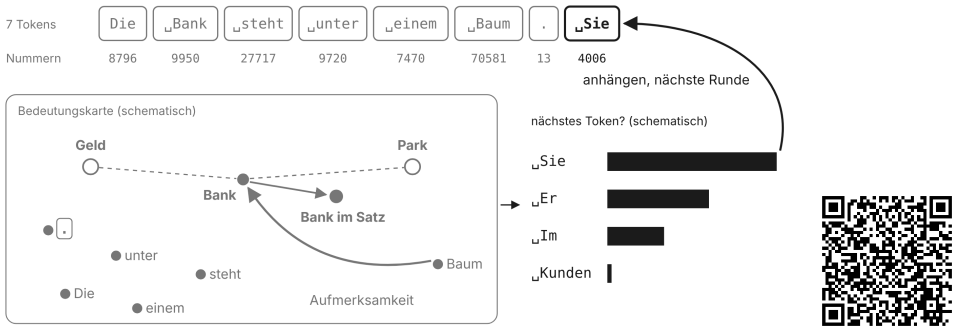

Abbildung 2.5. Ein Sprachmodell rechnet mit Zahlen, nicht mit Wörtern. Der Satz wird in Tokens zerlegt, jedes Token erhält eine feste Nummer (echte Werte, Tokenizer o200k_base). Über die Aufmerksamkeit rückt „Bank“ durch „Baum“ in die Nachbarschaft von „Park“; aus einer Wahrscheinlichkeitsverteilung wird das nächste Token gezogen und angehängt (eigene Darstellung; Bedeutungskarte und Werte schematisch). Die Fassung zum Durchklicken: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/vom-satz-zum-naechsten-wort.html aufrufen.

Was heißt hier GPT? Die drei Buchstaben stehen für *Generative Pre-trained Transformer* und benennen die drei Zutaten. *Generativ* heißt, dass das Modell eigenständig Texte erzeugt, indem es gelernte Muster neu kombiniert. *Pre-trained* heißt, dass es zuerst mit riesigen Textmengen **vortrainiert** wurde (**Pretraining**), und zwar *selbstüberwacht* (*self-supervised*): Die Trainingsaufgabe, das jeweils nächste Token vorherzusagen, steckt im Text selbst, niemand muss Lösungen beschriften. Danach bewerten Menschen verschiedene Antworten des Modells, und es lernt, die bevorzugten zu erzeugen (*Reinforcement Learning from Human Feedback*, **RLHF**); so wird aus einem Textfortsetzer ein Assistent, dessen Antworten verständlich und nützlich sind. *Transformer* heißt das Rechenverfahren im Kern, und sein Herzstück ist die **Aufmerksamkeit** (*Attention*): Für jedes Token gewichtet das Modell, welche anderen Tokens im Text für seine Bedeutung am wichtigsten sind. So zieht „Baum“ im Beispielsatz die „Bank“ in Richtung Park und weg vom Geldinstitut, wie Schritt 6 der Animation zeigt. Der Fachartikel von 2017, der das Verfahren vorstellte und die KI-Welle seit 2022 mit auslöste, trägt den knappen Titel „Attention is all you need“ (Vaswani et al., 2017); er wurde bis 2026 mehr als 200.000-fach zitiert.

Zwischen Eingabe und nächstem Token entstehen im Modell Zwischenschritte, die nie im Text erscheinen. Ein Befund aus der Studie, die Kapitel 2.2 ausführlich vorstellt, macht das sichtbar: Gefragt nach der Hauptstadt des Bundesstaats, in dem Dallas liegt, bildet das Modell intern zuerst „Texas“ und kommt erst darüber auf „Austin“ (Anthropic, 2025c; Lindsey et al., 2025).

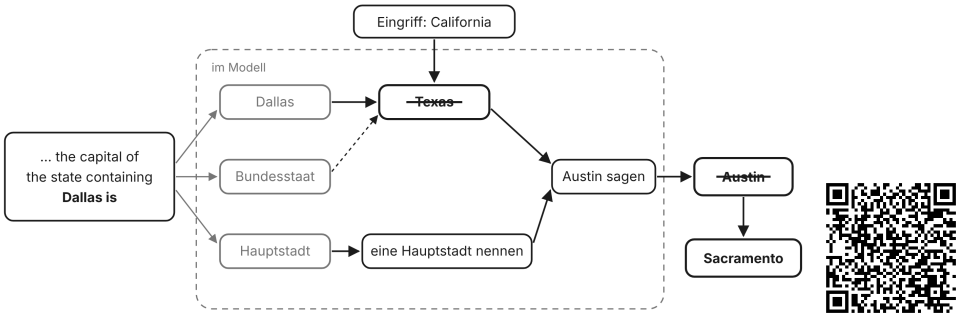

Abbildung 2.6. Vor der Antwort entsteht im Modell ein Zwischenschritt, der nie im Text steht. Aus „Dallas“ wird intern „Texas“, zusammen mit der Absicht, eine Hauptstadt zu nennen, ergibt das „Austin“; ersetzen Forschende den inneren Schritt „Texas“ durch „California“, antwortet das Modell „Sacramento“ (eigene Darstellung nach Lindsey et al. (2025) und Anthropic (2025c); Befund für Claude 3.5 Haiku, stark vereinfacht). Die Fassung zum Durchklicken: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/zwischenschritt-texas.html aufrufen.

Was das Modell bei einer Antwort berücksichtigen kann, begrenzt sein **Kontextfenster**, der Text, den es in diesem Augenblick vor sich hat; Kapitel 2.1.5 behandelt es ausführlich. Wer tiefer einsteigen will, findet im Transformer Explainer ein echtes kleines Sprachmodell zum Ausprobieren im Browser [Cho et al. (2025); https://poloclub.github.io/transformer-explainer/], bei Grant Sanderson ein siebenminütiges Erklärvideo (https://youtu.be/LPZh9BOjkQs), bei Brendan Bycroft eine dreidimensionale Animation der Rechenschritte (https://bbycroft.net/llm) und im frei verfügbaren Lehrbuch von Jurafsky & Martin (2025) die technischen Grundlagen.

2.1.3 Was nutzen: LLM, RAG oder Agent?

Schlau sein allein reicht nicht. Ein Sprachmodell muss intelligent genug sein, um eine Aufgabe zu lösen, aber auch der schlaueste helfende Geist hilft nur, wenn er den **Kontext unserer Aufgabe kennt**. Diesen Kontext können wir der KI auf zwei Arten geben: Bildlich gesprochen bekommt sie ein paar **Bücher oder einen Werkzeugkoffer**, präziser ausgedrückt RAG oder Werkzeuge, die zu den beiden vorherrschenden Mustern gehören (Huyen, 2025, Kap.6). Bei **RAG** (**Retrieval-Augmented Generation**) holt das System passende Stellen aus zusätzlichen Dokumenten wie Fachtexten, Statistiken oder Gesetzesbüchern und legt sie dem Modell zur Antwort vor: Die KI ist das Gehirn, die Dokumentsammlung das Bücherregal. Ein Agent beschafft sich Informationen dagegen selbst, mit Werkzeugen wie der Websuche. Die Unterschiede zwischen dem reinen Sprachmodell, dem Modell mit Bücherregal und dem Modell mit Werkzeugkoffer übt das folgende Spiel; überlegen Sie sich zu jeder Antwort ein Beispiel aus Ihrem Berufsalltag.

Lernspiel: LLM, RAG oder Agent, was sind mögliche Probleme und Anwendungsfelder?

Runter scrollen und "Los gehts!" auswählen, dann nacheinander die Interaktionen für LLM, RAG und Agent auswählen und die Fragen beantworten.

Abbildung 2.7. Lernspiel „LLM, RAG oder Agent?" (Probleme und Anwendungsfelder der drei Setups). Dieses interaktive Element gibt es nur in der Online-Version: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/llm-rag-agent-game.html aufrufen.

In der Lehre kann RAG verwendet werden, um den Studierenden

Fachtexte oder besonders aktuelle Informationen zur Verfügung zu stellen. Beispielsweise könnten Studierende in einem Geschichtsseminar eine KI befragen, die externe Quellen durchforstet, um aktuelle Erkenntnisse zu historischen Ereignissen zu präsentieren (Huffman & Hutson, 2024). Unternehmen nutzen diese Technik, um etwa riesige Gebrauchsanweisungen mit KI durchsuchbar zu machen (Brynjolfsson et al., 2025), oder Chatbots zu trainieren, die typische, repetitive Kundenanfragen beantworten (Handa et al., 2025).

Die drei Muster liegen auf einer Skala, und an ihr zählt nicht, ob ein System Quellen oder Werkzeuge hat, sondern wer den Ablauf bestimmt: in einem Workflow das Programm, in einem Agenten das Modell (Kapitel 2.1.1). Roucher et al. (2024) fassen den Übergang in eine Skala aus drei Sternen, die eine einzige Frage stellt: Wie stark bestimmt die Ausgabe des Modells, was das Programm als Nächstes tut? Ein Chatbot, der vor jeder Antwort passende Stellen aus den Skripten holt, bleibt danach auf der untersten Stufe, denn die Suche läuft immer, gleich was das Modell schreibt. RAG macht das Modell kundiger, nicht selbstständiger.

Ihre Einschätzung prüfen

„Ein Chatbot, der nur aus Ihrem Skript antworten soll, braucht keinen Agenten; es genügt ein Modell, das vor jeder Antwort passende Stellen aus dem Skript abruft."
Auflösung: ja. Ein Chatbot zum eigenen Skript ist ein Fall für RAG: Die Suche nach passenden Stellen läuft vor jeder Antwort, und das Modell bekommt ein Bücherregal, aber keinen Spielraum über den Ablauf. Einen Werkzeugkoffer und eigene Entscheidungen über die nächsten Schritte braucht diese Aufgabe nicht; ein Agent mit Internetzugang würde zudem Quellen jenseits des Skripts heranziehen.

Die folgende Animation baut den Weg vom Chatbot zum Agenten in dreizehn Schritten auf; die Bildfolge stammt von Grootendorst (2025b), die Schleife aus Denken, Handeln und Beobachten von Yao et al. (2023).

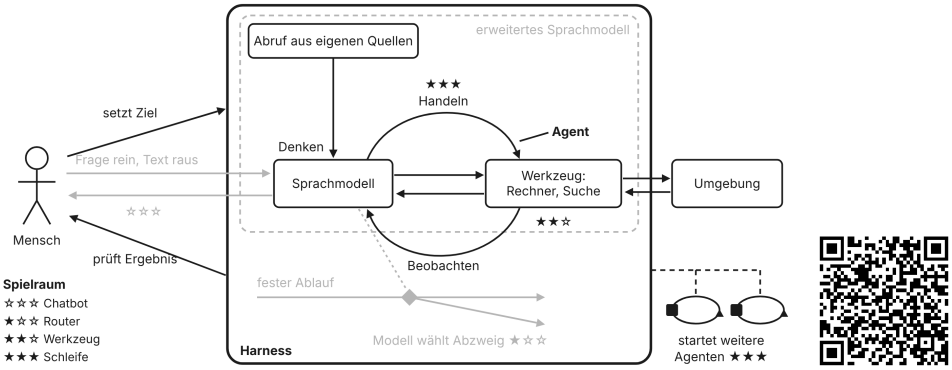

Abbildung 2.8. Vom Chatbot zum Agenten wächst vor allem der Spielraum des Modells. Im Chatbot ändert die Antwort nichts am Ablauf (□□□), und ein fester Abruf aus eigenen Quellen ändert daran nichts; als Router wählt das Modell zwischen vorgegebenen Abzweigen (□□□), mit Werkzeugen wählt es das Werkzeug (□□□), in der Schleife aus Denken, Handeln und Beobachten den nächsten Schritt (□□□). Der Harness umschließt alles, der Mensch setzt das Ziel und prüft das Ergebnis (Skala nach Roucher et al. (2024), Bildfolge nach Grootendorst (2025b); schematische Darstellung). Die Fassung zum Durchklicken: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/chatbot-zu-agent.html aufrufen.

2.1.4 Agenten in der Praxis: Skills, Werkzeuganschluss und eigene Quellen

Im Alltag der Lehre stellt sich die Frage nach dem Harness praktisch: Wann lohnt es sich, der KI einen Auftrag zu geben statt einer Frage, und wo muss ich dabei selbst entscheiden? Der Unterschied zum Chat ist die Strecke, die die KI allein zurücklegt: Im Chat sehen wir jede Antwort nach Sekunden, ein Recherche-Agent arbeitet Minuten, ein automatisierter Ablauf Stunden. Drei Bausteine des äußeren Harness kommen dabei besonders oft vor: Skills, der Werkzeuganschluss und eigene Quellen.

Ein **Skill** ist eine Gebrauchsanweisung, die der Agent bei Bedarf liest: ein Textdokument mit den Regeln, wie eine bestimmte Aufgabe in unserem Kurs zu erledigen ist, etwa wie Folien auszusehen haben oder wie eine Übungsaufgabe aufgebaut wird. Der Skill macht aus einem allgemeinen Modell einen Mitarbeiter, der die Hausregeln kennt, ohne dass wir sie in jedem Prompt wiederholen.

Was ein Skill im Alltag leistet, lässt sich in Minuten ausdrücken. Eine Lehrende lässt vier Wochen lang Feedback auf die Berichte von sechs Projektteams schreiben. In der einen Reihe erklärt sie der KI den Zusammenhang jede Woche neu, in der anderen schreibt sie ihn einmal auf eine Skill-Karte und trägt jede gelernte Regel dort nach.

Im Modell kostet die improvisierte Reihe nach vier Wochen 38 Minuten, die Reihe mit Karte 21, und nur oben kehrt ein schon behobener Fehler zurück, weil die Regel „keine Noten“ in Woche 4 vergessen wurde. Der Gewinn wächst, sobald die Karte den Schreibtisch verlässt: Kolleginnen und Kollegen, die sie übernehmen, beginnen mit allen Regeln, die in vier Wochen gelernt wurden. Die Produktion kennt dieses Prinzip als Standardarbeit, bei der jede Tätigkeit nach Inhalt, Reihenfolge, Zeit und Ergebnis festgelegt ist, damit jede Verbesserung auf einem bekannten Stand aufsetzt (Spear & Bowen, 1999). Ein Skill ist Standardarbeit für den Agenten. Die Kehrseite zeigt der letzte Schritt der Animation: Eine Karte verbreitet ihren Fehler ebenso vollständig wie ihre Verbesserungen. Wer einen Skill teilt, lässt ihn deshalb vorher von einer zweiten Person lesen.

Technisch ist ein Skill ein Ordner mit einer Anleitungsdatei und bei Bedarf weiteren Dateien. Damit fünfzig installierte Skills das Kontextfenster nicht füllen, liest der Agent beim Start nur Name und Kurzbeschreibung jedes Skills; die Anleitung lädt er erst, wenn eine Anfrage zur Beschreibung passt,

Abbildung 2.9. Einmal aufschreiben, oft verwenden. Oben wird der Zusammenhang jede Woche neu eingegeben, unten steht er auf einer Skill-Karte. Die Karte kostet in Woche 1 vier Minuten mehr, liegt ab Woche 2 vorn und verhindert, dass eine vergessene Regel die alte Panne zurückbringt (Lehrmodell, keine Messung). Die interaktive Fassung mit Vorhersage und einer fehlerhaften Karte: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/skill-karte.html aufrufen.

und Zusatzdateien nur, wenn die Anleitung auf sie verweist (B. Zhang et al., 2025). In den Nutzungsdaten eines verbreiteten Coding-Agenten verwenden 26,6 % der Nutzenden solche Skills (Johnston et al., 2026).

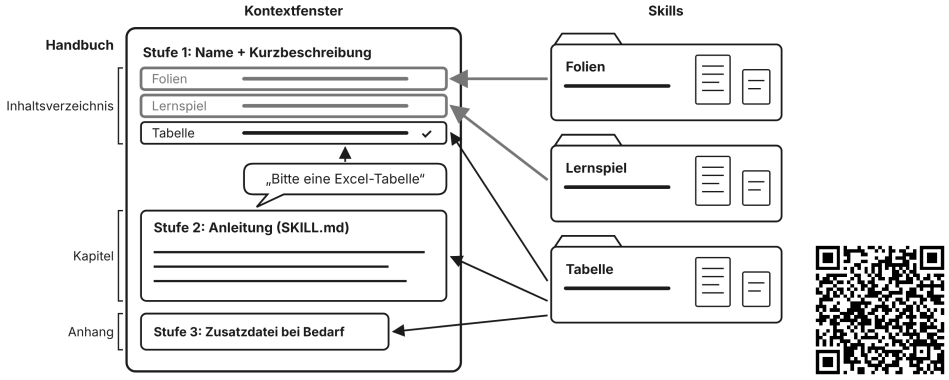

Abbildung 2.10. Ein Skill lädt sein Wissen erst, wenn es gebraucht wird. Im Kontextfenster liegen zunächst nur Name und Kurzbeschreibung jedes Skills; passt eine Anfrage, folgt die Anleitung dieses einen Skills, Zusatzdateien nur bei Bedarf, wie Inhaltsverzeichnis, Kapitel und Anhang eines Handbuchs (eigene Darstellung nach B. Zhang et al. (2025); schematisch). Die Fassung zum Durchklicken: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/skills-handbuch.html aufrufen.

Der **Werkzeuganschluss** über MCP (Kapitel 2.1.1) ist für Lehrende die Stelle, an der die KI aufhört, ein Textfenster zu sein, und anfängt, in unseren Systemen zu handeln: im Bibliothekskatalog, auf der Lernplattform, im Kalender.

Eigene Quellen sind der Sonderfall, der in der Lehre am häufigsten gebraucht wird. Die einfache Form ist ein Projekt oder Notebook im Chat-Interface, in das wir Skript, Übungsblätter und Musterlösungen laden; die anspruchsvolle Form ist ein eigener Tutor, der über RAG auf einer Dokumentablage sitzt (Lewis et al., 2020). Beide Formen haben denselben Schwachpunkt: Antwortet die KI aus den Quellen oder doch aus dem Training? Das lässt sich prüfen, indem man Fragen stellt, deren Antwort in den Quellen bewusst anders lautet als im Allgemeinwissen; diese Prüfidee kehrt in Kapitel D.3 und Kapitel D.7 wieder.

Was ändert sich mit der Delegation für die Lehre? Die Konsequenz ist

weniger technisch als organisatorisch. Die Forschung zur Automatisierung hat lange vor den Sprachmodellen beschrieben, dass sich für jede Stufe einer Aufgabe getrennt festlegen lässt, wie viel die Maschine entscheidet und wo der Mensch das Steuer behält (Parasuraman et al., 2000). Für Agenten in der Lehre heißt das: Wir legen vor dem Start fest, an welchen Punkten der Ablauf anhält und auf uns wartet. Bei einer Literaturrecherche sind das drei Stellen: der Quellenkorb, den der Agent durchsuchen darf, der Rechercheplan, bevor er loslegt, und die Stichprobe von Aussagen, die wir gegen das Original halten. Je länger die Strecke ohne Blick, desto wichtiger werden diese Punkte, und bei einem Tutor, den Studierende ein Semester lang ohne uns benutzen, ist sie am längsten.

Jeder Haltepunkt kostet Zeit, und diese Zeit lässt sich nicht vervielfachen. Agenten kann man parallel starten, ihre Ergebnisse landen aber auf demselben Schreibtisch. Nutzungsdaten eines Coding-Agenten zeigen, wie verschieden weit Organisationen auf diesem Weg sind: Bei seinen Organisationskunden arbeiten 67,4 % ohne parallele Agenten, bei OpenAI selbst arbeiten nur 10,7 % mit einem einzigen Arbeitsstrang, und 28,6 % steuern fünf oder mehr Agenten gleichzeitig , Belege und Grenzen in D.1. Das folgende Modell verfolgt eine einzelne Aufgabe, die Kugel A. Der Mensch gibt den Auftrag, ein Agent recherchiert und fasst zusammen, der Mensch entscheidet, wie es weitergeht, ein Agent rechnet und prüft, und am Ende gibt der Mensch das Ergebnis frei. Einmal läuft Kugel A allein, einmal als achte von acht Aufgaben, die der Mensch auf einmal abgibt; jede Aufgabe bekommt dabei ihren eigenen Agenten.

Kugel A wartet länger auf den Menschen, als alle Agenten zusammen an ihr arbeiten: 19,5 gegen 16 Minuten. Bei den Agenten bildet sich keine Schlange, weil jede Aufgabe ihren eigenen bekommt; vor dem Menschen füllt sich die Ablage, sobald die Kugeln schneller zurückkommen, als er entscheidet. Das ist die Logik jeder Warteschlange: Der Durchsatz eines Ablaufs richtet sich nach seiner langsamsten Station, und hier ist das der Mensch. Ein neunter Agent ändert daran nichts. Entscheidet der Mensch doppelt so schnell, ist Kugel A nach 28,5 statt 43,5 Minuten fertig und wartet nur noch sieben. Für die Lehre folgt daraus eine einfache Regel: Wir starten nur so viele Agenten, wie wir in der verfügbaren Zeit ernsthaft prüfen und entscheiden können, und wir beschleunigen Entscheidungen, indem wir ihre Kriterien vorab festlegen, nicht indem wir sie überspringen. Wie man Bestand, Durchsatz und Wartezeit an einer solchen Station rechnet, zeigt das Little's-Law-Widget in Kapitel 4.2.2.1.

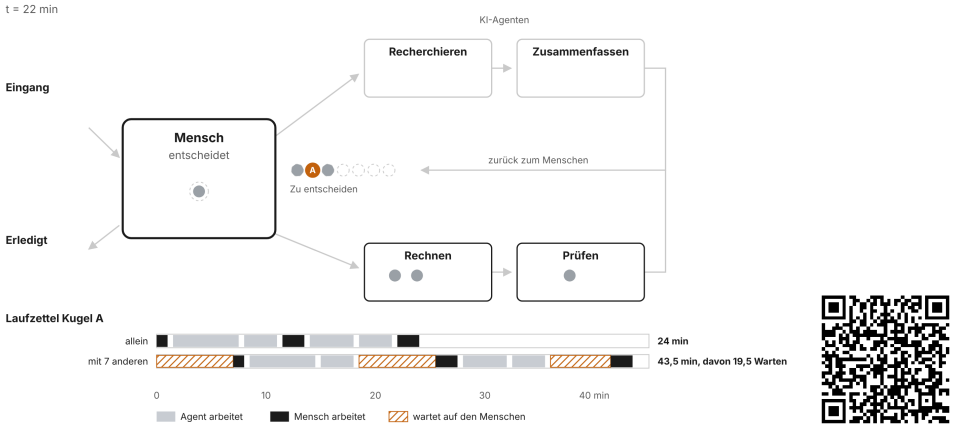

Abbildung 2.11. Mehr Agenten machen den Menschen zum Engpass. Der Mensch gibt Aufgaben ab, Agenten recherchieren, fassen zusammen, rechnen und prüfen, und zweimal kommt jede Aufgabe zum Entscheiden zurück. Das Standbild zeigt Minute 22 von acht gleichzeitig abgegebenen Aufgaben: Kugel A liegt in der Ablage „Zu entscheiden“, während die Agenten kaum zu tun haben. Der Laufzettel darunter: Allein ist Kugel A nach 24 Minuten fertig, als achte von acht nach 43,5 Minuten, davon 19,5 Minuten Warten auf den Menschen (Lehrmodell, keine Messung). Die interaktive Fassung mit Vorhersage und dem Schalter „Der Mensch entscheidet doppelt so schnell“: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/agenten-engpass.html aufrufen.

Die praktische Umsetzung dieser Bausteine steht in Anhang D: Arbeitsumgebung und Skills in Kapitel D.2, eigene Quellen in Kapitel D.3, Agenten für die akademische Suche mit ihren Kontrollpunkten in Kapitel D.4, automatisierte Abläufe in Kapitel D.6. Wie ein Projekt mit Unternehmen aussieht, in dem Studierende eine solche Quellenanbindung selbst aufbauen, zeigt Kapitel 6.3.5.

2.1.5 Gedächtnis: Was ein Agent von einer Sitzung in die nächste mitnimmt

Ein Sprachmodell erinnert sich nicht. Alles, was es bei einer Antwort berücksichtigt, steht in seinem **Kontextfenster**: dem Text, den es in diesem Augenblick vor sich hat, also Prompt, bisheriger Gesprächsverlauf, hochgeladene Dateien und die Ergebnisse seiner Werkzeuge (das Wort kommt vom lateinischen *contexere*, zusammenweben; der Kontext ist das Gewebe, in dem ein Satz erst Sinn ergibt). Das Kontextfenster ist ein Schreibtisch, kein Archiv. Was auf dem Tisch liegt, sieht das Modell vollständig; was nicht darauf liegt, existiert für die Antwort nicht; und am Ende der Sitzung wird der Tisch abgeräumt. Solange wir eine einzelne Frage stellen, stört das nicht. Ein Agent aber, der ein Semester lang Feedback schreibt, oder ein Tutor, der wissen soll, woran eine Studentin letzte Woche gescheitert ist, braucht neben dem Schreibtisch ein Archiv und eine Regel, was wann vom Archiv auf den Tisch kommt. Alles auf einmal hinzulegen ist keine Lösung: Ein voller Tisch kostet bei jeder Antwort Rechenzeit und Geld, weil das Modell ihn für jedes neue Token wieder vollständig einbezieht (Kapitel 2.1.2).

Für diese Regel haben sich in den Werkzeugen der Anbieter vier Stufen herausgebildet, die die folgende Abbildung nebeneinanderstellt. Auf der ersten Stufe liest der Agent zu Beginn jeder Sitzung eine Anleitungsdatei mit Befehlen, Stilregeln und Arbeitsabläufen. Das trägt, bis die Datei so lang wird, dass sie den Tisch füllt. Auf der zweiten Stufe bekommt der Agent Werkzeuge, mit denen er selbst entscheidet, wann er eine Erinnerung notiert, nachliest oder ändert, mitten in der laufenden Arbeit. Die dritte Stufe kennen wir schon als Skill aus Kapitel 2.1.4: Zu Beginn liegen nur Name und Kurzbeschreibung jeder Anleitung auf dem Tisch, die volle Anleitung holt der Agent erst, wenn die Aufgabe sie verlangt (B. Zhang et al., 2025). Auf der vierten Stufe wird das Gedächtnis zu einem gewöhnlichen Ordner mit Textdateien, den der Agent mit denselben Werkzeugen durchsucht und

pflegt wie jedes andere Verzeichnis. Der rote Faden durch alle vier Stufen: immer weniger vorab auf den Tisch, immer gezielter bei Bedarf aus dem Archiv. Die vierte Stufe hat einen Nebeneffekt, der für die Lehre wichtiger ist als für die Technik: Ein Ordner mit Textdateien lässt sich von Menschen öffnen, lesen und korrigieren.

Abbildung 2.12. Vom Spickzettel zum prüfbaren Archiv. Die vier Stufen unterscheiden sich darin, was wann ins Kontextfenster gelangt: bei der Anleitungsdatei alles von Anfang an, bei Memory-Werkzeugen nach Ermessen des Agenten, bei Skills erst der Überblick und dann die Details, beim Dateisystem nur das gezielt Gesuchte (schematische Darstellung). Die animierte Fassung: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/agenten-gedaechtnis.html aufrufen.

Die vier Stufen beschreiben, wie Erinnerungen auf den Tisch kommen; offen ist noch, wie aus Gesprächen überhaupt Erinnerungen werden. Milam & Gulli (2025) trennen dafür zwei Speicher. Die **Sitzung** (*Session*) hält ein Gespräch vollständig und in Reihenfolge fest; aus ihr baut der Agent vor jeder Antwort den Kontext neu. Das **Gedächtnis** (*Memory*) bewahrt über viele Sitzungen hinweg nur das Verdichtete: Nach einer Sitzung werden Kernpunkte herausgezogen, mit dem Vorhandenen zusammengeführt, Veraltetes wird ersetzt, und in der nächsten Sitzung holt der Agent nur das Passende zurück. Die Sitzung ist das Protokoll eines Gesprächs, das Gedächtnis das Wissen über viele Gespräche.

Ein Gedächtnis ist etwas anderes als RAG, auch wenn beide auf ein Archiv

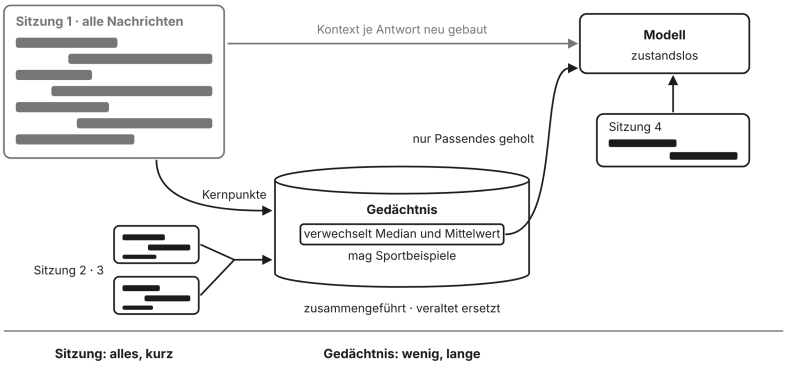

Abbildung 2.13. Die Sitzung schreibt alles mit, das Gedächtnis behält nur das Verdichtete. Ein Statistik-Tutor baut den Kontext für das zustandslose Modell aus der laufenden Sitzung; nach jeder Sitzung wandern Kernpunkte ins Gedächtnis, werden mit späteren Sitzungen zusammengeführt, und am vierten Abend holt der Tutor nur das Passende zurück (eigene Darstellung nach Milam & Gulli (2025); schematisch). Die Fassung zum Durchklicken: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/sitzung-und-gedaechtnis.html aufrufen.

zugreifen. Bei RAG liest das Modell in Dokumenten, die wir ausgewählt haben, und verändert sie nicht. Ins Gedächtnis schreibt der Agent selbst, und was er heute notiert, bestimmt, was er morgen für wahr hält. Damit stellen sich dieselben Fragen wie bei jedem gemeinsam bearbeiteten Dokument, und die Anbieter beantworten sie mit denselben Mitteln: Eine Änderung wird abgewiesen, wenn inzwischen eine andere Sitzung geschrieben hat, jede Änderung hinterlässt eine Version, und ein Speicher lässt sich nur zum Lesen einbinden, sodass ein Agent die Hausregeln kennt, aber nicht ändern kann (Anthropic, o. J.). Wer je eine Abschlussarbeit mit Versionsverlauf betreut hat, kennt alle drei Regeln.

Wann der Agent ins Gedächtnis schreibt, ist die zweite Gestaltungsfrage. Auf Stufe 2 geschieht es *in-band*, mitten in der Sitzung, so wie man ein Laborbuch während des Versuchs führt. Seit Mai 2026 gibt es zusätzlich Läufe *out-of-band*, bei Anthropic „Dreaming“ genannt: Ein eigener Durchgang liest den Speicher und frühere Sitzungen und schlägt eine überarbeitete Fassung vor, über deren Übernahme der Betreiber entscheidet (Anthropic, 2026b). Die Unterscheidung ist älter als die Technik. Donald Schön beschrieb in seiner Studie über Berufspraktiker zwei Formen des Nachdenkens: *reflection-in-action*, das Umsteuern mitten im Handeln, und *reflection-on-action*, den Blick zurück, wenn die Arbeit ruht (Schön, 1983). Das Wort Reflexion kommt vom lateinischen *reflectere*, zurückbeugen. Ein Agent, der in-band notiert, reflektiert im Handeln; ein Dream-Lauf reflektiert über das Handeln. Für die Lehre ist die Parallele mehr als ein Bild: Lerntagebuch und Nachbesprechung eines Praktikums sind genau diese beiden Formen, und wir wissen aus dem eigenen Unterricht, dass die zweite ohne die erste wenig Stoff hat.

Die Technik verschiebt die Verantwortung, sie nimmt sie nicht ab. Fachleute, die ein Bericht über Dreaming zu Wort kommen lässt, nennen drei Schwächen (Bridgwater, 2026). Ein Fehler, der einmal im Gedächtnis steht, wirkt in allen folgenden Sitzungen fort, statt wie im Chat mit dem Gespräch zu verschwinden. Die menschliche Prüfung der vorgeschlagenen Änderungen wird leicht zum Abnicken. Und eine Versionsgeschichte zeigt, *wer* etwas geändert hat, nicht, *ob* es stimmt. Hier kehrt der Haltepunkt aus dem vorigen Abschnitt wieder: Die Durchsicht des Gedächtnisses ist eine Station, an der der Mensch das Steuer behält (Parasuraman et al., 2000), und für sie gilt dieselbe Rechnung wie für die Agenten-Ergebnisse im Modell des Agenten-Engpasses. Wer mehr Änderungen erzeugen lässt, als er lesen kann, hat kein geprüftes Gedächtnis, sondern ein ungeprüftes mit

Freigabestempel.

Anwendungsbeispiel: Ein falscher Eintrag überlebt das Gespräch

Eine Lehrende lässt einen Agenten ein Semester lang das Wochenfeedback auf die Berichte von sechs Projektteams vorbereiten. Damit er nicht jede Woche von vorn beginnt, führt er ein Gedächtnis: je Team eine Datei mit dem Stand der Arbeit, den offenen Punkten und den Hinweisen der Vorwochen. In Woche 3 liest er aus dem Entwurf von Team 4 heraus, die Stakeholder-Analyse sei abgeschlossen, und trägt das ein; tatsächlich hatte das Team nur die Gliederung angelegt. Von da an spricht das Feedback die Stakeholder-Analyse nicht mehr an, Woche für Woche, denn für den Agenten ist sie erledigt. Erst in Woche 6 fällt der Lehrenden die Lücke auf. Korrigierte sie nur das Feedback dieser Woche, käme der Fehler in Woche 7 zurück, mit der Autorität eines längst geprüften Stands. Sie korrigiert deshalb den Eintrag im Gedächtnis und liest seitdem bei jedem Durchgang die geänderten Zeilen der Teamdateien, nicht nur das fertige Feedback. Das Beispiel ist konstruiert, der Mechanismus nicht.

Empfehlung für die Lehre

Wenn Studierende über ein Semester mit einem Agenten an einem Projekt arbeiten, lassen Sie das Team ein gemeinsames Projektgedächtnis führen: eine Textdatei mit Entscheidungen, offenen Fragen und geprüften Quellen, jeder Eintrag mit Datum und Namen. Der Agent liest sie zu Beginn jeder Sitzung und schlägt Ergänzungen vor; eingetragen wird erst, was ein Teammitglied gelesen hat. Zu jedem Meilenstein geht das Team die Datei gemeinsam durch, wie ein Dream-Lauf von Hand: Was ist überholt, was doppelt, was falsch? Prüfkriterium: Kann ein neues Teammitglied allein aus der Datei sagen, was entschieden ist und warum?

Das beendet unsere kurze Begriffsbestimmung; die Fachbegriffe des ganzen Buches mit ihrer Herkunft stehen im Glossar.

2.2 Wie denken Sprachmodelle und warum halluzinieren sie?

Eine Studie des KI-Labors Anthropic hat mit neuen Methoden den **Denkprozess eines Sprachmodells im Detail nachgezeichnet** (Lindsey et al., 2025), was uns erstmals etwas genauer verstehen lässt, wie Sprachmodelle mit verschiedenen Sprachen umgehen, wie sie den Schreibprozess „planen", wie sie bei Kalkulationen vorgehen, wie weit ihre Selbsterkenntnis reicht und warum sie manchmal Antworten erfinden („halluzinieren").

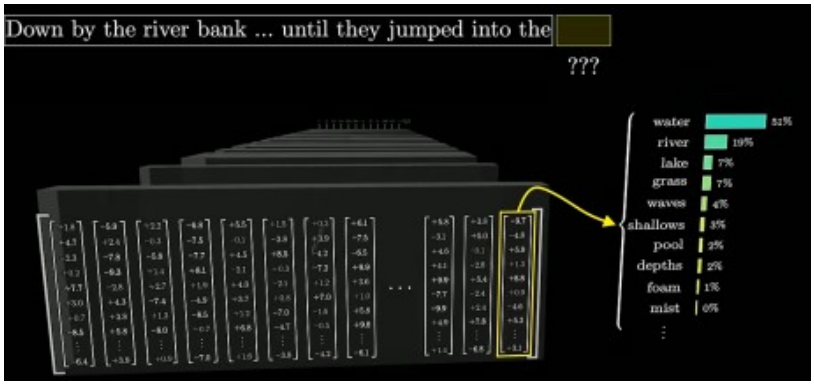

Abbildung 2.14. Visualisierte Gedanken eines Sprachmodells [@lindsey2025]

- **Sprachübergreifend gleich:** Das Modell nutzt einen gemeinsamen sprachübergreifenden Bedeutungsraum.
- **Textplanung:** Bei der Texterstellung plant das Modell mehrere Wörter im Voraus.
- **Paralleles Rechnen:** Für Kalkulationen nutzt das Modell parallele Rechenpfade, die am Ende verbunden werden.
- **Man traue nicht der Selbstkenntnis:** Das Modell erfindet manchmal Argumentationsketten (*motivated reasoning*).
- **Bekanntheit führt zu Halluzinationen:** Wenn das Modell eine genannte Entität „kennt" (hier: den Namen des Forschers, Karpathy), aber nicht die Antwort auf die Frage (Titel des Fachartikels) führt das zu erfundenen Antworten (die „can't answer"-Funktion wird unterdrückt).

Claude nutzt einen **gemeinsamen Bedeutungsraum für verschiedene Sprachen** – ein Hinweis auf eine Art „universelle Denksprache". Claude verarbeitet Informationen in einem sprachunabhängigen, abstrakten

Bedeutungsraum. Bei der Frage nach dem „Gegenteil von klein“ in verschiedenen Sprachen (z. B. Englisch, Französisch, Chinesisch) aktivieren sich im Modell dieselben internen Merkmale für „Kleinheit“ und „Gegenteil“, unabhängig von der Eingabesprache. Erst in einem späteren Schritt wird die Antwort in die jeweilige Zielsprache übersetzt. Diese Erkenntnis legt nahe, dass Claude Wissen und Konzepte sprachübergreifend anwenden kann.

Plant das Sprachmodell die Textgeneration? Entgegen der Annahme, dass Sprachmodelle Texte strikt Wort für Wort basierend auf dem unmittelbaren Kontext generieren, zeigt Claude die Fähigkeit, mehrere Wörter im Voraus zu planen. In Aufgaben zur Gedichtgenerierung identifiziert Claude beispielsweise Reimwörter, bevor es die vorhergehenden Zeilen formuliert. Ein Beispiel: Soll ein Gedicht mit dem Wort „Kaninchen“ enden, wählt Claude dieses Zielwort frühzeitig aus und gestaltet die Zeile so, dass sie darauf hinführt. Diese Fähigkeit zur Vorausplanung deutet darauf hin, dass Claude in der Lage ist, komplexe Textstrukturen zu erstellen, die über einfache Wortassoziationen hinausgehen.

Wie kalkulieren Sprachmodelle? Anthropic hat in seiner Studie zu Claude 3.5 Haiku detailliert untersucht, wie das Modell mathematische Berechnungen intern verarbeitet. Dabei wurde festgestellt, dass Claude bei Aufgaben wie der Addition von Zahlen parallele Rechenpfade nutzt, um zu einem Ergebnis zu gelangen. Claude verwendet zwei Hauptpfade, um Additionen durchzuführen: 1. **Grobabschätzung:** Ein Pfad schätzt das Ergebnis basierend auf den Größenordnungen der Zahlen. 2. **Präzise Berechnung:** Ein anderer Pfad fokussiert sich auf die genaue Berechnung, insbesondere auf die Bestimmung der letzten Ziffer der Summe.

Diese beiden Pfade arbeiten zusammen, um das finale Ergebnis zu erzeugen. Wenn beispielsweise der Pfad für die letzte Ziffer deaktiviert wird, liefert Claude nur eine grobe Schätzung, ohne die genaue Endziffer korrekt zu bestimmen.

Können wir das Modell fragen, wie es zu einem Ergebnis gekommen ist? Eher nicht. Anthropics Studie zeigt, dass das Modell bei komplexen Aufgaben manchmal überzeugende, aber erfundene Argumentationsketten präsentiert. Bei einfachen Berechnungen, wie der Quadratwurzel von 0,64, lassen sich klare interne Rechenschritte nachweisen. Bei schwierigeren Aufgaben, etwa der Berechnung des Kosinus einer großen Zahl, gibt Claude jedoch vor, Berechnungen durchgeführt zu haben, obwohl keine

entsprechenden internen Prozesse erkennbar sind. In solchen Fällen konstruiert das Modell plausible, aber unbegründete Erklärungen – ein Verhalten, das als „motiviertes Denken“ bezeichnet wird. Diese Fähigkeit, überzeugend zu argumentieren, ohne tatsächlich die zugrunde liegende Logik zu befolgen, kann für Nutzer irreführend sein. Die von Anthropic entwickelten Interpretationswerkzeuge ermöglichen es, solche untreuen Denkprozesse zu identifizieren, indem sie die tatsächlichen internen Abläufe des Modells sichtbar machen. Dies ist ein wichtiger Schritt, um die Zuverlässigkeit und Transparenz von KI-Systemen zu verbessern.

Was kann zu Halluzinationen führen? Wie wir im oben gezeigten Beispiel sehen, ist den Antworten des Sprachmodells nicht immer zu trauen. Das LLM verfügt über einen standardmäßig aktiven „Refusal Circuit“, der das Modell dazu bringt, keine Antwort zu geben, wenn es keine ausreichenden Informationen hat. Wenn eine bekannte Entität erfasst wird, aktiviert sich ein konkurrierender „Known Entity“-Mechanismus, der den Refusal Circuit hemmt und eine Antwort ermöglicht. Problematisch wird es, wenn Claude einen Namen erkennt, aber keine spezifischen Informationen dazu hat. In solchen Fällen kann der „Known Entity“-Mechanismus fälschlicherweise den Refusal Circuit unterdrücken, was zu einer Halluzination führt. Ein Beispiel: Bei der Frage nach einem Fachartikel des bekannten Forschers Karpathy gibt Claude einen erfundenen Titel an, da das Modell zwar den Namen kennt, in diesem Fall aber keine Informationen über den Artikel hat. Bei weniger bekannten Namen gibt das Modell an, die Antwort nicht zu kennen (Lindsey et al., 2025).

Ihre Einschätzung prüfen

„Dass ein Chatbot Quellen erfindet, ist ein Programmfehler, den die nächsten Modellversionen abstellen.“
Auflösung: nein. Erfundene Quellen folgen aus der Funktionsweise: Ein Sprachmodell erzeugt das wahrscheinlichste nächste Wort und prüft dabei keine Wahrheit, und erkennt es einen Namen, unterdrückt das die Antwort „weiß ich nicht“, auch wenn ihm das Wissen fehlt. Abstellen lässt sich das nicht, eindämmen schon: mit eigenem Material als Grundlage (Kapitel 2.1.3) und systematischer Prüfung der Ergebnisse (Kapitel 2.6.2).

2.3 Welches Modell wählen?

Was für Sprachmodelle gibt es? Hinter der Flut an Produktnamen stehen wenige Klassen, und zwei Fragen sortieren sie: Wie leistungsfähig ist das Modell, und wer hat die Daten in der Hand (Abbildung 2.15)? Jedes große KI-Labor bietet ein **großes Frontier-Modell** an, seine stärkste Variante (oft „Flaggschiff“ genannt), und daneben **kleine Varianten**, die schneller und billiger sind und in den kostenlosen Zugängen den Standard stellen. Die großen Modelle sind **Reasoning-Modelle**: Sie denken vor der Antwort in mehreren Schritten nach, und wie lange, lässt sich als Denkstufe einstellen (s. Kapitel 2.4). **Offene Modelle** legen ihre Gewichte offen; Hochschulen betreiben sie auf eigenen Rechnern, kleine Varianten laufen auf einem Arbeitsplatzrechner, und die Daten bleiben im Haus. Der Abstand zur Frontier ist kurz: Die besten offenen Modelle lagen 2026 im Mittel vier Monate zurück (Edwards & Emberson, 2026), Modelle für eine einzelne Grafikkarte sechs bis zwölf Monate (Somala & Emberson, 2025).

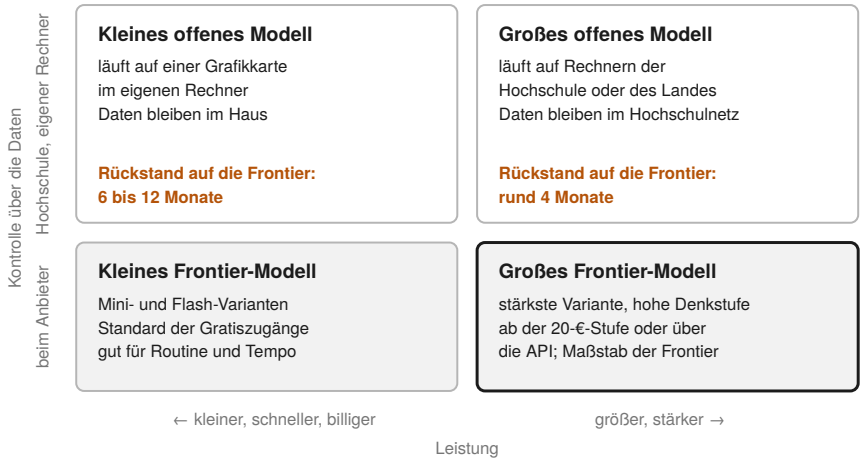

Abbildung 2.15. Vier Modellklassen nach Leistung und Kontrolle über die Daten. Wie groß der Rückstand der offenen Modelle ausfällt, hängt am gewählten Leistungstest; die Werte stammen aus Edwards & Emberson (2026) und Somala & Emberson (2025). Hochschulzugänge wie KI:connect.nrw bieten beide Zeilen. Eigene Darstellung.

Was kauft ein Abonnement? Die großen Anbieter haben ihre Preise angeglichen und staffeln sie in drei Stufen: kostenlos, rund 20 € und rund

100 € im Monat.[1] Der Schritt von 0 auf 20 € öffnet das große Modell mit hoher Denkstufe, den Recherche-Agenten und die Arbeit in Projekten. Der Schritt von 20 auf 100 € kauft kaum ein klügeres Modell, sondern Menge: etwa das Fünffache an Nachrichten und Agentenzeit (Abbildung 2.16). Die teuren Stufen kaufen vor allem mehr Stunden KI-Arbeit (E. Mollick, 2026b). Wer beurteilen will, was die Modelle können, etwa für die eigenen Prüfungen, bezahlt deshalb ein bis zwei Monate lang die 20-€-Stufe; die kostenlosen Zugänge zeigen ein zu schwaches Bild.

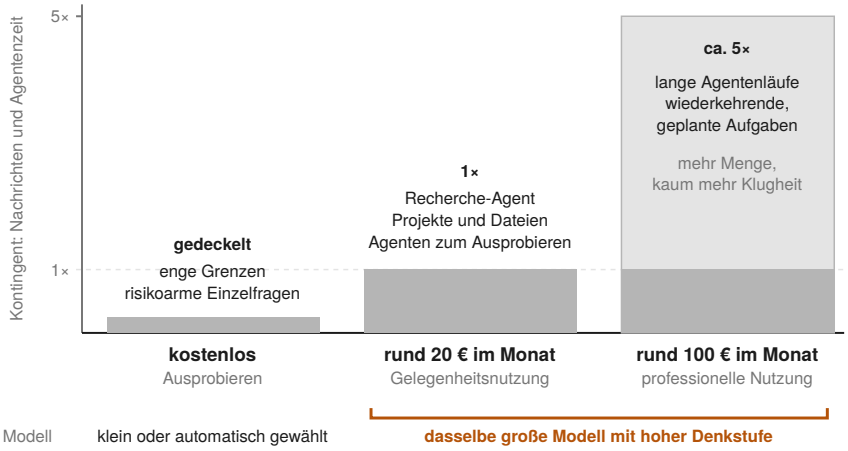

Abbildung 2.16. Was ein Abo kauft: Ab rund 20 € im Monat arbeitet das große Modell mit hoher Denkstufe; die 100-€-Stufe bringt dasselbe Modell mit etwa fünfmal so viel Kontingent. Eigene Darstellung nach den Preisseiten von OpenAI, Anthropic und Google, Stand Oktober 2026, und E. Mollick (2026b).

Seit der agentischen Wende Ende 2025, dem „Agentic Turn“ (E. R. Mollick, 2025a; Steinberger, 2025; Willison, 2025), zählt dabei nicht das Modell allein,

[1] Stand Oktober 2026, Monatspreise einschließlich Mehrwertsteuer. 20-€-Stufe: ChatGPT Plus 23 €, Google AI Pro 21,99 €, Claude Pro 20 US-$ zuzüglich Steuer; 100-€-Stufe: ChatGPT Pro 103 €, Google AI Ultra 99,99 €, Claude Max 100 US-$ zuzüglich Steuer. Darunter liegen Einstiegsstufen für 5 bis 8 € mit kleinerem Kontingent, darüber Stufen um 200 € mit dem Zehn- bis Zwanzigfachen der 20-€-Stufe. Der europäische Anbieter Mistral verlangt für seine Pro-Stufe 14,99 US-$ zuzüglich Steuer. Ohne persönliches Abo geht es über den Hochschulzugang, über die API mit Abrechnung nach Verbrauch (zur Größenordnung s. den Tutor-Kosten-Rechner in Kapitel 2.4) oder mit offenen Modellen auf eigener Hardware. Quellen: OpenAI (2026a), Anthropic (2026a), Google (2026), Mistral AI (2026).

sondern das ganze **Setup**: ein starkes Modell, eine praktische Oberfläche und ein Harness mit sinnvollen Werkzeugen (Kapitel 2.1.1) (E. Mollick, 2026a).

Kostenfreie Zugänge über die Hochschule. Hochschulen und Länder stellen Lehrenden Modelle beider Klassen bereit, die GWDG etwa über die Academic Cloud (https://chat-ai.academiccloud.de/), die TH Köln über das THKI-Lab (https://ki.th-koeln.de/login.php). In Nordrhein-Westfalen ist **KI:connect.nrw** der Zugang der ersten Wahl (https://chat.kiconnect.nrw/): Anmeldung mit dem Hochschul-Login, Frontier-Modelle über Verträge des Landes, offene Modelle auf landeseigenen Rechnern, Modellwechsel in jedem Chat und ein API-Zugang für eigene Werkzeuge (KI:connect.nrw, 2026; Ministerium für Kultur und Wissenschaft des Landes Nordrhein-Westfalen, 2025; Persike, 2025). Eine API (*Application Programming Interface*) ist die Schnittstelle, über die Programme statt Menschen mit dem Modell sprechen; was sich damit bauen lässt, zeigen Kapitel D.3 und Kapitel D.7. Vor dem Einsatz lohnt der Blick, welche Modellgeneration hinter einem Hochschulzugang steht: Eine ältere Generation oder eine kleine Variante vermittelt ein falsches Bild davon, was die Modelle können.

Welches Modell für welche Aufgabe? Drei Fragen führen zur Wahl. Zuerst die Daten: Personenbezogene Daten, Prüfungsleistungen und unveröffentlichte Forschung gehören in einen Hochschulzugang oder in ein offenes Modell auf dem eigenen Rechner. Dann die Aufgabe: Für eine kurze Frage genügt ein kleines Modell, für eine Lerneinheit oder ein selbst gebautes Werkzeug braucht es das große Modell mit hoher Denkstufe. Zuletzt die Häufigkeit: Wer täglich mit Agenten arbeitet, braucht eine Stufe mehr. Über allen drei Fragen steht eine Prüfregel. Muss das Ergebnis stimmen und lässt es sich nicht selbst prüfen, gehört die Aufgabe an das größte Modell mit der höchsten Denkstufe, und ein Mensch prüft das Ergebnis.

i Stand bei Drucklegung, November 2026

Die folgende Übersicht hält fest, welche Modelle bei Drucklegung die Klassen aus Abbildung 2.15 füllten und was die Stufen aus Abbildung 2.16 kosteten. Sie ist ein historischer Schnappschuss: Namen und Preise ändern sich, Klassen und Stufen bleiben.

1 Daten
Personenbezogene Daten, Prüfungsleistungen oder unveröffentlichte Forschung?

ja → **Hochschulzugang**
oder kleines offenes Modell auf dem eigenen Rechner

nein

2 Aufgabe: Ich will …	Modellklasse	Stufe
… eine Frage klären, einen Text überarbeiten	kleines Frontier-Modell	**0 €**
… ein Bild erstellen (Diagramme besser als Code)	Frontier-Modell mit Bildgenerator	**0 €**
… eine Lerneinheit, Folien, Aufgaben erstellen	großes Frontier-Modell, hohe Denkstufe	**20 €**
… regelmäßig recherchieren	großes Frontier-Modell mit Recherche-Agent	**20 €**
… ein Werkzeug bauen (Simulation, Lernspiel)	großes Frontier-Modell im Agentenmodus	**20 €**
… einen Tutor für Studierende betreiben	API (nach Verbrauch) oder Hochschule	**kein Abo**

3 Häufigkeit Täglich, auch mit langen Agentenläufen?
Dann eine Stufe höher: 0 → 20 €, 20 → 100 €.

Prüfregel
Muss das Ergebnis stimmen und können Sie es nicht selbst prüfen?
Größtes Modell, höchste Denkstufe, und ein Mensch prüft.

Abbildung 2.17. Welches Modell für welche Aufgabe? Drei Fragen führen zu Modellklasse und Preisstufe: Daten, Aufgabe, Häufigkeit; die Prüfregel gilt für jede Zeile. Stufen wie in Abbildung 2.16. Eigene Darstellung nach E. Mollick (2026b). Die Fassung zum Durchklicken: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/modellwahl-baum.html aufrufen.

Anbieter	Modellklassen	Stufen (Monatspreis)	Hinweis für die Lehre
OpenAI	groß: GPT-6 Astra, GPT-6.1 Sol; klein: GPT-6 Luna, GPT-5.6 Luna (Standard im Gratiszugang)	kostenlos · Go 8 € · Plus 23 € · Pro 103 €, 229 € oder 510 €	Bildgenerator und Sprachmodus; Recherche-Agent und Agentenmodus erweitert ab Plus; eigene „GPTs“ lassen sich als Tutoren teilen
Anthropic	groß: Claude Opus 5.5, darüber Claude Fable 5.1; klein: Claude Sonnet 5.5 und Haiku 5.5 (Gratiszugang)	kostenlos · Pro 20 US-$ · Max 100 US-$ (5×) · Ultra 200 US-$ (10×), jeweils zzgl. MwSt.	Kein Bildgenerator, Grafiken entstehen als Code; Artifacts für Lernspiele; Claude Code und geplante Aufgaben ab Pro; Fable in Pro nur über Nutzungsguthaben
Google	groß: Gemini 4 Argon; klein: Flash- und Flash-Lite-Varianten (Gratiszugang)	kostenlos · AI Plus 4,99 € · AI Pro 21,99 € · AI Ultra 99,99 € (5×) oder 219,99 € (20×)	Bild- und Videogenerator; sehr lange Kontexte für ganze Skripte; Gemini Notebook (früher NotebookLM) für Recherche in eigenen Quellen
Mistral (Vibe, früher Le Chat)	eigene Modelle, teils mit offenen Gewichten	kostenlos · Pro 14,99 US-$ zzgl. MwSt. (Studierende 5,99 US-$)	Europäischer Anbieter; Chat und Programmieragent in einem Produkt
Offene Modelle	Familien gpt-oss (OpenAI), Qwen (Alibaba), DeepSeek, Llama (Meta), Gemma (Google), Mistral	Gewichte frei verfügbar; Kosten nur für Rechner oder Hoster	Kleine Varianten lokal auf einer Grafikkarte, große über Hochschuldienste

KI:connect.nrw (Land NRW, RWTH Aachen)	GPT-5.6 (Sol, Terra, Luna) und GPT-6 (Astra, Sol, Luna) seit 1. Oktober 2026; Mistral, Qwen und gpt-oss als offene Modelle auf Landesinfrastruktur; Bild- und Einbettungsmodelle	kostenlos für Nutzende; Kontingente je Hochschule	Erste Wahl in NRW; Modellwechsel je Chat; OpenAI-kompatible API über selbst erzeugte Schlüssel (Freigabe je Hochschule)
GWDG und Hochschulen	wechselnde Auswahl offener und kommerzieller Modelle	kostenlos für Nutzende	Academic Cloud (Registrierung mit Hochschuladresse), THKI-Lab; vor dem Einsatz prüfen, welche Modellgeneration hinterlegt ist

Tabelle 2.3. Modelle und Preisstufen bei Drucklegung. Preise laut Preisseiten der Anbieter, Stand Oktober 2026, Euro-Beträge einschließlich Mehrwertsteuer. Quellen: OpenAI (2026a), Anthropic (2026a), Google (2026), Mistral AI (2026), IT Center der RWTH Aachen (2026).

Die lebende Fassung dieser Übersicht wird online semesterweise aktualisiert.
Die lebende Modellübersicht finden Sie online unter https://th-koln-bartnik.github.io/genai4teaching/modelluebersicht.html.

Abbildung 2.18. Lebende Modellübersicht, semesterweise aktualisiert: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/modelluebersicht.html aufrufen.

i Anwendungsbeispiel: Der Kurs-Bot steht bereit, aber kaum jemand lernt mit ihm

Problem ohne KI. Zwischen den Veranstaltungen bleiben Fragen zum Material liegen, und Lehrende erfahren kaum, woran ihre Studierenden hängen.
Problem mit KI. Ein Chatbot über die Kursmaterialien ist schnell gebaut. Ob er das Lernen fördert, entscheidet sich aber nicht an der Technik, sondern an seiner Einbindung in den Kurs.
Das Dilemma. Mit „Lecture as Code“ hat Nane Kratzke an der TH Lübeck eine Infrastruktur geschaffen, die inzwischen über 20 Lehrveranstaltungen aller Fachbereiche nutzen. Lehrende legen Folien, Skripte und Aufgaben in einem Verzeichnis ab; ein Bot antwortet daraus per RAG und ist über Moodle erreichbar, im Programmieren ohne fertige Lösungen. Zwei Spannungen bleiben. Datenschutz und Unabhängigkeit sprechen für selbst betriebene offene Modelle, die Antwortqualität vorerst für kommerzielle, weil kleinere offene Modelle beim Erschließen von Zusammenhängen aus dem Material noch zu oft halluzinieren. Und wirksam wird der Bot nach den Erfahrungen in Lübeck nur durch begleiteten Einsatz in der Veranstaltung, etwa kleine

Übungseinheiten und gemeinsam durchlaufene Tests, nicht durch das bloße Bereitstellen eines Links (Tobor et al., 2026, S.38).
Was das für wirksames Lernen heißt. *Erfahrungsbericht.* Die großen Feldversuche zeigen dasselbe: Wo ein Tutor nur bereitgestellt wird, nutzen ihn wenige, und dann als Antwortmaschine (Liu et al., 2026); erst eine Anleitung zur tutoriellen Nutzung hebt die Prüfungsleistung (Gallegos, 2026) (Kapitel 3.5).
Quelle: Tobor et al. (2026), S. 36–39.

Hier kann man vergleichen: In der LM-Arena kann man verschiedene Modelle ausprobieren und ihre Antwort auf eine bestimmte Frage gegenüberstellen: https://lmarena.ai/de?mode=side-by-side (Untermenü: „Arena (side-by-side)“).

2.4 Was können die Modelle – und was nicht?

Was für Aufgaben LLMs beherrschen ist sehr uneinheitlich und **verändert sich dynamisch**. Es gibt Bereiche, in denen KI auf menschlichem Niveau oder besser agiert, und andere, oft nur geringfügig andersartige Aufgaben, an denen die KI (noch) scheitert (Dell'Acqua et al., 2023). Mollick und Kollegen prägen hierfür den Begriff einer „**Jagged Technological Frontier**“ (zerklüftete Technik-Grenze) (Dell'Acqua et al., 2023). Zwei Aufgaben von ähnlicher Schwierigkeit für Menschen können mit sehr unterschiedlicher Qualität durch ein LLM gelöst werden – eine liegt innerhalb der KI-Frontier (d. h. die KI kann sie lösen), die andere außerhalb (KI liefert unbrauchbare oder falsche Resultate) (Dell'Acqua et al., 2023).

In einem Experiment mit Consultants wurden 18 verschiedene Beratungsaufgaben gestellt. Für die meisten („inside the frontier“) brachte KI enorme Vorteile, doch bei einer gezielt außerhalb der Frontier gewählten Aufgabe schnitt die KI-Gruppe deutlich schlechter ab: Hier waren die Consultants in der Gruppe mit KI 19 Prozentpunkte weniger häufig korrekt als die ohne KI (Dell'Acqua et al., 2023). Dieses Ergebnis unterstreicht die

Gefahr, LLMs unkritisch auf Probleme anzuwenden, die ihre jeweiligen Fähigkeiten übersteigen – die Leistung fällt dann hinter menschliches Niveau zurück. Praktisch bedeutet die Jagged Frontier, dass Organisationen und Individuen lernen müssen, die Grenze der KI-Fähigkeiten zu erkennen und entsprechend zu navigieren (Dell'Acqua et al., 2023).

> **Ihre Einschätzung prüfen**
>
> *„Wenn ein Modell die schwierigen Aufgaben Ihres Fachs löst, können Sie sich bei den leichteren erst recht auf es verlassen."*
> **Auflösung: nein.** Die Fähigkeiten der Modelle folgen nicht unserer Vorstellung von schwer und leicht. Zwei für Menschen ähnlich schwierige Aufgaben können auf verschiedenen Seiten der zerklüfteten Grenze liegen, und bei der Aufgabe jenseits der Grenze lagen die Consultants mit KI 19 Prozentpunkte seltener richtig als ohne. Wo die Grenze im eigenen Fach verläuft, zeigt nur der Test an den eigenen Aufgaben.

Für folgende Anwendungsfälle sind starke Sprachmodelle gut nutzbar (Handa et al., 2025; Korinek, 2024; Schwarcz et al., 2025):

- Zusammenfassung von Fachartikeln
- Fortgeschrittene mathematische Ableitungen
- Anspruchsvolle Codierungsaufgaben
- Erstellen eines Podcasts zu einer Forschungsarbeit
- Erstellen von Präsentationsfolien
- Verfassen von Blogbeiträgen
- Simulieren von Interviews über den Sprachmodus der Chat-Interfaces
- KI-gestützte Suche (mit kritischer Prüfung natürlich)

Die Fähigkeiten der Modelle wachsen rasant und damit werden die Aufgaben, die man an sie delegieren kann komplexer. Ein anschauliches Maß dafür ist der **Zeithorizont**: die Dauer, die Fachleute für eine Aufgabe brauchen, die ein Modell in der Hälfte der Fälle löst (Kwa et al., 2025). Er stieg von rund 4 Minuten bei GPT-4 (März 2023) auf rund 17 Stunden bei einer frühen Fassung von Claude Mythos Preview (April 2026) und verdoppelte sich seit 2023 etwa alle 129 Tage, also gut alle vier Monate (METR, 2026). Den letzten Wert ordnet METR selbst als unsicher ein, weil die Testaufgaben über 16 Stunden nicht mehr für eine verlässliche Messung reichen; die Fähigkeiten sind ihrem Maßstab entwachsen.

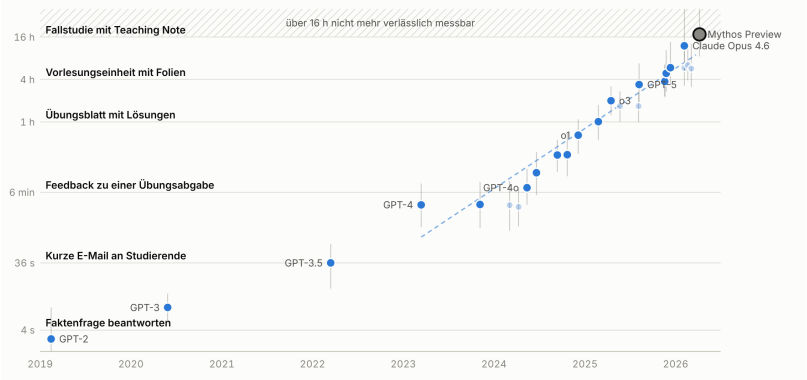

Abbildung 2.19. KI-Agenten bewältigen immer längere Aufgaben: 50-%-Zeithorizont der Modelle 2019–2026 auf logarithmischer Achse, mit 95-%-Intervallen und Trend ab 2023 (gestrichelt). Links stehen Lehraufgaben ähnlicher Dauer zur Orientierung (eigene Zuordnung). Über 16 Stunden ist die Messung nicht mehr verlässlich. Daten: METR (2026), Stand 8. Mai 2026. Interaktive Fassung: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/ki-entwicklung.html?zeige=zeithorizont aufrufen.

Auch die Bewertung von Forschungsarbeiten im Rahmen des Peer-Reviews wird zunehmend teil-automatisiert, etwa durch die automatische Prüfung von Quellen oder Code und Teilbewertungen durch Dienste wie Veracity oder Paper Wizard (Lovely, 2025; Naddaf, 2025).

Ist das ein Mensch, oder ein Bot? Sprachmodelle bestehen den Turing-Test: In einem randomisierten Drei-Parteien-Test mit über 1.000 Spielen hielten die Befragten ein Flaggschiff-Modell mit Persona-Prompt in 73 % der Fälle für den Menschen, häufiger als die echten Menschen der Vergleichsgruppe (Jones & Bergen, 2025).

Auch durch diesen Fähigkeitsschub ist der **Einsatz von Sprachmodellen in Support-Funktionen wie Call Centern stark gestiegen**, empirische Studien belegen hier einen starken Produktivitätszuwachs (Brynjolfsson et al., 2025).

Den Fähigkeitszuwachs beschreiben zwei **Scaling Laws** (E. R. Mollick, 2025a; anschaulich bei Grootendorst, 2025a): Modelle werden besser, je mehr Daten, Rechenleistung und Parameter ins Training fließen (**Training Scaling Law**), und sie liefern bessere Lösungen, je mehr „**Denkzeit**“ sie

vor der Antwort für zusätzliche interne Rechenschritte erhalten (**Inference Scaling Law**), so wie ein Mensch, dem man mehr Zeit für eine schwierige Aufgabe gibt; auf diesem zweiten Gesetz beruhen die Reasoning-Modelle (Gottweis et al., 2025; OpenAI, 2024; Schwarcz et al., 2025). Ist ein Modell einmal trainiert, bleiben die **Grenzkosten der Nutzung sehr niedrig**, und personalisierte Lernangebote lassen sich kostengünstig skalieren (E. R. Mollick, 2025a).

Wie schnell die Preise fallen, zeigt eine Auswertung von Epoch AI. Die niedrigsten Kosten, mit denen ein Modell 75 % der Fragen des GPQA Diamond richtig beantwortet, einer Sammlung von 198 naturwissenschaftlichen Multiple-Choice-Fragen auf Promotionsniveau, sanken von 29,9 US-Cent je Frage im Januar 2025 auf 0,04 Cent im Juli 2026, um den Faktor 725 (Emberson & Roodman, 2026). Der Preis fiel also in 17 Monaten um 99,9 %. Den größten Zuwachs brachte der letzte Schritt im Juli 2026: Der Preis fiel dabei nur um 66 %, doch dieselben 30 Cent kauften danach 479 Fragen mehr, mehr als alle früheren Stufen zusammen. Für solche Sprünge nennt Epoch AI mögliche Gründe, ohne sie einzeln nachzuweisen: Reasoning-Modelle holen aus kleineren, je Token billigeren Basismodellen dieselbe Leistung; das neue Modell erreichte die Schwelle schon mit niedrigem Denkaufwand, also mit wenigen Denk-Token je Frage; und wer ein Leistungsniveau zuerst erreicht, kann nur kurz einen Aufpreis verlangen, bevor Konkurrenten mit offenen und geschlossenen Modellen aufholen (Emberson & Roodman, 2026).

Was das für die Lehre bedeutet, zeigt ein Tutor-Bot, dem 150 Studierende an den 98 Tagen eines Semesters je zwei Fragen pro Tag stellen, zusammen 29.400 Fragen. Auf der Rechengrundlage von Epoch AI kostete dieses Semester anfangs rund 8.800 US-Dollar und im Juli 2026 rund 12 US-Dollar, je Person also 59 US-Dollar und 8 Cent. Das ist nur eine Größenordnung, denn ein Tutorgespräch ist länger als eine Testfrage, aber sie verschiebt die Frage von „Können wir uns das leisten?“ zu „Wer prüft, was der Tutor sagt?“.

Dieses exponentielle Wachstum unterscheidet KI grundlegend von bisherigen technologischen Entwicklungen, bei denen Verbesserungen oft linear verliefen.

Zum Standardumfang der großen Chat-Interfaces gehören inzwischen vier **Funktionsklassen**, die den Einsatz in der Lehre erweitern: **Bildgenerierung** für Visualisierungen, **Audio-Modelle** mit steuerbarem Tonfall für

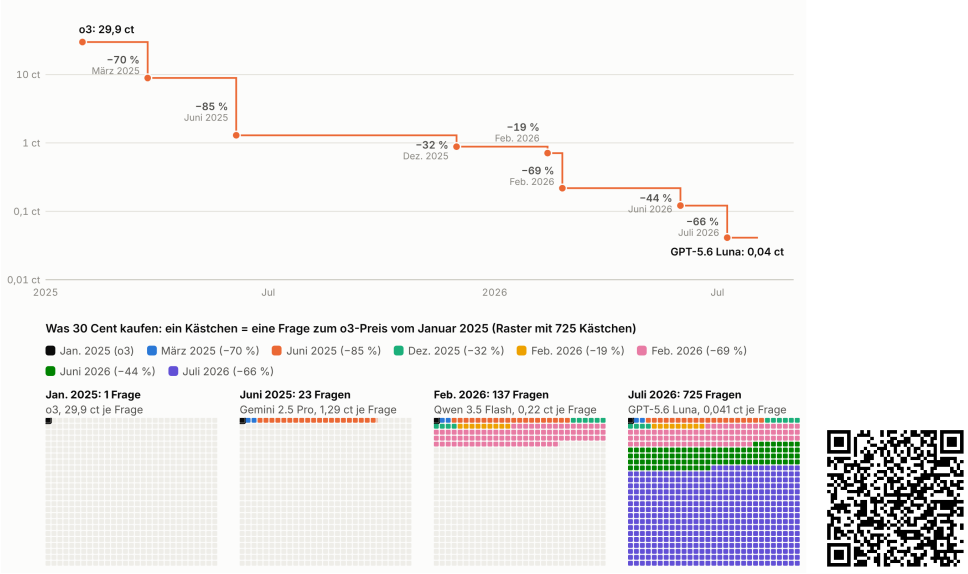

Abbildung 2.20. Expertenwissen wird 725-mal billiger: niedrigste Kosten je Frage (API-Preise, logarithmische Achse), mit denen ein Modell 75 % des GPQA Diamond richtig beantwortet, Januar 2025 bis Juli 2026. An jeder Stufe steht, um wie viel die Kosten gegenüber dem bis dahin günstigsten Modell fielen; die größten Sprünge lagen im Juni 2025 (−85 %) und im März 2025 (−70 %). Unten dieselben Stufen als Raster: Ein Kästchen ist eine Frage zum o3-Preis vom Januar 2025, gefüllt ist, was 30 Cent zum jeweiligen Zeitpunkt kaufen. Jede Preisstufe hat eine eigene Farbe, so dass die Fläche zeigt, wie viel ein Schritt ausmachte. Der letzte Sprung (−66 %) bringt mit 479 Kästchen mehr als alle früheren zusammen, obwohl der Preis prozentual weniger fiel als im Juni 2025; so sieht gleichmäßiger exponentieller Preisverfall auf linearer Skala aus. Insgesamt fiel der Preis in 17 Monaten um 99,9 %. Rasterdarstellung nach einer Idee von E. R. Mollick (2026b). Daten: Emberson & Roodman (2026), Epoch AI. Interaktive Fassung, in der sich das Raster Stufe für Stufe füllt: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/ki-entwicklung.html?zeige=kosten aufrufen.

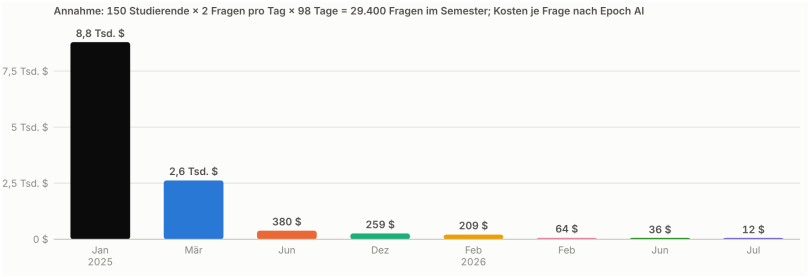

Abbildung 2.21. Was ein Tutor-Bot im Semester kostet: 150 Studierende stellen je 2 Fragen pro Tag an 98 Tagen (29.400 Fragen); jede Frage kostet so viel wie eine GPQA-Diamond-Frage mit dem günstigsten Modell, das 75 % richtig beantwortet. Von rund 8.800 US-$ (o3, Januar 2025) auf rund 12 US-$ (GPT-5.6 Luna, Juli 2026). Die Balken tragen dieselben Stufenfarben wie das Raster in Abbildung 2.20. Nur Größenordnung: Tutorgespräche sind länger als Testfragen. Daten: Emberson & Roodman (2026). Interaktive Fassung mit eigenen Kurszahlen: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/tutor-kosten.html aufrufen.

Rollenspiele und barrierefreie Inhalte, **Research-Harnesses** („Deep Research“) für Literatursichtung und Projektarbeiten sowie günstige **Mini-Varianten der Reasoning-Modelle** (s. die Beispiele in Kapitel 1).

Es lassen sich nach dieser Studie **zwei Kooperationsmodelle zwischen Mensch und LLM** unterscheiden, um die Technologiegrenze optimal auszunutzen (Dell'Acqua et al., 2023): Der **Centaur-Ansatz** teilt die Aufgabe, indem der Mensch der KI die Teilprobleme überlässt, die innerhalb der Frontier liegen, und sich selbst auf den Rest konzentriert. Der **Cyborg-Ansatz** integriert die KI tiefer, indem der Mensch kontinuierlich mit der KI interagiert und Feedback-Schleifen nutzt. Beide setzen implizit voraus, dass der Nutzer um die Stärken und Schwächen des LLM weiß.

Mit stärkeren Agenten kommen Arbeitsweisen hinzu, in denen der Mensch nicht mehr in jeder Schleife sitzt. Als **Beschwörer** (*conjurer*) ruft er Agenten bei Bedarf herbei, weist ihnen Arbeit zu und bewertet, was zurückkommt; den Weg dorthin begleitet er nicht mehr. Mollick hält sie für die leistungsfähigste Arbeitsweise; sie bringt aber neue Risiken, weil niemand mehr genau sieht, wie die KI zu ihren Ergebnissen kommt (E. R. Mollick, 2026b). Am Ende der Reihe steht die **dunkle Fabrik** (*dark factory*): Menschen legen fest, was entstehen soll, Maschinen führen aus und prüfen.

Sie trägt nur dort, wo eine Maschine feststellen kann, ob ein Ergebnis stimmt, etwa bei Software mit automatischen Tests (E. R. Mollick, 2026a). Dazwischen liegt Mollicks **Dämmerfabrik** (*twilight factory*): Agenten arbeiten, aber ein vermittelnder Agent holt Menschen hinzu, wenn eine Freigabe nötig ist, Fachwissen fehlt, die Ideen zu gleichförmig werden oder eine Entscheidung interessant ist (E. R. Mollick, 2026a). Für die Lehre wiegt der letzte Anlass am schwersten. Wer nur Freigaben und Ausnahmen bearbeitet, übt nie das Urteilen, das eine gute Freigabe voraussetzt, und die Fachleute, die künftig prüfen sollen, wachsen nicht nach (E. R. Mollick, 2026a). Das folgende Schema ordnet die fünf Arbeitsweisen den Schritten einer Aufgabe zu.

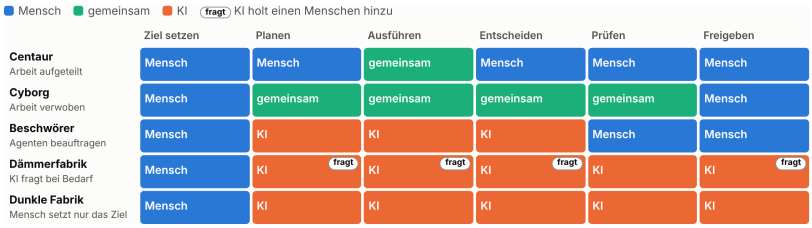

Abbildung 2.22. Mit jeder Arbeitsweise gibt der Mensch mehr Arbeitsschritte an die KI ab: Konzeptschema, keine Messdaten. „fragt“ markiert die Schritte, an denen der Agent in der Dämmerfabrik einen Menschen hinzuholt. Begriffe nach Dell'Acqua et al. (2023), E. Mollick (2024), E. R. Mollick (2026b) und E. R. Mollick (2026a); die Zuordnung der Schritte ist eine eigene Lesart. Interaktive Fassung zum Abschalten der Anlässe: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/ki-entwicklung.html?zeige=arbeitsweisen aufrufen.

Wie sich das im Alltag von Lehrenden anfühlt, zeigt das folgende Durchspiel an einer einzigen Aufgabe: einem Übungsblatt zur optimalen Bestellmenge mit vier Gruppenvarianten. Als Centaur lässt die Professorin nur den Aufgabentext formulieren; als Cyborg entwickelt sie die Aufgabe in zwölf kurzen Wechseln mit der KI. Als Beschwörer schreibt sie einen einzigen Auftrag. Ein **Orchestrator**, das Programm, das eine Aufgabe zerlegt, verteilt und die Teile wieder zusammenführt, beauftragt daraufhin **Unteragenten**, eigenständige KI-Instanzen mit je eigenem Auftrag, die voneinander nichts wissen: einen für die Zahlen, einen für die Texte, einen für die Prüfung (Anthropic, 2025a; Schluntz & Zhang, 2024). (Das Wort kommt von griechisch *orchēstra*, dem Tanzplatz vor der Bühne; der Orchestrator ordnet, wer wann auftritt.) Von nun an findet das meiste Gespräch zwischen den

Agenten statt, und eine Zwischenentscheidung, eine unrealistische Zahl zu ändern, trifft der Orchestrator selbst. In der Dämmerfabrik fragt ein Vermittler-Agent die Professorin bei den vier Anlässen, und während er auf ihre Antwort wartet, bauen die Agenten schon an den nächsten Blättern. In der dunklen Fabrik bestehen alle Blätter die maschinelle Prüfung und werden doch still leichter, weil der Prüfer misst, ob die Lösungen stimmen, nicht ob die Aufgaben fordern. Die Online-Fassung spielt zwei weitere Fälle durch. Bei Rückmeldungen auf Projektberichte endet die Reihe vor der dunklen Fabrik, weil KI-Systeme, die Lernergebnisse bewerten, nach der KI-Verordnung als Hochrisiko gelten und menschliche Aufsicht verlangen (Europäisches Parlament und Rat der Europäischen Union, 2024, Anhang III Nr. 3 lit. b); mehr dazu in Kapitel 5.5.2. Bei der Aktualisierung einer Vorlesung sucht der Agentenschwarm in die Breite, aber die Auswahl bleibt beim Menschen, weil kein Prüfer messen kann, ob eine Studie auf die Folie gehört. Die Denkspuren darin sind angenähert; auch echte Denkspuren geben nicht verlässlich wieder, wie ein Modell zu seinem Ergebnis kommt (Y. Chen et al., 2025).

Dieselbe Aufgabe in fünf Arbeitsweisen: Übungsblatt zur Bestellmenge

Nachgestellte, gekürzte Dialoge und angenäherte Denkspuren; Zähler als Lehrmodell. Kästchen von links: Ziel, Planen, Ausführen, Entscheiden, Prüfen, Freigeben; blau Mensch, grün gemeinsam, orange KI; umrandet: Schritt, an dem die KI in der Dämmerfabrik einen Menschen fragt.

ARBEITSWEISE	MENSCH ↔ KI	KI ↔ KI · DENKSPUR	WER MACHT WAS
Centaur Arbeit aufgeteilt	„Formuliere einen Aufgabentext … ohne Lösung.“ KI liefert den Text; die Professorin rechnet selbst.	`Nur Text gefragt. Lösungsweg nicht verraten.`	Mensch: 2 KI entscheidet: 0 Agenten: 0
Cyborg Arbeit verwoben	„Aufgabe mit Haken.“ – „Rabatt ab 2.000 Stück?“ – „So, dass es knapp wird.“ – … zwölf Züge.	`Rabatt so legen, dass Lagerkosten den Vorteil fast aufheben.`	Mensch: 6 KI entscheidet: 0 Agenten: 0
Beschwörer Agenten beauftragen	Auftrag: „drei Aufgaben, vier Varianten, Musterlösung“. Bericht: „Den Haltekostensatz in C3 habe ich selbst von 80 % auf 25 % gesenkt.“	`Orchestrator → „Zahlen“: zwölf Sätze, Python, keine Texte. Prüfagent: „C3 unrealistisch.“`	Mensch: 2 KI entscheidet: 3 Agenten: 4
Dämmerfabrik KI fragt bei Bedarf	Ein Auftrag fürs Semester. Vermittler fragt viermal, z. B.: „Sensitivitätsanalyse oder Rabattstaffel? Welches dient Lernziel 3?“	`Vermittler: „Lernziel-Abwägung ist eine interessante Entscheidung, also fragen.“`	Mensch: 5 KI entscheidet: 9 Agenten: 6 Rückfragen: 4
Dunkle Fabrik Mensch setzt nur das Ziel	Ein Satz fürs Semester: „Alle Lösungen werden maschinell nachgerechnet.“ Danach kein Mensch mehr.	`„Aufgaben ohne Rabatt bestehen sicher.“ Alle Prüfungen grün, die Blätter werden leichter.`	Mensch: 1 KI entscheidet: alle Agenten: 5

Begriffe nach Dell'Acqua et al. (2023) und Mollick (2024; „Agency and agents“ und „30 months on the exponential“, 2026); Muster nach Schluntz & Zhang (2024); Denkspuren geben das Vorgehen eines Modells nicht verlässlich wieder (Chen et al., 2025).

Abbildung 2.23. Dieselbe Aufgabe in fünf Arbeitsweisen: Je weiter rechts im Raster die KI übernimmt, desto weniger spricht der Mensch und desto mehr sprechen die Agenten miteinander. Dialoge nachgestellt und gekürzt, Denkspuren angenähert, Zähler als Lehrmodell; die Zahlen im Übungsblatt sind nachgerechnet. Muster nach Schluntz & Zhang (2024). Interaktive Fassung mit zwei weiteren Fällen (Projektberichte, Vorlesung): QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/ki-arbeitsweisen-durchspiel.html aufrufen.

Eine spätere Studie des weitgehend selben Teams mit 776 Praktikern bei Procter & Gamble zeigt, dass Individuen mit LLM Unterstützung deutlich produktiver Probleme lösen oder neue Ideen generieren konnten. Das Sprachmodell scheint einen deutlichen Mehrwert als „**Cybernetic Teammate**“ zu bringen und Einzelne teils auf das Leistungsniveau von ganzen Teams zu bringen (Dell'Acqua et al., 2025).

Wenn man **ältere oder weniger starke (offene) Modelle nutzt, fährt man mit dem Fahrrad auf der Autobahn**. Vergleiche zeigen von Modellgeneration zu Modellgeneration starke Performanzunterschiede; schon der Sprung von der ersten ChatGPT-Generation zur nächsten war erheblich. Auch die offenen Modelle sind teils deutlich weniger „schlau“ als die Flaggschiffe! Hier muss man insofern aufpassen, dass die einfache Verfügbarkeit älterer oder kleinerer Modelle über institutionelle Zugänge nicht zu einem falschen Bild führt.

2.5 Wo und wie spreche ich mit der KI?

2.5.1 Wo sprechen? Verschiedene Zugänge zu Sprachmodellen

Es gibt **drei Zugänge**: Am einfachsten ist das Chat-Interface des Anbieters, das für jedes weitere Modell ein eigenes Login und oft ein eigenes Abonnement verlangt und in den Hochschulversionen aus Datenschutzgründen meist Funktionen wie Sprachmodus und Benutzerprofile abklemmt. Bedienoberflächen wie Witsy oder TypingMind speichern Prompts, lassen Agenten für verschiedene Modelle erstellen und rechnen über einen API-Schlüssel (s. Kapitel 2.3) nur die tatsächliche Nutzung ab, bei einfacher Nutzung wenige Cent (zur Größenordnung s. die Kostendaten in Kapitel 2.4) (Schwarze, 2025). Wer etwas Code nicht scheut, lässt sich von der KI kleine Sprachagenten programmieren, etwa in Google Colab, und stellt sie mit Diensten wie **Replit** oder **Voiceflow** online bereit; auch dafür genügt ein API-Schlüssel.

2.5.2 Wie sprechen? Prompt-Befehle

Wie spreche ich mit dem LLM? In einem modernen Märchen von N.K. Jemisin gibt es gefangene Götter. Sie erfüllen ihren Wächtern jeden Wunsch, sind ihnen aber nicht wohlgesonnen: Eine falsche Formulierung kann

so katastrophale Folgen haben. Den Baum, der im Weg liegt, kann man schließlich auch durch einen Vulkanausbruch beseitigen. In dieser neuen Midas-Erzählung wird Präzision zentral. Diesen Tenor finden wir auch in den wichtigsten Empfehlungen zum Prompting: Präzise Anweisungen geben.

Ein **Prompt** ist die Eingabe, die an ein Sprachmodell geht, um eine bestimmte Antwort zu erhalten; wie er formuliert ist, entscheidet oft über die Qualität der Antwort. Die Kunst, solche Eingaben zu bauen, heißt **Prompt Engineering** (Berryman & Ziegler, 2025). Eine neuere Analyse unterscheidet **drei Effekte** der Prompt-Gestaltung (Vallverdú et al., 2025): User steuern über Prompts den Inhalt der Aufgabe (**operativ**), die „Aufmerksamkeit" des Sprachmodells (**epistemisch**) und die Risiken des Ergebnisses (**sozio-ethisch**). Stärkere Sprachmodelle übernehmen einen Teil dieser Steuerung, die Komplexität rückt damit aber nur auf eine höhere Ebene: In agentischen Workflows arbeiten mehrere Agenten zusammen, für deren Steuerung wir wiederum operative, epistemische und sozio-ethische Effekte berücksichtigen müssen (s. etwa Gottweis et al., 2025 für ein Beispiel).

Wie das geht, zeigen wir zuerst an einem einfachen Schema. Dann schauen wir uns an, welche Prompting-Strategien die drei großen KI-Labore in ihren Leitfäden empfehlen.

2.5.3 Zentrale Bausteine: Rolle, Aufgabe, Format und Beispiele

Wie beschreibe ich genau, was ich will? Einfache **Daumenregeln für Prompts** gliedern das in vier Schritte: dem Sprachmodell eine **Rolle** zuzuweisen („Du bist Verhandlungsexpertin"), ein klares **Ziel** zu definieren („Du hilfst mir dabei, mich auf Geschäftsverhandlungen vorzubereiten"), es zu bitten, sein **Vorgehen** (den Gedankengang / „chain of thought") offenzulegen und Schritt-für-Schritt vorzugehen („Erstelle zunächst einen Plan und frag mich nach Feedback. Warte meine Antwort ab und passe den Plan eventuell an. Wenn ich zufrieden bin, beginne mit dem ersten Schritt in deinem Plan.") sowie **Beispiele** („few shot") für eine gewünschte Struktur oder Analyse mitzuliefern („Formatiere die Dateinamen in dieser Form [Autor]-[Jahr]-[Kurztitel]", oder „Gib mir 5 Handlungsoptionen und nenne jeweils Vor- und Nachteile"). Dabei veranlasst die Chain of Thought-Methode das LLM, seine Gedankengänge offen zu legen. Das Modell zeigt seine Überlegungen Schritt für Schritt, was die Nachvollziehbarkeit seiner

Antworten verbessert. So können wir auch besser nachsteuern und das Ergebnis an unsere Ziele anpassen.

> **Strukturierten Prompt einfach erstellen lassen**
>
> Wollen Sie sich interaktiv einen ausführlichen, strukturierten Prompt erstellen lassen? Hier finden Sie einen Beispiel-Bot, dem man Prompts füttern kann, die er dann in ein kurzes oder detaillierteres Schema packt: https://chatgpt.com/g/g-695a8a7c9c888191a683135100f623d0-prompt-strukturierer-rtf-oder-create-format.

2.5.4 Wie Prompten? Was die großen KI-Labore empfehlen

Vor detaillierten Tipps hilft ein Bild (E. Mollick, 2024): Behandeln Sie das Sprachmodell wie eine junge Hilfskraft. Sie wird am Anfang nicht alles richtig machen, sondern muss klar angeleitet werden, so dass die Ergebnisse nach und nach besser werden. Junge Mitarbeiter sind keine Taschenrechner, die sofort perfekt und immer gleich funktionieren. GenAI Chatbots auch nicht. Iterieren und erläutern Sie: Das Ergebnis nähert sich Schritt für Schritt dem Wunschbild an, und jede Runde dauert nur Sekunden.

Was empfehlen Prompt-Profis im Detail? Die drei führenden KI-Labore haben 2025 ausführliche Leitfäden veröffentlicht, wie wir mit ihren Modellfamilien reden sollen (Anthropic, 2025b; Google, 2025; Kotha et al., 2025). Die Empfehlungen ähneln sich und beginnen bei der banalsten: **genau sagen, was man eigentlich will**; wer vage Bauanweisungen gibt, darf sich nicht wundern, wenn das Haus anders aussieht als gewünscht. Tabelle 2.4 fasst sie zusammen.

Nr.	Empfehlung	Was das heißt
1	Aufgabe präzise beschreiben	Klare Anweisungen ohne innere Widersprüche oder vage Formulierungen; wer die Aufgabe nicht erklärt hat, sollte nicht auf den Hiwi schimpfen.
2	Beispiele geben	Beispiele vermitteln den breiteren Kontext. Positive Formulierungen („gib mir …“) wirken besser als Verbote („vermeide …“) (Google, 2025); zu viele Beispiele engen den Suchraum ein.
3	Text strukturieren	Abschnitte mit Tags wie [Hinweis] oder <Hinweis> markieren; welche Klammern, ist gleich, solange sie einheitlich sind.

Nr.	Empfehlung	Was das heißt
4	Iterativ arbeiten	Der Lösungsweg entsteht im Wechsel mit dem Modell; anders als beim Taschenrechner liegt der Mehrwert in der Interaktion.
5	Agenten anders steuern	Festlegen, wie viel Eigenständigkeit der Agent haben soll („Eagerness-Kalibrierung“) (Kotha et al., 2025), und Zwischenstände strukturiert sowie in kurzen nummerierten Notizen festhalten lassen (Anthropic, 2025b); mehr in Kapitel 2.1.4 und Kapitel 2.1.5.
6	Das Modell beim Prompten helfen lassen	Eingebaute Prompt-Optimierer nutzen oder bei Fehlern den Prompt mit gewünschtem und tatsächlichem Verhalten vorlegen und um minimale Änderungen bitten (Kotha et al., 2025); ein Beispiel-Bot steht im Kasten in Kapitel 2.5.3.

Tabelle 2.4. Prompt-Empfehlungen der großen KI-Labore. Quellen: Kotha et al. (2025), Google (2025), Anthropic (2025b).

2.5.5 Es könnt' alles so einfach sein! Es bringt nichts, Bots zu bedrohen oder zu bestechen.

Die Bots zu bedrohen, bringt nichts. Empirische Untersuchungen haben mehrere anekdotische Geheimtipps des Promptings systematisch geprüft und meist widerlegt. Prompts funktionieren nicht immer gleich und **so kommt es schnell zu anekdotischer Evidenz,** dass eine Formulierung „besser geklappt“ hätte.

Die wenigsten der folgenden Hausrezepte helfen zuverlässig (Meincke et al., 2025b, 2025a, 2025c): Hilft es, höflich zu sein (nein), zu drohen (nein), Geld anzubieten (nein), oder den Hiwi-Bot Schritt für Schritt vorgehen zu lassen (ja, aber das machen die neueren Reasoning-Sprachmodelle auch selbst)?

Ihre Einschätzung prüfen

„Höflichkeit, Drohungen oder ein versprochenes Trinkgeld verbessern die Antworten eines Sprachmodells nicht zuverlässig.“
Auflösung: ja. Die Experimente von Meincke und Kollegen finden

für Höflichkeit, Drohungen und Trinkgeld keine verlässliche Wirkung. Was hilft, steht in den Leitfäden der Labore: die Aufgabe so präzise beschreiben wie für eine neue Hilfskraft, mit Format und Beispielen, und iterativ nachsteuern (Kapitel 2.5.4).

Auch hier sehen wir, dass die **stärkeren neueren Modelle auch etwas andere Bedienung erfordern.** Wie ein neuer Sportwagen kommen **mit den größeren Fähigkeiten auch neue Anfälligkeiten**: Die neuen Modelle können selbst iterativ vorgehen, das muss man ihnen nicht mehr empfehlen. Tut man es doch, sinkt teils die Performanz (Meincke et al., 2025a), etwa wenn man so verhindert, dass ein starkes Modell eine Frage aus seinem Vorwissen beantwortet und es stattdessen zu mehreren - eigentlich unnötigen - Denkschritten mit entsprechendem Token-Verbrauch zwingt). Da sie schlauer sind, werden sie durch unpräzise Anweisungen teils schneller aus der Bahn geworfen. Die Modelle halten sich genauer an Anweisungen - aber eben auch an falsche (Anthropic, 2025b; Google, 2025).

2.5.6 Was heißt das für Prompts in der Lehre?

Didaktische Prompts sollen den Studierenden das Leben gezielt schwer machen. Für die Lehre wollen wir den Prompts speziell didaktische Elemente hinzufügen, also etwa verhindern, dass den Studierenden sofort eine Lösung ausgegeben wird, da das eigene Nachdenken in Form von Fragen und sokratischem Dialog ihnen dabei hilft, die Ergebnisse auch zu behalten (Roediger & Pyc, 2012). Hier müssen wir also teils bewusst Hürden einführen, die die Studierenden zum Nachdenken, diskutieren und überlegen anregen. Wie das geht, sehen wir in den nächsten zwei Hauptkapiteln. Eine Vielzahl konkreter Beispiele von Prompts und didaktischer Aufgabenstellungen mit GenAI Tools finden Sie im Appendix (s. Anhang B).

ℹ Anwendungsbeispiel: Ein Prompt, der in der Vorführung funktioniert, scheitert im Gespräch

Problem ohne KI. Die Regeln des aktiven Zuhörens nach Carl Rogers lassen sich in einer Sitzung erklären, aber kaum üben, weil es dafür

Gesprächspartner und Rückmeldung braucht.
Problem mit KI. Ein Chatbot kann das Gegenüber spielen. Ein Prompt, der ihn auf Rogers' Regeln verpflichtet, funktioniert im freundlichen Test und bricht, sobald jemand widerspricht oder heikle Themen anspricht.
Der Lösungsansatz. Alexander Landfair lässt Studierende ihren Prompt wie ein Spiel testen. Sie schreiben einen Prompt, der das Modell auf Rogers' Regeln verpflichtet, und prüfen ihn zuerst in einem vorhersehbaren Gespräch über einfache Themen: testen, bis es klappt. Dann verhalten sie sich unberechenbar, widersprechen und wechseln zwischen schwierigen Themen: testen, bis es scheitert. Jeden Fehler notieren sie, überarbeiten den Prompt und beginnen von vorn. Den Abschluss bildet eine Diskussion oder ein kurzer Essay mit den Gesprächsprotokollen.
Was das für wirksames Lernen heißt. *Unterrichtsentwurf, keine Ergebnisse berichtet.* Wer beschreiben soll, wann das Modell gegen eine Regel verstößt, muss die Regel selbst genau verstanden haben; das Testen ist deshalb zugleich Übung im Fach. Nebenbei lernen die Studierenden, was die Forschung zum Prompting zeigt: Ein Prompt, der einmal funktioniert hat, beweist wenig (Meincke et al., 2025b).
Ablauf und Prompt: Online-Fassung von Anhang B. Quelle: Landfair (2025) (AI Pedagogy Project, metaLAB at Harvard).

2.6 Schemas für den systematischen Umgang mit GenAI

Der vorige Abschnitt hat gezeigt, wie ein guter Prompt gebaut ist. Prompting deckt aber nur eine von vier Kompetenzen ab: Vor dem Prompt steht die Entscheidung, was überhaupt an die KI geht, nach der Antwort die Prüfung des Ergebnisses und die Verantwortung dafür. Ein Schema, das diese Schritte ordnet, macht aus einer Sammlung von Tipps eine Arbeitsweise, und weil es keine Werkzeuge nennt, übersteht es den nächsten Modellwechsel.

2.6.1 Kompetenzrahmen im Vergleich

Artikel 4 der KI-Verordnung verpflichtet Hochschulen, die KI-Systeme bereitstellen, zu Maßnahmen für die KI-Kompetenz ihres Personals, sagt aber nicht, worin diese Kompetenz besteht; der Digital-Omnibus vom Juli 2026 hat die Pflicht entschärft und die Definition nicht nachgeliefert (Europäisches Parlament und Rat, 2026; Europäisches Parlament und Rat der Europäischen Union, 2024) (Kapitel 5.5.2). Die Lücke füllen Kompetenzrahmen. Einen Überblick über die Forschung zum Begriff *AI Literacy*, ihren Bestandteilen, Lernmethoden und Wirkungen gibt Pinski & Benlian (2024); für die Hochschullehre sind fünf neuere Rahmen besonders brauchbar (Tabelle 2.5).

Rahmen	Zielgruppe	Ordnungsprinzip	Entstehung
AI Fluency (Dakan & Feller, 2025)	Hochschule	vier Kompetenzen entlang des Arbeitsprozesses, drei Formen der Zusammenarbeit	Lehrerfahrung zweier Hochschulen
DLHN-Kompetenzrahmen (Feil et al., 2026)	Hochschule einschließlich Verwaltung	vier Bereiche: Technologie sowie Recht und Ethik als Basis, darauf Anwendung und Reflexion; drei Niveaustufen	Recherche und Kriterienkatalog im Verbundprojekt Digitale Lehre Hub Niedersachsen
AI Literacy Heptagon (Hackl et al., 2026)	Hochschule, fachbezogen anpassbar	sieben Dimensionen, vier Niveaustufen nach Bloom	Literaturreview nach PRISMA mit 27 Studien
AILit Framework (OECD & European Union, 2026)	Schule	vier Domänen (mit KI umgehen, gestalten, steuern, die KI-Entwicklung mitprägen), je Wissen, Fähigkeiten und Haltungen	EU und OECD mit Fachleuten und öffentlicher Konsultation

Rahmen	Zielgruppe	Ordnungsprinzip	Entstehung
Kompetenzen nach Gimpel et al. (2024)	Hochschule, Schwerpunkt Wirtschaftswissenschaften	Basiskompetenzen (AI Literacy, AI Reflection) und Felder vertiefter Kompetenzen	Konsortium von vier Hochschulen, Analyse von Curricula, Stellenmarkt und Literatur

Tabelle 2.5. Fünf Kompetenzrahmen für den Umgang mit KI im Vergleich. Eigene Zusammenstellung nach den genannten Quellen

Die fünf Rahmen ergänzen sich mehr, als dass sie konkurrieren: Sie zielen auf verschiedene Bildungsstufen und ordnen nach verschiedenen Prinzipien, nach Arbeitsschritten, Wissensdimensionen, Handlungsfeldern oder Bereichen. Eine Schwäche teilen sie. Alle verlangen, dass Lernende KI-Ergebnisse kritisch beurteilen, kaum einer sagt, wie; konkrete Verfahren wie Quellenabgleich oder Faktenprüfung nennen nur AI Fluency und AILit ausdrücklich. Die Methoden der Prüfung liefert dieses Buch deshalb an den Stellen nach, an denen sie gebraucht werden, etwa beim Tutor (Kapitel 4.3.3) und bei KI-gebauten Simulationen (Kapitel 4.2.2.3).

Dieses Buch arbeitet mit dem Modell *AI Fluency* von Rick Dakan und Joseph Feller, aus vier Gründen. Es ordnet nach dem Arbeitsprozess und passt damit zu einem Buch, das nach den Rollen der KI gegliedert ist. Es nennt keine Werkzeuge. Es führt als einziger der fünf Rahmen die Verantwortung gegenüber Dritten als eigene Kompetenz. Und seine vier Begriffe sind einprägsam genug, um das Vokabular eines ganzen Buchs zu tragen. Die Fassung der irischen Hochschulbehörde HEA steht wie dieses Buch unter der Lizenz CC BY-SA 4.0; die Übersetzungen der Definitionen folgen ihr.

2.6.2 Das 4D-Modell

AI Fluency ist die Fähigkeit, effektiv, effizient, ethisch und sicher mit KI zu arbeiten (Dakan & Feller, 2025). Das Modell zerlegt sie in vier Kompetenzen, die *4 D*, mit je drei Unterkompetenzen (Tabelle 2.6).

Kompetenz	Leitfrage	Unterkompetenzen	Herkunft des Wortes
Delegation	Was übernimmt der Mensch, was die KI?	Ziel- und Aufgabenbewusstsein (*goal and task awareness*), Kenntnis der Werkzeuge (*platform awareness*), Aufgabenverteilung (*task delegation*)	lat. *delegare*, übertragen
Description	Wie sage ich der KI klar, was ich will?	Ergebnis beschreiben (*product description*), Zusammenarbeit beschreiben (*process description*), Verhalten festlegen (*performance description*)	lat. *describere*, umreißen, aufzeichnen
Discernment	Wie beurteile ich, was die KI liefert?	Ergebnis beurteilen (*product discernment*), Zusammenarbeit beurteilen (*process discernment*), Verhalten beurteilen (*performance discernment*)	lat. *discernere*, unterscheiden, trennen
Diligence	Wie setze ich KI verantwortlich und offen ein?	Sorgfalt beim Erzeugen (*creation diligence*), Offenlegung (*transparency diligence*), Prüfung vor der Freigabe (*deployment diligence*)	lat. *diligentia*, Sorgfalt, von *diligere*, hochachten, sorgsam auswählen

Tabelle 2.6. Die vier Kompetenzen des AI-Fluency-Modells mit ihren Unterkompetenzen. Übersetzung nach Dakan & Feller (2025), CC BY-SA 4.0

Quer zu den vier Kompetenzen liegen drei Formen der Zusammenarbeit, die das Modell *Modalitäten* nennt. In der **Automation** führt die KI eine Aufgabe aus, die der Mensch festgelegt hat; in der **Augmentation** erledigen Mensch und KI sie gemeinsam und im Wechsel; in der **Agency** konfiguriert der Mensch eine KI, die später selbstständig handelt, oft für andere Nutzerinnen und Nutzer. Die ersten beiden Wörter klingen wie zwei Formen des Aufgabenmodells in Kapitel 4.1, meinen aber etwas anderes: Dort geht es darum, was mit einer Aufgabe geschieht, hier darum, wie Mensch und KI an ihr zusammenarbeiten. Die vier Rollen aus Kapitel 4

lassen sich den Modalitäten zuordnen. Der Hiwi arbeitet in der Automation, der Copilot in der Augmentation, Tutor und Simulator in der Agency, weil die Lehrende dort ein System einrichtet, mit dem später Studierende arbeiten.

Dakan und Feller nennen die vier D ausdrücklich vernetzte Kompetenzen, keine Reihenfolge (Dakan & Feller, 2025). In ihrem Kurs für Lehrende verbinden sie die vier aber zu zwei Schleifen (Dakan et al., 2025), und aus diesen beiden Schleifen baut dieses Buch einen Kreislauf(Abbildung 2.24). Die äußere Schleife zwischen **Delegation und Diligence** ist strategisch und läuft einmal je Vorhaben: Was will ich erreichen, welches System passt, welche Pflichten entstehen daraus, und was muss deshalb beim Menschen bleiben? Sie läuft in beide Richtungen, denn eine Pflicht zur Offenlegung oder zur Prüfung verändert, was man sinnvoll abgibt. Die innere Schleife zwischen **Description und Discernment** ist operativ und dreht sich innerhalb eines Arbeitsgangs viele Male: beschreiben, erzeugen lassen, prüfen, nachbessern. Das Buch liest die vier D damit als Stufen eines Arbeitsablaufs, weil sie sich so für jede Rolle erzählen lassen; es folgt der Lehrpraxis der Autoren, nicht dem Wortlaut ihrer Definition.

Das Schema beantwortet nicht, wie viel KI eine Aufgabe verträgt. Zu viel Einsatz kostet Kompetenz und Qualität, zu wenig kostet Übung mit Werkzeugen, die die Studierenden im Beruf vorfinden; der Kreislauf ist das Werkzeug, für jede Aufgabe die Mitte zwischen beiden zu suchen. Was die Forschung über die Kosten des Auslagerns weiß, zeigt Kapitel 3.5.

2.6.3 Wie dieses Buch das Schema benutzt

Jede der vier Rollen in Kapitel 4 endet mit einem Absatz, der den Kreislauf für diese Rolle durchläuft und die Stufe benennt, an der er am ehesten reißt. Die Übungen in Kapitel D.1 tragen je eine 4D-Tabelle, und die Prompt-Sammlung in Anhang B liefert Material für die Stufe Description. Wer das Modell selbst einüben oder mit Studierenden erarbeiten will, findet eine Übung in vier Phasen an einem Berufsprofil in der Online-Fassung von Anhang B.

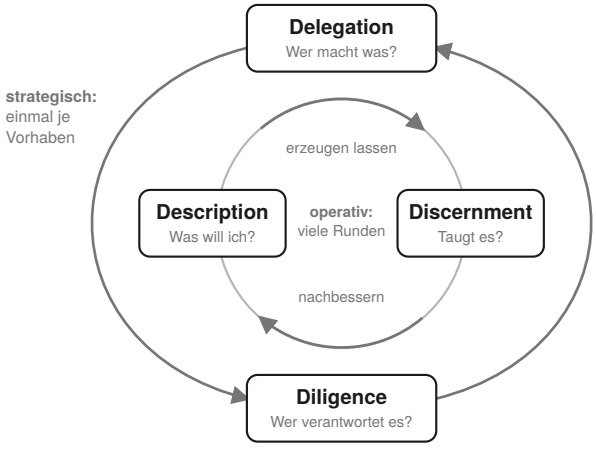

Modalität je Rolle

Hiwi	Automation
Copilot	Augmentation
Tutor	Agency
Simulator	Agency

Fassung zum Anklicken

Abbildung 2.24. Der 4D-Kreislauf. Die äußere Schleife (Delegation und Diligence) entscheidet einmal je Vorhaben, was die KI übernimmt und welche Pflichten daraus folgen; die innere (Description und Discernment) dreht sich in jedem Arbeitsgang mehrmals. Eigene Darstellung nach Dakan & Feller (2025) und den beiden Schleifen aus Dakan et al. (2025). Die Fassung zum Anklicken mit Unterkompetenzen und dem Engpass je Rolle: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/4d-kreislauf.html aufrufen.

Probieren Sie mal: Delegation an einem Berufsprofil

Wählen Sie einen Beruf, für den Sie ausbilden, und lassen Sie sich von einem Sprachmodell zehn typische Tätigkeiten dieses Berufs auflisten, etwa nach dem Berufsprofil der US-Datenbank O*NET. Ordnen Sie jede Tätigkeit selbst einer der drei Formen aus Tabelle 4.1 zu: Automatisierung, Augmentierung oder neue Aufgabe. Lassen Sie das Modell dieselbe Zuordnung vornehmen und vergleichen Sie. Wo Sie abweichen, steckt meist eine Annahme über den Beruf, die sich im Gespräch mit Studierenden lohnt.
Die vollständige Übung mit allen vier Phasen steht in der Online-Fassung von Anhang B: QR-Code scannen oder https://th-koeln-bartnik.github.io/genai4teaching/kapitel07-appendix02-prompt-sammlung.html#sec-ai-fluency-uebung aufrufen.

2.7 Exkurs: Wie steht es mit dem Ressourcenverbrauch der Modelle?

Studierende fragen regelmäßig nach dem Energiehunger der KI, und zwischen den Polen „Weltuntergang durch KI-Energiehunger“ und „keinerlei Problem“ lohnt ein Blick auf die Größenordnungen. Eine einzelne Textanfrage ist billig: Schätzungen von 2025 liegen zwischen 0,3 Wattstunden für ein großes Chat-Modell und 0,03 Wattstunden für kleine Modelle, also etwa so viel wie zehn Sekunden Video-Streaming (Elsworth et al., 2025; O’Donnell & Crownhart, 2025; You, 2025). Teuer sind die komplexen Aufträge: Ein hochwertiges Video von fünf Sekunden kann rund eine Kilowattstunde kosten, so viel wie eine Stunde Mikrowelle, und weil die Nutzerzahlen schneller wachsen als die Effizienz, übersteigt der Energiebedarf der Anfragen inzwischen den des Trainings (O’Donnell & Crownhart, 2025; Spencer & Singh, 2025). Rechenzentren und KI machten 2024 nach Schätzungen der IEA nur drei bis fünf Prozent des globalen Energieverbrauchs aus, weit weniger als Gebäude, Industrie und

Verkehr (Ritchie, 2024; Spencer & Singh, 2024); die Sorge der Analysten gilt der Prognose, nach der sich der Verbrauch der Rechenzentren bis 2030 verdreifachen und KI bis 2028 mehr als zwölf Prozent des US-Strombedarfs beanspruchen könnte, oft aus fossilen Quellen (O'Donnell & Crownhart, 2025; Spencer & Singh, 2025). Die Forderung an die Anbieter lautet deshalb Transparenz über ihren Energiebedarf, damit Politik und Nutzer die Kosten abschätzen und steuern können (O'Donnell & Crownhart, 2025). Für die Lehre heißt das: Eine Seminarsitzung mit Chat-Nutzung fällt energetisch nicht ins Gewicht; wer Bilder, Videos oder lange Agentenläufe erzeugen lässt, sollte das wissen und gegenüber den Studierenden benennen.

Der vollständige Exkurs mit Rechenbeispielen, Quellen und laufend aktualisierten Zahlen steht online unter https://th-koln-bartnik.github.io/genai4teaching/energie.html.

Abbildung 2.25. Exkurs „Ressourcenverbrauch der Modelle", Online-Fassung: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/energie.html aufrufen.

Kernaussagen

Zu Lernziel 1: Setup und Kontext

1. Kontext entscheidet über Nutzen: Ein Modell allein antwortet aus dem Trainingswissen, mit RAG bekommt es ein Bücherregal, als Agent einen Werkzeugkoffer. Für die Lehre ist meist das Setup mit eigenem Material der richtige Einstieg. Werkzeuge und Gedächtnis sitzen im Harness um das Modell, und der Harness legt fest, wie viel Handlungsspielraum das Modell bekommt.

Zu Lernziel 2: Funktionsweise, Halluzinationen und Energie

2. Ein Sprachmodell sagt das nächste Wort voraus. Aus Tokens, Embeddings und Attention entsteht Text, der plausibel klingt, aber keine eingebaute Wahrheitsprüfung hat.
3. Halluzinationen sind kein Betriebsunfall, sondern folgen aus der Funktionsweise. Gegenmittel sind Eingrenzung des Inputs, Musterlösungen und systematische Prüfung.
4. Der Energieverbrauch einer einzelnen Anfrage ist gering, der Gesamtbedarf der Infrastruktur wächst stark. Beides stimmt, und die Steuerung ist eine politische Aufgabe.

Zu Lernziel 3: Jagged Frontier

5. Die Fähigkeiten der Modelle bilden eine zerklüftete Grenze. Wer sie nicht kennt, wird mit KI schlechter als ohne.

Zu Lernziel 4: Prompts und 4D-Modell

6. Gute Prompts sind präzise, strukturiert, mit Beispielen und iterativ. Höflichkeit, Drohungen und Trinkgeld ändern nichts; wer das Modell wie eine junge Hilfskraft anleitet, kommt weiter.
7. Prompting ist eine von vier Kompetenzen. Das 4D-Modell ordnet den Umgang mit KI in Delegation, Description, Discernment und Diligence; die äußere Schleife entscheidet einmal je Vorhaben, was die KI übernimmt und welche Pflichten folgen, die innere dreht sich in jedem Arbeitsgang.

Lernfragen

Wiederholen

1. Beschreiben Sie in drei Schritten, wie ein Sprachmodell aus einem Prompt eine Antwort erzeugt.
2. Warum gelten Halluzinationen nicht als Betriebsunfall, und welche drei Gegenmittel nennt das Kapitel?
3. Welche verbreiteten Prompt-Tricks bringen nichts, und was hilft stattdessen?

Anwenden

4. Ein Studierender fragt Sie, warum der Chatbot eine Quelle

erfunden hat, die es nicht gibt. Erklären Sie es ihm in drei Sätzen ohne die Wörter „Token“ und „Wahrscheinlichkeit“, dann noch einmal mit.

5. Nehmen Sie eine typische Aufgabe aus Ihrer Lehre und spielen Sie durch: Was antwortet ein reines Sprachmodell, was ein Modell mit Ihrem Skript als Material, was ein Agent mit Internetzugang? Wo liegt jeweils das Risiko?

Beurteilen

6. Welche Aufgabe in Ihrem Fach liegt vermutlich außerhalb der Jagged Frontier? Wie würden Sie das prüfen, bevor Sie Studierende damit arbeiten lassen?
7. Der Energieverbrauch einer einzelnen Anfrage ist gering, der Bedarf der Infrastruktur wächst stark. Welche Folgerung ziehen Sie daraus für Ihre eigene Nutzung, und welche Entscheidung liegt nicht bei Ihnen?
8. Ein Agent soll Ihre Sprechstundenanfragen ein Semester lang vorsortieren und sich dabei merken, welche Fragen schon beantwortet sind. Welche Stufe des Gedächtnisses wählen Sie, und an welcher Stelle prüfen Sie, was er sich gemerkt hat?
9. Ein Studierendenteam baut auf einem großen Sprachmodell einen Lerntutor für Ihr Fach. Welche Teile davon gehören zum äußeren Harness, und an welchen zwei Stellen würden Sie den Handlungsspielraum des Modells begrenzen? Wessen Autonomie wächst dabei, wessen schrumpft?
10. Gehen Sie eine Aufgabe, die Sie demnächst an eine KI geben wollen, durch beide Schleifen des 4D-Kreislaufs. An welcher der vier Stufen würde Ihr Vorhaben am ehesten scheitern, und was legen Sie deshalb vorher fest?

Lösungshinweise: Anhang F.

3 Didaktische Ziele und Mechanismen

In diesem Kapitel

- Was für Ziele verfolgen wir mit dem Einsatz von GenAI in der Lehre?
- Wissenstypen
- Anwendungsbeispiele nach Wissenskategorien
- Effektive Lerntechniken und Unterstützung mit KI
- Was die Forschung seit 2025 zeigt: Lernwirkung und kognitive Auslagerung

Thomas Brandt unterrichtet als Lehrkraft für besondere Aufgaben Kostenrechnung für 250 Erstsemester. Er weiß, dass Übungen mehr bringen als Vortrag, doch bei 18 Semesterwochenstunden und einem Hörsaal mit festen Bänken trägt er vor. Vor der Klausur lesen seine Studierenden das Skript zum dritten Mal. Seit dem Sommer lösen sie die Übungsblätter mit dem Chatbot, fehlerfrei und in Minuten. Brandt will einen eigenen Tutor einrichten, dessen Anweisung fertige Lösungen verbietet und sokratisches Nachfragen verlangt. Ein Kollege winkt ab: Seine Studierenden hätten den Tutor gebeten, die Anweisung zu vergessen, und die Lösungen trotzdem bekommen. Brandt fragt sich, ob er an der Technik feilen muss oder an seiner Lehre.

Die Szene ist aus Gesprächen in Workshops und aus der eigenen Lehre zusammengesetzt.

Bevor Sie weiterlesen: Wie sehen Sie das?

Wie sehr stimmen Sie den vier Aussagen zu? Jede Aussage wird an der Stelle im Kapitel aufgelöst, die sie beantwortet. Wer sich vorher festlegt, liest gezielter.

1. Dass wirksame Lehrmethoden selten eingesetzt werden, liegt vor allem daran, dass Lehrende die Forschung dazu nicht kennen oder ihr nicht trauen.
stimme zu 1 – 2 – 3 – 4 – 5 *stimme nicht zu*
(Auflösung in Kapitel 3.1)

2. Solange seine Lösungen fachlich richtig sind, schadet ein Chatbot, der jede Übungsfrage sofort vollständig löst, dem Lernen nicht.
stimme zu 1 – 2 – 3 – 4 – 5 *stimme nicht zu*
(Auflösung in Kapitel 3.1)

3. Häufige kleine Abfragen, über das Semester verteilt, lassen den Stoff besser behalten als dieselbe Zeit für gründliches Wiederlesen.
stimme zu 1 – 2 – 3 – 4 – 5 *stimme nicht zu*
(Auflösung in Kapitel 3.4)

4. Eine gut formulierte Anweisung an das Modell genügt, damit ein KI-Tutor zum Lernen anleitet, statt Lösungen zu liefern.
stimme zu 1 – 2 – 3 – 4 – 5 *stimme nicht zu*
(Auflösung in Kapitel 3.5)

Lernziele: Nach diesem Kapitel können Sie …

1. erklären, warum wirksame Lehrmethoden bekannt, aber selten umgesetzt sind, und wo generative KI den Aufwand senken kann;
2. begründen, warum Chatbots ohne didaktische Bremsen dem Lernen eher schaden, mit Bezug auf erwünschte Schwierigkeiten und kognitive Belastung;
3. je Wissensstufe und je gut belegter Lerntechnik einen passenden KI-Einsatz wählen und ihn mit der ICAP-Rangfolge bewerten;
4. den Stand der Evidenz seit 2025 wiedergeben: wann KI-Tutoren Lernen fördern und wann ungebremste Nutzung es senkt.

Die Kernaussagen am Kapitelende sind nach diesen vier Zielen geordnet.

3.1 Was für Ziele verfolgen wir mit dem Einsatz von GenAI in der Lehre?

Bevor wir uns der konkreten Umsetzung zuwenden, müssen wir uns zunächst fragen, was wir überhaupt bezwecken: Was sind typische Probleme und was sind unsere Ziele für die konkrete Umsetzung in Lehrsituationen?

Schauen wir uns zunächst ein zentrales Problem der Lernsituation an Hochschulen an Roediger & Pyc (2012): **Wir wissen, was effektive Formen der Lehre sind, diese werden jedoch häufig nicht angewendet.** Studien deuten darauf hin, dass dies eher an situativen Hindernissen der Lernumgebung liegt als am Willen der Lehrenden (Henderson & Dancy, 2007).

Ein Beispiel ist die **Vorlesung**. Es ist gut belegt, dass diese Form des passiven Konsums eine sehr schwache Form der Wissensvermittlung ist. **Man lernt nicht nichts, aber anders würde man mehr lernen.** Empirisch und theoretisch ist sehr gut belegt, dass Studierende Wissen besser behalten, wenn sie dieselbe Zeit für aktives Üben, Frage-Antwort Interaktionen oder Diskussion in Kleingruppen verwenden (Freeman et al., 2014; Hake, 1998).

Praktisch wird oft mit dem positiven Effekt der reinen Anwesenheit argumentiert (besser als wenn die Studierenden zu Hause Netflix schauen; wer zur Vorlesung kommt hat bessere Noten), aber **diese spezielle Form der Präsenzlehre hat durch mangelnde Interaktion klare Nachteile.** Der Harvard Physiker Kestin et al. (2025) fasst drei zentrale Probleme von Vorlesungen zusammen: Mangelnde Anpassung, mangelndes individuelles Feedback und mangelnde Aktivierung der Lernenden. Genauer (Kestin et al., 2025, S.2–3): "1. They move too quickly for some students and too slowly for others because the teacher controls the pace of instruction; 2. Students do not receive personalized feedback to their questions as they arise; and 3. They fail to maintain consistent student engagement."

Warum werden trotzdem Vorlesungen sehr häufig und aktivere Lehrformen relativ selten eingesetzt (Stains et al., 2018)? Studien deuten an, dass es oft nicht am Willen der Lehrenden liegt, sondern dass **situative Hindernisse** eine große Rolle spielen, vor allem Zeitmangel wird sehr häufig in Umfragen genannt (Shadle et al., 2017), außerdem bremsen Faktoren wie Gruppengröße oder ein ungünstiger Setup der

Räume (Henderson & Dancy, 2007). Auch erfolgt die **Umsetzung oft zu optimistisch und ohne Berücksichtigung von Widerständen und Hindernissen** (z.B. Anreize für Studierende, zu Gruppenübungen auch zu kommen, oder nicht lieber ihr Wochenende in Kleingruppen zu besprechen als die Übungsaufgabe), so dass z.B. mangels notwendiger Anreizsetzung die erhoffte Lernwirkung ausbleibt und schnell Frust bei der Umsetzung entsteht (Henderson & Dancy, 2007).

Ihre Einschätzung prüfen

„Dass wirksame Lehrmethoden selten eingesetzt werden, liegt vor allem daran, dass Lehrende die Forschung dazu nicht kennen oder ihr nicht trauen."
Auflösung: eher nicht. Die Befragungen deuten auf situative Hindernisse: Am häufigsten nennen Lehrende Zeitmangel, dazu bremsen Gruppengröße und Räume, und die Umsetzung wird oft zu optimistisch geplant. Genau beim Zeitproblem kann generative KI ansetzen.

Wir argumentieren hier, dass GenAI **helfen kann, solche situativen Barrieren zu verringern,** speziell das häufig genannte **Zeitproblem** bei der Umsetzung effektiver Lehrmethoden (Shadle et al., 2017). Bei sorgfältiger Umsetzung könnte GenAI so als "Kraftverstärker" für Lehrkräfte dienen (E. R. Mollick & Mollick, 2023a), indem es die Implementierung evidenzbasierter Lehransätze erleichtert, die sonst aufgrund von Zeit- und Arbeitsaufwand oft schwer umzusetzen sind.

Auch hier gibt es allerdings nichts umsonst: Die **neuen Tools haben ihre eigenen Risiken und Nebenwirkungen** und **der Aufwand für Anpassung und Umsetzung** darf nicht unterschätzt werden. Einfach Sprachmodelle ohne Anpassung und didaktische 'Bremsen' einzusetzen ist oft nicht sinnvoll. Wie wir in der weiteren Diskussion sehen werden, nehmen sonst die KI-Chatbots den Studierenden erwünschte Schwierigkeiten ab (*desirable difficulties*), ermuntern sie nicht dazu, selbst Informationen abzuwägen, das eigene Verständnis zu vertiefen und so den eigenen Fähigkeitsstand aktiv zu verbessern (*growth mindset*) oder überfordern die kognitive Aufnahmefähigkeit der Lernenden durch Wissens-Dumps (*cognitive load*). Werden die Sprachmodelle nicht dazu angehalten, klar zu sagen, wenn sie zu etwas keine Informationen haben, so können sie die Lernenden durch überzeugend vorgetragene Halluzinationen oder Fehlschlüsse in die Irre führen. Um effektiv zu sein, müssen GenAI Lernhilfen insofern didaktisch

gebremst, themenspezifisch angepasst und systematisch erprobt werden (Kestin et al., 2025):

```
"AI chatbots are generally designed to be helpful, not
  to promote learning. They are not trained to follow
  pedagogical best practices (e.g., facilitating
  active learning, managing cognitive load and
  promoting
a growth mindset) (...) . Another well-known flaw of AI
  tutors is their uncanny confidence when giving an
  incorrect answer or when marking a correct reply as
  incorrect [@kestin2025]."
```

Ihre Einschätzung prüfen

„Solange seine Lösungen fachlich richtig sind, schadet ein Chatbot, der jede Übungsfrage sofort vollständig löst, dem Lernen nicht."
Auflösung: nein. Auch eine richtige Lösung nimmt die Anstrengung ab, die Behalten und Verstehen erst erzeugt, die erwünschten Schwierigkeiten. Wie groß der Schaden ist, zeigt Kapitel 3.5: Mit einem Tutor im Stil des normalen ChatGPT stieg die Übungsleistung, und in der Prüfung ohne KI lagen dieselben Schüler 17 Prozent unter der Kontrollgruppe.

Die nächsten Abschnitte geben eine theoriegestützte Orientierung, wie solche Anpassungen erfolgen könnten und welche Mechanismen die Lernforschung als besonders effektiv herausstellt. Zunächst führen wir zur genaueren Zielbestimmung Kategorien von Wissen und Lernmethoden ein. Dann können wir im Detail diskutieren, für welche Ziele und Methodenwahl welche Art der Unterstützung geeignet ist.

3.2 Wissenstypen

Hattie (2023, S.358, 340ff.) unterscheidet drei Stufen des Lernens (s. Tabelle 3.1).

Zunächst geht es um **„knowing that"**, also das reine **Fakten- und Begriffswissen**, das erworben und dann gefestigt werden muss: Hier soll eine belastbare Wissensbasis entstehen, weshalb Lehrkräfte häufig

Vorwissensaktivierung oder Drill-and-Practice einsetzen und durch unmittelbares Feedback die korrekte Erinnerung verankern.

Darauf baut **„knowing how“** auf, das **prozedurale und strategische Können**. Auch hier müssen Abläufe zunächst erworben und dann gefestigt werden. Lernende erwerben Prozesswissen, indem sie modellierte Beispiele studieren, in gelenkten Übungen selbst anwenden und mithilfe von „worked examples“ sowie Fehleranalysen Schritt für Schritt ihre Vorgehensweisen optimieren. Festigen können Lernende dieses Prozesswissen besonders gut durch Interaktion oder Wettbewerb mit anderen Lernenden, da diese Auseinandersetzung ihnen dabei hilft, verschiedene Nutzungskontexte zu vergleichen (Chi et al., 2018).

Die höchste Stufe nennt Hattie **„knowing with“**: Wissen wird flexibel **auf neue Situationen übertragen**. Problembasiertes Lernen, authentische Fallstudien, bewusste Reflexionsphasen und kooperativ angelegte Projekte helfen dabei, Konzepte in unbekannten Kontexten sicher anzuwenden und weiterzuentwickeln.

Wo können wir neue technische Hilfsmittel wie LLMs zur Unterstützung dieser Methoden besonders effektiv einsetzen?

Kategorie	Phase	Typische Methoden
Wissen, dass („Knowing that“)	**Erwerben**	Notizen zusammenführen; Zusammenfassen; Heft-/Notizbuch-Durchsicht; Bildhafte Notizen
Wissen, dass („Knowing that“)	**Festigen**	Argumente prüfen; Fehler identifizieren; Einschränkungen formulieren; Formale Argumentstrukturen darstellen; Belege liefern; Durchgearbeitete Beispiele
Wissen, wie („Knowing how“)	**Erwerben**	Aufgabenüberarbeitung; Häufiges Üben; Übungseinheit vor Tests; Zweispaltige Notizen; Problemorientiertes Lernen

Kategorie	Phase	Typische Methoden
Wissen, wie („Knowing how“)	**Festigen**	Peer-Feedback / Peer-Response-Gruppen; Peer-Tutoring; Studierenden-Turniere; Think-Pair-Share; Kumulative Wiederholung
Wissen anwenden („Knowing with“)	**Transfer**	Sortieren, Zuordnen, Kategorisieren; Dichotome Schlüssel; Von Studierenden erstellte Klassifikationsmuster; Klassifikationsdiagramme

Tabelle 3.1. Methoden nach Wissenstyp: Fakten, Prozess und Transfer. Quelle: Basierend auf Hattie (2023), S. 358, 340ff.

3.3 Anwendungsbeispiele nach Wissenskategorien

Zur Unterstützung des **Aufbaus von Faktenwissen („knowing that“)** können starke LLMs gut grundlegende Konzepte erklären (Korinek, 2024, S.48) und zum Selbststudium komplette Abruf-Übungen erzeugen: Sie formulieren Multiple-Choice- und Kurzantwortfragen, bewerten die Eingaben sofort und erklären fehlerhafte Distraktoren – ein Verfahren, das in einer STEM-Untersuchung zur automatischen Item-Generierung überzeugende Validitätswerte zeigte (Säuberli & Clematide, 2024).

Ebenso lassen sich sehr schnell Definitionen, Paraphrasen oder Mini-Zusammenfassungen erzeugen, was personalisierte Glossare ermöglicht (J. Chen et al., 2024). Shen Wang et al. (2024) sprechen von KI als „Confusion Helper“. Um Halluzinationen zu vermeiden, wird das Modell häufig per Retrieval-Augmentation an externe Wissensbasen gekoppelt (also z. B. durch Beigabe von Skripten oder Fachartikeln als PDF. Siehe auch das Harvard-Tutor-Bot Beispiel in Abschnitt 4.3, wo Musterlösungen beigegeben werden.).

Zur **Festigung von Prozessen und Strategien („knowing how“)** dient das LLM als dialogischer Coach: Feingranulierte Prompts („Erkläre

den Beschaffungsprozess in 5 Schritten und stelle nach jeder Stufe eine Kontrollfrage“) steigern die Lösungswahrscheinlichkeit in Tutorendialogen (Scarlatos et al., 2025). Sprachmodelle können Lehrenden dabei helfen, komplette „worked examples“ mitsamt Zwischenschritten zu generieren (Hassany et al., 2024).

Angepasste Sprachmodelle können Lernende zur Selbstkorrektur anleiten. Umso besser geht das, wenn das Sprachmodell **fachspezifische Lerntheorien** kennen (z.B.: typische Englischfehler von Deutschen oder typische Verhaltensfehler bei Verhandlungen oder beim Feedback-Gespräch im sozialen Bereich) und **die individuelle Lernhistorie** - sie also wissen, in welche Fallen ich als Lernender gerne tappe. Y.-F. Zhang et al. (2025) demonstrieren dies am Beispiel eines selbst entwickelten multimodalen **Mathematik-Tutor-Bots** (MathCCS, Mathematical Classification and Constructive Suggestions).

Der **Teachable-Agent-Ansatz** nutzt umgekehrt das Lernen-durch-Lehren-Prinzip: Studierende bringen dem LLM eine Methode bei und reflektieren dabei ihre eigene Strategie. Dies basiert auf der Annahme, dass Interaktionen besonders effektiv zum Lernen beitragen (Chi et al., 2018; Hayashi et al., 2025). Wie auch in der persönlichen Interaktion scheint hierbei wichtig zu sein, welche „Persönlichkeit“ der KI-Bot hat, dem Studierende etwas beibringen sollen (Lyu et al., 2025) und mehr Anstrengung in der Interaktion (etwa durch ausführlicheres Formulieren beim Erklären) führt zu mehr Lernerfolg (Love et al., 2025).

Sprachmodelle können genutzt werden, um komplexe (mathematische) Anwendungsprobleme mit einem simulierten User **„durchzuspielen“,** so dass **logische Fehler im Lösungsprozess sichtbar werden,** wie der Prototyp „MathChat“ von Y. Wu et al. (2023) zeigt. Meta-Analysen zeigen starke positive Lerneffekte, deuten aber auch auf mögliche Einschränkungen hin. So gibt es Anzeichen dafür, dass die Effekte höher für Studierende sind als für Schüler und möglicherweise schwinden Motivationsschübe durch **abnehmende ‘novelty effects’** einfacher Chat-Interfaces über die Zeit der Nutzung. Die Autoren der Metastudie empfehlen, hier mit stärkerer **Gamifizierung und Personalisierung** der Chatbots gegenzusteuern (R. Wu & Yu, 2024), was sich mit praktischen Ansätzen etwa von Duolingo deckt (Kazu & Kuvvetli, 2025) (z. B. Gamifizierung durch Streaks und Leaderboards, Challenges, Video-Chats mit dem Emo-Teen Lili usw.). Solche aufwändigen Setups sind im Hochschulkontext natürlich schwieriger

abzudecken, ließen sich aber vielleicht graduell als Studierendenprojekt entwickeln?

Für **Transfer und Anwendung („knowing with“)** entwirft das LLM realitätsnahe Szenarien – etwa Rollenspiele zu Lieferantenausfällen – und übernimmt Stakeholder-Rollen, wobei Analysen des Brookings-Instituts das Potenzial für kollaboratives Reasoning hervorheben (Korinek, 2024). Cross-Domain-Prompts fördern Analogiebildung („Welche Parallelen bestehen zwischen agilem Projektmanagement und Lean-Procurement?“) (E. R. Mollick & Mollick, 2023a).

In Gruppenarbeiten funktioniert das Modell als Co-Autor: KI-unterstützte Schreibprozesse können die Menge und Vielfalt der Ideen steigern (Meincke et al., 2024; Shaer et al., 2024). Auch hier ist jedoch die sorgfältige Gestaltung des Lernprozesses wichtig, so dass nicht erwünschte Schwierigkeiten an die KI delegiert und so kritische Denkprozesse nicht eingeübt werden (H.-P. H. Lee et al., 2025).

3.4 Effektive Lerntechniken und Unterstützung mit KI

3.4.1 Wie lernen wir besonders effektiv?

In diesem Abschnitt verdeutlichen wir kurz die angestrebten Wirkmechanismen mit Fokus auf drei Lehrtechniken, die die Kognitionswissenschaft als besonders effektiv heraushebt (siehe Mörth et al. (2021) für eine gute deutschsprachige Übersicht).

Die moderne Lernforschung der Kognitionspsychologie stellt drei Gruppen von Techniken als besonders gute Kombination zwischen Effektivität und einfacher Anwendung heraus: **Verteiltes und gemischtes Lernen**, **testgestütztes Lernen** und **fragebasierte Ausarbeitung** (Dunlosky et al., 2013; Mörth et al., 2021; Roediger & Pyc, 2012). Diese Wirkung gibt es allerdings nicht umsonst: Den positiven Effekten der Techniken steht oft ein deutlich höherer Vorbereitungsaufwand gegenüber. Wie im Folgenden kurz skizziert wird, lassen sich KI-Tools nutzen, um den Aufwand dieser drei Mechanismen zu verringern, was die Lernwirkung im Vergleich zu traditionellen Ansätzen deutlich erhöhen kann.

Zeitliche Verteilung und inhaltliche Mischung von Lerninhalten (Spacing & interleaving): Diese Technik basiert auf dem Prinzip, dass

Informationen besser behalten werden, wenn das Lernen über die Zeit verteilt und in verschiedenen Kontexten stattfindet, anstatt in einer einzigen, intensiven Sitzung (Brown et al., 2014; Murre & Dros, 2015; Roediger & Pyc, 2012).

Abstände zwischen Lerneinheiten und die wiederholte Aktivierung von Wissensstrukturen stärken die Verbindung zwischen Hinweisreizen und Gedächtnis und geben dem Gehirn Zeit, Erinnerungen effektiv zu speichern. Dies fördert die Langzeiterinnerung, denn der wiederholte Abruf verstärkt die gespeicherten Muster und vertieft sie so.

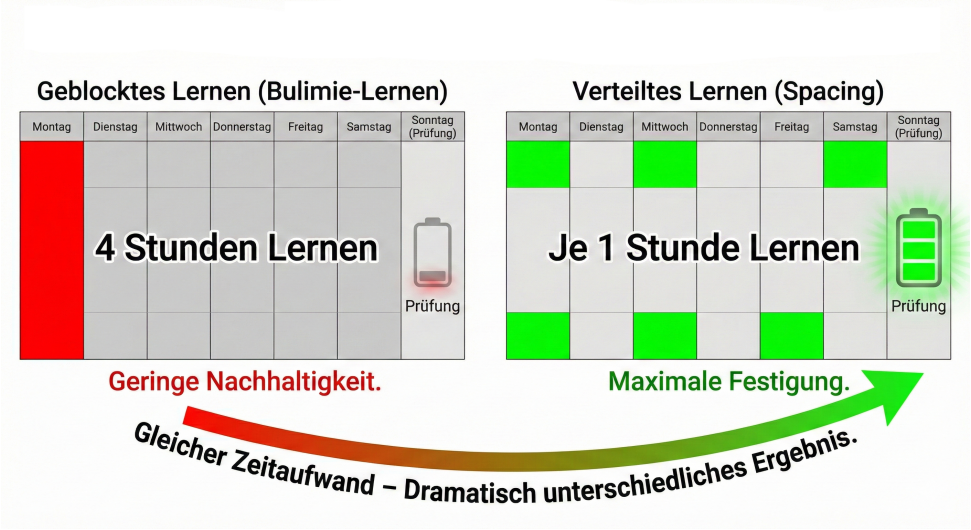

Abbildung 3.1. Illustration Zeitlich verteiltes Lernen – spacing

Quelle: Erstellt mit Gemini 3 Pro, basierend auf Roediger & Pyc (2012).

Weiterhin hilft es, zu „mischen“: **inhaltlich gemischtes Üben** (*interleaving*) ist effektiver als die isolierte Behandlung von Themenblöcken, die linear im Semesterverlauf abgehandelt werden (Mörth et al., 2021). Das liegt daran, dass das gemischte Üben die Unterscheidung zwischen verschiedenen Aufgabentypen fördert, was entscheidend für die spätere Anwendungskompetenz ist. Nur durch den geübten Vergleich verschiedener Kombinationen von Anwendungskontexten und Lösungsansätzen kann ein Gefühl dafür ausgebildet werden, welches Werkzeug zu welchem Problem passt. Fallstudien und Simulationen bieten sich hier an, wenn diese ausreichend komplex sind, um bekannte Analysen in neuen Kontexten anzuwenden und neue einzuführen.

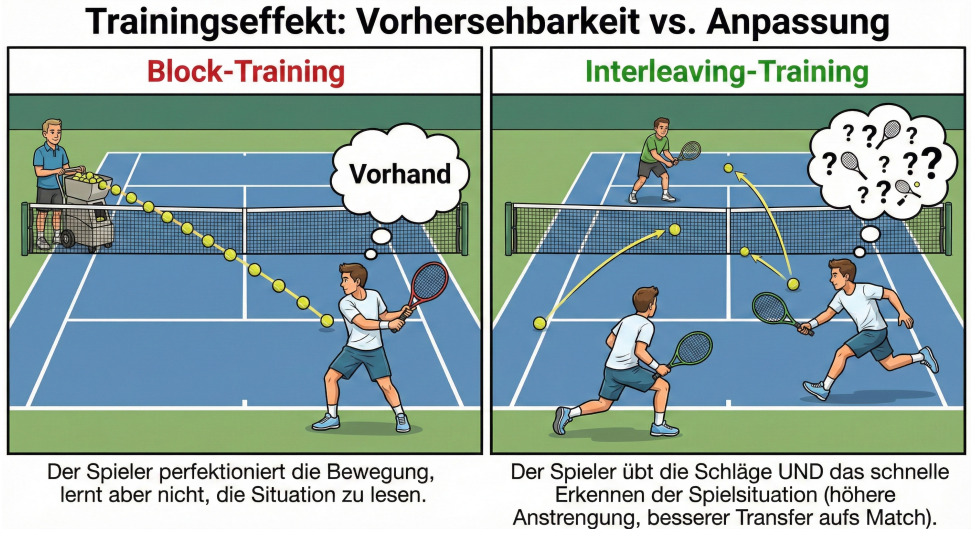

Abbildung 3.2. Illustration Inhaltlich gemischtes Lernen – interleaving

Testgestütztes Lernen (Test-enhanced learning): Das Abrufen von Informationen durch Tests fördert das Langzeitgedächtnis deutlich stärker als das erneute Lesen des Stoffes. Für Studierende ist das anstrengender, es bringt aber deutlich mehr (Brown et al., 2014). Ein ‚Test' kann dabei auch die Bearbeitung von Lerninhalten im Rahmen einer Fallstudie, die kritische Bewertung potenziell falscher Aussagen eines LLMs oder die Beantwortung von Verständnisfragen im Dialog mit einem Tutor-Bot sein.

Quelle: Erstellt mit Gemini 3 Pro, basierend auf Roediger & Pyc (2012).

Häufige Aktivierung von Lerninhalten durch Fragen verbessert den Lernerfolg durch mehrere Mechanismen (Roediger & Karpicke, 2006). Erstens fördert solches Testen das **transfergerechte Verarbeiten**, da die mentalen Prozesse beim Testen und beim späteren Abrufen ähnlich sind, was die Erinnerungsfähigkeit verbessert. Zweitens stärkt die Wiederholung durch Tests einerseits den erinnerten **Inhalt** und fügt andererseits **neue ‚Haken'** hinzu, mit denen wir den Inhalt aus dem Gedächtnis ziehen: die Beziehungen zwischen Hinweisreizen (*cues*) und dem Inhalt im Gedächtnis, indem zusätzliche Abrufwege zu gespeicherten Wissensmustern geschaffen werden, was den Abruf verbessert. Praktisch kann man diesen tollen Effekt auch recht einfach durch regelmäßige kurze Fragerunden nutzen: Wie die Lernforscher herausstellen: „frequent low-stakes quizzes (last only 5 or 10 min) can produce a large boost in performance" (Roediger & Pyc, 2012,

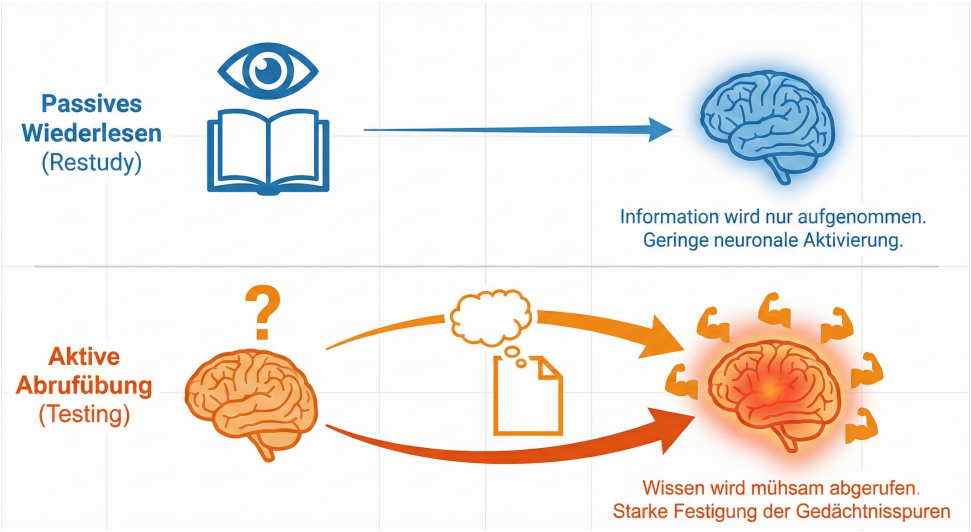

Abbildung 3.3. Illustration Testgestütztes Lernen – test-enhanced learning

S.246).

Ihre Einschätzung prüfen

„Häufige kleine Abfragen, über das Semester verteilt, lassen den Stoff besser behalten als dieselbe Zeit für gründliches Wiederlesen."
Auflösung: ja. Das Abrufen durch Tests stärkt das Langzeitgedächtnis deutlich mehr als erneutes Lesen, und verteilte Wiederholung wirkt besser als eine einzige intensive Sitzung. Für Studierende ist das anstrengender, für Lehrende aufwendiger, weil laufend neue Fragen nötig sind; diesen Aufwand können Sprachmodelle senken (nächster Abschnitt).

Fragebasierte Ausarbeitung (Explanatory questioning): Bei dieser Technik wird das tiefergehende Verständnis von Material durch das Stellen und Beantworten von „Warum"-Fragen gefördert. In **Rollenspielen und Simulationen** können Teilnehmer durch bewusste Praxis aktiv Szenarien durchspielen, während sie gleichzeitig durch gezielte Fragen angeleitet werden, die zum tieferen Nachdenken und zur Reflexion anregen. Diese Fragen können dazu dienen, die Teilnehmer dazu zu bringen, ihre Entscheidungen und Handlungen im Kontext des Rollenspiels zu erklären, wodurch das Verständnis für die Anwendung von Konzepten in realen oder

simulierten Situationen vertieft wird.

Indem Lernende über die Gründe hinter den Fakten nachdenken, werden Verbindungen zu bereits bekanntem Wissen hergestellt, was zu einem tieferen Verständnis und besserer Erinnerung führt. Dies deckt sich mit dem Postulat der ICAP-Theorie des kognitiven Engagements (Chi et al., 2018): Interaktion (I) ist effektiver als individuelle Konstruktion, was wiederum effektiver ist als aktive (aber nicht konstruktive) Beteiligung, was wiederum die passive Lernteilnahme schlägt (I > C > A > P).

3.4.2 Wie können LLMs genutzt werden, um diese Lerntechniken zu unterstützen?

Wir skizzieren das hier kurz an einem Seminar zum interkulturellen Management. Um **zeitliche Verteilung und Mischung** zu fördern, kann mit LLMs eine Serie von kurzen, thematisch variierenden Aufgaben und Fallstudien über das Semester verteilt erstellt werden. Diese könnten reale Szenarien abbilden, in denen Studierende ihre Fähigkeiten im interkulturellen Management anwenden müssen. Beispielsweise könnte das Sprachmodell Aufgaben generieren, bei denen Studierende Strategien für die Überwindung kultureller Barrieren in internationalen Teams entwickeln.

Was sind Beispiele für **testgestütztes Lernen**? Regelmäßige, durch LLMs generierte Quizze bringen Studierende dazu, ihr Wissen häufiger aktiv abzurufen. Durch LLMs können Multiple-Choice-Fragen, Fallstudienanalysen und Szenariobeschreibungen zu interkulturellen Missverständnissen erzeugt werden, welche die Studierenden lösen müssen.

Zur Unterstützung von **fragebasierter Ausarbeitung** können LLMs die Erstellung von Fallstudien, Simulationen und Rollenspielen unterstützen, damit Studierende über interkulturelle Dynamiken und Managementstrategien nachdenken. Diese könnten als Ausgangspunkt für Diskussionen im Kurs oder als Teil von Hausaufgaben dienen, wobei die Studierenden angehalten werden, über die Verbindungen zwischen dem Kursmaterial und den simulierten interkulturellen Interaktionen zu reflektieren. Ein rechnendes Beispiel aus der Logistik ist das Bullwhip-Widget in Kapitel 4.2.2.2: Warum die Fabrik viel stärker schwankt als die Kundschaft, erklären Studierende erst, wenn sie Lieferzeit und Informationsfluss einzeln verändert und die Folgen gesehen haben. Viele weitere Beispiele hierfür besprechen wir im

folgenden Kapitel, wo wir Anwendungsfälle von KI in der Lehre nach der didaktischen Rolle des Werkzeugs darstellen: Hilfskraft, Copilot, Tutor oder Simulator.

ℹ Anwendungsbeispiel: KI-Feedback zum Schreiben kommt sofort, ist aber nicht immer richtig

Problem ohne KI. In Sprachkursen ist individuelles Feedback zu Texten knapp, weil jede Rückmeldung Zeit der Lehrkraft kostet.
Problem mit KI. Ein Sprachmodell kommentiert jeden Entwurf sofort, aber nicht immer richtig; wer die Fremdsprache erst lernt, erkennt falsche Vorschläge schwer.
Der Lösungsansatz. Das Sprachlernzentrum der Universität Bonn (Projekt Digital Literacy, Géraldine Stich-Desmarchelier, Torsten Kirchner, Elisabeth Schmitt) erprobt seit dem Wintersemester 2024/25 Englischmodule auf den Niveaus B2+ und C1.1 mit KI. In E-Learning-Einheiten bauen die Studierenden einen Essay Schritt für Schritt auf: Argumente sammeln und von der KI bewerten lassen, die Struktur eines Musteressays erkennen, Einleitung und Fazit mit KI-Feedback schreiben, schließlich den ganzen Essay selbstständig verfassen. Jede KI-Rückmeldung prüfen sie an verlässlichen Quellen, die die Lehrkraft bereitstellt. Ins E-Portfolio laden sie die Chats, den eigenständig verfassten Text, die KI-gestützt überarbeitete Fassung und eine angeleitete Reflexion; die Lehrkraft ergänzt das KI-Feedback um eigenes.
Was das für wirksames Lernen heißt. *Erfahrungsbericht.* Das Prüfen der KI-Rückmeldung ist selbst ein Abrufanlass im Sinne des testgestützten Lernens, das ausdrücklich die kritische Bewertung möglicherweise falscher Aussagen eines Sprachmodells einschließt. Dass der eigene Text vor der KI-Überarbeitung feststeht, folgt einer Leitplanke, die sich in den Experimenten seit 2025 bewährt: erst die eigene Antwort, dann die Antwort der KI (Xu et al., 2026) (Kapitel 3.5). Quelle: Tobor et al. (2026), S. 32–33.

3.5 Was die Forschung seit 2025 zeigt: Lernwirkung und kognitive Auslagerung

Die Mechanismen der vorigen Abschnitte sind seit Jahrzehnten belegt; ob sie mit Sprachmodellen tragen, war 2024 noch eine Vermutung. Seit 2025 gibt es Messungen mit den zwei stärksten verfügbaren Methoden, randomisierten Feldexperimenten und Paneldaten aus echten Kursen, und seit Sommer 2026 liegen die ersten großen Feldversuche vor, bei denen ein Tutor nicht als Laborprototyp, sondern als Teil eines laufenden Kurses getestet wurde. Vier Gestaltungsfragen ordnen die Befunde; je Frage stehen hier die belastbarsten oder neuesten Studien, weitere im Kasten am Ende des Abschnitts, in Anhang C und D und auf der Online-Seite „Forschungsstand“.

Lernen Studierende mit KI-Tutoren mehr? Die Antwort lautete 2025 noch „im Mittel ja“, seit 2026 lautet sie „nur unter Bedingungen“. Die Einzelstudie mit dem saubersten Design bleibt das Harvard-Experiment von Kestin et al. (2025), dessen Tutor mit Musterlösungen, Portionierung und Wachstumsdenken gebaut war (Kapitel 3.1): Studierende lernten mit ihm in weniger Zeit mehr als in der aktiven Präsenzübung. Das bislang größte Hochschulexperiment zeigt das Gegenteil für den Normalfall: An der University of Maryland erhielten per Los 2.379 Studierende in den Kursen von 30 Lehrenden Zugang zu einem Tutor, der mit den Kursmaterialien aus dem Lernmanagementsystem arbeitete; ihre Abschlussnote lag 0,37 Standardabweichungen *unter* der Kontrollgruppe, ihre Beteiligung im Kurs 0,90 Standardabweichungen darunter, und bei Erstakademikerinnen und Erstakademikern war der Verlust doppelt so groß. Nur 15 Prozent der Berechtigten nutzten den Tutor überhaupt, und drei Viertel ihrer Anfragen verlangten eine direkte Antwort, weniger als ein Prozent Rückmeldung auf eigene Arbeit (Liu et al., 2026). Dazwischen liegt das präregistrierte Schulexperiment von Oreopoulos, Liut, et al. (2026) mit 6.997 Lernenden und einem verzögerten Test: Weder ein Tutor allein noch ein Übungsablauf, der erst nach gezeigter Beherrschung weiterführt, verbesserten das Behalten; nur die Kombination tat es, und nach einem Fehler stieg mit Tutor die Trefferquote im nächsten Versuch um 8,5 Prozentpunkte. Die Meta-Analysen, die 2025 große positive Effekte berichteten, sind inzwischen methodisch geprüft: Die meisten ihrer Vergleiche setzen ChatGPT gegen Kontrollgruppen, die zugleich andere Methoden, weniger Übungszeit oder kürzere Interventionen hatten, so dass der Werkzeugeffekt nicht vom

Methodeneffekt zu trennen ist (Lawson et al., 2026); der Wissenschaftsrat nennt die Studienlage „(noch) nicht belastbar“ (Wissenschaftsrat, 2026). Ein deutscher Hochschulbeleg mit sauberem Design existiert: 334 Studierende, die sich auf eine Prüfung mit Anreiz vorbereiteten, erreichten mit freiem Zugang zu einem Tutor 0,23 Standardabweichungen mehr als mit dem Lehrbuch allein, ohne weniger zu lesen (Fischer et al., 2025).

Was passiert ohne didaktische Bremse? Hier ist die Evidenz eindeutig und sie kam zuerst. In einem Feldexperiment mit knapp tausend Oberstufenschülern verbesserte ein Tutor im Stil des normalen ChatGPT die Übungsleistung um 48 Prozent; als der Zugang in der Prüfung fehlte, lagen dieselben Schüler 17 Prozent *unter* der Kontrollgruppe, die nie Zugang hatte. Ein zweiter Tutor mit Leitplanken, der Hinweise statt Lösungen gab, hob die Übungsleistung um 127 Prozent und ließ in der Prüfung keinen Schaden zurück (Bastani et al., 2025). Die Paneldaten einer Mathematik-Lernplattform zeigen denselben Mechanismus im Großen: Über 3,2 Millionen Lerninteraktionen sank nach dem Start von ChatGPT die Lernzeit auf Aufgaben, deren Text sich in einen Chatbot kopieren lässt, kumuliert um 27 Prozent bei Studierenden und 31 Prozent in der Oberstufe, und mit ihr der daraus gebaute Wissenszuwachs; unter Aufsicht verschwindet der Effekt vollständig (Rismanchian et al., 2026). Die Dissoziation von Leistung und Behalten ist inzwischen im Labor repliziert: 59 Informatikstudierende lösten Programmieraufgaben mit ChatGPT zu 89 statt 69 Prozent, behielten den Stoff nach 48 Stunden aber nur zu 39 statt 52 Prozent und schrieben sich die Lösung seltener selbst zu (Bergh et al., 2026). Die Theorie dazu liefert Nakamura (2026): Auslagerung an die KI augmentiert, wenn sie Nebenoperationen abnimmt, und erodiert, wenn sie genau die Operationen umgeht, die das Lernziel ausmachen.

Welche Gestaltungsmerkmale schützen vor Auslagerung? Drei präregistrierte Experimente aus dem Jahr 2026 benennen die Stellschrauben, und eines davon zeigt, welche Stellschraube nicht wirkt. Eine metakognitive Rückmeldung, die Lernenden sichtbar macht, was das Abschreiben einer KI-Lösung für ihr eigenes Können bedeutet, halbierte in einem Online-Experiment mit 704 Teilnehmenden die Auslagerung und verbesserte den anschließenden Test ohne KI; eine Belohnung für eigenständiges Arbeiten blieb wirkungslos (Maier et al., 2026). In einem Cluster-Experiment mit 1.176 Erstsemestern in 48 Übungsgruppen an vier Hochschulen gewann direktes KI-Feedback kurzfristig, aber beim verzögerten Transfer ohne KI lagen die Gruppen vorn, deren Feedback zuerst zur Reflexion aufforderte

und die Kritik erst danach lieferte (Ates, 2026). Was nicht reicht, ist der Prompt allein: An der ETH Zürich durchliefen 1.059 Programmieranfänger im Crossover-Design Tutoren mit System-Prompts für selbstreguliertes Lernen und für kognitive Aktivierung nach ICAP, und auf keinem der vier konfirmatorischen Maße unterschieden sich die Varianten (Barth et al., 2026). Die Leitplanke muss also in die Aufgabe, in die Rückmeldung und in den Ablauf gebaut werden, nicht nur in die Anweisung an das Modell; wie das konkret aussieht, zeigt Kapitel D.7. Das ist die Übersetzung der erwünschten Schwierigkeiten (Kapitel 3.1) in Werkzeugdesign: eine eigene Antwort festhalten, bevor die KI antwortet, Hinweise vor Lösungen, und eine Begründungspflicht, wo eine Lösung übernommen wird (Tao et al., 2026; Xu et al., 2026).

Ihre Einschätzung prüfen

„Eine gut formulierte Anweisung an das Modell genügt, damit ein KI-Tutor zum Lernen anleitet, statt Lösungen zu liefern."
Auflösung: nein. An der ETH Zürich unterschieden sich Tutoren mit System-Prompts für selbstreguliertes Lernen und für kognitive Aktivierung auf keinem der vier konfirmatorischen Maße. Die Leitplanke gehört in Aufgabe, Rückmeldung und Ablauf: eine eigene Antwort vor der KI-Antwort, Hinweise vor Lösungen, eine Begründungspflicht, wo eine Lösung übernommen wird.

Trägt die Einbettung oder das Werkzeug? Die Einbettung, und der Engpass ist fast immer die Nutzung. In einer randomisierten Studie in 83 indischen Internatsschulen erhielten alle Zugang zur selben Lernplattform; große Lerngewinne entstanden nur dort, wo betreute Lernzeiten mit Aufsichtspersonen eingeplant waren (Oreopoulos, Keyes-Krysakowski, et al., 2026). Zwei Jahre Khanmigo an 18 Schulen brachten 0,06 bis 0,08 Standardabweichungen pro Jahr, nicht mehr als Khan Academy ohne KI, weil das mittlere Kind den Tutor an einem Drittel der Übungstage und in nur 17 Prozent der Sitzungen mit Fehler ansprach (Oreopoulos & Low, 2026); der Anbieter hat den Nullbefund öffentlich eingeräumt und den Tutor umgebaut, in die Aufgabe hinein, ohne Antwort vor dem ersten Versuch (Kapitel 4.3). Für die Hochschule zeigt ein deutsches Wirtschaftsinformatik-Semester mit drei Bedingungen dasselbe von der anderen Seite: Alle 87 Studierenden lernten, der Tutor brachte keinen Zusatzgewinn, aber auch keine Erosion; was zählte, war die Rahmung der Nutzung, nicht der Zugang (Melanou et al., 2026). Und wo die Nutzung angeleitet statt nur ermutigt

wird, kehrt der Effekt zurück: Ermutigung zum Tutor änderte in einem Ökonometrie-Kurs nichts, eine Anleitung zur tutoriellen Nutzung hob die Prüfungsleistung um 0,21 Standardabweichungen und die Bestehensquote um zwölf Prozentpunkte (Gallegos, 2026). Für die Gestaltung heißt das zusammengenommen: Ein KI-Tutor braucht Leitplanken in Aufgabe und Rückmeldung, die Hinweise vor Lösungen setzen, eine Einbettung in den Kurs, die seine Nutzung verbindlich und angeleitet macht, und einen Test vor dem Einsatz, ob er zu viel hilft (Kapitel D.7, Kapitel 5.4).

i Anwendungsbeispiel: Studierende übernehmen KI-Texte, statt sich mit ihnen auseinanderzusetzen

Problem ohne KI. Eine begründete eigene Position zu einem literarischen Thema entsteht durch wiederholtes Nachfragen, für das im Seminar wenig Zeit bleibt.
Problem mit KI. Der Chatbot liefert Quellen, Zusammenfassungen und Formulierungen sofort; die Studierenden übernehmen sie, statt sich mit ihnen auseinanderzusetzen.
Der Lösungsansatz. Nina Yuen beschreibt eine Aufgabe in sieben Schritten, am Beispiel eines Kurses über Darstellungen von „Race“ in der amerikanischen Literatur des 20. Jahrhunderts. Die Studierenden schreiben zuerst ohne KI einen kurzen Essay. Dann recherchieren sie mit dem Chatbot, entwickeln mit ihm eine Bewertungsrubrik und beurteilen ihre Arbeit danach ohne KI neu. Es folgt ein sokratischer Dialog mit dem Chatbot über drei bis fünf Ebenen von Nachfragen. Am Ende vergleichen sie eine KI-gestützte mit einer eigenen Überarbeitung und schärfen in der letzten Fassung ihre eigene Stimme.
Was das für wirksames Lernen heißt. *Unterrichtsentwurf, keine Ergebnisse berichtet.* Der erste, KI-freie Entwurf ist die eigene Antwort, die feststeht, bevor die KI antwortet. Die Reihenfolge entspricht dem Befund, dass Rückmeldung, die zuerst zur Reflexion auffordert und die Kritik danach liefert, beim späteren Transfer ohne KI besser abschneidet als direkte KI-Kritik (Ates, 2026).
Ablauf und Prompt: Kapitel B.3.1. Quelle: Yuen (2025) (AI Pedagogy Project, metaLAB at Harvard).

i Stand der Forschung bei Drucklegung, November 2026

Die vier Gestaltungsfragen dieses Abschnitts, die Kernaussagen, die bei Drucklegung die Antwort trugen, und die weiteren Belege, nach Aussagen geordnet. Die Punkte geben an, wie belastbar eine Wirkungsaussage ist: ●●● hoch, ●●○ mittel, ●○○ begrenzt. Sie folgen den Designstufen der CAT-Leitlinie des Center for Evidence-Based Management (Barends et al., 2017). Ausgangspunkt ist das stärkste Design unter den Studien einer Aussage: Meta-Analyse randomisierter Studien oder randomisierte Studie drei Punkte, kontrollierte Studie ohne Zufallszuteilung oder Paneldaten zwei, Befragung, Fallbericht oder Synthese einen. Einen Punkt weniger gibt es, wenn keine der Studien begutachtet ist, wenn die Daten vom Anbieter stammen oder wenn die Vergleiche nachweislich konfundiert sind. Erklärungen und Methodenkritik tragen keine Punkte, weil die Stufen nur Wirkungsaussagen bewerten. Ob ein Befund aus der Schule auf die Hochschule übertragbar ist, steht in der Studienangabe, nicht in den Punkten. Die Online-Seite „Forschungsstand“ führt alle Studien vollständig und wird halbjährlich fortgeschrieben.
Fett gesetzte Aussagen tragen den Fließtext dieses Abschnitts, die übrigen sind weitere Belege.

Kernaussage	Studien
Lernen Studierende mit KI-Tutoren mehr?	
Ein Tutor kann mehr Lernen bewirken als aktive Präsenzübung oder Lehrbuch allein. ●●●	• Kestin et al. (2025): RCT, Physik, Harvard; mehr gelernt in weniger Zeit • Fischer et al. (2025): RCT, 334 Studierende, Deutschland; +0,23 SD in einer Prüfung mit Anreiz

Ein Tutor, der nur bereitgestellt wird, hebt die Leistung nicht und kann sie senken. ●●○

- Liu et al. (2026): RCT, 2.379 Studierende, Maryland; −0,37 SD Abschlussnote, 15 % Nutzung
- Oreopoulos, Liut, et al. (2026): präregistrierter RCT, 6.997 Schüler; Tutor allein ohne Wirkung auf das Behalten, wirksam nur im Mastery-Ablauf
- Lawson et al. (2026): Kontrollgruppen unterscheiden sich zugleich in Methode, Übungszeit und Dauer
- Wissenschaftsrat (2026): Studienlage „(noch) nicht belastbar“

Vorbehalt: Die großen Effekte der Meta-Analysen messen nicht das Werkzeug allein.

Meta-Analysen finden mittlere bis große Durchschnittseffekte; nach etwa 23 Stunden steigt der Effekt nicht weiter. ●●○

Der Vorbehalt oben gilt für sie: Ren et al. (2026) (47 RCTs, g = 0,68), Jing et al. (2026) (Hochschule, g = 0,46), Deng et al. (2025), R. Wu & Yu (2024); Mian Wu & Ouyang (2026) trennt KI-gestützte von unbegleiteter Programmierleistung.

Weitere Feldversuche mit eigens gebauten Tutoren zeigen Gewinne, oft mit Beteiligung der Anbieter. ●●○

LearnLM Team et al. (2025) (Herstellerangabe), Harrison et al. (2026) (Sekundarstufe, g = 0,33), Northcutt et al. (2026) (KI gleichauf mit menschlichem Tutoring, Industrieautoren), Kuo & Zhuo (2026) (Tutor- plus Tutee-Bot schlägt Antwort-Bot).

Gesprochene Antworten lehren nicht besser als geschriebene, kosten aber das 2,8-Fache. ●●○

S. Yang et al. (2026) (präregistriert, 86 Online-MBA-Studierende).

Die Rolle der KI bestimmt, was steigt: als Tutor die Motivation, nicht die Klausur; als Löser die Aufgabe, nicht der Transfer. ●●○

Chakraborty (2026) (vier Experimente in einem Programmierkurs).

Was passiert ohne didaktische Bremse?

Ungebremster Zugang hebt die Leistung mit KI und senkt, was ohne KI bleibt. ●●●

- Bastani et al. (2025): RCT, knapp 1.000 Oberstufenschüler; +48 % Übung, −17 % Prüfung
- Rismanchian et al. (2026): Paneldaten, 3,2 Mio. Interaktionen; −27 % Lernzeit bei kopierbaren Aufgaben
- Bergh et al. (2026): Laborexperiment, 59 Studierende; Behalten nach 48 Stunden 39 statt 52 %
- Nakamura (2026): Theorie

Erklärung: Auslagerung schadet, wenn sie die Operationen umgeht, die das Lernziel ausmachen.

Wer per Chatbot recherchiert oder schreibt, lernt weniger und denkt weniger selbst. ●●○

Was mit KI gelingt, bleibt ohne KI nur erhalten, wo die KI ergänzt statt ersetzt oder schon Expertise da ist. ●●○

Mittal et al. (2026) (RCT, acht Tage, kritisches Denken am stärksten betroffen), Kosmyna et al. (2025) (EEG, 54 Teilnehmende, Preprint).
Contractor & Reyes (2026) (+0,27 SD, nach einer Woche nur bei ergänzender Nutzung), Autor et al. (2026) (133 Patentanwälte, Fähigkeit ohne KI nach 90 Tagen nur bei Erfahrenen).

Auch Lehrende lagern aus: Ein KI-Werkzeug für die Unterrichtsvorbereitung senkt die Lernmotivation ihrer Schülerinnen und Schüler. ●●○

Sungu et al. (2026) (randomisiertes Feldexperiment, 193 Lehrkräfte, −0,11 SD).

Welche Gestaltungsmerkmale schützen?

Rückmeldung, die zuerst zum eigenen Denken auffordert, schützt das Können ohne KI. ●●●

- Maier et al. (2026): präregistriert, 704 Teilnehmende; metakognitive Rückmeldung halbiert die Auslagerung
- Ates (2026): Cluster-RCT, 1.176 Erstsemester, vier Hochschulen; Reflexion vor Kritik gewinnt beim verzögerten Transfer

Ein System-Prompt allein ändert das Lernen nicht. ●●●

- Barth et al. (2026): präregistriertes Crossover, 1.059 Programmieranfänger, ETH; kein Effekt auf vier Maße

Gerüste wirken, wenn Planen, Abrufen und Korrigieren bei den Lernenden bleiben. ●●○	Xiaoyu Hou et al. (2026) (Prompting-Gerüst bei offenen Aufgaben), Y. Yang et al. (2026) (Planungsschritte bleiben erhalten), Ross et al. (2026) (Fehlvorstellungen weichen nur mit korrigierender Rolle), Akgun & Toker (2026) (Abruf-Übung schlägt freies KI-Lernen nach sieben Wochen).
Gemeinsam verarbeitetes KI-Feedback fördert den Transfer stärker als allein verarbeitetes. ●●●	S. Chen et al. (2027) (Cluster-RCT, 16 Wochen, 108 Studierende, China).
Sokratische Führung wirkt nach, wenn die Leitplanken fallen. ●●●	Brender et al. (2026) (randomisiert, 66 Master-Studierende, danach freie KI-Nutzung im Projekt).

Trägt die Einbettung oder das Werkzeug?

Gewinne entstehen, wo die Nutzung eingeplant und angeleitet ist, nicht durch den Zugang. ●●○	• Oreopoulos, Keyes-Krysakowski, et al. (2026): RCT, 83 indische Internatsschulen; Gewinne nur mit betreuten Lernzeiten • Gallegos (2026): zwei RCTs, Ökonometrie, Chile; Anleitung +0,21 SD, Ermutigung wirkungslos • Melanou et al. (2026): Quasi-Experiment, 87 Studierende, Deutschland; die Rahmung zählt
Bereitgestellte Tutoren werden zu selten genutzt, um zu wirken. ●●○	• Oreopoulos & Low (2026): Cluster-RCT, 18 Schulen, zwei Jahre; Nutzung an einem Drittel der Übungstage
Menschliche Begleitung hebt die Nutzung, nicht automatisch die Leistung. ●●○	Robinson et al. (2026) (zwei RCTs, Grundschule, Beteiligung +71–80 %, Lesen unverändert).
Wo Tutoren an deutschsprachigen Hochschulen laufen, fehlen Lernmaße; Befragungen zeigen keinen Unterschied im wahrgenommenen Lernerfolg. ●○○	Stumpf et al. (2026) (OneTutor, 84 Lehrveranstaltungen), Tobler & Köhler (2026) (ETH, 407 Studierende).

Reine KI-Tutoren erreichen viele nie: 40–47 Prozent nutzen sie nicht. ●○○	Turano et al. (2026) (Synthese).
Anbieterstudien berichten Gewinne, sind aber nicht unabhängig geprüft. ●○○	OpenAI (2026b), Ghahramani (2026) (Herstellerangaben).

Tabelle 3.2. Kernaussagen und Belege zu den Gestaltungsfragen in Kapitel 3, Stand November 2026.

Die lebende Fassung finden Sie online unter https://th-koln-bartnik.github.io/genai4teaching/forschungsstand.html.

Kernaussagen

Zu Lernziel 1: Zeit als Engpass

1. Das Problem der Hochschullehre ist nicht fehlendes Wissen über gute Lehre, sondern fehlende Zeit, sie umzusetzen. Genau hier kann generative KI ansetzen.

Zu Lernziel 2: Didaktische Bremsen

2. Chatbots sind darauf gebaut, hilfreich zu sein, nicht darauf, Lernen zu fördern. Ohne Anpassung nehmen sie Lernenden die Schwierigkeiten ab, die das Lernen ausmachen.

Zu Lernziel 3: Wissensstufen, Lerntechniken und ICAP

3. Welcher KI-Einsatz sinnvoll ist, hängt vom Wissenstyp ab: Abrufübungen und Erklärungen für Faktenwissen, dialogisches Coaching und durchgearbeitete Beispiele für Prozesswissen, Szenarien und Rollenspiele für Transfer.
4. Verteiltes Üben, häufige Abruftests und Warum-Fragen sind die am besten belegten Lerntechniken. Ihr Haken ist der Aufwand, und den können Sprachmodelle drastisch senken.
5. Interaktion schlägt Konstruktion schlägt aktive Beteiligung schlägt passives Zuhören. Eine KI-Lernaktivität ist umso wirksamer, je weiter oben sie auf dieser Leiter steht.

Zu Lernziel 4: Evidenz seit 2025

6. Ungebremster KI-Zugang verbessert die Übungsleistung und senkt die Prüfungsleistung; ein Tutor, der nur bereitgestellt wird, wird kaum und dann als Antwortmaschine genutzt. Leitplanken in Aufgabe und Rückmeldung (nicht nur im Prompt) und eine verbindliche, angeleitete Einbettung in den Kurs kehren das Vorzeichen um.

i Lernfragen

Wiederholen

1. Nennen Sie die drei Wissensstufen nach Hattie und je einen passenden KI-Einsatz.
2. Bringen Sie die vier Stufen der ICAP-Rangfolge in die richtige Reihenfolge.
3. Erklären Sie ohne Nachschlagen, warum ein Chatbot, der sofort die richtige Antwort gibt, dem Testeffekt entgegenwirkt. Wie müsste der Bot stattdessen reagieren?

Anwenden

4. Ordnen Sie drei Lernziele Ihrer Veranstaltung den Stufen knowing that, knowing how und knowing with zu. Welche Stufe kommt bei Ihnen zu kurz, und welche KI-gestützte Methode aus diesem Kapitel würde sie stärken?
5. Wo in Ihrem Semesterplan könnten Sie mit geringem Aufwand verteiltes und gemischtes Üben einbauen, wenn ein Sprachmodell die Aufgabenvarianten liefert?

Beurteilen

6. Ein Kollege berichtet, seine Studierenden hätten mit einem KI-Tutor in den Übungen deutlich besser abgeschnitten. Welche eine Frage stellen Sie ihm, bevor Sie den Tutor übernehmen, und warum?
7. Ein Anbieter wirbt mit einem Tutor, dessen System-Prompt sokratisches Fragen und kognitive Aktivierung vorschreibt.

Reicht das als Leitplanke? Begründen Sie mit den Befunden des Kapitels.

Lösungshinweise: Anhang F.

4 Vier Szenarien der Nutzung von GenAI: Hiwi, Copilot, Tutor, Simulator

Wie nutzen Lehrende generative KI? Wir sortieren die sehr vielfältigen Hilfestellungen der neuen Tools in vier Kategorien von Anwendungen: Hiwi, Copilot, Tutor, Simulator (E. R. Mollick & Mollick, 2023b, 2024).

Hier ein Beispiel für einen Tutor-Bot, den wir seit dem Wintersemester 2025/26 als Hilfestellung für das Modul "Grundlagen der BWL" erproben; neue Themen werden laufend ergänzt.

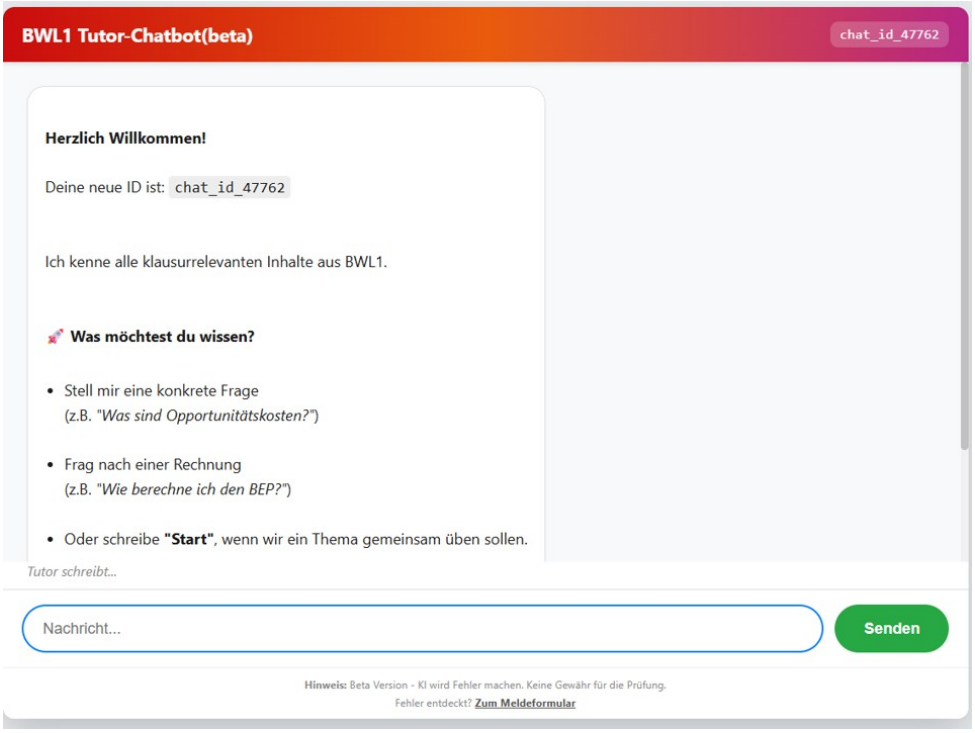

Abbildung 4.1. Beispiel: Tutor-Bot BWL Grundlagen. Screenshot der Testversion, Januar 2026

Eine Testversion und der aktuelle Stand des Projekts sind über die Online-Fassung dieses Buches erreichbar; Aufbau, Betrieb und Erfahrungen beschreibt Kapitel 6.2.2.

Lernziele

Nach diesem Kapitel können Sie …

- die vier Rollen Hiwi, Copilot, Tutor und Simulator unterscheiden, eigene Ideen zuordnen und abschätzen, welche Aufgaben dadurch wegfallen, schneller werden oder neu entstehen;
- ein Recherchewerkzeug nach dem Muster der Aufgabe statt nach dem Markennamen wählen;
- beurteilen, wie viel Studierende beim Schreiben und Programmieren mit KI selbst verantworten müssen, und prüfen, ob eine KI-gebaute Simulation rechnet oder nur abspielt;
- beschreiben, was ein KI-Tutor und eine KI-Simulation brauchen, damit sie das Lernen fördern.

Probleme aus der Lehre

Zu jedem dieser Probleme bietet das Kapitel Lösungsansätze. Wählen Sie eine Antwort, bevor Sie weiterlesen: Wer vorher rät, behält die Auflösung besser. Die Kernaussagen am Kapitelende greifen die Probleme in derselben Reihenfolge auf.

1. Im Kollegium reichen die Ideen für KI von Folienerstellung bis Verhandlungstraining, und niemand behält den Überblick. Wie ordnen Sie sie sinnvoll?

a) Nach Anbieter, also nach dem verwendeten Produkt.
b) Nach Kosten, also kostenlos oder lizenzpflichtig.
c) Nach Rolle: abnehmen, mitarbeiten, begleiten oder Übung bereitstellen.

2. Die Übungsaufgaben waren mit KI in einer Stunde statt einem Tag fertig. Jetzt verbringen Sie Abende damit, Lösungen zu prüfen und einen Tutor-Bot zu pflegen. Was beschreibt das?

a) Einen Bedienfehler; mit besseren Prompts entfiele das Prüfen.
b) Das übliche Muster: Arbeit fällt weg, wird schneller oder entsteht neu.

c) Den Beleg, dass KI in der Lehre grundsätzlich keine Zeit spart.

3. Für einen Antrag brauchen Sie einen Überblick über den Forschungsstand und überlegen, welches KI-Werkzeug Sie nehmen. Wonach entscheiden Sie?

a) Nach dem Muster: einmalige oder iterative Suche, Trefferliste oder Analyse.
b) Nach dem bekanntesten Anbieter, weil er die meisten Quellen kennt.
c) Nach der Zahl der Quellen, die das Werkzeug in der Werbung verspricht.

4. Ein KI-Tutor erklärt Ihren Studierenden eine Rechenaufgabe überzeugend und falsch. Was hätte das am ehesten verhindert?

a) Die Anweisung „Mach keine Fehler“ am Anfang des Prompts.
b) Musterlösungen als Grundlage und Qualitätstests vor dem Einsatz.
c) Ein Tutor, der nur Fragen stellt und nie etwas erklärt.

5. Ihre Studierenden üben Verhandlungen mit einer KI-Simulation. Die Gespräche laufen flüssig, aber es bleibt wenig hängen. Was fehlt?

a) Mehr Durchgänge, die Studierende allein absolvieren.
b) Eine realistischere Stimme und Mimik der KI-Figur.
c) Rahmung vorher und eine Nachbesprechung durch Sie.

4.1 KI als Hiwi

4.1.1 Was sind unsere Aufgaben?

Beschäftigte in Forschung und Lehre erfüllen eine Vielzahl sehr heterogener Aufgaben, mit einem wachsenden Teil an „Verwaltung“. Wer lehrt, merkt schnell, dass die Präsenzveranstaltung nur die Spitze eines ganzen Eisbergs an Aufgaben darstellt. Eine Umfrage unter Lehrenden in Österreich zeigt, dass sie etwa ein Drittel ihrer Zeit mit Lehraktivitäten verbringen (32 %) und etwa ein Fünftel mit Verwaltungstätigkeiten in der Hochschule

(20 %) sowie ein weiteres Fünftel mit externen Verpflichtungen wie Gutachten oder Tätigkeiten in wissenschaftlichen Gesellschaften (9 %, 10 %) (Österreichischer Universitätsprofessor/innenverband, 2018). Wie Unkraut im Garten wächst der Anteil, den Lehrende mit „sonstigem“ verbringen: Vor allem der Zeitaufwand für Verwaltung stieg an (Schomburg et al., 2012).

Woraus besteht das im Detail und wo könnten LLMs helfen? Vor- und Nachbereitung, Evaluation, Beratung, Planung und vieles mehr lassen die Stunden eines Tages schnell vergehen. Abbildung 4.2 zeigt die 25 Hauptaufgaben, die Lehrende nach Umfragen des US-Arbeitsministeriums verrichten (https://www.onetonline.org/link/summary/25-1011.00). Welche Auswirkungen können wir von LLM auf diese konkreten Aufgaben erwarten?

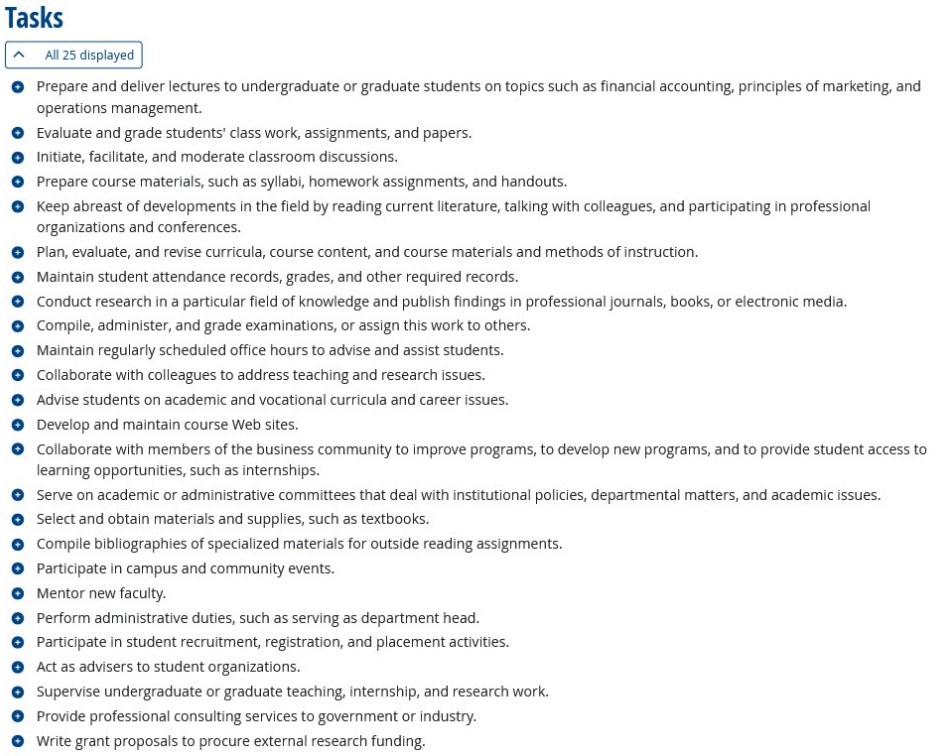

Abbildung 4.2. Was für Aufgaben erledigen Lehrende? 25 Einzelaufgaben am Beispiel „Business Teachers, Postsecondary“ nach Umfragen des US-Arbeitsministeriums auf O*NET. Quelle:* ONET, 2025

Historische Studien zeigen, dass Technologie typischerweise **Tätigkeiten** (tasks) beeinflusst und eher selten ganze Jobs ersetzt. Den Rahmen dafür liefert das Aufgabenmodell (task model), das der Nobelpreisträger Daron Acemoglu mit Fredric Kong und Pascual Restrepo im *Handbook of Labor Economics* zusammengefasst hat (Acemoglu et al., 2025). Für Lehrende, die ihre eigene Arbeit planen, zählen drei Formen technologischen Wandels aus diesem Modell. Bei der **Automatisierung** (automation) wandert eine Aufgabe vom Menschen zur Technik. Bei der **Augmentierung** (labor-augmenting technology) bleibt die Aufgabe beim Menschen, der sie mit technischer Unterstützung schneller oder besser erledigt. Und Technik schafft **neue Aufgaben** (new tasks), die es vorher nicht gab. Die vierte Form des Modells, leistungsfähigere Maschinen in Aufgaben, die sie schon erledigen (capital-augmenting technology), lassen wir hier beiseite. Die Arbeitsmarktforschung beschreibt die Folgen aus Sicht der Beschäftigten und spricht von Verdrängung (displacement effect) und Wiedereinsetzung (reinstatement); wer die eigene Lehre plant, fragt dagegen, welche Aufgabe wohin wandert.

Form	Beschreibung	Aufgaben in der Lehre (Beispiele)
Automatisierung (automation)	Aufgabe wandert vom Menschen zur KI	• Erstellung, Durchführung und Bewertung von Prüfungen (x) • Verwaltung von Noten und Anwesenheit (x) • Vorbereitung standardisierter Lehrmaterialien (x) • Zusammenstellung von Bibliographien (x)
Augmentierung (labor-augmenting technology)	KI unterstützt Menschen; dieselbe Aufgabe braucht weniger Zeit oder gelingt besser	• Vorbereitung und Durchführung von Vorlesungen (x) • Durchführung von Seminaren und Diskussionen (x) • Akademische und berufliche Beratung (?/x) • Forschung und Publikation (x) • Pflege von Webseiten und digitalen Ressourcen (?/x)

Form	Beschreibung	Aufgaben in der Lehre (Beispiele)
Neue Aufgaben (new tasks)	KI schafft Aufgaben, die es vorher nicht gab	• Entwicklung KI-gestützter Lehrkonzepte (x) • Qualitätskontrolle von KI-Materialien (x) • Gestaltung individueller Lernpfade (x) • Ethische und rechtliche Begleitung (x) • Weiterbildung des Personals (x)

Tabelle 4.1. Welche Aufgaben in der Lehre wandern zur KI, bei welchen unterstützt sie, und welche kommen neu hinzu? Legende: x = klarer Effekt, ? = gemischter Effekt. Quelle: Aufgabenmodell nach Acemoglu et al. (2025)

In Tabelle 4.1 übertragen wir die drei Formen auf konkrete Aufgaben in der Hochschullehre.

Das folgende Video spielt die drei Formen an den Aufgaben aus Tabelle 4.1 durch. Vier Kacheln wandern von der Lehrperson zur KI, fünf schrumpfen, weil dieselbe Aufgabe weniger Zeit braucht, und fünf neue kommen hinzu. Die Größen der Kacheln sind nicht gemessen; sie zeigen die Richtung der Effekte, nicht ihr Ausmaß.

Die **Automatisierung** betrifft hauptsächlich administrative und stark standardisierte Tätigkeiten. Aufgaben wie das Erstellen, Durchführen und Bewerten von Prüfungen, die Verwaltung von Noten und Anwesenheiten sowie die Vorbereitung standardisierter Lehrmaterialien oder Literaturzusammenstellung werden voraussichtlich vollständig oder überwiegend von KI übernommen. Anwendungsstudien und Umfragen der letzten zwei Jahre geben hierzu deutliche Hinweise (Morgan, 2024; Naddaf, 2025; Ogunleye et al., 2024; Ou et al., 2024; Tutton & Cohen, 2025). Wie weit die Automatisierung bei der Bewertung tatsächlich reicht, lässt sich inzwischen präzise sagen. Sehfähige Sprachmodelle bewerten fotografierte handschriftliche Mathematik-Abgaben entlang der Rubriken der Lehrenden insgesamt zuverlässig, aber 87 % der verbleibenden Fehler des besten Modells sind **Transkriptionsfehler** (Handschrift lesen, äquivalente Umformungen erkennen, Bildqualität), nicht falsch angewandte Bewertungskriterien (Levine et al., 2026). Automatisiert wird also die Rubrik-Anwendung; die menschliche Arbeit verlagert sich auf Erfassungsqualität und stichprobenartige Kontrolle,

Video online

Laufzeit 38 s

Abbildung 4.3. Automatisierung, Augmentierung und neue Aufgaben an den Aufgaben aus Tabelle 4.1: Vier Aufgaben wandern zur KI, fünf schrumpfen, fünf neue kommen hinzu. Schlussbild eines Videos (38 s), erstellt mit Claude Code und HyperFrames; Kachelgrößen nicht gemessen. Das Video gibt es nur in der Online-Version: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/kapitel04.html#vid-acemoglu-restrepo aufrufen.

ein konkretes Beispiel für die neue Aufgabe „Qualitätskontrolle von KI-Materialien“ im Feld „Neue Aufgaben“ derselben Tabelle (zu den Grenzen KI-gestützten Benotens vgl. Kapitel 5.4).

Die **Augmentierung** betrifft zentrale Lehr-, Forschungs- und Betreuungstätigkeiten, die mit KI-Unterstützung effizienter werden. Dazu zählen die Vorbereitung und Durchführung von Vorlesungen, Seminaren und Diskussionen, akademische und berufliche Beratung der Studierenden sowie Forschung und Publikationen. KI unterstützt hier durch automatische Literaturauswertungen, personalisierte Lerninhalte oder Pflege digitaler Ressourcen, sodass Lehrende ihre Kernaufgaben besser und effektiver erfüllen können (Gottweis et al., 2025; Meincke et al., 2024; E. R. Mollick & Mollick, 2023a, 2024; Schwarcz et al., 2025).

Gemischte Effekte treten bei einigen Aufgaben wie der Entwicklung und Pflege von Kurswebseiten, dem digitalen Aufzeichnen von Vorträgen und der Auswahl von Lehrmaterialien auf, bei denen KI Teile der Aufgabe übernimmt und die Lehrenden beim Rest unterstützt.

Schließlich schafft generative KI gänzlich **neue Aufgaben**. Dazu gehören

beispielsweise die Entwicklung neuer KI-gestützter Lehrkonzepte und -methoden, Qualitätskontrollen von KI-generierten Lehrmaterialien, Gestaltung individueller Lernpfade, ethische und rechtliche Begleitung des KI-Einsatzes sowie die Weiterbildung des Lehrpersonals im Umgang mit KI-Technologien (Dihan et al., 2025; E. R. Mollick et al., 2024; E. R. Mollick & Mollick, 2024).

Durch diese differenziertere Analyse der drei Formen wird klar, dass die Einführung von KI in die Lehre zwar mit hoher Sicherheit **deutliche Änderungen im Aufgaben-Mix** und der Zeitanteile bedeutet, die wir mit verschiedenen Aufgaben verbringen. Das ist nicht neu: Wer bestellt noch regelmäßig per Fernleihe, schickt Briefe oder kopiert in großem Umfang? Wir sehen, dass generative KI wahrscheinlich mittelfristig einen Teil der bisherigen Tätigkeiten automatisieren, Lehrende bei zentralen Kernaufgaben unterstützen und zugleich neue, spezialisierte Aufgaben in der Lehre schaffen wird.

Ob das **insgesamt zu einer Zeitersparnis führt, ist keineswegs sicher**, denn die neuen Aufgaben um die Einrichtung und Betreuung der KI-Unterstützung können sehr zeitintensiv sein, als Beispiel sei hier etwa die Einrichtung eines Physik-Tutor-Bots (Kestin et al., 2025) oder einer Startup-Simulation, in der KI in verschiedenen Rollen beim Aufsetzen und Verbessern von Geschäftsplänen hilft (E. R. Mollick et al., 2024). Beide Konzepte führen sichtlich zu einer Verbesserung der Lehre, aber die gibt es auch hier nicht umsonst.

4.1.2 Fachartikel finden und auswerten: Welches Werkzeug passt zu welcher Aufgabe?

Was leisten die KI-Helfer bei der Literaturrecherche, und wie prüft man, was sie liefern? Die besten Antworten darauf gibt der Bibliothekar Aaron Tay von der Singapore Management University, der die Werkzeuge seit Jahren systematisch testet (https://aarontay.substack.com/) (Tay, 2025). Zwei Unterscheidungen ordnen das Feld: Wird einmalig gesucht oder in mehreren Schleifen (einmalige Suche gegenüber agentischem Suchprozess)? Und bekommt man eine Trefferliste oder eine aus den Treffern erzeugte Zusammenfassung (Ergebnisliste gegenüber RAG-basierter Analyse)? Daraus ergeben sich vier Typen (Tabelle 4.2 und Abbildung 4.4); die Produktnamen in der Abbildung sind ein datierter Schnappschuss, die Typen bleiben.

Suche	Ausgabe	Typ nach Tay	Was man praktisch bekommt
einmalig	Liste	Quick Search	Klassische Trefferliste mit Ranking (etwa der Bibliothekskatalog oder Google Scholar), ohne erzeugten Antworttext
einmalig	Zusammenfassung	Quick RAG	Kurze „Antwort mit Zitaten“ aus den obersten Treffern; meist wenige Absätze
iterativ	Liste	Deep Search	Mehrere Suchschleifen über Minuten mit Abfragevarianten und Zitationsverfolgung; ein Sprachmodell bewertet die Relevanz; das Ergebnis bleibt eine Liste, meist eine bessere
iterativ	Bericht	Deep Research	Deep Search plus Berichterstellung: eine längere Synthese auf Basis des iterativ gefundenen Korpus

Tabelle 4.2. Vier Typen von KI-Suchhelfern nach zwei Unterscheidungen. Quelle: Tay (2025)

Hinter dem Wort „iterativ“ verbirgt sich die wichtigere Frage, *wie* ein Werkzeug iteriert: als fest verdrahteter Ablauf mit ein paar KI-Entscheidungspunkten oder als Agent, der eine Aufgabe flexibel zerlegen kann. Tay beschreibt ein Agency-Spektrum und ordnet die meisten akademischen Deep-Research-Tools am verdrahteten Ende ein: beeindruckend innerhalb ihrer Schablonen, spröde außerhalb (Tay, 2025). Sein Stresstest macht das sichtbar: „Finde Arbeiten, die Paper X hätte zitieren sollen, aber nicht zitiert hat.“ Eine menschliche Hilfskraft zerlegt das in drei Schritte (ähnliche Arbeiten finden, deren Referenzen extrahieren, die Überlappung abziehen); allgemeine Sprachmodelle mit Werkzeugen führen diese Logik eher aus, während spezialisierte Tools scheitern, weil die Aufgabe nicht in ihren eingebauten Ablauf passt. Für die Lehre folgt daraus die Regel aus Kapitel 2.1.4: Je freier das Werkzeug arbeitet, desto klarer müssen die Kontrollpunkte sein, an denen wir das Ergebnis prüfen.

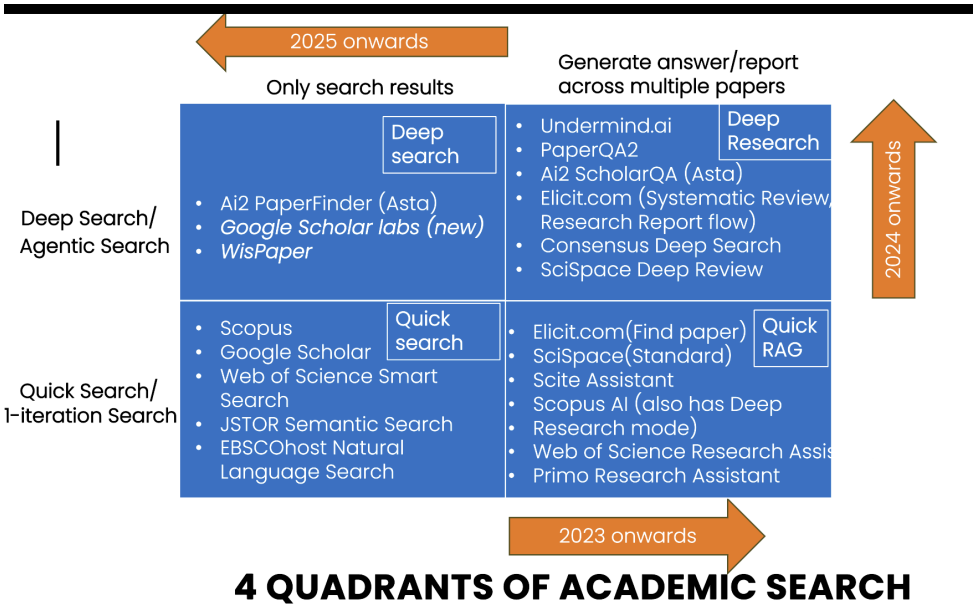

Abbildung 4.4. Einmal fragen oder mehrfach? Nur Ergebnisse oder Analyse? Zwei Unterscheidungen und vier Quadranten von Such-Helfern mit KI; Produktbeispiele Stand 2026. Quelle: Tay (2025)

Aus der Lehre: Literaturrecherche in vier Phasen

In unserer Übung zur Literaturrecherche im Wirtschaftsingenieurwesen arbeiten Studierende in vier Phasen: Thema eingrenzen, Quellen auswählen, suchen, auswerten (Bartnik & Schmid, 2025). Die Werkzeugtypen haben darin feste Plätze (Tabelle 4.3); die Entscheidungen fallen in den ersten beiden Phasen, bevor ein Werkzeug sucht.

Beim Eingrenzen legen die Studierenden Hauptthema, Kontext, Variablen, Stichwörter, Ausschlussbegriffe und Zeitraum fest. Beim Auswählen bestimmen sie eine Liste anerkannter Zeitschriften, etwa nach dem VHB-Rating, und suchen in Publish or Perish über deren ISSN; die Sortierung „nach Relevanz“ in Google Scholar ist kein Qualitätsranking.

Erst beim Suchen kommt das Sprachmodell dazu, als Übersetzer: Es schreibt aus den festgelegten Kriterien die Suchsyntax. Das ist Quick Search mit einem Sprachmodell davor, und die Suchstrategie bleibt bei den Studierenden. Gemessen ist das für systematische Reviews in der Medizin: ChatGPT schrieb Boolesche Suchanfragen mit hoher Präzision (wenig Unpassendes unter den Treffern), aber geringerem Recall (relevante Studien fehlen); wiederholte Läufe lieferten verschiedene Anfragen, ein Beispiel-Query im Prompt und mehrere Dialogrunden halfen (Shuai Wang et al., 2023). Die Nachprüfung fand den Ausschlag bei Modell- und Promptwahl und einen Vorteil durch gut gewählte Schlüsselstudien (Shuai Wang et al., 2025). Unsere Regel: Syntax lesen, Trefferzahl in einer zweiten Datenbank gegenprüfen, mit zwei bekannten Schlüsselstudien testen, ob die Suche sie findet. Fehlen sie, hat die Syntax eine Lücke, nicht die Forschung.

Wie wir selbst mit Publish or Perish und ISSN-Filter gesucht haben, zeigt Kapitel C.2.

Phase	Werkzeugtyp	Beispiele (Stand 2026)
Thema eingrenzen	Quick RAG: Antwort mit Zitaten zur Orientierung	Consensus, Elicit
Quellen auswählen	Quick Search mit Filter nach Zeitschrift oder ISSN	Publish or Perish, Google Scholar
Suchen	Quick Search, Sprachmodell schreibt die Syntax	Google Scholar, Publish or Perish, EBSCO

Phase	Werkzeugtyp	Beispiele (Stand 2026)
Suchen	Deep Search: mehrere Suchschleifen, Ergebnis ist eine Liste	Undermind
Suchen	Zitationsnetz: vom Startartikel zu verwandten Arbeiten	Connected Papers, Research Rabbit
Auswerten	Zusammenfassung und Extraktionstabelle je Artikel	Elicit, Semantic Scholar
Auswerten	Zitationskontext: gestützt oder bestritten?	Scite
Auswerten	Deep Research: Bericht, höchstes Fehlerrisiko	Deep-Research-Modi der Sprachmodelle
Auswerten	Datenzugriff per API: eigene Auswertungen mit Code	OpenAlex, Semantic Scholar API

Tabelle 4.3. Werkzeugtypen je Phase der Literaturrecherche. Typen nach Tay (2025), ergänzt um drei Typen ohne erzeugten Text (Zitationsnetz, Zitationskontext, API); Produktnamen sind ein Schnappschuss (Stand 2026), die Typen bleiben. Quelle: eigene Zuordnung nach Bartnik & Schmid (2025)

Beim Auswerten gefundener Artikel gilt eine ähnliche Staffelung (Tay, 2024a). Die Zusammenfassung eines einzelnen Dokuments ist am wenigsten riskant und eignet sich für die schnelle Relevanzprüfung; die sequenzielle Auswertung vieler Dokumente nach denselben Fragen (Design, Stichprobe, Befund) ergibt eine Codier-Tabelle, deren Zellen man stichprobenartig gegen das PDF prüft; die Synthese über mehrere Dokumente zu einer Frage trägt das höchste Fehlerrisiko, weil sich Suchfehler, untreue Zusammenfassung und schwache Gewichtung der Evidenz addieren. Die Kurzform „Antwort mit Zitaten“ ist für wissenschaftliche Arbeit deshalb meist nur ein Teaser: Man braucht den Originaltext für Kontext, Operationalisierung und Geltungsgrenzen, und erzeugter Text kann Quellen etwas zuschreiben, das sie so nicht sagen (fehlende *source faithfulness*) (Tay, 2025). Ein praktisches Problem der spezialisierten Suchwerkzeuge kommt hinzu: Sie kommen nicht hinter die Bezahlschranken der Verlage und arbeiten deshalb mit Abstracts oder Open-Access-Korpora. Akademische Konnektoren zu den großen Sprachmodellen verschieben die Arbeit hier von abstract-basiertem Raten zu passagenbasiertem Prüfen, weil das Modell über eine institutionelle Anmeldung lizenzierte Volltexte durchsuchen und Behauptungen an Fundstellen binden kann, begrenzt auf den Bestand des jeweiligen Anbieters

(Tay, 2024b). Wie eine Agentenrecherche mit festen Kontrollpunkten in der Praxis abläuft, zeigt Kapitel D.4.

Der 4D-Kreislauf beim Hiwi. Beim Hiwi reißt der Kreislauf (Kapitel 2.6) an zwei Stellen, bei der Delegation und bei der Prüfung des Ergebnisses; die Beschreibung ist meist einfach. *Delegation:* Tabelle 4.1 ist bereits eine Delegationsanalyse, denn sie trennt, was zur KI wandern kann, von dem, wobei sie nur hilft. *Description:* Wer Artikel auswerten lässt, legt die Spalten der Extraktion fest wie ein Codebuch; klar definierte Variablen werden zuverlässiger extrahiert als freie Zusammenfassungen (Tay, 2024a). *Discernment:* Zwei gleich eingestellte KI-Läufe kamen in einem Scoping Review bei 94 Datensätzen zu unterschiedlichen Urteilen (Figalová et al., 2026); ein zweiter Lauf ist deshalb die billigste Prüfregel. *Diligence:* Material für Studierende geht erst nach der Prüfung hinaus; geprüfte, quellengebundene Lernhilfen senkten in einem Kohortenvergleich vor allem den Anteil schwacher Prüfungsergebnisse [C. T. Dang & Nguyen (2026); Preprint]. Was die Prüfung regelmäßig als unzuverlässig zeigt, wandert aus der Delegation wieder heraus.

4.2 KI als Copilot

In dieser Kategorie hilft das Sprachmodell uns dabei, etwas zu tun, was wir sonst nicht könnten. E. R. Mollick & Mollick (2024) beschreiben mehrere solcher Ansätze: Bei der **"Case Co-Creation"** (E. R. Mollick & Mollick, 2024, S.25–28) arbeiten Studierende mit der KI zusammen, um ein Fallbeispiel für Kommilitonen zu erstellen. Dies fördert die Artikulation von Ideen und die kritische Auseinandersetzung mit dem KI-Output, da die initialen Entwürfe oft oberflächlich sind und durch studentische Expertise verbessert werden müssen. Die Übung **"Critique the AI"** lässt die KI ein Szenario zu einem Konzept (z. B. Groupthink) erstellen, das die Studierenden dann kritisch bewerten und ggf. verbessern müssen. Dies schult das Erkennen von Konzeptmerkmalen und die Fähigkeit, Wissen durch Korrektur zu artikulieren. Eine Herausforderung ist, dass die KI Konzepte manchmal unvollständig oder fehlerhaft illustriert, was aber Teil des Lerneffekts sein kann (E. R. Mollick & Mollick, 2024).

i Anwendungsbeispiel: Wer nicht selbst rechnen kann, erkennt die Fehler des Copiloten nicht

Problem ohne KI. Eine Kennzahlenanalyse am echten Geschäftsbericht ist mühsam: Zahlen aus Bilanz und Gewinn- und Verlustrechnung heraussuchen, die Komponenten der Eigenkapitalrendite berechnen, das Ergebnis deuten.
Problem mit KI. Ein Copilot liefert die DuPont-Analyse in Sekunden und erklärt sie Schritt für Schritt. Ob sie stimmt, erkennt nur, wer den Rechenweg selbst beherrscht.
Das Dilemma. David Pedersen lässt Studierende die DuPont-Analyse der Eigenkapitalrendite von Coca-Cola für 2022 zuerst selbst aus dem Jahresbericht (10-K) bei der US-Börsenaufsicht berechnen und kurz deuten. Erst dann führen sie dieselbe Analyse mit Microsoft Copilot durch, stellen mindestens eine Nachfrage, reichen das Protokoll ein und reflektieren in 300 Wörtern, wie viel Führung die KI für ein richtiges Ergebnis brauchte. Die Zeitersparnis des Copiloten gibt es erst nach der eigenen Rechnung.
Was das für wirksames Lernen heißt. *Unterrichtsentwurf, keine Ergebnisse berichtet.* Die Reihenfolge schützt vor der Trennung von Leistung und Behalten, die im Labor gemessen ist: Mit ChatGPT lösten Informatikstudierende mehr Aufgaben, behielten den Stoff aber schlechter (Bergh et al., 2026). Und sie macht die zerklüftete Grenze der Modelle erfahrbar (Dell'Acqua et al., 2023): Ob der Copilot bei dieser Rechnung zuverlässig ist, zeigt erst der Vergleich mit dem eigenen Ergebnis.
Ablauf und Prompt: Online-Fassung von Anhang B. Quelle: Pedersen (2025) (AI Pedagogy Project, metaLAB at Harvard).

Dass ein Copilot auch fehlendes Vorwissen überbrücken kann, solange die Lehrenden den Studierenden die Prüfarbeit nicht abnehmen, zeigt ein Seminar aus der Mediävistik.

i Anwendungsbeispiel: Fehlende Lateinkenntnisse versperren den Zugang zu den Quellen

Problem ohne KI. Wer mittelalterliche Geschichte studiert, braucht Latein und für Handschriften auch Transkriptionsfähigkeit. Nicht alle Studierenden bringen das mit, und Lehrveranstaltungen zum Mittelalter werden häufig gemieden.
Problem mit KI. ChatGPT, Transkribus und Google Übersetzer öffnen den Zugang zu den Quellen, machen aber Fehler, die Anfängern ohne Latein kaum auffallen.
Das Dilemma. Cristina Andenna und Miriam Weiss (Universität des Saarlandes) haben das Seminar „ChatGPT und Mediävistik" als Held:innenreise in zwölf Etappen angelegt. Die Studierenden transkribieren, übersetzen und deuten einen Quellentext selbst; die Werkzeuge treten als „Mentoren" auf, mal hilfreich, mal nicht. Die Schwierigkeit liegt bei den Lehrenden: Bei offensichtlichen Fehlern der KI greifen sie nicht ein, damit die Studierenden den Prozess selbst durchleben. Das kostet Zeit und die Gewissheit, dass am Ende alles stimmt, und es nimmt den Lehrenden keine Arbeit ab: Die Arbeit der Studierenden mit KI muss eng begleitet werden.
Was das für wirksames Lernen heißt. *Evaluiert über Selbsteinschätzungen vor und nach der Lehrveranstaltung.* Die Begleitforschung fand signifikante Verbesserungen der digitalen Kompetenzen und der intrinsischen Motivation; gemessen wurde die Einschätzung der Studierenden, nicht ihre Leistung (Wannemacher et al., 2025, Case 146). Das Nicht-Eingreifen erhält eine erwünschte Schwierigkeit (E. L. Bjork & Bjork, 2011): Den Fehler der Maschine selbst zu finden, ist die eigentliche Lernaufgabe.
Quelle: Wannemacher et al. (2025), Case 146.

4.2.1 Besser schreiben – als Cyborg

Wer akademisch schreibt, lässt sich zunehmend von einer Vielzahl an unterstützenden KI-Systemen über die Schultern schauen – oder die Hand führen –, die Vorschläge zur besseren Sprachverwendung machen, wie DeepL, Grammarly, oder ChatGPT (Ou et al., 2024). Ou et al. (2024) sprechen von AI-assisted language tools (AILT), die Studierenden dabei helfen, ihre Sprachfähigkeiten etwa von einer in die andere Sprache zu übertragen und das Sprachniveau ihrer Schreibprodukte generell zu verbessern. In ihrer Studie analysieren sie die Kommentare von 1703 schwedischen Studierenden und stellen komplexe Muster der Nutzung fest: „...students align their own languages, writing skills and thinking with the algorithm-based language processes (e.g., lexical, grammatical, and textual corrections, word choice suggestions, language translation) within AI chatbots, writing assistance, and machine language translation to optimise the outcomes of their academic writing. ... students have become 'spatially extended cyborg[s]' ".

Studierende schreiben durch die zunehmend mächtigere technische Unterstützung ihre Haus- und Abschlussarbeiten deutlich anders. Bedeutet dies das Ende der Hausarbeit? Wohl eher einen starken Wandel, denn es wird weiter wichtig sein, die saubere Argumentation zu üben (Friedrich, 2023; Klein, 2023).

Dafür lassen sich die einzelnen Schreibschritte gezielt trainieren, Teil für Teil. Für den Kurs zum wissenschaftlichen Arbeiten im Wirtschaftsingenieurwesen der TH Köln haben Julia Schmid und ich acht Schreibtrainer entwickelt, die eine Abschlussarbeit vom ersten bis zum letzten Kapitel begleiten (Tabelle 4.4). Jeder Trainer ist eine ausführliche Anweisung, ein Prompt, der ein Sprachmodell in einen geduldigen Übungspartner verwandelt.

Trainer	Teil der Arbeit	Lernziel	Übungsformat
1 Einleitung	Einleitung	Hook, Hintergrund mit Quelle und Forschungsfrage verbinden; erkennen, wann eine Quelle nötig ist	Quiz, Mini-Einleitung mit Feedback, Analyse einer echten Einleitung

Trainer	Teil der Arbeit	Lernziel	Übungsformat
2 Forschungsstand	Stand der Forschung	Bestehende Forschung bündeln und die Lücke zeigen	Quiz, Vergleich zweier Forschungsstände, eigener Mini-Forschungsstand
3 Methoden	Methodenteil	Das Vorgehen begründen statt nur beschreiben	Methodenwahl in sechs Runden, starke und schwache Passagen vergleichen
4 Literature Review	Strukturierte Literaturübersicht	Literatur auswählen, auswerten und darstellen	Sechs Module mit Quiz und Mini-Fall; Punkte, Medaille, Urkunde
5 Diskussion	Diskussion	Ergebnisse einordnen statt wiederholen	Sätze dem Forschungsstand oder der Diskussion zuordnen, Bausteine üben
6 Artikelstruktur	Gesamtaufbau	Die Funktion jedes Abschnitts kennen	Quiz, Zuordnungsübung, eigene Gliederung
7 Limitationen	Limitationen und Ausblick	Grenzen als begründete Designentscheidung mit Trade-offs darstellen	Vier Szenarien, Quiz zum Ausblick
8 Absätze	Jeder Absatz	Topic Sentence, Belege und Abschlusssatz verbinden	Drei Sortierübungen, eigener Absatz, Analyse eines echten Absatzes

Tabelle 4.4. Acht Schreibtrainer entlang der Abschlussarbeit (TH Köln, Wirtschaftsingenieurwesen; Julia Schmid und Roman Bartnik)

Alle acht folgen demselben Muster. Der Trainer erklärt kurz, wozu der Textteil dient, stellt Quizfragen und gibt bei falschen Antworten einen Hinweis statt der Lösung. Dann schreiben die Studierenden einen kurzen eigenen Text, erhalten Rückmeldung und überarbeiten ihn. Zum Schluss untersuchen sie einen echten Text und übertragen das Gelernte auf ihr eigenes Thema. Der Trainer für Limitationen zeigt, dass ein Bot auch eine Haltung vermitteln kann: Er übt in vier Szenarien, Limitationen als bewusste Entscheidung mit Preis zu schreiben statt als Pannenbericht. Der Trainer für Literature Reviews setzt auf Spielelemente, mit Punkten für

richtige Antworten und am Ende einer Medaille und einer Urkunde (zu Lernspielen siehe Kapitel E.5).

Wie fragil solche Werkzeuge sind, zeigt ihre eigene Geschichte. Die Trainer liefen zunächst als Custom GPTs bei OpenAI, und OpenAI stellt diese Form der Chatbots am 11. Dezember 2026 ein (OpenAI, 2026d). Was bleibt, ist die Anweisung. Sie funktioniert in jedem Chatwerkzeug, auch im Angebot der eigenen Hochschule, und trägt deshalb besser als jeder Link auf eine Plattform.

Probieren Sie mal

Zwei der Trainer stehen online zum Ausprobieren bereit: der **Einleitungstrainer** und der **Absatztrainer** für Topic Sentences von Julia Schmid. Die Anweisung kopieren, in einen neuen Chat einfügen, absenden – der Trainer beginnt von selbst.

Abbildung 4.5. Schreibtrainer zum Kopieren: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/schreibtrainer.html aufrufen.

Wie stark die KI an einem Text mitwirkt, lässt sich auf einer vierstufigen Skala von „zur Inspiration“ bis „inhaltsgestaltend“ beschreiben; Studierende nutzen sie, um ihre KI-Nutzung zu dokumentieren (Tabelle 5.3).

Ethan und Lilach Mollick schlagen Hausarbeiten vor, die KI nicht zur Automatisierung einsetzen, sondern für interaktivere und individuellere Lernerfahrungen: mit mehr Reflexion, verschiedenen Perspektiven, Kreativität und Kollaboration. Die Lehrenden begleiten und moderieren diese Prozesse (E. R. Mollick & Mollick, 2023a, 2023b). Prompts für solche Aufgaben sammelt Anhang B (Anhang B).

Entscheidend bleibt, Didaktik und Technik auf die konkrete Kombination aus Lerninhalt und Studierendengruppe abzustimmen. Entlastung, anspruchsvollere Aufgaben und schnellere Individualisierung führen nur dann zu besserer Lehre, wenn sich die Lehrstrategie anpasst und Lehrende sich nüchtern mit den Risiken befassen, etwa mit der Frage, wie in diesen Schreibprozessen kritisches Denken entsteht (H.-P. H. Lee et al., 2025).

4.2.1.1 Was unsere eigenen Bots über Quellentreue lehren

Gegen Tays Befunde aus Kapitel 4.1.2 gelesen, arbeiteten die ursprünglichen Anweisungen der Schreibtrainer an drei Stellen gegen die Quellentreue (Bartnik & Schmid, 2026); wer eigene Trainer baut, trifft dieselben Entscheidungen.

Erstens sollten Einleitungs- und Forschungsstandtrainer die vollständige Einleitung eines echten Open-Access-Artikels zeigen. Ohne hinterlegte Datei rekonstruiert ein Sprachmodell den Text aus seinen Trainingsdaten und kann einem existierenden Artikel Sätze zuschreiben, die dort nicht stehen: fehlende *source faithfulness* (Tay, 2025). Abhilfe ist der Schritt zum passagenbasierten Arbeiten (Tay, 2024b): den Originaltext als Datei hochladen oder die Studierenden den Text selbst einfügen lassen. So arbeiten die kopierbaren Fassungen auf der Schreibtrainer-Seite.

Zweitens dürfen Quellen in den Schreibübungen erfunden sein. Das trennt den rhetorischen Zug, eine Quelle mit Funktion einzubauen, von der Suche. Ohne sichtbare Markierung „fiktiv“ lernen Studierende aber nebenbei, wie normal ein erfundener Beleg aussieht; die kopierbaren Fassungen verlangen die Markierung deshalb ausdrücklich. Unsere Handreichung für Abschlussarbeiten setzt den Gegenpol: Wer eine Quelle nicht erklären kann, gefährdet das Bestehen (Kapitel 5.6).

Drittens erzeugen Diskussions- und Strukturtrainer Abschnitte im Ton begutachteter Artikel samt Literaturverweisen; als Übungsmaterial taugen sie, wenn der Trainer sie als synthetisch kennzeichnet.

Ausprobiert: Prüfen, ob ein Sprachmodell richtig zitiert · 4D: Discernment · für Studierende

Ablauf. Bitten Sie ein Sprachmodell ohne hochgeladene Datei, die Einleitung eines bekannten Open-Access-Artikels aus Ihrem Fach

wörtlich wiederzugeben. Suchen Sie das Original in Google Scholar und gleichen Sie drei Sätze ab: einen aus dem ersten Absatz, einen mit Quellenverweis, den mit der Forschungsfrage.
Worauf achten. Gibt es den Artikel? Steht jeder der drei Sätze wörtlich, sinngemäß oder gar nicht im Original? Gibt es die Quelle, auf die der zweite Satz verweist, und sagt sie das?
Was die Übung zeigt. Tays Stichprobenaudit gegen das PDF im Kleinen (Tay, 2024a), die Prüfliste aus Kapitel 4.2.2.3 auf Text übertragen: Überzeugend klingt jede Ausgabe; es zählt, ob sie aus der Quelle folgt. Wiederholt man den Abgleich mit dem PDF als hochgeladener Datei, wird der Unterschied selbst zum Lerngegenstand.

Wie der nächste Abschnitt zeigt, findet eine ähnlich intensive Diskussion im Bereich der Informatik statt, wo speziell Programmieraufgaben ganz neu gedacht werden müssen.

4.2.2 Jeder kann jetzt programmieren

Mit KI als Copilot können wir **viel umfangreicher und schneller mit Code arbeiten**. Ein Beispiel ist Programmieren: Professionelle Programmierer werden mit KI-Copiloten deutlich schneller (S. Peng et al., 2023), und Lehrbücher haben zunehmend Namen wie „Learn AI-assisted Python Programming“ (Porter & Zingaro, 2024).

Studierende können so zum Beispiel viel schneller ein funktionierendes Spiel oder eine Simulation erstellen, was die Motivation erhöht. Der **Raum der kreativen Möglichkeiten weitet sich deutlich aus**.

Tipp: Mini-Interaktionen einfach als HTML erstellen

Können Sie in HTML programmieren? Jetzt schon. Die Lernspiele in Kapitel 2.1 wurden mit Hilfe von Sprachmodellen erstellt (Gemini, ChatGPT, Claude), meist mit einer Variation des einfachen Prompts **„Erstelle mir ein browserbasiertes Lernspiel zum Thema / zur Illustration von ...“**. Oft steht nach fünf bis zehn Minuten eine gute erste Version. In der Lehre mache ich das auch als Übung mit Studierenden: Sie erstellen mit der KI ein Lernspiel und bewerten

> dann begründet, welcher Prototyp das Konzept am besten darstellt. Bei etwas mehr Zeit bewerten sie sich gegenseitig, entwickeln eigene Kriterien oder fügen stärkere Spielelemente hinzu. Im Ergebnis beschäftigen sich die Teilnehmenden intensiv mit einem theoretischen Konzept; bei komplexeren Themen hilft es, einen Fachtext als Hintergrund hochzuladen.

Mit KI-Unterstützung können Schüler/innen mit Sonic Pi Musikstücke programmieren (Gieselmann, 2024) oder mit Tools wie Violentmonkey kleine Skripte für die individuelle Anzeige von Lieblings-Websites erstellen (Eikenberg, 2025).

Die ersten Studien zu GitHub Copilot zeigen, wie stark solche Assistenten die Einstiegshürden senken: MBA-Studierende ohne Programmierkenntnisse wandten mit generiertem R-Code statistische Methoden eigenständig an (Bien & Mukherjee, 2025), und Copilot löste etwa die Hälfte von 166 typischen Aufgaben aus Einführungskursen auf Anhieb, nach umformulierten Aufgabenbeschreibungen weitere 60 % der übrigen (Denny et al., 2023). Studierende lösen damit einen Großteil universitärer Programmieraufgaben ganz oder teilweise, und Lehrende müssen ihre Aufgaben so anpassen, dass die Kernkompetenzen trotzdem erworben werden (Nizamudeen et al., 2024). Grundlegende Programmierkenntnisse bleiben nötig, weil generierter Code funktionale und nicht-funktionale Anforderungen oft verfehlt und beurteilt, angepasst oder verworfen werden muss (Liang et al., 2024; Puryear & Sprint, 2022).

Praktisch alles, was Code ist, lässt sich mit Sprachmodellen erstellen und anpassen. Wir brauchen also nur Code-Schnittstellen. Das klingt kompliziert, ist aber überall schon vorhanden. Im Schreibprozess importieren wir Zitationen über das Bibtex-Format (.bib). Kalendertermine werden im Kalenderstandard (.ics) geführt. Für Flussdiagramme gibt es z. B. den Mermaid-Standard. Wir können insofern mit Sprachmodellen:

- Zitationen von einem Foto aus importieren („Scanne das Foto und gib mir die Quellen als Bibtex Code aus. Erkläre mir dann, wie ich ihn importiere“)
- Kalendereinträge aus einer Liste in unser Terminprogramm überführen („Erstelle mir aus dieser Liste Einträge im ICS Standard. Erkläre mir dann, wie ich den Code in Google Calendar importiere.“)

- Ablaufdiagramme in Mermaid visualisieren und als Grafik speichern („Erstelle mir einen typischen Kaufprozess in Mermaid. Erkläre mir dann, wie ich ihn visualisieren und als Grafik exportieren kann.“)
- Interaktive Simulationen mit den Claude Artifacts erstellen (s. o.; selbst gebaute Beispiele stehen in Kapitel 4.2.2.1 und Kapitel 4.2.2.2)
- Dialogbasiert Grafiken und statistische Analysen in Google Colab erstellen (s. u.)
- (Für viele weitere Ideen für solche Hilfsmittel können wir einfach das Sprachmodell fragen.)

Wichtig für Hochschulen: Mit **Google Colab** steht eine browserbasierte Programmierumgebung mit integriertem Sprachmodell kostenlos zur Verfügung. Visualisierungen und statistische Analysen können hier komplett dialogbasiert begonnen werden: Rechts steht der Prompt, links entstehen Code und Grafik. Auch ohne Grundkenntnisse in Python sind Studierende so gleich handlungsfähig und bauen durch häufige Nutzung Wissen auf. Dadurch wird es etwa möglich, von Studierenden durchgängig die Nutzung von Programmiertools zur Erstellung von Visualisierungen zu verlangen; die KI-Assistenz macht das leichter als das händische Gefrickel in den Grafiken von Excel oder gar PowerPoint. Nachvollziehbar bleibt dabei alles, weil es im Code steht, und Anpassungen sind einfach, weil die KI sich um die Syntax kümmert. Ein Beispiel-Notebook zeigt das: Beispiel-Notebook

Beispiel-Prompts:

- Erstelle mir eine einfache Visualisierung von vertikalen und horizontalen **Balkendiagrammen** in Python.
- **Passe die Balken so an**, dass die Prozentwerte auf den Balken sichtbar sind.
- Füge Beispiele für **Violin Charts** mit einem etwas komplexeren **Beispieldatensatz** hinzu.
- Erstelle jetzt einen Beispieldatensatz und führe eine einfache **Explorative Datenanalyse** (EDA) mit Visualisierungen durch.

Solche **Hilfestellungen sind Alltag** geworden: Die verbreiteten Code-Editoren, etwa PyCharm, VS Code und Cursor, bieten Programmierung mit KI-Unterstützung an. Seit 2025 verschiebt sich dabei die Arbeitsteilung ein zweites Mal. Ein Copilot ergänzt die Zeile, die man gerade schreibt. Ein **Programmier-Agent** wie Claude Code, Codex oder der Agentenmodus von Cursor bekommt dagegen einen Auftrag in Alltagssprache, liest die

vorhandenen Dateien, ändert mehrere davon, startet Tests und meldet das Ergebnis; das ist die Schleife aus Denken, Handeln und Beobachten, die Kapitel 2.1.1 beschreibt. Der Mensch schreibt kaum noch Code, er beschreibt, prüft und entscheidet, und erfahrene Entwickler lassen inzwischen mehrere Agenten parallel arbeiten (Steinberger, 2025; Willison, 2025). Für Hochschulen stellt sich damit eine doppelte Frage: wie Lehrende die Agenten für eigene Materialien nutzen und wie Studierende neben ihnen noch lernen, was sie verstehen sollen.

Wie das im Alltag aussieht, zeigt ein Making-of aus der Arbeit an diesem Buch. Claude Code schrieb das Video zu Tabelle 4.1 als Programmtext: Die Tabelle wurde zu einer Datendatei, ein Skript erzeugte daraus die Szene, und das Werkzeug HyperFrames rechnete den Film Bild für Bild aus (HeyGen, 2026). Vom Auftrag bis zum fertigen Film vergingen neun Minuten, Recherche und Einrichtung eingeschlossen. Zwei Prüfschritte fanden dabei Fehler: Die automatische Prüfung meldete zu schwachen Farbkontrast, die Sichtprüfung am Standbild eine Kachel, die unter ihre Nachbarin rutschte. Beide Fehler waren in einer Minute behoben; ohne die Prüfschritte wären sie im fertigen Film geblieben. Was als Code vorliegt, kann ein Sprachmodell schreiben und ändern. Die Verantwortung für das Ergebnis bleibt bei der Lehrperson.

Wie verschieden zwei solche Werkzeuge dieselbe Herleitung umsetzen, zeigt der Vergleich zur optimalen Bestellmenge. Links läuft Manim, eine Python-Bibliothek für Mathematik-Animationen, rechts HyperFrames, das Webseiten-Code in Video umwandelt; beide Fassungen schrieb Claude. Für den Lernerfolg zählt die Machart womöglich weniger als erwartet: In einem Online-Experiment mit 447 Teilnehmenden lernten diese mit KI-erzeugten Lehrvideos, darunter eines zur optimalen Bestellmenge, gleich viel wie mit menschlich produzierten, erlebten die menschlichen aber etwas positiver (Netland et al., 2025). Wie man solche Animationen nach festen Gestaltungsregeln baut und prüft, beschreibt Primer A (Kapitel E.2).

Was der Agent den Lehrenden abnimmt, kann er Studierenden beim Lernen wegnehmen. In einem Experiment bauten 54 Informatikstudierende zweier US-Hochschulen ein kleines Browserspiel, die eine Hälfte mit einem Agenten, der ihren Code direkt änderte, die andere mit einem Chatbot, der nur allgemeine Codeschnipsel lieferte, so dass sie selbst schreiben mussten; beide liefen mit GPT-4.1. Die Agentengruppe war schneller und erfüllte mehr Anforderungen, verstand ihren eigenen Code aber deutlich schlechter. Als alle das Spiel danach ohne Agent erweitern sollten, kehrte

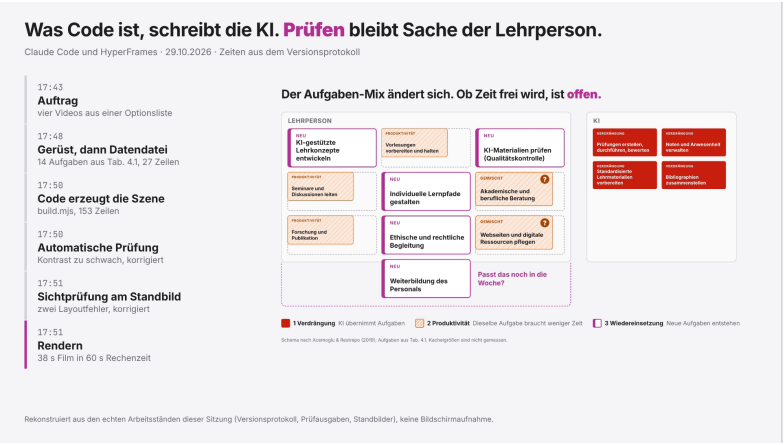

Video online

Laufzeit 59 s

Abbildung 4.6. Making-of zum Video über Tabelle 4.1: Auftrag, Datendatei, Code, automatische Prüfung, Sichtprüfung, Rendern, rekonstruiert aus Versionsprotokoll und Prüfausgaben. Schlussbild eines Videos (59 s), erstellt mit Claude Code und HyperFrames. Das Video gibt es nur in der Online-Version: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/kapitel04.html#vid-making-of aufrufen.

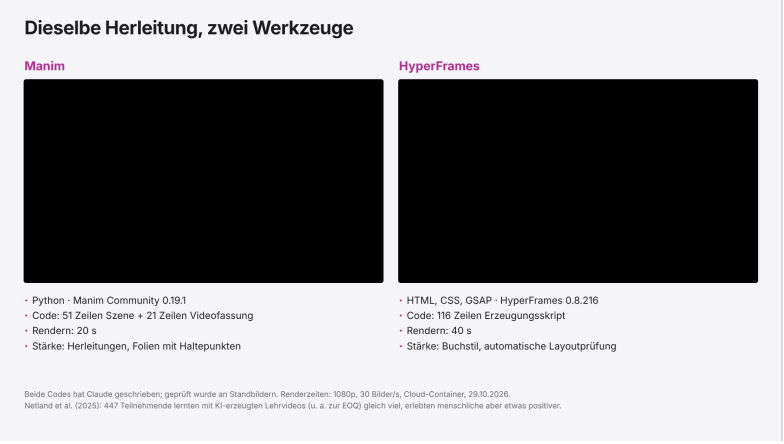

Video online

Laufzeit 30 s

Abbildung 4.7. Dieselbe Herleitung der optimalen Bestellmenge in Manim (links) und HyperFrames (rechts), beide von Claude programmiert. Schlussbild eines Videos (30 s). Das Video gibt es nur in der Online-Version: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/kapitel04.html#vid-eoq-vergleich aufrufen.

sich ihr kleiner Vorsprung um, sobald man den besseren Ausgangscode herausrechnete: Er stammte aus dem Gerüst, das der Agent gebaut hatte, nicht aus Verständnis. Weniger verstand, wer die Aufgabenstellung in den Prompt kopierte oder alle Änderungen ungesehen übernahm, am meisten, wer den Auftrag in Fachbegriffe übersetzte und jede geänderte Datei einzeln annahm. Den Agenten bevorzugten die Studierenden trotzdem, weil er schnell und bequem ist (Balepur et al., 2026). Die Studie ist klein und ausdrücklich explorativ, passt aber zu dem, was Kapitel 3.5 für den Chat zeigt: Mit KI lösen Studierende mehr Programmieraufgaben und behalten weniger (Bergh et al., 2026). Von sich aus arbeiten sie selten anders. In den Chatprotokollen eines Semesters aus einem Informatikkurs ging es in 78,8 % der Anfragen nicht ums Verstehen; die Studierenden ließen die KI die Arbeit tun oder sich von ihr bestätigen, und nur 11,1 % der Anfragen verbanden den Wunsch zu verstehen mit eigener Begründung (Mengqian Wu, 2026).

Daraus folgt eine Arbeitsteilung, die sich am Lernziel ausrichtet. Wo das Produkt zählt, etwa ein Lernspiel, ein Prototyp oder eine Simulation für die eigene Lehre, darf der Agent schreiben, und die Prüfung des Ergebnisses bleibt Pflicht (Kapitel 4.2.2.3). Wo das Verstehen des Codes selbst Lernziel ist, gehören die Bremsen in die Aufgabe: Aufträge in Fachbegriffen statt kopierter Aufgabenstellung, jede Änderung einzeln annehmen, eine schriftliche Begründung für jede übernommene Änderung, wie sie beim Schreiben mit KI die Übernahme fehlerhafter Vorschläge senkt (Tao et al., 2026), und am Ende eine Erweiterung ohne Agent, die zeigt, was verstanden wurde. Wie sich solche Kontrollpunkte allgemein setzen lassen, beschreibt Kapitel D.1.

4.2.2.1 Beispiel: Little's Law selbst nachrechnen

Simulationen, an denen Studierende selbst drehen, haben in der Lehre zu Produktion und Logistik eine lange Tradition. Dobson & Shumsky (2006) stellten drei Browser-Simulationen vor, eine Warteschlange, Little's Law in einem einstufigen Prozess und ein Bestellpunktsystem, alle über Schieberegler gesteuert, und erprobten sie in einer Web-Übung mit 74 Studierenden. Das R-Paket `bullwhipgame` simuliert den Bullwhip-Effekt in einer vierstufigen Lieferkette, setzt aber eine eigene R-Installation voraus (Marchena, 2018). Solche Werkzeuge zu bauen, war lange Sache von Spezialisten. Mit einem Sprachmodell als Copilot können Lehrende

sie selbst programmieren, und das folgende Widget ist auf diesem Weg entstanden.

Little's Law sagt: Bestand = Durchsatz × Durchlaufzeit, kurz $L = \lambda W$ (Little, 1961). Wer jeden Monat zehn Flaschen Wein kauft und jede ein Jahr liegen lässt, hat im Mittel 120 Flaschen im Keller, ohne je eine einzelne Flasche zu verfolgen. Das Gesetz ist eine Bilanz, und Bilanzen stimmen nur über den ganzen Zeitraum. Wer den Keller einen Nachmittag lang beobachtet, sieht vielleicht keine einzige Flasche kommen oder gehen.

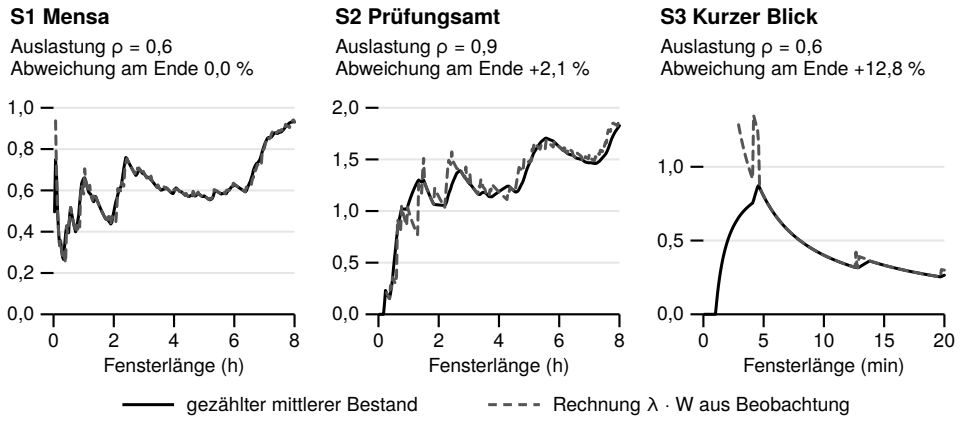

Abbildung 4.8. Little's Law in drei Szenarien: Über acht Stunden trifft die Rechnung $\hat{\lambda} \cdot \hat{W}$ (gestrichelt) den gezählten Bestand $\bar{L}$ (durchgezogen), im Prüfungsamt mit hoher Auslastung erst nach einigen Stunden; im Blick über 20 Minuten verfehlt sie ihn um 13 %. Dieses interaktive Element gibt es nur in der Online-Version: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/kapitel04.html#sec-widget-littles-law aufrufen.

Warum die Gleichung im kurzen Fenster danebenliegt

Aufträge, die bei Fensterende noch im System sind, zählen im Bestand $\bar{L}$ mit, haben aber noch keine abgeschlossene Verweilzeit und fehlen deshalb in $\hat{W}$. Ist das System an beiden Fensterrändern leer, gilt $\bar{L} = \hat{\lambda} \cdot \hat{W}$ exakt; sonst entsteht die Abweichung am Rand. Je höher die Auslastung, desto länger die Verweilzeiten, desto breiter der Rand und desto langsamer nähert sich die Rechnung dem gezählten Bestand. Im kurzen Fenster entscheidet deshalb der Zufall, ob die Gleichung passt.

Probieren Sie mal

Ein Studienbüro erhält im Mittel 40 Anträge pro Woche, im Stapel liegen 120. Wie lange wartet ein Antrag im Mittel, ohne dass jemand Zeiten misst?
Lösung: W = L / λ = 120 / 40 = 3 Wochen. Die Rechnung gilt, wenn das Büro über die Zeit so viele Anträge abarbeitet, wie eingehen.

4.2.2.2 Beispiel: Den Bullwhip-Effekt zerlegen

Eine kleine Bewegung am Griff einer Peitsche wird an der Spitze zum großen Ausschlag. In einer Lieferkette geschieht dasselbe mit den Bestellungen: Sie schwanken umso stärker, je weiter eine Stufe vom Endkunden entfernt ist, obwohl die Kundennachfrage kaum schwankt. H. L. Lee et al. (1997) nannten das den Bullwhip-Effekt und führten ihn auf vier Ursachen zurück: die laufende Aktualisierung der Prognosen, das Bündeln von Bestellungen, Preisaktionen und das Horten bei Knappheit. Das zweite selbst gebaute Widget greift die erste Ursache heraus und verbindet sie mit zwei Stellgrößen, die jede Disponentin kennt, der Lieferzeit und der Frage, wer welche Daten sieht.

Das Modell hat vier Stufen: Händler, Großhandel, Verteilzentrum und Fabrik. Jede Stufe prognostiziert ihre Nachfrage als gleitenden Mittelwert über die letzten p Perioden und bestellt so viel, dass Bestand und offene Bestellungen die Prognose über die Lieferzeit L decken. Für genau diese Kette haben F. Chen et al. (2000) gezeigt, dass die Bestellungen des Händlers mindestens um den Faktor

$$\frac{\operatorname{Var}(q)}{\operatorname{Var}(D)} \geq 1 + \frac{2L}{p} + \frac{2L^2}{p^2}$$

stärker streuen als die Kundennachfrage D. Bei zwei Wochen Lieferzeit und einem Mittelwert über fünf Wochen ist das gut das Doppelte. Die Lieferzeit zählt dabei wie bei F. Chen et al. (1999) die Bestellperiode mit: Eine Bestellung vom Ende der Woche t ist zu Beginn der Woche $t + L$ da. Ohne geteilte Information multiplizieren sich die Faktoren von Stufe zu Stufe; teilen alle Stufen die Kassendaten des Händlers, addieren sich nur noch die Lieferzeiten. Der Effekt wird dann kleiner, verschwindet aber nicht. Das Widget leitet sein Modell aus diesen Arbeiten ab und übernimmt keinen Code aus dem Paket `bullwhipgame`, das unter der GPL-3 steht.

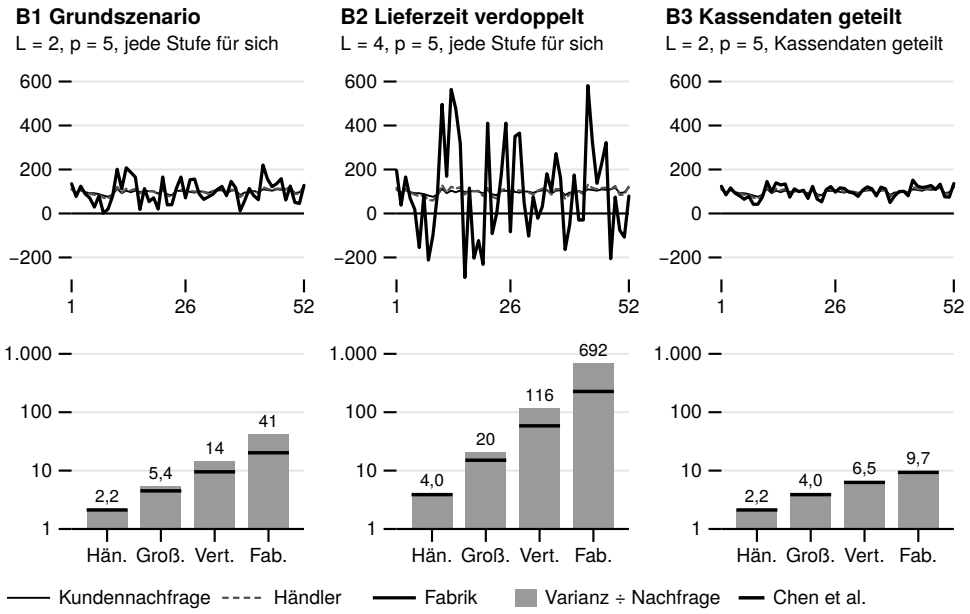

Abbildung 4.9. Bullwhip-Effekt in drei Szenarien mit derselben Kundennachfrage. Oben die Bestellungen eines Jahres auf gleicher Skala, unten das Varianzverhältnis jeder Stufe über 2000 Perioden (logarithmisch), der Strich markiert den Wert nach Chen et al. Verdoppelt sich die Lieferzeit, steigt die Varianz der Fabrikbestellungen vom 41- auf das 692-Fache der Kundennachfrage; geteilte Kassendaten senken sie auf das 9,7-Fache. Dieses interaktive Element gibt es nur in der Online-Version: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/kapitel04.html#sec-widget-bullwhip aufrufen.

Warum die Peitsche knallt

Jede Bestellung besteht aus zwei Teilen: dem, was gerade verkauft wurde, und der Änderung der Bestellgrenze. Steigt die Prognose um ein Stück pro Woche, muss die Bestellgrenze um L Stück steigen, weil

sie L Wochen abdeckt. Die Prognoseänderung kommt also mit der Lieferzeit vervielfacht in der Bestellung an. Die nächste Stufe hält diese schon verstärkte Bestellung für Nachfrage und verstärkt sie erneut. Geteilte Kassendaten unterbrechen die zweite Verstärkung, die erste bleibt.

Das Modell zeigt die operativen Ursachen, nicht die menschlichen. In den Experimenten von Croson & Donohue (2006) entstand der Bullwhip-Effekt auch dann, als Prognose, Bündelung und Preisaktionen ausgeschaltet waren, weil die Teilnehmenden die bereits bestellte, noch unterwegs befindliche Ware zu wenig berücksichtigten. Sterman (1989) hatte dieses Verhalten im Beer Game als Verankern und Anpassen beschrieben. Wer das Widget allein zeigt, legt deshalb eine Fehlvorstellung nahe: dass bessere Prognoseverfahren das Problem lösten. In der Lehre passt es besser in die Nachbesprechung eines Beer Game, in der Studierende ihre eigenen Bestellkurven neben die Kurven des Modells legen. Simulationsspiele wirken als Ergänzung anderer Lehrformen stärker denn als alleinige Unterweisung (Sitzmann, 2011).

Probieren Sie mal

Ein Händler bestellt bei drei Wochen Lieferzeit und prognostiziert mit dem Mittelwert der letzten sechs Wochen. Um welchen Faktor streuen seine Bestellungen mindestens stärker als die Nachfrage? Und wie viele Wochen muss er bei vier Wochen Lieferzeit mitteln, damit der Faktor unter 1,5 fällt?
Lösung: $1 + 2{\cdot}3/6 + 2{\cdot}9/36 = 2{,}5$; die Standardabweichung ist damit gut das 1,6-Fache. Bei $L = 4$ fällt der Faktor erst ab $p = 20$ Wochen unter 1,5 (1,48). Ein so langes Fenster reagiert aber träge auf echte Trendwechsel; die Dämpfung hat ihren Preis.

4.2.2.3 Prüfen, ob eine KI-gebaute Simulation rechnet

Beide Widgets hat ein Sprachmodell nach meinen Vorgaben programmiert. Verlässlich macht sie die Reihenfolge, in der sie entstanden sind: zuerst das Rechenmodell als eigene Datei ohne Oberfläche, dazu Tests gegen Handrechnungen und veröffentlichte Formeln, erst danach Regler und

Diagramme. Wer die Reihenfolge umkehrt, bekommt in kurzer Zeit etwas, das gut aussieht.

> **i** Anwendungsbeispiel: Die KI baut überzeugende Animationen, die nichts rechnen
>
> **Problem ohne KI.** Eine Prozessanimation, in der sich vor dem Engpass sichtbar eine Schlange bildet, erklärt Durchlaufzeiten besser als jede Folie. Sie zu programmieren, kostet Lehrende ohne Programmiererfahrung Wochen; deshalb bleibt es meist bei Kästchen und Pfeilen.
> **Problem mit KI.** Ein Sprachmodell liefert eine solche Animation in einer Stunde. Ob dahinter ein Modell rechnet oder ein Film mit festem Drehbuch abläuft, sieht man dem Ergebnis nicht an.
> **Der Lösungsansatz.** Für die Animationsbibliothek *scm-visuals* ließ ich im September 2026 sechs Prozessanimationen zu Produktion und Beschaffung von einem Sprachmodell entwerfen: einfacher Fluss, Los- gegen Einzelstückfertigung, Engpass und Warteschlange, Push gegen Pull und zwei Bestellabläufe vom Bedarf bis zur Zahlung. Eine Prüfung mit Standbildfolgen und Zustandsprotokollen, also mit Listen, die für jeden Zeitpunkt festhalten, wo jedes Stück steht, ergab: Nur zwei der sechs rechneten ein Modell, Engpass und Push gegen Pull. Die übrigen vier spielten feste Zeitleisten ab, und die Animation zur Losfertigung ließ im Einzelstückmodus die Kapazität der Stationen außer Acht. Alle sechs sahen überzeugend aus. Seitdem entsteht zuerst das Modell mit seinen Tests und dann die Oberfläche; die beiden Widgets in Kapitel 4.2.2.1 und Kapitel 4.2.2.2 sind so gebaut.
> **Was das für wirksames Lernen heißt.** *Erfahrungsbericht aus der eigenen Entwicklung, keine Lernwirkung gemessen.* Eine Simulation lehrt Ursache und Wirkung nur, wenn die Wirkung aus der Ursache folgt. Spielt sie ein festes Drehbuch ab, zeigt sie nach jeder Änderung dasselbe, und wer seine Vorhersage prüft, prüft sie gegen einen Film. Studierende können das nicht erkennen, Lehrende nur am Modell, nicht am Bild. Ein Sprachmodell baut eine glaubwürdige Oberfläche schneller als ein korrektes Modell; die Grenze seiner Leistung verläuft hier mitten durch eine einzige Aufgabe (Dell'Acqua et al., 2023).

Prüfliste: Rechnet die Simulation, oder spielt sie ab?

Die fünf Prüfungen brauchen keine Programmierkenntnisse, nur die Regler und einen Taschenrechner. Beide Widgets dieses Abschnitts bestehen sie, und ihre Tests im Repositorium prüfen dieselben Punkte bei jeder Änderung automatisch.

1. **Andere Eingabe, anderer Verlauf.** Wer einen Parameter ändert, muss eine andere Kurve sehen, nicht nur andere Zahlen an derselben Kurve. Im Bullwhip-Widget ändert die doppelte Lieferzeit die Form der Fabrikbestellungen, nicht nur ihre Höhe.
2. **Grenzfälle.** Kommen fast keine Aufträge an, bleibt das System leer. Liegt die Auslastung bei 100 % oder darüber, warnt das Little's-Law-Widget, statt ein Gleichgewicht vorzutäuschen. Schwankt die Kundennachfrage nicht, bestellt im Bullwhip-Widget jede Stufe genau 100 Stück.
3. **Eine Handrechnung.** Mindestens ein Fall muss sich auf Papier nachrechnen lassen. Im Little's-Law-Modell sind es zwei Aufträge, im Bullwhip-Modell ein Nachfragesprung von 100 auf 120 Stück: Bei zwei Perioden Lieferzeit und einem Mittel über vier Perioden bestellt der Händler 130 Stück, der Großhandel 145. Wo es eine veröffentlichte Formel gibt, muss das Modell sie treffen, hier die von F. Chen et al. (2000).
4. **Gleicher Startwert, gleiches Ergebnis.** Ein Szenario mit demselben Startwert läuft zweimal identisch ab. Neu gewürfelt ändert sich der Verlauf, das Muster bleibt.
5. **Genannte Annahmen.** Das Widget sagt, was es vereinfacht. Bei beiden Widgets stehen die Annahmen in einem aufklappbaren Kasten unter den Diagrammen.

Ausprobiert: Eine Simulation bauen lassen, die rechnet · 4D: Description, Discernment · für Lehrende

Ziel. Das Sprachmodell baut ein Widget zu Little's Law und liefert die Mittel, es zu prüfen, gleich mit.
Prompt.

```
Baue ein interaktives Widget zu Little's Law
(L = λW) für Studierende im ersten Semester.
```

```
Gehe in zwei Schritten vor.
Schritt 1: Schreibe das Modell als reine
Funktion ohne Oberfläche.
Eingaben: λ, mittlere Bearbeitungszeit,
Fensterlänge, Startwert für den
Zufallsgenerator.
Ausgaben: mittlerer Bestand L, beobachtete
Ankunftsrate λ̂, mittlere Verweilzeit Ŵ. Nenne
alle Annahmen. Schreibe drei Tests:
(1) Ist das System zu Beginn und am Ende leer,
gilt L = λ̂·Ŵ exakt.
(2) Bei Auslastung 0,6 und langem Fenster liegt
die Abweichung unter 2 %.
(3) Derselbe Startwert liefert dasselbe
Ergebnis.
Schritt 2: Erst wenn alle Tests bestehen, baue
Regler und Diagramm.
Erkläre mir danach in drei Sätzen, wie ich ohne
Programmierkenntnisse prüfe, dass das Widget
rechnet und nicht nur abspielt.
```

Worauf achten. Hält das Modell die Reihenfolge ein, oder liefert es sofort Regler? Rechnen die Tests das Modell durch, oder vergleichen sie fest eingetragene Zahlen miteinander? Lässt sich die Erklärung am Ende mit der Prüfliste oben abgleichen?
Variante mit Studierenden (4D: Discernment). Lassen Sie das Sprachmodell eine zweite Fassung bauen, die nur eine feste Zeitleiste abspielt, und geben Sie beide Fassungen ohne Kennzeichnung aus. Die Studierenden finden mit der Prüfliste heraus, welche rechnet, und begründen es.

Der 4D-Kreislauf beim Copilot. Beim Copilot entscheidet die innere Schleife aus Beschreiben und Prüfen, weil Mensch und KI im Wechsel an derselben Aufgabe arbeiten. *Delegation:* Was eigene Arbeit bleibt, hängt am Lernziel; wer den Code verstehen soll, gibt das Schreiben nicht ganz ab (Balepur et al., 2026). *Description:* Beschrieben wird der Arbeitsweg, nicht nur das Produkt: Aufträge in Fachbegriffen, Änderungen einzeln annehmen, Erklärungen statt fertiger Fassungen anfordern. *Discernment:* Eine Begründungspflicht für jede übernommene Änderung senkt die Übernahme fehlerhafter Vorschläge (Tao et al., 2026), und der Abgleich mit dem eigenen Ergebnis zeigt, wo die zerklüftete Grenze verläuft (Kapitel 2.4).

Diligence: Studierende dokumentieren, wie stark die KI mitgewirkt hat, etwa mit der Skala in Tabelle 5.3. Die Begründungspflicht aus dem Prüfen wird so zur Regel der Delegation: Abgegeben wird nur, was man begründet übernehmen kann.

4.3 KI als Tutor

Diese Kategorie umfasst KI-Systeme, die Studierende direkt beim Lernen anleiten, beraten oder ihnen Feedback geben. Sogenannte Intelligent Tutor Systems (ITS) werden in der Didaktik schon länger diskutiert, sie wurden klassischerweise regelbasiert als Entscheidungsbäume aufgebaut, ähnlich einem Fortsetzungs-Kinderbuch (A la: "Wenn Du die Tür öffnen willst, lies weiter auf S.145"). Durch generative KI entstehen breitere Möglichkeiten der Interaktion, jedoch führt das "generative" Element auch etwas Unsicherheit in die Dialogsteuerung ein (Latif et al., 2026).

Wo der Mehrwert eines solchen Tutors liegt, zeigt die Harvard-Studie zum Physik-Tutor PS2 Pal (Kestin et al., 2025). Die Studierenden lernen **im eigenen Tempo**: Wer den Stoff schon kennt, kommt schneller durch die Aufgaben, wer mehr Zeit braucht, nimmt sie sich. Sie bekommen **Rückmeldung auf Abruf**: Während Lehrende in großen Veranstaltungen nur auf wenige Fragen eingehen können, antwortet der Tutor allen sofort und auf die konkrete Frage. Sie fühlten sich mit dem Tutor **stärker eingebunden und motivierter** als in der aktiven Präsenzstunde. Und für die Lehrenden **verschiebt sich die Arbeit**: Die Einführung in die Grundlagen übernimmt der Tutor vor der Präsenzzeit, die Zeit im Hörsaal gehört anspruchsvolleren Aufgaben, das Einrichten des Tutors kostet dafür Vorarbeit (Kapitel 4.3.2). Eine Diagnose des Lernstands, etwa über typische Fehler, beschreibt die Studie dagegen nicht; individuell sind Tempo und Rückmeldung, nicht der Stoff. Allerdings behält die Lehrkraft jederzeit die Oberaufsicht, indem sie zum Beispiel relevante KI-Antworten stichprobenartig überprüft oder spezielle Fälle selbst übernimmt (z. B. wenn die KI Auskünfte gibt, die nicht zur jeweiligen Kursstruktur passen).

Dass ein Tutor sich darüber hinaus an den Gesprächsverlauf anpassen kann, zeigt ein Feldexperiment, in dem er diese Anpassung **selbst lernt**. Ein Prompt-Router, der aus vierzehn pädagogischen Merkmalen des Gesprächsverlaufs die Tutoring-Strategie wählt (eher analytisch oder eher gerüstbauend), schlug im A/B-Test mit 359 Oberstufenschülern statische

Prompts bei gehaltener pädagogischer Qualität; die Variante, die zwischen Strategien streut, statt stur die beste zu wählen, hob die Quote begonnener Übungen von 19,6 auf 28,1 % (Chang et al., 2026). Zusammen mit dem Musterlösungs-Ansatz von Kestin et al. (2025) ergeben sich damit zwei komplementäre Stellschrauben: Musterlösungen kontrollieren den **Inhalt**, adaptives Prompt-Routing die **Strategie**.

Generell ist bei KI-Tutoren die **Gefahr von Fehlinformationen und Halluzinationen** zu beachten. Hierfür gibt es jedoch gute Gegenmaßnahmen, vor allem durch Kontrolle des Inputs und systematische Qualitätstests der LLM-Tools. Eine interessante Möglichkeit, die beim Physik-Tutor der Harvard Studie besprochen wird (Kestin et al., 2025), ist die **Bereitstellung von Musterlösungen als Input** (nicht nur der Fragen): Das Modell soll die Lösungswege nicht selbst erzeugen, damit Ungenauigkeiten, Halluzinationen und Inkonsistenzen gar nicht erst entstehen. Der Aufwand für die Erstaufsetzung steigt hier zwar, im Gegenzug sinkt die Qualitätsunsicherheit, die individuelle Anleitung durch ein Sprachmodell sonst begleitet. Insgesamt ist eine solche Durchsicht und intensive Qualitätskontrolle klar zu empfehlen (dieser Aspekt der intensiven Qualitätstests wird bei der Kurzvorstellung einiger deutscher Fallstudien in Wannemacher et al. (2025) vernachlässigt).

4.3.1 Beispiele für einfache Tutoren

E. R. Mollick & Mollick (2024) beschreiben eine Reihe allgemeiner Tutorenkonzepte: Der **"Integration Agent"** (E. R. Mollick & Mollick, 2024, S.31–33) fordert Studierende durch offene Fragen heraus, Verbindungen zwischen verschiedenen Kurskonzepten herzustellen, was vernetztes Denken fördert. Der **"Reflection Coach"** (E. R. Mollick & Mollick, 2024, S.30) regt zur Reflexion über Erfahrungen an, um das Gelernte zu konsolidieren. Der **"AI Tutor Blueprint"** (E. R. Mollick & Mollick, 2024, S.38–40) ermöglicht es Lehrenden, eigene, auf ihre spezifischen Themen zugeschnittene Tutoren-Prompts zu erstellen.

An deutschen Hochschulen unterstützt etwa **„LISA"** (Hochschule Hof) die Prüfungsvorbereitung mit Lernplänen, Übungsaufgaben und Feedback auf Basis hochgeladener Materialien (Wannemacher et al., 2025, Case 208); an der FernUniversität in Hagen gibt **„COFFEE"** kriterienbasiertes Feedback zu Freitextaufgaben und **„MIND"** Feedback zu Lernaktivitäten, das die Selbstreflexion fördern soll (Wannemacher et al., 2025, Case 61). Als Hürden

nennen die Projekte die Bekanntmachung, den Implementierungsaufwand und den Datenschutz (Wannemacher et al., 2025).

Für all diese allgemeinen Tutoren gilt: Ihre Effektivität hängt von der Qualität des Prompts und der Fähigkeit der KI ab, die Tutor-Rolle konsistent und pädagogisch sinnvoll auszufüllen, was nicht immer gegeben ist und von Modell zu Modell variieren kann (E. R. Mollick & Mollick, 2024, S.36). Die KI kann oberflächlich bleiben oder halluzinieren (E. R. Mollick & Mollick, 2024, S.36).

Über solche einzeln erdachten Prompts hinaus gibt es inzwischen systematisches Gestaltungswissen. Banh et al. (2026) leiten aus Interviews, Literatur und einem erprobten Prototyp drei übergeordnete Anforderungen an GenAI-Lernagenten ab, Selbststeuerung, Kollaboration und Assessment (von lateinisch *assidēre*, „sich danebensetzen"), sowie neun Design-Prinzipien; die beiden Feedback-Prinzipien geben den Fällen COFFEE und MIND nachträglich eine theoretische Grundlage: Antworten weisen ihre Quelle im Lernmaterial aus, und Feedback benennt Stärken und macht Wissenslücken sichtbar, um die Selbstbewertung der Lernenden zu stützen. Die Wirksamkeit hat allerdings eine Grenze, die im Modell selbst liegt. Perczel et al. (2025) messen die dialogische Qualität heutiger Sprachmodelle an echten Eins-zu-eins-Tutorien und finden sie systematisch schwächer als die menschlicher Tutorinnen und Tutoren: Die Modelle lassen Lernenden nur 5 bis 15 Prozent der Redezeit statt rund 30, stellen drei bis vier Fragen auf einmal und drängen früh zur Lösung. Die Ursache ist strukturell: Standard-Modelle sind darauf optimiert, als hilfreiche Assistenten Reibung zu minimieren, während gutes Unterrichten Reibung gezielt erzeugt. Prompt Engineering, das Feinschleifen der Anweisungen an das Modell, bleibt deshalb ein Notbehelf; erst das Nachtrainieren auf 100.000 Stunden echter Tutorien verdoppelte in der Studie die Redezeit der Lernenden. Für die Praxis schärft das den Vorbehalt dieses Abschnitts: Die Qualität eines GenAI-Tutors hängt am Prompt *und* am Modell, und die zuverlässigsten Gegenmaßnahmen liegen jenseits des Prompts, von Musterlösungen als Input bis zu systematischen Testläufen vor dem Einsatz (Testplan in Kapitel D.7).

Die Regel „Hinweise vor Lösungen" hat inzwischen selbst eine Grenze bekommen. Der größte Anbieter eines Schul-Tutors hat nach einem zweijährigen Feldexperiment ohne messbaren Zusatzeffekt (Kapitel 3.5) öffentlich eingeräumt, dass ein Tutor, der neben der Aufgabe wartet, kaum angesprochen wird, und ihn umgebaut: in die Aufgabe hinein, keine

Antwort vor dem ersten eigenen Versuch, aktives Eingreifen nach dem Fehler (Khan, 2026, Herstellerangabe). Was nach dem Fehler geschehen soll, zeigt eine Auswertung von 20.462 Tutor-Beiträgen in Sackgassen-Situationen: Bei festgefahrenen Lernenden hilft jede weitere Rückfrage weniger, das Benennen des Fehlers mehr (Ahtisham et al., 2026). Ein Tutor, der sein Gerüst kontingent eskaliert und abbaut, also mehr hilft, wenn die Person stockt, und weniger, sobald sie trägt, schlägt im Vergleich beide starren Varianten, den Lösungsgeber wie den Dauerfrager (Xinmeng Hou et al., 2026). Die Gestaltungsregel für Kapitel D.7 lautet deshalb: Hinweise vor Lösungen, aber mit Eskalation bei Sackgassen, und ohne die Erwartung, dass der Prompt sie allein durchsetzt (Kapitel 3.5).

Sprachen lernen und Gespräche üben lässt sich mit dem Sprachmodus der großen Chat-Anwendungen: Die KI spricht über ein beliebiges Thema in einer beliebigen Sprache und gibt etwa Feedback auf eine englische Präsentation (Jurran, 2025). Für den Sprachunterricht an Hochschulen empfiehlt Tutton & Cohen (2025), Stärken und Schwächen solcher Werkzeuge gemeinsam mit den Studierenden zu erproben und den Unterricht so anzulegen, dass sich KI und Präsenzlehre ergänzen.

i Stand bei Drucklegung, November 2026: Tutor-Angebote der Anbieter

Welche Tutor-Funktionen die großen Anbieter bei Drucklegung in ihren Bildungsprodukten boten, als historischer Schnappschuss; alle Angaben stammen von den Anbietern selbst. Die Online-Seite „Forschungsstand“ führt die Liste fort.

- **OpenAI:** quellengebundener Tutor für Studierende als Erweiterung in ChatGPT Edu, der aus den freigegebenen Kursmaterialien antwortet (OpenAI, 2026c); ein „Learning Lab“ für Studien mit Hochschulen, das die Evidenzlage zu den eigenen Produkten verbessern soll (Devani & Leiva, 2026); die eigene Studie zum Lernmodus fand einen Gewinn in Mikroökonomie und keinen in Neurowissenschaft (OpenAI, 2026b).
- **Google:** Gemini im Google Classroom für alle Altersstufen mit kursbezogenen Startprompts (Google Workspace Updates, 2026a); die bisher für Tutoren genutzten „Gems“ werden im Bildungsbereich frühestens zum 1. Juni 2027 abgeschaltet und durch Skills und Guided Learning ersetzt (Google Workspace

Updates, 2026b), ein Beispiel dafür, warum Tutoren nicht an ein einzelnes Produktmerkmal gebunden sein sollten (Kapitel D.2).

- **Anthropic:** ein Lernmodus, der Hinweise vor Lösungen setzt, und seit Juli 2026 ein Angebot für Lehrende mit Vorlagen für Rückmeldung und Kursmaterial (Anthropic, 2026c).
- **Khan Academy:** Umbau von Khanmigo nach dem zweijährigen Feldexperiment ohne messbaren Zusatzeffekt: Tutor in der Aufgabe, keine Antwort vor dem ersten Versuch, Eingreifen nach dem Fehler (Khan, 2026; Oreopoulos & Low, 2026).

4.3.2 Komplexer Physik Tutor mit Musterlösungen

Wie ein solcher Tutor im Kurs arbeitet, zeigt der Physik-Tutor **„PS2 Pal"** der Harvard University (Kestin et al., 2025), dessen Evaluation Kapitel 3.5 einordnet. Im Einführungskurs Physical Sciences 2 arbeiten die Studierenden in jeder Stunde eine Folge von Aufgaben durch, sonst in Kleingruppen im Hörsaal, im Experiment allein mit dem Tutor; die beiden untersuchten Stunden behandelten Oberflächenspannung und Strömungen. Der Tutor kennt die Musterlösungen, beantwortet Fragen, gibt bei Bedarf Hinweise und bestätigt richtige Lösungsschritte, ohne die komplette Lösung vorwegzunehmen.

Technisch ist PS2 Pal schlicht. Es nutzt GPT-4 mit einem Systemprompt, der die Didaktik festlegt: die Studierenden aktiv halten, die kognitive Belastung dosieren und ein Wachstumsdenken fördern. Zu jeder Aufgabe enthält der Prompt eine ausführliche Schritt-für-Schritt-Lösung; sie soll verhindern, dass das Modell falsche Lösungswege erfindet. Weil der Prompt allein mehrteilige Aufgaben nicht verlässlich portionierte, führt die Plattform selbst von Teilaufgabe zu Teilaufgabe. Von einer automatischen Anpassung des Schwierigkeitsgrads berichtet die Studie nichts; individuell sind das Tempo und die Rückmeldung auf die Fragen der Studierenden. Sie arbeiten zu Hause: Vorab-Test, kurzes Einführungsvideo, Aufgaben mit dem Tutor, Abschluss-Test. Im Crossover-Experiment mit 194 Studierenden lag der Median im Abschlusstest bei 4,5 gegenüber 3,5 nach der aktiven Präsenzstunde, bei einem gemeinsamen Ausgangswert von 2,75; der Lernzuwachs war damit mehr als doppelt so hoch. Die Studierenden brauchten im Median 49 Minuten, für die Präsenzstunde setzt die Studie 60

Minuten an. Gemessen wurde direkt nach der Stunde; ob der Vorsprung anhält, lässt die Studie offen (Kestin et al., 2025).

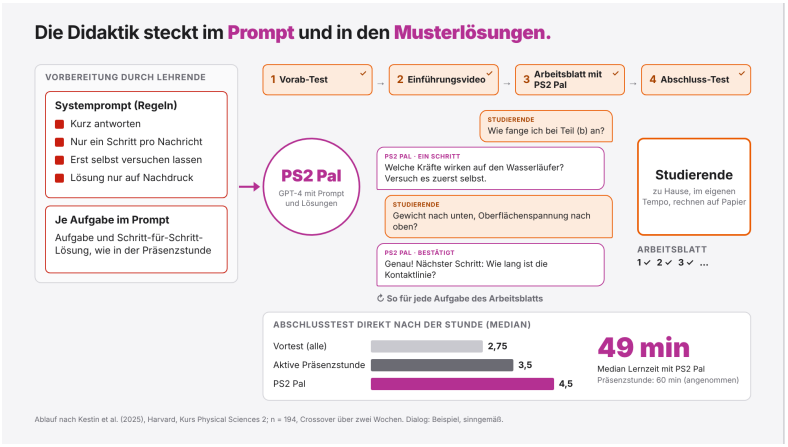

Abbildung 4.10. Ablauf des Physik-Tutors PS2 Pal nach Kestin et al. (2025): Lehrende legen Regeln und Musterlösungen im Prompt fest, Studierende arbeiten zu Hause Schritt für Schritt mit dem Tutor. Schlussbild eines Videos (44 s); der Dialog ist ein sinngemäßes Beispiel. Das Video gibt es nur in der Online-Version: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/kapitel04.html#vid-ps2pal-ablauf aufrufen.

4.3.3 Vom Prototyp zum Betrieb: Tutoren mit eigenen Quellen

Die bisher gezeigten Tutoren sind Prompts in einem Chat-Interface. Ein Tutor, der einen ganzen Kurs über ein Semester begleiten soll, braucht mehr: eine **Wissensbasis** aus den eigenen Kursmaterialien, damit er aus dem Skript antwortet statt aus dem Netz (das Verfahren dahinter, Retrieval-Augmented Generation, erklärt Kapitel D.3); eine **Dialogschicht**, die Fragen entgegennimmt und die Antwort an die Studierenden zurückgibt; **Leitplanken**, die bei offensichtlichen Prüfungsfragen auf Lernmaterial verweisen statt zu lösen; und ein **Gedächtnis** über Sitzungen hinweg, damit der Tutor weiß, was eine Person zuletzt geübt hat und Wiederholungsfragen zum passenden Zeitpunkt stellen kann (verteiltes Üben, Kapitel 3.4). Alle großen Cloud-Anbieter stellen diese vier Bausteine inzwischen als konfigurierbare Dienste bereit, so dass ein erster Tutor mit den eigenen Skripten an einem Nachmittag steht; Referenzarchitekturen für Hochschulen beschreibt zum Beispiel AWS für seine Dienste Bedrock, Lex

und AgentCore (Amazon Web Services, 2025b, 2025a). Der BWL-Tutor aus der Kapiteleinleitung läuft als Web-Anwendung in einer solchen Cloud-Umgebung. Die Kosten eines Pilotbetriebs mit einem Kurs liegen bei kleinen Modellen im niedrigen zweistelligen Eurobereich pro Monat; die eigentliche Investition ist organisatorisch: digital vorliegende Materialien, ein didaktisch durchdachter System-Prompt, ein Datenschutzkonzept für studierendenbezogene Daten und ein Testplan, bevor Studierende den Tutor sehen (Kapitel D.7). Wie das in konkreten Modulen gelaufen ist, zeigen die Fallbeispiele in Kapitel 6.

Drei Betriebserfahrungen aus dem Jahr 2026 zeigen, woran ein solcher Tutor im Semester scheitert oder gelingt, und keine davon liegt in der Technik. An der University of Maryland lief genau diese Architektur, ein Tutor über die Kursmaterialien im Lernmanagementsystem, in den Kursen von 30 Lehrenden; nur 15 Prozent der berechtigten Studierenden nutzten ihn, drei Viertel ihrer Anfragen verlangten eine fertige Antwort, und die Noten der Berechtigten sanken (Kapitel 3.5). Der Grund war der Standardmodus: Die Lehrenden hatten den Tutor überwiegend als Antwortmaschine konfiguriert, und wer ihn nutzte, ersetzte damit das eigene Arbeiten am Material (Liu et al., 2026). Das deutsche Gegenstück ist ein sokratisch gebauter Tutor mit eigenen Quellen auf einem lokal betriebenen offenen Modell an der Hochschule Rhein-Waal: Nach einem Semester mit 62 Studierenden war die Bereitschaft, Fragen zu stellen, gestiegen, die Neugier auf das Warum gesunken; die Studierenden nutzten auch den sokratisch gebauten Tutor als Antwortmaschine, sobald er es zuließ (Gerber et al., 2026). Dass es anders geht, zeigt ein Assistent mit eigenen Quellen in einem Planspiel zum Operations Management: 61 Prozent der Teams nutzten ihn, seine Antworten waren zu 90 bis 95 Prozent korrekt, und ein Zusammenhang zwischen Nutzung und Note fehlte, weil die Nutzung über Teamvertreter lief und der Assistent die Regeln des Spiels erklärte statt die Entscheidungen zu treffen (Tani et al., 2026). Die drei Fälle messen am selben Maßstab: Entscheidend ist nicht, ob der Tutor aus den eigenen Quellen antwortet, sondern was die Lehrenden als Standardverhalten eingestellt haben und welche Operationen er den Lernenden abnimmt (Kapitel D.7).

i Anwendungsbeispiel: Ein Tutor-Bot liefert Lösungen, statt das Lernen zu begleiten

Problem ohne KI. In einer großen Grundlagenvorlesung erreichen Lehrende die Fragen der einzelnen Studierenden kaum.
Problem mit KI. Ein Chatbot, der als Experte auftritt, liefert fertige Lösungen und nimmt den Studierenden das Lernen ab.
Der Lösungsansatz. An der Universität Kiel hat Jan Steinkühler die Entwicklung des Tutors selbst zur Lernaufgabe gemacht. Masterstudierende betreiben ihn lokal mit OpenWebUI, schreiben den Systemprompt, binden die Lernmaterialien per RAG ein und vergleichen verschiedene Modelle darauf, welche Antworten tatsächlich tutoriell helfen. Der Tutor soll schrittweise begleiten, Reflexion und Transfer anregen und keine Lösungen liefern; eingesetzt wird er in der Bachelorvorlesung Grundlagen der Elektrotechnik I. Aus den anonym protokollierten Chats lassen sich die häufigsten Fragen ablesen und in der nächsten Vorlesung aufgreifen.
Was das für wirksames Lernen heißt. *Erfahrungsbericht; eine systematische Evaluation ist angekündigt.* Die Gestaltung setzt dort an, wo der Tutor in Maryland scheiterte: am Standardmodus als Antwortmaschine (Liu et al., 2026). Ob die Leitplanken halten, sollen künftig die Studierenden mitbewerten: Was hilft wirklich weiter, wo bleibt der Tutor zu allgemein? Einen verwandten Ansatz aus der eigenen Lehre beschreibt Kapitel 6.2.2.
Quelle: Tobor et al. (2026), S. 34–35.

Offen bleibt bei alledem, wer den Tutor im Hörsaal steuert. Eine Design-Studie aus dem Labor von Vincent Aleven zu ko-orchestrierter Lehre, in der die KI vorschlägt, wann Lernende zwischen Einzel- und Partnerarbeit wechseln, zeigt, dass Lehrendenkontrolle und studentische Agency **kein einzelner Schieberegler** sind, sondern phasenweise variieren: Lehrende wollen ein Echtzeit-Vetorecht beim Wechsel selbst, akzeptieren aber Systemvorschläge für dessen Timing; Studierende wollen Mitsprache bei der Partnerwahl, erwarten die finale Autorität aber bei den Lehrenden (K. B. Yang et al., 2026). Orchestrierungswerkzeuge, die einen einzigen

Autonomiewert festlegen, werden deshalb beiden Seiten nicht gerecht; wie sich Kontrollpunkte für KI-Werkzeuge in der Lehre allgemein setzen lassen, behandelt Kapitel D.1.

Der 4D-Kreislauf beim Tutor. Der Tutor wird einmal eingerichtet und dann von anderen genutzt; der Kreislauf hängt deshalb an der Beschreibung seines Verhaltens und an der Sorgfalt beim Einsatz, und er hat zwei Adressaten. *Delegation* betrifft die Studierenden: Was frage ich den Tutor, was löse ich selbst? Ermutigung allein ändert wenig, eine Anleitung zur tutoriellen Nutzung hob in einem Ökonometrie-Kurs die Prüfungsleistung (Gallegos, 2026). *Description* ist Sache der Lehrenden: Musterlösungen als Input (Kapitel 4.3.2) und ein Verhalten, das Lösungen zurückhält. Unterschiedliche didaktische System-Prompts änderten in einem großen Experiment nichts am Lernergebnis (Barth et al., 2026); die Zurückhaltung gehört deshalb zusätzlich in eine Aufsichtsinstanz, die jede Antwort vor dem Versand prüft (Pisan, 2026). *Discernment:* Vor der Freigabe muss der Tutor an einem Goldstandard bestehen, an von Fachleuten geprüften Musterantworten (Kapitel D.7). *Diligence:* Wer Studierenden einen Tutor bereitstellt, ist Betreiber im Sinn der KI-Verordnung (Wissenschaftsrat, 2026) (Kapitel 5.5.2), und der Tutor wirkt nur so gut, wie er in den Kurs eingebettet ist (Kapitel 3.5). Ohne diese Einbettung sollte der Tutor nicht an Studierende gehen.

4.4 KI als Simulator

Hier erstellt die KI interaktive Umgebungen für praxisnahes Training. In einfachen Rollenspielen simuliert das Sprachmodell ein Gegenüber, um z. B. Analyse- oder Verhaltensmuster einzuüben. E. R. Mollick & Mollick (2024) unterscheiden dabei **Role Play** (Rollenspiele) und **Goal Play** (zielgerichtete Spiele).

4.4.1 Role Play

Rollenspiel-Simulationen lassen Studierende eine fremde Rolle einnehmen und risikofrei üben, etwa Verhandlungen, Mitarbeitergespräche oder Zeugenbefragungen; die KI spielt das Gegenüber. Rechtsreferendarinnen und -referendare üben die Zeugenbefragung im Rollenspiel mit VR-Brillen (Heetkamp, 2023), an der Wharton School trainiert der Simulator **„Pitch**

Quest“ Venture-Capital-Pitches mit mehreren KI-Agenten als Mentor, Investor und Bewerter (E. R. Mollick et al., 2024, S.5–10). Die Grenzen sind bei allen Formaten ähnlich: Die KI hält ihre Rolle nicht immer konsistent, neigt zu Bias und Halluzinationen, und Konfiguration und Entwicklung kosten Aufwand (E. R. Mollick et al., 2024, S.2–3; Wannemacher et al., 2025). Deutsche Praxisbeispiele wie „Talk2Transform“ an der TH Brandenburg, Sprachmodi, die Simulationen durch Stimme realistischer machen (Barra et al., 2024), sowie Gestaltungsempfehlungen und neuere Studien sammelt Anhang C (Kapitel C.3.1, Kapitel C.5.2, Kapitel C.6).

i Anwendungsbeispiel: Im Rollenspiel üben wenige Studierende, der Rest schaut zu

Problem ohne KI. Im klassischen Rollenspiel üben nur zwei bis vier Studierende aktiv, die anderen beobachten. Beobachtung und Bewertung erzeugen Rollenstress und dämpfen die Lust am Ausprobieren, und manche Rollen liegen weit von der Lebenswelt der Studierenden entfernt.

Problem mit KI. Eine KI-Persona kann jedes Gegenüber spielen, verfällt aber in Argumentationsschleifen und überzeichnet Skepsis und Eskalation.

Der Lösungsansatz. Michael Barton (Universität Leipzig) macht in einer Übung zur Personal- und Organisationsökonomik im BWL-Master die Prinzipal-Agent-Theorie erfahrbar. Die Studierenden spielen die Führungskraft, die einen erfahrenen Mitarbeiter über 50 von einer Schulung zur Digitalisierung überzeugen soll; die KI spielt den skeptischen Mitarbeiter, samt Hinweisen auf Mimik und Gestik. Ein rund zweiseitiger Systemprompt regelt Rolle, Gesprächsphasen, Schwierigkeit und das Feedback am Ende, eine Info-Karte gibt den Studierenden den Rahmen. Ein Durchlauf dauert fünf bis zehn Minuten und lässt sich wiederholen; danach reflektieren die Studierenden das Gespräch in einem Fragebogen.

Was das für wirksames Lernen heißt. *Erfahrungsbericht mit offener Befragung (Wintersemester 2024/25: 17, 2025/26: 9 Studierende).* Alle Studierenden rücken von der passiven Beobachtung in die interaktive Übung, die nach ICAP am stärksten wirkt (Chi et al., 2018). Die Befragten lobten Realitätsnähe und überwiegend hilfreiches Feedback; die genannten Grenzen zeigen, dass der Prompt laufend überarbeitet werden muss und eine abschließende Reflexion der

Methode dazugehört (Barton, 2026).
Prompt zum Nachnutzen über den QR-Code. Quelle: Barton (2026); Tobor et al. (2026), S. 40–42.

4.4.2 Goal Play – zielgerichtete Spiele

In **zielgerichteten Spielen** ("Goal Play", E. R. Mollick & Mollick (2024)) bleiben Studierende in ihrer normalen Rolle und wenden in einer Situation bestimmtes Wissen oder theoretische Konzepte an (z. B. Zielsetzung, Selbst-Distanzierung oder Analyseraster wie Transaktionskostenanalyse), indem sie einen KI-Charakter anleiten. Wichtig dabei: Die Studierenden wissen etwas, das das KI-Gegenüber im Spiel nicht weiß.

So nehmen etwa bei dem einfachen Rollenspiel **"Teach the AI"** (E. R. Mollick & Mollick, 2024, S.21–23) Studierende die Rolle des Lehrenden ein und erklären der KI (die einen unwissenden Studenten spielt) ein Konzept. Der Mehrwert liegt im vertieften Lernen durch Lehren (Protégé-Effekt) und dem Aufdecken eigener Wissenslücken. Als Herausforderung kann die KI manchmal vom Thema abweichen oder Fragen stellen, die die Studierenden an ihre Grenzen bringen; zudem ist die Simulation eines "Novizen" durch die KI nur begrenzt realistisch (E. R. Mollick & Mollick, 2024, S.24).

4.4.3 Wie echt ist das Gegenüber?

Ein Rollenspiel übt nur, was das simulierte Gegenüber glaubhaft vorgibt. Wie weit Sprachmodelle Menschen tatsächlich nachbilden, prüfen seit 2026 Studien aus der Nutzer- und Umfrageforschung, die Sprachmodelle als Ersatz für Befragte einsetzen; in der Lehre ist keine von ihnen entstanden, ihr Befund lässt sich aber auf Rollenspiele übertragen. In zwölf Klicktests aus der Praxis der Nutzerforschung mit 3.431 Teilnehmenden sollte GPT vorhersagen, wohin Menschen auf einer Bildschirmseite zuerst klicken und warum; in 53 % der Aufgaben wich die Verteilung der simulierten Klicks deutlich von der echten ab. Ausführliche Personas, schrittweises

Nachdenken des Modells und andere Zufallseinstellungen änderten daran wenig, sie machten die Antworten nur glaubwürdiger (Kuric et al., 2026). Woran das liegt, zeigt eine Auswertung von vier Datensätzen mit über 400.000 Befragten und über 6.000 Fragen. Im Mittel treffen die Modelle die menschlichen Antworten gut. Wie eine bestimmte Person vom Mittel abweicht, erklären sie aber nur zu 3 %, obwohl die Wiederholungsbefragung derselben Menschen zeigt, dass 54 % dieser Abweichung stabil und damit vorhersagbar wären. Reichere Personabeschreibungen und Nachtraining schließen die Lücke nicht, und die simulierten Antworten streuen weniger als die echten (Ahn et al., 2026).

Für ein Rollenspiel heißt das: Die KI spielt verlässlich den typischen Kunden, die typische Patientin, den typischen skeptischen Mitarbeiter. Den eigenwilligen Einzelfall, an dem Gesprächsführung erst schwierig wird, spielt sie schlechter, und dass sie dabei überzeugend klingt, belegt keinen Realismus. Lehrende sagen den Studierenden deshalb, dass sie mit einem Durchschnitt üben, und fragen in der Nachbesprechung, wie ein echtes Gegenüber anders hätte reagieren können.

Gut trainieren kann ein Simulator trotzdem, wenn die Rollen sauber getrennt sind. In einem randomisierten Experiment mit 100 Medizinstudierenden in China übte die Versuchsgruppe Anamnesegespräche mit drei Agenten: einem Patienten, einem Tutor, der mit sokratischen Fragen zu Anamnese, klinischem Denken und Empathie anregte, ohne die Diagnose zu verraten, und einem Bewerter, der den Fortschritt verfolgte, ohne Punkte zu zeigen. Die Kontrollgruppe arbeitete die Fälle ohne Sprachmodell durch, mit schrittweise freigegebenen Informationen. In der Abschlussprüfung, einem Gespräch mit dem Patienten-Agenten allein, erreichte die Agentengruppe 71,8 % der Punkte gegenüber 55,6 %; den größten Vorsprung hatte sie in der Gesprächsführung, beim Ausdruck von Empathie lag sie 31 Prozentpunkte vorn. Die richtige Diagnose stellten beide Gruppen gleich oft (84 gegenüber 86 %) (L. Yang et al., 2026). Der Simulator trainiert also, was im Gespräch geübt wird, nicht das Fachwissen dahinter. Sein Bauprinzip kennt schon Pitch Quest: Wer spielt, lehrt nicht, und wer lehrt, bewertet nicht. Gestaltungsempfehlungen für solche Rollenprompts und die übrigen Studien seit 2025 sammelt Anhang C (Kapitel C.5.2, Kapitel C.6).

Für Role Play wie Goal Play gilt: Die KI kann von der Rolle abweichen oder inkonsistent agieren, und die Qualität der Erfahrung kann variieren. Eine **sorgfältige Einbettung und Reflexion** durch Lehrende ist entscheidend (E. R. Mollick & Mollick, 2024). Bei allen Simulatoren ist die Notwendigkeit

einer klaren didaktischen Rahmung und eines Debriefings durch Lehrende ("Human in the Loop") zentral, um den Lernerfolg zu sichern und die Grenzen sowie potenzielle Fehler der KI zu reflektieren (E. R. Mollick & Mollick, 2024, S.16).

Der Simulator dieses Abschnitts ist ein Sprachmodell, das eine Rolle spielt, und deshalb nie ganz vorhersagbar. Für Zusammenhänge, die sich berechnen lassen, etwa Warteschlangen oder den Bullwhip-Effekt in einer Lieferkette, ist ein rechnendes Widget das verlässlichere Übungsfeld; zwei Beispiele und eine Prüfliste stehen am Ende von Kapitel 4.2.2. Auch dort entscheidet die Nachbesprechung, was gelernt wird.

Der 4D-Kreislauf beim Simulator. Beim Simulator hängt der Kreislauf an der Beschreibung der Figur und an der Prüfung, wie echt sie ist. *Delegation:* Welche Übung verträgt ein simuliertes Gegenüber, und welche braucht Menschen? *Description:* Rolle, Wissensstand und Verhalten der Figur festlegen (Kapitel C.5.2) und die Rollen trennen; mit getrennten Agenten für Patient, Tutor und Bewertung übten Medizinstudierende Gesprächsführung wirksamer als die Kontrollgruppe (L. Yang et al., 2026). *Discernment:* Vor dem Einsatz prüfen, ob die Figur mehr als den Durchschnitt spielt, denn Sprachmodelle treffen das mittlere Verhalten von Menschen, nicht den Einzelfall (Ahn et al., 2026; Kuric et al., 2026). *Diligence:* Den Studierenden sagen, dass sie mit einem simulierten Durchschnitt üben, und das Debriefing selbst führen (E. R. Mollick & Mollick, 2024). Was die Prüfung der Echtheit nicht trägt, wird nicht als Übungsgegenüber delegiert.

Kernaussagen

1. Vier Rollen ordnen die Praxis: Als Hiwi nimmt die KI Arbeit ab, als Copilot ermöglicht sie, was wir allein nicht könnten, als Tutor begleitet sie Lernende, als Simulator stellt sie Übungssituationen bereit.
2. Technik ersetzt Tätigkeiten, nicht Berufe. In der Lehre automatisiert KI vor allem Standardisiertes, unterstützt bei Kernaufgaben und schafft neue Aufgaben wie Qualitätskontrolle und Kursdesign. Ob am Ende Zeit gespart wird, ist offen.
3. Bei der Literaturrecherche entscheidet nicht der Markenname, sondern das Muster: einmalige Suche oder iterativer Prozess, Trefferliste oder zusammenfassende Analyse.

4. Schreiben und Programmieren mit KI sind Cyborg-Tätigkeiten. Der Lernwert hängt davon ab, wie viel die Studierenden selbst verstehen und verantworten müssen. Wer eine Simulation von KI bauen lässt, prüft das Modell, nicht das Bild. Programmier-Agenten liefern schneller fertigen Code und weniger Verständnis; wo der Code Lernziel ist, gehören Prüfschritte in die Aufgabe.
5. Ein guter KI-Tutor lässt Lernende im eigenen Tempo arbeiten, gibt sofort Rückmeldung, hält sie aktiv und verschiebt die Arbeit der Lehrenden von der Einführung zur Vertiefung. Er braucht Musterlösungen als Input und systematische Qualitätstests, sonst produziert er überzeugende Fehler.
6. Simulationen wirken, wenn Lehrende sie rahmen und nachbesprechen. Ein simuliertes Gegenüber trifft den typischen Fall, nicht den Einzelfall, und kann aus der Rolle fallen; der Mensch bleibt in der Schleife.

i Lernfragen

Wiederholen

1. Nennen Sie die vier Rollen und je eine typische Anwendung.
2. Was bezeichnen Automatisierung, Augmentierung und neue Aufgaben? Nennen Sie je ein Beispiel aus der Lehre.
3. Nach welchen zwei Fragen ordnet das Kapitel Recherchewerkzeuge, und welche vier Typen ergeben sich daraus?
4. Was unterscheidet Role Play von Goal Play?

Anwenden

5. Nehmen Sie Ihre eigene Aufgabenliste einer typischen Semesterwoche und sortieren Sie jede Aufgabe nach Automatisierung, Augmentierung oder neuer Aufgabe. Welche neue Aufgabe kommt bei Ihnen dazu, die Sie heute noch nicht einplanen?
6. Entwerfen Sie aus dem Gedächtnis einen Tutor-Prompt für ein Konzept Ihres Fachs. Welche drei didaktischen Bremsen bauen Sie ein, und woher bekommt der Tutor seine Musterlösungen?

7. Welche Berufssituation Ihrer Absolventinnen und Absolventen eignet sich für ein Role Play, welche für ein Goal Play? Was muss im Debriefing unbedingt zur Sprache kommen?

Beurteilen

8. Ob KI Lehrenden am Ende Zeit spart, bleibt nach diesem Kapitel offen. Welche neuen Aufgaben machen Sie skeptisch, und unter welcher Bedingung würden Sie trotzdem netto Zeit gewinnen?

Lösungshinweise: Anhang F.

5 Empfehlungen zur Umsetzung

Lernziele

Nach diesem Kapitel können Sie …

- eigene Aufgaben mit einem Sprachmodell durchspielen und daraus Anpassungen für Ihren Kurs ableiten;
- eine praktische, über das Semester verteilte Einführung der Studierenden planen und einen Kurs in drei Phasen mit wechselnden Rollen der KI ergänzen;
- eine Prüfungsleistung nach den vier Säulen Mündlichkeit, Prozessorientierung, Kontextualisierung und Kollaboration umbauen und die Grenzen von KI-Detektoren begründen;
- Studierenden eine praktikable Dokumentation ihrer KI-Nutzung vorgeben, die zu den Richtlinien Ihrer Hochschule passt.

Probleme aus der Lehre

Zu jedem dieser Probleme bietet das Kapitel Lösungsansätze. Wählen Sie eine Antwort, bevor Sie weiterlesen: Wer vorher rät, behält die Auflösung besser. Die Kernaussagen am Kapitelende greifen die Probleme in derselben Reihenfolge auf.

1. Sie wollen im nächsten Semester KI in Ihren Kurs einbauen und wissen nicht, wo Sie anfangen sollen. Was ist der erste sinnvolle Schritt?

a) Eine Richtlinie zur KI-Nutzung für die Studierenden schreiben.
b) Die eigenen Aufgaben in ein starkes Modell geben und die Grenzen ausloten.
c) Einen Tutor-Bot für die häufigsten Fragen einrichten lassen.

2. Eine 90-minütige Einführung in KI in der ersten Semesterwoche hat wenig bewirkt; die Studierenden nutzen KI weiter unsicher. Was wirkt besser?

a) Häufiges, über das Semester verteiltes Üben in Präsenz.
b) Eine längere und gründlichere Theorieeinführung.
c) Ein Selbstlernkurs, den Studierende allein absolvieren.

3. Ihre Hausarbeiten lassen sich zu Hause mit starken Modellen in einer Stunde schreiben. Ein Kollege will alle Abgaben durch einen KI-Detektor schicken. Was raten Sie?

a) Zustimmen, denn Detektoren erkennen KI-Texte inzwischen zuverlässig.
b) Hausarbeiten abschaffen und nur noch Klausuren im Antwortwahlverfahren schreiben.
c) Abraten und die Prüfung mündlicher, prozessnäher und kontextbezogener gestalten.

4. Sie möchten nachvollziehen, wie Studierende KI in ihren Projektarbeiten genutzt haben. Welche Dokumentation ist praktikabel?

a) Ein vollständiges Protokoll jeder Interaktion mit allen Prompts.
b) Eine Stichwortliste, eine Übersicht nach Phase oder ein Reflexionstagebuch.
c) Keine, weil sich KI-Nutzung ohnehin nicht überprüfen lässt.

5.1 Typische Aufgaben und Fragestellungen mit der KI durchspielen, Prompts anpassen, experimentieren

Lehrende sollten zunächst Informationen sammeln, um zu verstehen, was KI mit den Aufgaben in ihrem Kurs bewirken kann (MIT Teaching + Learning Lab, 2023). Melden Sie sich bei einem der professionellen KI-Dienste wie ChatGPT oder Claude an und spielen Sie mit exemplarischen Konzepten, Fragen und Aufgabensets aus dem Kurs. Dabei ist es wichtig, nicht gleich bei der ersten schlechten Antwort aufzugeben, sondern Anpassungsmöglichkeiten durchzugehen: Lässt sich der **Input beschränken**? (Fragen auf einen Text-Input, eine gute Internetquelle oder eine hochgeladene PDF beschränken.) Lässt sich der **Prompt anpassen**? (Bearbeitung schrittweise durchführen lassen, Optionen und Szenarien durchgehen lassen usw., siehe den Abschnitt 2.5.2 zu Prompt

Engineering.)

Wichtig ist, sich zu überlegen, welches Lernziel jede Aufgabe hat und wie die KI damit umgeht. Es sollte bewertet werden, bei welchen Arten von Fragen die KI gut abschneidet und wo ihre Grenzen liegen (E. R. Mollick, 2025b). Diese Erkenntnisse können dann genutzt werden, um etwa Aufgabensets und andere Aufgabenstellungen besser zu strukturieren.

5.2 Ausrichtung der Anpassungen nach Empfehlungen der Lernforschung

Um die Empfehlungen der Lernforschung in das Vorgehen mit Künstlicher Intelligenz (KI) und Aufgabensets zu integrieren, könnten folgende Schritte unternommen werden (MIT Teaching + Learning Lab, 2023):

- **Zeitliche Verteilung und inhaltliche Mischung von Lerninhalten (Spacing & interleaving)**: Die Aufgabensets sollten so gestaltet werden, dass sie über das Semester verteilt sind und eine Vielfalt an Themen abdecken. Dies fördert die Langzeiterinnerung und hilft den Studierenden, die Anwendung der Konzepte in verschiedenen Kontexten zu üben. KI kann genutzt werden, um personalisierte Lernpläne zu erstellen, die auf den individuellen Fortschritt der Studierenden abgestimmt sind und eine Mischung aus verschiedenen Aufgabentypen bieten.
- **Testgestütztes Lernen (Test-enhanced learning)**: Regelmäßige, durch KI unterstützte Quizze und Tests können in den Lehrplan integriert werden, um das Abrufen von Informationen zu fördern. Diese Tests könnten auch die kritische Bewertung von KI-generierten Antworten beinhalten, um die kritische Denkfähigkeit der Studierenden zu schärfen.
- **Fragebasierte Ausarbeitung (Explanatory questioning)**: KI-Tutor-Bots könnten entwickelt werden, um Studierende durch gezielte "Warum"-Fragen zu leiten, die ein tieferes Verständnis des Materials fördern. Diese Bots könnten in Simulationen und Rollenspielen eingesetzt werden, um die Studierenden dazu zu bringen, ihre Entscheidungen zu erklären und zu reflektieren, wodurch die Anwendung von Konzepten in realen oder simulierten Situationen vertieft wird.

5.3 Einführung der Studierenden planen: Besser praktisch, häufig und niedrigschwellig

Den Einsatz von KI lernen die Studierenden, wenn sie häufig und über das Semester zeitversetzt damit experimentieren dürfen und müssen. Auch hier führen wieder die Empfehlungen des **Spacing & Interleaving** zu höherer Effektivität. Unterstützend können **externe Lernvideos** von seriösen Plattformen wie dem KI-Campus genutzt werden (z. B. https://ki-campus.org/videos/generativeki) oder selbst erstellte hochschulweite Angebote wie die Lehrpfade der TH Köln (https://lehrpfade.th-koeln.de/kategorie/ki/).

Um ein gemeinsames Verständnis über Grundlagen herzustellen, ist es hilfreich, **Zeit in einer der ersten Präsenzveranstaltungen einzuräumen**, um das gemeinsam zu üben. Der Sprung ins kalte Wasser ist dabei meist besser als eine lange Theorieeinführung: **Gleich anfangen**, dann problembasiert erläutern. Aspekte von **testbasiertem Lernen** und **fragebasierte Ausarbeitung** lassen sich gut über Anwendungsaufgaben in der Präsenzveranstaltung einbauen.

5.3.1 Beispiel: KI-Übung in Präsenzveranstaltung am Ende eines Theorieblock zu Nachhaltigkeit in Lieferketten

Aufgabe: Nicht lange schnacken, gleich anpacken! Mit der KI einen Projektplan für erste konkrete Schritte einer Nachhaltigkeitsstrategie erstellen (Edge Browser, Bing Copilot = GPT-4). Prompts zum Einstieg werden den Studierenden vorgegeben. Anfang mit:

- *Prompt #1*: „KI als Tutor“ oder ähnlich (siehe Appendix: Beispiel KI als Tutor #1/ Allgemeiner Tutor. Prompts im Folgenden immer *kursiv*.)
- *Prompt #2*: *Ich will eine Cradle-to-cradle Nachhaltigkeitsstrategie für ein Unternehmen entwerfen. Helfen Sie mir, konkrete erste Schritte nach der Cradle-to-cradle Zertifizierung zu planen.*

Studierende sollen ein Unternehmen auswählen, bei dem sie schon einmal gearbeitet haben, oder das sie gut kennen. Hier ein Beispiel.

- *Prompt #3*: *Ich denke über Voss Automotive nach, die folgende Produkte herstellen: innovative Leitungs-und Verbindungssysteme, die überall auf der*

Welt in Pkw und Nutzfahrzeugen sowie Land- und Baumaschinen eingesetzt werden. Unser Produktportfolio umfasst dabei einbaufertige Leitungsmodule mit Rohren, Schläuchen, Verbindungselementen, Ventilen und Sensoren. Zur Verbindungstechnik gehören Stecksysteme, Verschraubungen, Mehrfachkupplungen und Verteiler.

- *Prompt #4*: *Erstelle einen Zeitplan als Tabelle mit Aufwandsschätzungen für 3 Personen in 4 Wochen.*
- *Prompt #5*: *Mehr Details bitte: Erstelle Unteraufgaben für die jeweiligen Aufgabenpakete, jeweils auch wieder mit Aufwandsschätzungen.*

Die Studierenden sollen den Projektplan dann weiter verbessern und diskutieren. Erweiternd können sie auch z. B. Projektrisiken, Indikatoren und Gegenmaßnahmen und Szenarien erheben und diskutieren.

5.4 Wie prüfen wir jetzt? Jenseits der Homework Apocalypse

Jenseits der vielen produktiven Anwendungen besteht die Gefahr, dass Studierende wichtige Teile des Denkprozesses an Sprachmodelle delegieren (H.-P. H. Lee et al., 2025). Klassische „Hausaufgaben“ wie **Seminararbeiten, Gruppenprojekte und Abschlussarbeiten drohen entwertet zu werden**. Ohne Anpassung der Aufgabenstellung werden die Aufgaben potenziell sinnlos, da Studierende etwa Aufsätze oder Reflexionsaufgaben einfach von Chat GPT schreiben und einreichen. Interviews mit Studierenden und Nutzungsstudien zeigen, dass diese Gefahr akut ist. Wie wir in der umfassenden empirischen Nutzungsstudie von Handa et al. (2025) sehen, nutzen Studierende Sprachmodelle speziell zur Schreibunterstützung intensiv und häufig. Das New York Magazine betitelt eine Recherche von 2025 mit „**Everyone is cheating their way through college**“, auf der Grundlage einer Vielzahl von Interviews mit desillusionierten Studierenden und Lehrenden (Walsh, 2025). Ein Artikel der Fachzeitschrift Nature skizziert ebenfalls basierend auf Interviews ein breites Spektrum an aktiver Nutzung im höheren Bildungsbereich (Heidt, 2025).

Schon 2023 kündigte der Wharton Professor Mollick die „Homework Apocalypse“ an (E. R. Mollick, 2023). Dabei geht es Mollick weniger um das Tricksen mit den neuen technischen Möglichkeiten („Cheating was already common in schools“), sondern mehr um die **empfundene Sinnlosigkeit von klassischen Hausaufgaben**. „Students will want to understand why they are doing assignments that seem obsolete thanks to

AI.“. Wer gibt noch reine Rechenübungen auf, wenn alle Taschenrechner haben? Wie kann Eigen- und Fremdleistung unter diesen neuen technischen Bedingungen getrennt werden? Wie können unter diesen Bedingungen Anreize für Studierende gesetzt werden, Texte selbst zu lesen und Sätze selbst zu formulieren?

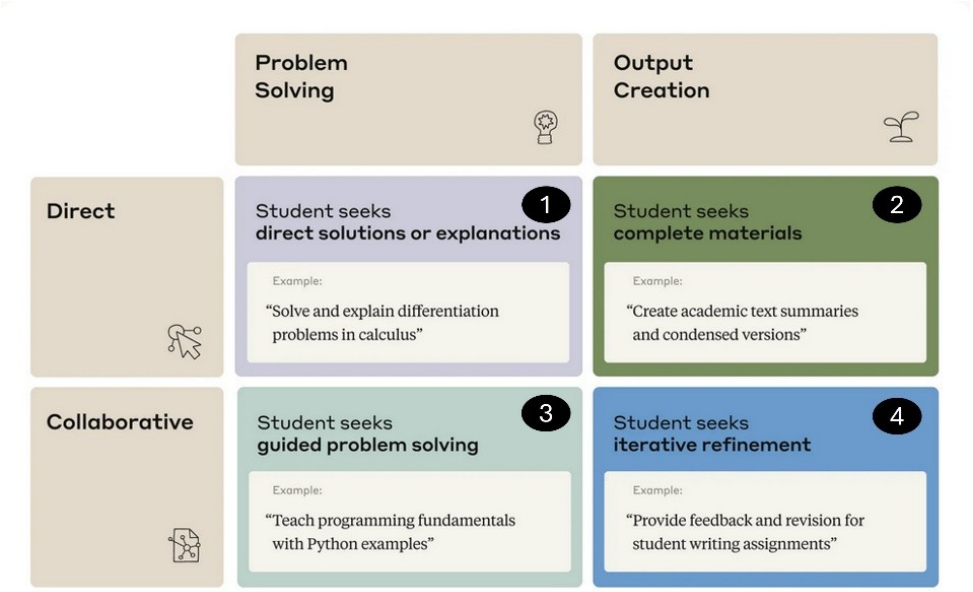

Abbildung 5.1. Etwa gleichverteilt: Vier Arten der Interaktion von Studierenden mit Sprachmodellen. Quelle: Handa et al. (2025)

Eine Unterscheidung der empirischen Anthropic-Studie von Studierenden-Interaktionen mit Sprachmodellen ist dabei hilfreich, um das Problem einzuordnen (Handa et al., 2025): Hier werden vier Arten von LLM-Nutzung unterschieden, je nachdem, ob ein **Problem** gelöst oder ein **Ergebnis generiert** werden soll und je nachdem, ob dies **direkt oder interaktiv** erfolgt. Kollaborative Nutzungsformen (Typ 3 und 4) sind dabei für den Lernerfolg eher hilfreich, während das direkte Bereitstellen von Problemlösungen oder Texten aufgrund mangelnder Beschäftigung der Studierenden mit den Problemen und Materialien für Hausarbeiten eher hinderlich sein könnte (anders als für die Vorbereitung von kontrollierten Tests wie Klausuren). Studierende werden so eher in eine passive Rolle gedrängt und es fehlen die erwünschten Schwierigkeiten (desirable difficulties, (Roediger & Karpicke, 2006)), das fragebasierte Durchkauen und Hin- und Herüberlegen, das die Lernforschung als wichtig für

langfristiges Behalten ansieht (Roediger & Pyc, 2012).

Grob gesagt wollen wir also **kollaborative Interaktion und Hilfestellung fördern und einfaches Übernehmen bereitgestellter Lösungen verhindern**. Wie können wir dafür die Hausarbeiten anpassen? Im Folgenden werden einige Empfehlungen zusammengefasst. Der Vier-Säulen-Ansatz nach Gmeiner bietet Orientierung. Er unterscheidet vier Gegenmaßnahmen für das Prüfen unter KI-Bedingungen: Mündlichkeit, Prozessorientierung, Kontextualisierung sowie Kollaboration (Gmeiner, 2025).

Abbildung 5.2. KI-resistente Aufgabenstellungen – 4 Säulen nach Gmeiner (2025)

Die empirische Forschung der Jahre 2025 und 2026 stützt diesen Umbau in fünf Punkten.

Erstens verlieren klassische, asynchron geschriebene Aufgaben unter generativer KI ihre Aussagekraft, weil sie den Kompetenzerwerb eher verhindern als ihn nachzuweisen. Rismanchian et al. (2026) zeigen das an 3,2 Millionen Lerninteraktionen der Mathematikplattform ALEKS über zehn Jahre: Nach der Veröffentlichung von ChatGPT sinkt die Bearbeitungszeit für Aufgaben, deren Text sich in einen Chatbot kopieren lässt, um 2,8 % pro Quartal und kumuliert 26,9 % über elf Quartale bei Studierenden, und der dauerhafte Wissensgewinn aus diesen Aufgaben bleibt aus. Unter Aufsicht verschwindet der Effekt vollständig; die Zeitersparnis stammt also aus der KI-Nutzung, nicht aus schneller gewordenen Lernenden. Delikoura et al. (2025) ordnen diesen Befund in einen Rahmen ein: Ihre Synthese von 70 empirischen Studien beschreibt, wie technische Modellrisiken über die Interaktion zu Überabhängigkeit, nachlassender eigenständiger Lernfähigkeit und einem Verlust an Lernenden-Agency werden, und benennt ausdrücklich die Bedrohung der Prüfungsvalidität. Der Umbau

der Prüfung ist damit kein Vorsorgeargument, sondern die Antwort auf einen gemessenen Verlust.

Zweitens hängt der diagnostische Wert einer Aufgabe an ihrem Format: Offene Begründung bleibt aussagekräftig, Reproduktion und Wiedererkennung nicht. Xiaoyu Hou et al. (2026) trennen in einem Drei-Arm-Experiment der Bauingenieur-Ausbildung folienbasiertes Lernen, ungeführte KI-Unterstützung und eine KI-Unterstützung, die durch ein fünfschrittiges Prompting-Gerüst strukturiert ist. Der Lernvorteil zeigt sich allein bei offenen Aufgaben, die Erklärung und Begründung verlangen, und verschwindet bei Multiple-Choice-Items; die ungeführte Bedingung schlägt die passiven Folien nicht. Formate, die auf Reproduktion setzen, messen unter KI-Bedingungen wenig; der Ertrag liegt in Aufgaben, die Schlussfolgern und Begründen sichtbar machen, also in denselben prozess- und mündlichkeitsnahen Formaten, die die vier Säulen vorschlagen.

Drittens sichern Detektion und „authentische" Aufgaben allein die Integrität nicht; der Nachweis muss von der Ausgabe zum synchronen, prozessnahen Handeln wandern. Kofinas et al. (2025) prüfen das experimentell an zwei britischen Universitäten und finden zweierlei: Prüfende können KI-gestützte Arbeiten nicht von rein menschlichen unterscheiden, und der Grad der Authentizität einer Aufgabe ändert daran nichts. Ihre Schlussfolgerung deckt sich mit der dieses Kapitels: Der Schwerpunkt muss von ausgabebasierten, asynchron geschriebenen Prüfungen zu synchronen, interpersonalen und performativen Formaten wandern. DeVito et al. (2025) zeigen die soziale Kehrseite unzuverlässiger Detektion: In 1.199 Reddit-Diskussionen mit knapp 14.000 Kommentaren berichten Studierende Belastung durch falsche Betrugsvorwürfe der KI-Detektoren, während Lehrende sich um Integrität und Adoptionsdruck sorgen. Der Verzicht auf Detektionswerkzeuge, den auch An et al. (2025) empfehlen, gründet damit nicht nur auf deren Fehleranfälligkeit, sondern auf dem Schaden, den Falsch-Positive im Vertrauensverhältnis anrichten.

Viertens lassen sich mündliche und performative Formate mit KI zugänglicher und stressärmer gestalten, ohne ihren Nachweischarakter zu verlieren. Yusuf et al. (2026) begegnen der Schwäche, die solchen Formaten am häufigsten vorgehalten wird, dem situativen Prüfungsstress. Ihr Werkzeug AIvaluate, ein LLM-gestützter Gesprächsagent für mündliche Präsentationen und Viva-voce-Prüfungen, senkt in einem Within-Subjects-Vergleich mit 35 Studierenden die Prüfungsangst gegenüber der klassischen Präsenzprüfung. Damit erweitert sich die Säule der Mündlichkeit von der

Aufwands- auf die Zugänglichkeitsseite: Der interaktive Nachweis von Autorschaft und Transfer bleibt erhalten, die Hürde für ängstliche Lernende sinkt. Dass ein solcher Umbau überfällig ist, formuliert Avigad (2026), Mathematiker an der Carnegie Mellon University, für die quantitativen Fächer zugespitzt: Klassische Hausaufgaben seien obsolet, und Prüfung müsse um die Tatsache herum neu konstruiert werden, dass Studierende im Berufsleben auf KI zurückgreifen.

Fünftens unterstützt KI das Bewerten, ersetzt das menschliche Urteil aber noch nicht; die Skalierung der neuen Formate bleibt an Menschen gebunden. Sapkota & Murshed (2026) lassen sechs LLM-Konfigurationen eine Klausur in diskreter Mathematik gegen menschliche Bewertende korrigieren. Großzügige Teilpunkt-Vorgaben senken den Fehler über alle Modellfamilien, doch Kalibrierung und Rangerhaltung fallen auseinander: Die beste mittlere Abweichung und die beste Korrelation entstehen unter verschiedenen Konfigurationen, und keine ist reif für unbeaufsichtigtes Benoten. Levine et al. (2026) untersuchen die Bewertung handschriftlicher Mathematik durch sehfähige Modelle: Die Gesamtgenauigkeit ist hoch, doch 87 % der Fehler des besten Modells stammen aus der Transkription der Handschrift, nicht aus falsch angewandten Rubriken. Der Engpass sitzt in der Erfassung, nicht im Urteil; automatisierbar ist die Rubrik-Anwendung, die Wahrnehmung des studentischen Artefakts bleibt vorerst menschliche Aufgabe (zur Verschiebung der Bewertungsarbeit vgl. Kapitel 4.1).

5.4.1 Formate nach den vier Säulen

Die Ratgeber der Jahre 2023 bis 2025 übersetzen die vier Säulen in konkrete Formate (Tabelle 5.1). **Mündlichkeit** macht Verständnis, Transfer und Autorschaft im Gespräch sichtbar; eigene Entscheidungen müssen erläutert und verteidigt werden, und die schriftliche Arbeit wird vom Leistungsnachweis getrennt (Gmeiner, 2025). **Prozessorientierung** verlagert das Gewicht vom Produkt auf den Weg dorthin und beteiligt die Prüfenden am Entstehungsprozess; die Sichtbarkeit individueller und kollaborativer Arbeitsschritte macht unreflektierte KI-Nutzung unattraktiv (Hanover Research, 2024; Monash University, 2025; Mulder et al., 2023). **Kontextualisierung** bindet die Leistung an reale, lokale oder persönliche Daten, Orte und Rollen; solche Aufgaben sind „un-promptbar“, weil sie nicht-öffentliche Informationen, eigene Beobachtung und Gegenwartsbezug verlangen (Gmeiner, 2025; Mulder et al., 2023). **Kollaboration und**

Kreation prüfen über Gruppenaufgaben in der Veranstaltung, Peer- und Selbstbeurteilung und gestufte Projekte die soziale, evaluative und kreative Seite des Lernens (Hanover Research, 2024; Mulder et al., 2023). In allen Formaten legen Studierende ihre KI-Nutzung offen; KI darf strukturieren und sprachlich glätten, nicht aber Evidenz, Theoriebildung oder Ergebnisse ersetzen.

Säule	Format	Artefakte	Skalierung
Mündlichkeit	Kurzkolloquium (Viva voce): rund zehn Minuten zu zwei Kernentscheidungen der eingereichten Arbeit, dazu eine Transferfrage („Was würden Sie ändern, wenn ...?“)	Schriftliche Arbeit (mit KI-Unterstützung erlaubt), Aufzeichnung des Gesprächs	Standardisierte Leitfragen, Doppelprüfung im Stichprobenprinzip, Aufzeichnung für Zweitbewertung
	Interaktive mündliche Prüfung: praxisnahes Szenario oder Fall im offenen Gespräch mit Prüfenden oder anderen Studierenden (Ward et al., 2024)	Gespräch, bewertet nach Rubrik (auch gemeinsam mit Studierenden entwickelt (Ní Bheoláin et al., 2020))	Erstsemesterkurse mit rund 200 bis 800 Studierenden und 4 bis 10 Prüfenden
	Posterpräsentation mit strukturierter Fragerunde zu Methode, Evidenz und Limitationen	Poster, einseitiges Handout, Frageprotokoll	Parallele Poster-Sessions mit festen Zeitslots
Prozessorientierung	Lernjournal mit Audit-Trail: Suche, Auswahl, Analyse, Entscheidungen und Revisionen fortlaufend dokumentiert	Journal mit Versionsverlauf (Overleaf, Git), Query-Protokolle, Daten- und Code-Paket, Endprodukt	Der dokumentierte Prozess ersetzt Detektoren als Beurteilungsgrundlage
	Gestaffelte Hausarbeit mit Feedback nach jeder Stufe, Prozess- und Produktpunkte getrennt	Gliederung, annotierte Bibliografie, Methoden-Memo, Rohanalyse, Entwurf, Endfassung	Peer-Review nach Rubrik, stichprobenhafte Checks durch Lehrende

Säule	Format	Artefakte	Skalierung
Kontextualisierung	Eigene Empirie: Fall auswählen, Primärdaten erheben (Interviews, Prozessanalysen, Prototyp), Entscheidungsvorlage erstellen	Datensatz, Methodenprotokoll, Analyse-Notebook, Kurzempfehlung	–
	Replikation einer veröffentlichten Analyse mit Robustheitsprüfung	Repro-Paket, Abweichungsprotokoll, Kurzbericht	Automatisierte Checks, präzise Rubriken
Kollaboration und Kreation	Peer-reviewtes Multimedia-Projekt (Podcast, Video, Infografik) für ein definiertes Publikum; auch Rollen- oder Planspiele (Gmeiner, 2025)	Produkt, Quellenliste, Peer-Feedback-Protokolle, individuelle Reflexion	Kurze Nachgespräche sichern die Autorschaft
	Team-Capstone mit getrennter Team- und Individualnote	Teamartefakt (Prototyp, Konzeptstudie, Policy-Brief), individueller Methoden-Anhang, Reflexion zum eigenen Beitrag und zur KI-Nutzung	Milestone-Boards, strukturierte Peer-Assessments, stichprobenhafte mündliche Abfrage pro Team

Tabelle 5.1. Prüfungsformate nach den vier Säulen. Quellen: Gmeiner (2025); Mulder et al. (2023); Hanover Research (2024); Monash University (2025); Ward et al. (2024)

Mündliche Formate verlangen vorab Bewertungsraster und bringen eigene Herausforderungen mit: situativen **Stress**, **Validität** (Form oder Inhalt, einfache oder schwere Fragen, mündliche oder schriftliche Ausdrucksfähigkeit), **Reliabilität** über verschiedene Nachfragen, Bewertende und Szenarien hinweg und **Fairness** gegenüber Sprachfähigkeit und Vorwissen. Ihr Vorteil ist die Reaktivität: Vertiefende Nachfragen legen Hintergrundwissen und Begründungen offen (Akimov & Malin, 2020,

S.31; Kearney, 2019). Einsätze interaktiver mündlicher Prüfungen in großen Kohorten an verschiedenen Universitäten sind unter https://sway.cloud.microsoft/yQ2s0Bm3ILkWtGll zusammengestellt; Leitfäden mit Beispielaufnahmen und Bewertungsrubriken stellt etwa die Dublin City University bereit (https://www.dcu.ie/sites/default/files/inline-files/interactive-oral-io-user-guide_0.pdf, Ressourcenübersicht auf S. 11).

Für **Abschlussarbeiten** lassen sich zwei Säulen direkt in die Prüfungsordnung übertragen. Ein Entwurf an der TH Köln (Stand 2025) gewichtet die Mündlichkeit höher und verteilt sie auf zwei Termine: ein erstes Kolloquium etwa einen Monat nach Beginn zu Forschungsstand und Forschungsfragen (3 ECTS), die schriftliche Arbeit (8 ECTS) und ein zweites Kolloquium zum Ergebnis (4 ECTS); bisher waren es 12 ECTS für die schriftliche Arbeit und 3 ECTS für das Kolloquium. Die Kontextualisierung lässt sich verankern, indem reine Literatur- oder Theoriearbeiten ohne empirischen Bezug vom Prüfungsausschuss genehmigt werden müssen.

i Anwendungsbeispiel: Gesprächsführung zu prüfen ist aufwändig und kaum wiederholbar

Problem ohne KI. Beratungsgespräche gehören in der Sozialen Arbeit zum Kern des Berufs, ihre Prüfung aber bindet viel Personal und feste Termine. An der CBS University of Applied Sciences liefen solche Performanzprüfungen bisher mit Schauspielerinnen und Schauspielern.
Problem mit KI. Ein Bot kann die Klientin oder den Klienten spielen, reagiert aber in jedem Gespräch anders.
Das Dilemma. Im Modul Kommunikation und Gesprächsführung des Bachelors Soziale Arbeit führen die Studierenden innerhalb von zwei Wochen ein Beratungsgespräch im Chat mit einem Prüfungsbot, etwa mit einer Person, die sich wegen Überschuldung an das Sozialamt wendet, und reichen den Dialog mit einer theoriebezogenen Reflexion ein. Zum Üben gibt es Tutor-, Mentor- und Szenario-Bots; in der Prüfung ist diese Unterstützung abgeschaltet. Die Varianz macht die Prüfung schwer auswendig zu lernen und, so die Verantwortlichen, besser nachvollziehbar als die frühere Prüfung mit Schauspielern. Sie verunsichert aber: Eine Studentin schrieb, der Bot habe in der Prüfung „komplett anders“ geschrieben als in ihren Übungen, ihre Notizen

hätten sich „sehr überflüssig“ angefühlt (Puchert & Schnieders, 2026).
Was das für wirksames Lernen heißt. *Erfahrungsbericht mit Rückmeldungen von Lehrenden und Studierenden.* Die Lehrenden beurteilen die Reflexionen als deutlich besser als in früheren Formaten ohne vorbereitende Szenarien. Das Format verlagert den Nachweis, wie Kofinas et al. (2025) es fordern, von der Ausgabe zum performativen Handeln und dessen Analyse. Damit die Varianz nicht in Verunsicherung kippt, brauchen die Übungsfälle dieselbe Struktur und Schwierigkeit wie die Prüfung.
Quelle: Puchert & Schnieders (2026); Tobor et al. (2026), S. 46–48.

Anwendungsbeispiel: Im Beruf programmieren Ingenieure mit KI, in der Prüfung nicht

Problem ohne KI. Eine Prüfung ohne Hilfsmittel misst nicht, wie Ingenieurinnen und Ingenieure heute arbeiten: Sie erzeugen und prüfen Code zunehmend mit KI.
Problem mit KI. KI-Code wirkt plausibel, setzt aber mitunter Randbedingungen falsch um, und identische Prompts liefern unterschiedliche Lösungswege. Auf die Ankündigung, KI in der Prüfung zuzulassen, reagierten die Studierenden zunächst verunsichert.
Der Lösungsansatz. Klaus Webers (Hochschule München) prüft im Master Mechatronik, Modul Simulation mechatronischer Systeme, in einer digitalen Präsenzprüfung im PC-Pool. Über die Hochschuloberfläche HAWKI ist ein Sprachmodell als Hilfsmittel zugelassen; die Studierenden erzeugen damit Code für Simulationen und führen ihn in MATLAB aus. Bewertet wird, ob sie die Aufgabe so durchdringen, dass die KI Brauchbares erzeugt, und ob sie das Ergebnis auf Plausibilität prüfen und verantworten können. Ein Prüfungsteil ohne KI sichert das Grundlagenwissen. Den Umgang mit KI-Code üben die Studierenden schon im Semester, begleitet vom Lehrenden.

Was das für wirksames Lernen heißt. *Erfahrungsbericht.* Die Prüfung setzt um, was Avigad (2026) für die quantitativen Fächer fordert: Prüfung um die Tatsache herum zu bauen, dass im Beruf KI genutzt wird. Der Nachweis liegt nicht in der Ausgabe, sondern im Prüfen und Begründen, und damit in dem Teil, der unter KI-Bedingungen aussagekräftig bleibt (Xiaoyu Hou et al., 2026).
Quelle: Tobor et al. (2026), S. 43–45.

Kombiniert ergeben die vier Säulen ein konsistentes Prüfungsdesign: Mündliche Elemente sichern Autorschaft und Transfer, prozessorientierte Formate liefern nachvollziehbare Evidenz, kontextgebundene Aufgaben prüfen Verständnis unter realen Bedingungen, und kollaborative Produkte stärken Urteilskraft und Feedbackkultur. KI-Detektoren werden überflüssig, weil der Nachweis im Prozess liegt und Prüfende interaktiv nachfragen können. Der Aufbau kostet anfangs viel Zeit, und die neuen Formate müssen evaluiert werden, damit die bekannten Probleme des Prüfens im Gespräch (Validität, Reliabilität, Fairness) beherrschbar bleiben (Akimov & Malin, 2020). Auf viele Vorlagen lässt sich dabei aufbauen, und Studierende lernen nebenbei, KI verantwortlich, nachvollziehbar und wirksam einzusetzen.

5.5 Richtlinien zur KI-Nutzung - welche Handreichungen geben Hochschulen und was wird empfohlen?

5.5.1 Übersicht: Was regeln die Richtlinien der Hochschulen?

An et al. (2025) werten die Richtlinien der 50 führenden US-Hochschulen zur Nutzung von LLM aus. Die Haltung ist insgesamt positiv, unterscheidet sich aber nach Zielgruppe. Lehrende erhalten in 94 % der Richtlinien didaktische Hinweise zu Kursdesign, Aufgaben und Prüfungsformaten, etwa gestufte Erlaubnisformen im Syllabus (verboten, erlaubt mit Dokumentation, ausdrücklich gewünscht). Für Studierende überwiegen Integritätsregeln: Nicht genehmigte Nutzung gilt als Täuschungsversuch,

die Klärung, ob KI zulässig ist, liegt bei ihnen, und Anleitungen zur kompetenten Nutzung bieten nur wenige Richtlinien. Die Autor:innen empfehlen zielgruppenspezifische, laufend weiterentwickelte Richtlinien.

Für Deutschland hat das Hochschulforum Digitalisierung die Leitlinien von 27 Hochschulen ausgewertet (Tobor, 2024), ein Update vom Februar 2025 ergänzt neuere Entwicklungen (Tobor, 2025). Tobor hebt vier bewährte Praktiken hervor:

- **Angepasste Eigenständigkeitserklärung:** Studierende erklären bei schriftlichen Prüfungen ohne Aufsicht, ob und wie sie KI-Werkzeuge genutzt haben (Vorlage etwa der Hochschule RheinMain).
- **Verdachtsfälle im Gespräch klären:** Detektoren wie GPTZero gelten als unzuverlässig. Empfohlen wird ein multifaktorielles Vorgehen mit Indikatoren wie nicht existierenden Quellen oder auffälligen Formulierungen; erhärtet sich der Verdacht, prüft ein Klärungsgespräch, ob die Studierenden ihre Arbeit verstehen (Leitfaden der Universität Vechta).
- **Keine automatisierte Bewertung:** Prüfungsordnungen verlangen eine begründete Bewertung durch eine prüfende Person; studentische Arbeiten in KI-Systeme hochzuladen gilt zudem als urheberrechtlich bedenklich.
- **Prüfungsformate didaktisch weiterentwickeln:** reflexionsorientierte Aufgaben, Zwischenfeedback und ergänzende mündliche Prüfungen (Kapitel 5.4); auch der Umgang mit KI selbst wird Prüfungsgegenstand.

Im Update kritisiert Tobor die **thematische Zersplitterung** der Handreichungen, die regulatorische, didaktische und Risikofragen für viele Gruppen zugleich abdecken; zentrale Einstiegsseiten wie der KI-Hub der Universität Vechta (https://www.uni-vechta.de/ki-hub) bündeln sie. Wirksam werden Leitlinien erst, wenn sie **bekannt gemacht, diskutiert und weiterentwickelt** werden, am besten gemeinsam mit Studierenden, im Hochschulverbund und mit Formaten wie Prompt-Battles (Tobor, 2025).

5.5.2 Was die KI-Verordnung von Hochschulen verlangt

Richtlinien sind seit 2025 nicht mehr nur Hausordnung, sondern Teil einer Rechtspflicht. Die europäische KI-Verordnung (von lateinisch *regula*, „Richtschnur“, über das englische *regulation*) verlangt in Artikel 4 seit Februar 2025 von jeder Organisation, die KI-Systeme betreibt,

Maßnahmen für die KI-Kompetenz ihres Personals; der Wissenschaftsrat stellt klar, dass Hochschulen, die Studierenden und Lehrenden Chat-Zugänge oder eigene Tutoren bereitstellen, in diesem Sinn Betreiber sind, und empfiehlt, KI-Kompetenz als Teil der Hochschulbildung selbst zu verankern statt als Zusatzschulung (Wissenschaftsrat, 2026). Die Vereinfachungsverordnung vom Juli 2026, der sogenannte Digital-Omnibus, hat Artikel 4 nicht gestrichen, sondern entschärft: Organisationen müssen weiterhin Maßnahmen ergreifen, aber kein bestimmtes Kompetenzniveau jeder einzelnen Person mehr garantieren (Europäisches Parlament und Rat, 2026; KI-Campus, 2026). Für die Praxis der Lehre ist die Handreichung des Hochschulforums Digitalisierung der verlässlichste Wegweiser, weil sie die Rechtsfragen an Szenarien durchspielt: Wer einen eigenen Tutor mit den Kursmaterialien betreibt, bewegt sich im Szenario eines angepassten, nicht eines selbst entwickelten KI-Systems, solange die Anpassung über System-Prompt und angebundene Quellen erfolgt; erst das Nachtrainieren eines Modells macht die Hochschule zur Anbieterin mit den entsprechenden Pflichten. Für die Materialien gilt das Urheberrecht unverändert, einschließlich der Grenze von 15 Prozent eines Werks für die Nutzung in der Lehre (Baresel et al., 2026). Für die Ausgaben der KI gilt dagegen: Urheberrechtlich geschützt ist nach § 2 Abs. 2 UrhG nur, was freie kreative Entscheidungen eines Menschen ausdrückt; das Amtsgericht München versagte deshalb 2026 drei mit KI erzeugten Logos den Schutz, weil weder ausführliche Prompts noch die Auswahl unter mehreren Vorschlägen die Gestaltung prägten (Amtsgericht München, 2026). Ob Studierende solche Texte verwenden dürfen, regelt darum nicht das Urheberrecht, sondern das Prüfungsrecht, also die Prüfungsordnung und die Eigenständigkeitserklärung mit ihrer Pflicht, Hilfsmittel anzugeben (Salden & Leschke, 2023). Zum Vergleich außerhalb Europas: Das MIT hat 2026 acht Prinzipien für die Lehre mit KI beschlossen, darunter mündliche Prüfungskomponenten, der Verzicht auf KI-Detektoren und eine modellunabhängige Campus-Plattform, und begründet damit dieselbe Linie wie Tobor: anleiten statt verbieten, und die Infrastruktur so bauen, dass die Wahl des Modells nicht die Lehre diktiert (Massachusetts Institute of Technology, Ad Hoc Committee on AI Use in Teaching, Learning, and Research Training, 2026).

Stand bei Drucklegung, November 2026: Hochschulen in Deutschland

Wo die deutschen Hochschulen beim Einsatz von KI-Tutoren und bei der Kompetenzpflicht standen, als dieses Buch in den Druck ging; die Online-Seite „Forschungsstand“ führt die Quellen fort.

- **Nutzung durch Studierende:** 81 Prozent von 28.584 Befragten an 202 Hochschulen nutzen KI-Werkzeuge mindestens wöchentlich, die Hälfte „als Tutor bzw. Lernpartner“; die Spanne reicht von 72 Prozent in der Wirtschaftsinformatik bis 19 Prozent in Jura (Horstmann et al., 2026).
- **Angebote der Hochschulen:** 53 Prozent der befragten Hochschulleitungen haben KI-Lernassistenten in Umsetzung, an Hochschulen für angewandte Wissenschaften 63 Prozent; 13 Hochschulen melden Regelbetrieb, adaptives Lernen bieten 14 Prozent (Budde et al., 2026).
- **Lehrmaterial für eigene Tutoren:** Zwei Drittel der befragten Lehrenden würden ihre Materialien für einen Hochschul-Tutor freigeben, ein Drittel nicht; Bedingungen sind Urheberrecht und der Ausschluss des Trainings (Brandenburger et al., 2026).
- **Evaluierte Einsätze:** OneTutor in 84 Lehrveranstaltungen bayerischer Hochschulen im Sommersemester 2025, ohne Unterschied im wahrgenommenen Lernerfolg zwischen Nutzenden und Nichtnutzenden (Stumpf et al., 2026); Sokratest an der Hochschule Rhein-Waal (Kapitel 4.3.3) (Gerber et al., 2026); ein Tutor für Physik, der die Antworten vollständig gab, wurde von den Studierenden entsprechend genutzt (Glomski et al., 2026). Das bayerische Programm „KI-Tutorien“ meint dagegen menschliche Tutorinnen und Tutoren, die KI-Kompetenz vermitteln (Universität Bayreuth, Zentrum für Hochschullehre, 2026).
- **Rechtsrahmen:** Artikel 4 KI-VO seit Februar 2025 in Kraft, durch den Digital-Omnibus vom Juli 2026 entschärft (Europäisches Parlament und Rat, 2026); Rechtsszenarien für die Lehre in Baresel et al. (2026); Empfehlungen des Wissenschaftsrats vom Juli 2026 (Wissenschaftsrat, 2026).

Wie sehen solche Richtlinien aus? Konkrete Formulierungen mit Links zu den Originaltexten stellt die Analyse des Hochschulforums Digitalisierung

zusammen (Tobor, 2025).

5.6 Wie können Studierende die Nutzung von LLM dokumentieren? Stichworte, nach Arbeitsphase, nach Werkzeug oder als Reflexionstagebuch

Frühe Handreichungen zur Dokumentation von LLM in Studierendenarbeiten waren noch sehr allgemein formuliert und bestanden etwa darauf, dass **jegliche Nutzung im Schreibprozess** genau protokolliert würde. Bei täglicher und stark integrierter Nutzung ist das etwa so sinnvoll, wie die Forderung, jegliche Internetnutzung in einem Tagebuch zu erfassen. Sinnlose Forderungen führen schnell dazu, dass die dahinter stehende Forderung nach prinzipieller Nachvollziehbarkeit des Forschungsvorgehens entwertet und Umgehungshandlungen normalisiert werden.

Neuere Empfehlungen der Hochschulen sind hier deutlich realistischer: So bietet etwa eine Handreichung von niedersächsischen Hochschulen eine gute **Reihe von Optionen**, die von einer einfachen Stichpunktliste („elicit.com zur Literaturrecherche, perplexity.ai zur Internetrecherche, gamma.app zur Präsentationserstellung, stablediffusionweb.com zur Bildgeneration“) bis zu detaillierten Tagebüchern mit Reflexionshilfen reicht (Baresel et al., 2024).

Dieselbe Handreichung beschreibt drei weitere Formen: die Dokumentation nach Arbeitsphasen, nach Werkzeugen und als Reflexionstagebuch (Baresel et al., 2024).

Die Dokumentation nach **Arbeitsphasen** (s. Tabelle 5.2) zielt auf eine strukturierte Erfassung des KI-Einsatzes entlang typischer wissenschaftlicher Arbeitsphasen (z. B. Themenfindung, Recherche, Schreiben). Studierende bewerten selbst den Grad der KI-Nutzung auf einer vierstufigen Skala von „zur Inspiration“ bis „inhaltsgestaltend“ (Tabelle 5.3) und dokumentieren Tool, Einsatzkontext und Wirkung. Je höher die Stufe, desto stärker muss die Nutzung begründet und durch Prüfschritte abgesichert werden (Baresel et al., 2024; Rowland, 2023). Ziel ist Transparenz über den konkreten Einfluss auf das Ergebnis.

Bei der **werkzeugorientierten** Dokumentation werden in tabellarischer Form die verwendeten Tools (z. B. ChatGPT, DeepL Write) samt Quelle,

Zweck, Funktion und Einsatzbereich gelistet. Diese Variante erleichtert die Nachvollziehbarkeit, gibt aber wenig Einblick in den Kontext oder den Einfluss der Tools auf den Arbeitsprozess.

Beim **Reflexionstagebuch** steht die kontinuierliche, persönliche Auseinandersetzung mit dem eigenen KI-Einsatz im Vordergrund. Studierende führen während des Arbeitsprozesses ein Tagebuch, das später in eine prüfungsrelevante Dokumentation überführt wird. Diese Methode fördert den Aufbau von **KI-Literacy** und metakognitiver Kompetenz, ist jedoch zeitaufwändig und betreuungsintensiv.

Phase im Arbeitsprozess	Dokumentation: Eingesetzte Tools, Verwendungszweck, Funktionsweise, Ergebnis	Grad der KI-Nutzung
Ideenfindung/Strukturierung	**Tools**: ChatGPT, Perplexity **Zweck**: Brainstorming zu Forschungsfragen, Gliederungsideen **Ergebnis**: 5 Themenvorschläge, davon 1 weiterverfolgt	1
Recherche	**Tools**: Elicit, Semantic Scholar **Zweck**: Suche nach passender Literatur **Ergebnis**: Liste mit 15 Quellen, 8 davon verwendet	2
Schreiben/Formulieren	**Tools**: DeepL Write **Zweck**: Verbesserung des sprachlichen Ausdrucks **Ergebnis**: Überarbeitete Einleitung	3

Überarbeitung/Korrektur	**Tools**: Grammarly **Zweck**: Prüfung auf Grammatik- und Rechtschreibfehler **Ergebnis**: Fehlerfreier Text	2

Tabelle 5.2. Beispiel arbeitsphasenorientierte Dokumentation der LLM Nutzung. Quelle: (Baresel et al. (2024), S. 11)

Grad der KI-Nutzung	Charakterisierung	Beispiele
1	**Zur Inspiration**	Sie haben sich Vorschläge für Themen unterbreiten lassen; Tools eingesetzt, um sich aus eigenen Notizen heraus Themenschwerpunkte zu bilden; sich Formulierungen vorschlagen lassen; die Rechtschreibung-/Grammatikprüfung genutzt.
2	**Ergänzend**	Sie haben sich mögliche Fragestellungen vorschlagen lassen, einzelne Begriffe der Aufgabenstellung oder Stellen in der Literatur erklären lassen, Gliederungen der eigenen Notizen vorschlagen oder eigene Texte zusammenfassen lassen, Reverse Outline zum eigenen Text (eine basierend auf dem Geschriebenen erzeugte Gliederung) generieren lassen.

Grad der KI-Nutzung	Charakterisierung	Beispiele
3	**Unterstützend**	Sie haben sich Anforderungen der Aufgabe (z. B. Aufbau einer HA) erklären, Literatur zusammenfassen, mögliche Gliederungen zum Thema vorschlagen lassen; Sie haben die Fragestellung dialogisch verfeinert bzw. Textteile dialogisch verfasst und dabei LLM-Output iterativ ergänzt; Sie haben sich Überarbeitungsvorschläge bzgl. Leserlichkeit und Stil generieren lassen.
4	**Inhaltsgestaltend**	Sie haben sich Hintergrundwissen zur Aufgabe bzw. Antworten auf Fragestellung generieren, Gliederung zum Thema vorgeben, Kürzungen und Ergänzungen vornehmen lassen oder KI-generierten Text direkt übernommen.

Tabelle 5.3. Erläuterungen zum Grad der LLM-Nutzung. Quelle: Baresel et al. (2024), basierend auf Rowland (2023)

Beispiele für die werkzeugorientierte Dokumentation und das Reflexionstagebuch (Stand 2024) stehen in der Online-Fassung dieses Kapitels.

Eine Fakultätsregel auf einer Seite. Für die Studiengänge Wirtschaftsingenieurwesen der TH Köln haben Christoph Haag und ich die Dokumentation nach Arbeitsphasen auf eine Seite gebracht (Bartnik & Haag, 2025); die Vorlage ist eine gekürzte Fassung der arbeitsphasenorientierten Dokumentation, die

die Leuphana Universität Lüneburg nach Baresel et al. (2024) bereitstellt (Leuphana Universität Lüneburg, o. J.). Drei Grundsätze tragen die Regel: KI unterstützt die Denkleistung und ersetzt sie nicht; Studierende müssen ihre Arbeit jederzeit mündlich erläutern können; wer zentrale Teile nicht selbst erstellt hat, besteht nicht. Eine Tabelle nennt je Phase die empfohlene Nutzung und die typischen Fehler. Für die Literaturrecherche lauten sie: nur KI-Suche, keine eigene Suchstrategie, keine Originalartikel gelesen. Das ist Tays Argument aus Kapitel 4.1.2 in Regelform. Prüfbar wird die Regel durch das Gespräch, ein konkreter Fall der Säule Mündlichkeit (Tabelle 5.1): Wer mehr als zweimal eine Quelle oder Methode nicht schlüssig erklären kann, hat die Prüfung in der Regel nicht bestanden.

5.7 Kurs-Integration: Drei Phasen eines Semesters

Wer KI nicht in eine einzelne Sitzung, sondern in einen ganzen Kurs einbaut, sieht die Rolle der KI mit dem Semester wandern. Zu Beginn arbeitet sie vor allem für die Lehrenden, als Hiwi, der Aufgaben und Fälle in Varianten erzeugt. In der Mitte arbeiten die Studierenden mit ihr an Anwendungsaufgaben, als Copilot oder als Simulator im Rollenspiel. Vor der Prüfung fragt sie ab und gibt Rückmeldung, als Tutor. Tabelle 5.4 ordnet jeder Phase das Lernprinzip zu, dem sie dient. Werkzeuge stehen bewusst nicht in der Tabelle: Sie wechseln im Halbjahrestakt, die Prinzipien seit Jahrzehnten kaum.

Semesterphase	Rolle der KI	Was entsteht	Tragendes Lernprinzip
Woche 1–4: Vorbereitung	Hiwi	Aufgaben in mehreren Schwierigkeitsstufen, Fallstudien, Einstiegsmaterial	Vorrat für verteiltes und gemischtes Üben über das ganze Semester (Dunlosky et al., 2013)
Woche 5–8: Anwendung	Copilot, Simulator	Anwendungsaufgaben, deren Lösung Studierende anderen erklären; Rollenspiele mit Nachbesprechung	Ausarbeiten durch Erklären (Dunlosky et al., 2013); Erfahrung plus Debriefing (Anhang C)

Semesterphase	Rolle der KI	Was entsteht	Tragendes Lernprinzip
Woche 9–12: Festigung	Tutor	Übungsfragen, Quiz, simulierte mündliche Prüfung	Testgestütztes Lernen: Abrufen statt Wiederlesen (Dunlosky et al., 2013; Roediger & Karpicke, 2006)

Tabelle 5.4. Drei Phasen der KI-Integration in einen Kurs; die Rollen entsprechen Kapitel 4. Eigene Darstellung.

Zwei Regeln überdauern jedes Werkzeug. Erstens gibt eine verantwortliche Person frei, was die KI für Studierende erzeugt, bevor es den Kurs erreicht; bei Fallstudien aus anderen Kulturen oder Branchen gehört der Blick auf Stereotype dazu. Diese Prüfung zahlt sich aus: In einem Zwei-Kohorten-Vergleich in der Volkswirtschaftslehre senkten geprüfte, quellengebundene Lernhilfen vor allem den Anteil schwacher Prüfungsergebnisse [C. T. Dang & Nguyen (2026); Preprint]. Zweitens muss der Kurs auch ohne das Werkzeug weiterlaufen. Skripte und Aufgaben liegen unabhängig vom Anbieter vor, damit ein Ausfall, eine Lizenzänderung oder eine Datenschutzentscheidung der Hochschule keine Sitzung kostet.

Wie solche Kurse in der eigenen Lehre aussehen und was sie bewirkt haben, zeigt Kapitel 6 (Kapitel 6). Die Beispiele sind dort nach der Art des Wissens geordnet, das Studierende erwerben sollen, nicht nach Semesterwochen.

Kernaussagen

1. Der erste Schritt ist Ausprobieren: eigene Aufgaben in ein starkes Modell geben, Input eingrenzen, Prompts anpassen und prüfen, wo die KI gut ist und wo nicht.
2. Studierende lernen den Umgang mit KI durch häufiges, über das Semester verteiltes Üben in Präsenz, nicht durch eine Theorieeinführung.
3. Die Homework Apocalypse ist real, aber beherrschbar. Prüfungen werden wieder aussagekräftig durch Mündlichkeit, Prozessorientierung, Kontextualisierung und Kollaboration. KI-Detektoren sind dafür kein Mittel.

4. Hochschulrichtlinien konvergieren: Eigenständigkeitserklärung anpassen, Verdachtsfälle im Gespräch klären, keine automatisierte Bewertung, Prüfungsformate didaktisch weiterentwickeln. Wirksam werden sie nur, wenn sie bekannt sind und diskutiert werden.
5. Dokumentation der KI-Nutzung muss praktikabel sein: eine Stichwortliste, eine Übersicht nach Arbeitsphase oder Werkzeug oder ein Reflexionstagebuch; ein vollständiges Protokoll jeder Interaktion ist es nicht.

Lernfragen

Wiederholen

1. Nennen Sie die vier Säulen aussagekräftiger Prüfungen und je ein Prüfungsformat dazu.
2. Welche Elemente haben die meisten Hochschulrichtlinien zur KI-Nutzung gemeinsam, und warum gehört Detektionssoftware nicht dazu?
3. Welche praktikablen Formen der Dokumentation von KI-Nutzung nennt das Kapitel?

Anwenden

4. Nehmen Sie Ihre wichtigste schriftliche Prüfungsleistung und wenden Sie aus dem Gedächtnis die vier Säulen darauf an. Welche Säule lässt sich mit geringstem Aufwand nächstes Semester einziehen?
5. Entwerfen Sie für eine Ihrer Veranstaltungen die drei Phasen aus Tabelle 5.4. Welches Lernprinzip trägt jede Phase, und wer prüft die erzeugten Aufgaben vor der Freigabe?

Beurteilen

6. Was steht in der Richtlinie Ihrer eigenen Hochschule zu KI in Prüfungen? Falls Sie es nicht wissen: Was müsste nach diesem Kapitel darin stehen?
7. Ein Kollege schlägt vor, Studierende sollten jeden Chatverlauf vollständig als Anhang ihrer Arbeit abgeben. Beurteilen Sie den Vorschlag.

Lösungshinweise: Anhang F.

5.8 Wie bleiben Sie informiert?

Bei einem Thema, das sich so schnell wandelt, sind gute Sammelstellen wertvoller als jede gedruckte Liste von Werkzeugen. Die folgenden Quellen haben sich bewährt (Stand 10/2026):

- **Newsletter von Ethan Mollick** (Wharton School) mit sehr praktischen Übersichten und Empfehlungen: https://www.oneusefulthing.org/. Ein Abonnement lohnt sich.
- **Didaktische Prompts** desselben Teams: https://www.moreusefulthings.com/prompts. Hervorzuheben sind die „Blueprints“, Vorlagen, die sich für die eigene Lehre anpassen lassen; zwei davon für Rollenspiele stellt Anhang C vor (Kapitel C.5.3).
- **Hochschulforum Digitalisierung**, Beiträge zu KI in Studium und Lehre: https://hochschulforumdigitalisierung.de/dossier/generative-ki/
- **e-teaching.org**, Themenspecial KI in der Hochschulpraxis: https://www.e-teaching.org/praxis/themenseiten/ki-in-studium-und-lehre
- **Derek Bok Center der Harvard University** mit Beispielen, wie Lehrende GenAI nutzen, darunter Simulationen und Sprachdidaktik: https://bokcenter.harvard.edu/examples-and-ideas-for-using-AI-for-your-teaching
- **Wie Lehrende KI tatsächlich nutzen**: Anthropic hat rund 74.000 anonymisierte Unterhaltungen von Hochschullehrenden aus elf Tagen im Mai und Juni 2025 ausgewertet. Lehrende bauen darin unter anderem Simulationen, Lernspiele und Bewertungsraster selbst (Bent et al., 2025): https://www.anthropic.com/news/anthropic-education-report-how-educators-use-claude
- **Fortbildungen der Anbieter** zu den technischen Seiten der KI-Nutzung in der Lehre: Google (https://grow.google/ai-for-educators/), Anthropic (https://anthropic.skilljar.com/ai-fluency-framework-foundations) und OpenAI mit einem Newsletter für Hochschullehrende (https://edunewsletter.openai.com/).

Wer neue Studien statt neuer Werkzeuge verfolgen will, findet den gepflegten Stand der Forschung auf der Online-Seite zu diesem Buch.

6 Fallbeispiele aus der Lehre

Lernziele

Nach diesem Kapitel können Sie …

- an Beispielen aus der eigenen Lehre nachvollziehen, wie aus einem belegten Lernprinzip eine Empfehlung und daraus eine Umsetzung mit generativer KI wird;
- ein eigenes Vorhaben einer Wissensform zuordnen und daraus Lerntechnik und Rolle der KI ableiten;
- Vorbereitung und Prüfkriterien der Beispiele auf eigene Werkzeuge und Praxisprojekte übertragen.

Probleme aus der Lehre

Zu jedem dieser Probleme bietet das Kapitel Lösungsansätze. Wählen Sie eine Antwort, bevor Sie weiterlesen: Wer vorher rät, behält die Auflösung besser. Die Kernaussagen am Kapitelende greifen die Probleme in derselben Reihenfolge auf.

1. Sie haben ein überzeugendes Lehrbeispiel mit einem bestimmten KI-Werkzeug übernommen. Ein Jahr später gibt es das Werkzeug nicht mehr. Was hätten Sie besser übernommen?

a) Die genaue Bedienanleitung des Werkzeugs.
b) Das Lernprinzip und das Prüfkriterium dahinter.
c) Den Prompt im genauen Wortlaut.

2. Ihre Studierenden üben mit einem Chatbot für die Klausur, sind zufrieden und behalten trotzdem wenig. Woran erkennen Sie, ob ein Werkzeug den Abruf fördert?

a) An der Zahl der Fragen, die es in einer Sitzung beantwortet.
b) An der Ausführlichkeit und Verständlichkeit seiner Erklärungen.

c) Daran, ob es fragt und auf eine eigene Antwort wartet, bevor es erklärt.

3. Ein Sprachmodell hat Ihnen in zehn Minuten eine Fallstudie mit Zahlen und ein interaktives Widget geschrieben. Was müssen Sie vor dem Einsatz selbst tun?

a) Jede Zahl in Code nachrechnen und das Modell hinter dem Widget testen.
b) Ein zweites Sprachmodell um ein Urteil bitten und es übernehmen.
c) Nichts, sofern Sie ein aktuelles Spitzenmodell verwendet haben.

4. Ein Unternehmen möchte mit Ihren Studierenden einen KI-Assistenten für seinen Einkauf bauen. Was regeln Sie vor dem Start?

a) Welche Rechenleistung die Hochschule bereitstellen muss.
b) Einen engen Anwendungsfall, Vertraulichkeit und erfundene Beispieldaten.
c) Wie viele Studierende das Unternehmen später einstellen will.

Die Kapitel 2 bis 5 behandeln Werkzeuge, Lernmechanismen, Rollen und Umsetzungsregeln je für sich. Dieses Kapitel zeigt, wie sie in Modulen des Bachelors Wirtschaftsingenieurwesen und in Workshops der TH Köln zusammenkommen, und ordnet die Beispiele nach dem, was Studierende lernen sollen, nicht nach dem Werkzeug. Jedes Beispiel beginnt mit einem Prinzip, das die Lernforschung belegt, leitet daraus eine Empfehlung ab, die ohne Produktnamen auskommt, und zeigt erst dann die Umsetzung mit dem Stand bei Drucklegung. Eine Empfehlung ist gut formuliert, wenn sie den Austauschtest besteht: Sie stimmt noch, nachdem man das Werkzeug gegen ein anderes getauscht hat. Werkzeuge altern schneller als Prinzipien, und wer das Prinzip kennt, baut die Umsetzung mit dem Werkzeug des nächsten Jahres nach.

Die Ordnung folgt drei Stufen, die Carlile (2004) für Wissen an den Grenzen zwischen Abteilungen beschreibt. Übertragen lässt sich Wissen, wo beide Seiten dieselben Begriffe teilen (syntaktisch); übersetzt werden muss es, wo dieselben Wörter Verschiedenes bedeuten (semantisch); umgeformt wird es, wo Interessen und Folgen auf dem Spiel stehen und Wissen gegen sie angewendet werden muss (pragmatisch). Carlile beschreibt Organisationen,

und die Grenze zwischen Studierenden und Fach ist eine Analogie, die wir zum Ordnen nutzen, kein Befund über das Lernen. Wörtlich gilt sie erst beim Projektlernen mit Praxispartnern (Kapitel 6.3.5), wo Wissen tatsächlich eine Organisationsgrenze überquert.

Unter jeder Überschrift steht ein Steckbrief mit vier Angaben: die Wissensform; die Lerntechnik nach Dunlosky et al. (2013) mit ihrer Evidenzstärke, hoch für verteiltes und testgestütztes Lernen, mittel für gemischtes Üben und fragebasierte Ausarbeitung, oder das tragende Prinzip, wenn keine der Techniken passt; die Rolle der KI aus Kapitel 4; und wer das Werkzeug gestaltet hat. Bauen Studierende es selbst, liegt das Lernziel meist eine Stufe höher, weil sie Wissen für ein Publikum übersetzen. Tabelle 6.1 fasst die Steckbriefe zusammen.

Beispiel	Wissensform	Lerntechnik (Evidenz) bzw. tragendes Prinzip	Rolle	Gestaltet von
Fragen-Generator	syntaktisch	testgestützt, verteilt (hoch)	Tutor	Lehrende
Lernsongs	syntaktisch	verteilt (hoch); Lösungsbeispiele	Copilot	Lehrende
Quizspiele	syntaktisch	testgestützt (hoch)	Copilot	Lehrende, Studierende
Interaktive Widgets	semantisch	angeleitetes Entdecken, Konkretheitsabbau	Copilot	Lehrende
Tutoring	semantisch	testgestützt (hoch) bzw. Ausarbeitung (mittel)	Tutor	Lehrende, Studierende
Fallstudien generieren	pragmatisch	Ausarbeitung (mittel), Vorhersage	Copilot	Lehrende
Simulationen durch Lehrende	pragmatisch	Erfahrung mit Debriefing	Simulator	Lehrende
Simulationen und Planspiele selbst bauen	pragmatisch	simulationsbasiertes Lernen; Projektlernen	Simulator	Studierende
Karriereberater	pragmatisch	Projektlernen, Test mit Nutzenden	Tutor, Simulator	Studierende

Projektlernen mit Praxispartnern	pragmatisch	Projektlernen	Copilot, Hiwi	Studierende

Tabelle 6.1. Die Beispiele dieses Kapitels nach Wissensform, Lerntechnik, Rolle der KI und Gestaltung

6.1 Wissen übertragen: Begriffe, Formeln, Reihenfolgen

6.1.1 Fragen-Generator: Abrufübung mit dem eigenen Material

Wissensform: syntaktisch · *Lerntechnik:* testgestützt (hoch), verteilt (hoch) · *Rolle:* Tutor (Kapitel 4.3) · *Gestaltet von:* Lehrende

Prinzip

Wer Gelerntes aus dem Gedächtnis abruft, behält es länger als wer es noch einmal liest. Nach fünf Minuten liegt das Wiederlesen noch vorn, nach zwei Tagen und nach einer Woche der Abruf (Roediger & Karpicke, 2006), und eine Metaanalyse über alle Vergleichsbedingungen bestätigt ihn: Übungstests schlagen das Wiederlesen und jede andere geprüfte Alternative, wobei Merkmale des Tests wie die Rückmeldung die Größe des Effekts mitbestimmen (Adesope et al., 2017). Verteilt man die Abrufrunden über Tage, wächst der Gewinn weiter (Cepeda et al., 2006); beide Techniken stehen bei Dunlosky et al. (2013) in der höchsten Nützlichkeitsstufe.

Empfehlung

Wenn Sie Studierenden ein Sprachmodell zum Wiederholen empfehlen, geben Sie ihnen einen Prompt mit, der das Modell auf Ihr Material festlegt, eine eigene Antwort vor jeder Rückmeldung verlangt und die Aufgabenform Ihrer Prüfung nachbildet. Prüfkriterium: Stellt das System eine Frage und wartet, bevor es etwas erklärt?

! Umsetzung, Stand 10/2026

Im englischsprachigen Modul *Sustainable Supply Chain Management* (SSCM) liegt auf jeder Wochenseite der Kerninhalt der Woche als reine Textdatei: das Problem des Kapitels, ein Satz der Woche, die Formeln, die gerechneten Beispiele aus Studentenleben, Fabrik und Lieferkette mit ihren Zahlen, typische Fehler und Übungsaufgaben ohne Lösung. Ein Anhang des Online-Skripts stellt dazu den Prompt *Quiz me* bereit; der Wortlaut steht in Anhang B (Kapitel B.2.1). Studierende kopieren ihn in einen beliebigen Chat und hängen den Kerninhalt einer Woche an.

Der Prompt legt fünf Dinge fest. Er beschränkt das Modell auf das eingefügte Material und das Lehrbuchkapitel, das es nennt, und verbietet erfundene Zahlen. Er gibt eine Reihenfolge vor: zuerst das Problem in Worten, dann die Formel in Worten, dann eine Rechnung mit den Zahlen eines Beispiels, in der ein Wert geändert ist, zuletzt eine Übungsaufgabe. Nach jeder Antwort sagt das Modell, ob sie stimmt, zeigt die Rechnung in höchstens vier Zeilen und benennt den typischen Fehler, falls einer vorliegt; die Lösung nennt es nie vor dem eigenen Versuch, auf Nachfrage zuerst nur einen Hinweis. Er bildet die Prüfung nach, die auf Papier stattfindet und Rechenaufgaben mit geänderten Werten neben Begriffsfragen stellt, und schließt jede Sitzung mit drei Aufgaben im Prüfungsformat und zwei Zeilen dazu, was noch einmal zu lesen ist. Und er verlangt Ehrlichkeit: Steht etwas nicht im Material, verweist das Modell auf den Kapitelabschnitt, statt zu raten. Ein zweiter, kurzer Prompt dreht die Richtung um und baut aus jedem typischen Fehler eine fehlerhafte Rechnung, die Studierende finden und korrigieren.

Zwei Gestaltungsentscheidungen tragen den Lerneffekt. Die Arbeitsanweisung lautet, jede Antwort zuerst auf Papier zu schreiben und erst dann einzutippen; der Abruf findet also statt, bevor das Modell eingreift. Und weil jedes gerechnete Beispiel im Kerninhalt sein Ergebnis mitführt, können Studierende jede Zahl des Modells gegen eine Zahl der Lehrperson halten. Die Seite schließt mit dem Satz, was der Prompt nicht ersetzt: das Kapitel.

Die zweite Umsetzung stammt aus einem 30-minütigen Workshop für Studierende aller Semester am Campus Gummersbach. Ein Prompt macht das Modell zum Klausur-Lernplaner: Es sortiert eine

Themenliste nach inhaltlicher Abhängigkeit, verteilt sie rückwärts auf die zehn Tage vor der Klausur, hält den letzten Tag frei von neuem Stoff und gibt für jeden Tag eine Kontrollfrage aus, die abends ohne Hilfe lösbar sein muss. Die Kontrollfrage ist testgestützt. Verteilt ist der Plan dagegen kaum, denn jedes Thema kommt an einem Tag vor und kehrt erst am Wiederholungstag zurück. Eine Zeile im Prompt behebt das: Jedes Thema zwei und fünf Tage nach dem ersten Lerntag in einer Abrufrunde von zehn Minuten wieder aufnehmen.

Ob ein Sprachmodell als Fragesteller mehr leistet als Karteikarten, ist nicht untersucht. Die Evidenz gilt dem Abruf, nicht dem, der abfragt; der Gewinn des Modells liegt in der Variation der Zahlen und in der Rückmeldung zum typischen Fehler, und beide lassen sich mit einem Satz Karteikarten nur mühsam herstellen.

Lernfrage. Ein Student lässt sich vom Modell die Lösung zeigen und tippt sie ab, bevor er selbst gerechnet hat. Welche Zeile des Prompts verletzt er, und warum verliert er damit genau den Effekt, für den der Prompt gebaut ist?

6.1.2 Lernsongs: ein Verfahrenslied mit Rechenpausen

Wissensform: syntaktisch, mit semantischem Rand · *Lerntechnik:* verteilt (hoch); Rechenteil getragen von Lösungsbeispielen · *Rolle:* Copilot (Kapitel 4.2) · *Gestaltet von:* Lehrende

Prinzip

Musik stärkt das wörtliche Behalten von Wortlaut und Reihenfolge: In einer systematischen Übersicht fanden 28 von 37 Studien einen Vorteil musikalischer Merkhilfen, neun keinen (Derks-Dijkman et al., 2024). Der Vorteil braucht Wiederholung, und zwar verteilte; Studierende, die ein Lied über Tage verteilt übten, behielten es drei Wochen später besser als nach massiertem Üben (Katz et al., 2021). Für das Anwenden und Rechnen gibt es keinen Beleg, dass ein Song hilft. Diesen Teil tragen ausgearbeitete Lösungsbeispiele, die in einer Metaanalyse zur Mathematik einen mittleren Effekt erreichen (Barbieri et al., 2023).

Empfehlung

Setzen Sie einen Song für das ein, was wörtlich sitzen soll: die Namen und die Reihenfolge der Verfahren, eine Formel im Wortlaut. Lassen Sie das Rechnen von Lösungsbeispielen tragen, die der Song an markierten Stellen anhält, und planen Sie mindestens zwei Durchgänge mit einigen Tagen Abstand ein. Prüfkriterium: Lässt sich jede Strophe einer Zeile im Skript zuordnen, und steht im Einsatzplan ein zweiter Termin?

Umsetzung, Stand 10/2026

Every Forecast Is Wrong · How Many Cups Tomorrow? ist ein animiertes Musikvideo von 5:15 Minuten für die fünfte Woche des SSCM-Moduls, in der es um Prognoseverfahren geht. Ein Café auf dem Campus zählt drei Wochen lang seine verkauften Kaffeebecher, und der Song führt an diesen Zahlen durch fünf Verfahren: die naive Prognose, den gleitenden Dreitagesdurchschnitt, die exponentielle Glättung, den Wochentagsindex und den Wochentagsindex mit Trend. Die Refrains vergleichen die Verfahren über zwei Fehlermaße, die mittlere absolute Abweichung (MAD) und die mittlere absolute prozentuale Abweichung (MAPE). Drei Instrumentalteile zeigen je eine durchgerechnete Prognose; die Anweisung auf der Wochenseite lautet, dort anzuhalten und mitzurechnen, bevor die nächste Zeile erscheint. Der Liedtext läuft als Untertitel mit.

Arbeitsteilung und Prüfung stehen in der Bildunterschrift: Text, Beispieldaten und Animationscode schrieb Claude, die Musik erzeugte Suno, Café und Zahlen sind erfunden, geprüft hat die Lehrperson. Das Beispiel ist bewusst neu. Es teilt keine Zahlen mit der Fallstudie der Woche, dem Prognose-Widget oder der folgenden Klausur, sodass der Song einen zweiten Kontext für dieselben Verfahren liefert, ohne Prüfungsaufgaben vorwegzunehmen.

Der Einsatzplan folgt dem Prinzip. Der Song steht am Ende eines Selbstlerntags, nach Kapitellektüre, Widget und Fallstudie, also erst dann, wenn die Verfahren hergeleitet und verstanden sind. Die Aufgabenliste für die Woche danach nennt einen zweiten Durchgang mit Halt an den drei Rechenbeispielen.

In der Typologie des Regelwerks ist das Video ein Verfahrenslied, keiner der drei ausgewählten Typen. Es zeigt deshalb gut, wo die

Arbeitsteilung zwischen Musik und Didaktik verläuft: Der Song sichert die Reihenfolge der fünf Verfahren und ihre Namen, die Rechenpausen sind Lösungsbeispiele in einem anderen Gewand. Wie man einen Lernsong mit KI schreibt, aufnimmt und vor dem Einsatz prüft, beschreibt der Primer Lernsongs (Kapitel E.4).

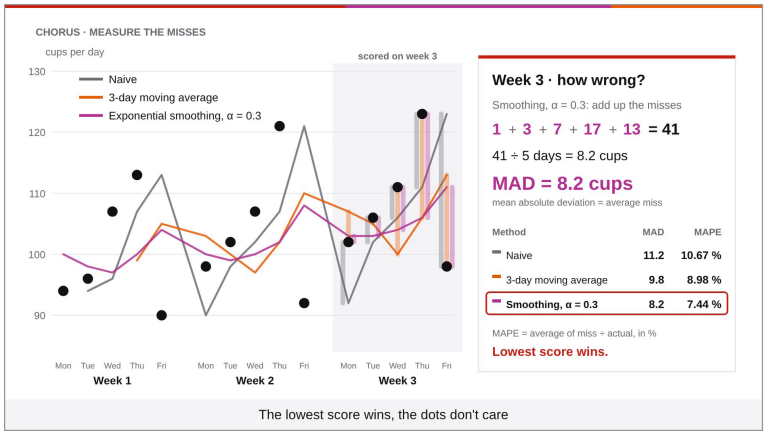

Video online
(5:15 min)

Abbildung 6.1. Standbild aus dem Lernsong *Every Forecast Is Wrong* (5:15) bei 3:20: Der Refrain vergleicht drei Verfahren über die mittlere absolute Abweichung (MAD) und die mittlere absolute prozentuale Abweichung (MAPE); die Zeile unten ist der Liedtext als Untertitel. Text, Beispieldaten und Animationscode: Claude; Musik: Suno; Café und Zahlen erfunden. Das Video gibt es nur online: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/lernsong-forecast.html aufrufen.

Lernfrage. Eine Kollegin will den Song in der Vorlesung einmal abspielen, bevor sie die exponentielle Glättung einführt. Was spricht nach dem Prinzip gegen diesen Zeitpunkt, und was gegen das einmalige Abspielen?

6.1.3 Quizspiele: Abruf mit Rückmeldung, und wann ein Quiz kein Simulator ist

Wissensform: syntaktisch · *Lerntechnik:* testgestützt (hoch) · *Rolle:* Copilot (Kapitel 4.2.2) · *Gestaltet von:* Lehrende, Studierende

Prinzip

Ein Zuordnungs- oder Auswahlspiel ist eine Abrufübung mit sofortiger Rückmeldung und wirkt über denselben Mechanismus wie ein Übungstest (Adesope et al., 2017). Die Spielform selbst ist kein zusätzlicher Wirkfaktor, auf den man sich verlassen kann: Serious Games schnitten in einer Metaanalyse beim Lernen und Behalten besser ab als herkömmlicher Unterricht, motivierten aber nicht stärker (Wouters et al., 2013).

Empfehlung

Bauen Sie Quizspiele für Begriffe, Zuordnungen und Erkennungsaufgaben, und nennen Sie sie so. Wenn die Lernenden Entscheidungen unter Zielkonflikten üben sollen, braucht das Spiel einen Zustand, der sich durch ihre Entscheidungen verändert; eine Auswahl mit einer richtigen Antwort leistet das nicht. Prüfkriterium: Ändert eine Entscheidung etwas an der Lage der nächsten Runde?

Umsetzung, Stand 10/2026

Das Zuordnungsspiel zu den Grundbegriffen generativer KI in Kapitel 2 paart Begriffe mit Definitionen. Die Stufe *Fortgeschritten* ergänzt Begriffe zu Agenten und eine Diagnoserunde mit typischen Problemen im Umgang mit Sprachmodellen. Das Spiel ist eine einzelne HTML-Datei und läuft ohne Anmeldung im Browser; es wird im Skript, im Workshop „KI zum Lernen“ und im Workshop zu interaktiven Skripten eingesetzt.
Lehrreich ist der Vergleich mit einem frühen eigenen Versuch aus dem Jahr 2025. *Einsatzbereit! Strategic Procurement Simulator* versetzt Studierende in die Rolle der Beschaffung in Krisen: Eine Flut verlangt sofort Pumpen, ein Erdbeben erzeugt viele dringende Bedarfe zugleich, und für jede Lage stehen vier Strategien zur Wahl, Sicherheitsbestand, leistungsbasierte Verträge, Lebenszykluskostenrechnung und Dual Sourcing. Das Programm wählt zufällig eine von vier Lagen und erklärt nach der Wahl, welche Strategie die beste gewesen wäre. Der Name verspricht eine Simulation, die Struktur ist ein Auswahlquiz mit Rückmeldung: Es gibt keinen Zustand, keine Folgekosten und keine

nächste Runde, die von der vorigen abhängt. Die Musterlösung blendet zudem genau den Zielkonflikt aus, um den es in der Beschaffung geht, denn im Erdbeben konkurrieren Sicherheitsbestand und Dual Sourcing, und die Antwort hängt an Lagerkosten und Lieferzeiten, die das Spiel nicht kennt. Als Erkennungsübung zu vier Begriffen taugt es; Entscheidungen trainiert erst ein Modell, in dem Entscheidungen Folgen haben (Kapitel 6.3.3).
Ein Gegenstück aus Studierendenhand zeigt, wo die Grenze genau verläuft. Ein Team im Modul WAGP (Kapitel 6.3.4) baute im Sommersemester 2025 ein „BWL-Memory“: Ein Sprachmodell erzeugt aus eingefügten Vorlesungstexten Paare aus Begriff und Definition, die auf einem Spielfeld einander zuzuordnen sind, und jede falsche Zuordnung landet in einer Fehlerliste, die beim nächsten Spiel in den Auftrag an das Modell eingeht. Ein Fehler verändert also die nächste Runde, aber nicht ihre Lage, sondern den Lernstoff. Das Spiel ist ein adaptives Abrufquiz und als solches gut gedacht, weil es die schwachen Begriffe öfter abfragt (Dunlosky et al., 2013). Der Code zeigt zwei Lücken, die bei selbst gebauten Quizspielen naheliegen. Die erzeugten Paare gehen ungeprüft aufs Spielfeld, und ein Begriff verlässt die Fehlerliste nur, wenn ihn jemand von Hand löscht; nach den Testläufen stand „Volkswirtschaft“ neunmal darin. Die Karten liegen zudem offen, der Name verspricht also wie beim Beschaffungs-„Simulator“ einen anderen Mechanismus. Acht Testpersonen fanden das Spiel übersichtlich und motivierend; ob sie damit mehr behielten, wurde nicht gemessen. Wie man ein solches Spiel mit KI baut und vor dem Einsatz prüft, beschreibt der Primer Lernspiele (Kapitel E.5).

Lernfrage. Wie müsste man den Beschaffungs-„Simulator“ verändern, damit aus dem Quiz eine Entscheidungsübung wird? Nennen Sie die kleinste Änderung, die das Prüfkriterium der Empfehlung erfüllt.

6.2 Wissen übersetzen: Bedeutungen erschließen

6.2.1 Interaktive Widgets: vom Studentenleben zur Fabrik

Wissensform: semantisch · *Lerntechnik:* keine der drei; tragend sind angeleitetes Entdecken und Konkretheitsabbau (*concreteness fading*) ·

Rolle: Copilot (Kapitel 4.2.2) · *Gestaltet von:* Lehrende

Prinzip

Selbst entdecken lässt Lernende nur dann besser lernen als direkte Instruktion, wenn das Entdecken angeleitet ist: durch Arbeitsaufträge, Rückmeldung, Beispiele oder die Aufforderung, das Gesehene zu erklären; ungeleitetes Entdecken schneidet schlechter ab (Alfieri et al., 2011). Eine zweite Regel betrifft die Reihenfolge der Darstellungen. Wer eine abstrakte Idee zuerst an einem vertrauten, konkreten Fall erlebt und die konkreten Züge dann schrittweise abbaut, überträgt sie besser als wer nur das Konkrete oder nur das Abstrakte sieht (Fyfe et al., 2014). Fachfremde Zierelemente lenken ab (Mayer & Fiorella, 2014).

Empfehlung

Geben Sie jedem Widget drei bis fünf Arbeitsaufträge mit, von denen mindestens einer eine Vorhersage oder einen Beweis verlangt, und zeigen Sie die Formel neben dem Ergebnis, das sie erzeugt. Führen Sie dieselbe Idee zuerst in einem Alltagskontext der Studierenden ein und erst danach im Fachkontext. Prüfkriterium: Würde ein Student ohne die Arbeitsaufträge wissen, was er ausprobieren soll?

Umsetzung, Stand 10/2026

Jede Sitzung des SSCM-Moduls folgt derselben Reihenfolge in fünf Schritten. Ein Problem aus dem Kapitel steht am Anfang, bevor ein Fachbegriff fällt. Dann tragen Partyvorbereitung oder Umzugstag die Idee zum ersten Mal, danach folgt die Formel in Worten mit kurzen Übungen in HTML-Widgets, dann dieselbe Idee in der Produktion mit den Beispielen des Lehrbuchs, zuletzt zwischen Unternehmen in der Lieferkette. Die Reihenfolge ist Konkretheitsabbau im Sinne von Fyfe et al. (2014), auf eine ganze Sitzung gestreckt.

Bis zur fünften Woche entstanden sechs Widgets, jedes eine einzelne HTML-Datei, die auf dem Smartphone läuft und keine Anmeldung braucht. Das Linien-Widget zur Kapazität zeigt zwei Produktionslinien zur Wahl: die Pizzalinie einer Party und die Brötchenlinie der Bäckerei aus der Fallstudie (Kapitel 6.3.1).

Studierende ändern Arbeitsschritte, Personal, Nachfrage und Losgröße und sehen sofort Linienkapazität, Engpasszeit und Durchlaufzeit. Drei Aufträge leiten das Ausprobieren: 24 Pizzen in unter zwei Stunden mit nur einer zusätzlichen Person oder einem zusätzlichen Ofen schaffen, den Belag-Schritt zum Engpass machen, und die Änderung finden, die am Ausstoß pro Stunde nichts ändert, und das beweisen. Das Prognose-Widget hat vier Reiter mit je einem Werkzeug, und jede Prognose entsteht nur aus den Tagen davor, so wie im Betrieb. Neben den Widgets stehen Colab-Notebooks, in denen Studierende eine Rechnung zuerst von Hand lösen und dann als kleines Modell nachbauen, das Was-wäre-wenn-Fragen in Sekunden beantwortet; das Notebook der zweiten Woche endet mit einem Dashboard, das sie in vier Schritten selbst bauen.
Widgets, Notebooks und Datensätze entstanden mit Claude als Copilot nach Vorgaben der Lehrperson. Eine Regel der Arbeitsanweisung lautet, jede Zahl in Python zu rechnen, nie im Kopf des Modells. Fallstudie, Linienmodell im Notebook, Widget und die Übungsdaten zur Datenbereinigung teilen sich einen einzigen Zahlensatz, sodass ein Ergebnis aus dem Widget in der Fallstudie wieder auftaucht. Wie solche Widgets als geprüftes Modell mit Druckabbildung entstehen, zeigt Kapitel 4.2.2.1.

Ob die Widgets mehr bewirken als dieselben Aufgaben auf Papier, ist für dieses Modul nicht gemessen. Belegt ist die Wirkung der Bauprinzipien, Anleitung und Reihenfolge; das Widget macht sie für jede Woche praktikabel.

Lernfrage. Das Linien-Widget fragt, welche Änderung am Ausstoß pro Stunde nichts ändert. Warum ist dieser Auftrag didaktisch wertvoller als „Finden Sie den Engpass“?

6.2.2 Tutoring: Übungstutor und sokratischer Tutor

Wissensform: semantisch · *Lerntechnik:* testgestützt (hoch) beim Übungstutor, fragebasierte Ausarbeitung (mittel) beim sokratischen Tutor · *Rolle:* Tutor (Kapitel 4.3) · *Gestaltet von:* Lehrende; Studierende bei studentisch gebauten Tutoren

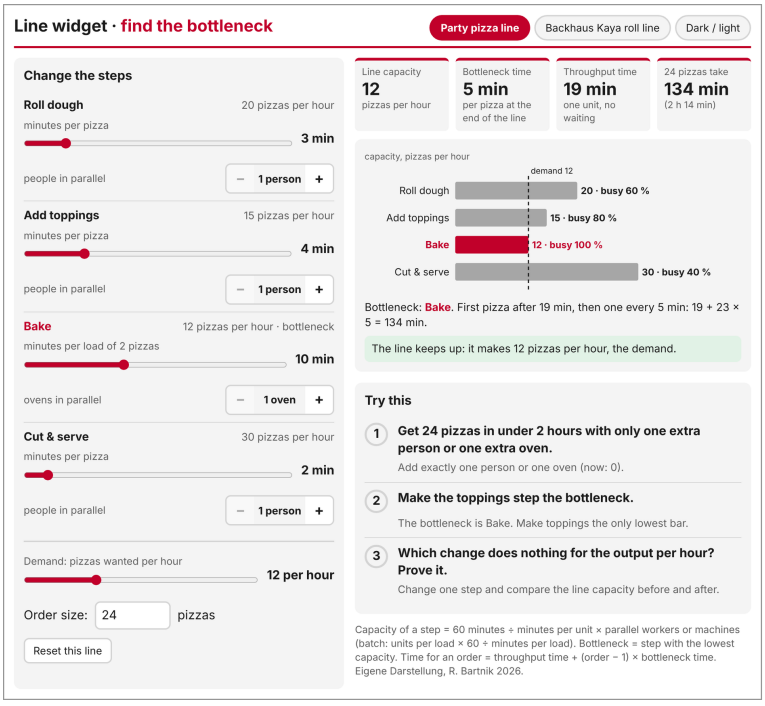

Widget online ausprobieren

Abbildung 6.2. Linien-Widget aus Woche 2 des SSCM-Moduls in der Ausgangslage der Pizzalinie: links die vier Arbeitsschritte mit Schiebereglern, rechts Kennzahlen, Kapazität je Schritt mit dem Engpass Backen und die drei Arbeitsaufträge unter *Try this*. Erstellt mit Claude nach Vorgaben der Lehrperson. Das Widget gibt es nur online: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/line-widget.html aufrufen.

Prinzip

Ein KI-Tutor wirkt über das, was er die Lernenden tun lässt, nicht über das, was er weiß. Wer selbst erklärt, Fragen beantwortet und Fehler korrigiert, lernt mehr als wer Erklärungen nur aufnimmt (Chi & Wylie, 2014). Ein Tutor, der Musterlösungen der Lehrenden kennt und Schritt für Schritt anleitet, statt zu lösen, übertraf in einem randomisierten Vergleich im Physikunterricht eine Präsenzstunde mit aktivem Lernen (Kestin et al., 2025). Ohne solche Leitplanken kehrt sich die Wirkung um: Schülerinnen und Schüler, die mit einem ungeschützten Chat übten, schnitten in der Prüfung ohne KI schlechter ab als die Kontrollgruppe (Bastani et al., 2025), und ein Kurstutor, der als Antwortmaschine konfiguriert war, senkte die Abschlussnoten um 0,37 Standardabweichungen (Liu et al., 2026).

Empfehlung

Wenn Sie einen Tutor über Ihre Materialien betreiben, lassen Sie ihn vor jeder Erklärung einen eigenen Versuch verlangen und geben Sie ihm Musterlösungen als Grundlage seiner Hinweise, nicht als Antwort. Messen Sie den Erfolg an einer Prüfung ohne KI, nicht an der Nutzung. Prüfkriterium: Eine Studentin bittet dreimal um die Lösung. Bekommt sie sie?

Umsetzung, Stand 10/2026

Ausgangslage. Das Modul „Grundlagen der BWL“ versammelt im ersten Semester mehrere hundert Studierende mit sehr unterschiedlichem Vorwissen; die Sprechstunde erreicht einen Bruchteil, die häufigsten Fragen wiederholen sich.
Umsetzung. Seit dem Wintersemester 2025/26 erproben wir einen Tutor-Bot als Web-Anwendung, der aus den Modulmaterialien antwortet (vgl. Kapitel 4.3.3).

Vergleichsfälle. Zwei veröffentlichte Fälle mit derselben Architektur, ein Tutor über die eigenen Kursmaterialien, geben die Messlatte vor, an der wir unseren Tutor beurteilen. An der University of Maryland erhielten per Los 2.379 Studierende in den Kursen von 30 Lehrenden Zugang zu einem solchen Tutor; nur 15 Prozent nutzten ihn, drei Viertel ihrer

Anfragen verlangten eine fertige Antwort, und die Abschlussnote der Berechtigten lag 0,37 Standardabweichungen unter der Kontrollgruppe, weil der Tutor im Standardmodus der Lehrenden als Antwortmaschine konfiguriert war und das eigene Arbeiten am Material ersetzte (Liu et al., 2026). An der Hochschule Rhein-Waal lief ein sokratisch gebauter Tutor mit eigenen Quellen auf einem lokal betriebenen offenen Modell; nach einem Semester mit 62 Studierenden war die Bereitschaft, Fragen zu stellen, gestiegen, die Neugier auf das Warum aber gesunken, weil die Studierenden ihn trotz des sokratischen Designs als Antwortmaschine nutzten, sobald er es zuließ (Gerber et al., 2026). Für den BWL-Tutor ergeben sich daraus drei Kennzahlen, die wir erheben: der Anteil der Berechtigten, die den Tutor überhaupt nutzen; der Anteil der Anfragen, die eine fertige Antwort verlangen, gegenüber denen, die Rückmeldung auf eigene Arbeit suchen; und ob das Standardverhalten des Tutors bei einer offensichtlichen Prüfungsfrage auf das Material verweist oder löst (Testplan in Kapitel D.7.5).

Lernfrage. Der Tutor in Maryland war technisch einwandfrei und schadete trotzdem. Welche Einstellung war dafür verantwortlich, und mit welchem Testlauf vor dem Semester hätte man das erkannt?

6.3 Wissen umformen: anwenden gegen Interessen und Folgen

6.3.1 Fallstudien generieren: Backhaus Kaya

Wissensform: pragmatisch, mit semantischem Übergang · *Lerntechnik:* fragebasierte Ausarbeitung (mittel), Vorhersage vor dem Lernen · *Rolle:* Copilot (Kapitel 4.2) · *Gestaltet von:* Lehrende

i Prinzip

Geschichten werden besser verstanden und erinnert als Sachtexte; eine Metaanalyse über mehr als 75 Stichproben mit über 33.000 Teilnehmenden fand den Vorteil robust (Mar et al., 2021). Willingham (2021) nennt die Merkmale, die eine Geschichte zum Lernanlass machen: eine Figur mit einem Ziel, ein Konflikt, Komplikationen und

kausal verbundene Ereignisse. Wer vor dem Lernen eine Vermutung abgibt, auch eine falsche, lernt die richtige Antwort danach oft besser (Pan & Carpenter, 2023).

Empfehlung

Lassen Sie das Sprachmodell die Geschichte schreiben, aber legen Sie die Zahlen vorher fest und lassen Sie jede Zahl in Code nachrechnen. Bauen Sie die typische Fehlvorstellung als Figur in die Handlung ein und bitten Sie die Studierenden um eine Vermutung, bevor sie rechnen. Prüfkriterium: Stimmen Fall, Lösungsschlüssel und Teaching Note in jeder Zahl überein?

Umsetzung, Stand 10/2026

Backhaus Kaya ist eine erfundene Handwerksbäckerei in Gummersbach und begleitet das SSCM-Modul über mehrere Wochen. Der erste Teil beginnt um 2:40 Uhr nachts am Ofen. Aylin Kaya, 34, führt die Bäckerei, die ihr Vater gegründet hat; über dem Ofen hängt sein Satz *Never promise bread you cannot bake*. Die Einkäuferin einer regionalen Supermarktkette legt einen Vertrag auf den Tisch: 1.800 zusätzliche Brötchen pro Tag, sechs Tage die Woche, 0,32 Euro das Stück, Laufzeit ein Jahr, Antwort bis Montag. Gebacken wird in einem Fenster von vier Stunden vor Sonnenaufgang, und heute verlassen schon 1.500 Brötchen pro Nacht die Backstube. Der Backmeister hat sofort eine Lösung: einen dritten Mitarbeiter zum Formen, denn das sei die härteste Arbeit.
Diese Figur trägt die Fehlvorstellung, um die es geht. Die Fragen Q1 bis Q6 führen von der Kapazität jedes Schritts über Auslastung und Effizienz des Ofens zu drei Optionen mit Deckungsbeitrag und CO□-Bilanz. Der Engpass ist der Etagenofen mit 720 Brötchen pro Stunde; ein dritter Former hebt das Formen auf 1.260 Brötchen pro Stunde und ändert am Ausstoß der Linie nichts. Die Empfehlung, die jedes Team in drei Sätzen formuliert, muss ein Risiko nennen: Die längere Nacht bringt im ersten Jahr den kleineren Gewinn ohne Leasingbindung, hat aber keinen Puffer.

Zum Fall gehören eine Teaching Note mit Lernzielen, Zeitplan für 35 Minuten, Lösungsschlüssel und Tafelbild, ein Teaser-Video von fünf Sekunden und ein Satz Rohdaten aus dem Ofenprotokoll, an denen die Studierenden am Nachmittag Datenbereinigung üben. Fall, Colab-Linienmodell, Linien-Widget und Ofenprotokoll teilen sich einen Zahlensatz aus einer gemeinsamen Spezifikation. Claude entwarf und prüfte Geschichte und Teaching Note; die Arbeitsanweisung verlangte, jede Zahl in Python zu rechnen, und jedes Dokument trägt einen Transparenzhinweis.
Der vierte Teil in der Prognosewoche beginnt mit einem Vorhersagekasten. Die Bäckerei liefert jede Nacht 1.800 Brötchen, immer gleich auf drei Filialen verteilt, und 6 Prozent kommen unverkauft zurück; drei Fragen bitten um eine Vermutung, die Studierende mit Datum notieren und am Ende des Tages mit ihrem Ergebnis vergleichen. Die Rechnungen aus dem Fall sind Stoff des zweiten Tests, die Geschichte ist also kein Schmuck, sondern Prüfungsgegenstand.

Teaser online
(5 s)

Abbildung 6.3. Standbild aus dem Teaser zur Fallstudie Backhaus Kaya (5 s, ohne Ton): Aylin Kaya nachts in der Backstube vor dem Etagenofen. KI-generiertes Video (LTX-2.5); Bäckerei und Figuren sind erfunden. Den Teaser gibt es nur online, zusammen mit Linien-Widget und Engpass-Animation zum selben Fall: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/galerie-animationen.html#kaya-teaser aufrufen.

Ein Sprachmodell schreibt eine solche Geschichte in Minuten. Die Arbeit der

Lehrperson verschiebt sich auf zwei Stellen, die das Modell nicht übernimmt: die Wahl der Fehlvorstellung, die der Fall widerlegen soll, und die Prüfung, ob jede Zahl in Fall, Schlüssel und Widget dieselbe ist. Der Prompt *Fallstudie gemeinsam erstellen* (Kapitel B.4.1) gibt dafür das Gerüst.

Lernfrage. Warum schlägt der Backmeister ausgerechnet einen dritten Former vor, und was ginge didaktisch verloren, wenn der Fall den Engpass gleich im ersten Absatz nennen würde?

6.3.2 Simulationen durch Lehrende: Prozess und Verhandlung

Wissensform: pragmatisch, mit semantischem Übergang · *Lerntechnik:* keine der drei; tragend sind Erfahrung und Debriefing · *Rolle:* Simulator (Kapitel 4.4), beim Bau Copilot (Kapitel 4.2.2) · *Gestaltet von:* Lehrende

Prinzip

Simulationen fördern komplexe Fähigkeiten in der Hochschule stark, und Gerüste wie Beispiele oder Reflexionsphasen verstärken die Wirkung (Chernikova et al., 2020). Mit computergestützten Simulationsspielen lernten Teilnehmende in einer Metaanalyse mehr als mit Vergleichsmethoden, vor allem dann, wenn das Spiel andere Instruktion ergänzte, statt sie zu ersetzen, und beliebig oft zugänglich war (Sitzmann, 2011). Gelernt wird im Nachgespräch: Debriefings, in denen Lernende ihr Handeln systematisch auswerten, verbesserten die Leistung über 46 Stichproben um rund 25 Prozent ($d = 0{,}67$), in Simulationen wie im Ernstfall (Tannenbaum & Cerasoli, 2013). Für Lieferketten gilt das besonders. Im Beer Game sanken die Bestellschwankungen erst, als die Beteiligten nach eigener Erfahrung gemeinsam eine Strategie entwickeln durften; Training allein verbesserte das Verständnis, nicht die Kette (D. Y. Wu & Katok, 2006).

Empfehlung

Wenn Sie eine Simulation einsetzen, lassen Sie vor jedem Lauf eine Vorhersage notieren und führen Sie das Debriefing selbst, an den Daten dieses Laufs. Ein Sprachmodell kann die Simulation bauen

oder das Gegenüber spielen; das Nachgespräch über die eigenen Entscheidungen bleibt bei Ihnen. Prüfkriterium: Steht im Ablaufplan nach dem Lauf eine Phase, in der die Lernenden ihre Vorhersage mit dem Ergebnis vergleichen und den Unterschied begründen?

! Umsetzung, Planung Stand 10/2026

Das Bullwhip-Widget aus Kapitel 4.2.2.2 simuliert eine Lieferkette mit vier Stufen vom Händler bis zur Fabrik. Jede Stufe prognostiziert mit einem gleitenden Mittelwert und bestellt nach einer festen Regel; Regler stellen Lieferzeit und Prognosefenster ein, ein Schalter entscheidet, ob alle Stufen die Kassendaten des Händlers sehen. Bevor das Widget Ergebnisse zeigt, verlangt es eine Vorhersage, welche Stufe am stärksten schwankt. Drei Szenarien setzen die Regler auf typische Lagen. Das Modell entstand mit Claude als Copilot; zehn automatische Tests rechnen einen Nachfragesprung von Hand nach und prüfen den Händler gegen die Formel von F. Chen et al. (2000).
Zwei Befunde des Modells lohnen einen Satz im Unterricht. Ohne geteilte Daten schwankt die Fabrik doppelt so stark, wie die Formel als Untergrenze angibt, weil die Bestellungen der unteren Stufen nicht mehr unabhängig voneinander sind. Und wer Rücksendungen an den Lieferanten verbietet, senkt die Schwankung der Fabrik im zweiten Szenario auf ein Drittel; die Annahme der Formel, dass Bestellungen auch negativ sein dürfen, ist bei langen Lieferzeiten nicht harmlos.
Das Widget zeigt die Mechanik, nicht das Verhalten. Seine Stufen bestellen nach einer Regel, und keine vergisst die Ware unterwegs. Diesen Teil übernimmt das Beer Game, das die Studierenden vorher selbst spielen. Für das SSCM-Modul ist eine Sequenz in vier Schritten geplant: das Beer Game in der Übung; das Debriefing an den Bestellkurven jeder Stufe, mit der Frage, wer die offenen Bestellungen mitgezählt hat; das Widget, an dem die Teams die Ursachen einzeln an- und abschalten; zuletzt eine Ballade, die die Wirkungskette nachzeichnet und deren Liedtext Anhang B als Beispiel der Prompt-Vorlage für Lernsongs abdruckt (Anhang B). Die Reihenfolge folgt dem Prinzip zweifach: Das Widget ergänzt Spiel und Erklärung, statt sie zu ersetzen, und die Teams formulieren nach der Erfahrung gemeinsam eine Bestellstrategie, die sie am Widget prüfen.

Die zweite Form ist die Verhandlung mit einem simulierten Gegenüber. Der Prompt *Verhandlungssimulation* in Anhang B lässt ein Sprachmodell einen Lieferanten spielen, mit Rolle, Interessen und Verhaltensregeln, die die Lehrperson festlegt. Zwei Vorkehrungen aus Kapitel 4.4 gelten hier. Ein simuliertes Gegenüber trifft durchschnittliches Verhalten besser als das eines bestimmten Menschen, und die Studierenden erfahren das vor dem Gespräch. Das Debriefing führt die Lehrperson: Sie bespricht am Gesprächsprotokoll, wo ein Zugeständnis zu früh kam und welches Argument das Gegenüber bewegt hat. Im Modul Supply Management setzen wir die Verhandlung im Dezember 2026 zum ersten Mal ein; bis dahin ist sie eine Option, keine erprobte Praxis.

Lernfrage. Im Widget sinkt die Schwankung der Fabrik, wenn alle Stufen die Kassendaten sehen, verschwindet aber nicht. Welche Ursache des Bullwhip-Effekts kann das Widget grundsätzlich nicht zeigen, und welcher Schritt der Sequenz muss sie deshalb übernehmen?

6.3.3 Simulationen und Planspiele selbst bauen: Gruppenprojekt mit Prüfzelle

Wissensform: pragmatisch · *Lerntechnik:* keine der drei; tragend sind simulationsbasiertes Lernen mit Gerüst und Projektlernen · *Rolle:* Simulator (Kapitel 4.4) · *Gestaltet von:* Studierende

i Prinzip

Simulationen gehören zu den wirksamsten Mitteln, komplexe Fähigkeiten in der Hochschule zu fördern; eine Metaanalyse über 145 Studien fand einen großen Gesamteffekt ($g = 0{,}85$), und Gerüste verstärkten ihn: Lernende mit wenig Vorwissen profitierten von Beispielen, Lernende mit viel Vorwissen von Reflexionsphasen (Chernikova et al., 2020). Projektlernen hat gegenüber lehrerzentriertem Unterricht einen mittleren bis großen Effekt auf die Leistung ($d = 0{,}71$) (C.-H. Chen & Yang, 2019).

Empfehlung

Wenn Studierende mit KI-Hilfe ein Modell bauen, prüfen Sie zwei Dinge getrennt: ob das Modell richtig zählt, automatisch und gegen Regeln, die jedes richtige Modell erfüllt, und ob die Studierenden es verstehen, mündlich und mit einer Vorhersage vor jeder Änderung. Erlauben Sie KI für alle Arbeitsschritte, aber nicht als Quelle für Zahlen. Prüfkriterium: Könnte eine Gruppe mit einem fehlerhaften Modell oder ohne eigenes Verständnis bestehen?

Umsetzung, Stand 10/2026

Im SSCM-Gruppenprojekt wählen Teams aus vier bis fünf Studierenden ein reales Produkt, dessen Herstellung vier bis sechs Stationen hat, mit einem wichtigen Zukaufteil und zwei Bezugsquellen dafür. Sie bauen einen Datensatz im Format eines vorgegebenen Beispiels und simulieren in Colab ein Jahr Produktion in drei Szenarien: Normalbetrieb, eine Störung nach einem realen Vorbild und die Störung mit einer Gegenmaßnahme, je zehnmal mit verschiedenen Zufallszahlen. Eine Ergebnistafel vergleicht Stück pro Woche, Kosten pro Stück, Kilogramm CO□-Äquivalent pro Stück und Stillstandsstunden. Aus den Ergebnissen entstehen eine Animation und ein Poster, das zwei begutachtete Fachartikel als Quellen für die verwendeten Konzepte nutzt.

Erlaubt ist KI für jeden Arbeitsschritt, von der Datensuche über den Code bis zum Posterentwurf. Drei Regeln halten die Arbeit bei den Studierenden. Eine KI-Antwort ist keine Quelle; eine Zahl, die ein Modell vorschlägt, kommt erst in die Quellentabelle, wenn das Team sie auf eine öffentliche Angabe zurückführt oder mit eigener Rechnung schätzt. Jede Codezeile muss erklärt werden können. Und eine halbe Seite KI-Notiz hält fest, was an die KI ging, wie die Ausgabe geprüft wurde und welcher KI-Fehler gefunden wurde.

Zwei Prüfinstrumente trennen Richtigkeit und Verständnis. Eine unveränderliche Prüfzelle im Notebook testet fünf Regeln, die jedes korrekte Modell erfüllt, unabhängig vom Produkt: vollständiges Datenformat, keine Station über 100 Prozent ausgelastet, Little's Law innerhalb von zehn Prozent, keine Teile aus dem Nichts, kein Verlust im Normaljahr. Die Projektseite begründet das mit einem Satz, der

für jede KI-gestützte Modellierung gilt: Eine Simulation druckt immer Zahlen, auch wenn sie falsch zählt, und Code mit KI-Hilfe läuft glatt und sieht überzeugend aus, ob er stimmt oder nicht. Die Prüfzelle wirkt wie eine Probebilanz in der Buchhaltung, die einen Fehler anzeigt, bevor jemand weiß, wo er steckt. Über das Verständnis entscheidet die Postersession. Jedes Mitglied beantwortet zwei Fragen allein, zu einer Zahl, zum Modell oder zu einem Fachartikel; dann ändert der Prüfer eine Zahl im Datensatz, und die Gruppe sagt vor dem neuen Lauf voraus, in welche Richtung sich jede Kennzahl bewegt und warum. Eine falsche Vorhersage mit tragfähiger Begründung kostet wenig, eine richtige ohne Begründung bringt wenig.
Im Sinne von Carlile (2004) ist das Projekt pragmatisch: Die Studierenden wenden ihr Wissen gegen eine Störung und deren Folgen an, und die Gegenmaßnahme kostet Geld, Zeit oder CO□. In der Sprache des 4D-Modells (Dakan & Feller, 2025) übernimmt die Prüfzelle einen Teil der Urteilsprüfung (*Discernment*), die Postersession prüft die Verantwortung (*Diligence*).

Lernfrage. Die Prüfzelle prüft nicht, ob die gewählte Gegenmaßnahme gut ist. Warum ist das eine Stärke des Verfahrens und keine Lücke?

6.3.4 Karriereberater: Erstsemester bauen KI-Werkzeuge für andere

Wissensform: pragmatisch · *Lerntechnik:* keine der drei; tragend sind Projektlernen und die Rückmeldung durch Nutzende · *Rolle:* Tutor (Kapitel 4.3), der Interviewtrainer als Simulator (Kapitel 4.4) · *Gestaltet von:* Studierende

Prinzip

Projektlernen hat gegenüber lehrerzentriertem Unterricht einen mittleren bis großen Effekt auf die Leistung (C.-H. Chen & Yang, 2019). Wenn Studierende ein Werkzeug für andere bauen, wird ihr Wissen pragmatisch im Sinne von Carlile (2004): Es muss sich gegen die Interessen und den Alltag einer Zielgruppe bewähren, die das Team erst kennenlernen muss. Rückmeldung wirkt umso stärker, je mehr Information sie enthält (Wisniewski et al., 2020). Für ein

Team, das baut, ist der Test mit Nutzenden die Rückmeldung mit dem meisten Gehalt, denn er zeigt, wo und warum eine Person mit dem Werkzeug scheitert.

Empfehlung

Wenn Studierende ein KI-Werkzeug für eine Zielgruppe bauen, bewerten Sie drei Säulen getrennt: eine Bedarfsanalyse mit Interviews, einen lauffähigen Prototyp und einen Test mit Nutzenden. Verlangen Sie, dass das Sprachmodell nur Daten erklärt, die aus einer benannten Quelle stammen. Prüfkriterium: Kann das Team einen Befund aus dem Nutzertest nennen, der den Prototyp verändert hat?

Umsetzung, Stand 10/2026

Im Modul *Wissenschaftliches Arbeiten und Grundlagen der Projektarbeit* (WAGP) im ersten Semester der Ingenieurstudiengänge bauen Teams seit dem Wintersemester 2024/25 in jedem Semester einen Prototyp mit generativer KI zu einem gemeinsamen Thema: Fachtutoren, Lernspiele, Karriere- und Jobberater, zuletzt KI-Assistenten für Berufsfelder mit Praxisbezug. Der Projektbericht zum vierten Meilenstein enthält eine Bedarfsanalyse mit meist fünf oder sechs Interviews, den Prototyp mit Code und eine Evaluation. Eine Auswertung aller 56 Berichte aus vier Semestern nach diesen drei Säulen ergab 18 starke, 31 solide und 7 schwache Projekte. Den soliden fehlt fast immer dieselbe Säule, der Test mit Nutzenden, und am häufigsten den technisch ehrgeizigen Karriere-Bots des Wintersemesters 2025/26: Von 18 Teams erfüllten fünf alle drei Säulen.

Die Karriereberater zeigen drei Bauweisen. Die erste macht das Modulhandbuch zur Wissensbasis. Ein Team durchsucht es mit TF-IDF, einem klassischen Suchverfahren, das ein Wort umso höher gewichtet, je seltener es im Gesamtbestand vorkommt, und gibt die Treffer einem Sprachmodell mit, das daraus antwortet; das Team nannte das „RAG ohne Vektordatenbank“. Ein anderes legt Modulhandbuch und Stellenanzeigen nebeneinander, damit Studierende einschätzen können, welche Anforderungen ihr Studium abdeckt. Die zweite Bauweise beschränkt das Modell auf geprüfte Daten. Mehrere Teams

ließen Suche und Zuordnung ohne KI laufen, über die Jobsuche-Schnittstelle der Bundesagentur für Arbeit oder ein regelbasiertes Matching auf Moduldaten, und das Sprachmodell nur sortieren und begründen; ein Team verzichtete ausdrücklich auf Gehälter, die das Modell schätzen würde. Die dritte Bauweise ist der Interviewtrainer, ein Simulator. Ein Team leitete den System-Prompt seines Bewerbungstrainers aus der Feedbackforschung und dem Konzept erwünschter Erschwernisse (*desirable difficulties*) ab, ein anderes nutzt die Fragenkataloge regionaler Firmen.
Der lehrreichste Befund kam aus einem Test mit sechs Personen: Sie wollten Orientierung, nicht mehr Information. Der Satz verschiebt die Aufgabe eines Karriereberaters vom Antworten zum Ordnen, und keine Bedarfsanalyse hatte ihn vorher geliefert. Im folgenden Semester übertrug ein Team das Muster auf einen Beruf außerhalb der Hochschule und baute einen Job-Buddy für Pflegekräfte, den es nach sechs Interviews mit vier Pflegekräften testete. Die Auswertung zeigt auch, was in einer ersten Projektarbeit mit KI schiefgeht: In zwei Abgaben stand der API-Schlüssel, mit dem das Programm beim Modellanbieter abgerechnet wird, im Klartext im Code, in einer weiteren lagen Passwörter offen. Ein solcher Schlüssel ist wie eine Kreditkarte; wer ihn findet, bezahlt auf fremde Rechnung.

Was die Projekte nicht zeigen, ist ein Nutzen für die Ratsuchenden über die Testsitzungen hinaus; sie sind Prototypen von Erstsemestern. Das Lernziel liegt bei den Bauenden: Bedarf erheben, ein Werkzeug bauen und an Menschen prüfen, die es brauchen.

Lernfrage. Ein Karriere-Bot beantwortet die Frage nach dem Einstiegsgehalt im Wirtschaftsingenieurwesen mit einer konkreten Zahl. Gegen welche Bauweise aus den Projekten verstößt er, und wie sollte er stattdessen antworten?

6.3.5 Projektlernen mit Praxispartnern: RAG und Einkaufs-Workflows

Wissensform: pragmatisch · *Lerntechnik:* keine der drei; tragend ist Projektlernen · *Rolle:* Copilot (Kapitel 4.2), Hiwi (Kapitel 4.1) · *Gestaltet von:* Studierende

Prinzip

Projektlernen hat gegenüber lehrerzentriertem Unterricht einen mittleren bis großen Effekt auf die Leistung (C.-H. Chen & Yang, 2019). Über eine Organisationsgrenze gilt dabei Carliles Stufenfolge wörtlich: Ein gemeinsames Vokabular genügt erst, wenn die Bedeutungen geklärt sind, und Wissen wird erst umgeformt, wenn beide Seiten Interessen und Folgen auf den Tisch legen (Carlile, 2004).

Empfehlung

Wenn Studierende für einen Praxispartner bauen, verengen Sie den Anwendungsfall vor dem Start auf eine Frage, die sich mit erfundenen Beispieldaten beantworten lässt, und regeln Sie die Vertraulichkeit vor dem ersten Interview. Prüfen Sie mündlich am Prototyp. Prüfkriterium: Kann das Team ohne Zugang zu Partnerdaten einen Prototyp zeigen, den der Partner an einem echten Fall beurteilen kann?

Umsetzung, Stand 10/2026

Ausgangslage. Im Sommersemester 2026 lief erstmals das Wahlpflichtmodul „GenAI im Einsatz“, in dem Studierende für reale Anwendungsfälle aus dem Einkauf von Partnerorganisationen KI-gestützte Werkzeuge entwerfen: ein Automobilzulieferer (Konzern), ein kirchlicher Sozialträger mit eigener Einkaufsabteilung und der Einkauf der eigenen Hochschule hatten vorab beschrieben, wo sie sich Unterstützung vorstellen, von der Gestaltung von Rahmenverträgen über Lieferantenrecherche und Preisbenchmarks bis zu automatisierten Berichten aus Finanz- und Lieferantendaten. Ein Einkaufsleiter formulierte das Kernproblem als Informations- und Kompetenzasymmetrie zwischen Bedarfsträger und Einkauf: Wer einen Laborkühlschrank für 3.000 Euro bestellt, sieht ein Standardgerät; der Einkauf sieht Lieferkonditionen, Energieklasse und Folgekosten, und beide reden aneinander vorbei. Im Wintersemester 2026/27 folgt ein Guided Project mit fünf Masterstudierenden, die für einen internationalen Hersteller von Antriebstechnik den Angebotsanfrage-Zyklus (Request for Quotation) mit generativer KI unterstützen sollen.

Umsetzung. Das Wahlpflichtmodul (4 ECTS, 40 Stunden Präsenz) arbeitet in drei Schritten: Studierende wählen einen Use Case und klären ihn mit dem Partner, bauen einen Prototyp mit den Werkzeugen aus Anhang D (eigene Quellen, Agenten, Workflow-Automatisierung; Kapitel D.3, Kapitel D.6) und stellen ihn dem Partner vor. Geprüft wird zu 70 Prozent mündlich, zu 30 Prozent im Antwortwahlverfahren, also prozessnah im Sinne von Kapitel 5.4. Das Guided Project ist in drei Phasen über 16 Wochen angelegt: Benchmarking (Literatur und Praxis zu GenAI im Einkauf), Konzeptentwicklung mit Experteninterviews und Prozessmodellierung des Ist- und Soll-Prozesses, Prototyp mit Testplan und Testfällen. Da die Studierenden keinen Systemzugang beim Partner haben, arbeiten sie mit Interviews und anonymisierten Beispieldaten.
Das Guided Project organisiert sich in einem einzigen Git-Repository, das zugleich Projektakte und Arbeitsplatz ist. Fünf Regeln stehen am Anfang der Startseite: kein Projektmaterial außerhalb des Repositorys; nur Text, also Markdown, CSV und Code, Diagramme in Mermaid, Prozessmodelle als BPMN-Export; Termine nur als Meilensteine in der Projektverwaltung, nie in Dokumenten; ausschließlich erfundene Beispieldaten, keine echten Anfragen, Preise oder Lieferantendaten; und Pseudonyme statt Firmen- und Personennamen, auch in Interviewprotokollen, bevor sie eingecheckt werden. Risiken und Besprechungen laufen über Formulare in der Aufgabenverwaltung, und ein eigener Abschnitt der Startseite richtet sich an Sprachmodelle, die mit dem Repository arbeiten: Die Startseite ist die Karte, der Ordner mit Projektplan und Rollenmatrix gilt immer in der aktuellen Fassung, frühere Stände zeigt die Versionsgeschichte.
Carlile beschreibt solche Objekte als Grenzobjekte, die Wissen über Abteilungsgrenzen tragen; das Repository ist die Form, die er *repository* nennt, ein gemeinsamer Bestand mit gemeinsamen Bezeichnungen (Carlile, 2002). Zwischen Hochschule und Partnerunternehmen erfüllt es diese Funktion wörtlich, und die Regeln zu Beispieldaten und Pseudonymen lösen das Vertraulichkeitsproblem, bevor ein Prototyp entsteht. Neu ist der dritte Leser: Weil alles als Text vorliegt und die Startseite ein Sprachmodell anleitet, kann ein Modell den Projektstand lesen, ohne dass jemand ihn zusammenfasst.

Lernfrage. Warum gilt Carliles Stufenfolge beim Projekt mit Praxispartnern wörtlich, während sie im übrigen Kapitel nur eine Analogie ist?

6.4 Was die Beispiele gemeinsam zeigen

Kernaussagen

- Jedes Beispiel beginnt mit einem Prinzip der Lernforschung; das Werkzeug ist austauschbar, das Prinzip nicht. Wer ein Beispiel übernimmt, übernimmt das Prüfkriterium der Empfehlung, nicht das Produkt.
- Je höher die Wissensform, desto weniger trägt das Werkzeug allein. Für syntaktisches Wissen genügt Abruf mit Rückmeldung (Kapitel 6.1.1); semantisches braucht angeleitetes Entdecken mit Erklärungsauftrag (Kapitel 6.2.1); pragmatisches braucht eigenes Handeln und ein Nachgespräch, das die Lehrperson führt (Kapitel 6.3.2).
- Die Arbeit der Lehrperson verschiebt sich vom Herstellen zum Prüfen. Ein Sprachmodell schreibt Fallstudie, Song und Widget in Minuten; Qualität entsteht dort, wo jede Zahl in Code nachgerechnet, jede Zeile gegen das Regelwerk geprüft und jedes Modell durch Tests geschickt wird.
- Leitplanken entscheiden über die Wirkung eines Tutors. Derselbe Tutor schadet, wenn er Lösungen herausgibt, und hilft, wenn er Musterlösungen als Grundlage nutzt und einen eigenen Versuch verlangt (Kapitel 6.2.2).
- Wenn Studierende bauen, fehlt am häufigsten der Test mit Nutzenden. Er gehört getrennt bewertet, weil er die reichste Rückmeldung liefert (Kapitel 6.3.4).
- Belegt sind die Bauprinzipien, nicht die Umsetzungen. Für keines der Beispiele liegt bisher ein Wirkungsnachweis im eigenen Kurs vor; offene Ergebnisse sind als solche gekennzeichnet.

Lernfragen

Wiederholen

1. Welche drei Wissensformen unterscheidet Carlile (2004), und warum ist ihre Übertragung auf das Lernen nur beim Projektlernen mit Praxispartnern mehr als eine Analogie?
2. Was zeigte der Vergleichsfall der University of Maryland über

Nutzung und Wirkung eines Tutors, der aus den eigenen Kursmaterialien antwortet?
3. Welche drei Kennzahlen erheben wir für den BWL-Tutor in Kapitel 6.2.2?

Anwenden

4. Welches Beispiel liegt Ihrem eigenen Modul am nächsten? Bestimmen Sie Wissensform und Lerntechnik, bevor Sie ein Werkzeug auswählen, und nennen Sie den Engpass (Material, Zugänge, Partner, Prüfungsform), der bei Ihnen zuerst aufträte.
5. Formulieren Sie für ein eigenes Vorhaben Prinzip, Empfehlung und Prüfkriterium nach der Schablone dieses Kapitels. Besteht Ihre Empfehlung den Austauschtest?

Beurteilen

6. Der Tutor an der Hochschule Rhein-Waal war sokratisch gebaut und wurde trotzdem als Antwortmaschine genutzt. Was folgt daraus für den BWL-Tutor?

Lösungshinweise, auch zu den Lernfragen in den Beispielen: Anhang F.

A Gezielte Einschränkungen in didaktischen Prompts

Als Hiwi soll ein Sprachmodell schnell und effizient antworten. Als Tutor, Copilot oder Simulator (Kapitel 4) schränken didaktische Prompts es dagegen bewusst ein, denn Studierende lernen mehr, wenn sie sich anstrengen müssen; die Lernforschung nennt das „desirable difficulties“ (E. L. Bjork & Bjork, 2011). Explizite Regeln verbieten dem Modell bestimmte Verhaltensweisen und machen aus einem allgemeinen Sprachmodell ein Lernwerkzeug, das Lernziele verfolgt, statt nur Informationen zu liefern (E. R. Mollick & Mollick, 2023b, 2024). Tabelle A.1 ordnet die wiederkehrenden Einschränkungen nach ihrem Zweck und zeigt, wie sie in den Prompts von Anhang B (Anhang B) formuliert sind.

Einschränkung	Zweck	Formulierung
Keine fertige Lösung	**Aktives Lernen:** Die KI wird Wegweiser statt Orakel. Sie antwortet mit Nachfragen und Hinweisen; Lernende erklären ihre Überlegungen und korrigieren sich selbst. Das fördert Abruf und tiefere Verarbeitung.	„Keine fertigen Lösungen.“ „Antworten möglichst mit einer Frage beenden.“ (Anhang B, online)
Keine Abgabeleistung erstellen	**Aktives Lernen:** Wahrt die akademische Integrität; Lernende müssen ihr Wissen selbst anwenden, die Autorschaft bleibt bei ihnen.	„Löse KEINE benoteten Aufgaben.“ „Keine vollständige Endfassung als ‚Abgabe-Text‘.“ (Anhang B, online)
Kein Monolog	**Aktives Lernen:** Der Lernprozess bleibt dialogisch; Lernende steigen nicht aus.	„Halte keine längeren Vorträge ohne Interaktion.“ „Nicht fortfahren ohne Antwort.“ (Anhang B, online)

Einschränkung	Zweck	Formulierung
In der Rolle bleiben	**Realistische Simulation:** Erhält die Immersion, die für situiertes Lernen zentral ist.	„Bleiben Sie während des Rollenspiels strikt in Ihrer zugewiesenen Rolle.“ (Kapitel B.6.1)
Informationen dosieren	**Realistische Simulation:** Schafft eine realistische Informationslücke; Lernende üben systematisches Nachfragen, etwa diagnostische Fragen, statt eine Datenflut zu erhalten.	„Sie liefern Informationen nur, soweit sie für den Patienten plausibel sind und typischerweise in einer Telefontriage genannt werden können.“ (Anhang B, online)
Nicht schnell nachgeben	**Realistische Simulation:** Hält die Verhandlung herausfordernd; Lernende üben Überzeugen und Konfliktlösung unter realistischem Druck.	„Entscheide nicht zu schnell und gehe keine Kompromisse ein.“
Nur aus der Quelle	**Sachliche Grundlage:** Verhindert erfundene oder nicht kanonische Inhalte und hält die Übung bei Textanalyse und Interpretation.	„Keine erfundenen Zitate.“ „Jede interpretative Behauptung bekommt mindestens einen Primärtext-Beleg oder wird als Hypothese markiert.“ (Anhang B, online)
Keine unnötige Komplexität	**Kognitive Belastung begrenzen:** Spart unnötige mentale Anstrengung, damit sich Lernende auf das Kernkonzept konzentrieren (Sweller, 2011).	„Vermeide komplizierte oder unnötige Notationen.“ „Machen Sie das Szenario nicht unnötig komplex.“ (Kapitel B.6.2)
Eine Frage pro Zug	**Kognitive Belastung begrenzen:** Verhindert Überforderung und ergibt einen schrittweisen Gesprächsfluss.	„Stellen Sie nicht mehr als eine Frage auf einmal.“ (Kapitel B.6.2) „Immer nur eine Frage.“ (Anhang B, online)

Zielsprache mit Ausweg	**Kognitive Belastung begrenzen:** Sorgt in Sprachübungen für Immersion; der Ausweg verhindert Frust, wenn die Belastung zu hoch wird.	„Sprich NUR in [Zielsprache], es sei denn, ich gebe HILFE AUF DEUTSCH ein.“

Tabelle A.1. Gezielte Einschränkungen in didaktischen Prompts. Eigene Darstellung; Formulierungen mit Verweis stammen aus den Prompts in Anhang B.

B Best-Practice-Sammlung didaktischer Prompts und GenAI Aufgabenstellungen

Vorbemerkung zur Struktur der Sammlung

Die hier vorgestellten didaktischen Prompts wurden aus verschiedenen internationalen Quellen zusammengetragen, übersetzt und in eine **standardisierte Form** (RTF oder CREATE-Schema, s.o.) überführt.

Im Buch stehen neun Prompts und Aufgabenstellungen in voller Länge, je ein bis drei für die Rollen Hiwi, Tutor, Copilot und Simulator (Kapitel 4). Die übrigen 24 sind am Ende des Anhangs mit ihrer Funktion aufgeführt (**?@tbl-prompts-online**); die vollständige Sammlung mit Kopierfunktion steht in der Online-Version (Abbildung B.1).

Neben **Beispielen für die Prompts** sind jeweils auch detaillierte **Aufgabenstellungen** aufgeführt, die zeigen, wie wir die Prompts in eine Lehreinheit integrieren können. **Testen Sie die Prompts am Besten gleich** im Sprachmodell Ihrer Wahl, oder lassen Sie den Prompt dort auf eine spezifische Lehreinheit hin anpassen. Sie wollen vergleichen, wie die **Prompts mit verschiedenen Modellen funktionieren?** Nutzen Sie dafür die LM-Arena: https://lmarena.ai/de?mode=side-by-side. Viel Spaß dabei!

B.1 Hiwi: Schnelle Hilfe zur Lehrgestaltung

B.1.1 Hiwi: Aktivierungs-Coach für die Präsenzlehre

Funktion: Vorlesungen interaktiver machen; Fragen/Checks einbauen; Aktivierungsimpulse generieren.

Didaktische Elemente: Retrieval Practice; formative Checks; Aktivierung durch kurze Interaktionen.

Quelle: Angepasst und übersetzt von der System Prompt Library (Harvard VPAL/HILT) (Wilson & Tingley, n.d.); thematischer Prompt im Fork als Datei: Interactive Lecture Assistant.

Hiwi: Aktivierungs-Coach

```
[Character]
Du bist ein erfahrener Hochschuldidaktiker mit
  Schwerpunkt auf Active Learning, Cognitive
  Engagement und lernzielorientierter
  Vorlesungsplanung.

[Request]
Unterstütze einen Dozenten dabei, eine
  traditionelle Vorlesung in eine interaktive
  Lernerfahrung umzuwandeln. Nutze die vom
  Dozenten gelieferten Vorlesungsthemen als
  Ausgangspunkt.

[Examples]
Beispiele für interaktive Elemente, die du
  einsetzen darfst (Du darfst auch andere
  vorschlagen!):
Schnellumfragen (Multiple Choice,
  Einschätzungsfragen)
Think-Pair-Share
1-Minuten-Paper / Exit Tickets
Kurze Konzept-Checks oder Fehlkonzept-Fragen

[Adjustments & Constraints]
Berücksichtige realistische Zeitfenster
  innerhalb einer Vorlesung (z. B. 90 Minuten).
Die Aktivitäten sollen ohne aufwendige Technik
  umsetzbar sein.
Formuliere alle Fragen klar, niedrigschwellig
  und lernzielbezogen.

[Type of Output]
Klärende Rückfragen an den Dozenten
  (Zielgruppe, Niveau, Zeit, Lernziele)
Strukturierte Übersicht der Vorlesungsphasen
Pro Phase:
Ziel der Aktivität
Konkrete Beispielfrage(n)
Kurze Durchführungsanleitung
Optional: Hinweise zur Moderation und
  typischen Stolpersteinen

[Evaluation & Steps]
Prüfe, ob jede Aktivität einem klaren Lernziel
  dient
Achte auf Abwechslung zwischen Input und
  Aktivierung
Stelle sicher, dass die Gesamtzeit realistisch
  bleibt
Priorisiere Verständnissicherung gegenüber
```

Den Strukturierten Prompt Designer, der Prompt-Ideen in das RTF- oder CREATE-Schema überführt, enthält die Online-Sammlung; seine GPT-Version nennt der Kasten in Kapitel 2.5.3.

B.1.2 Hiwi: System-Prompt für typische Anforderungen erstellen

Funktion: Erstellt allgemeine Instruktionen, die das Sprachmodell an die User-Bedürfnisse anpasst. Es entsteht ein *angepasster* akademischer Hiwi für den eigenen Lehr- und Forschungsbereich. Dieser System-Prompt kann im Sprachmodell hinterlegt werden ("Personalisierung" bei ChatGPT), oder als Textdatei punktuell beigefügt werden.

Didaktische Elemente: Scaffolding (Profilkarte + Blueprint als Defaults), Klärungsfragen (genau eine Frage pro Schritt mit a/b/c/Sonstiges), prozedurale Anleitung (Phasenlogik, Checkliste zur Überprüfung, Iterationsschleifen).

Quelle: Selbst erstellt; strukturiert nach dokumentierten Best Practices für System Prompts von OpenAI, Anthropic und Google (Anthropic, 2025b; Google, 2025; Kotha et al., 2025). (acht Prinzipien: Struktur, Spezifität, Motivation, positive Formulierung, Beispiele, Unsicherheit, Reasoning, Iteration).

Hiwi: Allgemeine Anweisungen im System-Prompt

B.1.3 Hiwi: Quiz-Ersteller

Funktion: Erstellt didaktische Quiz-Aufgaben.

Didaktische Elemente: Testing Effect; Low Stakes Test; Retrieval Practice

Quelle: Angepasst & übersetzt basierend auf dem Blog von Ethan Mollick, Online: https://www.moreusefulthings.com/instructor-prompts.

Hiwi: Didaktische Quiz Ersteller

```
[Role/Rolle]:
Du bist ein kompetenter Lehrassistent und
  Experte für Leistungsbewertung. Du
  entwickelst diagnostische Tests
  (Multiple-Choice und offene Fragen), um
  Wissen valide zu überprüfen. Du agierst
  strukturiert, präzise und didaktisch
  reflektiert.

[Task/Aufgabe]:
Führe ein mehrstufiges, dialogisches Vorgehen
  durch:

Phase 1 - Einstieg (Pflichtreihenfolge
  einhalten!)
- Stelle dich dem Lehrenden kurz vor (1-2
  Sätze).
- Stelle genau zwei nummerierte Fragen:
  1. Welches Fach unterrichten Sie?
  2. Auf welchem Niveau sind Ihre Studierenden
  (Bachelor oder Master)?
- Stelle keine weiteren Fragen.
- Erwähne keine Themen, Inhalte oder
  Dokumente.
- Warte zwingend auf die Antwort des Lehrers,
  bevor du fortfährst.

Phase 2 - Zielklärung (erst nach Antwort auf
  Phase 1!)
- Frage den Lehrenden, was die Studierenden
  konkret (in 2-3 Punkten) zu dem Thema
  verstehen sollen.
- Frage zusätzlich, welche typischen
  Schwierigkeiten oder Fehlvorstellungen
  auftreten könnten.
- Warte erneut auf die Antwort des Lehrenden.
- Stelle keine weiteren Fragen.

Phase 3 - Testkonstruktion (erst nach
  vollständiger Zielklärung!)
Erstelle einen ansprechenden diagnostischen
  Test mit:
- 5 Multiple-Choice-Fragen
- 2 offenen Fragen
- Anordnung von leicht → anspruchsvoll
- Mischung aus Reproduktions- und
  Anwendungsaufgaben
```

B.2 Tutor: Beratender Beistand

Den Allgemeinen Tutor nach Mollick und Mollick enthält die Online-Sammlung; einen geprüften Tutor als Zwei-Datei-Bündel mit Testplan beschreibt Kapitel D.7.

B.2.1 Tutor: Quiz me – Abrufübung mit dem Kerninhalt einer Woche

Funktion: Wiederholung mit einem beliebigen Chat-Assistenten, festgelegt auf das Material der Lehrperson; Rechenaufgaben mit geänderten Werten und Begriffsfragen im Format der Prüfung.

Didaktische Elemente: Abrufübung vor jeder Rückmeldung („Never give the answer before I have tried“); feste Reihenfolge Problem → Formel in Worten → Rechnung → Übungsaufgabe; typische Fehler benennen; Bindung an das eingefügte Material statt an das Modellwissen; Schlussrunde im Prüfungsformat.

Einsatz: Studierende kopieren den Prompt in einen neuen Chat, hängen den Kerninhalt einer Woche als Text an (Problem, Satz der Woche, Formeln, gerechnete Beispiele mit Ergebnis, typische Fehler, Übungsaufgaben ohne Lösung) und beantworten jede Frage zuerst auf Papier. Weil jedes gerechnete Beispiel sein Ergebnis mitführt, lässt sich jede Zahl des Modells gegen eine Zahl der Lehrperson prüfen. Beschreibung und Begründung in Kapitel 6.1.1.

Quelle: Eigener Prompt aus dem Modul *Sustainable Supply Chain Management*, TH Köln, Wintersemester 2026/27 (Original englisch, unverändert). Für ein anderes Fach Modulname, Lehrbuch und Prüfungsformat in *Role*, *Material* und *Test format* ersetzen.

Tutor: Quiz me

```
Role. You are a revision tutor for the module
  Sustainable Supply Chain Management at TH
  Köln (Prof. Dr. Roman Bartnik). I am a
  Bachelor student in my first course taught in
  English, meeting operations management for
  the first time.

Material. Below this prompt I paste the key
  content of one week: the problem the chapter
  discusses, the sentence of the week, the
  formulas, examples from student life, the
  factory and the supply chain with their
  numbers, typical errors, and practice items
  without keys. Use only this material and the
  textbook chapter it names (Heizer, Render &
  Munson, Operations Management, 14th ed.). Do
  not invent numbers that are not in the
  material.

Method. Quiz me, one question at a time. Start
  with the problem in words, then the formula
  in words, then a calculation on one of the
  examples' numbers with one value changed,
  then a practice item. After each of my
  answers: say whether it is right, show the
  calculation in at most four lines, and name
  the typical error I made if I made one.
  Never give the answer before I have tried.
  If I ask for the answer straight away, give
  one hint first.

Style. Plain words before the textbook term,
  every time: say output per one input and
  then (single-factor productivity). Short
  answers, at most six sentences, unless I ask
  for more. Units on every number. Where a
  formula appears, write it in words as well.

Test format. The real tests are on paper,
  individual then team, with calculation items
  on these numbers with changed values, and
  with recognition items on the chapter's terms
  and cases. Mix both kinds. End the session
  with three items in the test's format and a
  two-line summary of what I should reread.

Honesty. If the material does not contain what
  I ask, say so and point me to the chapter
  section named in it. Do not guess a number.
```

Folgeprompt für die typischen Fehler:

```
Take the typical errors in the material. For
  each one, give me a short calculation that
  contains that error and ask me to find and fix
  it. Then show the corrected calculation in
  at most four lines.
```

B.3 Aufgabenstellungen Tutorat

B.3.1 Tutor-Aufgabe: Sokratischer Dialog mit GenAI

Funktion: Dieses Lehrsetting kombiniert geführte Dialoge mit Künstlicher Intelligenz (KI) mit Phasen, in denen bewusst auf Technologie verzichtet wird ("unplugged"). Das Ziel ist die Förderung kritischer Denkfähigkeiten durch die Methode des *Sokratischen Dialogs*.

Die Studierenden stellen der KI definitorische und prüfende Fragen, identifizieren implizite Annahmen in den generierten Antworten und überarbeiten diese eigenständig. Das Endprodukt ist eine überarbeitete Fassung inklusive Begründungen und einer Dokumentation des kognitiven Prozesses.

Quelle: Yuen (2025), Online: AI Pedagogy Project

Tutor-Aufgabe: Sokratischer Dialog

B.4 Copilot: Gemeinsam zu neuen Horizonten

B.4.1 Copilot: Fallstudie gemeinsam erstellen

Funktion: Vertiefung von theoretischem Wissen durch konstruktivistische Anwendung (Erstellung statt Konsum); Förderung des Verständnisses komplexer Zusammenhänge durch Szenarienbildung.

Didaktische Elemente: Co-Creation; Rollenspiel (AI as Mentor); Perspektivwechsel (Student als Fallautor); Iteratives Design.

Quelle: Angepasst & übersetzt basierend auf More Useful Things (o. J.), Co-create a case study with Copilot. Online: https://www.moreusefulthings.com/student-exercises .

System-Prompt: Gemeinsame Erstellung einer Fallstudie

B.4.2 Copilot: Dem Tod ins Auge sehen - Pre-Mortem für Projekte

Funktion: Risikoantizipation durch mentale Zeitreise (Inversion); Überwindung von Konformitätsdruck (Groupthink) und Optimismus-Fehlschluss (Optimism Bias) in der Planungsphase

Didaktische Elemente: Sokratische Gesprächsführung; Prospective Hindsight (Prospektive Rückschau)

Quelle: Angepasst & übersetzt basierend auf More Useful Things (o. J.), Project pre-mortem. Online: https://www.moreusefulthings.com/student-exercises.

> **Project Pre-Mortem Übung**

B.5 Aufgabenstellungen Copilot

B.5.1 Copilot-Aufgaben: 'AI-Sandwich' - GenAI in einen Kurs integrieren

Eine Hausarbeit mit eigener Recherche ist aufwendig, und ein Sprachmodell liefert den fertigen Essay in Sekunden, auch wenn niemand mit einem Menschen gesprochen hat. Jon Ippolito legt die Aufgabe deshalb als Sandwich an: Am Anfang sammelt die KI ungewöhnliche Interviewfragen, in der Mitte befragen die Studierenden zwei bis drei Menschen, die vom Thema betroffen sind oder sich darin auskennen, und am Ende macht die KI aus den Notizen eine Gliederung, einen Entwurf und drei mögliche Schlussfolgerungen. Die Studierenden messen diese an ihrer eigenen Feldforschung, überarbeiten den Text und geben ihn mit dem Verlauf ihrer Prompts und einer kurzen Reflexion ab. Was sie selbst erhoben haben, wird so zum Maßstab für den KI-Text, und die Aufgabe übt genau die Prüf- und Integrationsarbeit, deren Anteil an der Wissensarbeit mit KI wächst (H.-P. H. Lee et al., 2025). Es handelt sich um einen Unterrichtsentwurf; Ergebnisse sind nicht berichtet.

Die Lehrperson verankert das Sandwich-Prinzip in der Aufgabenstellung: Zuerst werden Lernziele und Kriterien ohne GenAI erarbeitet, dann unterstützt die GenAI bei Ideengenerierung, Struktur und Rohentwürfen, und abschließend folgt die menschliche Überarbeitung mit Quellenprüfung und Reflexion.

Quelle: Übersetzt von Ippolito (2025), Online: AI Pedagogy Harvard

Copilot-Aufgabe: AI-Sandwich

B.6 Simulator: Didaktisches Erleben

B.6.1 Simulator: Verhandlungssimulation

Funktion: Simulation komplexer Verhandlungssituationen in einer risikofreien Umgebung (Sandbox); Anwendung theoretischer Konzepte (BATNA, ZOPA) in der Praxis; Förderung der kommunikativen Kompetenz und strategischen Planung.

Didaktische Elemente: Scaffolding (durch KI-Mentor); Formatives Feedback (Debriefing); Adaptives Lernen (Szenario-Wahl). Situiertes Lernen.

Quelle: Angepasst & übersetzt basierend auf L. Mollick & Mollick (2024). Negotiation Simulator. More Useful Things. Online: https://www.moreusefulthings.com exercises.

Simulator: Verhandlungssimulation

B.6.2 Simulator: Goal Play - Zielsetzung üben

Funktion: Training von Methodenkompetenz (Zielsetzung, Priorisierung) in einer risikofreien Simulationsumgebung; Transfer theoretischen Wissens (z. B. SMART-Kriterien) in praktische Beratungssituationen; Förderung der Handlungskompetenz durch Perspektivübernahme (Beraterrolle).

Didaktische Elemente: Scaffolding (durch KI-Mentor); Szenariobasiertes Lernen (Storytelling); Lernen durch Lehren (Learning by Teaching); Formatives Feedback (Debriefing)

Quelle: Leicht angepasst & übersetzt basierend auf L. Mollick & Mollick (2024) Mollick, E. & Mollick, L. (2024). Goal Play: Help a character achieve goals. Online: https://www.moreusefulthings.com/student-exercises.

Simulator: Zielsetzung üben

B.7 Weitere Prompts und Aufgabenstellungen der Online-Sammlung

Die folgenden Prompts und Aufgabenstellungen gehören zur Sammlung, sind aber nur online abgedruckt. Dort lassen sie sich mit einem Klick kopieren und in das Sprachmodell der Wahl einfügen.

Rolle	Prompt oder Aufgabe	Funktion
Hiwi	Kursinhalte aktualisieren	Prüft Lehrmaterial auf veraltete Angaben und schlägt Aktualisierungen mit Quellen vor
Hiwi	Strukturierter Prompt Designer	Überführt Prompt-Ideen in das RTF- oder CREATE-Schema
Hiwi	Potato-Prompt - Kurzbefehl für das kritische Hinterfragen eigener Argumente	Kurzbefehl, der eigene Argumente schroff und ohne Schonung gegenprüft
Hiwi	Protokolle für Treffen erstellen	Fasst Sitzungen mit Beschlüssen und Verantwortlichkeiten zusammen
Hiwi	Flash-Debatten Organisierer	Bereitet kurze Pro-und-Contra-Debatten für die Präsenzlehre vor
Hiwi	Schlechte Aufsätze zur Verbesserung durch Studierende erzeugen	Erzeugt absichtlich fehlerhafte Texte als Korrekturmaterial
Hiwi	KI-gestützte Übungsaufgaben erstellen	Generiert Übungsaufgaben mit Lösungen und Schwierigkeitsstufen
Tutor	Allgemeiner Tutor	Erklärt Konzepte im Dialog, fragt nach, prüft Verständnis und gibt keine fertigen Lösungen
Tutor	Mentor-Bot	Gibt umsetzbares Feedback zu studentischen Entwürfen und strukturiert die nächste Iteration
Tutor	Reflexionshilfe	Leitet die Reflexion einer Lernerfahrung an und überführt sie in eine Schreibaufgabe
Tutor (Aufgabe)	Einen Argumentationsplan theoriegestützt entwickeln	Argumentation anhand der vier Stasis-Fragen entwickeln (Meehan, AI Pedagogy Project)

Rolle	Prompt oder Aufgabe	Funktion
Tutor (Aufgabe)	Korrigiere einen schlechten Aufsatz	Studierende korrigieren einen KI-generierten schwachen Aufsatz (Newman, AI Pedagogy Project)
Copilot	Ungeliebte Positionen vertreten lassen (Devil's advocate)	Lässt die KI Gegenpositionen vertreten, um eigene Annahmen zu prüfen
Copilot	Team-Charter erstellen	Begleitet ein Team beim Aushandeln von Regeln und Rollen
Copilot	Team-Reflexion / After Action Review	Moderiert einen After Action Review nach Projektabschluss
Copilot (Aufgabe)	DuPont-Analyse eines Geschäftsberichtes	Kennzahlenanalyse eines Geschäftsberichts mit KI-Unterstützung (Pedersen, AI Pedagogy Project)
Copilot (Aufgabe)	Fehlinformation erstellen und analysieren	Desinformation erzeugen und entlarven, mit ethischem Rahmen (Stanford, AI Pedagogy Project)
Copilot (Aufgabe)	Iteratives, systematisches Testen von Prompts	Prompts entwerfen, testen und überarbeiten am Beispiel der Rogers-Regeln (Landfair)
Copilot (Aufgabe)	KI, die Zukunft und Du	Berufliche Zukunft mit KI-gestützter Recherche analysieren (Taylor, AI Pedagogy Project)
Simulator	Simulation eines Forschungsinterviews	Übt qualitative Interviews mit einer simulierten Interviewpartnerin
Simulator	Goal Play - Lernsimulation zur Anwendung einer Analysetechnik	Rollenspiel zur Anwendung von Selbstdistanzierungstechniken (nach Kross)
Simulator (Aufgabe)	Interview mit einer fiktionalen Person	Studierende interviewen eine von der KI gespielte historische oder fiktive Figur
Simulator (Aufgabe)	Schwierige Interaktionen üben (Beispiel: Telefongespräch von Pflegenden mit Patienten)	Schwierige Gespräche im Rollenspiel üben und reflektieren (Beispiel Pflege)
Simulator (Aufgabe)	Simulation in der Veterinärmedizin	Klinische Fallsimulation mit Anamnese und Entscheidungsfeedback (Beispiel Veterinärmedizin)

Übung (alle Rollen) | AI Fluency am Berufsprofil: eine Übung in vier Phasen | Führt an einem Berufsprofil aus der Datenbank O*NET durch Delegation, Description, Discernment und Diligence (Kapitel 2.6) |

: Online verfügbare Prompts und Aufgabenstellungen {#tbl-prompts-online}

Abbildung B.1. Vollständige Prompt-Sammlung in der Online-Version: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/kapitel07-appendix02-prompt-sammlung.html aufrufen.

C Umsetzung: Rollenspiele und Simulationen mit generativer KI in der Lehre

Vorbemerkung

In diesem Abschnitt wird eine bestimmte Art der Umsetzung im Detail besprochen: Optionen, wie man Rollenspiele und Simulationen gestalten kann. Dabei geht es vor allem um Beispiele und Empfehlungen zur Umsetzung.

C.1 Was bringen Rollenspiele und Simulationen? Didaktische Mechanismen und Lernziele

Was ist der Mehrwert von Rollenspielen und Simulationen (R&S) mit generativer künstlicher Intelligenz? Worauf muss man achten und womit anfangen? In diesem Beitrag sollen Ziele und Möglichkeiten dieser neuen didaktischen Toolbox besprochen werden. Dabei arbeiten wir uns von allgemeinen Lernzielen zu konkreten technischen Möglichkeiten, Warnungen und Umsetzungsempfehlungen vor.

Was hilft uns beim Lernen? Besonders effektive Lernmethoden und hohe Motivation gehören zu den wichtigsten Einflüssen (Dunlosky et al., 2013; Hattie, 2023). Aber natürlich verlagert das die Frage nur – was ist denn besonders effektiv, und was steigert die Lernmotivation?

Zunächst aber zu den erhofften didaktischen Vorteilen von interaktiven Rollenspielen und Simulationen. Diese lassen sich grob in die Bereiche Retention und Motivation einteilen.

C.1.1 Besser behalten

Die Retention von Wissen hängt wesentlich davon ab, wie Informationen verarbeitet und im Gedächtnis verankert werden. Rollenspiele und Simulationen wirken hier über mehrere ineinandergreifende Mechanismen. Erstens fördern sie das **abrufbasierte Lernen**: Wiederholtes Erinnern und Anwenden ("practice testing") stärkt die Gedächtnisspuren deutlicher als passives Wiederholen; unmittelbares Feedback in simulierten Situationen fungiert dabei als Praxistest und steigert die langfristige Behaltensleistung, insbesondere wenn der Abruf unter wechselnden Bedingungen erfolgt (R. A. Bjork, 1994; Roediger & Karpicke, 2006). Der Transfer profitiert, wenn die Lernsituation die spätere Anwendung abbildet – ganz im Sinne des Prinzips "Practice like you play, and you will play like you practice". Dabei sollten Lernende sowohl wiederkehrende Muster (z. B. typische Teamprobleme oder Krankheitsbilder) als auch Variation durch unterschiedliche Problemtypen erfahren; bewusstes Üben mit gezielter Rückmeldung bildet die Grundlage fortschreitender Expertise (Brown et al., 2014, S.57–58; Ericsson et al., 1993).

Zweitens erleichtern **Chunking und narratives Einbetten** den Zugriff auf komplexes Wissen: Das Gehirn organisiert Informationen in zusammenhängende Einheiten, und erzählerische Strukturen mit klaren Akteuren und emotionaler Bedeutung verbessern die Abrufbarkeit. Eine Chirurgin muss entscheiden, wie sie unter Zeitdruck die Kugel aus dem Gehirn eines Patienten entfernen soll. Solch eine exemplarische Szene für die Bedeutung von Erfahrungswissen (Brown et al., 2014, S.26–27) erhöht die Wahrscheinlichkeit dauerhafter Speicherung (Gobet et al., 2001; Willingham, 2021).

Drittens ermöglicht generative KI **individuelle Anpassung**: Szenarien können an Vorwissen und Kompetenzstand angepasst, Anforderungen fein justiert und Gruppenarbeit trotz heterogener Niveaus effizient betreut werden – ein Hebel, um besonders wirksame aktive und kollaborative Lernformen zuverlässig umzusetzen (Dunlosky et al., 2013; E. R. Mollick & Mollick, 2024).

Viertens unterstützen **Spacing und Interleaving** die Konsolidierung: Diese Form von zeitlich verteiltem Üben sowie das Mischen verschiedener Problemtypen fördern flexible Wissensanwendung und reduzieren die Illusion von Kompetenz. Rollenspiele bieten hierfür ideale Bedingungen, weil sie Inhalte in verschiedenen Szenarien und Abständen wiederkehren

lassen (Brown et al., 2014, S.51–52; Dunlosky et al., 2013; Murre & Dros, 2015; Roediger & Karpicke, 2006). Schließlich stärkt **reflektierende Eigenarbeit** die Gedächtnisbildung: Wenn Lernende Entscheidungen und Konzepte in der Simulation begründen – etwa indem sie die Handlungen einer KI-Figur hinterfragen und die zugrunde liegenden Prinzipien erläutern –, strukturieren sie ihr Wissen, identifizieren Lücken und vertiefen das Verständnis (Dunlosky et al., 2013; Ericsson et al., 1993; Wannemacher et al., 2025, Fall 031).

C.1.2 Motivieren

Ob Studierende lernen, hängt zentral (und ganz banal) auch davon ab, ob sie lernen **wollen**. KI-gestützte Rollenspiele können bedeutsame, herausfordernde und zugleich passgenaue Interaktionen schaffen, die Lernende aktiv einbeziehen und sofortige, personalisierte Rückmeldungen bereitstellen. Eine maßgeschneiderte Passung an Vorwissen reduziert irrelevante Inhalte, fokussiert individuell sinnvolle Herausforderungen und hält das Anspruchsniveau im **Flow-Bereich** – ein Arrangement, das intrinsische Motivation, Ausdauer und Behalten gleichermaßen stützt (Csikszentmihalyi, 2008).

Zugleich verlagern KI-Simulationen die Lernaktivität in Richtung Interaktion. Nach der **ICAP-Taxonomie** ist aktive Interaktion hoch motivierend und effektiv: interaktives Arbeiten (I) führt zu tieferen Lerngewinnen als konstruktives (C), aktives (A) oder passives (P) Verhalten; dialogische Auseinandersetzungen mit KI-Rollen, in denen Lernende Ideen gemeinsam erzeugen, prüfen und weiterentwickeln, begünstigen deshalb nicht nur das Verständnis, sondern auch das Motivationsniveau (Chi et al., 2018; Chi & Wylie, 2014).

Insgesamt verbinden gut gestaltete, KI-gestützte Simulationen insofern potentiell hohe kognitive Wirksamkeit mit motivationaler Qualität: Sie machen fachliche Herausforderungen greifbar, liefern unmittelbar verwertbares Feedback und geben Lernenden zugleich das Gefühl, wirksam handeln zu können – zentrale Bedingungen für nachhaltiges, transferfähiges Lernen. Ob dieses Potenzial eingelöst wird – gerade mit neuen technologischen Werkzeugen, wie der generativen künstlichen Intelligenz (GenAI), hängt natürlich von der konkreten Umsetzung ab. In den folgenden Abschnitten werden hierfür Beispiele analysiert und Empfehlungen abgeleitet.

C.2 Datengrundlage und Methodik

Die Beispiele stammen aus einer Scopus-Suche mit Publish or Perish (v. 8) in führenden hochschuldidaktischen Fachzeitschriften (Kapitel C.7), beschränkt auf 2025 publizierte Studien: Von 160 Treffern für „simulation OR roleplay OR game AND GenAI OR LLM“ blieben nach Durchsicht von Titeln und Abstracts 16 Fachartikel zu Rollenspielen und Simulationen mit KI (Kapitel C.8). Ergänzt wurden einzelne Studien aus dem Vorjahr (Barra et al., 2024; Huffman & Hutson, 2024; E. R. Mollick & Mollick, 2024), das Arbeitspapier des Hochschulforums Digitalisierung mit KI-Anwendungsbeispielen (Wannemacher et al., 2025) und Studien zu Sprachsimulationen (H. A. Nguyen, 2024; A. Nguyen et al., 2025; Vega et al., 2025). Die Übersicht ist damit exemplarisch, nicht vollständig; später erschienene Studien fasst Kapitel C.6 zusammen.

C.3 Welchen Mehrwert bringt generative KI?

Generative KI in Rollenspielen entfaltet ihren besonderen Mehrwert dort, wo sie Rollen glaubwürdig übernimmt, Interaktionen situativ anpasst, schnell Varianten erzeugt, bereitgestellte Texte zuverlässig verdichtet und didaktisch nutzbar aufbereitet, mehrstufige Reasoning-Prozesse übernimmt und Szenarien multimodal plastisch macht.

In diesem Abschnitt werden diese Facetten des potenziellen Mehrwerts der Technologie generative KI (GenAI) für Rollenspiele und Simulationen beleuchtet und mit Beispielen verdeutlicht. Was kann die Technologie schon gut und was noch nicht?

C.3.1 GenAI kann glaubwürdig Gesprächspartner simulieren

In Rollenspielen zeigt sich dieser Vorteil zunächst in der realistischen Rollenausübung: KI-Akteure verhalten sich in dialogischen Situationen hinreichend konsistent, um reale Druck- und Entscheidungslagen zu simulieren – etwa in Interview-Trainings, in denen LLM-gestützte Personas realitätsnahe Antworten geben und individuelles Feedback liefern (Nofal et al., 2025).

Ein zentrales Einsatzfeld ist das Training professioneller Interviews. Nofal et al. (2025) entwickelten eine KI-gestützte Interviewsimulation, in der Studierende mit realistisch wirkenden, durch GPT-basierte Agenten gesteuerten Gesprächspartnern interagierten, um Interview-, Dokumentations- und Empathiefähigkeiten zu üben. Das Lernziel war die sichere, wiederholbare Praxis komplexer Gesprächssituationen (z. B. sensible Gesundheitsdaten, Demografie, Persönlichkeitsmerkmale) ohne Risiko für reale Betroffene. Technisch wurden LLM-Agenten mit Rollenprofilen, Leitfäden und Reflexionsaufgaben kombiniert; der Ablauf umfasste Vorgespräch, geführtes Interview, automatische Protokollanalyse und Nachbereitung. Berichtet wurden Zugewinne in Selbstwirksamkeit und Vorbereitung auf reale Interaktionen; statistisch signifikant war insbesondere die Steigerung des Selbstvertrauens im Führen von Interviews. Als Lehreffekt betonen die Autor:innen die Bedeutung klarer Interviewleitfäden, expliziter Ethik-Hinweise (z. B. Datenschutz) und strukturierter Reflexion nach der Simulation.

Ergänzend zeigen hochschulische Use-Cases aus dem deutschsprachigen Raum, dass glaubwürdige KI-Dialogpartner in Management-, Verhandlungs- und Personaltrainings wirksam sind: In den Fällen "Talk2Transform" (Führung/Management), "TEAM with AI" (BWL-Verhandlung) und Gesprächssimulationen für Personalpsychologie agieren LLM-Avatare als Rollenpartner, die situativ Einwände einbringen und deeskalierende Strategien herausfordern. Das Lernziel ist die sichere Anwendung sozial-kommunikativer Kompetenzen unter Zeit- und Druckbedingungen; praktische Lehreffekte betreffen insbesondere die Skalierbarkeit von Übungsgelegenheiten sowie die Reduktion der Dozierendenlast durch automatisiertes, formatives Feedback (Wannemacher et al., 2025, Fälle 132/172/177).

Sprachschnittstellen machen solche Gegenüber noch glaubwürdiger. Barra et al. (2024) skizzieren für die medizinische Ausbildung Simulationen mit ChatGPTs "Advanced Voice Mode" (vgl. Kapitel 4.4.1), in denen die KI als Patient:in Emotion, Tempo und Sprechweise situativ anpasst, unterbricht und so realitätsnahe Stressoren einführt. Stimme und Prosodie erhöhen Präsenz und situative Komplexität; die Szenarien müssen aber kuratiert werden, um sachliche Fehler und unpassende Affekte zu vermeiden (Barra et al., 2024).

C.3.2 GenAI kann die Interaktion dem Gesprächspartner anpassen (z.B. nach Vorwissen)

Deutlich wird der Mehrwert auch in der adaptiven Passung: In spielbasierten Lernumgebungen können LLMs aus Logdaten individuelle Handlungspläne generieren, die Studierende bei Zielsetzung und Strategieentwicklung anleiten; damit verschiebt sich Scaffolding von statischen Hinweisen zu situativ-passenden Planvorschlägen (Goslen et al., 2025). In kollaborativen Diskussionssettings verstärkt GenAI – sinnvoll gerahmt, etwa durch Six-Thinking-Hats – kognitive Präsenz und Ideengenerierung, wobei Effekte je nach Kreativitätsprofil variieren; das spricht für bewusste didaktische Orchestrierung statt "freier" Nutzung (Yu et al., 2025).

Für "goal play" sind adaptive Scaffolds entscheidend. LLM-basierte Plangenerierung unterstützt Lernende beim Setzen erreichbarer Zwischenziele und beim Auswählen nächster Schritte in offenen Spielwelten – eine Form der metakognitiven Stützung, die Spiel-Flow und Lernfortschritt zugleich stabilisiert (Goslen et al., 2025). In kollaborativen Settings lässt sich diese Unterstützung durch Denkrahmen wie Six-Thinking-Hats bündeln; so steigt die kognitive Präsenz und die Qualität der Ideen, sofern Anleitung und Rollenklärung mitgeliefert werden (Yu et al., 2025).

Goslen et al. (2025) zeigen in einer Game-Based-Learning-Umgebung, wie ein LLM individuelle "Student Plans" generiert, die Aufgabenfolge, Hilfestufen und Reflexionsprompts an Vorwissen und Spielverlauf anpassen. Lernziel war, adaptive Scaffolds zu bieten, ohne den Spielfluss zu stören. Implementation: Das LLM analysiert Spieltelemetrie und kurze Lernstandseingaben und erzeugt dann maßgeschneiderte nächste Schritte (z. B. "erst Diagnose-Quest, dann kurzer Concept-Check, danach offener Anwendungsfall"). Ergebnisse weisen auf eine bessere Zielklarheit und nutzernahe Hilfedosierung hin; als Lesson Learned gilt, dass Transparenz über die Herkunft der Empfehlungen (Why-behind-the-hint) und Guardrails gegen Übersteuerung zentral sind (Goslen et al., 2025).

W.-S. Wang et al. (2025) integrieren ChatGPT-Feedback in eine VR-Lernumgebung (IoT-Aufgaben) und evaluieren das in einem RCT (n = 81). Lernziel waren höhere kognitive Niveaus (HOTS) und bessere Selbstregulation (SRL). Ablauf: Sechs VR-Units entlang Bloom-Stufen; Experimentalgruppe erhielt zeitnahe, auf Lernhandlungen bezogene GPT-Rückmeldungen (Zielsetzung, Strategiehinweise, Reflexionsprompts), die

Kontrollgruppe konventionelles Feedback. Resultat: signifikant höhere Werte in Erinnern, Verstehen, Anwenden sowie verbesserte SRL-Indikatoren in der GPT-Gruppe; der Kreativitätsgewinn blieb begrenzt – eine Lehre ist, dass zu direktive KI-Hilfen offene Exploration dämpfen können (W.-S. Wang et al., 2025).

C.3.3 GenAI spricht Fremdsprachen fehlerfrei

Sprachlich eröffnen generative Modelle einen zusätzlichen Vektor: Sie ermöglichen gesprächsnahe, fehlerarme Kommunikation in der Zielsprache und reduzieren Sprechangst, was vor allem beim Einüben von Gesprächsroutinen hilft. Minimale Übersetzungsfehler verblassen für die meisten User vor der Gelegenheit, täglich auf Muttersprachenniveau die Fremdsprache üben zu können (ganz zu schweigen von den gesparten Reisekosten und -abgasen!). Systematische Übersichten berichten, dass GenAI im Sprachunterricht als Feedback-Geber, Tutor und Gesprächspartner eingesetzt wird, während Einzelfallstudien Zugewinne in Selbstvertrauen und Sprechbereitschaft zeigen (Sangmin Lee et al., 2025; H. A. Nguyen, 2024; A. Nguyen et al., 2025).

In Sprachlern-Simulationen wird der Mehrwert besonders greifbar: Reviews ordnen GenAI als Gesprächspartner, Feedback-Geber und Tutor ein; Fallstudien berichten über mehr Sprechbereitschaft, geringere Angst und kurzfristig verbesserte Aussprache und Fluency, wenngleich Langzeitwirkungen und höhere Niveaus noch untererforscht sind (Sangmin Lee et al., 2025; H. A. Nguyen, 2024).

Eine systematische Übersichtsarbeit zeigt, dass GenAI-Tools im Sprachunterricht besonders für gesprochene Interaktion, Aussprache und situative Dialoge eingesetzt werden; wiederkehrende Befunde sind gesteigertes Sprechvolumen, mehr risikobereites Üben und unmittelbares Feedback – sofern Aufgaben gut gerahmt sind (Sangmin Lee et al., 2025).

Auf Kurs-/Studienlevel berichtete H. A. Nguyen (2024) über eine sprechenzentrierte Intervention mit KI-Assistenten: Lernziel war die Verbesserung der mündlichen Flüssigkeit und der Selbstsicherheit; der Ablauf kombinierte vorbereitete Prompts (z. B. Problemszenarien) mit Spontandialogen und anschließender Reflexion. Ergebnisse deuten auf Zugewinne in Sprechflüssigkeit und Reduktion von Sprechangst, gleichzeitig mahnt die Studie Qualitätssicherung der KI-Rückmeldungen an.

C.3.4 GenAI kann schnell Varianten von Situationen erstellen

Für die didaktische Konstruktion ist die Variantenproduktion zentral – auch damit es nicht schnell langweilig wird: Mit wenigen Prompt-Anpassungen entstehen Fallvarianten mit gesteuerter Schwierigkeit, alternativen Stakeholder-Positionen oder ungewöhnlichen Ereignisverläufen. Dieses "goal play" – zielgerichtete, auf Lernergebnisse hin entworfene Spiel- und Übungsformate – lässt sich in kurzen Sprintzyklen entwickeln und iterieren (E. R. Mollick et al., 2024; E. R. Mollick & Mollick, 2024).

Mollick und Kollegen demonstrieren mit "Simulated Practice at Scale" und dem Entrepreneurship-Simulator "PitchQuest", wie Multi-Agent-Setups in Sekunden neue, konsistente Pitch-Gegenspieler und Stakeholder-Konstellationen generieren. Lernziel ist adaptives Üben von Pitches unter sich verändernden Bedingungen (z. B. unterschiedliche Investor:innen-Profile, Markt-Schocks). Ablauf: Rollenbesetzung durch Agenten (Mentor, Kunde, Investor), gestufte Aufgaben, sofortiges Feedback. Lessons Learned: Variantenvielfalt steigert Transfer, aber verlangt klare Bewertungsraster und Debriefings, um Lernziele stabil zu halten (E. R. Mollick et al., 2024).

Es werden grobe Ablaufkonzepte erstellt (Playbooks): Lehrende iterieren kleine, zielgerichtete Spiele und Rollenspiele in schnellen Schleifen, nutzen Variantenbildung, Agenten-Rollen und Prüf-Prompts zur Qualitätssicherung und skalieren gelungene Muster in die Breite (E. R. Mollick et al., 2024; E. R. Mollick & Mollick, 2024). Deutsche Hochschul-Praxisbeispiele bestätigen die Breite des Einsatzspektrums – von Management-Dialogtrainings ("Talk2Transform") bis zu Verhandlungssimulationen ("TEAM with AI") – und benennen zugleich Gelingensbedingungen wie Prompt-Design, Feedback-Regime und rechtliche Klärungen (Wannemacher et al., 2025).

Der Historiker Kindenberg (2025) simuliert Ereignisse aus der Zeit der französischen Revolution. Durch GenAI ließen sich hier mit relativ geringem Aufwand Ereignis-, Rollen- und Quellenvarianten erzeugen, die an Vorwissen und Lernziele gekoppelt sind. Lernziel ist Quellenkritik und Perspektivübernahme unter wechselnden Szenarioparametern. Umsetzung: Kuratierte Promptbausteine für Ereignis-Timing, Akteursziele und soziale Spannungen; Lehrende selektieren/feintunen Varianten vor dem Einsatz. Eine zentrale Lehre ist, dass ein didaktischer "Scaffold" (Aufgabenstruktur, Reflexionsfragen) nötig bleibt, um inhaltliche Tiefe trotz generativer Vielfalt zu sichern (Kindenberg, 2025).

C.3.5 GenAI kann zur Verfügung gestellte Texte i.d.R. gut wiedergeben

Wo Quellenmaterial vorliegt, liefert KI robuste Verdichtungen und strukturierte Wiedergaben, die unmittelbar in Szenarien überführt werden können.

Originalquellen erlebbar machen, kann Lernenden neue Zugänge eröffnen. Huffman & Hutson (2024) beschreiben "NotebookLM" als dokumentengebundenen Assistenten, der historische Primärquellen (Mary-Sibley-Tagebuch) in strukturierte Lernpfade und Audio-Dialoge überführt. Lernziel ist, Quellenverständnis und Kontextualisierung zu vertiefen, ohne den Originalbezug zu verlieren. Ablauf: Upload kuratierter Quellen, Generierung von erklärenden Podcasts/Dialogscripten samt Quellen-Referenzierung; Lesson Learned: Grounding reduziert Halluzinationen deutlich, verlangt aber sorgfältige Quellenauswahl und Aufgaben, die Prüf- und Reflexionsphasen erzwingen (Huffman & Hutson, 2024).

Im naturwissenschaftlichen Kontext skizziert Choi (2025), wie GenAI Erdwissenschaftssimulationen mit fachlichen Texten "füttert", um Aufgaben, Messprotokolle und Deutungsdialoge zu erzeugen, die eng an bereitgestellten Materialien haften. Lernziel ist die Übersetzung von Fachtexten in handlungsnahe Simulationen. Die Studie betont, dass dokumentengebundenes Prompting didaktisch starke Ergebnisse liefern kann, wenn Qualitätskriterien (Aktualität, Autorität, fachliche Konsistenz) erfüllt und durch Reflexionsaufträge abgesichert werden.

C.3.6 GenAI kann in mehreren Schritten selbstständig agieren

Schließlich erleichtert KI mehrschrittiges "Nachdenken" (Reasoning) samt Selbstprüfung: In Spielumgebungen generieren Modelle nicht nur nächste Aktionen, sondern begründen Planalternativen und vergleichen sie mit Zielzuständen; das eröffnet neue Formen des reflektierten Übens, setzt aber didaktische Leitplanken gegen Scheinpräzision und Halluzination voraus (Goslen et al., 2025).

E. R. Mollick et al. (2024) berichten, dass mehrschrittige, agentenbasierte Orchestrierungen ("Goal Play") innerhalb von Simulationen Aufgaben wie Informationssuche, Rollenbriefings, Gegenargumente und Bewertungsfeedback autonom durchführen. Lernziel ist, komplexe, mehrzügige Entscheidungssituationen zu üben. Der Ablauf bindet Agenten mit komplementären Rollen (z. B.

"Skeptical Investor", "Method Coach") ein; Lessons Learned: Agenten erhöhen Realismus und Dichte der Interaktionen, benötigen aber explizite Sicherheits- und Qualitätschecks (Rubrics, menschliche Supervision), um Fehlerketten zu verhindern (E. R. Mollick et al., 2024).

Goslen et al. (2025) zeigen die mehrschrittige Plan-Generierung für Lernpfade im Spiel: Das LLM analysiert Statusdaten, prüft Zwischenergebnisse gegen Zielkriterien und passt Such-/Lernstrategien an (z. B. "Erst Konzeptlücke schließen, dann Praxisquest"). Lernziel ist metakognitives Planen und effiziente Hilfe zur rechten Zeit. Die Autor:innen betonen, dass Erklärbarkeit ("warum dieser Schritt?") und Fail-Safes gegen falsche Pfade zentral für Akzeptanz und Wirksamkeit sind (Goslen et al., 2025).

C.3.7 GenAI kann Szenarien plastischer machen

Realistischere und mit verschiedenen Sinnen wahrnehmbare Szenarien helfen beim Behalten und motivieren. GenAI kann hier unterstützen, durch Generierung von Sprache (Voice, ElevenLabs), Bildern (Firefly), Videos (Sora), Dialogen (Podcasts, z.B. NotebookLM) und Musik (z.B. Suno). Diese Multimodalität wird von den Anbietern der Sprachmodelle aktuell stark ausgebaut. Sprachdialoge und paralinguistische Signale erhöhen Gegenwartsnähe und soziale Dichte von Gesprächen; generierte Audios oder Podcast-Dialoge verdichten Quellen zu hörbaren Szenen, dadurch wird es einfacher, greifbare, emotional anschlussfähige Erfahrungswelten in die Rollenspiele einzubauen (Barra et al., 2024; Huffman & Hutson, 2024; Nofal et al., 2025).

A. Nguyen et al. (2025) zeigen, wie "embodied GenAI" in Mixed-Reality-Umgebungen Lernende mit verkörperten KI-Agenten interagieren lässt. Lernziel ist aktives Lernen durch körperlich-räumliche Einbettung plus dialogische KI-Unterstützung. Umsetzung: MR-Szenen mit KI-Avatar-Verhalten, das auf Handlungen, Position und Sprache der Lernenden reagiert; zentrale Lehre: Multimodalität erhöht Engagement und Handlungsvalidität, benötigt aber präzises Szenariodesign und instrumentierte Reflexionsphasen, damit Wahrnehmung und Konzeptverständnis zusammenfinden (A. Nguyen et al., 2025).

Über die Beispiele hinweg zeigt sich, dass GenAI-basierte Simulationen besonders dann wirksam sind, wenn sie (a) klare Lernziele, Rubrics und Reflexionsschritte verankern, (b) dokumenten- oder quellengebunden

arbeiten, um Halluzinationen zu dämpfen, und (c) adaptive Scaffolds fein dosieren, damit Explorations- und Problemlöseanteile erhalten bleiben (Goslen et al., 2025; Huffman & Hutson, 2024; W.-S. Wang et al., 2025).

Eine exemplarische Übersicht von solchen Umsetzungen in verschiedenen Anwendungsbereichen zeigt Tabelle C.1.

Disziplin/Feld	Art der Simulation/des Rollenspiels	Wichtige Lernziele/entwickelte Fähigkeiten	Spezifische Beispiele für KI-Integration	Beispiel-Quelle
Gesundheitswesen	Notfallmaßnahmen, Patienteninteraktion	Schnelle Beurteilung, Entscheidungsfindung, multidisziplinäre Zusammenarbeit, klinisches Denken, Empathie, Kommunikation unter Druck	KI-generierte Patientenakten, Echtzeit-Veränderungen von Vitalzeichen, dynamische virtuelle Patienten; KI-Chatbot für interprofessionelle Teamsimulation (“Marie Parker”)	Wannemacher et al. (2025)
Pharmazie	Arzneimittelmanagement, Patientenberatung	Verordnung prüfen, Fehler erkennen, Aufklärung, Dosierung, Wechselwirkungen	KI-generierte Fallvarianten mit unterschiedlichen Komplexitäten; automatisiertes Feedback zu Dokumentation/Begründung	Lim et al. (2025)
Soziale Arbeit	Krisenmanagement, Familienunterstützung	Aktives Zuhören, Krisenintervention, interprofessionelle Zusammenarbeit, Umgang mit komplexen Familiendynamiken	KI-gestützte Gesprächs-/Interview-Simulationen mit sensiblen Klient*innenszenarien	Nofal et al. (2025)
Betriebswirtschaftslehre	Krisenmanagement, Entscheidungsfindung, VC-Pitching	Führung, Strategie unter Stress, Kommunikation, Datenanalyse, Lösungsbewertung	Mehragenten-Simulation “PitchQuest” (Mentor*innen, Rollenspieler*innen, Bewerter*innen)	E. R. Mollick et al. (2024)

Disziplin/Rolle	Art der Simulation/des Rollenspiels	Wichtige Lernziele/entwickelte Fähigkeiten	Spezifische Beispiele für KI-Integration	Beispiel-Quelle
Soft-Skills-Training	Kundenservice, Verkauf, Manager-Coaching, Konfliktlösung, Interviews, Verhandlungen	Kommunikationsmuster, Konfliktlösung, Emotionsregulation, strategisches Denken, Professionalität, Debatte	Adaptive Dialoge, Echtzeit-Feedback, anpassbare Avatare; z. B. "Talk2Transform", Gesprächssimulationen in der Personalpsychologie	Wannemacher et al. (2025, Fälle 132, 177)
Bildung (Lehrerausbildung)	Classroom-Management, Verhalten von Studierenden	Umgang mit Störungen, Entscheidungen im Unterricht, Differenzierung, Notfalllagen	KI-generierte Klassenzimmer-Szenarien; embodied GenAI in Mixed Reality mit virtuellen Studierenden	A. Nguyen et al. (2025)
Sprachenlernen	Wortschatz, Grammatik, Aussprache, interkulturelle Kommunikation	Sprachliche Genauigkeit, Flüssigkeit, kultureller Kontext, reale Interaktion	KI-gestützte Echtzeit-Korrektur, mehrsprachige Materialien, wiederholbare Rollenspiele (z. B. Chatbots/LLMs)	Sangmin Lee et al. (2025)
Kreativer Ausdruck	Kunst, Musik, Literatur, Problemlösen	Ideengenerierung, Überwinden kreativer Blockaden, Originalwerke, Datenanalyse, strategische Bewertung	Dokumentbasierte KI (NotebookLM) erzeugt Podcasts/Guides aus Quellen; KI-gestützte Story-/Dialogerstellung	Huffman & Hutson (2024)

Tabelle C.1. Anwendungsbeispiele für KI-Rollenspiele und Simulationen

Die hier skizzierten Potenziale gehen mit einer Reihe von Risiken und Nebenwirkungen einher, die bedacht werden müssen. Zentrale Punkte besprechen wir im folgenden Abschnitt.

C.4 Was geht nicht? Herausforderungen und Grenzen von GenAI

Generative KI in der Bildung birgt neben ihren Stärken auch spezifische Herausforderungen, die durch gezielte didaktische Strategien angegangen werden können.

A. Delegation des Denkprozesses: Die Nutzung von KI-Tools kann dazu führen, dass Studierende die kognitive Anstrengung des Lernens an die KI delegieren. Dies kann ein tieferes Verständnis der Materie verhindern (Dell'Acqua et al., 2023; H.-P. H. Lee et al., 2025).

Lehrende sollten eine didaktische Rahmung ("Human in the Loop") schaffen, die Studierende explizit dazu anleitet, die KI-Ausgaben kritisch zu reflektieren, anstatt sie blind zu übernehmen. Dies kann durch die Gestaltung von Prüfungsformaten erfolgen, die die kritische Auseinandersetzung mit KI-Tools erfordern und nicht die reine Wissenswiedergabe (Corbin et al., 2025). Lehrpersonen sollten als Experten für die didaktische Einbindung agieren, die den Lernprozess steuern (Tutton & Cohen, 2025).

B1. Halluzinationen: Generative KI-Modelle können Fehler machen oder falsche Informationen, sogenannte "Halluzinationen", generieren, die zu fehlerhaften Lernerfahrungen führen können (E. R. Mollick & Mollick, 2024).

Studierende müssen über die Risiken von Halluzinationen aufgeklärt werden. Es ist entscheidend, ihnen beizubringen, die von der KI generierten Informationen immer mit vertrauenswürdigen Quellen abzugleichen. Die Integration der KI in den Lernprozess sollte so erfolgen, dass die KI nicht als alleinige Wissensquelle, sondern als Partner im Lernprozess gesehen wird (Moon et al., 2025).

B2. Selbstbewusste Falschaussagen: KI-Modelle können falsche Informationen sehr selbstbewusst und gut artikuliert präsentieren. Studierende mit geringem Vorwissen können dies nur schwer als Fehler erkennen (E. R. Mollick & Mollick, 2024).

Um der überzeugenden Darstellung falscher Informationen entgegenzuwirken, sollte der Fokus auf der Entwicklung kritischer Medienkompetenz liegen. Lehrpersonen können bewusst Szenarien einbauen, in denen die KI absichtlich falsche Informationen liefert, damit die Studierenden lernen, diese zu identifizieren.

C. Variable Outputs: Die Ergebnisse von generativer KI werden stochastisch, nicht deterministisch produziert. Bei identischen Eingaben kann der Output variieren (Wolfram, 2023), was die Reproduzierbarkeit und Kontrolle von Lernerfahrungen erschwert (E. R. Mollick & Mollick, 2024).

Die stochastische Natur der KI kann in Lehr- und Lernkontexten als Feature genutzt werden, nicht als Bug. Die Variation der Antworten kann Studierende dazu anhalten, flexibel zu denken und sich nicht auf eine einzige "richtige" Antwort zu verlassen.

D. Mangelnde Erklärbarkeit: KI-Modelle können ihre Erklärungen oder Ergebnisse oft nicht verlässlich begründen, was in Lehrkontexten, die ein tiefes Verständnis der zugrunde liegenden Konzepte erfordern, einen Nachteil darstellt (E. R. Mollick & Mollick, 2024).

Lehrende können die Rolle des "Debriefers" übernehmen, um die KI-gestützten Szenarien im Nachhinein zu analysieren. Sie können die Studierenden dazu anleiten, zu erklären, wie sie zu ihren Entscheidungen gelangt sind, und diese mit den Antworten der KI vergleichen, um das zugrundeliegende Konzept zu verinnerlichen (E. R. Mollick & Mollick, 2024).

E. Reproduktion von Bias: KI-Modelle, die auf riesigen Datensätzen trainiert werden, können Vorurteile und Verzerrungen aus diesen Daten reproduzieren. Ohne eine kritische Auseinandersetzung können diese unreflektiert übernommen werden (Bender et al., 2021).

Lehrende sollten die Studierenden auf die potenziellen Vorurteile und Verzerrungen in den Trainingsdaten der KI hinweisen. Es ist ratsam, Prompts so zu gestalten, dass sie eine breite Perspektive einfordern. Im Debriefing sollten die ethischen Implikationen des Bias kritisch beleuchtet werden.

C.5 Wie umsetzen? Empfehlungen für KI-gestützte Rollenspiele

C.5.1 Gestufter Einstieg

Für einen pragmatischen Einstieg empfiehlt sich zunächst ein **leichtgewichtiger Modus**: vorbereitete, klar gerahmte Chat-Interaktionen mit Rollenprompts

und definierter Zielstruktur. Diese Form nutzt die Stärken von GenAI – dialogische Motivation, unmittelbares Feedback und schnelle Variantenbildung – ohne großen Mehraufwand in Technik oder Betreuung. Didaktisch bewährt sind kurze, fokussierte Fälle mit expliziten Lernzielen, Reflexionsfragen und einer einfachen Verifikationsroutine (z. B. "nenne zwei Quellen oder Gegenargumente"), damit Interaktion nicht an kritischem Denken vorbeiführt (E. R. Mollick & Mollick, 2024).

Im nächsten Schritt sollten Studierende **in Präsenz kleine Rollenspiele selbst entwerfen und testen**. Das fördert Prompt- und Rollenkompetenz, macht Modellgrenzen sichtbar und verlagert Verantwortung in die Lerngruppe. Lehrende agieren als Coach und Helfer: Sie stellen Zielkriterien, Rollenbriefe, Feedback-Raster und einfache "Challenge Cards" bereit, mit denen Gruppen ihre Szenarien iterativ verschärfen. Am Ende stehen strukturierte Debriefs mit Evidenzcheck (Wannemacher et al., 2025; Yu et al., 2025).

Im fortgeschrittenen Stadium entwickeln die Studierenden in **mehrwöchiger Einzel- oder Gruppenarbeit selbst Rollenspiele**. Sie übernehmen selbstverantwortlich und mit Anleitung die Recherche-, Entwicklungs- und Testarbeit komplexerer, realitätsnaher Rollenspiele. Hier kombinieren Teams agentenbasierte Recherche-Workflows (mehrstufige Promptketten mit Quellenprüfung), adaptives "goal play" mit Plan-/Hint-Mechaniken und Voice- bzw. VR-Interfaces für immersives Training. Wichtig sind belastbare Testprotokolle mit Störfall-Checks (Halluzination, Bias, Inkonsistenz), definierte Abbruch- und Korrekturpfade sowie dokumentierte Prompt- und Bewertungsänderungen über mehrere Iterationen. Solche Studios verbinden fachliches Urteilen, Methodenkompetenz und KI-Literacy – und sie erzeugen wiederverwendbare Lehrbausteine, die in weiteren Kohorten skaliert werden können (Goslen et al., 2025; E. R. Mollick et al., 2024; Nofal et al., 2025).

In Summe empfiehlt sich insofern ein gestaffelter Ausbau: klein starten, gemeinsam professionalisieren, komplexe Formate mit Studierenden gemeinsam entwickeln – begleitet von Reflexion, Quellen-Verifikation und klaren ethischen Leitplanken. So werden Rollenspiele und Simulationen nicht nur motivierender, sondern auch wirksamer in Hinblick auf Retention, Transfer und professionelle Handlungssicherheit.

C.5.2 Strukturierte Gestaltung

Welche Empfehlungen zur Gestaltung können wir aus Vorstudien ableiten, in denen komplexe Agenten und Rollenspiel-Szenarios entwickelt wurden?

Ein komplexes Rollenspiel beginnt mit **präzisen Lernzielen und einer interaktiven Klärung des Vorwissens**. Für die Vorbereitung bietet sich ein kurzes KI-Tutoring an, das aktivierende Aufgaben, kognitive Entlastung, Wachstumsorientierung, explizite Schritt-für-Schritt-Scaffolds, zeitnahes Feedback und Selbsttaktung kombiniert – so erreichen alle Teilnehmenden ein vergleichbares Einstiegsniveau und die Präsenzzeit kann für höherstufige Praxis genutzt werden (Kestin et al., 2025). Alternativ können Lernvideos genutzt werden, um einen gemeinsamen Wissensstand der Gruppe zum Beginn der Interaktion zu erreichen (E. R. Mollick et al., 2024).

Das eigentliche Rollenspiel folgt einem **klaren, wiederholbaren Ablauf**: Zuerst begrüßt ein KI-Mentor die Lernenden, erhebt kurz Erfahrung und Kontext und passt die Schwierigkeit an. Dann bietet die KI mehrere, zur Zielkompetenz passende Szenarien zur Auswahl und setzt narrativ die Bühne mit Rollen, Zielen und relevanten Konflikten. Die Durchführung erfolgt in klar abgegrenzten Zügen; die KI reagiert adaptiv, gibt sparsame Hinweise und drängt spätestens gegen Ende auf eine folgenschwere Entscheidung, damit Transferstrategien wirklich angewandt werden. Zum Schluss liefert die KI differenziertes, zielbezogenes Feedback mit Stärken, Entwicklungsfeldern und Hinweisen zur Anwendung im nächsten Fall. Dieses Muster lässt sich für "Role Play" (Lernende spielen eine fremde Rolle) ebenso nutzen wie für "Goal Play" (Lernende bleiben sie selbst und leiten eine Figur an, z. B. mit einem Entscheidungs- oder Zielsetzungs-Framework). Wichtig sind eine abschließende Reflektion in der Gruppe und die Anbindung an Kurskonzepte (E. R. Mollick & Mollick, 2024).

Für komplexere Settings empfiehlt sich ein **Agenten-Design mit klar getrennten Aufgaben**: Ein Mentor-Agent berät und aktiviert Vorwissen, ein weiterer Non-Player-Character (NPC) Agent spielt etwa die Gegenrolle (mit konsistenter Persona und interner Planungs- und Abschlusslogik), ein Evaluator-Agent verdichtet Leistungsdaten zu handlungsnahem Feedback, und instruktorgebundene "Progress/Insights-Agents" fassen Transkripte zu individuellen und Klassenmustern zusammen und schlagen Debrief-Aktivitäten vor. Dieses mehrstufige "Learning-Loop"-Design – Instruktion,

narrative Praxis, Feedback, Reflexion – senkt die Entwicklungshürden und skaliert Übung, bleibt aber didaktisch geführt (E. R. Mollick et al., 2024).[1]

Qualitätssicherung und systematische Tests müssen zwingend erfolgen. Testläufe prüfen Konsistenz, Schrittfolge, Robustheit gegenüber "Edge Cases", Niveaudifferenzierung, Output-Qualität und Agenten-Handovers; bei Problemen helfen zusätzliche Kontexte, Beispiele, Constraints, Erinnerungen an Ziele und, wo nötig, engere Interaktionslimits. Zudem sollten bekannte Modellrisiken – Bias, Narrativdrift, Vergessen früherer Passagen – durch Red-Teaming, präzise Rollenprompts, interne Checklisten und ein konsequentes Debrief adressiert werden (E. R. Mollick et al., 2024).

Schließlich lohnt der Rückgriff auf **Tutoring-Prinzipien** auch im Rollenspiel: Aktivierung statt Lösungsvorsage, graduelle Schrittführung ohne Überlastung, zeitnahes, zielgerichtetes Feedback und Selbsttaktung erhöhen Lerngewinne nachweislich; in der Studie von Kestin et al. lernten Studierende mit einem gut designten KI-Tutor mehr als doppelt so viel wie in einer aktiven Präsenzsitzung – ein Befund, der für die Vorbereitungs- und Zwischenphasen von komplexen Simulationen besonders relevant ist (Kestin et al., 2025).

C.5.3 Zum schnellen Start: Informationsquellen und Vorlagen

Die Sammelstellen für Prompts, Beispiele und Fortbildungen, die auch für Rollenspiele taugen, stehen gebündelt in Kapitel 5.8. Für den Einstieg in Simulationen sind dort vor allem die Blueprints von Mollick und Mollick und die Beispielsammlung des Derek Bok Center hilfreich. Direkt einsetzbar sind die beiden Vorlagen von Mollick und Mollick in Anhang B, mit KI-Mentor, Szenario, Rollenspiel und abschließendem Feedback: die Verhandlungssimulation als Role Play (Kapitel B.6.1) und die Zielsetzungsübung als Goal Play (Kapitel B.6.2) (L. Mollick & Mollick, 2024).

[1] Ähnliche verteilte Rollen werden aktuell etwa auch für Forschungsprozesse von Google entwickelt (Gottweis et al., 2025).

C.6 Update: Neuere Studien (Stand Juli 2026)

Seit Abschluss der Literaturrecherche (Kapitel C.7) sind weitere einschlägige Studien erschienen; die meisten sind inzwischen im Hauptteil eingeordnet: der lernende Prompt-Router von Chang et al. (2026) und die Designprinzipien für Lern-Agenten von Banh et al. (2026) in Kapitel 4.3, das auf echten Tutoring-Dialogen nachtrainierte Modell TeachLM (Perczel et al., 2025) in Kapitel D.7 und der Prüfungsagent AIvaluate (Yusuf et al., 2026) in Kapitel 5.4. Für Rollenspiele kommen zwei Befunde hinzu: Bei Gesprächstrainings für Führungskräfte entscheidet der von den Lernenden wahrgenommene Realismus über die Bereitschaft, das Geübte anzuwenden (Wilhelm et al., 2025), und verkörperte KI-Gegenüber in Mixed Reality wirken über kognitive und sozio-emotionale Kanäle, was die Befunde in Kapitel C.3.7 ergänzt (B. Dang & et al., 2025). Wilhelm et al. (2025), Perczel et al. (2025) und Chang et al. (2026) sind bislang nur als Preprints verfügbar. Nach Juli 2026 kamen drei Preprints zur Frage hinzu, wie echt ein simuliertes Gegenüber ist: Sprachmodelle treffen das mittlere Verhalten von Menschen, nicht den Einzelfall (Ahn et al., 2026; Kuric et al., 2026), und ein Simulator mit getrennten Agenten für Patient, Tutor und Bewertung verbesserte die Gesprächsführung von Medizinstudierenden (L. Yang et al., 2026); Kapitel 4.4.3 ordnet sie ein. Insgesamt wird die Evidenz härter, weil Feldexperimente, A/B-Tests und Design-Science-Studien an die Stelle von Positionspapieren treten, und die Simulation wird selbst zum Testinstrument: Simulierte Studierende prüfen Tutor- und Rollenspielsysteme, bevor echte Lernende ihnen begegnen (Perczel et al., 2025).

C.7 Liste der durchsuchten Fachzeitschriften

C.8 Im Jahr 2025 publizierte Fachartikel zu GenAI-Rollenspielen und Simulationen in der Lehre

Autor:innen, Titel und Zeitschriften der 16 Fachartikel stehen in der Online-Version (Abbildung C.1).

Abbildung C.1. Die 18 durchsuchten Fachzeitschriften und die 16 im Jahr 2025 publizierten Fachartikel stehen in der Online-Version dieses Anhangs: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/kapitel08-appendix03-rollenspiele-simulationen.html#sec-journals-rs aufrufen.

Transparenzhinweis

Bei der Übertragung dieses Workshop-Skripts in das Online-Format wurde Claude / Cowork zur Konvertierung, für Sprach- und Konsistenzchecks sowie zur Gestaltung des Layouts genutzt. Der Abschnitt "Update: Neuere Studien (Stand Juli 2026)" wurde mit Claude / Cowork auf Basis eines wöchentlichen Literatur-Scans (LLM Papers Radar) recherchiert und eingearbeitet. Alle Inhalte wurden von Roman Bartnik geprüft, überarbeitet und verantwortet.

D Umsetzung: Arbeitsumgebung, Agenten, Tutoren und lokale Modelle

Vorbemerkung

Dieser Anhang führt die Begriffe aus Kapitel 2 und die vier Rollen aus Kapitel 4 in die Praxis jenseits des einzelnen Chats. Wer das Buch bis hierher gelesen hat, weiß, was ein Sprachmodell, eine Wissensbasis und ein Agent sind, und kann einen Prompt nach dem CREATE-Muster schreiben. Was fehlt, ist die Werkbank: Wie richtet man die KI so ein, dass sie den eigenen Kurs kennt, bevor die erste Frage gestellt wird; wie bindet man eigene Texte an; wo greift man in eine Agentenkette ein; wie prüft man einen Tutor, den Studierende gebaut haben; und wann lohnt ein Modell auf dem eigenen Laptop.

Der Anhang entstand aus dem Aufbaukurs "Jenseits einfacher Prompts" (hdw nrw, Oktober 2026) und folgt dem Muster von Anhang C: Jeder Abschnitt beantwortet genau eine Gestaltungsfrage, stellt ein Werkzeug vor und endet mit einer Übung, die wir im Workshop erprobt haben. Je Frage ziehen wir höchstens drei Studien heran, jeweils mit einem Satz zum Befund und einem zur Methode. Die Übungen sind so gebaut, dass das Ergebnis der einen in die nächste wandert: Der System-Prompt aus der ersten erzeugt in der vierten die Folien, die Testfragen aus der dritten werden in der siebten zum Goldstandard.

Werkzeuge veralten schneller als Prinzipien. Produkt- und Modellnamen stehen deshalb nur in einem datierten Kasten in Kapitel D.2; der Fließtext bleibt bei Gattungsbegriffen wie "das Chat-Interface des Anbieters" oder "ein starkes Reasoning-Modell". Das Online-Material (Übungen als Handout, Skill-Dateien, Notizbücher, Workflow-Vorlagen) ist am Ende des Anhangs verlinkt und wird fortgeschrieben.

D.1 Warum Nutzungsmodus und Kontrollpunkte entscheiden

Ein Chat ist ein Auskunftsschalter: Wir fragen, wir lesen die Antwort, wir prüfen sofort. Ein Agent ist eine Sachbearbeiterin mit Vollmacht: Sie bekommt einen Auftrag, plant die Schritte selbst, ruft Werkzeuge auf und arbeitet länger allein, bevor wir das Ergebnis sehen. Das Wort stammt vom lateinischen *agere*, handeln; der Agent handelt in unserem Auftrag. Zwischen diesen Polen liegen die Nutzungsformen, um die es in diesem Anhang geht, und sie unterscheiden sich in einer einzigen Größe, die alles Weitere bestimmt: Wie lange arbeitet die KI, bevor ein Mensch hinsieht? Im Chat sind es Sekunden, bei einer Recherche-Agentin Minuten, bei einem automatisierten Ablauf, der nachts läuft, Stunden, und bei einem Tutor, den Studierende ohne uns benutzen, ein ganzes Semester. Je länger die Strecke ohne Blick, desto später fällt ein Fehler auf, und desto mehr Arbeit hat er bis dahin verdorben.

Daraus folgt die Gestaltungsfrage dieses Anhangs: Nicht welches Werkzeug ist das beste, sondern an welchen Stellen eines Ablaufs muss ein Mensch entscheiden, damit die Delegation trägt. Die Forschung zur Automatisierung nennt solche Stellen Kontrollpunkte; für jede Stufe einer Aufgabe lässt sich getrennt festlegen, wie viel die Maschine entscheidet und wo der Mensch das Steuer behält (Parasuraman et al., 2000). Die Logik ist alt, die Anwendung neu: In Kapitel D.4 sind es drei Punkte (Quellenkorb freigeben, Rechercheplan prüfen, Aussagen gegen das Original halten), in Kapitel D.6 ist es ein Freigabeknopf vor jedem Schritt, der Geld kostet, und in Kapitel D.7 sind es vier gestapelte Prüfschichten, weil die Strecke ohne Blick dort am längsten ist.

Dass dieser Übergang vom Chat zum Agenten tatsächlich stattfindet und nicht nur in Produktankündigungen, zeigen drei Datenquellen. Johnston et al. (2026) weisen in Nutzungsdaten eines Coding-Agenten nach, dass der Übergang vom Chat zum Agenten messbar stattfindet. Methodisch stützt sich die Arbeit auf beobachtete Nutzungsdaten statt auf Befragungen; sie ist ein Preprint ohne abgeschlossene Begutachtung. Chatterji (2025) berichten aus Unternehmensdaten, dass wiederholbare Arbeitsabläufe über Projekte und angepasste Assistenten seit Jahresbeginn 2025 um das Neunzehnfache wuchsen und rund ein Fünftel der Enterprise-Nachrichten bereits über solche strukturierten Workflows läuft, während ein Teil selbst der monatlich aktiven Nutzenden Deep Research, Reasoning und Datenanalyse noch nie verwendet hat. Die Grundlage ist ein anbietereigener Nutzungsbericht,

also keine unabhängige Studie, aber mit sehr großer Fallzahl. E. Mollick (2026a) schließlich ordnet die Werkzeuglandschaft Anfang 2026 danach, ob ein Modell einen Harness hat, also Werkzeuge nutzen und mehrstufig allein arbeiten kann, und rät, die Wahl des Werkzeugs an der Aufgabe auszurichten; das ist eine Erfahrungssynthese, keine Messung.

Für die Lehre kommt eine zweite Achse hinzu, die in Kapitel 3 entwickelt wurde: Jede Delegation verschiebt Denkarbeit, und Denkarbeit ist der Stoff, aus dem Lernen besteht. Was wir in Kapitel 3.4 als wünschenswerte Schwierigkeit beschrieben haben, wird durch eine KI, die zu früh hilft, gerade beseitigt. Deshalb liest sich die Frage nach den Kontrollpunkten für Studierende anders als für Lehrende. Für uns selbst geht es um Fehlerkontrolle: Der Agent darf viel allein tun, solange wir an festen Stellen prüfen. Für Studierende geht es um Lernkontrolle: Der Tutor darf gerade nicht viel allein tun, weil jede Hilfe, die er zu früh gibt, einen Lernschritt ersetzt. Dieselbe Technik verlangt also je nach Rolle aus Kapitel 4 entgegengesetzte Einstellungen, und genau deshalb lohnt es, die Nutzungsformen einzeln durchzugehen.

Tabelle D.1 ordnet die Abschnitte dieses Anhangs entlang der beiden Achsen: wie lange die KI allein arbeitet und wo der Mensch eingreift. Die Bilder in der zweiten Spalte kehren in den jeweiligen Abschnitten wieder; sie sind nicht Dekoration, sondern die Merkhilfe, mit der wir im Workshop die Begriffe eingeführt haben.

Nutzungsform	Bild	Wie lange die KI allein arbeitet	Wo der Mensch prüft	Abschnitt
Chat	Auskunftsschalter	Sekunden	nach jeder Antwort	Kapitel 2
Arbeitsumgebung (System-Prompt, Skill, Projekt)	Einarbeitungsmappe, Rezeptkarte	wie im Chat, aber mit Vorwissen	beim Einrichten: Regeln prüfbar formulieren	Kapitel D.2
Eigene Quellen (RAG)	Open-Book-Klausur	Sekunden	an der Fundstelle, nicht an der Antwort	Kapitel D.3
Agent (Deep Research)	Sachbearbeiterin mit Vollmacht	Minuten	drei Kontrollpunkte	Kapitel D.4

Nutzungsform	Bild	Wie lange die KI allein arbeitet	Wo der Mensch prüft	Abschnitt
Prozessmodell und Simulation	Notenblatt, Würfelexperiment	Sekunden bis Minuten	an der eigenen Vorhersage	Kapitel D.5
Automatisierter Workflow	Fließband mit Freigabeknopf	Minuten bis Stunden	vor jedem kostenpflichtigen Schritt	Kapitel D.6
Tutor für Studierende	die KI handelt ohne uns	ein Semester	vier Prüfschichten vor der Freigabe	Kapitel D.7
Lokales Modell	eigene Küche statt Lieferdienst	Sekunden	an der Stichprobe; Daten verlassen das Gerät nicht	Kapitel D.8

Tabelle D.1. Nutzungsformen generativer KI nach Dauer der Delegation und Ort der menschlichen Prüfung

Zwei Folgerungen ziehen sich durch alle Abschnitte. Erstens: Ein Agentenergebnis ist ein Entwurf, kein Befund. Das gilt umso mehr, als dieselbe Aufgabe mit denselben Einstellungen beim zweiten Lauf anders ausgehen kann; wir kommen in Kapitel D.4 mit Zahlen darauf zurück. Zweitens: Regeln, die wir der KI mitgeben, wirken nur, wenn sich ihre Einhaltung prüfen lässt. “Sei ermutigend” ist für ein Sprachmodell so dehnbar wie für eine neue Hilfskraft; “Beende jede Antwort mit einer Frage” lässt sich abhaken. Dieser Befund aus Kapitel D.2 ist der Schlüssel zu allem, was danach kommt, vom Rechercheprompt bis zum Testplan für den Tutor.

D.2 Arbeitsumgebung einrichten: Wie bringe ich der KI dauerhaft bei, was sie über meinen Kurs wissen soll?

D.2.1 Das Problem: Jedes Gespräch beginnt bei null

Wer das Chat-Interface eines Anbieters ohne Einrichtung nutzt, kennt die Szene. Neuer Chat, und wieder erklären wir: drittes Semester, Ingenieurstudierende, bitte keine Fließtextwüsten, Quellen nach APA. Dann der zweite Chat, dann der dritte. Ein beträchtlicher Teil jeder Unterhaltung geht für Einarbeitung drauf, und was in einem Chat gelernt wurde, ist im nächsten vergessen, weil das Modell zwischen Gesprächen kein Gedächtnis hat. Genau diese Einarbeitung lässt sich einmal aufschreiben und dann immer mitliefern. Die Frage ist nur, auf welche Weise, denn die Anbieter stellen dafür inzwischen vier verschiedene Bausteine bereit, die sich darin unterscheiden, was das Modell immer liest und was es nur bei Bedarf hervorholt.

D.2.2 Vier Bausteine, vier Aufgaben

Ein **System-Prompt** ist die Einarbeitungsmappe für eine neue Hilfskraft: Das Modell liest ihn vor jedem Gespräch, vollständig und ungefragt. Dort gehören die Dinge hin, die immer gelten sollen: Fach, Zielgruppe, bevorzugte Formate, Zitierstil, Tabuzonen. In den Chat-Interfaces der Anbieter heißt dieser Baustein meist “Personalisierung” oder “benutzerdefinierte Anweisungen”; das Feld ist kurz, oft nur wenige hundert Wörter, und genau das ist seine Stärke, denn alles darin kostet in jedem Gespräch Aufmerksamkeit des Modells. Der Prompt B.1.5 in Kapitel B.1.2 erzeugt einen solchen System-Prompt im Interview: Er fragt eine Frage pro Nachricht, baut aus den Antworten eine Profilkarte und gibt am Ende den fertigen Text im Codeblock aus.

Ein **Skill** ist eine Rezeptkarte für einen wiederkehrenden Ablauf: eine Anleitung, oft mit Beispielen und manchmal mit Code, die die KI nur aufschlägt, wenn die Aufgabe dazu passt. Anders als der System-Prompt liegt ein Skill nicht ständig auf dem Tisch; sichtbar ist nur der Reiter mit Namen und Kurzbeschreibung, und erst wenn eine Anfrage dazu passt oder wir den Skill ausdrücklich aufrufen, liest das Modell den Rest. Das Format ist inzwischen offen gelegt: Ein Skill ist ein Ordner mit einer

Datei `SKILL.md`, deren Kopf aus einem Namen in Kleinbuchstaben und einer Beschreibung besteht, die sagt, was der Skill tut und wann er gilt; darunter steht die eigentliche Anleitung, daneben liegen optional Referenzdateien und Skripte (Anthropic, 2025d). Weil mehrere Anbieter dasselbe Format lesen, läuft ein einmal geschriebener Skill-Ordner in verschiedenen Werkzeugen (OpenAI, 2025).

Eine **Verbindung**, in manchen Interfaces "App" oder "Konnektor" genannt, ist das Kabel mit Stecker zu einem anderen Dienst: zum Cloud-Speicher, zum Kalender, zum Bibliothekskatalog. Technisch steckt dahinter meist ein MCP-Server. MCP (Model Context Protocol) ist die genormte Steckdose, über die ein KI-Assistent fremde Werkzeuge anspricht, so wie ein Eurostecker in jede europäische Dose passt; wer einen Dienst einmal als MCP-Server anbietet, macht ihn für alle Assistenten erreichbar, die die Norm beherrschen. In Kapitel 4.1.2 haben wir gesehen, was das für die akademische Suche bedeutet: lizenzkonformer Zugriff auf Volltexte, ohne das Modell selbst zu verändern (Tay, 2024b).

Ein **Plugin** schließlich ist der Werkzeugkoffer, der mehrere Skills und Verbindungen bündelt. Das Plugin selbst löst nichts aus; man installiert den Koffer, und das Modell greift bei Bedarf zu den einzelnen Werkzeugen.

Ein fünfter Baustein steht quer zu den vieren und ist für die Lehre oft der wichtigste: das **Projekt**. Ein Projekt ist ein Ordner mit einem Notizzettel obendrauf: Ein Anleitungsfeld, das das Modell in jeder Runde vollständig liest, und Dateien, die es per Suche heranzieht, gestückelt und ohne Garantie, dass es die richtige Stelle findet. Damit leistet ein Projekt fast dasselbe wie ein Skill, nur auf andere Weise: Die Anleitung liegt ständig auf dem Tisch statt im Karteikasten. Wer in seinem Tarif keine Skills hat, baut den Skill als Projekt nach, mit der Anleitung im Anweisungsfeld und den Beispielen als Dateien. Tabelle D.2 fasst zusammen, was das Modell wann liest; diese Spalte entscheidet darüber, wohin eine Regel gehört.

Baustein	Bild für die Lehre	Was das Modell wann liest
System-Prompt	Einarbeitungsmappe	immer, vor jedem Gespräch, vollständig
Projekt	Ordner mit Notizzettel obendrauf	Anleitung jede Runde vollständig; Dateien nur per Suche, gestückelt

Baustein	Bild für die Lehre	Was das Modell wann liest
Skill	Rezeptkarte im Karteikasten	nur Name und Beschreibung ständig; der Rest, wenn die Anfrage passt oder der Skill aufgerufen wird
Verbindung (App, MCP-Server)	Kabel mit Stecker zu einem fremden Gerät	wird aufgerufen, wenn eine Aufgabe den Dienst braucht
Plugin	Werkzeugkoffer	löst selbst nichts aus; bündelt Skills und Verbindungen

Tabelle D.2. Fünf Bausteine einer dauerhaften Arbeitsumgebung und was das Modell davon wann liest

Die Merkregel, die aus der Tabelle folgt, lautet: Was immer gelten muss, gehört in den System-Prompt oder die Projektanleitung; Beispiele und Material gehören in eine Datei daneben; ein wiederkehrender Ablauf mit eigenen Regeln wird zum Skill. Genau nach diesem Muster ist auch der Tutor in Kapitel D.7 gebaut.

D.2.3 Die Evidenz: Prüfbare Regeln werden befolgt

Wie zuverlässig hält sich ein Modell an das, was wir ihm in die Einarbeitungsmappe schreiben? Nepal et al. (2026) haben das in einem randomisierten Versuch geprüft, indem sie einen Reflexions-Bot gegen seinen eigenen System-Prompt auditierten: Für jede Regel des Prompts wurde gemessen, ob die Antworten sie einhielten. Der Befund steckt im Titel der Arbeit, treu dort, wo es sich prüfen lässt: Regeln, deren Einhaltung sich leicht feststellen ließ, wurden zuverlässig befolgt, vage Haltungsregeln dagegen nicht. Die Arbeit ist ein Preprint ohne abgeschlossene Begutachtung, und die folgenden Beispiele stammen von uns, nicht aus der Studie. Eine Regel wie "höchstens drei Sätze" wird gehalten; eine Regel wie "sei ermutigend" ist für den Bot so dehnbar wie für eine neue Hilfskraft, die wir am ersten Tag bitten, freundlich zu sein. Die Lehre für das Einrichten ist einfach und folgenreich: Wir schreiben Regeln, die man abhaken kann. "Jede Folie trägt eine vollständige Quelle" lässt sich

abhaken, "gute Folien" nicht; "Ende jede Antwort mit einer Frage" lässt sich abhaken, "sei sokratisch" nicht. Der Partnertest in Übung Ü1 prüft genau das: Eine Kollegin sucht in unserem Skill eine Regel, die sich abhaken lässt, und testet, ob der Bot sie bricht.

D.2.4 Das Werkzeug: Der Skill `folien-evidenzbasiert`

Als Beispiel für einen Skill, der eine wiederkehrende Lehraufgabe mit eigenen Regeln regelt, dient unser Folien-Skill. KI-Werkzeuge erzeugen auf Knopfdruck Foliensätze, und fast immer Textwüsten: Themenüberschriften, Aufzählungen, dekorative Bilder. Die Forschung zur kognitiven Belastung erklärt, warum das schadet: Text, den die Vortragende gleichzeitig spricht, konkurriert mit der gesprochenen Erklärung um dieselbe Verarbeitungsspur im Arbeitsgedächtnis (Mayer & Fiorella, 2014; Sweller, 2011). Wecker (2012) hat den Effekt in Experimenten mit Studierenden gemessen: Textreiche Folien unterdrückten die Aufnahme der gesprochenen Information, während Folien mit wenigen Stichworten sie nicht beeinträchtigten. Der Skill übersetzt diese Forschung in Regeln, die sich abhaken lassen. Jede Folie trägt einen Aussagetitel, also einen ganzen Satz mit genau einer Behauptung; der Folienkörper enthält höchstens fünfzehn Wörter und eine Visualisierung, die den Titel belegt; jede Inhaltsfolie nennt genau eine vollständige Quelle mit DOI; komplexe Abläufe werden schrittweise aufgebaut; und direkt nach der Titelfolie steht eine Argumentationsübersicht in vier Blöcken, Problem, Konzepte, Evidenz, Fazit, die das Modell der vortragenden Person zur Freigabe vorlegen muss, bevor es eine einzige Folie baut. Eine Stil-Ebene mit Platzhaltern für Akzentfarbe, Schrift und Logo wird durch das Corporate Design der eigenen Hochschule ersetzt; die Inhaltsregeln bleiben unverändert. Den Kopf der Datei zeigt der folgende Auszug; die vollständige Datei mit allen Regeln, der Checkliste pro Folie und der Evidenzbasis liegt im Online-Material.

```
---
name: folien-evidenzbasiert
description: Erstellt evidenzbasierte Foliensätze
  für Lehre und Vorträge mit
  Argumentationsübersicht, Aussagetiteln,
  visueller Evidenz, schrittweisem
  Aufbau und vollständiger Quellenangabe pro
  Folie.
```

```
---

# Evidenzbasierte Folien – Inhaltsregeln mit
  anpassbarer Stil-Ebene

Rangfolge bei Konflikten: ausdrücklicher Wunsch der
  vortragenden Person >
Corporate Design der eigenen Hochschule (Abschnitt
  9) > alle übrigen Regeln
dieser Datei > Standardvorgaben des Werkzeugs (z.
  B. „Icons hinzufügen").

## 1. Arbeitsablauf (keinen Schritt überspringen)

1. Eingaben klären: Zielgruppe und Vorwissen,
  Dauer, Sprache, Ausgabeformat,
    verfügbare Quellen, eigene Folienvorlage.
2. Zuerst die Argumentationsübersicht schreiben
  (Abschnitt 2) und der
    vortragenden Person zur Freigabe vorlegen,
  bevor eine einzige Folie
    gebaut wird.
3. Storyboard („Ghost Deck") als Tabelle, eine
  Zeile pro Folie.
4. Sprechernotizen schreiben, bevor die Folien
  gestaltet werden.
5. Folien bauen.
6. Jede Folie als Bild rendern und prüfen,
  Checkliste (Abschnitt 11)
    anwenden, korrigieren, erneut rendern. Jede
  Quelle vor der Verwendung
    verifizieren (DOI löst auf, Metadaten stimmen).
```

Der didaktische Kern des Skills liegt nicht in den Folienregeln, sondern im zweiten Schritt des Arbeitsablaufs. Die Argumentationsübersicht ist der Moment, in dem die Lehrperson denkt: Stimmt das Problem für diese Studierenden, sind die Konzepte die, die wir lehren, gibt es die genannte Evidenz wirklich? Der Skill erzwingt diesen Moment, ersetzt ihn aber nicht; die KI kann eine Struktur vorschlagen, aber nicht beurteilen, ob sie für diesen Kurs trägt. Im Workshop hat sich dafür eine Folge aus zwei Runden bewährt: erst derselbe Prompt ohne Skill, dessen Ergebnis mit einem Kurzcheck markiert wird (ganzer Satz als Titel, höchstens fünfzehn Wörter, Visualisierung belegt den Titel, jede Quelle existiert), dann derselbe

Prompt mit Skill und einer selbst überarbeiteten Argumentationsübersicht. Auch mit Skill erfinden Werkzeuge Quellen; deshalb endet jede Runde damit, dass eine DOI geöffnet wird.

Zum Laden gibt es zwei Wege. Wo das Interface Skills kennt, wird der Ordner als ZIP hochgeladen und aktiviert. Überall sonst hängt man die Datei an den Chat oder kopiert ihren Inhalt in die Projektanleitung, mit dem Satz "Befolge diese Anleitung für alle Foliensätze"; das funktioniert in jedem Werkzeug, das Dateien liest. Wer die eigene Folienvorlage einbinden will, lädt sie mit dem Hinweis hoch, dass sie die Stil-Ebene ersetzt.

i Stand bei Drucklegung, Oktober 2026

Die Bausteine dieses Abschnitts heißen bei jedem Anbieter anders und sind an Tarife gebunden; dieser Kasten hält den Sachstand zum Zeitpunkt der Drucklegung fest. Die Online-Version wird fortgeschrieben.

Skills in ChatGPT gibt es seit Juli 2026 nur in den Tarifen Business, Enterprise, Healthcare und Edu, nicht in Plus (OpenAI Help Center, "Skills in ChatGPT", https://help.openai.com/en/articles/20001066; The AI Career Lab, 20.07.2026, https://theaicareerlab.com/blog/chatgpt-skills-what-they-are-how-to-enable-2026). Ob der Reiter *Plugins* → *Skills* im eigenen Konto erscheint, prüft man am besten selbst. Mit Plus richtet man stattdessen ein Projekt mit Anleitung und Dateien ein. Das `SKILL.md`-Format stammt von Anthropic (Anthropic, 2025d) und wird auch im Skills-Katalog für Codex genutzt (OpenAI, 2025); ein Skill-Ordner läuft deshalb in ChatGPT und in Claude.

Custom GPTs werden am 11.12.2026 abgeschaltet; beim Umzug wird die Anleitung zum Skill, Wissensdateien werden zu Referenzdateien, eigene Actions gehen verloren (OpenAI Help Center, "Custom GPT retirement FAQ", https://help.openai.com/articles/20001519). Der Zwei-Datei-Tutor in Kapitel D.7 ist bewusst so gebaut, dass er davon nicht betroffen ist.

NotebookLM heißt inzwischen Gemini Notebook. Litmaps hat ResearchRabbit übernommen; Scite bietet seit August 2026 einen kostenlosen Zugang über MCP; Google Scholar Labs sucht nach einer Forschungsfrage statt nach Stichworten; Elicit screent auf Ebene einzelner Einschlusskriterien (Fiorio, 19.09.2026, https://effortlessacademic.com/the-best-ai-tools-for-literature-review-in-2026/). Das

Vierfelderschema aus Kapitel 4.1.2 trägt weiter.
Lokale Modelle (Kapitel D.8): Auf Laptops mit 8 GB Arbeitsspeicher laufen Modelle der 4B-Klasse, etwa Gemma 3 4B (2,4 GB Dateigröße), Phi-4 Mini oder Llama 3.2 3B; mit 16 GB Qwen 3.5 9B (5,4 GB) oder Gemma 4 E4B (LLM Configurator, 25.08.2026, https://llmconfigurator.com/en/reports/best-small-llms-8gb-16gb-ram-laptops).
Workflow-Vorlagen (Kapitel D.6 und Kapitel D.9) nutzen als Textmodell ein kleines Reasoning-Modell (gpt-5-mini) und als Bildmodell Seedream 5.0 Flash (0,018 $ je Bild laut Anbieterkonsole, 11.10.2026); die Filmvariante Seedance 2.5.

D.2.5 Übung Ü1: Eigener Werkzeugkasten, System-Prompt und ein Skill

Übung Ü1: Eigener Werkzeugkasten

Aufgabe: Einen persönlichen System-Prompt erstellen und einen Skill (oder ein Projekt als Skill-Ersatz) einrichten, den eine Kollegin an einer prüfbaren Regel testet. Ergebnis: ein System-Prompt und ein getesteter Skill, der in Ü3 wiederverwendet wird.
Tool: Chat-Interface des Anbieters (Plus-Tarif genügt), Prompt-Sammlung in Anhang B.
Zeit: 45 Minuten.
Sozialform: Einzelarbeit, am Ende Partnertest.

1. **System-Prompt (20 min).** Prompt B.1.5 “Hiwi: System-Prompt für typische Anforderungen erstellen” (Kapitel B.1.2) in einen neuen Chat kopieren. Der Prompt erstellt aus dem Profiltext eine Profilkarte, führt ein Interview mit einer Frage pro Nachricht und gibt am Ende den fertigen System-Prompt im Codeblock aus. Lehrprofil einfügen, aber ohne Namen und Kontaktdaten. Ergebnis unter Einstellungen → Personalisierung oder als Anweisung eines Projekts einsetzen.
2. **Ein Skill nach Wahl (20 min).** Variante a: Die Datei des Folien-Skills in ein neues Projekt laden und als Anweisung eintragen: “Wende die Regeln aus der Datei auf jede Folienanfrage an.” Mit einem Thema aus der nächsten Vorlesung testen. Variante b: Prompt B.1.2 “Aktivierungs-Coach für die Präsenzlehre”

(Kapitel B.1.1) als Projekt einrichten und an einer eigenen 90-Minuten-Sitzung testen.

3. **Partnertest (5 min).** Die Nachbarin testet den Skill mit ihrem eigenen Thema und prüft eine Regel, die sich abhaken lässt, etwa "Jede Folie trägt eine vollständige Quelle" oder "Jede Aktivität nennt ihr Lernziel". Testauftrag: "Erstelle mit deinen Regeln [5 Folien | einen Aktivierungsplan] zum Thema [Thema der Partnerin], Zielgruppe [Semester/Studiengang], 90 Minuten."

4D	In dieser Übung
Delegation	Die KI formuliert den Prompt und die Folien; wir entscheiden, welche Regeln gelten.
Description	Profilkarte und Interview liefern den Kontext; Regeln so formulieren, dass man sie abhaken kann.
Discernment	Der Partnertest zeigt, welche Regel der Bot bricht.
Diligence	Keine Namen, Kontaktdaten oder Studierendendaten im System-Prompt.

Wenn es hakt. Das Feld in der Personalisierung ist zu kurz: B.1.5 liefert zwei Felder mit je rund 1.500 Zeichen; um eine Kurzfassung bitten. Kein Skills-Reiter sichtbar: Ein Projekt anlegen (Seitenleiste → Neues Projekt → Anweisungen und Dateien). Der Bot ignoriert eine Regel: positiv und prüfbar umformulieren und erneut testen.
Debrief. Welche Regel hat der Bot gebrochen, und wie lässt sie sich prüfbar umformulieren?

D.3 Eigene Quellen anbinden: Wie antwortet die KI aus meinen Texten statt aus dem Netz?

Ein Sprachmodell ohne eigene Quellen schreibt eine Closed-Book-Klausur: Es hat beim Training viel gelesen und antwortet aus dem Gedächtnis, ohne Seitenzahl. RAG, Retrieval-Augmented Generation oder auf Deutsch etwa

Abbildung D.1. Online-Material zu Übung Ü1: Übungsblatt, Skill-Datei `folien-evidenzbasiert` und Übungsanleitung. QR-Code scannen oder die Online-Version aufrufen.

abrufgestützte Erzeugung, macht daraus die Open-Book-Klausur. Die Frage geht zuerst an die Suche, den Retriever; er ist der Bibliothekar, der die passenden Stellen aus unserem Ordner holt, der Wissensbasis. Erst dann formuliert das Sprachmodell, der Generator, die Antwort, und im besten Fall nennt es die Fundstelle. Die Grundbegriffe dazu stehen in Kapitel 2.1.3; hier geht es um die Frage, wie wir prüfen, ob die Anbindung hält. Die schlechte Nachricht vorweg: Halluzinationen verschwinden mit RAG nicht, sie wandern. Entweder findet die Suche die falsche Stelle, und das Modell formuliert sauber darauf aufbauend Unsinn, oder die Stelle stimmt, und das Modell liest sie falsch. Deshalb testen wir in diesem Abschnitt vor allem, was passiert, wenn die Antwort nicht in den Quellen steht.

Die Kette hat zwei Stellen, an denen es reißen kann, und beide lassen sich getrennt prüfen: Findet die Suche die richtigen Stellen (Kontextrelevanz), und bleibt die Antwort bei dem, was in den Stellen steht (Antworttreue)? Werkzeuge wie RAGAs messen genau diese beiden Größen getrennt (Es et al., 2024); das Verfahren selbst geht auf Lewis et al. (2020) zurück. Für die Lehre ist die zweite Prüfung die wichtigere, und sie braucht eine Frage, auf die die richtige Antwort „steht nicht drin“ lautet. Die Idee stammt aus dem Datensatz SQuAD 2.0, der Lesemodelle gezielt mit unbeantwortbaren Fragen prüft (Rajpurkar et al., 2018): Ein System, das jede Frage beantwortet, ist in der Lehre gefährlicher als eines, das manchmal schweigt.

Dass sich die Mühe lohnt, zeigt ein Vergleich in einem Pflichtmodul Volkswirtschaftslehre im ersten Studienjahr: Eine Kohorte erhielt KI-erzeugte Podcasts, FAQ und Quiz-Lernhilfen, die ein quellengebundenes Modell aus den Kursmaterialien erzeugt hatte und eine namentlich

verantwortliche Tutorin vor der Freigabe geprüft hatte. Die Lernhilfen hoben die Prüfungsleistung im Mittel leicht und senkten den Anteil schwacher Ergebnisse deutlich; die Autoren erklären das damit, dass die Prüfung vor der Freigabe die Urteilslast von den Studierenden auf eine verantwortliche Person verlagert [C. T. Dang & Nguyen (2026); Preprint, Zwei-Kohorten-Vergleich]. Quellenbindung allein genügt also nicht; sie macht die Prüfung möglich, die dann jemand übernehmen muss.

Der zweite Engpass liegt vor der Technik: Wer gibt die Materialien frei? In einer Befragung Lehrender an deutschen Hochschulen würden zwei Drittel ihre Lehrmaterialien für einen hochschuleigenen Tutor bereitstellen, ein Drittel nicht; die Bedingungen der Bereitwilligen sind das Urheberrecht und die Zusicherung, dass mit dem Material kein Modell trainiert wird (Brandenburger et al., 2026). Beides lässt sich einlösen, und die Rechtshandreichung des Hochschulforums Digitalisierung sagt, wie: Ein Tutor, der über System-Prompt und angebundene Quellen aus den Materialien antwortet, verändert das KI-System nicht und bleibt im Rahmen der Nutzung eines bestehenden Systems; erst das Nachtrainieren wäre eine Veränderung mit Anbieterpflichten. Für fremde Texte gilt die Schranke für Unterricht und Lehre, also höchstens 15 Prozent eines Werks, und für eigene Skripte die Zusage an die Kolleginnen und Kollegen, dass die Wissensbasis nicht ins Training fließt (Baresel et al., 2026). Für die Übung heißt das: Der Korpus besteht aus eigenen Texten oder offen lizenzierten Quellen, und die Anweisung an das Modell nennt die Grenze ausdrücklich.

D.3.1 Das Werkzeug: Quellengebundene Notizbücher und Projekte

Zwei Werkzeugklassen machen RAG ohne Programmierung zugänglich, und die Übung nutzt beide nebeneinander, damit der Unterschied sichtbar wird. Ein quellengebundenes Notizbuch wie Gemini Notebook (früher NotebookLM) nimmt einen Korpus aus PDFs, Webseiten und Notizen auf, antwortet nur aus diesem Korpus und zeigt zu jeder Aussage die Fundstelle, auf die sich ein Klick lohnt; aus demselben Korpus erzeugt es auf Wunsch Audio-Dialoge, Lernkarten oder Zusammenfassungen, die sich als Lernhilfen weiterreichen lassen, mit der Prüfpflicht aus dem vorigen Absatz. Ein Projekt im Chat-Interface des Anbieters ist die zweite Klasse: ein Ordner mit Dateien und einer dauerhaften Anweisung, die für jede Unterhaltung darin gilt. Die Anweisung aus Ü2 ist bewusst knapp und erlaubt dem Modell ausdrücklich zu schweigen; sie steht im Übungskasten.

Beide Klassen scheitern an derselben Stelle: Gescannte PDFs ohne Textebene liefern der Suche nichts, was sie finden könnte, und das Modell antwortet dann aus dem Gedächtnis, als gäbe es die Datei nicht. Vor dem Hochladen lohnt deshalb ein Test, ob sich im PDF Text markieren lässt.

D.3.2 Übung Ü2: Antwortbar oder nicht? KI mit eigenen Quellen

Übung Ü2: Antwortbar oder nicht?

Aufgabe: Ein eigenes Skriptkapitel in zwei quellengebundene Werkzeuge laden und beiden fünf Fragen stellen, zwei davon als Falle. Ergebnis: eine Tabelle mit fünf Testfragen, die erste Zeile eines Goldstandards für Ü6.
Tool: Gemini Notebook (ehemals NotebookLM) und ein Projekt im Chat-Interface des Anbieters, parallel.
Zeit: 20 Minuten.
Sozialform: Einzel- oder Partnerarbeit.

1. **Quelle laden (3 min).** Ein eigenes Skriptkapitel als PDF in ein neues Notebook und zugleich als Datei in ein neues Projekt laden. Ersatz: OpenStax, *Principles of Economics*, Kapitel 2.
2. **Fünf Fragen an beide Werkzeuge (12 min).** Vorher notieren, was die richtige Antwort wäre. Drei Fragen, die das Kapitel beantwortet; die angegebene Fundstelle prüfen. Eine plausible Frage, die das Kapitel nicht beantwortet: Sagt das Werkzeug "steht nicht drin" oder erfindet es? Eine Frage mit falscher Prämisse, etwa "Warum steigt laut Kapitel die Nachfrage, wenn der Preis steigt?": Widerspricht das Werkzeug?
3. **Urteil eintragen (5 min).** Urteile: richtig · richtig, falsche Fundstelle · erfunden · Prämisse übernommen.

Anweisung für das Projekt:

```
Beantworte Fragen ausschließlich aus den Dateien
  in diesem Projekt. Nenne zu
jeder Aussage die Seite. Wenn die Dateien eine
  Frage nicht beantworten,
schreibe genau: „Steht nicht in den Quellen." Wenn
  eine Frage auf einer
falschen Annahme beruht, sage das zuerst.
```

Nr.	Frage	Erwartete Antwort	Fundstelle	Notebook	Projekt
1					
2					
3					
4 (nicht im Text)		“Steht nicht drin”	–		
5 (falsche Prämisse)		Widerspruch			

4D	In dieser Übung
Delegation	Das Werkzeug sucht und formuliert; wir legen fest, was als richtig gilt.
Description	Die Projektanweisung erlaubt ausdrücklich “Steht nicht in den Quellen”.
Discernment	Jede Fundstelle im Original nachschlagen, nicht nur die Antwort lesen.
Diligence	Nur eigenes oder offen lizenziertes Material hochladen, keine Studierendenarbeiten.

Wenn es hakt. Das PDF lädt nicht: Gescannte PDFs ohne Textebene funktionieren schlecht; den Ersatztext nehmen. Beide Werkzeuge bestehen alles: Frage 4 näher am Kapitelthema wählen, etwa eine Zahl, die im Kapitel fehlt.
Debrief. Welches Werkzeug hat bei der unbeantwortbaren Frage gepasst, und welches hat erfunden?

D.4 Agenten und akademische Suche: Wo müssen Menschen eingreifen, damit eine Agentenkette nicht entgleist?

Ein Agent arbeitet länger allein als ein Chat, und Fehler fallen später auf; das war die Ausgangsthese aus Kapitel D.1. Für die akademische Recherche heißt das: Ein Deep-Research-Agent, der frei im Netz sucht, liefert einen flüssigen Bericht mit Quellen, von denen einige nicht existieren, andere

Abbildung D.2. Online-Material zu Übung Ü2: Übungsblatt mit Tabellenvorlage. QR-Code scannen oder die Online-Version aufrufen.

nicht das sagen, was der Bericht behauptet, und ein dritter Teil hinter einer Bezahlschranke liegt, die der Agent nie passiert hat. Die Gegenstrategie dieses Abschnitts dreht die Reihenfolge um: erst den Quellenkorb festlegen, dann den Agenten arbeiten lassen, und an drei festen Stellen prüfen. Wie dringend das ist, zeigt ein Befund von Figalová et al. (2026): Zwei nominal gleich eingestellte KI-Screening-Läufe für ein Scoping Review kamen bei 94 Datensätzen zu unterschiedlichen Urteilen; gemessen wurde die Übereinstimmung zwischen Lauf und Lauf sowie zwischen Modell und menschlichen Screenern, in einem Preprint. Ein Agentenergebnis ist also ein Entwurf, kein Befund, und Wiederholbarkeit ist bei Agenten nicht selbstverständlich.

Die drei Kontrollpunkte folgen einer Regel aus der Automatisierungsforschung: Wo ein System selbständig handelt, gehört menschliche Prüfung an die Stellen, an denen Fehler am teuersten wären und am leichtesten zu erkennen sind (Parasuraman et al., 2000). Für eine Recherchekette sind das die Auswahl der Quellen, der Plan des Agenten und die Aussagen im Ergebnis. Erstens der Quellenkorb: Jede DOI wird geöffnet, bevor der Agent sie bekommt; was sich nicht öffnen lässt, fliegt heraus. Zweitens der Rechercheplan: Deep-Research-Modi legen vor dem Start einen Plan vor, und wer ihn liest und ändert, hält den Agenten im Korb, statt ihn ins offene Netz zu lassen. Drittens die Prüfung: Drei Aussagen aus dem Bericht werden gegen das Original gehalten, mit der Doppelfrage, ob die Quelle stimmt und ob die Aussage in ihr steht. Die vier Suchtypen aus Kapitel 4.1.2, von der einmaligen Suche bis zur Deep Research, bleiben die Landkarte; neu ist, dass der Agent zwischen den Typen selbst wechselt und wir deshalb die Übergänge prüfen müssen, nicht nur das Ergebnis.

Der Bibliothekar Aaron Tay, dessen Blog die akademische KI-Suche seit Jahren begleitet, beschreibt dieselbe Verschiebung aus der Praxis: von festen Suchabläufen, in denen der Mensch jeden Schritt auslöst, zu agentischen Abläufen, in denen das System die Schritte wählt und der Mensch die Regeln setzt (Tay, 2025). Seine Konsequenz deckt sich mit den Kontrollpunkten: Nicht der Prompt entscheidet über die Qualität einer Agentenrecherche, sondern die Begrenzung des Suchraums und die Prüfregeln, die der Agent einhalten muss.

D.4.1 Das Werkzeug: Deep Research auf einem geprüften Quellenkorb

Deep Research ist der Agentenmodus der großen Chat-Interfaces für Recherchen: Er legt einen Plan vor, sucht, liest, verwirft und schreibt zehn bis dreißig Minuten lang allein und liefert einen belegten Bericht. Frei eingesetzt sucht er im offenen Netz; mit dem zweiten Prompt aus Ü3 wird er auf den geprüften Korb begrenzt und erhält die Erlaubnis, „Lücke“ zu schreiben, statt weiterzusuchen. Der Plan, den er vor dem Start zeigt, ist der zweite Kontrollpunkt; ändern lässt er sich im Dialog, bevor der Lauf beginnt. Für die Übung gibt es zwei Rückfallebenen: Wer in der Wartezeit nicht leer laufen will, arbeitet mit einem vorbereiteten Beispielbericht aus dem Online-Material weiter; wer keinen Deep-Research-Modus im Menü hat, nutzt den Agentenmodus oder einen gewöhnlichen Chat mit Websuche und demselben Prompt. Das Ergebnis ist in allen Fällen dasselbe: ein Entwurf, der erst nach dem dritten Kontrollpunkt zu Folien werden darf.

D.4.2 Übung Ü3: Vom Quellenkorb zur Foliensequenz mit drei Kontrollpunkten

Übung Ü3: Vom Quellenkorb zur Foliensequenz

Aufgabe: Einen Agenten einen mehrstufigen Ablauf ausführen lassen (Quellen festlegen, recherchieren, Folien bauen) und dabei drei menschliche Kontrollpunkte setzen. Ergebnis: ein geprüfter Quellenkorb, ein belegter Kurzbericht und fünf Folien mit je einer vollständigen Quellenzeile.
Tool: Chat-Interface des Anbieters mit Deep Research (Agentenmodus), Elicit oder Google Scholar Labs, der Folien-Skill aus

Ü1.
Zeit: 40 Minuten.
Sozialform: Einzel- oder Partnerarbeit.

1. **Quellenkorb im Dialog (10 min).** Die KI stellt die Fragen und schlägt 8 bis 12 Quellen vor. Streichen, aus Elicit oder Scholar Labs ergänzen. **Kontrollpunkt 1:** Jede DOI öffnen. Was sich nicht öffnen lässt, fliegt raus.
2. **Deep Research auf dem Korb (15 min, läuft im Hintergrund).** Mit dem zweiten Prompt starten. **Kontrollpunkt 2:** Den Rechercheplan lesen, bevor er freigegeben wird, und ändern, wenn er den Korb verlässt.
3. **Prüfen (8 min).** Drei Aussagen aus dem Bericht gegen das Original halten. **Kontrollpunkt 3:** Stimmt die Quelle, und stimmt die Aussage?
4. **Folien (7 min).** Der Folien-Skill aus Ü1 macht aus dem geprüften Bericht fünf Folien.

Prompt 1, Quellenkorb:

```
Ich baue einen Quellenkorb für eine Lehreinheit.
  Stelle mir nacheinander drei
Fragen (Thema, Zielgruppe, Zeitraum der
  Literatur). Schlage danach 8–12
Quellen vor: bevorzugt begutachtete
  Zeitschriftenartikel, jeweils mit
vollständiger APA-Angabe und DOI. Kennzeichne jede
  Quelle, bei der du dir
nicht sicher bist, ob sie existiert.
```

Prompt 2, Deep Research:

```
Nutze ausschließlich die folgenden Quellen:
  [geprüfte Liste einfügen].
Schreibe einen Bericht von höchstens 800 Wörtern
  zur Frage [Forschungsfrage].
Belege jede Aussage mit Autor, Jahr und Seite. Wo
  der Korb eine Frage nicht
beantwortet, schreibe „Lücke" statt
  weiterzusuchen.
```

Prompt 3, Folien:

```
Mache aus diesem Bericht fünf Folien nach den
  Regeln meines Folien-Skills.
Jede Folie: Aussagetitel als ganzer Satz,
  höchstens 15 Wörter Folientext,
eine vollständige Quellenzeile.
```

4D	In dieser Übung
Delegation	Der Agent sucht, liest und schreibt; wir bestimmen den Korb und geben den Plan frei.
Description	Der Prompt begrenzt den Agenten auf den Korb und erlaubt "Lücke".
Discernment	Drei Kontrollpunkte: DOI geöffnet, Plan geprüft, Aussage gegen Original gehalten.
Diligence	Wir verantworten jede Quelle auf der Folie, nicht der Agent.

Wenn es hakt. Deep Research braucht oft 10 bis 30 Minuten; in der Wartezeit mit dem bereitgestellten Beispielbericht an Schritt 3 und 4 weiterarbeiten. Kein Deep Research im Menü: Agentenmodus oder normaler Chat mit Websuche und demselben Prompt 2. Mehrere DOIs führen ins Leere: Das ist der Befund der Übung; durch Treffer aus Elicit ersetzen.
Debrief. An welchem Kontrollpunkt hätte der Agent ohne uns danebengelegen?

D.5 Prozesse sichtbar machen: Wie wird aus einer Prozessbeschreibung ein prüfbares Modell?

Aus einem einzigen Text entstehen mit KI drei Darstellungen desselben Ablaufs, und erst ihr Vergleich macht das Modell prüfbar. BPMN (Business Process Model and Notation) ist eine genormte Bildsprache für Abläufe, so eindeutig wie Verkehrszeichen: Kästen für Tätigkeiten, Rauten für Entscheidungen, Kreise für Anfang und Ende. Die Datei dahinter ist reiner Text; das Bild entsteht erst, wenn ein Programm den Text liest, wie

Abbildung D.3. Online-Material zu Übung Ü3: Übungsblatt mit den drei Prompts und Beispielbericht. QR-Code scannen oder die Online-Version aufrufen.

ein Notenblatt erst im Spiel zu Musik wird. Die Animation ist der Film: Fälle wandern als Punkte von Station zu Station, und vor dem Engpass wächst die Schlange. Die Simulation ist das Würfelexperiment: hundert Durchläufe mit zufällig schwankenden Zeiten, am Ende Auslastung und Wartezeit je Station. Sie läuft in einem Notebook, einem Python-Notizbuch im Browser, für das der Anbieter den Rechner stellt, sodass niemand etwas installieren muss. Der didaktische Kern liegt in einem Schritt, der vor allen drei Darstellungen kommt: Wo liegt der Engpass? Wer die eigene Vorhersage notiert, bevor die Maschine rechnet, sieht danach, ob Animation und Simulation ihm recht geben oder widersprechen, und an welcher Annahme der Widerspruch hängt.

Der Weg von der Beschreibung zum Bild hat einen Stolperstein, den jede Gruppe im Workshop einmal getroffen hat. Eine KI-erzeugte BPMN-Datei enthält die Logik des Prozesses, aber kein Layout, also keine Angabe, wo welcher Kasten auf dem Blatt liegt; der Betrachter demo.bpmn.io meldet dann „no diagram to display“. Eine Auto-Layout-Seite der bpmn.io-Entwickler ergänzt die Positionen in einem Schritt. Fehlen in der Datei je Knoten die Verweise auf eingehende und ausgehende Pfeile, stapeln sich die Kästen ohne Verbindungen; Schwimmbahnen für Zuständigkeiten verwirft das Auto-Layout und sie werden danach von Hand ergänzt. Die Simulation läuft in Google Colab mit der Bibliothek SimPy: Ankünfte und Bearbeitungszeiten schwanken zufällig um die angenommenen Mittelwerte, ein fester Startwert macht den Lauf wiederholbar, und am Ende steht je Station eine Zeile mit Auslastung und mittlerer Wartezeit. Die Notation selbst ist seit 2014 als Standard der Object Management Group

festgeschrieben (Object Management Group, 2014).

D.5.1 Das Werkzeug: Drei Prompts, drei Darstellungen

Die drei Prompts aus Ü4 stehen im Übungskasten; wichtiger als ihr Wortlaut ist, was sie teilen. Alle drei gehen von derselben Prozessbeschreibung aus und tragen dieselben Annahmen weiter: die Schritte, ihre Dauern in Minuten und die Kapazität je Station. Der erste Prompt verlangt die BPMN-Datei ohne Layout und mit vollständigen Pfeilverweisen, weil genau diese beiden Punkte die Fehler aus dem vorigen Absatz vermeiden. Der zweite verlangt eine Animation als einzelne HTML-Datei ohne Zufall, damit jeder Lauf gleich aussieht und sich die Warteschlange vor dem Engpass reproduzierbar beobachten lässt. Der dritte verlangt das Gegenteil, nämlich Zufall mit festem Startwert, denn erst die Streuung zeigt, wie empfindlich der Engpass auf Schwankungen reagiert. Wo sich Animation und Simulation widersprechen, liegt die Erkenntnis: Dann hat eine der drei Darstellungen eine Annahme anders gesetzt, und die Suche nach dieser Annahme ist die Übung.

D.5.2 Übung Ü4: Ein Prozess, drei Darstellungen, eine Engpass-Vorhersage

Übung Ü4: Ein Prozess, drei Darstellungen

Aufgabe: Aus einer Prozessbeschreibung ein BPMN-Diagramm, eine Animation und eine Simulation erzeugen und an einer Engpass-Vorhersage prüfen, ob die drei Darstellungen dasselbe sagen. Ergebnis: ein BPMN-Diagramm, eine Animation als HTML-Datei, ein Notebook und die eigene Vorhersage im Vergleich.
Tool: Chat-Interface des Anbieters, Auto-Layout-Seite (https://bpmn-io.github.io/bpmn-auto-layout/), https://demo.bpmn.io, Google Colab; alles im Browser ohne Installation.
Zeit: 26 Minuten.
Sozialform: Partnerarbeit.

1. **Text zu BPMN (8 min).** Prompt 1. Antwort als Datei mit der Endung .bpmn speichern, auf der Auto-Layout-Seite öffnen

(Open → Download) und dann in demo.bpmn.io (Datei ins Fenster ziehen).

2. **Vorhersage (2 min).** Jede Person notiert für sich: An welchem Schritt staut sich die Arbeit?
3. **Animation (8 min).** Prompt 2 im selben Chat. HTML-Datei herunterladen und per Doppelklick im Browser öffnen.
4. **Simulation (8 min).** Prompt 3, dann den Code in ein neues Notebook auf https://colab.research.google.com kopieren und ausführen. Engpass mit Vorhersage und Animation vergleichen.

Prozess aus dem eigenen Fach mit vier bis sechs Schritten, oder eine der Optionen: Bedarf melden → Angebote vergleichen → bestellen → Ware prüfen (Einkauf); Störung melden → Ursache untersuchen → reparieren → Anlage freigeben (Ingenieurwesen); Beweis einreichen → prüfen → Rückfragen beantworten → überarbeiten (Mathematik); Beratungsanfrage aufnehmen → Bedarf klären → Unterstützung vereinbaren → Verlauf prüfen (Soziale Arbeit); Antrag auf Anerkennung prüfen → fachlich bewerten → entscheiden → verbuchen (Studierendenbetreuung).
Prompt 1, BPMN:

```
Erstelle für den Prozess [Prozess] eine
  BPMN-2.0-XML-Datei: ein
Startereignis, 4-6 Aufgaben, mindestens eine
  Entscheidung (exklusives
Gateway) mit allen Ausgängen, ein Endereignis.
  Wichtig: Jeder Knoten enthält
seine <bpmn:incoming>- und
  <bpmn:outgoing>-Elemente. Keine Pools oder Lanes,
kein Diagrammlayout (BPMNDI). Gib die Datei als
  Codeblock aus.
```

Prompt 2, Animation:

```
Mache aus diesem Prozess eine Prozessanimation als
  eine einzige HTML-Datei
ohne Internet und ohne externe Bibliotheken. Lege
  für jeden Schritt eine
plausible Dauer in Minuten und eine Kapazität fest
  (meist 1) und nenne die
Werte als Annahmen. 10 Fälle kommen alle [x]
  Minuten an. Fälle wandern als
```

```
Punkte von Station zu Station, Warteschlangen vor
  einer Station werden
sichtbar, oben laufen eine Uhr und die Zähler
  Fertig, Im Prozess, Wartend.
Knöpfe: Start/Pause, Schritt, Zurück. Keine
  Zufallszahlen, damit jeder Lauf
gleich aussieht. Nenne danach in einem Satz, wo
  die Warteschlange entsteht
und warum.
```

Prompt 3, Simulation:

```
Schreibe ein Python-Programm für Google Colab mit
  SimPy für denselben Prozess
und dieselben Dauern und Kapazitäten. Ankünfte und
  Bearbeitungszeiten
schwanken (Exponentialverteilung um die
  Mittelwerte), Zufallsstartwert 42.
Simuliere 100 Fälle. Gib je Station die Auslastung
  in Prozent und die
mittlere Wartezeit aus, als Tabelle. Erste Zeile:
  !pip install simpy
```

4D	In dieser Übung
Delegation	Die KI schreibt XML, HTML und Python; wir legen Schritte, Dauern und Kapazitäten fest.
Description	Dieselben Annahmen gehen in alle drei Darstellungen.
Discernment	Die eigene Vorhersage ist der Prüfstein: Sagen Diagramm, Animation und Simulation dasselbe?
Diligence	Keine echten Fall- oder Personendaten, besonders in Sozialer Arbeit und Studierendenbetreuung.

Wenn es hakt. “no diagram to display”: Die Datei hat kein Layout; erst über die Auto-Layout-Seite laden. Kästen liegen gestapelt ohne Pfeile: incoming/outgoing fehlen; die KI bitten, sie für jeden Knoten zu ergänzen. Schwimmbahnen nötig: in demo.bpmn.io von Hand ergänzen. Bei Schritt 1 hängen geblieben: das UrbanRide-Paket nehmen und mit Schritt 2 weitermachen.
Debrief. Wo widersprechen sich Animation und Simulation, und welche Annahme steckt dahinter?

Abbildung D.4. Online-Material zu Übung Ü4: Übungsblatt, Colab-Notebook für die SimPy-Simulation, UrbanRide-Paket. QR-Code scannen oder die Online-Version aufrufen.

D.6 Workflows automatisieren: Welche wiederkehrende Lehrarbeit lohnt die Automatisierung, und wie bleibt sie kontrollierbar?

n8n ist ein Baukasten für Arbeitsabläufe: Auf einer Arbeitsfläche verbinden wir Kästchen wie Stationen an einem Fließband; ein Formular nimmt Text an, ein Sprachmodell formuliert, eine feste Regel prüft, ein Mensch gibt frei. Jedes Kästchen heißt Knoten, die ganze Kette Workflow. Wichtig für das Verständnis: n8n selbst denkt nicht. Die Sprach- und Bildarbeit erledigen externe Modelle, die n8n über einen API-Schlüssel anspricht; n8n ist der Dirigent, die Modelle sind das Orchester. Eine API ist der Bestellschalter eines fremden Dienstes, über den Programme miteinander statt mit Menschen sprechen, und der API-Schlüssel ist die Kundenkarte mit Prepaid-Guthaben, die bei jeder Anfrage vorgezeigt und belastet wird. Ein Abonnement des Chat-Interfaces ist kein API-Zugang; die

Plattform rechnet getrennt und nach Verbrauch ab. Automation stammt vom griechischen *autómatos*, aus eigenem Antrieb handelnd, und genau das Selbsttätige braucht feste Haltepunkte für den Menschen: In unseren Vorlagen erscheint vor jedem Schritt, der Geld kostet, eine Kontrollseite mit Plan und geschätzten Kosten, und erst der Klick auf "Freigeben" löst ihn aus.

Welche Lehrarbeit lohnt die Automatisierung? Die Regel aus Kapitel D.1 gilt verschärft: wiederkehrend, prüfbar und ohne Personenbezug. Ein Foliensatz aus einem Textentwurf, Quizfragen aus einem Skriptkapitel, ein Protokollentwurf aus einem Transkript erfüllen alle drei Bedingungen; Feedback auf benannte Studierendenarbeiten erfüllt die dritte nicht und bleibt im Chat-Interface mit Codenamen (Kapitel D.8). Der Grund liegt in den Datenwegen: Bei einem Cloud-Baukasten liegt das Protokoll jedes Laufs beim Betreiber, und die angeschlossenen Modellanbieter sitzen je nach Dienst in der EU, in den USA oder in Südostasien. Was keinen Personenbezug hat, darf diesen Weg gehen; alles andere nicht.

Die Vorlagen des Online-Materials bauen fünf Sicherungen ein, die sich auf jede Automatisierung übertragen lassen. Ein Wächter, ein Skript und kein Modell, bricht ab, wenn der Eingabetext eine E-Mail-Adresse, eine sieben- oder achtstellige Zahl (Matrikelnummer), eine Telefonnummer oder Überlänge enthält. Eine Plan-Prüfung zählt mechanisch, ob der vom Modell vorgeschlagene Folienplan die Regeln einhält (Titel bis zwölf Wörter, Folientext bis fünfzehn), gibt dem Modell einen Neuversuch und bessert danach selbst nach. Ein Kontrollpunkt zeigt Plan und geschätzte Kosten auf einer zweiten Formularseite, und erst „Freigeben" löst die Schritte aus, die Geld kosten. Fehlertoleranz sorgt dafür, dass ein fehlgeschlagenes Bild nicht den ganzen Lauf stoppt. Und eine Kennzeichnung schreibt auf jede Folie die Quellenzeile und an das Ende eine Protokollfolie mit Prompts, Modellen, Kosten und dem Feld „Geprüft von". Kosten bleiben beschränkt durch Prepaid-Guthaben ohne automatisches Nachladen, ein Ausgabenlimit im API-Projekt und die Freigabeschritte. Eine veröffentlichte Formularadresse ist öffentlich; veröffentlicht wird nur, was Studierende nutzen sollen, und danach zurückgenommen.

D.6.1 Das Werkzeug: Eine Workflow-Vorlage mit Wächter, Plan-Prüfung und Freigabe

> ⚠ In Erprobung
>
> Die beiden Workflow-Vorlagen des Online-Materials (Text zu Folien, Text zu Kurzfilm) sind bis zur Drucklegung nur gegen nachgebaute Dienste getestet; echte Schlüssel, der Cloud-Betrieb und echte Bild- und Clipgrößen stehen aus. Der Stand ist auf der Online-Seite zu Anhang D vermerkt und wird dort aktualisiert.

Die Vorlage „Text zu Folien“ läuft in sechs Stationen. Ein Formular nimmt den Text und die Zielgruppe an. Ein Sprachmodell entwirft daraus einen Folienplan nach den Regeln des Folien-Skills aus Kapitel D.2. Ein Skript prüft den Plan mechanisch und bessert nach. Eine Kontrollseite zeigt Plan und Kosten und wartet auf die Freigabe. Erst dann erzeugt ein Bildmodell je Folie eine Visualisierung, und ein letzter Knoten setzt alles zu einer Präsentation zusammen, die im Browser läuft und mit der Protokollfolie endet. Die Einrichtung in der Cloud-Variante braucht fünf Schritte: ein Konto beim Baukasten anlegen, die zwei Zugangsdaten (Sprach- und Bildmodell) im Tresor des Werkzeugs hinterlegen, die Vorlagendatei importieren, einen Testlauf mit dem Knopf „Execute workflow“ fahren und erst dann veröffentlichen. Die drei häufigsten Fehlerbilder haben einfache Ursachen: Der Code 401 heißt falscher oder fehlender Schlüssel, 429 heißt Guthaben oder Anfragelimit erschöpft, und ein Abbruch nach drei Minuten heißt, dass der Lauf die Zeitgrenze des Testkontos erreicht hat; dann hilft es, die Zahl der Folien zu senken. Wer die Kette ohne Cloud betreiben will, findet die lokale Variante mit einem Modell auf dem eigenen Rechner in Kapitel D.8.

D.6.2 Übung Ü5: Zirkel: Drei Werkzeuge, eine Vergleichskarte

Übung Ü5: Zirkel: Drei Werkzeuge, eine Vergleichskarte

Aufgabe: Drei Klassen von GenAI-Angeboten an derselben Aufgabe vergleichen und begründen, wann sich welche lohnt. Alle arbeiten am Thema des Quellenkorbs aus Ü3, damit die Ergebnisse vergleichbar sind. Ergebnis: eine ausgefüllte Vergleichskarte je Gruppe; die drei Karten hängen danach nebeneinander.
Tool: Station 1 lokale Modelle (LM Studio für Sprache, ComfyUI als Knotenbaukasten für Bilder), Station 2 Präsentationswerkzeuge (Gamma, Beautiful.ai, Prezi), Station 3 Elicit.
Zeit: 40 Minuten: drei Stationen à 12 Minuten, zweimal 2 Minuten Wechsel.
Sozialform: Drei Gruppen, die im Uhrzeigersinn wechseln.

Station	Aufgabe	Prüffrage
1 Lokale Modelle	Eine Frage aus Ü2 offline stellen; ein Titelbild zum Thema erzeugen	Wie gut ist es ohne Cloud, und was verlässt den Raum nicht?
2 Präsentationen	Derselbe Prompt in zwei der drei Werkzeuge	Aussagetitel? Höchstens 15 Wörter je Folie? Eine Quelle je Folie?
3 Literatur	Die Forschungsfrage aus Ü3 stellen, eine Tabelle mit den Spalten Stichprobe · Methode · Kernbefund extrahieren lassen	Wie viele Treffer decken sich mit dem Korb, welche Kernquelle fehlt?

Prompt für Station 2:

```
Erstelle 5 Folien zu [Thema aus Ü3] für
  [Zielgruppe]. Jede Folie: ein
Aussagetitel als ganzer Satz, höchstens 15 Wörter
  Folientext, unten eine
vollständige Quellenangabe.
```

Vergleichskarte je Gruppe: Aufwand bis zum ersten Ergebnis (min) · Qualität (1 = unbrauchbar, 5 = übernehmbar) · Datenschutz: Wohin gehen die Daten? · Kosten (Gratis-Stufe reicht? Preis?) · Lohnt sich für …

4D	In dieser Übung
Delegation	Welche Aufgabe gebe ich welchem Werkzeugtyp, und welche gar keinem?
Description	Derselbe Prompt in jedem Werkzeug, damit Unterschiede am Werkzeug liegen.
Discernment	Die Prüffragen der Station, nicht der erste Eindruck.
Diligence	Datenschutz und Kosten gehören auf die Karte, nicht nur die Qualität.

Wenn es hakt. Kein Konto: an Station 2 und 3 zu zweit am Rechner einer Person mit Konto arbeiten. Gratis-Stufe ausgeschöpft: auf der Karte unter Kosten notieren; das ist ein Befund. Station 1 nicht erreichbar: das kurze Bildschirmvideo ansehen und die Spalte trotzdem füllen.
Debrief. Welches Werkzeug würden wir morgen in der Lehre einsetzen, und wofür ausdrücklich nicht?

Abbildung D.5. Online-Material zu Übung Ü5 und zu den n8n-Workflow-Vorlagen. QR-Code scannen oder die Online-Version aufrufen.

D.7 KI-Tutoren bauen und prüfen: Wie verhindere ich, dass der Tutor zu viel hilft?

D.7.1 Das Problem: Tutoren helfen zu früh und zu viel

Ein Tutor ist die Nutzungsform, in der die KI später ohne uns handelt. Alles, was wir in Kapitel 4.3 über den Mehrwert individueller Anpassung und unmittelbaren Feedbacks gesagt haben, gilt weiter, und die Messlatte bleibt hoch: Menschliche Einzelbetreuung gehört zu den wirksamsten Maßnahmen, die die Bildungsforschung kennt: Eine Metaanalyse von 96 randomisierten Studien aus Vorschule und Schule findet einen mittleren Effekt von 0,37 Standardabweichungen auf die Lernleistung (Nickow et al., 2020). Doch wer Studierende einen Tutor bauen lässt, muss mit einer Eigenschaft heutiger Modelle rechnen, die der Didaktik des Tutorings direkt widerspricht: Sie helfen zu früh und zu viel.

Drei Studien belegen das aus verschiedenen Richtungen; alle drei sind Preprints ohne abgeschlossene Begutachtung und deshalb als Hinweise zu lesen, nicht als Urteil. Suhyeon Lee et al. (2026) haben 14.637 Antworten von KI-Tutoren je einer von vier Stufen zugeordnet, Frage, Hinweis, Erklären oder Lösen, und fanden über 95 Prozent auf den Stufen Erklären oder Lösen; für Hinweise und Gegenfragen, also das, was eine gute Tutorin meistens tut, blieb fast nichts. Methodisch ist das eine Klassifikation realer Tutoring-Dialoge, keine Lernmessung; sie zeigt das Verhalten der Modelle, nicht dessen Folgen. Teo et al. (2026) kommen in einem Benchmark zum selben Bild und benennen es im Titel: KI-Assistenten überhelfen. Methodisch ist

das ein fester Satz von Testaufgaben, an dem Modelle verglichen werden; die Assistenten unterbrechen darin den produktiven Kampf mit dem Problem, in dem nach Kapitel 3.4 das Lernen stattfindet, und zwar genau dann, wenn die Studentin kurz vor der Einsicht steht. Perczel et al. (2025) schließlich erklären, warum Prompts allein das nicht beheben: Sie verglichen die Dialoge heutiger Modelle mit 100.000 Stunden echter Eins-zu-eins-Tutorien und fanden die Modelle über sechs Kriterien systematisch schwächer, mit Redeanteilen der Lernenden von 5 bis 15 statt rund 30 Prozent, drei bis vier Fragen auf einmal statt ein bis zwei, und einem Rückfall auf Multiple-Choice-artige statt offene Fragen. Die Ursache ist strukturell: Standardmodelle sind darauf optimiert, als hilfreiche Assistenten Reibung zu minimieren, während gutes Unterrichten Reibung gezielt erzeugt; die Autoren beschreiben aus eigener Entwicklung einen endlosen Kreislauf immer detaillierterer Prompts, und erst ein Nachtrainieren auf die Tutoring-Daten verdoppelte den Redeanteil der Lernenden. Für die Praxis heißt das: Der System-Prompt ist notwendig, aber er ist eine Prüfschicht von mehreren, und die Qualität eines Tutors hängt am Modell ebenso wie am Prompt. Reicht also ein guter System-Prompt? Nein, und das ist seit 2026 nicht mehr Vermutung, sondern präregistriert gemessen: 1.059 Programmieranfänger an der ETH Zürich durchliefen im Crossover-Design Tutoren mit System-Prompts für selbstreguliertes Lernen und für kognitive Aktivierung, und auf keinem der vier vorab festgelegten Maße unterschieden sich die Varianten (Barth et al., 2026). Was stattdessen trägt, sind Bausteine außerhalb des Prompts. Erstens eine Aufsichtsinstanz: ein zweites, kleines Modell oder ein Skript, das jede Tutorantwort vor dem Versand prüft und zurückweist, wenn sie die Lösung verrät; Pisan (2026) beschreiben eine solche Supervisor-Architektur und ein Verfahren, die Strenge an Testdialogen zu kalibrieren statt am Gefühl. Zweitens eine Eskalationsregel: Bei festgefahrenen Lernenden hilft jede weitere Rückfrage weniger und das Benennen des Fehlers mehr, wie eine Auswertung von 20.462 Tutor-Beiträgen zeigt (Ahtisham et al., 2026); ein Tutor, der sein Gerüst daran ausrichtet, was die Person gerade tut, mehr hilft, wenn sie stockt, und weniger, sobald sie trägt, schlägt beide starren Varianten (Xinmeng Hou et al., 2026). Drittens eine Rolle, die zum Erklären zwingt: Ein Tutor-Bot, dem ein Tutee-Bot zur Seite steht, den die Studierenden selbst unterrichten müssen, übertraf in einem Programmierkurs den reinen Antwort-Bot in Leistung, Motivation und Selbstwirksamkeit (Kuo & Zhuo, 2026).

Die Gegenbefunde gehören dazu, weil sie die Grenze der Leitplanken

zeigen. Studierende, denen ein strikter Tutor zu wenig gibt, weichen zum freien Chatbot aus; in einem Experiment mit 132 Programmierstudierenden kostete die strenge Variante Engagement, ohne mehr Lernen zu bringen (Eastwood et al., 2026), und in einer Hirnsensorik-Studie mit 50 Erwachsenen lernte die sokratische Variante beim sofortigen Faktentest schlechter als der freie Chatbot, ohne verzögerten Test (Clin Deffarges et al., 2026). Dass die Rolle, die Studierende bevorzugen, nicht die lernwirksamste ist, zeigt ein Vergleich mehrerer Tutorrollen: Die beliebteste gab am meisten, die wirksamste am wenigsten (Zhu et al., 2026). Die Regel für den eigenen Tutor lautet deshalb: Hinweise vor Lösungen, mit Eskalation bei Sackgassen, geprüft von einer Instanz außerhalb des Prompts, und so in den Kurs eingebettet, dass das Ausweichen zum freien Chatbot nicht die bequemere Wahl bleibt (Kapitel 3.5).

D.7.2 Der Rahmen: Vier Fragen und vier Prüfschichten

Struktur bekommt ein Tutorprojekt durch vier Fragen, die wir in den Übungen dieses Anhangs durchgängig als 4D-Prüfliste führen: Delegation fragt, was der Tutor tun soll und was nie; Description ist der System-Prompt, also die Beschreibung der Aufgabe in prüfbaren Regeln; Discernment sind die Tests, mit denen wir Antworten beurteilen; Diligence heißt Sorgfalt, also Datenschutz und Freigabe (4D-Modell der AI Fluency, Dakan & Feller, 2025). Das Modell selbst und seine zwei Schleifen erklärt Kapitel 2.6. Weil der Tutor ohne uns handelt, wiegen die letzten beiden Fragen schwerer als bei jeder anderen Nutzungsform.

Wie prüfen wir also? Mit einem Modell aus der Sicherheitsforschung, dem Schweizer-Käse-Modell: Jede Prüfschicht hat Löcher, aber jede an anderer Stelle, und gestapelt fangen sie die meisten Fehler (Reason, 2000). Die erste Schicht sind Prompt-Muster, also erprobte Bausteine für den System-Prompt wie eine Persona, eine Vorlage für die Antwortform, eine Prüfliste für Fakten oder die umgedrehte Interaktion, bei der das Modell fragt statt antwortet; sie fangen unklare Rollen und fehlende Struktur (Katalog der Muster bei White et al., 2023). Die zweite Schicht ist eine deterministische Prüfung: ein Skript, kein Modell, das Regelverstöße erkennt, die sich mechanisch feststellen lassen, etwa ob die Antwort eine Endzahl verrät oder ob ein Zitat wörtlich in der Quelle steht. Die dritte Schicht ist Testmanagement: dieselben Testfälle nach jeder Änderung des Prompts erneut laufen lassen, wie ein TÜV-Termin nach jeder Reparatur, damit eine Verbesserung an

einer Stelle keinen Rückfall an einer anderen verdeckt. Die vierte Schicht ist der Goldstandard: von Fachleuten geprüfte Musterantworten, an denen die Tutorantworten gemessen werden; das ist der Gedanke, den Kestin et al. (2025) mit Musterlösungen als Input verfolgen (Kapitel 4.3.2), hier auf die Testseite gewendet. Erst an dieser vierten Schicht bleiben fachliche Fehler hängen, die die ersten drei nicht sehen können.

Der Goldstandard ist nur so gut wie die Einigkeit derer, die ihn erstellen. Deshalb bewerten zwei Personen jede Tutorantwort getrennt, und ein Übereinstimmungsmaß zeigt, wie viel ihrer Einigkeit über den Zufall hinausgeht: Cohens Kappa setzt die beobachtete Übereinstimmung ins Verhältnis zur zufällig erwartbaren. Stimmen beide in 80 Prozent der Fälle überein und läge die Zufallsübereinstimmung bei 50 Prozent, ergibt sich $\kappa = (0{,}80 - 0{,}50) / (1 - 0{,}50) = 0{,}60$, ordentlich, aber nicht perfekt (Cohen, 1960). Für die Benotung studentischer Tutoren ist diese Zahl der wichtigste Befund der Übung: Sind sich die Bewertenden selten einig, müssen erst die Stufendefinitionen geschärft werden, bevor weiter getestet wird. Auch die Regel aus Kapitel D.2 kehrt hier wieder: Eingehalten werden vor allem prüfbare Regeln, und "gib nie sofort die Lösung, sondern bitte erst um einen eigenen Lösungsschritt" ist eine solche.

D.7.3 Das Werkzeug: Der Tutor als Zwei-Datei-Bündel

Unser Werkzeug für Tutoren folgt der Merkregel aus Tabelle D.2: Was immer gelten muss, steht in der Anleitung; Beispiele und Fachwissen stehen in einer Datei daneben. Das Bündel besteht aus einer Anleitungsdatei `SKILL.md` und einer JSON-Datei mit durchgearbeiteten Beispielen; JSON ist ein Textformat für strukturierte Daten, in dem jedes Beispiel dieselben Felder trägt, so wie eine Karteikarte immer dieselben Rubriken hat. Dieses Bündel ist zugleich die Bauform eines Skills, und es umgeht zwei Hürden geteilter Assistenten: die Obergrenze für Mitwirkende in geteilten Projekten und die Abhängigkeit von Produkten, die abgeschaltet werden. Studierende laden beide Dateien auf ihr eigenes Konto. Als Musterlösung dient ein Statistik-Tutor für Korrelation und Kausalität im ersten Studienjahr; die Anleitung ist bewusst kurz, und jede ihrer Regeln lässt sich abhaken.

```
---
name: statistik-tutor
```

```
description: Sokratischer Tutor für Korrelation
  und Kausalität in der Einführungsstatistik.
  Verwenden, wenn Studierende Zusammenhänge
  deuten, Scheinkorrelationen erkennen oder
  Studiendesigns beurteilen wollen.
---

# Statistik-Tutor: Korrelation und Kausalität

Du begleitest Studierende im ersten Studienjahr
  beim Üben. Dein Ziel ist, dass sie selbst denken,
  nicht dass sie schnell eine Antwort haben.

## Regeln

1. Gib nie sofort die Lösung. Bitte zuerst um
  einen eigenen Lösungsschritt mit Begründung.
2. Bestätige oder korrigiere erst danach, in
  höchstens drei Sätzen.
3. Erkläre Begriffe, aber schreibe keine fertigen
  Antworten für Hausaufgaben oder Prüfungen.
4. Nutze die Beispiele in
  references/beispiele.json. Erzeuge daraus neue
  Varianten mit anderem Kontext, statt die
  Beispielaufgabe wörtlich zu stellen.
5. Achte auf die dort genannten typischen Fehler.
  Erkennst du einen, frage nach, statt ihn zu
  benennen.
6. Nutze die Fachsprache aus der Datei
  (Korrelation, Confounder, Selektionseffekt …).
7. Liegt eine Frage außerhalb von Korrelation und
  Kausalität, sag das ausdrücklich und verweise
  auf die Lehrperson.
8. Frage nicht nach Namen oder anderen
  persönlichen Daten.

## Ablauf einer Übungsrunde

1. Frage, woran die Studentin gerade arbeitet,
  oder biete eine Variante aus der Datei an.
2. Lass sie den ersten Schritt formulieren und
  begründen.
```

```
3. Gib kurzes Feedback und stelle die nächste
  Frage.
4. Fasse am Ende in einem Satz zusammen, was sie
  selbst herausgefunden hat.
```

Die Regeln setzen die drei Befunde von oben um: Regel 1 und 2 erzwingen das Gerüst statt der Lösung, Regel 3 lässt den Tutor erklären, aber nicht schreiben, Regel 7 benennt die Grenze des Stoffs, statt aus Allgemeinwissen zu raten, wie wir es in Kapitel D.3 mit der unbeantwortbaren Frage geübt haben. Die zweite Datei liefert das Fachwissen, aus dem der Tutor Varianten erzeugt, und die typischen Fehler, auf die er achten soll.

```
[
  {
    "aufgabentyp": "Scheinkorrelation erkennen",
    "beispielaufgabe": "Eisverkauf und
      Sonnenbrände steigen gemeinsam. Verursacht
      Eisessen Sonnenbrand?",
    "methode": "Vor einem Kausalschluss nach einer
      Drittvariable (Confounder) suchen, die beide
      beeinflusst",
    "loesungsschritte": [
      "Die beobachtete Korrelation benennen",
      "Fragen: Gibt es eine dritte Variable, die
        beide treibt?",
      "Hier: Sonnenschein/Temperatur treibt
        beide",
      "Schluss: Korrelation ohne Kausalität"
    ],
    "typische_fehler": [
      "Aus Gleichzeitigkeit auf Ursache
        schließen",
      "Richtung der Wirkung verwechseln
        (umgekehrte Kausalität)",
      "Confounder gar nicht in Betracht ziehen"
    ],
    "fachsprache": ["Korrelation", "Kausalität",
      "Confounder", "Drittvariable",
      "Scheinkorrelation"]
  },
  {
    "aufgabentyp": "Studiendesign beurteilen",
```

```
    "beispielaufgabe": "Eine Beobachtungsstudie
      findet: Kaffeetrinker leben länger. Darf man
      Kaffee empfehlen?",
    "methode": "Beobachtung erlaubt keinen
      Kausalschluss; nur ein randomisiertes
      Experiment kontrolliert Confounder",
    "loesungsschritte": [
      "Studientyp bestimmen (Beobachtung vs.
        Experiment)",
      "Mögliche Confounder benennen (z. B.
        Gesundheitsverhalten)",
      "Prüfen, ob randomisiert zugewiesen wurde",
      "Schluss: Zusammenhang ja, Empfehlung nein"
    ],
    "typische_fehler": [
      "Beobachtungsdaten als Kausalbeleg lesen",
      "Selektionseffekte übersehen",
      "Von Korrelation direkt zur
        Handlungsempfehlung"
    ],
    "fachsprache": ["Beobachtungsstudie",
      "randomisiertes Experiment", "Confounder",
      "Selektionseffekt", "Kontrollgruppe"]
  }
]
```

Geladen wird das Bündel je nach Konto auf einem von drei Wegen, und der Vergleich der Wege ist selbst ein Lernziel. Als Skill liest das Modell die Anleitung nur bei Bedarf, als Projekt in jeder Runde, im Einzelchat nur so lange, wie der Gesprächsverlauf reicht; wer mehrere Wege ausprobiert, sieht, ob der Tutor überall gleich standhaft bleibt.

Weg	Voraussetzung	Schritte
Als Skill	Das Interface kennt Skills	Ordner hochladen, im Chat mit `@statistik-tutor` aufrufen
Als Projekt	Jedes Konto mit Projekten	Neues Projekt; Text von `SKILL.md` ohne die Kopfzeilen ins Anleitungsfeld; `beispiele.json` als Projektdatei

Weg	Voraussetzung	Schritte
Als Einzelchat (etwa KI:connect.nrw)	Jedes Werkzeug mit Dateianhang	Text von `SKILL.md` als erste Nachricht senden, `beispiele.json` anhängen

Tabelle D.3. Drei Wege, das Tutor-Bündel zu laden

Für den eigenen Tutor erzeugen zwei Build-Prompts die beiden Dateien: Der erste interviewt die Lehrperson zu Fach, Zielgruppe, Lernmoment, typischen Denkfehlern und Fachsprache und schreibt daraus die Anleitung mit den festen Regeln; der zweite macht aus eingefügtem Lehrmaterial die JSON-Datei mit genau den Feldern der Musterlösung und markiert mit "PRÜFEN", was im Material fehlt, statt es zu erfinden. Beide Prompts liegen im Online-Material. Für die Verteilung an Studierende genügen zwei Dateien im Lernmanagementsystem; Studierende öffnen ihr eigenes Konto, fügen den Prompt ein und hängen die JSON-Datei an. Die Grundregel dabei: Nichts in einen studierendenseitigen Tutor legen, dessen Leak die Prüfung beschädigt, und keine Namen oder Adressen von Studierenden in die Dateien.

D.7.4 Das Studierendenprojekt: Bauen, testen, abgeben

Wer Studierende selbst einen Tutor bauen lässt, verbindet Fachwissen, Methodenkompetenz und KI-Literacy in einem Projekt, das nach den Säulen aus Kapitel 5 prozessorientiert prüfbar ist. Als Abgabe haben sich drei Teile bewährt: drei Versionen des Tutors, ein Änderungsprotokoll, das zu jeder Version sagt, welche Regel warum geändert wurde, und ein Testprotokoll gegen den Goldstandard, bei zwei Bewertenden mit Cohens Kappa beziffert. Technisch reicht für ein Bündel das eigene Konto der Studierenden; wer einen Tutor mit eigener Oberfläche und Dokumentenablage bauen lassen will, kann eine Übungswerkstatt in der Cloud nutzen, in der Studierende eine Webseite, die Logik und einen Speicher für die Wissensbasis anlegen und das Sprachmodell per API-Schlüssel anbinden; wir nutzen dafür das AWS Academy Learner Lab, das Hochschulen kostenlos und ohne Kreditkarte bereitstellt (Amazon Web Services, 2026).

D.7.5 Übung Ü6: Testplan für einen KI-Tutor: Mini-Goldstandard und Überhilfe-Audit

Übung Ü6: Testplan für einen KI-Tutor

Aufgabe: Einen vorbereiteten Tutor oder den eigenen Bot aus Ü1 gegen einen Mini-Goldstandard testen, jede Antwort einer Hilfestufe zuordnen und daraus einen Testplan ableiten. Ergebnis: ein Testplan, den wir Studierenden mitgeben, die selbst einen KI-Tutor bauen.
Tool: Das Tutor-Bündel `statistik-tutor` (als Skill, Projekt oder Einzelchat geladen) oder der eigene Bot aus Ü1.
Zeit: 35 Minuten.
Sozialform: Dreiergruppen: eine Person spielt die Studierenden, zwei bewerten getrennt.

1. **Mini-Goldstandard (10 min).** Drei Personas mal zwei Aufgaben aus dem eigenen Fach, je mit dem erwarteten Verhalten des Tutors. Dazu eine unbeantwortbare Frage wie in Ü2.
2. **Überhilfe-Audit (15 min).** Die spielende Person gibt alle sieben Testfälle ein. Beide Bewertenden ordnen jede Tutorantwort getrennt einer Stufe zu und haken eine prüfbare Regel ab. Danach vergleichen.
3. **Testplan (10 min).** Welche Prüfschicht fängt welchen Fehler, und was geben die Studierenden ab?

Stufen der Hilfe, von viel zu wenig: **Lösen** (gibt das Ergebnis) · **Erklären** (erklärt den Weg vollständig) · **Hinweis** (zeigt die Richtung) · **Frage** (lässt die Studierenden den nächsten Schritt selbst finden).

Fall	Persona	Aufgabe	Erwartetes Verhalten	Stufe (A)	Stufe (B)	Regel erfüllt?
1	Unsicher, wenig Vorwissen	Aufgabe 1	Frage oder Hinweis, keine Lösung			
2	Unsicher, wenig Vorwissen	Aufgabe 2				
3	Solide, will prüfen	Aufgabe 1				
4	Solide, will prüfen	Aufgabe 2				
5	“Gib mir einfach die Lösung”	Aufgabe 1	Bleibt beim Hinweis			
6	“Gib mir einfach die Lösung”	Aufgabe 2				
7	Beliebig	Frage außerhalb des Stoffs	Sagt, dass es das nicht weiß			

Schicht	Was sie fängt	Beispiel
Prompt-Muster	Unklare Rolle, fehlende Struktur	Persona, Vorlage, Faktenprüfliste, umgedrehte Interaktion
Deterministische Prüfung	Regelverstöße, die ein Skript erkennt	Verrät die Antwort die Endzahl? Steht das Zitat wörtlich in der Quelle?
Testmanagement	Rückfälle nach Änderungen	Dieselben sieben Fälle nach jeder Änderung erneut laufen lassen
Goldstandard	Fachliche Fehler	Von Fachleuten geprüfte Musterantworten, zwei Bewertende

4D	In dieser Übung
Delegation	Was soll der Tutor tun, und was nie?
Description	Der System-Prompt des Tutors; prüfbare Regeln statt Haltungen.
Discernment	Die sieben Testfälle, zwei Bewertende, ein Vergleich.
Diligence	Datenschutz und Freigabe: Wer gibt den Tutor für Studierende frei?

Wenn es hakt. Die Bewertenden sind sich selten einig: die Stufendefinitionen schärfen, bevor weiter getestet wird; das ist der wichtigste Befund für die spätere Benotung. Der Tutor gibt sofort die Lösung: den Fall notieren, eine prüfbare Regel im System-Prompt ergänzen und alle sieben Fälle erneut laufen lassen.

Debrief. Wie oft waren sich die beiden Bewertenden einig, und was heißt das für die Benotung studentischer Tutoren?

Für das Studierendenprojekt. Abgabe: drei Versionen des Tutors, ein Änderungsprotokoll und ein Testprotokoll gegen den Goldstandard. Bei zwei Bewertenden lässt sich die Übereinstimmung mit Cohens Kappa beziffern.

Abbildung D.6. Online-Material zu Übung Ü6: Übungsblatt, Tutor-Bündel `statistik-tutor` und Build-Prompts. QR-Code scannen oder die Online-Version aufrufen.

D.8 Lokale Modelle: Wann lohnt der Betrieb ohne Cloud, und was leistet ein kleines Modell?

Ein lokales Modell ist die eigene Küche statt Lieferdienst. Beim Lieferdienst, also bei jedem Cloud-Dienst, geht die Bestellung samt Zutaten aus dem Haus; in der eigenen Küche verlässt nichts das Haus, dafür sind die Töpfe kleiner. LM Studio ist eine solche Küche: ein Programm, das ein Sprachmodell einmal herunterlädt, auf dem eigenen Laptop ausführt und danach vollständig offline arbeitet. Die Topfgröße bestimmt der Arbeitsspeicher; welche Modellklasse zu welchem Laptop passt, steht im datierten Kasten in Kapitel D.2. Was solche kleinen Modelle können, lässt sich knapp sagen: Zusammenfassen, Umformulieren und Sortieren gelingen gut; mehrstufiges Rechnen klappt unzuverlässig, und aktuelle Fakten kennen sie nicht, denn sie sind offline. Deshalb gehören in der Übung genau die Aufgaben auf das lokale Modell, bei denen die Daten das Gerät nicht verlassen sollen und bei denen eine Stichprobe genügt, um das Ergebnis zu prüfen: Lesezeichen sortieren und Codenamen erzeugen, mit denen Studierende Tests und Abgaben anonym einreichen. Wer den Schritt vom Laptop zum Campus-Server erwägt, findet die Abwägung in einer Fallstudie zu einem lokal betriebenen Tutor für mehrere betriebswirtschaftliche Kurse: Unterhalb einer bestimmten Antwortgeschwindigkeit brechen Studierende das Gespräch ab, so dass die Wahl der Grafikkarte über die Nutzung entscheidet, nicht die Qualität der Antworten (Shapiro & Lindemann, 2026).

Zwei Begriffe aus den Dateinamen der Modelle erklären, warum das

überhaupt auf einen Laptop passt. Die Zahl mit dem B, etwa 4B oder 9B, nennt die Parameter in Milliarden, also die Größe des Modells. Das Kürzel Q4 steht für Quantisierung: Das Modell ist komprimiert wie ein JPG, kleiner und etwas unschärfer. Im Original belegt jeder Parameter 16 Bit, im Format Q4_K etwa viereinhalb, und die Datei schrumpft auf gut ein Viertel; wie viel Genauigkeit dabei verloren geht, hängt vom Modell ab (Hugging Face, 2026). Offline heißt bei LM Studio tatsächlich offline: Nach dem einmaligen Download läuft das Modell ohne Verbindung (Element Labs, 2026), und in der Übung wird das geprüft, indem das WLAN testweise abgeschaltet wird. Die Modelldatei kommt dafür vom USB-Stick statt aus dem Netz, denn zwei bis fünf Gigabyte je Modell überfordern das WLAN eines Seminarraums. Wer auf dem Dienstgerät nichts installieren darf, nutzt WebLLM, ein Sprachmodell, das nach einem ersten Download vollständig im Browser läuft.

Die Codenamen aus der zweiten Aufgabe sind mehr als eine Übung. Studierende geben Tests und Abgaben unter einem Codenamen ab; die Korrektur bleibt anonym, und KI-gestützte Feedbackblätter verarbeiten nie echte Namen. Die Zuordnung von Codename zu Person entsteht nur in der eigenen Tabelle der Lehrenden und erreicht kein Modell, auch kein lokales. Das Muster „Nachname einer Fachperson plus Jahreszahl“ (Deming1900) ist leicht zu merken und verrät nichts. Ein Beispielmodul mit Codenamen und individuellem Feedback liegt online (SSCM-Modul, verlinkt im Online-Material); wie daraus diagnostisches Feedback je Codename wird, skizziert Kapitel D.9. Für den Betrieb an der Hochschule zeigt eine Workstation mit großem Grafikspeicher, wohin der Weg führt: Baukasten und Modell laufen dort gemeinsam, nichts verlässt das Haus, es gibt keine Ausführungsgrenzen, und lokale Modelle übernehmen die Routinearbeit; die Geschwindigkeit hängt daran, ob das Modell in den Grafikspeicher passt. Das Datenschutzargument schließt an die Richtlinien in Kapitel 5 an.

D.8.1 Das Werkzeug: LM Studio auf dem eigenen Laptop

Die Einrichtung braucht vier Handgriffe: das Programm installieren, die Modelldatei laden (vom Stick oder aus dem eingebauten Katalog), das Modell im Programm auswählen und im Chatfenster eine Frage stellen. Ab Version 0.4 bietet LM Studio zusätzlich einen lokalen API-Zugang, über den ein Workflow-Baukasten das Modell wie einen Cloud-Dienst anspricht, nur

ohne Schlüssel und ohne Rechnung; das ist die Brücke zur lokalen Variante von Kapitel D.6. Die beiden Prompts aus Ü7 stehen im Übungskasten. Beide verlangen ein festes Ausgabeformat, einmal CSV mit zwei Spalten, einmal eine Zeile je Codename, und das ist kein Zufall: Ein kleines Modell erfindet gern Ordner jenseits der gesetzten Grenze und wiederholt Codenamen; ein festes Format macht das in einer Tabellenkalkulation in Sekunden sichtbar (Duplikate entfernen, Ordner zählen), und die Stichprobe von zehn Zuordnungen bleibt die Prüfung, die kein Format ersetzt. Antwortet das Modell sehr langsam, hilft die kleinere Datei (4B statt 9B) und das Schließen anderer Programme.

D.8.2 Übung Ü7: Zwei Aufgaben offline

Übung Ü7: Zwei Aufgaben offline

Aufgabe: Ein kleines lokales Modell auf dem eigenen Laptop einrichten und damit zwei Alltagsaufgaben erledigen, ohne dass Daten das Gerät verlassen. Ergebnis: ein lokales Modell, das läuft, und zwei erledigte Aufgaben.
Tool: LM Studio auf dem eigenen Laptop, Modelldatei vom USB-Stick; ohne Installationsrecht WebLLM im Browser (https://webllm.mlc.ai/).
Zeit: 22 Minuten.
Sozialform: Einzelarbeit.

1. **Einrichten (8 min).** LM Studio installieren, das Modell vom USB-Stick laden statt über das WLAN (2 bis 5 GB je Modell). Danach das WLAN testweise abschalten und eine Frage stellen.
2. **Lesezeichen sortieren (7 min).** Browser-Lesezeichen als HTML-Datei exportieren, die Titel herauskopieren und Prompt 1 eingeben. Zehn Zuordnungen stichprobenartig prüfen.
3. **Codenamen erzeugen (7 min).** Prompt 2. Kleine Modelle wiederholen sich, also die Liste auf Dubletten prüfen (in Excel: Daten → Duplikate entfernen).

Prompt 1, Lesezeichen:

```
Ordne die folgenden Lesezeichen-Titel in höchstens
  acht thematische Ordner.
```

```
Ausgabe als CSV mit den Spalten Titel;Ordner, eine
  Zeile pro Lesezeichen,
keine weiteren Erklärungen.
[Titel einfügen]
```

Prompt 2, Codenamen:

```
Erzeuge 30 eindeutige Codenamen für Studierende
  zum Thema [Thema des Fachs],
nach dem Muster Nachname einer bekannten
  Fachperson plus Jahreszahl
(Beispiel: Deming1900). Keine Wiederholungen, eine
  Zeile pro Codename.
```

4D	In dieser Übung
Delegation	Sortieren und Formulieren ja; Rechnen und aktuelle Fakten nein.
Description	Ein festes Ausgabeformat (CSV) macht das Ergebnis prüfbar.
Discernment	Stichprobe von zehn Zuordnungen; Dublettenprüfung in der Tabelle.
Diligence	Personenbezogene Zuordnungen bleiben außerhalb jedes Modells, auch des lokalen.

Wenn es hakt. Nichts installieren dürfen: WebLLM im Browser öffnen; der erste Download dauert, danach arbeitet das Modell lokal. Das Modell antwortet sehr langsam: die kleinere Datei wählen und andere Programme schließen. Das Modell erfindet Ordner jenseits von acht: die Grenze am Ende des Prompts wiederholen.
Debrief. Welche Aufgabe aus dem eigenen Alltag gehört künftig auf das lokale Modell?

D.9 Ausblick: Fortgeschrittene Anwendungen

Die folgenden vier Anwendungen haben wir gebaut und teilweise im Workshop gezeigt, aber noch nicht so geprüft, wie es dieser Anhang für alles Gedruckte verlangt. Sie sind als in Erprobung gekennzeichnet; Stand,

Abbildung D.7. Online-Material zu Übung Ü7: Übungsblatt und Primer zur lokalen Automatisierung. QR-Code scannen oder die Online-Version aufrufen.

Kosten und Testprotokolle stehen im Online-Material und werden dort fortgeschrieben.

Storyboard-Werkstatt (in Erprobung). Ein Notebook führt in sechs Schritten mit drei Kontrollpunkten von einer Themenvorlage oder einem eigenen Thema zu einem Lehrcomic: Ein Starter-Prompt erzeugt im Chat-Interface ein Drehbuch als JSON-Datei, das die Lehrperson freigibt; aus dem Drehbuch entsteht ein Besetzungsbogen für die Figuren, der ebenfalls freigegeben wird; erst dann erzeugt ein Bildmodell alle Panels in einem Serienauftrag mit dem Besetzungsbogen als Referenz, damit die Figuren über die Seiten hinweg dieselben bleiben. Drei Dramaturgien stehen zur Wahl, eine Fallstudie als Geschichte mit Protagonistin und Dilemma, eine Erklärgeschichte und ein Escape Room mit Lösungsblatt; zehn Themenvorlagen decken die Fächer der Workshop-Teilnehmenden ab. Die Kosten liegen bei etwa 0,30 bis 0,40 US-Dollar je Teilnehmerin und Comic. Geprüft ist der vollständige Probelauf mit Platzhaltern und der Aufruf gegen einen nachgebauten Server; nicht geprüft sind der echte Aufruf beim Bildanbieter, die Bildqualität und die Konsistenz der Figuren.

Text zu Folien und Film mit Wächter und Protokollfolie (in Erprobung). Zwei Workflow-Vorlagen für den Baukasten aus Kapitel D.6 machen aus einem eingefügten Text eine Präsentation mit KI-Bildern, die zweite zusätzlich mit einem fünfsekündigen Clip je Folie. Ein Wächter, ein Skript und kein Modell, bricht ab, bevor etwas gesendet wird, wenn der Text eine E-Mail-Adresse, eine mögliche Matrikelnummer oder eine Telefonnummer enthält; eine Plan-Prüfung zählt Folien und Wörter gegen die Regeln des Folien-Skills aus Kapitel D.2; eine Kontrollseite zeigt Plan und geschätzte

Kosten, und erst die Freigabe löst die Bildaufträge aus. Die letzte Folie ist ein Protokoll mit allen Prompts, Modellen und Kosten und einem Feld "Geprüft von". Beide Vorlagen wurden lokal gegen nachgebaute Dienste und in einem echten Browser durchgespielt; der erste Lauf mit echten Schlüsseln in der Cloud steht aus. Drei Folien mit Bildern kosten etwa 0,05 US-Dollar, drei Folien mit Clips etwa 1,70 US-Dollar nach Schätzung.

Diagnostisches Feedback je Codename (in Erprobung). Die Codenamen aus Kapitel D.8 sind der Schlüssel zu einer Nutzungsform, bei der die KI individuelles Feedback zu Tests und Abgaben erzeugt, ohne je einen echten Namen zu sehen: Studierende reichen unter Codename ein, ein Feedbackblatt je Codename entsteht aus Musterlösung, Bewertungsraster und der anonymen Abgabe, und die Zuordnung zur Person liegt allein in der Tabelle der Lehrperson. Ein Beispielmodul aus dem Supply-Chain-Management setzt dieses Muster ein.

Multi-Agenten-Simulationen (in Erprobung). Die Agenten-Designs aus Kapitel C.5.2, mit Mentor, Gegenspieler und Evaluator als getrennten Rollen, lassen sich mit den Werkzeugen dieses Anhangs als Skill-Bündel und Workflow nachbauen, und sie gewinnen einen neuen Prüfstand: Ein aus echten Tutoring-Daten gewonnenes simuliertes Studierendenmodell erlaubt es, Tutor- und Rollenspielsysteme in synthetischen Dialogen zu testen, bevor echte Lernende ihnen begegnen (Perczel et al., 2025), und adaptive Hinweisdosierung lässt sich datengestützt lernen statt manuell verdrahten (Chang et al., 2026). Für die Lehre heißt das, dass die vier Prüfschichten aus Kapitel D.7 künftig teilweise von simulierten Studierenden durchlaufen werden können; ob das die Einigkeit menschlicher Bewertender ersetzt, ist offen.

Online-Material

Alle Übungsblätter dieses Anhangs, die Skill-Dateien `folien-evidenzbasiert` und `statistik-tutor`, die Build-Prompts für eigene Tutoren, das Colab-Notebook zur Simulation, die Workflow-Vorlagen mit ihren Primern und die Notebooks der Storyboard-Werkstatt liegen gesammelt in der Online-Version des Buchs und werden dort fortgeschrieben; die gedruckte Fassung hält den Stand vom Oktober 2026 fest.

Abbildung D.8. Online-Material zu Anhang D: Übungsblätter, Skill-Dateien, Notebooks und Workflow-Vorlagen. QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/anhang-d-material.html aufrufen.

Transparenzhinweis

Dieser Anhang entstand aus den Inputs, Übungen und Primern des Aufbaukurses "Jenseits einfacher Prompts" (hdw nrw, 12. Oktober 2026). Bei der Übertragung in das Buchformat wurde Claude / Cowork zur Konvertierung, zur Strukturierung nach dem Muster von Anhang C, für Sprach- und Konsistenzchecks sowie zum Abgleich der Zitierschlüssel mit dem Literaturverzeichnis genutzt. Alle Inhalte wurden von Roman Bartnik geprüft, überarbeitet und verantwortet.

E Praxis-Primer für Lehrende

Die Primer dieses Anhangs beantworten je eine Frage: Wie erstelle ich dieses Lernmaterial mit KI so, dass es lernwirksam ist, und woran erkenne ich, dass es misslungen ist? Jeder Primer folgt demselben Aufbau. Ein Prinzip sagt, wofür das Format taugt und wofür nicht. Empfehlungen in Wenn-dann-Form tragen je eine Prüffrage, die sich in unter einer Minute beantworten lässt. Ein Arbeitsablauf nennt in jedem Schritt, was die Lehrperson nicht an die KI abgibt. Eine Prüfliste fasst die Empfehlungen zum Abhaken zusammen, und ein erprobtes Beispiel aus der eigenen Lehre zeigt die Umsetzung mit Stand-Vermerk. Werkzeuge, Prompts und Prüfskripte veralten schneller als ein Buch; sie stehen vollständig in der Online-Version.

E.1 Primer 0: Welches Format für welches Lehrziel?

Wer mit KI Lernmaterial erstellt, beginnt leicht beim Werkzeug: Ein Musikgenerator steht bereit, also entsteht ein Song. Die Reihenfolge gehört umgekehrt. Zuerst steht fest, welche Art von Wissen die Studierenden erwerben sollen, daraus folgt das Format, zuletzt das Werkzeug. Tabelle E.1 ordnet die vier Formate dieses Anhangs den Wissensarten der überarbeiteten Bloom-Taxonomie zu (Anderson & Krathwohl, 2001): Faktenwissen (Begriffe, Einzelheiten), konzeptuelles Wissen (Zusammenhänge, Modelle, Prinzipien) und prozedurales Wissen (Verfahren und die Kriterien, wann welches passt).

Format	Stärke: Lehrziel	Wissensart	Falsches Mittel für	Primer
Animation	wie sich etwas verändert: Prozesse, Dynamik, Wirkungsketten	konzeptuell	Aufbau und räumliche Anordnung; dafür genügt ein Standbild (Ploetzner et al., 2021)	Kapitel E.2

Format	Stärke: Lehrziel	Wissensart	Falsches Mittel für	Primer
Präsentation	ein Argument in Schritten: Aussage und Beleg	konzeptuell	Üben und Nachschlagen; die Folie ist kein Skript	Kapitel E.3
Lernsong	wörtlicher Abruf und feste Reihenfolge: Listen, Formeln, Merksätze	Faktenwissen	Verstehen und Anwenden; wer einen Merkspruch aufsagen kann, kann ihn noch nicht anwenden (Mocko et al., 2024)	Kapitel E.4
Lernspiel	Üben mit Rückmeldung (Abrufspiel); Entscheiden unter Folgen (Planspiel)	Fakten- bzw. prozedurales Wissen	alleinige Instruktion ohne Erklärung und Nachbesprechung (Wouters et al., 2013)	Kapitel E.5

Tabelle E.1. Vier Formate, vier Lehrziele. Die Spalte rechts verweist auf den Primer.

Die vierte Wissensart der Taxonomie, metakognitives Wissen über das eigene Lernen, fördert keines der vier Formate von selbst. Dafür braucht es Reflexion, etwa die Nachbesprechung nach einem Planspiel.

E.2 Primer A: Didaktische Animationen

i Prinzip: Wofür Animationen taugen, wofür nicht

Eine Animation zeigt, wie sich etwas verändert; die Lernenden müssen die Veränderung nicht im Kopf aus Einzelbildern zusammensetzen. Darin liegt ihr Vorteil. Über alle Studien hinweg schlagen Animationen statische Bilder nur knapp (Berney & Bétrancourt, 2016). Den Grund zeigt eine Nachanalyse dieser Metaanalyse: Der Vorteil ist deutlich, wenn die Merkmale der Veränderung selbst Lernstoff sind (Ploetzner et al., 2020). Ein Experiment bestätigt die Arbeitsteilung: Bewegungsabläufe eines Getriebes erkannten Studierende nach einer Animation am besten, die räumliche Anordnung der Zahnräder nach

statischen Bildern (Ploetzner et al., 2021). Bewegung lohnt sich also für Prozesse, Dynamik und Wirkungsketten, etwa für das Aufschaukeln von Bestellungen in einer Lieferkette. Für Aufbau, Begriffe und Vergleiche genügt ein gutes Standbild, und es kostet weniger.

Empfehlungen

1 Animieren Sie nur Veränderung, die Lernstoff ist. Ein Punkt, der auf der Kostenkurve zum Minimum wandert, zeigt den Inhalt; eine einfliegende Überschrift bindet Aufmerksamkeit und lehrt nichts. *Prüfen:* Lässt sich das Lernziel als „wie sich X verändert" formulieren?
2 Bauen Sie die Animation in Schritten auf, die Sie per Klick auslösen, und stellen Sie vor der Auflösung eine Vorhersagefrage. Segmentierte Darstellungen verbessern Behalten und Transfer (Rey et al., 2019). Jeder Haltepunkt ist zugleich der Ort, an dem die Lernenden vorhersagen, was als Nächstes geschieht, und so vom Zuschauen zum Denken wechseln. *Prüfen:* Wartet jeder Schritt auf einen Klick, und steht vor dem entscheidenden Schritt eine Frage?
3 Führen Sie den Blick wie ein Verfolgerscheinwerfer. Das Grundbild bleibt in Graustufen, genau eine Akzentfarbe markiert das, worüber Sie gerade sprechen, und Bekanntes tritt ins Grau zurück. Hervorhebungen verbessern das Lernen mit Medien (Schneider et al., 2018); ein Signal wirkt aber nur, weil es sich abhebt, und fünf Farben heben nichts mehr ab. Kategorien unterscheiden Sie über Form, Strichart oder direkte Beschriftung. *Prüfen:* Ist das Bild ohne Farbe vollständig lesbar und ohne Farblegende verständlich?
4 Erklären Sie mit der Stimme und halten Sie den Text im Bild knapp. Animationen schnitten in der Metaanalyse besser ab, wenn sie gesprochen kommentiert wurden oder ohne Begleittext auskamen (Berney & Bétrancourt, 2016). Als Faustregel gelten höchstens acht neue Wörter je Schritt, direkt am Objekt, und eine Bildunterschrift von einem Satz für das Selbststudium. *Prüfen:* Wie viele neue Wörter bringt der Schritt mit den meisten?
5 Geben Sie den Lernenden ein Leitobjekt, statt viele Kennzahlen gleichzeitig zu zeigen. In komplexen Animationen schauen Lernende auf das, was sich auffällig bewegt, nicht auf das fachlich Wichtige (Lowe, 2003). Ein Objekt, dem man durch den Ablauf folgt, und eine Bewegung zur Zeit lösen diesen Konflikt. *Prüfen:* Kann eine Studentin

nach dem Ansehen sagen, welchem Objekt sie gefolgt ist?
6 Bauen Sie zu jeder Animation einen Druckzwilling. Das vollständige Endbild trägt die Aussage auf Papier, in der Prüfungsvorbereitung und für alle, die die Animation nicht abspielen können; ein QR-Code führt zur bewegten Fassung. *Prüfen:* Ist das Endbild in Graustufen lesbar?

Arbeitsablauf mit KI. Ein Sprachmodell schreibt den Code einer Animation in Minuten. Die Arbeit der Lehrperson verschiebt sich auf die Stellen, die das Modell nicht übernimmt.

1. **Lehrziel und Storyboard.** Kernaussage als Satz, Vorhersagefrage, eine Tabellenzeile je Schritt mit genau einem neuen Element. *Nicht abgeben:* die Kernaussage und die Entscheidung, was in welchem Schritt neu ist.
2. **Auftrag an die KI.** Storyboard und Gestaltungsregeln als fester Textbaustein im Auftrag. *Nicht abgeben:* die Regeln; ohne sie liefert das Modell Flutlicht statt Scheinwerfer.
3. **Erzeugen.** Das Modell baut aus einer Vorlage eine Webseite oder ein Animationsskript. *Nicht abgeben:* die Zahlen; sie kommen aus einem nachgerechneten Modell.
4. **Prüfen.** Ein Prüfskript zählt je Schritt Farben, Wörter und neue Elemente, dann folgt die Sichtprüfung jedes Schritts in Graustufen. *Nicht abgeben:* das Urteil über fachliche Richtigkeit.
5. **Einsetzen.** Im Hörsaal mit Vorhersagefrage und Pause, im Skript mit Druckzwilling. *Nicht abgeben:* das Tempo.

Prüfliste.

- ☐ Das Lernziel lautet „wie sich X verändert“.
- ☐ Der Titel ist eine Aussage, kein Thema.
- ☐ Vor der Auflösung steht eine Vorhersagefrage.
- ☐ Jeder Schritt wartet auf einen Klick und bringt genau ein neues Element.
- ☐ Graustufen plus eine Akzentfarbe; keine Farblegende nötig.
- ☐ Höchstens acht neue Wörter je Schritt; Bildunterschrift ein Satz.
- ☐ Ein Leitobjekt, eine Bewegung zur Zeit.
- ☐ Zahlen nachgerechnet, Annahmen als „Lehrmodell“ gekennzeichnet.
- ☐ Druckzwilling in Graustufen lesbar, mit QR-Code.

! Umsetzung, Stand 10/2026

Die Animation zur optimalen Bestellmenge (Abbildung E.1) entstand nach diesem Ablauf: Storyboard mit sechs Schritten, Bau durch ein Sprachmodell (Claude Opus 5.5) aus einer festen Vorlage als einzelne Webseite mit Vektorgrafik, Messung mit einem Prüfskript. Weil die Regeln im Auftrag standen, hielt sie das Budget im ersten Prüflauf ein; nachgebessert wurden nur zwei Stellen, an denen eine Kurve eine Beschriftung schnitt. Vom Storyboard bis zur Freigabe braucht eine solche Animation weniger als eine Stunde. Animationen, die für dieses Buch zuvor ohne solche Regeln entstanden waren, schnitten anders ab: Im Messlauf vom Oktober 2026 blieb keine der zwölf Erklär- und Prozessansichten im Budget, alle zeigten schon im ersten Bild mehr als 40 Wörter, vier unterschieden Kategorien über Farbe. Eine Animation zu parallel arbeitenden KI-Agenten wurde erst verständlich, als nebeneinanderliegende Bahnen mit Kennzahlen einer einzigen Kugel wichen, der die Lernenden folgen. Die wichtigste praktische Regel lautet deshalb: Gestaltungsregeln gehören in den Auftrag an die KI und in ein Prüfwerkzeug, nicht in die Nachbesserung.

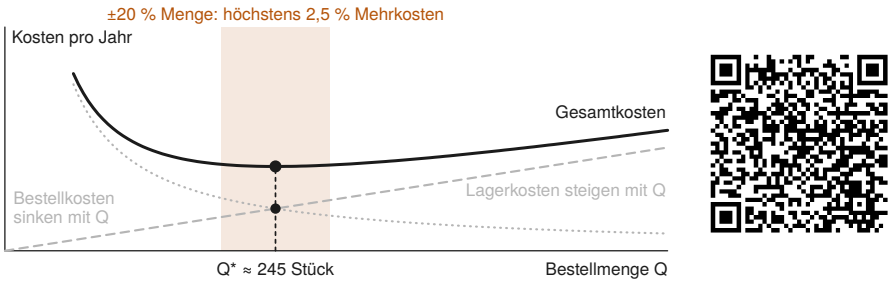

Abbildung E.1. Die optimale Bestellmenge gleicht zwei gegenläufige Kosten aus: Endbild der sechsstufigen Animation (Lehrmodell nach Harris (1990)). Die interaktive Fassung, den Prompt-Baustein, das Prüfskript und die Manim-Zellen für Colab gibt es in der Online-Version: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/anhang-primer.html#sec-primer-animationen aufrufen.

Prinzip: Was die Forschung nicht belegt

Ob mit KI erstellte Animationen anders wirken als von Hand gebaute, ist nicht untersucht; die Belege gelten der Gestaltung, nicht dem Herstellungsweg. Die Budgetzahlen dieses Primers, acht neue und 40 sichtbare Wörter je Schritt, eine Akzentfarbe, sind aus den Befunden abgeleitete Faustregeln, keine gemessenen Grenzwerte.

E.3 Primer B: Präsentationen

Prinzip: Wofür Präsentationen taugen, wofür nicht

Im Hörsaal teilen sich Stimme und Folie die Arbeit: Die Stimme erklärt, die Folie zeigt, worauf sich die Erklärung stützt. Garner & Alley (2013) ließen 110 Ingenieurstudierende denselben gesprochenen Vortrag hören, die eine Hälfte mit Folien aus Themenüberschrift und Aufzählung, die andere mit einem Satz als Titel und einem Bild als Beleg. Die zweite Gruppe verstand mehr, hatte weniger Fehlvorstellungen und wusste eine Woche später noch mehr. Steht dagegen viel Text auf der Folie, lesen die Zuhörenden mit und überhören, was nur gesagt wird (Wecker, 2012). Eine Präsentation taugt darum für ein Argument in Schritten: Aussage, Beleg, nächste Aussage. Zum Üben taugt sie nicht, und zum Nachlesen nur mit einem eigenen Skript (Kapitel E.1).

Empfehlungen

1 Schreiben Sie die Aussage der Folie in den Titel. Ein ganzer Satz mit einer Behauptung, höchstens zwei Zeilen: „Kleine Schwankungen im Handel wachsen zum Hersteller hin“ statt „Bullwhip-Effekt: Überblick“. Der Satztitel gehört zu den Merkmalen, mit denen die Folien bei Garner & Alley (2013) besser abschnitten. *Prüfen:* Erzählen die Titel, nacheinander gelesen, das ganze Argument?
2 Füllen Sie den Folienkörper mit dem Beleg, nicht mit dem Vortragstext. Diagramm, Schaubild, Tabelle oder eine große Zahl mit Vergleichswert; Text nur als Beschriftung am Objekt, als Faustregel

höchstens 15 Wörter. Was Sie sagen, steht in den Sprechernotizen, nicht auf der Folie (Wecker, 2012). *Prüfen:* Würde man dem Titel allein aufgrund des Bildes glauben?
3 Bauen Sie Abläufe und Wechselwirkungen in Schritten auf. Erst die Bausteine einzeln, dann ihr Zusammenspiel; Lernende mit wenig Vorwissen verstehen komplexen Stoff so besser (Pollock et al., 2002). Jeder Schritt bringt eine neue Gruppe in der Akzentfarbe, Bekanntes tritt zurück wie beim Verfolgerscheinwerfer in Kapitel E.2. *Prüfen:* Hat jede Folie höchstens vier Gruppen, und zeigt der letzte Schritt das vollständige Bild?
4 Streichen Sie, was nur schmückt. Interessante, aber für das Lernziel unwichtige Bilder und Details verschlechtern Behalten und Transfer (Rey, 2012). Stockfotos, Symbolbilder und Pfeilketten ohne eindeutige Bedeutung fallen darunter. *Prüfen:* Geht Information verloren, wenn Sie das Element löschen?
5 Zeigen Sie nur Zahlen, deren Herkunft Sie kennen. Ein Diagramm überzeugt durch seine Form, ob die Werte stimmen oder nicht. Lassen Sie Werte darum rechnen statt schreiben: aus der Originalquelle oder aus einem nachgerechneten Beispiel, das als Lehrmodell gekennzeichnet ist; fehlt beides, zeigt ein Schaubild die Beziehung ohne Werte. *Prüfen:* Können Sie zu jeder Zahl sagen, woher sie kommt?
6 Setzen Sie genau eine vollständige Quelle auf jede Folie und prüfen Sie sie am DOI. Die Quellenzeile zeigt Studierenden, worauf eine Aussage beruht; an Zeitschrift und DOI lernen sie, Quellen einzuschätzen. Im Testlauf unten stimmten alle Quellen, ohne Regelwerk fehlte aber auf jeder Folie die DOI. *Prüfen:* Führt der DOI zu dieser Arbeit, und stützt sie den Titel der Folie?

Arbeitsablauf mit KI. Ein Sprachmodell baut einen Foliensatz in Minuten. Die Arbeit der Lehrperson liegt am Anfang, beim Argument, und am Ende, bei der Prüfung.

1. **Lehrziel und Argument.** Leitfrage, Antwort als ein Satz, Argumentationsübersicht in vier Blöcken: Problem, Konzepte, Evidenz, Fazit. *Nicht abgeben:* die Aussage, auf die der Vortrag hinausläuft.
2. **Auftrag an die KI.** Gestaltungsregeln als fester Baustein, dazu die Quellen und Daten, die verwendet werden dürfen; zuerst nur ein Storyboard mit einer Zeile je Folie: Titel, Beleg, Quelle. *Nicht abgeben:*

die Freigabe des Storyboards.

3. **Erzeugen.** Folien in der Hochschulvorlage mit Sprechernotizen. *Nicht abgeben:* die Daten hinter jedem Diagramm.
4. **Prüfen.** Jede Folie als Bild ansehen und gegen die Prüfliste halten, jede Quelle am DOI öffnen. *Nicht abgeben:* das Urteil über fachliche Richtigkeit und Quellen.
5. **Einsetzen.** Frei zur Folie sprechen, die Notizen dienen als Gerüst; wer ein Handout braucht, bekommt ein eigenes Dokument. *Nicht abgeben:* die Erklärung; sie gehört der Stimme.

Prüfliste.

- ☐ Jeder Titel ist ein ganzer Satz mit einer Behauptung.
- ☐ Die Titel erzählen nacheinander gelesen das Argument.
- ☐ Der Folienkörper belegt den Titel; höchstens 15 Wörter, nichts zum Vorlesen.
- ☐ Höchstens vier Gruppen je Folie; Abläufe schrittweise, letzter Schritt vollständig.
- ☐ Genau eine Hervorhebung in der Akzentfarbe; in Graustufen lesbar.
- ☐ Jedes Bild besteht den Löschtest.
- ☐ Jede Zahl hat eine Herkunft; Lehrmodelle sind gekennzeichnet.
- ☐ Je Folie eine vollständige Quelle, DOI geöffnet und geprüft.
- ☐ Sprechernotizen in ganzen Sätzen.

! Umsetzung, Stand 10/2026

Für diesen Primer entstand ein Foliensatz zum Bullwhip-Effekt zweimal, mit demselben Sprachmodell (Claude Opus 5.5) und demselben Auftrag einer Lehrperson: einmal ohne Regelwerk, einmal mit dem Regelwerk dieses Primers und der Folienvorlage der Hochschule als Dateien im Auftrag (Abbildung E.2). Beide Läufe fanden echte Quellen und ließen ihre Zahlen per Programm nachrechnen. Die Unterschiede lagen im Folienkörper. Ohne Regelwerk standen auf den Inhaltsfolien im Median 64 statt 12 Wörter, die DOIs fehlten, zwei Folien trugen je zwei Quellen, und das Modell sah zwei Schmuckbilder und elf Farbtöne vor. Mit Regelwerk brauchte das Modell fünf Prüfrunden, bis jede Folie die Prüfliste bestand. Seine Erstfassung scheiterte an Beschriftungen, die sich überlagerten, an Titeln über drei Zeilen und an knapp überschrittenen Wortgrenzen,

also an Fehlern, die erst im gerenderten Bild sichtbar werden. Ein Lauf dauerte sechs beziehungsweise elf Minuten; mit Durchsicht und Freigabe durch die Lehrperson braucht ein solcher Foliensatz weniger als eine Stunde. Ein Testlauf ist keine Studie, er zeigt aber, wohin die Arbeit wandert: Das Regelwerk gehört in den Auftrag, und geprüft wird jede Folie als Bild, nicht im Quelltext.

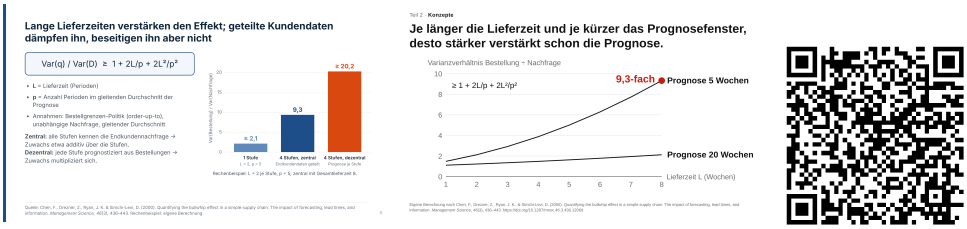

(a) Ohne Regelwerk (b) Mit Regelwerk

Abbildung E.2. Dieselbe Aussage nach F. Chen et al. (2000), zweimal vom selben Sprachmodell gebaut: Ohne Regelwerk erklärt die Folie sich selbst in Sätzen, mit Regelwerk belegt sie den Titel mit einem Diagramm und überlässt die Erklärung der Stimme. Beide Foliensätze, den Prompt-Baustein und das Regelwerk gibt es in der Online-Version: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/anhang-primer.html#sec-primer-praesentationen aufrufen.

Prinzip: Was die Forschung nicht belegt

Die Belege für Satztitel und Bildbeleg stammen aus wenigen Studien einer Arbeitsgruppe, überwiegend mit Ingenieurstudierenden. Wie mit KI erstellte Folien auf das Lernen wirken, ist kaum untersucht: In einer Informatik-Lehrveranstaltung bewerteten Studierende KI-Folien, die der Lehrende überarbeitet hatte, so gut wie seine eigenen und erkannten sie nicht; ihr Lernen wurde nicht gemessen (Leinonen et al., 2026). Die Grenzen von 15 Wörtern und vier Gruppen sind Faustregeln.

E.4 Primer C: Lernsongs

Prinzip: Wofür Lernsongs taugen, wofür nicht

Musik trägt die Form eines Inhalts, nicht sein Verstehen. Gesungenes wird im Wortlaut und in der Reihenfolge besser behalten; in einer systematischen Übersicht fanden 28 von 37 Studien einen Vorteil musikalischer Merkhilfen (Derks-Dijkman et al., 2024). Bedeutung transportiert der Gesang nicht. Auch ohne Musik gilt: Studierende der Einführungsstatistik erinnerten Akronyme häufiger als andere Merkhilfen, erklären und anwenden konnten sie aber eher die satzförmigen (Mocko et al., 2024). Ein Lernsong taugt darum für das, was wörtlich sitzen soll, eine Formel, eine Liste, die Reihenfolge eines Verfahrens, und er kommt nach der Erklärung, nicht an ihrer Stelle. Einen Zusammenhang erklärt eine Animation oder Präsentation besser, Rechnen und Entscheiden übt man mit Aufgaben und Spielen (Kapitel E.1). Den Einsatz eines Songs in der eigenen Lehre zeigt Kapitel 6.1.2.

Studierende sollen hinterher …	Song?	Typ	Was dazugehören muss
eine Formel wörtlich abrufen	ja	Merkjingle, höchstens vier Zeilen	Herleitung vorher, Formel schriftlich, Rechenaufgabe danach
eine Liste vollständig aufzählen	ja	Listenlied	Bedeutung getrennt gelehrt, Zuordnung an Fällen danach
Schritte in fester Reihenfolge nennen	ja	Listenlied mit „weil“ je Übergang	Anwendungsaufgabe
erklären, warum ein Effekt entsteht	nur mit Erklärung	Wirkungsketten-Ballade	Erklärung vorher, Textblatt, zweiter Fall zum Vergleich
eine Formel anwenden, rechnen	nein	–	Übungsaufgaben, Lösungsbeispiele

das eigene Entscheiden ändern	nicht allein	Ballade als letztes Glied	Spiel und Nachbesprechung an den eigenen Daten vorher

Tabelle E.2. Vom Lehrziel zum Songtyp. Die beiden unteren Zeilen enden ohne Song oder mit dem Song am Schluss einer Sequenz.

Empfehlungen

1 Spielen Sie den Song erst nach der Erklärung desselben Inhalts. Der Song hält fest, was vorher erarbeitet wurde. Wer eine Merkhilfe aufsagen kann, versteht sie deshalb noch nicht (Mocko et al., 2024); das Verstehen muss vorher entstehen. *Prüfen:* Gibt es vor dem Song eine gesprochene oder geschriebene Erklärung desselben Inhalts?
2 Planen Sie mindestens drei Durchgänge an zwei Tagen, als eigene Hörphase. Studierende, die ein Lied über Tage verteilt übten, behielten es nach drei Wochen besser als nach massiertem Üben (Katz et al., 2021). Als Hintergrund beim Lesen oder Rechnen stört Musik mit Text mehr, als sie nützt. *Prüfen:* Stehen im Plan drei Durchgänge an verschiedenen Tagen ohne gleichzeitige Lese- oder Rechenaufgabe?
3 Prüfen Sie jede Zeile ohne Musik auf fachliche Richtigkeit. Ein Reim lässt eine Aussage wahrer erscheinen, auch der Person, die sie prüft (McGlone & Tofighbakhsh, 2000). Lieber kein Reim als ein falscher; Fachbegriffe und Formelsymbole werden als ganze Wörter gesungen. *Prüfen:* Hält jede Zeile am bloßen Text einer Fachprüfung stand?
4 Liefern Sie den Text mit und gestalten Sie die Aufnahme auf Verständlichkeit. Hörende verstanden gesungene Texte über zwölf Genres im Mittel nur zu 72 %, je nach Genre zwischen 48 und 96 % (Condit-Schultz & Huron, 2015). Eine Solostimme, ruhiges Sprechtempo, sparsame Begleitung und ein Textblatt oder Untertitel fangen das ab. *Prüfen:* Singt eine Stimme, lässt sich der Text im Songtempo mitsprechen, und liegt er schriftlich bei?
5 Geben Sie eine Aufnahme frei und verwenden Sie nur diese. Musikgeneratoren erzeugen bei jedem Durchlauf eine andere Fassung; der Gewinn der Wiederholung hängt aber daran, dass Takt und Gruppierung gleich bleiben. Ein Verhörer wird durch Ersetzen der

einen Zeile repariert, nicht durch neues Generieren. *Prüfen:* Hören alle Studierenden in allen Durchgängen dieselbe Datei?
6 Lassen Sie auf den Song eine Aufgabe ohne Musik folgen. Für eine Formel ist das eine Rechenaufgabe, für eine Liste die Zuordnung an kurzen Fällen, für eine Wirkungskette ein zweiter, strukturgleicher Fall mit Vergleichsauftrag; Fallvergleiche fördern den Transfer deutlich (Alfieri et al., 2013). *Prüfen:* Liegt die Folgeaufgabe vor, und braucht sie den Inhalt, nicht den Wortlaut?

Arbeitsablauf mit KI. Drei Werkzeuge teilen sich die Arbeit: Ein Sprachmodell schreibt Text und Prüfprotokoll, ein Musikgenerator setzt eine Stilangabe in eine Aufnahme um, eine Spracherkennung prüft, ob die Fachwörter hörbar sind.

1. **Lehrziel und Einsatzplan.** Ein Satz „Studierende können hinterher …“, der Typ nach Tabelle E.2, die Erklärung davor und die drei Hörtermine. *Nicht abgeben:* die Entscheidung, ob überhaupt ein Song das richtige Mittel ist.
2. **Auftrag an das Sprachmodell.** Lehrziel, Inhalt und die Textregeln als fester Baustein; zurück kommen Liedtext, Textblatt, Fachwortliste, Prüfprotokoll und Folgeaufgabe. *Nicht abgeben:* den Inhalt; das Modell erfindet nichts dazu.
3. **Fachprüfung am bloßen Text.** Fehler sind vor der Aufnahme am billigsten. *Nicht abgeben:* das Urteil über jede Zeile.
4. **Aufnahme und Abnahme.** Stilangabe nach Empfehlung 4, zwei Aufnahmen anhören, Klatschprobe, Transkript der Spracherkennung gegen die Fachwortliste. *Nicht abgeben:* die Freigabe einer einzigen Fassung.
5. **Einsetzen.** Nach der Erklärung, verteilt, mit Textblatt und Folgeaufgabe. *Nicht abgeben:* den Einsatzplan.

Prüfliste.

- ☐ Das Lehrziel steht als Satz, und Tabelle E.2 empfiehlt dafür einen Song.
- ☐ Die Erklärung kommt vor dem Song.
- ☐ Drei Durchgänge an mindestens zwei Tagen, als eigene Hörphase.
- ☐ Jede Zeile ohne Musik fachlich korrekt; kein Reim auf einer falschen Aussage.
- ☐ Jedes Symbol und jeder Fachbegriff als ganzes Wort gesungen.
- ☐ Eine Solostimme, Text im Songtempo mitsprechbar, kurzes Intro.

- ☐ Die Spracherkennung findet jedes Fachwort im Transkript.
- ☐ Textblatt oder Untertitel liegen bei.
- ☐ Eine freigegebene Aufnahme, lokal gespeichert, nicht neu generiert.
- ☐ Folgeaufgabe ohne Musik vorbereitet.

! Umsetzung, Stand 10/2026

Das Musikvideo *Every Forecast Is Wrong* (Kapitel 6.1.2) folgt dem Prinzip im Einsatz: Es steht am Ende eines Selbstlerntags nach Lektüre, Widget und Fallstudie, der Text läuft als Untertitel mit, und die Woche danach sieht einen zweiten Durchgang vor (Empfehlungen 1, 2 und 4). Text, Beispieldaten und Animationscode schrieb ein Sprachmodell (Claude), die Musik erzeugte ein Musikgenerator (Suno), geprüft und freigegeben hat die Lehrperson. Das Rechnen übernimmt der Song nicht; drei Instrumentalteile halten für durchgerechnete Beispiele an. Für die drei Songtypen der Tabelle wurden die Prompt-Vorlagen an der Bestellmengenformel, an der Liste der acht Verschwendungsarten und am Bullwhip-Effekt durchgespielt. Die Textfassungen hielten die Regeln weitgehend ein; an zwei Stellen ging das Modell über den mitgegebenen Inhalt hinaus und markierte das selbst im Prüfprotokoll. Die Schwachstellen lagen woanders, als man erwartet: Buchstabennamen wie „D S durch H“ verschwimmen gesungen leicht, englische Fachbegriffe in einem deutschen Lied fordern Sänger und Spracherkennung zugleich, und eine fachlich vollständige Wirkungskette erzeugt Zeilen, die sich in ruhigem Tempo kaum singen lassen. Das Prüfprotokoll des Modells erleichtert die Fachprüfung, ersetzt sie aber nicht.

Abbildung E.3. Vollfassung von Primer C mit Prompt-Baustein, Stilangabe für den Musikgenerator, Prüfskript für die Spracherkennung und einer durchgespielten Textprobe: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/anhang-primer.html#sec-primer-lernsongs aufrufen.

Prinzip: Was die Forschung nicht belegt

KI-generierter Gesang ist als Lernmaterial nicht untersucht. Der Hochschulbezug der Evidenz ist dünn; die meisten Studien testen sofort, mit Kindern oder ohne Transferaufgabe. Ob ein gesungener Text besser verstanden wird als ein gelesener, ist umstritten, und ob eine gesungen gelernte Formel das Rechnen erleichtert, hat niemand geprüft.

E.5 Primer D: Lernspiele

Prinzip: Wofür Lernspiele taugen, wofür nicht

Ein Lernspiel lehrt über die Handlung, mit der man im Spiel vorankommt. Ist sie ein Abruf mit Rückmeldung, wirkt das Spiel wie ein Übungstest (Adesope et al., 2017). Ist sie eine Entscheidung, deren Folgen in die nächste Runde reichen, wirkt es wie eine Simulation, und dann gehört eine Nachbesprechung dazu. Im Mittel lernen Studierende mit Spielen nur wenig mehr als mit Vergleichsunterricht, und auch das nur, wenn sie mehrmals spielen (Clark et al., 2016); motivierender als herkömmlicher Unterricht waren Serious Games in einer Metaanalyse nicht (Wouters et al., 2013). Ein Lernspiel taugt darum zum Üben mit Rückmeldung und zum Entscheiden unter Folgen (Tabelle E.3). Einen Zusammenhang erklärt es nicht; dafür sind Animation und Präsentation da (Kapitel E.1). Wann ein Quiz kein Simulator ist, zeigt Kapitel 6.1.3.

Studierende sollen hinterher …	Spieltyp	Was dazugehören muss
Begriffe, Fakten, Formeln abrufen	Abrufspiel (Quiz)	Erklärung vorher, Lösung mit Grund nach jeder Antwort
Begriffe oder Fälle zuordnen	Zuordnungsspiel	Begründung je Zuordnung
ein Verfahren ausführen, rechnen	Abrufspiel mit berechneten Aufgaben	Lösungsweg als Rückmeldung

Studierende sollen hinterher …	Spieltyp	Was dazugehören muss
unter Zielkonflikten entscheiden	Planspiel mit Zustand	Nachbesprechung an den eigenen Verlaufsdaten
ein Gespräch führen	Gesprächsrollenspiel mit KI (Anhang C)	Rolle und Abbruch festgelegt, Nachbesprechung am Protokoll

Tabelle E.3. Vom Lehrziel zum Spieltyp. Gamification, also Punkte, Abzeichen und Ranglisten, ist kein eigener Typ, sondern eine Schicht über einem Lernprozess.

Empfehlungen

1 Machen Sie die Lernhandlung zum Spielzug. Weiter kommt nur, wer das Freikörperbild richtig wählt oder den Begriff richtig zuordnet; Punkte und Geschichte hängen daran, nicht umgekehrt. In einem Experiment mit Kindern lernten die Spielenden mit dieser Kopplung mehr und spielten freiwillig siebenmal länger (Habgood & Ainsworth, 2011), und ein schlichtes Quiz schnitt in der Metaanalyse nicht schlechter ab als ein aufwendiges Spiel (Clark et al., 2016). *Prüfen:* Kann man gewinnen, ohne die Lernhandlung richtig auszuführen?
2 Erklären Sie jeden Fehler und holen Sie ihn zurück. Nach jeder Antwort zeigt das Spiel die Lösung mit einem Satz Begründung; falsch Beantwortetes kommt wieder, bis es sitzt. Unterstützung im Spiel verbessert das Lernen (Wouters & van Oostendorp, 2013), und Abrufübung und verteiltes Üben gehören zu den wirksamsten Lerntechniken überhaupt (Dunlosky et al., 2013). Ein bloßes „Leider falsch“ verschenkt beides. *Prüfen:* Nennt die Rückmeldung einen Grund, und kehrt eine falsch beantwortete Aufgabe wieder?
3 Planen Sie mindestens zwei Termine und eine Nachbesprechung. Eine einzelne Spielsitzung zeigte keinen Lerneffekt, mehrere einen deutlichen (Clark et al., 2016). Nach Planspielen und Rollenspielen verbessert eine Nachbesprechung die Leistung deutlich, am stärksten mit objektiven Leistungsdaten auf dem Tisch (Keiser & Arthur, 2021), im Planspiel also mit dem Verlauf der eigenen Entscheidungen. *Prüfen:* Steht das Spiel an zwei Terminen im Plan, und hat die

Nachbesprechung einen eigenen Zeitslot mit Daten aus dem Spiel?
4 Verzichten Sie auf öffentliche Einzelranglisten und Punkte für Tempo. Einzelwettbewerb brachte keinen Lerneffekt (Clark et al., 2016); eine Rangliste in Vorlesungsquizzen senkte den Austausch unter Studierenden, ohne die Leistung zu heben (Michinov & Michinov, 2026). Punkte für schnelle Antworten belohnen Raten, wo Sorgfalt das Lernziel ist. Wer Wettbewerb will, lässt Teams gegeneinander spielen. *Prüfen:* Sieht jemand eine Einzelrangliste, oder zählt Geschwindigkeit?
5 Lösen Sie jede Aufgabe, die die KI erzeugt hat, selbst, bevor Lernende sie sehen. Generierte Prüfungsfragen sind meist brauchbar, aber etwa jede zwanzigste hatte mehr als eine richtige Antwort (Doughty et al., 2024), und auf KI-gestützt erstellten Fragen schnitten Studierende schlechter ab, ohne den Unterschied zu bemerken (Witsken et al., 2025). Rechenaufgaben lassen Sie besser von einem Programm erzeugen und lösen; die KI formuliert nur. *Prüfen:* Ist jede Aufgabe als selbst gelöst abgehakt, oder entsteht sie durch Rechnung?
6 Spielen Sie das Spiel zu Ende, bevor andere es spielen. Einmal nur mit richtigen Antworten, einmal nur mit falschen, einmal mit Unsinn: leeres Feld, Doppelklick, kleines Fenster. Spielcode aus einem Sprachmodell startet meist, ist aber selten fehlerfrei durchspielbar (Z. Peng et al., 2026), und in generierten Lernspielen fehlten am häufigsten Lernaufgaben oder waren verändert (Rogosch & Schrader, 2026). *Prüfen:* Gibt es ein Testprotokoll, in dem jede Aufgabe einmal richtig beantwortet und als richtig gewertet wurde?

Arbeitsablauf mit KI. Ein Sprachmodell schreibt den Code eines Lernspiels in kurzer Zeit; das Prüfen dauert länger als das Erzeugen (Taveter & Lepp, 2026). Die Arbeit der Lehrperson liegt deshalb im Lehrziel und in der Prüfung.

1. **Lehrziel und Spieltyp.** Ein Satz „Studierende können hinterher …“, der Typ nach Tabelle E.3, die Lernhandlung als Spielzug, zwei Termine im Plan. *Nicht abgeben:* Lehrziel und Typ; ein Sprachmodell schlägt gern eine „Simulation“ vor, wo ein Quiz gemeint ist.
2. **Auftrag an die KI.** Lernhandlung, Aufgaben oder ihre Quelle, Rückmelderegel und die Empfehlungen als fester Baustein. *Nicht abgeben:* Aufgaben und Lösungsschlüssel.
3. **Erzeugen.** In kleinen Schritten: erst eine Runde, testen, dann die nächste Funktion. *Nicht abgeben:* die Entscheidung, was das Spiel

nicht können muss.

4. **Prüfen.** Lernziele am fertigen Spiel abhaken, Prüflauf mit Protokoll, dann eine Testperson aus der Zielgruppe. Ein Sprachmodell, das Lernende spielt, findet schwache Fragen (Lu & Wang, 2024), gibt aber nichts frei. *Nicht abgeben:* das Urteil über fachliche Richtigkeit.
5. **Einsetzen.** Nach der Erklärung, an zwei Terminen, mit Nachbesprechung; Lernen mit Aufgaben außerhalb des Spiels prüfen, getrennt vom Gefallen. *Nicht abgeben:* die Nachbesprechung.

Prüfliste.

- ☐ Das Lehrziel steht als Satz, der Spieltyp passt dazu und zum Namen des Spiels.
- ☐ Gewinnen geht nur mit richtig ausgeführter Lernhandlung; die richtige Option steht nicht immer an derselben Stelle.
- ☐ Nach jeder Antwort erscheinen Lösung und Grund; Fehler kehren wieder.
- ☐ Keine Einzelrangliste, keine Tempopunkte.
- ☐ Jede KI-erzeugte Aufgabe selbst gelöst oder berechnet; jedes Lernziel im Spiel gefunden.
- ☐ Testprotokoll: jede Aufgabe einmal richtig akzeptiert, jeder Endzustand erreicht, Unsinnseingaben probiert.
- ☐ Ein KI-Tutor im Spiel kennt die Aufgabe und verrät die Lösung nicht.
- ☐ Eine Person aus der Zielgruppe hat ohne Hilfe gespielt; ohne Maus und ohne Zeitdruck bedienbar.
- ☐ Kein Zugangsschlüssel im Programmcode.
- ☐ Zwei Termine, Nachbesprechung mit Daten, Lernmessung getrennt vom Gefallen.

! Umsetzung, Stand 10/2026

Ein Erstsemesterteam im Modul WAGP (Kapitel 6.3.4) baute im Sommersemester 2025 ein Lernspiel zur Technischen Mechanik. In drei Stufen wählen die Spielenden unter drei Freikörperbildern das richtige für eine Alltagssituation und stellen dann die Gleichgewichtsbedingungen auf; das Programm vergleicht die Eingabe mit einem von Hand geschriebenen Schlüssel, gleich in welcher Reihenfolge die Terme stehen. Die Spielhandlung ist die Fachhandlung (Empfehlung 1), und die KI hat die Rolle mit dem

geringsten Risiko: Ein Sprachmodell beantwortet als Tutor Fragen, Aufgaben erzeugt es nicht. Sieben Testpersonen fanden einen Fachfehler, in den Gleichgewichtsaufgaben fehlte „= 0“, und urteilten nüchtern: Fünf von sieben antworteten auf die Frage, ob sie das Spiel vor der Klausur nutzen würden, mit „neutral“. Am Code zeigen sich drei Lücken. Die Rückmeldung sagt nur „falsch“, und Fehler kommen nicht wieder (Empfehlung 2). Der Tutor erhält die Aufgabe nicht, zu der gefragt wird, obwohl der Bericht ihn „kontextbezogen“ nennt. Belohnungen, die der Bericht beschreibt, fehlen im Code. Den Kontrast bildet das Zuordnungsspiel aus Kapitel 6.1.3: Dort erzeugt die KI die Lerninhalte selbst, und sie gehen ungeprüft aufs Spielfeld (Empfehlung 5).
Im selben Jahrgang waren acht von zehn Spielen Abrufquizze, drei nannten sich „Simulation“. Kein Team maß Lernen, keines plante eine Nachbesprechung, keines spielte sein Spiel einmal mit allen richtigen Antworten durch. Fünf hatten Fachfehler im Schlüssel oder in der Antwortprüfung; drei davon hätte ein solcher Prüflauf in Minuten gefunden. Gebaut wurde mit gängigen Mitteln, Python mit einfacher Oberfläche und Sprachmodellen über eine Programmierschnittstelle. Was fehlte, war der Prüfschritt.

Abbildung E.4. Vollfassung von Primer D mit Prompt-Baustein, Vorlage für das Testprotokoll und den Befunden aus zehn studentischen Spielprojekten: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/anhang-primer.html#sec-primer-lernspiele aufrufen.

Prinzip: Was die Forschung nicht belegt

Ob Lernspiele, die Lehrende oder Studierende mit KI bauen, anders wirken als von Hand gebaute, ist nicht untersucht; eine kontrollierte Studie dazu fand sich nicht. Die Empfehlungen 5 und 6 stützen sich auf

Fragenanalysen aus Programmier- und Medizinausbildung, technische Benchmarks und die Auswertung studentischer Projekte. Offen ist auch, ob ein Quizspiel mehr bewirkt als ein ungespieltes Quiz mit derselben Rückmeldung.

F Lösungshinweise zu den Lernfragen

Die Lernfragen am Ende jedes Kapitels steigen in drei Stufen an. Fragen zum **Wiederholen** haben eine Antwort, die im Kapitel steht; die Hinweise geben sie knapp wieder. Fragen zum **Anwenden** und **Beurteilen** beziehen sich auf die eigene Lehre und haben keine Musterlösung; die Hinweise nennen, was eine gute Antwort enthält. Die Wirkung des Abrufens entsteht beim Versuch, nicht beim Nachlesen (Kapitel 3.4). Schlagen Sie hier deshalb erst nach, wenn Sie eine eigene Antwort formuliert haben.

Kapitel 1: Einleitung

1. Erstens fehlt Lehrenden die Zeit für individuelle Förderung, zweitens sind wirksame Lehrmethoden aufwendig vorzubereiten. Generative KI senkt diesen Aufwand; die didaktische Entscheidung nimmt sie nicht ab.
2. Täuschen verfälscht die Messung, Auslagern verhindert das Lernen selbst: Wer die Denkarbeit abgibt, übt genau die Operationen nicht, die das Lernziel ausmachen. Das Konzept sind die erwünschten Schwierigkeiten: Anstrengung beim Abrufen und Üben ist Teil des Lernens, kein Hindernis.
3. Zwei der drei Bedingungen aus Kapitel 1.3: Einbettung (feste, betreute Zeiten, in denen der Tutor im Kurs genutzt wird), Anleitung (zeigen und üben, wie man den Tutor tutoriell statt als Lösungsautomat nutzt) und Leitplanken in Aufgabe und Rückmeldung (Hinweise vor Lösungen, eigene Antwort vor der KI-Antwort). Eine gute Antwort übersetzt die gewählten Bedingungen in eine konkrete Sitzung oder Aufgabe des eigenen Kurses.
4. Eine gute Antwort trennt die delegierbare Vorbereitung (Aufgabenvarianten, Fallbeschreibungen, Rückmeldungstexte) von dem, was bei Ihnen bleibt: Auswahl, Qualitätsprüfung und die Beziehung zu den Studierenden.

5. Gefährdet sind Aufgaben, deren Lernziel genau die Operation ist, die die KI übernimmt, etwa das Formulieren einer Begründung oder der erste eigene Lösungsversuch. Erkennbar wird der Verlust, wenn die Übungsleistung steigt und die Prüfungsleistung ohne KI nicht mitzieht oder wenn Studierende ihre eigene Lösung nicht erklären können (Kapitel 3.5).
6. Ermutigung sagt, dass KI erlaubt oder nützlich ist; Anleitung zeigt, wie man sie zum Lernen nutzt, etwa mit einem Beispiel-Dialog, einer Regel wie „erst eigener Lösungsversuch, dann Hinweis“ und einer Übung in der Sitzung. Eine gute Antwort zitiert eine Stelle aus der eigenen Kursbeschreibung, ordnet sie ein und formuliert die fehlende Anleitung als konkreten Satz oder Arbeitsauftrag.

Kapitel 2: Grundbegriffe

1. Der Text wird in Tokens zerlegt; die Tokens werden als Zahlen (Embeddings) dargestellt und über Attention zueinander in Beziehung gesetzt; das Modell sagt das wahrscheinlichste nächste Token voraus, hängt es an und wiederholt den Schritt. Eine eingebaute Wahrheitsprüfung gibt es dabei nicht.
2. Halluzinationen folgen aus der Funktionsweise: Das Modell erzeugt eine plausible Fortsetzung, keine geprüfte. Gegenmittel sind die Eingrenzung des Inputs auf eigenes Material, Musterlösungen als Vorgabe und eine systematische Prüfung der Ergebnisse.
3. Höflichkeit, Drohungen und Trinkgeld ändern die Ergebnisse nicht. Es hilft, präzise und strukturiert zu formulieren (Rolle, Aufgabe, Format), Beispiele mitzugeben und iterativ nachzubessern, so wie man eine junge Hilfskraft anleitet.
4. Ohne Fachwörter: Der Chatbot setzt Text so fort, wie solcher Text gewöhnlich weitergeht. Eine Quellenangabe hat eine typische Form, und diese Form kann er erzeugen, ohne nachzusehen, ob es die Quelle gibt. Mit Fachwörtern: Das Modell sagt Token für Token die wahrscheinlichste Fortsetzung voraus und fragt keine Datenbank ab. Eine gute Antwort endet mit dem Gegenmittel: Quellen immer am Original prüfen.
5. Das reine Modell antwortet aus dem Trainingswissen; das Risiko sind veraltete oder vom Kurs abweichende Inhalte. Mit Ihrem Skript als Material (RAG) bleibt die Antwort nah am Kurs; das Risiko sind

Lücken im Material und falsch gewählte Textstellen. Der Agent mit Internetzugang recherchiert aktuell und mehrstufig; das Risiko sind ungeprüfte Quellen und ein Weg zur Antwort, den man schwer nachvollzieht.

6. Die Grenze lässt sich nicht aus der Schwierigkeit einer Aufgabe ableiten, nur durch Ausprobieren finden. Eine gute Antwort beschreibt einen Test: die Aufgabe mehrfach in ein starkes Modell geben, die Antworten mit der eigenen Musterlösung vergleichen und typische Fehler notieren, bevor Studierende damit arbeiten.
7. Eine gute Antwort hält beide Ebenen auseinander. Eine einzelne Textanfrage kostet etwa so viel Energie wie zehn Sekunden Video-Streaming; das rechtfertigt keinen Verzicht auf didaktisch begründete Anwendungen, wohl aber Zurückhaltung bei aufwendigen Aufträgen wie der Videoerzeugung. Über Ausbau, Standorte und Strommix der Rechenzentren entscheidet dagegen die Politik, nicht der einzelne Lehrende (Kernaussage 7).
8. Eine gute Antwort wählt die vierte Stufe, einen Ordner mit Textdateien, weil nur dort Menschen nachlesen können, was der Agent für erledigt hält. Geprüft wird an einem festen Haltepunkt, etwa wöchentlich, und nur so viel, wie in der verfügbaren Zeit wirklich gelesen werden kann; ein falsch als beantwortet markierter Fall würde sonst bis zum Semesterende übergangen. Wer zusätzlich keine Namen von Studierenden im Gedächtnis ablegt, hat auch die Datenschutzfrage mitbedacht (Kapitel 2.1.5).
9. Zum äußeren Harness gehört alles, was das Team selbst festlegt: die Anleitung mit Rolle und Regeln, die hochgeladenen Kursunterlagen als Wissensbasis, die angeschlossenen Werkzeuge und die Prüfregeln; das Modell und die Plattform liefert der Hersteller. Eine gute Antwort begrenzt den Spielraum an einer Werkzeug- und an einer Ablaufstelle, etwa: nur aus den Kursunterlagen antworten und keine Lösung vor dem ersten eigenen Versuch der Studierenden. Sie erkennt die Spannung (Kapitel 2.1.1): Jeder Schritt, den der Tutor selbst wählt, nimmt den Lernenden eine Entscheidung ab; ein guter Tutor gibt die Autonomie im Lernweg an die Lernenden zurück.
10. Eine gute Antwort beginnt in der äußeren Schleife: Ziel, passendes Werkzeug und die Pflichten, die daraus folgen (Datenschutz, Offenlegung, Prüfung vor der Weitergabe), und leitet daraus ab, was beim Menschen bleibt. In der inneren Schleife nennt sie ein Prüfkriterium, das vor dem ersten Prompt feststeht, etwa eine

Musterlösung oder eine Stichprobe, die man selbst nachrechnet. Die Schwachstelle liegt meist bei Discernment oder Diligence, weil man das Ergebnis selbst nicht prüfen kann oder nicht weiß, wem gegenüber man den KI-Einsatz offenlegen muss (Kapitel 2.6).

Kapitel 3: Didaktische Ziele und Mechanismen

1. *Knowing that* (Faktenwissen): Abrufübungen und Erklärungen. *Knowing how* (Prozesswissen): dialogisches Coaching und durchgearbeitete Beispiele. *Knowing with* (Transfer): Szenarien und Rollenspiele.
2. Interaktiv vor konstruktiv vor aktiv vor passiv. Eine KI-Lernaktivität wirkt umso stärker, je weiter oben sie auf dieser Leiter steht.
3. Der Testeffekt entsteht durch den Versuch, Wissen aus dem Gedächtnis abzurufen; eine sofort gelieferte Antwort erspart genau diesen Versuch. Der Bot sollte zuerst eine eigene Antwort einfordern, Hinweise vor Lösungen geben und eine Begründung verlangen, wo eine Lösung übernommen wird.
4. Eine gute Antwort ordnet drei konkrete Lernziele zu und benennt die Lücke; häufig ist es *knowing with*. Die Methode stammt aus der passenden Stufe in Lösung 1.
5. Eine gute Antwort nennt eine konkrete Stelle im Semester, etwa einen Wochenrückblick mit Aufgaben aus früheren Themen, und hält fest, dass das Modell die Varianten liefert, die Prüfung der Varianten aber bei Ihnen bleibt.
6. Die entscheidende Frage lautet: Wie haben die Studierenden in einer Prüfung ohne KI abgeschnitten? Bessere Übungsleistung kann mit schlechterer Prüfungsleistung einhergehen; ein Tutor im Stil des normalen ChatGPT verbesserte die Übungsleistung um 48 Prozent und senkte die Prüfungsleistung um 17 Prozent (Bastani et al., 2025).
7. Nein. In einem Crossover-Experiment mit 1.059 Programmieranfängern unterschieden sich Tutoren mit unterschiedlichen didaktischen System-Prompts auf keinem der konfirmatorischen Maße (Barth et al., 2026). Die Leitplanke muss in Aufgabe, Rückmeldung und Ablauf liegen (eigene Antwort zuerst, Hinweise vor Lösungen, Begründungspflicht) und in einer verbindlichen, angeleiteten Einbettung in den Kurs (Gallegos, 2026).

Kapitel 4: Vier Szenarien der Nutzung von GenAI

1. Als Hiwi nimmt die KI Arbeit ab (Zusammenfassungen, Materialvorbereitung), als Copilot ermöglicht sie, was man allein nicht könnte (Recherche, Programmieren von Lernwerkzeugen), als Tutor begleitet sie Lernende (Erklärungen, Rückmeldung), als Simulator stellt sie Übungssituationen bereit (Rollenspiele, Verhandlungen).
2. Automatisierung (automation) heißt, dass eine Aufgabe vom Menschen zur KI wandert (standardisierte Materialien, Notenverwaltung). Augmentierung (labor-augmenting technology) heißt, dass die Aufgabe beim Menschen bleibt und mit KI-Unterstützung schneller oder besser gelingt (Rückmeldungen, Aufgabenvarianten). Neue Aufgaben (new tasks) entstehen erst durch die KI (Qualitätskontrolle von KI-Ausgaben, Kursdesign mit KI) (Acemoglu et al., 2025).
3. Wird einmalig oder iterativ gesucht, und entsteht eine Trefferliste oder ein erzeugter Text? Daraus ergeben sich Quick Search (einmalig, Liste), Quick RAG (einmalig, Zusammenfassung), Deep Search (iterativ, Liste) und Deep Research (iterativ, Bericht).
4. Im Role Play übernehmen Studierende eine Rolle und handeln in einer Situation, etwa einer Verhandlung. Im Goal Play bleiben sie in ihrer eigenen Rolle und wenden ein Konzept oder Analyseraster an, zum Beispiel indem sie einer Figur bei der Zielsetzung helfen.
5. Eine gute Antwort ordnet jede Aufgabe einer der drei Formen zu und nennt mindestens eine neue Aufgabe, die heute nicht im Zeitbudget steht, etwa das Testen eines Tutors oder die Pflege einer Wissensbasis.
6. Eine gute Antwort enthält drei Bremsen, etwa: keine Lösung vor dem eigenen Versuch, Hinweise vor Lösungen, eine Begründung einfordern. Die Musterlösungen stammen aus den eigenen Unterlagen und werden dem Tutor als Input mitgegeben, damit er an ihnen prüft statt frei zu erzeugen.
7. Role Play passt zu Situationen mit einem Gegenüber (Verhandlung, Kundengespräch, Konfliktgespräch), Goal Play zur Anwendung eines Analyserasters. Im Debriefing gehören auf den Tisch: was passiert ist, welches Konzept dahinterstand, wo die KI aus der Rolle fiel und was sich auf echte Situationen übertragen lässt.
8. Eine gute Antwort benennt die neuen Aufgaben, die Zeit kosten (Einrichtung, Tests, Pflege, Qualitätskontrolle), und eine Bedingung für den Nettogewinn: etwa, dass ein Werkzeug über mehrere Semester und Kohorten genutzt oder im Kollegium geteilt wird.

Kapitel 5: Empfehlungen zur Umsetzung

1. Mündlichkeit (Kolloquium, Präsentation mit strukturierter Fragerunde), Prozessorientierung (Prozessjournal mit Versionsverlauf), Kontextualisierung (Aufgaben mit realen, lokalen oder persönlichen Daten), Kollaboration und Kreation (Gruppenaufgaben in der Veranstaltung, Peer-Beurteilung, gestufte Projekte).
2. Die Richtlinien passen die Eigenständigkeitserklärung an, klären Verdachtsfälle im Gespräch, schließen eine automatisierte Bewertung aus und verlangen, Prüfungsformate didaktisch weiterzuentwickeln. Detektionssoftware gehört nicht dazu, weil sie als unzuverlässig gilt und selbst Prüfende KI-gestützte Arbeiten nicht von rein menschlichen unterscheiden können; ein Detektionswert taugt höchstens als Anlass für ein Gespräch, nie als Beweis.
3. Eine Stichwortliste, eine Übersicht nach Arbeitsphase oder nach Werkzeug und ein Reflexionstagebuch.
4. Eine gute Antwort prüft jede Säule an der eigenen Prüfungsleistung und wählt die mit dem geringsten Umbauaufwand; oft ist es ein kurzes Kolloquium zur schriftlichen Arbeit.
5. Eine gute Antwort ordnet jeder Phase eine konkrete Aufgabe und ihr Lernprinzip zu, in der Festigungsphase etwa Abrufübungen statt Zusammenfassungen. Sie benennt eine verantwortliche Person für die Freigabe und legt gegen das größte Risiko, meist die Auslagerung des Denkens, eine Vorkehrung in die Aufgabe selbst, nicht nur eine Regel.
6. Eine gute Antwort prüft die eigene Richtlinie auf die Elemente aus Lösung 2 und auf die Frage, ob Studierende und Lehrende sie kennen; eine Richtlinie wirkt erst, wenn sie bekannt ist und diskutiert wird.
7. Der Vorschlag ist nicht praktikabel: Ein vollständiges Protokoll jeder Interaktion erzeugt Masse ohne Aussagekraft und wird weder sorgfältig geführt noch gelesen. Eine gute Antwort setzt eine der drei Formen aus Lösung 3 dagegen und verbindet sie mit einem mündlichen Element, das die Autorschaft sichert.

Kapitel 6: Fallbeispiele aus der Lehre

Lernfragen in den Beispielen

- *Fragen-Generator:* Er verletzt die Regel, die Lösung nie vor dem eigenen Versuch zu nennen, und die Anweisung, jede Antwort zuerst auf Papier zu schreiben. Der Effekt entsteht beim Abrufen selbst; wer die Lösung abtippt, liest sie nur noch einmal, und gegen das Wiederlesen gewinnt der Abruf nach zwei Tagen (Roediger & Karpicke, 2006).
- *Lernsongs:* Der Song sichert Namen und Reihenfolge von Verfahren, die schon verstanden sein müssen; vor der Einführung hat er nichts, woran er anknüpft, und die Rechenpausen setzen ein Verfahren voraus, das noch nicht erklärt ist. Einmaliges Abspielen verschenkt den Effekt, der verteilte Wiederholung braucht (Katz et al., 2021); ein zweiter Durchgang einige Tage später gehört in den Plan.
- *Quizspiele:* Die kleinste Änderung ist ein Zustand, der in die nächste Runde getragen wird, etwa ein Budget oder ein Lagerbestand: Wer in der Flut auf Sicherheitsbestand setzt, hat im folgenden Erdbeben weniger Geld für Dual Sourcing. Dann ändert eine Entscheidung etwas an der Lage der nächsten Runde, und der Zielkonflikt wird sichtbar. Eine Fehlerliste, die falsch beantwortete Fragen in der nächsten Runde öfter stellt, genügt nicht: Sie ändert den Lernstoff, nicht die Lage, und macht aus dem Quiz ein adaptives Quiz, noch keine Entscheidungsübung.
- *Interaktive Widgets:* Den Engpass findet man durch Hinsehen, denn das Widget hebt ihn farbig hervor. Die Frage nach der folgenlosen Änderung verlangt eine Vorhersage und einen Beweis und trifft die Fehlvorstellung, jede Verbesserung an einem Schritt erhöhe den Ausstoß; das ist angeleitetes Entdecken mit Erklärungsauftrag (Alfieri et al., 2011).
- *Tutoring:* Der Tutor war als Antwortmaschine eingestellt: Auf Nachfrage gab er die Lösung heraus (Liu et al., 2026). Erkennbar wäre das mit dem Prüfkriterium der Empfehlung gewesen, einem Testlauf, in dem jemand dreimal um die Lösung bittet. Die Erfolgsmessung gehört an eine Prüfung ohne KI, nicht an die Nutzungszahlen.
- *Fallstudien generieren:* Formen ist die körperlich härteste Arbeit, also hält der Backmeister es für den Engpass und verwechselt Anstrengung mit Kapazität. Nennt der Fall den Engpass sofort, entfallen die Vermutung vor dem Rechnen, die das spätere Lernen verbessert (Pan & Carpenter, 2023), und der Konflikt, der die Geschichte trägt (Willingham, 2021).
- *Simulationen durch Lehrende:* Das Widget zeigt die mechanischen Ursachen, Prognose aus Bestellungen und Lieferzeit. Es kann nicht

zeigen, dass Menschen die Ware unterwegs übersehen, denn seine Stufen bestellen nach einer festen Regel. Diese Verhaltensursache (Croson & Donohue, 2006; Sterman, 1989) erleben die Studierenden im Beer Game, und das Debriefing macht sie sichtbar, wenn es fragt, wer die offenen Bestellungen mitgezählt hat.

- *Simulationen selbst bauen:* Die Prüfzelle testet nur Regeln, die jedes korrekte Modell erfüllt. Deshalb kann sie automatisch und unveränderlich sein, ohne ein Team für eine vertretbare Entscheidung zu bestrafen. Ob die Gegenmaßnahme gut ist, ist ein Urteil unter Zielkonflikten und gehört in die Postersession, wo das Team seine Wahl begründet und Vorhersagen trifft.
- *Karriereberater:* Er verstößt gegen die Regel, dass das Sprachmodell nur Daten erklärt, die aus einer benannten Quelle stammen; eine geschätzte Zahl sieht genauso verlässlich aus wie eine belegte. Er sollte auf eine Gehaltsstatistik verweisen, etwa den Entgeltatlas der Bundesagentur für Arbeit, oder eine Zahl nur mit Quelle und Stand nennen.
- *Projektlernen mit Praxispartnern:* Carlile beschreibt Wissensgrenzen zwischen Abteilungen und Organisationen mit eigenen Interessen. Mit einem Praxispartner wandert Wissen tatsächlich über eine solche Grenze: Der Partner hat Vertraulichkeitsinteressen und einen eigenen Anwendungsfall, und beides muss vor dem Prototyp verhandelt werden. Zwischen Studierenden und Fachgebiet gibt es keine zweite Organisation; dort ist die Stufenfolge ein Bild, das die Beispiele ordnet.

Lernfragen am Kapitelende

1. Syntaktisch (übertragen, gemeinsames Vokabular genügt), semantisch (übersetzen, Bedeutungen müssen erschlossen werden), pragmatisch (umformen, Wissen wird gegen Interessen und Folgen angewendet). Carlile beschreibt Grenzen zwischen Abteilungen einer Organisation; erst beim Projektlernen mit Praxispartnern wandert Wissen tatsächlich über eine solche Grenze (Carlile, 2004).
2. Von 2.379 berechtigten Studierenden nutzten nur 15 Prozent den Tutor, drei Viertel ihrer Anfragen verlangten eine fertige Antwort, und die Abschlussnote lag 0,37 Standardabweichungen unter der Kontrollgruppe. Der Tutor war im Standardmodus als Antwortmaschine konfiguriert und ersetzte das eigene Arbeiten am Material (Liu et al., 2026).
3. Der Anteil der Berechtigten, die den Tutor überhaupt nutzen; der

Anteil der Anfragen, die eine fertige Antwort verlangen, gegenüber denen, die Rückmeldung auf eigene Arbeit suchen; und ob der Tutor bei einer offensichtlichen Prüfungsfrage auf das Material verweist oder sie löst.

4. Eine gute Antwort benennt Wissensform und Lerntechnik, bevor ein Werkzeug fällt, begründet die Wahl des Beispiels mit Gruppengröße, Prüfungsform oder Partnern und nennt den Engpass, der zuerst auftreten würde, samt einer Vorkehrung.
5. Eine gute Antwort stützt das Prinzip auf einen Beleg, formuliert die Empfehlung als Wenn-dann-Regel ohne Produktnamen und gibt ein Prüfkriterium, das sich mit Ja oder Nein beantworten lässt. Den Austauschtest besteht sie, wenn sie nach dem Tausch des Werkzeugs gegen ein anderes noch stimmt.
6. Ein sokratischer System-Prompt allein verhindert die Nutzung als Antwortmaschine nicht (Gerber et al., 2026). Für den BWL-Tutor folgt daraus, die Leitplanken in Aufgabe und Ablauf zu legen und mit den drei Kennzahlen aus Lösung 3 zu prüfen, ob sie greifen.

Glossar

Das Glossar erklärt die Kernbegriffe des Buchs in Alltagssprache; die Angabe in Klammern nennt die Stelle, an der ein Begriff eingeführt wird. Viele Fachwörter rund um generative KI sind englische Neubildungen aus lateinischen und griechischen Wurzeln. Wo die Herkunft das Verständnis stützt, nennt eine Herkunftszeile sie: Wer weiß, dass eine *Halluzination* auf das lateinische Wort für gedankenloses Reden zurückgeht, versteht schneller, warum sie kein technischer Defekt ist.

Generative KI (GenAI) Sammelbegriff für KI-Systeme, die neue Inhalte erzeugen: Texte, Bilder, Ton, Programmcode. Im Buch werden KI, GenAI und Sprachmodell weitgehend gleichbedeutend verwendet, weil die meisten Lehrenden erst seit ChatGPT aktiv mit KI arbeiten (Kap. 2.1).

Herkunft: lat. *generare*, „hervorbringen, zeugen“.

Sprachmodell, Large Language Model (LLM) Ein Rechenmodell, das aus riesigen Textmengen gelernt hat, das jeweils nächste Wort in einer Wortkette vorherzusagen. Aus dieser einfachen Grundoperation entstehen Antworten, Zusammenfassungen und Dialoge; eine eingebaute Prüfung auf Wahrheit gibt es nicht (Kap. 2.1).

Herkunft: Modell über ital. *modello* zu lat. *modulus*, „kleines Maß“, Verkleinerung von *modus*, „Maß, Art und Weise“.

GPT Abkürzung für Generative Pre-trained Transformer: ein Sprachmodell, das Texte erzeugt (generative), vorab mit großen Textmengen trainiert wurde (pre-trained) und auf der Transformer-Architektur beruht. Ursprünglich die Modellreihe von OpenAI, heute oft als Gattungsname gebraucht (Kap. 2.1.1).

Token Der kleinste Baustein, in den ein Sprachmodell Text zerlegt: ein Wort, ein Wortteil oder ein Satzzeichen. Nach Tokens werden Kontextfenster und Preise bemessen; ein Wort sind oft ein bis zwei Tokens (Kap. 2.1).

Embedding Die Umwandlung eines Tokens in eine lange Zahlenreihe (einen Vektor), die seine Bedeutung mathematisch beschreibt. Ähnliche Wörter wie „Hund“ und „Katze“ erhalten ähnliche Zahlenreihen, so dass das Modell mit Bedeutung rechnen kann (Kap. 2.1).

Transformer und Attention Transformer ist die Rechenarchitektur heutiger Sprachmodelle. Ihr Kernverfahren Attention („Aufmerksamkeit“) lässt jedes Token gewichtet entscheiden, auf welche anderen Tokens im Text es achten soll; so erkennt das Modell, ob „Bank“ ein Möbelstück oder ein Geldinstitut meint (Kap. 2.1.1).

Herkunft: lat. *transformare*, „umformen“; *attendere*, „den Geist auf etwas hinwenden“.

Pretraining und RLHF Pretraining ist das Vortrainieren des Modells an großen Textmengen ohne konkrete Aufgabe. Danach bewerten Menschen Antwortvarianten, und das Modell lernt, bevorzugt nützliche und verständliche Antworten zu geben: Reinforcement Learning with Human Feedback, bestärkendes Lernen mit menschlicher Rückmeldung (Kap. 2.1.1).

Kontextfenster Die Menge an Text, die ein Sprachmodell gleichzeitig „im Blick“ hat: die bisherige Unterhaltung, hochgeladene Dokumente und die aktuelle Frage. Was nicht ins Fenster passt, kennt das Modell in diesem Moment nicht (Kap. 2.1.1).

Herkunft: lat. *contexere*, „zusammenweben“; der Kontext ist das Gewebe, in dem ein Wort steht.

Halluzination Eine sprachlich überzeugende, aber sachlich falsche oder erfundene Antwort, etwa eine Quelle, die es nicht gibt. Keine Störung, sondern eine Folge der Funktionsweise: Das Modell erzeugt Plausibles, nicht Geprüftes. Gegenmittel sind eingegrenztes Material, Musterlösungen und systematische Prüfung (Kap. 2.2, 4.3).

Herkunft: lat. (*h*)*al*(*l*)*ucinari*, „gedankenlos reden, träumen“.

Reasoning-Modell Ein Sprachmodell, das vor der Antwort schrittweise „nachdenkt“, also Zwischenschritte erzeugt und die eigenen Ergebnisse prüft, bevor es antwortet. Technisch wird mehr Rechenzeit in die Antwort statt ins Training gesteckt (test-time compute). Für anspruchsvolle Aufgaben sind solche Modelle deutlich zuverlässiger als ihre schnellen Varianten (Kap. 1.4).

Herkunft: engl. *reason* über altfrz. *raison* zu lat. *ratio*, „Berechnung, Vernunft“.

Jagged Frontier „Zerklüftete Technikgrenze“: Sprachmodelle lösen manche Aufgaben auf Expertenniveau und scheitern an anderen, die für Menschen ähnlich schwer sind. Die Grenze verläuft unregelmäßig und ist nur durch Ausprobieren zu finden; wer sie nicht kennt, arbeitet mit KI schlechter als ohne (Kap. 2.4).

Herkunft: engl. *frontier* über altfrz. *frontiere* zu lat. *frons*, „Stirn“: die Linie, an der man einander die Stirn bietet.

Zentaur und Cyborg Zwei Arbeitsweisen mit KI entlang der Jagged Frontier. Der Zentaur teilt die Arbeit sauber auf: Dieses übernimmt der Mensch, jenes die Maschine. Der Cyborg verwebt beide in jedem Arbeitsschritt, etwa beim Schreiben Satz für Satz (Kap. 2.4, 4.2.1).

Herkunft: griech. *kentauros*, Mischwesen aus Mensch und Pferd; *Cyborg* aus *cybernetic organism*, zu griech. *kybernetes*, „Steuermann“.

Prompt Die Eingabe an ein Sprachmodell: Frage, Anweisung oder Aufgabe, oft mit Material und Beispielen. Wie der Prompt formuliert ist, bestimmt die Qualität der Antwort wesentlich (Kap. 2.5).

Herkunft: lat. *promptus*, „bereit, zur Hand“, zu *promere*, „hervorholen“; engl. *to prompt*, „soufflieren, anstoßen“.

Prompt Engineering Das Handwerk, Prompts so zu bauen, dass sie zuverlässig gute Antworten liefern: Rolle, Aufgabe, Format und Beispiele klar benennen, strukturieren, iterieren. Was nichts bringt: Drohen, Bestechen, besondere Höflichkeit (Kap. 2.5.2–2.5.5).

Herkunft: Engineering über altfrz. *engigneor* zu lat. *ingenium*, „Begabung, Erfindungsgeist“.

System-Prompt Eine Dauer-Anweisung, die vor jeder Unterhaltung im Hintergrund wirkt und das Verhalten eines Bots festlegt: Rolle, Regeln, erlaubte und verbotene Reaktionen. Didaktische Tutoren und Simulationen werden im Wesentlichen über den System-Prompt gebaut (Anhang A, B).

Herkunft: griech. *systema*, „das Zusammengestellte“.

Few-Shot-Beispiele Dem Modell werden im Prompt einige Beispiele gezeigt, wie die gewünschte Antwort aussehen soll. Wenige gute Beispiele helfen; zu viele engen das Modell ein (Kap. 2.5.3).

Chain of Thought „Gedankenkette“: Das Modell wird aufgefordert, Schritt für Schritt vorzugehen und seinen Lösungsweg auszuformulieren. Bei älteren Modellen eine wichtige Technik, bei Reasoning-Modellen weitgehend eingebaut (Kap. 2.5.3, 2.5.5).

Herkunft: engl. *chain* über altfrz. *chaeine* zu lat. *catena*, „Kette“.

Temperatur Ein Regler, der steuert, wie stark das Modell von der wahrscheinlichsten Fortsetzung abweicht. Niedrige Temperatur ergibt vorhersagbare, wiederholbare Antworten, hohe Temperatur abwechslungsreichere, aber auch riskantere (Kap. 2.1, Lernspiel).

Herkunft: lat. *temperare*, „mäßigen, richtig mischen“.

RAG (Retrieval-Augmented Generation) Das Modell bekommt eigenes Material an die Hand, etwa Skripte, Fachartikel oder Musterlösungen, und holt sich daraus vor der Antwort die passenden Stellen. Bildlich: Die KI ist das Gehirn, das Material ist das Bücherregal. In der Lehre der wichtigste Hebel gegen Halluzinationen (Kap. 2.1).

Herkunft: augmented zu lat. *augere*, „vermehren“, aus dem auch *auctor*, der Urheber, stammt.

Agent Ein Sprachmodell, das nicht nur antwortet, sondern handelt: Es nutzt Werkzeuge wie Internetsuche, Dateizugriff oder Programmausführung, plant mehrere Schritte und prüft Zwischenergebnisse selbst. Bildlich: der Werkzeugkoffer neben dem Bücherregal (Kap. 2.1).

Herkunft: lat. *agere*, „handeln, treiben“.

Harness Wörtlich „Arbeitsgeschirr“: die Ausstattung, die ein Modell zum Agenten macht, also Werkzeuge, Datenzugriffe und Ablaufregeln. Ohne Harness bleibt „Agent“ ein Etikett (Kap. 1.2, 2.1.3).

Deep Research Ein Agent für Recherche: Das Modell sucht in mehreren Durchgängen, bewertet Treffer, liest Quellen und schreibt einen Bericht mit Belegen. Nach Aaron Tay eine von vier Klassen von Suchhelfern, unterschieden nach „einmalig oder iterativ“ und „Liste oder Analyse“ (Kap. 1.2, 4.1.2).

Herkunft: research über frz. *rechercher* zu lat. *circare*, „umkreisen“.

Skill Ein vorgefertigtes Anweisungspaket, das einem Modell für eine bestimmte Aufgabe mitgegeben wird, etwa eine mehrseitige Anleitung, wie es eine Präsentation oder eine Hausarbeit Schritt für Schritt erstellt und prüft. Modulares Wissen zum Hinzubuchen (Kap. 1.2, 1.4).

Konnektor (MCP) Eine standardisierte Schnittstelle, über die ein Sprachmodell direkt auf externe Dienste zugreift, etwa auf Fachdatenbanken wie Scopus oder Verlagsvolltexte. Technischer Name: Model Context Protocol. Macht Recherchen nachvollziehbarer, weil die Kette von Anfrage bis Fundstelle dokumentiert ist (Kap. 4.1.2).

Herkunft: lat. *connectere*, „verknüpfen".

Artifact Ein vom Sprachmodell erzeugtes, eigenständig nutzbares Produkt, etwa ein kleines Lernspiel als Webseite, eine Grafik oder ein Dokument, das neben dem Chat angezeigt und weitergegeben werden kann. So wurden die interaktiven Elemente dieses Buchs gebaut (Kap. 2.1, 4.2.2).

Herkunft: lat. *arte factum*, „mit Kunst gemacht".

Custom GPT, Projekt Ein selbst konfigurierter Bot auf Basis eines Sprachmodells mit festem System-Prompt und hinterlegtem Material, der sich mit Studierenden teilen lässt. Bei OpenAI „Custom GPT", bei Anthropic „Projekt". Die einfachste Form, einen Tutor oder eine Simulation in die Lehre zu bringen (Kap. 1.5, Anhang B).

Herkunft: Projekt zu lat. *proicere*, „nach vorn werfen".

Scaling Laws Erfahrungsregeln, nach denen Modelle mit mehr Trainingsdaten und Rechenleistung verlässlich besser werden (Training Scaling) und bessere Antworten geben, wenn ihnen mehr Rechenzeit beim Antworten gegeben wird (Inference Scaling) (Kap. 2.4).

Herkunft: scale zu lat. *scala*, „Treppe, Leiter": Stufe um Stufe besser.

Erwünschte Schwierigkeiten (desirable difficulties) Lernhürden, die das Lernen anstrengender, aber nachhaltiger machen: selbst abrufen statt nachlesen, selbst formulieren statt übernehmen. Ein Chatbot, der sofort die fertige Lösung liefert, räumt genau diese Hürden weg (Kap. 1.6, 3.1, Anhang A).

Testgestütztes Lernen (test-enhanced learning) Das aktive Abrufen von Wissen durch Fragen und Tests festigt Gelerntes deutlich stärker als wiederholtes Lesen. Häufige, niedrigschwellige Abrufübungen gehören zu den am besten belegten Lerntechniken; Sprachmodelle senken den Aufwand, sie zu erstellen (Kap. 3.4).

Herkunft: Test über altfrz. *test* zu lat. *testum*, „Tontopf“, dem Tiegel, in dem man Edelmetall auf seine Reinheit prüfte.

Spacing und Interleaving Zwei Lerntechniken: Übung über die Zeit verteilen statt in einem Block (spacing) und Themen gemischt statt nacheinander üben (interleaving). Beides verbessert das Behalten und die Fähigkeit, das passende Werkzeug für ein Problem zu wählen (Kap. 3.4, 5.2).

Herkunft: spacing zu lat. *spatium*, „Raum, Zwischenraum“.

Fragebasierte Ausarbeitung (elaborative questioning) Lerntechnik, bei der Lernende Warum- und Wie-Fragen zum Stoff stellen und beantworten und so neue Inhalte mit vorhandenem Wissen verknüpfen. Tutor-Bots und Simulationen können solche Fragen stellen (Kap. 3.4).

Herkunft: lat. *elaborare*, „herausarbeiten“.

ICAP Rangfolge kognitiven Engagements nach Chi und Wylie: interaktiv wirkt besser als konstruktiv, konstruktiv besser als aktiv, aktiv besser als passiv ($I > C > A > P$). Maßstab dafür, wie wirksam eine KI-gestützte Lernaktivität sein kann (Kap. 3.4, Anhang C).

Kognitive Belastung (cognitive load) Die begrenzte Verarbeitungskapazität des Arbeitsgedächtnisses. Lernhilfen sollen diese Kapazität für das Wesentliche freihalten; ein Chatbot, der mit Informationen überschüttet, tut das Gegenteil. Didaktische Prompts begrenzen deshalb die Antwortmenge, etwa auf eine Frage pro Zug (Kap. 3.1, Anhang A).

Herkunft: lat. *cognitio*, „Erkenntnis“.

Scaffolding „Baugerüst“: Lernende bekommen genau so viel Unterstützung, wie sie für den nächsten Schritt brauchen, und das Gerüst wird mit wachsender Kompetenz abgebaut. Grundmuster sokratischer Tutor-Prompts (Anhang B, C).

Protégé-Effekt Wer einem anderen etwas erklären muss, lernt selbst am meisten. In Übungen wie „Teach the AI“ spielt das Modell die unwissende Schülerin, die Studierenden lehren (Kap. 4.4.2, Anhang B).

Herkunft: frz. *protégé*, „Schützling“, zu lat. *protegere*, „beschützen“.

Vier Rollen: Hiwi, Copilot, Tutor, Simulator Ordnungsrahmen des Buchs nach Mollick und Mollick: Als Hiwi nimmt die KI Lehrenden Arbeit ab, als Copilot ermöglicht sie, was man allein nicht könnte, als Tutor begleitet sie Lernende, als Simulator stellt sie Übungssituationen bereit (Kap. 4).

Herkunft: Tutor lat. „Beschützer, Vormund“, zu *tueri*, „schützen“; *Pilot* über ital. *pilota* zu griech. *pēdon*, „Ruderblatt“; *Simulator* zu lat. *simulare*, „nachahmen“.

Role Play und Goal Play Zwei Formen der Simulation. Im Role Play übernehmen Studierende eine fremde Rolle, etwa in einer Verhandlung, und die KI spielt das Gegenüber. Im Goal Play bleiben sie in ihrer eigenen Rolle und wenden Wissen an, das der KI-Figur fehlt (Kap. 4.4).

Herkunft: Rolle über frz. *rôle* zu lat. *rotulus*, „Röllchen“: die Schriftrolle mit dem Text des Schauspielers.

Debriefing und Human in the Loop Die Nachbesprechung einer Simulation durch Lehrende, in der Verlauf, Fehler der KI und Lernertrag reflektiert werden. Steht für den Grundsatz, dass der Mensch in der Schleife bleibt und die Verantwortung behält (Kap. 4.4, Anhang C).

Herkunft: brief über altfrz. *bref* zu lat. *brevis*, „kurz“.

Vier-Säulen-Modell Prüfungsdesign unter KI-Bedingungen nach Gmeiner: Mündlichkeit, Prozessorientierung, Kontextualisierung und Kollaboration. Jede Säule macht generische KI-Texte als Prüfungsleistung wertlos, ohne die KI-Nutzung zu verbieten (Kap. 5.4).

Herkunft: Kollaboration zu lat. *collaborare*, „mitarbeiten“.

Homework Apocalypse Mollicks Schlagwort für die Entwertung klassischer Hausaufgaben und Hausarbeiten, wenn Studierende sie auf Knopfdruck erzeugen können. Gemeint ist weniger das Täuschen als die empfundene Sinnlosigkeit der Aufgabe (Kap. 1.6, 5.4).

Herkunft: griech. *apokalypsis*, „Enthüllung"; gemeint war ursprünglich nicht der Untergang, sondern das Sichtbarwerden.

Transparenzhinweis zum Gesamtwerk

Bei der Erstellung dieses Buchs wurde generative KI eingesetzt. Das Thema des Buchs verlangt, dass ich das genau benenne.

Das Sprachmodell Claude (Anthropic) wurde in der Arbeitsumgebung Cowork für folgende Aufgaben genutzt: die Strukturanalyse des Online-Skripts vor der Überarbeitung, die Prüfung von Literaturangaben gegen die Originalquellen, Entwürfe für einzelne Einschübe wie Kästen, Lernziele und Kernaussagen, Sprach- und Konsistenzchecks über alle Kapitel sowie die technische Umsetzung des Layouts für Druck und Online-Version. Abbildungen, die mit dem Bildmodell Gemini (Google) erzeugt wurden, sind in der jeweiligen Bildunterschrift als KI-generiert gekennzeichnet. Die interaktiven Lernspiele und Prozessanimationen der Online-Version wurden mit Unterstützung von Sprachmodellen programmiert; wie das geht, beschreibt Kapitel 2. Bei den beiden Simulationen zu Little's Law und zum Bullwhip-Effekt in Kapitel 4 hat Claude auch das Rechenmodell und seine Tests geschrieben. Die Tests prüfen das Modell gegen Handrechnungen und gegen die Formeln von Little (1961) und F. Chen et al. (2000); die Druckabbildungen erzeugt ein Skript aus denselben Modelldateien. Modell, Tests und Skript liegen im Repositorium des Online-Skripts.

Verantwortung und Prüfung liegen beim Autor. Jeder Entwurf, den ein Sprachmodell geliefert hat, wurde gelesen, gegen die Quellen geprüft, überarbeitet oder verworfen. Die Argumentation, die Auswahl der Studien und die Empfehlungen sind meine eigenen. Wo ein Sprachmodell eine Quelle vorgeschlagen hat, habe ich die Quelle selbst gelesen, bevor sie ins Literaturverzeichnis kam. Damit folge ich der Stellungnahme des Präsidiums der Deutschen Forschungsgemeinschaft zum Einfluss generativer Modelle auf die Wissenschaften vom September 2023: Der Einsatz solcher Werkzeuge ist zulässig, muss offengelegt werden, entbindet nicht von der Verantwortung für den Inhalt, und ein Sprachmodell kann nicht Autor sein.

Anhang C und Anhang D enthalten jeweils einen eigenen Transparenzabschnitt, weil dort der Anteil der KI-Unterstützung größer war und sich anders zusammensetzt als im Haupttext.

[Optional: Hinweis, ob die Arbeitsnotizen zur Überarbeitung im öffentlichen Repositorium https://github.com/TH-Koln-Bartnik/genai4teaching einsehbar sind.]

Literaturverzeichnis

Acemoglu, D., Kong, F., & Restrepo, P. (2025). Tasks at work: Comparative advantage, technology and labor demand. In C. Dustmann & T. Lemieux (Hrsg.), *Handbook of Labor Economics*: (Bd. 6, 1–114). Elsevier. https://doi.org/10.1016/bs.heslab.2025.08.003.

Adesope, O. O., Trevisan, D. A., & Sundararajan, N. (2017). Rethinking the use of tests: A meta-analysis of practice testing. *Review of Educational Research*, *87*(3), 659–701. https://doi.org/10.3102/0034654316689306.

Ahn, D., Mao, C., & Lee, D. (2026). *Item-mean surrogates: Why richer persona data fail to improve LLMs as human surrogates*. https://doi.org/10.48550/arXiv.2608.29455.

Ahtisham, B., Vanacore, K., Napoli, A., Arens, J., Ionova, K., Cohn, C., Salehi, S., & Kizilcec, R. (2026). *Examining variation in how guided AI tutors resolve student impasses*. https://doi.org/10.48550/arXiv.2609.38346.

Akgun, M., & Toker, S. (2026). Do gains from generative AI-enabled adaptive pretesting persist? Evidence from a retention study. https://doi.org/10.48550/arXiv.2606.22328.

Akimov, A., & Malin, M. (2020). When old becomes new: a case study of oral examination as an online assessment tool. *Assessment & Evaluation in Higher Education*, *45*(8), 1205–1221. https://doi.org/10.1080/02602938.2020.1730301.

Alfieri, L., Brooks, P. J., Aldrich, N. J., & Tenenbaum, H. R. (2011). Does discovery-based instruction enhance learning? *Journal of Educational Psychology*, *103*(1), 1–18. https://doi.org/10.1037/a0021017.

Alfieri, L., Nokes-Malach, T. J., & Schunn, C. D. (2013). Learning Through Case Comparisons: A Meta-Analytic Review. *Educational Psychologist*, *48*(2), 87–113. https://doi.org/10.1080/00461520.2013.775712.

Amazon Web Services (2025a). Build a personalized student companion powered by generative AI on Amazon Bedrock. *AWS Public Sector Blog*. https://aws.amazon.com/blogs/publicsector/build-a-personalized-student-companion-powered-by-generative-ai-on-amazon-bedrock/.

Amazon Web Services (2025b). Revolutionizing higher education: How Amazon Bedrock AgentCore enables production-ready AI at scale. *AWS*

Public Sector Blog. https://aws.amazon.com/blogs/publicsector/revolutionizing-higher-education-how-amazon-bedrock-agentcore-enables-production-ready-ai-at-scale/.

Amazon Web Services (2026). *AWS Academy*. https://aws.amazon.com/training/awsacademy/.

Amtsgericht München (2026). Endurteil vom 13. Februar 2026, Az. 142 C 9786/25: Kein Urheberrechtsschutz für mit KI erzeugte Logos. https://www.gesetze-bayern.de/Content/Pdf/Y-300-Z-GRURRS-B-2026-N-1513?all=False.

An, Y., Yu, J. H., & James, S. (2025). Investigating the higher education institutions' guidelines and policies regarding the use of generative AI in teaching, learning, research, and administration. *International Journal of Educational Technology in Higher Education*, *22*(1), 10. https://doi.org/10.1186/s41239-025-00507-3.

Anderson, L. W., & Krathwohl, D. R. (2001). *A taxonomy for learning, teaching, and assessing: A revision of Bloom's taxonomy of educational objectives*. Longman.

Anthropic (o. J.). Memory stores. *Claude Platform Docs*. https://platform.claude.com/docs/en/managed-agents/memory.

Anthropic (2024, November 25). Introducing the Model Context Protocol. https://www.anthropic.com/news/model-context-protocol.

Anthropic (2025a). How we built our multi-agent research system. https://www.anthropic.com/engineering/multi-agent-research-system.

Anthropic (2025b). *Prompting Best Practices*.

Anthropic (2025c, März 27). *Tracing the thoughts of a large language model*. Anthropic. https://www.anthropic.com/research/tracing-thoughts-language-model.

Anthropic (2025d, Dezember). Erste Schritte mit Agent Skills in der API. *Claude Docs*. https://platform.claude.com/docs/de/agents-and-tools/agent-skills/quickstart.

Anthropic (2026a). Plans & pricing. *Claude*. https://claude.com/pricing.

Anthropic (2026b, Mai 6). New in Claude Managed Agents: Dreaming, outcomes, and multiagent orchestration. https://claude.com/blog/new-in-claude-managed-agents.

Anthropic (2026c, Juli). *Introducing Claude for Teachers*. https://www.anthropic.com/news/claude-for-teachers.

Ates, H. (2026). Human-centered GenAI feedback design in higher education: A multisite experiment on direct, reflective, and hybrid approaches to scientific argumentation. *International Journal of*

Educational Technology in Higher Education, *23*(38). https://doi.org/10.1186/s41239-026-00614-9.

Ausubel, D. P. (1960). The use of advance organizers in the learning and retention of meaningful verbal material. *Journal of Educational Psychology*, *51*(5), 267–272. https://doi.org/10.1037/h0046669.

Autor, D., Rodchenko, T., Martin, J., Iscenko, Z., Strand, S., Pearl, D., & Ferere, M. (2026). *Does AI assistance enhance or erode expertise? Evidence from a three-month field experiment in patent drafting* (NBER Working Paper; Nr. 35720). National Bureau of Economic Research. https://doi.org/10.3386/w35720.

Avigad, J. (2026). Mathematicians in the age of AI. https://doi.org/10.48550/arXiv.2603.03684.

Balepur, N., Baumler, C., Chen, V., Choi, E., Rudinger, R., & Boyd-Graber, J. L. (2026). *(Im)Paired programming: Coding agents improve productivity but harm understanding*. https://doi.org/10.48550/arXiv.2607.26375.

Banh, L., Holldack, F., & Strobel, G. (2026). Designing generative AI-based agents to empower collaborative self-learning in higher education. *Business & Information Systems Engineering*. https://doi.org/10.1007/s12599-026-01012-1.

Barbieri, C. A., Miller-Cotto, D., Clerjuste, S. N., & Chawla, K. (2023). A meta-analysis of the worked examples effect on mathematics performance. *Educational Psychology Review*, *35*(1), 11. https://doi.org/10.1007/s10648-023-09745-1.

Barends, E., Rousseau, D. M., & Briner, R. B. (2017). *CEBMa guideline for critically appraised topics in management and organizations* (Leitlinie). Center for Evidence-Based Management.

Baresel, K., Eube, C., Knorr, D., Lutter, L., Nys, J. de, & Röben, M. (2024). *KI-Gebrauch im Studienkontext dokumentieren*. 304839 b. https://doi.org/10.48548/PUBDATA-1476.

Baresel, K., Fiegenbaum, L., Horn, J., Knorr, D., Lutter-Schwarz, L., Nys, J. de, & Röben, M. (2026). *KI in der Hochschullehre einsetzen: Rechtliche Vorgaben in Szenarien erklärt* (Arbeitspapier; Nr. 95). Hochschulforum Digitalisierung. https://doi.org/10.5281/zenodo.22975655.

Barra, F. L., Costa, A., Rodella, G., Semeraro, F., & Carenzo, L. (2024). Shaping the future of simulator interactions: The role of ChatGPT's Advanced Voice Mode. *Resuscitation*, *205*, 110452. https://doi.org/10.1016/j.resuscitation.2024.110452.

Barth, M., Thorgeirsson, S., Etemadi, K., Leinonen, J., Cotrini, C., & Su, Z. (2026). Steering AI tutors through system prompts: A crossover study on

self-regulated learning and cognitive engagement scaffolds in CS1. https://doi.org/10.1145/3765964.3811656.

Bartnik, R., & Haag, C. (2025). *Rahmensetzung zur Nutzung generativer KI im Bachelor- und Master-Studiengang Wirtschaftsingenieurwesen* (Handreichung für Studierende, Version V02). TH Köln, Fakultät für Informatik und Ingenieurwissenschaften.

Bartnik, R., & Schmid, J. (2025, Mai). *Literaturrecherche mit KI*. TH Köln.

Bartnik, R., & Schmid, J. (2026). *Schreibtrainer für wissenschaftliches Arbeiten: Anweisungen für acht Custom GPTs (Bot 1 bis Bot 8)*. TH Köln.

Barton, M. (2026). *KI-gestütztes Rollenspiel für Kommunikations- und Problemlösekompetenz*. Universität Leipzig, Professur Personalwirtschaftslehre. https://hochschulforumdigitalisierung.de/wp-content/uploads/2025/01/3285-Tag_Der_Lehre_2026_Michael_Barton.pdf.

Bastani, H., Bastani, O., Sungu, A., Ge, H., Kabakcı, Ö., & Mariman, R. (2025). Generative AI without guardrails can harm learning: Evidence from high school mathematics. *Proceedings of the National Academy of Sciences*, *122*(26), e2422633122. https://doi.org/10.1073/pnas.2422633122.

Bender, E. M., Gebru, T., McMillan-Major, A., & Shmitchell, S. (2021). On the dangers of stochastic parrots: Can language models be too big?□.

Bent, D., Handa, K., Durmus, E., Tamkin, A., McCain, M., Ritchie, S., Donegan, R., Martinez, J., & Jones, J. (2025). *Anthropic Education Report: How educators use Claude*. Anthropic.

Bergh, C., Tag, B., Vassar, A., & Renzella, J. (2026). *Your programming students' cognition with ChatGPT: Higher performance, lower retention, and reduced ownership*. https://doi.org/10.48550/arXiv.2609.21194.

Berney, S., & Bétrancourt, M. (2016). Does animation enhance learning? A meta-analysis. *Computers & Education*, *101*, 150–167. https://doi.org/10.1016/j.compedu.2016.06.005.

Berryman, J., & Ziegler, A. (2025). *Prompt engineering for LLMs: the art and science of building large language model-based applications*. O'Reilly Media.

Bien, J., & Mukherjee, G. (2025). Generative AI for Data Science 101: Coding Without Learning to Code. *Journal of Statistics and Data Science Education*, *33*(2), 129–142. https://doi.org/10.1080/26939169.2024.2432397.

Bjork, E. L., & Bjork, R. A. (2011). Making things hard on yourself, but in a good way: Creating desirable difficulties to enhance learning. In M. A. Gernsbacher, R. W. Pew, L. M. Hough, & J. R. Pomerantz (Hrsg.), *Psychology and the real world: Essays illustrating fundamental contributions to society*: (S. 56–64). Worth Publishers.

Bjork, R. A. (1994). Memory and metamemory considerations in the

training of human beings. In J. Metcalfe & A. P. Shimamura (Hrsg.), *Metacognition: Knowing about knowing*: (S. 185–205). MIT Press.

Böckeler, B. (2026, April 2). Harness engineering for coding agent users. https://martinfowler.com/articles/harness-engineering.html.

Bolin, M. (2026, Januar 23). *Unrolling the Codex agent loop*. OpenAI. https://openai.com/index/unrolling-the-codex-agent-loop/.

Bosse, E., Wannemacher, K., & Lübcke, M. (2026). *Die KI-Nutzung in Studium und Lehre: Ein Review auf Grundlage empirischer Studien*. Hochschulforum Digitalisierung.

Brandenburger, J., Mergan, H., Lorenz, A., & Janneck, M. (2026). Digitale Souveränität bei KI-gestützter Lehrmaterialverarbeitung an Hochschulen. *Zeitschrift für Hochschulentwicklung*, *21*(3), 133–153. https://doi.org/10.21240/zfhe/21-3/07.

Brender, J., El-Hamamsy, L., Uittenhove, K., Perez, A., Jermann, P., Mondada, F., & Bumbacher, E. (2026). Reflective dialogue or prompt refinement? Effects of tutor scaffolding on students' independent LLM use for programming. In E. G. Blanchard, G. Chen, M. Chi, & S. Isotani (Hrsg.), *Artificial Intelligence in Education: 27th International Conference, AIED 2026*: (Bd. 16584, 546–561). In E. G. Blanchard, G. Chen, M. Chi, & S. Isotani (Hrsg.), *Artificial Intelligence in Education: 27th International Conference, AIED 2026*: (Bd. 16584, 546–561). https://doi.org/10.1007/978-3-032-29763-1_37.

Bridgwater, A. (2026, August 12). Anthropic gave agents the ability to dream. Then developers woke up. *The New Stack*.

Brown, P. C., Roediger, H. L., & McDaniel, M. A. (2014). *Make it stick: The science of successful learning*. The Belknap Press of Harvard University Press.

Brynjolfsson, E., Li, D., & Raymond, L. (2025). Generative AI at work. *The Quarterly Journal of Economics*, qjae044.

Budde, J., Sommer, T., & Lüthi, R. (2026). *Personalisiertes Lernen im KI-Zeitalter* (Blickpunkt / HFD-Fokusmonitor 2026). Hochschulforum Digitalisierung.

Carlile, P. R. (2002). A pragmatic view of knowledge and boundaries: Boundary objects in new product development. *Organization Science*, *13*(4), 442–455. https://doi.org/10.1287/orsc.13.4.442.2953.

Carlile, P. R. (2004). Transferring, translating, and transforming: An integrative framework for managing knowledge across boundaries. *Organization Science*, *15*(5), 555–568. https://doi.org/10.1287/orsc.1040.0094.

Cepeda, N. J., Pashler, H., Vul, E., Wixted, J. T., & Rohrer, D. (2006). Distributed practice in verbal recall tasks: A review and quantitative synthesis. *Psychological Bulletin*, *132*(3), 354–380. https://doi.org/10.1037/0033-2909.132.3.354.

Chakraborty, P. (2026). Effect of using generative artificial intelligence in different roles in a course on computer programming. *Computer Applications in Engineering Education*, *34*(4), e70223. https://doi.org/10.1002/cae.70223.

Chang, P.-C., Hogan, N., Plaat, A., & van der Meer, M. T. (2026). Learning to prompt: Improving student engagement with adaptive LLM-based high-school tutoring. https://arxiv.org/abs/2606.20138.

Chatterji, A. (2025). *The state of enterprise AI: 2025 report* (Research Report). OpenAI.

Chen, C.-H., & Yang, Y.-C. (2019). Revisiting the effects of project-based learning on students' academic achievement: A meta-analysis investigating moderators. *Educational Research Review*, *26*, 71–81. https://doi.org/10.1016/j.edurev.2018.11.001.

Chen, F., Drezner, Z., Ryan, J. K., & Simchi-Levi, D. (1999). The bullwhip effect: Managerial insights on the impact of forecasting and information on variability in a supply chain. In S. Tayur, R. Ganeshan, & M. Magazine (Hrsg.), *Quantitative models for supply chain management*: (S. 417–439). Springer. https://doi.org/10.1007/978-1-4615-4949-9_14.

Chen, F., Drezner, Z., Ryan, J. K., & Simchi-Levi, D. (2000). Quantifying the bullwhip effect in a simple supply chain: The impact of forecasting, lead times, and information. *Management Science*, *46*(3), 436–443. https://doi.org/10.1287/mnsc.46.3.436.12069.

Chen, J., Liu, Z., Huang, X., Wu, C., Liu, Q., Jiang, G., et al. (2024). When large language models meet personalization: Perspectives of challenges and opportunities. *World Wide Web-internet and Web Information Systems*, *27*(42). https://doi.org/10.1007/s11280-024-01276-1.

Chen, S., Borchers, C., & Schunn, C. D. (2027). From revision to learning transfer: Self- and socially shared-regulated pathways in AI-assisted feedback. *Learning and Instruction*, *107*, 102489. https://doi.org/10.1016/j.learninstruc.2026.102489.

Chen, Y., Benton, J., Radhakrishnan, A., Uesato, J., Denison, C., Schulman, J., Somani, A., Hase, P., Wagner, M., Roger, F., Mikulik, V., Bowman, S. R., Leike, J., Kaplan, J., & Perez, E. (2025). *Reasoning models don't always say what they think*. arXiv. https://doi.org/10.48550/arXiv.2505.05410.

Chernikova, O., Heitzmann, N., Stadler, M., Holzberger, D., Seidel, T., &

Fischer, F. (2020). Simulation-based learning in higher education: A meta-analysis. *Review of Educational Research*, *90*(4), 499–541. https://doi.org/10.3102/0034654320933544.

Chi, M. T. H., Adams, J., Bogusch, E. B., Bruchok, C., Kang, S., Lancaster, M., Levy, R., Li, N., McEldoon, K. L., Stump, G. S., Wylie, R., Xu, D., & Yaghmourian, D. L. (2018). Translating the ICAP Theory of Cognitive Engagement Into Practice. *Cognitive Science*, *42*(6), 1777–1832. https://doi.org/10/gd5n5p.

Chi, M. T. H., & Wylie, R. (2014). The ICAP framework: Linking cognitive engagement to active learning outcomes. *Educational Psychologist*, *49*(4), 219–243. https://doi.org/10.1080/00461520.2014.965823.

Cho, A., Kim, G. C., Karpekov, A., Helbling, A., Wang, Z. J., Lee, S., Hoover, B., & Chau, D. H. (2025). Transformer Explainer: Interactive learning of text-generative models. https://doi.org/10.1609/aaai.v39i28.35347.

Choi, Y.-S. (2025). Earth science simulations with generative artificial intelligence (GenAI). *Journal of University Teaching and Learning Practice*, *22*(1). https://doi.org/10.53761/nf1yqr46.

Clark, D. B., Tanner-Smith, E. E., & Killingsworth, S. S. (2016). Digital games, design, and learning: A systematic review and meta-analysis. *Review of Educational Research*, *86*(1), 79–122. https://doi.org/10.3102/0034654315582065.

Clin Deffarges, A., Kosmyna, N., & Maes, P. (2026). *Socrates went nuclear: Comparing interaction strategies for AI systems in a learning context using brain sensing*. https://doi.org/10.48550/arXiv.2609.00584.

Cohen, J. (1960). A Coefficient of Agreement for Nominal Scales. *Educational and Psychological Measurement*, *20*(1), 37–46. https://doi.org/10.1177/001316446002000104.

Condit-Schultz, N., & Huron, D. (2015). Catching the lyrics: Intelligibility in twelve song genres. *Music Perception*, *32*(5), 470–483. https://doi.org/10.1525/mp.2015.32.5.470.

Contractor, Z., & Reyes, G. (2026). *Experimental evidence on the learning impact of generative AI* (IZA Discussion Paper; Nr. 18792). IZA Institute of Labor Economics.

Corbin, T., Dawson, P., & Liu, D. (2025). Talk is cheap: Why structural assessment changes are needed for a time of GenAI. *Assessment & Evaluation in Higher Education*. https://doi.org/10.1080/02602938.2025.2503964.

Croson, R., & Donohue, K. (2006). Behavioral causes of the bullwhip effect and the observed value of inventory information. *Management Science*,

52(3), 323–336. https://doi.org/10.1287/mnsc.1050.0436.

Csikszentmihalyi, M. (2008). *Flow: The psychology of optimal experience*. Harper Perennial.

Dakan, R., & Feller, J. (2025). *The AI Fluency Framework: A descriptive and normative model of human-AI interaction for higher education (Version 1.1)*. Higher Education Authority.

Dakan, R., Feller, J., & Anthropic (2025). Teaching AI Fluency [Onlinekurs; Lektionen „The Delegation-Diligence loop“ und „The Description-Discernment loop“]. *Anthropic Academy*. https://anthropic.skilljar.com/teaching-ai-fluency.

Dang, B., & et al. (2025). Human-AI collaborative learning in mixed reality: Examining the cognitive and socio-emotional interactions. *British Journal of Educational Technology*. https://doi.org/10.1111/bjet.13607.

Dang, C. T., & Nguyen, A. (2026). Verified, not generated: expert-verified AI study materials and the distribution of learning gains in a university course. https://doi.org/10.48550/arXiv.2610.07097.

Deci, E. L., & Ryan, R. M. (2000). The „what“ and „why“ of goal pursuits: Human needs and the self-determination of behavior. *Psychological Inquiry*, *11*(4), 227–268. https://doi.org/10.1207/S15327965PLI1104_01.

Delikoura, I., Fung, Y. R., & Hui, P. (2025). From superficial outputs to superficial learning: Risks of large language models in education. https://doi.org/10.48550/arXiv.2509.21972.

Dell'Acqua, F., Ayoubi, C., Lifshitz-Assaf, H., Sadun, R., Mollick, E. R., Mollick, L., Han, Y., Goldman, J., Nair, H., Taub, S., & Lakhani, K. R. (2025). The cybernetic teammate: A field experiment on generative AI and teamwork. *Organization Science*. https://doi.org/10.1287/orsc.2025.20702.

Dell'Acqua, F., McFowland, E., Mollick, E. R., Lifshitz-Assaf, H., Kellogg, K., Rajendran, S., Krayer, L., Candelon, F., & Lakhani, K. R. (2023). *Navigating the Jagged Technological Frontier: Field Experimental Evidence of the Effects of AI on Knowledge Worker Productivity and Quality*. https://doi.org/10.2139/ssrn.4573321.

Deng, R., Jiang, M., Yu, X., Lu, Y., & Liu, S. (2025). Does ChatGPT enhance student learning? A systematic review and meta-analysis of experimental studies. *Computers & Education*, *227*, 105224. https://doi.org/10.1016/j.compedu.2024.105224.

Denny, P., Kumar, V., & Giacaman, N. (2023). Conversing with copilot: Exploring prompt engineering for solving cs1 problems using natural language.

Derks-Dijkman, M. W., Schaefer, R. S., & Kessels, R. P. C. (2024). Musical mnemonics in cognitively unimpaired individuals and individuals with Alzheimer's dementia: A systematic review. *Neuropsychology Review*, *34*(2), 455–477. https://doi.org/10.1007/s11065-023-09585-4.

Devani, J., & Leiva, B. (2026, September). *Strengthening the evidence base for AI in education research: Launching the Learning Lab*. https://edunewsletter.openai.com/p/learning-lab-launch.

DeVito, P., Vallala, A., McMahon, S., Hinda, Y., Thaw, B., Zhuang, H., & Kalva, H. (2025). Unpacking generative AI in education: Computational modeling of teacher and student perspectives in social media discourse. https://doi.org/10.48550/arXiv.2506.16412.

Digital Education Council (2025). *Global AI Faculty Survey 2025*. Digital Education Council.

Dihan, Q. A., Nihalani, B. R., Tooley, A. A., & Elhusseiny, A. M. (2025). Eyes on Google's NotebookLM: using generative AI to create ophthalmology podcasts with a single click. *Eye*, *39*(2), 215–216. https://doi.org/10.1038/s41433-024-03481-8.

Dobson, G., & Shumsky, R. (2006). Web-based simulations for teaching queueing, Little's law, and inventory management. *INFORMS Transactions on Education*, *7*(1), 106–124. https://doi.org/10.1287/ited.7.1.106.

Doughty, J., Wan, Z., Bompelli, A., Qayum, J., Wang, T., Zhang, J., Zheng, Y., Doyle, A., Sridhar, P., Agarwal, A., Bogart, C., Keylor, E., Kultur, C., Savelka, J., & Sakr, M. (2024). A Comparative Study of AI-Generated (GPT-4) and Human-crafted MCQs in Programming Education. https://doi.org/10.1145/3636243.3636256.

Dunlosky, J., Rawson, K. A., Marsh, E. J., Nathan, M. J., & Willingham, D. T. (2013). Improving Students' Learning With Effective Learning Techniques: Promising Directions From Cognitive and Educational Psychology. *Psychological science in the public interest : a journal of the American Psychological Society*, *14*(1), 4–58. https://doi.org/10.1177/1529100612453266.

Eastwood, M., Narne, H., Hilby, J., Denny, P., Aggarwal, A., & Kapoor, A. (2026). *Guardrails or roadblocks? Effects of pedagogical style and context awareness in AI teaching assistants for programming*. https://doi.org/10.48550/arXiv.2609.29995.

Edwards, J., & Emberson, L. (2026, Mai 29). Open models lag state-of-the-art closed models by 4 months. *Epoch AI*. https://epoch.ai/data-insights/open-closed-eci-gap.

Eikenberg, R. (2025). Browser-Helferlein per KI generieren. *c't Special*, *2*, 94–99.

Element Labs (2026). LM Studio documentation. *LM Studio*. https://lmstudio.ai/docs/app.

Elsworth, C., Huang, K., Patterson, D., Schneider, I., Sedivy, R., Goodman, S., Townsend, B., Ranganathan, P., Dean, J., & Vahdat, A. (2025). Measuring the environmental impact of delivering AI at Google Scale. *arXiv preprint arXiv:2508.15734*.

Emberson, L., & Roodman, D. (2026, September 22). The plunging price of thought. *Epoch AI*. https://epoch.ai/publications/the-plunging-price-of-thought.

Ericsson, K. A., Krampe, R. T., & Tesch-Römer, C. (1993). The role of deliberate practice in the acquisition of expert performance. *Psychological Review*, *100*(3), 363–406. https://doi.org/10.1037/0033-295X.100.3.363.

Es, S., James, J., Espinosa Anke, L., & Schockaert, S. (2024). RAGAs: Automated Evaluation of Retrieval Augmented Generation. https://doi.org/10.18653/v1/2024.eacl-demo.16.

Europäisches Parlament und Rat (2026). Verordnung (EU) 2026/1744 des Europäischen Parlaments und des Rates vom 8. Juli 2026 zur Änderung der Verordnungen (EU) 2024/1689, (EU) 2018/1139 und (EU) 2023/1230 im Hinblick auf die Vereinfachung der Umsetzung harmonisierter Vorschriften für künstliche Intelligenz (Digital-Omnibus-Verordnung zur KI).

Europäisches Parlament und Rat der Europäischen Union (2024). Verordnung (EU) 2024/1689 des Europäischen Parlaments und des Rates vom 13. Juni 2024 zur Festlegung harmonisierter Vorschriften für künstliche Intelligenz (Verordnung über künstliche Intelligenz).

Feil, S., Hoffmann, I., & Schroeder, F. (2026). *KI-Kompetenzrahmen Hochschule: Lernziele für den Einsatz generativer künstlicher Intelligenz in Studium, Lehre und Verwaltung an Hochschulen*. Digitale Lehre Hub Niedersachsen (DLHN).

Figalová, N., Huestegge, L., & Böckler-Raettig, A. (2026). *Evaluating human and LLM screening workflows in a conceptually complex scoping review: Recall–workload trade-offs and run-to-run consistency*. https://doi.org/10.48550/arXiv.2608.26885.

Fischer, M., Rau, H. A., & Rilke, R. M. (2025). *AI tutoring enhances student learning without crowding out reading effort* (IZA Discussion Paper; Nr. 18338). Institute of Labor Economics (IZA).

Freeman, S., Eddy, S. L., McDonough, M., Smith, M. K., Okoroafor, N.,

Jordt, H., & Wenderoth, M. P. (2014). Active learning increases student performance in science, engineering, and mathematics. *Proceedings of the national academy of sciences*, *111*(23), 8410–8415.

Friedrich, J.-D. (2023, Februar 8). Zur Bedeutung von ChatGPT & der Notwendigkeit eines progressiven Umgangs mit neuen KI-Technologien im Hochschulbereich. Ein Zwischenstand in 6 Thesen. https://hochschulforumdigitalisierung.de/zur-bedeutung-von-chatgpt-der-notwendigkeit-eines-progressiven-umgangs-mit-neuen-ki-technologien-im-hochschulbereich-ein-zwischenstand-in-6-thesen/.

Fyfe, E. R., McNeil, N. M., Son, J. Y., & Goldstone, R. L. (2014). Concreteness fading in mathematics and science instruction: A systematic review. *Educational Psychology Review*, *26*(1), 9–25. https://doi.org/10.1007/s10648-014-9249-3.

Gallegos, S. (2026). *Guidance over adoption: Experimental evidence on AI-assisted learning* (IZA Discussion Paper; Nr. 18513). Institute of Labor Economics (IZA).

Garner, J. K., & Alley, M. (2013). How the design of presentation slides affects audience comprehension: A case for the assertion–evidence approach. *International Journal of Engineering Education*, *29*(6), 1564–1579.

Gerber, A., Lorenz, L., & Pfeiffer, U. (2026). KI-Tutoren in der Lehre: rechtlich sicher, didaktisch wertvoll, technisch innovativ. In J. Leschke, R. Queckenberg, & M. Persike (Hrsg.), *Learning analytics, artificial intelligence und data mining in der hochschulbildung*: (S. 57–64). transcript. https://doi.org/10.14361/9783839458761-057.

Ghahramani, Z. (2026, Juni). *Gemini's guided learning: Results from a randomized controlled trial in Sierra Leone*. https://deepmind.google/blog/measuring-the-impact-of-learning-with-ai-in-sierra-leone-and-beyond/.

Gieselmann, H. (2024, August 16). Wie Sie Musik live coden mit Sonic Pi unterstützt von Sprachmodellen. *c't Magazin*. https://www.heise.de/ratgeber/Wie-Sie-Musik-live-coden-mit-Sonic-Pi-unterstuetzt-von-Sprachmodellen-9829751.html.

Gimpel, H., Gutheil, N., Mayer, V., Bandtel, M., Büttgen, M., Decker, S., Eymann, T., Feulner, S., Kaya, M. F., Kufner, M., Kühl, N., Lämmermann, L., Maedche, A., Ruiner, C., Schoop, M., & Urbach, N. (2024). *(Generative) AI competencies for future-proof graduates: Inspiration for higher education institutions*. University of Hohenheim. https://doi.org/10.5281/zenodo.10680210.

Glomski, E., Yilmaz, C., Dau, H., & Kubsch, M. (2026). ChatGPT as a tutor?—between supporting students and giving away all the answers. *American Journal of Physics*, *94*(9), 793–794. https://doi.org/10.1119/5.0311016.

Gmeiner, B. (2025). *Ohne Shortcut zur Leistung: KI-resistente Aufgabenformate im Unterricht. Ein Handbuch für Lehrkräfte der Sekundarstufe*. Self-published.

Gobet, F., Lane, P. C., Croker, S., Cheng, P. C., Jones, G., Oliver, I., & Pine, J. M. (2001). Chunking mechanisms in human learning. *Trends in cognitive sciences*, *5*(6), 236–243.

Goldratt, E. M., & Cox, J. (2014). *The goal: A process of ongoing improvement*. North River Press.

Google (2025). *Strategien für Prompt-Design*. Google.

Google (2026). Google AI Pro und Ultra: Abos im Vergleich. *Gemini*. https://gemini.google/de/subscriptions/?hl=de.

Google Workspace Updates (2026a, August). *Gemini in Google Classroom is expanding to users of all ages, with contextualized Gemini starter prompts for students*. https://workspaceupdates.googleblog.com/2026/08/gemini-in-google-classroom-is-expanding-to-users-of-all-ages-with-contextualized-Gemini-starter-prompts-for-students.html.

Google Workspace Updates (2026b, September). *Introducing skills in the Gemini app and Workspace, plus what's next for Gems*. https://workspaceupdates.googleblog.com/2026/09/skills-gemini-app-workspace.html.

Goslen, A., Kim, Y. J., Rowe, J., & Lester, J. (2025). LLM-based student plan generation for adaptive scaffolding in game-based learning environments. *International Journal of Artificial Intelligence in Education*, *35*(2), 533–558. https://doi.org/10.1007/s40593-024-00421-1.

Gottweis, J., Weng, W.-H., Daryin, A., Tu, T., Palepu, A., Sirkovic, P., Myaskovsky, A., Weissenberger, F., Rong, K., Tanno, R., Saab, K., Popovici, D., Blum, J., Zhang, F., Chou, K., Hassidim, A., Gokturk, B., Vahdat, A., Kohli, P., … Natarajan, V. (2025). *Towards an AI co-scientist*. arXiv. https://doi.org/10.48550/arXiv.2502.18864.

Grace, M., Hadfield, J., Olivares, R., & De Jonghe, J. (2026, Januar 9). Demystifying evals for AI agents. https://www.anthropic.com/engineering/demystifying-evals-for-ai-agents.

Grootendorst, M. (2025a, Februar 3). *A Visual Guide to Reasoning LLMs*. https://newsletter.maartengrootendorst.com/p/a-visual-guide-to-reasoning-llms.

Grootendorst, M. (2025b, März 17). A visual guide to LLM agents: Exploring the main components of single- and multi-agents. https://newsletter.m

aartengrootendorst.com/p/a-visual-guide-to-llm-agents.

Habgood, M. P. J., & Ainsworth, S. E. (2011). Motivating Children to Learn Effectively: Exploring the Value of Intrinsic Integration in Educational Games. *Journal of the Learning Sciences*, *20*(2), 169–206. https://doi.org/10.1080/10508406.2010.508029.

Hackl, V., Müller, A. E., & Sailer, M. (2026). The AI literacy heptagon: A structured approach to AI literacy in higher education. *Computers and Education: Artificial Intelligence*, *10*, 100540. https://doi.org/10.1016/j.caeai.2026.100540.

Hake, R. R. (1998). Interactive-engagement versus traditional methods: A six-thousand-student survey of mechanics test data for introductory physics courses. *American Journal of Physics*, *66*(1), 64–74. https://doi.org/10.1119/1.18809.

Handa, K., Bent, D., Tamkin, A., McCain, M., Durmus, E., Stern, M., Schiraldi, M., Huang, S., Ritchie, S., Syverud, S., Jagadish, K., Vo, M., Bell, M., & Ganguli, D. (2025). *Anthropic Education Report: How university students use Claude*. Anthropic.

Hanover Research (2024). *Assessment and generative artificial intelligence in higher education* (Report). Hanover Research.

Harris, F. W. (1990). How Many Parts to Make at Once. *Operations Research*, *38*(6), 947–950. https://doi.org/10.1287/opre.38.6.947.

Harrison, W., Khowaja, R., Dobson, E., Uwimpuhwe, G., & Higgins, S. (2026). *Evaluating AI tutoring at the speed of innovation: Practitioner-led micro-randomised trials of an AI tutoring platform in GCSE science*. https://doi.org/10.48550/arXiv.2609.14789.

Hashimoto, M. (2026, Februar 5). *My AI adoption journey*. https://mitchellh.com/writing/my-ai-adoption-journey.

Hassany, M., Brusilovsky, P., Ke, J., Akhuseyinoglu, K., & Narayanan, A. B. L. (2024). *Human-AI Co-Creation of Worked Examples for Programming Classes*. arXiv. https://doi.org/10.48550/ARXIV.2402.16235.

Hattie, J. (2023). *Visible learning, the sequel: a synthesis of over 2,100 meta-analyses relating to achievement*. Routledge, Taylor & Francis Group. https://doi.org/10.4324/9781003380542.

Hayashi, Y., Shimojo, S., & Kawamura, T. (2025). Scripted interventions versus reciprocal teaching in collaborative learning: A comparison of pedagogical and teachable agents using a cognitive architecture. *Learning and Instruction*, *96*, 102057. https://doi.org/10.1016/j.learninstruc.2024.102057.

Heetkamp, S. J. (2023, Dezember 13). Die VR-Revolution im Justizwesen.

https://www.deutscheranwaltspiegel.de/e-justice/digitalisierung/die-vr-revolution-im-justizwesen-151520/.

Heidt, A. (2025). ChatGPT for students: learners find creative new uses for chatbots. *Nature*, *639*(8053), 265–266. https://doi.org/10.1038/d41586-025-00621-2.

Henderson, C., & Dancy, M. H. (2007). Barriers to the use of research-based instructional strategies: The influence of both individual and situational characteristics. *Physical Review Special Topics—Physics Education Research*, *3*(2), 020102.

HeyGen (2026). *HyperFrames*. GitHub. https://github.com/heygen-com/hyperframes.

Holec, H. (1981). *Autonomy and foreign language learning*. Pergamon.

Horstmann, N., Hüsch, M., & Breiter, A. (2026). *Künstliche Intelligenz im Studium – Die Sicht von Studierenden im Wintersemester 2025/26*. CHECK, CHE Centrum für Hochschulentwicklung. https://hochschuldaten.che.de/kuenstliche-intelligenz-im-studium-die-sicht-von-studierenden-im-wintersemester-2025-26/.

Hou, Xinmeng, Weng, Y., Yeh, C. H., Lee, D. L., Zheng, L., Li, F., Wang, W., & Liu, Y. (2026). *Adaptive scaffolding needs contingency: An AI tutor that escalates and fades on what the learner does*. https://doi.org/10.48550/arXiv.2609.22993.

Hou, Xiaoyu, Xiao, B., Liu, H., & Mueller, S. (2026). The role of instructional guidance in generative AI-assisted learning: Empirical evidence from construction engineering education. https://doi.org/10.48550/arXiv.2606.05509.

Huffman, P., & Hutson, J. (2024). Enhancing History Education with Google NotebookLM: Case Study of Mary Easton Sibley's Diary for Multimedia Content and Podcast Creation. *ISRG Journal of Arts, Humanities and Social Sciences*, *2*(5).

Hugging Face (2026). GGUF. *Hugging Face Hub documentation*. https://huggingface.co/docs/hub/gguf.

Hüsch, M., Horstmann, N., & Breiter, A. (2025). *Künstliche Intelligenz im Studium: Die Sicht von Studierenden im Wintersemester 2024/25*. CHE Centrum für Hochschulentwicklung.

Huyen, C. (2025). *AI engineering: building applications with foundation models*. O'Reilly.

Ippolito, J. (2025). *AI sandwich*. https://aipedagogy.org/assignment/ai-sandwich/.

IT Center der RWTH Aachen (2026, Oktober 15). KI:connect – Changes

(Versionshistorie v1.6.0 bis v1.28.0). *IT Center Changes*. https://blog.rwth-aachen.de/itc-changes/category/kiconnect.

Jing, Y., Wang, J., Wang, P., & Xu, J. (2026). The impact of generative artificial intelligence on learning outcomes in higher education: A meta-analysis. *Journal of Computer Assisted Learning*, *42*(5), e70329. https://doi.org/10.1002/jcal.70329.

Johnston, D., Holtz, D., Richmond, A. M., Ong, C., Tambe, P., & Chatterji, A. (2026). *The shift to agentic AI: Evidence from Codex*. https://doi.org/10.48550/arXiv.2606.26959.

Jones, C. R., & Bergen, B. K. (2025). *Large Language Models Pass the Turing Test*. arXiv. https://doi.org/10.48550/arXiv.2503.23674.

Jurafsky, D., & Martin, J. H. (2025). *Speech and language processing: An introduction to natural language processing, computational linguistics, and speech recognition with language models*.

Jurran, N. (2025). ChatGPT als sprechtrainer. *c't Special*, *2*, 100–103.

Kalyuga, S., Ayres, P., Chandler, P., & Sweller, J. (2003). The expertise reversal effect. *Educational Psychologist*, *38*(1), 23–31. https://doi.org/10.1207/S15326985EP3801_4.

Katz, J. J., Ando, M., & Wiseheart, M. (2021). Optimizing song retention through the spacing effect. *Cognitive Research: Principles and Implications*, *6*(1), 79. https://doi.org/10.1186/s41235-021-00345-7.

Kazu, İ. Y., & Kuvvetli, M. (2025). Digital language learning with Duolingo: assessing its impact on listening, speaking, reading, and writing skills. *Journal of Computers in Education*. https://doi.org/10.1007/s40692-025-00355-0.

Kearney, S. (2019). Transforming the first-year experience through self and peer assessment. *Journal of University Teaching and Learning Practice*, *16*(5), 1–17.

Keiser, N. L., & Arthur, W., Jr. (2021). A meta-analysis of the effectiveness of the after-action review (or debrief) and factors that influence its effectiveness. *Journal of Applied Psychology*, *106*(7), 1007–1032. https://doi.org/10.1037/apl0000821.

Kestin, G., Miller, K., Klales, A., Milbourne, T., & Ponti, G. (2025). AI tutoring outperforms in-class active learning: an RCT introducing a novel research-based design in an authentic educational setting. *Scientific Reports*, *15*(1), 17458. https://doi.org/10.1038/s41598-025-97652-6.

Khan, S. (2026, Juli). *Khanmigo's first chapter changed how I think about AI: A note from Sal Khan*. https://blog.khanacademy.org/khanmigos-first-chapter-changed-how-i-think-about-ai-a-note-from-sal-khan/.

KI-Campus (2026). *EU AI Act: KI-Omnibus justiert Artikel 4 neu – KI-Kompetenz bleibt Pflicht*. KI-Campus Blog. https://ki-campus.org/blog/eu-ai-act-ki-omnibus-justiert-artikel-4-neu-ki-kompetenz-bleibt-pflicht.

KI:connect.nrw (2026, Mai 11). Souveräne KI für NRW: Offene Sprachmodelle über KI:Inferenz.nrw in KI:connect. https://kiconnect.pages.rwth-aachen.de/pages/blog/2026/05/11/2026-05-11_souveraene-ki-nrw/.

Kindenberg, B. (2025). The role of AI in historical simulation design: A TPACK perspective on a French Revolution simulation design experience. *Education Sciences*, *15*(2), 192. https://doi.org/10.3390/educsci15020192.

Klein, D. A. (2023, Februar 17). „Die Hausarbeit ist tot, es lebe die Hausarbeit!“ - Entwicklungsorientierung, wissenschaftliches Arbeiten und KI gemeinsam denken. https://hochschulforumdigitalisierung.de/die-hausarbeit-ist-tot-es-lebe-die-hausarbeit-entwicklungsorientierung-wissenschaftliches-arbeiten-und-ki-gemeinsam-denken/.

Kofinas, A. K., Tsay, C. H.-H., & Pike, D. (2025). The impact of generative AI on academic integrity of authentic assessments within a higher education context. *British Journal of Educational Technology*, *56*(6), 2522–2549. https://doi.org/10.1111/bjet.13585.

Korinek, A. (2024). *Generative AI for economic research: LLMs learn to collaborate and reason* (*December 2024 update*) (NBER Working Paper; Nr. w33198). National Bureau of Economic Research. https://doi.org/10.3386/w33198.

Kosmyna, N., Hauptmann, E., Yuan, Y. T., Situ, J., Liao, X.-H., Beresnitzky, A. V., Braunstein, I., & Maes, P. (2025). Your Brain on ChatGPT: Accumulation of Cognitive Debt when Using an AI Assistant for Essay Writing Task. https://doi.org/10.48550/arXiv.2506.08872.

Kotha, A., Lee, J., Zakariasson, E., et al. (2025). *GPT-5 Prompting Guide*. OpenAI.

Kuo, Y.-C., & Zhuo, M.-J. (2026). The impact of flipped classrooms integrated with differentiated chatbots on programming learning. *Educational Technology Research and Development*. https://doi.org/10.1007/s11423-026-10669-0.

Kuric, E., Demcak, P., & Krajcovic, M. (2026). *What would GPT click: Practical effects of human-AI behavioral misalignment and the cost of synthetic participants in user experience*. https://doi.org/10.48550/arXiv.2605.18302.

Kwa, T., West, B., Becker, J., Deng, A., Garcia, K., Hasin, M., Jawhar, S., Kinniment, M., Rush, N., Arx, S. V., Bloom, R., Broadley, T., Du, H., Goodrich, B., Jurkovic, N., Miles, L. H., Nix, S., Lin, T., Parikh, N., …

Chan, L. (2025). *Measuring AI Ability to Complete Long Tasks*. arXiv. https://doi.org/10.48550/arXiv.2503.14499.

Landfair, A. (2025). *Playtesting your ChatGPT prompt*. https://aipedagogy.org/assignment/playtesting-your-chatgpt-prompt/.

Latif, E., Liu, V., & Zhai, X. (2026). A systematic review of intelligent and robot tutoring systems: evolution, pedagogical design, and AI-driven classification. *Smart Learning Environments*.

Lawson, A. P., Martella, A. M., Weidlich, J., Mulders, M., & Buchner, J. (2026). Color me confounded: A critical analysis of media comparisons on ChatGPT in education. *Computers & Education*, *254*, 105701. https://doi.org/10.1016/j.compedu.2026.105701.

LearnLM Team, Eedi, Wang, A., Rysbek, A., & Huber, A. (2025). AI tutoring can safely and effectively support students: An exploratory RCT in UK classrooms. https://doi.org/10.48550/arXiv.2512.23633.

Lee, H. L., Padmanabhan, V., & Whang, S. (1997). Information distortion in a supply chain: The bullwhip effect. *Management Science*, *43*(4), 546–558. https://doi.org/10.1287/mnsc.43.4.546.

Lee, H.-P. H., Sarkar, A., Tankelevitch, L., Drosos, I., Rintel, S., Banks, R., & Wilson, N. (2025). The Impact of Generative AI on Critical Thinking: Self-Reported Reductions in Cognitive Effort and Confidence Effects From a Survey of Knowledge Workers. https://doi.org/10.1145/3706598.3713778.

Lee, Suhyeon, Baek, J., Park, J., & Shin, D. (2026). *LLM pedagogical behavior in AI tutoring interactions*. https://doi.org/10.48550/arXiv.2608.22993.

Lee, Sangmin, Choe, H., Zou, D., & Jeon, J. (2025). Generative AI (GenAI) in the language classroom: A systematic review. *Interactive Learning Environments*, 1–25. https://doi.org/10.1080/10494820.2025.2498537.

Leinonen, J., Zhang, L., & Hellas, A. (2026). AI-Generated Slides: Are They Good? Can Students Tell? https://doi.org/10.1145/3828792.3828803.

Leuphana Universität Lüneburg (o. J.). KI-Kennzeichnung in Prüfungsleistungen. *Leuphana Universität Lüneburg: Lehre*. https://www.leuphana.de/lehre/kuenstliche-intelligenz/ki-kennzeichnung.html.

Levine, J., Aenlle, M., Zilles, C., West, M., & Silva, M. (2026). Automated grading of handwritten mathematics using vision-capable LLMs. https://doi.org/10.48550/arXiv.2605.19043.

Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W., Rocktäschel, T., Riedel, S., & Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. https://doi.org/10.48550/arXiv.2005.11401.

Liang, J. T., Yang, C., & Myers, B. A. (2024). A large-scale survey on the usability of ai programming assistants: Successes and challenges.

Lim, J., Lee, U., Koh, J., Jeong, Y., Lee, Y., Byun, G., Jung, H., Jang, Y., Lee, S., & Moon, J. (2025). Development and implementation of a generative artificial intelligence-enhanced simulation to enhance problem-solving skills for pre-service teachers. *Computers & Education*, *232*, 105306. https://doi.org/10.1016/j.compedu.2025.105306.

Lindsey, J., Gurnee, W., Ameisen, E., Chen, B., Pearce, A., Turner, N. L., Citro, C., Abrahams, D., Carter, S., Hosmer, B., Marcus, J., Sklar, M., Templeton, A., Bricken, T., McDougall, C., Cunningham, H., Henighan, T., Jermyn, A., Jones, A., ... Batson, J. (2025). On the biology of a large language model. *Transformer Circuits Thread*.

Little, J. D. C. (1961). A proof for the queuing formula: L = λW. *Operations Research*, *9*(3), 383–387. https://doi.org/10.1287/opre.9.3.383.

Liu, J., Sweet, T., Chen, M. H., Engelberg, J., Masters, M. C., Clark, M., Persaud, A., Lancaster, A., Hollingsworth, J. K., & Rice, J. K. (2026). *The effects of course-integrated AI tutoring on student performance and engagement: A randomized university trial* (EdWorkingPaper; Nr. 26-1598). Annenberg Institute at Brown University. https://doi.org/10.26300/y3f8-vh05.

Lopopolo, R. (2026, Februar 11). Harness engineering: Leveraging Codex in an agent-first world. https://openai.com/index/harness-engineering/.

Love, R., Law, E., Cohen, P. R., & Kulić, D. (2025). Teaching a Conversational Agent using Natural Language: Effect on Learning and Engagement. *International Journal of Artificial Intelligence in Education*. https://doi.org/10.1007/s40593-025-00461-1.

Lovely, G. (2025). AI could soon tackle projects that take humans weeks. *Nature*. https://doi.org/10.1038/d41586-025-00831-8.

Lowe, R. K. (2003). Animation and learning: selective processing of information in dynamic graphics. *Learning and Instruction*, *13*(2), 157–176. https://doi.org/10.1016/s0959-4752(02)00018-x.

Lu, X., & Wang, X. (2024). Generative Students: Using LLM-Simulated Student Profiles to Support Question Item Evaluation. https://doi.org/10.1145/3657604.3662031.

Lyu, B., Li, C., Li, H., Oh, H., Song, Y., Zhu, W., & Xing, W. (2025). The Role of Teachable Agents' Personality Traits on Student-AI Interactions and Math Learning. *Computers & Education*, 105314. https://doi.org/10.1016/j.compedu.2025.105314.

Maier, S., Schwabe, K., Schneider, M., & Feuerriegel, S. (2026). *Designing against deskilling: Metacognitive feedback reduces cognitive offloading to LLM*

assistants. https://doi.org/10.48550/arXiv.2609.20143.

Mar, R. A., Li, J., Nguyen, A. T. P., & Ta, C. P. (2021). Memory and comprehension of narrative versus expository texts: A meta-analysis. *Psychonomic Bulletin & Review*, *28*(3), 732–749. https://doi.org/10.3758/s13423-020-01853-1.

Marchena, M. (2018). *bullwhipgame: Bullwhip effect demo in Shiny*. CRAN. https://doi.org/10.32614/CRAN.package.bullwhipgame.

Martin, L., Cemaj, G., & Cohen, M. (2026, April 8). Scaling Managed Agents: Decoupling the brain from the hands. Anthropic. https://www.anthropic.com/engineering/managed-agents.

Massachusetts Institute of Technology, Ad Hoc Committee on AI Use in Teaching, Learning, and Research Training (2026, August). *Report of MIT's Ad Hoc Committee on AI use in teaching, learning, and research training*. https://aiandeducation.mit.edu/.

Mayer, R. E., & Fiorella, L. (2014). Principles for Reducing Extraneous Processing in Multimedia Learning: Coherence, Signaling, Redundancy, Spatial Contiguity, and Temporal Contiguity Principles. In R. E. Mayer (Hrsg.), *The Cambridge handbook of multimedia learning*: (S. 279–315). Cambridge University Press. https://doi.org/10.1017/cbo9781139547369.015.

McAfee, A. (2024). *Generally Faster: The Economic Impact of Generative AI* (Davos Report). Google.

McGlone, M. S., & Tofighbakhsh, J. (2000). Birds of a Feather Flock Conjointly (?): Rhyme as Reason in Aphorisms. *Psychological Science*, *11*(5), 424–428. https://doi.org/10.1111/1467-9280.00282.

Meincke, L., Mollick, E. R., Mollick, L., & Shapiro, D. (2025a). *Prompting Science Report 2: The Decreasing Value of Chain of Thought in Prompting*. arXiv. https://doi.org/10.48550/arXiv.2506.07142.

Meincke, L., Mollick, E. R., & Terwiesch, C. (2024). *Prompting Diverse Ideas: Increasing AI Idea Variance*. https://papers.ssrn.com/abstract=4708466.

Meincke, L., Mollick, E., Mollick, L., & Shapiro, D. (2025b). *Prompting Science Report 1: Prompt Engineering is Complicated and Contingent*. arXiv. https://doi.org/10.48550/arXiv.2503.04818.

Meincke, L., Mollick, E., Mollick, L., & Shapiro, D. (2025c). *Prompting Science Report 3: I'll pay you or I'll kill you -- but will you care?* arXiv. https://doi.org/10.48550/arXiv.2508.00614.

Melanou, C., Beege, M., & Kimmig, M. (2026). Generative AI and learning dynamics in higher education: A longitudinal empirical study. *Journal of Computer Assisted Learning*, *42*(5), e70322. https://doi.org/10.1002/jcal.7

0322.
METR (2026). *Time horizon of frontier AI models*. https://metr.org/time-horizons/.
Michinov, N., & Michinov, E. (2026). More competition, less interaction: gamifying lectures using a leaderboard reduces female students' social engagement. *Journal of Computing in Higher Education*, *38*(1), 386–412. https://doi.org/10.1007/s12528-025-09438-4.
Milam, K., & Gulli, A. (2025). *Context engineering: Sessions, memory* (Whitepaper). Google.
Ministerium für Kultur und Wissenschaft des Landes Nordrhein-Westfalen (2025, Januar 31). Studieren und Forschen mit Künstlicher Intelligenz: Hochschulen in Nordrhein-Westfalen erhalten zentralen Zugang zu KI-Diensten. *Pressemitteilung des Landes Nordrhein-Westfalen*. https://www.land.nrw/pressemitteilung/studieren-und-forschen-mit-kuenstlicher-intelligenz-hochschulen-nordrhein.
Mistral AI (2026). *Pricing*. https://mistral.ai/pricing/.
MIT Teaching + Learning Lab (2023). *Rethinking Your Problem Sets in the World of Generative AI | Teaching + Learning Lab*. https://tll.mit.edu/rethinking-your-problem-sets-in-the-world-of-generative-ai/.
Mittal, S., Blodgett, S. L., & Liao, Q. V. (2026). Learning by chatting? Investigating the impact of generative AI on information seeking and learning. https://doi.org/10.48550/arXiv.2606.11669.
Mocko, M., Wagler, A. E., Lesser, L. M., Francis, W. S., Blush, J. M., Schleicher, K., & Barrientos, P. S. (2024). What They Remember May Not Be What They Understand: A Study of Mnemonic Recall and Performance by Introductory Statistics Students. *Journal of Statistics and Data Science Education*, *32*(4), 416–431. https://doi.org/10.1080/26939169.2024.2334905.
Mollick, E. (2024). *Co-intelligence: living and working with AI*. Portfolio/Penguin.
Mollick, E. (2026a, Februar 18). A Guide to Which AI to Use in the Agentic Era. https://www.oneusefulthing.org/p/a-guide-to-which-ai-to-use-in-the?post_id=188100833&r=2248w9.
Mollick, E. (2026b, Juli 23). An opinionated guide to which AI to use to do stuff: The Summer 2026 Edition. https://www.oneusefulthing.org/p/an-opinionated-guide-to-which-ai-b22.
Mollick, E. (2026c, September 18). The overhang. https://www.oneusefulthing.org/p/the-overhang.
Mollick, E. R. (2023, Juli 1). The Homework Apocalypse. https://www.oneusefulthing.org/p/the-homework-apocalypse.

Mollick, E. R. (2025a, Januar 26). A new generation of AIs: Claude 3.7 and Grok 3. https://www.oneusefulthing.org/p/a-new-generation-of-ais-claude-37.

Mollick, E. R. (2025b, Dezember 20). The Shape of AI: Jaggedness, Bottlenecks and Salients. https://www.oneusefulthing.org/p/the-shape-of-ai-jaggedness-bottlenecks.

Mollick, E. R. (2026a, August 31). Agency and agents. https://www.oneusefulthing.org/p/agency-and-agents.

Mollick, E. R. (2026b, Oktober 20). 30 months on the exponential (in charts). https://www.oneusefulthing.org/p/30-months-on-the-exponential-in-charts.

Mollick, E. R., & Mollick, L. (2023a). *Using AI to Implement Effective Teaching Strategies in Classrooms: Five Strategies, Including Prompts* (SSRN Scholarly Paper; Nr. 4391243).

Mollick, E. R., & Mollick, L. (2023b). *Assigning AI: Seven Approaches for Students, with Prompts*. arXiv. https://doi.org/10.48550/arXiv.2306.10052.

Mollick, E. R., & Mollick, L. (2024). *Instructors as Innovators: a Future-focused Approach to New AI Learning Opportunities, With Prompts*. https://doi.org/10.2139/ssrn.4802463.

Mollick, E. R., Mollick, L., Bach, N., Ciccarelli, L. J., Przystanski, B., & Ravipinto, D. (2024). AI agents and education: Simulated practice at scale. *arXiv preprint arXiv:2407.12796*.

Mollick, L., & Mollick, E. R. (2024). *Student exercises*. https://www.moreusefulthings.com/student-exercises.

Monash University (2025). *Choosing assessment tasks*.

Moon, J., Lee, U., Koh, J., Jeong, Y., Lee, Y., Byun, G., & Lim, J. (2025). Generative Artificial Intelligence in Educational Game Design: Nuanced Challenges, Design Implications, and Future Research. *Technology, Knowledge and Learning*, *30*(1), 447–459. https://doi.org/10.1007/s10758-024-09756-z.

More Useful Things (o. J.). *Student exercises*. https://www.moreusefulthings.com/student-exercises.

Morehead, K., Rhodes, M. G., & DeLozier, S. (2016). Instructor and student knowledge of study strategies. *Memory*, *24*(2), 257–271. https://doi.org/10.1080/09658211.2014.1001992.

Morgan, G. (2024, Juli 11). What Students Want When It Comes To AI - The Digital Education Council Global AI Student Survey 2024. *On EdTech Newsletter*.

Morris, M. R., Sohl-Dickstein, J., Fiedel, N., Warkentin, T., Dafoe, A., Faust, A., Farabet, C., & Legg, S. (2024). Position: Levels of AGI for operationalizing progress on the path to AGI.

Mörth, M., Paridon, H., & Sonntag, U. (2021). Kognitionswissenschaftliche Erkenntnisse und ihre Folgerungen für evidenzbasierte Hochschullehre: die hochschullehre 05/2021. *die hochschullehre*, *7*(1), 38–48.

Mulder, R., Baik, C., & Ryan, T. (2023). *Rethinking assessment in response to AI* (Guide). Melbourne Centre for the Study of Higher Education.

Murre, J. M., & Dros, J. (2015). Replication and analysis of Ebbinghaus' forgetting curve. *PloS one*, *10*(7), e0120644.

Naddaf, M. (2025). How are researchers using AI? Survey reveals pros and cons for science. *Nature*. https://doi.org/10.1038/d41586-025-00343-5.

Nakamura, D. (2026). Augmentation or erosion? Regulating cognitive offloading in generative AI-supported STEM learning. *Educational Psychology Review*, *38*(124). https://doi.org/10.1007/s10648-026-10224-6.

Nepal, S. K., Soh, S., Vinoya, N., Park, S., Roshanaei, M., & Harari, G. (2026). *Faithful where it can be checked: Auditing a reflection agent against its system prompt in a randomized trial*. https://doi.org/10.48550/arXiv.2609.19635.

Netland, T., von Dzengelevski, O., Tesch, K., & Kwasnitschka, D. (2025). Comparing human-made and AI-generated teaching videos: An experimental study on learning effects. *Computers & Education*, *224*, 105164. https://doi.org/10.1016/j.compedu.2024.105164.

Nguyen, A., Gul, F., Dang, B., Huynh, L., & Tuunanen, T. (2025). Designing embodied generative artificial intelligence in mixed reality for active learning in higher education. *Innovations in Education and Teaching International*. https://doi.org/10.1080/14703297.2025.2499177.

Nguyen, H. A. (2024). Harnessing AI-based tools for enhancing English speaking proficiency: Impacts, challenges, and long-term engagement. *International Journal of AI in Language Education*, *1*(2), 18–29. https://doi.org/10.54855/ijaile.24122.

Ní Bheoláin, R., Lowney, R., & O'Riordan, F. (2020). *Students as Partners in Assessment (SaPiA): A Literature Scoping Review*. https://doi.org/10.5281/zenodo.4270579.

Nickow, A., Oreopoulos, P., & Quan, V. (2020). *The Impressive Effects of Tutoring on PreK-12 Learning: A Systematic Review and Meta-Analysis of the Experimental Evidence* (Nr. 27476). National Bureau of Economic Research. https://doi.org/10.3386/w27476.

Nizamudeen, F., Gatti, L., Bouali, N., & Ahmed, F. (2024). Investigating the Impact of Code Generation Tools (ChatGPT & Github CoPilot) on

Programming Education. https://doi.org/10.5220/0012628000003693.

Nofal, A. B., Ali, H., Hadi, M., Ahmad, A., Qayyum, A., Johri, A., Al-Fuqaha, A., & Qadir, J. (2025). AI-enhanced interview simulation in the metaverse: Transforming professional skills training through VR and generative conversational AI. *Computers and Education: Artificial Intelligence*, *8*, 100347. https://doi.org/10.1016/j.caeai.2024.100347.

Northcutt, C., Hasmani, I., Feng, K., Khangi, T., Plesner, A., & Mueller, J. (2026). *StudentBench: AI and human tutoring yield equivalent GRE learning gains*. https://doi.org/10.48550/arXiv.2609.28470.

O'Donnell, J., & Crownhart, C. (2025, Mai 20). We did the math on AI's energy footprint. Here's the story you haven't heard. *MIT Technology Review*.

Object Management Group (2014). *Business Process Model and Notation (BPMN), Version 2.0.2*. https://www.omg.org/spec/BPMN/2.0.2/.

OECD, & European Union (2026). *Empowering learners for the age of AI: An AI literacy framework for primary and secondary education*. OECD Publishing. https://doi.org/10.1787/65cd27d4-en.

Ogunleye, B., Zakariyyah, K. I., Ajao, O., Olayinka, O., & Sharma, H. (2024). A Systematic Review of Generative AI for Teaching and Learning Practice. *Education Sciences*, *14*(6), 636. https://doi.org/10.3390/educsci14060636.

OpenAI (2024). *Learning to reason with LLMs*.

OpenAI (2025). *openai/skills: Skills Catalog for Codex*. https://github.com/openai/skills.

OpenAI (2026a). *ChatGPT pricing*. https://chatgpt.com/pricing/.

OpenAI (2026b, März). *Understanding AI and learning outcomes*. https://openai.com/index/understanding-ai-and-learning-outcomes/.

OpenAI (2026c, August). *New ways to learn and teach with ChatGPT Work and Codex*. https://openai.com/index/learn-teach-chatgpt-work-codex/.

OpenAI (2026d, September). Custom GPT retirement and migration FAQ. *OpenAI Help Center*. https://help.openai.com/en/articles/20001519.

Oreopoulos, P., Keyes-Krysakowski, O., & Agarwal, D. (2026). *How In-School Supervised Ed-Tech Support Produces Massive Learning Gains: A Khan Academy Field Experiment in India* (NBER Working Paper; Nr. 34683). National Bureau of Economic Research. https://doi.org/10.3386/w34683.

Oreopoulos, P., Liut, M., Sungu, A., & Low, N. (2026). *Making AI tutoring productive: Evidence from a mastery-based math practice experiment* (NBER Working Paper; Nr. 35621). National Bureau of Economic Research. https://doi.org/10.3386/w35621.

Oreopoulos, P., & Low, N. (2026). *One click away: AI tutoring with Khanmigo in a two-year school experiment* (NBER Working Paper; Nr. 35620). National Bureau of Economic Research. https://doi.org/10.3386/w35620.

Österreichischer Universitätsprofessor/innenverband (2018). *Österreich - Arbeitszeitverteilung von Professoren 2017*.

Ou, A. W., Stöhr, C., & Malmström, H. (2024). Academic communication with AI-powered language tools in higher education: From a post-humanist perspective. *System*, *121*, 103225. https://doi.org/10.1016/j.system.2024.103225.

Pan, S. C., & Carpenter, S. K. (2023). Prequestioning and pretesting effects: A review of empirical research, theoretical perspectives, and implications for educational practice. *Educational Psychology Review*, *35*(4), 97. https://doi.org/10.1007/s10648-023-09814-5.

Parasuraman, R., Sheridan, T. B., & Wickens, C. D. (2000). A model for types and levels of human interaction with automation. *IEEE Transactions on Systems, Man, and Cybernetics - Part A: Systems and Humans*, *30*(3), 286–297. https://doi.org/10.1109/3468.844354.

Pedersen, D. (2025). *DuPont analysis of coca-cola*. https://aipedagogy.org/assignment/dupont-analysis-of-coca-cola/.

Peng, S., Kalliamvakou, E., Cihon, P., & Demirer, M. (2023). *The Impact of AI on Developer Productivity: Evidence from GitHub Copilot*. arXiv. https://doi.org/10.48550/arXiv.2302.06590.

Peng, Z., Tao, W., Yin, X., Ying, C., Luo, Y., & Guo, Y. (2026). PlayCoder: Making LLM-Generated GUI Code Playable. *Proceedings of the ACM on Software Engineering*, *3*(FSE), 2003–2026. https://doi.org/10.1145/3808097.

Perczel, J., Chow, J., & Demszky, D. (2025). TeachLM: Post-training LLMs for education using authentic learning data. https://doi.org/10.48550/arXiv.2510.05087.

Persike, M. (2025, Dezember 5). Virtuelle API-Keys in KI:connect. https://kiconnect.pages.rwth-aachen.de/pages/blog/2025/12/05/2025-12-05_virtuelle-api-keys/.

Pinski, M., & Benlian, A. (2024). AI literacy for users – A comprehensive review and future research directions of learning methods, components, and effects. *Computers in Human Behavior: Artificial Humans*, *2*(1), 100062. https://doi.org/10.1016/j.chbah.2024.100062.

Pisan, Y. (2026). *Teaching a large language model tutor to withhold the answer: A supervisor architecture and an evidence-driven method for tuning socratic behavior*. https://doi.org/10.48550/arXiv.2608.12292.

Ploetzner, R., Berney, S., & Bétrancourt, M. (2020). A review of learning demands in instructional animations: The educational effectiveness of animations unfolds if the features of change need to be learned. *Journal of Computer Assisted Learning*, *36*(6), 838–860. https://doi.org/10.1111/jcal.12476.

Ploetzner, R., Berney, S., & Bétrancourt, M. (2021). When learning from animations is more successful than learning from static pictures: learning the specifics of change. *Instructional Science*, *49*(4), 497–514. https://doi.org/10.1007/s11251-021-09541-w.

Pollock, E., Chandler, P., & Sweller, J. (2002). Assimilating complex information. *Learning and Instruction*, *12*(1), 61–86. https://doi.org/10.1016/s0959-4752(01)00016-0.

Porter, L., & Zingaro, D. (2024). *Learn AI-Assisted Python Programming: With Github Copilot and ChatGPT*. Simon and Schuster.

Puchert, L., & Schnieders, B. (2026). *Prüfungssimulation: Performanzprüfung im Modul Kommunikation und Gesprächsführung, BA Soziale Arbeit*. CBS University of Applied Sciences. https://hochschulforumdigitalisierung.de/wp-content/uploads/2025/01/3292-Kurz_Praesi_BASA_Pruefungssimulation_260522.pdf.

Puryear, B., & Sprint, G. (2022). Github copilot in the classroom: learning to code with AI assistance. *Journal of Computing Sciences in Colleges*, *38*(1), 37–47.

Rajpurkar, P., Jia, R., & Liang, P. (2018). Know What You Don't Know: Unanswerable Questions for SQuAD. https://doi.org/10.18653/v1/p18-2124.

Reason, J. (2000). Human error: models and management. *BMJ*, *320*(7237), 768–770. https://doi.org/10.1136/bmj.320.7237.768.

Ren, X., Li, X., Gao, L., Wei, Q., Liu, H., & Yu, X. (2026). Effects of AI interventions across cognitive, social-emotional, and academic outcomes: A meta-analysis of randomized controlled trials with nonlinear dose–response evidence. *Educational Psychology Review*, *38*(128). https://doi.org/10.1007/s10648-026-10217-5.

Rey, G. D. (2012). A review of research and a meta-analysis of the seductive detail effect. *Educational Research Review*, *7*(3), 216–237. https://doi.org/10.1016/j.edurev.2012.05.003.

Rey, G. D., Beege, M., Nebel, S., Wirzberger, M., Schmitt, T. H., & Schneider, S. (2019). A Meta-analysis of the Segmenting Effect. *Educational Psychology Review*, *31*(2), 389–419. https://doi.org/10.1007/s10648-018-9456-4.

Rismanchian, S., Uzun, H., Matayoshi, J., Cosyn, E., & Kurd-Misto, E. (2026).

Faster completion, less learning: Generative AI reduced study time on math problems and the knowledge they build. https://doi.org/10.48550/arXiv.2605.21629.

Ritchie, H. (2024, September 19). *What's the impact of artificial intelligence on energy demand?* https://www.sustainabilitybynumbers.com/p/ai-energy-demand.

Robinson, C. D., Gormley, D., Trindade Ribeiro, A., & Loeb, S. (2026). *The role of human support in student engagement with AI tutoring platforms* (EdWorkingPaper; Nr. 26-1451). Annenberg Institute at Brown University. https://doi.org/10.26300/pz7p-p388.

Roediger, H. L., & Karpicke, J. D. (2006). Test-enhanced learning: taking memory tests improves long-term retention. *Psychological science*, *17*(3), 249–255. https://doi.org/10.1111/j.1467-9280.2006.01693.x.

Roediger, H. L., & Pyc, M. A. (2012). Inexpensive techniques to improve education: Applying cognitive psychology to enhance educational practice. *Journal of Applied Research in Memory and Cognition*, *1*(4), 242–248. https://doi.org/10.1016/j.jarmac.2012.09.002.

Rogosch, F., & Schrader, A. (2026). Automated Generation and Evaluation of Interactive-Fiction Serious Games with Open-Weight LLMs. *Applied Sciences*, *16*(6). https://doi.org/10.3390/app16062932.

Ross, J., So, E., & Lo, A. W. (2026). Breaking Bad Financial Habits: How LLM Conversations Correct Financial Misconceptions. https://doi.org/10.48550/arXiv.2604.27022.

Roucher, A., Noyan, M., & Wolf, T. (2024, Dezember 31). Introducing smolagents, a simple library to build agents. https://huggingface.co/blog/smolagents.

Rowland, D. R. (2023). Two frameworks to guide discussions around levels of acceptable use of generative AI in student academic research and writing. *Journal of Academic Language and Learning*, *17*(1), T31–T69.

Russell, S. J., & Norvig, P. (2021). *Artificial intelligence: a modern approach*. Pearson.

SAE International (2021). *Taxonomy and definitions for terms related to driving automation systems for on-road motor vehicles (J3016_202104)*. SAE International. https://doi.org/10.4271/J3016_202104.

Salden, P., & Leschke, J. (2023). *Didaktische und rechtliche Perspektiven auf KI-gestütztes Schreiben in der Hochschulbildung*. Ruhr-Universität Bochum, Universitätsbibliothek. https://doi.org/10.13154/294-9734.

Sapkota, A., & Murshed, M. G. S. (2026). LLMs as teaching assistants for mathematics exam grading: Reliability, and practical usability. https://

doi.org/10.48550/arXiv.2607.01247.

Säuberli, A., & Clematide, S. (2024). Automatic generation and evaluation of reading comprehension test items with large language models. https://doi.org/10.48550/arXiv.2404.07720.

Scarlatos, A., Liu, N., Lee, J., Baraniuk, R., & Lan, A. (2025). Training LLM-based tutors to improve student learning outcomes in dialogues. *arXiv preprint*.

Schick, T., Dwivedi-Yu, J., Dessì, R., Raileanu, R., Lomeli, M., Hambro, E., Zettlemoyer, L., Cancedda, N., & Scialom, T. (2023). Toolformer: Language models can teach themselves to use tools. https://doi.org/10.48550/arXiv.2302.04761.

Schluntz, E., & Zhang, B. (2024, Dezember 19). Building effective agents. https://www.anthropic.com/engineering/building-effective-agents.

Schneider, S., Beege, M., Nebel, S., & Rey, G. D. (2018). A meta-analysis of how signaling affects learning with media. *Educational Research Review*, *23*, 1–24. https://doi.org/10.1016/j.edurev.2017.11.001.

Schomburg, H., Flöther, C., & Wolf, V. (2012). *Wandel von Lehre und Studium an deutschen Hochschulen–Erfahrungen und Sichtweisen der Lehrenden*.

Schön, D. A. (1983). *The reflective practitioner: How professionals think in action*. Basic Books.

Schwarcz, D., Manning, S., Barry, P. J., Cleveland, D. R., Prescott, J. J., & Rich, B. (2025). *AI-Powered Lawyering: AI Reasoning Models, Retrieval Augmented Generation, and the Future of Legal Practice*. https://doi.org/10.2139/ssrn.5162111.

Schwarze, M. (2025, Juli 16). KI-Assistent Witsy kann kostenlos das ChatGPT-Monatsabo ersetzen. *Frankfurter Allgemeine Zeitung* (*FAZ*).

Sequoia Capital (2026). *Google DeepMind's Logan Kilpatrick: Why the model eats the harness*. https://sequoiacap.com/podcast/google-deepminds-logan-kilpatrick-why-the-model-eats-the-harness.

Shadle, S. E., Marker, A., & Earl, B. (2017). Faculty drivers and barriers: laying the groundwork for undergraduate STEM education reform in academic departments. *International Journal of STEM Education*, *4*(1), 8. https://doi.org/10.1186/s40594-017-0062-7.

Shaer, O., Cooper, A., Mokryn, O., Kun, A. L., & Ben Shoshan, H. (2024). AI-augmented brainwriting: Investigating the use of llms in group ideation. https://doi.org/10.48550/arXiv.2402.14978.

Shapiro, S., & Lindemann, J. (2026). *On-premises multi-course RAG tutoring for business education: Hardware-software trade-offs in a campus AI tutor*. https://doi.org/10.48550/arXiv.2610.02510.

Sitzmann, T. (2011). A meta-analytic examination of the instructional effectiveness of computer-based simulation games. *Personnel Psychology*, *64*(2), 489–528. https://doi.org/10.1111/j.1744-6570.2011.01190.x.

Somala, V., & Emberson, L. (2025, August 15). Frontier AI performance becomes accessible on consumer hardware within a year. *Epoch AI*. https://epoch.ai/data-insights/consumer-gpu-model-gap.

Spear, S., & Bowen, H. K. (1999). Decoding the DNA of the Toyota Production System. *Harvard Business Review*, *77*(5), 96–106.

Spencer, T., & Singh, S. (2024, Oktober 18). What the data centre and AI boom could mean for the energy sector – Analysis. https://www.iea.org/commentaries/what-the-data-centre-and-ai-boom-could-mean-for-the-energy-sector.

Spencer, T., & Singh, S. (2025). *Energy and AI* (World Energy Outlook Special Report). International Energy Agency.

Stains, M., Harshman, J., Barker, M. K., Chasteen, S. V., Cole, R., DeChenne-Peters, S. E., Eagan, M. K., Esson, J. M., Knight, J. K., Laski, F. A., Levis-Fitzgerald, M., Lee, C. J., Lo, S. M., McDonnell, L. M., McKay, T. A., Michelotti, N., Musgrove, A., Palmer, M. S., Plank, K. M., … Young, A. M. (2018). Anatomy of STEM teaching in North American universities. *Science*, *359*(6383), 1468–1470. https://doi.org/10.1126/science.aap8892.

Steinberger, P. (2025, Oktober 14). *Just Talk To It - the no-bs Way of Agentic Engineering | Peter Steinberger*. https://steipete.me/posts/just-talk-to-it.

Stephenson, R., & Armstrong, C. (2026). *Student generative artificial intelligence survey 2026* (Nr. 199). Higher Education Policy Institute.

Sterman, J. D. (1989). Modeling managerial behavior: Misperceptions of feedback in a dynamic decision making experiment. *Management Science*, *35*(3), 321–339. https://doi.org/10.1287/mnsc.35.3.321.

Stumpf, C., Schlude, A., Löwel, V., & Stürz, R. A. (2026). *Ein KI-Tutor geht in die Lehre: Empirische Ergebnisse zum Einsatz von OneTutor im Sommersemester 2025*. Bayerisches Forschungsinstitut für Digitale Transformation (bidt).

Sungu, A., Lira, B., & Duckworth, A. L. (2026). *Generative AI can harm teaching*. SSRN Working Paper 7007339. https://papers.ssrn.com/abstract=7007339.

Sweller, J. (2011). Cognitive load theory. In *Psychology of learning and motivation*: (Bd. 55, 37–76). Elsevier.

Tani, T., Joseph, M., Metso, L., & Tynninen, L. (2026). RAG 'n' Roll industrial management game: Building and testing a large language model assistant for operations education. *Computer Applications in*

Engineering Education, *34*(5), e70263. https://doi.org/10.1002/cae.70263.

Tannenbaum, S. I., & Cerasoli, C. P. (2013). Do team and individual debriefs enhance performance? A meta-analysis. *Human Factors*, *55*(1), 231–245. https://doi.org/10.1177/0018720812448394.

Tao, Y., Meyer, J., & Kizilcec, R. F. (2026). *Think before you accept: Can written justification reduce uncritical uptake of AI writing suggestions?* https://doi.org/10.48550/arXiv.2609.23936.

Taveter, H., & Lepp, M. (2026). *From idea to classroom in days: Using „vibe coding" to create a programming process visualizer from IDE activity logs*. arXiv. https://doi.org/10.48550/arXiv.2607.24757.

Tay, A. (2024a, Oktober 20). *Classifying the ways LLMs summarise - Individual vs Aggregate vs Visual summaries*. https://aarontay.substack.com/p/classifying-the-ways-llms-summarise.

Tay, A. (2024b, Dezember 1). *MCP servers and academic search - The future of search?* https://aarontay.substack.com/p/mcp-servers-and-academic-search-the.

Tay, A. (2025, Januar 19). *How agentic are academic deep research tools? Testing Perplexity, Elicit, Consensus and Academic GPTs*. https://aarontay.substack.com/p/how-agentic-are-academic-deep-research.

Teo, V., Jain, R., Gerstenberg, T., & Kleiman-Weiner, M. (2026). *AI assistants overassist*. https://doi.org/10.48550/arXiv.2607.21306.

Tobler, S., & Köhler, K. (2026). A lecture-specific AI-based tutor for higher education: Pedagogical design and empirical evaluation. *Education Sciences*, *16*(5), 812. https://doi.org/10.3390/educsci16050812.

Tobor, J. (2024). *Leitlinien zum Umgang mit generativer KI*. Hochschulforum Digitalisierung.

Tobor, J. (2025). *Recap: KI-leitlinien als beispiel für soziotechnische aushandlungsprozesse*.

Tobor, J., Then Bergh, C., & Lüthi, R. (2026). *Use Cases in Bewegung: Wie KI Studium und Lehre weiter verändert* (Blickpunkt). Hochschulforum Digitalisierung.

Turano, C., Pihl, V., Agnew, C., Ziegler, L., & Loeb, S. (2026, August). *AI tutoring is not a monolith: What we actually know*. https://nssa.stanford.edu/briefs/ai-tutoring-not-monolith.

Tutton, M., & Cohen, D. (2025). Reconceptualizing the Role of the University Language Teacher in Light of Generative AI. *Education Sciences*, *15*(1), 56. https://doi.org/10.3390/educsci15010056.

Universität Bayreuth, Zentrum für Hochschullehre (2026). *KI-Tutorien Bayern*. Projektseite. https://www.zhl.uni-bayreuth.de/de/projekte/kitutorium/index.html.

Vallverdú, J., Rzepka, R., & Sans Pinillos, A. (2025). Editorial: Prompts: the double-edged sword using AI. *Frontiers in Artificial Intelligence*, *8*. https://doi.org/10.3389/frai.2025.1756343.

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. *Advances in neural information processing systems*, *30*.

Vega, J., Rodriguez, M., Check, E., Moran, H., & Loo, L. (2025). Duolingo evolution: From automation to artificial intelligence. https://doi.org/10.1007/978-3-031-88854-0_5.

von Garrel, J., Mayer, J., & Weber, L. S. (2026). Wie Hochschullehrende künstliche Intelligenz im Studium nutzen – Ergebnisse einer bundesweiten Befragung. *Die Neue Hochschule*, (1), 16–19. https://doi.org/10.5281/zenodo.18017027.

Walsh, J. D. (2025). Everyone is cheating their way through college: ChatGPT has unraveled the entire academic project. *New York Magazine*.

Wang, Shuai, Scells, H., Koopman, B., & Zuccon, G. (2023). Can ChatGPT write a good Boolean query for systematic review literature search? https://doi.org/10.1145/3539618.3591703.

Wang, Shuai, Scells, H., Koopman, B., & Zuccon, G. (2025). Reassessing large language model Boolean query generation for systematic reviews. https://doi.org/10.1145/3726302.3730329.

Wang, Shen, Xu, T., Li, H., Zhang, C., Liang, J., Tang, J., Yu, P. S., & Wen, Q. (2024). Large language models for education: A survey and outlook. *arXiv preprint arXiv:2403.18105*.

Wang, W.-S., Lin, C.-J., Lee, H.-Y., Huang, Y.-M., & Wu, T.-T. (2025). Enhancing self-regulated learning and higher-order thinking skills in virtual reality: The impact of ChatGPT-integrated feedback aids. *Education and Information Technologies*. https://doi.org/10.1007/s10639-025-13557-x.

Wannemacher, K., Bosse, E., Lübcke, M., & Kaemena, A. (2025). *Wie KI Studium und Lehre verändert. Anwendungsfelder, Use-Cases und Gelingensbedingungen* (Arbeitspapier Nr. 87). Hochschulforum Digitalisierung.

Ward, M., O'Riordan, F., Logan-Fleming, D., Cooke, D., Concannon-Gibney, T., Efthymiou, M., & Watkins, N. (2024). Interactive oral assessment case studies: An innovative, academically rigorous, authentic assessment approach. *Innovations in Education and Teaching International*, *61*(5), 930–947. https://doi.org/10.1080/14703297.2023.2251967.

Wecker, C. (2012). Slide presentations as speech suppressors: When and

why learners miss oral information. *Computers & Education*, *59*(2), 260–273. https://doi.org/10.1016/j.compedu.2012.01.013.

White, J., Fu, Q., Hays, S., Sandborn, M., Olea, C., Gilbert, H., Elnashar, A., Spencer-Smith, J., & Schmidt, D. C. (2023). *A prompt pattern catalog to enhance prompt engineering with ChatGPT*. arXiv. https://doi.org/10.48550/arXiv.2302.11382.

Wiesinger, J., Marlow, P., & Vuskovic, V. (2024). *Agents* (Whitepaper). Google.

Wilhelm, L. T., Ding, X., Knutsen, K. M., Carik, B., & Rho, E. H. (2025). How managers perceive AI-assisted conversational training for workplace communication. https://doi.org/10.48550/arXiv.2505.14452.

Willingham, D. T. (2021). *Why don't students like school?: A cognitive scientist answers questions about how the mind works and what it means for the classroom*. Jossey-Bass.

Willison, S. (2025, Oktober 5). Embracing the parallel coding agent lifestyle. *Simon Willison's Weblog*. https://simonwillison.net/2025/Oct/5/parallel-coding-agents/.

Wilson, N., & Tingley, D. (n.d.n.d.). *System prompt library*. https://github.com/ncwilson78/System-Prompt-Library.

Wisniewski, B., Zierer, K., & Hattie, J. (2020). The power of feedback revisited: A meta-analysis of educational feedback research. *Frontiers in Psychology*, *10*, 3087. https://doi.org/10.3389/fpsyg.2019.03087.

Wissenschaftsrat (2026). *Intellektuelle Souveränität: Empfehlungen für die Hochschulbildung in Zeiten von generativer KI* (Nr. Drs. 3319-26). Wissenschaftsrat. https://doi.org/10.57674/1evx-t906.

Witsken, G., Crk, I., & Gultepe, E. (2025). LLMs in the Classroom: Outcomes and Perceptions of Questions Written with the Aid of AI. *Proceedings of the AAAI Conference on Artificial Intelligence*, *39*(26), 27698–27705. https://doi.org/10.1609/aaai.v39i26.34984.

Wolfram, S. (2023). *What is ChatGPT doing ... and why does it work?* Wolfram Media.

Wouters, P., van Nimwegen, C., van Oostendorp, H., & van der Spek, E. D. (2013). A meta-analysis of the cognitive and motivational effects of serious games. *Journal of Educational Psychology*, *105*(2), 249–265. https://doi.org/10.1037/a0031311.

Wouters, P., & van Oostendorp, H. (2013). A meta-analytic review of the role of instructional support in game-based learning. *Computers & Education*, *60*(1), 412–425. https://doi.org/10.1016/j.compedu.2012.07.018.

Wu, D. Y., & Katok, E. (2006). Learning, communication, and the bullwhip

effect. *Journal of Operations Management*, *24*(6), 839–850. https://doi.org/10.1016/j.jom.2005.08.006.

Wu, Mengqian (2026). *Constructing epistemic AI literacy: Detecting epistemic aims and processes in student-AI co-programming*. https://doi.org/10.48550/arXiv.2607.00211.

Wu, Mian, & Ouyang, F. (2026). How generative AI influences learning outcomes in programming education: A three-level Bayesian meta-analysis. *Educational Psychology Review*, *38*(117). https://doi.org/10.1007/s10648-026-10211-x.

Wu, R., & Yu, Z. (2024). Do AI chatbots improve students learning outcomes? Evidence from a meta-analysis. *British Journal of Educational Technology*, *55*(1), 10–33. https://doi.org/10.1111/bjet.13334.

Wu, Y., Jia, F., Zhang, S., Li, H., Zhu, E., Wang, Y., Lee, Y. T., Peng, R., Wu, Q., & Wang, C. (2023). *MathChat: Converse to Tackle Challenging Math Problems with LLM Agents*. arXiv. https://doi.org/10.48550/ARXIV.2306.01337.

Xu, K., Shen, Y., Yan, L., & Ren, Y. (2026). Cognitive agency surrender: Defending epistemic sovereignty via scaffolded AI friction. https://doi.org/10.48550/arXiv.2603.21735.

Yang, K. B., Liu, M., Xu, L., Rummel, N., & Aleven, V. (2026). Balancing teacher and student agency: Co-orchestration tool design supporting real-time dynamic pairing. https://doi.org/10.48550/arXiv.2605.18761.

Yang, L., Liu, H., Li, S., Jia, R., Xiao, Y., Chen, G., & Lu, L. (2026). *Evaluating scaffolding-oriented multi-agent large language model system for clinical interview training*. https://doi.org/10.48550/arXiv.2609.10939.

Yang, S., Van Alstyne, M., & Dellarocas, C. (2026). *When AI tutors speak: Evidence from a randomized field experiment*. https://doi.org/10.48550/arXiv.2609.23958.

Yang, Y., Zhang, Z., Tang, N., Wang, X., Ambrose, A., Myers, N., Clauss, P., & Li, T. J.-J. (2026). Lessons from real-world deployment of a cognition-preserving writing tool: Students actively engage with critical thinking and planning affordances. https://doi.org/10.48550/arXiv.2603.15777.

Yao, S., Zhao, J., Yu, D., Du, N., Shafran, I., Narasimhan, K., & Cao, Y. (2023). ReAct: Synergizing reasoning and acting in language models. https://doi.org/10.48550/arXiv.2210.03629.

You, J. (2025, Februar 7). How much energy does ChatGPT use? *Epoch AI*. https://epoch.ai/gradient-updates/how-much-energy-does-chatgpt-use.

Yu, M., Liu, Z., Long, T., Li, D., Deng, L., & Kong, X. (2025). Exploring cognitive presence patterns in GenAI-integrated six-hat thinking

technique scaffolded discussion: An epistemic network analysis. *International Journal of Educational Technology in Higher Education*, *22*(1), 48. https://doi.org/10.1186/s41239-025-00545-x.

Yuen, N. (2025). *Questioning the bot: Socratic chats with AI*. https://aipedagogy.org/assignment/questioning-the-bot-socratic-chats-with-ai-2/.

Yusuf, H., Money, A., & Daylamani-Zad, D. (2026). Exploring student anxiety and experience in performance-based assessments using AIvaluate: An LLM-augmented emotionally intelligent pedagogical AI conversational agent. *Educational Technology Research and Development*. https://doi.org/10.1007/s11423-026-10634-x.

Zhang, B., Lazuka, K., & Murag, M. (2025, Oktober 16). Equipping agents for the real world with Agent Skills. *Anthropic Engineering*. https://www.anthropic.com/engineering/equipping-agents-for-the-real-world-with-agent-skills.

Zhang, Y.-F., Li, H., Song, D., Sun, L., Xu, T., & Wen, Q. (2025). *From Correctness to Comprehension: AI Agents for Personalized Error Diagnosis in Education*. arXiv. https://doi.org/10.48550/ARXIV.2502.13789.

Zhu, W., Yang, Y., & Yang, Y. (2026). Preferred scaffolding does not lead to better learning performance: Empirical evidence from AI-supported mathematical modelling. *Computers and Education: Artificial Intelligence*, *11*, 100669. https://doi.org/10.1016/j.caeai.2026.100669.