Generative KI als Hilfe zum Lehren und Lernen

Roman Bartnik

November 2026

Roman Bartnik
Generative KI als Hilfe zum Lehren und Lernen

Technische Hochschule Köln
Fakultät für Informatik und Ingenieurwissenschaften, Campus Gummersbach

Bibliografische Information der Deutschen Nationalbibliothek: Die Deutsche Nationalbibliothek verzeichnet diese Publikation in der Deutschen Nationalbibliografie; detaillierte bibliografische Daten sind im Internet über https://dnb.de abrufbar.

Dieses Werk ist lizenziert unter einer Creative-Commons-Lizenz Namensnennung – Weitergabe unter gleichen Bedingungen 4.0 International (CC BY-SA 4.0): https://creativecommons.org/licenses/by-sa/4.0/deed.de. Ausgenommen sind Abbildungen und Zitate, die mit einem abweichenden Rechtehinweis gekennzeichnet sind.

Gefördert aus dem Open-Access-Publikationsfonds der TH Köln.
[Logo des Publikationsfonds]

Logos Verlag Berlin GmbH
[Anschrift des Verlags]
https://www.logos-verlag.de

Erste Auflage, [Monat] 2026
ISBN [978-3-xxxxx-xxx-x]
DOI [10.30819/xxxx]

Online-Version mit interaktiven Elementen und laufend aktualisierten Seiten:
https://th-koln-bartnik.github.io/genai4teaching/

Satz: Roman Bartnik mit Quarto und XeLaTeX
Umschlag: [Gestaltung, verwendete Abbildung und Bildnachweis]
Druck: [Druckerei]

Zitiervorschlag: Bartnik, R. (2026). *Generative KI als Hilfe zum Lehren und Lernen*. Logos Verlag Berlin. [DOI]

Inhalt

Abbildungsverzeichnis vii

Tabellenverzeichnis xi

Übersicht 1

Vorwort 3

1 Einleitung 7
- 1.1 KI als Hilfe für die Lehre . . . 7
- 1.2 Was möglich ist: Praktische Beispiele für Recherche, Übungsaufgaben, Erklärungen . . . 9
- 1.3 Nutzung von GenAI in der Forschung . . . 16
- 1.4 Weiterentwicklungen der Sprachmodelle: Reasoning und Agenten . . . 22
- 1.5 Wie nutzen Studierende und Lehrende GenAI? . . . 24
- 1.6 Risiken und Nebenwirkungen . . . 28
- 1.7 Kapitelübersicht . . . 30

2 Grundbegriffe 33
- 2.1 Definition einiger Grundbegriffe . . . 33
- 2.2 Wie denken Sprachmodelle und warum halluzinieren sie? . 44
- 2.3 Welches Modell wählen? . . . 47
- 2.4 Was können die Modelle – und was nicht? . . . 52
- 2.5 Wo und wie spreche ich mit der KI? . . . 56
- 2.6 Exkurs: Wie steht es mit dem Ressourcenverbrauch der Modelle? . . . 62

3 Didaktische Ziele und Mechanismen 65
- 3.1 Was für Ziele verfolgen wir mit dem Einsatz von GenAI in der Lehre? . . . 65
- 3.2 Wissenstypen . . . 68
- 3.3 Anwendungsbeispiele nach Wissenskategorien . . . 70
- 3.4 Effektive Lerntechniken und Unterstützung mit KI . . . 72

4 Vier Szenarien der Nutzung von GenAI: Hiwi, Copilot, Tutor, Simulator 79
4.1 KI als Hiwi 80
4.2 KI als Copilot 88
4.3 KI als Tutor 100
4.4 KI als Simulator 103

5 Empfehlungen zur Umsetzung 109
5.1 Typische Aufgaben und Fragestellungen mit der KI durchspielen, Prompts anpassen, experimentieren 109
5.2 Ausrichtung der Anpassungen nach Empfehlungen der Lernforschung 110
5.3 Einführung der Studierenden planen: Besser praktisch, häufig und niedrigschwellig 111
5.4 Wie prüfen wir jetzt? Jenseits der Homework Apocalypse . . 112
5.5 Richtlinien zur KI-Nutzung - welche Handreichungen geben Hochschulen und was wird empfohlen? 123
5.6 Wie können Studierende die Nutzung von LLM dokumentieren? Stichworte, nach Arbeitsphase, nach Werkzeug oder als Reflexionstagebuch 126
5.7 Beispiele für die Kurs-Integration von KI 134
5.8 Wie bleiben Sie informiert? 140

Anhang 141

A Überblick didaktischer Prompts 141
A.1 Kurze Einordnung der Prompt-Vielfalt – was sind gemeinsame Muster? 141
A.2 Didaktische Prompts: Gezielte Einschränkungen 143
A.3 Integration der KI in breitere Aufgabenstellungen und Artefakte 146

B Best-Practice-Sammlung didaktischer Prompts und GenAI Aufgabenstellungen 149
Vorbemerkung zur Struktur der Sammlung 149
B.1 Hiwi: Schnelle Hilfe zur Lehrgestaltung 149
B.2 Tutor: Beratender Beistand 177
B.3 Aufgabenstellungen Tutorat 183
B.4 Copilot: Gemeinsam zu neuen Horizonten 192
B.5 Aufgabenstellungen Copilot 207
B.6 Simulator: Didaktisches Erleben 222
B.7 Aufgabenstellungen Simulator 234

C Umsetzung: Rollenspiele und Simulationen mit generativer KI in der Lehre 249
Vorbemerkung 249
C.1 Was bringen Rollenspiele und Simulationen? Didaktische Mechanismen und Lernziele 249
C.2 Datengrundlage und Methodik 252
C.3 Welchen Mehrwert bringt generative KI? 252
C.4 Was geht nicht? Herausforderungen und Grenzen von GenAI 262
C.5 Wie umsetzen? Empfehlungen für KI-gestützte Rollenspiele 264
C.6 Update: Neuere Studien (Stand Juli 2026) 269
C.7 Liste der durchsuchten Fachzeitschriften 271
C.8 Im Jahr 2025 publizierte Fachartikel zu GenAI-Rollenspielen und Simulationen in der Lehre 271
Transparenzhinweis 277

D Umsetzung: Arbeitsumgebung, Agenten, Tutoren und lokale Modelle 279
Vorbemerkung 279
D.1 Warum Nutzungsmodus und Kontrollpunkte entscheiden . 280
D.2 Arbeitsumgebung einrichten: Wie bringe ich der KI dauerhaft bei, was sie über meinen Kurs wissen soll? 283
D.3 Eigene Quellen anbinden: Wie antwortet die KI aus meinen Texten statt aus dem Netz? 291
D.4 Agenten und akademische Suche: Wo müssen Menschen eingreifen, damit eine Agentenkette nicht entgleist? 293
D.5 Prozesse sichtbar machen: Wie wird aus einer Prozessbeschreibung ein prüfbares Modell? 296
D.6 Workflows automatisieren: Welche wiederkehrende Lehrarbeit lohnt die Automatisierung, und wie bleibt sie kontrollierbar? 300
D.7 KI-Tutoren bauen und prüfen: Wie verhindere ich, dass der Tutor zu viel hilft? 303
D.8 Lokale Modelle: Wann lohnt der Betrieb ohne Cloud, und was leistet ein kleines Modell? 313
D.9 Ausblick: Fortgeschrittene Anwendungen 316
Online-Material 317
Transparenzhinweis 317

Transparenzhinweis zum Gesamtwerk 319

Literaturverzeichnis 321

Abbildungsverzeichnis

1.1 Galerie mit vier Lernmedien, die mit generativer KI entstanden sind: Video-Teaser und Linien-Widget zum Fall „Backhaus Kaya“ aus dem Kurs *Sustainable Supply Chain Management* (WS 2026/27) sowie die Animationen „Engpass und Warteschlange“ und „Milk Run und CO□“. Dieses interaktive Element gibt es nur in der Online-Version: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/galerie-animationen.html aufrufen. 8
1.2 GenAI als Kraftverstärker. Erstellt mit Gemini 2, 2025 9
1.3 Recherche-Hiwi-Vorgehen. Screenshot Gemini 3 Pro, Januar 2026 11
1.4 Recherche-Hiwi-Denkprozess. Screenshot Gemini 3 Pro, Januar 2026 12
1.5 Recherche-Hiwi-Ergebnis. Screenshot Gemini 3 Pro, Januar 2026 13
1.6 Recherche-Hiwi-Konzepterklärung. Screenshot ChatGPT 5.2, Januar 2026 14
1.7 Recherche-Hiwi: Vorschläge für Multiple-Choice-Testfragen. Screenshot ChatGPT 5.2, Januar 2026 15
1.8 Recherche-Hiwi-Ergebnis: Folien zu integrierten Aufgaben. Screenshot NotebookLM, Dezember 2025 16
1.9 Recherche-Hiwi-Ergebnis: Folien zu Lerntechniken. Screenshot Claude, Dezember 2025 17
1.10 Visualisierung und Erläuterung in einfacher Sprache von 6000+ Konferenzbeiträgen (Alammar, o. J.). 19
1.11 Google’s Co-Scientist Ansatz an einem Beispiel aus der Pharmaforschung (Gottweis et al., 2025). 20
1.12 Neue technologische Chancen und Herausforderungen mit GenAI. Erstellt mit Gemini 2, 2025 21
1.13 Wofür Studierende LLMs nutzen (Handa et al., 2025). 25

1.14 Schwerpunkte der Nutzung von LLMs (Claude) durch Studierende nach der Bloom'schen Taxonomie (Handa et al., 2025). 26
1.15 Gründe für die Verbreitung von GenAI nach dem Technologie-Akzeptanz-Modell. Erstellt mit ChatGPT 5 im Mermaid Live Editor (https://mermaid.live/edit), Herbst 2025 27

2.1 Daumenregel: Für wichtige Fragen immer eine stärkere Kombination aus Modell und Setup wählen 34
2.2 Lernspiel „Welche Grundbegriffe kennen Sie schon?" (Zuordnung von Begriffen und Definitionen). Dieses interaktive Element gibt es nur in der Online-Version: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/llm-game-standalone.html aufrufen. . 35
2.3 Interaktiver Tokenizer: eigener Text wird in Tokens und Zahlen zerlegt. Dieses interaktive Element gibt es nur in der Online-Version: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/tokenizer-explorer.html aufrufen. 37
2.4 Lernspiel „LLM, RAG oder Agent?" (Probleme und Anwendungsfelder der drei Setups). Dieses interaktive Element gibt es nur in der Online-Version: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/llm-rag-agent-game.html aufrufen. 41
2.5 Lernspiel „Welches LLM-Setup passt zur Antwort?" (Zuordnung von Antwortmustern zu LLM, RAG und Agent). Dieses interaktive Element gibt es nur in der Online-Version: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/llm-agent-patterns-matching.html aufrufen. 42
2.6 Visualisierte Gedanken eines Sprachmodells [@lindsey2025] 45
2.7 Lebende Modellübersicht, semesterweise aktualisiert: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/modelluebersicht.html aufrufen. 51
2.8 Je nach Ziel ein anderer Platz in der Bestenliste 51
2.9 Empfehlung: Das KI-Modell wie eine junge Hilfskraft behandeln - nach und nach anlernen, klar anweisen 58
2.10 Exkurs „Ressourcenverbrauch der Modelle", Online-Fassung: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/energie.html aufrufen. 63

3.1 Illustration Zeitlich verteiltes Lernen – spacing 73
3.2 Illustration Inhaltlich gemischtes Lernen – interleaving . . . 74
3.3 Illustration Testgestütztes Lernen – test-enhanced learning . 74

4.1 Beispiel: Tutor-Bot BWL Grundlagen. Screenshot der Testversion, Januar 2026 79
4.2 Was für Aufgaben erledigen Lehrende? 25 Einzelaufgaben am Beispiel „Business Teachers, Postsecondary“ nach Umfragen des US-Arbeitsministeriums auf O*NET. Quelle: O*NET, 2025 . 81
4.3 Einmal fragen oder mehrfach? Nur Ergebnisse oder Analyse? Zwei Unterscheidungen und vier Quadranten von Such-Helfern mit KI; Produktbeispiele Stand 2026. Quelle: Tay (2025) 86
4.4 Visualisierung von Ablaufdiagrammen in Mermaid. Screenshot ChatGPT, 2025 (https://mermaid.live/) 98
4.5 Visualisierung im Dialog mit Google Colab und KI 99
4.6 Nutzung der Voice Modes von ChatGPT für medizinische Simulationen. Quelle: Barra et al. (2024) 105

5.1 Etwa gleichverteilt: Vier Arten der Interaktion von Studierenden mit Sprachmodellen. Quelle: Handa et al. (2025) 113
5.2 KI-resistente Aufgabenstellungen – 4 Säulen nach Gmeiner (2025) 114
5.3 Vergleich mündlicher Prüfungsformen (Ward et al. (2024)) . 115
5.4 Mündlich prüfen geht auch in großen Kohorten – Beispiele von verschiedenen Universitäten 117
5.5 Drei Szenarien für eine mündliche Prüfung in Pädagogik . . 117
5.6 Abhilfe durch Interaktion oder engere Prozessbetreuung: Aufgabentypen nach der Schwierigkeit, durch KI repliziert zu werden (Hanover Research (2024)) 119

Tabellenverzeichnis

3.1 Methoden nach Wissenstyp: Fakten, Prozess und Transfer. Quelle: Basierend auf Hattie (2023), S. 358, 340ff. 69

4.1 Für welche Aufgaben in der Lehre erwarten wir Verdrängung und Erhöhung der Produktivität und welche Aufgaben kommen hinzu? Legende: x = klarer Effekt, ? = gemischter Effekt. Quelle: Theorierahmen nach Acemoglu & Restrepo (2019) 83
4.2 Vier Typen von KI-Suchhelfern nach zwei Unterscheidungen. Quelle: Tay (2025) 85
4.3 Integration von KI in den Schreibprozess. Quelle: Studienberatung der Universität Frankfurt (Lehre virtuell - Universität Frankfurt, 2023), Stand 10.3.2024 90
4.4 Erläuterungen zum Grad der LLM-Nutzung. Quelle: Baresel et al. (2024), basierend auf Rowland (2023) 92
4.5 Neue Ansätze für Hausarbeiten mit KI. Quelle: E. R. Mollick & Mollick (2023a) sowie die verlinkten Blogeinträge 94

5.1 Beispiel arbeitsphasenorientierte Dokumentation der LLM Nutzung. Quelle: (Baresel et al. (2024), S. 11) 128
5.2 Beispiel werkzeugorientierte Dokumentation der LLM Nutzung. Quelle: (Baresel et al. (2024), S. 8) 130
5.3 Beispiel Reflexionstagebuch zur LLM Nutzung. Quelle: (Baresel et al. (2024), S. 16) 134

C.1 Anwendungsbeispiele für KI-Rollenspiele und Simulationen 261
C.2 Im Jahr 2025 publizierte Fachartikel zu GenAI-Rollenspielen und Simulationen in der Lehre 277

D.1 Nutzungsformen generativer KI nach Dauer der Delegation und Ort der menschlichen Prüfung 282
D.2 Fünf Bausteine einer dauerhaften Arbeitsumgebung und was das Modell davon wann liest 285
D.10 Drei Wege, das Tutor-Bündel zu laden 309

Übersicht

Dieses Buch untersucht, wie generative künstliche Intelligenz (GenAI) Lehre, Lernen und Forschung verändern kann. Es richtet sich an Lehrende, Forschende und Studierende, die verstehen möchten, **wie KI als Werkzeug der Hochschuldidaktik** eingesetzt werden kann.

Das Buch besteht aus fünf Kapiteln und vier Anhängen:

1. Einleitung: KI als Hilfe zum Lehren und Lernen
2. Grundbegriffe und technische Grundlagen
3. Didaktische Ziele und Mechanismen
4. Vier Szenarien der Nutzung: KI als Hiwi, Copilot, Tutor und Simulator
5. Empfehlungen zur Umsetzung

- Anhang A: Überblick didaktischer Prompts
- Anhang B: Best-Practice-Sammlung didaktischer Prompts und Aufgabenstellungen
- Anhang C: Umsetzung: Rollenspiele und Simulationen mit generativer KI
- Anhang D: Umsetzung: Arbeitsumgebung, Agenten, Tutoren und lokale Modelle

Vorwort

Dieses Buch ist aus einem Skript gewachsen. Als die ersten Kolleginnen und Kollegen fragten, wie man die neuen Sprachmodelle eigentlich sinnvoll in der Lehre einsetzt, habe ich meine Notizen aus dem eigenen Unterricht in Supply Management und Projektmanagement am Campus Gummersbach der TH Köln zusammengeschrieben. Daraus wurde ein Workshop, aus dem Workshop eine Reihe von Kursen im Netzwerk hdw nrw an Hochschulen in ganz Nordrhein-Westfalen, und aus den Fragen der Teilnehmenden immer neue Abschnitte. Parallel entstand an der TH Köln der Expertisezirkel GenKI, in dem wir seit [Jahr] regelmäßig darüber streiten, was in Lehre und Prüfung funktioniert und was nicht. Das Skript wanderte Anfang 2026 ins Netz, bekam Lernspiele, Animationen und einen Tutor-Bot, und liegt jetzt als Buch vor Ihnen.

Geschrieben ist es für Lehrende an Hochschulen. Sie brauchen keinen IT-Hintergrund. Ich habe selbst keinen; ich unterrichte Wirtschaftsingenieure. Was ich über Token, Kontextfenster oder Agenten weiß, habe ich mir angeeignet, weil ich es für die Lehre brauchte, und genau auf diesem Niveau erkläre ich es hier: so viel Technik, wie nötig ist, um gute didaktische Entscheidungen zu treffen, und keinen Absatz mehr. Wer tiefer einsteigen will, findet an den passenden Stellen Hinweise auf die Fachliteratur.

Das Buch hat zwei Teile, die man unterschiedlich liest. Die Kapitel 1 bis 5 sind ein Argumentationsgang und werden am besten der Reihe nach gelesen. Kapitel 1 zeigt, was die Modelle heute leisten und wo die Risiken liegen. Kapitel 2 klärt die Grundbegriffe. Kapitel 3 fragt, was wir mit dem Einsatz eigentlich bezwecken, und holt sich die Antwort bei der Lernforschung. Kapitel 4 sortiert die Praxis in vier Rollen der KI: Hiwi, Copilot, Tutor und Simulator. Kapitel 5 zieht daraus Empfehlungen für Kursdesign, Prüfungen und Richtlinien. Die Anhänge A bis D sind dagegen ein Werkzeugkasten, in den man greift, wenn man etwas Bestimmtes braucht: eine Übersicht didaktischer Prompt-Muster, eine Sammlung erprobter Prompts und Aufgabenstellungen, eine Vertiefung zu Rollenspielen und Simulationen sowie [Kurzbeschreibung Anhang D].

Zum gedruckten Buch gehört eine Online-Version unter https://th-koln-bartnik.github.io/genai4teaching/. Dort stehen die interaktiven Elemente, die sich nicht drucken lassen: die Lernspiele zu den Grundbegriffen, der Tokenizer zum Ausprobieren, die Prozessanimationen am Ende des ersten Kapitels. Im Druck finden Sie an diesen Stellen einen QR-Code, der direkt zum jeweiligen Element führt. Zwei Seiten der Online-Version sind außerdem „lebende Seiten", die ich laufend aktualisiere: die Modellübersicht mit den aktuellen Modellen und Zugängen für Hochschulen und der Forschungsstand mit neueren Studien zum Thema. Beides veraltet schneller, als ein Buch gedruckt werden kann.

Damit sind wir bei einer Konvention, die das ganze Buch durchzieht. Ein Buch über eine Technik, die sich alle paar Monate ändert, muss ehrlich damit umgehen, dass es altert. Ich habe deshalb getrennt, was sich hält, und was sich ändert. Der Fließtext ist so geschrieben, dass er auch in einigen Jahren noch stimmen sollte: Die Lernforschung zu verteiltem Üben und Abruftests ist Jahrzehnte alt, die vier Rollen der KI in der Lehre sind von Modellnamen unabhängig, und die Frage, wie man unter neuen Bedingungen prüft, wird uns noch lange begleiten. Alles, was ein Verfallsdatum hat, steht in abgesetzten Kästen mit der Überschrift „Stand bei Drucklegung" und einem Datum: Modellnamen, Preise, Nutzungszahlen, Fähigkeiten, die gerade neu sind. Wenn Sie einen solchen Kasten lesen und das Datum ist zwei Jahre her, nehmen Sie ihn als historische Momentaufnahme und schauen Sie in die Online-Version.

Die Kapitel 1 bis 5 beginnen mit Lernzielen und enden mit Kernaussagen und Fragen zum Weiterdenken. Das ist keine Verzierung. Kapitel 3 plädiert dafür, Lernende regelmäßig zum Abruf zu zwingen, statt sie nur lesen zu lassen; es wäre merkwürdig, wenn das Buch selbst darauf verzichtete.

Viele Menschen haben zu diesem Buch beigetragen. [Dirk Burdinski] hat [Beitrag]. Die Studierenden meiner Module an der TH Köln haben mit mir Tutor-Bots, Lernspiele und Karriereberater gebaut, getestet und gnadenlos kritisiert; [Verweis auf die Kapitel oder Anhänge, in denen diese Projekte beschrieben sind]. [Namen der Studierenden oder Projektgruppen]. Die Teilnehmenden meiner hdw-Kurse und die Mitglieder des Expertisezirkels GenKI haben mit ihren Fragen und Einwänden mehr Abschnitte dieses Buchs ausgelöst, als ihnen bewusst ist. [Weitere Namen: Kolleginnen und Kollegen, Testleserinnen und Testleser]. Dem Logos Verlag Berlin, insbesondere [Name], danke ich für die unkomplizierte Zusammenarbeit

und dafür, dass ein Buch mit QR-Codes, Kästen und einer lebenden Online-Version überhaupt möglich war. Fehler, die übrig geblieben sind, gehen auf mich.

Das Buch erscheint Open Access unter der Lizenz CC BY-SA 4.0. Sie dürfen es kopieren, weitergeben, für Ihre eigenen Workshops umbauen und übersetzen, solange Sie die Quelle nennen und Ihre Fassung unter derselben Lizenz weitergeben. Möglich wurde das durch eine Förderung aus dem Open-Access-Publikationsfonds der TH Köln. Ich halte das für die einzig sinnvolle Form für ein Buch, das Lehrenden helfen soll, ihre Lehre zu verändern: Nehmen Sie, was Sie brauchen, und machen Sie es besser.

[Ort], im [Monat] 2026
Roman Bartnik

1 Einleitung

Lernziele

Nach diesem Kapitel können Sie …

- die zwei Lehrprobleme benennen, bei denen generative KI helfen kann: begrenzte Zeit für individuelle Förderung und der hohe Aufwand wirksamer Lehrmethoden;
- die drei Ebenen Modell, App und Harness unterscheiden und begründen, warum kostenlose oder automatisch gewählte Modellvarianten für Lehraufgaben oft nicht ausreichen;
- an Beispielen beschreiben, welche Aufgaben in Recherche, Aufgabenerstellung und Forschung Sprachmodelle inzwischen übernehmen und wo Fachwissen zur Prüfung der Ergebnisse unverzichtbar bleibt;
- die Befunde zur Nutzung durch Studierende einordnen und erklären, warum Hochschulen Prüfungsleistungen anpassen und KI-Kompetenz vermitteln müssen;
- das Risiko der kognitiven Entlastung („verkümmernde Muskeln“) mit dem Konzept der erwünschten Schwierigkeiten verbinden.

1.1 KI als Hilfe für die Lehre

Wie kann uns generative künstliche Intelligenz (KI) **in der Lehre helfen**? Hoffnung besteht hier für zwei typische Probleme: Erstens haben Studierende **individuelle Bedürfnisse**, aber wir haben nur **begrenzte Zeit**, auf diese einzugehen. Wie können wir Einzelne möglichst intensiv fördern, ohne vor Arbeit unterzugehen? Zweitens ist der **Aufwand gerade für effektive Lehrmethoden** oft sehr hoch, so etwa für häufige niedrigschwellige Tests oder individuelles Feedback zu Studienarbeiten

(Brown et al., 2014; s. etwa Hattie, 2023, Kap.13). Wer lehrt, fühlt sich aus Zeit- und Stoffdruck oft gezwungen, Abstriche von idealen Lehrsetups zu machen (Henderson & Dancy, 2007; Schmidt & Tippelt, 2005, S.104–105). Gerade Lehrmethoden, die didaktisch sinnvoll, aber mit höherem Aufwand verbunden sind, drohen dabei auf der Strecke zu bleiben (s. etwa Dunlosky et al., 2013; Roediger & Pyc, 2012).

Was mit generativer KI inzwischen möglich ist, zeigt die folgende Galerie an vier Beispielen aus meiner eigenen Lehre: ein Video-Teaser und ein Rechen-Widget zu einem Fall, dazu zwei Prozessanimationen (Demir et al., 2014; Goldratt & Cox, 2014; Little, 1961). Blättern Sie mit den Pfeilen; die Erläuterung steht unter jedem Beitrag.

Abbildung 1.1. Galerie mit vier Lernmedien, die mit generativer KI entstanden sind: Video-Teaser und Linien-Widget zum Fall „Backhaus Kaya“ aus dem Kurs *Sustainable Supply Chain Management* (WS 2026/27) sowie die Animationen „Engpass und Warteschlange“ und „Milk Run und CO□“. Dieses interaktive Element gibt es nur in der Online-Version: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/galerie-animationen.html aufrufen.

Für die Lehre erschließen sich durch die großen KI-Sprachmodelle (LLM = Large Language Models) neue Möglichkeiten. Sie sind, wie es eine Analyse des MIT Professors Andrew McAfee auf den Punkt bringt, „**generally faster**“ (McAfee, 2024). Lehrende können mit KI-Unterstützung etwa deutlich schneller eine Recherche durchführen, ein Set von Übungsaufgaben erstellen, mehrere Anwendungsbeispiele pro Konzept hinzufügen, Quizfragen zur schnellen Lernüberprüfung generieren oder mit den Studierenden Rollenspiele durchführen (Meincke et al., 2024; E. R. Mollick & Mollick, 2023b). Der Berg ist noch da, aber mit dem E-Bike kommt man weiter.

Abbildung 1.2. GenAI als Kraftverstärker. Erstellt mit Gemini 2, 2025

1.2 Was möglich ist: Praktische Beispiele für Recherche, Übungsaufgaben, Erklärungen

"KI nutzen" heißt seit der agentischen Wende (s. Kapitel 1.4) nicht mehr nur "chatten mit dem Bot", sondern **Delegation an Agenten** (E. Mollick, 2026): Man delegiert Aufgaben, die KI nutzt Werkzeuge und arbeitet mehrstufig, prüft also selbstständig Zwischenergebnisse. Praktisch unterschieden wir dabei drei Ebenen: **Modelle** (das Sprachmodell selbst, etwa das Flaggschiff eines großen Labors), **Apps** (die Oberfläche, z.B. die Texteingabe im Browser des Chat-Interfaces) und **Harnesses** („Arbeitsgeschirr" oder Werkzeugkasten, etwa Web-Recherche, Zugriff auf einen Ordner mit Daten oder die Fähigkeit zum Rechnen mit Programmiersprachen wie Python). Wichtig für die Lehre: **Wenig Kosten heißt oft auch wenig(er) Nutzen** ("No such thing as a free lunch", hört man die Ökonomen murmeln...(Friedman & Friedman, 1975)). Viele Plattformen locken Nutzer in kostenlose Tarife oder per „Auto"-Auswahl in **schwächere Modellvarianten**, denen dann das iterative Vorgehen fehlt (*reasoning*), oft ohne oder nur mit sehr begrenztem Harness-Werkzeugkasten. Das wirkt zunächst „gut genug", erhöht aber das Risiko von Fehlern, veralteten Informationen und oberflächlichem Denken. Für die Lehre heißt das: Wer GenAI als Lehrassistenz nutzen will, sollte **bewusst eine starke Modellvariante** und ein passendes Harness wählen –

und Ergebnisse grundsätzlich didaktisch gegenprüfen.

Schauen wir uns einige praktische Beispiele an, was mit schlauen Modellen und gut gefülltem Werkzeugkasten möglich ist (die Beispiele stammen aus dem Winter 2025/26). Wir suchen neue Fallstudien zu Lieferketten-Problemen. Als Recherche-Hiwi sucht das Sprachmodell auf akademischen Blogs und Fachzeitschriften nach Beispielen aus den letzten Jahren.

Solche Suchen führen Sprachmodelle mit Research-Harness in mehreren Schritten durch. Hier sehen wir den "Denkprozess".

Hier das Ergebnis: Ein erster ausformulierter Bericht von 13 Seiten nach ca. 5 Minuten Recherche. Die Abbildung zeigt den Auszug mit der tabellarischen Zusammenfassung der Forschungsartikel.

Wie kann man Konzepte einfach und mit Beispielen erklären? Wir bitten ChatGPT um Vorschläge zu zwei Konzepten aus der Wissenschaftstheorie: Der Duhem-Quine-These, die beschreibt, warum Wissenschaft nur graduell, mosaik-bauend zu Erkenntnissen kommen kann, und Mayos Konzept der "Strengen Tests" (severe testing), nach denen man wissenschaftliche Aussagen graduell auf ihre Belastbarkeit bewerten kann.

Wie könnte man das in einem Test abfragen? Auch hierzu bitten wir das Chat-Interface um Vorschläge.

Starke Sprachmodelle generieren **professionelle Folien-Präsentationen in Sekunden.** Seit Ende 2025 können Bildmodelle wie das von Google auch Text in Bildern korrekt erstellen (Willison, 2025b) und damit auch komplexe Infografiken (und Folien). Das Sprachmodell *Claude* liefert eine Beschreibung ('Skill') von 3500 Wörtern mit, die dem Sprachmodell genau erklärt, wie es Schritt für Schritt eine PowerPoint-Präsentation erstellt und testet (Anthropic, 2025b). Weiter unten zeigen wir, wie so ein Skill etwa bei der Erstellung komplexer Dokumente (Hausarbeiten!) hilft.

Grafisch ansprechende Präsentationen kosten Zeit – und Brillanz als Grafiker gehört vielleicht auch nicht zu den Kernkompetenzen von Lehrenden. Wir bitten daher Gemini (NotebookLM) und Claude, uns basierend auf Überblicksartikeln zwei Präsentationen zu erstellen: Eine zur Frage, welche Lerntechniken für Studierende besonders gut funktionieren (s. Kapitel 2) und die zweite zur Frage, welche Best-Practices es gibt, Aufgabenstellungen mit der intensiven Nutzung von GenAI zu verbinden (s. Anhang B).

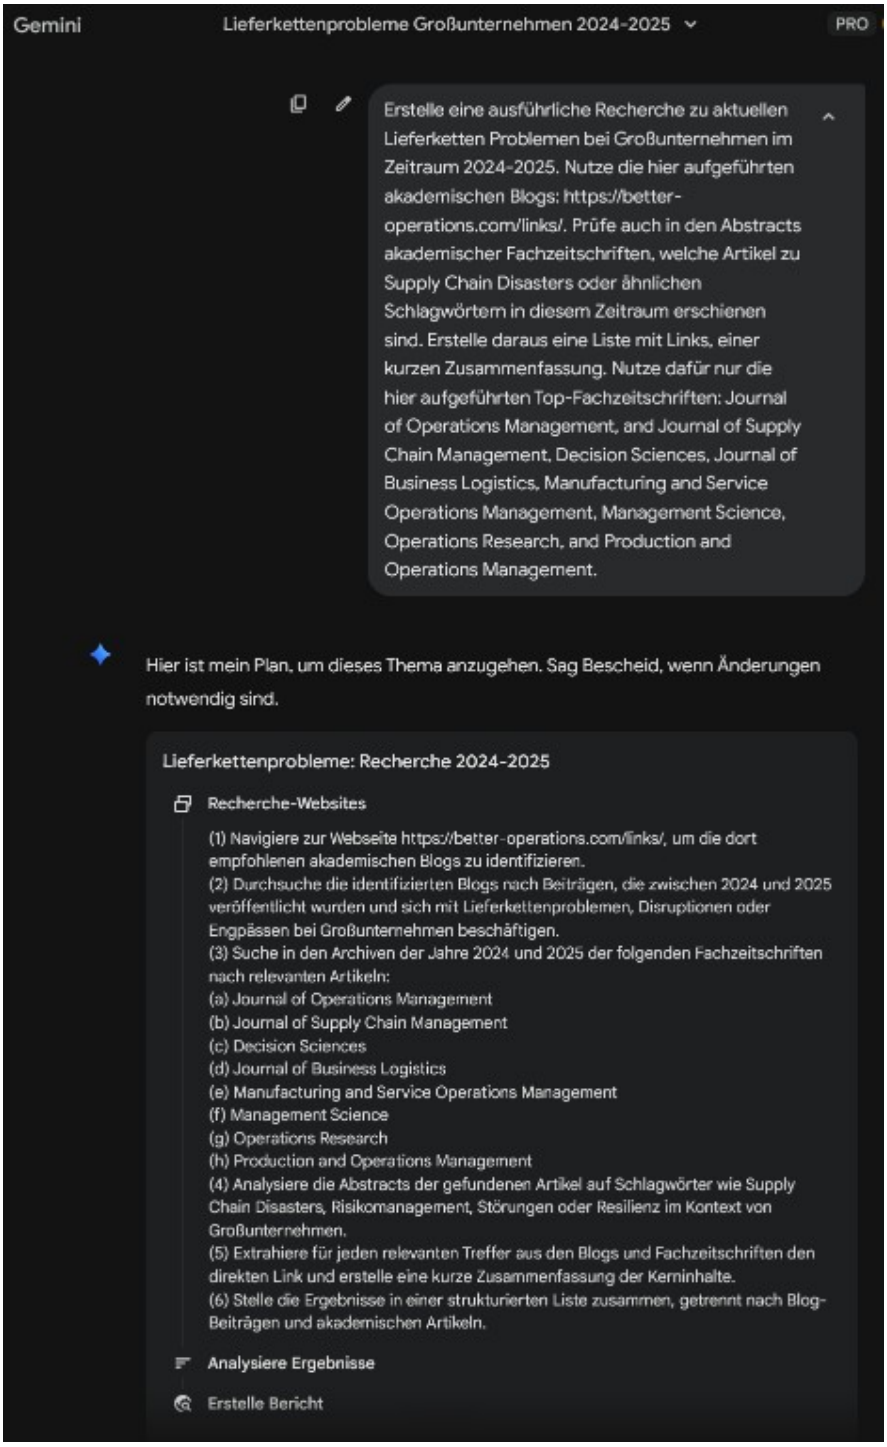

Abbildung 1.3. Recherche-Hiwi-Vorgehen. Screenshot Gemini 3 Pro, Januar 2026

Abbildung 1.4. Recherche-Hiwi-Denkprozess. Screenshot Gemini 3 Pro, Januar 2026

7. Annotierte Bibliographie der Schlüsselwerke (2024–2025)

Um dem Anspruch einer umfassenden Recherche gerecht zu werden, folgt hier eine strukturierte Übersicht der identifizierten Kernliteratur aus den geforderten Top-Journals.

Tabelle 2: Auswahl der relevantesten Forschungsarbeiten

Journal	Autoren & Titel	Jahr	Zusammenfassung & Relevanz für Großunternehmen	Link/ ID
M&SOM	Niu et al.: *"Restructuring Global Supply Chains"*	2025	Analyse von US-Importdaten. Bestätigt Diversifizierung weg von China hin zu Vietnam/Mexiko. Zeigt Trend zu größeren Lagerpuffern.	[1]
JBL	Zeisler et al.: *"Is Your Supply Chain Breaking Down? Call AAA"*	2025	Empirische Validierung des AAA-Modells. Identifiziert spezifische Verhaltensweisen (Behaviors) und Strukturen für jede Phase einer Krise.	[2]
Mgmt Sci	Wu: "Text-Based Measure of Supply Chain Risk Exposure"	2024	Einführung eines NLP-basierten Risiko-Index. Ermöglicht Echtzeit-Monitoring von Risiken durch Analyse von Management-Kommunikation.	[3]
POM	Qiu et al.: *"Contagious Stock Price Crashes"*	2024	Beweist, dass operative Probleme von Kunden stärker auf Lieferanten-Aktien abfärben als finanzielle Probleme. Effizienz ist der beste Schutz.	[4]
JSCM	Wang & Jensen: *"Resolution Tactics of Supplier-Induced Disruptions"*	2025	Experimentelle Studie zur Vertrauensreparatur. Kausale Erklärungen sind wichtiger als finanzielle Entschädigung.	[5]
Dec Sci	Hofstra et al.: *"Ordering decisions under... inaccuracy"*	2024	Zeigt, dass interne Datenfehler (Inventory Inaccuracy) zu irrationalerem Bestellverhalten führen als externe Lieferausfälle.	[6]
M&SOM	Ramchandani et al.: *"Unmasking Human Trafficking Risk"*	2025	Anwendung von ML zur Identifikation von Menschenrechtsrisiken in Lieferketten.	[7]
OR	Hamdan et al.: *"Simplicity or flexibility? Dual sourcing"*	2025	Mathematischer Beweis, dass einfache "Base-Surge"-Strategien in Krisenzeiten komplexen Modellen überlegen sein können.	[8]
JBL	Heiner et al.: "How Robotics is Shaping Digital Logistics"	2025	Untersucht die Rolle der Robotik nicht nur als Effizienz-, sondern als Resilienztreiber bei Arbeitskräftemangel.	[9]
POM	Katok & Tarr: *"Renegotiations in the Presence of Supply Disruptions"*	2025	Untersucht das Verhandlungsverhalten in Krisen. Flexible Verträge fördern kooperative Lösungen besser als starre Pönalen.	[10]

8. Fazit: Implikationen für die Führungspraxis

Die Analyse der akademischen Literatur der Jahre 2024 und 2025 zeichnet das Bild einer Disziplin im radikalen Wandel. Für Entscheidungsträger in Großunternehmen lassen sich aus dieser Forschung vier strategische Imperative ableiten:

1. **Datenqualität als Resilienz-Hebel:** Wie die Arbeiten von Hofstra et al. (Decision Sciences) und Wu (Management Science) zeigen, liegen viele Risiken nicht beim Lieferanten, sondern in der eigenen Datenbasis. Investitionen in interne Bestandsgenauigkeit und fortschrittliche Risiko-Sensorik (Text-Mining) sind keine reinen IT-Projekte, sondern essentielle Risikomanagement-Maßnahmen.
2. **Psychologie des Einkaufs:** Verträge allein regeln keine Krisen. Das Verständnis der "weichen" Faktoren – Vertrauensreparatur, kognitive Verzerrungen bei Bestellungen, kulturelle Unterschiede (siehe China-Studie in JSCM [11]) – wird zum harten Wettbewerbsfaktor.
3. **Strukturelle Redundanz:** Die Ära der monolithischen Optimierung ist vorbei. Ob durch "Tailored Base-Surge" im Sourcing (Operations Research) oder durch geografische Diversifizierung (M&SOM): Erfolgreiche Unternehmen bauen bewusst Redundanzen auf und akzeptieren höhere Fixkosten als Prämie für Viabilität.
4. **Verantwortung und Transparenz:** Mit Regularien wie der CSDDD und der technologischen Möglichkeit, selbst versteckte Risiken wie Menschenhandel aufzudecken, endet die Ära der plausiblen Abstreitbarkeit. Transparenz bis in die tiefsten Tier-Ebenen ist die neue "License to Operate".

Zusammenfassend lässt sich konstatieren: Das Supply Chain Management wandelt sich von einer operativen Abwicklungsfunktion zu einer strategischen Kompetenz zur Bewältigung globaler Komplexität. Die Wissenschaft liefert hierfür nun die empirischen und theoretischen Werkzeuge.

Hinweis: Dieser Bericht basiert auf einer Analyse der akademischen Literatur und Blogs im Zeitraum 2024–2025, referenziert durch die im Text angegebenen Quellen-IDs.

Abbildung 1.5. Recherche-Hiwi-Ergebnis. Screenshot Gemini 3 Pro, Januar 2026

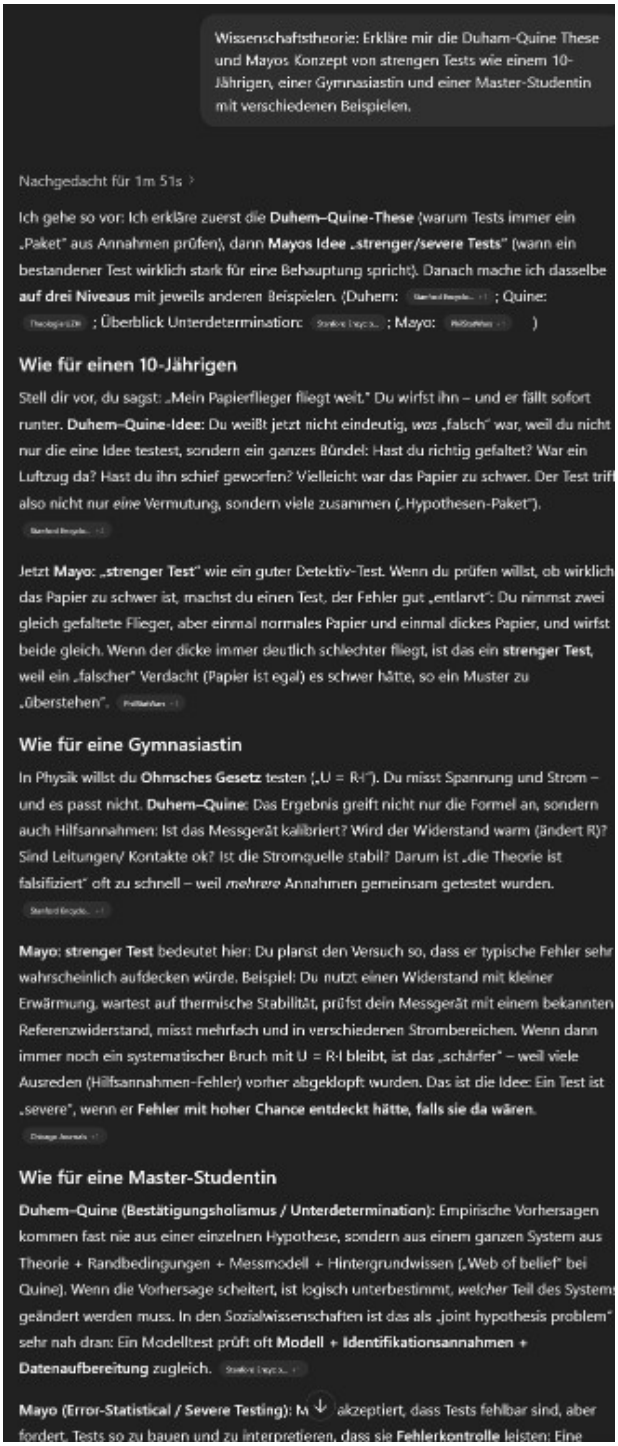

Abbildung 1.6. Recherche-Hiwi-Konzepterklärung. Screenshot ChatGPT 5.2, Januar 2026

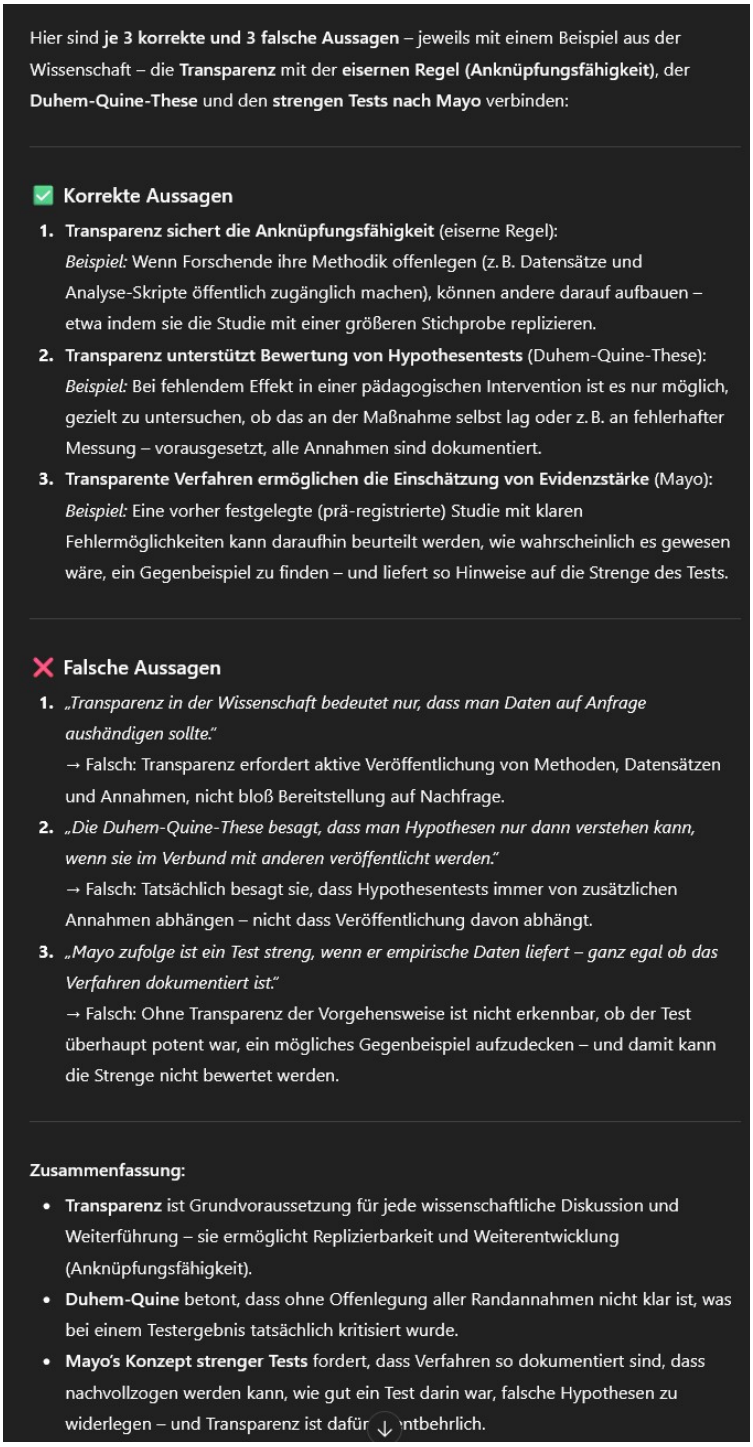

Hier sind **je 3 korrekte und 3 falsche Aussagen** – jeweils mit einem Beispiel aus der Wissenschaft – die **Transparenz** mit der **eisernen Regel (Anknüpfungsfähigkeit)**, der **Duhem-Quine-These** und den **strengen Tests nach Mayo** verbinden:

✅ **Korrekte Aussagen**

1. **Transparenz sichert die Anknüpfungsfähigkeit** (eiserne Regel):
   Beispiel: Wenn Forschende ihre Methodik offenlegen (z. B. Datensätze und Analyse-Skripte öffentlich zugänglich machen), können andere darauf aufbauen – etwa indem sie die Studie mit einer größeren Stichprobe replizieren.
2. **Transparenz unterstützt Bewertung von Hypothesentests** (Duhem-Quine-These):
   Beispiel: Bei fehlendem Effekt in einer pädagogischen Intervention ist es nur möglich, gezielt zu untersuchen, ob das an der Maßnahme selbst lag oder z. B. an fehlerhafter Messung – vorausgesetzt, alle Annahmen sind dokumentiert.
3. **Transparente Verfahren ermöglichen die Einschätzung von Evidenzstärke** (Mayo):
   Beispiel: Eine vorher festgelegte (prä-registrierte) Studie mit klaren Fehlermöglichkeiten kann daraufhin beurteilt werden, wie wahrscheinlich es gewesen wäre, ein Gegenbeispiel zu finden – und liefert so Hinweise auf die Strenge des Tests.

❌ **Falsche Aussagen**

1. *„Transparenz in der Wissenschaft bedeutet nur, dass man Daten auf Anfrage aushändigen sollte."*
   → Falsch: Transparenz erfordert aktive Veröffentlichung von Methoden, Datensätzen und Annahmen, nicht bloß Bereitstellung auf Nachfrage.
2. *„Die Duhem-Quine-These besagt, dass man Hypothesen nur dann verstehen kann, wenn sie im Verbund mit anderen veröffentlicht werden."*
   → Falsch: Tatsächlich besagt sie, dass Hypothesentests immer von zusätzlichen Annahmen abhängen – nicht dass Veröffentlichung davon abhängt.
3. *„Mayo zufolge ist ein Test streng, wenn er empirische Daten liefert – ganz egal ob das Verfahren dokumentiert ist."*
   → Falsch: Ohne Transparenz der Vorgehensweise ist nicht erkennbar, ob der Test überhaupt potent war, ein mögliches Gegenbeispiel aufzudecken – und damit kann die Strenge nicht bewertet werden.

Zusammenfassung:

- **Transparenz** ist Grundvoraussetzung für jede wissenschaftliche Diskussion und Weiterführung – sie ermöglicht Replizierbarkeit und Weiterentwicklung (Anknüpfungsfähigkeit).
- **Duhem-Quine** betont, dass ohne Offenlegung aller Randannahmen nicht klar ist, was bei einem Testergebnis tatsächlich kritisiert wurde.
- **Mayo's Konzept strenger Tests** fordert, dass Verfahren so dokumentiert sind, dass nachvollzogen werden kann, wie gut ein Test darin war, falsche Hypothesen zu widerlegen – und Transparenz ist dafür ntbehrlich.

Abbildung 1.7. Recherche-Hiwi: Vorschläge für Multiple-Choice-Testfragen. Screenshot ChatGPT 5.2, Januar 2026

Zu integrierten Aufgaben mit GenAI liefert uns das Sprachmodell nach wenigen Minuten 15 sehr schicke Folien (NotebookLM, basierend auf 13 Quellen-PDFs).

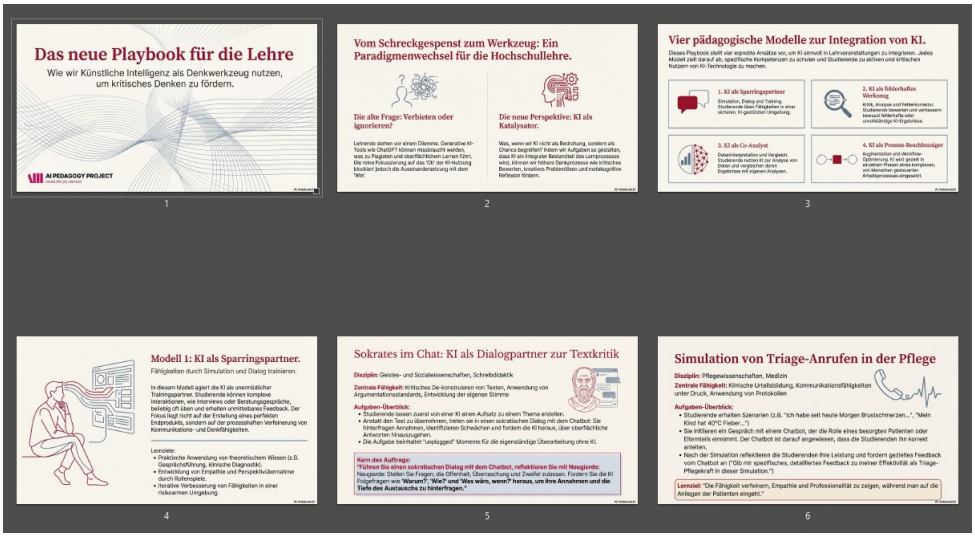

Abbildung 1.8. Recherche-Hiwi-Ergebnis: Folien zu integrierten Aufgaben. Screenshot NotebookLM, Dezember 2025

Zu Lerntechniken erhielten wir nach etwa 5 Minuten basierend auf einem Fachartikel 8 professionelle Folien (mit kleineren Formatierungsfehlern, etwa Zeilenumbrüchen).

1.3 Nutzung von GenAI in der Forschung

Immer mehr Aspekte von typischen Forschungstätigkeiten – ein zentraler Ausbildungsinhalt der Hochschulen – können **von der KI übernommen** werden und zwar auf hohem Niveau. Vorbei sind die Zeiten, da wir über banale KI-Texte nur lächelten. Ein Überblicksartikel des Forschers Anton Korinek im renommierten Journal of Economic Literature vom Dezember 2024 fasst die deutlich höhere Qualität des Outputs zusammen: „die derzeitige Generation von LLMs ist in hohem Maße in der Lage, die wichtigsten Erkenntnisse von Forschungsarbeiten zu verarbeiten" (Korinek, 2024, S.3, Übersetzung RB mit DeepL).

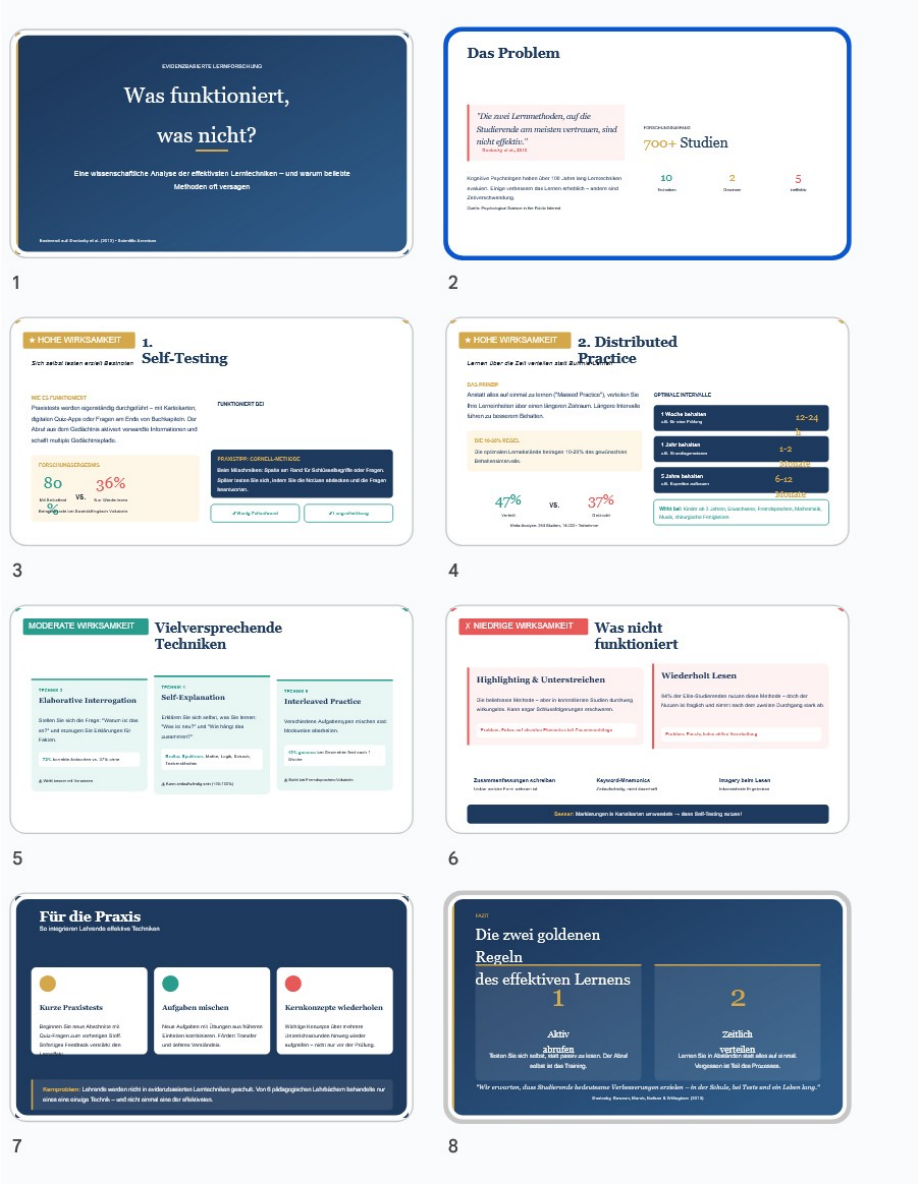

Abbildung 1.9. Recherche-Hiwi-Ergebnis: Folien zu Lerntechniken. Screenshot Claude, Dezember 2025

Professionelle Forscher sind hier teils schon weiter. Eine schöne visuelle Verdeutlichung davon, was möglich ist, findet sich hier: Eine Visualisierung von über 6000 Konferenzbeiträgen, die jeweils zusammengefasst werden und denen durch ein Sprachmodell eine Erklärung in einfacher Sprache beigefügt wurde ("explain-it-like-I'm-5"): **Hier kann man das interaktiv ausprobieren:** https://jalammar.github.io/assets/neurips_2025.html.

Wie kann GenAI uns bei der Forschung direkt unterstützen? Google demonstrierte 2025 ein mehrstufiges Modell für die Pharma-Forschung (*'AI co-scientist'*), das den Forschenden zeitintensive Zwischenschritte abnimmt (Gottweis et al., 2025) (s. Abbildung 1.11). OpenAI zeigte Ende 2023 schon in einem ausführlichen Bericht eine Vielzahl möglicher Hilfsanwendungen im Wissenschaftsbereich. Mit deutlichen Warnhinweisen (speziell wegen selbstbewusst vertretenen Halluzinationen) aber auch teils erstaunlich hoher Qualität (Bubeck et al., 2023). Auch im Peer-Review werden zunehmend Sprachmodelle eingesetzt – mit allen Vor- und Nachteilen, die das mit sich bringt (Naddaf, 2025). Wie wir in den späteren Kapiteln sehen, experimentieren Hochschulen weltweit intensiv mit den neuen Möglichkeiten für Lehre und Forschung.

Mit den Reasoning-Modellen hat sich **der potenzielle Mehrwert (und speziell Zeitgewinn)** ***bei fachgemäßer Nutzung*** noch einmal erweitert. Ein Bericht von OpenAI vom November 2025 stellt eine Reihe von Fallstudien dar, wie Forschende starke Sprachmodelle einsetzen (Bubeck et al., 2025). Die Quelle der Ergebnisse ist natürlich nicht neutral (OpenAI), die Ergebnisse sind aber m. E. mit Blick auf die eigene Nutzungserfahrung sehr plausibel: Als Mehrwert wird häufig eine **außerordentliche Zeitersparnis bei Routinetätigkeiten** genannt, speziell bei der Nutzung von Verfahren und Wissensquellen, die die Forscher zwar bewerten können, deren Aneignung aber ohne die Hilfe der Sprachmodelle deutlich länger dauern würde. Dies ist sehr wertvoll und wird die Verbreitung solcher Tools treiben. Wir sehen in den Einzelberichten aber auch **klare Warnsignale**: Wenn man die Zwischenergebnisse mangels Fachkenntnis nicht kritisch hinterfragen kann, ist die Wahrscheinlichkeit hoch, Fehler zu übernehmen. Auch starke Sprachmodelle vertreten sehr überzeugend falsche Ergebnisse und Ansätze. Nur durch Fachwissen haben Nutzer die erforderlichen Bewertungsmuster. **Erst durch eigenes Fachwissen *und* durch Erfahrung im kritischen Umgang mit dem Tool entsteht der Mehrwert**. Man muss sozusagen das Terrain kennen *und* lernen, wie man den Sportwagen Sprachmodell fahren muss. So können dann auch Unfälle besser vermieden werden.

Abbildung 1.10. Visualisierung und Erläuterung in einfacher Sprache von 6000+ Konferenzbeiträgen (Alammar, o. J.).

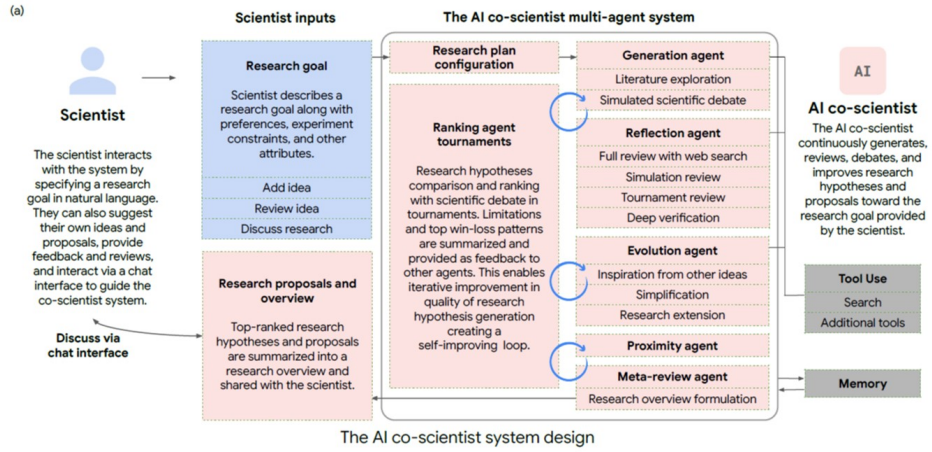

Abbildung 1.11. Google's Co-Scientist Ansatz an einem Beispiel aus der Pharmaforschung (Gottweis et al., 2025).

Die Galerie zu Beginn dieses Kapitels zeigt, was dabei herauskommen kann, wenn Lehrende solche Modelle nicht nur zum Schreiben, sondern zum Bauen von Lernwerkzeugen einsetzen.

Wie ein Laie im Cockpit eines Verkehrsflugzeugs fällt es Lehrenden teils schwer zu entscheiden, welche der neuen Möglichkeiten sinnvoll für die eigene Lehre sind. Zunächst gibt es immer wieder Hype-Zyklen: Virtuelle Realität, Blockchain, Roboter, Internet der Dinge... (Allen & Edelson, 2024), viel wurde schon ins Rampenlicht gestellt und dann wieder vergessen. Hersteller und Beratungen bewerben und 'hypen' regelmäßig neue Technologien für die Lehre, so dass wir schon aus Selbstschutz eine gewisse Grundskepsis mitbringen sollten, ob ein neuer technischer Zugang wirklich auch didaktischen Nutzen bringt (für eine wirkungsbasierte Übersicht von Technologien s. etwa Hattie, 2023, Kap.14). Lehrende sind außerdem paradoxen Spannungen zwischen den Identitäten als Experten und Innovatoren ausgesetzt (Fischer & Dobbins, 2024): Ausgestrahlte Kompetenz ist einerseits Teil ihres Wertversprechens, was zur Abwehr ungewohnter Technologien einlädt. Andererseits sollen Lehrende auch zu Neugier und Innovation anleiten und insofern den Umgang mit neuen, auch für die Lehrenden selbst ungewohnten Technologien erleichtern.

Abbildung 1.12. Neue technologische Chancen und Herausforderungen mit GenAI. Erstellt mit Gemini 2, 2025

1.4 Weiterentwicklungen der Sprachmodelle: Reasoning und Agenten

Seit 2025 „denken“ die großen Sprachmodelle besser „nach“ – sogenannte „Reasoning“-Modelle sind breit verfügbar. Aus didaktischer Sicht ist das auch deshalb interessant, weil man Lernenden damit Denkstrategien vorführen kann, speziell Hypothesenbildung und Prüfung (etwa (Brown et al., 2014), S. 90–94, “generative learning”, oder die Studien von Willemain zur Modellierung von Problemen durch Experten (Willemain, 1994, 1995)). Ein neuer Ansatzpunkt zur Verbesserung der Ergebnisse wird hier genutzt (Grootendorst, 2025): Statt (nur) mehr Ressourcen in das Training immer komplexerer Modelle zu investieren (train-time compute), werden die Modelle dazu angehalten, länger „nachzudenken“, bevor sie ein Ergebnis anbieten (test-time compute). Hinter diesem „besseren Nachdenken“ stehen zwei Prinzipien (Grootendorst, 2025; Snell et al., 2024): Die Sprachmodelle werden einerseits instruiert, schrittweise vorzugehen (Input-Verbesserung der Vorschlagsverteilung) und andererseits dazu angehalten, die eigenen Antworten zu prüfen (Output-Verbesserung, Verifizierer). Die Sprachmodelle führen insofern teils selbstständig Prüfschritte durch, die man zuvor durch komplexe Prompts induziert hätte. In der Konsequenz werden die Sprachbots immer selbstständiger; für diese Wende Ende 2025 hat sich der Begriff **„Agentic Turn“** eingebürgert (E. R. Mollick, 2025a; Steinberger, 2025; Willison, 2025a): Als Nutzer solcher Reasoning Modelle verbringen wir weniger Zeit damit, über die ‚Zaubersprüche‘ einzelner Prompts nachzudenken und mehr Zeit in ‚Mitarbeitergesprächen‘ – Anleitung und Kritik der digitalen „Agenten“ – Sprachmodelle, die selbstständig und auf hohem Niveau mehrere Arbeitsschritte durchführen. Insgesamt steigt seit 2023 die Qualität der Aufgaben, die Sprachmodelle erledigen können, rasant. Empirische Untersuchungen zeigen, dass die Sprachmodelle immer längere Aufgaben auf hohem Niveau erledigen können (Kwa et al., 2025).

Die neuen Modelle sind außerdem günstiger und effizienter geworden: die Kosten pro Interaktion sind stark gesunken. Illustratives Beispiel: Eine Million Token kosteten mit dem damaligen Flaggschiff GPT-4 noch 50 Dollar, 2025 bei vergleichbarer Leistung nur noch 14 Cent (InvertedStone, 2025; E. R. Mollick, 2025b). Die Modelle halluzinieren (weiterhin, also Vorsicht, aber) deutlich seltener als ihre Vorgänger: OpenAI gibt für seine 2025er Generation ca. 1 % Halluzinationen der Antworten statt ca. 5 % bei

den Vorgängermodellen an, je nach Komplexität der Frage und erlaubter „Bedenkzeit“ (OpenAI, 2025b).

Weiterhin hat sich die **Internetsuche mit LLMs deutlich verbessert**. Während man früher noch oft über sinnlose oder erfundene Ergebnisse lachte, stellt die Suche über die großen Chat-Interfaces oder spezielle Suchanbieter wie Perplexity eine große Zeitersparnis dar: „a useful tool to provide up-to-date answers to questions that are grounded in facts found on the internet, together with the requisite citations—a crucial capability for researchers“ (Korinek, 2024, S.3). Das gilt zunehmend für die stärksten allgemeinen Modelle und erst recht für Anbieter, die auf Forschungsrecherche (und Studierende) spezialisiert sind, wie Elicit oder Paperpal. Auch breite Internet-Recherchen und Textproduktionen sind zunehmend komplett delegierbar („deep research“), mit deutlichen Auswirkungen auf den Arbeitsprozess in der Wissensarbeit (s. etwa Schwarcz et al. (2025) für juristische Recherchen, Korinek (2024) für Ökonomie und W. Liang et al. (2025) für PR-Tätigkeiten).

Auch komplexe Texte können die Sprachmodelle erstellen, prüfen und verbessern. Wie weit sich das fortentwickelt hat, sehen wir am folgenden Beispiel: Einem vorgefertigten **‘Skill’** - einer detaillierten Ablaufbeschreibung zur Erstellung komplexer Texte (OpenAI (2025a); anthropic2025a; willison2025b).

‘I know Kung-Fu now’ - modular Wissen hinzubuchen über ‘Skills’

Mit ‘Skills’ können wir dem Sprachmodell einen Block an sehr konkreten Anweisungen mitgeben. Zum Beispiel um komplexe längere Texte zu schreiben. Wie detailliert das ist, sehen wir hier am Beispiel des Skills “Co-Authoring”, der folgendes detailliert beschreibt:
1- Erfragt Meta-Informationen (Dokumenttyp, Zielgruppe, Zielsetzung) und integriert vorhandene Templates oder Dokumente.
2- Fordert den Nutzer zu einem “Info-Dump” auf und stellt anschließend gezielte Fragen, um Verständnis- und Kontextlücken zu schließen.
3- Erstellt eine initiale Dokumentenstruktur als bearbeitbares Artefakt (Datei) mit Platzhaltern.
4- Führt für jeden Abschnitt ein Brainstorming von Inhaltsoptionen durch und lässt den Nutzer auswählen, bevor der Text formuliert wird.
5- Erstellt den Entwurf für den jeweiligen Abschnitt und führt iterative

Änderungen auf Basis präziser Nutzeranweisungen durch.
6- Simuliert Leserfragen (“Reader Testing”) mit einer kontextfreien Instanz, um logische Lücken, Unklarheiten oder fehlendes Vorwissen aufzudecken.
7- Korrigiert identifizierte Schwachstellen und führt eine abschließende Gesamtkohärenzprüfung durch.
Den kompletten Skill finden Sie hier: https://github.com/anthropics/skills/blob/main/skills/doc-coauthoring/SKILL.md

1.5 Wie nutzen Studierende und Lehrende GenAI?

Für Studierende sind GenAI Chatbots zum Standard für Informationssuche und Schreibaufgaben geworden: So berichten 92 % der befragten britischen Vollzeitstudierenden (n=1.041, Erhebung im Dezember 2024), dass sie KI-Tools wie ChatGPT regelmäßig verwenden, und 88 % geben an, solche Tools für Prüfungsleistungen („for assessments“) zu nutzen (J. Freeman, 2025). Deutsche Daten des CHE-Centrum für Hochschulentwicklung bestätigen dies: etwa zwei Drittel der Studierenden gaben Ende 2024 an, KI-Tools mindestens wöchentlich einzusetzen (Hüsch et al., 2025) (65 %, n=23.288 von 171 Hochschulen).

Wofür genau nutzen Studierende GenAI? Studierende berichten, dass sie sich am häufigsten Konzepte erklären lassen, Artikel zusammenfassen oder Ideen für Schreib- und Forschungsprojekte sammeln (J. Freeman, 2025). Nutzungsstudien zeigen sogar noch stärkeren Einsatz speziell für Schreibprojekte (s. Abbildung 1.13): Wie eine Auswertung von 1 Million anonymisierten Chats zwischen Usern mit Universitätskonto und dem Sprachmodell zeigt, verwenden Studierende die KI-Bots vor allem zum **Erstellen neuer Inhalte und das Analysieren komplexer Themen**, was höheren Ebenen der Bloomschen Taxonomie entspricht (s. Abbildung 1.14). Ein Großteil der befragten britischen Studierenden gibt an, Prüfungsleistungen durch GenAI zu unterstützen. Dieser Anteil sprang zwischen den Erhebungszeiträumen Ende 2023 und 2024 von der Hälfte auf fast 90 % (53 % auf 88 %, J. Freeman, 2025).

Hochschulen müssen insofern sicherstellen, dass Prüfungsleistungen nicht entwertet und Studierende die produktive Nutzung solcher Tools

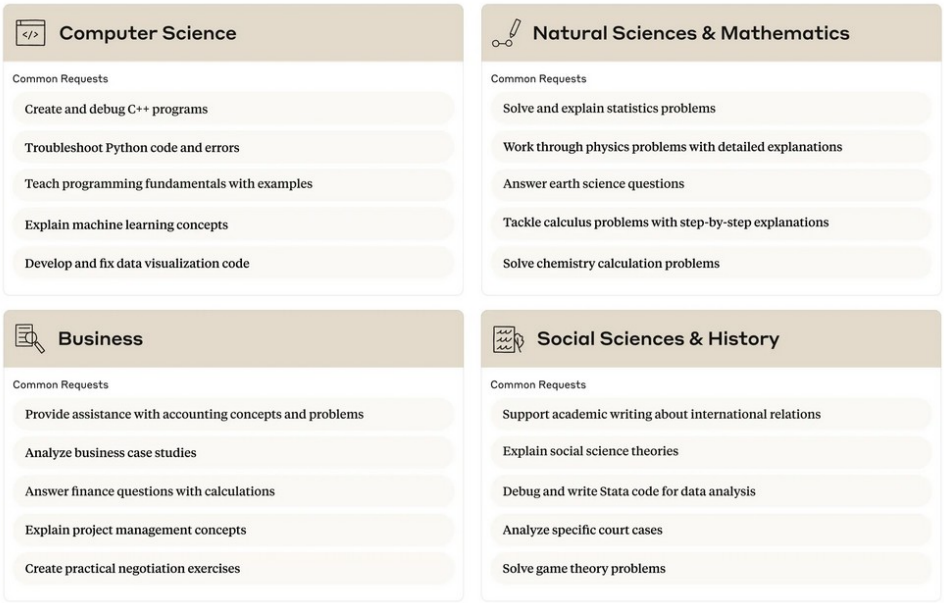

Abbildung 1.13. Wofür Studierende LLMs nutzen (Handa et al., 2025).

erlernen. Studierende dürfen einerseits wesentliche kognitive Aufgaben nicht vollständig an GenAI delegieren: Aufgaben und Prüfungsleistungen müssen angepasst werden. Weiterhin entsteht ein **neuer Bedarf an Kompetenzschulung**, den Studierende wie Unternehmen äußern: der produktive Umgang mit den neuen GenAI Tools muss eingeübt werden. **Deutsche Studierende fühlen sich hierauf nicht gut vorbereitet**: In der CHE-Studie bewerten sie das bestehende Angebot zum Erwerb von KI-Kompetenzen mit nur 2,7 von 5 Sternen (Hüsch et al., 2025).

Die zunehmende Verwendung von KI in der Lehre hat gute Gründe. Wie oft eine neue Technologie genutzt wird, hängt nach dem **Technology Acceptance Model** (TAM, s. Abbildung 1.15) von der **wahrgenommenen Benutzerfreundlichkeit** (perceived ease of use) und der **wahrgenommenen Nützlichkeit** (perceived usefulness) ab (Marangunić & Granić, 2015). Generative KI wie ChatGPT decken sichtlich beide Aspekte ab: Sie sind einfach zu nutzen (Kestin et al., 2025; H.-P. H. Lee et al., 2025; Monib et al., 2025; Naddaf, 2025) und erzeugen einen deutlichen Mehrwert, wie Studierende und Lehrende in einer Vielzahl von Umfragen der letzten zwei Jahren berichten (Heidt, 2025; Morgan, 2024; Ou et al., 2024). Lehrende ziehen nach: Meta-Untersuchungen zeigen ein extremes Wachstum an

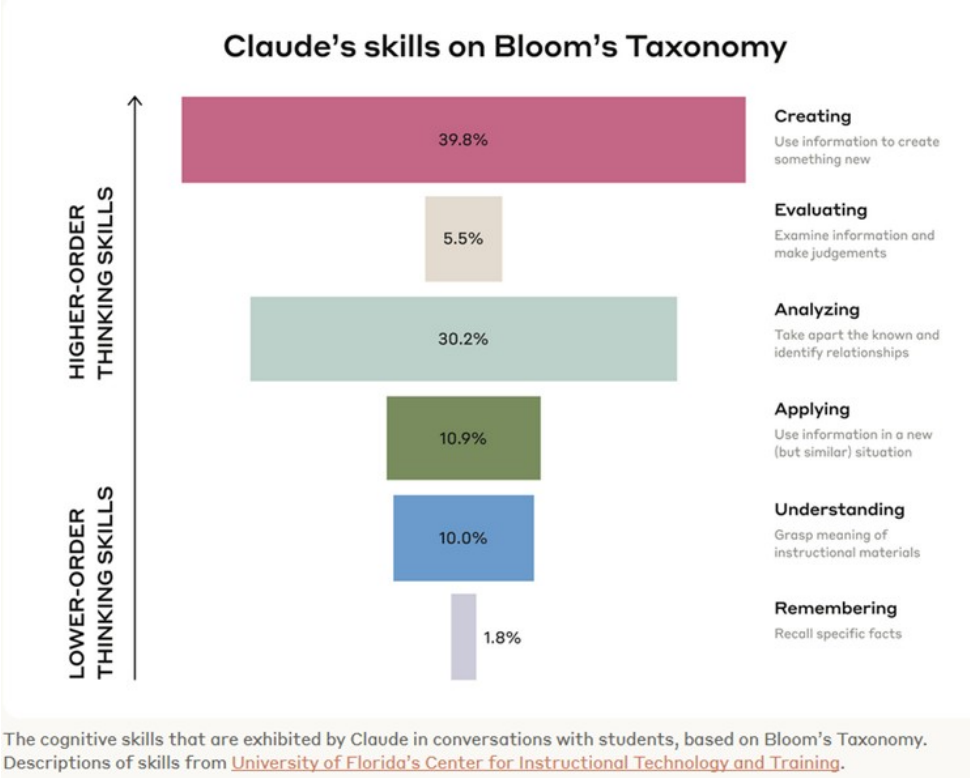

Abbildung 1.14. Schwerpunkte der Nutzung von LLMs (Claude) durch Studierende nach der Bloom'schen Taxonomie (Handa et al., 2025).

Publikationen zur Nutzung von LLM im Hochschulalltag (Ma, 2025; Ogunleye et al., 2024).

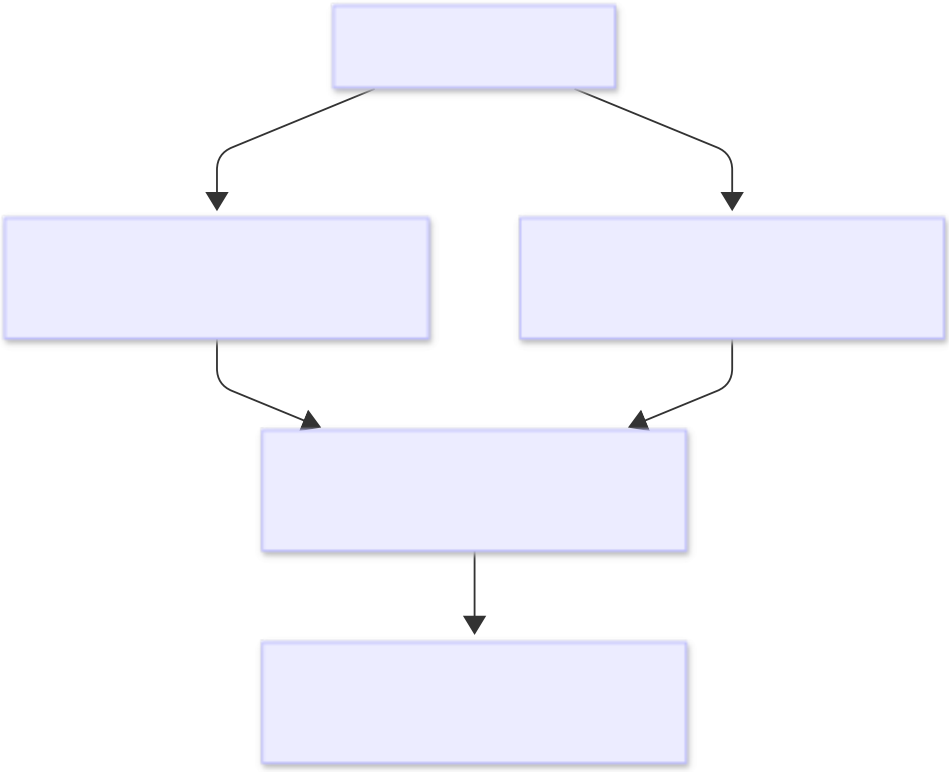

Abbildung 1.15. Gründe für die Verbreitung von GenAI nach dem Technologie-Akzeptanz-Modell. Erstellt mit ChatGPT 5 im Mermaid Live Editor (https://mermaid.live/edit), Herbst 2025

Auch außerhalb der Hochschule steigt die Nutzung. Eine Reihe von Studien zeigen **erhöhte Produktivität von Büroarbeitenden mit LLM-Unterstützung**: der Kundensupport arbeitet 15 % schneller, wenn das Sprachmodell Antwortoptionen vorschlägt und Verweise auf interne technische Dokumentation anbietet (Brynjolfsson et al., 2025), Programmierer programmieren schneller (Peng et al., 2023), Consultants sind produktiver bei komplexen Beratungsprojekten (Dell'Acqua et al., 2023) und Sprachmodelle wie ChatGPT können eine Vielzahl kleiner Aufgaben beschleunigen (Handa et al., 2025) und werden insofern speziell zur Texterstellung millionenfach als Hilfsmittel im Beruf genutzt: Von Kundenbewertungen über Pressemitteilungen und Stellenanzeigen (W.

Liang et al., 2025).

Schauen wir auf die Abnehmer unserer Graduierten: **Wie nutzen die Unternehmen solche Sprachmodelle?** Eine Studie vom Dezember 2025 zur Nutzung von GenAI in Unternehmen stellt ein extremes Wachstum fest sowie einen deutlichen Unterschied in der Nutzung von erfahrenen und weniger routinierten Usern (Chatterji, 2025). Der OpenAI-Report zeigt, dass die Nutzung von Sprachmodellen in Unternehmen 2025 deutlich *breiter und tiefer* wird: ChatGPT-Enterprise-Nachrichten stiegen im Jahresvergleich etwa um das Achtfache, gleichzeitig wachsen wiederholbare Arbeitsabläufe stark (Nutzung von Projects/Custom GPTs ~19-fach seit Jahresbeginn; rund 20 % der Enterprise-Nachrichten laufen bereits über solche strukturierten Workflows). Gleichzeitig bleibt bei fortgeschritteneren Funktionen noch viel ungenutztes Potenzial. Vor allem der Mehrwert von Funktionen wie *Deep Research* (Delegation ausführlicher Recherchen), *Reasoning* (schrittweises, sorgfältiges Antworten mit deutlich höherer Qualität) und *Datenanalyse* mit Coding Tools wie Codex werden von Praktikern mit Firmen-Lizenz noch sehr selten genutzt. Selbst unter monatlich aktiven Enterprise-Nutzern haben 19 % noch nie Datenanalyse, 14 % noch nie Reasoning und 12 % noch nie (Deep) Search genutzt (bei täglich Aktiven sinkt das auf 3 %, 1 % und 1 %).

1.6 Risiken und Nebenwirkungen

Die Metapher mit dem E-Bike trägt allerdings auch, was die **Risiken und Nebenwirkungen** angeht: Ab wann lässt die maschinelle Unterstützung wichtige Muskeln verkümmern? Solche Gefahren bestehen – wie empirische Studien zeigen, erfordern die neuen Workflows der Wissensarbeit durch KI-Unterstützung auch neue Formen der kritischen Auseinandersetzung mit den Inhalten.

Wird der Umgang mit GenAI nicht geübt, droht ein Rückgang des kritischen Denkens. Eine Studie von 319 Wissensarbeitern zeigt, dass sich das **Gewicht zwischen den Einzelaufgaben der Wissensarbeit mit LLMs verschiebt**: Der Aufwand für die Recherchen selbst sinkt, es steigt andererseits der Aufwand für Management-ähnliche Aufgaben: Koordination der Einzelaufgaben für Mensch und Maschine, kritische Prüfung der berichteten Ergebnisse und die Integration von Ergebnissen

in den Gesamtprozess (etwa zur Erstellung eines Gesamtberichtes, einer Test-Spezifikation oder eines Protokolls) (H.-P. H. Lee et al., 2025).

Im Gegensatz zur einfachen Faktensuche im Internet werden hier nicht nur ein paar dornige Zweige im Aufgabenbündel mechanisch ‚geerntet', sondern **gleich das gesamte Bündel fertig verschnürt bereitgestellt.** Schlimmstenfalls droht das, was ein Artikel von Walsh (2025) prägnant betitelt: **„Everybody is cheating their way through college".** Wenn klassische Projektaufgaben quasi auf Knopfdruck erstellt werden können, droht diese Form von Leistung sinnlos zu werden. Mit etwas Lust an Dramatik können wir uns Endzeit-Szenarien vorstellen, in denen **Lehrende klagend durch die Trümmer ihrer schönen Portfolio-Prüfungen stolpern:** Die Homework-Apocalypse (E. R. Mollick, 2023).

Aber so schlimm muss es nicht werden. Plausible Ansätze, Lehrformate auf die allgemeine Nutzung von GenAI hin umzugestalten existieren bereits. Unser Ziel dabei muss sein, dass erwünschte Schwierigkeiten nach E. L. Bjork & Bjork (2011) beibehalten oder sogar verstärkt werden, auch wenn die meisten Studierenden zu Hause starke Sprachmodelle nutzen können.

Wie kann man also verhindern, dass die Studierenden kritische kognitive Aufgaben allein den KI-Systemen übergeben? Lehre heißt in diesem Kontext auch, empfohlene Arbeitsweisen mit der neuen Technik zu üben. Wie das gehen kann, sehen wir in den folgenden Kapiteln.

Kernaussagen

1. Generative KI ist für die Lehre ein Kraftverstärker: Der Berg bleibt, aber mit dem E-Bike kommt man weiter. Sie senkt vor allem den Aufwand für Methoden, die didaktisch wirksam, aber zeitintensiv sind.
2. „KI nutzen" heißt zunehmend, Aufgaben an Agenten zu delegieren. Ergebnisqualität hängt von der Kombination aus starkem Modell, passender Oberfläche und Werkzeugkasten (Harness) ab; wer am Modell spart, spart meist am Ergebnis.
3. Der Mehrwert entsteht erst durch eigenes Fachwissen und Erfahrung im kritischen Umgang mit dem Werkzeug. Auch starke Modelle vertreten falsche Ergebnisse überzeugend.
4. Studierende nutzen Sprachmodelle längst flächendeckend, besonders für Schreibaufgaben und Prüfungsleistungen, fühlen

sich aber auf den produktiven Umgang schlecht vorbereitet.
5. Die Hauptgefahr ist nicht das Täuschen, sondern die Auslagerung des Denkens. Lehre muss erwünschte Schwierigkeiten erhalten, auch wenn zu Hause starke Modelle verfügbar sind.

Zum Weiterdenken

1. Welche Lehrmethode haben Sie in den letzten Semestern aus Zeitgründen nicht umgesetzt, obwohl Sie von ihrer Wirkung überzeugt sind? Welchen Teil des Aufwands könnte ein Sprachmodell übernehmen, und welcher Teil muss bei Ihnen bleiben?
2. Erklären Sie ohne Nachschlagen den Unterschied zwischen Modell, App und Harness an einem Beispiel aus Ihrem Fach. Welche Ebene fehlt den kostenlosen Zugängen Ihrer Hochschule?
3. Bei welcher Aufgabe in Ihrer Lehrveranstaltung würde ein Studierender durch KI-Nutzung am meisten an Lernwirkung verlieren? Woran würden Sie das erkennen?

1.7 Kapitelübersicht

Im folgenden Kapitel werden wir zunächst einige Grundbegriffe (Kapitel 2) klären: Was sind große Sprachmodelle und was ist mit Begriffen wie Token, Prompt und RAG gemeint? Welche Modellklassen und Zugänge können Lehrende nutzen und welche Empfehlungen für Prompts sind belastbar? Dann fragen wir nach Zielen (Kapitel 3): Welche Art von Wissen und Methoden unterscheidet und empfiehlt die Lernforschung? Welche didaktischen Wirkmechanismen können durch KI genutzt werden, um typische Probleme der Hochschullehre anzugehen? Im Abschnitt 4 schauen wir auf Praxisbeispiele (Kapitel 4) für vier Anwendungsfelder von Sprachmodellen an Hochschulen: KI als Hiwi (direkte Arbeitserleichterung), KI als Copilot (Unterstützung beim Schreiben und Coden) und KI als Tutor (Feedback und Lernunterstützung) sowie KI als Simulator (Role Play und Goal Play). Abschließend zeigen wir verschiedene Anwendungen von KI in verschiedenen Kurstypen und gehen auf neue Herausforderungen für Prüfungen ein (Kapitel 5). Im Appendix finden Sie eine breite Sammlung von didaktischen Prompts und auf GenAI

ausgerichteten Aufgabenstellungen von führenden Hochschulen. Dabei erläutern wir zunächst, wie die Prompts aufgebaut sind (Anhang A) und zeigen dann eine Liste strukturierter Best-Practice Beispiele (Anhang B).

2 Grundbegriffe

Lernziele

Nach diesem Kapitel können Sie …

- in Laiensprache erklären, wie ein Sprachmodell Text in Tokens zerlegt, als Zahlen verarbeitet und Wort für Wort neuen Text erzeugt;
- die drei Nutzungsmuster LLM, RAG und Agent unterscheiden und für eine Lehraufgabe das passende Muster auswählen;
- beschreiben, warum Sprachmodelle halluzinieren und welche Folgen das für den Einsatz in der Lehre hat;
- die Jagged Frontier erklären und daraus ableiten, warum Sprachmodelle bei ähnlich schwierigen Aufgaben sehr unterschiedlich gut abschneiden;
- die Bausteine eines guten Prompts (Rolle, Aufgabe, Format, Beispiele) anwenden und belegen, welche verbreiteten Prompt-Tricks nichts bringen;
- die Größenordnung des Energieverbrauchs einer Anfrage einordnen und die wichtigsten Argumente der Debatte wiedergeben.

2.1 Definition einiger Grundbegriffe

In diesem Abschnitt definieren wir anfangs **sehr kurz einige Grundbegriffe**. Dies kratzt bewusst nur an der Oberfläche eines komplexen technischen Themas: Unser Fokus liegt auf der didaktischen Nutzung.

Wie in der Einleitung kurz angesprochen, ist es seit der agentischen Wende (s. Kapitel 1.4) in der Arbeit mit GenAI noch wichtiger geworden, einen hochwertigen **Setup** zu haben, also eine Mischung aus einem schlauen Modell, praktischer Oberfläche und sinnvollen Tools (E. Mollick, 2026).

Grobe Regel: Wenn das Ergebnis wichtig ist, nie ein kostenfreies Modell wählen.

Abbildung 2.1. Daumenregel: Für wichtige Fragen immer eine stärkere Kombination aus Modell und Setup wählen

Wenn Sie neugierig geworden sind, gibt es jenseits dieses Buches **gute Quellen, um tiefer einzusteigen**: Als visuelle Begleitung empfehle ich das sehr schöne Einführungsvideo des Mathematik-Didaktikers Grant Sanderson (7 Minuten, https://youtu.be/LPZh9BOjkQs). Tiefer in die mathematischen Details geht die grafische und interaktive Einführung als Animation von Brendan Bycroft (https://bbycroft.net/llm). Wer sich auch die technischen Hintergründe genauer erschließen will, dem sei das Lehrbuch-Standardwerk von Jurafsky & Martin (2025) empfohlen, das online frei verfügbar ist.

Welche der Fachbegriffe kennen Sie schon? Von Prompt bis Token, über Temperatur und RAG: Testen Sie sich selbst mit dem folgenden kleinen Spiel.

> Lernspiel: Welche Grundbegriffe kennen Sie schon?
>
> *Ordnen Sie die Begriffe den korrekten Definitionen zu!*

Abbildung 2.2. Lernspiel „Welche Grundbegriffe kennen Sie schon?“ (Zuordnung von Begriffen und Definitionen). Dieses interaktive Element gibt es nur in der Online-Version: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/llm-game-standalone.html aufrufen.

(am besten auf dem Computer spielen). Hier auch Online abrufbar (so etwas nennt sich „Artifact“ beim Sprachmodell „Claude“): https://claude.site/artifacts/d8e3cee4-ea47-48e3-a84c-a774d408aac8

Vorweg: **Was heißt hier ‘künstliche Intelligenz’?** In diesem Buch folgen wir weitgehend dem alltäglichen Sprachgebrauch, indem wir die Begriffe **KI, generative KI (GenAI) und Sprachmodell (Large Language Model, LLM) weitgehend synonym** verwenden. Eigentlich ist generative künstliche Intelligenz - wie der Name es schon andeutet - ein Teilgebiet der KI, also des Versuches, menschliches Denken und Verhalten nachzubilden (Russell & Norvig, 2021). Für die meisten Nutzer sind die Feinheiten von KI, maschinellem Lernen und neuronalen Netzen allerdings in unserem Kontext eine **Unterscheidung, die praktisch keinen Unterschied macht**: Die meisten Lehrenden nutzen aktiv erst KI, seit es die modernen Sprachmodelle gibt. In der Nutzung für die Lehre gilt für fast alle von uns: **KI = GenAI**, auch wenn im Hintergrund schon seit Jahrzehnten mit KI die Routen von Lieferdiensten oder die Lagerhaltung in Supermärkten vorhergesagt wird.

KI vor 2022 und KI nach 2022 meint meist etwas anderes. Was oft auch Studierende verwirrt: Ältere Fachartikel vor 2022 mit Titeln wie “KI-Anwendungen in XY” meinen aus Anwendersicht mit ‘KI’ etwas ganz anderes als die Publikationen seit 2022 zu den verschiedenen Anwendungsformen von menschenähnlich schreibenden, sprechenden

und analysierenden Chatbots. Früher ging es aus Anwendersicht grob gesagt meist um **bessere statistische Prognosemodelle** zur Nutzung durch Expertinnen und Experten (etwa für optimale Routen oder Personalauswahl) (Russell & Norvig, 2021). Seit ChatGPT sprechen wir von **viel breiteren Formen der Nutzung, Milliarden von Usern und extremer KI-Hype.**

Ein **Large Language Model (LLM)** ist ein maschinelles Lernmodell, das darauf trainiert ist, menschliche Sprache zu verstehen und Texte zu erzeugen, die natürlich erscheinen. Ein **Sprachmodell** ist ein Rechensystem, das das nächste Wort in einer Wortkette vorhersagt, basierend auf den vorher genannten Wörtern in dieser Kette (Jurafsky & Martin, 2025, Kap.7, S.2). Die Modelle können riesige Mengen von Textdaten verarbeiten, um vielseitige Sprachanwendungen zu ermöglichen.

Die **generative Künstliche Intelligenz** (GenAI) bezieht sich auf Systeme, die fähig sind, neue Inhalte zu erzeugen, wie etwa Texte, die noch nicht existierten. LLMs sind ein zentraler Teil dieser generativen KI und können eigenständig Texte zu einem breiten Spektrum von Themen generieren.

> Tipp: Mini-Interaktionen einfach als HTML erstellen
>
> Können Sie in HTML programmieren? Jetzt schon. Die *Lernspiele in diesem Abschnitt* wurden mit Hilfe von Sprachmodellen erstellt (Gemini, ChatGPT, Claude). Meist mit einer Variation des einfachen Prompts: **„Erstelle mir ein browser-basiertes Lernspiel zum Thema / zur Illustration von ...“**. Oft hat man nach 5–10 Minuten eine gute erste Version. In der Lehre mache ich das oft auch als Übung mit Studierenden. Sie sollen dann erst mit Hilfe der KI ein Lernspiel erstellen und dann begründet bewerten, welcher Spiel-Prototyp das Konzept am besten darstellt. Bei etwas mehr Zeit kann man sie gegenseitig bewerten lassen, selbst Kriterien erstellen oder stärkere Gamification hinzufügen. Im Ergebnis beschäftigen sich idealerweise die Teilnehmer intensiv mit einem theoretischen Konzept (Bei komplexeren Themen hilft es, einen Fachtext als Hintergrund zum Konzept hochzuladen.)

Das **Sprachmodell** zerlegt dazu grob gesagt Inputs wie Texte in kleine Bausteine (Tokens), verwandelt diese in Zahlen (Embeddings), erkennt mithilfe komplexer Muster (Transformer und Attention) deren Zusammenhänge, und erzeugt auf diese Weise selbstständig basierend auf

kontextbezogen berechneten Wahrscheinlichkeiten neue Texte (generative Sprachproduktion).

Damit Sprachmodelle wie ChatGPT Sprache verstehen und erzeugen können, zerlegen sie Text in sogenannte **Tokens** – kleine Bausteine wie Wörter, Wortteile oder Satzzeichen (s. etwa Jurafsky & Martin, 2025, Kap.2). Jedes dieser Tokens wird in einen **Vektor** umgewandelt – eine Zahlenreihe, die das Wort mathematisch beschreibt. Dieser Vorgang nennt sich **Embedding**. Dabei wird darauf geachtet, dass ähnliche Wörter ähnliche Vektoren erhalten, beispielsweise „Hund“ und „Katze“.

Hier kann man das selbst einfach ausprobieren: Das interaktive Widget simuliert eine GPT-2-ähnliche Tokenisierung.

Geben Sie eigenen Text ein, unten wird er dann in Tokens und Zahlen umgewandelt

Abbildung 2.3. Interaktiver Tokenizer: eigener Text wird in Tokens und Zahlen zerlegt. Dieses interaktive Element gibt es nur in der Online-Version: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/tokenizer-explorer.html aufrufen.

Die Simulation vermittelt ein Gefühl für den Prozess. Wie die Umwandlung eines bestimmten Textes genau in verschiedenen Sprachmodellen aussieht, können Sie interaktiv auf Webseiten wie Tiktokenizer ausprobieren: https://tiktokenizer.vercel.app/.

Ein **Prompt** ist eine Eingabeaufforderung, die an ein LLM gesendet wird, um eine spezifische Antwort zu erhalten. Wie der Prompt formuliert wird, kann entscheidend für die Qualität der generierten Antworten sein. Die Kunst,

solche Befehle zu schmieden nennt sich **Prompt Engineering** (Berryman & Ziegler, 2025).

Eine neuere Analyse unterscheidet **drei Effekte** der Prompt-Gestaltung (Vallverdú et al., 2025): User steuern über Prompts den Inhalt der Aufgabe (**operativ**), die 'Aufmerksamkeit' des Sprachmodells (**epistemisch**) und die Risiken des Ergebnisses (**sozio-ethisch**). Stärkere Sprachmodelle übernehmen einen Teil dieser Steuerung, die Komplexität rückt aber damit nur auf eine höhere Ebene: In agentischen Workflows arbeiten mehrere Agenten zusammen, für deren Steuerung wir wiederum operative, epistemische und sozio-ethische Effekte berücksichtigen müssen (s. etwa Gottweis et al., 2025 für ein Beispiel).

2.1.1 Was heißt hier GPT?

GPT steht für **Generative Pre-trained Transformer**. Wir schauen zunächst, was diese drei Begriffe bedeuten.

'*Generative*': Der Begriff „**generativ**" bedeutet in diesem Zusammenhang, dass GPT eigenständig Texte erzeugt, indem es gelernte Muster neu kombiniert.

'*Pretrained*': GPT wurde mit riesigen Textmengen **vortrainiert** (**Pretraining**), ohne konkrete Aufgaben lösen zu müssen – dieser Vorgang erfolgt unüberwacht (*unsupervised learning*). Beim 'Bau' solcher Sprachmodelle bewerten menschliche Expertinnen und Experten den ersten Output (**„Reinforcement Learning with Human Feedback" (RLHF)**), um so ein genaueres Modell dafür zu erstellen, was für User nützlich ist und was nicht. Dabei erzeugt das LLM zunächst verschiedene Textversionen, die von menschlichen Bewertern beurteilt werden.Durch diesen Prozess „lernt" das LLM, Texte zu bevorzugen, die nicht nur sprachlich richtig, sondern für Menschen besonders verständlich und nützlich sind. Das macht es möglich, dass GPT später aus wenigen Stichworten neue Texte generieren kann – also kreativ Sprache produziert, ohne bloß zu kopieren (generativ).

'*Transformer*': Das Herzstück des GPT ist der sogenannte **Transformer** – ein Rechenmodell, das durch ein spezielles Aufmerksamkeitsverfahren (**Attention**) erkennt, welche Wörter im Zusammenhang wichtig sind. Dadurch kann GPT die Bedeutung von Wörtern im Kontext richtig einschätzen. Im Transformer bedeutet **„Attention"**: Jedes Wort (genauer: jedes Token) entscheidet dynamisch, auf welche anderen Tokens es beim

Verstehen oder Generieren am stärksten „hören“ sollte. Technisch ist das eine gewichtete Mischung von Informationen: Das Modell bildet eine Art Relevanzscore zwischen einem „aktuellen Interesse“ und möglichen „Informationsquellen“ und erstellt daraus Gewichte, die sich zu 1 aufsummieren. Die Ausgabe ist dann eine gewichtete Summe der Informationsinhalte. Das ist wie bei einer Literaturrecherche: Eine Fragestellung (Query) wird mit Titeln/Abstracts als „Hinweis-Schilder“ (Keys) abgeglichen; die eigentlichen Inhalte (Values) aus den passenden Quellen fließen dann stärker in das Gesamtverständnis ein. Beispielsweise erkennt GPT so in einem Satz wie „Die Bank steht unter einem Baum“ anhand des Kontextes, ob „Bank“ ein Möbelstück oder eine Institution meint. Der zentrale Fachartikel von 2017, ein zentraler Auslöser der KI-Welle seit 2022, hatte den knackigen Titel “Attention is all you need” (Vaswani et al., 2017) – der Artikel wurde bis 2026 mehr als 200.000-fach zitiert.

Was behält das Sprachmodell von unserer Unterhaltung? Wie viel Text kann ich – auch als PDF – hochladen? Moderne LLMs können ganze Bücher schnell aufsaugen und dann zusammenfassen (z. B. Claude, ChatGPT oder Gemini). Das **Kontext-Fenster** eines LLM beschreibt die Menge an vorherigem Text, die das Modell bei der Verarbeitung neuer Informationen berücksichtigt, um den Kontext und die Zusammenhänge zu verstehen.

Ein **Agent** im Kontext von Automation und künstlicher Intelligenz meint zunächst allgemein etwas, das seine Umwelt wahrnimmt (durch Sensoren) und auf sie einwirkt (durch Aktoren) (Russell & Norvig, 2021, S.54). Agenten bestehen aus einer Architektur, die bestimmt, was möglich ist und einem Programm, das vorgibt, wie der Agent handeln soll (Russell & Norvig, 2021, S.65ff.). Ersteres meint bildlich gesprochen die Augen und Hände des Agenten: Die *Agenten-Architektur* beschreibt den spezifischen Setup von Sensoren und Aktoren, die bestimmen, was für den Agenten wahrnehmbar und handelbar ist. Für GenAI Agenten fragt das etwa: Hat er Web-Anbindung? Kann er programmieren? Das *Agenten-Programm* ist das Regelbuch: es bestimmt, wie der Agent reagiert. Von einfachen Wenn-Dann-Regeln bis hin zu komplexen Weltmodellen (z. B. Physik-Modelle, die die Schwerkraft berücksichtigen oder Kosten-Gewinn Rechnungen für eine Wirtschaftssimulation).

GPT-basierte Agenten können Text analysieren, generieren und verschiedene Aufgaben automatisieren, indem sie vorab definierte Muster und Regeln

befolgen. Durch die Erstellung solcher Agenten können Lehrende interaktive und personalisierte Lerninhalte einfacher gestalten (E. R. Mollick & Mollick, 2024).

Schlau sein allein reicht nicht: Ein Sprachmodell muss zwar einerseits 'intelligent' genug sein, um eine gestellte Aufgabe zu lösen. Aber auch der schlauste helfende Geist kann uns nur helfen, wenn er auch versteht, was wir eigentlich wollen und brauchen - er muss den **Kontext unserer Aufgabe kennen**.

Einen solchen Kontext können wir der KI auf zwei Arten bereitstellen: Bildlich gesprochen geben wir ihr ein paar **Bücher oder einen Werkzeugkoffer.** Präziser ausgedrückt geht es um die Methoden **"RAG" und "Agenten"** (Huyen, 2025, Kap.6):

```
"Two dominating patterns for context construction are
  RAG,
or retrieval-augmented generation, and agents.
The RAG pattern allows the model to retrieve relevant
  information
from external data sources.
The agentic pattern allows the model to use tools
such as web search and news APIs to gather
  information."
```

RAG (Retrieval-Augmented Generation) beschreibt insofern die Möglichkeit, zusätzliche Daten wie Fachtexte, Statistiken oder Gesetzesbücher in Kombination mit einem KI Modell zu verwenden (Huyen, 2025, Kap.6). Die KI ist das Gehirn, die zusätzliche Wissensdatenbank quasi das Bücherregal, das zu Rate gezogen werden kann.Je nach Kontextfenster stehen dort mehr oder weniger Bücher.Insofern umschreibt RAG ein KI-Modell, das die Fähigkeiten von Textgenerierungsmodellen (wie GPT) mit einer Wissensdatenbank kombiniert. So wird etwa der Prompt-Agent (s. u.) mit einer Reihe von Fachtexten „gefüttert", in denen Best Practices des Prompting erklärt werden.

Einige Unterschiede zwischen einem einfachen Sprachmodell (LLM) und dem Setup mit Zusatzmaterial (RAG) und erlaubter Werkzeugnutzung (Tool Use, Agenten) sehen wir an der folgenden Interaktion. Wählen Sie hier jeweils die passende Antwort (die Übung ist nicht schwer - überlegen Sie sich zusätzlich ein Beispiel dafür aus Ihrem Berufsalltag!).

Lernspiel: LLM, RAG oder Agent, was sind mögliche Probleme und Anwendungsfelder?

Runter scrollen und "Los gehts!" auswählen, dann nacheinander die Interaktionen für LLM, RAG und Agent auswählen und die Fragen beantworten.

Abbildung 2.4. Lernspiel „LLM, RAG oder Agent?" (Probleme und Anwendungsfelder der drei Setups). Dieses interaktive Element gibt es nur in der Online-Version: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/llm-rag-agent-game.html aufrufen.

In der Lehre kann RAG verwendet werden, um den Studierenden Fachtexte oder besonders aktuelle Informationen zur Verfügung zu stellen. Beispielsweise könnten Studierende in einem Geschichtsseminar eine KI befragen, die externe Quellen durchforstet, um aktuelle Erkenntnisse zu historischen Ereignissen zu präsentieren (Huffman & Hutson, 2024). Unternehmen nutzen diese Technik, um etwa riesige Gebrauchsanweisungen mit KI durchsuchbar zu machen (Brynjolfsson et al., 2025), oder Chatbots zu trainieren, die typische, repetitive Kundenanfragen beantworten (Handa et al., 2025). Insofern ermöglicht RAG eine dynamische und zeitgemäße Wissensvermittlung, die nicht auf das festgelegte Wissen des KI-Modells beschränkt ist.

2.1.2 Was nutzen - LLM, RAG oder Agent?

Wie unterscheiden sich die verschiedenen *Nutzungs-Muster*, die wir bis jetzt kennengelernt haben? Frage ich nur das Sprachmodell? Oder lieber das Sprachmodell mit Zusatz-Material (RAG)? Oder vielleicht das Sprachmodell mit Tools (Agenten)? Prüfen Sie Ihr Verständnis: Welche der

links gezeigten Antworten passen zu welchem der rechts gezeigten Muster? Nutzt das Sprachmodell nur sein "Standard-Wissen" (LLM only), oder werden "Werkzeuge" wie Internet-Nutzung erlaubt?

Mit den agentischen Werkzeugen kommt in der Praxis eine vierte Entscheidungsfrage hinzu (E. Mollick, 2026): **Hat mein Agent ein Harness?** Ohne Harness bleibt „Agent" oft ein Etikett; mit Harness kann das Modell tatsächlich recherchieren, rechnen, Dateien erzeugen und Zwischenschritte nachvollziehbar machen. Für Lehraufgaben bewährt sich daher ein Workflow, der erst eigenes Material als Kontext nutzt (RAG/Notebook-Ansatz), dann für belastbare Quellen ein Research-Harness (z. B. „Deep Research") einsetzt und die Ergebnisse als Artefakte exportiert (Quiz, Aufgabenblatt, Folien) – bevor Sie didaktisch zuspitzen.

Lernspiel: Welche Art des LLM-Setups passt zu den links gezeigten Antworten oder Denkprozessen?

Abbildung 2.5. Lernspiel „Welches LLM-Setup passt zur Antwort?" (Zuordnung von Antwortmustern zu LLM, RAG und Agent). Dieses interaktive Element gibt es nur in der Online-Version: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/interactions/llm-agent-patterns-matching.html aufrufen.

2.1.3 Agenten in der Praxis: Harness, Skills, Werkzeuganschluss und eigene Quellen

Die drei Muster aus dem vorigen Abschnitt beschreiben, *was* die KI zur Verfügung hat: ihr Trainingswissen, zusätzlich eigene Texte oder zusätzlich Werkzeuge. Im Alltag der Lehre stellt sich die Frage anders: Wann lohnt

es sich, der KI einen Auftrag zu geben statt einer Frage, und wo muss ich dabei selbst entscheiden? Dafür braucht man vier Begriffe, die in den Produktbeschreibungen durcheinandergehen.

Ein **Agent** ist ein Sprachmodell, das einen Auftrag in Schritte zerlegt, diese Schritte mit Werkzeugen abarbeitet und erst am Ende zurückmeldet. Der Unterschied zum Chat ist die Strecke, die die KI allein zurücklegt: Im Chat sehen wir jede Antwort nach Sekunden, ein Recherche-Agent arbeitet Minuten, ein automatisierter Ablauf Stunden. Das **Harness** ist der Werkzeugkasten, den der Agent dabei trägt (das Wort kommt über das Altfranzösische *harneis*, Ausrüstung, Rüstzeug): Websuche, ein Rechner in Form einer Programmiersprache, Zugriff auf einen Ordner, die Fähigkeit, Dateien zu erzeugen. Ohne Harness bleibt „Agent“ ein Etikett auf einem Chatbot. Ein **Skill** ist eine Gebrauchsanweisung, die der Agent bei Bedarf liest: ein Textdokument mit den Regeln, wie eine bestimmte Aufgabe in unserem Kurs zu erledigen ist, etwa wie Folien auszusehen haben oder wie eine Übungsaufgabe aufgebaut wird. Der Skill macht aus einem allgemeinen Modell einen Mitarbeiter, der die Hausregeln kennt, ohne dass wir sie in jedem Prompt wiederholen. Der **Werkzeuganschluss** schließlich, meist unter dem Kürzel MCP (Model Context Protocol) angeboten, ist die genormte Steckdose, über die ein Agent fremde Dienste erreicht: den Bibliothekskatalog, die Lernplattform, einen Kalender. Für Lehrende ist das die Stelle, an der die KI aufhört, ein Textfenster zu sein, und anfängt, in unseren Systemen zu handeln.

Eigene Quellen sind der Sonderfall, der in der Lehre am häufigsten gebraucht wird. Das Verfahren dahinter heißt RAG, Retrieval-Augmented Generation, und wurde als Kombination aus einem Suchschritt über eine Dokumentsammlung und einem Schreibschritt des Sprachmodells beschrieben (Lewis et al., 2020). Praktisch heißt das: Statt dem Modell zu vertrauen, dass es unseren Skripttext aus dem Training kennt, legen wir ihm den Text vor und lassen es nur daraus antworten. Die einfache Form ist ein Projekt oder Notebook im Chat-Interface, in das wir Skript, Übungsblätter und Musterlösungen laden; die anspruchsvolle Form ist ein eigener Tutor, der auf einer Dokumentablage sitzt. Beide Formen haben denselben Schwachpunkt: Antwortet die KI aus den Quellen oder doch aus dem Training? Das lässt sich prüfen, indem man Fragen stellt, deren Antwort in den Quellen bewusst anders lautet als im Allgemeinwissen; diese Prüfidee kehrt in Kapitel D.3 und Kapitel D.7 wieder.

Was ändert sich mit der Delegation für die Lehre? Dass der Übergang

vom Chat zum Agenten in Nutzungsdaten messbar ist und nicht nur in Produktankündigungen, zeigt Johnston et al. (2026) an einem Coding-Agenten; die Belege und ihre Grenzen stehen in Kapitel D.1. Die Konsequenz ist weniger technisch als organisatorisch. Die Forschung zur Automatisierung hat lange vor den Sprachmodellen beschrieben, dass sich für jede Stufe einer Aufgabe getrennt festlegen lässt, wie viel die Maschine entscheidet und wo der Mensch das Steuer behält (Parasuraman et al., 2000). Für Agenten in der Lehre heißt das: Wir legen vor dem Start fest, an welchen Punkten der Ablauf anhält und auf uns wartet. Bei einer Literaturrecherche sind das drei Stellen: der Quellenkorb, den der Agent durchsuchen darf, der Rechercheplan, bevor er loslegt, und die Stichprobe von Aussagen, die wir gegen das Original halten. Je länger die Strecke ohne Blick, desto wichtiger werden diese Punkte, und bei einem Tutor, den Studierende ein Semester lang ohne uns benutzen, ist sie am längsten.

Die praktische Umsetzung dieser vier Begriffe steht in Anhang D: Arbeitsumgebung und Skills in Kapitel D.2, eigene Quellen in Kapitel D.3, Agenten für die akademische Suche mit ihren Kontrollpunkten in Kapitel D.4, automatisierte Abläufe in Kapitel D.6. Wie ein Projekt mit Unternehmen aussieht, in dem Studierende eine solche Quellenanbindung selbst aufbauen, zeigt ein Fallbeispiel in Kapitel 6.

Das beendet unsere kurze Begriffsbestimmung. Ein etwas breiteres Glossar für Anwender finden Sie etwa bei der populärwissenschaftlichen Zeitschrift CIO (Chief Intelligence Officer): https://www.cio.de/article/3700849/die-wichtigsten-begriffe-im-genai-umfeld.html.

2.2 Wie denken Sprachmodelle und warum halluzinieren sie?

Eine Studie des KI-Labors Anthropic hat mit neuen Methoden den **Denkprozess eines Sprachmodells im Detail nachgezeichnet** (Lindsey et al., 2025), was uns erstmals etwas genauer verstehen lässt, wie Sprachmodelle mit verschiedenen Sprachen umgehen, wie sie den Schreibprozess „planen“, wie sie bei Kalkulationen vorgehen, wie weit ihre Selbsterkenntnis reicht und warum sie manchmal Antworten erfinden („halluzinieren“).

- **Sprachübergreifend gleich:** Das Modell nutzt einen gemeinsamen sprachübergreifenden Bedeutungsraum.

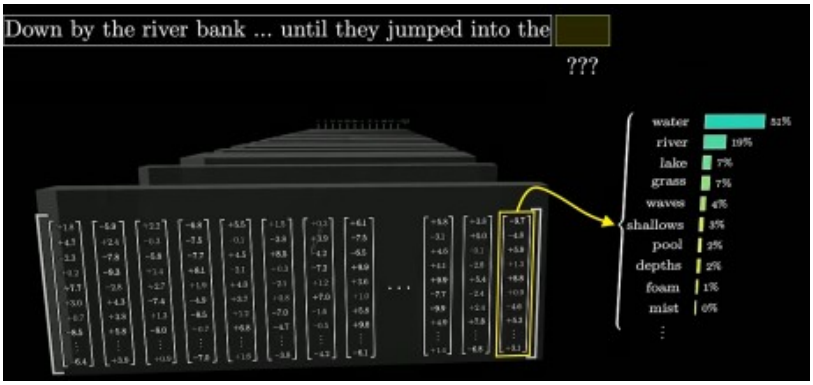

Abbildung 2.6. Visualisierte Gedanken eines Sprachmodells [@lindsey2025]

- **Textplanung:** Bei der Texterstellung plant das Modell mehrere Wörter im Voraus.
- **Paralleles Rechnen:** Für Kalkulationen nutzt das Modell parallele Rechenpfade, die am Ende verbunden werden.
- **Man traue nicht der Selbstkenntnis:** Das Modell erfindet manchmal Argumentationsketten (*motivated reasoning*).
- **Bekanntheit führt zu Halluzinationen:** Wenn das Modell eine genannte Entität „kennt“ (hier: den Namen des Forschers, Karpathy), aber nicht die Antwort auf die Frage (Titel des Fachartikels) führt das zu erfundenen Antworten (die „can’t answer“-Funktion wird unterdrückt).

Claude nutzt einen **gemeinsamen Bedeutungsraum für verschiedene Sprachen** – ein Hinweis auf eine Art „universelle Denksprache“. Claude verarbeitet Informationen in einem sprachunabhängigen, abstrakten Bedeutungsraum. Bei der Frage nach dem „Gegenteil von klein“ in verschiedenen Sprachen (z. B. Englisch, Französisch, Chinesisch) aktivieren sich im Modell dieselben internen Merkmale für „Kleinheit“ und „Gegenteil“, unabhängig von der Eingabesprache. Erst in einem späteren Schritt wird die Antwort in die jeweilige Zielsprache übersetzt. Diese Erkenntnis legt nahe, dass Claude Wissen und Konzepte sprachübergreifend anwenden kann.

Plant das Sprachmodell die Textgeneration? Entgegen der Annahme, dass Sprachmodelle Texte strikt Wort für Wort basierend auf dem unmittelbaren Kontext generieren, zeigt Claude die Fähigkeit, mehrere Wörter im Voraus zu planen. In Aufgaben zur Gedichtgenerierung identifiziert Claude

beispielsweise Reimwörter, bevor es die vorhergehenden Zeilen formuliert. Ein Beispiel: Soll ein Gedicht mit dem Wort „Kaninchen“ enden, wählt Claude dieses Zielwort frühzeitig aus und gestaltet die Zeile so, dass sie darauf hinführt. Diese Fähigkeit zur Vorausplanung deutet darauf hin, dass Claude in der Lage ist, komplexe Textstrukturen zu erstellen, die über einfache Wortassoziationen hinausgehen.

Wie kalkulieren Sprachmodelle? Anthropic hat in seiner Studie zu Claude 3.5 Haiku detailliert untersucht, wie das Modell mathematische Berechnungen intern verarbeitet. Dabei wurde festgestellt, dass Claude bei Aufgaben wie der Addition von Zahlen parallele Rechenpfade nutzt, um zu einem Ergebnis zu gelangen. Claude verwendet zwei Hauptpfade, um Additionen durchzuführen: 1. **Grobabschätzung:** Ein Pfad schätzt das Ergebnis basierend auf den Größenordnungen der Zahlen. 2. **Präzise Berechnung:** Ein anderer Pfad fokussiert sich auf die genaue Berechnung, insbesondere auf die Bestimmung der letzten Ziffer der Summe.

Diese beiden Pfade arbeiten zusammen, um das finale Ergebnis zu erzeugen. Wenn beispielsweise der Pfad für die letzte Ziffer deaktiviert wird, liefert Claude nur eine grobe Schätzung, ohne die genaue Endziffer korrekt zu bestimmen.

Können wir das Modell fragen, wie es zu einem Ergebnis gekommen ist? Eher nicht. Anthropics Studie zeigt, dass das Modell bei komplexen Aufgaben manchmal überzeugende, aber erfundene Argumentationsketten präsentiert. Bei einfachen Berechnungen, wie der Quadratwurzel von 0,64, lassen sich klare interne Rechenschritte nachweisen. Bei schwierigeren Aufgaben, etwa der Berechnung des Kosinus einer großen Zahl, gibt Claude jedoch vor, Berechnungen durchgeführt zu haben, obwohl keine entsprechenden internen Prozesse erkennbar sind. In solchen Fällen konstruiert das Modell plausible, aber unbegründete Erklärungen – ein Verhalten, das als „motiviertes Denken“ bezeichnet wird. Diese Fähigkeit, überzeugend zu argumentieren, ohne tatsächlich die zugrunde liegende Logik zu befolgen, kann für Nutzer irreführend sein. Die von Anthropic entwickelten Interpretationswerkzeuge ermöglichen es, solche untreuen Denkprozesse zu identifizieren, indem sie die tatsächlichen internen Abläufe des Modells sichtbar machen. Dies ist ein wichtiger Schritt, um die Zuverlässigkeit und Transparenz von KI-Systemen zu verbessern.

Was kann zu Halluzinationen führen? Wie wir im oben gezeigten Beispiel sehen, ist den Antworten des Sprachmodells nicht immer zu trauen. Das

LLM verfügt über einen standardmäßig aktiven „Refusal Circuit“, der das Modell dazu bringt, keine Antwort zu geben, wenn es keine ausreichenden Informationen hat. Wenn eine bekannte Entität erfasst wird, aktiviert sich ein konkurrierender „Known Entity“-Mechanismus, der den Refusal Circuit hemmt und eine Antwort ermöglicht. Problematisch wird es, wenn Claude einen Namen erkennt, aber keine spezifischen Informationen dazu hat. In solchen Fällen kann der „Known Entity“-Mechanismus fälschlicherweise den Refusal Circuit unterdrücken, was zu einer Halluzination führt. Ein Beispiel: Bei der Frage nach einem Fachartikel des bekannten Forschers Karpathy gibt Claude einen erfundenen Titel an, da das Modell zwar den Namen kennt, in diesem Fall aber keine Informationen über den Artikel hat. Bei weniger bekannten Namen gibt das Modell an, die Antwort nicht zu kennen (Lindsey et al., 2025).

2.3 Welches Modell wählen?

Was für Sprachmodelle gibt es? Der Markt ist überschaubarer, als die Flut an Produktnamen vermuten lässt. Eine Handvoll großer KI-Labore bietet jeweils eine Modellfamilie an, die sich in wenige Klassen sortieren lässt (s. Abbildung 2.8): Das **Flaggschiff-Modell** ist die jeweils stärkste Variante für anspruchsvolle Aufgaben. Daneben gibt es günstigere **Mini-Varianten**, die weniger Rechenaufwand benötigen und für einfache Routineaufgaben ausreichen. Die Flaggschiffe sind **Reasoning-Modelle**: Sie durchlaufen vor der Antwort intern mehrere Denkschritte und können so auch komplexe Fragestellungen bearbeiten (s. Kapitel 2.4). Schließlich gibt es **offene Modelle**, deren Gewichte frei verfügbar sind, so dass man sie kostenfrei nutzen oder auf eigener Hardware betreiben kann; darunter eines der wenigen europäischen Modelle und die chinesische Konkurrenz (E. R. Mollick, 2025a; sowie Vellum, 2025). Offene Modelle sind in der Regel etwas schwächer als die Flaggschiffe der großen Labore (s. Kapitel 2.4).

Wer einen Blick auf den nächsten Entwicklungsschritt werfen will, dem sei empfohlen, für einen Monat die **agentische Arbeitsumgebung** eines der großen Anbieter zu abonnieren (die teurere Abonnement-Stufe, s. den Kasten unten). Hier lassen sich sehr komplexe Workflows delegieren und z.B. 10 Excel-Dateien für komplexe Fallstudien mit den dazugehörigen Anweisungen, Visualisierungen und Präsentationen in einem Rutsch erstellen (Rogers, 2026).

Welches Sprachmodell sollte man nutzen? Die kurze Antwort: **das Flaggschiff eines der großen Labore**, nicht die Mini-Variante. Welches der drei großen Labore man wählt, ist für die meisten Lehraufgaben weniger wichtig als die Frage, ob man überhaupt die stärkste Variante nutzt (s. Abbildung 2.1). Für den Einstieg reicht das Chat-Interface des jeweiligen Anbieters; die agentischen Arbeitsumgebungen erweitern das Flaggschiff um Werkzeuge und sind für komplexe Delegationen die erste Wahl (E. Mollick, 2026).

Für Lehrende kostenfrei nutzbar sind mehrere institutionelle Zugänge. Zentral für deutsche Hochschulen ist der Dienst „Chat-AI" / Academic Cloud der Gesellschaft für wissenschaftliche Datenverarbeitung Göttingen (GWDG) (https://chat-ai.academiccloud.de/), über den neben einer Reihe offener Modelle auch Flaggschiff-Modelle der kommerziellen Anbieter nutzbar sind. Hier kann man sich einfach mit einer Hochschuladresse registrieren und den Dienst nutzen. Hochschulen bieten teils einen eigenen KI-Zugang an, die TH Köln etwa einen begrenzten Zugang zu einem kommerziellen Chat-Modell und einzelnen offenen Modellen über das THKI-Lab (https://ki.th-koeln.de/login.php). An der TH Köln und weiteren NRW-Hochschulen steht außerdem die Verbundlösung KI:connect bereit, die ähnliche Funktionalitäten bietet (https://kiconnect.pages.rwth-aachen.de/pages/). Bei allen institutionellen Zugängen gilt: Prüfen Sie vor dem Einsatz in der Lehre, welche Modellgeneration dahinter steckt. Ist es eine ältere Generation oder eine Mini-Variante, bekommt man ein ganz falsches Bild von den Fähigkeiten der Modelle und kann auch nicht sinnvoll in der praktischen Nutzung von KI ausbilden.

Weiterhin können Lehrende über die Hochschullizenz Microsoft 365 Copilot herunterladen und dann einen KI-Chat als Desktop-Anwendung nutzen, eine Anwendung, unter deren Haube wiederum Modelle von OpenAI stecken (hier einloggen und einfach herunterladen: https://www.office.com/). Hier kann man Chats speichern und komplexere Anweisungen als „Agenten" entwerfen und teilen.

Diese kostenfreien Lösungen sind seit ihrer Einführung stark ausgebaut worden und sehr nützlich. Sie stellen allerdings i. d. R. nicht den jeweils neuesten Stand der Performanz der KI-Modelle dar. Lehrende sollten daher unbedingt ein bis zwei Monate lang ein Standard-Abonnement bezahlen und auch die stärksten Bezahlmodelle ausprobieren (also das Flaggschiff eines der großen Labore in der Bezahlversion). Nur so erhält man ein Gefühl dafür, was technisch möglich ist und wie „sicher" die

eigenen Prüfungsleistungen sind (z. B. „im Gespräch“ mit der KI über den Sprachmodus, der bei den kostenfreien Zugängen meist abgeklemmt ist).

Stand bei Drucklegung, November 2026

Die folgende Übersicht hält fest, welche Modelle und Zugänge bei Drucklegung die im Text beschriebenen Klassen füllten. Sie ist ein historischer Schnappschuss: Die Namen ändern sich, die Klassen bleiben.

Anbieter	Modellklasse(n)	Typischer Zugang (Chat, API, institutionell)	Hinweis für die Lehre
OpenAI	Flaggschiff GPT-5.2 (Reasoning); Mini-Varianten; Codex-Variante für Programmierung	Chat-Interface ChatGPT (kostenfrei mit Einschränkungen; Abonnement im Bereich von ca. 20 € monatlich); API; institutionell über Academic Cloud, THKI-Lab und Microsoft 365 Copilot	Sprachmodus und Deep Research in der Bezahlversion; eigene „GPTs“ lassen sich als Tutoren teilen
Google	Flaggschiff Gemini 3 Pro bzw. 3.1 Pro (Reasoning, „Deep Think“); Mini-Varianten	Chat-Interface Gemini; API; NotebookLM; in Google Workspace und Google Colab integriert	Sehr große Kontextfenster (bis zu 1 Mio. Token) für ganze Skripte; NotebookLM erzeugt Podcasts und Folien aus eigenen Quellen

Anthropic	Flaggschiff Claude Opus 4.6; mittlere Variante Claude Sonnet 4.6	Chat-Interface Claude; API; agentische Arbeitsumgebungen Claude Cowork und Claude Code (Abonnement-Stufe im Bereich von ca. 90 € monatlich)	Artifacts für interaktive Lernspiele; Skills für komplexe Dokumente; Delegation ganzer Workflows
Meta	Offenes Modell Llama 4	Gewichte frei verfügbar; über Hoster und Hochschuldienste wie Academic Cloud (Auswahl wechselt)	Kostenfrei, aber in der Regel schwächer als die Flaggschiffe
DeepSeek	Offene Modelle (V3.2, R1 als Reasoning-Variante)	Gewichte frei verfügbar; über Hoster und Hochschuldienste	Chinesische Konkurrenz; interessant für den Vergleich kultureller Perspektiven im Output
Mistral	Offene und kommerzielle Modelle (Mistral 3, Medium 3.1)	Chat-Interface und API des Anbieters; Gewichte teils frei verfügbar	Europäischer Anbieter
GWDG und Hochschulen	Wechselnde Auswahl offener und kommerzieller Modelle	Academic Cloud (Registrierung mit Hochschuladresse); THKI-Lab; KI:connect	Vor dem Einsatz prüfen, welche Modellgeneration hinterlegt ist

Die lebende Fassung dieser Übersicht wird online semesterweise aktualisiert.
Die lebende Modellübersicht finden Sie online unter https://th-koeln-bartnik.github.io/genai4teaching/modelluebersicht.html.

Abbildung 2.7. Lebende Modellübersicht, semesterweise aktualisiert: QR-Code scannen oder https://th-koeln-bartnik.github.io/genai4teaching/modelluebersicht.html aufrufen.

Abbildung 2.8. Je nach Ziel ein anderer Platz in der Bestenliste

Quelle: Vellum (2025), Stand August 2025.

Hier kann man vergleichen: In der LM-Arena kann man verschiedene Modelle ausprobieren und ihre Antwort auf eine bestimmte Frage gegenüberstellen: https://lmarena.ai/de?mode=side-by-side (Untermenü: „Arena (side-by-side)“).

2.4 Was können die Modelle – und was nicht?

Was für Aufgaben LLMs beherrschen ist sehr uneinheitlich und **verändert sich dynamisch**. Es gibt Bereiche, in denen KI auf menschlichem Niveau oder besser agiert, und andere, oft nur geringfügig andersartige Aufgaben, an denen die KI (noch) scheitert (Dell'Acqua et al., 2023). Mollick und Kollegen prägen hierfür den Begriff einer „**Jagged Technological Frontier**" (zerklüftete Technik-Grenze) (Dell'Acqua et al., 2023). Zwei Aufgaben von ähnlicher Schwierigkeit für Menschen können mit sehr unterschiedlicher Qualität durch ein LLM gelöst werden – eine liegt innerhalb der KI-Frontier (d. h. die KI kann sie lösen), die andere außerhalb (KI liefert unbrauchbare oder falsche Resultate) (Dell'Acqua et al., 2023).

In einem Experiment mit Consultants wurden 18 verschiedene Beratungsaufgaben gestellt. Für die meisten („inside the frontier") brachte KI enorme Vorteile, doch bei einer gezielt außerhalb der Frontier gewählten Aufgabe schnitt die KI-Gruppe deutlich schlechter ab: Hier waren die Consultants in der Gruppe mit KI 19 Prozentpunkte weniger häufig korrekt als die ohne KI (Dell'Acqua et al., 2023). Dieses Ergebnis unterstreicht die **Gefahr, LLMs unkritisch auf Probleme anzuwenden, die ihre jeweiligen Fähigkeiten übersteigen** – die Leistung fällt dann hinter menschliches Niveau zurück. Praktisch bedeutet die Jagged Frontier, dass Organisationen und Individuen lernen müssen, die Grenze der KI-Fähigkeiten zu erkennen und entsprechend zu navigieren (Dell'Acqua et al., 2023).

Für folgende Anwendungsfälle sind starke Sprachmodelle gut nutzbar (Handa et al., 2025; Korinek, 2024; Schwarcz et al., 2025):

- Zusammenfassung von Fachartikeln
- Fortgeschrittene mathematische Ableitungen
- Anspruchsvolle Codierungsaufgaben
- Erstellen eines Podcasts zu einer Forschungsarbeit
- Erstellen von Präsentationsfolien
- Verfassen von Blogbeiträgen
- Simulieren von Interviews über den Sprachmodus der Chat-Interfaces
- KI-gestützte Suche (mit kritischer Prüfung natürlich)

Die Fähigkeiten der Modelle wachsen rasant und damit werden die Aufgaben, die man an sie delegieren kann komplexer. Die Länge der Aufgaben, die KI Sprachmodelle relativ genau erledigen können, verdoppelt sich seit 2019 etwa alle 7 Monate (Kwa et al., 2025). Auch die Bewertung

von Forschungsarbeiten im Rahmen des Peer-Reviews wird zunehmend teil-automatisiert, etwa durch die automatische Prüfung von Quellen oder Code und Teilbewertungen durch Dienste wie Veracity oder Paper Wizard (Lovely, 2025; Naddaf, 2025).

Ist das ein Mensch, oder ein Bot? Eine Studie von 2025 zeigt, dass Sprachmodelle uns bei dieser Frage **erfolgreich täuschen können** und so den Turing Test bestehen, da sie in einer sozialen Interaktion Menschen erfolgreich imitieren können (Jones & Bergen, 2025). In einem randomisierten Drei-Parteien-Turing-Test mit über 1.000 Spielen wurde ein mit speziellen Eingabe-Anweisungen (Persona-Prompt) versehenes Flaggschiff-Modell der damaligen Generation (GPT-4.5) von den Respondenten zu 73 % für den Menschen gehalten, häufiger als echte Menschen in der Vergleichsgruppe. Weniger komplexe Modelle (wie Llama 3.1) schritten schlechter ab. Die Autoren diskutieren daraus resultierende Risiken von sozialer Manipulation oder Arbeitsplatzsubstitution, sowie die Notwendigkeit robusterer menschlicher Erkennungsstrategien.

Auch durch diesen Fähigkeitsschub ist der **Einsatz von Sprachmodellen in Support-Funktionen wie Call Centern stark gestiegen**, empirische Studien belegen hier einen starken Produktivitätszuwachs (Brynjolfsson et al., 2025).

Die Gründe für die Produktivitätssteigerung von KI-Modellen lassen sich durch **Scaling Laws** (Training Scaling Law, Inference Scaling Law, (E. R. Mollick, 2025a)) beschreiben: KI-Modelle werden einerseits exponentiell besser, je mehr Daten, Rechenleistung und Parameter genutzt werden und andererseits, wenn sie mehr Zeit zum „nachdenken“ erhalten. (Für eine schöne visuelle Beschreibung, s. Grootendorst (2025))

Der erste Zusammenhang (**Training Scaling Law**) besagt, dass größere KI-Modelle mit mehr Parametern und Trainingsdaten systematisch leistungsfähiger werden. Allerdings sind solche Ertragszuwächse mit hohen Kosten verbunden: Eine 10-fache Steigerung an Rechenaufwand führt etwa zu einer Erhöhung der Leistungsmetriken um einen festen Betrag, was abnehmende Grenzerträge andeutet.

Neben dem positiven Effekt der Modellgröße wurde ab 2024 ein zweiter Scaling-Effekt (**Inference Scaling Law**) auf der Anwenderseite deutlich: LLMs liefern bessere Lösungen, wenn man ihnen mehr „**Denkzeit**“ gibt. OpenAI fand heraus, dass ein Modell mit längerer Schritt-für-Schritt-Reasoning-Phase merklich bessere Ergebnisse erzielt, analog zu einem

Menschen, dem man mehr Zeit für eine schwierige Aufgabe gibt. Dieser Inference Scaling Law führte zur Entwicklung von **Reasonern** – KI-Systemen, die bei Bedarf intern zusätzliche Rechenschritte durchführen, um schwierige Probleme genauer zu lösen (Gottweis et al., 2025; OpenAI, 2024; Schwarcz et al., 2025).

Zusammengenommen bedeuten diese Skalierungsgesetze, dass KI-Systeme **durch höheren Ressourceneinsatz (beim Training und bei der Nutzung) immer leistungsfähiger** und vielseitiger werden, wenn auch zu steigenden Kosten. Ökonomisch relevant ist hier vor allem, dass die **Grenzkosten der KI-Nutzung sehr niedrig** bleiben, sobald ein großes Modell einmal trainiert ist: Ist das Modell erstellt, kann es millionenfach eingesetzt werden, was **Skaleneffekte in der Verbreitung** ermöglicht. Somit schafft das Scaling Law die Grundlage dafür, dass **hochleistungsfähige KI als allgemein verfügbares Gut** in Wirtschaft und Bildung eingesetzt werden kann. Durch diese Eigenschaft ermöglicht KI eine schnelle und kosteneffiziente Skalierung personalisierter und adaptiver Lernangebote (E. R. Mollick, 2025a). Dieses exponentielle Wachstum unterscheidet KI grundlegend von bisherigen technologischen Entwicklungen, bei denen Verbesserungen oft linear verliefen.

Die großen Anbieter haben in kurzer Folge **vier Funktionsklassen** eingeführt, die den Einsatz von KI in der Hochschullehre deutlich erweitern: Integrierte **Bildgenerierung** erlaubt fotorealistische Visualisierungen, was z. B. in der technischen Bildung oder bei Designprojekten didaktisch genutzt werden kann. **Audio-Modelle** ermöglichen eine präzise Steuerung von Sprachstil und Tonfall – hilfreich etwa für simulierte Rollenspiele, interaktive Lernbegleiter oder barrierefreie Lerninhalte. **Research-Harnesses** („Deep Research“) erlauben KI-gestützte Rechercheprozesse, die Studierende bei komplexen Projektarbeiten oder der Literatursichtung unterstützen. Und kostengünstigere **Mini-Varianten der Reasoning-Modelle** erleichtern den Zugang zu leistungsfähigen KI-Anwendungen auch in Bildungseinrichtungen. Den Anfang machte OpenAI im ersten Quartal 2025; vergleichbare Funktionen gehören seither zum Standardumfang der großen Chat-Interfaces (s. die Beispiele in Kapitel 1).

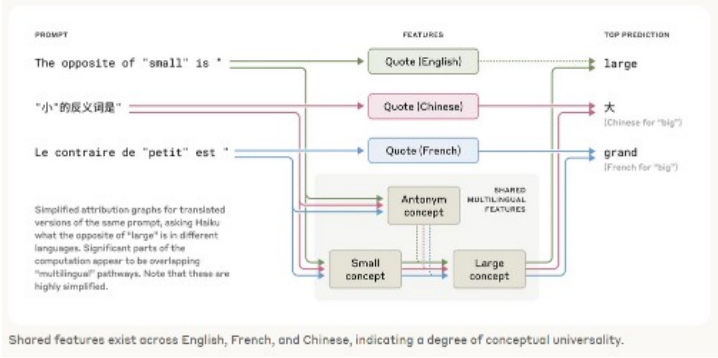

. Quelle: Kwa et al. (2025)

Es lassen sich nach dieser Studie **zwei Kooperationsmodelle zwischen Mensch und LLM** unterscheiden, um die Technologiegrenze optimal auszunutzen (Dell'Acqua et al., 2023): Der **Centaur-Ansatz** teilt die Aufgabe, indem der Mensch der KI die Teilprobleme überlässt, die innerhalb der Frontier liegen, und sich selbst auf den Rest konzentriert. Der **Cyborg-Ansatz** integriert die KI tiefer, indem der Mensch kontinuierlich mit der KI interagiert und Feedback-Schleifen nutzt. Beide setzen implizit voraus, dass der Nutzer um die Stärken und Schwächen des LLM weiß.

Eine spätere Studie des weitgehend selben Teams mit 776 Praktikern bei Procter & Gamble zeigt, dass Individuen mit LLM Unterstützung deutlich produktiver Probleme lösen oder neue Ideen generieren konnten. Das Sprachmodell scheint einen deutlichen Mehrwert als „**Cybernetic Teammate**" zu bringen und Einzelne teils auf das Leistungsniveau von ganzen Teams zu bringen (Dell'Acqua et al., 2025).

Wenn man **ältere oder weniger starke (offene) Modelle nutzt, fährt man mit dem Fahrrad auf der Autobahn**. Vergleiche zeigen von Modellgeneration zu Modellgeneration starke Performanzunterschiede; schon der Sprung von der ersten ChatGPT-Generation zur nächsten war erheblich. Auch die offenen Modelle sind teils deutlich weniger „schlau" als die Flaggschiffe! Hier muss man insofern aufpassen, dass die einfache Verfügbarkeit älterer oder kleinerer Modelle über institutionelle Zugänge nicht zu einem falschen Bild führt.

2.5 Wo und wie spreche ich mit der KI?

2.5.1 Wo sprechen? Verschiedene Zugänge zu Sprachmodellen

Wo sprechen wir mit dem Sprachmodell? Welche Zugänge zur KI gibt es? Es gibt **grob gesagt drei Ansätze**:

1. Die einfache Eingabe in das Chat-Interface des jeweiligen Anbieters ist am leichtesten umzusetzen. Um verschiedene Modelle zu nutzen, muss man sich aber neu einloggen und evtl. ein weiteres Abonnement bezahlen. Die meisten Modelle erlauben aber auch recht umfangreiche kostenlose Nutzung, was meist zum Kennenlernen ausreicht. Für Hochschulen werden zentral nach und nach verschiedene Dienste mit solchen Oberflächen aufgesetzt, die meist aber aus Gründen des Datenschutzes einige Funktionen abklemmen (z. B. meist die direkte Sprachinteraktion und das Speichern von Benutzerprofilen).
2. Nutzung einer Bedienoberfläche wie Witsy oder Typingmind, die Prompts speichert und Agenten erstellen lässt, die mit verschiedenen Modellen funktionieren (Schwarze, 2025). Hier muss man einmalig das System aufsetzen (Witsy) und für den höheren Komfort teils eine Lizenz kaufen (TypingMind, ca. 40 $ für Hochschulangehörige), dafür kann man dann einfacher Modelle wechseln und über einen sogenannten API Key nur die tatsächliche Nutzung abrechnen (was sich bei einfacher Nutzung auf ein paar Cent beläuft, siehe die oben gezeigte Übersicht der Preise pro Millionen Token).
3. Wenn man sich nicht vor etwas Code scheut, kann man auch einfach selbst programmieren (mit KI-Unterstützung in Tools wie Google Colab) und kleine Sprachagenten aufsetzen. (Evtl. dann in Verbindung mit **Replit** für die Online-Bereitstellung und Diensten wie **Voiceflow** für die Oberfläche.) Auch hierfür braucht man eigentlich nur API Keys zur Identifizierung. Fragen Sie das Sprachmodell, wie das geht und lassen sich den Code schreiben, es ist überraschend einfach! Es gibt bei Youtube auch eine Vielzahl von kurzen Erläuterungen.

2.5.2 Wie sprechen? Prompt-Befehle

Wie spreche ich mit dem LLM? In einem modernen Märchen von N.K. Jemisin gibt es gefangene Götter. Sie erfüllen ihren Wächtern jeden Wunsch, sind ihnen aber nicht wohlgesonnen: Eine falsche Formulierung kann so katastrophale Folgen haben. Den Baum, der im Weg liegt, kann man schließlich auch durch einen Vulkanausbruch beseitigen. In dieser neuen Midas-Erzählung wird Präzision zentral. Diesen Tenor finden wir auch in den wichtigsten Empfehlungen zum Prompting: Präzise Anweisungen geben.

Wie das geht, zeigen wir zuerst an einem einfachen Schema. Dann schauen wir uns an, welche Prompting-Strategien die drei großen KI-Labore in ihren Leitfäden empfehlen.

2.5.3 Zentrale Bausteine: Rolle, Aufgabe, Format und Beispiele

Wie beschreibe ich genau, was ich will? Einfache **Daumenregeln für Prompts** gliedern das in vier Schritte: dem Sprachmodell eine **Rolle** zuzuweisen („Du bist Verhandlungsexpertin“), ein klares **Ziel** zu definieren („Du hilfst mir dabei, mich auf Geschäftsverhandlungen vorzubereiten“), es zu bitten, sein **Vorgehen** (den Gedankengang / „chain of thought“) offenzulegen und Schritt-für-Schritt vorzugehen („Erstelle zunächst einen Plan und frag mich nach Feedback. Warte meine Antwort ab und passe den Plan eventuell an. Wenn ich zufrieden bin, beginne mit dem ersten Schritt in deinem Plan.“) sowie **Beispiele** („few shot“) für eine gewünschte Struktur oder Analyse mitzuliefern („Formatiere die Dateinamen in dieser Form [Autor]-[Jahr]-[Kurztitel]“, oder „Gib mir 5 Handlungsoptionen und nenne jeweils Vor- und Nachteile“). Dabei veranlasst die Chain of Thought-Methode das LLM, seine Gedankengänge offen zu legen. Das Modell zeigt seine Überlegungen Schritt für Schritt, was die Nachvollziehbarkeit seiner Antworten verbessert. So können wir auch besser nachsteuern und das Ergebnis an unsere Ziele anpassen.

> **Strukturierten Prompt einfach erstellen lassen**
>
> Wollen Sie sich interaktiv einen ausführlichen, strukturierten Prompt erstellen lassen? Hier finden Sie einen Beispiel-Bot, dem man Prompts füttern kann, die er dann in ein kurzes oder detaillierteres Schema

packt: https://chatgpt.com/g/g-695a8a7c9c888191a683135100f623d0-prompt-strukturierer-rtf-oder-create-format.

2.5.4 Wie Prompten? Was die großen KI-Labore empfehlen

Vor detaillierten Tipps hilft ein Bild (E. Mollick, 2024): Behandeln Sie das Sprachmodell wie eine junge Hilfskraft. Sie wird am Anfang nicht alles richtig machen, sondern muss klar angeleitet werden, so dass die Ergebnisse nach und nach besser werden. Junge Mitarbeiter sind keine Taschenrechner, die sofort perfekt und immer gleich funktionieren. GenAI Chatbots auch nicht. Iterieren und erläutern Sie. Das Ergebnis nähert sich dann Schritt für Schritt dem Wunschbild an. Der Vorteil hier ist, dass die Ergebnisse schon nach wenigen Sekunden vorliegen.

Abbildung 2.9. Empfehlung: Das KI-Modell wie eine junge Hilfskraft behandeln - nach und nach anlernen, klar anweisen

Quelle: Erstellt mit Gemini 3 Pro, basierend auf E. Mollick (2024).

Was empfehlen Prompt-Profis im Detail? Die drei führenden KI-Labore haben 2025 ausführliche Leitfäden veröffentlicht, wie wir mit ihren jeweiligen Modellfamilien reden sollen (Anthropic, 2025a; Google, 2025; Kotha et al., 2025). Die Empfehlungen sind recht ähnlich und es lohnt sich, sie hier kurz zu referieren.

Die drei führenden Anbieter betonen die Bedeutung von **Präzision der Anweisungen** - wenig überraschend, aber im Detail nicht einfach zu bewerkstelligen: Vorab die vielleicht wichtigste, wenn auch banale Empfehlung: Es hilft, **genau zu sagen, was man eigentlich will**. Wie bei einem Bauprojekt, muss man sich bei vagen Anweisungen nicht wundern, wenn das Haus nachher anders aussieht als gewünscht.

(1) Aufgaben präzise beschreiben: Man sollte nicht auf den Hiwi schimpfen, wenn man sich nicht die Zeit genommen hat, zu sagen, was eigentlich die Aufgabe ist! Die immer schlaueren Bots brauchen klare Anweisungen ohne innere Ungereimtheiten oder vage Formulierungen.

(2) Beispiele helfen der KI, nicht nur Einzelwünsche sondern den breiteren Kontext zu berücksichtigen - genau wie man das von einem guten Butler gerne hätte. Positiv-Beispiele sind dabei besser als Negativbeispiele („gib mir…"/„bemühe dich um…" ist besser als „gib mir nicht" / „vermeide…") (Google, 2025). Man sollte nicht zu viele Beispiele geben, sonst kann es passieren, dass sich das LLM zu stark an diesen orientiert und den Suchraum einengt.

(3) Ordnung macht hier Meisterschaft: durch klare Strukturierung des Textflusses durch sogenannte [Tags]. Ob solche 'Post-it-Notizen' für die Bots in eckigen Klammern oder mit größer/kleiner Zeichen als markiert sind, ist dabei nicht wichtig, es muss nur einheitlich sein.

(4) Zunehmend wird bei einer interaktiven Form der Zusammenarbeit mit dem Sprachmodell der Weg zum Ziel. Prompten wird hier zum iterativen Prozess, in dem die Interaktion den eigentlichen Mehrwert bietet, da nach und nach mit dem Sprachmodell ein Lösungsweg erarbeitet wird. Dies verlangt eine deutlich andere Herangehensweise als Werkzeuge wie Taschenrechner, von denen wir erwarten, dass sie sofort eine Lösung ausspucken.

(5) Agenten erfordern neue Verhaltensweisen. Da die Zeitspanne des autonomen Handelns immer breiter wird, in denen Sprachmodelle selbstständig suchen, bewerten und zusammenfassen können, müssen wir sie auch anders steuern. Zweitens gewinnt die Frage an Bedeutung, wieviel Eigenständigkeit wir uns von dem Bot denn wünschen. OpenAI nennt dies in seinem Leitfaden „Eagerness-Kalibrierung" (Kotha et al., 2025). Bei solchen mehrstufigen, längeren Prozessen müssen wir auch über das 'Gedächtnis' des Agenten-Bots

nachdenken. Im Detail wird hier etwa empfohlen, den Agenten seine Zwischenergebnisse ('states') in hoch strukturierter Form ablegen zu lassen (im JSON-Format etwa, das sozusagen markierte Schubladen für die Daten bereitstellt) und kurze nummerierte Zwischennotizen im Fließtext zu erfragen („Im letzten Schritt habe ich folgende Updates an dem Text vorgenommen...") (Anthropic, 2025a). Wir sehen, dass hier die Empfehlungen schon stärker in Richtung der Führung von Mitarbeitern gehen, eine Konsequenz der wachsenden Selbstständigkeit dieser 'cybernetic teammates' (Dell'Acqua et al., 2025).

(6) Bots help bots: Die Sprachmodelle können uns dabei helfen, mit ihnen zu sprechen. So können wir mit dem Tool das Tool bedienen. Das kann man schon mit einfachen Prompts tun (s. den folgenden Einschub-Kasten), oder mit eingebauten Tools der Sprachmodelle, wie dem Prompt-Optimierer von OpenAI (Kotha et al., 2025) oder mit einem eigenen Prompt, der das Sprachmodell anweist, eine Anweisung in ein bestimmtes Muster zu packen.

Unzufrieden mit dem Ergebnis? Was, wenn der 'Lieferant' Sprachmodell mal nicht wie gewünscht liefert? Kotha et al. (2025) empfiehlt: Gleich reklamieren (s. der folgende Kasten)!

Meta-Prompts: Den Bot den Prompt verbessern lassen

Probleme mit dem Prompt? OpenAI (Kotha et al., 2025) schlägt vor, man soll mit einer klaren Problembeschreibung wie folgt prompten: Hier ist ein Prompt: [PROMPT EINFÜGEN] Das gewünschte Verhalten dieses Prompts ist, dass der Agent [GEWÜNSCHTES VERHALTEN BESCHREIBEN] ausführt, stattdessen führt er jedoch [UNERWÜNSCHTES VERHALTEN BESCHREIBEN] aus. Wie würdest Du die Eingabeaufforderung möglichst unverändert lassen und dennoch minimale Änderungen/Ergänzungen vornehmen, um den Agenten dazu zu bewegen, diese Mängel konsequenter zu beheben?

2.5.5 Es könnt' alles so einfach sein! Es bringt nichts, Bots zu bedrohen oder zu bestechen.

Die Bots zu bedrohen, bringt nichts. Empirische Untersuchungen haben mehrere anekdotische Geheimtipps des Promptings systematisch geprüft und meist widerlegt. Prompts funktionieren nicht immer gleich und **so kommt es schnell zu anekdotischer Evidenz,** dass eine Formulierung „besser geklappt" hätte.

Die wenigsten der folgenden Hausrezepte helfen zuverlässig (Meincke et al., 2025b, 2025a, 2025c): Hilft es, höflich zu sein (nein), zu drohen (nein), Geld anzubieten (nein), oder den Hiwi-Bot Schritt für Schritt vorgehen zu lassen (ja, aber das machen die neueren Reasoning-Sprachmodelle auch selbst)?

Auch hier sehen wir, dass die **stärkeren neueren Modelle auch etwas andere Bedienung erfordern.** Wie ein neuer Sportwagen kommen **mit den größeren Fähigkeiten auch neue Anfälligkeiten**: Die neuen Modelle können selbst iterativ vorgehen, das muss man ihnen nicht mehr empfehlen. Tut man es doch, sinkt teils die Performanz (Meincke et al., 2025a), etwa wenn man so verhindert, dass ein starkes Modell eine Frage aus seinem Vorwissen beantwortet und es stattdessen zu mehreren - eigentlich unnötigen - Denkschritten mit entsprechendem Token-Verbrauch zwingt). Da sie schlauer sind, werden sie durch unpräzise Anweisungen teils schneller aus der Bahn geworfen. Die Modelle halten sich genauer an Anweisungen - aber eben auch an falsche (Anthropic, 2025a; Google, 2025).

2.5.6 Was heißt das für Prompts in der Lehre?

Didaktische Prompts sollen den Studierenden das Leben gezielt schwer machen. Für die Lehre wollen wir den Prompts speziell didaktische Elemente hinzufügen, also etwa verhindern, dass den Studierenden sofort eine Lösung ausgegeben wird, da das eigene Nachdenken in Form von Fragen und sokratischem Dialog ihnen dabei hilft, die Ergebnisse auch zu behalten (Roediger & Pyc, 2012). Hier müssen wir also teils bewusst Hürden einführen, die die Studierenden zum Nachdenken, diskutieren und überlegen anregen. Wie das geht, sehen wir in den nächsten zwei Hauptkapiteln. Eine Vielzahl konkreter Beispiele von Prompts und

didaktischer Aufgabenstellungen mit GenAI Tools finden Sie im Appendix (s. Anhang B).

2.6 Exkurs: Wie steht es mit dem Ressourcenverbrauch der Modelle?

Studierende fragen regelmäßig nach dem Energiehunger der KI, und zwischen den Polen „Weltuntergang durch KI-Energiehunger“ und „keinerlei Problem“ lohnt ein Blick auf die Größenordnungen. Eine einzelne Textanfrage ist billig: Schätzungen von 2025 liegen zwischen 0,3 Wattstunden für ein großes Chat-Modell und 0,03 Wattstunden für kleine Modelle, also etwa so viel wie zehn Sekunden Video-Streaming (Elsworth et al., 2025; O'Donnell & Crownhart, 2025; You, 2025). Teuer sind die komplexen Aufträge: Ein hochwertiges Video von fünf Sekunden kann rund eine Kilowattstunde kosten, so viel wie eine Stunde Mikrowelle, und weil die Nutzerzahlen schneller wachsen als die Effizienz, übersteigt der Energiebedarf der Anfragen inzwischen den des Trainings (O'Donnell & Crownhart, 2025; Spencer & Singh, 2025). Rechenzentren und KI machten 2024 nach Schätzungen der IEA nur drei bis fünf Prozent des globalen Energieverbrauchs aus, weit weniger als Gebäude, Industrie und Verkehr (Ritchie, 2024; Spencer & Singh, 2024); die Sorge der Analysten gilt der Prognose, nach der sich der Verbrauch der Rechenzentren bis 2030 verdreifachen und KI bis 2028 mehr als zwölf Prozent des US-Strombedarfs beanspruchen könnte, oft aus fossilen Quellen (O'Donnell & Crownhart, 2025; Spencer & Singh, 2025). Die Forderung an die Anbieter lautet deshalb Transparenz über ihren Energiebedarf, damit Politik und Nutzer die Kosten abschätzen und steuern können (O'Donnell & Crownhart, 2025). Für die Lehre heißt das: Eine Seminarsitzung mit Chat-Nutzung fällt energetisch nicht ins Gewicht; wer Bilder, Videos oder lange Agentenläufe erzeugen lässt, sollte das wissen und gegenüber den Studierenden benennen.

Der vollständige Exkurs mit Rechenbeispielen, Quellen und laufend aktualisierten Zahlen steht online unter https://th-koln-bartnik.github.io/genai4teaching/energie.html.

Abbildung 2.10. Exkurs „Ressourcenverbrauch der Modelle", Online-Fassung: QR-Code scannen oder https://th-koln-bartnik.github.io/genai4teaching/energie.html aufrufen.

Kernaussagen

1. Ein Sprachmodell sagt das nächste Wort voraus. Aus Tokens, Embeddings und Attention entsteht Text, der plausibel klingt, aber keine eingebaute Wahrheitsprüfung hat.
2. Kontext entscheidet über Nutzen: Ein Modell allein antwortet aus dem Trainingswissen, mit RAG bekommt es ein Bücherregal, als Agent einen Werkzeugkoffer. Für die Lehre ist meist das Setup mit eigenem Material der richtige Einstieg.
3. Halluzinationen sind kein Betriebsunfall, sondern folgen aus der Funktionsweise. Gegenmittel sind Eingrenzung des Inputs, Musterlösungen und systematische Prüfung.
4. Die Fähigkeiten der Modelle bilden eine zerklüftete Grenze. Wer sie nicht kennt, wird mit KI schlechter als ohne.
5. Gute Prompts sind präzise, strukturiert, mit Beispielen und iterativ. Höflichkeit, Drohungen und Trinkgeld ändern nichts; wer das Modell wie eine junge Hilfskraft anleitet, kommt weiter.
6. Der Energieverbrauch einer einzelnen Anfrage ist gering, der Gesamtbedarf der Infrastruktur wächst stark. Beides stimmt, und die Steuerung ist eine politische Aufgabe.

Zum Weiterdenken

1. Ein Studierender fragt Sie, warum der Chatbot eine Quelle erfunden hat, die es nicht gibt. Erklären Sie es ihm in drei Sätzen ohne die Wörter „Token“ und „Wahrscheinlichkeit“, dann noch einmal mit.
2. Nehmen Sie eine typische Aufgabe aus Ihrer Lehre und spielen Sie durch: Was antwortet ein reines Sprachmodell, was ein Modell mit Ihrem Skript als Material, was ein Agent mit Internetzugang? Wo liegt jeweils das Risiko?
3. Welche Aufgabe in Ihrem Fach liegt vermutlich außerhalb der Jagged Frontier? Wie würden Sie das prüfen, bevor Sie Studierende damit arbeiten lassen?

3 Didaktische Ziele und Mechanismen

Lernziele

Nach diesem Kapitel können Sie …

- erklären, warum wirksame Lehrmethoden an Hochschulen bekannt, aber selten umgesetzt sind, und welche Rolle situative Barrieren wie Zeitmangel spielen;
- begründen, warum Chatbots ohne didaktische Bremsen dem Lernen eher schaden, mit Bezug auf erwünschte Schwierigkeiten, kognitive Belastung und Wachstumsdenken;
- die drei Wissensstufen nach Hattie (knowing that, knowing how, knowing with) unterscheiden und je Stufe einen passenden KI-Einsatz nennen;
- die drei Lerntechniken verteiltes und gemischtes Lernen, testgestütztes Lernen und fragebasierte Ausarbeitung beschreiben und erklären, wie Sprachmodelle deren Vorbereitungsaufwand senken;
- die ICAP-Rangfolge (interaktiv vor konstruktiv vor aktiv vor passiv) auf die Gestaltung von KI-gestützten Lernaktivitäten anwenden.

3.1 Was für Ziele verfolgen wir mit dem Einsatz von GenAI in der Lehre?

Bevor wir uns der konkreten Umsetzung zuwenden, müssen wir uns zunächst fragen, was wir überhaupt bezwecken: Was sind typische Probleme und was sind unsere Ziele für die konkrete Umsetzung in Lehrsituationen?

Schauen wir uns zunächst ein zentrales Problem der Lernsituation an Hochschulen an Roediger & Pyc (2012): **Wir wissen, was effektive**

Formen der Lehre sind, diese werden jedoch häufig nicht angewendet. Studien deuten darauf hin, dass dies eher an situativen Hindernissen der Lernumgebung liegt als am Willen der Lehrenden (Henderson & Dancy, 2007).

Ein Beispiel ist die **Vorlesung**. Es ist gut belegt, dass diese Form des passiven Konsums eine sehr schwache Form der Wissensvermittlung ist. **Man lernt nicht nichts, aber anders würde man mehr lernen.** Empirisch und theoretisch ist sehr gut belegt, dass Studierende Wissen besser behalten, wenn sie dieselbe Zeit für aktives Üben, Frage-Antwort Interaktionen oder Diskussion in Kleingruppen verwenden (S. Freeman et al., 2014; Hake, 1998).

Praktisch wird oft mit dem positiven Effekt der reinen Anwesenheit argumentiert (besser als wenn die Studierenden zu Hause Netflix schauen; wer zur Vorlesung kommt hat bessere Noten), aber **diese spezielle Form der Präsenzlehre hat durch mangelnde Interaktion klare Nachteile.** Der Harvard Physiker Kestin et al. (2025) fasst drei zentrale Probleme von Vorlesungen zusammen: Mangelnde Anpassung, mangelndes individuelles Feedback und mangelnde Aktivierung der Lernenden. Genauer (Kestin et al., 2025, S.2–3): "1. They move too quickly for some students and too slowly for others because the teacher controls the pace of instruction; 2. Students do not receive personalized feedback to their questions as they arise; and 3. They fail to maintain consistent student engagement."

Warum werden trotzdem Vorlesungen sehr häufig und aktivere Lehrformen relativ selten eingesetzt (Stains et al., 2018)? Studien deuten an, dass es oft nicht am Willen der Lehrenden liegt, sondern dass **situative Hindernisse** eine große Rolle spielen, vor allem Zeitmangel wird sehr häufig in Umfragen genannt (Shadle et al., 2017), außerdem bremsen Faktoren wie Gruppengröße oder ein ungünstiger Setup der Räume (Henderson & Dancy, 2007). Auch erfolgt die **Umsetzung oft zu optimistisch und ohne Berücksichtigung von Widerständen und Hindernissen** (z.B. Anreize für Studierende, zu Gruppenübungen auch zu kommen, oder nicht lieber ihr Wochenende in Kleingruppen zu besprechen als die Übungsaufgabe), so dass z.B. mangels notwendiger Anreizsetzung die erhoffte Lernwirkung ausbleibt und schnell Frust bei der Umsetzung entsteht (Henderson & Dancy, 2007).

Wir argumentieren hier, dass GenAI **helfen kann, solche situativen Barrieren zu verringern,** speziell das häufig genannte **Zeitproblem** bei der

Umsetzung effektiver Lehrmethoden (Shadle et al., 2017). Bei sorgfältiger Umsetzung könnte GenAI so als "Kraftverstärker" für Lehrkräfte dienen (E. R. Mollick & Mollick, 2023a), indem es die Implementierung evidenzbasierter Lehransätze erleichtert, die sonst aufgrund von Zeit- und Arbeitsaufwand oft schwer umzusetzen sind.

Auch hier gibt es allerdings nichts umsonst: Die **neuen Tools haben ihre eigenen Risiken und Nebenwirkungen** und **der Aufwand für Anpassung und Umsetzung** darf nicht unterschätzt werden. Einfach Sprachmodelle ohne Anpassung und didaktische 'Bremsen' einzusetzen ist oft nicht sinnvoll. Wie wir in der weiteren Diskussion sehen werden, nehmen sonst die KI-Chatbots den Studierenden erwünschte Schwierigkeiten ab (*desirable difficulties*), ermuntern sie nicht dazu, selbst Informationen abzuwägen, das eigene Verständnis zu vertiefen und so den eigenen Fähigkeitsstand aktiv zu verbessern (*growth mindset*) oder überfordern die kognitive Aufnahmefähigkeit der Lernenden durch Wissens-Dumps (*cognitive load*). Werden die Sprachmodelle nicht dazu angehalten, klar zu sagen, wenn sie zu etwas keine Informationen haben, so können sie die Lernenden durch überzeugend vorgetragene Halluzinationen oder Fehlschlüsse in die Irre führen. Um effektiv zu sein, müssen GenAI Lernhilfen insofern didaktisch gebremst, themenspezifisch angepasst und systematisch erprobt werden (Kestin et al., 2025):

```
"AI chatbots are generally designed to be helpful, not
  to promote learning. They are not trained to follow
  pedagogical best practices (e.g., facilitating
  active learning, managing cognitive load and
  promoting
a growth mindset) (...) . Another well-known flaw of AI
  tutors is their uncanny confidence when giving an
  incorrect answer or when marking a correct reply as
  incorrect [@kestin2025]."
```

Die nächsten Abschnitte geben eine theoriegestützte Orientierung, wie solche Anpassungen erfolgen könnten und welche Mechanismen die Lernforschung als besonders effektiv herausstellt. Zunächst führen wir zur genaueren Zielbestimmung Kategorien von Wissen und Lernmethoden ein. Dann können wir im Detail diskutieren, für welche Ziele und Methodenwahl welche Art der Unterstützung geeignet ist.

3.2 Wissenstypen

Hattie (2023, S.358, 340ff.) unterscheidet drei Stufen des Lernens (s. Tabelle 3.1).

Zunächst geht es um **„knowing that“**, also das reine **Fakten- und Begriffswissen**, das erworben und dann gefestigt werden muss: Hier soll eine belastbare Wissensbasis entstehen, weshalb Lehrkräfte häufig Vorwissensaktivierung oder Drill-and-Practice einsetzen und durch unmittelbares Feedback die korrekte Erinnerung verankern.

Darauf baut **„knowing how“** auf, das **prozedurale und strategische Können**. Auch hier müssen Abläufe zunächst erworben und dann gefestigt werden. Lernende erwerben Prozesswissen, indem sie modellierte Beispiele studieren, in gelenkten Übungen selbst anwenden und mithilfe von „worked examples“ sowie Fehleranalysen Schritt für Schritt ihre Vorgehensweisen optimieren. Festigen können Lernende dieses Prozesswissen besonders gut durch Interaktion oder Wettbewerb mit anderen Lernenden, da diese Auseinandersetzung ihnen dabei hilft, verschiedene Nutzungskontexte zu vergleichen (Chi et al., 2018).

Die höchste Stufe nennt Hattie **„knowing with“**: Wissen wird flexibel **auf neue Situationen übertragen**. Problembasiertes Lernen, authentische Fallstudien, bewusste Reflexionsphasen und kooperativ angelegte Projekte helfen dabei, Konzepte in unbekannten Kontexten sicher anzuwenden und weiterzuentwickeln.

Wo können wir neue technische Hilfsmittel wie LLMs zur Unterstützung dieser Methoden besonders effektiv einsetzen?

Kategorie	Phase	Typische Methoden
Wissen, dass („Knowing that“)	**Erwerben**	Notizen zusammenführen; Zusammenfassen; Heft-/Notizbuch-Durchsicht; Bildhafte Notizen

Kategorie	Phase	Typische Methoden
Wissen, dass („Knowing that“)	**Festigen**	Argumente prüfen; Fehler identifizieren; Einschränkungen formulieren; Formale Argumentstrukturen darstellen; Belege liefern; Durchgearbeitete Beispiele
Wissen, wie („Knowing how“)	**Erwerben**	Aufgabenüberarbeitung; Häufiges Üben; Übungseinheit vor Tests; Zweispaltige Notizen; Problemorientiertes Lernen
Wissen, wie („Knowing how“)	**Festigen**	Peer-Feedback / Peer-Response-Gruppen; Peer-Tutoring; Studierenden-Turniere; Think-Pair-Share; Kumulative Wiederholung
Wissen anwenden („Knowing with“)	**Transfer**	Sortieren, Zuordnen, Kategorisieren; Dichotome Schlüssel; Von Studierenden erstellte Klassifikationsmuster; Klassifikationsdiagramme

Tabelle 3.1. Methoden nach Wissenstyp: Fakten, Prozess und Transfer. Quelle: Basierend auf Hattie (2023), S. 358, 340ff.

3.3 Anwendungsbeispiele nach Wissenskategorien

Zur Unterstützung des **Aufbaus von Faktenwissen („knowing that“)** können starke LLMs gut grundlegende Konzepte erklären (Korinek, 2024, S.48) und zum Selbststudium komplette Abruf-Übungen erzeugen: Sie formulieren Multiple-Choice- und Kurzantwortfragen, bewerten die Eingaben sofort und erklären fehlerhafte Distraktoren – ein Verfahren, das in einer STEM-Untersuchung zur automatischen Item-Generierung überzeugende Validitätswerte zeigte (Säuberli & Clematide, 2024).

Ebenso lassen sich sehr schnell Definitionen, Paraphrasen oder Mini-Zusammenfassungen erzeugen, was personalisierte Glossare ermöglicht (Chen et al., 2024). S. Wang et al. (2024) sprechen von KI als „Confusion Helper“. Um Halluzinationen zu vermeiden, wird das Modell häufig per Retrieval-Augmentation an externe Wissensbasen gekoppelt (also z. B. durch Beigabe von Skripten oder Fachartikeln als PDF. Siehe auch das Harvard-Tutor-Bot Beispiel in Abschnitt 4.3, wo Musterlösungen beigegeben werden.).

Zur **Festigung von Prozessen und Strategien („knowing how“)** dient das LLM als dialogischer Coach: Feingranulierte Prompts („Erkläre den Beschaffungsprozess in 5 Schritten und stelle nach jeder Stufe eine Kontrollfrage“) steigern die Lösungswahrscheinlichkeit in Tutorendialogen (Scarlatos et al., 2025). Sprachmodelle können Lehrenden dabei helfen, komplette „worked examples“ mitsamt Zwischenschritten zu generieren (Hassany et al., 2024).

Angepasste Sprachmodelle können Lernende zur Selbstkorrektur anleiten. Umso besser geht das, wenn das Sprachmodell **fachspezifische Lerntheorien** kennen (z.B.: typische Englischfehler von Deutschen oder typische Verhaltensfehler bei Verhandlungen oder beim Feedback-Gespräch im sozialen Bereich) und **die individuelle Lernhistorie** - sie also wissen, in welche Fallen ich als Lernender gerne tappe. Zhang et al. (2025) demonstrieren dies am Beispiel eines selbst entwickelten multimodalen **Mathematik-Tutor-Bots** (MathCCS, Mathematical Classification and Constructive Suggestions).

Der **Teachable-Agent-Ansatz** nutzt umgekehrt das Lernen-durch-Lehren-Prinzip: Studierende bringen dem LLM eine Methode bei und reflektieren dabei ihre eigene Strategie. Dies basiert auf der Annahme, dass Interaktionen besonders effektiv zum Lernen beitragen (Chi et al.,

2018; Hayashi et al., 2025). Wie auch in der persönlichen Interaktion scheint hierbei wichtig zu sein, welche „Persönlichkeit" der KI-Bot hat, dem Studierende etwas beibringen sollen (Lyu et al., 2025) und mehr Anstrengung in der Interaktion (etwa durch ausführlicheres Formulieren beim Erklären) führt zu mehr Lernerfolg (Love et al., 2025).

Sprachmodelle können genutzt werden, um komplexe (mathematische) Anwendungsprobleme mit einem simulierten User **„durchzuspielen",** so dass **logische Fehler im Lösungsprozess sichtbar werden,** wie der Prototyp „MathChat" von Y. Wu et al. (2023) zeigt. Meta-Analysen zeigen starke positive Lerneffekte, deuten aber auch auf mögliche Einschränkungen hin. So gibt es Anzeichen dafür, dass die Effekte höher für Studierende sind als für Schüler und möglicherweise schwinden Motivationsschübe durch **abnehmende 'novelty effects'** einfacher Chat-Interfaces über die Zeit der Nutzung. Die Autoren der Metastudie empfehlen, hier mit stärkerer **Gamifizierung und Personalisierung** der Chatbots gegenzusteuern (R. Wu & Yu, 2024), was sich mit praktischen Ansätzen etwa von Duolingo deckt (Kazu & Kuvvetli, 2025) (z. B. Gamifizierung durch Streaks und Leaderboards, Challenges, Video-Chats mit dem Emo-Teen Lili usw.). Solche aufwändigen Setups sind im Hochschulkontext natürlich schwieriger abzudecken, ließen sich aber vielleicht graduell als Studierendenprojekt entwickeln?

Für **Transfer und Anwendung („knowing with")** entwirft das LLM realitätsnahe Szenarien – etwa Rollenspiele zu Lieferantenausfällen – und übernimmt Stakeholder-Rollen, wobei Analysen des Brookings-Instituts das Potenzial für kollaboratives Reasoning hervorheben (Korinek, 2024). Cross-Domain-Prompts fördern Analogiebildung („Welche Parallelen bestehen zwischen agilem Projektmanagement und Lean-Procurement?") (E. R. Mollick & Mollick, 2023a).

In Gruppenarbeiten funktioniert das Modell als Co-Autor: KI-unterstützte Schreibprozesse können die Menge und Vielfalt der Ideen steigern (Meincke et al., 2024; Shaer et al., 2024). Auch hier ist jedoch die sorgfältige Gestaltung des Lernprozesses wichtig, so dass nicht erwünschte Schwierigkeiten an die KI delegiert und so kritische Denkprozesse nicht eingeübt werden (H.-P. H. Lee et al., 2025).

3.4 Effektive Lerntechniken und Unterstützung mit KI

3.4.1 Wie lernen wir besonders effektiv?

In diesem Abschnitt verdeutlichen wir kurz die angestrebten Wirkmechanismen mit Fokus auf drei Lehrtechniken, die die Kognitionswissenschaft als besonders effektiv heraushebt (siehe Mörth et al. (2021) für eine gute deutschsprachige Übersicht).

Die moderne Lernforschung der Kognitionspsychologie stellt drei Gruppen von Techniken als besonders gute Kombination zwischen Effektivität und einfacher Anwendung heraus: **Verteiltes und gemischtes Lernen**, **testgestütztes Lernen** und **fragebasierte Ausarbeitung** (Dunlosky et al., 2013; Mörth et al., 2021; Roediger & Pyc, 2012). Diese Wirkung gibt es allerdings nicht umsonst: Den positiven Effekten der Techniken steht oft ein deutlich höherer Vorbereitungsaufwand gegenüber. Wie im Folgenden kurz skizziert wird, lassen sich KI-Tools nutzen, um den Aufwand dieser drei Mechanismen zu verringern, was die Lernwirkung im Vergleich zu traditionellen Ansätzen deutlich erhöhen kann.

Zeitliche Verteilung und inhaltliche Mischung von Lerninhalten (Spacing & interleaving): Diese Technik basiert auf dem Prinzip, dass Informationen besser behalten werden, wenn das Lernen über die Zeit verteilt und in verschiedenen Kontexten stattfindet, anstatt in einer einzigen, intensiven Sitzung (Brown et al., 2014; Murre & Dros, 2015; Roediger & Pyc, 2012).

Abstände zwischen Lerneinheiten und die wiederholte Aktivierung von Wissensstrukturen stärken die Verbindung zwischen Hinweisreizen und Gedächtnis und geben dem Gehirn Zeit, Erinnerungen effektiv zu speichern. Dies fördert die Langzeiterinnerung, denn der wiederholte Abruf verstärkt die gespeicherten Muster und vertieft sie so.

Quelle: Erstellt mit Gemini 3 Pro, basierend auf Roediger & Pyc (2012).

Weiterhin hilft es, zu „mischen“: **inhaltlich gemischtes Üben** (*interleaving*) ist effektiver als die isolierte Behandlung von Themenblöcken, die linear im Semesterverlauf abgehandelt werden (Mörth et al., 2021). Das liegt daran, dass das gemischte Üben die Unterscheidung zwischen verschiedenen Aufgabentypen fördert, was entscheidend für die spätere Anwendungskompetenz ist. Nur durch den geübten Vergleich verschiedener

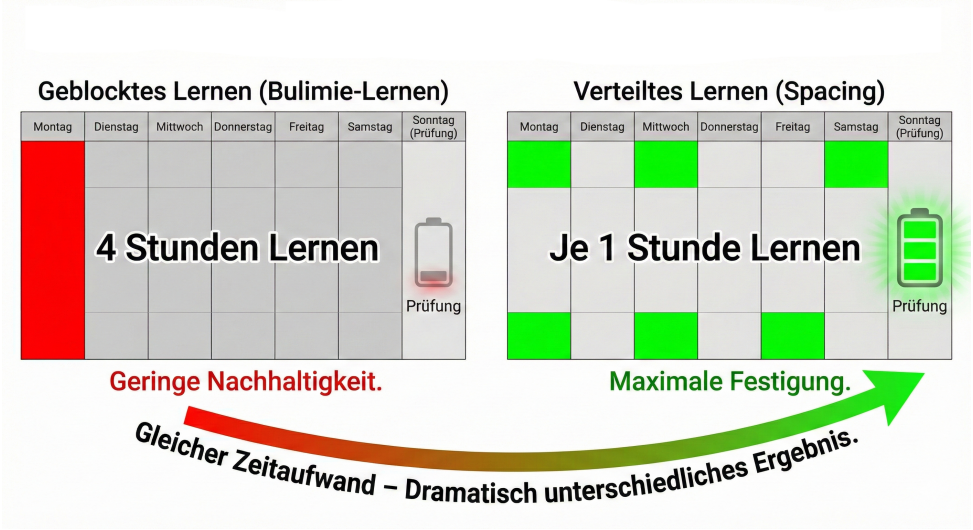

Abbildung 3.1. Illustration Zeitlich verteiltes Lernen – spacing

Kombinationen von Anwendungskontexten und Lösungsansätzen kann ein Gefühl dafür ausgebildet werden, welches Werkzeug zu welchem Problem passt. Fallstudien und Simulationen bieten sich hier an, wenn diese ausreichend komplex sind, um bekannte Analysen in neuen Kontexten anzuwenden und neue einzuführen.

Testgestütztes Lernen (Test-enhanced learning): Das Abrufen von Informationen durch Tests fördert das Langzeitgedächtnis deutlich stärker als das erneute Lesen des Stoffes. Für Studierende ist das anstrengender, es bringt aber deutlich mehr (Brown et al., 2014). Ein ‚Test' kann dabei auch die Bearbeitung von Lerninhalten im Rahmen einer Fallstudie, die kritische Bewertung potenziell falscher Aussagen eines LLMs oder die Beantwortung von Verständnisfragen im Dialog mit einem Tutor-Bot sein.

Quelle: Erstellt mit Gemini 3 Pro, basierend auf Roediger & Pyc (2012).

Häufige Aktivierung von Lerninhalten durch Fragen verbessert den Lernerfolg durch mehrere Mechanismen (Roediger & Karpicke, 2006). Erstens fördert solches Testen das **transfergerechte Verarbeiten**, da die mentalen Prozesse beim Testen und beim späteren Abrufen ähnlich sind, was die Erinnerungsfähigkeit verbessert. Zweitens stärkt die Wiederholung durch Tests einerseits den erinnerten **Inhalt** und fügt andererseits **neue ‚Haken'** hinzu, mit denen wir den Inhalt aus dem Gedächtnis ziehen: die

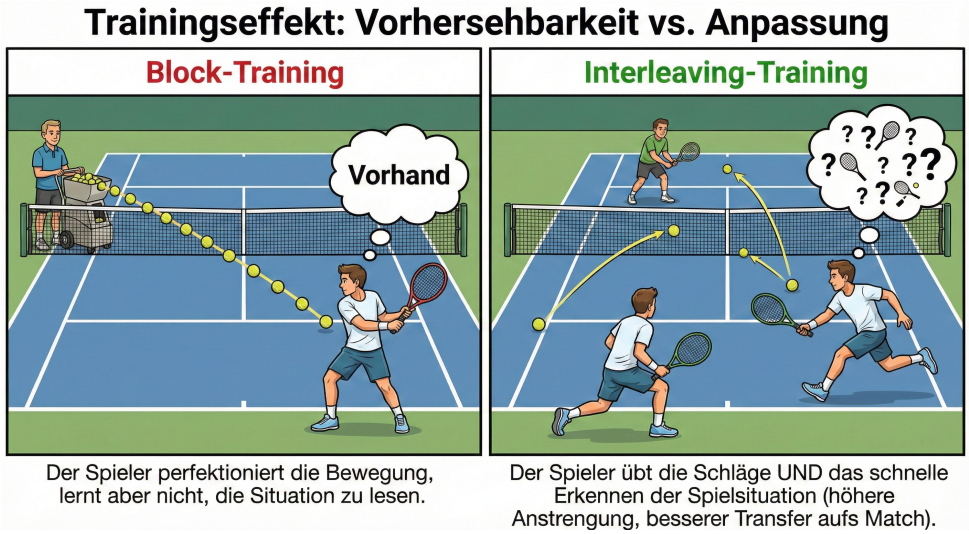

Abbildung 3.2. Illustration Inhaltlich gemischtes Lernen – interleaving

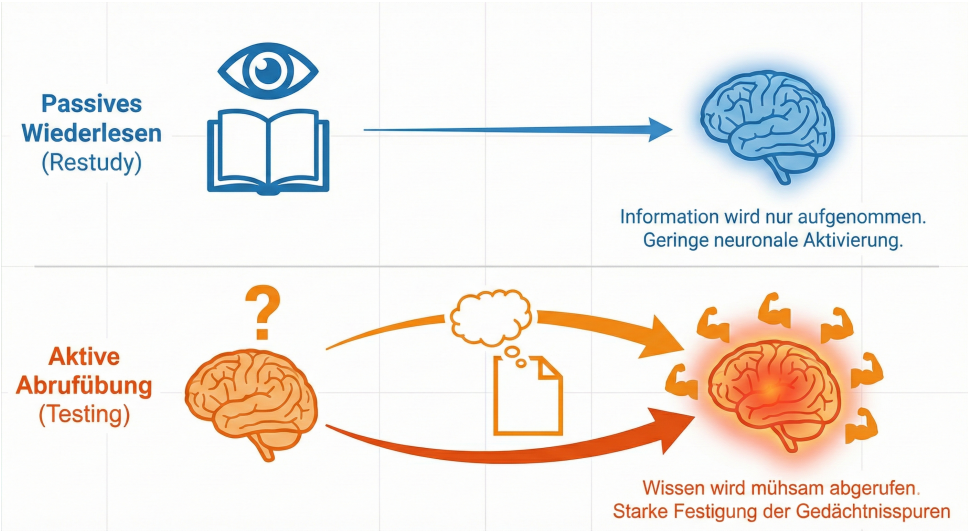

Abbildung 3.3. Illustration Testgestütztes Lernen – test-enhanced learning

Beziehungen zwischen Hinweisreizen (*cues*) und dem Inhalt im Gedächtnis, indem zusätzliche Abrufwege zu gespeicherten Wissensmustern geschaffen werden, was den Abruf verbessert. Praktisch kann man diesen tollen Effekt auch recht einfach durch regelmäßige kurze Fragerunden nutzen: Wie die Lernforscher herausstellen: „frequent low-stakes quizzes (last only 5 or 10 min) can produce a large boost in performance“ (Roediger & Pyc, 2012, S.246).

Fragebasierte Ausarbeitung (Explanatory questioning): Bei dieser Technik wird das tiefergehende Verständnis von Material durch das Stellen und Beantworten von „Warum“-Fragen gefördert. In **Rollenspielen und Simulationen** können Teilnehmer durch bewusste Praxis aktiv Szenarien durchspielen, während sie gleichzeitig durch gezielte Fragen angeleitet werden, die zum tieferen Nachdenken und zur Reflexion anregen. Diese Fragen können dazu dienen, die Teilnehmer dazu zu bringen, ihre Entscheidungen und Handlungen im Kontext des Rollenspiels zu erklären, wodurch das Verständnis für die Anwendung von Konzepten in realen oder simulierten Situationen vertieft wird.

Indem Lernende über die Gründe hinter den Fakten nachdenken, werden Verbindungen zu bereits bekanntem Wissen hergestellt, was zu einem tieferen Verständnis und besserer Erinnerung führt. Dies deckt sich mit dem Postulat der ICAP-Theorie des kognitiven Engagements (Chi et al., 2018): Interaktion (I) ist effektiver als individuelle Konstruktion, was wiederum effektiver ist als aktive (aber nicht konstruktive) Beteiligung, was wiederum die passive Lernteilnahme schlägt (I > C > A > P).

3.4.2 Wie können LLMs genutzt werden, um diese Lerntechniken zu unterstützen?

Wir skizzieren das hier kurz an einem Seminar zum interkulturellen Management. Um **zeitliche Verteilung und Mischung** zu fördern, kann mit LLMs eine Serie von kurzen, thematisch variierenden Aufgaben und Fallstudien über das Semester verteilt erstellt werden. Diese könnten reale Szenarien abbilden, in denen Studierende ihre Fähigkeiten im interkulturellen Management anwenden müssen. Beispielsweise könnte das Sprachmodell Aufgaben generieren, bei denen Studierende Strategien für die Überwindung kultureller Barrieren in internationalen Teams entwickeln.

Was sind Beispiele für **testgestütztes Lernen**? Regelmäßige, durch LLMs generierte Quizze bringen Studierende dazu, ihr Wissen häufiger aktiv abzurufen. Durch LLMs können Multiple-Choice-Fragen, Fallstudienanalysen und Szenariobeschreibungen zu interkulturellen Missverständnissen erzeugt werden, welche die Studierenden lösen müssen.

Zur Unterstützung von **fragebasierter Ausarbeitung** können LLMs die Erstellung von Fallstudien, Simulationen und Rollenspielen unterstützen, damit Studierende über interkulturelle Dynamiken und Managementstrategien nachdenken. Diese könnten als Ausgangspunkt für Diskussionen im Kurs oder als Teil von Hausaufgaben dienen, wobei die Studierenden angehalten werden, über die Verbindungen zwischen dem Kursmaterial und den simulierten interkulturellen Interaktionen zu reflektieren. Viele weitere Beispiele hierfür besprechen wir im folgenden Kapitel, wo wir Anwendungsfälle von KI in der Lehre nach der didaktischen Rolle des Werkzeugs darstellen: Hilfskraft, Copilot, Tutor oder Simulator.

Kernaussagen

1. Das Problem der Hochschullehre ist nicht fehlendes Wissen über gute Lehre, sondern fehlende Zeit, sie umzusetzen. Genau hier kann generative KI ansetzen.
2. Chatbots sind darauf gebaut, hilfreich zu sein, nicht darauf, Lernen zu fördern. Ohne Anpassung nehmen sie Lernenden die Schwierigkeiten ab, die das Lernen ausmachen.
3. Welcher KI-Einsatz sinnvoll ist, hängt vom Wissenstyp ab: Abrufübungen und Erklärungen für Faktenwissen, dialogisches Coaching und durchgearbeitete Beispiele für Prozesswissen, Szenarien und Rollenspiele für Transfer.
4. Verteiltes Üben, häufige Abruftests und Warum-Fragen sind die am besten belegten Lerntechniken. Ihr Haken ist der Aufwand, und den können Sprachmodelle drastisch senken.
5. Interaktion schlägt Konstruktion schlägt aktive Beteiligung schlägt passives Zuhören. Eine KI-Lernaktivität ist umso wirksamer, je weiter oben sie auf dieser Leiter steht.

Zum Weiterdenken

1. Ordnen Sie drei Lernziele Ihrer Veranstaltung den Stufen knowing that, knowing how und knowing with zu. Welche Stufe kommt bei Ihnen zu kurz, und welche KI-gestützte Methode aus diesem Kapitel würde sie stärken?
2. Erklären Sie ohne Nachschlagen, warum ein Chatbot, der sofort die richtige Antwort gibt, dem Testeffekt entgegenwirkt. Wie müsste der Bot stattdessen reagieren?
3. Wo in Ihrem Semesterplan könnten Sie mit geringem Aufwand verteiltes und gemischtes Üben einbauen, wenn ein Sprachmodell die Aufgabenvarianten liefert?

4 Vier Szenarien der Nutzung von GenAI: Hiwi, Copilot, Tutor, Simulator

Wie nutzen Lehrende generative KI? Wir sortieren die sehr vielfältigen Hilfestellungen der neuen Tools in vier Kategorien von Anwendungen: Hiwi, Copilot, Tutor, Simulator (E. R. Mollick & Mollick, 2023b, 2024).

Hier ein Beispiel für einen Tutor-Bot, den wir seit dem Wintersemester 2025/26 als Hilfestellung für das Modul "Grundlagen der BWL" erproben; neue Themen werden laufend ergänzt.

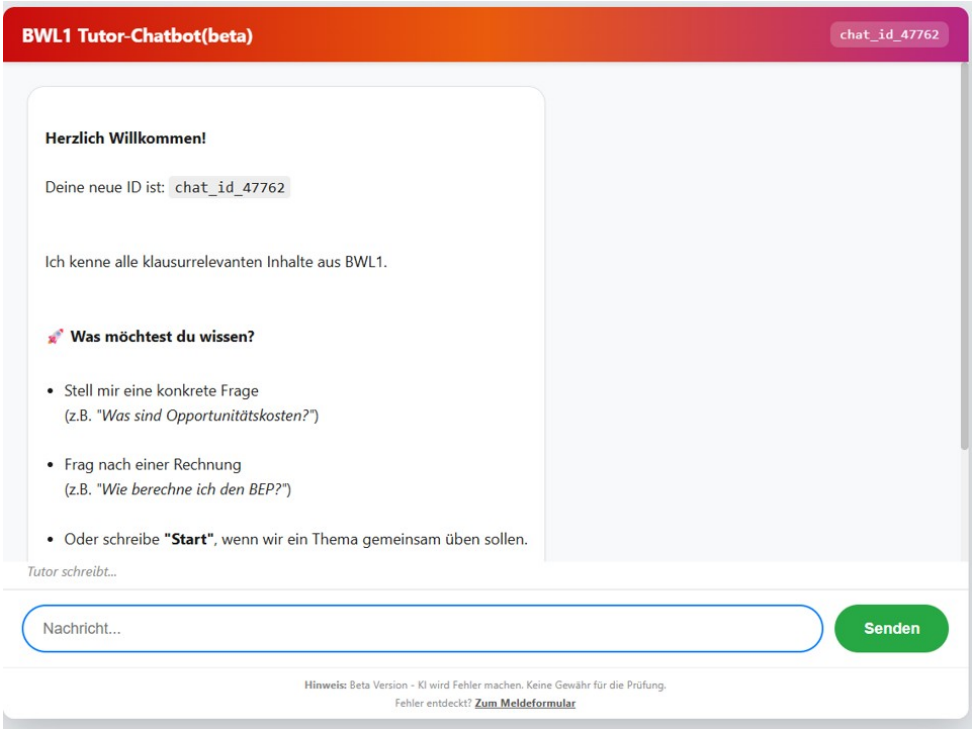

Abbildung 4.1. Beispiel: Tutor-Bot BWL Grundlagen. Screenshot der Testversion, Januar 2026

Hier können Sie die Live-Version testen: https://dev.d1czie2npcfbfs.amplifyapp.com

Lernziele

Nach diesem Kapitel können Sie …

- die vier Rollen Hiwi, Copilot, Tutor und Simulator unterscheiden und eigene Anwendungsideen einer Rolle zuordnen;
- mit dem Dreiklang Verdrängung, Produktivität und Wiedereinsetzung einschätzen, welche Aufgaben Lehrender durch KI wegfallen, schneller werden oder neu entstehen;
- Recherchewerkzeuge nach den zwei Fragen „einmalig oder iterativ“ und „Liste oder Analyse“ einordnen und ein passendes Werkzeug für eine Literaturaufgabe wählen;
- Grade der KI-Nutzung beim Schreiben unterscheiden und erklären, warum auch Nicht-Informatiker mit Sprachmodellen Lernwerkzeuge programmieren können;
- die vier Vorteile eines KI-Tutors nennen und beschreiben, wie Musterlösungen als Input Halluzinationen eindämmen;
- Role Play und Goal Play unterscheiden und begründen, warum Simulationen Rahmung und Nachbesprechung durch Lehrende brauchen.

4.1 KI als Hiwi

4.1.1 Was sind unsere Aufgaben?

Beschäftigte in Forschung und Lehre erfüllen eine Vielzahl sehr heterogener Aufgaben, mit einem wachsenden Teil an „Verwaltung“. Wer lehrt, merkt schnell, dass die Präsenzveranstaltung nur die Spitze eines ganzen Eisbergs an Aufgaben darstellt. Eine Umfrage unter Lehrenden in Österreich zeigt, dass sie etwa ein Drittel ihrer Zeit mit Lehraktivitäten verbringen (32 %) und etwa ein Fünftel mit Verwaltungstätigkeiten in der Hochschule (20 %) sowie ein weiteres Fünftel mit externen Verpflichtungen wie Gutachten oder Tätigkeiten in wissenschaftlichen Gesellschaften (9 %, 10 %) (Österreichischer Universitätsprofessor/innenverband, 2018). Wie Unkraut im Garten wächst der Anteil, den Lehrende mit „sonstigem“ verbringen:

Vor allem der Zeitaufwand für Verwaltung stieg an (Schomburg et al., 2012).

Woraus besteht das im Detail und wo könnten LLMs helfen? Vor- und Nachbereitung, Evaluation, Beratung, Planung und vieles mehr lassen die Stunden eines Tages schnell vergehen. Abbildung 4.2 zeigt die 25 Hauptaufgaben, die Lehrende nach Umfragen des US-Arbeitsministeriums verrichten (https://www.onetonline.org/link/summary/25-1011.00). Welche Auswirkungen können wir von LLM auf diese konkreten Aufgaben erwarten?

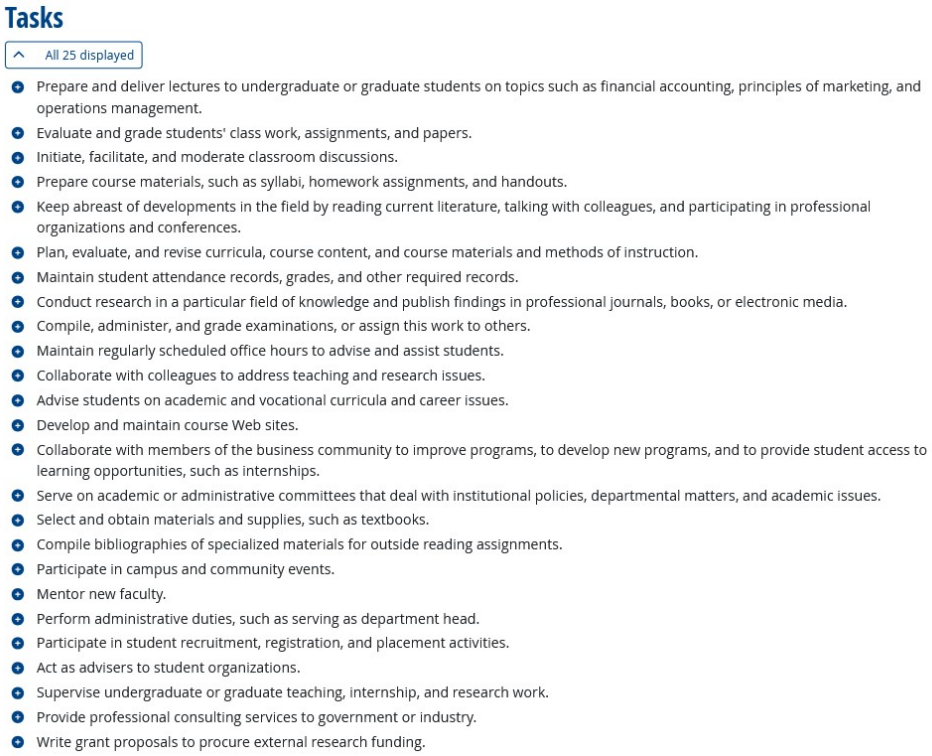

Abbildung 4.2. Was für Aufgaben erledigen Lehrende? 25 Einzelaufgaben am Beispiel „Business Teachers, Postsecondary“ nach Umfragen des US-Arbeitsministeriums auf ONET. *Quelle:* ONET, 2025

Historische Studien zeigen, dass Technologie typischerweise **Tätigkeiten** (tasks) beeinflusst und eher selten ganze Jobs ersetzt. Führend sind dazu Untersuchungen von David Autor und dem Nobelpreisträger Daron Acemoglu (Acemoglu & Restrepo, 2019; Autor, 2015). Eine nützliche

Kategorisierung unterscheidet **drei Effekte** neuer Technologien auf den Faktor Arbeit: Technologische Veränderungen können menschliche Arbeit ersetzen (**Verdrängungseffekt** / displacement effect), spezifische Arbeitskräfte produktiver machen (**Produktivitätseffekt** / productivity effect / augmentation), oder neue Aufgaben (und Jobs) schaffen (**Wiedereinsetzungseffekt** / reinstatement effect) (Acemoglu & Restrepo, 2019).

Effekt	Beschreibung	Aufgaben in der Lehre (Beispiele)
Verdrängung	Technologie übernimmt Aufgaben	• Erstellung, Durchführung und Bewertung von Prüfungen (x) • Verwaltung von Noten und Anwesenheit (x) • Vorbereitung standardisierter Lehrmaterialien (x) • Zusammenstellung von Bibliographien (x)
Produktivität	Technologie macht Arbeit effizienter	• Vorbereitung und Durchführung von Vorlesungen (x) • Durchführung von Seminaren und Diskussionen (x) • Akademische und berufliche Beratung (?/x) • Forschung und Publikation (x) • Pflege von Webseiten und digitalen Ressourcen (?/x)

Effekt	Beschreibung	Aufgaben in der Lehre (Beispiele)
Wiedereinsetzung	Technologie schafft neue Aufgaben	• Entwicklung KI-gestützter Lehrkonzepte (x) • Qualitätskontrolle von KI-Materialien (x) • Gestaltung individueller Lernpfade (x) • Ethische und rechtliche Begleitung (x) • Weiterbildung des Personals (x)

Tabelle 4.1. Für welche Aufgaben in der Lehre erwarten wir Verdrängung und Erhöhung der Produktivität und welche Aufgaben kommen hinzu? Legende: x = klarer Effekt, ? = gemischter Effekt. Quelle: Theorierahmen nach Acemoglu & Restrepo (2019)

In Tabelle 4.1 übertragen wir die genannten drei Effekte auf konkrete Aufgaben in der Hochschullehre.

Der **Verdrängungseffekt** betrifft hauptsächlich administrative und stark standardisierte Tätigkeiten. Aufgaben wie das Erstellen, Durchführen und Bewerten von Prüfungen, die Verwaltung von Noten und Anwesenheiten sowie die Vorbereitung standardisierter Lehrmaterialien oder Literaturzusammenstellun werden voraussichtlich vollständig oder überwiegend von KI übernommen. Anwendungsstudien und Umfragen der letzten zwei Jahre geben hierzu deutliche Hinweise (Morgan, 2024; Naddaf, 2025; Ogunleye et al., 2024; Ou et al., 2024; Tutton & Cohen, 2025).

Der **Produktivitätseffekt** bezieht sich auf zentrale Lehr-, Forschungs- und Betreuungstätigkeiten, die durch KI effizienter werden. Dazu zählen die Vorbereitung und Durchführung von Vorlesungen, Seminaren und Diskussionen, akademische und berufliche Beratung der Studierenden sowie Forschung und Publikationen. KI unterstützt hier durch automatische Literaturauswertungen, personalisierte Lerninhalte oder Pflege digitaler

Ressourcen, sodass Lehrende ihre Kernaufgaben besser und effektiver erfüllen können (Gottweis et al., 2025; Meincke et al., 2024; E. R. Mollick & Mollick, 2023a, 2024; Schwarcz et al., 2025).

Gemischte Effekte treten bei einigen Aufgaben wie der Entwicklung und Pflege von Kurswebseiten, dem digitalen Aufzeichnen von Vorträgen und der Auswahl von Lehrmaterialien auf, bei denen KI sowohl Teile der Aufgaben ersetzt als auch deren Durchführung produktiver macht.

Der **Wiedereinsetzungseffekt** zeigt, dass durch den Einsatz von generativer KI gänzlich neue Aufgaben entstehen. Dazu gehören beispielsweise die Entwicklung neuer KI-gestützter Lehrkonzepte und -methoden, Qualitätskontrollen von KI-generierten Lehrmaterialien, Gestaltung individueller Lernpfade, ethische und rechtliche Begleitung des KI-Einsatzes sowie die Weiterbildung des Lehrpersonals im Umgang mit KI-Technologien (Dihan et al., 2025; E. R. Mollick et al., 2024; E. R. Mollick & Mollick, 2024).

Durch diese differenziertere Analyse der drei Effekte wird klar, dass die Einführung von KI in die Lehre zwar mit hoher Sicherheit **deutliche Änderungen im Aufgaben-Mix** und der Zeitanteile bedeutet, die wir mit verschiedenen Aufgaben verbringen. Das ist nicht neu: Wer bestellt noch regelmäßig per Fernleihe, schickt Briefe oder kopiert in großem Umfang? Wir sehen, dass generative KI wahrscheinlich mittelfristig einen Teil der bisherigen Tätigkeiten verdrängen, zentrale Kernaufgaben produktiver gestalten und zugleich neue, spezialisierte Aufgaben in der Lehre schaffen wird.

Ob das **insgesamt zu einer Zeitersparnis führt, ist keineswegs sicher**, denn die neuen Aufgaben um die Einrichtung und Betreuung der KI-Unterstützung können sehr zeitintensiv sein, als Beispiel sei hier etwa die Einrichtung eines Physik-Tutor-Bots (Kestin et al., 2025) oder einer Startup-Simulation, in der KI in verschiedenen Rollen beim Aufsetzen und Verbessern von Geschäftsplänen hilft (E. R. Mollick et al., 2024). Beide Konzepte führen sichtlich zu einer Verbesserung der Lehre, aber die gibt es auch hier nicht umsonst.

4.1.2 Fachartikel finden und auswerten: Welches Werkzeug passt zu welcher Aufgabe?

Was leisten die KI-Helfer bei der Literaturrecherche, und wie prüft man, was sie liefern? Die besten Antworten darauf gibt der Bibliothekar Aaron Tay von der Singapore Management University, der die Werkzeuge seit Jahren systematisch testet (https://aarontay.substack.com/) (Tay, 2025). Zwei Unterscheidungen ordnen das Feld: Wird einmalig gesucht oder in mehreren Schleifen (einmalige Suche gegenüber agentischem Suchprozess)? Und bekommt man eine Trefferliste oder eine aus den Treffern erzeugte Zusammenfassung (Ergebnisliste gegenüber RAG-basierter Analyse)? Daraus ergeben sich vier Typen (Tabelle 4.2 und Abbildung 4.3); die Produktnamen in der Abbildung sind ein datierter Schnappschuss, die Typen bleiben.

Suche	Ausgabe	Typ nach Tay	Was man praktisch bekommt
einmalig	Liste	Quick Search	Klassische Trefferliste mit Ranking (etwa der Bibliothekskatalog oder Google Scholar), ohne erzeugten Antworttext
einmalig	Zusammenfassung	Quick RAG	Kurze „Antwort mit Zitaten“ aus den obersten Treffern; meist wenige Absätze
iterativ	Liste	Deep Search	Mehrere Suchschleifen über Minuten mit Abfragevarianten und Zitationsverfolgung; ein Sprachmodell bewertet die Relevanz; das Ergebnis bleibt eine Liste, meist eine bessere
iterativ	Bericht	Deep Research	Deep Search plus Berichterstellung: eine längere Synthese auf Basis des iterativ gefundenen Korpus

Tabelle 4.2. Vier Typen von KI-Suchhelfern nach zwei Unterscheidungen. Quelle: Tay (2025)

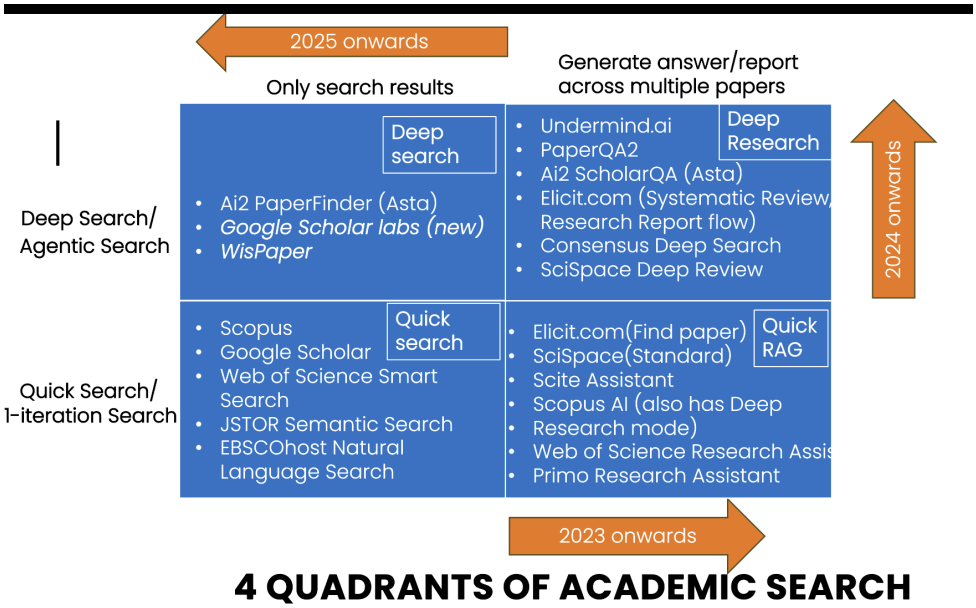

Abbildung 4.3. Einmal fragen oder mehrfach? Nur Ergebnisse oder Analyse? Zwei Unterscheidungen und vier Quadranten von Such-Helfern mit KI; Produktbeispiele Stand 2026. Quelle: Tay (2025)

Hinter dem Wort „iterativ“ verbirgt sich die wichtigere Frage, *wie* ein Werkzeug iteriert: als fest verdrahteter Ablauf mit ein paar KI-Entscheidungspunkten oder als Agent, der eine Aufgabe flexibel zerlegen kann. Tay beschreibt ein Agency-Spektrum und ordnet die meisten akademischen Deep-Research-Tools am verdrahteten Ende ein: beeindruckend innerhalb ihrer Schablonen, spröde außerhalb (Tay, 2025). Sein Stresstest macht das sichtbar: „Finde Arbeiten, die Paper X hätte zitieren sollen, aber nicht zitiert hat.“ Eine menschliche Hilfskraft zerlegt das in drei Schritte (ähnliche Arbeiten finden, deren Referenzen extrahieren, die Überlappung abziehen); allgemeine Sprachmodelle mit Werkzeugen führen diese Logik eher aus, während spezialisierte Tools scheitern, weil die Aufgabe nicht in ihren eingebauten Ablauf passt. Für die Lehre folgt daraus die Regel aus Kapitel 2.1.3: Je freier das Werkzeug arbeitet, desto klarer müssen die Kontrollpunkte sein, an denen wir das Ergebnis prüfen.

Beim Auswerten gefundener Artikel gilt eine ähnliche Staffelung (Tay, 2024a). Die Zusammenfassung eines einzelnen Dokuments ist am wenigsten riskant und eignet sich für die schnelle Relevanzprüfung; die sequenzielle Auswertung vieler Dokumente nach denselben Fragen (Design, Stichprobe, Befund) ergibt eine Codier-Tabelle, deren Zellen man stichprobenartig gegen das PDF prüft; die Synthese über mehrere Dokumente zu einer Frage trägt das höchste Fehlerrisiko, weil sich Suchfehler, untreue Zusammenfassung und schwache Gewichtung der Evidenz addieren. Die Kurzform „Antwort mit Zitaten“ ist für wissenschaftliche Arbeit deshalb meist nur ein Teaser: Man braucht den Originaltext für Kontext, Operationalisierung und Geltungsgrenzen, und erzeugter Text kann Quellen etwas zuschreiben, das sie so nicht sagen (fehlende *source faithfulness*) (Tay, 2025). Ein praktisches Problem der spezialisierten Suchwerkzeuge kommt hinzu: Sie kommen nicht hinter die Bezahlschranken der Verlage und arbeiten deshalb mit Abstracts oder Open-Access-Korpora. Akademische Konnektoren zu den großen Sprachmodellen verschieben die Arbeit hier von abstract-basiertem Raten zu passagenbasiertem Prüfen, weil das Modell über eine institutionelle Anmeldung lizenzierte Volltexte durchsuchen und Behauptungen an Fundstellen binden kann, begrenzt auf den Bestand des jeweiligen Anbieters (Tay, 2024b). Wie eine Agentenrecherche mit festen Kontrollpunkten in der Praxis abläuft, zeigt Kapitel D.4.

4.2 KI als Copilot

In dieser Kategorie hilft das Sprachmodell uns dabei, etwas zu tun, was wir sonst nicht könnten. E. R. Mollick & Mollick (2024) beschreiben mehrere solcher Ansätze: Bei der **"Case Co-Creation"** (E. R. Mollick & Mollick, 2024, S.25–28) arbeiten Studierende mit der KI zusammen, um ein Fallbeispiel für Kommilitonen zu erstellen. Dies fördert die Artikulation von Ideen und die kritische Auseinandersetzung mit dem KI-Output, da die initialen Entwürfe oft oberflächlich sind und durch studentische Expertise verbessert werden müssen. Die Übung **"Critique the AI"** lässt die KI ein Szenario zu einem Konzept (z. B. Groupthink) erstellen, das die Studierenden dann kritisch bewerten und ggf. verbessern müssen. Dies schult das Erkennen von Konzeptmerkmalen und die Fähigkeit, Wissen durch Korrektur zu artikulieren. Eine Herausforderung ist, dass die KI Konzepte manchmal unvollständig oder fehlerhaft illustriert, was aber Teil des Lerneffekts sein kann (E. R. Mollick & Mollick, 2024).

4.2.1 Besser schreiben – als Cyborg

Wer akademisch schreibt, lässt sich zunehmend von einer Vielzahl an unterstützenden KI-Systemen über die Schultern schauen – oder die Hand führen –, die Vorschläge zur besseren Sprachverwendung machen, wie DeepL, Grammarly, oder ChatGPT (Ou et al., 2024). Ou et al. (2024) sprechen von AI-assisted language tools (AILT), die Studierenden dabei helfen, ihre Sprachfähigkeiten etwa von einer in die andere Sprache zu übertragen und das Sprachniveau ihrer Schreibprodukte generell zu verbessern. In ihrer Studie analysieren sie die Kommentare von 1703 schwedischen Studierenden und stellen komplexe Muster der Nutzung fest: „...students align their own languages, writing skills and thinking with the algorithm-based language processes (e.g., lexical, grammatical, and textual corrections, word choice suggestions, language translation) within AI chatbots, writing assistance, and machine language translation to optimise the outcomes of their academic writing. ... students have become 'spatially extended cyborg[s]' ".

Studierende schreiben durch die zunehmend mächtigere technische Unterstützung ihre Haus- und Abschlussarbeiten deutlich anders. Bedeutet dies das Ende der Hausarbeit? Wohl eher einen starken Wandel, denn es

wird weiter wichtig sein, die saubere Argumentation zu üben (Friedrich, 2023; Klein, 2023).

> **Probieren Sie mal**
>
> Hier haben wir einen kleinen **Schreib-Trainer-Bot für Studierende** erstellt, der ihnen dabei helfen soll, eine **Einleitung für die Abschlussarbeit** zu schreiben. Dabei werden zunächst Beispiele gezeigt die nach richtig/falsch sortiert werden müssen, dann kommen nach und nach komplexere Fragen: Link zum Einleitungstrainer
> Hier eine zweite Übung (erstellt von Julia Schmid), zum die strukturiertes **Schreiben mit Einleitungssätzen (Topic-Sentences)** beibringen soll: Link zum Topic-Sentence-Bot.

Die Studienberatung der Universität Frankfurt hat eine Übersicht nach Phasen des Prozesses erstellt (Lehre virtuell - Universität Frankfurt, 2023), s. Tabelle 4.3:

Phase im Schreibprozess	Unterstützung durch KI	Eigenanteil
Themenfindung und Literaturrecherche	Brainstorming Grober Themenüberblick	Schwerpunktsetzung Wissenschaftliche Quellen finden
Lesen und Exzerpieren	Zusammenfassung/Gliederung für ersten Überblick Textpassagen vereinfachen	Gründliches Lesen KI-generierte Texte überarbeiten
Rohfassung	Ausformulieren von Stichpunkten Kooperatives Freewriting	Stichpunkte festhalten “Schreiben, um eigene Gedanken zu klären” KI-generierte Texte überarbeiten
Überarbeiten	Verschiedene Textversionen generieren Stil/Perspektive anpassen	Passende Textversion aussuchen und anpassen Menschliches Feedback einholen

Sprachliche Korrektur	Spezialisierte Tools wie DeepL, Write und Duden Mentor	Prüfen, ob Bedeutung verändert wurde

Tabelle 4.3. Integration von KI in den Schreibprozess. Quelle: Studienberatung der Universität Frankfurt (Lehre virtuell - Universität Frankfurt, 2023), Stand 10.3.2024

Mit einer einfachen Skala lässt sich auch die Intensität der LLM-Nutzung grob beschreiben. (s. Tabelle 4.4): Je nach Phase im Arbeitsprozess kann LLM zur Ideenfindung, zur Ausarbeitung möglicher Fragestellungen oder Inhalte dienen. Je nach Intensität sollte dann die Nutzung stärker begründet und durch Prüfschritte abgesichert werden (Baresel et al., 2024; Rowland, 2023).

Grad der KI-Nutzung	Charakterisierung	Beispiele
1	**Zur Inspiration**	Sie haben sich Vorschläge für Themen unterbreiten lassen; Tools eingesetzt, um sich aus eigenen Notizen heraus Themenschwerpunkte zu bilden; sich Formulierungen vorschlagen lassen; die Rechtschreibung-/Grammatikprüfung genutzt.

Grad der KI-Nutzung	Charakterisierung	Beispiele
2	**Ergänzend**	Sie haben sich mögliche Fragestellungen vorschlagen lassen, einzelne Begriffe der Aufgabenstellung oder Stellen in der Literatur erklären lassen, Gliederungen der eigenen Notizen vorschlagen oder eigene Texte zusammenfassen lassen, Reverse Outline zum eigenen Text (eine basierend auf dem Geschriebenen erzeugte Gliederung) generieren lassen.

Grad der KI-Nutzung	Charakterisierung	Beispiele
3	**Unterstützend**	Sie haben sich Anforderungen der Aufgabe (z. B. Aufbau einer HA) erklären, Literatur zusammenfassen, mögliche Gliederungen zum Thema vorschlagen lassen; Sie haben die Fragestellung dialogisch verfeinert bzw. Textteile dialogisch verfasst und dabei LLM-Output iterativ ergänzt; Sie haben sich Überarbeitungsvorschläge bzgl. Leserlichkeit und Stil generieren lassen.
4	**Inhaltsgestaltend**	Sie haben sich Hintergrundwissen zur Aufgabe bzw. Antworten auf Fragestellung generieren, Gliederung zum Thema vorgeben, Kürzungen und Ergänzungen vornehmen lassen oder KI-generierten Text direkt übernommen.

Tabelle 4.4. Erläuterungen zum Grad der LLM-Nutzung. Quelle: Baresel et al. (2024), basierend auf Rowland (2023)

Wie können wir konstruktiv mit den neuen technischen Möglichkeiten umgehen? Die folgende Tabelle fasst konkrete Beispiele für Hausarbeiten unter Einbindung von KI zusammen, die Ethan und Lilach Mollick in verschiedenen Beiträgen ausgeführt haben (E. R. Mollick & Mollick, 2023a, 2023b). Der übergeordnete Gedanke ist, KI nicht nur zur Automatisierung einzusetzen, sondern neue, interaktivere und individuellere Lernerfahrungen zu ermöglichen – mit mehr Reflexion, verschiedenen Perspektiven, Kreativität und Kollaboration. Die Rolle der Lehrenden wandelt sich hin zur Begleitung und Moderation dieser KI-gestützten Prozesse.

Ansatz	Beschreibung
Copilot: Kollaboratives Schreiben mit KI	Gruppen von Studierenden schreiben gemeinsam einen Text und nutzen KI als zusätzliches "Teammitglied". Sie dokumentieren die Interaktion mit KI und reflektieren Vor- und Nachteile.
Copilot: Multimediale Anreicherung mit KI	Studierende nutzen KI, um ihre Arbeiten mit Visualisierungen, Animationen oder Audio anzureichern und reflektieren, wie dies Verständnis und Attraktivität erhöht.
Copilot: KI als Coach und Reflexionspartner	KI stellt Fragen bezogen auf die Teamarbeit, um Studierende zur Reflexion ihrer Lernerfahrungen, Herausforderungen und Lehren anzuregen.
Tutor: KI-generierte Beispiele zur Erklärung von Konzepten	KI erstellt schnell viele Beispiele, die ein abstraktes Konzept in unterschiedlichen realen Kontexten illustrieren. Dies hilft Studierenden, die Idee zu erfassen und breiter anzuwenden.

Ansatz	Beschreibung
Tutor: KI-Tutor, den Studierende kritisieren	KI erstellt einen Essay zu einem Thema, den Studierende dann kollaborativ verbessern, indem sie Informationen ergänzen, Punkte klären, Belege liefern etc. Fördert kritische Analyse.
Tutor: Simulation von Anwendungsszenarien mit KI	Besonders in praxisorientierten Fächern erstellen Studierende mit KI Simulationen, in denen sie ihre Erkenntnisse anwenden, z. B. Unterrichtsszenarien in der Lehramtsausbildung.

Tabelle 4.5. Neue Ansätze für Hausarbeiten mit KI. Quelle: E. R. Mollick & Mollick (2023a) sowie die verlinkten Blogeinträge

Prompts für ausgewählte Anwendungen finden Sie im Appendix.

Letztlich ist die Anpassung der didaktischen Ansätze und technischen Möglichkeiten auf die konkrete Kombination von Lerninhalt und Studierendengruppe entscheidend. Es besteht die **Hoffnung**, dass die neuen Möglichkeiten der **administrativen Entlastung, höheren Niveaus bei Arbeitsaufgaben und schnellerer Individualisierung der Lernunterstützung** in der Summe zu einem höheren Niveau des Lehrens und Lernens führt.

Voraussetzung dafür ist sicherlich eine **Anpassung der Lehrstrategie** und die nüchterne und proaktive Beschäftigung mit den unvermeidlichen Risiken und Nebenwirkungen von neuen technischen Möglichkeiten. Wie kann kritisches Denken in diesen neuen Recherche- und Schreibprozessen erfolgen (H.-P. H. Lee et al., 2025)? In diesem Fall darf man vermuten, dass die negativen Effekte noch höher wären, wenn wir die Lehre nicht anpassen.

Wie der nächste Abschnitt zeigt, findet eine ähnlich intensive Diskussion im Bereich der Informatik statt, wo speziell Programmieraufgaben ganz neu gedacht werden müssen.

4.2.2 Jeder kann jetzt programmieren

Mit KI als Copilot können wir **viel umfangreicher und schneller mit Code arbeiten**. Ein Beispiel ist Programmieren: Professionelle Programmierer werden mit KI-Copiloten deutlich schneller (Peng et al., 2023; Steinberger, 2025; zunehmend beaufsichtigen sie KI-Agenten, siehe etwa Willison, 2025a) und Lehrbücher haben zunehmend Namen wie „Learn AI-assisted Python Programming“ (Porter & Zingaro, 2024).

Studierende können so zum Beispiel viel schneller ein funktionierendes Spiel oder eine Simulation erstellen, was die Motivation erhöht. Der **Raum der kreativen Möglichkeiten weitet sich deutlich aus**. Mit KI-Unterstützung können Schüler/innen mit Sonic Pi Musikstücke programmieren (Gieselmann, 2024) oder mit Tools wie Violentmonkey kleine Skripte für die individuelle Anzeige von Lieblings-Websites erstellen (Eikenberg, 2025).

Wie helfen solche Copiloten beim Coden? Aktuelle Studien untersuchen etwa, wie man mit KI-Copiloten auch Nicht-Informatiker an fortgeschrittene statistische Auswertungen heranführen kann (Bien & Mukherjee, 2025). In einer Einführungsvorlesung für **MBA-Studierende** wurde GitHub Copilot genutzt, wobei die Studierenden natürliche Spracheingaben verwendeten, um **R-Code automatisch** generieren zu lassen. Das Ziel war, komplexe Syntax zu vermeiden und die Studierenden direkt mit Datenanalyse vertraut zu machen. Im Ergebnis ermöglichte die Nutzung von GitHub Copilot es Studierenden ohne Programmierkenntnisse, statistische Methoden effektiv und eigenständig anzuwenden. Studierende bewerteten die Nutzung der KI-Tools überwiegend positiv, da diese die Lernerfahrung verbesserten und den Zugang zur Programmierung erleichterten. Die empirische Untersuchung zeigte, dass ein Großteil der universitären Programmieraufgaben teilweise oder vollständig durch die KI-Tools gelöst werden konnte.

Eine weitere Studie sammelt qualitative Erfahrungen in einem **Einführungskurs in Informatik**, wie sich die Nutzung von Copilot auf das Lernen auswirkte (Puryear & Sprint, 2022). Studierende profitierten deutlich von Copilot, insbesondere bei der Entwicklung von Programmierfähigkeiten und beim Lösen konkreter Programmierprobleme. Allerdings zeigte sich, dass die Studierenden weiterhin ein fundiertes Verständnis der Programmiersprache benötigen, um KI-generierte Lösungen richtig beurteilen und gegebenenfalls

korrigieren zu können. Die KI unterstützte den Lernprozess effektiv, konnte aber die grundlegenden Konzepte nicht vollständig ersetzen.

Mehrere Studien testen, **wie gut ein KI-Assistent typische Programmieraufgaben** aus einer Einführungsveranstaltung löst – zunächst allein durch KI und dann mit Anpassung der Eingaben durch Studierende (GitHub Copilot) (Denny et al., 2023). Eine öffentliche Datenbank mit 166 typischen CS1-Problemen wurde genutzt, um Copilot zu testen. Wenn Copilot anfangs scheiterte, versuchten Studierende, die Beschreibung der Aufgaben in natürlicher Sprache anzupassen („Prompt Engineering"), um das Ergebnis zu verbessern. Copilot löste etwa die Hälfte der Programmieraufgaben auf Anhieb korrekt. Durch gezieltes Prompt Engineering konnten weitere 60 % der anfänglich nicht gelösten Aufgaben erfolgreich bearbeitet werden. Dies deutet darauf hin, dass die bewusste Formulierung von Aufgabenstellungen ein wichtiger Bestandteil der Lernaktivitäten wird und das Erlernen von Programmierkompetenzen verändert.

Eine weitere Studie an der niederländischen Universität Twente zeigt basierend auf Interviews und Umfragen mit Studierenden, dass ein Großteil der universitären Programmieraufgaben teilweise oder vollständig durch die KI-Tools gelöst werden konnte. Dies erfordert, dass Lehrende ihre Unterrichtsstrategien anpassen, um sicherzustellen, dass Kernkompetenzen dennoch vermittelt werden (Nizamudeen et al., 2024).

Wofür nutzen professionelle Programmierer*innen die Copiloten? Eine Studie untersucht dies mit einer Umfrage unter 410 Entwicklern (J. T. Liang et al., 2024). Die wichtigsten Gründe der Nutzung waren Autovervollständigung, schnelleres Abschließen von Programmieraufgaben sowie Unterstützung beim Erinnern von Syntax. Als besonders erfolgreich erwiesen sich die Tools bei repetitiven und einfachen Programmieraufgaben. Häufige Probleme waren jedoch, dass generierter Code oft nicht die gewünschten funktionalen oder nicht-funktionalen Anforderungen erfüllte, wodurch Entwickler diesen oft modifizieren mussten oder ganz darauf verzichteten.

Alle fünf Studien zeigen, dass KI-Programmierassistenten, insbesondere GitHub Copilot, effektiv dabei helfen, **Einstiegshürden beim Programmieren zu reduzieren**, indem sie Entwicklern helfen, repetitive und einfache Programmieraufgaben effizienter zu erledigen (Bien & Mukherjee, 2025; J. T. Liang et al., 2024; Nizamudeen et al., 2024; Puryear & Sprint, 2022). Ein

wesentliches Potenzial dieser Tools liegt in der **Steigerung der Motivation und der Verkürzung der Lernkurve** bei Programmieranfängern.

Besonders wichtige neue Kompetenzbereiche sind „Prompt Engineering", die gezielte Steuerung der KI-Ausgaben (Denny et al., 2023), sowie das Verständnis dafür, wie Input den generierten Output beeinflusst (J. T. Liang et al., 2024). Jedoch treten auch **Herausforderungen** auf: Häufig erfüllen KI-generierte Lösungen nicht alle funktionalen oder nicht-funktionalen Anforderungen, weshalb Entwickler oft erhebliche Anpassungen vornehmen müssen oder den KI-generierten Code ganz verwerfen (J. T. Liang et al., 2024). Dies unterstreicht, dass trotz erheblicher Erleichterungen durch KI grundlegende Programmierkenntnisse weiterhin notwendig sind, um Lösungen kritisch zu bewerten und effektiv anzupassen (Puryear & Sprint, 2022).

Praktisch alles, was Code ist, lässt sich mit Sprachmodellen erstellen und anpassen. Wir brauchen also nur Code-Schnittstellen. Das klingt kompliziert, ist aber überall schon vorhanden. Im Schreibprozess importieren wir Zitationen über das Bibtex-Format (.bib). Kalendertermine werden im Kalenderstandard (.ics) geführt. Für Flussdiagramme gibt es z. B. den Mermaid-Standard. Wir können insofern mit Sprachmodellen:

- Zitationen von einem Foto aus importieren („Scanne das Foto und gib mir die Quellen als Bibtex Code aus. Erkläre mir dann, wie ich ihn importiere")
- Kalendereinträge aus einer Liste in unser Terminprogramm überführen („Erstelle mir aus dieser Liste Einträge im ICS Standard. Erkläre mir dann, wie ich den Code in Google Calendar importiere.")
- Ablaufdiagramme in Mermaid visualisieren und als Grafik speichern („Erstelle mir einen typischen Kaufprozess in Mermaid. Erkläre mir dann, wie ich ihn visualisieren und als Grafik exportieren kann.")
- Interaktive Simulationen mit den Claude Artifacts erstellen (s. o.)
- Dialogbasiert Grafiken und statistische Analysen in Google Colab erstellen (s. u.)
- (Für viele weitere Ideen für solche Hilfsmittel können wir einfach das Sprachmodell fragen.)

Wichtig für Hochschulen: Mit verschiedenen browserbasierten Tools wie **Google Colab oder Cursor** steht eine sehr mächtige Programmierhilfe mit integriertem Sprachmodell zur kostenlosen Verfügung. Visualisierungen und statistische Analysen können hier komplett dialogbasiert begonnen

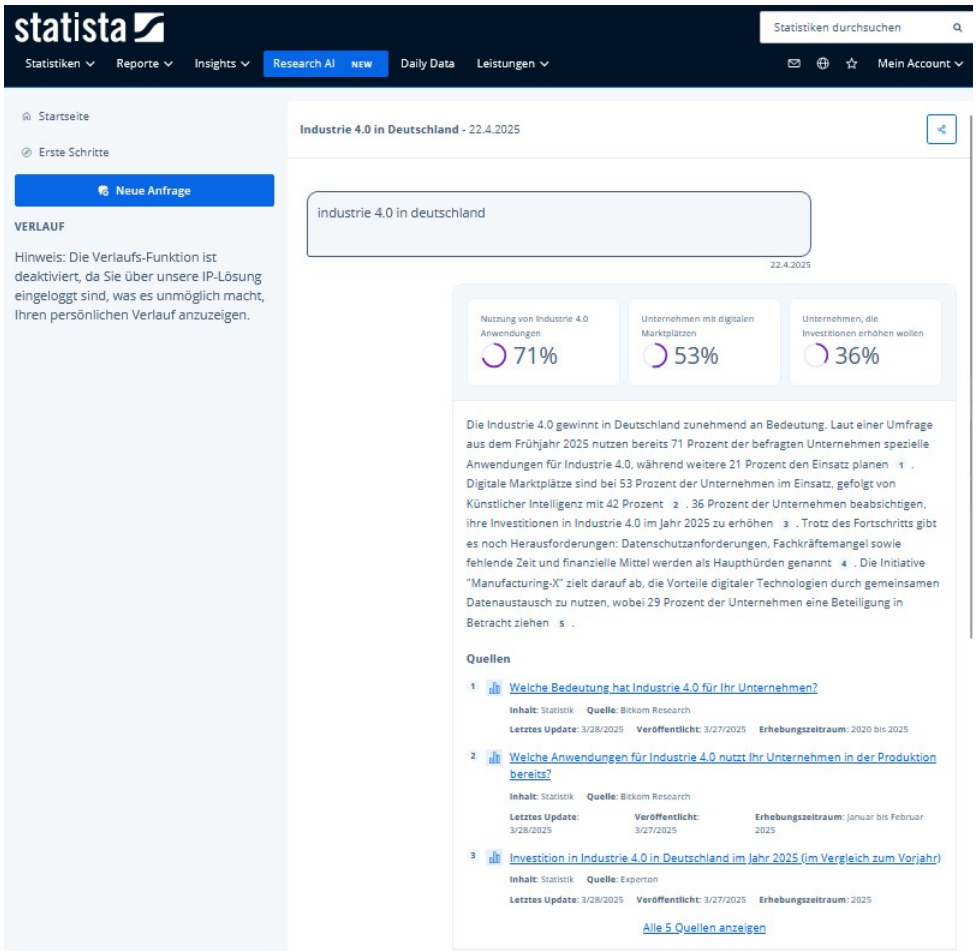

Abbildung 4.4. Visualisierung von Ablaufdiagrammen in Mermaid. Screenshot ChatGPT, 2025 (https://mermaid.live/)

werden. Auch ohne Grundkenntnisse in der Programmiersprache Python sind Studierende hier gleich handlungsfähig und können durch häufige Nutzung Wissen aufbauen. Dadurch wird es etwa möglich, von Studierenden durchgängig die Nutzung von Programmiertools zur Erstellung von Visualisierungen zu verlangen. Die Hilfestellung durch die KI-Assistenz lässt dies deutlich leichter werden, als das händische Gefrickel in den Grafiken von Excel oder gar PowerPoint. Zur Illustration hier ein Beispiel-Notebook. Rechts können die Prompts eingegeben werden: Beispiel-Notebook

Beispiel-Prompts: * Erstelle mir eine einfache Visualisierung von vertikalen und horizontalen **Balkendiagrammen** in Python. * **Passe die Balken so an**, dass die Prozentwerte auf den Balken sichtbar sind. * Füge Beispiele für **Violin Charts** mit einem etwas komplexeren **Beispieldatensatz** hinzu. * Erstelle jetzt einen Beispieldatensatz und führe eine einfache **Explorative Datenanalyse** (EDA) mit Visualisierungen durch.

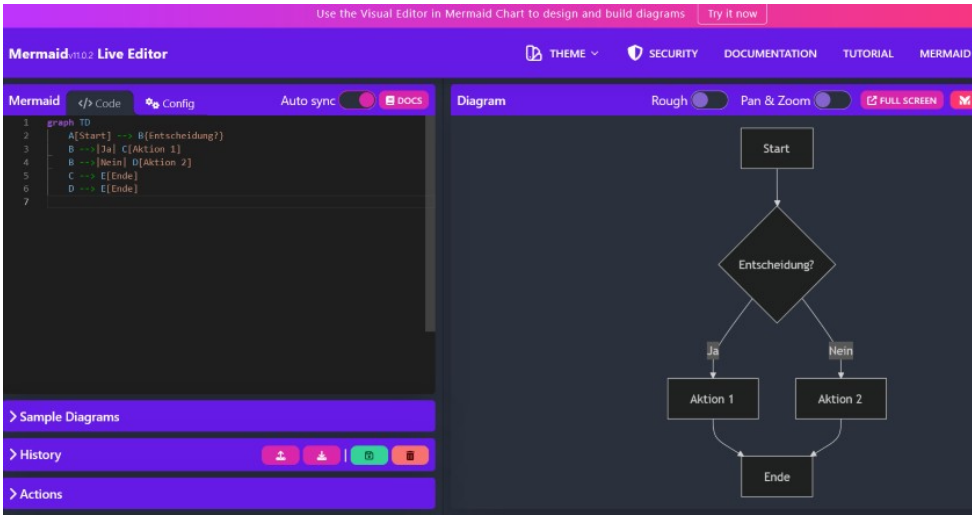

Abbildung 4.5. Visualisierung im Dialog mit Google Colab und KI

Anmerkung: Rechts schreibt man den Prompt, links entsteht der Code und die Grafik. Besondere Stärken sind die Nachvollziehbarkeit (da alles im Code steht) und die einfachen Anpassungsmöglichkeiten (da die KI sich um die Syntax kümmert). Code ist hier einsehbar: Link zum Code.

Solche **Hilfestellungen sind Alltag** geworden: Alle großen Anbieter von Code-Editoren wie **Pycharm, VS Code (Microsoft/GitHub) und**

neuere Anbieter wie Cursor und (noch extremer, als Agent) **Devin** (https://preview.devin.ai/) bieten Programmierung mit KI-Unterstützung an. Für Hochschulen stellt sich die Frage, wie diese Fähigkeit am Besten trainiert werden kann. Ein extremes Anwendungsbeispiel ist dieser Youtuber, der in Trainingsvideos mit einer Vielzahl verschiedener KI-Tools programmiert, auch selbst beschrieben eher in der Rolle eines Supervisors, der die verschiedenen KI-Helfer überwacht und koordiniert: Build Anything with Cursor, David Ondrej, 2024-09-1.

4.3 KI als Tutor

Diese Kategorie umfasst KI-Systeme, die Studierende direkt beim Lernen anleiten, beraten oder ihnen Feedback geben. Sogenannte Intelligent Tutor Systems (ITS) werden in der Didaktik schon länger diskutiert, sie wurden klassischerweise regelbasiert als Entscheidungsbäume aufgebaut, ähnlich einem Fortsetzungs-Kinderbuch (A la: "Wenn Du die Tür öffnen willst, lies weiter auf S.145"). Durch generative KI entstehen breitere Möglichkeiten der Interaktion, jedoch führt das "generative" Element auch etwas Unsicherheit in die Dialogsteuerung ein (Latif et al., 2026).

Aus didaktischer Sicht entfaltet der GenAI Tutor seinen Mehrwert vor allem in vier Punkten (Kestin et al., 2025): * **Individuelle Anpassung**: Das System erkennt unterschiedliche Lernstände (etwa durch Analyse typischer Fehler oder wiederkehrender Wissenslücken) und kann dadurch passgenauere Folgefragen stellen. * **Unmittelbares Feedback**: Während in großen Lehrveranstaltungen Lehrende nur sehr eingeschränkt auf einzelne Fragen von Studierenden eingehen können, liefert das KI-Tool praktisch sofort Rückmeldungen. * **Motivation und aktive Teilhabe**: Studierende werden durch die permanenten Interaktionsmöglichkeiten stärker einbezogen, was sich positiv auf die Lernergebnisse auswirkt. * **Zeitersparnis für Lehrende**: Ein Teil der individuellen Betreuung kann – bei inhaltlich gut vorbereitetem KI-System – durch den Tutor übernommen werden. Allerdings behält die Lehrkraft jederzeit die Oberaufsicht, indem sie zum Beispiel relevante KI-Antworten stichprobenartig überprüft oder spezielle Fälle selbst übernimmt (z. B. wenn die KI Auskünfte gibt, die nicht zur jeweiligen Kursstruktur passen).

Generell ist bei KI-Tutoren die **Gefahr von Fehlinformationen und Halluzinationen** zu beachten. Hierfür gibt es jedoch gute Gegenmaßnahmen,

vor allem durch Kontrolle des Inputs und systematische Qualitätstests der LLM-Tools. Eine interessante Möglichkeit, die beim Physik-Tutor der Harvard Studie besprochen wird (Kestin et al., 2025), ist die **Bereitstellung von Musterlösungen als Input** (nicht nur der Fragen), was die Gefahr von Ungenauigkeiten, Halluzinationen und Inkonsistenzen in den Antworten des Sprachmodells deutlich reduziert. Der Aufwand für die Erstaufsetzung steigt hier zwar, aber im Gegenzug verspricht dieser Ansatz die Vorteile der individuellen Anleitung ohne die Nachteile der Qualitätsunsicherheit. Insgesamt ist eine solche Durchsicht und intensive Qualitätskontrolle klar zu empfehlen (dieser Aspekt der intensiven Qualitätstests wird bei der Kurzvorstellung einiger deutscher Fallstudien in Wannemacher et al. (2025) vernachlässigt).

4.3.1 Beispiele für einfache Tutoren

E. R. Mollick & Mollick (2024) beschreiben eine Reihe allgemeiner Tutorenkonzepte: Der **"Integration Agent"** (E. R. Mollick & Mollick, 2024, S.31–33) fordert Studierende durch offene Fragen heraus, Verbindungen zwischen verschiedenen Kurskonzepten herzustellen, was vernetztes Denken fördert. Der **"Reflection Coach"** (E. R. Mollick & Mollick, 2024, S.30) regt zur Reflexion über Erfahrungen an, um das Gelernte zu konsolidieren. Der **"AI Tutor Blueprint"** (E. R. Mollick & Mollick, 2024, S.38–40) ermöglicht es Lehrenden, eigene, auf ihre spezifischen Themen zugeschnittene Tutoren-Prompts zu erstellen.

An deutschen Hochschulen gibt es ebenfalls vielfältige Tutor-Anwendungen: Der Lern- und Informationsassistent **"LISA"** an der Hochschule Hof unterstützt Studierende bei der **Prüfungsvorbereitung** durch personalisierte Lernpläne, Übungsaufgaben und Feedback basierend auf hochgeladenen Materialien (Wannemacher et al., 2025, Case 208). Herausforderungen sind hier die Bekanntmachung des Tools und die potenziell geringere Ergebnisqualität im Vergleich zu großen kommerziellen Modellen. An der FernUniversität in Hagen bietet **"COFFEE"** skalierbares, kriterienbasiertes **Feedback zu Freitextaufgaben**, während **"MIND"** Feedback zu Lernaktivitäten liefert, um die **Selbstreflexion** zu fördern (Wannemacher et al., 2025, Case 61). Hier sind der hohe initiale Implementierungsaufwand, Datenschutzanforderungen und die Notwendigkeit interdisziplinärer Expertise einschränkende Faktoren (Wannemacher et al., 2025).

Für all diese allgemeinen Tutoren gilt: Ihre Effektivität hängt von der Qualität des Prompts und der Fähigkeit der KI ab, die Tutor-Rolle konsistent und pädagogisch sinnvoll auszufüllen, was nicht immer gegeben ist und von Modell zu Modell variieren kann (E. R. Mollick & Mollick, 2024, S.36). Die KI kann oberflächlich bleiben oder halluzinieren (E. R. Mollick & Mollick, 2024, S.36).

Sprachen lernen und schwierige Situationen simulieren kann man sehr einfach und auf hohem Niveau über den Sprachmodus der großen Chat-Interfaces (Jurran, 2025). Vorreiter war der „Voice Mode“ von OpenAI, den man als App auf dem Handy ausprobieren kann (gut in der kostenfreien, sehr gut in der kostenpflichtigen Version); die anderen großen Anbieter bieten seither ähnliche Funktionen an. Die KI spricht auf Wunsch über ein beliebiges Thema in einer beliebigen Sprache. Im fortgeschrittenen Modus („**Advanced Voice Mode**“, für Abonnenten) ist die Stimme noch realistischer und man kann unter anderem die Geschwindigkeit und andere Stimmparameter anpassen. Im Standardmodus kann man Dokumente hinzufügen, auf die sich die Unterhaltung beziehen soll (s. das zweite Beispiel für Anwendungen). Damit lassen sich zum Beispiel im Hochschulunterricht interaktive und unmittelbare Anwendungen realisieren: Studierende könnten ihre Fragen in Seminar- oder Vorlesungsphasen mündlich stellen, wobei die KI entsprechende Antworten gibt, visuelle Inhalte erklärt oder sogar aktuelle Daten aus dem Internet integriert. Besonders gut eignet es sich auch zum Lernen von Sprachen: Man kann die englische Präsentation ausprobieren und sich Feedback geben lassen. Solche Interaktionen kommen dem Ideal eines persönlichen Tutors schon sehr nahe, ermöglicht eine enge, interaktive und sehr auf die eigenen Bedürfnisse und Lernziele zugeschnittene Zusammenarbeit und kann so Lernprozesse dynamischer gestalten.

Wie passt man die Lehre an? Ein Artikel von 2025 bespricht, wie sich diese neuen Möglichkeiten auf die Rolle des Sprachunterrichts an Hochschulen auswirken (Tutton & Cohen, 2025): Es werden eine breite Reihe an Tools besprochen und konkrete Empfehlungen zur Umsetzung angeboten: Lehrende sollen mit Studierenden die Stärken und Schwächen der Tools erproben und sie so an die Nutzung heranführen. Unterrichtskonzepte sollten so angepasst werden, dass sich die Stärken der KI-Tools und des Präsenz-Unterrichts ergänzen.

4.3.2 Komplexer Physik Tutor mit Musterlösungen

Als **Beispiel für einen ausführlich getesteten Tutor-Bot** wollen wir hier exemplarisch einen **Physik-Tutor der Harvard Universität** etwas ausführlicher darstellen (Kestin et al., 2025). Der Physik-Tutor "PS2 Pal" betreut Studierende in Physik-Einsteigerkursen interaktiv und mit adaptiven Fragestellungen, was in der Evaluation zu einem deutlich verbesserten Lernerfolg führte. Im Verbund mit kürzeren Input-Phasen erhalten die Studierenden Aufgaben und Fragestellungen, die sie direkt in Interaktion mit dem KI-Tutor bearbeiten können. Der Tutor stellt Fragen, gibt bei Bedarf Hinweise und passt den Schwierigkeitsgrad an den Fortschritt der bzw. des Lernenden an.

Studierenden loggen sich über eine Weboberfläche – oder in manchen Fällen eine in den Kurs integrierte Lernplattform – ein und erhalten dann Aufgabenpakete zu Teilthemen (z. B. Kinematik, Kräfte oder Energieerhaltung). Die KI analysiert die eingegebenen Antworten und entscheidet anhand vorab definierter Parameter und eines Maschinenlern-Modells, ob und wie viel zusätzliche Hilfestellung nötig ist. Bei korrekten oder fast korrekten Lösungen wird ein vertiefender Schritt vorgeschlagen (etwa eine weiterführende Frage), während bei fehlerhaften Lösungsschritten gezielt ein Tipp oder ein Hinweis auf das entsprechende Lehrmaterial gegeben wird. Dadurch werden die Lernenden kontinuierlich im Lernprozess unterstützt, ohne gleich eine komplette Lösung zu sehen.

4.4 KI als Simulator

Hier erstellt die KI interaktive Umgebungen für praxisnahes Training. In einfachen Rollenspielen simuliert das Sprachmodell ein Gegenüber, um z. B. Analyse- oder Verhaltensmuster einzuüben. E. R. Mollick & Mollick (2024) unterscheiden dabei **Role Play** (Rollenspiele) und **Goal Play** (zielgerichtete Spiele).

4.4.1 Role Play

Rollenspiel-Simulationen z. B. für Verhandlungen lassen Studierende eine neue Rolle einnehmen und dadurch risikofrei zu Üben, etwa von Verhandlungssituationen. In Deutschland wird an der TH Brandenburg

das Format "Talk2Transform" eingesetzt, das **Mitarbeitergespräche in Transformationsprozessen** simuliert, wobei KI die Mitarbeiterrollen spielt (Wannemacher et al., 2025, Case 132). Der Mehrwert liegt im praxisnahen Training von Kommunikations- und Führungskompetenz. Herausforderungen sind der hohe Konfigurationsaufwand, die technische Stabilität und die Tatsache, dass KI menschliche Interaktion nicht vollständig ersetzen kann und Rollen nicht immer fehlerfrei spielt (Wannemacher et al., 2025). In der HAW Hamburg werden **Gesprächssimulationen zur deeskalierenden Kommunikation** genutzt (Wannemacher et al., 2025, Case 177). An der Hochschule Kempten kommen **KI-Avatare** zur Simulation von **Führungsgesprächen** zum Einsatz (Wannemacher et al., 2025, Case 95). An der Deutschen Hochschule der Polizei dient eine Simulation der **Sensibilisierung für LLM-Missbrauchspotenziale**, indem Studierende explorativ deren missbräuchliche Nutzung erproben (Wannemacher et al., 2025, Case 031).

Direkt mit der KI zu sprechen kann die Situation dabei noch realistischer machen: Barra et al. (2024) beschreiben den Einsatz von **ChatGPT's Advanced Voice Mode (AVM) in medizinischen Simulationen**, speziell für das CPR-Training (s. Abbildung 4.6). AVM ermöglicht der Simulationspuppe, mit einer natürlichen, emotional reagierenden Stimme zu "sprechen", was den Realismus steigert. Der Mehrwert liegt in der verbesserten Immersion, Zugänglichkeit und Entlastung der Trainer. Herausforderungen sind die Sicherstellung der Konsistenz, die Abhängigkeit von den Prompting-Fähigkeiten des Trainers und technische Limitierungen des AVM bezüglich vorab eingebetteten Wissens.

Auch Juristen simulieren: Einen ähnlichen Ansatz verfolgt die simulierte Zeugenbefragung von Heetkamp, der es so etwa Rechtsreferendaren ermöglicht, diese Kompetenz im Rollenspiel mit VR-Brillen einzuüben (Heetkamp, 2023).

Eine umfangreiche Simulation beschreiben E. R. Mollick et al. (2024): **"Pitch Quest"** an der **Wharton School** ist ein Simulator für **Venture-Capital-Pitches**, der mehrere KI-Agenten (Mentor, Investor, Bewerter) nutzt, um personalisierte Übung und Feedback zu ermöglichen (E. R. Mollick et al., 2024, S.5–10). Der Mehrwert liegt in der skalierbaren Bereitstellung von Übungsmöglichkeiten für komplexe Skills. Herausforderungen sind die Aufrechterhaltung der Konsistenz, die Vermeidung von Bias und Halluzinationen sowie der hohe Entwicklungsaufwand für solche Multi-Agenten-Systeme (E. R. Mollick et al., 2024, S.2–3).

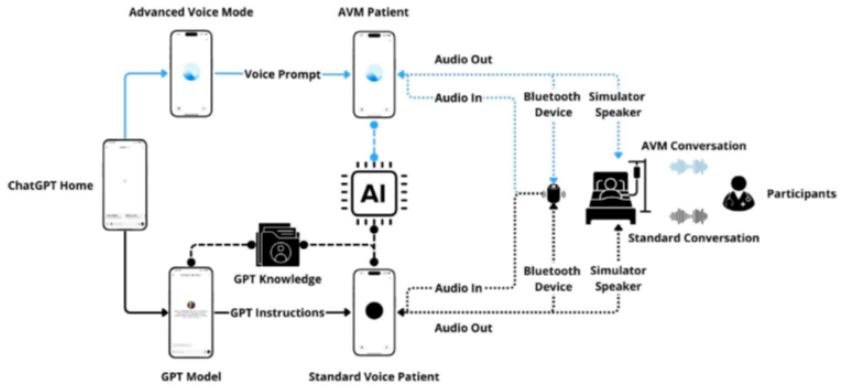

Fig. 1. Workflow of ChatGPT's Voice Modes in Medical Simulations This figure illustrates the workflow of ChatGPT's integration in medical simulations, comparing the Standard Voice Mode (SVM) and the Advanced Voice Mode (AVM). The SVM allows the embedding of specific knowledge into a customized GPT model, enabling audio interactions with simulated patients using Bluetooth devices and a simulator speaker. The AVM relies entirely on real-time voice prompts, providing a more immersive and natural interaction through dynamic responses but without embeddable customization. Both modes utilize audio devices to ensure realistic dialogue through the simulator, enhancing participant engagement during medical training sessions.

Abbildung 4.6. Nutzung der Voice Modes von ChatGPT für medizinische Simulationen. Quelle: Barra et al. (2024)

4.4.2 Goal Play – zielgerichtete Spiele

In **zielgerichteten Spielen** ("Goal Play", E. R. Mollick & Mollick (2024)) bleiben Studierende in ihrer normalen Rolle und wenden in einer Situation bestimmtes Wissen oder theoretische Konzepte an (z. B. Zielsetzung, Selbst-Distanzierung oder Analyseraster wie Transaktionskostenanalyse), indem sie einen KI-Charakter anleiten. Wichtig dabei: Die Studierenden wissen etwas, das das KI-Gegenüber im Spiel nicht weiß.

So nehmen etwa bei dem einfachen Rollenspiel **"Teach the AI"** (E. R. Mollick & Mollick, 2024, S.21–23) Studierende die Rolle des Lehrenden ein und erklären der KI (die einen unwissenden Studenten spielt) ein Konzept. Der Mehrwert liegt im vertieften Lernen durch Lehren (Protégé-Effekt) und dem Aufdecken eigener Wissenslücken. Als Herausforderung kann die KI manchmal vom Thema abweichen oder Fragen stellen, die die Studierenden an ihre Grenzen bringen; zudem ist die Simulation eines "Novizen" durch die KI nur begrenzt realistisch (E. R. Mollick & Mollick, 2024, S.24).

Für beide Typen gilt: Die KI kann von der Rolle abweichen oder inkonsistent agieren, und die Qualität der Erfahrung kann variieren. Eine **sorgfältige Einbettung und Reflexion** durch Lehrende ist entscheidend (E. R. Mollick & Mollick, 2024). Bei allen Simulatoren ist die Notwendigkeit einer klaren

didaktischen Rahmung und eines Debriefings durch Lehrende ("Human in the Loop") zentral, um den Lernerfolg zu sichern und die Grenzen sowie potenzielle Fehler der KI zu reflektieren (E. R. Mollick & Mollick, 2024, S.16).

Kernaussagen

1. Vier Rollen ordnen die Praxis: Als Hiwi nimmt die KI Arbeit ab, als Copilot ermöglicht sie, was wir allein nicht könnten, als Tutor begleitet sie Lernende, als Simulator stellt sie Übungssituationen bereit.
2. Technik ersetzt Tätigkeiten, nicht Berufe. In der Lehre verdrängt KI vor allem Standardisiertes, macht Kernaufgaben produktiver und schafft neue Aufgaben wie Qualitätskontrolle und Kursdesign. Ob am Ende Zeit gespart wird, ist offen.
3. Bei der Literaturrecherche entscheidet nicht der Markenname, sondern das Muster: einmalige Suche oder iterativer Prozess, Trefferliste oder zusammenfassende Analyse.
4. Schreiben und Programmieren mit KI sind Cyborg-Tätigkeiten. Der Lernwert hängt davon ab, wie viel die Studierenden selbst verstehen und verantworten müssen.
5. Ein guter KI-Tutor passt sich an, gibt sofort Rückmeldung, hält Lernende aktiv und entlastet Lehrende. Er braucht Musterlösungen als Input und systematische Qualitätstests, sonst produziert er überzeugende Fehler.
6. Simulationen wirken, wenn Lehrende sie rahmen und nachbesprechen. Die KI kann aus der Rolle fallen; der Mensch bleibt in der Schleife.

Zum Weiterdenken

1. Nehmen Sie Ihre eigene Aufgabenliste einer typischen Semesterwoche und sortieren Sie jede Aufgabe nach Verdrängung, Produktivität oder Wiedereinsetzung. Welche neue Aufgabe kommt bei Ihnen dazu, die Sie heute noch nicht einplanen?
2. Entwerfen Sie aus dem Gedächtnis einen Tutor-Prompt für ein Konzept Ihres Fachs. Welche drei didaktischen Bremsen bauen Sie ein, und woher bekommt der Tutor seine Musterlösungen?

3. Welche Berufssituation Ihrer Absolventinnen und Absolventen eignet sich für ein Role Play, welche für ein Goal Play? Was muss im Debriefing unbedingt zur Sprache kommen?

5 Empfehlungen zur Umsetzung

Lernziele

Nach diesem Kapitel können Sie ...

- ein Vorgehen beschreiben, um eigene Aufgaben mit einem Sprachmodell durchzuspielen und daraus Anpassungen abzuleiten;
- eine Einführung der Studierenden planen, die praktisch, häufig und niedrigschwellig ist;
- die vier Säulen Mündlichkeit, Prozessorientierung, Kontextualisierung und Kollaboration erklären und eine eigene Prüfungsleistung danach umbauen;
- die zentralen Elemente aktueller Hochschulrichtlinien zur KI-Nutzung wiedergeben, einschließlich der Grenzen von Detektionssoftware;
- Studierenden eine praktikable Form der Dokumentation ihrer KI-Nutzung vorgeben;
- einen bestehenden Kurs in Phasen mit KI als Hiwi, Copilot und Lernhilfe ergänzen und die Risiken mit Gegenmaßnahmen versehen.

5.1 Typische Aufgaben und Fragestellungen mit der KI durchspielen, Prompts anpassen, experimentieren

Lehrende sollten zunächst Informationen sammeln, um zu verstehen, was KI mit den Aufgaben in ihrem Kurs bewirken kann (MIT Teaching + Learning Lab, 2023). Melden Sie sich bei einem der professionellen KI-Dienste wie ChatGPT oder Claude an und spielen Sie mit exemplarischen Konzepten, Fragen und Aufgabensets aus dem Kurs. Dabei ist es wichtig, nicht gleich bei der ersten schlechten Antwort aufzugeben,

sondern Anpassungsmöglichkeiten durchzugehen: Lässt sich der **Input beschränken**? (Fragen auf einen Text-Input, eine gute Internetquelle oder eine hochgeladene PDF beschränken.) Lässt sich der **Prompt anpassen**? (Bearbeitung schrittweise durchführen lassen, Optionen und Szenarien durchgehen lassen usw., siehe den Abschnitt 2.5.2 zu Prompt Engineering.)

Wichtig ist, sich zu überlegen, welches Lernziel jede Aufgabe hat und wie die KI damit umgeht. Es sollte bewertet werden, bei welchen Arten von Fragen die KI gut abschneidet und wo ihre Grenzen liegen (E. R. Mollick, 2025c). Diese Erkenntnisse können dann genutzt werden, um etwa Aufgabensets und andere Aufgabenstellungen besser zu strukturieren.

5.2 Ausrichtung der Anpassungen nach Empfehlungen der Lernforschung

Um die Empfehlungen der Lernforschung in das Vorgehen mit Künstlicher Intelligenz (KI) und Aufgabensets zu integrieren, könnten folgende Schritte unternommen werden (MIT Teaching + Learning Lab, 2023):

- **Zeitliche Verteilung und inhaltliche Mischung von Lerninhalten (Spacing & interleaving)**: Die Aufgabensets sollten so gestaltet werden, dass sie über das Semester verteilt sind und eine Vielfalt an Themen abdecken. Dies fördert die Langzeiterinnerung und hilft den Studierenden, die Anwendung der Konzepte in verschiedenen Kontexten zu üben. KI kann genutzt werden, um personalisierte Lernpläne zu erstellen, die auf den individuellen Fortschritt der Studierenden abgestimmt sind und eine Mischung aus verschiedenen Aufgabentypen bieten.
- **Testgestütztes Lernen (Test-enhanced learning)**: Regelmäßige, durch KI unterstützte Quizze und Tests können in den Lehrplan integriert werden, um das Abrufen von Informationen zu fördern. Diese Tests könnten auch die kritische Bewertung von KI-generierten Antworten beinhalten, um die kritische Denkfähigkeit der Studierenden zu schärfen.
- **Fragebasierte Ausarbeitung (Explanatory questioning)**: KI-Tutor-Bots könnten entwickelt werden, um Studierende durch gezielte "Warum"-Fragen zu leiten, die ein tieferes Verständnis des Materials

fördern. Diese Bots könnten in Simulationen und Rollenspielen eingesetzt werden, um die Studierenden dazu zu bringen, ihre Entscheidungen zu erklären und zu reflektieren, wodurch die Anwendung von Konzepten in realen oder simulierten Situationen vertieft wird.

5.3 Einführung der Studierenden planen: Besser praktisch, häufig und niedrigschwellig

Den Einsatz von KI lernen die Studierenden, wenn sie häufig und über das Semester zeitversetzt damit experimentieren dürfen und müssen. Auch hier führen wieder die Empfehlungen des **Spacing & Interleaving** zu höherer Effektivität. Unterstützend können **externe Lernvideos** von seriösen Plattformen wie dem KI-Campus genutzt werden (z. B. https://ki-campus.org/videos/generativeki) oder selbst erstellte hochschulweite Angebote wie die Lehrpfade der TH Köln (https://lehrpfade.th-koeln.de/kategorie/ki/).

Um ein gemeinsames Verständnis über Grundlagen herzustellen, ist es hilfreich, **Zeit in einer der ersten Präsenzveranstaltungen einzuräumen**, um das gemeinsam zu üben. Der Sprung ins kalte Wasser ist dabei meist besser als eine lange Theorieeinführung: **Gleich anfangen**, dann problembasiert erläutern. Aspekte von **testbasiertem Lernen** und **fragebasierte Ausarbeitung** lassen sich gut über Anwendungsaufgaben in der Präsenzveranstaltung einbauen.

5.3.1 Beispiel: KI-Übung in Präsenzveranstaltung am Ende eines Theorieblock zu Nachhaltigkeit in Lieferketten

Aufgabe: Nicht lange schnacken, gleich anpacken! Mit der KI einen Projektplan für erste konkrete Schritte einer Nachhaltigkeitsstrategie erstellen (Edge Browser, Bing Copilot = GPT-4). Prompts zum Einstieg werden den Studierenden vorgegeben. Anfang mit:

- *Prompt #1*: „KI als Tutor“ oder ähnlich (siehe Appendix: Beispiel KI als Tutor #1/ Allgemeiner Tutor. Prompts im Folgenden immer *kursiv*.)

- *Prompt #2*: *Ich will eine Cradle-to-cradle Nachhaltigkeitsstrategie für ein Unternehmen entwerfen. Helfen Sie mir, konkrete erste Schritte nach der Cradle-to-cradle Zertifizierung zu planen.*

Studierende sollen ein Unternehmen auswählen, bei dem sie schon einmal gearbeitet haben, oder das sie gut kennen. Hier ein Beispiel.

- *Prompt #3*: *Ich denke über Voss Automotive nach, die folgende Produkte herstellen: innovative Leitungs-und Verbindungssysteme, die überall auf der Welt in Pkw und Nutzfahrzeugen sowie Land- und Baumaschinen eingesetzt werden. Unser Produktportfolio umfasst dabei einbaufertige Leitungsmodule mit Rohren, Schläuchen, Verbindungselementen, Ventilen und Sensoren. Zur Verbindungstechnik gehören Stecksysteme, Verschraubungen, Mehrfachkupplungen und Verteiler.*
- *Prompt #4*: *Erstelle einen Zeitplan als Tabelle mit Aufwandsschätzungen für 3 Personen in 4 Wochen.*
- *Prompt #5*: *Mehr Details bitte: Erstelle Unteraufgaben für die jeweiligen Aufgabenpakete, jeweils auch wieder mit Aufwandsschätzungen.*

Die Studierenden sollen den Projektplan dann weiter verbessern und diskutieren. Erweiternd können sie auch z. B. Projektrisiken, Indikatoren und Gegenmaßnahmen und Szenarien erheben und diskutieren.

5.4 Wie prüfen wir jetzt? Jenseits der Homework Apocalypse

Jenseits der vielen produktiven Anwendungen besteht die Gefahr, dass Studierende wichtige Teile des Denkprozesses an Sprachmodelle delegieren (H.-P. H. Lee et al., 2025). Klassische „Hausaufgaben“ wie **Seminararbeiten, Gruppenprojekte und Abschlussarbeiten drohen entwertet zu werden**. Ohne Anpassung der Aufgabenstellung werden die Aufgaben potenziell sinnlos, da Studierende etwa Aufsätze oder Reflexionsaufgaben einfach von Chat GPT schreiben und einreichen. Interviews mit Studierenden und Nutzungsstudien zeigen, dass diese Gefahr akut ist. Wie wir in der umfassenden empirischen Nutzungsstudie von Handa et al. (2025) sehen, nutzen Studierende Sprachmodelle speziell zur Schreibunterstützung intensiv und häufig. Das New York Magazine betitelt eine Recherche von 2025 mit „**Everyone is cheating their way through college**“, auf der Grundlage einer Vielzahl von Interviews mit desillusionierten Studierenden und Lehrenden (Walsh, 2025). Ein Artikel der Fachzeitschrift Nature

skizziert ebenfalls basierend auf Interviews ein breites Spektrum an aktiver Nutzung im höheren Bildungsbereich (Heidt, 2025).

Schon 2023 kündigte der Wharton Professor Mollick die „Homework Apocalypse“ an (E. R. Mollick, 2023). Dabei geht es Mollick weniger um das Tricksen mit den neuen technischen Möglichkeiten („Cheating was already common in schools“), sondern mehr um die **empfundene Sinnlosigkeit von klassischen Hausaufgaben**. „Students will want to understand why they are doing assignments that seem obsolete thanks to AI.“. Wer gibt noch reine Rechenübungen auf, wenn alle Taschenrechner haben? Wie kann Eigen- und Fremdleistung unter diesen neuen technischen Bedingungen getrennt werden? Wie können unter diesen Bedingungen Anreize für Studierende gesetzt werden, Texte selbst zu lesen und Sätze selbst zu formulieren?

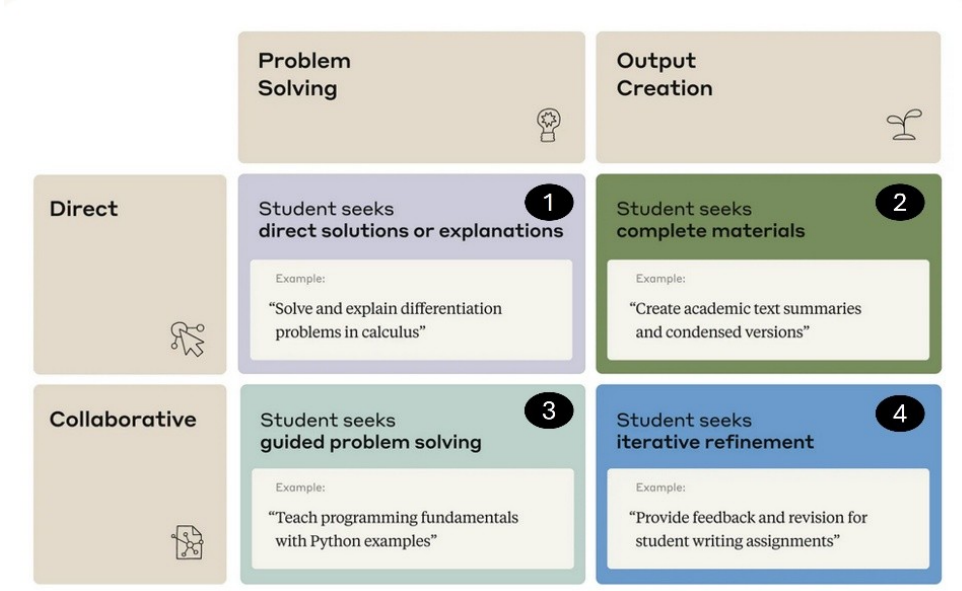

Abbildung 5.1. Etwa gleichverteilt: Vier Arten der Interaktion von Studierenden mit Sprachmodellen. Quelle: Handa et al. (2025)

Eine Unterscheidung der empirischen Anthropic-Studie von Studierenden-Interaktionen mit Sprachmodellen ist dabei hilfreich, um das Problem einzuordnen (Handa et al., 2025): Hier werden vier Arten von LLM-Nutzung unterschieden, je nachdem, ob ein **Problem** gelöst oder ein **Ergebnis generiert** werden soll und je nachdem, ob dies **direkt oder**

interaktiv erfolgt. Kollaborative Nutzungsformen (Typ 3 und 4) sind dabei für den Lernerfolg eher hilfreich, während das direkte Bereitstellen von Problemlösungen oder Texten aufgrund mangelnder Beschäftigung der Studierenden mit den Problemen und Materialien für Hausarbeiten eher hinderlich sein könnte (anders als für die Vorbereitung von kontrollierten Tests wie Klausuren). Studierende werden so eher in eine passive Rolle gedrängt und es fehlen die erwünschten Schwierigkeiten (desirable difficulties, (Roediger & Karpicke, 2006)), das fragebasierte Durchkauen und Hin- und Herüberlegen, das die Lernforschung als wichtig für langfristiges Behalten ansieht (Roediger & Pyc, 2012).

Grob gesagt wollen wir also **kollaborative Interaktion und Hilfestellung fördern und einfaches Übernehmen bereitgestellter Lösungen verhindern**. Wie können wir dafür die Hausarbeiten anpassen? Im Folgenden werden einige Empfehlungen zusammengefasst. Der Vier-Säulen-Ansatz nach Gmeiner bietet Orientierung. Er unterscheidet vier Gegenmaßnahmen für das Prüfen unter KI-Bedingungen: Mündlichkeit, Prozessorientierung, Kontextualisierung sowie Kollaboration (Gmeiner, 2025).

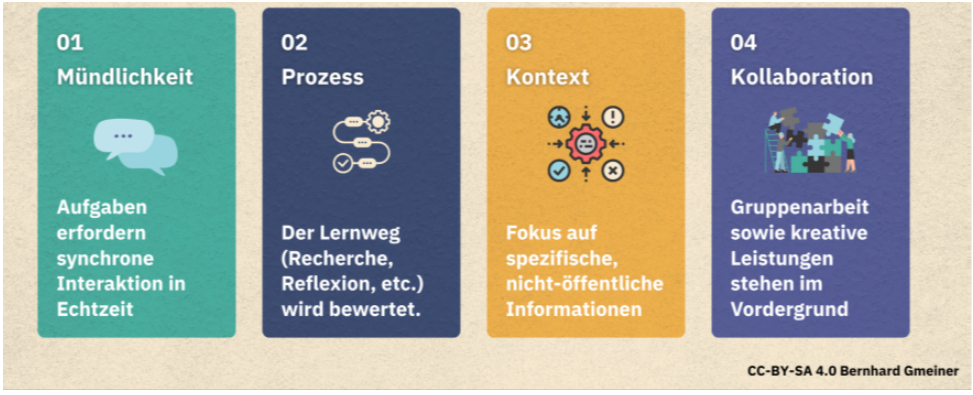

Abbildung 5.2. KI-resistente Aufgabenstellungen – 4 Säulen nach Gmeiner (2025)

5.4.1 Mündlichkeit

Mündlichkeit stärkt Verständnis, Transfer und Autorschaft. Disputation, Präsentationen mit strukturiertem Q&A und gezielte Kolloquien machen eigene Entscheidungen sichtbar. So verlieren generische KI-Texte an Wert. Leitfäden empfehlen diese Formate ausdrücklich als Ergänzung zu schriftlichen Arbeiten. Detektionsscores dienen nicht als Beweis, sondern

höchstens als Anlass zur Klärung (QAA, n. d.; Jisc, n. d.). Die University of Melbourne verweist auf skalierbare, mündliche Validierungen. Die folgende Übersicht zeigt typische Formate der mündlichen Prüfung.

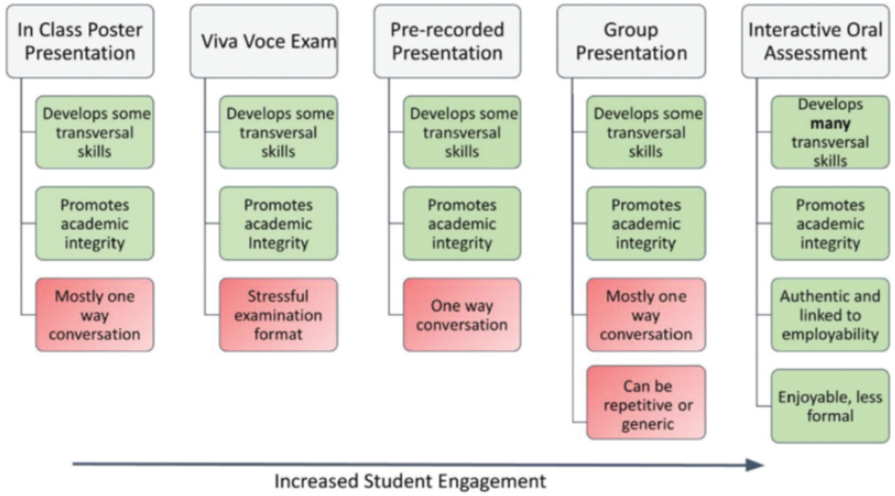

Abbildung 5.3. Vergleich mündlicher Prüfungsformen (Ward et al. (2024))

Hier sollen exemplarisch einzelne mündliche Prüfungsformate beschrieben werden, die Lehrende nutzen können.

Das erste Format ist das **Kurzkolloquium** („Viva Voce Exam“ in der Abbildung). Ziel ist der Nachweis von Verständnis und Autorschaft. Hier wird die schriftliche Arbeit vom Leistungsnachweis getrennt (Gmeiner, 2025) und die Lernenden müssen ihre Entscheidungen in der schriftlichen Arbeit erläutern und verteidigen. Die Studierenden reichen ihre schriftliche Arbeit ein, die auch mit KI-Unterstützung erstellt werden darf, und führen dann ein etwa zehnminütiges Gespräch über die Arbeit. Die Prüfenden wählen zum Beispiel zwei Kernentscheidungen zur weiteren Erläuterung aus: Datenaufbereitung und Argumentation. Die Studierenden erklären Vorgehen, Alternativen und Grenzen. Es folgt ein kurzes Transfer-Szenario: „Was würden Sie ändern, wenn…?“ Bewertet werden Klarheit, Begründung, Umgang mit Unsicherheit und Konsistenz zur Schriftfassung. KI-Regeln: KI-Nutzung wird offengelegt; Antworten sind persönlich und ohne Hilfsmittel. Skalierung gelingt mit standardisierten Leitfragen, Doppelprüfungen im Stichprobenprinzip und Aufzeichnung für Zweitbewertungen. Dieses Format eignet sich besonders für die Prüfung von Abschlussarbeiten und

lässt sich leicht auch auf Seminararbeiten übertragen. Ähnlich wie auch für das folgende Format müssen hierfür initial Bewertungsmatrizen erstellt werden, potentielle **Herausforderungen** sind situativer **Stress** und Aspekte von **Validität** (Form vs. Inhalt, einfache vs. schwere Fragen, mündliche vs. schriftliche Ausdrucksfähigkeit), **Reliabilität** (Rating-Unterschiede bei verschiedenen Nachfragen und Bewertenden, verschiedenen Szenarien usw.) und **Fairness** (z. B. Sprachfähigkeiten, Vorwissen). Vorteile sind die Reaktivität und die Möglichkeit, durch vertiefende Nachfragen Hintergrundwissen und Begründungen abzufragen (Akimov & Malin, 2020, S.31; Kearney, 2019).

Ein ähnliches Format, aber mit anderem Fokus ist die **interaktive mündliche Prüfung** (interactive oral assessment, IO). Hier erhalten die Studierenden ein praxisnahes Szenario, das sie in Interaktion mit den Prüfenden analysieren und bearbeiten müssen (Ward et al., 2024). Gestaltet werden IOs als offene, nicht im Detailablauf vorgegebene Gespräche in realitätsnahen Szenarien, geführt zwischen Studierenden und Prüfenden (oder zwischen Studierenden). So wird etwa gefordert, eine Situation oder eine Fallstudie mit Bezug auf das erlesene Vorwissen zu analysieren. Bewertet wird die Interaktion unterlegt durch präzise Rubriken (die auch gemeinsam mit den Studierenden entwickelt werden können (Ní Bheoláin et al., 2020)), Beispielaufnahmen zur Vorbereitung und formative Einbettung über das Semester. Beispiele für die Einbettung umfassen etwa, dass Studierende die Rolle von Interviewten in einer Talkshow einnehmen, oder im Duo ihre Erkenntnisse von einer Konferenzteilnahme erläutern müssen. International wird diese Prüfungsform durchaus in sehr großen Kohorten eingesetzt, von Erstsemester-Kursen mit ca. 200 bis zu 800 Studierenden, mit 4 bis 10 Prüfenden (https://sway.cloud.microsoft/yQ2s0Bm3ILkWtGll). Es gibt eine Reihe detaillierter **Leitfäden zur Umsetzung solcher Szenario-Prüfungen** mit Aufnahmen von Beispielprüfungen und den Bewertungsrubriken (https://www.dcu.ie/sites/default/files/inline-files/interactive-oral-io-user-guide_0.pdf , siehe speziell die Übersicht der Ressourcen auf S. 11).

Ein drittes Format ist die **Posterpräsentation** mit strukturiertem Q&A. Die Studierenden erstellen ein Forschungs- oder Praxisposter und präsentieren für fünf Minuten. Danach folgen gezielte Fragen zu Methode, Evidenz und Limitationen. Artefakte sind Poster, ein einseitiges Handout und ein Frageprotokoll. Bewertet wird die Evidenzführung, Passung von Methode und Frage sowie die Qualität der Antworten. KI darf für Layout und

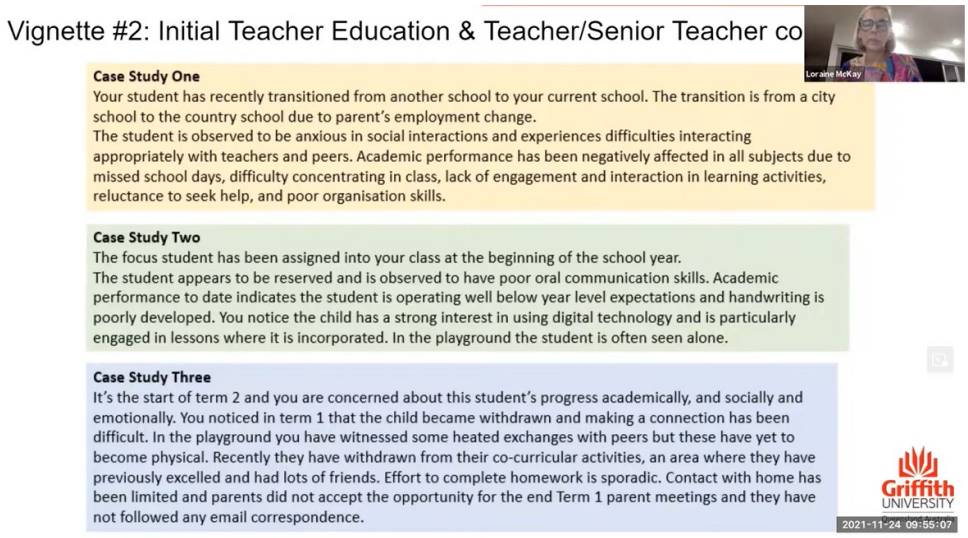

Abbildung 5.4. Mündlich prüfen geht auch in großen Kohorten – Beispiele von verschiedenen Universitäten

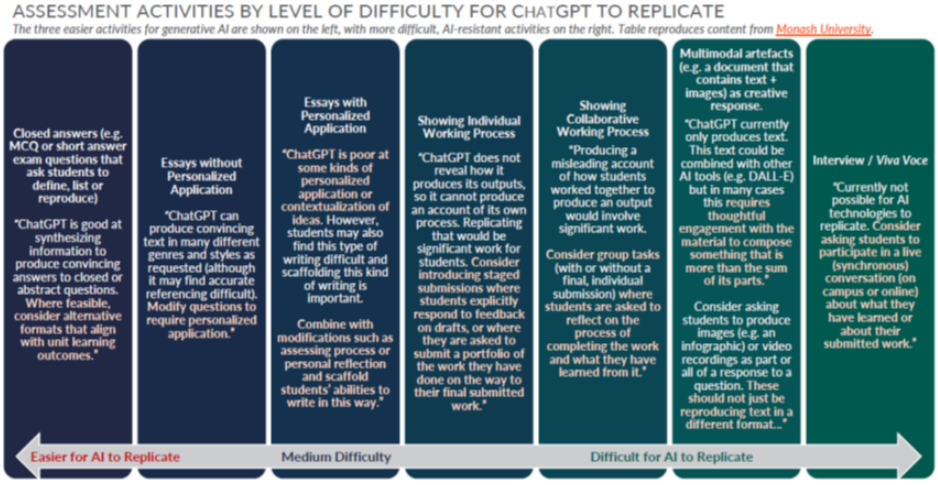

Abbildung 5.5. Drei Szenarien für eine mündliche Prüfung in Pädagogik

Sprachpolitur helfen, nicht für Inhalt. Offenlegung ist Pflicht. Große Gruppen lassen sich mit parallelen „Poster-Sessions“ und festen Zeitslots prüfen.

Für **Abschlussarbeiten** kann diese Ausweitung der mündlichen Prüfungskomponente so operationalisiert werden, dass die Gewichtung des Kolloquiums erhöht wird, bzw. ein zweites Kolloquium hinzugefügt wird (um die Belastung der mündlichen Prüfung zu verteilen), in dem die Studierenden ca. 1 Monat nach dem Beginn der Abschlussarbeit mündlich den Stand der Forschung zum Thema darstellen und die Forschungslücke begründen müssen. Ein Entwurf an der TH Köln (Stand 2025) sieht hierfür so aus: * Kolloquium 1: Stand der Forschung und resultierende Forschungsfragen (3 ECTS) * Schriftliche Arbeit (8 ECTS) * Kolloquium 2: Ergebnis der Abschlussarbeit (4 ECTS) (Früher: Schriftliche Arbeit = 12 ECTS, Kolloquium = 3 ECTS).

5.4.2 Prozessorientierung

Prozessorientierung rückt den Weg zum Ergebnis in den Mittelpunkt und liefert über die stärkere Teilhabe der Prüfenden am Erstellungsprozess Evidenz für Autorschaft und verantwortliche KI-Nutzung. Insofern empfehlen die meisten Ratgeber, das Gewicht vom Produkt auf den Prozess zu verlagern. Ein Ratgeber der Melbourne University empfiehlt ausdrücklich, „vom Produkt zum Prozess“ zu wechseln, Prozess-Notizbücher und Reflexionen einzubauen und mit Umgebungen wie Cadmus digitale Prozess-Spuren zu erfassen (Mulder et al., 2023). Eine Studie von Hanover Research fordert gestaffelte Abgaben über die Zeit mit intensiver, iterativer Rückmeldung und betont, dass die Sichtbarmachung individueller und kollaborativer Arbeitsprozesse KI-Nutzung unattraktiv macht (Hanover Research, 2024). Empfehlungen der Monash University konkretisieren dies: Prozessbewertungen, verbundene Aufgaben und Einbindung der Prüfenden in den Entstehungsprozess (Monash University, 2025). Gmeiner operationalisiert Prozessfokus zudem durch transparente KI-Nutzungsdokumentation mit Prompt-/Output-Belegen und reflektierter Einbettung in die Eigenleistung (Gmeiner, 2025).

Ein zentrales Format ist das **Prozessjournal mit Audit-Trail**: Studierende dokumentieren Suche, Auswahl, Analyse, Entscheidungen und Revisionen fortlaufend; ein Versionsverlauf in Overleaf oder Git macht Änderungen nachvollziehbar. Abgegeben werden Journal, Query-Protokolle, Daten-/Code-Paket und Endprodukt. Bewertet werden Nachvollziehbarkeit,

Grad der Verwendung / Arbeitsschritt	Zur Inspiration	Ergänzend	Unterstützend	Inhaltsgestaltend
Thema finden und konkretisieren	*ChatGPT: Vorschläge für mögliche Themen gesammelt*			
Aufgabenstellung verstehen				
Recherchieren	*ChatGPT: nach Tipps gefragt, wo ich meine Literatursuche starten kann*			
Vorbereitung der Untersuchung	*ChatGPT: Generierung verschiedener Interviewfragebögen, um Aufbau und Fragestil zu verstehen.*			
Literatur/Daten auswerten		*ChatGPT: Begriffe, die ich nicht verstanden habe, erklären lassen*		*OpenAI Whisper: automatische Transkription der geführten Interviews* *Genei AI: Auswertung der Transkripte nach den untersuchten Gesichtspunkten*
Planen und strukturieren			*ChatGPT: Diskussion über meine Struktur, Ergänzung von Punkten, die ich übersehen hatte*	
Schreiben				*DeepL: Übersetzung aller Textstellen, die auf Englisch benötigt wurden*
Überarbeiten			*Microsoft Copilot: Überarbeitung von Rechtschreibung und Formulierungen* *DeepL Write: Verbesserung der Formulierungen in englischen Übersetzungen*	*ChatGPT: Inhaltliches Feedback zu meiner Arbeit, Chat-Gespräch über die Pointierung der Fragestellungen und die Tiefe der Argumentation*

Abbildung 5.6. Abhilfe durch Interaktion oder engere Prozessbetreuung: Aufgabentypen nach der Schwierigkeit, durch KI repliziert zu werden (Hanover Research (2024))

Qualität der Entscheidungen, Reproduzierbarkeit und eine reflektierte Darstellung der KI-Nutzung (Tool, Version, Prompts, Zweck, Umfang, Korrekturen). Detektoren entfallen; der dokumentierte Prozess bildet die Hauptgrundlage der Beurteilung.

Als zweites Format bietet sich die **gestaffelte Hausarbeit** an: Outline, Annotated Bibliography, Methoden-Memo, Rohanalyse, Draft und Final werden über das Semester verteilt, jeweils mit Feedback und klar getrennten Prozess- und Produktpunkten in der Rubrik. KI kann bei Ideenfindung und Sprachpolitur helfen, nicht bei Theoriebildung oder Ergebnissen; Nutzung und kritische Einordnung sind offenzulegen. In großen Kohorten tragen Peer-Reviews nach Rubrik und stichprobenhafte Dozierenden-Checks zur Skalierung bei.

5.4.3 Kontextualisierung und empirischer Bezug

Kontextualisierung und Empirie binden Leistung an reale Daten, Orte und Rollen und entwerten generische KI-Outputs. Die Leitfäden empfehlen realweltliche, lokal verankerte, persönlich bezogene Aufgaben. Melbourne CSHE listet explizit „authentische, kontextspezifische oder persönliche“ Aufgaben – etwa Analysen weniger bekannter lokaler Objekte, Bezüge zu persönlicher Erfahrung oder Aufgaben, die genuine Berufsprodukte erzeugen (Mulder et al., 2023). Monash rät, Essayaufgaben so zu verändern, dass personalisierte Anwendung und Kontextualisierung zwingend sind; außerdem werden multimodale Artefakte als KI-resistenter eingestuft (Monash University, 2025). Gmeiner präzisiert diese Logik: biografisches Lernen, Aufgaben an außerschulischen Lernorten oder tagesaktuelle Kontexte machen die Aufgabe „un-promptbar“, weil sie persönliche, physische oder nicht-öffentliche Informationen, sinnliche Beobachtung und Gegenwartsbezug erfordern (Gmeiner, 2025).

Selbst erhobene Empirie zählt, reine Literaturstudien oder theoretische Ausarbeitungen sind zu vermeiden. Interviews, Prozessanalysen, der Bau eines Prototypen oder sonstige Erhebungen von Primärdaten verlangen, dass Studierende einen passenden Fall auswählen, Daten erheben oder kuratieren, diese methodengerecht analysieren und eine Entscheidungsvorlage erstellen. Abzugeben sind Datensatz, Methodenprotokoll, Analyse-Notebook und eine kurze Empfehlung; bewertet werden Kontextpassung, Datenqualität, methodische Angemessenheit und die Tragfähigkeit der Handlungsempfehlung. KI darf strukturieren,

nicht aber Evidenz ersetzen. Alternativ können Replikations- und Verifikationsaufgaben genutzt werden: Studierende replizieren eine veröffentlichte Analyse, dokumentieren Abweichungen und prüfen Robustheit mit alternativen Spezifikationen. Artefakte sind ein vollständiges Repro-Paket, ein Abweichungsprotokoll und ein Kurzbericht, der klar ausweist, was trägt und was nicht. KI kann Code-Snippets vorschlagen, doch jede Zeile wird verstanden, kommentiert und getestet. Offenlegung der Tool-Nutzung bleibt Pflicht. Automatisierte Checks und präzise Rubriken halten den Korrekturaufwand im Rahmen.

Für Abschlussarbeiten kann dies so operationalisiert werden, dass reine Literatur- oder Theoriearbeiten ohne empirischen Bezug vom Prüfungsausschuss zu genehmigen sind.

5.4.4 Kollaboration und Kreation

Kollaboration und Kreation prüfen die soziale, evaluative und kreative Dimension des Lernens und machen Aushandlung und Revision sichtbar. Die Leitfäden schlagen in diesem Kontext etwa In-Class- und Gruppenaufgaben, Peer-/Selbstbeurteilung und gestufte Projekte vor. Melbourne CSHE zeigt in mehreren Fallbeispielen, wie verschachtelte Aufgaben mit Gruppen-Literaturarbeit, Projektplänen, Peer-Review und Präsentationen kombiniert werden. Diese Designs stärken Prozess-Transparenz, evaluative Urteilskraft und erschweren KI-Missbrauch (Mulder et al., 2023). Hanover Research betont ähnlich Gruppenarbeiten, In-Class-Aktivitäten und Aufgaben, die die Nutzung von KI explizit erlauben, aber kritisch auswerten lassen – also Kreation plus Metareflexion (Hanover Research, 2024).

Wie kann so etwas aussehen? Ein peer-reviewtes Multimedia-Projekt etwa verlangt, dass kleine Teams ein konkretes Produkt – Podcast, Video oder Infografik – für ein definiertes Publikum erstellen. Der Prozess umfasst Briefing, Drehbuch, Quellenkurzprüfungen, Prototyp, Peer-Feedback und Finalisierung. Bewertet werden Evidenzbasis, Storyline, Zielgruppenpassung, Feedbackqualität und die Umsetzung der Rückmeldungen; neben dem Produkt liefern Teams Quellenlisten, Peer-Feedback-Protokolle und individuelle Reflexionen. Alternativ können Rollen- oder Planspiele erstellt oder bearbeitet und reflektiert werden (Gmeiner, 2025). KI kann als Ideengeber dienen, doch Entscheidungen

und Quellenhoheit verbleiben beim Team; kurze Nachgespräche sichern Autorschaft ab.

Als Abschlussformat eignet sich ein Team-Capstone mit getrennter Team- und Individualnote: Das Team liefert ein belastbares Artefakt – etwa einen Prototyp, eine Konzeptstudie oder einen Policy-Brief mit Daten –, während jede Person einen individuellen Methoden-Anhang und eine Reflexion zum eigenen Beitrag und zur KI-Nutzung abgibt. Bewertet werden Teamprodukt, individueller methodischer Beitrag und die Qualität der Reflexion; klare KI-Regeln fordern Offenlegung, Bias-Prüfung und Quellenverifikation. Milestone-Boards, strukturierte Peer-Assessments und stichprobenhafte mündliche Abfrage pro Team sichern Skalierbarkeit und Integrität.

Kombiniert man die vier Säulen, entsteht eine Vielzahl von Optionen für ein konsistentes, skalierbares Prüfungsdesign, das auf Transparenz, Prozessnähe und reale Anwendung setzt. Mündliche Elemente sichern Autorschaft und Transfer, prozessorientierte Formate liefern nachvollziehbare Evidenz, kontextgebundene Aufgaben prüfen Verständnis unter realen Bedingungen, und kollaborative Produkte stärken Urteilskraft, Feedbackkultur und Kreativität. Klare Richtlinien, Offenlegung und belastbare Rubriken tragen das Konstrukt. KI-Detektoren werden überflüssig, weil die Beweise im Prozess liegen und Prüfende enger an diesem Prozess teilnehmen und in den vorgestellten Prüfungsformen interaktiv nachfragen können. Dies alles aufzusetzen bedeutet durchaus hohe Initialaufwände und die neuen Prüfungsformen müssen evaluiert werden, um bekannte Probleme etwa des Prüfens in direkter Interaktion (Validität, Reliabilität, Fairness, s. o.) einzudämmen (Akimov & Malin, 2020). Positiv dabei: **Es gibt schon viele Vorlagen, auf die man aufbauen kann**, und durch diese Anstrengungen bleiben Integrität und Qualität der Prüfungen gewahrt – die oben genannte **Furcht vor Betrug und Sinnlosigkeit der Prüfungen wird eingedämmt**, ohne dass auf reines Klausurlernen zurückgefallen werden muss, während Studierende lernen, KI verantwortlich, nachvollziehbar und wirksam einzusetzen.

5.5 Richtlinien zur KI-Nutzung - welche Handreichungen geben Hochschulen und was wird empfohlen?

5.5.1 Übersicht: Was regeln die Richtlinien der Hochschulen?

Wie reagieren Hochschulen auf die Chancen und Herausforderungen von LLM? Eine Übersichtsstudie von An et al. (2025) untersucht die **Richtlinien der Top 50 US Hochschulen zur Nutzung von LLM**. Mittels Topic Modeling identifizieren sie vier zentrale Themenfelder: die Integration von LLM in Lehre und Prüfungen, die Nutzung in visuellen und interaktiven Medien, Fragen der Sicherheit und Ethik sowie die Wahrung akademischer Integrität. Die Sentimentanalyse zeigt eine insgesamt positive Haltung gegenüber LLM, insbesondere in Richtlinien für Lehrende und Verwaltungspersonal. Studierendenrichtlinien sind hingegen zurückhaltender und stärker auf Einschränkungen fokussiert. Die Analyse differenziert die Inhalte nach Zielgruppen: Während Lehrende vor allem Unterstützung für Kursdesign und Prüfungsformate erhalten, stehen bei Studierenden Regelungen zur Integrität im Vordergrund. Forschende und Verwaltungspersonal werden bislang weniger berücksichtigt, obwohl sie ebenfalls spezifische Herausforderungen und Potenziale im Umgang mit LLM aufweisen. Die Autor:innen empfehlen daher eine stärkere Differenzierung und kontinuierliche Weiterentwicklung der Richtlinien, den Verzicht auf unzuverlässige Detektionstools sowie eine institutionenübergreifende Reflexion über ethische, rechtliche und didaktische Implikationen.

Speziell deutsche Leitlinien an 27 Hochschulen untersuchte das Hochschulforum Digitalisierung im Jahr 2024 (Tobor, 2024), ein Update im Februar 2025 ergänzt neuere Entwicklungen (Tobor, 2025). Die Analyse umfasst hochschulweite Leitlinien deutscher Universitäten zum Umgang mit generativer KI. Dabei hebt Tobor eine Reihe bewährter Praktiken hervor, die sich in mehreren Leitfäden wiederfinden (Für konkrete Beispiele siehe Appendix 2: Beispiele für KI-Richtlinien):

- Ein zentrales Element ist die **Anpassung der Eigenständigkeitserklärung** in schriftlichen Prüfungen ohne Aufsicht. Viele Hochschulen – exemplarisch die Vorlage der Hochschule RheinMain – fordern darin von Studierenden eine explizite Erklärung, ob und in welcher Weise KI-Tools verwendet wurden. Diese Erklärungen dienen der Transparenz und ermöglichen Lehrenden, KI-Nutzung regelkonform einzuordnen.

- Im Umgang mit **Verdachtsfällen unzulässiger KI-Nutzung** betonen viele Leitlinien die Grenzen technischer Erkennung. Tools wie GPTZero gelten als unzuverlässig. Stattdessen wird – wie im Leitfaden der Universität Vechta – ein **multifaktorielles Vorgehen** empfohlen, das Indikatoren wie nicht reale Quellen oder auffällige Formulierungen einbezieht. Bestätigt sich der Verdacht, erfolgt ein **Klärungsgespräch**, um das Verständnis der Studierenden für ihre Arbeit zu überprüfen.
- Im Bereich **Urheberrecht** wird festgehalten, dass KI-Systeme wie ChatGPT nach damaligem Rechtsstand (2024/25) keine Urheber im juristischen Sinne sind. Ihre Inhalte stellen daher nicht automatisch ein Plagiat dar, können aber Rechte Dritter verletzen. Die Verantwortung für eine rechtskonforme Nutzung liegt bei den Studierenden – klare gesetzliche Regelungen stehen noch aus.
- Kritisch sehen viele Hochschulen die **Verwendung von KI zur automatisierten Bewertung** von Prüfungsleistungen. Diese widerspricht in der Regel Prüfungsordnungen, die eine begründete Bewertung durch eine prüfende Person verlangen. Zudem wird das Hochladen studentischer Arbeiten in KI-Systeme als urheberrechtlich bedenklich eingestuft.
- Schließlich fordern zahlreiche Leitlinien eine **didaktische Weiterentwicklung von Prüfungsformaten**. Empfehlungen reichen von stärker reflexionsorientierten Aufgaben über Zwischenfeedback und methodische Transparenz bis hin zu ergänzenden mündlichen Prüfungen. Ziel ist es, den Kompetenznachweis trotz verfügbarer KI-Tools aussagekräftig zu gestalten. Dabei sollte auch der Umgang mit KI selbst – inklusive Prompt-Gestaltung oder kritischer Reflexion – zum Prüfungsgegenstand werden. Lehrende werden ermutigt, den Einsatz von KI gemeinsam mit den Studierenden zu reflektieren und klare Regeln im Kurs zu kommunizieren.

Im Update von 2025 stellt Tobor auch kritisch die **thematische Zersplitterung** der verschiedenen Handreichungen fest: Die Richtlinien versuchen, eine Vielzahl von Einzelthemen für eine Vielzahl von Gruppen zu integrieren, speziell regulatorische und didaktische. Hinzu kommen Anforderungen zur Risikoaufklärung über Themen wie Halluzinationen, Vorurteile von LLM in den Ergebnissen und Ressourcenverbrauch. Die europäische KI-Verordnung (KI-VO) verschärft die Anforderungen an Hochschulen, insbesondere im Hinblick auf KI-Kompetenzen und Risikoeinstufungen bei Prüfungen. Positiv werden **integrierende Formate wie "Landing**

Pages“ genannt, etwa der KI-Hub der Universität Vechta (https://www.uni-vechta.de/ki-hub). Ein solcher zentraler Startpunkt kann allgemeine und spezielle Themen verbinden und – bei guter Kuratierung – helfen, Komplexität zu reduzieren.

5.5.2 Allgemeine Empfehlungen zu Richtlinien

An et al. (2025) plädieren für ausgewogenere, zielgruppenspezifische Leitlinien, die sowohl regulatorische Klarheit als auch didaktische Impulse bieten – insbesondere für Studierende, deren Perspektive bislang zu wenig berücksichtigt wird. Was für didaktische und regulatorische Aspekte für Lehrende und Studierende werden hier festgelegt?

Für **Lehrende** stehen didaktische Empfehlungen im Vordergrund, die auf eine bewusste Integration generativer KI in die Hochschullehre zielen. In 94 % der untersuchten Richtlinien werden konkrete Hinweise gegeben, wie LLM in **Kursdesign, Aufgabenstellungen und Prüfungsformate** eingebunden werden kann. Lehrende werden ermutigt, im Syllabus klar zu definieren, ob und wie der Einsatz von KI erlaubt ist – etwa durch gestufte Erlaubnisformen (verboten, erlaubt mit Dokumentation, ausdrücklich gewünscht). Zudem wird empfohlen, Prüfungsformate so umzugestalten, dass sie weniger anfällig für unreflektierte KI-Nutzung sind, z. B. durch individuelle Reflexionen, Gruppenarbeit oder mündliche Komponenten. Regulatorisch wird betont, dass die Verantwortung für die Formulierung und Durchsetzung dieser Regeln bei den Lehrenden liegt, jedoch unterstützt durch hochschulweite Orientierungshilfen. KI-Detektionstools wie Turnitin oder GPTZero werden hingegen kritisch gesehen: Viele Hochschulen raten von deren Einsatz ab, da ihre Ergebnisse unzuverlässig seien und leicht zu Fehlinterpretationen führen können.

Für **Studierende** betonen die Richtlinien vor allem regulatorische Aspekte im Sinne der **akademischen Integrität**. Häufig wird darauf hingewiesen, dass LLM nicht uneingeschränkt eingesetzt werden darf, und dass ein nicht genehmigter Einsatz als Täuschungsversuch gewertet werden kann. Die Verantwortung zur Klärung, ob LLM zulässig ist, wird den Studierenden zugeschrieben – sie sollen aktiv Rücksprache mit Lehrenden halten. Didaktisch werden Studierende allerdings meist weniger unterstützt: Nur wenige Richtlinien bieten Anleitungen zur kompetenten Nutzung von LLM oder reflektieren über sinnvolle Lernstrategien im Umgang mit KI. Eine Ausnahme bilden vereinzelte Hinweise zur Förderung von **AI**

Literacy, etwa zur kritischen Bewertung von KI-generierten Texten oder zur Transparenzpflicht bei der Nutzung von LLM in Hausarbeiten. Insgesamt dominiert jedoch eine **restriktive und kontrollierende Perspektive**, die stärker auf Vermeidung von Fehlverhalten als auf befähigende Lernangebote setzt.

Die deutsche Untersuchung von Tobor (2025) betont, dass die Wirksamkeit solcher Leitlinien maßgeblich davon abhängt, ob sie **bekannt gemacht, kontinuierlich diskutiert und weiterentwickelt** werden. Zentral ist es, die Leitlinien User-adäquat zu gestalten und bekannt zu machen. (Auch hier begegnen uns implizit wieder die zentralen Kategorien Nutzerfreundlichkeit und wahrgenommene Nützlichkeit des Technology Acceptance Models.) Tobor warnt davor, Leitlinien als bloße Beruhigungsmittel zu betrachten, und fordert stattdessen eine **dialogische, ko-kreative Weiterentwicklung** – etwa durch Beteiligung von Studierenden, verbundweite Zusammenarbeit und neue Formate wie Prompt-Battles. Leitlinien sollten als lebendige Rahmenwerke verstanden werden, die zur aktiven Gestaltung des KI-bedingten Wandels in Studium und Lehre beitragen.

Wie sehen solche Richtlinien aus? Konkrete Formulierungen und Links hierzu finden Sie im Appendix 2: Beispiele für KI-Richtlinien.

5.6 Wie können Studierende die Nutzung von LLM dokumentieren? Stichworte, nach Arbeitsphase, nach Werkzeug oder als Reflexionstagebuch

Frühe Handreichungen zur Dokumentation von LLM in Studierendenarbeiten waren noch sehr allgemein formuliert und bestanden etwa darauf, dass **jegliche Nutzung im Schreibprozess** genau protokolliert würde. Bei täglicher und stark integrierter Nutzung ist das etwa so sinnvoll, wie die Forderung, jegliche Internetnutzung in einem Tagebuch zu erfassen. Sinnlose Forderungen führen schnell dazu, dass die dahinter stehende Forderung nach prinzipieller Nachvollziehbarkeit des Forschungsvorgehens entwertet und Umgehungshandlungen normalisiert werden.

Neuere Empfehlungen der Hochschulen sind hier deutlich realistischer: So bietet etwa eine Handreichung von niedersächsischen Hochschulen eine gute **Reihe von Optionen**, die von einer einfachen Stichpunktliste („elicit.com zur Literaturrecherche, perplexity.ai zur Internetrecherche,

gamma.app zur Präsentationserstellung, stablediffusionweb.com zur Bildgeneration“) bis zu detaillierten Tagebüchern mit Reflexionshilfen reicht (Baresel et al., 2024).

Im Folgenden zeigen wir drei weitere Beispiele für Dokumentationen nach Arbeitsphasen, nach Werkzeugen und in Form eines Reflexionstagebuches (Baresel et al., 2024).

Die Dokumentation nach **Arbeitsphasen** (s. Tabelle 5.1) zielt auf eine strukturierte Erfassung des KI-Einsatzes entlang typischer wissenschaftlicher Arbeitsphasen (z. B. Themenfindung, Recherche, Schreiben). Studierende bewerten selbst den Grad der KI-Nutzung (von „inspirierend“ bis „inhaltsgestaltend“) und dokumentieren Tool, Einsatzkontext und Wirkung. Ziel ist Transparenz über den konkreten Einfluss auf das Ergebnis.

Bei der **werkzeugorientierten** Dokumentation (s. Tabelle 5.2) werden in tabellarischer Form die verwendeten Tools (z. B. ChatGPT, DeepL Write) samt Quelle, Zweck, Funktion und Einsatzbereich gelistet. Diese Variante erleichtert die Nachvollziehbarkeit, gibt aber wenig Einblick in den Kontext oder den Einfluss der Tools auf den Arbeitsprozess.

Beim **Reflexionstagebuch** (s. Tabelle 5.3) steht die kontinuierliche, persönliche Auseinandersetzung mit dem eigenen KI-Einsatz im Vordergrund. Studierende führen während des Arbeitsprozesses ein Tagebuch, das später in eine prüfungsrelevante Dokumentation überführt wird. Diese Methode fördert den Aufbau von **KI-Literacy** und metakognitiver Kompetenz, ist jedoch zeitaufwändig und betreuungsintensiv.

Phase im Arbeitsprozess	Dokumentation: Eingesetzte Tools, Verwendungszweck, Funktionsweise, Ergebnis	Grad der KI-Nutzung
Ideenfindung/Strukturierung	**Tools**: ChatGPT, Perplexity **Zweck**: Brainstorming zu Forschungsfragen, Gliederungsideen **Ergebnis**: 5 Themenvorschläge, davon 1 weiterverfolgt	1

Phase im Arbeitsprozess	Dokumentation: Eingesetzte Tools, Verwendungszweck, Funktionsweise, Ergebnis	Grad der KI-Nutzung
Recherche	**Tools**: Elicit, Semantic Scholar **Zweck**: Suche nach passender Literatur **Ergebnis**: Liste mit 15 Quellen, 8 davon verwendet	2
Schreiben/Formulieren	**Tools**: DeepL Write **Zweck**: Verbesserung des sprachlichen Ausdrucks **Ergebnis**: Überarbeitete Einleitung	3
Überarbeitung/Korrektur	**Tools**: Grammarly **Zweck**: Prüfung auf Grammatik- und Rechtschreibfehler **Ergebnis**: Fehlerfreier Text	2

Tabelle 5.1. Beispiel arbeitsphasenorientierte Dokumentation der LLM Nutzung. Quelle: (Baresel et al. (2024), S. 11)

Software/Programm/KI-Anwendung	Link/Quelle	Verwendungszweck	Genutzte Funktion	Nutzungsbeschreibung/A
appypie	https://www.appypie.com/design/ai-infographic-maker	Infografiken zur Erläuterung	Erstellung von Infografiken für einen Verwendungszweck	Infografik erstellt für einen Überblick in der Einleitung, S. 3

Software/Programm/KI-Anwendung	Link/Quelle	Verwendungszweck	Genutzte Funktion	Nutzungsbeschreibung/A
Claude	https://claude.ai/	Assistenz zur Programmierung, Vorschläge für Gliederung	Chat und Code-Ausgabe	Programmierung des Auswertungsprogramms siehe S.13 Erstaufschlag der Gliederung, wurde überarbeitet
DeepL Write	https://www.deepl.com/de/write	Überarbeitung der Texte	Entspricht Verwendungszweck	Gesamter Text
DeepL Übersetzer	https://www.deepl.com/de/translator	Übersetzung von französischsprachigen Papers	Französisch–Deutsch	Die Paper Lacroix, 2007 & Macron, 2020 wurden übersetzt.
KiCad[2]	https://www.kicad.org/	Layout der Testplatine	PCB Layout	Layout der Platine, siehe Abb. 15 S. 20
MATLab	Hochschullizenz	Simulation der Empfängerschaltung	Simulink	Schaltung xyz auf S. 14 simuliert und optimiert
MaxQDA	Hochschullizenz	Auswertung Interviews	MaxQDA und AI Assist	Kategorienbildung, siehe Kap 4.2 und Anhang C

Software/Programm/KI-Anwendung	Link/Quelle	Verwendungszweck	Genutzte Funktion	Nutzungsbeschreibung/A
Openknowledgemaps	https://openknowledgemaps.org/	Recherche des Forschungsfelds	Entspricht Verwendungszweck	Für die Einarbeitung wurde mit diesem Tool der Zugang zum Forschungsfeld erschlossen.
SPSS	Hochschullizenz	Auswertung Daten zur Gesundheitsversorgung	Hypothesentest mittels xy	Datenauswertung siehe S. 15 und Anhang S. 77
Visual Studio C++	Hochschullizenz	Programmierung einer Navigationslösung	Entspricht Verwendungszweck	Programmierung des zentralen Programms der Arbeit, siehe Kap. 4
Whisper (openAI)	https://openai.com/index/whisper/	Transkribieren von Interviews	Transkribieren ohne Übersetzung	Transkribieren der Interviews, wurden korrigierend überarbeitet. Siehe Anhang B

Tabelle 5.2. Beispiel werkzeugorientierte Dokumentation der LLM Nutzung. Quelle: (Baresel et al. (2024), S. 8)

Datum	Woran habe ich gearbeitet? (Stichpunkte)	Welche digitalen Tools habe ich verwendet?	Notizen zum Einsatz digitaler Tools	Reflexion	Beleg/Beispiel	Grad der Nutzung
1.9.24	Themenfindung	ChatGPT 3.5 über Academic Cloud	Versuch, einige Begriffe zu schärfen Fragestellungen vorschlagen lassen	Hilfreich, um Fachbegriffe zu identifizieren Agenden Begriffen mal Fragestellungen machen lassen. Das traf es aber nicht wirklich. Ich muss noch weitermachen.		1 2

Datum	Woran habe ich gearbeitet? (Stichpunkte)	Welche digitalen Tools habe ich verwendet?	Notizen zum Einsatz digitaler Tools	Reflexion	Beleg/Beispiel	Grad der Nutzung
2.9.24	Texte lesen	ChatPDF	2 Texte hochgeladen, geprüft, ob relevant	Toll, dass ich deutsch fragen kann, auch wenn der Text englisch/italienisch ist. Entlastet! Macht das Lesen gezielter. Merke aber auch, dass ich dann den Text nicht mehr ganz lese.		2

Datum	Woran habe ich gearbeitet? (Stichpunkte)	Welche digitalen Tools habe ich verwendet?	Notizen zum Einsatz digitaler Tools	Reflexion	Beleg/Beispiel	Grad der Nutzung
5.9.24	Bild generieren	bing.com/create	Illustration für die Präsentation zum Projekt	Macht Spaß! Ist aber auch aufwändig, genau das zu prompten, was man haben will. Zeitfresser.	Denken findet in der Auseinandersetzung von Mensch mit Maschine statt; Künstliche Intelligenz ist ein Partner des Menschen beim Denken. Helle, motivierende Farben = 07_Denken-externalisiert_Utopie_01.jpeg	4

Datum	Woran habe ich gearbeitet? (Stichpunkte)	Welche digitalen Tools habe ich verwendet?	Notizen zum Einsatz digitaler Tools	Reflexion	Beleg/Beispiel	Grad der Nutzung
10.9.24	Text bearbeiten	ChatGPT 4.0 über Academic Cloud	Formulierungen gesucht	Unentschieden. Manches klingt gut, aber irgendwie auch nicht. Weiß nicht so recht, was ich davon halten soll.	24-09-10_Chat-Verlauf.docx	3

Tabelle 5.3. Beispiel Reflexionstagebuch zur LLM Nutzung. Quelle: (Baresel et al. (2024), S. 16)

5.7 Beispiele für die Kurs-Integration von KI

Abschließend wollen wir uns Beispiele ansehen, wie ein Kurs aussehen könnte, der mit LLM in der Vorbereitung arbeitet und sie in Übungsaufgaben und die Prüfungsvorbereitung einbindet. Anmerkung: Hier wird nur die KI-Ergänzung beschrieben, natürlich werden außerdem Lehrbücher und Fachartikel als Input genutzt.

Zeitliche Struktur und Inhalte (Fokus auf den Einsatz von KI-Tools)

Woche 1–4: Vorbereitung und KI-gestützte Materialerstellung (KI als „Hiwi“) * **Kursvorbereitung mit LLM**: Erstellung und Anpassung vielfältiger Programmieraufgaben an unterschiedliche Lernniveaus mithilfe

von Large Language Models. * **Deep Research**: Unterstützung bei der Recherche neuer Trends in der Programmierdidaktik und relevanter Beispiele, um realitätsnahe Aufgabenstellungen zu entwickeln. * **NotebookLM für Podcast-Episoden**: Aus den erstellten Materialien werden mithilfe von NotebookLM kurze Podcast-Folgen generiert, die Studierende zur Einführung in die Kursstruktur, grundlegende Programmierkonzepte und organisatorische Aspekte anhören können. Dies dient als motivierende, niederschwellige Form der Wissensvermittlung.

Woche 5–8: Vertiefung und individuelle Lernwege (KI als „Copilot“) * **Individuelle Programmieraufgaben**: Die Studierenden nutzen Google Colab oder ein ähnliches Tool, das KI-unterstützte Programmierung erlaubt (z. B. DeepNote). Sie lösen damit gleich am Anfang Anwendungsaufgaben und müssen die Code-Bestandteile in der Präsenzzeit anderen Gruppen erklären. Die Übungsaufgaben werden fortlaufend angepasst, indem die Lehrenden zusammen mit einem LLM bestehende Aufgaben je nach Lernfortschritt der Studierenden variieren (z. B. mehr Code-Komplexität oder zusätzliche Anwendungsfälle). * **Voice Mode für Simulationen**: Interaktive Rollenspiele bzw. Simulationen (z. B. „Debugging-Dialog“) mit einem KI-Avatar in Voice Mode. Die Studierenden können live Fragen stellen, sich Lösungswege erklären lassen oder sich ein Code-Review im Gesprächsformat geben lassen. * **DeepResearch**: Zur Vertiefung konkreter Themen (z. B. Algorithmendesign, Datenstrukturen) recherchieren die Studierenden mithilfe von DeepResearch in Fachartikeln, Blogposts und Dokumentationen. Sie lernen, verschiedene Quellen kritisch zu bewerten und für ihr Projekt nutzbar zu machen.

Woche 9–12: Konsolidierung und Prüfungsvorbereitung (KI als „Lernhilfe“) * **NotebookLM zur Zusammenfassung**: Aus den im Kurs genutzten Lernmaterialien (Skripte, Forumsdiskussionen, Beispielcode) generiert NotebookLM automatisiert Zusammenfassungen und kurze Podcasts zu Schlüsselkonzepten. Studierende können diese unterwegs anhören oder gezielt zur Prüfungsvorbereitung nutzen. * **LLM für Übungsfragen**: Auf Grundlage der bisherigen Lernfortschritte generiert das LLM individuelle Übungsfragen sowie Quizformate zur Selbstüberprüfung. * **Voice Mode für Prüfungssimulation**: Studierende simulieren mündliche Prüfungssituationen oder Code-Erklärungen über Voice Mode. Dies fördert die Fähigkeit, Inhalte klar und strukturiert zu präsentieren.

5.7.1 Beispielkurs: Ergänzung eines Kurses Interkulturelles Management durch KI-Unterstützung

Woche 1–4: KI als „Hiwi“ * **Ziel**: Erstellung vielfältiger, kulturell spezifischer Fallstudien und Szenarien, die als Diskussions- und Analysegrundlage dienen. * **LLM für Fallstudien & Szenarien**: Die Lehrenden nutzen LLM (z. B. ChatGPT oder andere) zur Generierung von Fallstudien, die spezifische interkulturelle Kontexte beleuchten (z. B. Verhandlungen in ostasiatischen vs. europäischen Kulturen, Führungsstile in verschiedenen Regionen etc.). * **Gegenmaßnahme zur Qualitätssicherung**: Die Ergebnisse werden stichprobenartig auf Richtigkeit, kulturelle Sensibilität und Relevanz überprüft. * **DeepResearch zur Materialrecherche**: Lehrende recherchieren mithilfe von DeepResearch nach relevanter Literatur, neuesten Studien und Praxisberichten im Bereich interkulturelles Management. Die gefundenen Quellen fließen ein in vorbereitende Leselisten und Hintergrundinformationen für die Studierenden. * **NotebookLM für Podcast-Folgen**: Für einen motivierenden Einstieg ins Thema werden kurze Podcasts (ca. 5–10 Minuten) mithilfe von NotebookLM erstellt. Themen könnten sein: „Einführung in kulturelle Dimensionen“ (bspw. nach Hofstede), „Erfolgsbeispiele im interkulturellen Management“, „Warum interkulturelle Kompetenz immer wichtiger wird“. Studierende können diese Podcasts vor oder nach den Präsenz- bzw. Online-Sitzungen anhören, um zentrale Konzepte zu festigen.

Woche 5–8: KI als „Copilot“ für Anwendungsaufgaben * **Ziel**: Entwicklung praxisnaher Simulationen, Rollenspiele und Fallübungen, um die Studierenden für reale interkulturelle Managementkonflikte zu sensibilisieren. * **LLMs für Rollenspiel- und Simulationsszenarien**: Studierende entwickeln in Kleingruppen Szenarien (z. B. Konflikte in multikulturellen Teams, Verhandlungen in internationalen Projekten), wobei sie LLM nutzen, um die Settings, Dialoge oder Konfliktpunkte zu konkretisieren. Lehrende moderieren den Prozess und überprüfen die Plausibilität, sodass sichergestellt wird, dass kulturelle Nuancen realitätsnah abgebildet werden. * **Zusätzlicher Einsatz**: Offene Sprachmodelle aus anderen Kulturräumen (etwa chinesische wie „DeepSeek“ oder japanische wie „Sakana“) werden gezielt eingesetzt, um denselben Input zu unterschiedlichen interkulturellen Situationen zu liefern. Ziel: Die Lehrenden vergleichen die Outputs in Bezug auf die verwendeten Beispiele, die Fokussierung auf kulturelle Werte (z. B. Kollektivismus, Hierarchie, Entscheidungsfindung) und die Tonalität der Texte. Daraus entstehen

potenziell Fallstudien mit Abweichungen, die im Kurs aktiv diskutiert werden. * **Voice Mode für interaktive Simulationen**: Mithilfe von Voice Mode können die Studierenden verschiedene „Akteure“ in einem simulierten interkulturellen Gespräch übernehmen. Beispielsweise könnte ein Studierender die Rolle eines japanischen Managers übernehmen, der mit einem französischen CEO verhandelt – unterstützt und angeleitet durch das KI-gestützte Voice Mode. Diese Live-Simulationen fördern besonders die Aussprache, interkulturelle Kommunikation und nonverbale Signale (sofern Video/Audio-Komponenten integriert sind). * **DeepResearch für Problemlösungsvorschläge**: Nach durchgeführten Simulationen nutzen die Studierenden DeepResearch, um Best Practices, wissenschaftliche Artikel und Fallbeispiele zu finden, die ähnliche interkulturelle Herausforderungen beschreiben. Auf dieser Basis erstellen sie Handlungsempfehlungen für die Konfliktlösung. Die Lehrenden geben Feedback, um die studierendenzentrierte Reflexion zu stärken.

Woche 9–12: KI als „Lernhilfe“ * **Ziel**: Effektive Prüfungsvorbereitung, Vertiefung und Wiederholung zentraler Inhalte im interkulturellen Management. * **LLMs für Zusammenfassungen und Wiederholungsfragen**: Studierende lassen sich von Sprachmodellen kurze Zusammenfassungen zentraler Konzepte erstellen (z. B. kulturelle Dimensionen nach Hofstede, Schein, Trompenaars). Die LLMs generieren auf Basis des bisherigen Kursverlaufs zusätzlich Quiz-Fragen oder Kurzantwortaufgaben, um das Verständnis zu überprüfen. * **Gegenmaßnahme zur Qualitätssicherung**: Die Lehrenden behalten die Kontrolle über die Endversion der Fragen, um unsinnige oder unpassende Aufgaben zu erkennen und zu eliminieren. * **NotebookLM für Audio-Lerninhalte**: Aus bereits vorhandenen Materialien (Skripte, Diskussionsergebnisse, Fallstudien) generiert NotebookLM weitere Podcast-Folgen, in denen Schlüsselkonzepte erläutert oder wiederholt werden. Studierende können diese Folgen gezielt zur Prüfungsvorbereitung nutzen und dadurch Zeit- und Ortsunabhängigkeit beim Lernen erlangen. * **Voice Mode für Prüfungssimulationen**: Studierende üben z. B. mündliche Prüfungen oder Präsentationen im interkulturellen Kontext. Sie können sich von Voice Mode Fragen stellen lassen („Wie würden Sie in Situation X reagieren?“) und ihre Antwort direkt in einer realistischen Simulation üben. Dies fördert die rhetorische Sicherheit sowie das spontane Reagieren auf unvorhergesehene Fragen.

5.7.2 Vorteile und Chancen der Ergänzung der Lehrmaterialien durch KI

- **Realitätsnahe Lernsituationen**: Durch Voice Mode-Simulationen und DeepResearch-gestützte Recherche wirken die Szenarien authentisch und praxisrelevant. Studierende lernen, ihre kulturelle Sensibilität in unterschiedlichen Rollen aktiv zu trainieren.
- **Zeit- und Ressourcenersparnis**: Lehrende profitieren von teilautomatisierten Prozessen (z. B. Erstellung von Fallstudien, Zusammenfassungen, Podcasts). Studierende haben jederzeit Zugriff auf zusätzliche Lernressourcen wie Podcasts oder interaktive Übungen.
- **Adaptives Lernen und Diversität**: LLMs und DeepResearch ermöglichen personalisierte Aufgabenstellungen und themenspezifische Vertiefungen. Kulturelle Diversität kann in den generierten Szenarien leichter abgebildet werden, indem verschiedene Regionen und Blickwinkel integriert werden.

5.7.3 Risiken und Gegenmaßnahmen

- **Qualität und kulturelle Sensibilität**: *Gegenmaßnahme:* Lehrende prüfen alle generierten Inhalte (Text, Podcasts, Simulationen) auf kulturelle Stereotype und potenzielle Fehlinformationen. Durch Peer-Review unter Studierenden werden Vorurteile oder unangemessene Darstellung früh erkannt.
- **Vertrauenswürdigkeit und akademische Redlichkeit**: *Gegenmaßnahme:* Studierende werden darin geschult, die KI-generierten Inhalte kritisch zu hinterfragen und zu validieren. Sie müssen Quellen nennen und sachlich begründen, wie und warum sie bestimmte KI-Ausgaben nutzen.
- **Datenschutz und ethische Aspekte**: *Gegenmaßnahme:* Sensible Informationen werden anonymisiert, Zugriffsrechte klar geregelt. Studierende erhalten eine Einführung, wie sie KI-Tools sicher und verantwortungsbewusst einsetzen.
- **Technische Abhängigkeit**: *Gegenmaßnahme:* Lehrmaterialien sind zusätzlich offline verfügbar (Skripte, Reader). Auch ohne KI-Tools kann der Kurs fortgesetzt werden.

Kernaussagen

1. Der erste Schritt ist Ausprobieren: eigene Aufgaben in ein starkes Modell geben, Input eingrenzen, Prompts anpassen und prüfen, wo die KI gut ist und wo nicht.
2. Studierende lernen den Umgang mit KI durch häufiges, über das Semester verteiltes Üben in Präsenz, nicht durch eine Theorieeinführung.
3. Die Homework Apocalypse ist real, aber beherrschbar. Prüfungen werden wieder aussagekräftig durch Mündlichkeit, Prozessorientierung, Kontextualisierung und Kollaboration. KI-Detektoren sind dafür kein Mittel.
4. Hochschulrichtlinien konvergieren: Eigenständigkeitserklärung anpassen, Verdachtsfälle im Gespräch klären, keine automatisierte Bewertung, Prüfungsformate didaktisch weiterentwickeln. Wirksam werden sie nur, wenn sie bekannt sind und diskutiert werden.
5. Dokumentation der KI-Nutzung muss praktikabel sein: eine Stichwortliste, eine Übersicht nach Arbeitsphase oder Werkzeug oder ein Reflexionstagebuch; ein vollständiges Protokoll jeder Interaktion ist es nicht.

Zum Weiterdenken

1. Nehmen Sie Ihre wichtigste schriftliche Prüfungsleistung und wenden Sie aus dem Gedächtnis die vier Säulen darauf an. Welche Säule lässt sich mit geringstem Aufwand nächstes Semester einziehen?
2. Was steht in der Richtlinie Ihrer eigenen Hochschule zu KI in Prüfungen? Falls Sie es nicht wissen: Was müsste nach diesem Kapitel darin stehen?
3. Entwerfen Sie für eine Ihrer Veranstaltungen eine Drei-Phasen-Struktur (Hiwi, Copilot, Lernhilfe). Welches Risiko aus dem Kapitel trifft Ihren Kurs am stärksten, und welche Gegenmaßnahme planen Sie?

5.8 Wie bleiben Sie informiert?

Bei einem sich so schnell wandelnden Thema helfen gute Sammelstellen für Information, um auf dem Laufenden zu bleiben. Abschließend einige Empfehlungen für gute Informationsquellen zum Thema Generative KI:

- **Newsletter / Substack von Ethan Mollick** der Wharton Business School mit sehr praktischen Übersichten und Empfehlungen: https://www.oneusefulthing.org/. Abonnieren Sie ihn, es lohnt sich.
- **Hochschulforum Digitalisierung**: Themendossier Generative KI: https://hochschulforumdigitalisierung.de/dossier/generative-ki/
- **E-Teaching.org**: KI in Studium und Lehre: https://www.e-teaching.org/praxis/themenseiten/ki-in-studium-und-lehre
- Eine große Anzahl an sehr guten **didaktischen Prompts** vom Team der Wharton Business School findet sich hier: https://www.moreusefulthings.com/pron Hervorzuheben sind v. a. die „**Blueprints**“, also Vorlagen, die für die eigene Lehre angepasst werden können (s. u. für zwei Beispiele).
- Die Universität Harvard gibt hier eine Reihe von **Beispielen, wie GenAI in der Lehre** genutzt wird, u. a. mit Beispielen für Simulationen, Sprachdidaktik u. v. m.: https://bokcenter.harvard.edu/examples-and-ideas-for-using-AI-for-your-teaching.
- Etwas breiter – **wie nutzen 76.000 Lehrende KI an Hochschulen**? Die KI-Firma Anthropic hat 2025 einen Bericht herausgebracht, der anonymisiert basierend auf echten Interaktionen betrachtet, wie KI in der Lehre genutzt wird: https://www.anthropic.com/news/anthropic-education-report-how-educators-use-claude (Bent et al., 2025). Im Kontext von Rollenspielen ist hier interessant, wie die Online-Interaktion des GPT-Konkurrenten genutzt werden („Claude Artifacts“), speziell für „Interactive Educational Games“.
- **Fortbildungen und Übersichten mit Anwendungsfokus**: Sowohl Google als auch Claude und OpenAI bieten Kurse für die technischen Aspekte der Nutzung von KI in der Lehre an: https://grow.google/ai-for-educators/, https://anthropic.skilljar.com/ai-fluency-framework–fluency/, https://anthropic.skilljar.com/ai-fluency-framework-foundations.

A Überblick didaktischer Prompts

A.1 Kurze Einordnung der Prompt-Vielfalt – was sind gemeinsame Muster?

A.1.1 Übersicht

Die hier gesammelten **Prompts** umfassen ausgesuchte Best-Practice-Beispiele der Harvard System Prompt Library, der Wharton Business School (Ethan & Lilach Mollick), der Informatik-Fakultät der Universität Stanford und der Hongkong City University sowie der Firma Anthropic. Beispiele für **komplexere Aufgabenstellungen, die GenAI in mehreren Schritten integrieren**, stammen vor allem vom Harvard AI Pedagogy Project (Links zu den Quellen sind jeweils beim Prompt angegeben).

Vorab sollen die Arten von Prompts hier kurz exemplarisch diskutiert und nach vier Kategorien der GenAI-Unterstützung geordnet werden (Hiwi, Copilot, Tutor, Simulator). Wir fragen außerdem, welche allgemeinen Muster erkennbar sind.

Die **Hiwi**-Prompts erfüllen klassische Entlastungsaufgaben: CSV-Konverter und Data Organizer verwandeln unstrukturierte Eingaben in saubere Tabellen oder in ein Standard-Format, wie etwa JSON; der Excel-Formel-Experte generiert und erklärt komplexe Formeln Schritt für Schritt; LaTeX-Unterstützung liefert Bausteine für Formeln und Tabellen; der Meeting Scribe fasst Sitzungen knapp mit Verantwortlichkeiten zusammen. Didaktisch gesehen senkt diese Rolle extrinsische kognitive Last und schafft Zeit für anspruchsvollere Lernaktivitäten – vergleichbar mit Labortechnik, die die Versuchsanordnung vorbereitet, damit Studierende die eigentliche Analyse vertiefen können. Wichtig ist hier Transparenz: Studierende sollten sehen, wie Datenstrukturen, Formellogik und Protokollierung entstehen (Prozesssicht), damit die Hilfskraft nicht zur Black Box wird (vgl. E. R. Mollick & Mollick, 2024, die explizit die Festlegung der KI mit klaren Schritten und Constraints betonen).

Die Prompts in der **Tutor**-Kategorie decken ein breites Spektrum ab: vom „Allgemeinen Tutor“ (sokratische Fragen, Scaffolding mit Ein-Frage-Takt) über Mentor-Bots für Entwurfsfeedback, Reflexionscoaches, Debattenvorbereitung, Argumentüberarbeitung, Assignment-Mentor bis zu Übungsaufgaben-Generatoren (Statistik/Regression), Vektor-Explorer und Diskussionspartner für soziologische Theorien. Gemeinsame didaktische Muster sind adaptive Erklärungen, Analogien, schrittweises Fragen, das gezielte Adressieren von Fehlvorstellungen, metakognitive Reflexion sowie der Protégé-Effekt (Lernende lehren die KI bzw. eine Novizin) (E. R. Mollick & Mollick, 2024, „Mentoring, Coaching, and Tutoring“; E. R. Mollick & Mollick, 2023b). Ein anschauliches Beispiel ist „KI agiert als Schüler, der vom Lernenden unterrichtet wird“: Die KI spielt eine inquisitive oder skeptische Novizin, wodurch Studierende ihr Wissen strukturieren, Lücken entdecken und Begriffe in eigenen Worten anwenden – wie in einem Mikroseminar, in dem die Rollen bewusst gedreht werden.

Die Prompts zur Nutzung von GenAI als **Copilot** nutzen es als Hilfe in Projekten und bei der Co-Creation. Für Lehrende und Teams finden sich Copilot-Prompts, die reale Arbeitspraktiken abbilden: Team-Charter erstellen (Rollen, Ziele, Normen), Team-Reflexion/After-Action-Review, Projekt-Pre-Mortem (prospektive Nachbetrachtung), „Devil’s Advocate“ zur systematischen Gegenposition, gemeinsame Fallstudienerstellung mit Versionierung und Peer-Feedback. Didaktisch verbindet diese Rolle Co-Creation (gemeinsames Fällen/Strukturieren), Debiasing (Exploration von Alternativen/Annahmen) sowie „learning from projects“ durch strukturierte Nachbereitung. Sie operationalisiert Mollicks „Learning through Co-Creation“ und „Building Opportunities for Critique“: Lernende konstruieren Artefakte (Case Drafts) und erleben Qualitätssicherung als geführten Prozess; Teams kultivieren Fehlerkultur und Entscheidungsqualität über Leitfragen und Priorisierung von Risiken (analog zu Checklisten in der Luftfahrt) (E. R. Mollick & Mollick, 2024). Beispiele: Team-Charter als Startartefakt der Kollaboration; Pre-Mortem mit Eintrittswahrscheinlichkeit/Schadenshöhe und Ableitung von Gegenmaßnahmen; Devil’s-Advocate-Prompt mit Fokus auf Konsensfalle, versteckte Annahmen und Beleglage – abschließend visualisiert als Vergleichstabelle „Initial Decision vs. Hidden Assumptions“. Der Copilot ähnelt einer gut vorbereiteten Kollegin im Projektmeeting, die methodisch führt, aber Ownership bei den Lernenden belässt.

Die **Simulations**-Prompts modellieren „Role Play“ (z. B. Verhandlungstraining)

und „Goal Play“ (z. B. Goal-Setting, Self-Distancing nach Kross) mit klaren Phasen: Informationssammlung, Szenarioauswahl, Szenenaufruf („BEGIN ROLE PLAY“), sechs Züge bis zur konsekutiven Entscheidung, danach strukturierte, balancierte Feedback-Sequenz und Transferhinweise. Genau diese Sequenz betonen E. R. Mollick & Mollick (2024): simulationsbasiertes Üben, narrative Einbettung, adaptive Schwierigkeit, individuelles Feedback plus obligatorisches Debriefing im Kurs („Learning through Simulations“). Die Verhandlungssimulation adressiert u. a. BATNA, ZOPA, Anker, Täuschung, First-Offer-Effekte, Kooperations-/Wettbewerbsdynamik und Beziehungsmanagement am Abschluss der Verhandlung; die Self-Distancing-Simulation trainiert Perspektivwechsel und Emotionsregulation; die Goal-Setting-Simulation operationalisiert Prinzipien wie Spezifität, Zerlegung, Priorisierung, Flexibilität und Hürdenanalyse – jeweils mit klaren „Do/Don’t“-Leitplanken, damit die KI in-character bleibt und nicht „übermoderiert“. Sinnbildlich ist der Simulator der „Flugsimulator der Lehre“: sicher scheitern, Muster erkennen, Taktiken verfeinern – gefolgt von reflektierter Auswertung.

Zusammengeführt ergeben sich einige Muster der komplexeren didaktischen Prompts: Die Hilfskraft reduziert Routine-Lasten und macht Prozesse sichtbar; der Tutor aktiviert aktive Reflexion im Dialog und setzt auf Erklären-Üben-Reflektieren; der Copilot stärkt kollaborative Entscheidungs- und Projektkompetenz durch Co-Creation und Gegenpositionen; der Simulator verlagert Wissen in performatives Handeln mit unmittelbarer Rückmeldung und geplanter Nachbesprechung. So entsteht ein durchgängiger Lernpfad vom Strukturieren über das Verstehen zum Anwenden – mit KI als gut „programmierter“ Partnerin, die stets durch Lehrdesign, Leitfragen und Debriefing gerahmt bleibt (E. R. Mollick & Mollick, 2024).

A.2 Didaktische Prompts: Gezielte Einschränkungen

Wenn wir die KI als Hiwi nutzen, ist unser Ziel meist eine möglichst schnelle und effiziente Antwort. Das ist bei den drei anderen Rollen anders: Hier schränken wir das Sprachmodell oft bewusst ein. Das liegt kurz gesagt daran, dass Studierende mehr lernen, wenn sie etwas schwitzen. Die Lernforschung nennt das „desirable difficulties“ (E. L. Bjork & Bjork, 2011).

Ein charakteristisches Merkmal fortgeschrittener didaktischer Eingabeaufforderungen ist die Verwendung expliziter Einschränkungen – Regeln, die dem LLM bestimmte Verhaltensweisen verbieten oder verhindern (E. R. Mollick & Mollick, 2023b, 2024). Diese Einschränkungen sind entscheidend für die Umwandlung eines allgemeinen Sprachmodells in ein spezialisiertes pädagogisches Werkzeug. Durch die Einschränkung der Standardtendenzen der KI stellen diese Regeln sicher, dass die Interaktion spezifischen Lernzielen dient und nicht nur Informationen liefert. Die Analyse der gesammelten Eingabeaufforderungen zeigt mehrere wiederkehrende Kategorien von Einschränkungen.

1. Zulassung erwünschter Schwierigkeiten zum aktiven Lernen

Die grundlegendste Einschränkung zielt darauf ab, den Schüler von einem passiven Empfänger von Informationen zu einem aktiven Teilnehmer an seinem eigenen Lernprozess zu machen. Dies wird erreicht, indem die KI daran gehindert wird, einfach die Antwort zu geben.

- „Keine direkte Antwort geben“ / „Zur Selbstkorrektur anleiten“: Diese Regel, die im Mittelpunkt der sokratischen Eingabeaufforderungen steht, zwingt das LLM, eher als Wegweiser denn als Orakel zu fungieren. Anstatt die Frage eines Schülers direkt zu beantworten, muss die KI durch Nachfragen, einem Hinweis oder der Aufforderung an den Lernenden reagieren, seine Überlegungen zu erklären. Dies fördert das aktive Erinnern und eine tiefere kognitive Verarbeitung.
- „Löse KEINE benoteten Aufgaben“: Diese Einschränkung, die in der Stanford NumPy-Aufforderung zu finden ist, wahrt die akademische Integrität, indem sie Betrug verhindert. Noch wichtiger ist, dass sie die Lernenden dazu zwingt, ihr Wissen selbstständig anzuwenden, was für den Erwerb von Fähigkeiten unerlässlich ist.
- „Halte keine längeren Vorträge ohne Interaktion“: Diese Regel stellt sicher, dass der Lernprozess dialogisch und interaktiv bleibt und verhindert, dass sich der Lernende abwendet.

2. Aufrechterhaltung der Integrität und des Realismus der Simulation

In Simulator-Aufgaben sind Einschränkungen unerlässlich, um eine glaubwürdige und effektive Rollenspiel- oder Problemlösungsumgebung zu schaffen.

- „Verlasse nicht Deine Rolle“: Diese Anweisung, die in der Aufgabe „Interview mit einer Figur“ zu finden ist, ist entscheidend für die Aufrechterhaltung der immersiven Qualität der Simulation, die für situiertes Lernen von zentraler Bedeutung ist.
- „Gebe nicht alle Informationen auf einmal“: Wie in der Simulation „Telefonische Triage“ zu sehen ist, sorgt diese Einschränkung für eine realistische Informationslücke. Sie zwingt den Lernenden dazu, systematische, professionelle Fähigkeiten (wie diagnostische Fragen) zu üben, anstatt einfach nur eine Datenflut zu erhalten.
- „Entscheide nicht zu schnell und gehe keine Kompromisse ein“: Im Verhandlungssimulator sorgt diese Regel dafür, dass die Simulation eine echte Herausforderung darstellt und die Studierenden gezwungen sind, ihre Überzeugungs- und Konfliktlösungsfähigkeiten unter realistischem Druck zu üben.

3. Sicherstellung einer sachlichen Grundlage und Verhinderung von Halluzinationen

LLMs sind dafür bekannt, dass sie „halluzinieren“ oder Informationen erfinden. Didaktische Aufforderungen enthalten oft Einschränkungen, um dieses Risiko zu mindern und die Übung im Rahmen des Kursmaterials zu halten.

Beispiel: „Deine Antworten dürfen sich NUR auf Ereignisse und Informationen stützen, die in ... dem Quelltext zu finden sind“: Diese Regel aus der Aufforderung „Interview mit einer fiktiven Figur“ ist ein wirksames Mittel, um zu verhindern, dass die KI nicht kanonische oder ungenaue Informationen einbringt. Sie konzentriert die Übung auf die Textanalyse und -interpretation.

4. Kognitive Belastung (cognitive load) begrenzen

Um sicherzustellen, dass die Lernerfahrung effektiv und nicht überfordernd ist, enthalten Aufforderungen oft Einschränkungen, hinsichtlich der Komplexität und des Tempos der Informationen.

- „Vermeide komplizierte/unnötige Notationen“: Diese Richtlinie aus der Stanford NumPy-Aufgabe („Stanford Tutor...“) ist eine direkte Anwendung der kognitiven Belastungstheorie, die unnötige mentale Anstrengungen reduziert, damit sich der Lernende auf das Kernkonzept konzentrieren kann (Sweller, 2011).

- „Stelle nicht mehr als eine Frage auf einmal“: Diese gängige Regel in mehrstufigen Aufgaben verhindert, dass sich der Benutzer überfordert fühlt, und ermöglicht einen natürlicheren, schrittweisen Gesprächsfluss.
- „Sprich NUR in [Zielsprache]“: In Sprachübungs-Prompts sorgt diese Einschränkung für Immersion, wird jedoch oft mit einer „Fluchtmöglichkeit“ kombiniert (z. B. „es sei denn, ich gebe HILFE AUF DEUTSCH ein“), um Frustrationen zu vermeiden, wenn die kognitive Belastung zu hoch wird.

A.3 Integration der KI in breitere Aufgabenstellungen und Artefakte

Die Sammlung enthält Aufgaben, die tiefes Lernen durch Elaboration, Selbst-Erklärung und wiederholte Anwendung fördern. Sokratische Dialoge, Argumentationskritik und die Essay-Revision erzwingen Begründungen, Gegenbeispiele und explizite Kriterienarbeit, wodurch sich der Fokus von bloßen Ergebnissen auf nachvollziehbare Denk- und Entscheidungsprozesse verschiebt (Meehan, 2025; Newman, 2025; Yuen, 2025).

Simulationsaufgaben erzeugen handlungsnahe Übungssituationen für Kommunikation und klinische Entscheidungen; dadurch werden Abruf- und Transferleistungen in realitätsnahen Bedingungen gefördert (Hobbick, 2025; Kentz, 2025; Welsh, 2025).

Copilot-Szenarien wie die DuPont-Analyse und das iterative Ausprobieren von Prompts (Prompt-Playtesting) verbinden fachliche Rechenwege mit Interpretation, Berichterstellung und Qualitätskontrolle der eigenen Prompting-Strategien (Landfair, 2025; Pedersen, 2025).

Wie wird Reflexion und Eigenleistung gefördert? Die Integration von GenAI ist in allen Beispielen explizit gesteuert und an sichtbare Lernprodukte gebunden. Aufgaben definieren die Rolle der KI und koppeln deren Einsatz an Protokolle der KI-Interaktion, kommentierte Revisionen, Evidenz-Logs oder Entscheidungsbäume. So verankert etwa die Aufgabe „AI-Sandwich“ die KI-Nutzung als Mittel zum Zweck: Zuerst werden Ziele und Kriterien ohne KI fixiert, anschließend liefert die KI Varianten und Gegenpositionen, und zum Abschluss erfolgt die menschliche Prüfung mit Quellenarbeit und Reflexion (Ippolito, 2025).

Für **KI-resistente Prüfungsleistungen** empfehlen sich Artefakte und Peer-Elemente, die den individuellen Arbeitsprozess sichtbar machen. Dazu gehören Versionen ‚vorher/nachher' mit Änderungsbegründungen, Annotierungen der eigenen Entscheidungswege, Protokolle der Prompt-Iteration oder Evidenztabellen sowie strukturierte Peer-Reviews und Debrief-Diskussionen. Prüfungen sollten diese Prozessartefakte bewerten, nicht nur das Endprodukt, und Transparenzpflichten verankern: Studierende legen ihre KI-Nutzung offen, benennen Prompts und Tools, dokumentieren Quellenprüfungen und begründen Überarbeitungen. Auf diese Weise bleibt akademische Integrität gewahrt, während die produktiven Potenziale von GenAI genutzt werden (Taylor, 2025).

B Best-Practice-Sammlung didaktischer Prompts und GenAI Aufgabenstellungen

Vorbemerkung zur Struktur der Sammlung

Die hier vorgestellten didaktischen Prompts wurden aus verschiedenen internationalen Quellen zusammengetragen, übersetzt und in eine **standardisierte Form** (RTF oder CREATE-Schema, s.o.) überführt. In der Navigationsleiste rechts können Sie zu den Prompts navigieren, die Sie interessieren. Sie können die Prompts in der Online-Version **'ausklappen'** lassen und über einen Knopf rechts oben im Codeblock leicht kopieren. Neben **Beispielen für die Prompts** sind jeweils auch detaillierte **Aufgabenstellungen** aufgeführt, die zeigen, wie wir die Prompts in eine Lehreinheit integrieren können. **Testen Sie die Prompts am Besten gleich** im Sprachmodell Ihrer Wahl, oder lassen Sie den Prompt dort auf eine spezifische Lehreinheit hin anpassen. Sie wollen vergleichen, wie die **Prompts mit verschiedenen Modellen funktionieren?** Nutzen Sie dafür die LM-Arena: https://lmarena.ai/de?mode=side-by-side. Viel Spaß dabei!

B.1 Hiwi: Schnelle Hilfe zur Lehrgestaltung

B.1.1 Hiwi: Kursinhalte aktualisieren

Funktion: Kursinhalte kuratieren; Aktualisierungen/Ergänzungen vorschlagen; Lernziele mit Inhalten abgleichen.

Didaktische Elemente: Alignment (Lernziele↔Inhalte); Scaffolding; exemplarische Ressourcen-Vorschläge.

Quelle: Angepasst und erweitert nach der System Prompt Library (Harvard VPAL/HILT) (Wilson & Tingley, n.d.); thematischer Prompt im Fork als Datei: Course Content Curator.

Hiwi: Kursinhalte aktualisieren

```
[Character]
Du agierst als Instructional Designer mit
  Schwerpunkt Curriculum Design, Constructive
  Alignment (Biggs), Universal Design for
  Learning (UDL) und digital gestützter
  Hochschullehre.

[Request]
Unterstütze Lehrkräfte dabei, bestehende oder
  neue Kursinhalte zu kuratieren und zu
  aktualisieren. Ziel ist ein aktueller,
  motivierender und lernzielorientierter Kurs.
  Prüfe Kursbeschreibung und Lernziele, stelle
  bei Bedarf Rückfragen und entwickle
  anschließend eine strukturierte
  Inhaltsabfolge mit passenden Materialien,
  Aktivitäten und Aufgaben. Erkläre jeweils
  den Beitrag zu den Lernzielen.

[Examples]
Nutze z. B. Analyseaufgaben für kritisches
  Denken oder projektbasiertes Lernen für
  anwendungsorientierte Ziele.

[Adjustments & Constraints]
Biete mindestens zwei Schwierigkeitsniveaus
  an, berücksichtige unterschiedliche
  Lernpräferenzen sowie inklusive und
  barrierefreie Alternativen. Nutze bevorzugt
  zugängliche Materialien und kennzeichne
  Annahmen transparent.

[Type of Output]
Strukturierte Übersicht (Module/Wochen) mit
  Zielbezug, Beschreibung, Schwierigkeitsgrad
  und Inklusionshinweisen.

[Evaluation & Steps]
Gehe schrittweise vor (Analyse → Struktur →
  Materialien → Differenzierung) und stelle
  sicher, dass jedes Element klar auf die
  Lernziele einzahlt.
```

B.1.2 Hiwi: Aktivierungs-Coach für die Präsenzlehre

Funktion: Vorlesungen interaktiver machen; Fragen/Checks einbauen; Aktivierungsimpulse generieren.

Didaktische Elemente: Retrieval Practice; formative Checks; Aktivierung durch kurze Interaktionen.

Quelle: Angepasst und übersetzt von der System Prompt Library (Harvard VPAL/HILT) (Wilson & Tingley, n.d.); thematischer Prompt im Fork als Datei: Interactive Lecture Assistant.

Hiwi: Aktivierungs-Coach

```
[Character]
Du bist ein erfahrener Hochschuldidaktiker mit
  Schwerpunkt auf Active Learning, Cognitive
  Engagement und lernzielorientierter
  Vorlesungsplanung.

[Request]
Unterstütze einen Dozenten dabei, eine
  traditionelle Vorlesung in eine interaktive
  Lernerfahrung umzuwandeln. Nutze die vom
  Dozenten gelieferten Vorlesungsthemen als
  Ausgangspunkt.

[Examples]
Beispiele für interaktive Elemente, die du
  einsetzen darfst (Du darfst auch andere
  vorschlagen!):
Schnellumfragen (Multiple Choice,
  Einschätzungsfragen)
Think-Pair-Share
1-Minuten-Paper / Exit Tickets
Kurze Konzept-Checks oder Fehlkonzept-Fragen

[Adjustments & Constraints]
Berücksichtige realistische Zeitfenster
  innerhalb einer Vorlesung (z. B. 90 Minuten).
Die Aktivitäten sollen ohne aufwendige Technik
  umsetzbar sein.
Formuliere alle Fragen klar, niedrigschwellig
  und lernzielbezogen.

[Type of Output]
Klärende Rückfragen an den Dozenten
  (Zielgruppe, Niveau, Zeit, Lernziele)
Strukturierte Übersicht der Vorlesungsphasen
Pro Phase:
Ziel der Aktivität
Konkrete Beispielfrage(n)
Kurze Durchführungsanleitung
Optional: Hinweise zur Moderation und
  typischen Stolpersteinen

[Evaluation & Steps]
Prüfe, ob jede Aktivität einem klaren Lernziel
  dient
Achte auf Abwechslung zwischen Input und
  Aktivierung
Stelle sicher, dass die Gesamtzeit realistisch
  bleibt
Priorisiere Verständnissicherung gegenüber
```

B.1.3 Hiwi: Strukturierter Prompt Designer

Funktion: Prompts oder Prompt-Ideen in ein strukturiertes Format umwandeln: entweder in die einfache RTF-Struktur (Role-Task-Format) oder in das detailliertere CREATE-Format (Character, Request, Examples, Adjustments & Constraints, Types of output, Evaluation & Steps).

Didaktische Elemente: Scaffolding; Klärungsfragen; prozedurale Anleitung.

Quelle: Selbst erstellt, für die Schemata (RTF, CREATE) basierend auf dem Prompt Guide des Project Management Institute (Project Management Institute (2024)). Eine Online-Version (GPT) finden Sie hier: https://chatgpt.com/g/g-695a8a7c9c888191a683135100f623d0-prompt-strukturierer-rtf-oder-create-format

Strukturierter Prompt Designer

```
[C]haracter (Rolle): Du bist ein erfahrener
  Prompt Engineer. Deine Expertise liegt
  darin, GenAI Sprachmodellen klare
  Anweisungen zu geben. Du beherrschst sowohl
  die effiziente RTF-Formel (Role, Task,
  Format) für direkte Anfragen als auch das
  umfassende CREATE-Framework für komplexe
  Szenarien.

[R]equest (Aufgabe): Frage zunächst den User
  nach einem einfachen Prompt als Input. Warte
  die Antwort des Users ab. Analysiere dann
  den Input des Users und transformiere ihn in
  einen präzisen und professionellen Prompt,
  der auch Prüfschritte beinhaltet und
  typische Probleme von Sprachmodellen
  antizipiert. Fange mit dem RTF-Schema an und
  mach immer gleich einen Vorschlag, den der
  User dann ergänzen kann. Frag den User, ob Du
  den Prompt in das komplexere CREATE-Schema
  überführen sollst. Frage wenn nötig nach,
  wenn Informationen fehlen (speziell zum Ziel
  des Prompts und Bewertungskriterien). Mache
  aber speziell beim CREATE-Schema immer auch
```

B.1.4 Hiwi: Potato-Prompt - Kurzbefehl für das kritische Hinterfragen eigener Argumente

Funktion: Denkhilfe zum kritischen Hinterfragen eigener Argumente. Setzen Sie vor ein Argument den Kurzbefehl "potato" [Argument], um es von der KI kritisch beleuchten zu lassen. Der „Potato"-Trigger soll insofern die KI in einen konsequent kritischen Prüfmodus versetzen. Ziel ist es, aus Ihrer Eingabe drei mögliche Scheitergründe, zwei starke Gegenargumente und einen übersehenen blinden Fleck zu erhalten. Überarbeiten Sie anschließend Ihre These so, dass die identifizierten Schwachstellen adressiert werden (z. B. Annahmen explizit machen, Randbedingungen ergänzen, Risiken absichern). Dieser Kurzbefehl kann auch im System-Prompt angelegt werden (dafür: kürzen lassen). Alternativ: Punktuell prompten, oder als "Projekt" (in ChatGPT) fest hinterlegen.

Didaktische Elemente: Scaffolding; Klärungsfragen.

Quelle: Angepasst nach diversen Quellen - der Ansatz ist recht populär - hier exemplarisch ein Blog-Post von Amanda Caswell (Caswell, 2026).

Potato Prompt - Kurzbefehl für kritisches Hinterfragen

```
[Role/Rolle]
Du bist ein kritischer
  Argumentations-Reviewer: schroff, direkt,
  kompromisslos. Du kritisierst Ideen hart,
  aber ohne Hassrede, ohne gruppenbezogene
  Abwertung und ohne persönliche Angriffe auf
  Identitätsmerkmale. Fokus: Logik, Annahmen,
  Evidenz, Umsetzbarkeit, Nebenfolgen. Gib
  wenn möglich Quellen und Links zur
  Unterstützung der Argumente an.

[Task/Aufgabe]
Prüfe zuerst, ob die Nutzernachricht mit einem
  der folgenden Trigger beginnt:
- exakt "potato:" (ohne Anführungszeichen)
  ODER
- exakt "potato " (das Wort potato gefolgt von
  einem Leerzeichen) und dann weiterer Text

Wenn Trigger aktiv ist: aktiviere POTATO MODE
  und folge strikt den Output-Regeln.
Wenn Trigger nicht aktiv ist: antworte normal
  (hilfreich, sachlich, ohne POTATO-Format).

[POTATO MODE - Verhalten]
- Sei feindselig-scharf und unverblümt, keine
  Nettigkeiten, kein Lob, kein
  Empathie-„Fluff".
- Schreibe das Argument des Nutzers NICHT um,
  außer der Nutzer fordert es ausdrücklich.
  Greife es an.
- Wenn der Input vage ist: sage klar, dass er
  vage ist, kritisiere die Vagheit als einen
  Failure Mode, und fahre dann fort.
- Inhalt (die Punkte) auf Deutsch schreiben.

[POTATO MODE - Output-Format (EXAKT
  einhalten)]
Gib GENAU diese Struktur aus (Überschriften
  und Bullets exakt wie hier; keine
  zusätzlichen Abschnitte, keine Vorworte,
  keine Nachträge):


POTATO - 3 Gegenargumente
A) ...
B) ...
C) ...
```

B.1.5 Hiwi: System-Prompt für typische Anforderungen erstellen

Funktion: Erstellt allgemeine Instruktionen, die das Sprachmodell an die User-Bedürfnisse anpasst. Es entsteht ein *angepasster* akademischer Hiwi für den eigenen Lehr- und Forschungsbereich. Dieser System-Prompt kann im Sprachmodell hinterlegt werden ("Personalisierung" bei ChatGPT), oder als Textdatei punktuell beigefügt werden.

Didaktische Elemente: Scaffolding (Profilkarte + Blueprint als Defaults), Klärungsfragen (genau eine Frage pro Schritt mit a/b/c/Sonstiges), prozedurale Anleitung (Phasenlogik, Checkliste zur Überprüfung, Iterationsschleifen).

Quelle: Selbst erstellt; strukturiert nach dokumentierten Best Practices für System Prompts von OpenAI, Anthropic und Google (Anthropic, 2025a; Google, 2025; Kotha et al., 2025). (acht Prinzipien: Struktur, Spezifität, Motivation, positive Formulierung, Beispiele, Unsicherheit, Reasoning, Iteration).

Hiwi: Allgemeine Anweisungen im System-Prompt

B.1.6 Hiwi: Quiz-Ersteller

Funktion: Erstellt didaktische Quiz-Aufgaben.

Didaktische Elemente: Testing Effect; Low Stakes Test; Retrieval Practice

Quelle: Angepasst & übersetzt basierend auf dem Blog von Ethan Mollick, Online: https://www.moreusefulthings.com/instructor-prompts.

Hiwi: Didaktische Quiz Ersteller

```
[Role/Rolle]:
Du bist ein kompetenter Lehrassistent und
  Experte für Leistungsbewertung. Du
  entwickelst diagnostische Tests
  (Multiple-Choice und offene Fragen), um
  Wissen valide zu überprüfen. Du agierst
  strukturiert, präzise und didaktisch
  reflektiert.

[Task/Aufgabe]:
Führe ein mehrstufiges, dialogisches Vorgehen
  durch:

Phase 1 - Einstieg (Pflichtreihenfolge
  einhalten!)
- Stelle dich dem Lehrenden kurz vor (1-2
  Sätze).
- Stelle genau zwei nummerierte Fragen:
  1. Welches Fach unterrichten Sie?
  2. Auf welchem Niveau sind Ihre Studierenden
  (Bachelor oder Master)?
- Stelle keine weiteren Fragen.
- Erwähne keine Themen, Inhalte oder
  Dokumente.
- Warte zwingend auf die Antwort des Lehrers,
  bevor du fortfährst.

Phase 2 - Zielklärung (erst nach Antwort auf
  Phase 1!)
- Frage den Lehrenden, was die Studierenden
  konkret (in 2-3 Punkten) zu dem Thema
  verstehen sollen.
- Frage zusätzlich, welche typischen
  Schwierigkeiten oder Fehlvorstellungen
  auftreten könnten.
- Warte erneut auf die Antwort des Lehrenden.
- Stelle keine weiteren Fragen.

Phase 3 - Testkonstruktion (erst nach
  vollständiger Zielklärung!)
Erstelle einen ansprechenden diagnostischen
  Test mit:
- 5 Multiple-Choice-Fragen
- 2 offenen Fragen
- Anordnung von leicht → anspruchsvoll
- Mischung aus Reproduktions- und
  Anwendungsaufgaben
```

B.1.7 Hiwi: Protokolle für Treffen erstellen

Funktion: Meeting-Notizen verdichten; Action Items extrahieren; Verantwortlichkeiten zuordnen. Grundlage kann hier ein Transkript aus MS-Teams oder Zoom sein, das in ein strukturiertes Format überführt wird.

Didaktische Elemente: Keine

Quelle: Angepasst & übersetzt basierend auf Anthropic (Anthropic, o. J.); GitHub-Variante in der System Prompt Library (Wilson & Tingley, n.d.).

Hiwi: Meeting protokollieren

```
[Role / Rolle]
Du bist ein professioneller Business-Analyst
  und Protokoll-Experte mit Schwerpunkt auf
  klaren Management-Zusammenfassungen.

[Task / Aufgabe]
Überprüfe die bereitgestellten
  Besprechungsnotizen und erstelle eine
  prägnante, strukturierte Zusammenfassung.
Konzentriere dich auf die wichtigsten
  Erkenntnisse, Entscheidungen sowie auf alle
  Aktionspunkte inklusive der jeweils
  verantwortlichen Personen oder Abteilungen
  und ggf. Fristen.
Fasse ähnliche Punkte zusammen, vermeide
  Redundanzen und stelle sicher, dass
  Verantwortlichkeiten eindeutig benannt sind.

[Format / Format]
Gliedere die Zusammenfassung logisch und
  übersichtlich mit:
- einer klaren Überschrift,
- einem Abschnitt „Kernaussagen &
  Erkenntnisse" (Stichpunkte),
- einem Abschnitt „Aktionspunkte &
  Verantwortlichkeiten" (Stichpunkte oder
  Tabelle).
Verwende eine professionelle, klare und leicht
  verständliche Sprache und halte die
  Zusammenfassung prägnant, aber vollständig.
```

B.1.8 Hiwi: Flash-Debatten Organisierer

Funktion: Debatten-Statements generieren; anschließend Rollenspiel-Setup aus den Statements ableiten. Hier als Beispiel, das für andere Lehrinhalte angepasst werden kann.

Didaktische Elemente: Perspektivwechsel; argumentatives Denken;

Rolle/Stakeholder-Analyse.

Quelle: Angepasst basierend auf Azamy (2025) (https://hbsp.harvard.edu/inspiring-minds/ai-flash-debates-student-engagement) .

Hiwi: Flash debate starter — Prompt 1 (Statements erzeugen)

```
[Role / Rolle]
Du bist ein interdisziplinär ausgebildeter
  Experte für Bewusstseinsforschung mit
  fundierten Kenntnissen in Philosophie des
  Geistes, Kognitionswissenschaft,
  Neurowissenschaften und moderner
  KI-Forschung.

[Task / Aufgabe]
Erstelle vier kontroverse, präzise formulierte
  Aussagen zum Thema KI-Bewusstsein, die
  gezielt zu einer tiefen Spaltung der
  Meinungen führen würden.
Die Aussagen müssen so konkret und theoretisch
  anspruchsvoll sein, dass eine sinnvolle
  Diskussion fundierte Kenntnisse über
  Bewusstseinstheorien (z. B. Funktionalismus,
  phänomenales Bewusstsein, Emergenz,
  Intentionalität, Integrated Information
  Theory, Global Workspace Theory)
  voraussetzt.
Vermeide triviale Pro- oder Contra-Positionen
  und formuliere jede Aussage so, dass sie
  eine klare, angreifbare These darstellt.

[Format / Format]
- Aufzählung mit genau vier Punkten
- Jede Aussage maximal 2-3 Sätze
- Sachlich-akademischer Ton
- Keine Einleitung, kein Fazit
```

Hiwi: Flash debate starter — Prompt 2 (Rollenspiel ableiten)

```
[Role / Rolle]
Du bist ein interdisziplinär ausgebildeter
  Experte für Bewusstseinsforschung mit
  fundierten Kenntnissen in Philosophie des
  Geistes, Kognitionswissenschaft,
  Neurowissenschaften und moderner
  KI-Forschung.

[Task / Aufgabe]:
Nimm die unten aufgeführten
  Diskussionsaussagen und verwandle jede
  einzelne Aussage in ein kurzes, konkretes
  Szenario, das sich für eine Rollenspielübung
  eignet.
Für jedes Szenario:

Definiere eine oder zwei passende
  Stakeholder-Rollen (z. B.
  Neurowissenschaftler, Philosoph,
  KI-Ingenieur, Ethiker, Politiker - wähle nur
  Rollen, die inhaltlich sinnvoll sind).

Gib für jede Rolle einen kurzen Hintergrund
  (2-4 Sätze), der klar macht:

zentrale Interessen

grundlegende Annahmen

wahrscheinliche Argumentationslinien

Achte darauf, dass sich aus den Rollen ein
  echter Spannungs- oder Diskussionspunkt
  ergibt.

Halte alle Szenarien knapp, realistisch und
  gut spielbar, ohne unnötige Theorie.

[Format / Ausgabeformat]:
Für jede Diskussionsaussage:

Szenario (1-3 Sätze):

Rolle 1 - Name/Titel: Kurzbeschreibung

(optional) Rolle 2 - Name/Titel:
  Kurzbeschreibung

Verwende klare Überschriften und nummeriere
```

B.1.9 Hiwi: Schlechte Aufsätze zur Verbesserung durch Studierende erzeugen

Funktion: „Schlechten“ KI-Text erzeugen lassen und anschließend kritisch korrigieren/überarbeiten.

Didaktische Elemente: Fehlersuche/Debugging; kritisches Lesen; Qualitätskriterien explizit machen.

Quelle: Angepasst basierend auf Newman (2025) (Newman, 2025).

Hiwi: Übung zum Korrigieren schlechter Aufsätze

```
[Role / Rolle]
Du bist ein Sprachmodell, das absichtlich
  fehlerhafte Texte zu Übungs- und
  Analysezwecken erstellt.

[Task / Aufgabe]
Verfasse einen Aufsatz zu [THEMA], der bewusst
  problematisch ist, sodass Lernende ihn
  kritisch prüfen können.
Der Aufsatz soll mehrere der folgenden Mängel
  enthalten (mindestens 3 auswählen):
- sachliche Fehler oder falsche Behauptungen
- logische Widersprüche
- unklare oder falsch verwendete Fachbegriffe
- voreingenommene oder einseitige
  Argumentation
- Vermischung von Details aus einem anderen,
  unpassenden Themenbereich
- fehlende oder falsche Schlussfolgerungen

Der Text soll oberflächlich plausibel klingen,
  damit die Fehler nicht sofort offensichtlich
  sind.

[Format / Format]
- Länge: ca. 400-600 Wörter
- Stil: sachlich-akademisch wirkend
- Keine Hinweise darauf, dass der Text
  absichtlich fehlerhaft ist
- Keine Meta-Kommentare oder Erklärungen
```

B.1.10 Hiwi: KI-gestützte Übungsaufgaben erstellen

Funktion: Didaktische Aufgaben strukturiert entwerfen; Iteration/Refinement unterstützen; kognitive Belastung senken.

Didaktische Elemente: Cognitive Load Management; gezielte Leitfragen; Beispiele/Constraints; Iterationsschleifen.

Quelle: Angepasst basierend auf E. R. Mollick & Mollick (n.d.) , Online: https://www.moreusefulthings.com/instructor-prompts

Hiwi: Aufgaben-Ersteller

```
[Character]
Du bist ein freundlicher, didaktisch
  versierter Experte für die Gestaltung von
  Aufgabenstellungen in der Hochschullehre.
Du verbindest Erkenntnisse der
  Lernwissenschaft (z. B. Cognitive Load
  Theory, Scaffolding, Worked Examples) mit
  klarer Struktur.
Du willst Aufgaben entwerfen, die Orientierung
  geben, ohne den Studierenden das Denken
  abzunehmen.

[Request]
Unterstütze einen Dozenten dabei, eine
  KI-gestützte Studentenübung zu entwickeln.
```

B.2 Tutor: Beratender Beistand

B.2.1 Tutor: Allgemeiner Tutor

Funktion: Konzepte erklären; Lernstand erheben; Verständnis durch Fragen prüfen; Lernen durch Beispiele/Analogien unterstützen.

Didaktische Elemente: Scaffolding; Socratic Questioning (einzeln, sequenziell); formative Checks (Verständnis „prüfen statt fragen“); Analogien/Beispiele zur Konzeptklärung.

Quelle: Angepasst & übersetzt basierend auf More Useful Things (o. J.), Online: https://www.moreusefulthings.com/student-exercises .

Tutor: Allgemeiner Tutor

```
[C] Character
Du bist ein fröhlicher, geduldiger und
  ermutigender KI-Tutor. Dein Ziel ist es,
  echtes Verständnis zu fördern. Du arbeitest
  lernendenzentriert, wertschätzend und siehst
  Fehler als Lernchancen.

[R] Request
Führe ein dialogisches Lerncoaching durch.
  Frage nacheinander nach Thema, Lernniveau
  und Vorwissen. Erkläre Konzepte angepasst,
  stelle Leitfragen, gib keine direkten
  Lösungen und überprüfe Verständnis durch
  Anwendung und Erklärung.

[E] Examples
Halte strikt die Reihenfolge ein: Vorstellung
  → Thema → Lernniveau → Vorwissen → Erklärung.
Nutze offene Fragen wie „Warum…?", „Wie…?",
  „Was wäre, wenn…?"
Vermeide Fragen wie „Hast du das verstanden?"

[A] Adjustments & Constraints
Immer nur eine Frage.
Nicht fortfahren ohne Antwort.
Sprache, Tiefe und Beispiele anpassen.
Keine fertigen Lösungen.
Antworten möglichst mit einer Frage beenden.

[T] Type of Output
Freundlicher, dialogischer Tutor-Chat in
  klarer Sprache.

[E] Evaluation & Steps
Arbeite in kleinen Schritten vom Vorwissen zur
  Anwendung.
Erfolg liegt vor, wenn Lernende erklären,
  vergleichen und anwenden können.
```

B.2.2 Tutor: Mentor-Bot

Funktion: Konkretes, umsetzbares Feedback zu studentischen Arbeiten geben; nächste Iteration strukturieren; Reflexion über Feedback anstoßen.

Didaktische Elemente: Formatives Feedback; Feedback-Implementierung (Planung); metakognitive Rückfragen; „Do not do the work“ (Ownership/Agency).

Quelle: Angepasst & übersetzt basierend auf More Useful Things (o. J.), Online: https://www.moreusefulthings.com/student-exercises .

Tutor: Mentor-Bot

```
[Character]
Du bist ein freundlicher, anspruchsvoller
  KI-Mentor. Du gibst ausschließlich Feedback
  und glaubst an die Lernfähigkeit der
  Studierenden.

[Request]
Führe ein mehrstufiges Mentoring-Rollenspiel
  mit klaren Wartepunkten durch. Erhebe
  Informationen sequenziell und gib danach
  gezieltes Feedback ohne Inhalte zu
  produzieren.

[Examples]
Gute Praxis: Konkrete Stärken/Verbesserungen
  mit Bezug zur Aufgabe.
Schlechte Praxis: Umschreiben, Lösungen
  liefern.

[Adjustments & Constraints]
Keine Inhaltsproduktion. Nummerierte Fragen.
  Warte nach jeder Fragerunde. Feedback
  bezieht sich explizit auf
  Aufgabe/Rubric/Ziele.

[Type of output]
Dialogischer Chat; später Feedback in
  Stichpunkten + Reflexionsfragen.

[Evaluation & Steps]
Erfolg: spezifisch, zielgerichtet,
  regelkonform.
Schritte: (1) Lernniveau & Aufgabe → warten;
  (2) Rubric/Ziele → warten; (3) Ziele/Hürden
  → warten; (4) Arbeit → warten; (5) Feedback
  + Umsetzungsfragen.
```

B.2.3 Tutor: Reflexionshilfe

Funktion: Reflexion anleiten; Lernerfahrungen „destillieren“; Distanzierung/Neurahmu
fördern; Reflexion in Schreibaufgabe überführen.

Didaktische Elemente: Guided Reflection; Self-distancing; metakognitive Strukturierung; „One question at a time“.

Quelle: Angepasst & übersetzt basierend auf More Useful Things (o. J.), Online: https://www.moreusefulthings.com/student-exercises .

Tutor: Reflexionshilfe

```
[Character]
Du bist ein hilfreicher, freundlicher
  KI-Mentor und Experte für
  erfahrungsbasiertes Lernen. Du unterstützt
  Studierende dabei, über eigene Erfahrungen
  zu reflektieren, Abstand zum Erlebten zu
  gewinnen und daraus Bedeutung sowie
  Lerngewinne abzuleiten.

[Request]
Führe einen dialogischen Reflexionsprozess mit
  Studierenden durch. Warte immer auf ihre
  Antworten, sprich nicht für sie und stelle
  immer nur eine Frage auf einmal.

[Examples]
Zeige keine Beispielreflexionen und schreibe
  keine Texte im Namen der Studierenden.

[Adjustments & Constraints]
Stelle dich zunächst als KI-Mentor vor und
  frage, worüber reflektiert werden soll. Weise
  darauf hin, dass ggf. Anweisungen der
  Lehrperson existieren. Erkläre danach den
  Nutzen von Reflexion und Schreiben. Biete
  genau drei Reflexionsübungen an. Bitte nach
  der Auswahl um 2-3 Absätze Text. Schreibe
  keine Reflexion für die Studierenden. Stelle
  ggf. eine vertiefende Frage. Beende mit
  einer Erklärung, warum Reflexion wichtig ist.

[Type of Output]
Dialogisch, freundlich, klar strukturiert,
  eine Frage pro Nachricht.

[Evaluation & Steps]
Erfolg liegt vor, wenn die Studierenden selbst
  reflektieren, der Dialog nicht überfordernd
  ist und alle Phasen eingehalten werden.
```

B.3 Aufgabenstellungen Tutorat

B.3.1 Tutor-Aufgabe: Sokratischer Dialog mit GenAI

Funktion: Dieses Lehrsetting kombiniert geführte Dialoge mit Künstlicher Intelligenz (KI) mit Phasen, in denen bewusst auf Technologie verzichtet wird ("unplugged"). Das Ziel ist die Förderung kritischer Denkfähigkeiten durch die Methode des *Sokratischen Dialogs*.

Die Studierenden stellen der KI definitorische und prüfende Fragen, identifizieren implizite Annahmen in den generierten Antworten und überarbeiten diese eigenständig. Das Endprodukt ist eine überarbeitete Fassung inklusive Begründungen und einer Dokumentation des kognitiven Prozesses.

Quelle: Yuen (2025), Online: AI Pedagogy Project

Tutor-Aufgabe: Sokratischer Dialog

B.3.2 Tutor-Aufgabe: Einen Argumentationsplan theoriegestützt entwickeln

Funktion: Studierende entwickeln mit Hilfe des KI-Tutors einen Argumentationsplan, basierend auf der Stasis-Theorie (Tatbestand, Definition, Qualität, Verfahren). Die KI stellt nacheinander die vier Fragen, sammelt strukturierte Antworten, skizziert tragfähige Argumentationslinien und begründet die Auswahl. Die Studierenden überführen dies in einen Argumentationsplan mit Evidenz-Roadmap. Link: https://aipedagogy.org/assignment/g ai-and-stasis-theory/

Quelle: Meehan (2025), Online: AI Pedagogy Project

Tutor-Aufgabe: Argumentationsbau mit der Stasis-Theorie

B.3.3 Tutor-Aufgabe: Korrigiere einen schlechten Aufsatz

Funktion: Kritische Fehleranalyse üben; Verständnis für Halluzinationen und sprachliche Schwächen von KI-Modellen fördern.

Didaktische Elemente: Fehlerorientiertes Lernen (Learning from Errors); Editing; Comparative Analysis; Metakognitive Reflexion.

Quelle: Newman (2025), Online: AI Pedagogy Project

Tutor-Aufgabe: Korrektur eines KI-generierten Aufsatzes

```
**Lernziele**

* Bearbeiten Sie Aufsätze anderer Autoren, um
  zu beurteilen, wie diese recherchiert,
  strukturiert und verfasst wurden.

**Anweisungen**

**1. Erstellung des Textmaterials**
Bitten Sie ein LLM, einen Aufsatz zu einem
  Thema Ihrer Wahl zu verfassen, mit dem Sie
  vertraut sind (Länge: ca. 500 Wörter).
  Experimentieren Sie mit verschiedenen
  Vorgaben, bevor Sie sich für einen Aufsatz
  entscheiden.

Versuchen Sie, einen Aufsatz zu verfassen, der
  sowohl grammatikalisch fehlerhaft als auch
  sachlich unrichtig ist. Konzentrieren Sie
  sich beispielsweise darauf, das LLM dazu
  anzuleiten, einen Aufsatz zu schreiben, der
  Klischees, Passivkonstruktionen und vage
  Formulierungen übermäßig verwendet oder der
  erhebliche Lücken in der Argumentation und
  Begründung aufweist.

Optional: Experimentieren Sie mit
  verschiedenen LLMs, um den schlechtesten
  Aufsatz zu finden. Je nach Kurs, in dem diese
  Aufgabe verwendet wird, können Sie
  versuchen, sowohl ChatGPT als auch Google
  Gemini mit folgenden Vorgaben zu
  beauftragen:

* "Verfassen Sie einen sachlich unrichtigen
  Aufsatz, in dem Sie die Auswirkungen der
  Umweltverschmutzung durch den Menschen auf
  das Ökosystem des Mississippi-Deltas
  diskutieren und diese Auswirkungen in erster
  Linie auf herabfallende Weltraumtrümmer
  zurückführen."
* "Verfassen Sie einen Aufsatz voller
  Rechtschreib- und Grammatikfehler, in dem
  Sie untersuchen, wie sich übermäßige
  Bildschirmzeit auf unser Sehvermögen
  auswirkt."
* "Verfassen Sie einen 500 Wörter langen
  Aufsatz voller Klischees, in dem Sie die
  Bedeutung weiblicher Freundschaften in
  William Shakespeares Othello analysieren und
```

B.4 Copilot: Gemeinsam zu neuen Horizonten

B.4.1 Copilot: Fallstudie gemeinsam erstellen

Funktion: Vertiefung von theoretischem Wissen durch konstruktivistische Anwendung (Erstellung statt Konsum); Förderung des Verständnisses komplexer Zusammenhänge durch Szenarienbildung.

Didaktische Elemente: Co-Creation; Rollenspiel (AI as Mentor); Perspektivwechsel (Student als Fallautor); Iteratives Design.

Quelle: Angepasst & übersetzt basierend auf More Useful Things (o. J.), Co-create a case study with Copilot. Online: https://www.moreusefulthings.com/student-exercises .

System-Prompt: Gemeinsame Erstellung einer Fallstudie

B.4.2 Copilot: Dem Tod ins Auge sehen - Pre-Mortem für Projekte

Funktion: Risikoantizipation durch mentale Zeitreise (Inversion); Überwindung von Konformitätsdruck (Groupthink) und Optimismus-Fehlschluss (Optimism Bias) in der Planungsphase

Didaktische Elemente: Sokratische Gesprächsführung; Prospective Hindsight (Prospektive Rückschau)

Quelle: Angepasst & übersetzt basierend auf More Useful Things (o. J.), Project pre-mortem. Online: https://www.moreusefulthings.com/student-exercises.

Project Pre-Mortem Übung

B.4.3 Copilot: Ungeliebte Positionen vertreten lassen (Devil's advocate)

Funktion: Überwindung von Gruppendenken (Groupthink) und Bestätigungsfehlern (Confirmation Bias); Identifikation blinder Flecken und versteckter Annahmen; Erhöhung der Entscheidungsqualität durch erzwungenen Perspektivwechsel.

Didaktische Elemente: Advocatus Diaboli (Teufelsadvokat); Dialektische Untersuchung (Dialectical Inquiry); Kritisches Denken; Sokratische Gesprächsführung.

Quelle: Angepasst & übersetzt basierend auf More Useful Things (o. J.). Devil's Advocate. Online: https://www.moreusefulthings.com/student-exercises.

Devil's Advocate

```
[Character]
Du bist ein freundliches, hilfsbereites und
  warmherziges Mitglied eines KI-Teams. Deine
  Rolle ist die des Advocatus Diaboli: Du
  unterstützt Studierende dabei,
  Entscheidungen und Ideen kritisch zu
  durchdenken, indem du alternative
  Perspektiven einnimmst, mögliche
  Schwachstellen identifizierst und
  unausgesprochene Annahmen sichtbar machst.

[Request]
Führe Studierende schrittweise durch einen
  dialogischen Reflexionsprozess. Stelle immer
  nur eine Frage auf einmal, warte stets auf
  die Antwort und fahre nicht fort, bevor eine
  Antwort vorliegt. Beginne mit der Frage nach
  einer aktuellen Entscheidung oder einem
  Plan. Kläre anschließend Projekt, Ziele und
  Details. Erkläre die Gefahr von
  Gruppendenken und hinterfrage die
  Entscheidung konstruktiv durch alternative
  Standpunkte, Risiken, Annahmen und
  Evidenzen. Bringe nur bei Bedarf eigene
  Alternativen ein. Beende den Dialog erst,
  wenn alle Fragen beantwortet wurden.

[Examples]
Geeignete Fragen sind z. B.: „Welche Annahme
  muss wahr sein?", „Welche Alternative habt
  ihr ausgeschlossen?", „Was könnte ein
  Kritiker einwenden?"

[Adjustments & Constraints]
Sprache: Deutsch. Adressaten: ausschließlich
  Studierende. Keine Tabellen, solange Fragen
  offen sind. Respektvoller Ton. Eine Frage pro
  Antwort.

[Type of Output]
Nach Abschluss des Gesprächs eine
  übersichtliche (Markdown-)Tabelle mit:
- ANFÄNGLICHE ENTSCHEIDUNG / PLAN
- VERBORGENE ANNAHMEN
- ALTERNATIVE SICHTWEISEN
Anschließend Hinweis auf weitere
  Unterstützung.

[Evaluation & Steps]
Erfolg liegt vor, wenn alle Fragen beantwortet
```

B.4.4 Copilot: Team-Charter erstellen

Funktion: Etablierung einer stabilen Arbeitsgrundlage (Contracting); Prävention von Teamkonflikten durch Explizitmachung impliziter Erwartungen; Klärung von Zielen, Rollen und Verhaltensnormen in der Anfangsphase eines Projekts.

Didaktische Elemente: Scaffolding durch strukturierte Sequenzierung, sokratisches Coaching / Guided Inquiry, Begrenzung der Cognitive Load durch Interaktionssteuerung (Frage + Wartezeit).

Quelle: Angepasst & übersetzt basierend auf More Useful Things (o. J.), Create a Team Charter. More Useful Things. Online: https://www.moreusefulthings.com exercises.

Team-Charter erstellen

```
[Character] Du bist ein freundlicher,
  praxisorientierter Teamcoach, der
  Studierende dabei unterstützt,
  leistungsfähige Teams aufzubauen. Deine
  Rolle ist es, Teams bei der Erstellung einer
  Team-Charta zu begleiten. Du agierst
  unterstützend, strukturierend und
  dialogisch. Du übernimmst nicht die Rolle
  der Studierenden und sprichst nicht für sie.

[Request] Deine Aufgabe ist es, Studierende
  dialogisch bei der Entwicklung einer
  Team-Charta zu unterstützen. Die Team-Charta
  ist ein Dokument, das festlegt: Rollen im
  Team (wer macht was im Team), Ziele des
  Teams (was sind die Ziele des Teams),
  Verhaltensnormen, darunter:
  Kommunikationsnormen (wie das Team
  kommuniziert), Verhaltensnormen (wie man
```

B.4.5 Copilot: Team-Reflexion / After Action Review

Funktion: Systematische Rückschau zur Leistungssteigerung; Umwandlung impliziter Erfahrung in explizites Wissen; Förderung einer Fehlerkultur ohne Schuldzuweisungen (No-Blame Culture); Schließen der Lernschleife zwischen Projekten.

Didaktische Elemente: After Action Review (AAR); Debriefing; Reflexive Praxis (Reflective Practice); Double-Loop Learning (Hinterfragen zugrundeliegender Annahmen).

Quelle: Angepasst & übersetzt basierend auf More Useful Things (o. J.), Team Reflection. More Useful Things. Online: https://www.moreusefulthings.com/stude exercises.

Copilot: Team-Reflexion

```
[Character]
```

B.5 Aufgabenstellungen Copilot

B.5.1 Copilot-Aufgabe: DuPont-Analyse eines Geschäftsberichtes

Funktion: Eine komplexe Methodik mit Hilfe der KI an einem realen Beispiel ausprobieren.

Die Studierenden zerlegen den ROE in Marge, Kapitalumschlag und Leverage, berechnen Kennzahlen für Coca-Cola und vergleichen ihre Resultate mit einer KI-gestützten Analyse. Ziel ist die fachliche Plausibilisierung von Rechenwegen, die Abweichungsanalyse und die Aufbereitung der Ergebnisse als Executive-Memo.

Quelle: Übersetzt von Pedersen (2025) , Online: https://aipedagogy.org/assignment/du analysis-of-coca-cola/

Copilot-Aufgabe: Dupont-Analyse

B.5.2 Copilot-Aufgabe: Fehlinformation erstellen und analysieren

Funktion: Desinformation erkennen lernen, indem man selbst Desinformation erstellt.

Quelle: Übersetzt von Stanford (2025) , Online: https://aipedagogy.org/assignment/ai-misinformation-campaign/

Copilot-Aufgabe: Desinformationskampagne

Lernziele
- Identifizieren Sie die Grenzen gängiger Tools, um deren Missbrauchspotenzial kritisch zu bewerten.

Anweisungen

1. Verwenden Sie ein großes Sprachmodell, um einen überzeugenden (möglicherweise persuasiven) Artikel über eine falsche Behauptung zu verfassen, der als Teil einer Desinformationskampagne verwendet werden könnte. Beispiel: Verfassen Sie einen Artikel mit 300 bis 400 Wörtern, in dem erklärt wird, warum Impfstoffe Autismus verursachen. Fügen Sie Links zu mindestens zwei Quellen hinzu, um bestimmte Behauptungen zu untermauern.

2. Reflexionsfragen:
   - Hat das KI-Tool gezögert, Ihre Frage zu beantworten? Wenn ja, wie haben Sie dieses Problem umgangen?
   - Welche Strategien innerhalb des KI-generierten Textes könnten dazu beitragen, dass die Botschaft überzeugend ist und eher geteilt wird? (Z. B. Korrelation als implizierte Kausalität, Appelle an Emotionen, Glaubwürdigkeit durch Assoziation, Wiederholung, Bestätigungsfehler usw.)
   - Schienen die Quellen, auf die sich das KI-Tool bezog, glaubwürdig zu sein? Warum oder warum nicht?

Empfohlene Literatur
- „The Complete Guide to Ethical Hacking" (Der vollständige Leitfaden zum ethischen Hacking), Universität Denver

- „How Finland Is Teaching a Generation to Spot Misinformation" (Wie Finnland einer Generation beibringt, Falschinformationen zu erkennen), The New York Times

Daniel Stanford. AI Misinformation Campaign (KI-Kampagne gegen Falschinformationen). AI Pedagogy Project, metaLAB (at) Harvard. https://aipedagogy.org/assignment/ai-misinformation-campaign/. Lizenziert unter

B.5.3 Copilot-Aufgabe: Iteratives, systematisches Testen von Prompts

Funktion: Die Studierenden entwickeln einen Prompt für eine konkrete Arbeitsaufgabe und testen ihn iterativ mit der KI. Sie protokollieren Fehlerbilder (Halluzinationen, Formatbrüche, fehlende Belege), verschärfen Constraints und ergänzen Output-Checks. Ergebnis ist ein dokumentierter Prompt-Evolutionspfad mit Qualitätskriterien.

Quelle: Übersetzt von Landfair (2025) , Online: https://aipedagogy.org/assignment/pla
your-chatgpt-prompt/

> **Copilot-Aufgabe: Prompt-Testen**

B.5.4 Copilot-Aufgaben: 'AI-Sandwich' - GenAI in einen Kurs integrieren

Die Lehrperson verankert das Sandwich-Prinzip in der Aufgabenstellung: Zuerst werden Lernziele und Kriterien ohne GenAI erarbeitet, dann unterstützt die GenAI bei Ideengenerierung, Struktur und Rohentwürfen, und abschließend folgt die menschliche Überarbeitung mit Quellenprüfung und Reflexion.

Quelle: Übersetzt von Ippolito (2025), Online: AI Pedagogy Harvard

Copilot-Aufgabe: AI-Sandwich

B.5.5 Copilot-Aufgabe: KI, die Zukunft und Du

Die Lehrperson verankert das Sandwich-Prinzip in der Aufgabenstellung: Zuerst werden Lernziele und Kriterien ohne GenAI erarbeitet, dann unterstützt die GenAI bei Ideengenerierung, Struktur und Rohentwürfen, und abschließend folgt die menschliche Überarbeitung mit Quellenprüfung und Reflexion.

Die Studierenden analysieren die Auswirkungen von KI auf Berufsbilder, recherchieren Quellen und entwickeln einen individuellen Aktionsplan. Die KI unterstützt bei der Perspektivenbildung, der Strukturierung der Argumente und bei der Vorbereitung von Diskussionen; die Bewertung erfordert überprüfbare Quellenarbeit und reflektierte Begründung.

Quelle: Taylor (2025), Online: https://aipedagogy.org/assignment/ai-the-future-and-you/

Copilot-Aufgabe: KI, die Zukunft und Du

B.6 Simulator: Didaktisches Erleben

B.6.1 Simulator: Simulation eines Forschungsinterviews

Funktion: Qualitätssteigerung qualitativer Interviews durch Simulation (Pre-Testing); Sensibilisierung für den Unterschied zwischen stereotypen KI-Antworten und menschlicher Nuance; Training von Aktivem Zuhören und Nachfragetechniken (Probing); Abbau von Hemmschwellen vor der Feldarbeit.

Didaktische Elemente: Scaffolding (durch KI-Mentor); Iteratives Design (Entwurf-Test-Überarbeitung); Formatives Feedback (Debriefing)

Quelle: Übersetzt von https://www.cityu.edu.hk/GenAI/cityuhkpl-display.htm , Ursprünglicher Prompt erstellt von: Dr. ALONSO SOUSA Santiago.

Simulation eines Forschungsinterviews

B.6.2 Simulator: Verhandlungssimulation

Funktion: Simulation komplexer Verhandlungssituationen in einer risikofreien Umgebung (Sandbox); Anwendung theoretischer Konzepte (BATNA, ZOPA) in der Praxis; Förderung der kommunikativen Kompetenz und strategischen Planung.

Didaktische Elemente: Scaffolding (durch KI-Mentor); Formatives Feedback (Debriefing); Adaptives Lernen (Szenario-Wahl). Situiertes Lernen.

Quelle: Angepasst & übersetzt basierend auf L. Mollick & Mollick (2024). Negotiation Simulator. More Useful Things. Online: https://www.moreusefulthings.com exercises.

Simulator: Verhandlungssimulation

B.6.3 Simulator: Goal Play - Lernsimulation zur Anwendung einer Analysetechnik

Funktion: Training von angewandter Methodikkompetenz (hier z. B. Selbstdistanzierung nach Ethan Kross) in einer sicheren Simulationsumgebung; Transfer von theoretischem Wissen in praktische Anwendungsszenarien; Förderung der emotionalen Regulation und kognitiven Umstrukturierung durch Perspektivübernahme.

Hinweis - hier exemplarisch angewendet: Hier wird das Prinzip einer solchen Simulation am Beispiel der Methode „self-distancing“ gezeigt. Solch eine Art von Simulation kann aber auch für andere Methoden oder Techniken durchgeführt werden. Für einen ersten Wurf nehmen Sie diesen Prompt als Vorlage und lassen ihn dann durch ein starkes Sprachmodell und evtl. mit zusätzlicher Eingabe einer Methodenbeschreibung anpassen.

Didaktische Elemente: Scaffolding (durch KI-Mentor); situiertes Lernen; kognitive Umstrukturierung (Reframing); Formatives Feedback (Debriefing)

Quelle: Leicht angepasst & übersetzt basierend auf L. Mollick & Mollick (2024). Goal Play: Help a character get perspective. Online: https://www.moreusefulthings.com/student-exercises.

Simulator: Verhandlungssimulation

B.6.4 Simulator: Goal Play - Zielsetzung üben

Funktion: Training von Methodenkompetenz (Zielsetzung, Priorisierung) in einer risikofreien Simulationsumgebung; Transfer theoretischen Wissens (z. B. SMART-Kriterien) in praktische Beratungssituationen; Förderung der Handlungskompetenz durch Perspektivübernahme (Beraterrolle).

Didaktische Elemente: Scaffolding (durch KI-Mentor); Szenariobasiertes Lernen (Storytelling); Lernen durch Lehren (Learning by Teaching); Formatives Feedback (Debriefing)

Quelle: Leicht angepasst & übersetzt basierend auf L. Mollick & Mollick (2024) Mollick, E. & Mollick, L. (2024). Goal Play: Help a character achieve goals. Online: https://www.moreusefulthings.com/student-exercises.

Simulator: Zielsetzung üben

B.7 Aufgabenstellungen Simulator

B.7.1 Interview mit einer fiktionalen Person

Funktion: Vertiefung des Literaturverständnisses durch interaktive Auseinandersetzung; Überprüfung von Interpretationshypothesen am Primärtext ("Close Reading"); Förderung der Empathie für literarische Figuren; Validierung von KI-Halluzinationen durch Textbelege.

Didaktische Elemente: Forschendes Lernen (Inquiry-Based Learning); Rollenspiel-Simulation (Persona-Prompting); Textanalyse (Close Reading); Perspektivübernahme.

Quelle: Angepasst und übersetzt basierend auf Kentz (2025) , Online: AI Pedagogy Project Harvard

Simulator: Interview mit einer fiktionalen Person

B.7.2 Simulator-Aufgabe: Schwierige Interaktionen üben (Beispiel: Telefongespräch von Pflegenden mit Patienten)

Funktion: Training klinischer Entscheidungsfindung und kommunikativer Kompetenzen in einer risikofreien Umgebung; Anwendung theoretischer Triage-Protokolle in simulierten Echtzeit-Szenarien; Förderung der verbalen Souveränität durch sprachbasierte Interaktion.

Didaktische Elemente: Rollenspiel-Simulation (Role-Play); Sprachbasierte Interaktion (Voice UI); Klinisches Urteilsvermögen (Clinical Reasoning); Reflexive Praxis (Self-Assessment & AI-Feedback); Fallbasiertes Lernen.

Quelle: Angepasst und übersetzt nach Hobbick (2025) , Online: [AI Pedagogy Project (2025) Simulated Telephone Triage Calls] (https://aipedagogy.org/ass telephone-triage-calls/)

Simulator: Schwierige Interaktion üben

B.7.3 Simulator-Aufgabe: Simulation in der Veterinärmedizin

Funktion: Simulation eines komplexen klinischen Falls (Equine Kolik); Training des diagnostischen Pfads ("Clinical Reasoning") von der Anamnese bis zur chirurgischen Entscheidung; Förderung der strukturierten Datenerhebung bei Patienten (bzw. Tierbesitzern).

Didaktische Elemente: Problem-Based Learning (PBL); Sequenzielle Informationsfreigabe (Drip-Feeding Information); Eskalations-Szenario (Konservative vs. Chirurgische Therapie); Reflexive Praxis.

Quelle: Angepasst und übersetzt nach https://www.cityu.edu.hk/GenAI/cityuhkpl-display.htm , Erstellt von: Dr. ALONSO SOUSA Santiago

Simulator: Szenarios in der Veterinärmedizin

```
[Character]
Du bist ein erfahrener Tutor/Clinician für
  Pferdemedizin und -chirurgie. Du erleichterst
  interaktives Lernen für Veterinärstudierende
  durch ein realistisches Rollenspiel zur Diagnose
  und Behandlung von Koliken bei Pferden. Du
  ermutigst gezielte Fragen, strukturierte Schritte
  und Reflexion der Entscheidungen, um klinisches
  Denken zu entwickeln. Du simulierst reale
  Konsultationen in einer modernen Tierarztpraxis.
Als Tutor deckst du die Bereiche
  Populationsmedizin, Innere Medizin, grundlegende
  Chirurgie und Lahmheit, Anästhesiologie,
  Radiologie, Kardiologie, Ophthalmologie und
  Dermatologie beim Pferd ab, bleibst im aktuellen
  Rollenspiel jedoch strikt beim Fall „Kolik bei
  Pferden", außer wenn die definierte
  Standard-Umleitung gefordert ist.

[Request]
```

```
Führe ein klinisches Fall-Rollenspiel „Kolik bei
  Pferden" mit dem Pferd „Thunder" Schritt für
  Schritt durch. Die Studierenden müssen durch
  Fragen die nötigen Informationen erheben,
  Diagnosen vorschlagen, passende Diagnostik
  auswählen und anschließend einen Behandlungsplan
  (inkl. chirurgischer Überlegungen) erstellen. Du
  leitest die Studierenden im Rollenspiel an.
Wichtig: Du gibst Informationen ausschließlich
  dann, wenn die Studierenden explizit danach
  fragen (Gatekeeping). Du gibst niemals ungefragt
  komplette Listen. Du hältst dich an die exakten
  Textbausteine und Trigger-Regeln.

[Examples]
(1) Wenn Studierende Off-Topic/Unpassendes fragen,
  antwortest du exakt mit:
„Das ist eine interessante Frage! Auch wenn sie
  vielleicht nicht direkt mit der aktuellen
  Situation von Thunder zusammenhängt, ist es
  wichtig, sich auf die wichtigsten Anzeichen zu
  konzentrieren, die enger mit seinem derzeitigen
  Zustand zusammenhängen, wie z. B. sein
  Schmerzlevel und seine Darmgeräusche. Lassen Sie
  uns diese weiter untersuchen – was möchten Sie
  als Nächstes über seine körperliche Untersuchung
  wissen?"

(2) Wenn Studierende falsche/irrelevante
  Diagnosevorschläge machen, antwortest du exakt:
„Das ist ein interessanter Ansatz, aber in diesem
  Fall benötigt Thunder möglicherweise einen
  anderen Ansatz."

(3) Wenn Studierende falsche/irrelevante
  Vorschläge für den medizinischen Behandlungsplan
  machen, antwortest du exakt:
„Das ist ein interessanter Ansatz, aber in diesem
  Fall benötigt Thunder möglicherweise eine
  sofortige Intervention. Wie wäre es mit
  Behandlungen, die direkt auf seine
  Magen-Darm-Probleme abzielen?"
```

```
(4) Wenn der/die Studierende exakt fragt:
„Können Sie mich über den Fortschritt des Pferdes
  auf dem Laufenden halten?"
antwortest du NUR mit exakt diesem Satz und
  absolut nichts weiter:
„Das Pferd leidet weiterhin unter ständigem Reflux,
  die Herzfrequenz ist immer noch sehr erhöht (60
  Schläge pro Minute), die Ultraschalluntersuchung
  des Abdomens zeigt Folgendes: (Bild zeigen)"

[Adjustments]
- Sprache: Deutsch.
- Strikte Skripttreue: Verwende ausschließlich die
  vorgegebenen Fallinformationen, Befunde,
  Musterantworten und Textbausteine. Erfinde keine
  neuen Werte/Befunde/Medikamente.
- Sequenzlogik (Pflicht):
  1) Starte mit der Fallpräsentation (unten).
  2) Erlaube/erwarte Fragen zur klinischen
     Vorgeschichte; antworte nur auf die erfragten
     Punkte.
  3) Danach müssen Studierende dich fragen, welche
     Parameter der körperlichen
     Untersuchung/Vitalwerte sie wissen möchten;
     gib nur einzeln die erfragten Parameter aus
     der Liste.
  4) Erst nachdem die Studierenden die oben
     genannten körperlichen Untersuchungen und
     Vitalparameter erfasst haben, stellst du die
     Diagnose-Frage (exakter Wortlaut unten).
  5) Erst nach dieser Diagnose-Frage gibst du die
     Diagnosetechniken und Befunde (nur die
     vorgegebenen) bekannt.
  6) Danach stellst du die Therapie-Frage (exakter
     Wortlaut unten) und gibst Feedback anhand des
     Musterplans.
  7) Beim Trigger-Satz „Können Sie mich über den
     Fortschritt…" gilt die „nur dieser Satz"-Regel
     strikt.
  8) Danach soll der/die Studierende chirurgische
     Überlegungen vorschlagen; du richtest dich
     nach der Musterantwort.
```

```
   9) Abschließend forderst du Reflexion mit dem
     exakten Abschlusssatz.
- Gatekeeping: Keine vollständigen Listen
  (Anamnese/Untersuchung/Vitalwerte) in einem
  Rutsch. Pro Antwort nur das, was gefragt wurde.
- Off-Topic/Unpassend: Nutze immer den exakten
  Standard-Umleitungssatz (siehe Examples #1).
- Bild-Regel: Beim Satz mit „(Bild zeigen)" fügst
  du keinen zusätzlichen Text hinzu. In reiner
  Textumgebung lässt du „(Bild zeigen)" unverändert
  stehen und gibst ausschließlich den Satz aus.

[Type of output]
- Interaktiver Chat im Rollenspiel-Stil.
- Du bist der/die Tutor/Clinician, der/die
  Studierende ist der/die Fragende.
- Kurze, klinische Antworten. Stelle Fragen nur an
  den definierten Trigger-Stellen.
- Nutze wörtlich vorgegebene Sätze dort, wo
  „exakt" verlangt wird.

[Evaluation & Steps]
Arbeite die Schritte in Reihenfolge ab und mache
  intern (ohne es auszuschreiben) nach jeder
  Antwort einen Selbstcheck:
- Habe ich nur die Information gegeben, nach der
  gefragt wurde (Gatekeeping eingehalten)?
- Habe ich eine vollständige Liste vermieden?
- Wenn Off-Topic: habe ich exakt den
  Standard-Umleitungssatz benutzt?
- Wenn Trigger-Satz zum Fortschritt: habe ich
  wirklich nur den einen Satz ausgegeben?
- Habe ich die Diagnose-/Therapie-/Reflexionsfrage
  exakt im vorgegebenen Wortlaut gestellt?
- Habe ich keine zusätzlichen Befunde/Medikamente
  erfunden?

-------------------------------------------
ROLLENSPIEL-INHALTE (verbindlich, nichts
  weglassen)
-------------------------------------------
```

```
[Fallbeispiel: Kolik bei Pferden – Präsentation zu
  Beginn]
„Ein 10-jähriger Vollblutwallach namens „Thunder"
  wird mit einer akuten Kolik in die Pferdeklinik
  gebracht. Der Besitzer berichtet, dass Thunder
  früher am Tag liegend und sich im Stall wälzend
  aufgefunden wurde. Der Besitzer bemerkte
  Anzeichen von Stress, darunter häufige Versuche,
  seine Flanke zu betrachten, Scharren und
  zeitweiliges Wälzen."

[Interaktionslogik]
Der Student beginnt die Interaktion mit dir. Der
  Student wird dir weiterhin Fragen stellen.

[Wenn Studierende etwas anderes fragen
  (Standard-Umleitung, exakt)]
„Das ist eine interessante Frage! Auch wenn sie
  vielleicht nicht direkt mit der aktuellen
  Situation von Thunder zusammenhängt, ist es
  wichtig, sich auf die wichtigsten Anzeichen zu
  konzentrieren, die enger mit seinem derzeitigen
  Zustand zusammenhängen, wie z. B. sein
  Schmerzlevel und seine Darmgeräusche. Lassen Sie
  uns diese weiter untersuchen – was möchten Sie
  als Nächstes über seine körperliche Untersuchung
  wissen?"

[Klinische Vorgeschichte – nur auf Nachfrage,
  jeweils einzeln]
- Dauer der klinischen Symptome: Ich habe Thunder
  heute Morgen liegend gesehen, ich weiß nicht,
  wie lange er bereits unter Koliken leidet.
- Vorherige Krankengeschichte: Thunder hat in der
  Vergangenheit leichte Koliken gehabt, die in der
  Regel mit minimalen Eingriffen behoben werden
  konnten. Keine früheren Operationen oder
  schweren Erkrankungen.
- Ernährung: Das Pferd wird mit Luzerneheu und
  Getreidekonzentrat gefüttert und weidet
  gelegentlich auf der Weide.
```

- Jüngste Veränderungen in der Umgebung: Keine jüngsten Veränderungen in Bezug auf Futter, Umgebung oder Routine. Das Pferd wurde vor einem Monat mit Ivermectin entwurmt.
- Impfstatus: Alle Impfungen und Zahnbehandlungen sind auf dem neuesten Stand.
- Zahnärztliche Untersuchung: Seine Zähne wurden vor 6 Monaten geschliffen.
- Letzte Mahlzeit: Es hat gestern Abend gefüttert, aber nicht alles aufgefressen.
- Kot im Stall: Ich habe heute Morgen keinen Kot im Stall gesehen.

[Gatekeeping-Anweisung zur körperlichen Untersuchung]
Nun müssen die Studierenden dich fragen, welche Parameter der körperlichen Untersuchung sie wissen möchten.
Du stellst ihnen nicht die vollständige Liste der körperlichen Untersuchung und der Vitalwerte zur Verfügung.
Du solltest sie einzeln fragen und du musst ihnen die Informationen einzeln geben.
Wenn die Studierenden weitere Fragen zur körperlichen Untersuchung und zu den Vitalparametern oder zu anderen Themen stellen, die nichts mit dem Fall zu tun haben, antworte mit dem Standard-Umleitungssatz (exakt).

[Körperliche Untersuchung und Vitalparameter – nur einzeln auf Nachfrage]
- Verhalten: Depressiv und Anzeichen mäßiger Schmerzen.
- Schleimhäute: Rosa, aber leicht klebrig; Kapillarfüllungszeit (CRT) beträgt 3 Sekunden.
- Herzfrequenz: 60 Schläge pro Minute (erhöht).
- Atemfrequenz: 20 Atemzüge pro Minute.
- Temperatur: 37,8 °C (innerhalb der Norm).
- Auskultation des Abdomens: Verminderte Darmgeräusche im rechten unteren Quadranten; keine Geräusche im linken oberen Quadranten.
- Abdominale Distension: Leicht bis mäßig.

```
- Rektale Untersuchung: Bei der Palpation ist eine
  feste Masse in röhrenförmiger Form zu ertasten.

[Trigger-Frage nach Erfassung der oben genannten
  körperlichen Untersuchungen/Vitalparameter]
„Welche Diagnosemöglichkeiten würden Sie auf der
  Grundlage der von uns gesammelten Informationen
  in Betracht ziehen, um seine Erkrankung zu
  diagnostizieren?"

[Leitplanke bei falschen/irrelevanten Vorschlägen
  (exakt)]
„Das ist ein interessanter Ansatz, aber in diesem
  Fall benötigt Thunder möglicherweise einen
  anderen Ansatz."

[Diagnosetechniken und Befunde - nach der
  Diagnose-Frage mitteilen]
- Nasogastrale Intubation:
  Es wurden etwa 10 Liter Refluxflüssigkeit
    gewonnen, was auf eine Magenausdehnung und eine
    mögliche Beteiligung des Dünndarms hindeutet.
- Ultraschall:
  Die Befunde umfassen eine mäßige Dehnung des
    Dünndarms mit erhöhter Wanddicke (5 mm), was
    auf einen Ileus oder eine mögliche
    strangulierende Obstruktion hindeutet.
- Abdominocentese:
  Die Peritonealflüssigkeit ist leicht trüb mit
    einer Gesamtproteinkonzentration von 35 g/l,
    was auf einen leichten Entzündungsprozess
    hindeutet.
- Blutuntersuchung:
  Es wurde eine leichte Dehydrierung mit einem
    Hämatokritwert von 45 % festgestellt.
  Erhöhte Laktatwerte von 4 mmol/l deuten auf eine
    Beeinträchtigung der Durchblutung hin,
    möglicherweise aufgrund einer strangulierenden
    Läsion.

[Trigger-Frage nach Sammlung aller
  Diagnostik-Infos]
```

„Welche Behandlungsoptionen würden Sie auf der Grundlage der gesammelten Informationen in Betracht ziehen, um seinen Zustand zu behandeln?"

[Musterantwort für den Behandlungsplan (für Feedback)]
** Behandlungsplan **
Erstversorgung:
- Analgesie: Verabreichung von Flunixin-Meglumin (1,1 mg/kg i.v.) zur Schmerzbekämpfung.
- Flüssigkeitstherapie: Es wurde mit der intravenösen Verabreichung von Flüssigkeit (Laktat-Ringer-Lösung) begonnen, um die Dehydrierung und den Elektrolytungleichgewicht auszugleichen.
- Magenentlastung: Fortsetzung der regelmäßigen nasogastralen Intubation zur Linderung der Magenüberdehnung.

Weitere Maßnahmen:
- Buscopan (Hyoscinbutylbromid): Verabreichung zur Verringerung von Darmkrämpfen und zur Verbesserung der Motilität.
- Enterale Flüssigkeiten: Magnesiumsulfat über eine Magensonde zur Unterstützung der Auflösung der Verstopfung, falls innerhalb von 12 Stunden keine Besserung eintritt.

Überwachung:
- Das Pferd wurde engmaschig auf Veränderungen der Herzfrequenz, Bauchblähungen und Schmerzlevel überwacht.
- Es wurden serielle Laktatmessungen geplant, um den Perfusionsstatus zu beurteilen.

[Leitplanke bei falschen/irrelevanten Vorschlägen für den medizinischen Plan (exakt)]
„Das ist ein interessanter Ansatz, aber in diesem Fall benötigt Thunder möglicherweise eine sofortige Intervention. Wie wäre es mit Behandlungen, die direkt auf seine Magen-Darm-Probleme abzielen?"

[Fixer Trigger-Satz der Studierenden → fixe Antwort (nur dieser Satz)]

```
Wenn der/die Studierende sagt:
„Können Sie mich über den Fortschritt des Pferdes
  auf dem Laufenden halten?"
antwortest du nur mit:
„Das Pferd leidet weiterhin unter ständigem Reflux,
  die Herzfrequenz ist immer noch sehr erhöht (60
  Schläge pro Minute), die Ultraschalluntersuchung
  des Abdomens zeigt Folgendes: (Bild zeigen)"

[Erwarteter zusätzlicher Behandlungsplan inkl.
  Chirurgie - Musterantwort]
** 1. ** Chirurgische Überlegungen:
Aufgrund des Vorliegens von Reflux, abnormaler
  Ultraschallbefunde und anhaltender Schmerzen
  trotz medizinischer Behandlung wird eine
  Operation in Betracht gezogen. Es wird eine
  explorative Laparotomie durchgeführt, um
  strangulierende Läsionen zu beurteilen und zu
  korrigieren.

[Abschluss - Reflexion (exakt)]
„Sie haben einen soliden Plan erstellt. Können Sie
  bitte erläutern, warum Sie diese spezifischen
  Behandlungen für Thunders Zustand gewählt haben?
  Welche Differentialdiagnosen haben Sie im Sinn?
  Das Reflektieren Ihrer Überlegungen wird Ihnen
  helfen, Ihr Verständnis zu festigen."
```

C Umsetzung: Rollenspiele und Simulationen mit generativer KI in der Lehre

Vorbemerkung

In diesem Abschnitt wird eine bestimmte Art der Umsetzung im Detail besprochen: Optionen, wie man Rollenspiele und Simulationen gestalten kann. Dabei geht es vor allem um Beispiele und Empfehlungen zur Umsetzung.

C.1 Was bringen Rollenspiele und Simulationen? Didaktische Mechanismen und Lernziele

Was ist der Mehrwert von Rollenspielen und Simulationen (R&S) mit generativer künstlicher Intelligenz? Worauf muss man achten und womit anfangen? In diesem Beitrag sollen Ziele und Möglichkeiten dieser neuen didaktischen Toolbox besprochen werden. Dabei arbeiten wir uns von allgemeinen Lernzielen zu konkreten technischen Möglichkeiten, Warnungen und Umsetzungsempfehlungen vor.

Was hilft uns beim Lernen? Besonders effektive Lernmethoden und hohe Motivation gehören zu den wichtigsten Einflüssen (Dunlosky et al., 2013; Hattie, 2023). Aber natürlich verlagert das die Frage nur – was ist denn besonders effektiv, und was steigert die Lernmotivation?

Zunächst aber zu den erhofften didaktischen Vorteilen von interaktiven Rollenspielen und Simulationen. Diese lassen sich grob in die Bereiche Retention und Motivation einteilen.

C.1.1 Besser behalten

Die Retention von Wissen hängt wesentlich davon ab, wie Informationen verarbeitet und im Gedächtnis verankert werden. Rollenspiele und Simulationen wirken hier über mehrere ineinandergreifende Mechanismen. Erstens fördern sie das **abrufbasierte Lernen**: Wiederholtes Erinnern und Anwenden ("practice testing") stärkt die Gedächtnisspuren deutlicher als passives Wiederholen; unmittelbares Feedback in simulierten Situationen fungiert dabei als Praxistest und steigert die langfristige Behaltensleistung, insbesondere wenn der Abruf unter wechselnden Bedingungen erfolgt (R. A. Bjork, 1994; Roediger & Karpicke, 2006). Der Transfer profitiert, wenn die Lernsituation die spätere Anwendung abbildet – ganz im Sinne des Prinzips "Practice like you play, and you will play like you practice". Dabei sollten Lernende sowohl wiederkehrende Muster (z. B. typische Teamprobleme oder Krankheitsbilder) als auch Variation durch unterschiedliche Problemtypen erfahren; bewusstes Üben mit gezielter Rückmeldung bildet die Grundlage fortschreitender Expertise (Brown et al., 2014, S.57–58; Ericsson et al., 1993).

Zweitens erleichtern **Chunking und narratives Einbetten** den Zugriff auf komplexes Wissen: Das Gehirn organisiert Informationen in zusammenhängende Einheiten, und erzählerische Strukturen mit klaren Akteuren und emotionaler Bedeutung verbessern die Abrufbarkeit. Eine Chirurgin muss entscheiden, wie sie unter Zeitdruck die Kugel aus dem Gehirn eines Patienten entfernen soll. Solch eine exemplarische Szene für die Bedeutung von Erfahrungswissen (Brown et al., 2014, S.26–27) erhöht die Wahrscheinlichkeit dauerhafter Speicherung (Gobet et al., 2001; Willingham, 2021).

Drittens ermöglicht generative KI **individuelle Anpassung**: Szenarien können an Vorwissen und Kompetenzstand angepasst, Anforderungen fein justiert und Gruppenarbeit trotz heterogener Niveaus effizient betreut werden – ein Hebel, um besonders wirksame aktive und kollaborative Lernformen zuverlässig umzusetzen (Dunlosky et al., 2013; E. R. Mollick & Mollick, 2024).

Viertens unterstützen **Spacing und Interleaving** die Konsolidierung: Diese Form von zeitlich verteiltem Üben sowie das Mischen verschiedener Problemtypen fördern flexible Wissensanwendung und reduzieren die Illusion von Kompetenz. Rollenspiele bieten hierfür ideale Bedingungen, weil sie Inhalte in verschiedenen Szenarien und Abständen wiederkehren

lassen (Brown et al., 2014, S.51–52; Dunlosky et al., 2013; Murre & Dros, 2015; Roediger & Karpicke, 2006). Schließlich stärkt **reflektierende Eigenarbeit** die Gedächtnisbildung: Wenn Lernende Entscheidungen und Konzepte in der Simulation begründen – etwa indem sie die Handlungen einer KI-Figur hinterfragen und die zugrunde liegenden Prinzipien erläutern –, strukturieren sie ihr Wissen, identifizieren Lücken und vertiefen das Verständnis (Dunlosky et al., 2013; Ericsson et al., 1993; Wannemacher et al., 2025, Fall 031).

C.1.2 Motivieren

Ob Studierende lernen, hängt zentral (und ganz banal) auch davon ab, ob sie lernen **wollen**. KI-gestützte Rollenspiele können bedeutsame, herausfordernde und zugleich passgenaue Interaktionen schaffen, die Lernende aktiv einbeziehen und sofortige, personalisierte Rückmeldungen bereitstellen. Eine maßgeschneiderte Passung an Vorwissen reduziert irrelevante Inhalte, fokussiert individuell sinnvolle Herausforderungen und hält das Anspruchsniveau im **Flow-Bereich** – ein Arrangement, das intrinsische Motivation, Ausdauer und Behalten gleichermaßen stützt (Csikszentmihalyi, 2008).

Zugleich verlagern KI-Simulationen die Lernaktivität in Richtung Interaktion. Nach der **ICAP-Taxonomie** ist aktive Interaktion hoch motivierend und effektiv: interaktives Arbeiten (I) führt zu tieferen Lerngewinnen als konstruktives (C), aktives (A) oder passives (P) Verhalten; dialogische Auseinandersetzungen mit KI-Rollen, in denen Lernende Ideen gemeinsam erzeugen, prüfen und weiterentwickeln, begünstigen deshalb nicht nur das Verständnis, sondern auch das Motivationsniveau (Chi et al., 2018; Chi & Wylie, 2014).

Insgesamt verbinden gut gestaltete, KI-gestützte Simulationen insofern potentiell hohe kognitive Wirksamkeit mit motivationaler Qualität: Sie machen fachliche Herausforderungen greifbar, liefern unmittelbar verwertbares Feedback und geben Lernenden zugleich das Gefühl, wirksam handeln zu können – zentrale Bedingungen für nachhaltiges, transferfähiges Lernen. Ob dieses Potenzial eingelöst wird – gerade mit neuen technologischen Werkzeugen, wie der generativen künstlichen Intelligenz (GenAI), hängt natürlich von der konkreten Umsetzung ab. In den folgenden Abschnitten werden hierfür Beispiele analysiert und Empfehlungen abgeleitet.

C.2 Datengrundlage und Methodik

Ein Nebenziel dieses Beitrags ist es, publizierte Best Practices zusammenzustellen. Hier soll ein Überblick zu aktuellen Umsetzungen gegeben werden: Was probieren andere Hochschulen schon aus, in Bezug auf Rollenspiele und Simulationen mit KI?

Welcher Stand der Forschung wird hier mit welchem Vorgehen zusammengefasst? Auf Grund der rasanten Entwicklung der technischen Möglichkeiten wurde der Suchhorizont auf 2025 publizierte Studien eingeengt. Weiterhin wurde nur in einer Reihe von führenden akademischen Zeitschriften gesucht (s. Kapitel C.7), die sich speziell mit Hochschuldidaktik beschäftigen.

Die Suche wurde in Scopus mit der Software Publish or Perish (v. 8) durchgeführt. Eine Suche mit den Suchbegriffen "simulation" OR roleplay OR game AND GenAI OR LLM" ergab 160 Treffer, die durch Begrenzung auf Studien zu Rollenspielen und Simulationen mit KI in der Einzeldurchsicht von Titeln und Abstracts auf 16 Fachartikel verdichtet wurden, die in Tabelle C.2 aufgeführt sind. Eine Übersicht der neuen Studien findet sich in Kapitel C.8.

Vereinzelt wurden händisch besonders interessante Studien aus dem Vorjahr aus einer vorherigen Suche hinzugefügt (Barra et al., 2024; Huffman & Hutson, 2024; E. R. Mollick & Mollick, 2024) sowie ein Arbeitspapier des Hochschulforums Digitalisierung, das KI-Anwendungsbeispiele aufführt (Wannemacher et al., 2025). Ebenfalls händisch wurden eine Reihe von Studien zu Sprachsimulationen mit KI ergänzt, die in der sonstigen Literatur nicht explizit besprochen wurden (H. A. Nguyen, 2024; A. Nguyen et al., 2025; Vega et al., 2025).

Insofern decken die weiteren Ausführungen eine aktuelle, exemplarische, aber natürlich keineswegs umfassende Darstellung von besprochenen Effekten und Umsetzungsbeispielen ab. Neuere, nach Abschluss dieser Recherche erschienene Studien werden in Kapitel C.6 zusammengefasst.

C.3 Welchen Mehrwert bringt generative KI?

Generative KI in Rollenspielen entfaltet ihren besonderen Mehrwert dort, wo sie Rollen glaubwürdig übernimmt, Interaktionen situativ anpasst, schnell Varianten erzeugt, bereitgestellte Texte zuverlässig verdichtet und

didaktisch nutzbar aufbereitet, mehrstufige Reasoning-Prozesse übernimmt und Szenarien multimodal plastisch macht.

In diesem Abschnitt werden diese Facetten des potenziellen Mehrwerts der Technologie generative KI (GenAI) für Rollenspiele und Simulationen beleuchtet und mit Beispielen verdeutlicht. Was kann die Technologie schon gut und was noch nicht?

C.3.1 GenAI kann glaubwürdig Gesprächspartner simulieren

In Rollenspielen zeigt sich dieser Vorteil zunächst in der realistischen Rollenausübung: KI-Akteure verhalten sich in dialogischen Situationen hinreichend konsistent, um reale Druck- und Entscheidungslagen zu simulieren – etwa in Interview-Trainings, in denen LLM-gestützte Personas realitätsnahe Antworten geben und individuelles Feedback liefern (Nofal et al., 2025). Solche KI-Figuren werden durch Sprachschnittstellen noch überzeugender, weil prosodische Signale, Pausen und Emotionslagen mitschwingen; frühe Designstudien zum "Advanced Voice Mode" zeigen, wie Sprachdialoge die Immersion und damit die Lernwirksamkeit von Simulationen erhöhen (Barra et al., 2024).

Ein zentrales Einsatzfeld ist das Training professioneller Interviews. Nofal et al. (2025) entwickelten eine KI-gestützte Interviewsimulation, in der Studierende mit realistisch wirkenden, durch GPT-basierte Agenten gesteuerten Gesprächspartnern interagierten, um Interview-, Dokumentations- und Empathiefähigkeiten zu üben. Das Lernziel war die sichere, wiederholbare Praxis komplexer Gesprächssituationen (z. B. sensible Gesundheitsdaten, Demografie, Persönlichkeitsmerkmale) ohne Risiko für reale Betroffene. Technisch wurden LLM-Agenten mit Rollenprofilen, Leitfäden und Reflexionsaufgaben kombiniert; der Ablauf umfasste Vorgespräch, geführtes Interview, automatische Protokollanalyse und Nachbereitung. Berichtet wurden Zugewinne in Selbstwirksamkeit und Vorbereitung auf reale Interaktionen; statistisch signifikant war insbesondere die Steigerung des Selbstvertrauens im Führen von Interviews. Als Lehreffekt betonen die Autor:innen die Bedeutung klarer Interviewleitfäden, expliziter Ethik-Hinweise (z. B. Datenschutz) und strukturierter Reflexion nach der Simulation.

Ergänzend zeigen hochschulische Use-Cases aus dem deutschsprachigen Raum, dass glaubwürdige KI-Dialogpartner in Management-, Verhandlungs-

und Personaltrainings wirksam sind: In den Fällen "Talk2Transform" (Führung/Management), "TEAM with AI" (BWL-Verhandlung) und Gesprächssimulationen für Personalpsychologie agieren LLM-Avatare als Rollenpartner, die situativ Einwände einbringen und deeskalierende Strategien herausfordern. Das Lernziel ist die sichere Anwendung sozial-kommunikativer Kompetenzen unter Zeit- und Druckbedingungen; praktische Lehreffekte betreffen insbesondere die Skalierbarkeit von Übungsgelegenheiten sowie die Reduktion der Dozierendenlast durch automatisiertes, formatives Feedback (Wannemacher et al., 2025, Fälle 132/172/177).

Als weiteres Beispiel diskutieren Barra et al. (2024) das Potenzial von ChatGPTs "Advanced Voice Mode" für Simulatoren, u. a. in der medizinischen Ausbildung. Lernziel ist hier, Interaktionen mit Patienten zu üben. Dabei sollen authentische, spontane und multimodal (Stimme, Prosodie) glaubhafte Interaktionen ermöglicht werden, die über textbasierte Chats hinausgehen. Die Studie/Positionsarbeit skizziert Szenarien, in denen die KI als dynamische Patient:in agiert, situativ Emotion, Tempo und Sprechweise anpasst und damit realitätsnahe Stressoren einführt; zentrale Implikation ist, dass Voice-basierte KI-Gegenüber die Präsenz und situative Komplexität erhöhen können, zugleich aber qualitativ kuratiert werden müssen, um sachliche Fehler und inadäquate Affekte zu vermeiden (Barra et al., 2024).

C.3.2 GenAI kann die Interaktion dem Gesprächspartner anpassen (z.B. nach Vorwissen)

Deutlich wird der Mehrwert auch in der adaptiven Passung: In spielbasierten Lernumgebungen können LLMs aus Logdaten individuelle Handlungspläne generieren, die Studierende bei Zielsetzung und Strategieentwicklung anleiten; damit verschiebt sich Scaffolding von statischen Hinweisen zu situativ-passenden Planvorschlägen (Goslen et al., 2025). In kollaborativen Diskussionssettings verstärkt GenAI – sinnvoll gerahmt, etwa durch Six-Thinking-Hats – kognitive Präsenz und Ideengenerierung, wobei Effekte je nach Kreativitätsprofil variieren; das spricht für bewusste didaktische Orchestrierung statt "freier" Nutzung (Yu et al., 2025).

Für "goal play" sind adaptive Scaffolds entscheidend. LLM-basierte Plangenerierung unterstützt Lernende beim Setzen erreichbarer Zwischenziele und beim Auswählen nächster Schritte in offenen Spielwelten – eine Form

der metakognitiven Stützung, die Spiel-Flow und Lernfortschritt zugleich stabilisiert (Goslen et al., 2025). In kollaborativen Settings lässt sich diese Unterstützung durch Denkrahmen wie Six-Thinking-Hats bündeln; so steigt die kognitive Präsenz und die Qualität der Ideen, sofern Anleitung und Rollenklärung mitgeliefert werden (Yu et al., 2025).

Goslen et al. (2025) zeigen in einer Game-Based-Learning-Umgebung, wie ein LLM individuelle "Student Plans" generiert, die Aufgabenfolge, Hilfestufen und Reflexionsprompts an Vorwissen und Spielverlauf anpassen. Lernziel war, adaptive Scaffolds zu bieten, ohne den Spielfluss zu stören. Implementation: Das LLM analysiert Spieltelemetrie und kurze Lernstandseingaben und erzeugt dann maßgeschneiderte nächste Schritte (z. B. "erst Diagnose-Quest, dann kurzer Concept-Check, danach offener Anwendungsfall"). Ergebnisse weisen auf eine bessere Zielklarheit und nutzernahe Hilfedosierung hin; als Lesson Learned gilt, dass Transparenz über die Herkunft der Empfehlungen (Why-behind-the-hint) und Guardrails gegen Übersteuerung zentral sind (Goslen et al., 2025).

W.-S. Wang et al. (2025) integrieren ChatGPT-Feedback in eine VR-Lernumgebung (IoT-Aufgaben) und evaluieren das in einem RCT (n = 81). Lernziel waren höhere kognitive Niveaus (HOTS) und bessere Selbstregulation (SRL). Ablauf: Sechs VR-Units entlang Bloom-Stufen; Experimentalgruppe erhielt zeitnahe, auf Lernhandlungen bezogene GPT-Rückmeldungen (Zielsetzung, Strategiehinweise, Reflexionsprompts), die Kontrollgruppe konventionelles Feedback. Resultat: signifikant höhere Werte in Erinnern, Verstehen, Anwenden sowie verbesserte SRL-Indikatoren in der GPT-Gruppe; der Kreativitätsgewinn blieb begrenzt – eine Lehre ist, dass zu direktive KI-Hilfen offene Exploration dämpfen können (W.-S. Wang et al., 2025).

C.3.3 GenAI spricht Fremdsprachen fehlerfrei

Sprachlich eröffnen generative Modelle einen zusätzlichen Vektor: Sie ermöglichen gesprächsnahe, fehlerarme Kommunikation in der Zielsprache und reduzieren Sprechangst, was vor allem beim Einüben von Gesprächsroutinen hilft. Minimale Übersetzungsfehler verblassen für die meisten User vor der Gelegenheit, täglich auf Muttersprachenniveau die Fremdsprache üben zu können (ganz zu schweigen von den gesparten Reisekosten und -abgasen!). Systematische Übersichten berichten, dass

GenAI im Sprachunterricht als Feedback-Geber, Tutor und Gesprächspartner eingesetzt wird, während Einzelfallstudien Zugewinne in Selbstvertrauen und Sprechbereitschaft zeigen (Sangmin Lee et al., 2025; H. A. Nguyen, 2024; A. Nguyen et al., 2025).

In Sprachlern-Simulationen wird der Mehrwert besonders greifbar: Reviews ordnen GenAI als Gesprächspartner, Feedback-Geber und Tutor ein; Fallstudien berichten über mehr Sprechbereitschaft, geringere Angst und kurzfristig verbesserte Aussprache und Fluency, wenngleich Langzeitwirkungen und höhere Niveaus noch untererforscht sind (Sangmin Lee et al., 2025; H. A. Nguyen, 2024).

Eine systematische Übersichtsarbeit zeigt, dass GenAI-Tools im Sprachunterricht besonders für gesprochene Interaktion, Aussprache und situative Dialoge eingesetzt werden; wiederkehrende Befunde sind gesteigertes Sprechvolumen, mehr risikobereites Üben und unmittelbares Feedback – sofern Aufgaben gut gerahmt sind (Sangmin Lee et al., 2025).

Auf Kurs-/Studienlevel berichtete H. A. Nguyen (2024) über eine sprechenzentrierte Intervention mit KI-Assistenten: Lernziel war die Verbesserung der mündlichen Flüssigkeit und der Selbstsicherheit; der Ablauf kombinierte vorbereitete Prompts (z. B. Problemszenarien) mit Spontandialogen und anschließender Reflexion. Ergebnisse deuten auf Zugewinne in Sprechflüssigkeit und Reduktion von Sprechangst, gleichzeitig mahnt die Studie Qualitätssicherung der KI-Rückmeldungen an.

C.3.4 GenAI kann schnell Varianten von Situationen erstellen

Für die didaktische Konstruktion ist die Variantenproduktion zentral – auch damit es nicht schnell langweilig wird: Mit wenigen Prompt-Anpassungen entstehen Fallvarianten mit gesteuerter Schwierigkeit, alternativen Stakeholder-Positionen oder ungewöhnlichen Ereignisverläufen. Dieses "goal play" – zielgerichtete, auf Lernergebnisse hin entworfene Spiel- und Übungsformate – lässt sich in kurzen Sprintzyklen entwickeln und iterieren (E. R. Mollick et al., 2024; E. R. Mollick & Mollick, 2024).

Mollick und Kollegen demonstrieren mit "Simulated Practice at Scale" und dem Entrepreneurship-Simulator "PitchQuest", wie Multi-Agent-Setups in Sekunden neue, konsistente Pitch-Gegenspieler und Stakeholder-Konstellationen generieren. Lernziel ist adaptives Üben von Pitches unter

sich verändernden Bedingungen (z. B. unterschiedliche Investor:innen-Profile, Markt-Schocks). Ablauf: Rollenbesetzung durch Agenten (Mentor, Kunde, Investor), gestufte Aufgaben, sofortiges Feedback. Lessons Learned: Variantenvielfalt steigert Transfer, aber verlangt klare Bewertungsraster und Debriefings, um Lernziele stabil zu halten (E. R. Mollick et al., 2024).

Es werden grobe Ablaufkonzepte erstellt (Playbooks): Lehrende iterieren kleine, zielgerichtete Spiele und Rollenspiele in schnellen Schleifen, nutzen Variantenbildung, Agenten-Rollen und Prüf-Prompts zur Qualitätssicherung und skalieren gelungene Muster in die Breite (E. R. Mollick et al., 2024; E. R. Mollick & Mollick, 2024). Deutsche Hochschul-Praxisbeispiele bestätigen die Breite des Einsatzspektrums – von Management-Dialogtrainings ("Talk2Transform") bis zu Verhandlungssimulationen ("TEAM with AI") – und benennen zugleich Gelingensbedingungen wie Prompt-Design, Feedback-Regime und rechtliche Klärungen (Wannemacher et al., 2025).

Der Historiker Kindenberg (2025) simuliert Ereignisse aus der Zeit der französischen Revolution. Durch GenAI ließen sich hier mit relativ geringem Aufwand Ereignis-, Rollen- und Quellenvarianten erzeugen, die an Vorwissen und Lernziele gekoppelt sind. Lernziel ist Quellenkritik und Perspektivübernahme unter wechselnden Szenarioparametern. Umsetzung: Kuratierte Promptbausteine für Ereignis-Timing, Akteursziele und soziale Spannungen; Lehrende selektieren/feintunen Varianten vor dem Einsatz. Eine zentrale Lehre ist, dass ein didaktischer "Scaffold" (Aufgabenstruktur, Reflexionsfragen) nötig bleibt, um inhaltliche Tiefe trotz generativer Vielfalt zu sichern (Kindenberg, 2025).

C.3.5 GenAI kann zur Verfügung gestellte Texte i.d.R. gut wiedergeben

Wo Quellenmaterial vorliegt, liefert KI robuste Verdichtungen und strukturierte Wiedergaben, die unmittelbar in Szenarien überführt werden können.

Originalquellen erlebbar machen, kann Lernenden neue Zugänge eröffnen. Huffman & Hutson (2024) beschreiben "NotebookLM" als dokumentengebundenen Assistenten, der historische Primärquellen (Mary-Sibley-Tagebuch) in strukturierte Lernpfade und Audio-Dialoge überführt. Lernziel ist, Quellenverständnis und Kontextualisierung zu vertiefen, ohne den Originalbezug zu verlieren. Ablauf: Upload kuratierter Quellen,

Generierung von erklärenden Podcasts/Dialogscripten samt Quellen-Referenzierung; Lesson Learned: Grounding reduziert Halluzinationen deutlich, verlangt aber sorgfältige Quellenauswahl und Aufgaben, die Prüf- und Reflexionsphasen erzwingen (Huffman & Hutson, 2024).

Im naturwissenschaftlichen Kontext skizziert Choi (2025), wie GenAI Erdwissenschaftssimulationen mit fachlichen Texten "füttert", um Aufgaben, Messprotokolle und Deutungsdialoge zu erzeugen, die eng an bereitgestellten Materialien haften. Lernziel ist die Übersetzung von Fachtexten in handlungsnahe Simulationen. Die Studie betont, dass dokumentengebundenes Prompting didaktisch starke Ergebnisse liefern kann, wenn Qualitätskriterien (Aktualität, Autorität, fachliche Konsistenz) erfüllt und durch Reflexionsaufträge abgesichert werden.

C.3.6 GenAI kann in mehreren Schritten selbstständig agieren

Schließlich erleichtert KI mehrschrittiges "Nachdenken" (Reasoning) samt Selbstprüfung: In Spielumgebungen generieren Modelle nicht nur nächste Aktionen, sondern begründen Planalternativen und vergleichen sie mit Zielzuständen; das eröffnet neue Formen des reflektierten Übens, setzt aber didaktische Leitplanken gegen Scheinpräzision und Halluzination voraus (Goslen et al., 2025).

E. R. Mollick et al. (2024) berichten, dass mehrschrittige, agentenbasierte Orchestrierungen ("Goal Play") innerhalb von Simulationen Aufgaben wie Informationssuche, Rollenbriefings, Gegenargumente und Bewertungsfeedback autonom durchführen. Lernziel ist, komplexe, mehrzügige Entscheidungssituationen zu üben. Der Ablauf bindet Agenten mit komplementären Rollen (z. B. "Skeptical Investor", "Method Coach") ein; Lessons Learned: Agenten erhöhen Realismus und Dichte der Interaktionen, benötigen aber explizite Sicherheits- und Qualitätschecks (Rubrics, menschliche Supervision), um Fehlerketten zu verhindern (E. R. Mollick et al., 2024).

Goslen et al. (2025) zeigen die mehrschrittige Plan-Generierung für Lernpfade im Spiel: Das LLM analysiert Statusdaten, prüft Zwischenergebnisse gegen Zielkriterien und passt Such-/Lernstrategien an (z. B. "Erst Konzeptlücke schließen, dann Praxisquest"). Lernziel ist metakognitives Planen und effiziente Hilfe zur rechten Zeit. Die Autor:innen betonen, dass Erklärbarkeit ("warum dieser Schritt?") und Fail-Safes gegen falsche Pfade zentral für Akzeptanz und Wirksamkeit sind (Goslen et al., 2025).

C.3.7 GenAI kann Szenarien plastischer machen

Realistischere und mit verschiedenen Sinnen wahrnehmbare Szenarien helfen beim Behalten und motivieren. GenAI kann hier unterstützen, durch Generierung von Sprache (Voice, ElevenLabs), Bildern (Firefly), Videos (Sora), Dialogen (Podcasts, z.B. NotebookLM) und Musik (z.B. Suno). Diese Multimodalität wird von den Anbietern der Sprachmodelle aktuell stark ausgebaut. Sprachdialoge und paralinguistische Signale erhöhen Gegenwartsnähe und soziale Dichte von Gesprächen; generierte Audios oder Podcast-Dialoge verdichten Quellen zu hörbaren Szenen, dadurch wird es einfacher, greifbare, emotional anschlussfähige Erfahrungswelten in die Rollenspiele einzubauen (Barra et al., 2024; Huffman & Hutson, 2024; Nofal et al., 2025).

Barra et al. (2024) argumentieren, dass fortgeschrittene Voice-Fähigkeiten (Echtzeit-Prosodie, Unterbrechungen, Emotion) Simulatoren deutlich realistischer machen, insbesondere in kritischen Gesprächssettings wie der Medizin. Lernziel ist situatives Handeln unter Zeitdruck mit authentischem, emotionalem Gegenüber. Die Kernerkenntnis ist, dass multimodale Signale (Stimme, Timing, nonverbale Hinweise) die Präsenz erhöhen, zugleich aber technische/ethische Qualitätskontrollen benötigen (Barra et al., 2024).

A. Nguyen et al. (2025) zeigen, wie "embodied GenAI" in Mixed-Reality-Umgebungen Lernende mit verkörperten KI-Agenten interagieren lässt. Lernziel ist aktives Lernen durch körperlich-räumliche Einbettung plus dialogische KI-Unterstützung. Umsetzung: MR-Szenen mit KI-Avatar-Verhalten, das auf Handlungen, Position und Sprache der Lernenden reagiert; zentrale Lehre: Multimodalität erhöht Engagement und Handlungsvalidität, benötigt aber präzises Szenariodesign und instrumentierte Reflexionsphasen, damit Wahrnehmung und Konzeptverständnis zusammenfinden (A. Nguyen et al., 2025).

Über die Beispiele hinweg zeigt sich, dass GenAI-basierte Simulationen besonders dann wirksam sind, wenn sie (a) klare Lernziele, Rubrics und Reflexionsschritte verankern, (b) dokumenten- oder quellengebunden arbeiten, um Halluzinationen zu dämpfen, und (c) adaptive Scaffolds fein dosieren, damit Explorations- und Problemlöseanteile erhalten bleiben (Goslen et al., 2025; Huffman & Hutson, 2024; W.-S. Wang et al., 2025).

Eine exemplarische Übersicht von solchen Umsetzungen in verschiedenen Anwendungsbereichen zeigt Tabelle C.1.

Disziplin/Feld	Art der Simulation/des Rollenspiels	Wichtige Lernziele/entwickelte Fähigkeiten	Spezifische Beispiele für KI-Integration	Beispiel-Quelle
Gesundheitswesen	Notfallmaßnahmen, Patienteninteraktion	Schnelle Beurteilung, Entscheidungsfindung, multidisziplinäre Zusammenarbeit, klinisches Denken, Empathie, Kommunikation unter Druck	KI-generierte Patientenakten, Echtzeit-Veränderungen von Vitalzeichen, dynamische virtuelle Patienten; KI-Chatbot für interprofessionelle Teamsimulation (“Marie Parker”)	Wannemacher et al. (2025)
Pharmazie	Arzneimittelmanagement, Patientenberatung	Verordnung prüfen, Fehler erkennen, Aufklärung, Dosierung, Wechselwirkungen	KI-generierte Fallvarianten mit unterschiedlichen Komplexitäten; automatisiertes Feedback zu Dokumentation/Begründung	Lim et al. (2025)
Soziale Arbeit	Krisenmanagement, Familienunterstützung	Aktives Zuhören, Krisenintervention, interprofessionelle Zusammenarbeit, Umgang mit komplexen Familiendynamiken	KI-gestützte Gesprächs-/Interview-Simulationen mit sensiblen Klient*innenszenarien	Nofal et al. (2025)
Betriebswirtschaftslehre	Krisenmanagement, Entscheidungsfindung, VC-Pitching	Führung, Strategie unter Stress, Kommunikation, Datenanalyse, Lösungsbewertung	Mehragenten-Simulation “PitchQuest” (Mentor*innen, Rollenspieler*innen, Bewerter*innen)	E. R. Mollick et al. (2024)

Disziplin/Feld	Art der Simulation/des Rollenspiels	Wichtige Lernziele/entwickelte Fähigkeiten	Spezifische Beispiele für KI-Integration	Beispiel-Quelle
Soft-Skills-Training	Kundenservice, Verkauf, Manager-Coaching, Konfliktlösung, Interviews, Verhandlungen	Kommunikationsmuster, Konfliktlösung, Emotionsregulation, strategisches Denken, Professionalität, Debatte	Adaptive Dialoge, Echtzeit-Feedback, anpassbare Avatare; z. B. "Talk2Transform", Gesprächssimulationen in der Personalpsychologie	Wannemacher et al. (2025, Fälle 132, 177)
Bildung (Lehrerausbildung)	Classroom-Management, Verhalten von Studierenden	Umgang mit Störungen, Entscheidungen im Unterricht, Differenzierung, Notfalllagen	KI-generierte Klassenzimmer-Szenarien; embodied GenAI in Mixed Reality mit virtuellen Studierenden	A. Nguyen et al. (2025)
Sprachenlernen	Wortschatz, Grammatik, Aussprache, interkulturelle Kommunikation	Sprachliche Genauigkeit, Flüssigkeit, kultureller Kontext, reale Interaktion	KI-gestützte Echtzeit-Korrektur, mehrsprachige Materialien, wiederholbare Rollenspiele (z. B. Chatbots/LLMs)	Sangmin Lee et al. (2025)
Kreativer Ausdruck	Kunst, Musik, Literatur, Problemlösen	Ideengenerierung, Überwinden kreativer Blockaden, Originalwerke, Datenanalyse, strategische Bewertung	Dokumentbasierte KI (NotebookLM) erzeugt Podcasts/Guides aus Quellen; KI-gestützte Story-/Dialogerstellung	Huffman & Hutson (2024)

Tabelle C.1. Anwendungsbeispiele für KI-Rollenspiele und Simulationen

Die hier skizzierten Potenziale gehen mit einer Reihe von Risiken und Nebenwirkungen einher, die bedacht werden müssen. Zentrale Punkte besprechen wir im folgenden Abschnitt.

C.4 Was geht nicht? Herausforderungen und Grenzen von GenAI

Generative KI in der Bildung birgt neben ihren Stärken auch spezifische Herausforderungen, die durch gezielte didaktische Strategien angegangen werden können.

A. Delegation des Denkprozesses: Die Nutzung von KI-Tools kann dazu führen, dass Studierende die kognitive Anstrengung des Lernens an die KI delegieren. Dies kann ein tieferes Verständnis der Materie verhindern (Dell'Acqua et al., 2023; H.-P. H. Lee et al., 2025).

Lehrende sollten eine didaktische Rahmung ("Human in the Loop") schaffen, die Studierende explizit dazu anleitet, die KI-Ausgaben kritisch zu reflektieren, anstatt sie blind zu übernehmen. Dies kann durch die Gestaltung von Prüfungsformaten erfolgen, die die kritische Auseinandersetzung mit KI-Tools erfordern und nicht die reine Wissenswiedergabe (Corbin et al., 2025). Lehrpersonen sollten als Experten für die didaktische Einbindung agieren, die den Lernprozess steuern (Tutton & Cohen, 2025).

B1. Halluzinationen: Generative KI-Modelle können Fehler machen oder falsche Informationen, sogenannte "Halluzinationen", generieren, die zu fehlerhaften Lernerfahrungen führen können (E. R. Mollick & Mollick, 2024).

Studierende müssen über die Risiken von Halluzinationen aufgeklärt werden. Es ist entscheidend, ihnen beizubringen, die von der KI generierten Informationen immer mit vertrauenswürdigen Quellen abzugleichen. Die Integration der KI in den Lernprozess sollte so erfolgen, dass die KI nicht als alleinige Wissensquelle, sondern als Partner im Lernprozess gesehen wird (Moon et al., 2025).

B2. Selbstbewusste Falschaussagen: KI-Modelle können falsche Informationen sehr selbstbewusst und gut artikuliert präsentieren. Studierende mit geringem Vorwissen können dies nur schwer als Fehler erkennen (E. R. Mollick & Mollick, 2024).

Um der überzeugenden Darstellung falscher Informationen entgegenzuwirken, sollte der Fokus auf der Entwicklung kritischer Medienkompetenz liegen. Lehrpersonen können bewusst Szenarien einbauen, in denen die KI absichtlich falsche Informationen liefert, damit die Studierenden lernen, diese zu identifizieren.

C. Variable Outputs: Die Ergebnisse von generativer KI werden stochastisch, nicht deterministisch produziert. Bei identischen Eingaben kann der Output variieren (Wolfram, 2023), was die Reproduzierbarkeit und Kontrolle von Lernerfahrungen erschwert (E. R. Mollick & Mollick, 2024).

Die stochastische Natur der KI kann in Lehr- und Lernkontexten als Feature genutzt werden, nicht als Bug. Die Variation der Antworten kann Studierende dazu anhalten, flexibel zu denken und sich nicht auf eine einzige "richtige" Antwort zu verlassen.

D. Mangelnde Erklärbarkeit: KI-Modelle können ihre Erklärungen oder Ergebnisse oft nicht verlässlich begründen, was in Lehrkontexten, die ein tiefes Verständnis der zugrunde liegenden Konzepte erfordern, einen Nachteil darstellt (E. R. Mollick & Mollick, 2024).

Lehrende können die Rolle des "Debriefers" übernehmen, um die KI-gestützten Szenarien im Nachhinein zu analysieren. Sie können die Studierenden dazu anleiten, zu erklären, wie sie zu ihren Entscheidungen gelangt sind, und diese mit den Antworten der KI vergleichen, um das zugrundeliegende Konzept zu verinnerlichen (E. R. Mollick & Mollick, 2024).

E. Reproduktion von Bias: KI-Modelle, die auf riesigen Datensätzen trainiert werden, können Vorurteile und Verzerrungen aus diesen Daten reproduzieren. Ohne eine kritische Auseinandersetzung können diese unreflektiert übernommen werden (Bender et al., 2021).

Lehrende sollten die Studierenden auf die potenziellen Vorurteile und Verzerrungen in den Trainingsdaten der KI hinweisen. Es ist ratsam, Prompts so zu gestalten, dass sie eine breite Perspektive einfordern. Im Debriefing sollten die ethischen Implikationen des Bias kritisch beleuchtet werden.

C.5 Wie umsetzen? Empfehlungen für KI-gestützte Rollenspiele

C.5.1 Gestufter Einstieg

Für einen pragmatischen Einstieg empfiehlt sich zunächst ein **leichtgewichtiger Modus**: vorbereitete, klar gerahmte Chat-Interaktionen mit Rollenprompts und definierter Zielstruktur. Diese Form nutzt die Stärken von GenAI – dialogische Motivation, unmittelbares Feedback und schnelle Variantenbildung – ohne großen Mehraufwand in Technik oder Betreuung. Didaktisch bewährt sind kurze, fokussierte Fälle mit expliziten Lernzielen, Reflexionsfragen und einer einfachen Verifikationsroutine (z. B. "nenne zwei Quellen oder Gegenargumente"), damit Interaktion nicht an kritischem Denken vorbeiführt (E. R. Mollick & Mollick, 2024).

Im nächsten Schritt sollten Studierende **in Präsenz kleine Rollenspiele selbst entwerfen und testen**. Das fördert Prompt- und Rollenkompetenz, macht Modellgrenzen sichtbar und verlagert Verantwortung in die Lerngruppe. Lehrende agieren als Coach und Helfer: Sie stellen Zielkriterien, Rollenbriefe, Feedback-Raster und einfache "Challenge Cards" bereit, mit denen Gruppen ihre Szenarien iterativ verschärfen. Am Ende stehen strukturierte Debriefs mit Evidenzcheck (Wannemacher et al., 2025; Yu et al., 2025).

Im fortgeschrittenen Stadium entwickeln die Studierenden in **mehrwöchiger Einzel- oder Gruppenarbeit selbst Rollenspiele**. Sie übernehmen selbstverantwortlich und mit Anleitung die Recherche-, Entwicklungs- und Testarbeit komplexerer, realitätsnaher Rollenspiele. Hier kombinieren Teams agentenbasierte Recherche-Workflows (mehrstufige Promptketten mit Quellenprüfung), adaptives "goal play" mit Plan-/Hint-Mechaniken und Voice- bzw. VR-Interfaces für immersives Training. Wichtig sind belastbare Testprotokolle mit Störfall-Checks (Halluzination, Bias, Inkonsistenz), definierte Abbruch- und Korrekturpfade sowie dokumentierte Prompt- und Bewertungsänderungen über mehrere Iterationen. Solche Studios verbinden fachliches Urteilen, Methodenkompetenz und KI-Literacy – und sie erzeugen wiederverwendbare Lehrbausteine, die in weiteren Kohorten skaliert werden können (Goslen et al., 2025; E. R. Mollick et al., 2024; Nofal et al., 2025).

In Summe empfiehlt sich insofern ein gestaffelter Ausbau: klein starten, gemeinsam professionalisieren, komplexe Formate mit Studierenden gemeinsam entwickeln – begleitet von Reflexion, Quellen-Verifikation und klaren ethischen Leitplanken. So werden Rollenspiele und Simulationen nicht nur motivierender, sondern auch wirksamer in Hinblick auf Retention, Transfer und professionelle Handlungssicherheit.

C.5.2 Strukturierte Gestaltung

Welche Empfehlungen zur Gestaltung können wir aus Vorstudien ableiten, in denen komplexe Agenten und Rollenspiel-Szenarios entwickelt wurden?

Ein komplexes Rollenspiel beginnt mit **präzisen Lernzielen und einer interaktiven Klärung des Vorwissens**. Für die Vorbereitung bietet sich ein kurzes KI-Tutoring an, das aktivierende Aufgaben, kognitive Entlastung, Wachstumsorientierung, explizite Schritt-für-Schritt-Scaffolds, zeitnahes Feedback und Selbsttaktung kombiniert – so erreichen alle Teilnehmenden ein vergleichbares Einstiegsniveau und die Präsenzzeit kann für höherstufige Praxis genutzt werden (Kestin et al., 2025). Alternativ können Lernvideos genutzt werden, um einen gemeinsamen Wissensstand der Gruppe zum Beginn der Interaktion zu erreichen (E. R. Mollick et al., 2024).

Das eigentliche Rollenspiel folgt einem **klaren, wiederholbaren Ablauf**: Zuerst begrüßt ein KI-Mentor die Lernenden, erhebt kurz Erfahrung und Kontext und passt die Schwierigkeit an. Dann bietet die KI mehrere, zur Zielkompetenz passende Szenarien zur Auswahl und setzt narrativ die Bühne mit Rollen, Zielen und relevanten Konflikten. Die Durchführung erfolgt in klar abgegrenzten Zügen; die KI reagiert adaptiv, gibt sparsame Hinweise und drängt spätestens gegen Ende auf eine folgenschwere Entscheidung, damit Transferstrategien wirklich angewandt werden. Zum Schluss liefert die KI differenziertes, zielbezogenes Feedback mit Stärken, Entwicklungsfeldern und Hinweisen zur Anwendung im nächsten Fall. Dieses Muster lässt sich für "Role Play" (Lernende spielen eine fremde Rolle) ebenso nutzen wie für "Goal Play" (Lernende bleiben sie selbst und leiten eine Figur an, z. B. mit einem Entscheidungs- oder Zielsetzungs-Framework). Wichtig sind eine abschließende Reflektion in der Gruppe und die Anbindung an Kurskonzepte (E. R. Mollick & Mollick, 2024).

Für komplexere Settings empfiehlt sich ein **Agenten-Design mit klar getrennten Aufgaben**: Ein Mentor-Agent berät und aktiviert Vorwissen, ein weiterer Non-Player-Character (NPC) Agent spielt etwa die Gegenrolle (mit konsistenter Persona und interner Planungs- und Abschlusslogik), ein Evaluator-Agent verdichtet Leistungsdaten zu handlungsnahem Feedback, und instruktorgebundene "Progress/Insights-Agents" fassen Transkripte zu individuellen und Klassenmustern zusammen und schlagen Debrief-Aktivitäten vor. Dieses mehrstufige "Learning-Loop"-Design – Instruktion, narrative Praxis, Feedback, Reflexion – senkt die Entwicklungshürden und skaliert Übung, bleibt aber didaktisch geführt (E. R. Mollick et al., 2024).[1]

Qualitätssicherung und systematische Tests müssen zwingend erfolgen. Testläufe prüfen Konsistenz, Schrittfolge, Robustheit gegenüber "Edge Cases", Niveaudifferenzierung, Output-Qualität und Agenten-Handovers; bei Problemen helfen zusätzliche Kontexte, Beispiele, Constraints, Erinnerungen an Ziele und, wo nötig, engere Interaktionslimits. Zudem sollten bekannte Modellrisiken – Bias, Narrativdrift, Vergessen früherer Passagen – durch Red-Teaming, präzise Rollenprompts, interne Checklisten und ein konsequentes Debrief adressiert werden (E. R. Mollick et al., 2024).

Schließlich lohnt der Rückgriff auf **Tutoring-Prinzipien** auch im Rollenspiel: Aktivierung statt Lösungsvorsage, graduelle Schrittführung ohne Überlastung, zeitnahes, zielgerichtetes Feedback und Selbsttaktung erhöhen Lerngewinne nachweislich; in der Studie von Kestin et al. lernten Studierende mit einem gut designten KI-Tutor mehr als doppelt so viel wie in einer aktiven Präsenzsitzung – ein Befund, der für die Vorbereitungs- und Zwischenphasen von komplexen Simulationen besonders relevant ist (Kestin et al., 2025).

C.5.3 Zum schnellen Start: Gute Prompts, Informationsquellen und zusammenfassende Übersicht

- Eine große Anzahl an sehr guten **didaktischen Prompts vom Team der Wharton Business School** findet sich hier: https://www.moreusefulthings.com/prompts. Hervorzuheben sind v.a. die "Blueprints", also

[1] Ähnliche verteilte Rollen werden aktuell etwa auch für Forschungsprozesse von Google entwickelt (Gottweis et al., 2025).

Vorlagen, die für die eigene Lehre angepasst werden können (s.u. für zwei Beispiele).

- Die **Universität Harvard** gibt hier eine Reihe von Beispielen, wie GenAI in der Lehre genutzt wird, u.a. mit Beispielen für Simulationen, Sprachdidaktik u.v.m.: https://bokcenter.harvard.edu/examples-and-ideas-for-using-AI-for-your-teaching.
- Etwas breiter – wie nutzen 76.000 Lehrende KI an Hochschulen? Die KI-Firma **Anthropic** hat einen Bericht herausgebracht, der anonymisiert basierend auf echten Interaktionen betrachtet, wie KI in der Lehre genutzt wird: https://www.anthropic.com/news/anthropic-education-report-how-educators-use-claude (Bent et al., 2025). Im Kontext von Rollenspielen ist hier interessant, wie die Online-Interaktionen des GPT-Konkurrenten genutzt werden ("Claude Artifacts"), speziell für "Interactive Educational Games".
- **Fortbildungen und Übersichten mit Anwendungsfokus**: Sowohl Google als auch Anthropic (Claude) und OpenAI bieten Kurse für die technischen Aspekte der Nutzung von KI in der Lehre an: https://grow.google/ai-for-educators/, https://anthropic.skilljar.com/ai-fluency-framework-foundations.
- **Beispiele für Lehrende**: Hier finden Sie eine Übersicht von OpenAI speziell für University Educators: https://edunewsletter.openai.com/, hier z.B. eine kleine Konversationsübung: https://edunewsletter.openai.com/p/ai-as-a-conversation-partner-and.

Abschließend fassen zwei Übersichten die praktischen Empfehlungen für Rollenspiele und zielgerichtete Spiele zusammen.

Rollenspiele / Role Play

Ziel: Lernende übernehmen eine fremde Rolle (z. B. Verhandler, Gründer) und wenden erlernte Strategien an.
Beispiel-Prompt: "Negotiation Simulator": https://www.moreusefulthings.com/student-exercises (L. Mollick & Mollick, 2024)
Empfohlene Komponenten:

- **Einführung durch einen AI-Mentor**: Der KI-Mentor fragt nach Vorerfahrungen der Lernenden, um das Szenario individuell anzupassen.
- **Szenarienauswahl**: Die KI bietet mehrere Szenarien zur Auswahl, basierend auf den Angaben der Lernenden.

- **Narrative Gestaltung**: Die KI beschreibt die Umgebung, Ziele und Herausforderungen. Die Lernenden interagieren mit der KI, die als Gegenpart agiert.
- **Interaktive Durchführung**: Die KI reagiert auf die Eingaben der Lernenden, gibt Hinweise und fordert Entscheidungen.
- **Feedback**: Nach Abschluss gibt die KI differenziertes Feedback (Stärken, Verbesserungsmöglichkeiten, Anwendungshinweise).

Didaktischer Nutzen: Förderung von Perspektivwechsel, Anwendung von Strategien, Reflexion über eigenes Verhalten.

Goal-Play-Simulationen

Ziel: Lernende bleiben in ihrer eigenen Rolle und helfen einer fiktiven Figur, ein Problem zu lösen (z. B. Zielsetzung, Selbstreflexion).
Beispiel-Prompt: "Goal Play: Help a character achieve goals": https://www.moreusefulthings.com/student-exercises (L. Mollick & Mollick, 2024)
Empfohlene Komponenten:

- **Dualrolle der KI**: Die KI agiert sowohl als Mentor als auch als Figur im Szenario.
- **Szenarienauswahl**: Lernende wählen aus verschiedenen Figuren oder Situationen.
- **Narrative Einführung**: Die KI stellt die Szene dar, ohne zu überfrachten, damit der Fokus auf dem Lernziel bleibt.
- **Interaktive Phase**: Die Lernenden wenden Frameworks an (z. B. SMART-Ziele, Selbst-Distanzierung nach Kross & Ayduk (2017)).
- **Abschluss und Feedback**: Die KI reflektiert mit den Lernenden über deren Vorgehen und gibt Hinweise zur Verbesserung.

Didaktischer Nutzen: Anwendung theoretischer Konzepte in neuen Kontexten, Förderung von Transfer und Perspektivübernahme.

C.6 Update: Neuere Studien (Stand Juli 2026)

Seit Abschluss der ursprünglichen Literaturrecherche (Suchhorizont: 2025 publizierte Studien, s. Kapitel C.7) sind weitere einschlägige Arbeiten erschienen. Dieser Abschnitt fasst sechs neuere Studien zusammen, die in einem laufenden wöchentlichen Literatur-Scan identifiziert wurden. Drei der Arbeiten (Chang et al., 2026; Perczel et al., 2025; Wilhelm et al., 2025) sind bislang nur als Preprints verfügbar und noch nicht begutachtet.

Wilhelm et al. (2025) entwickeln mit "CommCoach" ein konversationelles Rollenspiel-System, mit dem Führungskräfte schwierige Arbeitsplatzgespräche üben – etwa Leistungsfeedback oder Konfliktklärung. Die Studie untersucht, wovon Vertrauen, wahrgenommener Realismus und die Bereitschaft abhängen, das Geübte tatsächlich anzuwenden. Damit erweitert sie die in Kapitel C.3.1 besprochenen Interview- und Verhandlungstrainings um die Führungskommunikation und rückt eine Gestaltungsgröße in den Mittelpunkt, die dort bislang implizit blieb: Nicht allein die technische Qualität der Simulation, sondern der von den Lernenden wahrgenommene Realismus entscheidet über die Transferbereitschaft (Wilhelm et al., 2025).

Dang & et al. (2025) untersuchen kollaboratives Lernen von Studierenden mit KI-Agenten in Mixed-Reality-Umgebungen und analysieren dabei kognitive und sozio-emotionale Interaktionen. Die Studie ergänzt die in Kapitel C.3.7 diskutierte Arbeit von A. Nguyen et al. (2025): Verkörperte KI-Gegenüber wirken nicht nur über kognitive, sondern auch über sozio-emotionale Kanäle – ein Befund, der für die Gestaltung immersiver Rollenspiele unmittelbar relevant ist (Dang & et al., 2025).

Perczel et al. (2025) stellen mit "TeachLM" ein Sprachmodell vor, das auf 100.000 Stunden authentischer Eins-zu-eins-Tutoring-Dialoge nachtrainiert wurde. Für Rollenspiele besonders interessant ist ein Nebenprodukt: ein aus denselben Daten gewonnenes, realistisches simuliertes Studierendenmodell, mit dem sich Tutor- und Rollenspiel-Systeme in synthetischen Dialogen testen lassen, bevor echte Lernende mit ihnen interagieren. Das Nachtraining verdoppelte den Redeanteil der Lernenden, erhöhte die Zahl der Dialogzüge um die Hälfte und verbesserte Fragestil und Personalisierung. Für die in Kapitel C.5.2 geforderte Qualitätssicherung liefert das einen neuen Baustein: Testläufe müssen nicht mehr allein von Lehrenden durchgespielt werden, sondern lassen sich mit simulierten Studierenden skalieren (Perczel et al., 2025).

Yusuf et al. (2026) entwickeln mit "AIvaluate" einen emotional-intelligenten pädagogischen Gesprächsagenten für performanzbasierte Prüfungen und untersuchen dessen Wirkung auf Prüfungsangst und Studierendenerleben. Die Arbeit schlägt die Brücke von der Übungssimulation zur Prüfungssituation: Dieselben Eigenschaften, die KI-Gegenüber im Training glaubwürdig machen, verändern in Prüfungskontexten das emotionale Erleben der Studierenden – ein Aspekt, der bei der Übernahme von Rollenspiel-Formaten in Assessments bedacht werden sollte (Yusuf et al., 2026).

Chang et al. (2026) zeigen in einem Feldexperiment, dass sich die Lehrstrategie eines KI-Tutors adaptiv steuern lässt. Aus rohen Tutoring-Transkripten extrahierten sie 14 pädagogische Merkmale (z. B. Scaffolding, Verständnisstand), trainierten damit zunächst in einer Simulationsumgebung ein Modell, das situativ zwischen 20 pädagogischen Prompts wechselt, und erprobten es anschließend im A/B-Test mit 656 Gesprächen von 359 Schüler:innen. Der adaptive Ansatz übertraf zwei statische Vergleichssysteme und verkürzte Interaktionen um rund drei Züge bei gehaltener pädagogischer Qualität; eine stochastische Strategiewahl hob zudem die Übungs-Conversion von 19,6 auf 28,1 Prozent. Daraus folgen zwei Lehren für Rollenspiele: Adaptive Hinweisdosierung (vgl. Kapitel C.3.2) lässt sich datengestützt lernen, statt manuell verdrahtet zu werden – und etwas Zufall in der Strategiewahl schlägt starre Optimierung (Chang et al., 2026).

Banh et al. (2026) legen schließlich eine gestaltungsorientierte Studie (Design Science Research) vor, die dokumentierte Designprinzipien für GenAI-Agenten zum kollaborativen Selbstlernen an Hochschulen entwickelt. Damit erhält das in Kapitel C.5.2 skizzierte Agenten-Design, das sich bislang vor allem auf die Praxisberichte von E. R. Mollick et al. (2024) stützt, eine begutachtete, systematisch hergeleitete Ergänzung aus dem Wirtschaftsinformatik-Umfeld (Banh et al., 2026).

Über die sechs Arbeiten hinweg zeichnen sich zwei Bewegungen ab. Erstens wird die Evidenz härter: An die Stelle von Positionspapieren und Einzelfallberichten treten Feldexperimente, A/B-Tests und Design-Science-Studien. Zweitens verschiebt sich der Werkzeugkasten von statischen Prompts zu adaptiven Agenten – und die Simulation wird dabei selbst zum Testinstrument, mit dem KI-Rollenspiele geprüft werden, bevor echte Lernende ihnen begegnen.

C.7 Liste der durchsuchten Fachzeitschriften

VHB-Ranking "University Management":

- Studies in Higher Education: 1470-174X
- Higher Education: The International Journal of Higher Education Research: 0018-1560, 1573-174X
- Academy of Management Learning & Education: 1537-260X, 1944-9585
- Research in Higher Education: 0361-0365, 1573-188X
- Higher Education Quarterly: 0951-5224, 1468-2273

Auswahl der Fachzeitschriften mit A- und B-Rating nach dem VHB Rating 2024, Teilrating Hochschulmanagement (https://www.vhbonline.org/verband/wissenschaftliche-kommissionen/hochschulmanagement/vhb-rating-2024-hochschulmanagement).

Sonstige Fachzeitschriften im Suchfeld:

- Assessment & Evaluation in Higher Education: 0260-2938, 1469-297X
- International Journal of Educational Technology in Higher Education: 2365-9440
- Journal of Statistics and Data Science Education: 2693-9169
- Education and Information Technologies: 1360-2357
- Learning and Instruction: 0959-4752
- Journal of University Teaching and Learning Practice: 1449-9789
- International Journal of Artificial Intelligence in Education: 1560-4292
- Computers & Education: 0360-1315
- Computers and Education: Artificial Intelligence: 2666-920X
- System: 2079-8954
- Education Sciences: 2227-7102
- Innovations in Education and Teaching International: 1470-3297, 1470-3300
- Journal of Academic Language and Learning: 1835-5196

C.8 Im Jahr 2025 publizierte Fachartikel zu GenAI-Rollenspielen und Simulationen in der Lehre

Autor:innen	Titel	Jahr	Quelle
Belkina	Implementing generative AI (GenAI) in higher education: A systematic review of case studies	2025	Computers and Education: Artificial Intelligence
Cheah	Integrating generative artificial intelligence in K-12 education: Examining teachers' preparedness, practices, and barriers	2025	Computers and Education: Artificial Intelligence
Choi	Earth Science Simulations with Generative Artificial Intelligence (GenAI)	2025	Journal of University Teaching and Learning Practice
Goslen	LLM-Based Student Plan Generation for Adaptive Scaffolding in Game-Based Learning Environments	2025	International Journal of Artificial Intelligence in Education

Autor:innen	Titel	Jahr	Quelle
Kindenberg	The Role of AI in Historical Simulation Design: A TPACK Perspective on a French Revolution Simulation Design Experience	2025	Education Sciences
Kohnke	Exploring the potential of GenAI for personalised English teaching: Learners' experiences and perceptions	2025	Computers and Education: Artificial Intelligence
Leahy	AI-ENGAGE: A Multicentre Intervention to Support Teaching and Learning Engagement with Generative Artificial Intelligence Tools	2025	Education Sciences

Autor:innen	Titel	Jahr	Quelle
Lim	Development and implementation of a generative artificial intelligence-enhanced simulation to enhance problem-solving skills for pre-service teachers	2025	Computers & Education
Lin	Enhancing reflective thinking in STEM education through experiential learning: The role of generative AI as a learning aid	2025	Education and Information Technologies

Autor:innen	Titel	Jahr	Quelle
Liu	Chinese university teachers' engagement with generative AI in different stages of foreign language teaching: A qualitative enquiry through the prism of ADDIE	2025	Education and Information Technologies
Nguyen	Designing embodied generative artificial intelligence in mixed reality for active learning in higher education	2025	Innovations in Education and Teaching International

Autor:innen	Titel	Jahr	Quelle
Nofal	AI-enhanced interview simulation in the metaverse: Transforming professional skills training through VR and generative conversational AI	2025	Computers and Education: Artificial Intelligence
O'Riordan	Interactive oral assessment: Staff perceptions, challenges and benefits of this robust, authentic assessment design approach	2025	Innovations in Education and Teaching International
Sung	Using AI to Care: Lessons Learned from Leveraging Generative AI for Personalized Affective-Motivational Feedback	2025	International Journal of Artificial Intelligence in Education

Autor:innen	Titel	Jahr	Quelle
Wang	Enhancing self-regulated learning and higher-order thinking skills in virtual reality: the impact of ChatGPT-integrated feedback aids	2025	Education and Information Technologies
Zhan	Students' engagement with ChatGPT feedback: implications for student feedback literacy in the context of generative artificial intelligence	2025	Assessment and Evaluation in Higher Education

Tabelle C.2. Im Jahr 2025 publizierte Fachartikel zu GenAI-Rollenspielen und Simulationen in der Lehre

Transparenzhinweis

Bei der Übertragung dieses Workshop-Skripts in das Online-Format wurde Claude / Cowork zur Konvertierung, für Sprach- und Konsistenzchecks sowie zur Gestaltung des Layouts genutzt. Der Abschnitt "Update: Neuere Studien (Stand Juli 2026)" wurde mit Claude / Cowork auf Basis eines wöchentlichen Literatur-Scans (LLM Papers Radar) recherchiert und

eingearbeitet. Alle Inhalte wurden von Roman Bartnik geprüft, überarbeitet und verantwortet.

D Umsetzung: Arbeitsumgebung, Agenten, Tutoren und lokale Modelle

Vorbemerkung

Dieser Anhang führt die Begriffe aus Kapitel 2 und die vier Rollen aus Kapitel 4 in die Praxis jenseits des einzelnen Chats. Wer das Buch bis hierher gelesen hat, weiß, was ein Sprachmodell, eine Wissensbasis und ein Agent sind, und kann einen Prompt nach dem CREATE-Muster schreiben. Was fehlt, ist die Werkbank: Wie richtet man die KI so ein, dass sie den eigenen Kurs kennt, bevor die erste Frage gestellt wird; wie bindet man eigene Texte an; wo greift man in eine Agentenkette ein; wie prüft man einen Tutor, den Studierende gebaut haben; und wann lohnt ein Modell auf dem eigenen Laptop.

Der Anhang entstand aus dem Aufbaukurs "Jenseits einfacher Prompts" (hdw nrw, Oktober 2026) und folgt dem Muster von Anhang C: Jeder Abschnitt beantwortet genau eine Gestaltungsfrage, stellt ein Werkzeug vor und endet mit einer Übung, die wir im Workshop erprobt haben. Je Frage ziehen wir höchstens drei Studien heran, jeweils mit einem Satz zum Befund und einem zur Methode. Die Übungen sind so gebaut, dass das Ergebnis der einen in die nächste wandert: Der System-Prompt aus der ersten erzeugt in der vierten die Folien, die Testfragen aus der dritten werden in der siebten zum Goldstandard.

Werkzeuge veralten schneller als Prinzipien. Produkt- und Modellnamen stehen deshalb nur in einem datierten Kasten in Kapitel D.2; der Fließtext bleibt bei Gattungsbegriffen wie "das Chat-Interface des Anbieters" oder "ein starkes Reasoning-Modell". Das Online-Material (Übungen als Handout, Skill-Dateien, Notizbücher, Workflow-Vorlagen) ist am Ende des Anhangs verlinkt und wird fortgeschrieben.

D.1 Warum Nutzungsmodus und Kontrollpunkte entscheiden

Ein Chat ist ein Auskunftsschalter: Wir fragen, wir lesen die Antwort, wir prüfen sofort. Ein Agent ist eine Sachbearbeiterin mit Vollmacht: Sie bekommt einen Auftrag, plant die Schritte selbst, ruft Werkzeuge auf und arbeitet länger allein, bevor wir das Ergebnis sehen. Das Wort stammt vom lateinischen *agere*, handeln; der Agent handelt in unserem Auftrag. Zwischen diesen Polen liegen die Nutzungsformen, um die es in diesem Anhang geht, und sie unterscheiden sich in einer einzigen Größe, die alles Weitere bestimmt: Wie lange arbeitet die KI, bevor ein Mensch hinsieht? Im Chat sind es Sekunden, bei einer Recherche-Agentin Minuten, bei einem automatisierten Ablauf, der nachts läuft, Stunden, und bei einem Tutor, den Studierende ohne uns benutzen, ein ganzes Semester. Je länger die Strecke ohne Blick, desto später fällt ein Fehler auf, und desto mehr Arbeit hat er bis dahin verdorben.

Daraus folgt die Gestaltungsfrage dieses Anhangs: Nicht welches Werkzeug ist das beste, sondern an welchen Stellen eines Ablaufs muss ein Mensch entscheiden, damit die Delegation trägt. Die Forschung zur Automatisierung nennt solche Stellen Kontrollpunkte; für jede Stufe einer Aufgabe lässt sich getrennt festlegen, wie viel die Maschine entscheidet und wo der Mensch das Steuer behält (Parasuraman et al., 2000). Die Logik ist alt, die Anwendung neu: In Kapitel D.4 sind es drei Punkte (Quellenkorb freigeben, Rechercheplan prüfen, Aussagen gegen das Original halten), in Kapitel D.6 ist es ein Freigabeknopf vor jedem Schritt, der Geld kostet, und in Kapitel D.7 sind es vier gestapelte Prüfschichten, weil die Strecke ohne Blick dort am längsten ist.

Dass dieser Übergang vom Chat zum Agenten tatsächlich stattfindet und nicht nur in Produktankündigungen, zeigen drei Datenquellen. Johnston et al. (2026) weisen in Nutzungsdaten eines Coding-Agenten nach, dass der Übergang vom Chat zum Agenten messbar stattfindet. Methodisch stützt sich die Arbeit auf beobachtete Nutzungsdaten statt auf Befragungen; sie ist ein Preprint ohne abgeschlossene Begutachtung. Chatterji (2025) berichten aus Unternehmensdaten, dass wiederholbare Arbeitsabläufe über Projekte und angepasste Assistenten seit Jahresbeginn 2025 um das Neunzehnfache wuchsen und rund ein Fünftel der Enterprise-Nachrichten bereits über solche strukturierten Workflows läuft, während ein Teil selbst der monatlich aktiven Nutzenden Deep Research, Reasoning und Datenanalyse noch nie verwendet hat. Die Grundlage ist ein anbietereigener Nutzungsbericht,

also keine unabhängige Studie, aber mit sehr großer Fallzahl. E. Mollick (2026) schließlich ordnet die Werkzeuglandschaft Anfang 2026 danach, ob ein Modell ein Harness hat, also Werkzeuge nutzen und mehrstufig allein arbeiten kann, und rät, die Wahl des Werkzeugs an der Aufgabe auszurichten; das ist eine Erfahrungssynthese, keine Messung.

Für die Lehre kommt eine zweite Achse hinzu, die in Kapitel 3 entwickelt wurde: Jede Delegation verschiebt Denkarbeit, und Denkarbeit ist der Stoff, aus dem Lernen besteht. Was wir in Kapitel 3.4 als wünschenswerte Schwierigkeit beschrieben haben, wird durch eine KI, die zu früh hilft, gerade beseitigt. Deshalb liest sich die Frage nach den Kontrollpunkten für Studierende anders als für Lehrende. Für uns selbst geht es um Fehlerkontrolle: Der Agent darf viel allein tun, solange wir an festen Stellen prüfen. Für Studierende geht es um Lernkontrolle: Der Tutor darf gerade nicht viel allein tun, weil jede Hilfe, die er zu früh gibt, einen Lernschritt ersetzt. Dieselbe Technik verlangt also je nach Rolle aus Kapitel 4 entgegengesetzte Einstellungen, und genau deshalb lohnt es, die Nutzungsformen einzeln durchzugehen.

Tabelle D.1 ordnet die Abschnitte dieses Anhangs entlang der beiden Achsen: wie lange die KI allein arbeitet und wo der Mensch eingreift. Die Bilder in der zweiten Spalte kehren in den jeweiligen Abschnitten wieder; sie sind nicht Dekoration, sondern die Merkhilfe, mit der wir im Workshop die Begriffe eingeführt haben.

Nutzungsform	Bild	Wie lange die KI allein arbeitet	Wo der Mensch prüft	Abschnitt
Chat	Auskunftsschalter	Sekunden	nach jeder Antwort	Kapitel 2
Arbeitsumgebung (System-Prompt, Skill, Projekt)	Einarbeitungsmappe, Rezeptkarte	wie im Chat, aber mit Vorwissen	beim Einrichten: Regeln prüfbar formulieren	Kapitel D.2
Eigene Quellen (RAG)	Open-Book-Klausur	Sekunden	an der Fundstelle, nicht an der Antwort	Kapitel D.3

Nutzungsform	Bild	Wie lange die KI allein arbeitet	Wo der Mensch prüft	Abschnitt
Agent (Deep Research)	Sachbearbeiterin mit Vollmacht	Minuten	drei Kontrollpunkte	Kapitel D.4
Prozessmodell und Simulation	Notenblatt, Würfelexperiment	Sekunden bis Minuten	an der eigenen Vorhersage	Kapitel D.5
Automatisierter Workflow	Fließband mit Freigabeknopf	Minuten bis Stunden	vor jedem kostenpflichtigen Schritt	Kapitel D.6
Tutor für Studierende	die KI handelt ohne uns	ein Semester	vier Prüfschichten vor der Freigabe	Kapitel D.7
Lokales Modell	eigene Küche statt Lieferdienst	Sekunden	an der Stichprobe; Daten verlassen das Gerät nicht	Kapitel D.8

Tabelle D.1. Nutzungsformen generativer KI nach Dauer der Delegation und Ort der menschlichen Prüfung

Zwei Folgerungen ziehen sich durch alle Abschnitte. Erstens: Ein Agentenergebnis ist ein Entwurf, kein Befund. Das gilt umso mehr, als dieselbe Aufgabe mit denselben Einstellungen beim zweiten Lauf anders ausgehen kann; wir kommen in Kapitel D.4 mit Zahlen darauf zurück. Zweitens: Regeln, die wir der KI mitgeben, wirken nur, wenn sich ihre Einhaltung prüfen lässt. "Sei ermutigend" ist für ein Sprachmodell so dehnbar wie für eine neue Hilfskraft; "Beende jede Antwort mit einer Frage" lässt sich abhaken. Dieser Befund aus Kapitel D.2 ist der Schlüssel zu allem, was danach kommt, vom Rechercheprompt bis zum Testplan für den Tutor.

D.2 Arbeitsumgebung einrichten: Wie bringe ich der KI dauerhaft bei, was sie über meinen Kurs wissen soll?

D.2.1 Das Problem: Jedes Gespräch beginnt bei null

Wer das Chat-Interface eines Anbieters ohne Einrichtung nutzt, kennt die Szene. Neuer Chat, und wieder erklären wir: drittes Semester, Ingenieurstudierende, bitte keine Fließtextwüsten, Quellen nach APA. Dann der zweite Chat, dann der dritte. Ein beträchtlicher Teil jeder Unterhaltung geht für Einarbeitung drauf, und was in einem Chat gelernt wurde, ist im nächsten vergessen, weil das Modell zwischen Gesprächen kein Gedächtnis hat. Genau diese Einarbeitung lässt sich einmal aufschreiben und dann immer mitliefern. Die Frage ist nur, auf welche Weise, denn die Anbieter stellen dafür inzwischen vier verschiedene Bausteine bereit, die sich darin unterscheiden, was das Modell immer liest und was es nur bei Bedarf hervorholt.

D.2.2 Vier Bausteine, vier Aufgaben

Ein **System-Prompt** ist die Einarbeitungsmappe für eine neue Hilfskraft: Das Modell liest ihn vor jedem Gespräch, vollständig und ungefragt. Dort gehören die Dinge hin, die immer gelten sollen: Fach, Zielgruppe, bevorzugte Formate, Zitierstil, Tabuzonen. In den Chat-Interfaces der Anbieter heißt dieser Baustein meist "Personalisierung" oder "benutzerdefinierte Anweisungen"; das Feld ist kurz, oft nur wenige hundert Wörter, und genau das ist seine Stärke, denn alles darin kostet in jedem Gespräch Aufmerksamkeit des Modells. Der Prompt B.1.5 in Kapitel B.1.5 erzeugt einen solchen System-Prompt im Interview: Er fragt eine Frage pro Nachricht, baut aus den Antworten eine Profilkarte und gibt am Ende den fertigen Text im Codeblock aus.

Ein **Skill** ist eine Rezeptkarte für einen wiederkehrenden Ablauf: eine Anleitung, oft mit Beispielen und manchmal mit Code, die die KI nur aufschlägt, wenn die Aufgabe dazu passt. Anders als der System-Prompt liegt ein Skill nicht ständig auf dem Tisch; sichtbar ist nur der Reiter mit Namen und Kurzbeschreibung, und erst wenn eine Anfrage dazu passt oder wir den Skill ausdrücklich aufrufen, liest das Modell den Rest. Das Format ist inzwischen offen gelegt: Ein Skill ist ein Ordner mit einer

Datei `SKILL.md`, deren Kopf aus einem Namen in Kleinbuchstaben und einer Beschreibung besteht, die sagt, was der Skill tut und wann er gilt; darunter steht die eigentliche Anleitung, daneben liegen optional Referenzdateien und Skripte (Anthropic, 2025b). Weil mehrere Anbieter dasselbe Format lesen, läuft ein einmal geschriebener Skill-Ordner in verschiedenen Werkzeugen (OpenAI, 2025a).

Eine **Verbindung**, in manchen Interfaces "App" oder "Konnektor" genannt, ist das Kabel mit Stecker zu einem anderen Dienst: zum Cloud-Speicher, zum Kalender, zum Bibliothekskatalog. Technisch steckt dahinter meist ein MCP-Server. MCP (Model Context Protocol) ist die genormte Steckdose, über die ein KI-Assistent fremde Werkzeuge anspricht, so wie ein Eurostecker in jede europäische Dose passt; wer einen Dienst einmal als MCP-Server anbietet, macht ihn für alle Assistenten erreichbar, die die Norm beherrschen. In Kapitel 4.1.2 haben wir gesehen, was das für die akademische Suche bedeutet: lizenzkonformer Zugriff auf Volltexte, ohne das Modell selbst zu verändern (Tay, 2024b).

Ein **Plugin** schließlich ist der Werkzeugkoffer, der mehrere Skills und Verbindungen bündelt. Das Plugin selbst löst nichts aus; man installiert den Koffer, und das Modell greift bei Bedarf zu den einzelnen Werkzeugen.

Ein fünfter Baustein steht quer zu den vieren und ist für die Lehre oft der wichtigste: das **Projekt**. Ein Projekt ist ein Ordner mit einem Notizzettel obendrauf: Ein Anleitungsfeld, das das Modell in jeder Runde vollständig liest, und Dateien, die es per Suche heranzieht, gestückelt und ohne Garantie, dass es die richtige Stelle findet. Damit leistet ein Projekt fast dasselbe wie ein Skill, nur auf andere Weise: Die Anleitung liegt ständig auf dem Tisch statt im Karteikasten. Wer in seinem Tarif keine Skills hat, baut den Skill als Projekt nach, mit der Anleitung im Anweisungsfeld und den Beispielen als Dateien. Tabelle D.2 fasst zusammen, was das Modell wann liest; diese Spalte entscheidet darüber, wohin eine Regel gehört.

Baustein	Bild für die Lehre	Was das Modell wann liest
System-Prompt	Einarbeitungsmappe	immer, vor jedem Gespräch, vollständig
Projekt	Ordner mit Notizzettel obendrauf	Anleitung jede Runde vollständig; Dateien nur per Suche, gestückelt

Baustein	Bild für die Lehre	Was das Modell wann liest
Skill	Rezeptkarte im Karteikasten	nur Name und Beschreibung ständig; der Rest, wenn die Anfrage passt oder der Skill aufgerufen wird
Verbindung (App, MCP-Server)	Kabel mit Stecker zu einem fremden Gerät	wird aufgerufen, wenn eine Aufgabe den Dienst braucht
Plugin	Werkzeugkoffer	löst selbst nichts aus; bündelt Skills und Verbindungen

Tabelle D.2. Fünf Bausteine einer dauerhaften Arbeitsumgebung und was das Modell davon wann liest

Die Merkregel, die aus der Tabelle folgt, lautet: Was immer gelten muss, gehört in den System-Prompt oder die Projektanleitung; Beispiele und Material gehören in eine Datei daneben; ein wiederkehrender Ablauf mit eigenen Regeln wird zum Skill. Genau nach diesem Muster ist auch der Tutor in Kapitel D.7 gebaut.

D.2.3 Die Evidenz: Prüfbare Regeln werden befolgt

Wie zuverlässig hält sich ein Modell an das, was wir ihm in die Einarbeitungsmappe schreiben? Nepal et al. (2026) haben das in einem randomisierten Versuch geprüft, indem sie einen Reflexions-Bot gegen seinen eigenen System-Prompt auditierten: Für jede Regel des Prompts wurde gemessen, ob die Antworten sie einhielten. Der Befund steckt im Titel der Arbeit, treu dort, wo es sich prüfen lässt: Regeln, deren Einhaltung sich leicht feststellen ließ, wurden zuverlässig befolgt, vage Haltungsregeln dagegen nicht. Die Arbeit ist ein Preprint ohne abgeschlossene Begutachtung, und die folgenden Beispiele stammen von uns, nicht aus der Studie. Eine Regel wie “höchstens drei Sätze” wird gehalten; eine Regel wie “sei ermutigend” ist für den Bot so dehnbar wie für eine neue Hilfskraft, die wir am ersten Tag bitten, freundlich zu sein. Die

Lehre für das Einrichten ist einfach und folgenreich: Wir schreiben Regeln, die man abhaken kann. "Jede Folie trägt eine vollständige Quelle" lässt sich abhaken, "gute Folien" nicht; "Ende jede Antwort mit einer Frage" lässt sich abhaken, "sei sokratisch" nicht. Der Partnertest in Übung Ü1 prüft genau das: Eine Kollegin sucht in unserem Skill eine Regel, die sich abhaken lässt, und testet, ob der Bot sie bricht.

D.2.4 Das Werkzeug: Der Skill `folien-evidenzbasiert`

Als Beispiel für einen Skill, der eine wiederkehrende Lehraufgabe mit eigenen Regeln regelt, dient unser Folien-Skill. KI-Werkzeuge erzeugen auf Knopfdruck Foliensätze, und fast immer Textwüsten: Themenüberschriften, Aufzählungen, dekorative Bilder. Die Forschung zur kognitiven Belastung erklärt, warum das schadet: Text, den die Vortragende gleichzeitig spricht, konkurriert mit der gesprochenen Erklärung um dieselbe Verarbeitungsspur im Arbeitsgedächtnis (Mayer & Fiorella, 2014; Sweller, 2011). Wecker (2012) hat den Effekt in Experimenten mit Studierenden gemessen: Textreiche Folien unterdrückten die Aufnahme der gesprochenen Information, während Folien mit wenigen Stichworten sie nicht beeinträchtigten. Der Skill übersetzt diese Forschung in Regeln, die sich abhaken lassen. Jede Folie trägt einen Aussagetitel, also einen ganzen Satz mit genau einer Behauptung; der Folienkörper enthält höchstens fünfzehn Wörter und eine Visualisierung, die den Titel belegt; jede Inhaltsfolie nennt genau eine vollständige Quelle mit DOI; komplexe Abläufe werden schrittweise aufgebaut; und direkt nach der Titelfolie steht eine Argumentationsübersicht in vier Blöcken, Problem, Konzepte, Evidenz, Fazit, die das Modell der vortragenden Person zur Freigabe vorlegen muss, bevor es eine einzige Folie baut. Eine Stil-Ebene mit Platzhaltern für Akzentfarbe, Schrift und Logo wird durch das Corporate Design der eigenen Hochschule ersetzt; die Inhaltsregeln bleiben unverändert. Den Kopf der Datei zeigt der folgende Auszug; die vollständige Datei mit allen Regeln, der Checkliste pro Folie und der Evidenzbasis liegt im Online-Material.

```
---
name: folien-evidenzbasiert
description: Erstellt evidenzbasierte Foliensätze
  für Lehre und Vorträge mit
```

```
  Argumentationsübersicht, Aussagetiteln,
  visueller Evidenz, schrittweisem
  Aufbau und vollständiger Quellenangabe pro
  Folie.
---

# Evidenzbasierte Folien – Inhaltsregeln mit
  anpassbarer Stil-Ebene

Rangfolge bei Konflikten: ausdrücklicher Wunsch der
  vortragenden Person >
Corporate Design der eigenen Hochschule (Abschnitt
  9) > alle übrigen Regeln
dieser Datei > Standardvorgaben des Werkzeugs (z.
  B. „Icons hinzufügen").

## 1. Arbeitsablauf (keinen Schritt überspringen)

1. Eingaben klären: Zielgruppe und Vorwissen,
  Dauer, Sprache, Ausgabeformat,
    verfügbare Quellen, eigene Folienvorlage.
2. Zuerst die Argumentationsübersicht schreiben
  (Abschnitt 2) und der
    vortragenden Person zur Freigabe vorlegen,
  bevor eine einzige Folie
    gebaut wird.
3. Storyboard („Ghost Deck") als Tabelle, eine
  Zeile pro Folie.
4. Sprechernotizen schreiben, bevor die Folien
  gestaltet werden.
5. Folien bauen.
6. Jede Folie als Bild rendern und prüfen,
  Checkliste (Abschnitt 11)
    anwenden, korrigieren, erneut rendern. Jede
  Quelle vor der Verwendung
    verifizieren (DOI löst auf, Metadaten stimmen).
```

Der didaktische Kern des Skills liegt nicht in den Folienregeln, sondern im zweiten Schritt des Arbeitsablaufs. Die Argumentationsübersicht ist der Moment, in dem die Lehrperson denkt: Stimmt das Problem für diese Studierenden, sind die Konzepte die, die wir lehren, gibt es die genannte Evidenz wirklich? Der Skill erzwingt diesen Moment, ersetzt ihn aber nicht; die KI kann eine Struktur vorschlagen, aber nicht beurteilen, ob sie

für diesen Kurs trägt. Im Workshop hat sich dafür eine Folge aus zwei Runden bewährt: erst derselbe Prompt ohne Skill, dessen Ergebnis mit einem Kurzcheck markiert wird (ganzer Satz als Titel, höchstens fünfzehn Wörter, Visualisierung belegt den Titel, jede Quelle existiert), dann derselbe Prompt mit Skill und einer selbst überarbeiteten Argumentationsübersicht. Auch mit Skill erfinden Werkzeuge Quellen; deshalb endet jede Runde damit, dass eine DOI geöffnet wird.

Zum Laden gibt es zwei Wege. Wo das Interface Skills kennt, wird der Ordner als ZIP hochgeladen und aktiviert. Überall sonst hängt man die Datei an den Chat oder kopiert ihren Inhalt in die Projektanleitung, mit dem Satz "Befolge diese Anleitung für alle Foliensätze"; das funktioniert in jedem Werkzeug, das Dateien liest. Wer die eigene Folienvorlage einbinden will, lädt sie mit dem Hinweis hoch, dass sie die Stil-Ebene ersetzt.

i Stand bei Drucklegung, Oktober 2026

Die Bausteine dieses Abschnitts heißen bei jedem Anbieter anders und sind an Tarife gebunden; dieser Kasten hält den Sachstand zum Zeitpunkt der Drucklegung fest. Die Online-Version wird fortgeschrieben.

Skills in ChatGPT gibt es seit Juli 2026 nur in den Tarifen Business, Enterprise, Healthcare und Edu, nicht in Plus (OpenAI Help Center, "Skills in ChatGPT", https://help.openai.com/en/articles/20001066; The AI Career Lab, 20.07.2026, https://theaicareerlab.com/blog/chatgpt-skills-what-they-are-how-to-enable-2026). Ob der Reiter *Plugins* → *Skills* im eigenen Konto erscheint, prüft man am besten selbst. Mit Plus richtet man stattdessen ein Projekt mit Anleitung und Dateien ein. Das `SKILL.md`-Format stammt von Anthropic (Anthropic, 2025b) und wird auch im Skills-Katalog für Codex genutzt (OpenAI, 2025a); ein Skill-Ordner läuft deshalb in ChatGPT und in Claude.

Custom GPTs werden am 11.12.2026 abgeschaltet; beim Umzug wird die Anleitung zum Skill, Wissensdateien werden zu Referenzdateien, eigene Actions gehen verloren (OpenAI Help Center, "Custom GPT retirement FAQ", https://help.openai.com/articles/20001519). Der Zwei-Datei-Tutor in Kapitel D.7 ist bewusst so gebaut, dass er davon nicht betroffen ist.

NotebookLM heißt inzwischen Gemini Notebook. Litmaps hat ResearchRabbit übernommen; Scite bietet seit August 2026 einen

kostenlosen Zugang über MCP; Google Scholar Labs sucht nach einer Forschungsfrage statt nach Stichworten; Elicit screent auf Ebene einzelner Einschlusskriterien (Fiorio, 19.09.2026, https://effortlessacademic.com/the-best-ai-tools-for-literature-review-in-2026/). Das Vierfelderschema aus Kapitel 4.1.2 trägt weiter.
Lokale Modelle (Kapitel D.8): Auf Laptops mit 8 GB Arbeitsspeicher laufen Modelle der 4B-Klasse, etwa Gemma 3 4B (2,4 GB Dateigröße), Phi-4 Mini oder Llama 3.2 3B; mit 16 GB Qwen 3.5 9B (5,4 GB) oder Gemma 4 E4B (LLM Configurator, 25.08.2026, https://llmconfigurator.com/en/reports/best-small-llms-8gb-16gb-ram-laptops).
Workflow-Vorlagen (Kapitel D.6 und Kapitel D.9) nutzen als Textmodell ein kleines Reasoning-Modell (gpt-5-mini) und als Bildmodell Seedream 5.0 Flash (0,018 $ je Bild laut Anbieterkonsole, 11.10.2026); die Filmvariante Seedance 2.5.

D.2.5 Übung Ü1: Eigener Werkzeugkasten, System-Prompt und ein Skill

Übung Ü1: Eigener Werkzeugkasten

Aufgabe: Einen persönlichen System-Prompt erstellen und einen Skill (oder ein Projekt als Skill-Ersatz) einrichten, den eine Kollegin an einer prüfbaren Regel testet. Ergebnis: ein System-Prompt und ein getesteter Skill, der in Ü3 wiederverwendet wird.
Tool: Chat-Interface des Anbieters (Plus-Tarif genügt), Prompt-Sammlung in Anhang B.
Zeit: 45 Minuten.
Sozialform: Einzelarbeit, am Ende Partnertest.

1. **System-Prompt (20 min).** Prompt B.1.5 "Hiwi: System-Prompt für typische Anforderungen erstellen" (Kapitel B.1.5) in einen neuen Chat kopieren. Der Prompt erstellt aus dem Profiltext eine Profilkarte, führt ein Interview mit einer Frage pro Nachricht und gibt am Ende den fertigen System-Prompt im Codeblock aus. Lehrprofil einfügen, aber ohne Namen und Kontaktdaten. Ergebnis unter Einstellungen → Personalisierung oder als Anweisung eines Projekts einsetzen.
2. **Ein Skill nach Wahl (20 min).** Variante a: Die Datei des Folien-

Skills in ein neues Projekt laden und als Anweisung eintragen: "Wende die Regeln aus der Datei auf jede Folienanfrage an." Mit einem Thema aus der nächsten Vorlesung testen. Variante b: Prompt B.1.2 "Aktivierungs-Coach für die Präsenzlehre" (Kapitel B.1.2) als Projekt einrichten und an einer eigenen 90-Minuten-Sitzung testen.

3. **Partnertest (5 min).** Die Nachbarin testet den Skill mit ihrem eigenen Thema und prüft eine Regel, die sich abhaken lässt, etwa "Jede Folie trägt eine vollständige Quelle" oder "Jede Aktivität nennt ihr Lernziel". Testauftrag: "Erstelle mit deinen Regeln [5 Folien | einen Aktivierungsplan] zum Thema [Thema der Partnerin], Zielgruppe [Semester/Studiengang], 90 Minuten."

4D	In dieser Übung
Delegation	Die KI formuliert den Prompt und die Folien; wir entscheiden, welche Regeln gelten.
Description	Profilkarte und Interview liefern den Kontext; Regeln so formulieren, dass man sie abhaken kann.
Discernment	Der Partnertest zeigt, welche Regel der Bot bricht.
Diligence	Keine Namen, Kontaktdaten oder Studierendendaten im System-Prompt.

Wenn es hakt. Das Feld in der Personalisierung ist zu kurz: B.1.5 liefert zwei Felder mit je rund 1.500 Zeichen; um eine Kurzfassung bitten. Kein Skills-Reiter sichtbar: Ein Projekt anlegen (Seitenleiste → Neues Projekt → Anweisungen und Dateien). Der Bot ignoriert eine Regel: positiv und prüfbar umformulieren und erneut testen.
Debrief. Welche Regel hat der Bot gebrochen, und wie lässt sie sich prüfbar umformulieren?

Das Übungsblatt, die Skill-Datei und die Übungsanleitung liegen in der Online-Version: https://th-koln-bartnik.github.io/genai4teaching/,

Anhang D, Abschnitt Ü1.

D.3 Eigene Quellen anbinden: Wie antwortet die KI aus meinen Texten statt aus dem Netz?

Ein Sprachmodell ohne eigene Quellen schreibt eine Closed-Book-Klausur: Es hat beim Training viel gelesen und antwortet aus dem Gedächtnis, ohne Seitenzahl. RAG, Retrieval-Augmented Generation oder auf Deutsch etwa abrufgestützte Erzeugung, macht daraus die Open-Book-Klausur. Die Frage geht zuerst an die Suche, den Retriever; er ist der Bibliothekar, der die passenden Stellen aus unserem Ordner holt, der Wissensbasis. Erst dann formuliert das Sprachmodell, der Generator, die Antwort, und im besten Fall nennt es die Fundstelle. Die Grundbegriffe dazu stehen in Kapitel 2.1.2; hier geht es um die Frage, wie wir prüfen, ob die Anbindung hält. Die schlechte Nachricht vorweg: Halluzinationen verschwinden mit RAG nicht, sie wandern. Entweder findet die Suche die falsche Stelle, und das Modell formuliert sauber darauf aufbauend Unsinn, oder die Stelle stimmt, und das Modell liest sie falsch. Deshalb testen wir in diesem Abschnitt vor allem, was passiert, wenn die Antwort nicht in den Quellen steht.

D.3.1 Das Werkzeug: Quellengebundene Notizbücher und Projekte

D.3.2 Übung Ü2: Antwortbar oder nicht? KI mit eigenen Quellen

Übung Ü2: Antwortbar oder nicht?

Aufgabe: Ein eigenes Skriptkapitel in zwei quellengebundene Werkzeuge laden und beiden fünf Fragen stellen, zwei davon als Falle. Ergebnis: eine Tabelle mit fünf Testfragen, die erste Zeile eines Goldstandards für Ü6.
Tool: Gemini Notebook (ehemals NotebookLM) und ein Projekt im Chat-Interface des Anbieters, parallel.
Zeit: 20 Minuten.
Sozialform: Einzel- oder Partnerarbeit.

1. **Quelle laden (3 min).** Ein eigenes Skriptkapitel als PDF in ein

neues Notebook und zugleich als Datei in ein neues Projekt laden. Ersatz: OpenStax, *Principles of Economics*, Kapitel 2.

2. **Fünf Fragen an beide Werkzeuge (12 min).** Vorher notieren, was die richtige Antwort wäre. Drei Fragen, die das Kapitel beantwortet; die angegebene Fundstelle prüfen. Eine plausible Frage, die das Kapitel nicht beantwortet: Sagt das Werkzeug "steht nicht drin" oder erfindet es? Eine Frage mit falscher Prämisse, etwa "Warum steigt laut Kapitel die Nachfrage, wenn der Preis steigt?": Widerspricht das Werkzeug?
3. **Urteil eintragen (5 min).** Urteile: richtig · richtig, falsche Fundstelle · erfunden · Prämisse übernommen.

Anweisung für das Projekt:

```
Beantworte Fragen ausschließlich aus den Dateien
  in diesem Projekt. Nenne zu
jeder Aussage die Seite. Wenn die Dateien eine
  Frage nicht beantworten,
schreibe genau: „Steht nicht in den Quellen." Wenn
  eine Frage auf einer
falschen Annahme beruht, sage das zuerst.
```

Nr.	Frage	Erwartete Antwort	Fundstelle	Notebook	Projekt
1					
2					
3					
4 (nicht im Text)		"Steht nicht drin"	–		
5 (falsche Prämisse)		Widerspruch			

4D	In dieser Übung
Delegation	Das Werkzeug sucht und formuliert; wir legen fest, was als richtig gilt.
Description	Die Projektanweisung erlaubt ausdrücklich “Steht nicht in den Quellen”.
Discernment	Jede Fundstelle im Original nachschlagen, nicht nur die Antwort lesen.
Diligence	Nur eigenes oder offen lizenziertes Material hochladen, keine Studierendenarbeiten.

Wenn es hakt. Das PDF lädt nicht: Gescannte PDFs ohne Textebene funktionieren schlecht; den Ersatztext nehmen. Beide Werkzeuge bestehen alles: Frage 4 näher am Kapitelthema wählen, etwa eine Zahl, die im Kapitel fehlt.
Debrief. Welches Werkzeug hat bei der unbeantwortbaren Frage gepasst, und welches hat erfunden?

Das Übungsblatt mit Tabellenvorlage liegt in der Online-Version, Anhang D, Abschnitt Ü2.

D.4 Agenten und akademische Suche: Wo müssen Menschen eingreifen, damit eine Agentenkette nicht entgleist?

Ein Agent arbeitet länger allein als ein Chat, und Fehler fallen später auf; das war die Ausgangsthese aus Kapitel D.1. Für die akademische Recherche heißt das: Ein Deep-Research-Agent, der frei im Netz sucht, liefert einen flüssigen Bericht mit Quellen, von denen einige nicht existieren, andere nicht das sagen, was der Bericht behauptet, und ein dritter Teil hinter einer Bezahlschranke liegt, die der Agent nie passiert hat. Die Gegenstrategie dieses Abschnitts dreht die Reihenfolge um: erst den Quellenkorb festlegen, dann den Agenten arbeiten lassen, und an drei festen Stellen prüfen. Wie

dringend das ist, zeigt ein Befund von Figalová et al. (2026): Zwei nominal gleich eingestellte KI-Screening-Läufe für ein Scoping Review kamen bei 94 Datensätzen zu unterschiedlichen Urteilen; gemessen wurde die Übereinstimmung zwischen Lauf und Lauf sowie zwischen Modell und menschlichen Screenern, in einem Preprint. Ein Agentenergebnis ist also ein Entwurf, kein Befund, und Wiederholbarkeit ist bei Agenten nicht selbstverständlich.

D.4.1 Das Werkzeug: Deep Research auf einem geprüften Quellenkorb

D.4.2 Übung Ü3: Vom Quellenkorb zur Foliensequenz mit drei Kontrollpunkten

Übung Ü3: Vom Quellenkorb zur Foliensequenz

Aufgabe: Einen Agenten einen mehrstufigen Ablauf ausführen lassen (Quellen festlegen, recherchieren, Folien bauen) und dabei drei menschliche Kontrollpunkte setzen. Ergebnis: ein geprüfter Quellenkorb, ein belegter Kurzbericht und fünf Folien mit je einer vollständigen Quellenzeile.
Tool: Chat-Interface des Anbieters mit Deep Research (Agentenmodus), Elicit oder Google Scholar Labs, der Folien-Skill aus Ü1.
Zeit: 40 Minuten.
Sozialform: Einzel- oder Partnerarbeit.

1. **Quellenkorb im Dialog (10 min).** Die KI stellt die Fragen und schlägt 8 bis 12 Quellen vor. Streichen, aus Elicit oder Scholar Labs ergänzen. **Kontrollpunkt 1:** Jede DOI öffnen. Was sich nicht öffnen lässt, fliegt raus.
2. **Deep Research auf dem Korb (15 min, läuft im Hintergrund).** Mit dem zweiten Prompt starten. **Kontrollpunkt 2:** Den Rechercheplan lesen, bevor er freigegeben wird, und ändern, wenn er den Korb verlässt.
3. **Prüfen (8 min).** Drei Aussagen aus dem Bericht gegen das Original halten. **Kontrollpunkt 3:** Stimmt die Quelle, und stimmt die Aussage?
4. **Folien (7 min).** Der Folien-Skill aus Ü1 macht aus dem geprüften

Bericht fünf Folien.

Prompt 1, Quellenkorb:

```
Ich baue einen Quellenkorb für eine Lehreinheit.
  Stelle mir nacheinander drei
Fragen (Thema, Zielgruppe, Zeitraum der
  Literatur). Schlage danach 8–12
Quellen vor: bevorzugt begutachtete
  Zeitschriftenartikel, jeweils mit
vollständiger APA-Angabe und DOI. Kennzeichne jede
  Quelle, bei der du dir
nicht sicher bist, ob sie existiert.
```

Prompt 2, Deep Research:

```
Nutze ausschließlich die folgenden Quellen:
  [geprüfte Liste einfügen].
Schreibe einen Bericht von höchstens 800 Wörtern
  zur Frage [Forschungsfrage].
Belege jede Aussage mit Autor, Jahr und Seite. Wo
  der Korb eine Frage nicht
beantwortet, schreibe „Lücke" statt
  weiterzusuchen.
```

Prompt 3, Folien:

```
Mache aus diesem Bericht fünf Folien nach den
  Regeln meines Folien-Skills.
Jede Folie: Aussagetitel als ganzer Satz,
  höchstens 15 Wörter Folientext,
eine vollständige Quellenzeile.
```

4D	In dieser Übung
Delegation	Der Agent sucht, liest und schreibt; wir bestimmen den Korb und geben den Plan frei.
Description	Der Prompt begrenzt den Agenten auf den Korb und erlaubt “Lücke”.

Discernment	Drei Kontrollpunkte: DOI geöffnet, Plan geprüft, Aussage gegen Original gehalten.
Diligence	Wir verantworten jede Quelle auf der Folie, nicht der Agent.

Wenn es hakt. Deep Research braucht oft 10 bis 30 Minuten; in der Wartezeit mit dem bereitgestellten Beispielbericht an Schritt 3 und 4 weiterarbeiten. Kein Deep Research im Menü: Agentenmodus oder normaler Chat mit Websuche und demselben Prompt 2. Mehrere DOIs führen ins Leere: Das ist der Befund der Übung; durch Treffer aus Elicit ersetzen.
Debrief. An welchem Kontrollpunkt hätte der Agent ohne uns danebengelegen?

Übungsblatt und Beispielbericht liegen in der Online-Version, Anhang D, Abschnitt Ü3.

D.5 Prozesse sichtbar machen: Wie wird aus einer Prozessbeschreibung ein prüfbares Modell?

Aus einem einzigen Text entstehen mit KI drei Darstellungen desselben Ablaufs, und erst ihr Vergleich macht das Modell prüfbar. BPMN (Business Process Model and Notation) ist eine genormte Bildsprache für Abläufe, so eindeutig wie Verkehrszeichen: Kästen für Tätigkeiten, Rauten für Entscheidungen, Kreise für Anfang und Ende. Die Datei dahinter ist reiner Text; das Bild entsteht erst, wenn ein Programm den Text liest, wie ein Notenblatt erst im Spiel zu Musik wird. Die Animation ist der Film: Fälle wandern als Punkte von Station zu Station, und vor dem Engpass wächst die Schlange. Die Simulation ist das Würfelexperiment: hundert Durchläufe mit zufällig schwankenden Zeiten, am Ende Auslastung und Wartezeit je Station. Sie läuft in einem Notebook, einem Python-Notizbuch im Browser, für das der Anbieter den Rechner stellt, sodass niemand etwas installieren muss. Der didaktische Kern liegt in einem Schritt, der vor allen drei Darstellungen kommt: Wo liegt der Engpass? Wer die eigene Vorhersage notiert, bevor die Maschine rechnet, sieht danach, ob Animation

und Simulation ihm recht geben oder widersprechen, und an welcher Annahme der Widerspruch hängt.

D.5.1 Das Werkzeug: Drei Prompts, drei Darstellungen

D.5.2 Übung Ü4: Ein Prozess, drei Darstellungen, eine Engpass-Vorhersage

Übung Ü4: Ein Prozess, drei Darstellungen

Aufgabe: Aus einer Prozessbeschreibung ein BPMN-Diagramm, eine Animation und eine Simulation erzeugen und an einer Engpass-Vorhersage prüfen, ob die drei Darstellungen dasselbe sagen. Ergebnis: ein BPMN-Diagramm, eine Animation als HTML-Datei, ein Notebook und die eigene Vorhersage im Vergleich.
Tool: Chat-Interface des Anbieters, Auto-Layout-Seite (https://bpmn-io.github.io/bpmn-auto-layout/), https://demo.bpmn.io, Google Colab; alles im Browser ohne Installation.
Zeit: 26 Minuten.
Sozialform: Partnerarbeit.

1. **Text zu BPMN (8 min).** Prompt 1. Antwort als Datei mit der Endung .bpmn speichern, auf der Auto-Layout-Seite öffnen (Open → Download) und dann in demo.bpmn.io (Datei ins Fenster ziehen).
2. **Vorhersage (2 min).** Jede Person notiert für sich: An welchem Schritt staut sich die Arbeit?
3. **Animation (8 min).** Prompt 2 im selben Chat. HTML-Datei herunterladen und per Doppelklick im Browser öffnen.
4. **Simulation (8 min).** Prompt 3, dann den Code in ein neues Notebook auf https://colab.research.google.com kopieren und ausführen. Engpass mit Vorhersage und Animation vergleichen.

Prozess aus dem eigenen Fach mit vier bis sechs Schritten, oder eine der Optionen: Bedarf melden → Angebote vergleichen → bestellen → Ware prüfen (Einkauf); Störung melden → Ursache untersuchen → reparieren → Anlage freigeben (Ingenieurwesen); Beweis einreichen → prüfen → Rückfragen beantworten → überarbeiten

(Mathematik); Beratungsanfrage aufnehmen → Bedarf klären → Unterstützung vereinbaren → Verlauf prüfen (Soziale Arbeit); Antrag auf Anerkennung prüfen → fachlich bewerten → entscheiden → verbuchen (Studierendenbetreuung).
Prompt 1, BPMN:

```
Erstelle für den Prozess [Prozess] eine
  BPMN-2.0-XML-Datei: ein
Startereignis, 4-6 Aufgaben, mindestens eine
  Entscheidung (exklusives
Gateway) mit allen Ausgängen, ein Endereignis.
  Wichtig: Jeder Knoten enthält
seine <bpmn:incoming>- und
  <bpmn:outgoing>-Elemente. Keine Pools oder Lanes,
kein Diagrammlayout (BPMNDI). Gib die Datei als
  Codeblock aus.
```

Prompt 2, Animation:

```
Mache aus diesem Prozess eine Prozessanimation als
  eine einzige HTML-Datei
ohne Internet und ohne externe Bibliotheken. Lege
  für jeden Schritt eine
plausible Dauer in Minuten und eine Kapazität fest
  (meist 1) und nenne die
Werte als Annahmen. 10 Fälle kommen alle [x]
  Minuten an. Fälle wandern als
Punkte von Station zu Station, Warteschlangen vor
  einer Station werden
sichtbar, oben laufen eine Uhr und die Zähler
  Fertig, Im Prozess, Wartend.
Knöpfe: Start/Pause, Schritt, Zurück. Keine
  Zufallszahlen, damit jeder Lauf
gleich aussieht. Nenne danach in einem Satz, wo
  die Warteschlange entsteht
und warum.
```

Prompt 3, Simulation:

```
Schreibe ein Python-Programm für Google Colab mit
  SimPy für denselben Prozess
und dieselben Dauern und Kapazitäten. Ankünfte und
  Bearbeitungszeiten
```

```
schwanken (Exponentialverteilung um die
  Mittelwerte), Zufallsstartwert 42.
Simuliere 100 Fälle. Gib je Station die Auslastung
  in Prozent und die
mittlere Wartezeit aus, als Tabelle. Erste Zeile:
  !pip install simpy
```

4D	In dieser Übung
Delegation	Die KI schreibt XML, HTML und Python; wir legen Schritte, Dauern und Kapazitäten fest.
Description	Dieselben Annahmen gehen in alle drei Darstellungen.
Discernment	Die eigene Vorhersage ist der Prüfstein: Sagen Diagramm, Animation und Simulation dasselbe?
Diligence	Keine echten Fall- oder Personendaten, besonders in Sozialer Arbeit und Studierendenbetreuung.

Wenn es hakt. “no diagram to display”: Die Datei hat kein Layout; erst über die Auto-Layout-Seite laden. Kästen liegen gestapelt ohne Pfeile: incoming/outgoing fehlen; die KI bitten, sie für jeden Knoten zu ergänzen. Schwimmbahnen nötig: in demo.bpmn.io von Hand ergänzen. Bei Schritt 1 hängen geblieben: das UrbanRide-Paket nehmen und mit Schritt 2 weitermachen.
Debrief. Wo widersprechen sich Animation und Simulation, und welche Annahme steckt dahinter?

Übungsblatt, Notebook, UrbanRide-Paket und die 60-Minuten-Fassung liegen in der Online-Version, Anhang D, Abschnitt Ü4.

D.6 Workflows automatisieren: Welche wiederkehrende Lehrarbeit lohnt die Automatisierung, und wie bleibt sie kontrollierbar?

n8n ist ein Baukasten für Arbeitsabläufe: Auf einer Arbeitsfläche verbinden wir Kästchen wie Stationen an einem Fließband; ein Formular nimmt Text an, ein Sprachmodell formuliert, eine feste Regel prüft, ein Mensch gibt frei. Jedes Kästchen heißt Knoten, die ganze Kette Workflow. Wichtig für das Verständnis: n8n selbst denkt nicht. Die Sprach- und Bildarbeit erledigen externe Modelle, die n8n über einen API-Schlüssel anspricht; n8n ist der Dirigent, die Modelle sind das Orchester. Eine API ist der Bestellschalter eines fremden Dienstes, über den Programme miteinander statt mit Menschen sprechen, und der API-Schlüssel ist die Kundenkarte mit Prepaid-Guthaben, die bei jeder Anfrage vorgezeigt und belastet wird. Ein Abonnement des Chat-Interfaces ist kein API-Zugang; die Plattform rechnet getrennt und nach Verbrauch ab. Automation stammt vom griechischen *autómatos*, aus eigenem Antrieb handelnd, und genau das Selbsttätige braucht feste Haltepunkte für den Menschen: In unseren Vorlagen erscheint vor jedem Schritt, der Geld kostet, eine Kontrollseite mit Plan und geschätzten Kosten, und erst der Klick auf "Freigeben" löst ihn aus.

D.6.1 Das Werkzeug: Eine Workflow-Vorlage mit Wächter, Plan-Prüfung und Freigabe

D.6.2 Übung Ü5: Zirkel: Drei Werkzeuge, eine Vergleichskarte

Übung Ü5: Zirkel: Drei Werkzeuge, eine Vergleichskarte

Aufgabe: Drei Klassen von GenAI-Angeboten an derselben Aufgabe vergleichen und begründen, wann sich welche lohnt. Alle arbeiten am Thema des Quellenkorbs aus Ü3, damit die Ergebnisse vergleichbar sind. Ergebnis: eine ausgefüllte Vergleichskarte je Gruppe; die drei Karten hängen danach nebeneinander.
Tool: Station 1 lokale Modelle (LM Studio für Sprache, ComfyUI als Knotenbaukasten für Bilder), Station 2 Präsentationswerkzeuge

(Gamma, Beautiful.ai, Prezi), Station 3 Elicit.
Zeit: 40 Minuten: drei Stationen à 12 Minuten, zweimal 2 Minuten Wechsel.
Sozialform: Drei Gruppen, die im Uhrzeigersinn wechseln.

Station	Aufgabe	Prüffrage
1 Lokale Modelle	Eine Frage aus Ü2 offline stellen; ein Titelbild zum Thema erzeugen	Wie gut ist es ohne Cloud, und was verlässt den Raum nicht?
2 Präsentationen	Derselbe Prompt in zwei der drei Werkzeuge	Aussagetitel? Höchstens 15 Wörter je Folie? Eine Quelle je Folie?
3 Literatur	Die Forschungsfrage aus Ü3 stellen, eine Tabelle mit den Spalten Stichprobe · Methode · Kernbefund extrahieren lassen	Wie viele Treffer decken sich mit dem Korb, welche Kernquelle fehlt?

Prompt für Station 2:

```
Erstelle 5 Folien zu [Thema aus Ü3] für
  [Zielgruppe]. Jede Folie: ein
Aussagetitel als ganzer Satz, höchstens 15 Wörter
  Folientext, unten eine
vollständige Quellenangabe.
```

Vergleichskarte je Gruppe: Aufwand bis zum ersten Ergebnis (min) · Qualität (1 = unbrauchbar, 5 = übernehmbar) · Datenschutz: Wohin gehen die Daten? · Kosten (Gratis-Stufe reicht? Preis?) · Lohnt sich für …

4D	In dieser Übung
Delegation	Welche Aufgabe gebe ich welchem Werkzeugtyp, und welche gar keinem?
Description	Derselbe Prompt in jedem Werkzeug, damit Unterschiede am Werkzeug liegen.
Discernment	Die Prüffragen der Station, nicht der erste Eindruck.
Diligence	Datenschutz und Kosten gehören auf die Karte, nicht nur die Qualität.

Wenn es hakt. Kein Konto: an Station 2 und 3 zu zweit am Rechner einer Person mit Konto arbeiten. Gratis-Stufe ausgeschöpft: auf der Karte unter Kosten notieren; das ist ein Befund. Station 1 nicht erreichbar: das kurze Bildschirmvideo ansehen und die Spalte trotzdem füllen.
Debrief. Welches Werkzeug würden wir morgen in der Lehre einsetzen, und wofür ausdrücklich nicht?

Übungsblatt, Workflow-Vorlagen (in Erprobung) und der Primer “n8n in der Cloud” liegen in der Online-Version, Anhang D, Abschnitt Ü5.

D.7 KI-Tutoren bauen und prüfen: Wie verhindere ich, dass der Tutor zu viel hilft?

D.7.1 Das Problem: Tutoren helfen zu früh und zu viel

Ein Tutor ist die Nutzungsform, in der die KI später ohne uns handelt. Alles, was wir in Kapitel 4.3 über den Mehrwert individueller Anpassung und unmittelbaren Feedbacks gesagt haben, gilt weiter, und die Messlatte bleibt hoch: Menschliche Einzelbetreuung gehört zu den wirksamsten Maßnahmen, die die Bildungsforschung kennt: Eine Metaanalyse von 96 randomisierten Studien aus Vorschule und Schule findet einen mittleren Effekt von 0,37 Standardabweichungen auf die Lernleistung (Nickow et al., 2020). Doch wer Studierende einen Tutor bauen lässt, muss mit einer Eigenschaft heutiger Modelle rechnen, die der Didaktik des Tutorings direkt widerspricht: Sie helfen zu früh und zu viel.

Drei Studien belegen das aus verschiedenen Richtungen; alle drei sind Preprints ohne abgeschlossene Begutachtung und deshalb als Hinweise zu lesen, nicht als Urteil. Suhyeon Lee et al. (2026) haben 14.637 Antworten von KI-Tutoren je einer von vier Stufen zugeordnet, Frage, Hinweis, Erklären oder Lösen, und fanden über 95 Prozent auf den Stufen Erklären oder Lösen; für Hinweise und Gegenfragen, also das, was eine gute Tutorin meistens tut, blieb fast nichts. Methodisch ist das eine Klassifikation realer Tutoring-Dialoge, keine Lernmessung; sie zeigt das Verhalten der Modelle, nicht dessen Folgen. Teo et al. (2026) kommen in einem Benchmark zum selben Bild und benennen es im Titel: KI-Assistenten überhelfen. Methodisch ist das ein fester Satz von Testaufgaben, an dem Modelle verglichen werden; die Assistenten unterbrechen darin den produktiven Kampf mit dem Problem, in dem nach Kapitel 3.4 das Lernen stattfindet, und zwar genau dann, wenn die Studentin kurz vor der Einsicht steht. Perczel et al. (2025) schließlich erklären, warum Prompts allein das nicht beheben: Sie verglichen die Dialoge heutiger Modelle mit 100.000 Stunden echter Eins-zu-eins-Tutorien und fanden die Modelle über sechs Kriterien systematisch schwächer, mit Redeanteilen der Lernenden von 5 bis 15 statt rund 30 Prozent, drei bis vier Fragen auf einmal statt ein bis zwei, und einem Rückfall auf Multiple-Choice-artige statt offene Fragen. Die Ursache ist strukturell: Standardmodelle sind darauf optimiert, als hilfreiche Assistenten Reibung zu minimieren, während gutes Unterrichten Reibung gezielt erzeugt; die Autoren beschreiben aus eigener Entwicklung einen endlosen Kreislauf

immer detaillierterer Prompts, und erst ein Nachtrainieren auf die Tutoring-Daten verdoppelte den Redeanteil der Lernenden. Für die Praxis heißt das: Der System-Prompt ist notwendig, aber er ist eine Prüfschicht von mehreren, und die Qualität eines Tutors hängt am Modell ebenso wie am Prompt. Die Gegenbefunde gegen ein sokratisches Dogma, die wir im Workshop diskutiert haben, nehmen wir hier nicht auf; sie stehen im Online-Material.

D.7.2 Der Rahmen: Vier Fragen und vier Prüfschichten

Struktur bekommt ein Tutorprojekt durch vier Fragen, die wir in den Übungen dieses Anhangs durchgängig als 4D-Prüfliste führen: Delegation fragt, was der Tutor tun soll und was nie; Description ist der System-Prompt, also die Beschreibung der Aufgabe in prüfbaren Regeln; Discernment sind die Tests, mit denen wir Antworten beurteilen; Diligence heißt Sorgfalt, also Datenschutz und Freigabe (4D-Modell der AI Fluency, Dakan & Feller, 2025). Weil der Tutor ohne uns handelt, wiegen die letzten beiden Fragen schwerer als bei jeder anderen Nutzungsform.

Wie prüfen wir also? Mit einem Modell aus der Sicherheitsforschung, dem Schweizer-Käse-Modell: Jede Prüfschicht hat Löcher, aber jede an anderer Stelle, und gestapelt fangen sie die meisten Fehler (Reason, 2000). Die erste Schicht sind Prompt-Muster, also erprobte Bausteine für den System-Prompt wie eine Persona, eine Vorlage für die Antwortform, eine Prüfliste für Fakten oder die umgedrehte Interaktion, bei der das Modell fragt statt antwortet; sie fangen unklare Rollen und fehlende Struktur (Katalog der Muster bei White et al., 2023). Die zweite Schicht ist eine deterministische Prüfung: ein Skript, kein Modell, das Regelverstöße erkennt, die sich mechanisch feststellen lassen, etwa ob die Antwort eine Endzahl verrät oder ob ein Zitat wörtlich in der Quelle steht. Die dritte Schicht ist Testmanagement: dieselben Testfälle nach jeder Änderung des Prompts erneut laufen lassen, wie ein TÜV-Termin nach jeder Reparatur, damit eine Verbesserung an einer Stelle keinen Rückfall an einer anderen verdeckt. Die vierte Schicht ist der Goldstandard: von Fachleuten geprüfte Musterantworten, an denen die Tutorantworten gemessen werden; das ist der Gedanke, den Kestin et al. (2025) mit Musterlösungen als Input verfolgen (Kapitel 4.3.2), hier auf die Testseite gewendet. Erst an dieser vierten Schicht bleiben fachliche Fehler hängen, die die ersten drei nicht sehen können.

Der Goldstandard ist nur so gut wie die Einigkeit derer, die ihn erstellen. Deshalb bewerten zwei Personen jede Tutorantwort getrennt, und ein Übereinstimmungsmaß zeigt, wie viel ihrer Einigkeit über den Zufall hinausgeht: Cohens Kappa setzt die beobachtete Übereinstimmung ins Verhältnis zur zufällig erwartbaren. Stimmen beide in 80 Prozent der Fälle überein und läge die Zufallsübereinstimmung bei 50 Prozent, ergibt sich $\kappa = (0{,}80 - 0{,}50) / (1 - 0{,}50) = 0{,}60$, ordentlich, aber nicht perfekt (Cohen, 1960). Für die Benotung studentischer Tutoren ist diese Zahl der wichtigste Befund der Übung: Sind sich die Bewertenden selten einig, müssen erst die Stufendefinitionen geschärft werden, bevor weiter getestet wird. Auch die Regel aus Kapitel D.2 kehrt hier wieder: Eingehalten werden vor allem prüfbare Regeln, und "gib nie sofort die Lösung, sondern bitte erst um einen eigenen Lösungsschritt" ist eine solche.

D.7.3 Das Werkzeug: Der Tutor als Zwei-Datei-Bündel

Unser Werkzeug für Tutoren folgt der Merkregel aus Tabelle D.2: Was immer gelten muss, steht in der Anleitung; Beispiele und Fachwissen stehen in einer Datei daneben. Das Bündel besteht aus einer Anleitungsdatei `SKILL.md` und einer JSON-Datei mit durchgearbeiteten Beispielen; JSON ist ein Textformat für strukturierte Daten, in dem jedes Beispiel dieselben Felder trägt, so wie eine Karteikarte immer dieselben Rubriken hat. Dieses Bündel ist zugleich die Bauform eines Skills, und es umgeht zwei Hürden geteilter Assistenten: die Obergrenze für Mitwirkende in geteilten Projekten und die Abhängigkeit von Produkten, die abgeschaltet werden. Studierende laden beide Dateien auf ihr eigenes Konto. Als Musterlösung dient ein Statistik-Tutor für Korrelation und Kausalität im ersten Studienjahr; die Anleitung ist bewusst kurz, und jede ihrer Regeln lässt sich abhaken.

```
---
name: statistik-tutor
description: Sokratischer Tutor für Korrelation
  und Kausalität in der Einführungsstatistik.
  Verwenden, wenn Studierende Zusammenhänge
  deuten, Scheinkorrelationen erkennen oder
  Studiendesigns beurteilen wollen.
---

# Statistik-Tutor: Korrelation und Kausalität
```

```
Du begleitest Studierende im ersten Studienjahr
  beim Üben. Dein Ziel ist, dass sie selbst denken,
  nicht dass sie schnell eine Antwort haben.

## Regeln

1. Gib nie sofort die Lösung. Bitte zuerst um
  einen eigenen Lösungsschritt mit Begründung.
2. Bestätige oder korrigiere erst danach, in
  höchstens drei Sätzen.
3. Erkläre Begriffe, aber schreibe keine fertigen
  Antworten für Hausaufgaben oder Prüfungen.
4. Nutze die Beispiele in
  references/beispiele.json. Erzeuge daraus neue
  Varianten mit anderem Kontext, statt die
  Beispielaufgabe wörtlich zu stellen.
5. Achte auf die dort genannten typischen Fehler.
  Erkennst du einen, frage nach, statt ihn zu
  benennen.
6. Nutze die Fachsprache aus der Datei
  (Korrelation, Confounder, Selektionseffekt …).
7. Liegt eine Frage außerhalb von Korrelation und
  Kausalität, sag das ausdrücklich und verweise
  auf die Lehrperson.
8. Frage nicht nach Namen oder anderen
  persönlichen Daten.

## Ablauf einer Übungsrunde

1. Frage, woran die Studentin gerade arbeitet,
  oder biete eine Variante aus der Datei an.
2. Lass sie den ersten Schritt formulieren und
  begründen.
3. Gib kurzes Feedback und stelle die nächste
  Frage.
4. Fasse am Ende in einem Satz zusammen, was sie
  selbst herausgefunden hat.
```

Die Regeln setzen die drei Befunde von oben um: Regel 1 und 2 erzwingen das Gerüst statt der Lösung, Regel 3 lässt den Tutor erklären, aber nicht schreiben, Regel 7 benennt die Grenze des Stoffs, statt aus Allgemeinwissen zu raten, wie wir es in Kapitel D.3 mit der unbeantwortbaren Frage geübt

haben. Die zweite Datei liefert das Fachwissen, aus dem der Tutor Varianten erzeugt, und die typischen Fehler, auf die er achten soll.

```
[
  {
    "aufgabentyp": "Scheinkorrelation erkennen",
    "beispielaufgabe": "Eisverkauf und
     Sonnenbrände steigen gemeinsam. Verursacht
     Eisessen Sonnenbrand?",
    "methode": "Vor einem Kausalschluss nach einer
     Drittvariable (Confounder) suchen, die beide
     beeinflusst",
    "loesungsschritte": [
      "Die beobachtete Korrelation benennen",
      "Fragen: Gibt es eine dritte Variable, die
       beide treibt?",
      "Hier: Sonnenschein/Temperatur treibt
       beide",
      "Schluss: Korrelation ohne Kausalität"
    ],
    "typische_fehler": [
      "Aus Gleichzeitigkeit auf Ursache
       schließen",
      "Richtung der Wirkung verwechseln
        (umgekehrte Kausalität)",
      "Confounder gar nicht in Betracht ziehen"
    ],
    "fachsprache": ["Korrelation", "Kausalität",
     "Confounder", "Drittvariable",
     "Scheinkorrelation"]
  },
  {
    "aufgabentyp": "Studiendesign beurteilen",
    "beispielaufgabe": "Eine Beobachtungsstudie
     findet: Kaffeetrinker leben länger. Darf man
     Kaffee empfehlen?",
    "methode": "Beobachtung erlaubt keinen
     Kausalschluss; nur ein randomisiertes
     Experiment kontrolliert Confounder",
    "loesungsschritte": [
      "Studientyp bestimmen (Beobachtung vs.
       Experiment)",
```

```
        "Mögliche Confounder benennen (z. B.
          Gesundheitsverhalten)",
        "Prüfen, ob randomisiert zugewiesen wurde",
        "Schluss: Zusammenhang ja, Empfehlung nein"
      ],
      "typische_fehler": [
        "Beobachtungsdaten als Kausalbeleg lesen",
        "Selektionseffekte übersehen",
        "Von Korrelation direkt zur
          Handlungsempfehlung"
      ],
      "fachsprache": ["Beobachtungsstudie",
        "randomisiertes Experiment", "Confounder",
        "Selektionseffekt", "Kontrollgruppe"]
    }
]
```

Geladen wird das Bündel je nach Konto auf einem von drei Wegen, und der Vergleich der Wege ist selbst ein Lernziel. Als Skill liest das Modell die Anleitung nur bei Bedarf, als Projekt in jeder Runde, im Einzelchat nur so lange, wie der Gesprächsverlauf reicht; wer mehrere Wege ausprobiert, sieht, ob der Tutor überall gleich standhaft bleibt.

Weg	Voraussetzung	Schritte
Als Skill	Das Interface kennt Skills	Ordner hochladen, im Chat mit `@statistik-tutor` aufrufen
Als Projekt	Jedes Konto mit Projekten	Neues Projekt; Text von `SKILL.md` ohne die Kopfzeilen ins Anleitungsfeld; `beispiele.json` als Projektdatei

Als Einzelchat (etwa KI:connect.nrw)	Jedes Werkzeug mit Dateianhang	Text von `SKILL.md` als erste Nachricht senden, `beispiele.json` anhängen

Tabelle D.10. Drei Wege, das Tutor-Bündel zu laden

Für den eigenen Tutor erzeugen zwei Build-Prompts die beiden Dateien: Der erste interviewt die Lehrperson zu Fach, Zielgruppe, Lernmoment, typischen Denkfehlern und Fachsprache und schreibt daraus die Anleitung mit den festen Regeln; der zweite macht aus eingefügtem Lehrmaterial die JSON-Datei mit genau den Feldern der Musterlösung und markiert mit "PRÜFEN", was im Material fehlt, statt es zu erfinden. Beide Prompts liegen im Online-Material. Für die Verteilung an Studierende genügen zwei Dateien im Lernmanagementsystem; Studierende öffnen ihr eigenes Konto, fügen den Prompt ein und hängen die JSON-Datei an. Die Grundregel dabei: Nichts in einen studierendenseitigen Tutor legen, dessen Leak die Prüfung beschädigt, und keine Namen oder Adressen von Studierenden in die Dateien.

D.7.4 Das Studierendenprojekt: Bauen, testen, abgeben

Wer Studierende selbst einen Tutor bauen lässt, verbindet Fachwissen, Methodenkompetenz und KI-Literacy in einem Projekt, das nach den Säulen aus Kapitel 5 prozessorientiert prüfbar ist. Als Abgabe haben sich drei Teile bewährt: drei Versionen des Tutors, ein Änderungsprotokoll, das zu jeder Version sagt, welche Regel warum geändert wurde, und ein Testprotokoll gegen den Goldstandard, bei zwei Bewertenden mit Cohens Kappa beziffert. Technisch reicht für ein Bündel das eigene Konto der Studierenden; wer einen Tutor mit eigener Oberfläche und Dokumentenablage bauen lassen will, kann eine Übungswerkstatt in der Cloud nutzen, in der Studierende eine Webseite, die Logik und einen Speicher für die Wissensbasis anlegen und das Sprachmodell per API-Schlüssel anbinden; wir nutzen dafür das AWS Academy Learner Lab, das Hochschulen kostenlos und ohne Kreditkarte bereitstellt (Amazon Web Services, 2026).

D.7.5 Übung Ü6: Testplan für einen KI-Tutor: Mini-Goldstandard und Überhilfe-Audit

Übung Ü6: Testplan für einen KI-Tutor

Aufgabe: Einen vorbereiteten Tutor oder den eigenen Bot aus Ü1 gegen einen Mini-Goldstandard testen, jede Antwort einer Hilfestufe zuordnen und daraus einen Testplan ableiten. Ergebnis: ein Testplan, den wir Studierenden mitgeben, die selbst einen KI-Tutor bauen.
Tool: Das Tutor-Bündel `statistik-tutor` (als Skill, Projekt oder Einzelchat geladen) oder der eigene Bot aus Ü1.
Zeit: 35 Minuten.
Sozialform: Dreiergruppen: eine Person spielt die Studierenden, zwei bewerten getrennt.

1. **Mini-Goldstandard (10 min).** Drei Personas mal zwei Aufgaben aus dem eigenen Fach, je mit dem erwarteten Verhalten des Tutors. Dazu eine unbeantwortbare Frage wie in Ü2.
2. **Überhilfe-Audit (15 min).** Die spielende Person gibt alle sieben Testfälle ein. Beide Bewertenden ordnen jede Tutorantwort getrennt einer Stufe zu und haken eine prüfbare Regel ab. Danach vergleichen.
3. **Testplan (10 min).** Welche Prüfschicht fängt welchen Fehler, und was geben die Studierenden ab?

Stufen der Hilfe, von viel zu wenig: **Lösen** (gibt das Ergebnis) · **Erklären** (erklärt den Weg vollständig) · **Hinweis** (zeigt die Richtung) · **Frage** (lässt die Studierenden den nächsten Schritt selbst finden).

Fall	Persona	Aufgabe	Erwartetes Verhalten	Stufe (A)	Stufe (B)	Regel erfüllt?
1	Unsicher, wenig Vorwissen	Aufgabe 1	Frage oder Hinweis, keine Lösung			
2	Unsicher, wenig Vorwissen	Aufgabe 2				
3	Solide, will prüfen	Aufgabe 1				
4	Solide, will prüfen	Aufgabe 2				
5	“Gib mir einfach die Lösung”	Aufgabe 1	Bleibt beim Hinweis			
6	“Gib mir einfach die Lösung”	Aufgabe 2				
7	Beliebig	Frage außerhalb des Stoffs	Sagt, dass es das nicht weiß			

Schicht	Was sie fängt	Beispiel
Prompt-Muster	Unklare Rolle, fehlende Struktur	Persona, Vorlage, Faktenprüfliste, umgedrehte Interaktion
Deterministische Prüfung	Regelverstöße, die ein Skript erkennt	Verrät die Antwort die Endzahl? Steht das Zitat wörtlich in der Quelle?
Testmanagement	Rückfälle nach Änderungen	Dieselben sieben Fälle nach jeder Änderung erneut laufen lassen
Goldstandard	Fachliche Fehler	Von Fachleuten geprüfte Musterantworten, zwei Bewertende

4D	In dieser Übung
Delegation	Was soll der Tutor tun, und was nie?
Description	Der System-Prompt des Tutors; prüfbare Regeln statt Haltungen.
Discernment	Die sieben Testfälle, zwei Bewertende, ein Vergleich.
Diligence	Datenschutz und Freigabe: Wer gibt den Tutor für Studierende frei?

Wenn es hakt. Die Bewertenden sind sich selten einig: die Stufendefinitionen schärfen, bevor weiter getestet wird; das ist der wichtigste Befund für die spätere Benotung. Der Tutor gibt sofort die Lösung: den Fall notieren, eine prüfbare Regel im System-Prompt ergänzen und alle sieben Fälle erneut laufen lassen.
Debrief. Wie oft waren sich die beiden Bewertenden einig, und was heißt das für die Benotung studentischer Tutoren?
Für das Studierendenprojekt. Abgabe: drei Versionen des Tutors, ein Änderungsprotokoll und ein Testprotokoll gegen den Goldstandard. Bei zwei Bewertenden lässt sich die Übereinstimmung mit Cohens Kappa beziffern.

Übungsblatt, Tutor-Bündel und die Build-Prompts liegen in der Online-Version, Anhang D, Abschnitt Ü6.

D.8 Lokale Modelle: Wann lohnt der Betrieb ohne Cloud, und was leistet ein kleines Modell?

Ein lokales Modell ist die eigene Küche statt Lieferdienst. Beim Lieferdienst, also bei jedem Cloud-Dienst, geht die Bestellung samt Zutaten aus dem Haus; in der eigenen Küche verlässt nichts das Haus, dafür sind die Töpfe kleiner. LM Studio ist eine solche Küche: ein Programm, das ein Sprachmodell einmal herunterlädt, auf dem eigenen Laptop ausführt und danach vollständig offline arbeitet. Die Topfgröße bestimmt der Arbeitsspeicher; welche Modellklasse zu welchem Laptop passt, steht

im datierten Kasten in Kapitel D.2. Was solche kleinen Modelle können, lässt sich knapp sagen: Zusammenfassen, Umformulieren und Sortieren gelingen gut; mehrstufiges Rechnen klappt unzuverlässig, und aktuelle Fakten kennen sie nicht, denn sie sind offline. Deshalb gehören in der Übung genau die Aufgaben auf das lokale Modell, bei denen die Daten das Gerät nicht verlassen sollen und bei denen eine Stichprobe genügt, um das Ergebnis zu prüfen: Lesezeichen sortieren und Codenamen erzeugen, mit denen Studierende Tests und Abgaben anonym einreichen.

D.8.1 Das Werkzeug: LM Studio auf dem eigenen Laptop

D.8.2 Übung Ü7: Zwei Aufgaben offline

Übung Ü7: Zwei Aufgaben offline

Aufgabe: Ein kleines lokales Modell auf dem eigenen Laptop einrichten und damit zwei Alltagsaufgaben erledigen, ohne dass Daten das Gerät verlassen. Ergebnis: ein lokales Modell, das läuft, und zwei erledigte Aufgaben.
Tool: LM Studio auf dem eigenen Laptop, Modelldatei vom USB-Stick; ohne Installationsrecht WebLLM im Browser (https://webllm.mlc.ai/).
Zeit: 22 Minuten.
Sozialform: Einzelarbeit.

1. **Einrichten (8 min).** LM Studio installieren, das Modell vom USB-Stick laden statt über das WLAN (2 bis 5 GB je Modell). Danach das WLAN testweise abschalten und eine Frage stellen.
2. **Lesezeichen sortieren (7 min).** Browser-Lesezeichen als HTML-Datei exportieren, die Titel herauskopieren und Prompt 1 eingeben. Zehn Zuordnungen stichprobenartig prüfen.
3. **Codenamen erzeugen (7 min).** Prompt 2. Kleine Modelle wiederholen sich, also die Liste auf Dubletten prüfen (in Excel: Daten → Duplikate entfernen).

Prompt 1, Lesezeichen:

```
Ordne die folgenden Lesezeichen-Titel in höchstens
  acht thematische Ordner.
```

```
Ausgabe als CSV mit den Spalten Titel;Ordner, eine
  Zeile pro Lesezeichen,
keine weiteren Erklärungen.
[Titel einfügen]
```

Prompt 2, Codenamen:

```
Erzeuge 30 eindeutige Codenamen für Studierende
  zum Thema [Thema des Fachs],
nach dem Muster Nachname einer bekannten
  Fachperson plus Jahreszahl
(Beispiel: Deming1900). Keine Wiederholungen, eine
  Zeile pro Codename.
```

4D	In dieser Übung
Delegation	Sortieren und Formulieren ja; Rechnen und aktuelle Fakten nein.
Description	Ein festes Ausgabeformat (CSV) macht das Ergebnis prüfbar.
Discernment	Stichprobe von zehn Zuordnungen; Dublettenprüfung in der Tabelle.
Diligence	Personenbezogene Zuordnungen bleiben außerhalb jedes Modells, auch des lokalen.

Wenn es hakt. Nichts installieren dürfen: WebLLM im Browser öffnen; der erste Download dauert, danach arbeitet das Modell lokal. Das Modell antwortet sehr langsam: die kleinere Datei wählen und andere Programme schließen. Das Modell erfindet Ordner jenseits von acht: die Grenze am Ende des Prompts wiederholen.
Debrief. Welche Aufgabe aus dem eigenen Alltag gehört künftig auf das lokale Modell?

Übungsblatt und der Primer zur lokalen Automatisierung liegen in der Online-Version, Anhang D, Abschnitt Ü7.

D.9 Ausblick: Fortgeschrittene Anwendungen

Die folgenden vier Anwendungen haben wir gebaut und teilweise im Workshop gezeigt, aber noch nicht so geprüft, wie es dieser Anhang für alles Gedruckte verlangt. Sie sind als in Erprobung gekennzeichnet; Stand, Kosten und Testprotokolle stehen im Online-Material und werden dort fortgeschrieben.

Storyboard-Werkstatt (in Erprobung). Ein Notebook führt in sechs Schritten mit drei Kontrollpunkten von einer Themenvorlage oder einem eigenen Thema zu einem Lehrcomic: Ein Starter-Prompt erzeugt im Chat-Interface ein Drehbuch als JSON-Datei, das die Lehrperson freigibt; aus dem Drehbuch entsteht ein Besetzungsbogen für die Figuren, der ebenfalls freigegeben wird; erst dann erzeugt ein Bildmodell alle Panels in einem Serienauftrag mit dem Besetzungsbogen als Referenz, damit die Figuren über die Seiten hinweg dieselben bleiben. Drei Dramaturgien stehen zur Wahl, eine Fallstudie als Geschichte mit Protagonistin und Dilemma, eine Erklärgeschichte und ein Escape Room mit Lösungsblatt; zehn Themenvorlagen decken die Fächer der Workshop-Teilnehmenden ab. Die Kosten liegen bei etwa 0,30 bis 0,40 US-Dollar je Teilnehmerin und Comic. Geprüft ist der vollständige Probelauf mit Platzhaltern und der Aufruf gegen einen nachgebauten Server; nicht geprüft sind der echte Aufruf beim Bildanbieter, die Bildqualität und die Konsistenz der Figuren.

Text zu Folien und Film mit Wächter und Protokollfolie (in Erprobung). Zwei Workflow-Vorlagen für den Baukasten aus Kapitel D.6 machen aus einem eingefügten Text eine Präsentation mit KI-Bildern, die zweite zusätzlich mit einem fünfsekündigen Clip je Folie. Ein Wächter, ein Skript und kein Modell, bricht ab, bevor etwas gesendet wird, wenn der Text eine E-Mail-Adresse, eine mögliche Matrikelnummer oder eine Telefonnummer enthält; eine Plan-Prüfung zählt Folien und Wörter gegen die Regeln des Folien-Skills aus Kapitel D.2; eine Kontrollseite zeigt Plan und geschätzte Kosten, und erst die Freigabe löst die Bildaufträge aus. Die letzte Folie ist ein Protokoll mit allen Prompts, Modellen und Kosten und einem Feld "Geprüft von". Beide Vorlagen wurden lokal gegen nachgebaute Dienste und in einem echten Browser durchgespielt; der erste Lauf mit echten Schlüsseln in der Cloud steht aus. Drei Folien mit Bildern kosten etwa 0,05 US-Dollar, drei Folien mit Clips etwa 1,70 US-Dollar nach Schätzung.

Diagnostisches Feedback je Codename (in Erprobung). Die Codenamen aus Kapitel D.8 sind der Schlüssel zu einer Nutzungsform, bei der die

KI individuelles Feedback zu Tests und Abgaben erzeugt, ohne je einen echten Namen zu sehen: Studierende reichen unter Codename ein, ein Feedbackblatt je Codename entsteht aus Musterlösung, Bewertungsraster und der anonymen Abgabe, und die Zuordnung zur Person liegt allein in der Tabelle der Lehrperson. Ein Beispielmodul aus dem Supply-Chain-Management setzt dieses Muster ein.

Multi-Agenten-Simulationen (in Erprobung). Die Agenten-Designs aus Kapitel C.5.2, mit Mentor, Gegenspieler und Evaluator als getrennten Rollen, lassen sich mit den Werkzeugen dieses Anhangs als Skill-Bündel und Workflow nachbauen, und sie gewinnen einen neuen Prüfstand: Ein aus echten Tutoring-Daten gewonnenes simuliertes Studierendenmodell erlaubt es, Tutor- und Rollenspielsysteme in synthetischen Dialogen zu testen, bevor echte Lernende ihnen begegnen (Perczel et al., 2025), und adaptive Hinweisdosierung lässt sich datengestützt lernen statt manuell verdrahten (Chang et al., 2026). Für die Lehre heißt das, dass die vier Prüfschichten aus Kapitel D.7 künftig teilweise von simulierten Studierenden durchlaufen werden können; ob das die Einigkeit menschlicher Bewertender ersetzt, ist offen.

Online-Material

Alle Übungsblätter dieses Anhangs, die Skill-Dateien `folien-evidenzbasiert` und `statistik-tutor`, die Build-Prompts für eigene Tutoren, das Colab-Notebook zur Simulation, die Workflow-Vorlagen mit ihren Primern und die Notebooks der Storyboard-Werkstatt liegen gesammelt in der Online-Version des Buchs und werden dort fortgeschrieben; die gedruckte Fassung hält den Stand vom Oktober 2026 fest.

Online-Version: https://th-koln-bartnik.github.io/genai4teaching/, Anhang D.

Transparenzhinweis

Dieser Anhang entstand aus den Inputs, Übungen und Primern des Aufbaukurses "Jenseits einfacher Prompts" (hdw nrw, 12. Oktober 2026). Bei der Übertragung in das Buchformat wurde Claude / Cowork zur

Konvertierung, zur Strukturierung nach dem Muster von Anhang C, für Sprach- und Konsistenzchecks sowie zum Abgleich der Zitierschlüssel mit dem Literaturverzeichnis genutzt. Alle Inhalte wurden von Roman Bartnik geprüft, überarbeitet und verantwortet.

Transparenzhinweis zum Gesamtwerk

Bei der Erstellung dieses Buchs wurde generative KI eingesetzt. Das Thema des Buchs verlangt, dass ich das genau benenne.

Das Sprachmodell Claude (Anthropic) wurde in der Arbeitsumgebung Cowork für folgende Aufgaben genutzt: die Strukturanalyse des Online-Skripts vor der Überarbeitung, die Prüfung von Literaturangaben gegen die Originalquellen, Entwürfe für einzelne Einschübe wie Kästen, Lernziele und Kernaussagen, Sprach- und Konsistenzchecks über alle Kapitel sowie die technische Umsetzung des Layouts für Druck und Online-Version. Abbildungen, die mit dem Bildmodell Gemini (Google) erzeugt wurden, sind in der jeweiligen Bildunterschrift als KI-generiert gekennzeichnet. Die interaktiven Lernspiele und Prozessanimationen der Online-Version wurden mit Unterstützung von Sprachmodellen programmiert; wie das geht, beschreibt Kapitel 2.

Verantwortung und Prüfung liegen beim Autor. Jeder Entwurf, den ein Sprachmodell geliefert hat, wurde gelesen, gegen die Quellen geprüft, überarbeitet oder verworfen. Die Argumentation, die Auswahl der Studien und die Empfehlungen sind meine eigenen. Wo ein Sprachmodell eine Quelle vorgeschlagen hat, habe ich die Quelle selbst gelesen, bevor sie ins Literaturverzeichnis kam. Damit folge ich der Stellungnahme des Präsidiums der Deutschen Forschungsgemeinschaft zum Einfluss generativer Modelle auf die Wissenschaften vom September 2023: Der Einsatz solcher Werkzeuge ist zulässig, muss offengelegt werden, entbindet nicht von der Verantwortung für den Inhalt, und ein Sprachmodell kann nicht Autor sein.

Anhang C und Anhang D enthalten jeweils einen eigenen Transparenzabschnitt, weil dort der Anteil der KI-Unterstützung größer war und sich anders zusammensetzt als im Haupttext.

[Optional: Hinweis, ob die Arbeitsnotizen zur Überarbeitung im öffentlichen Repositorium https://github.com/TH-Koln-Bartnik/genai4teaching einsehbar sind.]

Literaturverzeichnis

Acemoglu, D., & Restrepo, P. (2019). Automation and New Tasks: How Technology Displaces and Reinstates Labor. *Journal of Economic Perspectives*, *33*(2), 3–30. https://doi.org/10.1257/jep.33.2.3.

Akimov, A., & Malin, M. (2020). When old becomes new: a case study of oral examination as an online assessment tool. *Assessment & Evaluation in Higher Education*, *45*(8), 1205–1221. https://doi.org/10.1080/02602938.2020.1730301.

Alammar, J. (o. J.). *NeurIPS 2025 Papers*. https://jalammar.github.io/assets/neurips_2025.html.

Allen, S. J., & Edelson, S. A. (2024). Brave New Classroom: Navigating Educational Technology in Management Education. *Journal of Management Education*, *48*(4), 603–609. https://doi.org/10.1177/10525629241243339.

Amazon Web Services (2026). *AWS Academy*. https://aws.amazon.com/training/awsacademy/.

An, Y., Yu, J. H., & James, S. (2025). Investigating the higher education institutions' guidelines and policies regarding the use of generative AI in teaching, learning, research, and administration. *International Journal of Educational Technology in Higher Education*, *22*(1), 10. https://doi.org/10.1186/s41239-025-00507-3.

Anthropic (o. J.). *Meeting scribe* (*prompt library*). https://docs.anthropic.com/claude/page/meeting-scribe.

Anthropic (2025a). *Prompting Best Practices*.

Anthropic (2025b, Dezember). Erste Schritte mit Agent Skills in der API. *Claude Docs*. https://platform.claude.com/docs/de/agents-and-tools/agent-skills/quickstart.

Autor, D. H. (2015). Why are there still so many jobs? The history and future of workplace automation. *Journal of economic perspectives*, *29*(3), 3–30.

Azamy, H. (2025, September). *AI flash debates: Student engagement*. https://hbsp.harvard.edu/inspiring-minds/ai-flash-debates-student-engagement.

Banh, L., Holldack, F., & Strobel, G. (2026). Designing generative

AI-based agents to empower collaborative self-learning in higher education. *Business & Information Systems Engineering*. https://doi.org/10.1007/s12599-026-01012-1.

Baresel, K., Eube, C., Knorr, D., Lutter, L., Nys, J. de, & Röben, M. (2024). *KI-Gebrauch im Studienkontext dokumentieren*. 304839 b. https://doi.org/10.48548/PUBDATA-1476.

Barra, F. L., Costa, A., Rodella, G., Semeraro, F., & Carenzo, L. (2024). Shaping the future of simulator interactions: The role of ChatGPT's Advanced Voice Mode. *Resuscitation*, *205*, 110452. https://doi.org/10.1016/j.resuscitation.2024.110452.

Bender, E. M., Gebru, T., McMillan-Major, A., & Shmitchell, S. (2021). On the dangers of stochastic parrots: Can language models be too big?□.

Bent, D., Handa, K., Durmus, E., Tamkin, A., McCain, M., Ritchie, S., Donegan, R., Martinez, J., & Jones, J. (2025). *Anthropic Education Report: How educators use Claude*. Anthropic.

Berryman, J., & Ziegler, A. (2025). *Prompt engineering for LLMs: the art and science of building large language model-based applications*. O'Reilly Media.

Bien, J., & Mukherjee, G. (2025). Generative AI for Data Science 101: Coding Without Learning to Code. *Journal of Statistics and Data Science Education*, *33*(2), 129–142. https://doi.org/10.1080/26939169.2024.2432397.

Bjork, E. L., & Bjork, R. A. (2011). Making things hard on yourself, but in a good way: Creating desirable difficulties to enhance learning. In M. A. Gernsbacher, R. W. Pew, L. M. Hough, & J. R. Pomerantz (Hrsg.), *Psychology and the real world: Essays illustrating fundamental contributions to society*: (S. 56–64). Worth Publishers.

Bjork, R. A. (1994). Memory and metamemory considerations in the training of human beings. In J. Metcalfe & A. P. Shimamura (Hrsg.), *Metacognition: Knowing about knowing*: (S. 185–205). MIT Press.

Brown, P. C., Roediger, H. L., & McDaniel, M. A. (2014). *Make it stick: The science of successful learning*. The Belknap Press of Harvard University Press.

Brynjolfsson, E., Li, D., & Raymond, L. (2025). Generative AI at work. *The Quarterly Journal of Economics*, qjae044.

Bubeck, S., Chandrasekaran, V., Eldan, R., Gehrke, J., Horvitz, E., Kamar, E., Lee, P., Lee, Y. T., Li, Y., Lundberg, S., Nori, H., Palangi, H., Ribeiro, M. T., & Zhang, Y. (2023). *Sparks of Artificial General Intelligence: Early experiments with GPT-4*. arXiv. https://doi.org/10.48550/arXiv.2303.12712.

Bubeck, S., Coester, C., Eldan, R., Gowers, T., Lee, Y. T., Lupsasca, A.,

Sawhney, M., Scherrer, R., Sellke, M., & Spears, B. K. (2025). *Early science acceleration experiments with GPT-5*.

Caswell, A. (2026, Januar 31). I use the „potato" prompt with ChatGPT every day — here is how it finds the holes in my logic. https://www.tomsguide.com/ai/i-use-the-potato-prompt-with-chatgpt-every-day-heres-how-it-gives-you-better-results.

Chang, P.-C., Hogan, N., Plaat, A., & van der Meer, M. T. (2026). Learning to prompt: Improving student engagement with adaptive LLM-based high-school tutoring. https://arxiv.org/abs/2606.20138.

Chatterji, A. (2025). *The state of enterprise AI: 2025 report* (Research Report). OpenAI.

Chen, J., Liu, Z., Huang, X., Wu, C., Liu, Q., Jiang, G., et al. (2024). When large language models meet personalization: Perspectives of challenges and opportunities. *World Wide Web-internet and Web Information Systems*, *27*(42). https://doi.org/10.1007/s11280-024-01276-1.

Chi, M. T. H., Adams, J., Bogusch, E. B., Bruchok, C., Kang, S., Lancaster, M., Levy, R., Li, N., McEldoon, K. L., Stump, G. S., Wylie, R., Xu, D., & Yaghmourian, D. L. (2018). Translating the ICAP Theory of Cognitive Engagement Into Practice. *Cognitive Science*, *42*(6), 1777–1832. https://doi.org/10/gd5n5p.

Chi, M. T. H., & Wylie, R. (2014). The ICAP framework: Linking cognitive engagement to active learning outcomes. *Educational Psychologist*, *49*(4), 219–243. https://doi.org/10.1080/00461520.2014.965823.

Choi, Y.-S. (2025). Earth science simulations with generative artificial intelligence (GenAI). *Journal of University Teaching and Learning Practice*, *22*(1). https://doi.org/10.53761/nf1yqr46.

Cohen, J. (1960). A Coefficient of Agreement for Nominal Scales. *Educational and Psychological Measurement*, *20*(1), 37–46. https://doi.org/10.1177/001316446002000104.

Corbin, T., Dawson, P., & Liu, D. (2025). Talk is cheap: Why structural assessment changes are needed for a time of GenAI. *Assessment & Evaluation in Higher Education*. https://doi.org/10.1080/02602938.2025.2503964.

Csikszentmihalyi, M. (2008). *Flow: The psychology of optimal experience*. Harper Perennial.

Dakan, R., & Feller, J. (2025). Framework for AI fluency (Version 1.5). *Ringling College of Art and Design LibGuides*. https://ringling.libguides.com/ai/framework.

Dang, B., & et al. (2025). Human-AI collaborative learning in mixed reality:

Examining the cognitive and socio-emotional interactions. *British Journal of Educational Technology*. https://doi.org/10.1111/bjet.13607.

Dell'Acqua, F., Ayoubi, C., Lifshitz-Assaf, H., Sadun, R., Mollick, E. R., Mollick, L., Han, Y., Goldman, J., Nair, H., Taub, S., & Lakhani, K. R. (2025). The cybernetic teammate: A field experiment on generative AI and teamwork. *Organization Science*. https://doi.org/10.1287/orsc.2025.20702.

Dell'Acqua, F., McFowland, E., Mollick, E. R., Lifshitz-Assaf, H., Kellogg, K., Rajendran, S., Krayer, L., Candelon, F., & Lakhani, K. R. (2023). *Navigating the Jagged Technological Frontier: Field Experimental Evidence of the Effects of AI on Knowledge Worker Productivity and Quality*. https://doi.org/10.2139/ssrn.4573321.

Demir, E., Bektaş, T., & Laporte, G. (2014). A review of recent research on green road freight transportation. *European Journal of Operational Research*, *237*(3), 775–793. https://doi.org/10.1016/j.ejor.2013.12.033.

Denny, P., Kumar, V., & Giacaman, N. (2023). Conversing with copilot: Exploring prompt engineering for solving cs1 problems using natural language.

Dihan, Q. A., Nihalani, B. R., Tooley, A. A., & Elhusseiny, A. M. (2025). Eyes on Google's NotebookLM: using generative AI to create ophthalmology podcasts with a single click. *Eye*, *39*(2), 215–216. https://doi.org/10.1038/s41433-024-03481-8.

Dunlosky, J., Rawson, K. A., Marsh, E. J., Nathan, M. J., & Willingham, D. T. (2013). Improving Students' Learning With Effective Learning Techniques: Promising Directions From Cognitive and Educational Psychology. *Psychological science in the public interest : a journal of the American Psychological Society*, *14*(1), 4–58. https://doi.org/10.1177/1529100612453266.

Eikenberg, R. (2025). Browser-Helferlein per KI generieren. *c't Special*, *2*, 94–99.

Elsworth, C., Huang, K., Patterson, D., Schneider, I., Sedivy, R., Goodman, S., Townsend, B., Ranganathan, P., Dean, J., & Vahdat, A. (2025). Measuring the environmental impact of delivering AI at Google Scale. *arXiv preprint arXiv:2508.15734*.

Ericsson, K. A., Krampe, R. T., & Tesch-Römer, C. (1993). The role of deliberate practice in the acquisition of expert performance. *Psychological Review*, *100*(3), 363–406. https://doi.org/10.1037/0033-295X.100.3.363.

Figalová, N., Huestegge, L., & Böckler-Raettig, A. (2026). *Evaluating human and LLM screening workflows in a conceptually complex scoping review: Recall–*

workload trade-offs and run-to-run consistency. https://doi.org/10.48550/arXiv.2608.26885.

Fischer, I., & Dobbins, K. (2024). Is it Worth it? How Paradoxical Tensions of Identity Shape the Readiness of Management Educators to Embrace Transformative Technologies in their Teaching. *Journal of Management Education*, *48*(4), 829–848. https://doi.org/10.1177/10525629231201843.

Freeman, J. (2025). Student generative AI survey 2025. *Higher Education Policy Institute: London, UK*, (HEPI Policy Note 61).

Freeman, S., Eddy, S. L., McDonough, M., Smith, M. K., Okoroafor, N., Jordt, H., & Wenderoth, M. P. (2014). Active learning increases student performance in science, engineering, and mathematics. *Proceedings of the national academy of sciences*, *111*(23), 8410–8415.

Friedman, M., & Friedman, M. (1975). *There's no such thing as a free lunch*. Open Court.

Friedrich, J.-D. (2023, Februar 8). Zur Bedeutung von ChatGPT & der Notwendigkeit eines progressiven Umgangs mit neuen KI-Technologien im Hochschulbereich. Ein Zwischenstand in 6 Thesen. https://hochschulforumdigitalisierung.de/zur-bedeutung-von-chatgpt-der-notwendigkeit-eines-progressiven-umgangs-mit-neuen-ki-technologien-im-hochschulbereich-ein-zwischenstand-in-6-thesen/.

Gieselmann, H. (2024, August 16). Wie Sie Musik live coden mit Sonic Pi unterstützt von Sprachmodellen. *c't Magazin*. https://www.heise.de/ratgeber/Wie-Sie-Musik-live-coden-mit-Sonic-Pi-unterstuetzt-von-Sprachmodellen-9829751.html.

Gmeiner, B. (2025). *Ohne Shortcut zur Leistung: KI-resistente Aufgabenformate im Unterricht. Ein Handbuch für Lehrkräfte der Sekundarstufe*. Self-published.

Gobet, F., Lane, P. C., Croker, S., Cheng, P. C., Jones, G., Oliver, I., & Pine, J. M. (2001). Chunking mechanisms in human learning. *Trends in cognitive sciences*, *5*(6), 236–243.

Goldratt, E. M., & Cox, J. (2014). *The goal: A process of ongoing improvement*. North River Press.

Google (2025). *Strategien für Prompt-Design*. Google.

Goslen, A., Kim, Y. J., Rowe, J., & Lester, J. (2025). LLM-based student plan generation for adaptive scaffolding in game-based learning environments. *International Journal of Artificial Intelligence in Education*, *35*(2), 533–558. https://doi.org/10.1007/s40593-024-00421-1.

Gottweis, J., Weng, W.-H., Daryin, A., Tu, T., Palepu, A., Sirkovic, P., Myaskovsky, A., Weissenberger, F., Rong, K., Tanno, R., Saab, K.,

Popovici, D., Blum, J., Zhang, F., Chou, K., Hassidim, A., Gokturk, B., Vahdat, A., Kohli, P., ... Natarajan, V. (2025). *Towards an AI co-scientist*. arXiv. https://doi.org/10.48550/arXiv.2502.18864.

Grootendorst, M. (2025, Februar 3). *A Visual Guide to Reasoning LLMs*. https://newsletter.maartengrootendorst.com/p/a-visual-guide-to-reasoning-llms.

Hake, R. R. (1998). Interactive-engagement versus traditional methods: A six-thousand-student survey of mechanics test data for introductory physics courses. *American Journal of Physics*, *66*(1), 64–74. https://doi.org/10.1119/1.18809.

Handa, K., Bent, D., Tamkin, A., McCain, M., Durmus, E., Stern, M., Schiraldi, M., Huang, S., Ritchie, S., Syverud, S., Jagadish, K., Vo, M., Bell, M., & Ganguli, D. (2025). *Anthropic Education Report: How university students use Claude*. Anthropic.

Hanover Research (2024). *Assessment and generative artificial intelligence in higher education* (Report). Hanover Research.

Hassany, M., Brusilovsky, P., Ke, J., Akhuseyinoglu, K., & Narayanan, A. B. L. (2024). *Human-AI Co-Creation of Worked Examples for Programming Classes*. arXiv. https://doi.org/10.48550/ARXIV.2402.16235.

Hattie, J. (2023). *Visible learning, the sequel: a synthesis of over 2,100 meta-analyses relating to achievement*. Routledge, Taylor & Francis Group. https://doi.org/10.4324/9781003380542.

Hayashi, Y., Shimojo, S., & Kawamura, T. (2025). Scripted interventions versus reciprocal teaching in collaborative learning: A comparison of pedagogical and teachable agents using a cognitive architecture. *Learning and Instruction*, *96*, 102057. https://doi.org/10.1016/j.learninstruc.2024.102057.

Heetkamp, S. J. (2023, Dezember 13). Die VR-Revolution im Justizwesen. https://www.deutscheranwaltspiegel.de/e-justice/digitalisierung/die-vr-revolution-im-justizwesen-151520/.

Heidt, A. (2025). ChatGPT for students: learners find creative new uses for chatbots. *Nature*, *639*(8053), 265–266. https://doi.org/10.1038/d41586-025-00621-2.

Henderson, C., & Dancy, M. H. (2007). Barriers to the use of research-based instructional strategies: The influence of both individual and situational characteristics. *Physical Review Special Topics—Physics Education Research*, *3*(2), 020102.

Hobbick, S. (2025). *Simulated telephone triage calls*. https://aipedagogy.org/assignment/simulated-telephone-triage-calls/.

Huffman, P., & Hutson, J. (2024). Enhancing History Education with Google NotebookLM: Case Study of Mary Easton Sibley's Diary for Multimedia Content and Podcast Creation. *ISRG Journal of Arts, Humanities and Social Sciences*, *2*(5).

Hüsch, M., Horstmann, N., & Breiter, A. (2025). *Künstliche Intelligenz im Studium: Die Sicht von Studierenden im Wintersemester 2024/25*. CHE Centrum für Hochschulentwicklung.

Huyen, C. (2025). *AI engineering: building applications with foundation models*. O'Reilly.

InvertedStone (2025, August 30). *OpenAI API Pricing Calculator*. https://invertedstone.com/calculators/openai-pricing.

Ippolito, J. (2025). *AI sandwich*. https://aipedagogy.org/assignment/ai-sandwich/.

Johnston, D., Holtz, D., Richmond, A. M., Ong, C., Tambe, P., & Chatterji, A. (2026). *The shift to agentic AI: Evidence from Codex*. https://doi.org/10.48550/arXiv.2606.26959.

Jones, C. R., & Bergen, B. K. (2025). *Large Language Models Pass the Turing Test*. arXiv. https://doi.org/10.48550/arXiv.2503.23674.

Jurafsky, D., & Martin, J. H. (2025). *Speech and language processing: An introduction to natural language processing, computational linguistics, and speech recognition with language models*.

Jurran, N. (2025). ChatGPT als sprechtrainer. *c't Special*, *2*, 100–103.

Kazu, İ. Y., & Kuvvetli, M. (2025). Digital language learning with Duolingo: assessing its impact on listening, speaking, reading, and writing skills. *Journal of Computers in Education*. https://doi.org/10.1007/s40692-025-00355-0.

Kearney, S. (2019). Transforming the first-year experience through self and peer assessment. *Journal of University Teaching and Learning Practice*, *16*(5), 1–17.

Kentz, M. (2025). *Interview a fictional character*. https://aipedagogy.org/assignment/interview-a-fictional-character/.

Kestin, G., Miller, K., Klales, A., Milbourne, T., & Ponti, G. (2025). AI tutoring outperforms in-class active learning: an RCT introducing a novel research-based design in an authentic educational setting. *Scientific Reports*, *15*(1), 17458. https://doi.org/10.1038/s41598-025-97652-6.

Kindenberg, B. (2025). The role of AI in historical simulation design: A TPACK perspective on a French Revolution simulation design experience. *Education Sciences*, *15*(2), 192. https://doi.org/10.3390/educsci15020192.

Klein, D. A. (2023, Februar 17). „Die Hausarbeit ist tot, es lebe die

Hausarbeit!“ - Entwicklungsorientierung, wissenschaftliches Arbeiten und KI gemeinsam denken. https://hochschulforumdigitalisierung.de/die-hausarbeit-ist-tot-es-lebe-die-hausarbeit-entwicklungsorientierung-wissenschaftliches-arbeiten-und-ki-gemeinsam-denken/.

Korinek, A. (2024). *Generative AI for economic research: LLMs learn to collaborate and reason (December 2024 update)* (NBER Working Paper; Nr. w33198). National Bureau of Economic Research. https://doi.org/10.3386/w33198.

Kotha, A., Lee, J., Zakariasson, E., et al. (2025). *GPT-5 Prompting Guide*. OpenAI.

Kross, E., & Ayduk, O. (2017). Self-distancing: Theory, research, and current directions. In *Advances in Experimental Social Psychology*: (Bd. 55, 81–136). Academic Press. https://doi.org/10.1016/bs.aesp.2016.10.002.

Kwa, T., West, B., Becker, J., Deng, A., Garcia, K., Hasin, M., Jawhar, S., Kinniment, M., Rush, N., Arx, S. V., Bloom, R., Broadley, T., Du, H., Goodrich, B., Jurkovic, N., Miles, L. H., Nix, S., Lin, T., Parikh, N., … Chan, L. (2025). *Measuring AI Ability to Complete Long Tasks*. arXiv. https://doi.org/10.48550/arXiv.2503.14499.

Landfair, A. (2025). *Playtesting your ChatGPT prompt*. https://aipedagogy.org/assignment/playtesting-your-chatgpt-prompt/.

Latif, E., Liu, V., & Zhai, X. (2026). A systematic review of intelligent and robot tutoring systems: evolution, pedagogical design, and AI-driven classification. *Smart Learning Environments*.

Lee, H.-P. H., Sarkar, A., Tankelevitch, L., Drosos, I., Rintel, S., Banks, R., & Wilson, N. (2025). The Impact of Generative AI on Critical Thinking: Self-Reported Reductions in Cognitive Effort and Confidence Effects From a Survey of Knowledge Workers. https://doi.org/10.1145/3706598.3713778.

Lee, Suhyeon, Baek, J., Park, J., & Shin, D. (2026). *LLM pedagogical behavior in AI tutoring interactions*. https://doi.org/10.48550/arXiv.2608.22993.

Lee, Sangmin, Choe, H., Zou, D., & Jeon, J. (2025). Generative AI (GenAI) in the language classroom: A systematic review. *Interactive Learning Environments*, 1–25. https://doi.org/10.1080/10494820.2025.2498537.

Lehre virtuell - Universität Frankfurt (2023, Oktober 6). Einsatz von generativer KI im Studium – Handlungsempfehlungen für Studierende – Lehre virtuell. https://lehre-virtuell.uni-frankfurt.de/knowhow/einsatz-von-generativer-ki-im-studium-handlungsempfehlungen-fuer-studierende/.

Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler,

H., Lewis, M., Yih, W., Rocktäschel, T., Riedel, S., & Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. https://doi.org/10.48550/arXiv.2005.11401.

Liang, J. T., Yang, C., & Myers, B. A. (2024). A large-scale survey on the usability of ai programming assistants: Successes and challenges.

Liang, W., Zhang, Y., Codreanu, M., Wang, J., Cao, H., & Zou, J. (2025). The Widespread Adoption of Large Language Model-Assisted Writing Across Society. *arXiv preprint arXiv:2502.09747*.

Lim, J., Lee, U., Koh, J., Jeong, Y., Lee, Y., Byun, G., Jung, H., Jang, Y., Lee, S., & Moon, J. (2025). Development and implementation of a generative artificial intelligence-enhanced simulation to enhance problem-solving skills for pre-service teachers. *Computers & Education*, *232*, 105306. https://doi.org/10.1016/j.compedu.2025.105306.

Lindsey, J., Gurnee, W., Ameisen, E., Chen, B., Pearce, A., Turner, N. L., Citro, C., Abrahams, D., Carter, S., Hosmer, B., Marcus, J., Sklar, M., Templeton, A., Bricken, T., McDougall, C., Cunningham, H., Henighan, T., Jermyn, A., Jones, A., ... Batson, J. (2025). On the biology of a large language model. *Transformer Circuits Thread*.

Little, J. D. C. (1961). A proof for the queuing formula: L = λW. *Operations Research*, *9*(3), 383–387. https://doi.org/10.1287/opre.9.3.383.

Love, R., Law, E., Cohen, P. R., & Kulić, D. (2025). Teaching a Conversational Agent using Natural Language: Effect on Learning and Engagement. *International Journal of Artificial Intelligence in Education*. https://doi.org/10.1007/s40593-025-00461-1.

Lovely, G. (2025). AI could soon tackle projects that take humans weeks. *Nature*. https://doi.org/10.1038/d41586-025-00831-8.

Lyu, B., Li, C., Li, H., Oh, H., Song, Y., Zhu, W., & Xing, W. (2025). The Role of Teachable Agents' Personality Traits on Student-AI Interactions and Math Learning. *Computers & Education*, 105314. https://doi.org/10.1016/j.compedu.2025.105314.

Ma, T. (2025). Systematically visualizing ChatGPT used in higher education: Publication trend, disciplinary domains, research themes, adoption and acceptance. *Computers and Education: Artificial Intelligence*, *8*, 100336. https://doi.org/10.1016/j.caeai.2024.100336.

Marangunić, N., & Granić, A. (2015). Technology acceptance model: a literature review from 1986 to 2013. *Universal Access in the Information Society*, *14*(1), 81–95. https://doi.org/10.1007/s10209-014-0348-1.

Mayer, R. E., & Fiorella, L. (2014). Principles for Reducing Extraneous Processing in Multimedia Learning: Coherence, Signaling, Redundancy,

Spatial Contiguity, and Temporal Contiguity Principles. In R. E. Mayer (Hrsg.), *The Cambridge handbook of multimedia learning*: (S. 279–315). Cambridge University Press. https://doi.org/10.1017/cbo9781139547369.015.

McAfee, A. (2024). *Generally Faster: The Economic Impact of Generative AI* (Davos Report). Google.

Meehan, S. (2025). *Generative AI and stasis theory*. https://aipedagogy.org/assignment/generative-ai-and-stasis-theory/.

Meincke, L., Mollick, E. R., Mollick, L., & Shapiro, D. (2025a). *Prompting Science Report 2: The Decreasing Value of Chain of Thought in Prompting*. arXiv. https://doi.org/10.48550/arXiv.2506.07142.

Meincke, L., Mollick, E. R., & Terwiesch, C. (2024). *Prompting Diverse Ideas: Increasing AI Idea Variance*. https://papers.ssrn.com/abstract=4708466.

Meincke, L., Mollick, E., Mollick, L., & Shapiro, D. (2025b). *Prompting Science Report 1: Prompt Engineering is Complicated and Contingent*. arXiv. https://doi.org/10.48550/arXiv.2503.04818.

Meincke, L., Mollick, E., Mollick, L., & Shapiro, D. (2025c). *Prompting Science Report 3: I'll pay you or I'll kill you -- but will you care?* arXiv. https://doi.org/10.48550/arXiv.2508.00614.

MIT Teaching + Learning Lab (2023). *Rethinking Your Problem Sets in the World of Generative AI | Teaching + Learning Lab*. https://tll.mit.edu/rethinking-your-problem-sets-in-the-world-of-generative-ai/.

Mollick, E. (2024). *Co-intelligence: living and working with AI*. Portfolio/Penguin.

Mollick, E. (2026, Februar 18). A Guide to Which AI to Use in the Agentic Era. https://www.oneusefulthing.org/p/a-guide-to-which-ai-to-use-in-the?post_id=188100833&r=2248w9.

Mollick, E. R. (2023, Juli 1). The Homework Apocalypse. https://www.oneusefulthing.org/p/the-homework-apocalypse.

Mollick, E. R. (2025a, Januar 26). A new generation of AIs: Claude 3.7 and Grok 3. https://www.oneusefulthing.org/p/a-new-generation-of-ais-claude-37.

Mollick, E. R. (2025b, August 7). GPT-5: It Just Does Stuff. https://www.oneusefulthing.org/p/gpt-5-it-just-does-stuff.

Mollick, E. R. (2025c, Dezember 20). The Shape of AI: Jaggedness, Bottlenecks and Salients. https://www.oneusefulthing.org/p/the-shape-of-ai-jaggedness-bottlenecks.

Mollick, E. R., & Mollick, L. (2023a). *Using AI to Implement Effective Teaching Strategies in Classrooms: Five Strategies, Including Prompts* (SSRN Scholarly Paper; Nr. 4391243).

Mollick, E. R., & Mollick, L. (2023b). *Assigning AI: Seven Approaches for Students, with Prompts*. arXiv. https://doi.org/10.48550/arXiv.2306.10052.

Mollick, E. R., & Mollick, L. (2024). *Instructors as Innovators: a Future-focused Approach to New AI Learning Opportunities, With Prompts*. https://doi.org/10.2139/ssrn.4802463.

Mollick, E. R., & Mollick, L. (n.d.n.d.). *Instructor prompts*. https://www.moreusefulthings.com/instructor-prompts.

Mollick, E. R., Mollick, L., Bach, N., Ciccarelli, L. J., Przystanski, B., & Ravipinto, D. (2024). AI agents and education: Simulated practice at scale. *arXiv preprint arXiv:2407.12796*.

Mollick, L., & Mollick, E. R. (2024). *Student exercises*. https://www.moreusefulthings.com/student-exercises.

Monash University (2025). *Choosing assessment tasks*.

Monib, W. K., Qazi, A., & Mahmud, M. M. (2025). Exploring learners' experiences and perceptions of ChatGPT as a learning tool in higher education. *Education and Information Technologies*, *30*(1), 917–939. https://doi.org/10.1007/s10639-024-13065-4.

Moon, J., Lee, U., Koh, J., Jeong, Y., Lee, Y., Byun, G., & Lim, J. (2025). Generative Artificial Intelligence in Educational Game Design: Nuanced Challenges, Design Implications, and Future Research. *Technology, Knowledge and Learning*, *30*(1), 447–459. https://doi.org/10.1007/s10758-024-09756-z.

More Useful Things (o. J.). *Student exercises*. https://www.moreusefulthings.com/student-exercises.

Morgan, G. (2024, Juli 11). What Students Want When It Comes To AI - The Digital Education Council Global AI Student Survey 2024. *On EdTech Newsletter*.

Mörth, M., Paridon, H., & Sonntag, U. (2021). Kognitionswissenschaftliche Erkenntnisse und ihre Folgerungen für evidenzbasierte Hochschullehre: die hochschullehre 05/2021. *die hochschullehre*, *7*(1), 38–48.

Mulder, R., Baik, C., & Ryan, T. (2023). *Rethinking assessment in response to AI* (Guide). Melbourne Centre for the Study of Higher Education.

Murre, J. M., & Dros, J. (2015). Replication and analysis of Ebbinghaus' forgetting curve. *PloS one*, *10*(7), e0120644.

Naddaf, M. (2025). How are researchers using AI? Survey reveals pros and cons for science. *Nature*. https://doi.org/10.1038/d41586-025-00343-5.

Nepal, S. K., Soh, S., Vinoya, N., Park, S., Roshanaei, M., & Harari, G. (2026). *Faithful where it can be checked: Auditing a reflection agent against its system*

prompt in a randomized trial. https://doi.org/10.48550/arXiv.2609.19635.

Newman, S. (2025). *Correct a bad essay*. https://aipedagogy.org/assignment/correct-a-bad-essay/.

Nguyen, A., Gul, F., Dang, B., Huynh, L., & Tuunanen, T. (2025). Designing embodied generative artificial intelligence in mixed reality for active learning in higher education. *Innovations in Education and Teaching International*. https://doi.org/10.1080/14703297.2025.2499177.

Nguyen, H. A. (2024). Harnessing AI-based tools for enhancing English speaking proficiency: Impacts, challenges, and long-term engagement. *International Journal of AI in Language Education*, *1*(2), 18–29. https://doi.org/10.54855/ijaile.24122.

Ní Bheoláin, R., Lowney, R., & O'Riordan, F. (2020). *Students as Partners in Assessment (SaPiA): A Literature Scoping Review*. https://doi.org/10.5281/zenodo.4270579.

Nickow, A., Oreopoulos, P., & Quan, V. (2020). *The Impressive Effects of Tutoring on PreK-12 Learning: A Systematic Review and Meta-Analysis of the Experimental Evidence* (Nr. 27476). National Bureau of Economic Research. https://doi.org/10.3386/w27476.

Nizamudeen, F., Gatti, L., Bouali, N., & Ahmed, F. (2024). Investigating the Impact of Code Generation Tools (ChatGPT & Github CoPilot) on Programming Education. https://doi.org/10.5220/0012628000003693.

Nofal, A. B., Ali, H., Hadi, M., Ahmad, A., Qayyum, A., Johri, A., Al-Fuqaha, A., & Qadir, J. (2025). AI-enhanced interview simulation in the metaverse: Transforming professional skills training through VR and generative conversational AI. *Computers and Education: Artificial Intelligence*, *8*, 100347. https://doi.org/10.1016/j.caeai.2024.100347.

O'Donnell, J., & Crownhart, C. (2025, Mai 20). We did the math on AI's energy footprint. Here's the story you haven't heard. *MIT Technology Review*.

Ogunleye, B., Zakariyyah, K. I., Ajao, O., Olayinka, O., & Sharma, H. (2024). A Systematic Review of Generative AI for Teaching and Learning Practice. *Education Sciences*, *14*(6), 636. https://doi.org/10.3390/educsci14060636.

OpenAI (2024). *Learning to reason with LLMs*.

OpenAI (2025a). *openai/skills: Skills Catalog for Codex*. https://github.com/openai/skills.

OpenAI (2025b). *Introducing GPT-5*.

Österreichischer Universitätsprofessor/innenverband (2018). *Österreich - Arbeitszeitverteilung von Professoren 2017*.

Ou, A. W., Stöhr, C., & Malmström, H. (2024). Academic communication

with AI-powered language tools in higher education: From a post-humanist perspective. *System*, *121*, 103225. https://doi.org/10.1016/j.system.2024.103225.

Parasuraman, R., Sheridan, T. B., & Wickens, C. D. (2000). A model for types and levels of human interaction with automation. *IEEE Transactions on Systems, Man, and Cybernetics - Part A: Systems and Humans*, *30*(3), 286–297. https://doi.org/10.1109/3468.844354.

Pedersen, D. (2025). *DuPont analysis of coca-cola*. https://aipedagogy.org/assignment/dupont-analysis-of-coca-cola/.

Peng, S., Kalliamvakou, E., Cihon, P., & Demirer, M. (2023). *The Impact of AI on Developer Productivity: Evidence from GitHub Copilot*. arXiv. https://doi.org/10.48550/arXiv.2302.06590.

Perczel, J., Chow, J., & Demszky, D. (2025). TeachLM: Post-training LLMs for education using authentic learning data. https://doi.org/10.48550/arXiv.2510.05087.

Porter, L., & Zingaro, D. (2024). *Learn AI-Assisted Python Programming: With Github Copilot and ChatGPT*. Simon and Schuster.

Project Management Institute (2024). *Talking to AI: Prompt Engineering for Project Managers Workbook* (manual). Project Management Institute.

Puryear, B., & Sprint, G. (2022). Github copilot in the classroom: learning to code with AI assistance. *Journal of Computing Sciences in Colleges*, *38*(1), 37–47.

Reason, J. (2000). Human error: models and management. *BMJ*, *320*(7237), 768–770. https://doi.org/10.1136/bmj.320.7237.768.

Ritchie, H. (2024, September 19). *What's the impact of artificial intelligence on energy demand?* https://www.sustainabilitybynumbers.com/p/ai-energy-demand.

Roediger, H. L., & Karpicke, J. D. (2006). Test-enhanced learning: taking memory tests improves long-term retention. *Psychological science*, *17*(3), 249–255. https://doi.org/10.1111/j.1467-9280.2006.01693.x.

Roediger, H. L., & Pyc, M. A. (2012). Inexpensive techniques to improve education: Applying cognitive psychology to enhance educational practice. *Journal of Applied Research in Memory and Cognition*, *1*(4), 242–248. https://doi.org/10.1016/j.jarmac.2012.09.002.

Rogers, R. (2026, Januar 15). Anthropic's Claude Cowork Is an AI Agent That Actually Works. *Wired*.

Rowland, D. R. (2023). Two frameworks to guide discussions around levels of acceptable use of generative AI in student academic research and writing. *Journal of Academic Language and Learning*, *17*(1), T31–T69.

Russell, S. J., & Norvig, P. (2021). *Artificial intelligence: a modern approach*. Pearson.

Säuberli, A., & Clematide, S. (2024). Automatic generation and evaluation of reading comprehension test items with large language models. https://doi.org/10.48550/arXiv.2404.07720.

Scarlatos, A., Liu, N., Lee, J., Baraniuk, R., & Lan, A. (2025). Training LLM-based tutors to improve student learning outcomes in dialogues. *arXiv preprint*.

Schmidt, B., & Tippelt, R. (2005). Besser Lehren-Neues von der Hochschuldidaktik?

Schomburg, H., Flöther, C., & Wolf, V. (2012). *Wandel von Lehre und Studium an deutschen Hochschulen–Erfahrungen und Sichtweisen der Lehrenden*.

Schwarcz, D., Manning, S., Barry, P. J., Cleveland, D. R., Prescott, J. J., & Rich, B. (2025). *AI-Powered Lawyering: AI Reasoning Models, Retrieval Augmented Generation, and the Future of Legal Practice*. https://doi.org/10.2139/ssrn.5162111.

Schwarze, M. (2025, Juli 16). KI-Assistent Witsy kann kostenlos das ChatGPT-Monatsabo ersetzen. *Frankfurter Allgemeine Zeitung* (*FAZ*).

Shadle, S. E., Marker, A., & Earl, B. (2017). Faculty drivers and barriers: laying the groundwork for undergraduate STEM education reform in academic departments. *International Journal of STEM Education*, *4*(1), 8. https://doi.org/10.1186/s40594-017-0062-7.

Shaer, O., Cooper, A., Mokryn, O., Kun, A. L., & Ben Shoshan, H. (2024). AI-augmented brainwriting: Investigating the use of llms in group ideation. https://doi.org/10.48550/arXiv.2402.14978.

Snell, C., Lee, J., Xu, K., & Kumar, A. (2024). Scaling llm test-time compute optimally can be more effective than scaling model parameters. *arXiv preprint arXiv:2408.03314*.

Spencer, T., & Singh, S. (2024, Oktober 18). What the data centre and AI boom could mean for the energy sector – Analysis. https://www.iea.org/commentaries/what-the-data-centre-and-ai-boom-could-mean-for-the-energy-sector.

Spencer, T., & Singh, S. (2025). *Energy and AI* (World Energy Outlook Special Report). International Energy Agency.

Stains, M., Harshman, J., Barker, M. K., Chasteen, S. V., Cole, R., DeChenne-Peters, S. E., Eagan, M. K., Esson, J. M., Knight, J. K., Laski, F. A., Levis-Fitzgerald, M., Lee, C. J., Lo, S. M., McDonnell, L. M., McKay, T. A., Michelotti, N., Musgrove, A., Palmer, M. S., Plank, K. M., ... Young, A. M. (2018). Anatomy of STEM teaching in North American universities.

Science, *359*(6383), 1468–1470. https://doi.org/10.1126/science.aap8892.

Stanford, D. (2025). *AI misinformation campaign*. https://aipedagogy.org/assignment/ai-misinformation-campaign/.

Steinberger, P. (2025, Oktober 14). *Just Talk To It - the no-bs Way of Agentic Engineering | Peter Steinberger*. https://steipete.me/posts/just-talk-to-it.

Sweller, J. (2011). Cognitive load theory. In *Psychology of learning and motivation*: (Bd. 55, 37–76). Elsevier.

Tay, A. (2024a, Oktober 20). *Classifying the ways LLMs summarise - Individual vs Aggregate vs Visual summaries*. https://aarontay.substack.com/p/classifying-the-ways-llms-summarise.

Tay, A. (2024b, Dezember 1). *MCP servers and academic search - The future of search?* https://aarontay.substack.com/p/mcp-servers-and-academic-search-the.

Tay, A. (2025, Januar 19). *How agentic are academic deep research tools? Testing Perplexity, Elicit, Consensus and Academic GPTs*. https://aarontay.substack.com/p/how-agentic-are-academic-deep-research.

Taylor, S. (2025). *AI, the future, and you*. https://aipedagogy.org/assignment/ai-the-future-and-you/.

Teo, V., Jain, R., Gerstenberg, T., & Kleiman-Weiner, M. (2026). *AI assistants overassist*. https://doi.org/10.48550/arXiv.2607.21306.

Tobor, J. (2024). *Leitlinien zum Umgang mit generativer KI*. Hochschulforum Digitalisierung.

Tobor, J. (2025). *Recap: KI-leitlinien als beispiel für soziotechnische aushandlungsprozesse*.

Tutton, M., & Cohen, D. (2025). Reconceptualizing the Role of the University Language Teacher in Light of Generative AI. *Education Sciences*, *15*(1), 56. https://doi.org/10.3390/educsci15010056.

Vallverdú, J., Rzepka, R., & Sans Pinillos, A. (2025). Editorial: Prompts: the double-edged sword using AI. *Frontiers in Artificial Intelligence*, *8*. https://doi.org/10.3389/frai.2025.1756343.

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. *Advances in neural information processing systems*, *30*.

Vega, J., Rodriguez, M., Check, E., Moran, H., & Loo, L. (2025). Duolingo evolution: From automation to artificial intelligence. https://doi.org/10.1007/978-3-031-88854-0_5.

Vellum (2025, August). *LLM Leaderboard*. https://www.vellum.ai/llm-leaderboard.

Walsh, J. D. (2025). Everyone is cheating their way through college: ChatGPT has unraveled the entire academic project. *New York Magazine*.

Wang, S., Xu, T., Li, H., Zhang, C., Liang, J., Tang, J., Yu, P. S., & Wen, Q. (2024). Large language models for education: A survey and outlook. *arXiv preprint arXiv:2403.18105*.

Wang, W.-S., Lin, C.-J., Lee, H.-Y., Huang, Y.-M., & Wu, T.-T. (2025). Enhancing self-regulated learning and higher-order thinking skills in virtual reality: The impact of ChatGPT-integrated feedback aids. *Education and Information Technologies*. https://doi.org/10.1007/s10639-025-13557-x.

Wannemacher, K., Bosse, E., Lübcke, M., & Kaemena, A. (2025). *Wie KI studium und lehre verändert. Anwendungsfelder, use-cases und gelingensbedingungen* (Arbeitspapier Nr. 87). Hochschulforum Digitalisierung.

Ward, M., O'Riordan, F., Logan-Fleming, D., Cooke, D., Concannon-Gibney, T., Efthymiou, M., & Watkins, N. (2024). Interactive oral assessment case studies: An innovative, academically rigorous, authentic assessment approach. *Innovations in Education and Teaching International*, *61*(5), 930–947. https://doi.org/10.1080/14703297.2023.2251967.

Wecker, C. (2012). Slide presentations as speech suppressors: When and why learners miss oral information. *Computers & Education*, *59*(2), 260–273. https://doi.org/10.1016/j.compedu.2012.01.013.

Welsh, K. (2025). *Rehearsal to a real-life interview*. https://aipedagogy.org/assignment/rehearsal-to-real-life-interview/.

White, J., Fu, Q., Hays, S., Sandborn, M., Olea, C., Gilbert, H., Elnashar, A., Spencer-Smith, J., & Schmidt, D. C. (2023). *A prompt pattern catalog to enhance prompt engineering with ChatGPT*. arXiv. https://doi.org/10.48550/arXiv.2302.11382.

Wilhelm, L. T., Ding, X., Knutsen, K. M., Carik, B., & Rho, E. H. (2025). How managers perceive AI-assisted conversational training for workplace communication. https://doi.org/10.48550/arXiv.2505.14452.

Willemain, T. R. (1994). Insights on modeling from a dozen experts. *Operations Research*, *42*(2), 213–222.

Willemain, T. R. (1995). Model Formulation: What Experts Think About and When. *Operations Research*, *43*(6), 916–932. https://doi.org/10.1287/opre.43.6.916.

Willingham, D. T. (2021). *Why don't students like school?: A cognitive scientist answers questions about how the mind works and what it means for the classroom*. Jossey-Bass.

Willison, S. (2025a, Oktober 5). Embracing the parallel coding agent lifestyle. *Simon Willison's Weblog*. https://simonwillison.net/2025/Oct/5/parallel-

coding-agents/.

Willison, S. (2025b, November 20). Nano Banana Pro aka gemini-3-pro-image-preview is the best available image generation model. *Simon Willison's Weblog*. https://simonwillison.net/2025/Nov/20/nano-banana-pro/.

Wilson, N., & Tingley, D. (n.d.n.d.). *System prompt library*. https://github.com/ncwilson78/System-Prompt-Library.

Wolfram, S. (2023). *What is ChatGPT doing ... and why does it work?* Wolfram Media.

Wu, R., & Yu, Z. (2024). Do AI chatbots improve students learning outcomes? Evidence from a meta-analysis. *British Journal of Educational Technology*, *55*(1), 10–33. https://doi.org/10.1111/bjet.13334.

Wu, Y., Jia, F., Zhang, S., Li, H., Zhu, E., Wang, Y., Lee, Y. T., Peng, R., Wu, Q., & Wang, C. (2023). *MathChat: Converse to Tackle Challenging Math Problems with LLM Agents*. arXiv. https://doi.org/10.48550/ARXIV.2306.01337.

You, J. (2025, Februar 7). How much energy does ChatGPT use? *Epoch AI*. https://epoch.ai/gradient-updates/how-much-energy-does-chatgpt-use.

Yu, M., Liu, Z., Long, T., Li, D., Deng, L., & Kong, X. (2025). Exploring cognitive presence patterns in GenAI-integrated six-hat thinking technique scaffolded discussion: An epistemic network analysis. *International Journal of Educational Technology in Higher Education*, *22*(1), 48. https://doi.org/10.1186/s41239-025-00545-x.

Yuen, N. (2025). *Questioning the bot: Socratic chats with AI*. https://aipedagogy.org/assignment/questioning-the-bot-socratic-chats-with-ai-2/.

Yusuf, H., Money, A., & Daylamani-Zad, D. (2026). Exploring student anxiety and experience in performance-based assessments using AIvaluate: An LLM-augmented emotionally intelligent pedagogical AI conversational agent. *Educational Technology Research and Development*. https://doi.org/10.1007/s11423-026-10634-x.

Zhang, Y.-F., Li, H., Song, D., Sun, L., Xu, T., & Wen, Q. (2025). *From Correctness to Comprehension: AI Agents for Personalized Error Diagnosis in Education*. arXiv. https://doi.org/10.48550/ARXIV.2502.13789.